

Ein agrarwirtschaftliches KI-Ökosystem für die Agrar- und Ernährungswirtschaft

Stephan Epp

18. März 2026

Inhaltsverzeichnis

1	Einleitung und Motivation	3
1.1	Ausgangssituation	3
1.2	Zielsetzung	3
1.3	Beitrag dieser Arbeit	4
2	Grundlagen und verwandte Arbeiten	4
2.1	Qualitätsparameter der Kartoffelverarbeitung	4
2.2	Maschinelles Lernen für Qualitätsklassifikation	4
2.3	Optimierung in der Lebensmittellogistik	5
3	Formales Modell des Qualitätsklassifikators	5
3.1	Mathematische Formulierung	5
3.2	Architektur des KI-Klassifikators	5
3.3	Theoretische Garantien	5
4	Planungs- und Steuerungssystem: MILP-Formulierung	6
4.1	Problemformulierung	6
4.2	Lösbarkeit und Optimalität	8
5	Systemarchitektur und AGRI-GAIA Plattformintegration	9
5.1	Gesamtarchitektur	9
5.2	Federated Learning auf der AGRI-GAIA Plattform	9
6	Experimentelle Evaluation	9
6.1	Datenbasis und experimentelles Setup	9
6.2	Klassifikationsergebnisse	10
6.3	Materialfluss-Optimierung	11
6.4	Wirtschaftlichkeitsanalyse	11
7	Diskussion	11
7.1	Interpretation der Ergebnisse	11
7.2	Grenzen des Ansatzes	12

8	Zusammenfassung	12
8.1	Ausblick	13
8.1.1	Lebensmittel- und Agroverarbeitungsindustrie	14
8.1.2	Nicht-Lebensmittelbezogene Industrien	16
8.1.3	Wissenschaft und Forschung	17
8.1.4	Wirtschaft, Handel und Finanzsektor	18
8.1.5	Logistik, Transport und Supply-Chain-Management	19
8.1.6	Umwelt, Nachhaltigkeit und Kreislaufwirtschaft	20
8.1.7	Politik, Regulierung und Standardisierung	20
8.1.8	Gesellschaft, Globale Ernährungssicherheit und Entwicklungszusammenarbeit	21
8.1.9	Technologische Querschnittsthemen und Zukunftstrends	22
A	Ergänzende Beweise und Ableitungen	23
A.1	Beweis der Lipschitz-Stetigkeit der Softmax-Funktion	23
A.2	MILP-Relaxation und LP-Bound	23
B	Pseudocode: MILP-Solver-Wrapper	24

1 Einleitung und Motivation

1.1 Ausgangssituation

Die vorliegende Arbeit präsentiert das wissenschaftliche Fundament und die experimentellen Ergebnisse der Arbeitspakete AP5.3 und AP5.4 des AGRI-GAIA Verbundvorhabens. Im Mittelpunkt steht die Entwicklung eines KI-gestützten Klassifikationssystems zur Früherkennung von Kartoffelqualitätsparametern entlang der gesamten Wertschöpfungskette von der Lagerung beim Landwirt bis zur Anlieferung an das Verarbeitungsunternehmen Wernsing Feinkost GmbH sowie eines darauf aufbauenden Planungs- und Steuerungssystems zur Optimierung des Materialflusses. Wir formalisieren das Rohstoffbeschaffungsproblem als gemischt-ganzzahliges lineares Optimierungsprogramm (MILP), beweisen dessen Lösbarkeit unter praxisrelevanten Annahmen und demonstrieren anhand umfangreicher empirischer Daten, dass der trainierte KI-Klassifikator eine Qualitätszuordnungsgenauigkeit von $\geq 92\%$ ($AUC = 0.964$) erreicht. Das integrierte Planungssystem reduziert Rohstoffausschuss um $62,7\%$, Energieverbrauch um $16,9\%$ und Rüstzeiten um $48,6\%$. Der vollständige Softwarestack wird auf der AGRI-GAIA Plattform (Gaia-X) trainiert und kontinuierlich verbessert.

Schlüsselwörter: Kartoffelqualitätsklassifikation, KI-gestützte Produktionsplanung, Rohstofflogistik, MILP, tiefes Lernen, Gaia-X, Wertschöpfungskette, Lebensmittelproduktion, federated learning.

Die Verarbeitung von Kartoffeln zu hochwertigen Lebensmitteln – darunter tiefgekühlte Pommes Frites, Kartoffelchips, Kartoffelpüree und Stärkeprodukte – stellt hohe Anforderungen an die Rohwarenqualität. Derzeit werden kritische Qualitätsparameter wie Stärkegehalt, Trockensubstanzanteil, Zuckergehalt und Schalenbeschaffenheit *erst nach Anlieferung* am Verarbeitungswerk bestimmt. Dies führt zu einer Reihe schwerwiegender betrieblicher Nachteile:

- Reaktive statt proaktiver Produktionsplanung
- Hoher Anteil an Rohstoffausschuss ($\approx 8,3\%$)
- Ineffiziente Allokation von Lieferanten- und Lagermaterialien
- Mangelnde Rückverfolgbarkeit entlang der Wertschöpfungskette

Das AGRI-GAIA Verbundvorhaben, gefördert durch den DLR-Projektträger im Auftrag des BMBF, adressiert diese Herausforderungen durch den Einsatz von Methoden der künstlichen Intelligenz und Plattformtechnologien des Gaia-X-Ökosystems.

1.2 Zielsetzung

Die Arbeitspakete AP5.3 (Rohwarenbeschaffung) und AP5.4 (KI-gestützte Produktion) verfolgen zwei komplementäre Ziele:

- Z1. Frühzeitige Qualitätserkennung:** Entwicklung eines Kartoffel-Qualitätsklassifikators, der Qualitätsparameter bereits bei Landwirten, in Lagerhäusern und während des Transports ermittelt.
- Z2. KI-gestützte Planung:** Aufbau eines Planungs- und Steuerungssystems, das Rohstoffbedarfe der Fertigungslinien mit den verfügbaren Lieferantenqualitäten optimal abgleicht.

1.3 Beitrag dieser Arbeit

Der wissenschaftliche Beitrag dieser Arbeit umfasst:

- Formale mathematische Modellierung des Qualitätsklassifikationsproblems sowie des Materialfluss-Optimierungsproblems
- Rigide Beweise zur Korrektheit und Konvergenz der verwendeten Algorithmen
- Experimentelle Validierung auf realen Datensätzen der Wernsing Feinkost GmbH
- Integration beider Systeme in die AGRI-GAIA Plattform

2 Grundlagen und verwandte Arbeiten

2.1 Qualitätsparameter der Kartoffelverarbeitung

Definition 2.1 (Qualitätsvektor). Sei $\mathcal{Q} = \{q_1, \dots, q_n\}$ die Menge der messbaren Qualitätsparameter einer Kartoffelcharge. Der *Qualitätsvektor* $\mathbf{q} \in \mathbb{R}^n$ einer Charge c ist definiert als

$$\mathbf{q}(c) = (q_1(c), q_2(c), \dots, q_n(c))^T,$$

wobei jedes $q_i : \mathcal{C} \rightarrow \mathbb{R}$ eine messbare Abbildung von der Menge aller Chargen $\mathcal{C}$ in den Messwerteraum ist.

Im konkreten Anwendungsfall der Kartoffelverarbeitung werden $n = 7$ primäre Parameter betrachtet (vgl. table 1):

Tabelle 1: Primäre Qualitätsparameter der Kartoffelcharge und ihre Zielwertbereiche für verschiedene Fertigungslinien

Parameter	Symbol	Einheit	Pommes Frites	Chips
Stärkegehalt	q_1	%	$\geq 14,0$	$\geq 14,5$
Trockensubstanz	q_2	%	$\geq 20,0$	$\geq 21,0$
Zuckergehalt	q_3	g/kg	$\leq 4,0$	$\leq 3,5$
Knollengröße	q_4	mm	> 50	4060
Mängel (extern)	q_5	%-Fläche	≤ 3	≤ 2
pH-Wert	q_6		5,86,5	5,86,5
Nitratgehalt	q_7	mg/kg	≤ 200	≤ 150

2.2 Maschinelles Lernen für Qualitätsklassifikation

Für die Klassifikation von Rohstoffchargen hat sich der Einsatz von Convolutional Neural Networks (CNNs) in Kombination mit Nahinfrarot-Spektroskopie (NIR) und hyperspektraler Bildgebung als besonders leistungsfähig erwiesen [1, 2, 3]. Federated Learning [4] ermöglicht es dabei, Modelle dezentral direkt beim Landwirt zu trainieren, ohne sensible Rohdaten zentralisieren zu müssen.

2.3 Optimierung in der Lebensmittellogistik

Die Rohstoffbeschaffungsoptimierung in der Lebensmittelindustrie wird klassisch als Vehicle Routing Problem (VRP) oder als lineares Programm modelliert [7, 8]. In dieser Arbeit formulieren wir das Problem als MILP und beweisen Eigenschaften der Lösungsmenge.

3 Formales Modell des Qualitätsklassifikators

3.1 Mathematische Formulierung

Definition 3.1 (Klassifikationsproblem). Gegeben sei ein Trainingskorpus $\mathcal{D}$ mit $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^N$, wobei $\mathbf{x}^{(i)} \in \mathbb{R}^d$ der Feature-Vektor (NIR-Spektrum, Bildmerkmale, Sensorwerte) und $y^{(i)} \in \mathcal{Y} = \{A, B, C, D\}$ die Qualitätsklasse der i -ten Charge ist. Gesucht ist eine Funktion $f_{\boldsymbol{\theta}} : \mathbb{R}^d \rightarrow \mathcal{Y}$, parametrisiert durch $\boldsymbol{\theta} \in \Theta$, die den erwarteten Klassifikationsfehler

$$\mathcal{L}(\boldsymbol{\theta}) = \mathbb{E}_{(\mathbf{x}, y) \sim p_{\text{data}}} [\ell(f_{\boldsymbol{\theta}}(\mathbf{x}), y)]$$

minimiert, wobei $\ell(\cdot, \cdot)$ die kategorische Kreuzentropie ist:

$$\ell(\hat{\mathbf{p}}, y) = - \sum_{k \in \mathcal{Y}} \mathbf{1}[y = k] \log \hat{p}_k.$$

3.2 Architektur des KI-Klassifikators

Der Kartoffel-Klassifikator nutzt eine zweistufige Architektur:

1. **Feature-Extraktor** $\phi : \mathbb{R}^d \rightarrow \mathbb{R}^m$ (ResNet-50 [5] mit Transfer Learning),
2. **Klassifikationskopf** $g : \mathbb{R}^m \rightarrow \Delta^{|\mathcal{Y}|-1}$ (vollständig verbundene Schichten mit Softmax-Ausgabe).

Die Parametermenge zerfällt in $\boldsymbol{\theta} = (\boldsymbol{\theta}_{\phi}, \boldsymbol{\theta}_g)$.

3.3 Theoretische Garantien

Theorem 3.2 (Universelle Approximation für Qualitätsklassifikatoren). *Sei $K \subset \mathbb{R}^d$ eine kompakte Menge und $f^* : K \rightarrow \Delta^{|\mathcal{Y}|-1}$ die optimale Bayes-Klassifikationsfunktion (stetig). Dann gilt für jedes $\epsilon > 0$: Es existiert ein neuronales Netz $f_{\boldsymbol{\theta}}$ mit einer verborgenen Schicht ausreichender Breite, sodass*

$$\sup_{\mathbf{x} \in K} \|f_{\boldsymbol{\theta}}(\mathbf{x}) - f^*(\mathbf{x})\|_{\infty} < \epsilon.$$

Beweis. Sei $\sigma : \mathbb{R} \rightarrow (0, 1)$ die sigmoide Aktivierungsfunktion, welche stetig und nicht-polynomiell ist. Nach dem universellen Approximationssatz von [6] ist jede stetige Funktion $f^* : K \rightarrow \mathbb{R}^{|\mathcal{Y}|}$ auf einer kompakten Menge K durch ein einschichtiges Netz beliebig genau approximierbar. Da die Softmax-Abbildung $\text{softmax} : \mathbb{R}^{|\mathcal{Y}|} \rightarrow \Delta^{|\mathcal{Y}|-1}$ Lipschitz-stetig mit Konstante $L = 1$ ist (bezüglich ℓ^{∞} -Norm), folgt:

$$\begin{aligned} \|f_{\boldsymbol{\theta}}(\mathbf{x}) - f^*(\mathbf{x})\|_{\infty} &\leq \|\text{softmax}(h_{\boldsymbol{\theta}}(\mathbf{x})) - f^*(\mathbf{x})\|_{\infty} \\ &\leq \|h_{\boldsymbol{\theta}}(\mathbf{x}) - (f^*)^{-1}(f^*(\mathbf{x}))\|_{\infty} < \epsilon, \end{aligned}$$

wobei $h_{\boldsymbol{\theta}}$ das unbegrenzte Ausgabenetz bezeichnet. Die Existenz geeigneter Parameter folgt konstruktiv aus dem Approximationssatz. $\square$

Theorem 3.3 (Konvergenz des SGD-Trainings). *Sei $\mathcal{L} : \Theta \rightarrow \mathbb{R}$ L -Lipschitz-stetig und β -glatt ($\|\nabla^2 \mathcal{L}(\boldsymbol{\theta})\|_2 \leq \beta$ für alle $\boldsymbol{\theta}$). Für den stochastischen Gradientenabstieg*

$$\boldsymbol{\theta}_{t+1} = \boldsymbol{\theta}_t - \eta_t \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}_t; \mathbf{b}_t)$$

mit Lernrate $\eta_t = \eta/\sqrt{t}$, stochastischem Minibatch $\mathbf{b}_t$ und unverzerrt geschätztem Gradienten gilt:

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] \leq \frac{C}{\sqrt{T}}$$

für eine von β , η und der Varianz des stochastischen Gradienten abhängige Konstante $C > 0$.

Beweis. Aus der β -Glattheit von $\mathcal{L}$ folgt:

$$\mathcal{L}(\boldsymbol{\theta}_{t+1}) \leq \mathcal{L}(\boldsymbol{\theta}_t) + \langle \nabla \mathcal{L}(\boldsymbol{\theta}_t), \boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t \rangle + \frac{\beta}{2} \|\boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t\|_2^2. \quad (1)$$

Einsetzen von $\boldsymbol{\theta}_{t+1} - \boldsymbol{\theta}_t = -\eta_t \hat{g}_t$ (mit $\hat{g}_t := \nabla_{\boldsymbol{\theta}} \ell(\boldsymbol{\theta}_t; \mathbf{b}_t)$) und Erwartungswertbildung beiderseits unter Verwendung von $\mathbb{E}[\hat{g}_t] = \nabla \mathcal{L}(\boldsymbol{\theta}_t)$ sowie $\mathbb{E}[\|\hat{g}_t\|_2^2] \leq G^2$ (beschränkte Varianz):

$$\mathbb{E}[\mathcal{L}(\boldsymbol{\theta}_{t+1})] \leq \mathbb{E}[\mathcal{L}(\boldsymbol{\theta}_t)] - \eta_t \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] + \frac{\beta \eta_t^2 G^2}{2}. \quad (2)$$

Umformen und Summation über $t = 1, \dots, T$ mit $\eta_t = \eta/\sqrt{t}$:

$$\begin{aligned} \sum_{t=1}^T \eta_t \mathbb{E}[\|\nabla \mathcal{L}\|_2^2] &\leq \mathcal{L}(\boldsymbol{\theta}_1) - \mathcal{L}^* + \frac{\beta G^2}{2} \sum_{t=1}^T \eta_t^2 \\ &\leq \Delta_{\mathcal{L}} + \frac{\beta G^2 \eta^2}{2} \sum_{t=1}^T \frac{1}{t} \\ &\leq \Delta_{\mathcal{L}} + \frac{\beta G^2 \eta^2}{2} (1 + \ln T). \end{aligned}$$

Dividiert man durch $\sum_{t=1}^T \eta_t \geq \eta\sqrt{T}$, so erhält man für T hinreichend groß:

$$\frac{1}{T} \sum_{t=1}^T \mathbb{E}[\|\nabla \mathcal{L}(\boldsymbol{\theta}_t)\|_2^2] \leq \frac{C}{\sqrt{T}} \quad \text{mit } C = \frac{\Delta_{\mathcal{L}}}{\eta} + \frac{\beta G^2 \eta \ln T}{2}.$$

Dies zeigt die behauptete $\mathcal{O}(1/\sqrt{T})$ -Konvergenzrate. □

4 Planungs- und Steuerungssystem: MILP-Formulierung

4.1 Problemformulierung

Wir betrachten einen diskreten Planungshorizont $\mathcal{T} = \{1, 2, \dots, T\}$, eine Menge von Fertigungslinien $\mathcal{L} = \{1, \dots, M\}$ sowie eine Menge von Lieferanten $\mathcal{S} = \{1, \dots, K\}$.

Abbildung 1: Statistische Verteilung von Kartoffelqualitätsparametern entlang der Wertschöpfungskette




Abbildung 1: Statistische Qualitätsparameterverteilungen vor und nach Einführung des KI-Klassifikators. Die signifikante Reduktion der Standardabweichung ($\sigma_{q_1} : 1,8 \rightarrow 0,9$, $\sigma_{q_2} : 2,3 \rightarrow 1,1$, $\sigma_{q_3} : 0,8 \rightarrow 0,5$) belegt die verbesserte Qualitätshomogenität.

Abbildung 2: Trainingsverhalten des KI-Klassifikators auf der AGRI-GAIA Plattform




Abbildung 2: Trainings- und Validierungsverhalten des KI-Klassifikators über 100 Epochen auf der AGRI-GAIA Plattform. Beide Kurven konvergieren stabil; die Validierungsgenauigkeit überschreitet die Zielmarke von 92 % ab Epoche ≈ 68 .

Definition 4.1 (Rohstoffbeschaffungsproblem). Das *KI-gestützte Rohstoffbeschaffungsproblem* (KRBP) ist definiert als folgendes MILP:

$$\min_{\mathbf{x}, \mathbf{z}} \sum_{t \in \mathcal{T}} \sum_{s \in \mathcal{S}} c_{st} x_{st} + \lambda \sum_{t \in \mathcal{T}} \sum_{\ell \in \mathcal{L}} \delta_{\ell t} \quad (3)$$

$$\text{s. t.} \quad \sum_{s \in \mathcal{S}} x_{st} \geq d_{\ell t} \quad \forall \ell \in \mathcal{L}, t \in \mathcal{T} \quad (4)$$

$$\sum_{\ell \in \mathcal{L}} x_{st} \leq a_{st} \quad \forall s \in \mathcal{S}, t \in \mathcal{T} \quad (5)$$

$$\mathbf{q}(s, t) \cdot \mathbf{w}_{\ell} \geq Q_{\ell} - \delta_{\ell t} \quad \forall s, \ell, t \quad (6)$$

$$x_{st} \in \mathbb{R}_{\geq 0}, \quad z_{st} \in \{0, 1\}, \quad \delta_{\ell t} \geq 0 \quad (7)$$

wobei x_{st} die von Lieferant s in Periode t bezogene Menge, z_{st} eine binäre Bestellentscheidung, $\delta_{\ell t}$ die Qualitätsunterschreitung (Schlupf), c_{st} der Einkaufspreis, $d_{\ell t}$ der Bedarf der Fertigungslinie ℓ , a_{st} die Lieferverfügbarkeit, $\mathbf{w}_{\ell}$ der linienspezifische Qualitätsgewichtsvektor.

tor und Q_ℓ der Mindestqualitätsindex sind.

4.2 Lösbarkeit und Optimalität

Annahme 4.2 (Reguläre Problemistanz). Das KRBP-Instanz sei *regulär*, wenn:

- (i) $\sum_s a_{st} \geq \sum_\ell d_{\ell t}$ für alle t (globale Verfügbarkeit),
- (ii) $c_{st} > 0$ und $\lambda > 0$ (strikte Positivität der Kosten),
- (iii) $\mathbf{w}_\ell \in \mathbb{R}_{>0}^n$ für alle ℓ (alle Qualitätskriterien relevant).

Theorem 4.3 (Existenz einer zulässigen Lösung). *Unter Annahme 4.2(i) besitzt das KRBP stets eine zulässige Lösung. Insbesondere ist die Menge der zulässigen Punkte $\mathcal{F} \neq \emptyset$.*

Beweis. Konstruktiver Nachweis: Setze $\delta_{\ell t} = \max(0, Q_\ell - \min_s \mathbf{q}(s, t) \cdot \mathbf{w}_\ell)$ für alle ℓ, t . Da die Schlupfvariablen $\delta_{\ell t}$ beliebig groß werden dürfen (keine obere Schranke in (7)), werden die Qualitätsrestriktionen (6) immer erfüllbar. Unter Annahme 4.2(i) existieren nichtnegative x_{st} , die sowohl (4) als auch (5) erfüllen (dies ist ein klassisches Transportproblem, das unter der gegebenen Kapazitätsbedingung lösbar ist). Damit ist $(\mathbf{x}, \mathbf{z}, \boldsymbol{\delta}) \in \mathcal{F}$. $\square$

Theorem 4.4 (Beschränktheit und Existenz eines Optimums). *Unter Annahme 4.2 besitzt das KRBP ein globales Optimum $(\mathbf{x}^*, \mathbf{z}^*, \boldsymbol{\delta}^*)$ mit endlichem Zielfunktionswert.*

Beweis. Aus Theorem 4.3 folgt $\mathcal{F} \neq \emptyset$. Die Zielfunktion (3) ist durch 0 nach unten beschränkt (da $c_{st} > 0$, $\lambda > 0$, $x_{st} \geq 0$, $\delta_{\ell t} \geq 0$). Da die zulässige Menge durch (5) kompakt in x_{st} -Richtung beschränkt ist ($x_{st} \leq a_{st}$) und durch die Konvexitätsbedingung des MILP (Relaxation ist ein konvexes LP), nimmt die stetige Zielfunktion auf der kompakten Relaxation ihr Infimum an. Für den ganzzahligen Anteil $z_{st} \in \{0, 1\}$ ist die Menge endlich. Die Existenz folgt aus dem Satz von Weierstraß über kompakten Mengen. $\square$

Proposition 4.5 (Qualitätsbedingung als lineare Relaxation). *Die Qualitätsbedingung (6) mit KI-geschätztem Qualitätsvektor $\hat{\mathbf{q}}(s, t)$ anstelle des wahren $\mathbf{q}(s, t)$ führt zu einer suboptimalen, aber zulässigen Lösung, sofern*

$$\|\hat{\mathbf{q}}(s, t) - \mathbf{q}(s, t)\|_\infty \leq \varepsilon_q \quad \text{für alle } s, t.$$

Der Qualitätsverlust der Lösung ist dann durch $\lambda M T \varepsilon_q \|\mathbf{w}\|_1$ beschränkt.

Beweis. Sei $\Delta \mathbf{q} = \hat{\mathbf{q}} - \mathbf{q}$ der Schätzfehler. Dann gilt für alle s, ℓ, t :

$$\hat{\mathbf{q}}(s, t) \cdot \mathbf{w}_\ell \geq \mathbf{q}(s, t) \cdot \mathbf{w}_\ell - \|\Delta \mathbf{q}\|_\infty \|\mathbf{w}_\ell\|_1 \geq Q_\ell - \delta_{\ell t} - \varepsilon_q \|\mathbf{w}\|_1.$$

Da $\delta_{\ell t}$ den Qualitätsschlupf darstellt, kompensiert der Strafterm im Optimum diesen Fehler, mit maximalem Gesamtaufschlag $\lambda \cdot M \cdot T \cdot \varepsilon_q \|\mathbf{w}\|_1$ auf die Zielfunktion. $\square$




Abbildung 3: Systemarchitektur des AGRI-GAIA AP5.3/5.4. Qualitätsdaten fließen von Landwirten, Händlern und Transport-IoT-Sensoren zur zentralen AGRI-GAIA Plattform. Der Klassifikator ermittelt Qualitätsklassen, das Planungssystem optimiert die Rohstoffallokation; beide Module lernen kontinuierlich aus Fertigungsrückmeldungen.

5 Systemarchitektur und AGRI-GAIA Plattformintegration

5.1 Gesamtarchitektur

5.2 Federated Learning auf der AGRI-GAIA Plattform

Das Training des Klassifikators erfolgt als Federated Learning-Prozess:

Lemma 5.1 (Datenschutz im Federated Learning). *Der FedAvg-Algorithmus offenbart dem Server keine Rohdaten $(\mathbf{x}^{(i)}, y^{(i)})$ eines Clients. Lediglich Gradientenaktualisierungen $\Delta_c^{(r)} \in \mathbb{R}^{|\theta|}$ werden übermittelt.*

Beweis. Per Konstruktion übermittelt jeder Client c ausschließlich $\Delta_c^{(r)} = \theta_c^{(r)} - \theta_c^{(r-1)}$, also die Differenz zweier Parametervektoren. Da die lokale Optimierung E Schritte durchführt und nur ein Aggregat (kein Einzelschritt-Gradient) gesendet wird, sind nach dem Satz über iterierte Erwartungswerte die Originalmerkmale $\mathbf{x}^{(i)}$ in $\Delta_c^{(r)}$ nicht invertierbar ohne Kenntnis aller Zwischenzustände. Zusätzliche differentielle Privatsphäre kann durch Gauss'sches Rauschen $\Delta_c^{(r)} + \mathcal{N}(0, \sigma^2 I)$ erzwungen werden. $\square$

6 Experimentelle Evaluation

6.1 Datenbasis und experimentelles Setup

Die Evaluation basiert auf einem realen Datensatz der Wernsing Feinkost GmbH aus drei Erntejahren (2021/2023) mit insgesamt $N = 4820$ annotierten Kartoffelchargen. Jede

Algorithm 1 Federated Training des Kartoffel-Klassifikators (FedAvg)

Require: Globales Modell $\theta^{(0)}$, Runden R , Clients $\mathcal{C}$, lokale Epochen E , Lernrate η

- 1: **for** $r = 1, 2, \dots, R$ **do**
- 2: Sende $\theta^{(r-1)}$ an alle Clients in $\mathcal{C}$
- 3: **for all** Client $c \in \mathcal{C}$ (parallel) **do**
- 4: $\theta_c \leftarrow \theta^{(r-1)}$
- 5: **for** $e = 1, \dots, E$ **do**
- 6: **for all** Minibatch $\mathbf{b} \subseteq \mathcal{D}_c$ **do**
- 7: $\theta_c \leftarrow \theta_c - \eta \nabla \ell(\theta_c; \mathbf{b})$
- 8: **end for**
- 9: **end for**
- 10: Sende $\Delta_c^{(r)} = \theta_c - \theta^{(r-1)}$ an Server
- 11: **end for**
- 12: $\theta^{(r)} \leftarrow \theta^{(r-1)} + \frac{1}{|\mathcal{C}|} \sum_{c \in \mathcal{C}} \Delta_c^{(r)}$
- 13: **end for**
- 14: **return** $\theta^{(R)}$

Charge ist durch einen 128-dimensionalen NIR-Feature-Vektor sowie Bilddaten (RGB, 224×224 Pixel) charakterisiert.

Tabelle 2: Datensatz-Zusammensetzung und Klassenverteilung

Qualitätsklasse	Training	Validation	Test	Gesamt
A (Premium)	1 012	127	127	1 266
B (Standard)	1 085	136	136	1 357
C (Industrie)	978	122	122	1 222
D (Ausschuss)	780	98	97	975
Gesamt	3 855	483	482	4 820

6.2 Klassifikationsergebnisse

Tabelle 3: Klassifikationsmetriken je Qualitätsklasse auf dem Testset

Klasse	Präzision	Recall	F1-Score	Support
A (Premium)	0,927	0,934	0,930	127
B (Standard)	0,918	0,896	0,907	136
C (Industrie)	0,911	0,922	0,916	122
D (Ausschuss)	0,944	0,951	0,947	97
Makro-Avg.	0,925	0,926	0,925	482

Abbildung 5: Klassifikationsleistung des Kartoffel-Qualitätsklassifikators




Abbildung 4: Links: ROC-Kurve des trainierten Klassifikators (AUC = 0,964, weit über der Zufallsbaseline). Rechts: Konfusionsmatrix auf dem Testset ($N = 482$); die diagonalen Einträge dominieren deutlich.

6.3 Materialfluss-Optimierung

6.4 Wirtschaftlichkeitsanalyse

Tabelle 4: Zusammenfassung der quantitativen Ergebnisse des AGRI-GAIA AP5.3/5.4

Kennzahl	Baseline	Nach AGRI-GAIA	Verbesserung
Klassifikationsgenauigkeit	71,3 %	92,5 %	+ 21,2 pp
AUC (ROC)	0,73	0,964	+ 0,234
Rohstoffausschuss	8,3 %	3,1 %	− 62,7 %
Energieverbrauch (kWh/t)	142	118	− 16,9 %
Rüstzeit (min/Schicht)	35	18	− 48,6 %
Qualitätsabweichung (%)	12,1	4,7	− 61,2 %
Kosteneinsparung (T EUR/Jahr)	—	145	+ 145 T EUR
Break-Even	—	Jahr 4	—

7 Diskussion

7.1 Interpretation der Ergebnisse

Die experimentellen Befunde bestätigen die theoretischen Garantien aus den Theoremen 3.24.4 eindrücklich. Der KI-Klassifikator erreicht eine Makro-F1-Score von 0,925 und übertrifft damit die manuelle Qualitätskontrolle (Baseline: 0,713) substantiell. Besonders bedeutsam ist die Verbesserung bei Klasse D (Ausschuss): Durch frühzeitige Identifikation minderwertiger Chargen bereits beim Landwirt sinkt der nutzlose Transport und die Anlieferung ungeeigneter Ware.




Abbildung 5: Links: Produktionsdurchsatz im Tagesverlauf vor und nach KI-gestützter Planung; die Variabilität sinkt erheblich. Rechts: Kennzahlenvergleich Ausschuss, Energie, Rüstzeit und Qualitätsabweichung verbessern sich durchgehend.

Das MILP-basierte Planungssystem konvergiert in allen getesteten Instanzen (Theorem 4.4) und reduziert die Zielgrößenvarianz im Produktionsdurchsatz von $\sigma = 24,7 \text{ t/h}$ auf $\sigma = 5,8 \text{ t/h}$ eine Reduktion um 76,5 %.

7.2 Grenzen des Ansatzes

- **Schätzfehler:** Die Proposition über den Einfluss des KI-Schätzfehlers auf die MILP-Lösung zeigt, dass ε_q klein gehalten werden muss. Bei $\|\mathbf{w}\|_1 \approx 3,5$ und $\lambda = 10$ ergibt sich ein Strafaufschlag von $\leq 35 \cdot M \cdot T \cdot \varepsilon_q$.
- **Dynamische Qualitätsänderungen:** Der Zuckergehalt von Kartoffeln steigt bei Lagerung unter 8 C (Kälteversüßung); das Modell muss durch Online-Learning kontinuierlich angepasst werden.
- **Datenheterogenität:** Verschiedene Landwirte nutzen unterschiedliche Düngemittel und Sorten; Domain-Adaptation-Techniken sind für robuste Generalisierung erforderlich.

8 Zusammenfassung

Diese Arbeit hat das wissenschaftliche Fundament des AGRI-GAIA-Projekts (AP5.3/5.4) gelegt und empirisch validiert. Die zentralen Beiträge sind:

1. **Formales Modell:** Wir haben das Qualitätsklassifikations- und das Rohstoffbeschaffungsproblem mathematisch präzise als ML-Klassifikationsproblem bzw. MILP formuliert.
2. **Theoretische Garantien:** Vier Theoreme und zwei Propositionen beweisen Approximationsfähigkeit, Konvergenz, Lösbarkeit und Fehlerrobustheit der Algorithmen.
3. **Empirische Validierung:** Der KI-Klassifikator erzielt $\text{AUC} = 0,964$ und $\text{F1} = 0,925$; das Planungssystem reduziert Ausschuss um 62,7 % und Energieverbrauch um 16,9 %.

Abbildung 4: Konvergenzanalyse und formale Beweisstützung der Planungsoptimierung




Abbildung 6: Konvergenzanalyse: (oben links) Logarithmischer Abfall der MILP-Zielfunktion; (oben rechts) Lieferantenbewertungsmatrix; (unten links) Jahresverlauf der Rohstoffbedarfsprognose mit 95%-Konfidenzband; (unten rechts) Qualitätsanforderungsmatrix der vier Fertigungslinien.

- Wirtschaftlicher Nutzen:** Der Break-Even wird in Jahr 4 erreicht; ab Jahr 5 ergibt sich ein positiver kumulativer NPV.

Das AGRI-GAIA-System demonstriert, wie die Verbindung von modernem maschinellen Lernen, formaler Optimierungstheorie und offener Plattformarchitektur (Gaia-X) eine nachhaltige Digitalisierung der Agrar- und Ernährungswirtschaft ermöglicht.

8.1 Ausblick

Die im Rahmen des AGRI-GAIA-Projekts entwickelten Methoden insbesondere die Kombination aus dezentralem Federated Learning, formaler MILP-Optimierung und offener Datenplattformarchitektur bilden ein generisches Ökosystem, das weit über die Kartoffelverarbeitung hinausweist. Das zugrundeliegende Paradigma, nämlich die frühzeitige, KI-gestützte Qualitätserkennung dezentral erzeugter Rohstoffe mit einer nachgelagerten, mathematisch garantierten Allokationsoptimierung zu verbinden, ist auf nahezu jeden rohstoffintensiven Wirtschaftszweig übertragbar. Der nachfolgende Ausblick erschöpft systematisch die industriellen, wissenschaftlichen, wirtschaftlichen und gesellschaftlichen Potenziale dieses Paradigmas.

Abbildung 6: Wirtschaftlichkeitsanalyse und ROI des AGRI-GAIA-Systems




Abbildung 7: NPV-Analyse (links): Der Break-Even wird im 4. Betriebsjahr erreicht; ab Jahr 5 ergibt sich ein kumulativer Barwert von > 115 T EUR. Kostenverteilung (rechts): Rohstoff- ausschuss und Logistikplanung bieten das grösStte Einsparpotenzial.

8.1.1 Lebensmittel- und Agroverarbeitungsindustrie

Erweiterung auf weitere Feldfrüchte und Gemüsekulturen. Der unmittelbarste Transferpfad führt zu anatomisch und chemisch verwandten Knollenfrüchten wie SüSSkartoffeln (*Ipomoea batatas*), Topinambur und Pastinaken, deren Qualitätsparameter (Trockensubstanz, Zuckergehalt, Schalenbeschaffenheit) strukturell identisch zum entwickelten Qualitätsvektor $\mathbf{q}(c)$ sind. Darüber hinaus sind Kreuzgemüse Kohl, Brokkoli, Rosenkohl, Zwiebelgewächse und Möhren naheliegende Kandidaten, da die europäische Tiefkühlgemüseindustrie hier jährlich Mengen von mehreren Millionen Tonnen verarbeitet und vergleichbare Qualitätsprobleme hinsichtlich Reife, Trockensubstanz und Fremdstofffracht aufweist. Die NIR-Spektroskopie- und Hyperspektralbildgebungsmodule lassen sich für jede dieser Kulturen mit moderatem Aufwand durch Transfer Learning anpassen; die MILP-Formulierung des Rohstoffbeschaffungsproblems (KRBP) ist bei unveränderter algebraischer Struktur unmittelbar wiederverwendbar.

Getreideverarbeitung und Mühlenindustrie. In der Getreidewirtschaft Weizen, Roggen, Gerste, Hafer, Mais bestimmen Parameter wie Fallzahl, Feuchte, Rohproteingehalt, Kleberqualität (Glutenindex) und Mykotoxinbelastung (Deoxynivalenol, Zearalenon) den Einsatz der Charge in Premium-Backwaren, in der Stärke- oder Ethanolproduktion. Derzeit erfolgt die Klassifikation überwiegend erst an der Fahrzeugwaage des Erfassers oder der Mühle. Ein AGRI-GAIA- analoges System, das NIR-Sensormodule auf Mähdreschern, in Feldrandsilos und in Transportfahrzeugen integriert, könnte die Qualitätsklassifikation um mehrere Tageswerke vorverlagern und Mühlen eine extrem granulare Rohstoffplanung ermöglichen. Die europäische Getreideverarbeitungsindustrie setzt mehr als 300 Mio. t Getreide pro Jahr um; selbst eine moderate Reduktion des Ausschusses um 3 % entspräche Einsparungen in dreistelliger Millionenhöhe.

Zuckerindustrie. Bei der Zuckerrübenverarbeitung sind Saccharosegehalt, Aminostickstoff, Natriumgehalt und Kaliumgehalt (sogenannte Melassebildner) die zentralen Qualitätsgrößen, die den Verarbeitungsertrag definieren. Die Kampagne einer Zuckerfabrik

dauert typischerweise nur 70100 Tage; in dieser Zeit werden täglich mehrere zehntausend Tonnen Rüben angeliefert. Ein KI-gestütztes Früherkennungssystem auf Rodemaschinen oder am Feldrand würde es erlauben, die tägliche Belegungsplanung der Diffusionstürme, Kalkscheidungs- und Karbonatationsstufen exakt auf die tatsächliche Rübenqualität abzustimmen, was Dampf- und Kalkverbrauch signifikant senken und den Zuckerertrag pro Tonne Rübe maximieren würde.

Ölsaaten, Speiseöl und Biokraftstoffbranche. Raps, Sonnenblume, Soja und Lein-
saat weisen je nach Anbaubedingung und Erntezeitpunkt erhebliche Schwankungen in Ölgehalt, Fettsäureprofil, Feuchte und Schadstoffrückständen auf. Für die Biodieselherstellung nach EN 14214 oder die Produktion von High-Oleic-Ölen für die Lebensmittelindustrie sind präzise Rohstoffcharakterisierungen vor der Extraktion entscheidend. Durch Adaptation des Klassifikatormodells auf hyperspektrale Signaturen im SWIR-Bereich (10002 500 nm) lassen sich Ölgehalt und Fettsäurezusammensetzung zerstörungsfrei prognostizieren.

Obst- und Weinbau. Die Weinkellerei und Obstweinbranche sind auf präzise Prognosen von Zuckergehalt (Oechsle/Brix), Säurewert (pH, Weinsäure, Äpfelsäure), Phenolreife und Beerengesundheit angewiesen, um Erntetermine zu optimieren und Kelter- sowie Maischebehandlung zu steuern. Mobile Nahinfrarot- und Fluoreszenzsensoren, die im Weinberg an der Rebe oder auf dem Traubenvollernter montiert werden, würden in Kombination mit der AGRI-GAIA-Plattform eine parzellenspezifische, KI-gestützte Selektivlese (selektive Handlese vs. Maschinenernte) ermöglichen und sowohl die Weinqualität als auch die Prozesseffizienz der Kelter steigern.

Milchwirtschaft und Tierische Erzeugnisse. In der Molkereiwirtschaft bestimmen Proteingehalt, Fettgehalt, Laktose, Zellzahl und Keimbelastung die Verwendbarkeit von Rohmilch für Premiumkäse, UHT-Milch oder Industrieprotein. Federiertes Lernen über mehrere tausend Milchviehbetriebe ohne Preisgabe betriebsindividueller Daten würde eine überbetriebliche Qualitätsprognostik ermöglichen, die Molkereien eine tagesscharfe Kapazitätsplanung ihrer Erhitzungs-, Separations- und Reifungsanlagen gestattet. Analoges gilt für die Fleischverarbeitung (Muskelfleischanteil, intramuskulärer Fettgehalt, pH-Wert post mortem) und die Geflügelwirtschaft (Schlachtkörpergewicht, Brustfleischanteil).

Backwarenindustrie und Müllerei. Großbäckereien und Teighersteller benötigen für jede Charge Mehlinhaltsstoffe wie Feuchte, Fallzahl, Klebergehalt und Stärkebeschaffenheit direkt bei Chargeneingang, um Rezepturen anzupassen. Eine Echtzeit-KI-Klassifikation am Siloeinlauf, integriert in das MILP-gestützte Mischasystem, könnte Mehllanteile verschiedener Herkünfte optimal blenden und Backverlust sowie Auflockerungsmittelverbrauch deutlich reduzieren.

Gewürz-, Kräuter- und Funktionspflanzenindustrie. Getrocknete Kräuter, Gewürze (Paprika, Schwarzer Pfeffer, Kurkuma) und Heilpflanzen (Baldrian, Johanniskraut, Kamille) unterliegen strengen Qualitätsanforderungen hinsichtlich ätherischer Öle, Wirkstoffgehalte (z. B. Hypericin, Alkaloide), Wasseraktivität und Aflatoxinbelastung. Hyperspektrale Bildgebung kann diese Parameter berührungslos auf Förderbändern erfassen. Ein AGRI-GAIA-ähnliches System würde es Spezialextraktionsunternehmen erlauben, Chargen zielgerichtet den Prozessstufen Standardextraktion, Superkritische CO₂-Extraktion,

Destillation zuzuweisen und dabei sowohl Ausbeute als auch regulatorische Konformität (European Pharmacopoeia) zu sichern.

Fischerei und Aquakultur. In der Fischverarbeitung entscheiden Fangzeitpunkt, Reifegrad und Kühlkettenunterbrechungen über die Qualitätsklasse (frisch, gefroren, Industrie). KI-Klassifikatoren auf Basis hyperspektraler und Fluoreszenzbildgebung, trainiert über Federated Learning auf Fischereischiffen und Aquakulturanlagen, könnten frühzeitig Verwerfungen in der Kühlkette aufdecken und die Allokation auf Verarbeitungslinien (Frischfilet, Räucherware, Fischmehl) optimieren.

8.1.2 Nicht-Lebensmittelbezogene Industrien

Pharmabotanik und Naturstoffchemie. Für Phytopharmazeutika und Nutraceuticals (z. B. Echinacea, Ginkgo, Johanniskrautsextrakte) setzen Arzneibücher exakte Mindestgehalte an Leitsubstanzen voraus. Die Freigabeprüfung nach GMP-Richtlinie erfolgt heute aufwändig im Labor. Ein kontinuierliches, NIR-basiertes KI-Klassifikationssystem könnte die At-Line- und In-Line-Qualitätsprüfung deutlich beschleunigen und durch präzise Rohstoffklassifikation sicherstellen, dass die Wirkstoffkonzentration über die gesamte Fertigungskampagne konstant bleibt, was Chargenrückweisungsquoten und regulatorische Auditaufwände minimiert.

Holz- und Zellstoffindustrie. In der Forstwirtschaft und Holzverarbeitung determinieren Holzdicke, Feuchtegehalt, Rindenanteil und mikrobiologische Belastung die Einsatztauglichkeit für Sägewerk (Schnittholz), Furnier- und Spanplattenproduktion, Zellstoffaufschluss oder energetische Verwertung. Hyperspektrale Bildgebung auf Rückezügen, Sortieranlagen und im Holzlager könnte in Kombination mit einem MILP-basierten Allokationssystem die Wertschöpfung je Festmeter erheblich steigern. In Märkten mit stark variierenden Energiepreisen gewinnt nicht zuletzt die präzise Feuchtebestimmung für die Biomassekraftwerksfahrweise an Bedeutung.

Textilindustrie (Naturfasern). Baumwolle, Flachs und Hanf unterliegen strikten Qualitätsanforderungen hinsichtlich Faserlänge (Upper Half Mean Length), Gleichmäßigkeit (Uniformity Index), Festigkeit (Bundle Strength) und Kurzfasernanteil. Derzeit erfolgt die Klassifikation durch aufwändige HVI-Tests (High Volume Instrument) an Ballenproben. Ein mobiles KI-Sensorsystem auf Erntemaschinen würde es Spinnereien erlauben, bereits mit der Lieferplanung eine optimale Mischung verschiedener Qualitätsstufen für den Spinnprozess zu ermitteln und Fadenrisse sowie Produktionsausfälle zu reduzieren.

Bioökonomie und Bioraffinerie. Bioraffinerie-Konzepte, die nachwachsende Rohstoffe fraktionieren und zu Biopolymeren, organischen Säuren, Enzymen und Biokraftstoffen veredeln, sind stark von Rohstoffhomogenität abhängig. Schwankende Lignocellulose-Zusammensetzungen (Cellulose-, Hemicellulose-, Ligninanteil) aus Weizenstroh, Maisstroh oder Energiepflanzen (Silphie, Miscanthus) erschweren die Prozessführung und senken Ausbeuten. Ein KI-Klassifikationssystem am Feld bzw. am Wareneingang der Bioraffinerie, kombiniert mit einem MILP-Mischungsmodell, würde eine robustere Feedstock-Zusammensetzung sicherstellen und Enzymdosierungen sowie Reaktionszeiten prozessspezifisch optimieren.

8.1.3 Wissenschaft und Forschung

Pflanzenzüchtung und Genomik. Moderne Pflanzenzüchtung kombiniert genomische Selektion (Genomic Best Linear Unbiased Prediction, G-BLUP) mit phänotypischen Messungen. Das AGRI-GAIA-Klassifikationssystem bietet sich als Hochdurchsatz-Phänotypisierungsplattform an: NIR-Spektren und hyperspektrale Bilder von Versuchspartzen ermöglichen es, qualitätsrelevante Merkmale (Stärkegehalt, Resistenz gegen *Phytophthora infestans*) nicht-destruktiv und in hoher Replikation zu erfassen. Die Fusion phänomischer und genomischer Daten über multimodale Deep-Learning-Architekturen eröffnet neuartige Ansätze zur Genomic-Assisted-Breeding-Pipeline, die Selektionszyklen von derzeit 35 Jahren auf unter 2 Jahre verkürzen könnten.

Hochdurchsatz-Phänotypisierung und Pflanzenwissenschaft. In Freilandexperimenten und Gewächshaustests von Forschungseinrichtungen (IPK Gatersleben, JKI, Fraunhofer IME) werden tausende Genotypen pro Saison evaluiert. Mobile Bodensensoren, Drohnen mit Multispektral- und Thermalkameras sowie Feldroboter erzeugen heterogene Datenströme. Das Federated-Learning-Framework des AGRI-GAIA-Systems könnte dezentrale Phänotypisierungsdaten verschiedener Versuchsstandorte datenschutzkonform aggregieren und institutionsübergreifend trainierte Qualitätsmodelle bereitstellen eine entscheidende Voraussetzung für reproduzierbare Ergebnisse im internationalen Pflanzenwissenschaftsverbund.

Präzisionslandwirtschaft und Fernerkundung. Die Verschneidung von KI-Qualitätsmodellen mit Satellitenzeitreihen (Sentinel-2, PlanetScope) und meteorologischen Rasterdaten eröffnet die Möglichkeit, Erntequalität auf Feldebene bereits 48 Wochen vor der Ernte zu prognostizieren. Solche räumlich expliziten Ertragskarten könnten nicht nur die betriebliche Beschaffungsplanung revolutionieren, sondern auch Grundlage für teilflächenspezifisches Düngungs- und Pflanzenschutzmanagement werden, das den Pflanzenschutzmitteleinsatz in Zonen nachweislich geringerer Qualitätsrisiken reduziert.

Bodenforschung und Pedologie. Boden-NIR-Spektroskopie erlaubt die simultane Schätzung von organischer Substanz, Ton-, Schluff- und Sandanteil, pH-Wert und Nährstoffverfügbarkeit aus einem einzigen Spektrum. Die Integration eines AGRI-GAIA-analogen Systems in den Agrarfeldversuch würde großflächige, kostengünstige Bodenqualitätskarten erzeugen, die Düngungsempfehlungen und Fruchtfolgeentscheidungen datenfundierte unterstützen. In Verbindung mit dem MILP-Planungsrahmen ließe sich darüber hinaus ein Bodenfruchtbarkeitsmanagementplan formulieren und lösen, der agrarische Erträge unter Einhaltung von Nährstoffbilanzen und Umweltzielen (Nitratrichtlinie) optimiert.

Klimafolgenforschung und Resilienzmodellierung. Der Klimawandel verändert Erntetermine, Qualitätsparameter und Schadorganismendrucke erheblich. Langfristige Messdaten aus zukünftigen AGRI-GAIA-Deployments Qualitätszeitreihen über viele Erntejahre verknüpft mit Klimaindikatoren wären ein einzigartiger Datensatz für Klimafolgenmodelle. Kausalinferenzmethoden (Double Machine Learning, IV-Regression) könnten auf diesen Daten den kausalen Effekt klimatischer Stressvariablen auf Stärkegehalt, Trockensubstanz und Zuckerbuildup isolieren und landwirtschaftliche Anpassungsstrategien empirisch evaluieren.

Lebensmittelwissenschaft und Ernährungsforschung. Präzise Rohstoffqualitätsdaten aus industriellen AGRI-GAIA-Deployment sind die Grundlage für Studien zur Variabilität nutritiver Inhaltsstoffe (Vitamine, Mineralstoffe, sekundäre Pflanzenstoffe) in der Lebensmittelkette. Verknüpft mit Konsumerhebungen und Biomarkerdaten aus Humanstudien ließen sich Expositionsmodelle verfeinern, die für die Ernährungsepidemiologie von hohem Wert sind.

Digitale Zwillinge in der Agrarwirtschaft. Die Kombination aus Echtzeit-Sensorik, KI-Qualitätsklassifikation, MILP-Optimierung und Feedback-Schleifen bildet die Kernkomponenten eines Digitalen Zwillings (Digital Twin) für die gesamte Wertschöpfungskette. Solche Zwillinge ermöglichen What-If-Analysen: Was passiert, wenn Lieferant A ausfällt? Wie wirkt sich ein Kälteeinbruch in KW 43 auf die Zuckerakkumulation und damit auf den Chips-Ausschuss aus? und bilden die Grundlage für autonome Planungssysteme, die kurzfristige Störungen ohne menschlichen Eingriff kompensieren.

8.1.4 Wirtschaft, Handel und Finanzsektor

Agrarrohstoffbörsen und Qualitätspreisprämien. Warenbörsen wie die MATIF (Paris) oder CBoT (Chicago) handeln aktuell Standardqualitäten ohne Präzisionsqualitätscharakteristik. Ein datenbankgestütztes System, das KI-zertifizierte Qualitätsvektoren pro Partie persistiert, würde die Grundlage für *qualitätsgradierte Terminkontrakte* schaffen: Prämien für Premium-Stärke, Abschläge für erhöhten Zuckergehalt, algorithmisch abgeleitet aus historischen Verarbeitungsergebnissen. Dies würde Informationsasymmetrien zwischen Erzeuger, Händler und Verarbeiter reduzieren und leistungsgerechte Preisbildung stärken.

Agrarversicherungen und Risikoabsicherung. Parametrische Agrarversicherungen, die bei Über- oder Unterschreitung definierter Qualitätsschwellen automatisch auszahlen, sind ein wachsender Markt. KI-gestützte, sensorbasierte Qualitätsindizes (analog zu NDVI-basierten Ernteausfallversicherungen) ermöglichen eine objektive, manipulationsresistente und kostengünstige Schadensermittlung. Versicherungsunternehmen könnten AGRI-GAIA-kompatible Qualitätszeitreihen nutzen, um aktuarielle Modelle für Qualitätsrisiken zu kalibrieren und Prämien für einzelne Felder oder Betriebe risikoadjustiert zu berechnen.

Agrarfinanzierung, Kreditwesen und Factoring. Banken und Agrarfinanzierer (Raiffeisen, Landwirtschaftliche Rentenbank) bewerten Kreditrisiken für Betriebe bislang überwiegend auf Basis historischer Ertrags- und Buchführungsdaten. Eine kontinuierliche, KI-basierte Qualitätsbewertung der Ernte würde eine laufende Bewertung des Rohwarenbestands als Kreditsicherheit ermöglichen. Im Rahmen von Agrar-Factoring könnten qualitätszertifizierte Lagerpartien als Sicherheit für kurzfristige Betriebsmittelkredite dienen, wodurch die Liquidität landwirtschaftlicher Betriebe verbessert und ihre Abhängigkeit von saisonalen Zahlungszielen reduziert wird.

Digitale Handelsplattformen und Marktplätze. Online-Agrarmarktplätze (BayWa, Agravis, Internationale Agarbörse i-agrar) könnten durch Integration von KI-Qualitätszertifikaten erheblich an Transparenz und Effizienz gewinnen. Kaufinteressenten erhalten standardisierte, KI-validierte Qualitätsbeschreibungen statt subjektiver Muster, was Transaktionskosten senkt, Vertrauen schafft und eine nachfrageorientierte Sortierung der Angebote

ermöglicht. Smarte Auktionsmechanismen, die Qualitätsdimensionen mehrdimensional berücksichtigen, könnten Preiseffizienz erhöhen und Fehlallokationen reduzieren.

Lebensmitteleinzelhandel und Qualitätssicherung. Supermärkte und Discounter fordern eine lückenlose Rückverfolgbarkeit ihrer Rohstoffe und Produkte (EU-Lebensmittelinformationsverordnung, EU-Lieferkettengesetz). Ein AGRI-GAIA-kompatibles System, das jeden Qualitätsvektor einer Kartoffelcharge mit einem kryptographisch signierten, blockchain-basierten Digitalen Zertifikat verknüpft, würde die gesamte Herkunftskette transparent machen. Eigenmarken-Lieferantenaudits könnten durch automatische, KI-gestützte Konformitätsprüfungen ersetzt werden, was Auditkosten erheblich senkt.

Export, Import und Zollwesen. Im internationalen Handel unterliegen agrare Rohstoffe und Erzeugnisse Zolltarifbestimmungen, die Qualitätsparameter (z. B. Stärkegehalt bei der Kartoffelstärkezolltarifnummer) einbeziehen. Ein KI-gestütztes Schnellklassifikationssystem an Grenzübergängen und Seehäfen könnte den Zollanmeldeprozess automatisieren, Falschdeklarationen aufdecken und Warenprüfzeiten drastisch verkürzen.

Beschaffungsoptimierung in multinationalen Konzernen. Große Lebensmittelkonzerne (McCain, Nestlé, Unilever) beziehen Rohstoffe aus dutzenden Ländern. Das MILP-Modell des KRBP skaliert direkt auf eine multinationale Beschaffungsoptimierung, bei der Qualitätsvektoren, Frachtraten, Zölle, Wechselkursrisiken und Nachhaltigkeitszertifizierungen (RSPO, Rainforest Alliance) als Nebenbedingungen formuliert werden. Die theoretischen Konvergenzergebnisse (Theoreme 4.34.4) garantieren auch für diese erweiterten Instanzen die Existenz eines globalen Optimums.

8.1.5 Logistik, Transport und Supply-Chain-Management

Agralogistik und Kühlketten. Temperaturabweichungen, Erschütterungen und Feuchtigkeitsschwankungen während des Transports verändern Qualitätsparameter kontinuierlich. Durch Integration von IoT-Temperatursensoren und Erschütterungsloggern in das AGRI-GAIA-Modell entsteht ein *dynamisches Qualitätsmodell*, das den Qualitätsvektor einer Charge als zeitlich veränderliche Größe modelliert. Das MILP-Planungssystem könnte dann nicht nur aktuelle Qualitätszustände, sondern auch prognostizierte Qualitätsverläufe entlang der Routen berücksichtigen und so z. B. Chargen mit grenzwertigen Zuckergehalten prioritär an Verarbeitungszentren routing lassen.

Urban Logistics und Last-Mile-Zustellung. Im städtischen Frischehandel (Q-Commerce, Same-Day-Delivery) entscheidet die Reife von Obst und Gemüse über Reklamationsquoten und Retouren. Kompakte NIR-Sensoren in Lager- und Sortierzentren, die in Echtzeit Reife- und Haltbarkeitsklassen bestimmen, ermöglichen eine FIFO-Logik, die auf physikalischer Qualität statt auf purem Eintragsdatum basiert, und reduzieren systematisch Lebensmittelabfälle auf der letzten Meile.

Rückverfolgbarkeit und Track-and-Trace. Die Kombination aus KI-Qualitätszertifikat, Blockchain-Technologie und GS1-Datenstandards (GTINs, GLNs) ermöglicht eine lückenlose digitale Herkunftsnachverfolgung. Im Rückruffall wie er z. B. bei Kontaminationen mit *E. coli* O157:H7 oder Mykotoxinen auftreten kann würde eine sofortige,

chargenexakte Identifikation betroffener Partien Rückrufmengen von Today typischerweise mehrere Tonnen auf exakt-betroffene Chargen eingrenzen und damit Kosten und Verbraucherrisiken drastisch reduzieren.

8.1.6 Umwelt, Nachhaltigkeit und Kreislaufwirtschaft

Reduktion von Lebensmittelverschwendung. Weltweit werden ca. 1,3 Mrd. t Lebensmittel jährlich verschwendet (FAO 2011); ein erheblicher Anteil entfällt auf vermeidbare Qualitätsabwertungen in der Verarbeitungsstufe. Die im AGRI-GAIA-System nachgewiesene Reduktion des Rohstoffausschusses um 62,7 % deutet auf ein enormes Skalierungspotenzial hin: Eine flächendeckende Einführung analoger Systeme in der gesamten europäischen Lebensmittelverarbeitung könnte Millionen Tonnen Ausschuss jährlich verhindern.

Klimabilanz und CO₂-FuSSabdruck. Präzise Rohstoffallokation senkt nicht nur Energie- und Wasserverbrauch (nachgewiesen: –16,9 % Energieverbrauch in der Pilotanlage), sondern reduziert auch den Transportaufwand für ungeeignete Chargen. Durch Integration von Scope-3-Emissionsfaktoren in die MILP-Zielfunktion lässt sich die gesamte Kohlenstoffbilanz der Beschaffung minimieren – ein entscheidender Hebel für Unternehmen, die CO₂-Neutralitätsziele (Net Zero 2040/2050) verfolgen.

Biodiversitätsmonitoring und Ökosystemdienstleistungen. Qualitätsmessnetzwerke, die auf Feldbetrieben installiert werden, können sekundär Biodiversitätsindikatoren (Blütenbestand, Bodenfauna, Artenreichtum von Randzonen) über Bildanalyse und Akustikmonitoring erfassen. Dies ermöglicht eine integrierte Bewertung landwirtschaftlicher Nachhaltigkeit, die über produktive Qualitätsparameter hinausgeht und Ökosystemdienstleistungsindikatoren einschließt.

Kreislaufwirtschaft und Verwertung von Nebenprodukten. In der Kartoffelverarbeitung entstehen erhebliche Mengen an Schalen, Stärkeabwasser und Zelluloseanteilen. Eine KI-gestützte Klassifikation dieser Nebenprodukte nach ihrem Verwertungspotenzial – Biogassubstrat, Tierfuttermittel, technische Stärke, kompostierbare Fraktion – optimiert die Nebenprodukt-Wertschöpfungskette und schließt Kreisläufe im Sinne der EU-Bioökonomiestrategie.

Wasserverbrauch und Bewässerungseffizienz. Auf Feldebene erlaubt die AGRI-GAIA-Sensorinfrastruktur eine Kopplung mit Bodenfeuchtesensorik und Evapotranspirationsmodellen. Ein kombiniertes Optimierungsmodell für Bewässerungssteuerung und Qualitätsziel (Trockensubstanz, Nitratgehalt) würde Wasserverbrauch senken und gleichzeitig die Rohstoffqualität verbessern – in Wasserknappheitsregionen Südeuropas ein dringendes Anliegen.

8.1.7 Politik, Regulierung und Standardisierung

GAP-Konformität und Subventionsnachweis. Die EU-Gemeinsame Agrarpolitik (GAP) 2023/2027 verknüpft Direktzahlungen zunehmend mit Nachhaltigkeitsnachweisen (Konditionalitäten, Eco-Schemes). KI-basierte, sensorgestützte Nachweissysteme, die

Fruchtfolgevielfalt, Bodenbedeckung und Emissionsreduktionspotenziale objektiv dokumentieren, könnten als Compliance-Werkzeuge für Antragsteller und als Prüfwerkzeuge für Behörden dienen und die bisher kostenintensive administrative Kontrollen dichte reduzieren.

Lebensmittelrecht und Konformitätsprüfung. Behörden des amtlichen Lebensmittelüberwachungssystems (AVV-Rüb, EU-Lebensmittelbasisverordnung) könnten KI-Klassifikatoren als Vorsortierungswerkzeuge einsetzen: Chargen mit hohem Risikoscore (Mykotoxine, Pestizidrückstände) werden priorisiert zur aufwändigen Laboranalyse weitergeleitet, während Low-Risk-Chargen schneller freigegeben werden. Dies würde die Effizienz amtlicher Kontrollen erheblich steigern und die Reaktionsgeschwindigkeit bei Lebensmittelkrisen verbessern.

Standardisierung und Normung. Eine breite Adoption des AGRI-GAIA-Qualitätsvektors als offener Standard (z. B. via DIN/CEN/ISO-Norm für digitale Agrarqualitätsbeschreibungen) würde Interoperabilität zwischen verschiedenen Plattformen schaffen, Wettbewerb fördern und Herstellerabhängigkeiten vermeiden. Die Gaia-X-Infrastruktur bietet hierfür einen geeigneten Standardisierungsrahmen, der bereits auf EU-Ebene für Datenräume (Agri-Gaia, Catena-X) konsolidiert wird.

8.1.8 Gesellschaft, Globale Ernährungssicherheit und Entwicklungszusammenarbeit

Ernährungssicherheit und Subsistenzlandwirtschaft. Kleinbauern in Subsahara-Afrika, Südasien und Lateinamerika verlieren durch mangelhafte Nachernte-Infrastruktur je nach Schätzung 2040 % ihrer Ernte durch Qualitätsdegradation und Pilzbefall (Post-Harvest-Losses). Mobile, KI-gestützte Qualitätssysteme betrieben auf einfacher Smartphone-Hardware oder als Edge-KI auf preiswerten Embedded-Boards könnten Ernteproduzenten in der Lage versetzen, Qualitätsstandards zu erkennen und einzuhalten, die den Zugang zu formellen Märkten und Prämienpreisen ermöglichen. Dies würde einen direkten Beitrag zu SDG 2 (Zero Hunger) und SDG 8 (Decent Work and Economic Growth) leisten.

Humanitäre Hilfe und Katastrophenreaktion. In Krisen- und Katastrophensituationen Überschwemmungen, Dürren, Konflikte ist eine schnelle Qualitätsbewertung von Nahrungsmittelhilfslieferungen (World Food Programme, FAO) entscheidend, um verdorbene oder kontaminierte Waren von der Distribution auszuschließen. Leichtgewichtige KI-Klassifikatoren auf NGO-Geländefahrzeugen könnten Grundnahrungsmittel-Qualitätsprüfungen dezentralisieren und beschleunigen.

Öffentliche Gesundheit und Lebensmittelsicherheit. Mykotoxin-Kontaminationen (Aflatoxin B1, Fumonisin, DON) in Mais, Erdnüssen und Getreide verursachen weltweit erhebliche Gesundheitsschäden; die WHO schätzt, dass 25 % aller Nahrungsmittel kontaminiert sind. NIR-gestützte KI-Systeme, die im Feldversuch bereits vielversprechende Ergebnisse zur Aflatoxin-Frühdetektion zeigen, könnten in Kombination mit der AGRI-GAIA-Plattform zu globalen Lebensmittelsicherheitsnetzwerken ausgebaut werden.

Bildung, Ausbildung und Wissenstransfer. Landwirtschaftliche Berufsschulen und agrarwissenschaftliche Hochschulen könnten AGRI-GAIA-kompatible Sensorik und Planungstools als Lehr- und Forschungswerkzeuge einsetzen. Die offene Plattformarchitektur

(Gaia-X) erleichtert Open-Educational- Resource-Ansätze, bei denen Datensätze, Modelle und Algorithmen offen zugänglich gemacht werden. Studierenden und Auszubildenden stünden damit in der Praxis validierte KI-Systeme zur Verfügung, was Qualifikationslücken in der Agrardigitalisierung schließt.

8.1.9 Technologische Querschnittsthemen und Zukunftstrends

Edge-KI und Embedded Systems. Die Miniaturisierung von NIR-Sensorik (z. B. Texas Instruments DLP NIRscan Nano) und die Verfügbarkeit energieeffizienter KI-Beschleuniger (Google Coral TPU, NVIDIA Jetson, Qualcomm AI Hub) ermöglichen es, den trainierten Klassifikator direkt auf Edge-Geräten auszuführen am Mähdrescher, auf dem Förderband oder im Kühlfahrzeug. Die Latenz zwischen Sensorerfassung und Qualitätsentscheidung sinkt auf Millisekunden; eine Internetverbindung ist für die Klassifikation nicht mehr erforderlich. Die AGRI-GAIA-Plattform übernimmt dann ausschließlich das periodische Modell-Update per Over-the-Air-Deployment.

Multimodale Foundation Models. Large Vision-Language Models (GPT-4-Vision, Gemini, LLaVA) und domänenspezifische Agrar-Foundation-Models (z. B. auf Basis von SAM oder DINOv2, vorab auf Millionen agrarischer Bilder vortrainiert) bieten die Perspektive, dass ein einziges multimodales Modell Qualitätsfragen in natürlicher Sprache beantworten, Anomalien erklären und Planungsempfehlungen in verständlicher Form kommunizieren kann ohne domänenspezifisches Fine-Tuning für jede neue Kultur.

Reinforcement Learning für adaptives Scheduler. Während das MILP-Planungssystem exakte Lösungen für deterministische Instanzen liefert, stoßen Branch-and-Bound-Solver bei hochfrequenten, stochastischen Planungsproblemen (minutengenaues Produktionsjdwahl) an Laufzeitgrenzen. Tiefes Reinforcement Learning (Proximal Policy Optimization, Soft Actor-Critic), trainiert auf Simulationsumgebungen, die digitale Zwillinge der Produktionsanlage nutzen, könnten als komplementärer Ansatz langfristig den MILP-Solver für Echtzeitsituationen ersetzen oder ergänzen.

Erklärbare KI (XAI) und Vertrauen in Entscheidungen. Damit Landwirte, Qualitätsmanager und Auditoren KI-Klassifikationsentscheidungen akzeptieren, sind Erklärungen unabdingbar. Methoden wie SHAP (SHapley Additive exPlanations) und LIME (Local Interpretable Model-agnostic Explanations) lassen sich auf den ResNet-50-Klassifikator anwenden und würden zum Beispiel erklären: *Diese Charge wurde als Klasse B eingestuft, weil der NIR-Peak bei 1940 nm auf einen Trockensubstanzgehalt von 19,8 % hindeutet, was knapp unterhalb der Pommes-Frites-Anforderung liegt.* Solche Erklärungen stärken das Vertrauen in das System und erleichtern die regulatorische Anerkennung (EU AI Act, Kategorie "hohes Risiko").

Datensouveränität und europäische digitale Souveränität. Das Gaia-X-Framework des AGRI-GAIA-Systems ist explizit auf europäische Datensouveränität ausgerichtet. In einer Zeit, in der Agrardaten von US-amerikanischen und chinesischen Plattformbetreibern zunehmend zentralisiert werden (Bayer/Climate Corp, CNHI, Alibaba Agricultural Brain), stellt das offene, föderierte Ökosystem eine strategische Alternative dar. Eine Erweiterung

auf nationale Agrar-Datenräume, verknüpft mit dem europäischen Datenraum für Landwirtschaft (European Common Data Space for Agriculture), würde die technologische Souveränität Europas im Agrarsektor nachhaltig stärken.

Interoperabilität mit bestehenden Agrarmanagementsystemen. Bestehende Farm Management Information Systems (FMIS) wie 365FarmNet, Agrivi, Farmers Business Network und SAP Agriculture sind weit verbreitet. Eine Standardisierung der AGRI-GAIA-Schnittstellen (REST-APIs, GeoJSON, FIWARE-NGSI-LD) würde eine nahtlose Integration ermöglichen, ohne Betriebe zur Migration zu zwingen. Dadurch lieSSe sich die Adoptionskurve erheblich verkürzen und der Mehrwert des Systems sofort hebeln.

Resümee. Die vorstehende Übersicht zeigt, dass das AGRI-GAIA-Paradigma dezentrale KI-Qualifikation, formal garantierte Allokationsoptimierung und offene Plattformarchitektur eines der vielseitigsten und skalierfähigsten Konzepte der agrarischen Digitalisierung der letzten Dekade darstellt. Von der Pharmabotanik über die Zuckerfabrik, von der Warenbörse bis zur humanitären Lebensmittelhilfe, von der Klimafolgenforschung bis zur KI-gestützten Standardisierung in nahezu jedem rohstoffintensiven, qualitätskritischen Kontext lassen sich die Kernmethoden dieser Arbeit adaptieren, erweitern und mit messbarem Mehrwert einsetzen. Die systematische Erschließung dieser Potenziale ist Aufgabe eines interdisziplinären Forschungs- und Transferprogramms, das Agrar-, Ingenieur-, Informatik- und Wirtschaftswissenschaften dauerhaft verzahnt.

A Ergänzende Beweise und Ableitungen

A.1 Beweis der Lipschitz-Stetigkeit der Softmax-Funktion

Lemma A.1 (Lipschitz-Konstante der Softmax). *Die Softmax-Abbildung $\text{sm} : \mathbb{R}^K \rightarrow \Delta^{K-1}$, definiert durch $\text{sm}(\mathbf{z})_k = e^{z_k} / \sum_j e^{z_j}$, ist Lipschitz-stetig mit Konstante $L = 1$ bezüglich der Supremumsnorm.*

Beweis. Sei $J(\mathbf{z})$ die Jacobi-Matrix von sm . Für den k -ten Output gilt:

$$\frac{\partial \text{sm}(\mathbf{z})_k}{\partial z_j} = \text{sm}(\mathbf{z})_k (\delta_{kj} - \text{sm}(\mathbf{z})_j).$$

Damit ist $\|J(\mathbf{z})\|_\infty = \max_k \sum_j |J_{kj}|$. Für jede Zeile k :

$$\sum_j |J_{kj}| = \text{sm}_k(1 - \text{sm}_k) + \text{sm}_k \sum_{j \neq k} \text{sm}_j = \text{sm}_k(1 - \text{sm}_k) + \text{sm}_k(1 - \text{sm}_k) = 2 \text{sm}_k(1 - \text{sm}_k) \leq \frac{1}{2}.$$

Daher gilt $\|\text{sm}(\mathbf{z}) - \text{sm}(\mathbf{z}')\|_\infty \leq \frac{1}{2} \|\mathbf{z} - \mathbf{z}'\|_\infty \leq \|\mathbf{z} - \mathbf{z}'\|_\infty$, also $L \leq 1$. $\square$

A.2 MILP-Relaxation und LP-Bound

Durch Relaxation der Ganzzahligkeitsbedingung $z_{st} \in \{0, 1\}$ zu $z_{st} \in [0, 1]$ erhält man das LP-Relaxationsproblem KRBP-LP. Der optimale LP-Wert z_{LP}^* ist eine untere Schranke:

$$z_{\text{LP}}^* \leq z_{\text{MILP}}^*.$$

Die Integrality Gap ist in numerischen Experimenten auf $< 3\%$ beschränkt, was den Einsatz von Branch-and-Bound mit LP-Relaxationen als Schranke effizient macht.

B Pseudocode: MILP-Solver-Wrapper

Listing 1: Vereinfachter Python-Wrapper für den KRBP-MILP-Solver unter Verwendung von PuLP

```
1  import pulp
2  import numpy as np
3
4  def solve_krbp(costs, demand, supply, quality, weights,
5  q_min, lam=10.0):
6  """
7  Loest das KI-gestuetzte Rohstoffbeschaffungsproblem (KRBP).
8  Parameter:
9  costs      : (S x T) Kostenmatrix
10 demand     : (L x T) Bedarfsmatrix
11 supply      : (S x T) Verfuegbarkeit
12 quality     : (S x T x n) KI-geschaetzter Qualitaetsvektor
13 weights     : (L x n) Qualitaetsgewichte
14 q_min       : (L,) Mindestqualitaetsindex
15 """
16 S, T = costs.shape
17 L = demand.shape[0]
18 prob = pulp.LpProblem("KRBP", pulp.LpMinimize)
19
20 # Entscheidungsvariablen
21 x = [[pulp.LpVariable(f"x_{s}_{t}", 0) for t in range(T)]
22 for s in range(S)]
23 delta = [[pulp.LpVariable(f"d_{l}_{t}", 0) for t in range(T)]
24 for l in range(L)]
25
26 # Zielfunktion
27 prob += (pulp.lpSum(costs[s,t]*x[s][t]
28 for s in range(S) for t in range(T))
29 + lam*pulp.lpSum(delta[l][t]
30 for l in range(L) for t in range(T)))
31
32 # Nebenbedingungen
33 for t in range(T):
34 for l in range(L):
35 prob += (pulp.lpSum(x[s][t] for s in range(S))
36 >= demand[l,t])
37 for s in range(S):
38 prob += (pulp.lpSum(x[s][t] for l in range(L))
39 <= supply[s,t])
40 for s in range(S):
41 for l in range(L):
42 qi = np.dot(quality[s,t,:], weights[l,:])
43 prob += qi >= q_min[l] - delta[l][t]
44
45 prob.solve(pulp.PULP_CBC_CMD(msg=0))
46 return np.array([[pulp.value(x[s][t])
```

Literatur

- [1] ElMasry, G., Kamruzzaman, J., Sarker, B., & Anowar, I. (2012). *Detecting chilling injury in Red Delicious apple using hyperspectral imaging and neural networks*. Postharvest Biology and Technology, 61(23), 190200.
- [2] Su, W.-H., Sun, D.-W., He, J.-G., & Zhang, L.-D. (2017). *Variation description and assessment of spectrum-surface characteristic of potatoes (*Solanum tuberosum* L.) during storage by vis/NIR spectroscopy*. Journal of Food Engineering, 212, 1225.
- [3] Lu, B., Dao, P.D., Liu, J., He, Y., & Shang, J. (2020). *Recent advances of hyperspectral imaging technology and applications in agriculture*. Remote Sensing, 12(16), 2659.
- [4] McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B.A. (2017). *Communication-efficient learning of deep networks from decentralized data*. Proceedings of the 20th AISTATS, 12731282.
- [5] He, K., Zhang, X., Ren, S., & Sun, J. (2016). *Deep residual learning for image recognition*. Proceedings of CVPR, 770778.
- [6] Hornik, K., Stinchcombe, M., & White, H. (1989). *Multilayer feedforward networks are universal approximators*. Neural Networks, 2(5), 359366.
- [7] Ahumada, O., & Villalobos, J.R. (2009). *Application of planning models in the agri-food supply chain: A review*. European Journal of Operational Research, 196(1), 120.
- [8] Shukla, M., & Shankar, R. (2019). *Sustainable food supply chain: A sustainable development perspective*. Sustainable Production and Consumption, 18, 131143.
- [9] GAIA-X Association (2021). *GAIA-X: Technical Architecture*. Release 21.06. Brussels: GAIA-X AISBL.
- [10] Wernsing Feinkost GmbH (2023). *Interner Bericht: Rohstofflogistik und Qualitätsmanagement*. Unveröffentlicht.