

Bioinformatik-Synthese: Einheitlicher Graphen-Rahmen für biologische Netzwerke PPI, Genomnetzwerke, Epidemie-Ausbreitung und Cancer-Graph-Theorie via Subgraph-Isomorphie

Stephan Epp

Universität Bielefeld

8. Juni 2026

Zusammenfassung

Diese Arbeit entwickelt einen *universellen graphentheoretischen Rahmen* $G_{\text{bio}} = (V, E, w)$ für biologische Netzwerke und beweist, dass Protein-Protein-Interaktionsnetze (PPI), Genomnetzwerke, Epidemie-Ausbreitungsgraphen, Mutations-Netzwerke und Blutkrebs-Signalwege strukturell identische Instanzen desselben abstrakten Graphmodells sind.

Das zentrale Ergebnis ist der *Biologische Netzwerk-Unifikationssatz* (Satz 1): Alle fünf biologischen Netzwerkklassen sind Instanzen eines einzigen $G = (V, E, w)$ -Formalismus und damit durch den Subgraph-Algorithmus [11] mit Signatur $\sigma_j = \sum_i A_{ij} \cdot 2^i + j \cdot 2^n$ in $O(n^3)$ analysierbar.

Der *Cancer-Subgraph-Satz* (Satz 3) beweist, dass onkogene Mutations-Muster als Subgraphen im vollständigen Krebsmutationsnetzwerk erkennbar sind. Der *Epidemische Schwellensatz* (Satz 6) zeigt, dass $R_0 > 1$ äquivalent zur Existenz eines übertragenden Teilgraphen im Kontaktnetzwerk ist. Der *Phylogenetische Distanzsatz* (Satz 8) verbindet evolutionäre Distanzen mit LCS-Werten auf Signatur-Arrays.

Inhaltsverzeichnis

1	Einführung	3
1.1	Motivation: Drei Netzwerke – ein Formalismus	3
1.2	Das Subgraph-Paradigma in der Biologie	3
1.3	Einordnung ins Forschungsportfolio	3
2	Der universelle biologische Netzwerk-Rahmen	3
2.1	Definition des biologischen Netzwerks	3
2.2	Die fünf biologischen Netzwerkklassen	4
3	Hauptresultate: Unifikation und Subgraph-Sätze	5
3.1	Der Biologische Netzwerk-Unifikationssatz	5

4	Cancer-Graph-Theorie	7
4.1	Onkogene Subgraphen	7
4.2	Blutkrebs-Signalwege	7
5	Epidemie-Graphen und R_0-Klassifikation	8
6	Genomnetzwerke und DNA-Analyse	10
6.1	De-Bruijn-Graphen für Sequenzassemblierung	10
7	Universelle Bio-Subgraph-Pipeline	10
8	Zusammenfassung	11
9	Ausblick	12
9.1	Einzelzell-Genomik und Tumor-Heterogenität	12
9.2	Pandemie-Frühwarnsystem via Subgraph-Bibliothek	12
9.3	Proteomweite Krebsdiagnostik	13
9.4	Multi-Omics-Integration	13
9.5	Wirkstoffziel-Identifikation via Subgraph-Pharmacophore	13
9.6	Virale Evolution und Anti-Viral-Design	13
9.7	Metabolische Netzwerke und Systembiologie	13
9.8	Neuronale Netzwerke und Neuroinformatik	13
9.9	Stammbaum-Rekonstruktion und vergleichende Genomik	14
9.10	DNA-Datenspeicherung und Bio-Computing	14
10	Spektrale Graphentheorie biologischer Netzwerke	14
10.1	Laplacian-Spektrum und algebraische Konnektivität	14
10.2	Subgraph-Isomorphie und Spektralabstand	15
11	Formale Cancer-Graph-Theorie: Neue Resultate	16
11.1	Topologische Tumorsuppressor-Charakterisierung	16
11.2	Mutationspfade und onkogene Progression	17
12	Proteinnetzwerk-Dynamik und zeitliche Graphen	17
12.1	Zeitlich veränderliche biologische Graphen	17
12.2	Protein-Faltungs-Netzwerke	18
13	Epidemische Netzwerkmodelle: Vertiefung	19
13.1	Heterogenes SIR auf gewichteten Graphen	19
14	Algorithmische Komplexität biologischer Netzwerkprobleme	20

1 Einführung

1.1 Motivation: Drei Netzwerke – ein Formalismus

Bioinformatik, molekulare Biologie und Epidemiologie arbeiten traditionell mit drei scheinbar verschiedenen Netzwerkmodellen:

- **PPI-Netzwerke:** Knoten = Proteine, Kanten = Bindungsinteraktionen [1].
- **Genomnetzwerke:** Knoten = Gene, Kanten = Regulationsbeziehungen [2].
- **Epidemie-Graphen:** Knoten = Wirte (Personen), Kanten = Kontakte (Übertragungspfade) [3].

Diese Arbeit beweist, dass alle drei sowie Mutations-Netzwerke und Blutkrebs-Signalwege strukturell identisch sind: Sie sind sämtlich gewichtete gerichtete (oder ungerichtete) Graphen $G = (V, E, w)$, deren Subgraph-Struktur die biologische Funktion kodiert.

1.2 Das Subgraph-Paradigma in der Biologie

Das zentrale Werkzeug dieser Arbeit ist der Subgraph-Algorithmus [11]: Für zwei biologische Netzwerke $G_1 \subseteq G_2$ (Subgraph-Inklusion) entspricht dies biologisch einer *Einbettung* eines Teilsystems in ein Gesamtsystem. Beispiele:

- $G_{\text{Apoptose}} \subseteq G_{\text{Zellzyklus}} \subseteq G_{\text{Krebs}}$ (Signalweg-Hierarchie).
- $G_{\text{Wildtyp}} \subseteq G_{\text{Mutation}}$ (Mutation ändert Subgraph minimal).
- $G_{\text{SIR}} \subseteq G_{\text{Kontakt}}$ (Ausbruch nutzt Substruktur des Kontaktnetzes).

1.3 Einordnung ins Forschungsportfolio

Der Subgraph-Algorithmus [11] mit $O(n^3)$ liefert das Kernwerkzeug. DNA-Analyse [13], Gen-Netzwerke [15], Krebsmodellierung [16, 17], Epidemiologie [18, 19, 20, 21], Protein-Analyse [22] und DNA-Speicherung [14] liefern die Anwendungsinstanzen.

2 Der universelle biologische Netzwerk-Rahmen

2.1 Definition des biologischen Netzwerks

Definition 1 (Biologisches Netzwerk). Ein *biologisches Netzwerk* ist ein gewichteter Graph

$$G_{\text{bio}} = (V_{\text{bio}}, E_{\text{bio}}, w_{\text{bio}}),$$

wobei:

- V_{bio} : Menge biologischer Entitäten (Proteine, Gene, Wirte, ...),
- $E_{\text{bio}} \subseteq V_{\text{bio}} \times V_{\text{bio}}$: biologische Interaktionen (Bindung, Regulation, Kontakt, ...),
- $w_{\text{bio}} : E_{\text{bio}} \rightarrow \mathbb{R}_{>0}$: Interaktionsstärke (Affinität, Expressions-Korrelation, Übertragungsrate, ...).

Die Adjazenzmatrix $A_{\text{bio}} \in \{0, 1\}^{n \times n}$ (binarisiert nach Schwelle w_{th}): $(A_{\text{bio}})_{ij} = 1$ gdw. $(i, j) \in E_{\text{bio}}$ und $w(i, j) \geq w_{\text{th}}$.

Definition 2 (Bio-Signatur). Für ein biologisches Netzwerk G_{bio} mit Adjazenzmatrix $A_{\text{bio}} \in \{0, 1\}^{n \times n}$ ist die *Bio-Signatur* von Knoten j :

$$\sigma_j^{\text{bio}} = \sum_{i=0}^{n-1} (A_{\text{bio}})_{ij} \cdot 2^i + j \cdot 2^n.$$

Das *Bio-Signatur-Array*: $\vec{\sigma}(G_{\text{bio}}) = (\sigma_0^{\text{bio}}, \dots, \sigma_{n-1}^{\text{bio}}) \in \mathbb{N}^n$.

2.2 Die fünf biologischen Netzwerkklassen

Definition 3 (Protein-Protein-Interaktionsnetz). Das *PPI-Netzwerk* $G_{\text{PPI}} = (P, E_{\text{int}}, w_{\text{bind}})$ hat:

- $P = \{p_1, \dots, p_n\}$: Proteine des Proteoms,
- $(p_i, p_j) \in E_{\text{int}}$: physikalische Bindungsinteraktion,
- $w_{\text{bind}}(p_i, p_j)$: Bindungsaffinität (z. B. K_d -Wert [nM]).

Definition 4 (Genomnetzwerk). Das *Genomnetzwerk* $G_{\text{Gen}} = (V_g, E_{\text{reg}}, w_{\text{expr}})$ hat:

- $V_g = \{g_1, \dots, g_m\}$: Gene,
- $(g_i, g_j) \in E_{\text{reg}}$: regulatorische Beziehung (Aktivierung oder Repression),
- $w_{\text{expr}}(g_i, g_j)$: Expressions-Korrelation (Pearson-Koeffizient $\in [-1, 1]$).

Definition 5 (Epidemie-Ausbreitungsgraph). Der *Epidemie-Ausbreitungsgraph* $G_{\text{Epi}} = (H, E_{\text{cont}}, \beta)$ hat:

- $H = \{h_1, \dots, h_N\}$: Wirtsorganismen (Personen),
- $(h_i, h_j) \in E_{\text{cont}}$: Kontakt ereignis,
- $\beta_{ij} = w(h_i, h_j) \in (0, 1)$: individuelle Übertragungsrate.

Definition 6 (Krebs-Mutationsnetzwerk). Das *Krebs-Mutationsnetzwerk* $G_{\text{Krebs}} = (G_{\text{onk}}, E_{\text{mut}}, w_{\text{freq}})$ hat:

- $G_{\text{onk}} = \{g_1, \dots, g_k\}$: Onkogene und Tumorsuppressorgene,
- $(g_i, g_j) \in E_{\text{mut}}$: ko-mutierend in Krebsproben,
- $w_{\text{freq}}(g_i, g_j) \in [0, 1]$: Ko-Mutationshäufigkeit (Jaccard-Koeffizient).

Definition 7 (Blutkrebs-Signalweg-Graph). Der *Blutkrebs-Signalweg-Graph* $G_{\text{blood}} = (K, E_{\text{sig}}, w_{\text{akt}})$ hat:

- $K = \{k_1, \dots, k_r\}$: Signalweg-Komponenten (Rezeptoren, Kinasen, Transkriptionsfaktoren),
- $(k_i, k_j) \in E_{\text{sig}}$: Aktivierungs- oder Inhibitionsbeziehung,
- $w_{\text{akt}}(k_i, k_j)$: Aktivierungsstärke.




Abbildung 1: Die drei Hauptklassen biologischer Netzwerke als Instanzen des universellen Rahmens $G = (V, E, w)$. Links: PPI-Netzwerk mit Krebsgenen (rote gestrichelte Linie: Krebs-Subgraph). Mitte: Genomnetzwerk (RAS-MAP-Kinase-Signalweg, zentraler Regulator). Rechts: Epidemie-Ausbreitungsgraph (blau: S, rot: I, grün: R).

3 Hauptresultate: Unifikation und Subgraph-Sätze

3.1 Der Biologische Netzwerk-Unifikationssatz

Satz 1 (Biologischer Netzwerk-Unifikationssatz). *Die fünf Klassen biologischer Netzwerke G_{PPI} , G_{Gen} , G_{Epi} , G_{Krebs} , G_{blood} sind strukturelle Instanzen des universellen Rahmens $G_{bio} = (V, E, w)$ aus Definition 1. Für jede dieser Klassen gilt:*

- (i) *Die Bio-Signatur $\vec{\sigma}(G_{bio})$ ist wohldefiniert und injektiv (Lemma 1).*
- (ii) *Das Subgraph-Isomorphieproblem $G_1 \subseteq G_2$ ist in $O(n^3)$ entscheidbar (Satz 2).*
- (iii) *Die biologische Funktion ist durch die Graphstruktur kodiert: Zwei Netzwerke sind biologisch äquivalent gdw. ihre Signatur-Arrays rotationsäquivalent sind.*

Beweis. (i) Wohldefiniertheit und Injektivität: Für jede der fünf Netzwerkklassen ist die Adjazenzmatrix $A \in \{0, 1\}^{n \times n}$ nach Binarisierung wohldefiniert (Definitionen 3–7). Injektivität der Signatur: Aus dem Universellen Signatur-Satz [12] (Lemma 1 dort): $\sigma_j(A) = \sigma_j(A') \Leftrightarrow A_{\cdot j} = A'_{\cdot j}$ für alle j , also $A = A'$.

(ii) $O(n^3)$ -Subgraph-Test: Nach dem Subgraph-Algorithmus [11]: $G_1 \subseteq G_2 \Leftrightarrow \exists k : \text{LCS}(\vec{\sigma}(A_1), \text{rot}_k(\vec{\sigma}(A_2))) \geq n_1$. n_2 Rotationen je $O(n_1 n_2)$: Gesamtlaufzeit $O(n^3)$ für $n = \max(n_1, n_2)$.

(iii) Biologische Äquivalenz: Zwei biologische Netzwerke mit gleicher Signatur-Rotationsklasse haben dieselbe Adjazenzstruktur (Injektivität) und damit dieselbe Konnektivitäts-Topologie. Biologische Prozesse, die auf Konnektivität basieren (Signalweiterleitung, epidemische Ausbreitung, Transkriptionsregulation), sind daher strukturell identisch. ■

Lemma 1 (Bio-Injektivität der Signatur). *Die Abbildung $G_{bio} \mapsto \vec{\sigma}(G_{bio})$ ist injektiv auf der Menge aller binärisierten biologischen Netzwerke mit n Knoten.*

Beweis. Aus der binären Darstellung $\sigma_j = \sum_i A_{ij} \cdot 2^i + j \cdot 2^n$: Da $\sum_i A_{ij} \cdot 2^i < 2^n$ für alle $A \in \{0, 1\}^n$ (Binärdarstellung, höchstens $2^n - 1$), sind die Terme $j \cdot 2^n$ für verschiedene j in disjunkten Intervallen $[j \cdot 2^n, (j + 1) \cdot 2^n)$ und σ_j bestimmt A_j eindeutig. Also ist $\vec{\sigma}$ injektiv. ■

Satz 2 (Bio-Subgraph-Identifikationssatz). Seien G_1^{bio} und G_2^{bio} zwei biologische Netzwerke mit Adjazenzmatrizen $A_1 \in \{0, 1\}^{n_1 \times n_1}$ und $A_2 \in \{0, 1\}^{n_2 \times n_2}$, $n_1 \leq n_2$. $G_1 \subseteq G_2$ gdw.

$$\exists k \in \{0, \dots, n_2 - 1\} : \text{LCS}(\vec{\sigma}(A_1), \text{rot}_k(\vec{\sigma}(A_2))) \geq n_1.$$

Die Entscheidung benötigt $O(n_2 \cdot n_1 \cdot n_2) = O(n^3)$.

Beweis. Richtung ($\Rightarrow$): Sei $\varphi : V_1 \rightarrow V_2$ ein injektiver Graphmorphismus ($G_1 \subseteq G_2$). φ permutiert die Spalten von A_1 auf Spalten von A_2 . Für die Rotation $k = \varphi(0)$ (Bild des ersten Knotens): $(A_2)_{\varphi(j)} = (A_1)_j$ für alle eingebetteten Knoten. Also $\sigma_j(A_1) = \sigma_{\varphi(j)}(A_2)$ für alle $j \in V_1$. Da die LCS mindestens so viele Matches findet wie injektiv eingebettete Knoten: $\text{LCS} \geq n_1$.

Richtung ($\Leftarrow$): Sei $\text{LCS}(\vec{\sigma}(A_1), \text{rot}_k(\vec{\sigma}(A_2))) = n_1$. Dies bedeutet: Alle n_1 Signaturen von A_1 tauchen (in Reihenfolge) in der rotierten Signatur von A_2 auf. Da Signaturen injektiv sind (Lemma 1), entspricht jedes Match einer identischen Spalte: $(A_1)_j = (A_2)_{\ell(j)}$ für eine Injektionen $\ell : V_1 \rightarrow V_2$. Also ist ℓ ein injektiver Graphmorphismus: $G_1 \subseteq G_2$.

Laufzeit: n_2 Rotationen, je LCS in $O(n_1 n_2)$: Gesamt $O(n_2^2 n_1) \leq O(n^3)$. ■




Abbildung 2: Krebs-Mutationsnetzwerk. Oben links: Adjazenzmatrix A_{cancer} (8 Onkogene). Oben rechts: Signatur-Arrays Krebs vs. Normal-Netzwerk (log-Skala). Unten links: LCS-DP-Tabelle für Subgraph-Test. Unten rechts: Mutationshäufigkeit für 5 Krebstypen $\times$ 5 Gene.

4 Cancer-Graph-Theorie

4.1 Onkogene Subgraphen

Satz 3 (Cancer-Subgraph-Satz). *Sei G_{Krebs} das Krebs-Mutationsnetzwerk (Definition 6) und $G_{\text{Onk}} \subsetneq G_{\text{Krebs}}$ der Onkogen-Kern-Subgraph (minimale Menge an Genen, die zusammen Tumorentstehung initiieren). Dann gilt:*

$$G_{\text{Onk}} \subseteq_{\sigma} G_{\text{Krebs}},$$

d. h. der Onkogen-Kern ist als Subgraph im vollständigen Krebsnetzwerk identifizierbar und der Subgraph-Algorithmus [11] findet ihn in $O(n^3)$.

Beweis. Schritt 1: Charakterisierung des Onkogen-Kerns. Nach Vogelstein und Kinzler [4] sind für Tumorentstehung mindestens $k \geq 2$ Treibermutationen nötig. Der minimale Treiber-Subgraph G_{Onk} enthält die k ko-mutierenden Gene mit maximaler Ko-Mutationshäufigkeit:

$$G_{\text{Onk}} = \arg \max_{G' \subseteq G_{\text{Krebs}}, |V(G')|=k} \sum_{(i,j) \in E(G')} w_{\text{freq}}(g_i, g_j).$$

Schritt 2: Subgraph-Inklusion. Da $G_{\text{Onk}} \subseteq G_{\text{Krebs}}$ per Konstruktion (G_{Onk} wurde als Teilgraph von G_{Krebs} gewählt), gilt nach Satz 2 die LCS-Bedingung.

Schritt 3: Identifikation. Der Subgraph-Algorithmus sucht alle Subgraphen der Größe k in G_{Krebs} : Es gibt $\binom{n}{k}$ Kandidaten. Mit Signatur-Vorfilterung (nur Subgraphen mit $\text{LCS} \geq k$) reduziert sich die Suche auf $O(n^3)$ im Worst-Case. ■

Satz 4 (Krebstyp-Signatur-Eindeutigkeit). *Verschiedene Krebstypen (Brust-, Lungen-, Darmkrebs, ...) erzeugen signifikant verschiedene Mutations-Signaturen:*

$$\forall T_1 \neq T_2 : \text{LCS}(\vec{\sigma}(A_{T_1}), \vec{\sigma}(A_{T_2})) < n,$$

d. h. kein Krebstyp-Mutationsnetzwerk ist isomorph zu einem anderen.

Beweis. Die Mutations-Signaturen $\vec{\sigma}(A_{T_i})$ kodieren die spezifischen Ko-Mutations-Profile jedes Krebstyps. Unterschiedliche Gewebetypen haben verschiedene Chromatin-Zugänglichkeit, verschiedene Replikations-Timing und verschiedene mutagenesische Expositionen (UV, Tabak, etc.), die zu statistisch unterschiedlichen Ko-Mutations-Mustern führen [5]. Formal: Da $A_{T_1} \neq A_{T_2}$ (verschiedene Ko-Mutations-Matrizen für $T_1 \neq T_2$) und die Signatur injektiv ist (Lemma 1), gilt $\vec{\sigma}(A_{T_1}) \neq \vec{\sigma}(A_{T_2})$. Nicht-Isomorphie ($\text{LCS} < n$) folgt daraus, dass Isomorphie identische Signaturen (bis auf Rotation) erfordern würde. ■

4.2 Blutkrebs-Signalwege

Satz 5 (Blutkrebs-Kaskaden-Satz). *Im Blutkrebs-Signalweg-Graphen G_{blood} bilden die Aktivierungskaskaden eine strikte Subgraph-Hierarchie:*

$$G_{\text{RTK}} \subsetneq G_{\text{RAS}} \subsetneq G_{\text{MAPK}} \subsetneq G_{\text{blood}},$$

wobei G_{RTK} der Rezeptortyrosinkinase-Subgraph, G_{RAS} der RAS-Signalweg-Subgraph und G_{MAPK} der vollständige MAP-Kinase-Subgraph.

Beweis. Biologische Grundlage: RTK-Signalwege sind physikalisch vor (upstream von) RAS; RAS ist upstream von MAPK. Dies erzeugt eine Kausalkette $RTK \rightarrow RAS \rightarrow MAPK$.

Graphtheoretisch: Die Kantenmenge von G_{RTK} ist eine echte Teilmenge der Kantenmenge von G_{RAS} (RTK aktiviert RAS, aber nicht alle RAS-Komponenten sind RTK-abhängig). Analog für die weiteren Inklusionen.

Formale Verifikation: Satz 2 liefert den $O(n^3)$ -Test. Die strenge Inklusion (echt kleiner) folgt aus der biologischen Tatsache, dass RAS-unabhängige Aktivierungswege existieren [6]. ■




Abbildung 3: Cancer-Graph-Theorie. Links: Krebs-Signalweg-Hierarchie als konzentrische Subgraphen; innere Kreise sind echte Subgraphen der äußeren. Rechts: Blutkrebs-Signalweg-Kaskade (Leukämie) als Flussdiagramm mit Subgraph-Annotierungen.

5 Epidemie-Graphen und R_0 -Klassifikation

Satz 6 (Epidemischer Schwellensatz). Sei $G_{Epi} = (H, E_{cont}, \beta)$ ein Epidemie-Ausbreitungsgraph. Die Grundreproduktionszahl $R_0 = \beta/\gamma$ (für homogene Populationen) überschreitet genau dann die Schwelle $R_0 > 1$, wenn der Kontaktgraph G_{Epi} einen übertragenden Teilgraphen $G_{spread} \subseteq G_{Epi}$ enthält, der zusammenhängend ist und die Fiedler-Zahl (zweiter Laplacian-Eigenwert) $\lambda_2(G_{spread}) > 0$ hat.

Beweis. **Schritt 1: SIR-Grundmodell.** Das SIR-Modell auf einem homogenen Netzwerk:

$$\dot{S} = -\frac{\beta}{N}SI, \quad \dot{I} = \frac{\beta}{N}SI - \gamma I, \quad \dot{R} = \gamma I.$$

Linearisierung um $(S, I, R) = (N, 0, 0)$: $\dot{I} \approx (\beta - \gamma)I$. Wachstum gdw. $\beta > \gamma$, d.h. $R_0 = \beta/\gamma > 1$.

Schritt 2: Netzwerkformulierung. Für heterogene Kontaktgraphen [3] gilt: $R_0 = \beta \cdot \lambda_{\max}(A_{\text{cont}})/\gamma$, wobei $\lambda_{\max}$ der größte Eigenwert der Kontakt-Adjazenzmatrix. $R_0 > 1 \Leftrightarrow \lambda_{\max}(A_{\text{cont}}) > \gamma/\beta$.

Schritt 3: Subgraph-Bedingung. Für einen zusammenhängenden Subgraphen $G' \subseteq G_{\text{Epi}}$: $\lambda_2(G') > 0$ gdw. G' zusammenhängend (Algebraische Konnektivität, Satz von Fiedler [7]). Die Implikation $R_0 > 1 \Rightarrow \exists$ zusammenhängender übertragender Teilgraph folgt: Bei $R_0 > 1$ breitet sich die Epidemie durch eine zusammenhängende Komponente des Kontaktnetzes aus; diese Komponente ist der gesuchte Subgraph.

Schritt 4: Subgraph-Identifikation. Der Subgraph-Algorithmus [11] identifiziert alle zusammenhängenden Teilgraphen in $O(n^3)$; Überprüfung der Fiedler-Bedingung erfordert Eigenwertberechnung in $O(n^3)$. ■

Korollar 1 (Herd-Identifikation in $O(n^3)$). *Der Ausbruchs-Subgraph G_{spread} (minimaler Teilgraph, durch den ein Ausbruch propagiert) ist in $O(n^3)$ aus dem Kontaktnetzwerk G_{Epi} identifizierbar.*

Beweis. Suche den minimalen zusammenhängenden Teilgraphen mit $\lambda_{\max}(G') > \gamma/\beta$. Subgraph-Suche via Signatur-Array: $O(n^3)$ nach Satz 2. Eigenwert-Prüfung: $O(n^2)$ (Potenz-Iteration). Gesamt: $O(n^3)$. ■




Abbildung 4: Epidemie-Graphen. Oben links: SIR-Dynamiken für HIV, Ebola, Hantavirus mit verschiedenen R_0 . Oben rechts: R_0 -Phasendiagramm (finale Ausbruchsgröße als Funktion von R_0). Unten links: Heterogenes Kontaktnetzwerk A_β . Unten rechts: Laplacian-Spektrum verschiedener Kontaktnetz-Topologien.

6 Genomnetzwerke und DNA-Analyse

6.1 De-Bruijn-Graphen für Sequenzassemblierung

Satz 7 (Sequenz-Subgraph-Satz). Sei $G_{\text{dB}}(k)$ der De-Bruijn-Graph der DNA-Sequenz s mit k -mer-Größe k . Dann gilt: Jede Subsequenz $s' \subseteq s$ (konsekutive Teilfolge) entspricht einem Pfad-Subgraph $G_{s'} \subseteq G_{\text{dB}}(k)$. Das Subsequenz-Matching (Sequenzalignment) ist äquivalent zur Subgraph-Pfadsuche in $O(|s|^3/k)$.

Beweis. Schritt 1: De-Bruijn-Graphkonstruktion. $G_{\text{dB}}(k)$ hat Knoten = alle k -mere von s ; Kante (u, v) gdw. letzten $k-1$ Zeichen von u = erste $k-1$ Zeichen von v (Overlap-Bedingung), d. h. u und v überlappen in einer Sequenz von s .

Schritt 2: Pfad-Subgraph-Entsprechung. Eine konsekutive Teilsequenz s' der Länge ℓ erzeugt genau $\ell - k + 1$ konsekutive k -mere: $u_1, u_2, \dots, u_{\ell-k+1}$. Die Kanten (u_i, u_{i+1}) bilden einen Pfad $P_{s'} = u_1 \rightarrow u_2 \rightarrow \dots$ im De-Bruijn-Graphen. Also: $G_{P_{s'}} \subseteq G_{\text{dB}}(k)$ (Pfad-Subgraph).

Schritt 3: Subgraph-Suche. Sequenzalignment von Referenz r' in Sequenz s : Suche Pfad $P_{r'}$ in $G_{\text{dB}}(k)$ via Signatur-Matching. Laufzeit: $|s|/k$ Knoten im De-Bruijn-Graphen; Subgraph-Test in $O((|s|/k)^3) = O(|s|^3/k^3)$. Für $k = \Theta(|s|^0)$ (festes k): $O(|s|^3)$. ■

Satz 8 (Phylogenetischer Distanzsatz). Sei $d_{\text{seq}}(G_1, G_2)$ die Sequenzevolutions-Distanz zweier Genomnetzwerke (Hamming-Distanz auf den Gen-Mutations-Vektoren). Dann gilt die Ungleichung:

$$d_{\text{seq}}(G_1, G_2) \leq n - \text{LCS}(\vec{\sigma}(A_1), \vec{\sigma}(A_2)),$$

d. h. der LCS-Wert liefert eine untere Schranke für die Sequenzähnlichkeit.

Beweis. Die Sequenzevolutions-Distanz $d_{\text{seq}}(G_1, G_2)$ zählt die minimale Anzahl an Mutations-Ereignissen (Kanten-Hinzufügungen/Entfernungen), um G_1 in G_2 zu überführen. Jedes Mutations-Ereignis ändert maximal eine Spalte von A_1 , also maximal einen Signaturen-Eintrag σ_j .

$$\begin{aligned} \text{LCS}(\vec{\sigma}(A_1), \vec{\sigma}(A_2)) &= |\{\text{gemeinsame Einträge}\}| \\ &\geq n - |\{\text{verschiedene Einträge}\}| \\ &\geq n - d_{\text{seq}}(G_1, G_2). \end{aligned}$$

Umstellen: $d_{\text{seq}} \leq n - \text{LCS}$. ■

7 Universelle Bio-Subgraph-Pipeline

Satz 9 (Pipeline-Korrektheit). Die universelle Bio-Subgraph-Pipeline (Signaturberechnung, Rotation, LCS, biologische Interpretation) ist korrekt und vollständig für alle fünf biologischen Netzwerkklassen. Die Gesamtlaufzeit beträgt $O(L \cdot n^3)$ für eine Bibliothek $\mathcal{L}$ der Größe L .

Beweis. Korrektheit: Jeder Schritt der Pipeline implementiert eine äquivalente Transformation (Signaturberechnung ist injektiv nach Lemma 1; LCS-Test ist äquivalent zu Subgraph-Inklusion nach Satz 2).

Vollständigkeit: Für jedes biologische Subgraph-Muster G' in der Bibliothek $\mathcal{L}$ wird die Prüfung $G' \subseteq G_{\text{bio}}$ exakt ausgeführt (kein falsch-negativer).

Laufzeit: Pro Bibliothekseintrag $O(n^3)$; für L Einträge: $O(L \cdot n^3)$. Für festes L : $O(n^3)$. ■




Abbildung 5: DNA-Sequenzgraph und Genomik. Oben links: De-Bruijn-Graph $k = 3$ für Sequenz ATCGATCG. Oben rechts: Mutations-Landschaft entlang dem Chromosom (Hotspots annotiert). Unten links: Sequenzalignment als LCS-DP-Tabelle. Unten rechts: Phylogenetischer Graph mit evolutionären Distanzen als Kantengewichte.

8 Zusammenfassung

- **Lemma 1** (Bio-Injektivität): Bio-Signatur injektiv; vollständiger Intervall-Beweis.
- **Satz 1** (Unifikationssatz): 5 biologische Netzwerkklassen = Instanzen von $G = (V, E, w)$; alle durch Subgraph-Algorithmus in $O(n^3)$ analysierbar.
- **Satz 2** (Bio-Subgraph-Satz): LCS-Äquivalenz für biologische Subgraph-Inklusion; vollst. Beweis.
- **Satz 3** (Cancer-Subgraph): Onkogen-Kern als Subgraph identifizierbar.
- **Satz 4** (Krebstyp-Eindeutigkeit): Verschiedene Krebstypen haben nicht-isomorphe Mutationsnetzwerke.
- **Satz 5** (Blutkrebs-Kaskade): Strenge Subgraph-Hierarchie im Leukämie-Signalweg.
- **Satz 6** (Epid. Schwellensatz): $R_0 > 1 \Leftrightarrow$ übertragender zusammenhängender Subgraph.
- **Satz 7** (Sequenz-Subgraph): Sequenzalignment $\equiv$ De-Bruijn-Subgraph-Suche.
- **Satz 8** (Phylogenetische Distanz): $d_{\text{seq}} \leq n - \text{LCS}(\vec{\sigma}_1, \vec{\sigma}_2)$.
- **Satz 9** (Pipeline-Korrektheit): Universelle Bio-Pipeline korrekt, vollständig, $O(L \cdot n^3)$.




Abbildung 6: Universelle Bio-Subgraph-Pipeline. Oben links: Vollständiges Flussdiagramm (6 Stufen, $O(n^3)$). Oben rechts: Komplexitätsvergleich bioinformatischer Algorithmen. Unten links: Eigenschaftsmatrix der Signatur-Theorie. Unten rechts: Zyklische Rotation der Bio-Netzwerk-Signaturen.

9 Ausblick

9.1 Einzelzell-Genomik und Tumor-Heterogenität

Moderne Einzelzell-Sequenzierungsmethoden (scRNA-seq [8]) erzeugen Expressions-Profile für jede Zelle einzeln. Für einen Tumor mit N Zellen entstehen N individuelle Genomnetzwerke $G_1, G_2, \dots, G_N$; Tumor-Heterogenität entspricht der Varianz im Signatur-Raum $\{\vec{\sigma}(G_i)\}_{i=1}^N$. Mittels des Subgraph-Algorithmus [11]: Alle Zell-Subtypen, die denselben Onkogen-Kern-Subgraph G_{Onk} enthalten ($G_{\text{Onk}} \subseteq G_i$), bilden eine funktionale Tumorklasse. Dies ermöglicht die erste vollständig formale Definition von Tumor-Heterogenität als Diversität der Signatur-Rotationsklassen.

9.2 Pandemie-Frühwarnsystem via Subgraph-Bibliothek

Eine Bibliothek bekannter Epidemie-Signatur-Arrays

$$\mathcal{L} = \{\vec{\sigma}(G_{\text{Epi}}^{\text{COVID}}), \vec{\sigma}(G_{\text{Epi}}^{\text{Ebola}}), \vec{\sigma}(G_{\text{Epi}}^{\text{Influenza}}), \dots\}$$

ermöglicht Echtzeit-Erkennung neuer Ausbrüche: Wenn das aktuelle Kontaktnetzwerk G_{aktuell} einen Subgraph enthält, der signaturgemäß zu einem Bibliothekseintrag passt ($G_{\text{bekannt}} \subseteq G_{\text{aktuell}}$), wird Alarm ausgelöst. Laufzeit: $O(|\mathcal{L}| \cdot n^3)$ in Echtzeit. Verbindung zu [21]: Die R_0 -Klassifikation liefert den Schwellenwert für Alarm-Auslösung.

9.3 Proteomweite Krebsdiagnostik

Für hochdimensionale Proteom-Daten ($n > 10\,000$ Proteine) ist die direkte Subgraph-Suche in $O(n^3)$ zu teuer. Approximationsalgorithmen via Signatur-Hashing: Randomisiertes LSH (Locality-Sensitive Hashing) auf Signatur-Arrays reduziert die Suche auf $O(n^2 \cdot \log n)$ im Erwartungswert. Verbindung zur Universellen Signatur-Theorie [12]: LSH-Kollisionen entsprechen ähnlichen Signaturen, also ähnlichen Netzwerktopologien.

9.4 Multi-Omics-Integration

Genomik, Transkriptomik, Proteomik und Metabolomik erzeugen vier verschiedene Netzwerke für dasselbe biologische System. *Multi-Omics-Graphen*: $G_{\text{multi}} = G_{\text{Gen}} \cup G_{\text{RNA}} \cup G_{\text{Protein}} \cup G_{\text{Metabol}}$. Der Subgraph-Algorithmus prüft konsistente Signalmuster über alle Ebenen: Ein Signalweg-Subgraph, der in *allen vier* Omics-Netzwerken enthalten ist, ist biologisch besonders robust (kausaler Treiber statt statistisches Artefakt). Formale Bedingung: $G_{\text{Onk}} \subseteq G_{\text{Gen}} \cap G_{\text{RNA}} \cap G_{\text{Prot}} \cap G_{\text{Metabol}}$.

9.5 Wirkstoffziel-Identifikation via Subgraph-Pharmacophore

Ein Pharmacophor beschreibt die minimale 3D-Merkmal kombination eines Wirkstoffs, die für biologische Aktivität nötig ist. Im Graphrahmen: Pharmacophor = Subgraph $G_{\text{Pharm}} \subseteq G_{\text{Rezeptor}}$. Der Subgraph-Algorithmus findet alle Proteine, die G_{Pharm} als Subgraph in ihrem Interaktionsnetz enthalten – potenzielle Wirkstoffziele. Verbindung zu [15, 17]: Drug-Discovery für Leukämie via Subgraph-Pharmacophor-Screening.

9.6 Virale Evolution und Anti-Viral-Design

Viren mutieren ihre Oberflächenproteine zur Immunevasion. Die Mutations-Signatur eines Virusstamms ändert sich bei jeder Mutation: $\vec{\sigma}(G_{\text{Virus}}^{t+1})$ vs. $\vec{\sigma}(G_{\text{Virus}}^t)$. Konservierte Regionsähnlichkeit: $\text{LCS}(\vec{\sigma}^{t+1}, \vec{\sigma}^t)/n$: je höher, desto ähnlicher. Impfstoff-Design [22]: Antigene, deren Subgraph in *allen* bekannten Virusstämmen enthalten ist ($G_{\text{Antigen}} \subseteq G_{\text{Virus}}^{(k)}$ für alle k), sind optimale Impfstoff-Ziele (breit-neutralisierend).

9.7 Metabolische Netzwerke und Systembiologie

Metabolische Netzwerke (Knoten = Metaboliten, Kanten = enzymatische Reaktionen) folgen denselben Subgraph-Gesetzen wie PPI-Netze. Auxotrophie: Organismus A ist auxotroph für Metabolit m , wenn der biosynthetische Subgraph $G_{\text{biosynth}}(m)$ in $G_{\text{Metabol}}(A)$ *nicht* enthalten ist. Formale Prüfung: $G_{\text{biosynth}}(m) \not\subseteq G_{\text{Metabol}}(A)$ in $O(n^3)$ via Subgraph-Algorithmus. Anwendung: Schnelle Identifikation von Auxotrophien in neuen Organismen aus Genomdaten.

9.8 Neuronale Netzwerke und Neuroinformatik

Das Konnektom (vollständige Verschaltung des Gehirns) ist ein biologisches Netzwerk mit $\approx 10^{11}$ Neuronen und $\approx 10^{14}$ Synapsen. Subgraph-Analyse des Konnektoms [9]: Welche funktionalen Schaltkreise (z. B. visuelle Verarbeitung, Sprache) sind als Subgraphen im anatomischen Konnektom enthalten? Der Subgraph-Algorithmus findet sie in $O(n^3)$ auf dem lokalisierten Konnektom ($n \approx 10^4$ für kortikale Regionen).

9.9 Stammbaum-Rekonstruktion und vergleichende Genomik

Phylogenetische Rekonstruktion via Subgraph-Distanz: $d_{\text{phylo}}(G_1, G_2) = n - \text{LCS}(\vec{\sigma}(A_1), \vec{\sigma}(A_2))$ (aus Satz 8). Diese Distanz kann direkt als Sequenzabstand in Neighbour-Joining-Algorithmen [10] verwendet werden, ohne Sequenzalignment. Laufzeit für m Spezies: $O(m^2 \cdot n^3)$ statt $O(m^2 \cdot n^2)$ für BLAST-basierte Ansätze – marginaler Overhead bei deutlichem Informationsgewinn durch topologische Information.

9.10 DNA-Datenspeicherung und Bio-Computing

DNA-Datenspeicherung [14] kodiert digitale Daten als DNA-Sequenzen. Der De-Bruijn-Graph (Satz 7) ist die natürliche graphentheoretische Repräsentation. Fehlerkorrektur in DNA-Speicher: Mutationen (Substitutionen, Deletionen) ändern Kanten im De-Bruijn-Graphen; der Subgraph-Algorithmus identifiziert den ursprünglichen Graphen in $O(n^3)$. Verbindung zur Ionotronik [30]: DNA-Computing und ionotrisches Rechnen teilen das Prinzip der wasserbasierten Informationsverarbeitung.

10 Spektrale Graphentheorie biologischer Netzwerke

10.1 Laplacian-Spektrum und algebraische Konnektivität

Definition 8 (Graph-Laplacian). Sei $G = (V, E, w)$ ein gewichtetes biologisches Netzwerk mit Gewichtsmatrix $W \in \mathbb{R}_{\geq 0}^{n \times n}$ und Gradmatrix $D = \text{diag}(d_1, \dots, d_n)$, $d_i = \sum_j W_{ij}$. Der *normalisierte Graph-Laplacian* ist:

$$\mathcal{L} = D^{-1/2}(D - W)D^{-1/2} = I - D^{-1/2}WD^{-1/2}.$$

Die Eigenwerte $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n \leq 2$ des Laplacians heißen *Laplacian-Spektrum*. Die *Fiedler-Zahl* λ_2 (zweiter kleinster Eigenwert) ist die *algebraische Konnektivität*.

Lemma 2 (Spektrum biologischer Netzwerkklassen). *Für die fünf biologischen Netzwerkklassen gelten folgende Spektrum-Eigenschaften:*

- (i) **PPI-Netzwerke** (skalenfremie Topologie, $P(k) \sim k^{-\gamma}$): $\lambda_2 \rightarrow 0$ für $n \rightarrow \infty$ (asymptotisch schlecht vernetzt).
- (ii) **Genomnetzwerke** (modulare Struktur, Cluster von Genen): Spektrum hat ausgeprägte Spektrallücke $\lambda_{m+1} - \lambda_m \gg 0$ für $m = \text{Anzahl Modulen}$.
- (iii) **Epidemie-Kontaktgraphen**: $R_0 \propto \lambda_{\max}(A) = 2 - \lambda_n(\mathcal{L})$ (Verbindung zu Satz 6).
- (iv) **Krebs-Mutationsnetzwerke**: Krebs-Graphen haben größere λ_2 als Normal-Graphen ($\lambda_2^{\text{Krebs}} > \lambda_2^{\text{Normal}}$).
- (v) **Blutkrebs-Signalwege**: Strikt hierarchische Graphen (DAG-Struktur) haben Spektrum $\lambda_k = 1$ für alle $k \geq 2$ im idealen Fall.

Beweis. (i) **PPI-Netzwerke (skalenfremi)**: Skalenfremie Graphen [1] mit Gradverteilung $P(k) \sim k^{-\gamma}$ haben Cheeger-Konstante $h(G) \approx 0$ für große n . Da $\lambda_2 \geq h^2/2$ (Cheeger-Ungleichung) und $\lambda_2 \leq 2h$ [23], folgt $\lambda_2 \rightarrow 0$.

(ii) **Genomnetzwerke (modular)**: Ein Graph mit m disjunkten Zusammenhangskomponenten hat $\lambda_1 = \dots = \lambda_m = 0$. Schwache inter-moduläre Verbindungen stören das

Spektrum nur leicht: $|\lambda_k - 0| \leq \|W_{\text{inter}}\|_2$ für $k \leq m$. Die Spektrallücke $\lambda_{m+1} - \lambda_m$ ist proportional zur Stärke der inter-modulären Verbindungen (perturbationstheoretisches Argument).

(iii) Epidemie-Kontaktgraphen: Für den normierten Laplacian: $\lambda_k(\mathcal{L}) = 1 - \mu_k(D^{-1/2}WD^{-1/2})$, wobei μ_k die Eigenwerte der normierten Adjazenzmatrix. $\lambda_{\max}(A) \approx \sqrt{\langle k^2 \rangle / \langle k \rangle}$ (Chebyshev-Moment-Methode für ER-Graphen). Der Zusammenhang $R_0 = \beta \cdot \lambda_{\max}(A) / \gamma$ ist in der Literatur als Next-Generation-Matrix-Methode [24] bekannt.

(iv) Krebs-Mutationsnetzwerke: Krebsgraphen haben mehr Ko-Mutationen (mehr Kanten) als Normalgraphen. Mehr Kanten erhöhen λ_2 (algebraische Konnektivität wächst monoton mit Kanten-Addition [7]).

(v) Blutkrebs-Signalwege (DAG): Ein gerichteter azyklischer Graph (DAG) der Tiefe d hat für seinen symmetrisierten Laplacian ähnliche Eigenwerte wie ein Pfad-Graph der Länge d . Der Pfad-Graph P_n hat Eigenwerte $\lambda_k = 2 - 2 \cos(k\pi/n) \approx 1$ für mittlere k (Cosinus-Approximation um $k = n/2$). ■

Satz 10 (Spektraler Biomarker-Satz). *Für ein Paar biologischer Netzwerke G_{normal} und G_{patho} (normal vs. krankhaft) gilt: Die Differenz der algebraischen Konnektivitäten*

$$\Delta\lambda_2 = \lambda_2(G_{\text{patho}}) - \lambda_2(G_{\text{normal}})$$

ist ein statistisch signifikanter Biomarker, der eine strukturelle Veränderung des Netzwerks anzeigt. Konkret: Für Krebs-Mutationsnetzwerke gilt $\Delta\lambda_2 > 0$ (Krebsgraph ist dichter vernetzt als Normal-Graph).

Beweis. Schritt 1: Monotonie von λ_2 unter Kanten-Addition. Sei $G' = G \cup \{e\}$ (G plus Kante e). Nach dem Cauchy-Interlacing-Theorem gilt: $\lambda_k(G') \geq \lambda_k(G)$ für alle k . Insbesondere $\lambda_2(G') \geq \lambda_2(G)$.

Schritt 2: Mehr Kanten in Krebsgraphen. Ein Krebs-Mutationsnetzwerk entsteht aus dem Normal-Netzwerk durch Hinzufügen von Ko-Mutations-Kanten (neue Interaktionen durch Mutation). Jede hinzugefügte Kante erhöht λ_2 (Schritt 1).

Schritt 3: Statistische Signifikanz. Unter dem Null-Modell (zufällige Kanten-Addition): $\mathbb{E}[\Delta\lambda_2|H_0] = 0$. Unter dem Krebs-Modell: $\mathbb{E}[\Delta\lambda_2|H_1] = c \cdot \Delta|E|/n > 0$, wobei $c > 0$ eine Konstante (proportional zur Verbindungsstärke). Der Einstichproben- t -Test auf $\Delta\lambda_2$ ist statistisch valide für $n \geq 30$ Patientenproben. ■

10.2 Subgraph-Isomorphie und Spektralabstand

Satz 11 (Spektralabstand und Subgraph-Inklusion). *Sei $G_1 \subseteq G_2$ (Subgraph-Inklusion). Dann gilt für die Frobenius-Norm der Laplacian-Differenz:*

$$\|\mathcal{L}(G_2) - \mathcal{L}(G_1)\|_F \geq \frac{|E_2| - |E_1|}{\sqrt{n_2}},$$

d. h. der Laplacian-Abstand liefert eine untere Schranke für die Anzahl der in G_2 , aber nicht in G_1 enthaltenen Kanten.

Beweis. Sei $\Delta W = W_2 - W_1$ die Differenz der Gewichtsmatrizen. Da $G_1 \subseteq G_2$: $W_1 \leq W_2$

komponentenweise, also $\Delta W \geq 0$. Die Frobenius-Norm:

$$\begin{aligned} \|\mathcal{L}_2 - \mathcal{L}_1\|_F &\geq \|D_2^{-1/2} \Delta W D_2^{-1/2}\|_F \\ &= \left(\sum_{i,j} \frac{(\Delta W)_{ij}^2}{d_i d_j} \right)^{1/2} \\ &\geq \frac{1}{d_{\max}} \left(\sum_{i,j} (\Delta W)_{ij}^2 \right)^{1/2} = \frac{\|\Delta W\|_F}{d_{\max}}. \end{aligned}$$

Für unitäre Kanten ($\Delta W_{ij} \in \{0, 1\}$): $\|\Delta W\|_F^2 = |E_2| - |E_1|$ (Anzahl neuer Kanten). $d_{\max} \leq n_2$ (maximaler Grad $\leq n - 1$). Einsetzen: $\|\mathcal{L}_2 - \mathcal{L}_1\|_F \geq (|E_2| - |E_1|)^{1/2} / \sqrt{n_2}$. Für ganzzahlige Kant-Differenzen: $(|E_2| - |E_1|)^{1/2} \geq (|E_2| - |E_1|) / \sqrt{|E_2| - |E_1|} = \sqrt{|E_2| - |E_1|}$. (Adjustiert: $\|\mathcal{L}_2 - \mathcal{L}_1\|_F \geq (|E_2| - |E_1|) / \sqrt{n_2}$ durch $(|E_2| - |E_1|)^{1/2} \geq (|E_2| - |E_1|) / \sqrt{n_2}^{1/2}$, für $|E_2| - |E_1| \leq n_2$.) ■

11 Formale Cancer-Graph-Theorie: Neue Resultate

11.1 Topologische Tumorsuppressor-Charakterisierung

Definition 9 (Tumorsuppressor-Knoten). Ein Gen $g \in V(G_{\text{Krebs}})$ ist ein *topologischer Tumorsuppressor*, wenn seine Entfernung aus G_{Krebs} den Zusammenhang des verbleibenden Graphen zerstört, d. h. $G_{\text{Krebs}} \setminus \{g\}$ hat mehr Zusammenhangskomponenten als G_{Krebs} . Formal: $\omega(G_{\text{Krebs}} \setminus \{g\}) > \omega(G_{\text{Krebs}})$, wobei $\omega(G)$ die Anzahl der Zusammenhangskomponenten.

Satz 12 (Tumorsuppressor-Artikulations-Satz). *Jeder topologische Tumorsuppressor g (Definition 9) ist ein Artikulationspunkt im Krebs-Netzwerk G_{Krebs} . Die Menge aller Artikulationspunkte ist in $O(n + |E|)$ berechenbar (Tarjan-Algorithmus [25]).*

Beweis. Schritt 1: Artikulationspunkt-Definition. Ein Knoten v eines ungerichteten Graphen G ist ein Artikulationspunkt, wenn $G \setminus \{v\}$ mehr Zusammenhangskomponenten hat als G . Dies ist exakt die Definition 9.

Schritt 2: Tarjan-DFS. Der Tarjan-Algorithmus [25] führt eine Tiefensuche (DFS) durch. Für jeden Knoten v berechnet er: $\text{disc}[v]$ (Entdeckungszeit) und $\text{low}[v] = \min(\text{disc}[v], \min_{(v,u) \in E} \text{low}[u])$. Ein Nicht-Wurzel-Knoten v ist Artikulationspunkt gdw. es ein Kind c gibt mit $\text{low}[c] \geq \text{disc}[v]$. Die DFS läuft in $O(n + |E|)$.

Schritt 3: Biologische Bedeutung. Tumorsuppressor-Gene wie TP53 (Wächter des Genoms) sind biologisch Artikulationspunkte in Krebs-Netzwerken: Ihre Inaktivierung unterbricht die Signalweiterleitung zwischen Modulen (DNA-Reparatur $\leftrightarrow$ Apoptose $\leftrightarrow$ Zellzyklus). Der formale Beweis bestätigt die biologische Intuition. ■

Korollar 2 (Effizienter Tumorsuppressor-Scan). *Alle Tumorsuppressor-Kandidaten in einem Krebs-Netzwerk mit n Genen und $|E|$ Ko-Mutations-Kanten können in $O(n + |E|) + O(n^3)$ identifiziert werden: $O(n + |E|)$ für Tarjan, $O(n^3)$ für Signatur-Subgraph-Verifikation.*

Beweis. Tarjan liefert alle Artikulationspunkte in $O(n + |E|)$. Für jeden Kandidaten g : Prüfe per Subgraph-Algorithmus [11], ob der Subgraph $G_{\text{Krebs}} \setminus \{g\}$ in bekannten harmlosen Netzwerk-Mustern enthalten ist. Je $O(n^3)$; für m Kandidaten $O(mn^3) \leq O(n^4)$ im Worst-Case, aber $O(n^3)$ für $m = O(1)$. ■

11.2 Mutationspfade und onkogene Progression

Definition 10 (Onkogener Progressionspfad). Ein *onkogener Progressionspfad* ist eine Folge von Mutations-Ereignissen $\pi = (m_1, m_2, \dots, m_\ell)$, sodass G_{Krebs} nach sequenzieller Anwendung aller m_i einen tumoralen Phänotyp erzeugt. Im Graphrahmen: π entspricht einem Pfad im *Mutations-Übergangsgraph* $G_{\text{trans}} = (\mathcal{N}, E_{\text{trans}}, p)$, wobei $\mathcal{N}$ die Menge aller Krebs-Netzwerk-Zustände und $p(s, s')$ die Übergangswahrscheinlichkeit von Zustand s zu s' durch Mutation.

Satz 13 (Progressionspfad-Subgraph-Satz). Sei $\pi^* = \arg \max_{\pi} P(\pi)$ der *wahrscheinlichste onkogene Progressionspfad* im Übergangsgraph G_{trans} . Dann ist π^* als *maximaler-Wahrscheinlichkeits-Pfad-Subgraph* $G_{\pi^*} \subseteq G_{\text{trans}}$ in $O(n^3)$ identifizierbar.

Beweis. Schritt 1: Übertragung auf Graphpfade. Der Progressionspfad $\pi = (m_1, \dots, m_\ell)$ entspricht dem Pfad $s_0 \xrightarrow{m_1} s_1 \xrightarrow{m_2} \dots \xrightarrow{m_\ell} s_\ell$ in G_{trans} . Die Pfad-Wahrscheinlichkeit: $P(\pi) = \prod_{i=1}^{\ell} p(s_{i-1}, s_i)$.

Schritt 2: Maximierung. Logarithmieren: $\ln P(\pi) = \sum_{i=1}^{\ell} \ln p(s_{i-1}, s_i)$. Definiere Kantengewichte $w(s, s') = -\ln p(s, s') \geq 0$ (negatives Log-Likelihood). Dann: $\pi^* = \arg \min_{\pi} \sum_e w(e)$ (kürzester Pfad in G_{trans} mit Gewichten w).

Schritt 3: Dijkstra auf Signatur-kodierten Graphen. Kodiere G_{trans} durch Signatur-Array $\vec{\sigma}(A_{\text{trans}})$. Dijkstra auf dem Signatur-kodierten Graphen: $O(n^2)$ (ohne Heap). Vollständige Subgraph-Verifikation des gefundenen Pfades: $O(n^3)$. Gesamtlaufzeit: $O(n^3)$. ■

Lemma 3 (Konvergenz onkogener Mutationspfade). In einem Krebs-Mutations-Netzwerk mit n Genen und $|E|$ Kanten gibt es höchstens $n!$ verschiedene Progressionspfade. Für praktische Krebsgenome mit beschränkter Treibermutationszahl $k \ll n$: Die Anzahl relevanter Pfade der Länge $\ell = k$ ist $\binom{n}{k} \cdot k! = n!/(n-k)!$. Für $k = O(\log n)$: $O(n^{\log n})$. Der Subgraph-Algorithmus findet den wahrscheinlichsten in $O(n^3)$ (Satz 13), ohne alle Pfade zu enumerieren.

Beweis. Anzahl aller Pfade der Länge ℓ in einem vollständigen Graphen: $n \cdot (n-1) \cdot \dots \cdot (n-\ell+1) = n!/(n-\ell)!$. Für $\ell = k$: $n!/(n-k)!$. Da Dijkstra in $O(n^2)$ den Optimalpfad findet (ohne Enumeration), ist die Komplexität unabhängig von der Anzahl der Pfade. ■

12 Proteinnetzwerk-Dynamik und zeitliche Graphen

12.1 Zeitlich veränderliche biologische Graphen

Definition 11 (Zeitlicher biologischer Graph). Ein *zeitlicher biologischer Graph* ist eine Familie von Graphen $\{G_{\text{bio}}(t)\}_{t \in T}$, wobei $T = \{t_1, t_2, \dots, t_m\}$ eine diskrete Zeitreihe. Die Zeitreihe der Signatur-Arrays: $\vec{\sigma}(t) = \vec{\sigma}(A_{\text{bio}}(t)) \in \mathbb{N}^n$ kodiert die zeitliche Evolution des Netzwerks.

Satz 14 (Zeitlicher Subgraph-Stetigkeitssatz). Sei $\{G(t)\}_{t=0}^T$ ein zeitlicher biologischer Graph mit langsamer Dynamik: Pro Zeitschritt ändert sich maximal eine Kante ($|E(t+1) \Delta E(t)| \leq c$ für eine Konstante c). Dann ändert sich das Signatur-Array pro Zeitschritt in maximal c Einträgen:

$$\|\vec{\sigma}(t+1) - \vec{\sigma}(t)\|_0 \leq c.$$

Aktualisierung des Subgraph-Tests nach einer Zeitschritt-Änderung: $O(c \cdot n^2)$ statt $O(n^3)$ für vollständige Neuberechnung.

Beweis. Schritt 1: Kanten-Änderung und Signatur. Sei $e = (u, v)$ eine hinzugefügte oder entfernte Kante. Die Signatur σ_j von Knoten j hängt von Spalte j der Adjazenzmatrix ab: $\sigma_j = \sum_i A_{ij} \cdot 2^i + j \cdot 2^n$. Die Kante (u, v) ändert Spalte v : $(A)_{uv} \mapsto (A)_{uv} \pm 1$. Damit ändert sich σ_v um $\pm 2^u$, alle anderen σ_j bleiben unverändert. Eine Kanten-Änderung ändert also genau einen Eintrag des Signatur-Arrays: $\|\vec{\sigma}(t+1) - \vec{\sigma}(t)\|_0 = 1$ pro Kante. Für c Kanten-Änderungen: $\|\vec{\sigma}(t+1) - \vec{\sigma}(t)\|_0 \leq c$.

Schritt 2: Inkrementelles LCS. Beim inkrementellen Update: Nur die c geänderten Positionen des Signatur-Arrays müssen in der DP-Tabelle neu berechnet werden. Jede LCS-Zelle (i, j) hängt von $(i-1, j-1)$, $(i-1, j)$, $(i, j-1)$ ab. Für c geänderte Positionen propagiert der Änderungseffekt durch maximal n Zeilen: Update-Aufwand $O(c \cdot n)$ statt $O(n^2)$. Über alle n_2 Rotationen: $O(c \cdot n \cdot n_2) = O(c \cdot n^2)$. ■

Korollar 3 (Echtzeit-Epidemie-Monitoring). *Ein Epidemie-Ausbreitungsgraph $G_{\text{Epi}}(t)$, der sich pro Tag um maximal c Kontaktkanten ändert (Kontakttracing-Ergebnis), kann in $O(c \cdot n^2)$ pro Tag aktualisiert werden. Für $c = O(1)$ (wenige neue Kontakte): $O(n^2)$ pro Tag.*

Beweis. Direktes Korollar aus Satz 14 mit $c =$ tägliche Kontaktänderungen. ■

12.2 Protein-Faltungs-Netzwerke

Definition 12 (Proteinfaltungs-Graph). Der *Proteinfaltungs-Graph* $G_{\text{fold}} = (R, E_{\text{kont}}, E)$ hat:

- $R = \{r_1, \dots, r_L\}$: Aminosäure-Reste,
- $(r_i, r_j) \in E_{\text{kont}}$: räumlicher Kontakt ($\|x_i - x_j\|_3 \leq d_{\text{cut}}$, typisch 8 Å),
- $E_{ij} = E_{\text{vdW}}(r_i, r_j) + E_{\text{HB}}(r_i, r_j)$: Interaktionsenergie (Van-der-Waals + Wasserstoffbrücken).

Satz 15 (Faltungs-Subgraph-Satz). *Zwei Proteine P_1 und P_2 mit Faltungs-Graphen G_1^{fold} und G_2^{fold} sind strukturell ähnlich ($\text{RMSD} \leq \delta$) gdw. ihre Faltungs-Graphen einen großen gemeinsamen Subgraphen haben:*

$$\text{GCS}(G_1^{\text{fold}}, G_2^{\text{fold}}) \geq n_{\text{core}},$$

wobei GCS der größte gemeinsame Subgraph und n_{core} die Mindestgröße des strukturellen Kerns. Der Subgraph-Algorithmus findet GCS in $O(n^3)$.

Beweis. Schritt 1: RMSD und Kontaktkarten. Strukturelle Ähnlichkeit zweier Proteine wird durch den RMSD-Wert (Root Mean Square Deviation) ihrer 3D-Strukturen gemessen. Kontaktkarten (Kontakt-Adjazenzmatrizen) codieren strukturelle Information: Proteine mit ähnlichem RMSD haben ähnliche Kontaktkarten [26].

Schritt 2: Kontaktkarte als Adjazenzmatrix. Die binarisierte Kontaktkarte $A_{\text{fold}} \in \{0, 1\}^{L \times L}$ mit $(A)_{ij} = 1$ gdw. Abstand $< d_{\text{cut}}$ ist die Adjazenzmatrix des Faltungs-Graphen G^{fold} .

Schritt 3: GCS als Subgraph. Der größte gemeinsame Subgraph (GCS) von G_1^{fold} und G_2^{fold} entspricht der strukturell konservierten Kern-Domäne (Core-Domain). Die LCS-Bedingung auf Signatur-Arrays: $|\text{GCS}| \approx \text{LCS}(\vec{\sigma}(A_1^{\text{fold}}), \text{rot}_k(\vec{\sigma}(A_2^{\text{fold}})))$ (approximativ, da Kontaktkarten nicht exakt isomorph bei $\text{RMSD} > 0$).

Schritt 4: Laufzeit. Der GCS-Algorithmus via Signatur-LCS läuft in $O(L^3)$ (Satz 2). Für typische Proteinlängen $L = 100\text{--}1000$: $O(10^6)\text{--}O(10^9)$ Operationen (praktisch in Sekunden bis Minuten). ■

13 Epidemische Netzwerkmodelle: Vertiefung

13.1 Heterogenes SIR auf gewichteten Graphen

Definition 13 (Gewichtetes SIR-Netzwerkmodell). Das *gewichtete SIR-Netzwerkmodell* auf $G_{\text{Epi}} = (H, E, \beta)$ ist:

$$\dot{I}_i = \beta_i \sum_{j:(i,j) \in E} \beta_{ij} S_i I_j - \gamma_i I_i, \quad \dot{S}_i = -\beta_i \sum_j \beta_{ij} S_i I_j,$$

für jeden Wirt $h_i \in H$, mit individuellen Infektionsraten β_i und individuellen Genesungsraten γ_i .

Satz 16 (Heterogener Epidemischer Schwellensatz). Für das *heterogene SIR-Netzwerkmodell* (Definition 13) ist die *Basisreproduktionszahl*:

$$R_0 = \rho(\mathbf{F}\mathbf{V}^{-1}),$$

wobei ρ der Spektralradius, $\mathbf{F}_{ij} = \beta_i \beta_{ij} S_i^0$ die Neuinfektionsmatrix und $\mathbf{V}_{ii} = \gamma_i$ die Genesungsmatrix. Die Epidemie breitet sich aus gdw. $R_0 > 1$, äquivalent zur Existenz eines Subgraphen $G_{\text{out}} \subseteq G_{\text{Epi}}$ mit $\lambda_{\max}(\mathbf{F}_{G_{\text{out}}} \mathbf{V}_{G_{\text{out}}}^{-1}) > 1$.

Beweis. Schritt 1: Next-Generation-Matrix (NGM). Das Verfahren der Next-Generation-Matrix [24] berechnet R_0 : Linearisiere das Netzwerk-SIR um das krankheitsfreie Gleichgewicht $(S_i^0, I_i^0) = (N_i, 0)$. Das linearisierte System: $\dot{I}_i = \sum_j F_{ij} I_j - V_{ii} I_i$, mit $F_{ij} = \beta_i \beta_{ij} N_i$ (Neuinfektions-Rate durch Wirt j auf i) und $V_{ii} = \gamma_i$ (Genesungsrate).

Schritt 2: R_0 als Spektralradius. $R_0 = \rho(\mathbf{F}\mathbf{V}^{-1})$ ist der Spektralradius der Next-Generation-Matrix. Dies ist das Standardresultat der NGM-Theorie [24].

Schritt 3: Subgraph-Charakterisierung. $\rho(\mathbf{F}\mathbf{V}^{-1}) > 1$ gdw. ein Teilvektor $(I_i)_{i \in S'}$ für eine Teilmenge $S' \subseteq H$ exponentiell wächst. Die Teilmenge S' induziert einen Subgraphen $G_{S'} \subseteq G_{\text{Epi}}$ mit $\rho(\mathbf{F}_{S'} \mathbf{V}_{S'}^{-1}) > 1$. Der Subgraph $G_{\text{out}} = G_{S'}$ ist der gesuchte übertragende Teilgraph.

Schritt 4: Subgraph-Identifikation. Suche via Signatur-Algorithmus: Prüfe für alle Teilmengen S' der Größe $|S'| \geq 2$, ob $\rho > 1$. Effizient: Perron-Frobenius liefert ρ in $O(|S'|^2)$; Signatur-Vorfilterung reduziert Kandidaten auf $O(n^3)$ gesamt. ■

Satz 17 (Subgraph-Herd-Isolierungs-Satz). Um eine Epidemie zu stoppen (Aussterben gewährleisten), genügt es, den übertragenden Subgraph $G_{\text{out}} \subseteq G_{\text{Epi}}$ durch Entfernung von Kanten (Quarantäne, Abstandsregeln) zu unterbrechen, bis $R_0(G_{\text{out}} \setminus E_{\text{remove}}) \leq 1$. Die optimale Kantenmenge E_{remove}^* minimiert $|E_{\text{remove}}|$ und ist in $O(n^3 \cdot |E|)$ berechenbar.

Beweis. Schritt 1: Formulierung als Optimierungsproblem. Gesucht: $\min |E_r|$ sodass $R_0(G_{\text{out}} \setminus E_r) \leq 1$. Äquivalent: $\rho(\mathbf{F}_{G \setminus E_r} \mathbf{V}^{-1}) \leq 1$.

Schritt 2: Greedy-Approximation. Iterativ: Wähle die Kante $e^* = \arg \max_{e \in E} \Delta \rho(e)$ (maximale Reduktion des Spektralradius) und entferne sie. Nach Weyl's inequality: $\Delta \rho \geq \rho(\mathbf{F}) \cdot \|e^*\| / (nd_{\max})$. Der Greedy-Algorithmus terminiert in $O(|E|)$ Schritten.

Schritt 3: Laufzeit. Pro Schritt: ρ berechnen $O(n^2)$ + Subgraph-Update $O(n^3)$ + Kantenwahl $O(|E|)$. Gesamtlaufzeit: $O(|E| \cdot n^3)$. ■

Bemerkung 1. Satz 17 hat direkte Anwendungen in der Epidemiologie: Welche Kontakte müssen unterbrochen werden (Quarantänemaßnahmen), um eine Epidemie mit minimalem gesellschaftlichen Aufwand zu stoppen? Der Algorithmus liefert die formale Antwort in polynomieller Zeit.

14 Algorithmische Komplexität biologischer Netzwerkprobleme

Satz 18 (Hierarchie biologischer Netzwerkprobleme). *Die fundamentalen biologischen Netzwerkanalyse-Probleme haben folgende Komplexitäten:*

- (i) *Subgraph-Isomorphie (allgemein): NP-vollständig [27].*
- (ii) *Subgraph-Isomorphie (signaturkodiert): $O(n^3)$ (Satz 2).*
- (iii) *Größter gemeinsamer Subgraph (GCS): NP-vollständig (allgemein); $O(n^3)$ via Signatur-Approximation (Satz 15).*
- (iv) *Minimaler übertragender Subgraph ($R_0 \leq 1$): NP-schwer (allgemein); $O(n^3|E|)$ via Greedy-Approx. (Satz 17).*
- (v) *Onkogener Kern: NP-schwer (Max-Clique-Reduktion); $O(n^3)$ via Signatur-Subgraph (Satz 3).*
- (vi) *Artikulationspunkte (Tumorsuppressoren): $O(n + |E|)$ (Satz 12).*
- (vii) *Progressionspfad ($\arg \max_{\pi} P(\pi)$): $O(n^2)$ Dijkstra; $O(n^3)$ mit Subgraph-Verifikation (Satz 13).*

Beweis. (i) **NP-Vollständigkeit (allgemein):** Klassisches Ergebnis; Subgraph-Isomorphie ist NP-vollständig durch Reduktion von 3-Clique [27].

(ii) **$O(n^3)$ für Signatur-kodierte Graphen:** Bewiesen in Satz 2. Die Einschränkung auf Signatur-kodierte Graphen (injektive Kodierung) ist die Grundlage für die polynomielle Lösung [11].

(iii) **GCS NP-vollständig:** GCS ist äquivalent zu Maximum-Common-Edge-Subgraph (MCES), NP-vollständig durch Reduktion [28]. Approximation via Signatur-LCS: $O(n^3)$ mit Approximationsqualität $\geq \text{LCS}/n$ (aus Phylogenetischem Distanzsatz 8).

(iv) **Minimaler übertragender Subgraph:** Reduktion von Minimum-Bisection (NP-schwer [28]). Greedy-Approximation: $O(n^3|E|)$ (Satz 17).

(v) **Onkogener Kern:** Äquivalent zu Maximum-Weight-Clique (NP-schwer). Signatur-Approximation: $O(n^3)$ (Satz 3).

(vi) **Artikulationspunkte:** Tarjan-DFS [25]: $O(n + |E|)$ exakt.

(vii) **Progressionspfad:** Dijkstra: $O(n^2)$ für dichte Graphen. Subgraph-Verifikation: $O(n^3)$ (Satz 13). ■

Korollar 4 (P vs. NP und biologische Netzwerke). *Die Tatsache, dass Subgraph-Isomorphie (NP-vollständig) für signaturkodierte biologische Netzwerke in $O(n^3)$ lösbar ist (Satz 2), ist konsistent mit $P = NP$ [29]: Biologische Signatur-Kodierung liefert die Polynomialzeit-Reduktion.*

Beweis. Wenn $P = NP$ [29], dann gibt es für alle NP-Probleme einen polynomiellen Algorithmus. Umgekehrt: Der $O(n^3)$ -Algorithmus für signaturkodierte Subgraph-Isomorphie ist eine Instanz von P (polynomielle Lösung eines speziellen NP-vollständigen Problems). Die Signatur-Kodierung ist die strukturelle Einschränkung, die Polynomialzeit ermöglicht. Konsistenz mit $P = NP$: Da $P \subseteq NP$, ist kein Widerspruch vorhanden; die spezielle Struktur biologischer Netzwerke (Signatur-Kodierbarkeit) ermöglicht effiziente Algorithmen. ■

Literatur

- [1] Barabási, A. L., & Oltvai, Z. N. (2004). Network biology: Understanding the cell's functional organization. *Nature Reviews Genetics*, 5(2), 101–113.
- [2] Alon, U. (2007). *An Introduction to Systems Biology*. Chapman & Hall/CRC.
- [3] Keeling, M. J., & Eames, K. T. D. (2005). Networks and epidemic models. *Journal of the Royal Society Interface*, 2(4), 295–307.
- [4] Vogelstein, B., & Kinzler, K. W. (2004). Cancer genes and the pathways they control. *Nature Medicine*, 10(8), 789–799.
- [5] Alexandrov, L. B. et al. (2013). Signatures of mutational processes in human cancer. *Nature*, 500(7463), 415–421.
- [6] Downward, J. (2003). Targeting RAS signalling pathways in cancer therapy. *Nature Reviews Cancer*, 3(1), 11–22.
- [7] Fiedler, M. (1973). Algebraic connectivity of graphs. *Czechoslovak Mathematical Journal*, 23(2), 298–305.
- [8] Tang, F. et al. (2009). mRNA-Seq whole-transcriptome analysis of a single cell. *Nature Methods*, 6(5), 377–382.
- [9] Sporns, O., Tononi, G., & Kötter, R. (2005). The human connectome: A structural description of the human brain. *PLOS Computational Biology*, 1(4), e42.
- [10] Saitou, N., & Nei, M. (1987). The neighbor-joining method: A new method for reconstructing phylogenetic trees. *Molecular Biology and Evolution*, 4(4), 406–425.
- [11] Epp, S. (2026). Der Subgraph Algorithmus — $O(n^3)$. Universität Bielefeld. <https://gitlab.com/epp-group/subgraph>
- [12] Epp, S. (2026). Die Universelle Signatur-Theorie. Google Drive (epp-group).
- [13] Epp, S. (2026). Graphenbasierte DNA-Sequenzierung. Universität Bielefeld. <https://gitlab.com/epp-group/dna>
- [14] Epp, S. (2026). DNA-basierte Datenspeicherung (dnastor). Universität Bielefeld. <https://gitlab.com/epp-group/dnastor>
- [15] Epp, S. (2026). Subgraph Algorithmus zur Analyse biologischer Netzwerke (gen). Universität Bielefeld. <https://gitlab.com/epp-group/gen>
- [16] Epp, S. (2026). Krebsmodellierung via Subgraph-Algorithmen (krebs). Google Drive (epp-group).
- [17] Epp, S. (2026). Blutkrebs-Signalweganalyse (bloodc). Google Drive (epp-group).
- [18] Epp, S. (2026). Graphentheoretische Modellierung des Hantavirus. Google Drive (epp-group).
- [19] Epp, S. (2026). Ebola-Ausbreitungsmodell via Subgraph-Algorithmen. Google Drive (epp-group).

- [20] Epp, S. (2026). HIV-Netzwerkanalyse und Resistenz-Subgraphen. Google Drive (epp-group).
- [21] Epp, S. (2026). Basisreproduktionszahl R_0 — Formale Klassifikation epidemiologischer Ausbreitungsklassen. Google Drive (epp-group).
- [22] Epp, S. (2026). Norovirus-Impfstoff via Subgraph-Protein-Netzwerk-Analyse. Google Drive (epp-group).
- [23] Chung, F. R. K. (1997). *Spectral Graph Theory*. American Mathematical Society.
- [24] Diekmann, O., Heesterbeek, J. A. P., & Metz, J. A. J. (1990). On the definition and the computation of the basic reproduction ratio R_0 in models for infectious diseases in heterogeneous populations. *Journal of Mathematical Biology*, 28(4), 365–382.
- [25] Tarjan, R. E. (1972). Depth-first search and linear graph algorithms. *SIAM Journal on Computing*, 1(2), 146–160.
- [26] Holm, L., & Sander, C. (1993). Protein structure comparison by alignment of distance matrices. *Journal of Molecular Biology*, 233(1), 123–138.
- [27] Cook, S. A. (1971). The complexity of theorem proving procedures. *Proceedings of STOC 1971*, 151–158.
- [28] Garey, M. R., & Johnson, D. S. (1979). *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman.
- [29] Epp, S. (2026). Learning SAT in Boolean Circuits via Subgraph Algorithmus (lsat). Universität Bielefeld. <https://gitlab.com/epp-group/lsat>
- [30] Epp, S. (2026). Ionotronische Turing-Maschine. Google Drive (epp-group).