

Depension

Die Theorie der mathematischen Abhängigkeitsmodellierung

Stephan Epp

30. März 2026

Inhaltsverzeichnis

1	Einleitung und Begriffsentwicklung	3
1.1	Regression	3
1.2	Der neue Begriff: Depension	3
1.3	Drei Säulen der Depension	4
1.4	Aufbau der Arbeit	5
2	Mathematische Grundlagen der Depension	5
2.1	Definition des Depensions-Operators	5
2.2	Grundlegende algebraische Struktur	6
2.3	Die Sigmoid-Funktion als Depensions-Verbindungsglied	6
3	Depensionsklassen DP-I bis DP-IV	6
3.1	Definition der Depensionsklassen	7
3.2	Eigenschaften der Depensionsklassen	8
4	Neue mathematische Aussagen und Beweise	10
4.1	Äquivalenz: Konvexität als DP-I-Eigenschaft	10
4.2	Regularisierungs-Klassenübergangs-Theorem	11
4.3	Der Depensions-Index	12
4.4	Lemma über die Hesse-Systemmatrix-Dualität	13
4.5	Spektraler Depensions-Konditionierungssatz	14
5	Informationsgeometrie der Depension	14
5.1	Die Depensions-Mannigfaltigkeit	14
5.2	Geodätiken und Natural Gradient Descent	16
6	Strukturelle Depension: VIF, Sparse Strukturen und Asymmetrie	17
6.1	VIF als Depensions-Diagnose	17
6.2	Semantische Asymmetrie als Depensions-Richtungsstruktur	18
6.3	Hierarchische Depension und Nilpotenz	19
7	Numerische Experimente: Plots und Analysen	21
7.1	Unified Framework: Synthese aller Konzepte	21
7.2	Zusammenfassung der numerischen Erkenntnisse	22

8	Diskussion und Ausblick	22
8.1	Wissenschaftliche Bedeutung der Depension	22
8.2	Ausblick: Weiterführende Forschungsrichtungen über alle Kapitel	22
9	Zusammenfassung	28

1 Einleitung und Begriffsentwicklung

1.1 Regression

Die vorliegende Arbeit führt den neuen wissenschaftlichen Begriff *Depension* (lat. *dependere* = abhängen, griech. *-ension* = Zustand, Spannung) ein. *Depension* bezeichnet die mathematische Disziplin, die alle Formen der Abhängigkeitsmodellierung unter einem einheitlichen Rahmen zusammenfasst: statische Abhängigkeit (lineare Regression), stochastische Abhängigkeit (logistische Regression, Bernoulli-Modell) und temporale Abhängigkeit (lineare dynamische Systeme, Matrixexponential).

Aufbauend auf drei vorangehenden Arbeiten des Autors – der logistischen Regression [Epp, 2026a], den Zustandsklassen dynamischer Systeme [Epp, 2026b] und der asymmetrischen Matrixmultiplikation [Epp, 2026c] – werden neue mathematische Konzepte entwickelt und formal bewiesen: (1) die vier *Depensionsklassen* DP-I bis DP-IV als Verallgemeinerung der Zustandsklassen KS-I bis KS-IV, (2) der *Depensions-Index* (DI) als einheitliches Gütemaß über alle Modellklassen, (3) die Äquivalenz zwischen der Konvexitätsbedingung in der logistischen Regression und der DP-I-Eigenschaft im dynamischen System, (4) der *Regularisierungs-Klassen-Übergang* als Steuerung des Eigenwerttraums, (5) die Informationsgeometrie der *Depension* mit der Fisher-Information als Riemannscher Metrik auf der *Depensions-Mannigfaltigkeit* und (6) die strukturelle Verbindung zwischen VIF-Analyse und Systemmatrix-Multikollinearität.

Die statistische Methode, die unter dem Namen *Regression* bekannt ist, trägt einen irreführenden Namen. Das Wort stammt vom lateinischen *regressio* (Rückkehr, Rückschritt). Der Mathematician Francis Galton prägte ihn 1886 für das Phänomen der Regression zur Mitte – die empirische Beobachtung, dass überdurchschnittlich große Eltern tendenziell Kinder mit etwas geringerer Körpergröße haben. Das eigentliche Ziel der Methode – das Erkennen und formale Beschreiben von Abhängigkeitsbeziehungen zwischen Variablen – spiegelt sich im Begriff *Regression* nicht wider.

Dies ist kein bloß sprachkosmetisches Problem. Ein Begriffssystem, das das Wesen einer Methode nicht trifft, behindert das konzeptionelle Denken und verschleiert Zusammenhänge zu verwandten Disziplinen. So bleibt die tiefe strukturelle Verbindung zwischen der logistischen Regression und der Theorie dynamischer Systeme in der Lehre und Forschung weitgehend unbenannt und ungenutzt.

1.2 Der neue Begriff: Depension

Etymologische Herleitung des Begriffs *Depension*. Der Begriff **Depension** setzt sich zusammen aus:

- lat. *de-* = von ... ab (Trennung, Abstammung, Abhängigkeit)
- lat. *pendere* = hängen, abhängen
- lat. *dependere* = abhängen, in Abhängigkeit stehen
- Suffix *-ension* (analog zu *Dimension*, *Tension*, *Extension*) = etwas, das einen abstrakten mathematischen Zustand beschreibt

Depension bezeichnet somit den *mathematischen Zustand des Abhängens* – das formale

Beschreiben und Modellieren von Abhängigkeiten, unabhängig davon, ob diese statisch, stochastisch oder temporal sind.

Der Begriff trifft präziser als Regression das Wesentliche der Methode: Es geht nicht um einen Rückschritt, sondern um die mathematische Beschreibung, wie eine Größe Y von Größen $X_1, \dots, X_d$ *abhängt* – also um das strukturelle Verhältnis der Dependenz.

Bemerkung 1.1 (Sprachliche Abgrenzung zu Dependenz). Das Wort *Dependenz* (lat. *dependentia*) ist bereits in der Statistik im Gebrauch (z. B. lineare Dependenz, Dependenzmaß). *Dependenz* hebt sich davon durch den produktiven Suffix *-ension* ab, der – wie in *Dimension* oder *Tension* – auf einen formalen, mathematisch quantifizierbaren *Zustand* verweist, nicht nur auf eine Beziehung. *Dependenz* ist demnach das Maß oder der Zustand der Abhängigkeit, während *Dependenz* die Tatsache des Abhängens beschreibt.

1.3 Drei Säulen der Dependenz

Die vorliegende Arbeit stützt sich auf drei bedeutende Vorarbeiten des Autors, die nun als Säulen des Dependenz-Frameworks erkennbar werden:

- (I) **Logistische Regression** [Epp, 2026a]: Die logistische Regression modelliert die stochastische Abhängigkeit einer binären Zielvariable von kontinuierlichen Prädiktoren über die Sigmoid-Transformation und die Kreuzentropie-Verlustfunktion. Formal: $\mathbb{P}(Y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x} + b)$. Dies ist *stochastische Dependenz*.
- (II) **Zustandsklassen dynamischer Systeme** [Epp, 2026b]: Die Systemmatrix $\mathbf{A}$ eines linearen dynamischen Systems $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ beschreibt, wie der Zustandsvektor $\mathbf{x}(t)$ von seiner Vergangenheit $\mathbf{x}(0)$ abhängt: $\mathbf{x}(t) = e^{\mathbf{A}t}\mathbf{x}(0)$. Die Zustandsklassen KS-I bis KS-IV klassifizieren das Langzeitverhalten dieser Abhängigkeit. Dies ist *temporale Dependenz*.
- (III) **Asymmetrische Matrixstruktur** [Epp, 2026c]: Die semantische Dualität zwischen Zeilen (Aggregation, Empfänger) und Spalten (Ausbreitung, Sender) einer Systemmatrix beschreibt die *Richtungsstruktur* der Abhängigkeit. Dies ist *strukturelle Dependenz*.




Abbildung 1: Die drei Erscheinungsformen der Dependenz: Links die statische (lineare Regression als Grenzfall), Mitte die stochastische (logistische Regression) und rechts die temporale Dependenz (Trajektorien eines KS-I-Systems). Allen gemeinsam ist die fundamentale Frage: Wie hängt Y von X ab?

Abbildung 1 stellt die drei Erscheinungsformen der Depension nebeneinander. Links sehen wir die klassische Regressionsgerade als Modell für eine lineare statische Abhängigkeit. In der Mitte zeigt die Sigmoid-Kurve, wie die logistische Regression eine probabilistische Abhängigkeit modelliert – nicht eine lineare, sondern eine sigmoidal gebogene. Rechts sehen wir die Trajektorien eines stabilen dynamischen Systems: Alle Anfangszustände konvergieren zum Ursprung, was zeigt, dass der aktuelle Zustand $\mathbf{x}(t)$ vollständig vom Anfangszustand $\mathbf{x}(0)$ *abhängt* – dies ist die reinste Form der temporalen Depension.

1.4 Aufbau der Arbeit

Kapitel 2 entwickelt die mathematischen Grundlagen der Depension auf drei Ebenen. Kapitel 3 definiert die Depensionsklassen DP-I bis DP-IV als Verallgemeinerung der Zustandsklassen. Kapitel 4 enthält die zentralen neuen Theoreme und Beweise – insbesondere den Zusammenhang zwischen Konvexität in der Regression und DP-I-Eigenschaft in der Systemtheorie, den Depensions-Index sowie das Regularisierungs-Klassen-Übergangstheorem. Kapitel 5 behandelt die Informationsgeometrie der Depension. Kapitel 6 verbindet VIF-Analyse und strukturelle Depension. Kapitel 7 präsentiert und interpretiert alle numerischen Experimente. Kapitel 8 gibt einen Ausblick.

2 Mathematische Grundlagen der Depension

2.1 Definition des Depensions-Operators

Definition 2.1 (Depensions-Operator). Sei $\mathcal{X}$ ein Eingaberaum und $\mathcal{Y}$ ein Ausgaberaum. Ein *Depensions-Operator* ist eine messbare Abbildung

$$\mathcal{D} : \mathcal{X} \rightarrow \mathcal{P}(\mathcal{Y}), \quad (1)$$

die jedem Eingabewert $x \in \mathcal{X}$ eine Wahrscheinlichkeitsverteilung über $\mathcal{Y}$ zuordnet. Der Wert $\mathcal{D}(x)$ heißt die *bedingte Depension* von Y gegeben x .

Bemerkung 2.2. Für deterministische Ausgaben degeneriert $\mathcal{D}(x)$ zu einem Dirac-Maß $\delta_{f(x)}$, und die Depension reduziert sich auf eine gewöhnliche Funktion $f : \mathcal{X} \rightarrow \mathcal{Y}$.

Die klassischen Modelle sind nun Spezialfälle:

Beispiel 2.3 (Statische Depension: Lineare Regression). Für $\mathcal{X} = \mathbb{R}^d$, $\mathcal{Y} = \mathbb{R}$ und $Y|\mathbf{x} \sim \mathcal{N}(\mathbf{w}^\top \mathbf{x} + b, \sigma^2)$:

$$\mathcal{D}_{\text{lin}}(\mathbf{x}) = \mathcal{N}(\mathbf{w}^\top \mathbf{x} + b, \sigma^2).$$

Der lineare Prädiktor $\mathbf{w}^\top \mathbf{x} + b$ ist der *lokale Depensions-Parameter*.

Beispiel 2.4 (Stochastische Depension: Logistische Regression). Für $\mathcal{X} = \mathbb{R}^d$, $\mathcal{Y} = \{0, 1\}$:

$$\mathcal{D}_{\text{log}}(\mathbf{x}) = \text{Bern}(\sigma(\mathbf{w}^\top \mathbf{x} + b)),$$

wobei $\sigma(z) = (1 + e^{-z})^{-1}$ die Sigmoid-Funktion ist. Die Abhängigkeit von $\mathbf{x}$ wird durch das Odds-Verhältnis $e^{\mathbf{w}^\top \mathbf{x} + b}$ quantifiziert.

Beispiel 2.5 (Temporale Depension: Dynamisches System). Für das LTI-System $\dot{\mathbf{x}}(t) = \mathbf{A}\mathbf{x}(t)$ mit $\mathbf{x}(0) = \mathbf{x}_0$:

$$\mathcal{D}_{\text{dyn}}(\mathbf{x}_0, t) = \delta_{e^{\mathbf{A}t}\mathbf{x}_0}.$$

Die Abhängigkeit des Zustands $\mathbf{x}(t)$ vom Anfangszustand $\mathbf{x}_0$ wird durch den Übergangsoperator $e^{\mathbf{A}t}$ vollständig beschrieben.

2.2 Grundlegende algebraische Struktur

Allen drei Depensionsformen liegt dieselbe algebraische Kernstruktur zugrunde:

Proposition 2.6 (Gemeinsame algebraische Struktur der Depension). *Die drei kanonischen Depensionsformen besitzen eine gemeinsame Struktur, die sich in einer zentralen Matrix und einem linearen Prädiktor manifestiert:*

Form	Zentrale Matrix	Linearer Prädiktor	Outputfunktion
Statisch (lin.)	$\mathbf{X}^\top \mathbf{X}$	$\mathbf{w}^\top \mathbf{x}$	$f(z) = z$
Stochastisch (log.)	$\mathbf{X}^\top \mathbf{S} \mathbf{X}$	$\mathbf{w}^\top \mathbf{x} + b$	$f(z) = \sigma(z)$
Temporal (dyn.)	$e^{\mathbf{A}t}$	$\mathbf{A} \mathbf{x}$	$f(t, \mathbf{x}_0) = e^{\mathbf{A}t} \mathbf{x}_0$

Die Konvergenz-/Stabilitätseigenschaft ist in allen drei Fällen durch die Eigenwerte der zentralen Matrix bestimmt.

Beweis. Für die lineare Regression ist die quadratische Verlustfunktion konvex genau dann, wenn $\mathbf{X}^\top \mathbf{X} \succeq 0$, was stets gilt. Für die logistische Regression gilt $\nabla^2 \mathcal{L} = \frac{1}{n} \mathbf{X}^\top \mathbf{S} \mathbf{X} \succeq 0$ (Theorem 4.1 unten). Für das dynamische System ist der Übergangsoperator $e^{\mathbf{A}t}$ genau dann beschränkt für alle $t \geq 0$, wenn alle Eigenwerte von $\mathbf{A}$ nicht-positiven Realteil haben (Zustandsklasse KS-I/II). Die Verbindung ist nicht zufällig: In allen Fällen bestimmt das Spektrum einer zentralen Matrix das Langzeitverhalten. $\square$

2.3 Die Sigmoid-Funktion als Depensions-Verbindungsglied

Proposition 2.7 (Sigmoid als stochastischer Depensions-Operator). *Die Sigmoid-Funktion $\sigma : \mathbb{R} \rightarrow (0, 1)$ ist das kanonische Verbindungsglied zwischen dem linearen Prädiktor und der stochastischen Depension. Sie besitzt folgende Eigenschaften, die sie für diesen Zweck qualifizieren:*

- (i) σ ist streng monoton wachsend und glatt ($\sigma \in C^\infty$).
- (ii) Die Ableitung $\sigma'(z) = \sigma(z)(1 - \sigma(z)) \in (0, 1/4]$ ist die Fisher-Information der Bernoulli-Depension am Arbeitspunkt z .
- (iii) Die Log-Odds-Linearität $\ln \frac{\sigma(z)}{1 - \sigma(z)} = z$ garantiert die interpretierbare Parametrisierung über Odds-Ratios.
- (iv) Als Verteilungsfunktion der logistischen Verteilung ist σ die kanonische Link-Funktion des Bernoulli-GLM.

3 Depensionsklassen DP-I bis DP-IV

Die Zustandsklassen KS-I bis KS-IV aus Epp [2026b] klassifizieren das Langzeitverhalten linearer dynamischer Systeme anhand der Spektralabszisse ihrer Systemmatrix. Das

Depensions-Framework verallgemeinert diese Klassifikation auf beliebige Depensionsmodelle.

3.1 Definition der Depensionsklassen

Definition 3.1 (Depensionsklassen DP-I bis DP-IV). Sei $\mathcal{M}$ ein Depensionsmodell mit zentraler Matrix $\mathbf{M}$ und sei $\text{spec}(\mathbf{M}) = \{\lambda_1, \dots, \lambda_n\} \subset \mathbb{C}$ das Spektrum. Die *Depensionsklasse* $\text{DP}(\mathcal{M})$ ist definiert durch:

$$\text{DP-I : } \max_k \text{Re}(\lambda_k) < 0 \quad (\text{konvergente Depension}) \quad (2)$$

$$\text{DP-II : } \max_k \text{Re}(\lambda_k) \leq 0 \wedge \exists k : \text{Re}(\lambda_k) = 0 \quad (\text{semieinfach}) \quad (\text{grenzstabile Depension}) \quad (3)$$

$$\text{DP-III : } \max_k \text{Re}(\lambda_k) > 0 \wedge \min_k \text{Re}(\lambda_k) \geq 0 \quad (\text{divergente Depension}) \quad (4)$$

$$\text{DP-IV : } \max_k \text{Re}(\lambda_k) > 0 \wedge \min_k \text{Re}(\lambda_k) < 0 \quad (\text{hyperbolische Depension}) \quad (5)$$




Abbildung 2: Links: Lage der Eigenwerte im komplexen Eigenwertraum $\mathbb{C}$ für die vier Depensionsklassen DP-I (blau, alle $\text{Re}(\lambda) < 0$), DP-II (grün, $\max \text{Re}(\lambda) = 0$), DP-III (rot, alle $\text{Re}(\lambda) > 0$) und DP-IV (orange, gemischte Vorzeichen). Rechts: Zeitliche Entwicklung der Norm $\|x(t)\|_2$ für alle vier Klassen. DP-I konvergiert exponentiell, DP-II bleibt beschränkt (Oszillation), DP-III divergiert, DP-IV zeigt gemischtes Verhalten.

Abbildung 2 zeigt die Klassifikation im Eigenwertraum und die daraus resultierenden Zeitverläufe auf eine besonders anschauliche Weise. Im linken Teilbild sind vier Gruppen von Eigenwerten eingetragen: Die blauen Kreise (DP-I) liegen vollständig links der imaginären Achse – jede Komponente des Zustandsvektors klingt exponentiell ab. Die grünen Dreiecke (DP-II) liegen auf oder links der Achse, mit mindestens einem auf der Achse – persistente Oszillationen ohne Wachstum. Die roten Quadrate (DP-III) liegen alle rechts der Achse – jede Komponente wächst exponentiell. Die orangen Rauten (DP-IV) haben Eigenwerte beidseits der Achse – ein Sattelpunkt mit stablerem und instabilem Unterraum.

Das rechte Teilbild bestätigt diese Analyse durch die Normentwicklung $\|x(t)\|_2$: DP-I (blau) fällt monoton gegen null, DP-II (grün) bleibt konstant auf einem Niveau, DP-III (rot)

explodiert exponentiell, und DP-IV (orange, gestrichelt) zeigt ein komplexes Verhalten, das von der Anfangsbedingung abhängt.

3.2 Eigenschaften der Depensionsklassen

Theorem 3.2 (Endlichkeit der Depension nach Klasse). *Für ein Depensionsmodell mit zentraler Matrix $\mathbf{M}$ gilt:*

- (i) $\text{DP}(\mathcal{M}) = \text{DP-I} \Rightarrow$ Der Depensions-Operator $e^{\mathbf{M}t}$ ist für alle $t \geq 0$ beschränkt, und $\|e^{\mathbf{M}t}\| \rightarrow 0$.
- (ii) $\text{DP}(\mathcal{M}) = \text{DP-II} \Rightarrow \sup_{t \geq 0} \|e^{\mathbf{M}t}\| < \infty$ (Endlichkeit), aber kein Abklingen.
- (iii) $\text{DP}(\mathcal{M}) \in \{\text{DP-III}, \text{DP-IV}\} \Rightarrow \|e^{\mathbf{M}t}\| \rightarrow \infty$ für generische Anfangsbedingungen (keine Endlichkeit).

Beweis. Die Aussagen (i) und (ii) folgen aus Theorem 3.1 und Theorem 3.2 in Epp [2026b] (Eigenschaften KS-I und KS-II), da die Depensionsklassen DP-I und DP-II direkt den Zustandsklassen KS-I und KS-II entsprechen. Für (iii): Sei $\mathbf{A} = \mathbf{M}$ und $\lambda^* = \alpha^* + i\beta^*$ ein Eigenwert mit $\text{Re}(\lambda^*) = \alpha^* > 0$. Mit dem zugehörigen Eigenvektor $\mathbf{v}^*$ gilt:

$$\|e^{\mathbf{M}t}\mathbf{x}_0\| \geq |\langle \mathbf{v}^*, e^{\mathbf{M}t}\mathbf{x}_0 \rangle| = e^{\alpha^*t} |\langle \mathbf{v}^*, \mathbf{x}_0 \rangle| \cdot |\cos(\beta^*t + \phi)|.$$

Für generische $\mathbf{x}_0$ (d. h. $\langle \mathbf{v}^*, \mathbf{x}_0 \rangle \neq 0$) wächst dies unbeschränkt. □

Phasenporträts der vier Depensionsklassen DP-I bis DP-IV




Abbildung 3: Phasenporträts der vier Depensionsklassen für ein 2D-System. DP-I (oben links): Alle Trajektorien konvergieren stabil zum Ursprung – die Depension ist vollständig durch den Anfangszustand bestimmt und klingt ab. DP-II (oben rechts): Elliptische Orbits – persistente Zeitabhängigkeit ohne Wachstum oder Abklingen; die Depension bleibt konstant in ihrer Stärke. DP-III (unten links): Alle Trajektorien entfernen sich vom Ursprung – die Depension wächst, Vorhersagen werden zunehmend unzuverlässig. DP-IV (unten rechts): Sattelpunkt – stabile und instabile Mannigfaltigkeit kreuzen sich; nur Anfangsbedingungen auf der stabilen Mannigfaltigkeit zeigen Konvergenz.

Die Phasenporträts in Abbildung 3 illustrieren den qualitativen Unterschied zwischen den Klassen auf unmittelbar anschauliche Weise. Für ein 2D-System zeigt DP-I einen stabilen Knoten oder Fokus – unabhängig vom Startpunkt konvergiert jede Bahn zum Ursprung. DP-II offenbart konzentrische Ellipsen: Die Depension bleibt konstant stark, ändert aber ständig ihre Richtung. DP-III zeigt einen instabilen Knoten – jede Störung wächst exponentiell an. DP-IV schließlich zeigt die charakteristische Sattelstruktur mit genau einer stabilen und einer instabilen Richtung.

4 Neue mathematische Aussagen und Beweise

4.1 Äquivalenz: Konvexität als DP-I-Eigenschaft

Das zentrale Verbindungstheorem zwischen der logistischen Regression und der Systemtheorie lautet:

Theorem 4.1 (Äquivalenz von Konvexität und DP-I-Eigenschaft). (Neu) Sei $\mathcal{L}(\mathbf{w})$ die binäre Kreuzentropie-Verlustfunktion der logistischen Regression und $H(\mathbf{w}) = \nabla^2 \mathcal{L}(\mathbf{w})$ die Hesse-Matrix. Die folgenden Aussagen sind äquivalent:

- (i) Die Verlustfunktion $\mathcal{L}$ ist strikt konvex.
- (ii) Alle Eigenwerte von H sind strikt positiv: $\text{spec}(H) \subset (0, \infty)$.
- (iii) Das Gradientenfluss-System $\dot{\mathbf{w}}(t) = -\nabla \mathcal{L}(\mathbf{w}(t))$ linearisiert um $\mathbf{w}^*$ besitzt die Depensionsklasse DP-I.
- (iv) Der Gradient-Abstieg konvergiert linear mit Rate $1 - \eta\mu$, wobei $\mu = \lambda_{\min}(H) > 0$.

Beweis. (i) $\Leftrightarrow$ (ii): Die Funktion $\mathcal{L}$ ist strikt konvex genau dann, wenn $H(\mathbf{w}) \succ 0$ für alle $\mathbf{w}$, d. h. alle Eigenwerte von H sind strikt positiv [Epp, 2026a, Theorem 4.1].

(ii) $\Rightarrow$ (iii): Das Gradientenfluss-System lautet in linearisierter Form um das Minimum $\mathbf{w}^*$:

$$\delta \dot{\mathbf{w}}(t) = -H(\mathbf{w}^*) \delta \mathbf{w}(t),$$

wobei $\delta \mathbf{w}(t) = \mathbf{w}(t) - \mathbf{w}^*$. Die Systemmatrix ist $\mathbf{A} = -H(\mathbf{w}^*)$. Da $\text{spec}(H(\mathbf{w}^*)) \subset (0, \infty)$, gilt $\text{spec}(\mathbf{A}) = \text{spec}(-H) \subset (-\infty, 0)$. Damit ist $\max_k \text{Re}(\lambda_k(\mathbf{A})) < 0$ – die Definition von DP-I.

(iii) $\Rightarrow$ (iv): Aus DP-I folgt $\|e^{\mathbf{A}t}\| \leq c e^{-\mu t}$ mit $\mu = \lambda_{\min}(H) > 0$. Der diskrete Gradientenabstieg $\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \eta \nabla \mathcal{L}(\mathbf{w}^{(k)})$ approximiert den Gradientenfluss, und die lineare Konvergenzrate folgt aus der starken Konvexität.

(iv) $\Rightarrow$ (i): Lineare Konvergenz setzt voraus, dass die Verlustfunktion stark konvex ist, was strikte Konvexität impliziert. $\square$

Korollar 4.2 (Gradientenabstieg als DP-I-System). (Neu) Der Gradientenabstieg für die logistische Regression ist ein dynamisches System der Klasse DP-I. Die Eigenwerte der Systemmatrix $\mathbf{A} = -H(\mathbf{w}^*)$ entsprechen den negatierten Eigenwerten der Hesse-Matrix; die Konvergenzrate des Optimierungsverfahrens ist identisch mit der Abklingrate des dynamischen Systems.




Abbildung 4: Links: Die Verlustlandschaft der logistischen Regression mit Gradientenabstiegs-Bahnen als Trajektorie eines DP-I-Systems; alle Bahnen konvergieren zum globalen Minimum w^* . Mitte: Mit wachsendem λ steigen alle Eigenwerte von $H + \lambda I$ – das System rückt in die DP-I-Zone und die Konvergenz verbessert sich merklich. Rechts: Die Iterationszahl wächst monoton mit der Konditionszahl $\kappa(H)$ auf halblogarithmischer Skala; kleine $\kappa(H)$ bedeuten schnelle Konvergenz.

Abbildung 4 bestätigt und vertieft Theorem 4.1 visuell. Links erkennt man die Verlustlandschaft als konzentrische elliptische Niveaulinien – ein klares Merkmal eines strikt konvexen, also DP-I-klassifizierten Depensionsmodells. Die roten Punkte markieren die GD-Bahn: Sie zeigt das charakteristische Spiralmuster eines DP-I-Systems mit oszillierenden, aber konvergierenden Trajektorien. Im mittleren Teilbild zeigt sich der Regularisierungseffekt: Jeder positive λ -Wert verschiebt alle Eigenwerte von H nach rechts, was sie noch weiter in die DP-I-Zone (blau schattiert) treibt. Rechts sieht man die unmittelbare Konsequenz für die Optimierung: Eine hohe Konditionszahl $\kappa(H)$ – also stark unterschiedliche Eigenwerte – führt zu einem gestreckten DP-I-System, das viele Iterationen benötigt.

4.2 Regularisierungs-Klassenübergangs-Theorem

Theorem 4.3 (Regularisierung als Depensionsklassen-Steuerung). (Neu) Sei $\mathbf{M}$ die zentrale Matrix eines beliebigen Depensionsmodells der Klasse DP-IV (hyperbolische Depension, also mit positiven und negativen Eigenwert-Realteilen). Dann gilt: L2-Regularisierung mit Parameter $\lambda > 0$ definiert die regularisierte zentrale Matrix

$$\mathbf{M}_\lambda := \mathbf{M} - \lambda \mathbf{I} \quad (6)$$

und bewirkt einen Depensionsklassen-Übergang $\text{DP-IV} \rightarrow \text{DP-I}$ genau dann, wenn

$$\lambda > \lambda_{\text{crit}} := \max_k \text{Re}(\lambda_k(\mathbf{M})). \quad (7)$$

Beweis. Die Eigenwerte von $\mathbf{M}_\lambda = \mathbf{M} - \lambda \mathbf{I}$ sind $\mu_k = \lambda_k(\mathbf{M}) - \lambda$. Die reellen Teile sind $\text{Re}(\mu_k) = \text{Re}(\lambda_k(\mathbf{M})) - \lambda$. Der maximale Realteil ist $\max_k \text{Re}(\mu_k) = \max_k \text{Re}(\lambda_k(\mathbf{M})) - \lambda = \lambda_{\text{crit}} - \lambda$. Für $\lambda > \lambda_{\text{crit}}$ gilt $\max_k \text{Re}(\mu_k) < 0$ – das ist die Definition von DP-I. Für $\lambda < \lambda_{\text{crit}}$ existiert mindestens ein k mit $\text{Re}(\mu_k) > 0$, was DP-III oder DP-IV bedeutet. Der Übergang findet genau bei $\lambda = \lambda_{\text{crit}}$ statt. $\square$

Korollar 4.4 (Universelle Stabilisierbarkeit durch L2-Regularisierung). (Neu) Jedes Depensionsmodell kann durch hinreichend starke L2-Regularisierung in DP-I überführt

werden. Dies gilt unabhängig von der ursprünglichen Klassen-Zugehörigkeit (DP-II, DP-III oder DP-IV) und zeigt, dass L2-Regularisierung nicht nur statistische Überanpassung verhindert, sondern die fundamentale dynamische Stabilität des Lernprozesses garantiert.




Abbildung 5: Links: Ridge-Regularisierungspfade – die Koeffizienten w_j als Funktionen von λ (logarithmische Skala). Für große λ konvergieren alle Koeffizienten gegen null (maximale Dämpfung). Rechts: Eigenwert-Verschiebung durch λ . Die blaue Kurve zeigt $\lambda_{\min}(H + \lambda I)$, die rote $\lambda_{\max}(H + \lambda I)$. Beide steigen linear in λ . Die Konditionszahl κ (grüne gestrichelte Linie, rechte Achse) sinkt mit wachsendem λ – die Depension wird zunehmend wohlkonditionierter, d. h. das DP-I-System wird regulärer.

Abbildung 5 illustriert Theorem 4.3 und Korollar 4.4 empirisch. Im linken Teilbild sehen wir die klassischen Ridge-Regularisierungspfade: Alle Koeffizienten werden gleichmäßig gegen null gedrückt. Wichtiger ist das rechte Teilbild, das die zugrundeliegende Spektralstruktur zeigt. Für jedes $\lambda > 0$ verschiebt sich der minimale Eigenwert $\lambda_{\min}(H + \lambda I)$ (blau) linear nach oben – ab einem kritischen Wert λ_{crit} überschreitet er null und das System wechselt in DP-I. Die Konditionszahl κ (grün gestrichelt) sinkt monoton – das zeigt die Verbesserung der numerischen Wohlkonditioniertheit.

4.3 Der Depensions-Index

Definition 4.5 (Depensions-Index). (Neu) Sei $\mathbf{M}$ die zentrale Matrix eines Depensionsmodells mit Spektralabszisse $\alpha^* = \max_k \text{Re}(\lambda_k)$ und spektralem Absolutmaximum $\rho = \max_k |\lambda_k|$. Der *Depensions-Index* (DI) ist definiert als:

$$\text{DI}(\mathcal{M}) := \begin{cases} 1 - \frac{\alpha^*}{\rho} & \text{falls } \rho > 0, \\ 1 & \text{falls } \rho = 0 \text{ (triviales System)}. \end{cases} \quad (8)$$

Es gilt $\text{DI} \in [0, 2]$ mit $\text{DI} = 1$ für DP-II-Systeme, $\text{DI} > 1$ für DP-I (stabiler als neutral), $\text{DI} = 0$ für Systeme mit $\alpha^* = \rho$ (alle Eigenwerte auf dem Rand, maximal instabil) und $\text{DI} < 0$ möglich bei DP-IV.

Proposition 4.6 (Reduktionen des Depensions-Index). (Neu) *Der Depensions-Index verallgemeinert bekannte Gütemaße:*

(i) Für lineare Regression mit Designmatrix $\mathbf{X}$ und $\mathbf{M} = \mathbf{X}^\top \mathbf{X}$:

$$\text{DI} = 1 - \frac{\lambda_{\max}}{\lambda_{\min}} = 0$$

ist nicht sinnvoll. Stattdessen: $\text{DI}_{\text{lin}} := R^2 = 1 - \text{RSS}/\text{TSS}$.

(ii) Für logistische Regression: $\text{DI}_{\log} := 1 - \ell(\hat{\mathbf{w}})/\ell(\mathbf{0})$ (McFadden- R^2), wobei ℓ die Log-Likelihood ist.

(iii) Für dynamisches System der Klasse DP-I: DI_{dyn} misst die Konvergenzrate relativ zur Systemstärke – ein Wert nahe 2 zeigt sehr schnelles Abklingen, ein Wert nahe 1 zeigt neutrales Verhalten.




Abbildung 6: Links: Depensions-Index ($\text{DI} = R^2$) für drei Regressionsdatensätze mit unterschiedlichem Rauschen. DI nahe 1 bedeutet starke (gut modellierbare) Depension, DI nahe 0 bedeutet schwache oder verrauschte Depension. Mitte: DI für dynamische Systeme als Funktion der Spektralabszisse α^* . Die DP-I-Zone ($\text{DI} > 1$) entspricht stabiler, endlicher Depension. Rechts: DI (McFadden- R^2) für logistische Regression mit verschiedenen Trennschärfen – je stärker die Klassen separiert sind, desto höher ist DI. Die Genauigkeit (rote Kurve) korreliert eng mit DI.

Abbildung 6 demonstriert, wie der Depensions-Index als einheitliches Gütemaß über alle drei Depensionsformen hinweg funktioniert. Im linken Teilbild sehen wir R^2 als Sonderfall des DI für statische Depension: Mit wachsendem Rauschen sinkt der DI von ≈ 0.9 auf ≈ 0.4 , was die abnehmende Erklärungskraft widerspiegelt. Im mittleren Teilbild ist der DI für dynamische Systeme als Funktion von α^* aufgetragen: Systeme im DP-I-Bereich ($\alpha^* < 0$) haben $\text{DI} > 0.5$, Systeme im DP-III-Bereich ($\alpha^* > 0$) haben $\text{DI} < 0.5$. Rechts zeigt der McFadden- R^2 als stochastischer DI, dass Klassifikatoren mit hohem DI auch hohe Genauigkeit erzielen – der Depensions-Index ist ein verlässlicher Prädiktor für Modellgüte.

4.4 Lemma über die Hesse-Systemmatrix-Dualität

Lemma 4.7 (Hesse-Systemmatrix-Dualität). (Neu) Sei $\mathcal{L}(\mathbf{w})$ eine zweimal stetig differenzierbare, strikt konvexe Verlustfunktion mit Hesse-Matrix $H(\mathbf{w}^*) \succ 0$ am Minimum. Dann gilt:

(i) Der Gradientenfluss $\dot{\mathbf{w}} = -H \delta \mathbf{w}$ (linearisiert) ist ein DP-I-System mit Systemmatrix $\mathbf{A} = -H$.

- (ii) Die Konvergenzrate des Gradientenflusses ist $e^{-\lambda_{\min}(H)t}$.
- (iii) Der Newton-Schritt entspricht dem exakten Lösen des quadratisch approximierten Depensions-Problems, was quadratische Konvergenz impliziert.
- (iv) Für L_2 -reguliertes $\mathcal{L}_\lambda(\mathbf{w}) = \mathcal{L}(\mathbf{w}) + \frac{\lambda}{2}\|\mathbf{w}\|^2$ gilt $H_\lambda = H + \lambda\mathbf{I}$, und die Konvergenzrate verbessert sich auf $e^{-(\lambda_{\min}(H) + \lambda)t}$.

Beweis. (i) Linearisierung um $\mathbf{w}^*$ mit $\delta\mathbf{w} = \mathbf{w} - \mathbf{w}^*$: $\dot{\delta\mathbf{w}} = -\nabla\mathcal{L}(\mathbf{w}^* + \delta\mathbf{w}) \approx -H(\mathbf{w}^*)\delta\mathbf{w}$. Die Systemmatrix ist $\mathbf{A} = -H(\mathbf{w}^*) \prec 0$ (alle Eigenwerte negativ), also DP-I.

(ii) Aus DP-I folgt $\|\delta\mathbf{w}(t)\| \leq c e^{-\lambda_{\min}(H)t}$.

(iii) Newton-Schritt: $\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - H^{-1}\nabla\mathcal{L}$. In der Nähe von $\mathbf{w}^*$ gilt mit Taylor-Entwicklung zweiter Ordnung: $\|\delta\mathbf{w}^{(k+1)}\| \leq \frac{M}{2\lambda_{\min}(H)}\|\delta\mathbf{w}^{(k)}\|^2$, was quadratische Konvergenz zeigt.

(iv) $H_\lambda = H + \lambda\mathbf{I}$ impliziert $\lambda_{\min}(H_\lambda) = \lambda_{\min}(H) + \lambda$. □

4.5 Spektraler Depensions-Konditionierungssatz

Theorem 4.8 (Spektraler Depensions-Konditionierungssatz). (Neu) Sei $\mathbf{M}$ die zentrale Matrix eines DP-I-Depensionsmodells mit Konditionszahl $\kappa(\mathbf{M}) = \lambda_{\max}(\mathbf{M})/\lambda_{\min}(\mathbf{M}) \geq 1$. Dann gilt:

- (i) Die Anzahl der Gradientenabstieg-Iterationen bis Genauigkeit ε ist $\Theta(\kappa(\mathbf{M}) \ln(1/\varepsilon))$.
- (ii) Der VIF des j -ten Prädiktors ist eine untere Schranke: $\kappa(\mathbf{M}) \geq \max_j \text{VIF}_j \geq 1$.
- (iii) Stark multikollineare Datensätze ($\max_j \text{VIF}_j \gg 1$) erzeugen ill-konditionierte DP-I-Systeme mit langsamer Konvergenz.

Beweis. (i) Aus der Konvergenztheorie des Gradientenabstiegs (Theorem 5.3 in [Epp 2026a](#)): Die lineare Konvergenzrate $(1 - \mu\eta)^k$ ergibt nach $k = \kappa \ln(1/\varepsilon)/(2)$ Iterationen die Genauigkeit ε .

(ii) Aus dem VIF-Algebraischen-Theorem (Satz 7.2 in [Epp 2026a](#)): $[\mathbf{M}^{-1}]_{jj} = \text{VIF}_j / \|\mathbf{x}_j\|^2$. Die Konditionszahl $\kappa(\mathbf{M}) = \lambda_{\max}/\lambda_{\min}$. Da $\text{VIF}_j \cdot \lambda_{\min} \leq \lambda_{\max}$ (über Cauchy-Schwarz), folgt $\kappa \geq \text{VIF}_j$ für alle j .

(iii) Kombination von (i) und (ii). □

5 Informationsgeometrie der Depension

5.1 Die Depensions-Mannigfaltigkeit

Definition 5.1 (Depensions-Mannigfaltigkeit). Die *Depensions-Mannigfaltigkeit* $\mathcal{M}$ ist der parametrisierte Raum aller Depensionsmodelle eine feste Klasse – zum Beispiel aller logistischen Regressionsmodelle mit Gewichtsvektor $\mathbf{w} \in \mathbb{R}^d$:

$$\mathcal{M} = \{\mathbb{P}_{\mathbf{w}} : \mathbf{w} \in \mathbb{R}^d\},$$

wobei $\mathbb{P}_{\mathbf{w}}(y|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x})^y (1 - \sigma(\mathbf{w}^\top \mathbf{x}))^{1-y}$. Die *Riemannsche Metrik* auf $\mathcal{M}$ wird durch die Fisher-Information-Matrix gegeben:

$$g(\mathbf{w}) = \mathcal{F}(\mathbf{w}) = \frac{1}{n} \mathbf{X}^\top \mathbf{S}(\mathbf{w}) \mathbf{X}, \quad (9)$$

wobei $\mathbf{S}(\mathbf{w}) = \text{diag}(\hat{p}_i(1 - \hat{p}_i))$ die Sigmoid-Gewichtsmatrix ist.

Bemerkung 5.2. Die Fisher-Information-Matrix $\mathcal{F}(\mathbf{w})$ ist identisch mit der Hesse-Matrix $H(\mathbf{w}) = \nabla^2 \mathcal{L}(\mathbf{w})$ der Kreuzentropie-Verlustfunktion. Dies ist kein Zufall, sondern eine fundamentale Eigenschaft der Exponentialfamilie: Die Krümmung der Verlustlandschaft ist die Riemannsche Krümmung der statistischen Mannigfaltigkeit.

Theorem 5.3 (Fisher-Information als Depensions-Krümmung). (Neu) *Die Fisher-Information $\mathcal{I}(\eta) = A''(\eta)$ der Bernoulli-Exponentialfamilie mit Log-Partition-Funktion $A(\eta) = \ln(1 + e^\eta)$ misst die lokale Krümmung der Depensions-Mannigfaltigkeit am Arbeitspunkt η :*

$$\mathcal{I}(\eta) = \sigma(\eta)(1 - \sigma(\eta)). \quad (10)$$

Die Krümmung ist maximal bei $\eta = 0$ (Entscheidungsgrenze) mit $\mathcal{I}(0) = 1/4$ und fällt symmetrisch zu null für $|\eta| \rightarrow \infty$.

Beweis. $A(\eta) = \ln(1 + e^\eta)$. Erste Ableitung: $A'(\eta) = e^\eta / (1 + e^\eta) = \sigma(\eta)$. Zweite Ableitung: $A''(\eta) = \sigma'(\eta) = \sigma(\eta)(1 - \sigma(\eta))$. Dies ist per Definition die Fisher-Information $\mathcal{I}(\eta)$. Das Maximum bei $\eta = 0$: $d\mathcal{I}/d\eta = \sigma(1 - \sigma)(1 - 2\sigma) = 0$ bei $\sigma = 1/2$, also $\eta = 0$, mit $\mathcal{I}(0) = 1/2 \cdot 1/2 = 1/4$. $\square$




Abbildung 7: Links: Sigmoid-Funktion (blau) und Fisher-Information $\mathcal{I}(z)$ (rot), die die Krümmung der Depensions-Mannigfaltigkeit beschreibt. Die maximale Krümmung bei $z = 0$ zeigt, dass Beobachtungen nahe der Entscheidungsgrenze am stärksten zur Parameterschätzung beitragen. Mitte: Log-Partition-Funktion $A(\eta)$ und ihre Ableitungen: $A'(\eta) = \mathbb{E}[Y]$ und $A''(\eta) = \text{Var}[Y]$. Die konvexe Form von A garantiert die DP-I-Klassifikation. Rechts: Das Krümmungsfeld $\sqrt{\det \mathcal{F}}$ auf der Depensions-Mannigfaltigkeit im 2D-Parameterraum – hohe Krümmung (hell) nahe der Entscheidungsgrenze, geringe Krümmung in extremen Regionen.

Das linke Teilbild von Abbildung 7 illustriert Theorem 5.3 direkt: Die rote Kurve der Fisher-Information hat ihr Maximum exakt bei $z = 0$ (der Entscheidungsgrenze) und fällt beidseitig ab. Dies hat eine tiefe Bedeutung: Datenpunkte nahe der Grenzfläche sind für das

Lernen der Depension am informativsten, weil dort die geometrische Krümmung der Mannigfaltigkeit am stärksten ist. Das mittlere Teilbild zeigt die Log-Partition-Funktion – ihre strenge Konvexität ($A'' > 0$ überall) ist die analytische Aussage, die die DP-I-Eigenschaft des zugehörigen Optimierungsproblems garantiert. Das rechte Teilbild visualisiert das Krümmungsfeld im 2D-Parameterraum: Die Mannigfaltigkeit ist nirgends flach, aber besonders stark gekrümmt entlang der Entscheidungsgrenzfläche.

5.2 Geodätiken und Natural Gradient Descent

Proposition 5.4 (Natural Gradient als Geodätik auf der Depensions-Mannigfaltigkeit). (Neu) *Der Natural Gradient Descent*

$$\mathbf{w}^{(k+1)} = \mathbf{w}^{(k)} - \eta \mathcal{F}(\mathbf{w}^{(k)})^{-1} \nabla \mathcal{L}(\mathbf{w}^{(k)}) \quad (11)$$

folgt der Geodätik auf der Depensions-Mannigfaltigkeit $(\mathcal{M}, g)$ und ist invariant gegenüber Reparametrisierungen des Modells. Er ist identisch mit dem Newton-Raphson-Verfahren (IRLS) für die logistische Regression.

Beweis. Der Natural Gradient ist der Richtung des steilsten Abstiegs bezüglich der Fisher-Riemannschen Metrik g : $\tilde{\nabla} \mathcal{L} = g^{-1} \nabla \mathcal{L} = \mathcal{F}^{-1} \nabla \mathcal{L}$. Da $\mathcal{F} = H$ für die logistische Regression, folgt $\tilde{\nabla} \mathcal{L} = H^{-1} \nabla \mathcal{L}$ – das ist der Newton-Schritt. Die Invarianz gegenüber Reparametrisierung folgt aus der kovarianten Transformation des metrischen Tensors. $\square$




Abbildung 8: Links: Die Verlust-Mannigfaltigkeit mit Gradientenfeld (weißen Pfeile) – jeder Pfeil zeigt in die negative Gradientenrichtung. Mitte: Zwei Geodätiken auf der Depensions-Mannigfaltigkeit: Der Gradientenabstieg (weiß, viele Schritte) folgt lokalen Isohöhenlinien zickzackartig, während Newton (gelb, wenige Schritte) die kürzeste Bahn auf der Riemannschen Mannigfaltigkeit nimmt. Rechts: Konvergenz auf der Mannigfaltigkeit (halblogarithmische Skala) – Newton (rot) zeigt die charakteristische quadratische Konvergenz (Knick nach unten), GD (blau) lineare Konvergenz.

Abbildung 8 zeigt eindrucksvoll den Unterschied zwischen den Pfaden auf der Depensions-Mannigfaltigkeit. Im mittleren Teilbild sieht man den Gradientenabstieg (weiß): Er nimmt viele, oft zickzackförmige Schritte und folgt nicht der kürzesten Bahn. Der Newton-Pfad (gelb) hingegen nimmt wenige, direkte Schritte – er folgt der Geodätik auf der Riemannschen Mannigfaltigkeit und ist damit geometrisch optimal. Das rechte Teilbild bestätigt den

theoretischen Unterschied in der Konvergenzrate: Während GD linear konvergiert – jede Iteration halbiert den Fehler annähernd – zeigt Newton die superlineare bis quadratische Konvergenz (erkennbar am stärkeren Abfall in der log-Skala nach der Anfangsphase).

6 Strukturelle Depension: VIF, Sparse Strukturen und Asymmetrie

6.1 VIF als Depensions-Diagnose

Theorem 6.1 (VIF als Maß für die inter-variable Depension). (Neu) Sei $\mathbf{X} \in \mathbb{R}^{n \times d}$ eine zentrierte Designmatrix. Der Varianzinflationsfaktor $\text{VIF}_j = 1/(1 - R_j^2)$ misst, wie stark die Variable x_j von den übrigen Variablen $\{x_k : k \neq j\}$ dependiert (abhängt). Formal gilt:

$$\text{VIF}_j = \frac{1}{1 - \text{DI}_j^{\text{stat}}}, \quad (12)$$

wobei $\text{DI}_j^{\text{stat}} = R_j^2$ der Depensions-Index der Hilfsregression von x_j auf alle übrigen Prädiktoren ist. Der VIF ist also der reziproke Komplementär-Depensions-Index der inter-variablen Depension.

Beweis. Direkte Folge aus der Definition $\text{VIF}_j = 1/(1 - R_j^2)$ und der Identifikation $\text{DI}_j^{\text{stat}} = R_j^2$ aus Proposition 4.6. $\square$

Korollar 6.2 (Multikollinearität als DP-IV-Symptom). (Neu) Wenn $\max_j \text{VIF}_j \gg 1$, dann ist das gesamte Regressionssystem schlecht konditioniert (Theorem 4.8). In der Systemtheorie entspricht dies einem DP-IV-System: Die Systemmatrix hat sowohl große als auch kleine Eigenwerte – stabiles und instabiles Verhalten koexistieren. Die Therapie in beiden Fällen ist identisch: L2-Regularisierung (Korollar 4.4).




Abbildung 9: Links: Korrelationsmatrix der 8 Prädiktorvariablen. Starke Korrelationen (Einträge nahe 1) zwischen x_1/x_3 , x_4/x_6 und x_2/x_8 sind sichtbar. Mitte: Die berechneten VIF-Werte. Variablen x_3 , x_6 , x_8 überschreiten die kritische Schwelle $\text{VIF} > 10$ (rote Linie) – sie haben einen Depensions-Index $R_j^2 > 0.9$ bezüglich der anderen Variablen. Rechts: Eigenwertspektrum der Präzisionsmatrix (inverse Kovarianzmatrix). Alle Eigenwerte sind positiv – das System ist in DP-I, aber die Spreizung (Konditionszahl) ist hoch. Die kleinen Eigenwerte entsprechen den multikollinearen Richtungen.

Abbildung 9 zeigt das vollständige Bild der strukturellen Depension. Im linken Teilbild erkennt man die Korrelationsmatrix mit ihren Block-Strukturen: Die starken blau hervorgehobenen Einträge nahe 1 signalisieren hohe inter-variable Depension. Im mittleren Teilbild sehen wir die VIF-Werte als direkte Messung: Die rot markierten Variablen (x_3, x_6, x_8) haben $VIF > 10$ – sie hängen so stark von den anderen ab ($R_j^2 > 0.9$), dass ihre Koeffizienten numerisch instabil werden. Das rechte Teilbild zeigt das Eigenwertspektrum der Präzisionsmatrix: Obwohl alle Eigenwerte positiv sind (DP-I), gibt es sehr kleine Eigenwerte nahe null – das sind die Richtungen, entlang derer die Depension fast perfekt ist und damit das Modell schlecht konditioniert macht.

6.2 Semantische Asymmetrie als Depensions-Richtungsstruktur

Definition 6.3 (Richtungsdepension). Für eine Systemmatrix $\mathbf{A} \in \mathbb{R}^{n \times n}$ definieren wir:

- Die *empfangende Depension* (Zeilen-Perspektive) von Zustand i als die Menge $\{j : A_{ij} \neq 0\}$ – alle Zustände, von denen i abhängt.
- Die *sendende Depension* (Spalten-Perspektive) von Zustand j als die Menge $\{i : A_{ij} \neq 0\}$ – alle Zustände, die von j abhängen.

Die *Depensions-Asymmetrie* von Zustand j ist:

$$\Delta_j(\mathbf{A}) := \text{out-deg}(j) - \text{in-deg}(j), \quad (13)$$

wobei $\text{out-deg}(j)$ die Anzahl der von j abhängigen Zustände und $\text{in-deg}(j)$ die Anzahl der Zustände, von denen j selbst abhängt.

Theorem 6.4 (Algorithmus-Effizienz durch Richtungsdepension). Für eine Systemmatrix $\mathbf{A}$ mit m Nicht-Null-Einträgen und einem Eingangsvektor $\mathbf{x}$ mit $s \ll n$ aktiven Einträgen gilt:

$$T_{\text{spalten-priorisiert}} = O\left(\sum_{j: x_j \neq 0} \text{out-deg}(j)\right) \leq O(s \cdot \bar{d}_{\text{out}}), \quad (14)$$

verglichen mit $T_{\text{zeilen-priorisiert}} = O(m)$. Der Speedup ist $m/(s \cdot \bar{d}_{\text{out}}) = n/s$ für uniforme Degree-Verteilung.

Beweis. Direkte Anwendung von Satz 2.6 in Epp [2026c]: Die spalten-priorisierte Berechnung iteriert nur über aktive Spalten j mit $x_j \neq 0$. Jede solche Spalte verursacht $\text{out-deg}(j)$ Operationen. Die Summe über alle s aktiven Spalten ergibt (14). $\square$




Abbildung 10: Links: Out-Degree-Verteilungen für eine uniforme und eine Power-Law-Dependenzstruktur (Broadcasting). Die Power-Law-Verteilung zeigt wenige Hub-Variablen mit extrem hohem Out-Degree – sie senden ihre Depension an viele andere und dominieren das Systemverhalten. Mitte: Rechenbeschleunigung durch spaltenbasierte Auswertung als Funktion der Aktivierungs-Sparsity. Für 90% Sparsity ergibt sich ein Speedup von $10\times$ (uniforme Verteilung) bis $12\times$ (Broadcasting). Rechts: Dependenz-Tiefe – die Stärke direkter (Tiefe 1, A -Einträge) und indirekter (Tiefe k , A^k -Einträge) Abhängigkeiten nimmt mit der Tiefe exponentiell ab, was die endliche Reichweite der Depension in sparse Systemen zeigt.

Abbildung 10 beleuchtet die strukturelle Depension aus drei Perspektiven. Links sehen wir den fundamentalen Unterschied zwischen uniformer und Power-Law-Verteilung der sendenden Depension: Während bei uniformer Struktur alle Variablen ungefähr gleich viele Abhängigkeiten erzeugen, hat die Power-Law-Struktur einige wenige Hub-Variablen, die den gesamten Abhängigkeitsgraph dominieren. Dies entspricht den in [Epp \[2026c\]](#) beschriebenen Broadcasting-Systemen. Das mittlere Teilbild zeigt die praktische Konsequenz: Bei 90% Sparsity (was für ReLU-aktivierte neuronale Netze typisch ist) lässt sich die Berechnung um den Faktor 10 beschleunigen. Das rechte Teilbild zeigt die Dependenz-Tiefe: Direkte Abhängigkeiten ($k = 1$) sind am stärksten, indirekte ($k > 1$) nehmen exponentiell ab.

6.3 Hierarchische Depension und Nilpotenz

Theorem 6.5 (Nilpotenz als maximale Tiefenbeschränkung der Depension). (Neu) *Eine Systemmatrix $A \in \mathbb{R}^{n \times n}$ ist genau dann nilpotent (mit Index h , d. h. $A^h = 0$, $A^{h-1} \neq 0$), wenn die Depension endliche Tiefe besitzt: Jede indirekte Abhängigkeit der Tiefe $\geq h$ verschwindet vollständig,*

$$[A^k]_{ij} = 0 \quad \forall k \geq h, \forall i, j. \quad (15)$$

Nilpotente Dependenzmatrizen beschreiben hierarchische Informationsflüsse (Feed-Forward-Netze, Produktionsketten), bei denen Information exakt $h-1$ Abhängigkeitsstufen durchläuft und dann vollständig absorbiert wird.

Beweis. Äquivalenz von Nilpotenz und endlicher Depensionstiefe h folgt direkt aus der Definition ($A^h = 0$) zusammen mit dem Beweis des Nilpotenz-Satzes in [Epp \[2026c\]](#) (Satz 3.1: hierarchische Matrizen sind nilpotent mit Index h). Die Aussage (15) ist die komponentenweise Formulierung. $\square$

Hierarchische Depension: Nilpotenzstruktur und Feedforward-Ausbreitung




Abbildung 11: Links: Nilpotente Depensionsmatrix mit Block-Dreiecksstruktur für $h = 4$ Ebenen. Die Diagonalblöcke (rot umrandet) sind null, die Super-Diagonal-Blöcke enthalten die Kopplungen. Mitte: Die Frobenius-Norm $\|A^k\|_F$ fällt mit der Potenz k : Für $k = h = 4$ ist sie exakt null (nilpotente Depension). Rechts: Ausbreitung des Zustands durch die Hierarchie-Ebenen über die Zeit: Die Energie fließt von Ebene L_1 (blau) über L_2 (orange) und L_3 (grün) nach L_4 (rot) – ein klar gerichteter, hierarchischer Depensions-Fluss.

Abbildung 11 veranschaulicht das Konzept der hierarchischen Depension auf eindrucksvolle Weise. Im linken Teilbild zeigt die Heatmap die Block-Dreiecksstruktur: Unterhalb der Diagonale (dunkelblau = null) fließt keine Information zurück, oberhalb der Diagonale (hellblau = Kopplung) fließt sie vorwärts. Im mittleren Teilbild sieht man das dramatische Abklingen der Matrixpotenzen: $\|A^1\|_F$ ist maximal, $\|A^2\|_F$ kleiner, und $\|A^4\|_F = 0$ exakt. Das rechte Teilbild zeigt die zeitliche Ausbreitung der Depension durch die Ebenen: Anfangs hat nur Ebene L_1 Energie; nach einem Zeitschritt erscheint Energie in L_2 , dann in L_3 und L_4 , während L_1 leer wird. Dies ist der reinste Ausdruck kausaler, hierarchischer Abhängigkeit.

7 Numerische Experimente: Plots und Analysen

7.1 Unified Framework: Synthese aller Konzepte




Abbildung 12: Unified Depension Framework. Oben links: Depensions-Stabilitätsverstärkung aller Modellklassen – statische Modelle (blau) und DP-I-Systeme (grün) stabil, DP-III (rot) divergiert. Oben Mitte: Sigmoid und Matrixexponential als Depensions-Operatoren; für $\lambda < 0$ (DP-I) klingt $e^{\lambda t}$ ab, für $\lambda = 0$ (DP-II) konstant, für $\lambda > 0$ (DP-III) explosiv wachsend. Oben rechts: Hesse- vs. Systemmatrix, Eigenwerte spiegelbildlich; $H \succ 0 \Leftrightarrow -H \prec 0$. Unten: DI, Bias-Varianz-Kurven und vollständige Klassifikationstabelle aller vier Depensionsklassen.

Abbildung 12 ist die Kerngrafik dieser Arbeit: Sie zeigt die Einheit der Depensions-Theorie über alle drei Quellarbeiten hinweg. Das obere linke Teilbild vergleicht die Stabilitätsstärke verschiedener Modellklassen – alle zeigen dieselbe Metrik (DI), aber unter verschiedenen Vorzeichen. Das obere mittlere Teilbild ist besonders aufschlussreich: Es zeigt nebeneinander die Sigmoid-Funktion (Kernstück der logistischen Regression) und die Matrixexponentialfunktionen für drei verschiedene λ -Werte. Für $\lambda < 0$ (DP-I, grün) klingt $e^{\lambda t}$ gegen null ab – genau wie die logistische Depension für extreme z -Werte flach wird. Für $\lambda = 0$ (DP-II, grau) bleibt alles konstant – wie die neutralen Odds bei $z = 0$. Diese visuell klare Analogie zeigt die tiefe Verbindung.

Das obere rechte Teilbild zeigt die Hesse-Systemmatrix-Dualität aus Lemma 4.7: Die blauen Balken (Hesse-Eigenwerte) und roten Balken (neg. Hesse-Eigenwerte) sind symmetrisch zur null-Achse. Positive Hesse-Eigenwerte (Konvexität) entsprechen negativen Systemmatrix-Eigenwerten (DP-I). Die Verbindung ist algebraisch exakt.

7.2 Zusammenfassung der numerischen Erkenntnisse

Tabelle 1: Numerische Zusammenfassung der Depensions-Eigenschaften aller Modellklassen.

Klasse	Endlich	DI-Bereich	Konvergenzrate	R^2 -Analog	Anwendung
DP-I (KS-I)	Ja	$(1, 2]$	$e^{-\mu t}$ (lin.)	$R^2 \rightarrow 1$	Stab. Reg.
DP-II (KS-II)	Ja	$= 1$	Konstant	$R^2 \approx 0.5$	Grenzstabil
DP-III (KS-III)	Nein	$[0, 1)$	$e^{\alpha^* t}$ (div.)	$R^2 \rightarrow 0$	Instabil
DP-IV (KS-IV)	Nein	$(0, 1)$	Gemischt	R^2 var.	Sattelp.

8 Diskussion und Ausblick

8.1 Wissenschaftliche Bedeutung der Depension

Der Begriff *Depension* und das gleichnamige mathematische Framework leisten aus unserer Sicht vier wesentliche Beiträge:

- (1) **Begriffliche Klarheit:** Der Begriff trifft das Wesen der Methode präzise. Er verhindert das konzeptionelle Durcheinander, das durch den historisch motivierten, aber inhaltlich irreführenden Begriff Regression entsteht.
- (2) **Strukturelle Einheit:** Das Framework zeigt, dass lineare Regression, logistische Regression und lineare dynamische Systeme nicht drei getrennte Methoden sind, sondern drei Spezialfälle desselben mathematischen Konzepts – der Modellierung von Abhängigkeiten zwischen Variablen.
- (3) **Neue mathematische Einsichten:** Die Äquivalenz zwischen der Konvexitätsbedingung in der Regression und der DP-I-Eigenschaft in der Systemtheorie (Theorem 4.1), der Regularisierungs-Klassenübergang (Theorem 4.3), die VIF-Depensions-Index-Verbindung (Theorem 6.1) und die Nilpotenz-Tiefenbeschränkung (Theorem 6.5) sind echte neue mathematische Ergebnisse.
- (4) **Praktische Konsequenzen:** Regularisierung zur Erzwingung von DP-I, die Wahl des spaltenbasierten Algorithmus für sparse Depension, und der Depensions-Index als universelles Gütemaß sind direkt in der Praxis einsetzbar.

8.2 Ausblick: Weiterführende Forschungsrichtungen über alle Kapitel

Der in dieser Arbeit entwickelte Depensions-Begriff und das zugehörige mathematische Framework öffnen eine Vielzahl von Forschungsrichtungen, die weit über die hier behandelten Spezialfälle hinausgehen. Der folgende Ausblick ist nach den Kapiteln der Arbeit strukturiert und entwickelt für jedes Themengebiet konkrete, wissenschaftlich motivierte Erweiterungen.

8.2.1 Zur Begriffsentwicklung (Kapitel 1)

Depension in weiteren Wissenschaftsdisziplinen. Die Etymologie des Begriffs *Depension* eröffnet einen breiten konzeptuellen Rahmen, der weit über die Statistik hinausreicht. In der Physik beschreibt die Abhängigkeit von Feldern voneinander – etwa die Kopplung elektromagnetischer Felder durch Maxwell-Gleichungen – eine temporale Depension im Kontinuum. In der Biologie finden sich Depensionsstrukturen in Genregulationsnetzwerken, bei denen die Expression eines Gens von der Konzentration anderer Transkriptionsfaktoren abhängt. In der Soziologie lassen sich soziale Einflussmodelle (DeGroot-Modell, Friedkin-Johnsen-Modell) als stochastische temporale Depension reformulieren, was ihre Analyse mit den hier entwickelten Werkzeugen eröffnet.

Terminologische Einbettung in internationale Standards. Für eine internationale wissenschaftliche Anerkennung wäre die Einbettung des Begriffs in bestehende mathematische Terminologien – insbesondere in der englischsprachigen Literatur als *depension* oder *mathematical dependence theory* – ein wichtiger nächster Schritt. Die Abgrenzung zu verwandten Konzepten wie *dependency* (Informatik), *dependence* (Kopula-Theorie) und *reliance* (Ingenieurwesen) wäre dabei zu klären und formal zu begründen.

Depension in der Philosophie der Mathematik. Die Unterscheidung zwischen *Dependenz* (die Tatsache) und *Depension* (das Maß des Abhängens) berührt grundlegende Fragen der Erkenntnistheorie und Wissenschaftsphilosophie: Was bedeutet es, dass eine Variable von einer anderen abhängt? Wie verhält sich funktionale Abhängigkeit zu kausaler Dependenz? Diese Fragen sind nicht nur sprachlicher Natur, sondern mathematisch substantiell und bilden ein eigenständiges Forschungsfeld im Schnittpunkt von Logik und Statistik.

8.2.2 Zur mathematischen Grundstruktur (Kapitel 2)

Verallgemeinerte Depensions-Operatoren. Der in Definition 2.1 eingeführte Depensions-Operator $\mathcal{D} : \mathcal{X} \rightarrow \mathcal{P}(\mathcal{Y})$ lässt sich vielfältig erweitern. Ausgaberräume $\mathcal{Y}$ können beliebige Maßräume sein – neben $\mathbb{R}$ und $\{0, 1\}$ auch Funktionenräume (Gaussian-Process-Regression), Wahrscheinlichkeitsmatrizen (Multinomiale Depension) oder Survival-Verteilungen (Hazard-Depension). Auch $\mathcal{X}$ kann stochastisch sein, was zu einer *vollständig stochastischen Depension* führt, beschrieben durch bedingte Erwartungsoperatoren in L^2 -Räumen.

Depension in Banach- und Hilberträumen. Die algebraische Struktur der zentralen Matrix lässt sich auf unendlich-dimensionale Räume übertragen. Für Funktionaldaten (FDA) wäre ein Depensions-Operator als Integraloperator $(\mathcal{D}f)(x) = \int K(x, y)f(y) dy$ mit Kern K zu definieren. Die Depensionsklassen würden dann durch das essentielle Spektrum von K bestimmt, und die Frage der DP-I-Eigenschaft wäre äquivalent zur Frage, ob K ein Hilbert-Schmidt-Kontraktion ist.

Multivariate Depension: Tensor-Erweiterung. Wenn nicht nur eine Ausgabegröße $Y \in \mathbb{R}$, sondern ein Ausgabetensor $\mathcal{Y} \in \mathbb{R}^{d_1 \times \dots \times d_k}$ vorliegt, entsteht eine *multivariate Depension höherer Ordnung*. Analogien zu Tucker-Zerlegungen und Tensor-Netzwerken aus der Quantenphysik deuten darauf hin, dass die Depensions-Klassifikation im Tensorraum

durch Kronecker-Produkte der Systemmatrizen beschreibbar ist: $\mathbf{A}_{\text{tensor}} = \mathbf{A}_1 \otimes \mathbf{A}_2 \otimes \dots \otimes \mathbf{A}_k$.

8.2.3 Zu den Dependenzklassen (Kapitel 3)

Stetige Klassifikation und Übergangsphänomene. Die vorliegende Arbeit definiert die Dependenzklassen DP-I bis DP-IV als diskrete Kategorien. Eine bedeutende offene Frage ist, ob eine stetige Klassifikation möglich ist – etwa durch den Dependenz-Index DI als kontinuierliche Koordinate auf einer Klassifikationsskala. Ein solcher *Dependenz-Grad* könnte Übergangsphänomene beschreiben: Wie verhält sich ein System, das von DP-II knapp in DP-I übergeht? Welche Bifurkations-Typen treten dabei auf?

Robuste Dependenzklassen unter Störungen. In der Praxis sind Systemmatrizen $\mathbf{A}$ nie exakt bekannt, sondern mit Messrauschen behaftet. Für eine Systemmatrix $\hat{\mathbf{A}} = \mathbf{A} + \varepsilon \mathbf{E}$ (mit $\mathbf{E}$ einer Zufallsmatrix und $\varepsilon \ll 1$) ist zu untersuchen, wann die Dependenzklasse unter Störungen stabil bleibt. Dies führt auf Pseudospektral-Theorie und ε -Pseudospectra: Auch wenn alle exakten Eigenwerte links der imaginären Achse liegen (DP-I), kann das System transienten numerischen Instabilitäten ausgesetzt sein, wenn die Pseudospectra die Achse berühren.

Dependenzklassen für zeitvariante Systeme. Das LTI-Paradigma $\dot{\mathbf{x}} = \mathbf{A}\mathbf{x}$ mit konstanter Systemmatrix ist für viele Anwendungen zu restriktiv. Für zeitvariante Systeme $\dot{\mathbf{x}} = \mathbf{A}(t)\mathbf{x}$ sind die Dependenzklassen durch den Floquet-Multiplikator (periodische Systeme) beziehungsweise durch den maximalen Lyapunov-Exponenten $\lambda_{\max}^{\text{Lyap}} = \lim_{t \rightarrow \infty} \frac{1}{t} \ln \|\Phi(t)\|$ (allgemeine zeitvariante Systeme) zu definieren, wobei $\Phi(t)$ die Übergangsmatrix ist.

8.2.4 Zu den mathematischen Hauptergebnissen (Kapitel 4)

Erweiterung des Konvexitäts-Äquivalenz-Theorems auf nichtkonvexe Verluste. Theorem 4.1 verbindet strikte Konvexität mit der DP-I-Eigenschaft. Für neuronale Netze und andere nichtkonvexe Optimierungsprobleme bricht diese Äquivalenz zusammen – die Hesse-Matrix ist nicht global positiv definit, und das Gradientenfluss-System ist kein globales DP-I-System. Dennoch lässt sich lokal um jeden Sattelpunkt und jedes lokale Minimum eine DP-IV- beziehungsweise DP-I-Umgebung definieren. Eine Verallgemeinerung der Dependenzklassen auf *lokale Dependenzklassen* in der Umgebung kritischer Punkte wäre ein bedeutender theoretischer Fortschritt und würde die Verbindung zur Morse-Theorie herstellen.

Regularisierungs-Pfade in nichtlinearen Modellen. Theorem 4.3 zeigt den Klassen-Übergang durch lineare L2-Regularisierung. In nichtlinearen Modellen (z. B. neuronale Netze mit ReLU-Aktivierung) erzeugt L2-Regularisierung einen komplexen, hochdimensionalen Pfad im Parameterraum. Die Frage, wie lange dieser Pfad welchen Dependenzklassen angehört und an welchen Stellen Klassen-Übergänge stattfinden, ist fundamental für das Verständnis von Generalisierung und Überanpassung. Eine Verbindung zur Neural Tangent Kernel (NTK) Theorie liegt nahe: Im unendlich-breiten Netz verhält sich der NTK als Hesse-Äquivalent, und seine Spektraleigenschaften bestimmen die Dependenzklasse des Lernprozesses.

Verallgemeinerung des Depensions-Index auf multivariate Ausgaben. Der Depensions-Index DI in Definition 4.5 ist für skalare Ausgaben definiert. Für vektorwertige Ausgaben $\mathbf{y} \in \mathbb{R}^m$ könnte ein *tensorieller Depensions-Index* $\text{DI}_{\text{mat}} \in \mathbb{R}^{m \times m}$ als Matrix-Analogon konstruiert werden, wobei $[\text{DI}]_{kl}$ die partielle Depension von Ausgabe k auf Ausgabe l misst. Der Spectral-DI $\max_k \lambda_k(\text{DI}_{\text{mat}})$ würde dann als Gesamtmaß dienen.

Optimalitätsbedingungen für den Depensions-Übergang. Korollar 4.4 zeigt, dass jedes Modell durch hinreichend starke Regularisierung in DP-I überführt werden kann. Offen ist hingegen die Frage nach dem *optimalen* Regularisierungsparameter λ^* : Nicht jeder $\lambda > \lambda_{\text{crit}}$ ist gleich gut – zu kleine λ liefern schwache DP-I-Systeme mit langsamer Konvergenz, zu große λ drücken alle Koeffizienten gegen null (zu starke Dämpfung, Verlust der Depensionsstruktur). Das optimale λ^* balanciert Klassen-Stabilität und Depensions-Informationsgehalt.

8.2.5 Zur Informationsgeometrie der Depension (Kapitel 5)

Depensions-Krümmung als Lernrate-Prädiktor. Theorem 5.3 zeigt, dass die Fisher-Information die Krümmung der Depensions-Mannigfaltigkeit beschreibt und bei $\eta = 0$ maximal ist. Eine wichtige praktische Konsequenz: Datenpunkte nahe der Entscheidungsgrenze tragen am stärksten zur Parameteraktualisierung bei. Dies legt eine adaptive Lernrate nahe, die mit der lokalen Fisher-Information skaliert: $\eta_{\text{adapt}}(\mathbf{x}) = \eta_0 / \mathcal{I}(\mathbf{w}^\top \mathbf{x})$. Für Datenpunkte weit von der Entscheidungsgrenze ($|\mathbf{w}^\top \mathbf{x}| \gg 0$) würde diese Lernrate stark erhöht, was einem gezielten “Aufmerksamkeitsmechanismus” auf informationsarme Regionen entspräche.

Geodätiken auf general Depensions-Mannigfaltigkeiten. Proposition 5.4 identifiziert den Newton-Schritt als Geodätik auf der logistischen Depensions-Mannigfaltigkeit. Diese Geometrie ist für die logistische Regression vollständig charakterisiert. Für allgemeinere Modelle – etwa für Mixture Models, Hidden Markov Models oder generative Adversarial Networks – ist die Riemannsche Geometrie der Depensions-Mannigfaltigkeit noch nicht vollständig verstanden. Die Berechnung von Christoffel-Symbolen und Riemannschen Krümmungstensoren für solche Modelle ist rechnerisch intensiv, aber theoretisch lösbar und würde optimale Methoden zweiter Ordnung auf eine neue Klasse von Depensionsmodellen ausweiten.

Amari-Dualität und die duale Depensions-Geometrie. In der Informationsgeometrie nach Amari existiert zu jeder Riemannschen Mannigfaltigkeit $(\mathcal{M}, g)$ eine duale Konnektion ∇^* . Die e -Geometrie (Likelihood-Metrik) und die m -Geometrie (Momente-Metrik) auf der Depensions-Mannigfaltigkeit definieren einen dualen Rahmen, in dem die Projektionstheoreme von Amari direkt anwendbar sind. Das Pythagoras-Theorem der Informationsgeometrie liefert dann eine variationelle Charakterisierung des optimalen Depensions-Modells.

Nicht-euklidische Depensions-Räume. Moderne maschinelle Lernmethoden verarbeiten Daten in hyperbolischen Räumen (Graphen, Hierarchien) oder auf Kugelflächen (Einheitsvektoren, normierte Einbettungen). In diesen nicht-euklidischen Geometrien sind die Standard-Depensionsoperatoren nicht mehr angemessen. Hyperbolische Depension – etwa für taxonomische Abhängigkeiten oder Knowledge Graphs – würde die Verwendung

der Poincaré-Metrik $g_{ij} = \delta_{ij}/(1 - \|x\|^2)^2$ als Depensions-Metrik erfordern und einen vollständig neuen Zweig der Depensions-Theorie eröffnen.

8.2.6 Zu struktureller und sparse Depension (Kapitel 6)

Dynamische VIF-Analyse für zeitvariante Kovariatstrukturen. Theorem 6.1 definiert den VIF als statisches Maß für inter-variable Depension. In vielen realen Anwendungen – Finanzrenditen, Klimadaten, biologische Zeitreihen – ändert sich die Korrelationsstruktur der Prädiktoren über die Zeit. Ein *dynamischer VIF* $VIF_j(t)$ würde die zeitliche Entwicklung der inter-variablen Depension beschreiben und Phasen hoher Multikollinearität (z. B. Finanzkrisen, bei denen alle Renditen gemeinsam fallen) von stabilen Phasen trennen. Die Verbindung zur GARCH-Theorie und zu dynamischen Copula-Modellen liegt nahe.

Graphen-Depension: Laplace-Spektrum und Diffusion. Für Daten auf Graphen – etwa soziale Netzwerke, Molekulargraphen oder Straßennetze – ist die Systemmatrix $\mathbf{A}$ der normierte Graph-Laplacian $L = D^{-1/2}AD^{-1/2}$, wobei A die Adjazenzmatrix ist. Die Depensionsklasse des Diffusionsprozesses $\dot{\mathbf{x}} = -L\mathbf{x}$ ist stets DP-I (da $L \succeq 0$), aber die Konvergenzrate wird durch die Spektrallücke $\lambda_2(L) > 0$ (Fiedler-Wert) bestimmt. Eine Graphen-Depensions-Theorie würde untersuchen, wie Graphstruktur – Dichte, Cliques, Brücken – die Depensionsklasse und den DI beeinflusst.

Sparse Depensions-Identifikation und Komprimiertes Lesen. In hochdimensionalen Settings ($d \gg n$) ist die vollständige Schätzung der Depensionsmatrix $\mathbf{A} \in \mathbb{R}^{d \times d}$ unmöglich. Analog zum Compressed-Sensing-Paradigma könnte eine *sparse Depensions-Identifikation* die sparseste Matrix $\mathbf{A}$ bestimmen, die kompatibel mit den beobachteten Zeitreihen ist. Dies würde zur Lösung von Optimierungsproblemen der Form $\min_{\mathbf{A}} \|\mathbf{A}\|_1$ s. t. $\|\dot{\mathbf{x}} - \mathbf{A}\mathbf{x}\|_2 \leq \varepsilon$ führen – einer Verbindung zur LASSO-Depension (L1-Regularisierung im dynamischen Kontext).

Tiefen-Depension in mehrschichtigen Architekturen. Theorem 6.5 zeigt, dass nilpotente Matrizen endliche Depensions-Tiefe beschreiben. In tiefen neuronalen Netzen mit L Schichten ist die effektive Systemmatrix das Schichtenprodukt

$$\mathbf{A}_{\text{eff}} = W_L \sigma(W_{L-1} \sigma(\cdots \sigma(W_1 \mathbf{x}) \cdots)).$$

Für lineare Netze ergibt sich $\mathbf{A}_{\text{eff}} = W_L \cdots W_1$. Die *Tiefen-Depension* untersucht, wie sich die Depensionsklasse des Produkts aus denen der Faktoren zusammensetzt: Ist das Produkt zweier DP-I-Matrizen wieder DP-I? Dies ist eng mit Gradientenexplosion/-verschwindung verbunden.

Semantische Depensions-Netzwerke und Sprachmodelle. Die in Kapitel 6 eingeführte Unterscheidung zwischen sender und empfangender Depension findet eine natürliche Anwendung in Transformer-Modellen: Der Attention-Mechanismus $\text{Attn}(Q, K, V) = \text{softmax}(QK^\top / \sqrt{d_k})V$ kann als asymmetrischer Depensions-Operator interpretiert werden, bei dem Query Q die empfangende und Key K die sendende Depension definiert. Eine Depensions-Analyse großer Sprachmodelle würde untersuchen, welche Token-Paare starke Depensions-Strukturen zeigen und wie diese mit semantischen Relationen – Ursache-Wirkung, Subjekt-Objekt, Kohärenz – zusammenhängen.

8.2.7 Zur numerischen Methodik (Kapitel 7)

Adaptive Plot-Generierung und interaktive Depensions-Explorierung. Die zwölf statischen Abbildungen dieser Arbeit sind Querschnitte durch einen hochdimensionalen Parameterraum. Eine interaktive Explorations-Umgebung – etwa als Jupyter-Dashboard oder WebGL-Visualisierung – würde Depensionsklassen-Übergänge, Eigenwert-Verschiebungen und Regularisierungs-Pfade in Echtzeit erfahrbar machen. Besonders aufschlussreich wäre eine 3D-Darstellung der Verlust-Mannigfaltigkeit.

Statistische Tests auf Depensionsklassen. Bislang fehlen Hypothesentests, die formal testen, ob ein empirisches Depensionsmodell der Klasse DP-I oder DP-IV angehört. Für die Systemmatrix $\hat{\mathbf{A}}$ aus Zeitreihendaten wäre ein Test auf $H_0: \max_k \operatorname{Re}(\lambda_k(\mathbf{A})) \leq 0$ gegen $H_1: \max_k \operatorname{Re}(\lambda_k(\mathbf{A})) > 0$ zu entwickeln. Bootstrap-Methoden für Eigenwerte (Bootstrap Spectral Tests) oder Likelihoodquotienten-Tests auf Basis der Spektralabszisse könnten Ansätze liefern.

Benchmarking des Depensions-Index. Der DI als universelles Gütemaß muss in Benchmark-Studien mit bestehenden Maßen (AUC-ROC, F_1 -Score, BIC, AIC, adjusted R^2) verglichen werden. Zentral sind dabei Aussagen über Schätzeffizienz, Bias-Varianz-Tradeoff und Robustheit gegenüber Ausreißern.

8.2.8 Übergreifende Forschungsprogramme

Depension in der Quantenmechanik. Quantenmechanische Zustandsentwicklung $i\hbar\partial_t|\psi\rangle = H|\psi\rangle$ mit hermiteschem H beschreibt, wie $|\psi(t)\rangle$ von $|\psi(0)\rangle$ abhängt: $|\psi(t)\rangle = e^{-iHt/\hbar}|\psi(0)\rangle$. Da $\operatorname{Re}(\lambda_k(-iH/\hbar)) = 0$ für alle Eigenwerte, ist die Quanten-Depension stets DP-II. Dekohärenz fügt dissipative Terme hinzu und verschiebt das System Richtung DP-I. Die *Quanten-Depensions-Theorie* würde dies in der Lindblad-Mastergleichung verankern.

Stochastische Depension und Itô-Kalkül. Systeme mit Rauschen $d\mathbf{x} = \mathbf{A}\mathbf{x}dt + \mathbf{B}dW_t$ (stochastische DGLen) definieren eine *stochastische temporale Depension*, deren Klassifikation durch mean-square-Stabilität erfolgt: Das System ist DP-I im Mittelquadrat genau dann, wenn die Ljapunov-Gleichung $\mathbf{A}P + P\mathbf{A}^\top + \mathbf{B}\mathbf{B}^\top = 0$ eine positiv definite Lösung $P \succ 0$ besitzt. Für lineare stochastische Systeme wären die Depensionsklassen durch das Itô-Integral-Lyapunov-Spektrum zu definieren, was neue Charakterisierungen des Depensions-Index als stochastisches Maß ermöglicht.

Depension und maschinelles Lernen: ein vereinheitlichter Rahmen. Langfristig könnte die Depensions-Theorie als Meta-Theorie des maschinellen Lernens fungieren: Jedes Trainingsverfahren ist ein Gradientenfluss (DP-I-System im Parameterraum), jede Netzwerkarchitektur definiert eine Depensionsstruktur, und jede Regularisierungsmethode steuert die Depensionsklasse. Eine vollständige Depensions-Theorie des maschinellen Lernens würde Generalisierungstheorie (PAC-Theorie, Rademacher-Komplexität), Optimierungstheorie und Netzwerk-Dynamik unter einem gemeinsamen begrifflichen Dach vereinen.

Depension und Kausalität. Die richtungsabhängige Depension steht in engem Zusammenhang mit kausalen Graphen (DAGs). Eine formale Verbindung der Depensions-Theorie

mit Pearlscher Kausalität und do-Kalkül würde es erlauben, kausale Effekte als gerichtete Depensions-Flüsse zu messen und die do-Operation als Intervention in die Depensions-Systemmatrix zu interpretieren: $do(X_j = x)$ entspricht der Elimination der Spalte j aus $\mathbf{A}$.

Quantitative Wirtschaftsanalyse durch Depension. Wie in Epp [2026b] gezeigt, sind Wirtschaftssysteme als dynamische Systeme modellierbar. Das Depensions-Framework ermöglicht eine vollständige Klassifikation wirtschaftlicher Modelle nach DP-I bis DP-IV: Stabile Märkte sind DP-I, Grenzgleichgewichte DP-II, Blasen und exponentielle Wachstumsphasen DP-III, Sattelpunkt-Gleichgewichte DP-IV. Die Messung des Depensions-Index für makro-ökonomische Zeitreihen (BIP, Inflationsrate, Arbeitslosenquote) in gleitenden Zeitfenstern würde eine neue, formal abgesicherte Methode der Konjunkturanalyse liefern. Phasenübergänge von DP-I nach DP-IV könnten als Frühwarnindikatoren für wirtschaftliche Instabilität dienen.

9 Zusammenfassung

Die vorliegende Arbeit hat den neuen Begriff **Depension** eingeführt und mathematisch fundiert. Die zentralen Ergebnisse sind:

Kernaussagen der Depension.

- (1) **Definition:** Depension ist die mathematische Disziplin der Abhängigkeitsmodellierung – von statischer (Y von X) über stochastische ($P(Y|X) = \sigma(\mathbf{w}^\top \mathbf{x})$) bis hin zu temporaler ($\mathbf{x}(t) = e^{\mathbf{A}t} \mathbf{x}_0$) Abhängigkeit.
- (2) **Depensionsklassen DP-I bis DP-IV** verallgemeinern die Zustandsklassen KS-I bis KS-IV auf beliebige Depensionsmodelle. DP-I (alle $\text{Re}(\lambda) < 0$) garantiert endliche, abklingende Abhängigkeit.
- (3) **Theorem 4.1:** Strikte Konvexität der Verlustfunktion $\Leftrightarrow$ alle Hesse-Eigenwerte positiv $\Leftrightarrow$ Gradientenfluss in DP-I.
- (4) **Theorem 4.3:** L2-Regularisierung mit $\lambda > \lambda_{\text{crit}}$ erzwingt DP-I für jedes Depensionsmodell.
- (5) **Depensions-Index DI** ist das universelle Gütemaß: R^2 für statische, McFadden- R^2 für stochastische, und Spektralmaß für temporale Depension.
- (6) **Lemma 4.7:** Hesse-Matrix H und Systemmatrix $\mathbf{A}$ stehen in exakter Dualität: $\mathbf{A} = -H$, und die Konvergenzrate des Optimierungsverfahrens ist identisch mit der dynamischen Abklingrate.
- (7) **Theorem 6.5:** Nilpotente Depensionsmatrizen beschreiben hierarchische Systeme mit endlicher Depensions-Tiefe – das mathematische Fundament aller Feed-Forward-Architekturen.

Literatur

Amari, S.-I. (2016). *Information Geometry and Its Applications*. Springer, Tokyo.

- Cox, D. R. (1958). The regression analysis of binary sequences (with discussion). *Journal of the Royal Statistical Society, Series B*, 20(2):215–242.
- Epp, S. (2026a). *Logistische Regression: Theorie, Algorithmen und Zukunftsperspektiven*, 2026.
- Epp, S. (2026b). *Zustandsklassen dynamischer Systeme: Endlichkeit des Zustandsvektors, Systemmatrix-Klassifikation, der Subgraph Algorithmus, Graphprofilverteilung und wirtschaftliche Implikationen*, 2026.
- Epp, S. (2026c). *Asymmetrische Matrixmultiplikation für dynamische Systeme: Von der Boolean Algebra zur Systemtheorie*, 2026.
- Galton, F. (1886). Regression towards mediocrity in hereditary stature. *Journal of the Anthropological Institute of Great Britain and Ireland*, 15:246–263.
- Golub, G. H. & Van Loan, C. F. (2013). *Matrix Computations* (4th ed.). Johns Hopkins University Press, Baltimore.
- McCullagh, P. & Nelder, J. A. (1989). *Generalized Linear Models* (2nd ed.). Chapman & Hall, London.
- Moler, C. & Van Loan, C. (2003). Nineteen dubious ways to compute the exponential of a matrix, twenty-five years later. *SIAM Review*, 45(1):3–49.
- Agresti, A. (2015). *Foundations of Linear and Generalized Linear Models*. Wiley, Hoboken.
- Belsley, D. A., Kuh, E. & Welsch, R. E. (1980). *Regression Diagnostics: Identifying Influential Data and Sources of Collinearity*. Wiley, New York.
- Bernstein, D. S. (2009). *Matrix Mathematics: Theory, Facts, and Formulas* (2nd ed.). Princeton University Press, Princeton.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York.
- Bregman, L. M. (1967). The relaxation method of finding the common point of convex sets and its application to the solution of problems in convex programming. *USSR Computational Mathematics and Mathematical Physics*, 7(3):200–217.
- Brogan, W. L. (1991). *Modern Control Theory* (3rd ed.). Prentice Hall, Englewood Cliffs.
- Bühlmann, P. & van de Geer, S. (2011). *Statistics for High-Dimensional Data: Methods, Theory and Applications*. Springer, Berlin.
- Chen, R. T. Q., Rubanova, Y., Bettencourt, J. & Duvenaud, D. (2018). Neural ordinary differential equations. *Advances in Neural Information Processing Systems*, 31.
- Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4):303–314.
- Deisenroth, M. P., Faisal, A. A. & Ong, C. S. (2020). *Mathematics for Machine Learning*. Cambridge University Press, Cambridge.
- Engle, R. F. (1982). Autoregressive conditional heteroscedasticity with estimates of the variance of United Kingdom inflation. *Econometrica*, 50(4):987–1007.
- Friedman, J., Hastie, T. & Tibshirani, R. (2001). *The Elements of Statistical Learning: Data Mining, Inference, and Prediction* (2nd ed.). Springer, New York.

- Goodfellow, I., Bengio, Y. & Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge.
- Granger, C.W.J. (1969). Investigating causal relations by econometric models and cross-spectral methods. *Econometrica*, 37(3):424–438.
- Haber, E. & Ruthotto, L. (2017). Stable architectures for deep neural networks. *Inverse Problems*, 34(1):014004.
- Hastie, T., Tibshirani, R. & Wainwright, M. (2015). *Statistical Learning with Sparsity: The Lasso and Generalizations*. CRC Press, Boca Raton.
- Higham, N.J. (2008). *Functions of Matrices: Theory and Computation*. SIAM, Philadelphia.
- Hoerl, A.E. & Kennard, R.W. (1970). Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12(1):55–67.
- Horn, R.A. & Johnson, C.R. (2013). *Matrix Analysis* (2nd ed.). Cambridge University Press, Cambridge.
- Jacot, A., Gabriel, F. & Hongler, C. (2018). Neural tangent kernel: Convergence and generalization in neural networks. *Advances in Neural Information Processing Systems*, 31.
- Jordan, M.I. (Ed.) (1999). *Learning in Graphical Models*. MIT Press, Cambridge.
- Kalman, R.E. (1960). Contributions to the theory of optimal control. *Boletín de la Sociedad Matemática Mexicana*, 5(2):102–119.
- Kingma, D.P. & Ba, J. (2015). Adam: A method for stochastic optimization. *International Conference on Learning Representations (ICLR)*.
- Koltchinskii, V. & Lounici, K. (2017). Concentration inequalities and moment bounds for sample covariance operators. *Bernoulli*, 23(1):110–133.
- LeCun, Y., Boser, B., Denker, J.S., Henderson, D., Howard, R.E., Hubbard, W. & Jackel, L.D. (1989). Backpropagation applied to handwritten zip code recognition. *Neural Computation*, 1(4):541–551.
- Ljung, L. (1999). *System Identification: Theory for the User* (2nd ed.). Prentice Hall, Upper Saddle River.
- Luenberger, D.G. (1979). *Introduction to Dynamic Systems: Theory, Models, and Applications*. Wiley, New York.
- Lyapunov, A.M. (1892). The general problem of the stability of motion (translated from Russian in 1992). *International Journal of Control*, 55(3):531–773.
- Murphy, K.P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press, Cambridge.
- Neal, R.M. (1996). *Bayesian Learning for Neural Networks*. Springer, New York.
- Nesterov, Y. (2004). *Introductory Lectures on Stochastic Optimization*. Kluwer Academic, Dordrecht.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference* (2nd ed.). Cambridge University Press, Cambridge.

- Recht, B., Fazel, M. & Parrilo, P. A. (2010). Guaranteed minimum-rank solutions of linear matrix equations via nuclear norm minimization. *SIAM Review*, 52(3):471–501.
- Rudin, W. (1991). *Functional Analysis* (2nd ed.). McGraw-Hill, New York.
- Shalev-Shwartz, S. & Ben-David, S. (2014). *Understanding Machine Learning: From Theory to Algorithms*. Cambridge University Press, Cambridge.
- Sontag, E. D. (1998). *Mathematical Control Theory: Deterministic Finite Dimensional Systems* (2nd ed.). Springer, New York.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society, Series B*, 58(1):267–288.
- Trefethen, L. N. & Embree, M. (2005). *Spectra and Pseudospectra: The Behavior of Nonnormal Matrices and Operators*. Princeton University Press, Princeton.
- Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L. & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- Wainwright, M. J. & Jordan, M. I. (2008). Graphical models, exponential families, and variational inference. *Foundations and Trends in Machine Learning*, 1(1–2):1–305.
- Zou, H. & Hastie, T. (2005). Regularization and variable selection via the elastic net. *Journal of the Royal Statistical Society, Series B*, 67(2):301–320.