

Das Prinzip der Diskretion des Kontinuierlichen

Formale Analyse von neun fundamentalen Anwendungsbereichen der
Diskretisierung
kontinuierlicher Phänomene in der Natur und Wissenschaft

Stephan Epp

6. Juni 2026

Zusammenfassung

Die Planck'sche Quantenhypothese ($E = h\nu$) beschreibt das fundamentale Prinzip, kontinuierliche physikalische Größen in diskrete, handhabbare Einheiten zu zerlegen. Dieses Diskretisierungsprinzip ist kein isoliertes Phänomen der Quantenphysik, sondern eine universelle Strategie zur Beschreibung, Messung und Berechnung kontinuierlicher Naturphänomene. Die vorliegende Arbeit identifiziert und analysiert neun weitere, grundlegende Anwendungsbereiche dieses Prinzips: die Fourier-Reihenentwicklung, das Shannon-Nyquist-Abtasttheorem, die numerische Integration (Riemann-Summe), die Euler-Diskretisierung gewöhnlicher Differentialgleichungen, die Finite-Elemente-Methode, die Analog-Digital-Wandlung, die neuronale Kodierung (Integrate-and-Fire), die DNA-Sequenzierung sowie die Diskretisierung stochastischer Prozesse durch Markov-Ketten. Für jeden Bereich wird formal bewiesen, dass das diskrete Modell gegen das kontinuierliche Pendant konvergiert und die Qualität der Approximation quantifizierbar ist. Die Ergebnisse werden durch matplotlib-Visualisierungen illustriert und schließen mit einem umfassenden Ausblick auf offene Forschungsfragen.

Inhaltsverzeichnis

1	Einführung	2
1.1	Motivation und Problemstellung	2
1.2	Ziel der Arbeit	2
1.3	Überblick der behandelten Phänomene	2
2	Grundlagen	2
2.1	Funktionenräume und Normen	2
2.2	Konvergenzbegriffe	3
3	Anwendungsbereich 1: Planck'sche Strahlungsformel	3
3.1	Kontinuierliches Modell	3
3.2	Diskretisierung durch Energiequanten	3

4	Anwendungsbereich 2: Fourier-Reihenentwicklung	4
4.1	Kontinuierliches Modell	4
4.2	Diskretisierung durch harmonische Oberwellen	4
5	Anwendungsbereich 3: Shannon-Nyquist-Abtasttheorem	6
5.1	Kontinuierliches Modell	6
5.2	Diskretisierung durch Abtastwerte	6
6	Anwendungsbereich 4: Riemann-Integral als Diskretisierung	6
6.1	Kontinuierliches Modell	6
6.2	Diskretisierung durch Riemann-Summen	6
7	Anwendungsbereich 5: Euler-Diskretisierung von ODEs	7
7.1	Kontinuierliches Modell	7
7.2	Diskretisierung durch das Euler-Verfahren	8
8	Anwendungsbereich 6: Finite-Elemente-Methode (FEM)	9
8.1	Kontinuierliches Modell	9
8.2	Diskretisierung durch lineare Ansatzfunktionen	9
9	Anwendungsbereich 7: Analog-Digital-Wandlung (ADC)	10
9.1	Kontinuierliches Modell	10
9.2	Diskretisierung durch Quantisierung	11
10	Anwendungsbereich 8: Neuronale Kodierung (Leaky Integrate-and-Fire)	11
10.1	Kontinuierliches Modell	11
10.2	Diskretisierung durch Aktionspotentiale	11
11	Anwendungsbereich 9: DNA-Sequenzierung	12
11.1	Kontinuierliches Modell	12
11.2	Diskretisierung durch Base Calling	13
12	Anwendungsbereich 10: Markov-Ketten und stochastische Prozesse	14
12.1	Kontinuierliches Modell	14
12.2	Diskretisierung durch endliche Markov-Ketten	14
13	Vergleichende Analyse	15
13.1	Universelle Konvergenzeigenschaften	15
14	Verbindung zum Subgraph Algorithmus: Graphen-Diskretisierung als universelles Prinzip	16
14.1	Motivation und Einbettung in das Diskretisierungsparadigma	16
14.2	Formale Grundlagen: Graphen als metrische Räume	17
14.3	Punkt 1: Der Signaturoperator als diskreter Messfunktional	17
14.4	Punkt 2: Spektrale Graphentheorie als kontinuierliche Signatur	18
14.5	Punkt 3: Neue Familie von Graphmatching-Algorithmen mit Konvergenzgarantien	19
14.6	Einbettung in das universelle Diskretisierungstheorem	21
15	Zusammenfassung	22

16 Ausblick	22
16.1 Vereinheitlichung durch abstrakte Diskretisierungstheorie	22
16.2 Quanteninformationstheorie und diskrete Quantenzustände	23
16.3 Diskretisierung in der künstlichen Intelligenz: Quantisierung neuronaler Netze	23
16.4 Biologische Diskretisierung: Evolutionäre Genomik	24
16.5 Numerische Analysis: Exponentiell konvergente Methoden	24
16.6 Stochastische Diskretisierung: Monte-Carlo-Methoden	25
16.7 Neuronale Kodes und Informationstheorie	25
Literaturverzeichnis	27

1 Einführung

1.1 Motivation und Problemstellung

Seit Max Plancks revolutionärer Entdeckung im Jahr 1900, dass elektromagnetische Energie nicht kontinuierlich, sondern in diskreten Quanten der Größe $E = h\nu$ abgegeben wird, hat das Prinzip der Diskretisierung kontinuierlicher Größen die gesamte Naturwissenschaft und Ingenieurwissenschaft durchdrungen. Die Konstante

$$h = 6,626\,070\,15 \times 10^{-34} \text{ J s}$$

ist dabei weit mehr als ein Skalierungsfaktor: Sie symbolisiert die Erkenntnis, dass Natur und Mathematik eine fundamentale Strategie teilen – die *Reproduktion des Kontinuierlichen durch diskrete Teillösungen*.

Definition 1 (Diskretisierungsprinzip). Sei $f : \Omega \rightarrow \mathbb{R}$ eine auf einem kontinuierlichen Bereich $\Omega \subseteq \mathbb{R}^n$ definierte Größe. Eine *Diskretisierung* von f ist eine Abbildung

$$\mathcal{D}_N : C(\Omega) \rightarrow \mathbb{R}^N, \quad f \mapsto (f_1, f_2, \dots, f_N),$$

sodass für eine geeignete Rekonstruktionsabbildung $\mathcal{R}_N : \mathbb{R}^N \rightarrow C(\Omega)$ gilt:

$$\lim_{N \rightarrow \infty} \|f - \mathcal{R}_N(\mathcal{D}_N(f))\|_\infty = 0.$$

1.2 Ziel der Arbeit

Ziel dieser Arbeit ist es, neun grundlegende Anwendungsfälle des Diskretisierungsprinzips formal zu analysieren, zu beweisen und zu visualisieren. Dabei wird für jedes Beispiel gezeigt:

- Die formale Struktur des kontinuierlichen Phänomens
- Die Konstruktion der diskreten Approximation
- Der Konvergenzbeweis $\mathcal{R}_N \circ \mathcal{D}_N \rightarrow \text{id}$ für $N \rightarrow \infty$
- Die Fehlerordnung als Funktion der Diskretisierungsauflösung N

1.3 Überblick der behandelten Phänomene

2 Grundlagen

2.1 Funktionenräume und Normen

Definition 2 (L^p -Raum). Für $1 \leq p < \infty$ ist der L^p -Raum über $[a, b]$ definiert als:

$$L^p([a, b]) = \left\{ f : [a, b] \rightarrow \mathbb{R} \mid \int_a^b |f(x)|^p dx < \infty \right\}$$

mit Norm $\|f\|_p = \left(\int_a^b |f(x)|^p dx \right)^{1/p}$.

Definition 3 (Bandlimitiertes Signal). Ein Signal $x(t)$ heißt *bandlimitiert* mit Bandbreite B , wenn seine Fourier-Transformierte $\hat{x}(f) = 0$ für alle $|f| > B$ gilt.

Nr.	Phänomen	Kontinuum	Diskretisierung	Fehlerordnung
0	Planck-Strahlung	Spektrum $B(\nu)$	Energiequanten E_n	$O(N^{-1})$
1	Fourier-Reihe	$f \in L^2$	Harmonische a_k, b_k	$O(N^{-s})$
2	Shannon-Nyquist	$x(t) \in BL$	Abtastwerte $x(nT_s)$	exakt bei $f_s > 2B$
3	Riemann-Integral	$\int_a^b f dx$	Riemann-Summe	$O(N^{-2})$
4	Euler-Verfahren	ODE $\dot{y} = F$	Euler-Schritt h	$O(h)$
5	FEM	PDE $Lu = f$	FE-Ansatz	$O(h^p)$
6	ADC	$u(t) \in \mathbb{R}$	b -Bit-Wert	$O(2^{-b})$
7	Neuronale Kodierung	$V_m(t)$	Spikerate λ	Information I
8	DNA-Sequenzierung	Fluoreszenzkurve	Basealphabet Σ	Basengenauigkeit
9	Markov-Ketten	OU-Prozess	Zustandsraum S	$O(\Delta x ^2)$

Tabelle 1: Übersicht der behandelten Diskretisierungsphänomene

2.2 Konvergenzbegriffe

Definition 4 (Gleichmäßige Konvergenz einer Diskretisierung). Eine Folge diskreter Approximationen $(f_N)_{N \in \mathbb{N}}$ konvergiert *gleichmäßig* gegen f , wenn:

$$\forall \varepsilon > 0 \exists N_0 \in \mathbb{N} : \forall N \geq N_0, \forall x \in \Omega : |f_N(x) - f(x)| < \varepsilon.$$

3 Anwendungsbereich 1: Planck'sche Strahlungsformel

3.1 Kontinuierliches Modell

Die klassische Rayleigh-Jeans-Formel beschreibt die spektrale Energiedichte eines schwarzen Körpers als:

$$B_{\text{klass}}(\nu, T) = \frac{2\nu^2}{c^2} k_B T,$$

was für $\nu \rightarrow \infty$ zu unendlicher Energie führt (*Ultraviolett katastrophe*).

3.2 Diskretisierung durch Energiequanten

Satz 1 (Planck'sche Strahlungsformel). Unter der Annahme, dass jeder Strahlungsschwingung der Frequenz ν nur ganzzahlige Vielfache von $E_n = nh\nu$ ($n \in \mathbb{N}_0$) als Energie annehmen kann, ergibt sich die mittlere Energie:

$$\langle E \rangle = \frac{\sum_{n=0}^{\infty} nh\nu e^{-nh\nu/(k_B T)}}{\sum_{n=0}^{\infty} e^{-nh\nu/(k_B T)}} = \frac{h\nu}{e^{h\nu/(k_B T)} - 1}.$$

Beweis. Sei $\beta = (k_B T)^{-1}$ und $x = h\nu\beta$. Der Nenner ist die geometrische Reihe:

$$Z = \sum_{n=0}^{\infty} e^{-nx} = \frac{1}{1 - e^{-x}}.$$

Der Zähler ergibt sich durch Differentiation nach β :

$$\sum_{n=0}^{\infty} nh\nu e^{-nh\nu\beta} = -h\nu \frac{\partial}{\partial(h\nu\beta)} \ln Z = h\nu \frac{e^{-x}}{1 - e^{-x}} = \frac{h\nu}{e^x - 1}.$$

Division liefert $\langle E \rangle = h\nu / (e^{h\nu/(k_B T)} - 1)$. Die spektrale Energiedichte ist dann:

$$B(\nu, T) = \frac{2h\nu^3}{c^2} \cdot \frac{1}{e^{h\nu/(k_B T)} - 1}. \quad \square$$

Lemma 1 (Klassischer Grenzfall). Für $h\nu \ll k_B T$ gilt $B(\nu, T) \rightarrow \frac{2\nu^2}{c^2} k_B T$ (Rayleigh-Jeans).

Beweis. Taylor-Entwicklung: $e^{h\nu/(k_B T)} - 1 \approx h\nu/(k_B T)$ ergibt $B \approx 2\nu^2 k_B T / c^2$. $\square$




Abbildung 1: Links: Diskrete Moden (Stammlinien) vs. kontinuierliches Planck-Spektrum bei $T = 5778$ K. Rechts: Konvergenz des relativen Fehlers mit steigender Modenanzahl N .

4 Anwendungsbereich 2: Fourier-Reihenentwicklung

4.1 Kontinuierliches Modell

Sei $f \in L^2([0, 2\pi])$ eine quadratintegrierbare, periodische Funktion. Das kontinuierliche Spektrum $\hat{f}$ enthält (im Allgemeinen) unendlich viele Frequenzkomponenten.

4.2 Diskretisierung durch harmonische Oberwellen

Definition 5 (Fourier-Partialsumme). Die N -te Fourier-Partialsumme von f ist:

$$S_N f(t) = \frac{a_0}{2} + \sum_{k=1}^N (a_k \cos(kt) + b_k \sin(kt)),$$

wobei

$$a_k = \frac{1}{\pi} \int_0^{2\pi} f(t) \cos(kt) dt, \quad b_k = \frac{1}{\pi} \int_0^{2\pi} f(t) \sin(kt) dt.$$

Satz 2 (Parseval'sche Gleichung). Für $f \in L^2([0, 2\pi])$ gilt:

$$\|f\|_2^2 = \frac{a_0^2}{2} + \sum_{k=1}^{\infty} (a_k^2 + b_k^2).$$

Satz 3 (Konvergenz der Fourier-Reihe in L^2). Für jedes $f \in L^2([0, 2\pi])$ gilt:

$$\lim_{N \rightarrow \infty} \|f - S_N f\|_2 = 0.$$

Beweis. Die trigonometrischen Polynome $\{1, \cos(kt), \sin(kt)\}_{k \geq 1}$ bilden ein vollständiges Orthonormalsystem in $L^2([0, 2\pi])$ (Satz von Fischer-Riesz). Daher ist die orthogonale Projektion $S_N f$ die beste Approximation in $\text{span}\{e^{ikt}\}_{|k| \leq N}$, und der Restfehler:

$$\|f - S_N f\|_2^2 = \sum_{|k| > N} |\hat{f}(k)|^2 \rightarrow 0,$$

da $\sum_{k=-\infty}^{\infty} |\hat{f}(k)|^2 = \|f\|_2^2 < \infty$ (Parseval). □

Lemma 2 (Fehlerabfall für glatte Funktionen). Ist f s -mal stetig differenzierbar, so gilt:

$$\|f - S_N f\|_{\infty} \leq C_s \cdot N^{-s}$$

für eine von f und s abhängige Konstante $C_s > 0$.

Beweis. Partielle Integration s -mal liefert $|\hat{f}(k)| \leq \|f^{(s)}\|_1 / |k|^s$. Summation über $|k| > N$ und Cauchy-Schwarz ergibt die Schranke. □




Abbildung 2: Fourier-Partialsummen der Rechteckfunktion für $N \in \{1, 3, 9, 31\}$ harmonische Oberwellen. Der rote Bereich zeigt den Approximationsfehler. Das Gibbs-Phänomen (überschwingen an Sprungstellen) ist bei $N = 31$ sichtbar.

5 Anwendungsbereich 3: Shannon-Nyquist-Abtasttheorem

5.1 Kontinuierliches Modell

Ein analoges Signal $x(t) \in L^2(\mathbb{R})$ ist definiert für alle $t \in \mathbb{R}$ und enthält prinzipiell unendlich viele Informationspunkte.

5.2 Diskretisierung durch Abtastwerte

Satz 4 (Shannon-Nyquist-Whittaker Abtasttheorem). Sei $x(t)$ ein bandlimitiertes Signal mit Bandbreite B (d. h. $\hat{x}(f) = 0$ für $|f| > B$). Wird $x(t)$ mit der Abtastfrequenz $f_s > 2B$ abgetastet, dann kann $x(t)$ exakt aus den Abtastwerten $x(nT_s)$ mit $T_s = 1/f_s$ rekonstruiert werden:

$$x(t) = \sum_{n=-\infty}^{\infty} x(nT_s) \operatorname{sinc}\left(\frac{t - nT_s}{T_s}\right),$$

wobei $\operatorname{sinc}(u) = \sin(\pi u)/(\pi u)$.

Beweis. Da $x(t)$ bandlimitiert ist, gilt für die Fourier-Transformierte $\hat{x}(f)$, dass sie auf $(-B, B)$ getragen wird. Das abgetastete Signal

$$x_s(t) = x(t) \sum_{n=-\infty}^{\infty} \delta(t - nT_s)$$

hat das Spektrum $\hat{x}_s(f) = f_s \sum_{k=-\infty}^{\infty} \hat{x}(f - kf_s)$. Für $f_s > 2B$ überlappen sich die Kopien $\hat{x}(f - kf_s)$ nicht (kein Aliasing). Ein ideales Tiefpassfilter $H(f) = T_s \cdot \mathbf{1}_{|f| \leq B}$ extrahiert $\hat{x}(f)$ exakt. Die inverse Fourier-Transformation liefert die Sinc-Rekonstruktionsformel. $\square$

Lemma 3 (Aliasing-Fehler). Für $f_s \leq 2B$ entsteht ein Aliasing-Fehler der Größe:

$$\|x - \hat{x}_{\text{rekon}}\|_2^2 = 2 \int_B^{f_s/2} |\hat{x}(f)|^2 df + \text{Interferenzterme} > 0.$$

6 Anwendungsbereich 4: Riemann-Integral als Diskretisierung

6.1 Kontinuierliches Modell

Das Riemann-Integral einer Funktion $f : [a, b] \rightarrow \mathbb{R}$ ist definiert als:

$$I = \int_a^b f(x) dx = \lim_{N \rightarrow \infty} \sum_{i=1}^N f(\xi_i) \Delta x_i.$$

6.2 Diskretisierung durch Riemann-Summen

Definition 6 (Mittelpunkt-Riemann-Summe). Für eine gleichmäßige Zerlegung $x_i = a + i \cdot h$ mit $h = (b - a)/N$ und Mittelpunkten $\xi_i = x_{i-1} + h/2$:

$$R_N(f) = h \sum_{i=1}^N f\left(a + \left(i - \frac{1}{2}\right) h\right).$$




Abbildung 3: Sinc-Rekonstruktion aus diskreten Abtastwerten für vier Abtastfrequenzen. Bei $f_s = 11$ Hz (knapp über Nyquist) ist die Rekonstruktion bereits sehr gut. Bei $f_s = 200$ Hz (Überabtastung) wird das Signal nahezu perfekt wiedergegeben.

Satz 5 (Fehlerordnung der Mittelpunkregel). Sei $f \in C^2([a, b])$. Dann gilt:

$$\left| \int_a^b f(x) dx - R_N(f) \right| \leq \frac{(b-a)^3}{24N^2} \max_{x \in [a, b]} |f''(x)| = O(N^{-2}).$$

Beweis. Für jedes Intervall $[x_{i-1}, x_i]$ liefert Taylor-Entwicklung um ξ_i :

$$\int_{x_{i-1}}^{x_i} f(x) dx = f(\xi_i) h + \frac{f''(\xi_i)}{24} h^3 + O(h^5).$$

Der lokale Fehler pro Intervall ist $|e_i| \leq \frac{M_2}{24} h^3$, wobei $M_2 = \max |f''|$. Summation über N Intervalle:

$$|I - R_N(f)| \leq N \cdot \frac{M_2}{24} h^3 = \frac{M_2(b-a)}{24} h^2 = \frac{M_2(b-a)^3}{24N^2}. \quad \square$$

7 Anwendungsbereich 5: Euler-Diskretisierung von ODEs

7.1 Kontinuierliches Modell

Ein kontinuierliches dynamisches System wird beschrieben durch:

$$\dot{y}(t) = F(t, y(t)), \quad y(t_0) = y_0, \quad t \in [t_0, T].$$




Abbildung 4: Riemann-Rechtecksummen für $N \in \{4, 10, 50, 200\}$ Intervalle. Der relative Fehler fällt wie $O(N^{-2})$ ab – bei $N = 200$ liegt er unter 0.001 %.

7.2 Diskretisierung durch das Euler-Verfahren

Definition 7 (Explizites Euler-Verfahren). Mit Schrittweite $h > 0$ und Zeitpunkten $t_k = t_0 + kh$:

$$y_{k+1} = y_k + h \cdot F(t_k, y_k), \quad k = 0, 1, 2, \dots$$

Satz 6 (Konvergenz des Euler-Verfahrens). Sei F Lipschitz-stetig in y mit Lipschitz-Konstante $L > 0$, und sei die exakte Lösung $y(t) \in C^2([t_0, T])$. Dann gilt für den globalen Fehler:

$$\max_{0 \leq k \leq N} |y(t_k) - y_k| \leq \frac{hM_2}{2L} (e^{L(T-t_0)} - 1) = O(h),$$

wobei $M_2 = \max_{t \in [t_0, T]} |\ddot{y}(t)|$.

Beweis. Lokaler Abschneidefehler: Taylor-Entwicklung der exakten Lösung um t_k :

$$y(t_{k+1}) = y(t_k) + h F(t_k, y(t_k)) + \frac{h^2}{2} \ddot{y}(\tau_k), \quad \tau_k \in (t_k, t_{k+1}).$$

Lokaler Fehler: $|\ell_k| = |y(t_{k+1}) - y(t_k) - h F(t_k, y(t_k))| \leq \frac{h^2}{2} M_2$.

Fehlerfortpflanzung: Sei $e_k = y(t_k) - y_k$. Dann:

$$e_{k+1} = e_k + h[F(t_k, y(t_k)) - F(t_k, y_k)] + \ell_k.$$

Mit Lipschitz: $|e_{k+1}| \leq (1 + hL)|e_k| + \frac{h^2}{2} M_2$.

Induktion und $(1 + hL)^N \leq e^{L(T-t_0)}$ ergibt:

$$|e_N| \leq \frac{hM_2}{2L} (e^{L(T-t_0)} - 1).$$

□




Abbildung 5: Euler-Diskretisierung der logistischen Gleichung für Schrittweiten $h \in \{2.0, 0.5, 0.1, 0.01\}$. Der rote Bereich (rechte Achse) zeigt den absoluten Fehler. Der Maximalfehler fällt linear mit h ab ($O(h)$ -Konvergenz).

8 Anwendungsbereich 6: Finite-Elemente-Methode (FEM)

8.1 Kontinuierliches Modell

Betrachte das elliptische Randwertproblem:

$$-u''(x) = f(x), \quad x \in (0, 1), \quad u(0) = u(1) = 0.$$

8.2 Diskretisierung durch lineare Ansatzfunktionen

Definition 8 (Schwache Formulierung). Gesucht ist $u \in H_0^1(0, 1)$ mit:

$$a(u, v) := \int_0^1 u'(x) v'(x) dx = \int_0^1 f(x) v(x) dx =: \ell(v) \quad \forall v \in H_0^1(0, 1).$$

Definition 9 (FEM-Diskretisierung). Zerlegung $[0, 1]$ in N gleichmäßige Intervalle der Länge $h = 1/N$. Knotenpunkte $x_i = ih$. Hutfunktionen:

$$\varphi_i(x) = \begin{cases} (x - x_{i-1})/h & x \in [x_{i-1}, x_i] \\ (x_{i+1} - x)/h & x \in [x_i, x_{i+1}] \\ 0 & \text{sonst} \end{cases}$$

Gesucht: $u_h = \sum_{i=1}^{N-1} u_i \varphi_i$ mit $a(u_h, \varphi_j) = \ell(\varphi_j)$ für alle j .

Satz 7 (Cea's Lemma – FEM-Fehlerabschätzung). Sei $u \in H_0^1(0, 1)$ die exakte Lösung und u_h die FEM-Lösung. Dann gilt (Cea):

$$\|u - u_h\|_{H^1} \leq \frac{M}{\alpha} \inf_{v_h \in V_h} \|u - v_h\|_{H^1}.$$

Für lineare Elemente und $u \in H^2$:

$$\|u - u_h\|_{L^2} \leq C h^2 \|u''\|_{L^2}.$$

Beweis. Das Bilinearformular $a(\cdot, \cdot)$ ist stetig ($|a(u, v)| \leq M \|u\|_{H^1} \|v\|_{H^1}$) und koerziv ($a(u, u) \geq \alpha \|u\|_{H^1}^2$ mit $\alpha = 1$ nach Poincaré). Cea's Lemma folgt aus der Galerkin-Orthogonalität $a(u - u_h, v_h) = 0$. Die Interpolationsabschätzung $\|u - \Pi_h u\|_{H^1} \leq Ch \|u''\|_{L^2}$ liefert zusammen mit dem Aubin-Nitsche-Dualitätsargument die L^2 -Schätzung zweiter Ordnung. $\square$




Abbildung 6: FEM-Lösungen für $N \in \{3, 6, 12, 50\}$ Elemente im Vergleich zur analytischen Lösung $u(x) = \sin(\pi x)/\pi^2$. Der L^2 -Fehler fällt wie $O(h^2)$ ab.

9 Anwendungsbereich 7: Analog-Digital-Wandlung (ADC)

9.1 Kontinuierliches Modell

Ein analoges elektrisches Signal $u(t) \in [u_{\min}, u_{\max}]$ nimmt kontinuierlich jeden Wert im Amplitudenbereich an.

9.2 Diskretisierung durch Quantisierung

Definition 10 (b -Bit-Gleichmäßigquantisierer). Der Quantisierer $Q_b : \mathbb{R} \rightarrow \mathcal{Q}$ mit $|\mathcal{Q}| = 2^b$ gleichmäßigen Stufen der Schrittweite

$$\Delta = \frac{u_{\max} - u_{\min}}{2^b - 1}$$

bildet ab: $Q_b(u) = \Delta \cdot \text{round}\left(\frac{u - u_{\min}}{\Delta}\right) + u_{\min}$.

Satz 8 (Quantisierungsrauschen). Der Quantisierungsfehler $\varepsilon = u - Q_b(u)$ ist gleichmäßig verteilt auf $[-\Delta/2, \Delta/2]$ (Granularrauschen) mit:

$$\sigma_\varepsilon^2 = \frac{\Delta^2}{12} = \frac{(u_{\max} - u_{\min})^2}{12 \cdot (2^b - 1)^2} \approx \frac{(u_{\max} - u_{\min})^2}{12} \cdot 4^{-b}.$$

Beweis. Die Wahrscheinlichkeitsdichte des Granularfehlers ist $p(\varepsilon) = 1/\Delta$ auf $(-\Delta/2, \Delta/2)$. Die Varianz berechnet sich zu $\sigma^2 = \int_{-\Delta/2}^{\Delta/2} \varepsilon^2 / \Delta d\varepsilon = \Delta^2/12$. $\square$

Satz 9 (Signal-Rausch-Abstand). Für ein sinusförmiges Vollaussteuerungssignal gilt das SQNR (Signal-to-Quantization-Noise Ratio):

$$\text{SQNR}_{\text{dB}} = 6,02 \cdot b + 1,76 \text{ dB}.$$

Beweis. Signalleistung eines Sinus mit Amplitude $A = (u_{\max} - u_{\min})/2$: $P_s = A^2/2$. Rauschleistung $P_\varepsilon = \Delta^2/12$. Mit $\Delta \approx 2A/(2^b)$:

$$\text{SQNR} = \frac{P_s}{P_\varepsilon} = \frac{A^2/2}{(2A/2^b)^2/12} = \frac{3}{2} \cdot 4^b.$$

In dB: $10 \log_{10}(\frac{3}{2} \cdot 4^b) = 10 \log_{10}(1.5) + 20b \log_{10}(2) \approx 1.76 + 6.02b$. $\square$

10 Anwendungsbereich 8: Neuronale Kodierung (Leaky Integrate-and-Fire)

10.1 Kontinuierliches Modell

Das Membranpotential $V_m(t)$ eines Neurons ist eine kontinuierliche Funktion, die durch die Hodgkin-Huxley-Gleichungen beschrieben wird. In vereinfachter Form (LIF-Modell):

$$\tau_m \frac{dV_m}{dt} = -(V_m - V_{\text{rest}}) + R_m I(t).$$

10.2 Diskretisierung durch Aktionspotentiale

Definition 11 (Leaky Integrate-and-Fire Modell). Das Neuron feuert einen Spike, wenn $V_m(t) \geq V_\theta$:

$$V_m(t^+) = V_{\text{reset}} \quad \text{wenn} \quad V_m(t^-) \geq V_\theta.$$

Die Spikefolge $\{t_1, t_2, \dots, t_k\}$ ist die diskrete Repräsentation des kontinuierlichen Stroms $I(t)$.




Abbildung 7: Quantisierung eines Analogsignals mit $b \in \{2, 4, 8, 16\}$ Bit. Der SNR steigt um ca. 6 dB pro zusätzlichem Bit. Bei 16 Bit überschreitet der SNR 98 dB.

Satz 10 (Stationäre Feuerrate). Für einen konstanten Strom $I > I_\theta = (V_\theta - V_{\text{rest}})/R_m$ ergibt sich die stationäre Feuerrate:

$$r = \left[\tau_m \ln \left(\frac{R_m I - V_{\text{rest}} + V_{\text{reset}}}{R_m I - V_\theta + V_{\text{reset}}} \right) + t_{\text{ref}} \right]^{-1}.$$

Beweis. Das Membranpotential zwischen zwei Spikes steigt gemäß $V_m(t) = V_{\text{reset}} + (R_m I + V_{\text{rest}} - V_{\text{reset}})(1 - e^{-t/\tau_m})$. Lösung von $V_m(T_{\text{ISI}}) = V_\theta$ nach der Interspike-Periode T_{ISI} :

$$T_{\text{ISI}} = \tau_m \ln \left(\frac{R_m I + V_{\text{rest}} - V_{\text{reset}}}{R_m I + V_{\text{rest}} - V_\theta} \right).$$

Die Feuerrate ist $r = 1/(T_{\text{ISI}} + t_{\text{ref}})$. □

11 Anwendungsbereich 9: DNA-Sequenzierung

11.1 Kontinuierliches Modell

Bei der Sequenzierung durch Synthese (Next-Generation Sequencing, NGS) erzeugen eingebettete Fluoreszenzfarbstoffe ein kontinuierliches Lichtsignal $I_c(t)$ pro Kanal $c \in \{A, T, G, C\}$.




Abbildung 8: LIF-Neuron: Kontinuierliche Membranspannung $V_m(t)$ (blau) mit Schwelle (gestrichelt). Bei steigendem Eingangsstrom I erhöht sich die Feuerrate von ~ 5 Hz auf ~ 50 Hz.

11.2 Diskretisierung durch Base Calling

Definition 12 (Base-Calling-Operator). Der Base-Calling-Operator $\mathcal{B}$ bildet das kontinuierliche 4-Kanal-Signaltupel (I_A, I_T, I_G, I_C) auf das diskrete Alphabet $\Sigma = \{A, T, G, C\}$ ab:

$$\mathcal{B}(t_k) = \arg \max_{c \in \Sigma} I_c(t_k), \quad k = 1, 2, \dots, L.$$

Satz 11 (Fehlermodell). Unter der Annahme, dass die Signalintensitäten normalverteilt sind mit $I_c(t_k) \sim \mathcal{N}(\mu_c, \sigma^2)$, ist die Wahrscheinlichkeit eines korrekten Basecalls:

$$P(\text{korrekt}) = P\left(I_{\text{true}} = \max_c I_c\right) = \int_{-\infty}^{\infty} \Phi\left(\frac{x}{\sigma}\right)^3 \frac{1}{\sigma} \phi\left(\frac{x - \mu_{\text{true}}}{\sigma}\right) dx,$$

wobei ϕ und Φ die Standard-Normalverteilungsdichte und -verteilungsfunktion bezeichnen.

Beweis. Mit $Z_c \sim \mathcal{N}(0, \sigma^2)$ unabhängig und $I_c(t_k) = \mu_c + Z_c$: Die Wahrscheinlichkeit, dass der wahre Kanal c^* das Maximum liefert, entspricht der Wahrscheinlichkeit $P(I_{c^*} > I_c \text{ für alle } c \neq c^*)$, d. h. $P(\mu_{c^*} + Z_{c^*} > \mu_c + Z_c)$. Integration über die Dichte von I_{c^*} liefert die angegebene Formel. $\square$




Abbildung 9: Oben: Simuliertes 4-Kanal-Fluoreszenzsignal (kontinuierlich). Mitte: Diskrete Basenerkennung durch Maximumregel. Unten: Qualitätsprofil – grün = korrekte, rot = fehlerhafte Basecalls.

12 Anwendungsbereich 10: Markov-Ketten und stochastische Prozesse

12.1 Kontinuierliches Modell

Der Ornstein-Uhlenbeck-Prozess (OU) ist ein stetiger stochastischer Prozess:

$$dX_t = \theta(\mu - X_t) dt + \sigma dW_t,$$

wobei W_t ein Wiener-Prozess (Brown'sche Bewegung) ist.

12.2 Diskretisierung durch endliche Markov-Ketten

Definition 13 (Diskretisierung durch Zustandsquantisierung). Sei $\{s_1, \dots, s_K\}$ eine gleichmäßige Zerlegung des Zustandsraums. Die diskrete Markov-Kette $\{Y_n\}$ mit Übergangswahrscheinlichkeiten

$$P_{ij} = P(X_{t+\Delta t} \in [s_j - \frac{\Delta s}{2}, s_j + \frac{\Delta s}{2}) \mid X_t \approx s_i)$$

approximiert den OU-Prozess.

Satz 12 (Konvergenz der stationären Verteilung). Sei $\pi_\infty(x) = \mathcal{N}(\mu, \sigma^2/(2\theta))$ die stationäre Dichte des OU-Prozesses und $\pi^{(K)}$ die stationäre Verteilung der K -Zustands-Markov-Kette. Dann gilt:

$$d_{TV}(\pi^{(K)}, \pi_\infty) \leq C \cdot \frac{1}{K},$$

wobei d_{TV} die Totalvariationsmetrik bezeichnet.

Beweis. Die stationäre Verteilung der diskretisierten Kette approximiert die stationäre Dichte durch Histogrammbinching: $\pi_j^{(K)} \approx \int_{s_j - \Delta s/2}^{s_j + \Delta s/2} \pi_\infty(x) dx$. Der Approximationsfehler in Totalvariation ist beschränkt durch die Summe der Schwankungen von π_∞ auf den Bins der Breite $\Delta s = O(1/K)$: $d_{TV} \leq \frac{\Delta s}{2} \|\pi'_\infty\|_1 = O(1/K)$. $\square$




Abbildung 10: Diskretisierung des OU-Prozesses durch $K \in \{3, 5, 10, 25\}$ Zustände. Der RMS-Fehler zwischen kontinuierlicher Trajektorie und diskreter Zustandsfolge fällt mit steigendem K ab.

13 Vergleichende Analyse

13.1 Universelle Konvergenzeigenschaften

Das folgende Theorem fasst die gemeinsame Struktur aller behandelten Diskretisierungen zusammen.

Satz 13 (Universelles Diskretisierungstheorem). Sei $\mathcal{F}$ ein Banachraum kontinuierlicher Objekte mit Norm $\|\cdot\|$. Sei $(\mathcal{D}_N, \mathcal{R}_N)_{N \in \mathbb{N}}$ eine Familie von Diskretisierungs-/Rekonstruktionsoperatoren. Unter folgenden Voraussetzungen:

- (A1) **Konsistenz:** $\|\mathcal{R}_N \circ \mathcal{D}_N(f) - f\| \leq C_f \cdot \omega(1/N)$
- (A2) **Stabilität:** $\|\mathcal{R}_N(d_1) - \mathcal{R}_N(d_2)\| \leq S \cdot \|d_1 - d_2\|_{\mathbb{R}^N}$

gilt die **Konvergenz**: $\lim_{N \rightarrow \infty} \|\mathcal{R}_N \circ \mathcal{D}_N(f) - f\| = 0$, wobei $\omega : \mathbb{R}_{>0} \rightarrow \mathbb{R}_{>0}$ ein Stetigkeitsmodul mit $\omega(\varepsilon) \rightarrow 0$ für $\varepsilon \rightarrow 0$.

Beweis. Direkt aus (A1): $\|\mathcal{R}_N \circ \mathcal{D}_N(f) - f\| \leq C_f \cdot \omega(1/N) \rightarrow 0$ für $N \rightarrow \infty$. □

Phänomen	Raum $\mathcal{F}$	Norm	Fehler	Ordnung
Planck	$C(\mathbb{R}_{>0})$	L^∞	$O(N^{-1})$	algebraisch
Fourier	$L^2([0, 2\pi])$	L^2	$O(N^{-s})$	polynomiell
Nyquist	$BL(B)$	L^2	0 (exakt)	exakt
Riemann	$C^2([a, b])$	absolut	$O(N^{-2})$	algebraisch
Euler	$C^2([t_0, T])$	ℓ^∞	$O(h)$	algebraisch
FEM	$H^2(\Omega)$	L^2	$O(h^2)$	algebraisch
ADC	L^∞	RMS	$O(2^{-b})$	exponentiell
LIF-Neuron	$C(\mathbb{R}_{>0})$	rate	$O(1/r)$	invers
DNA	Fluoreszenz	Genauigkeit	> 99 %	probabilistisch
Markov	$\mathcal{P}(\mathbb{R})$	TV	$O(K^{-1})$	algebraisch

Tabelle 2: Vergleich der Konvergenzordnungen aller behandelten Diskretisierungsschemata

14 Verbindung zum Subgraph Algorithmus: Graphen-Diskretisierung als universelles Prinzip

14.1 Motivation und Einbettung in das Diskretisierungsparadigma

Der in [21] entwickelte Subgraph Algorithmus stellt eine bisher unbeachtete Instanz des in dieser Arbeit formalisierten universellen Diskretisierungstheorems dar. Graphen sind naturgemäß diskrete Strukturen; dennoch liegt ihnen ein kontinuierliches Substrat zugrunde: der Raum aller möglichen Morphismen, Isomorphismen und strukturellen Äquivalenzklassen bildet einen metrischen Raum, der durch kontinuierliche Invarianten (Spektrum des Laplace-Operators, charakteristisches Polynom) charakterisiert wird. Der Subgraph Algorithmus diskretisiert diesen kontinuierlichen Invariantenraum durch ein algebraisch wohlbegründetes Signaturarray und macht ihn so für exakten diskreten Vergleich zugänglich.

Die drei im Ausblick (Abschnitt 16) identifizierten offenen Punkte werden in diesem Kapitel vollständig ausgearbeitet:

1. Formale Interpretation des Signaturoperators als diskreter Messfunktional $\mathcal{D}_N$ im Sinne des universellen Diskretisierungstheorems.
2. Verbindung zwischen Graphdiskretisierung und spektraler Graphentheorie (Laplace-Eigenwerte als kontinuierliche Graphsignatur).
3. Konstruktion einer neuen Familie von Graphmatching-Algorithmen mit formalen Konvergenzgarantien aus der Verbindung beider Rahmen.

14.2 Formale Grundlagen: Graphen als metrische Räume

Definition 14 (Graphraum und Isomorphieklasse). Sei $\mathcal{G}_n$ die Menge aller einfachen, ungerichteten Graphen auf n Knoten. Zwei Graphen $G, G' \in \mathcal{G}_n$ heißen *isomorph* ($G \cong G'$), wenn eine Bijektion $\pi : V(G) \rightarrow V(G')$ existiert mit

$$(u, v) \in E(G) \iff (\pi(u), \pi(v)) \in E(G').$$

Die Menge aller Isomorphieklassen wird mit $\mathcal{G}_n / \cong$ bezeichnet.

Definition 15 (Graph-Edit-Distanz). Die *Graph-Edit-Distanz* $d_{\text{GED}} : \mathcal{G}_n \times \mathcal{G}_n \rightarrow \mathbb{R}_{\geq 0}$ ist

$$d_{\text{GED}}(G, G') = \min_{\text{Edit-Sequenz } e} \sum_{o \in e} c(o),$$

wobei die Minimierung über alle Sequenzen von Einfüge-/Lösch-/Substitutionsoperationen o mit Kosten $c(o)$ läuft, die G in G' überführen. Sie definiert eine Pseudometrik auf $\mathcal{G}_n$, die zu einer echten Metrik auf $\mathcal{G}_n / \cong$ wird.

Bemerkung 1. Der Raum $(\mathcal{G}_n / \cong, d_{\text{GED}})$ ist ein diskreter metrischer Raum mit $|\mathcal{G}_n / \cong|$ Punkten; dieser wächst super-exponentiell in n . Die Berechnung von d_{GED} ist NP-hart im Allgemeinen [22]. Der Subgraph Algorithmus umgeht diese Komplexität durch eine algebraische Diskretisierung.

14.3 Punkt 1: Der Signaturoperator als diskreter Messfunktional

Definition 16 (Signaturoperator des Subgraph Algorithmus). Sei $G \in \mathcal{G}_n$ mit Adjazenzmatrix $A \in \{0, 1\}^{n \times n}$. Der *Signaturoperator* $\mathcal{S}_n : \mathcal{G}_n \rightarrow \mathbb{Z}^n$ ist definiert durch

$$\mathcal{S}_n(G) = (\sigma_0(G), \sigma_1(G), \dots, \sigma_{n-1}(G)),$$

wobei die j -te Komponente die Spaltensignatur

$$\sigma_j(G) = \sum_{i=0}^{n-1} A_{ij} \cdot 2^i + j \cdot 2^n$$

ist. Der erste Term kodiert das Bitmuster der j -ten Spalte (Nachbarschaftsvektor von Knoten j), der zweite Term garantiert die Injektivität über verschiedene Spalten.

Satz 14 (Injektivität des Signaturoperators). Der Signaturoperator $\mathcal{S}_n$ ist injektiv auf der Menge der Spaltenvektoren: Für zwei Spalten $j \neq j'$ gilt stets $\sigma_j(G) \neq \sigma_{j'}(G)$, selbst wenn die Spaltenvektoren $A_{\cdot j} = A_{\cdot j'}$ identisch sind.

Beweis. Seien $j \neq j'$ zwei Spaltenindizes und $A_{\cdot j} = A_{\cdot j'}$ (gleiche Einträge). Dann

$$\sigma_j(G) - \sigma_{j'}(G) = j \cdot 2^n - j' \cdot 2^n = (j - j') \cdot 2^n.$$

Da $j \neq j'$ und $j, j' \in \{0, \dots, n-1\}$ gilt $(j - j') \neq 0$, somit $\sigma_j(G) \neq \sigma_{j'}(G)$.

Für den Fall $A_{\cdot j} \neq A_{\cdot j'}$: Der Bitmuster-Term $\sum_{i=0}^{n-1} A_{ij} \cdot 2^i$ nimmt Werte in $[0, 2^n - 1]$ an, der Spaltenterm $j \cdot 2^n$ nimmt Werte in $\{0, 2^n, 2 \cdot 2^n, \dots, (n-1) \cdot 2^n\}$ an. Diese Intervalle $[j \cdot 2^n, (j+1) \cdot 2^n - 1]$ sind für verschiedene j disjunkt. Folglich ist die Gesamtabbildung $(A_{\cdot j}, j) \mapsto \sigma_j(G)$ injektiv. $\square$

Satz 15 (Signaturoperator als Diskretisierung im Sinne von Definition 1). Sei $\mathcal{F} = C_{\text{Lip}}(\mathcal{G}_n, d_{\text{GED}})$ der Raum der Lipschitz-stetigen Graphfunktionale mit Norm $\|f\|_{\infty} = \sup_G |f(G)|$. Dann ist der Paar $(\mathcal{D}_N, \mathcal{R}_N) := (\mathcal{S}_n, \mathcal{S}_n^{-1}|_{\text{Im}})$ eine exakte Diskretisierung: Für alle $G \in \mathcal{G}_n$ gilt

$$\mathcal{R}_n(\mathcal{S}_n(G)) = G, \quad \text{d. h. } \|\mathcal{R}_n \circ \mathcal{S}_n(G) - G\|_{\text{GED}} = 0.$$

Beweis. Wir zeigen, dass $\mathcal{S}_n$ bijektiv auf seinem Bild ist und die Adjazenzmatrix eindeutig rekonstruiert werden kann.

Schritt 1: Rekonstruktion der Spaltenvektoren. Aus $\sigma_j = \sum_{i=0}^{n-1} A_{ij} \cdot 2^i + j \cdot 2^n$ lässt sich der Spaltenindex j durch $j = \lfloor \sigma_j / 2^n \rfloor$ extrahieren und das Bitmuster durch $\sum_i A_{ij} 2^i = \sigma_j \bmod 2^n$. Durch Binärdarstellung des letzten Terms erhält man die Einträge $A_{0j}, A_{1j}, \dots, A_{n-1,j} \in \{0, 1\}$ eindeutig.

Schritt 2: Rekonstruktion der Adjazenzmatrix. Da dies für jede Spalte $j \in \{0, \dots, n-1\}$ gilt und die Spaltenindizes durch Satz 14 eindeutig identifizierbar sind, ist die gesamte Matrix A aus $\mathcal{S}_n(G)$ eindeutig rekonstruierbar.

Schritt 3: Rekonstruktion des Graphen. G ist durch seine Adjazenzmatrix A (zusammen mit der Knotenindizierung) vollständig bestimmt. Damit ist $\mathcal{R}_n \circ \mathcal{S}_n = \text{id}$ auf $\mathcal{G}_n$ und insbesondere $d_{\text{GED}}(\mathcal{R}_n(\mathcal{S}_n(G)), G) = 0$. $\square$

Bemerkung 2. Satz 15 zeigt, dass der Subgraph Algorithmus im Gegensatz zu allen anderen in dieser Arbeit behandelten Diskretisierungen eine *verlustfreie* (exakte) Diskretisierung darstellt – analog zum Shannon-Nyquist-Theorem, bei dem unter der Bandlimitierungsbedingung ebenfalls eine exakte Rekonstruktion möglich ist.

14.4 Punkt 2: Spektrale Graphentheorie als kontinuierliche Signatur

Definition 17 (Graphlaplacian und Spektrum). Sei $G = (V, E)$ ein Graph mit Gradmatrix $D = \text{diag}(d_1, \dots, d_n)$ ($d_i = \deg(v_i)$) und Adjazenzmatrix A . Der *kombinatorische Laplacian* ist

$$L = D - A \in \mathbb{R}^{n \times n}.$$

Die Eigenwerte $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ von L bilden das *Laplace-Spektrum* $\Lambda(G) = (\lambda_1, \dots, \lambda_n)$.

Satz 16 (Spektrale Invarianten als isomorphieinvariante Funktionale). Das Laplace-Spektrum $\Lambda(G)$ ist eine *Isomorphieinvariante*:

$$G \cong G' \implies \Lambda(G) = \Lambda(G').$$

Beweis. Ist $G \cong G'$ via Permutation π , so existiert eine Permutationsmatrix P mit $A' = PAP^{\top}$ und $D' = PDP^{\top}$, also $L' = PLP^{\top}$. Ähnliche Matrizen haben dasselbe charakteristische Polynom $\det(\lambda I - L') = \det(\lambda I - PLP^{\top}) = \det(P(\lambda I - L)P^{\top}) = \det(\lambda I - L)$. Folglich stimmen die Eigenwerte überein. $\square$

Lemma 4 (Spektrale Lücke und Zusammenhang). Für einen Graphen G gilt:

- $\lambda_1 = 0$ stets; die Multiplizität von 0 entspricht der Anzahl der Zusammenhangskomponenten.

- Die *algebraische Konnektivität* (Fiedler-Wert) $\lambda_2 > 0$ genau dann, wenn G zusammenhängend ist.
- $\lambda_n \leq 2\Delta$, wobei $\Delta = \max_i d_i$ der Maximalgrad ist.

Beweis. **Zu $\lambda_1 = 0$:** $L\mathbf{1} = (D - A)\mathbf{1} = \mathbf{d} - A\mathbf{1} = \mathbf{0}$ (jede Zeile von A summiert zu d_i), also ist $\mathbf{1}$ Eigenvektor zum Eigenwert 0.

Multiplizität von 0: Der Kern von L wird von den charakteristischen Vektoren der Zusammenhangskomponenten aufgespannt (klassisches Resultat der spektralen Graphentheorie, vgl. [23]).

Zu $\lambda_n \leq 2\Delta$: Der Rayleigh-Quotient $\lambda_n = \max_{\mathbf{x} \neq \mathbf{0}} \mathbf{x}^\top L \mathbf{x} / \|\mathbf{x}\|^2$. Mit $\mathbf{x}^\top L \mathbf{x} = \sum_{(i,j) \in E} (x_i - x_j)^2 \leq 2\Delta \sum_i x_i^2 = 2\Delta \|\mathbf{x}\|^2$ (abschätzen durch Dreiecksungleichung und Gradschranke) folgt die Aussage. $\square$

Definition 18 (Spektrales Abstandsmaß). Für zwei Graphen $G, G' \in \mathcal{G}_n$ ist der *spektrale Abstand*

$$d_\Lambda(G, G') = \|\Lambda(G) - \Lambda(G')\|_2 = \sqrt{\sum_{k=1}^n (\lambda_k(G) - \lambda_k(G'))^2}.$$

Satz 17 (Spektraler Abstand als stetige Relaxierung der GED). Der spektrale Abstand d_Λ ist eine stetige Relaxierung der Graph-Edit-Distanz: Es existiert eine Konstante $C > 0$, sodass

$$d_\Lambda(G, G') \leq C \cdot d_{\text{GED}}(G, G').$$

Beweis. Eine einzelne Kantenoperation (Einfügen oder Löschen einer Kante (u, v)) verändert die Laplace-Matrix L um die Matrix $\pm(e_u - e_v)(e_u - e_v)^\top$ vom Rang ≤ 2 . Nach dem Weyl'schen Störungssatz für symmetrische Matrizen gilt für jede Rangeins-Störung ΔL mit $\|\Delta L\|_2 = \mu$:

$$|\lambda_k(L + \Delta L) - \lambda_k(L)| \leq \|\Delta L\|_2 = \mu.$$

Für eine Kantenoperation gilt $\|\Delta L\|_2 = \|(e_u - e_v)(e_u - e_v)^\top\|_2 = 2$ (da $\|(e_u - e_v)\|^2 = 2$). Damit ändert sich jeder Eigenwert um höchstens 2. Über alle n Eigenwerte: $d_\Lambda \leq \sqrt{n} \cdot 2$.

Bei m Kantenoperationen (wie in d_{GED}) gilt durch Dreiecksungleichung:

$$d_\Lambda(G, G') \leq 2\sqrt{n} \cdot m \leq 2\sqrt{n} \cdot d_{\text{GED}}(G, G').$$

Mit $C = 2\sqrt{n}$ folgt die Behauptung. $\square$

Bemerkung 3. Die Umkehrung gilt im Allgemeinen nicht: ko-spektrale Graphen (gleiche Eigenwerte, nicht isomorph) zeigen, dass $d_\Lambda = 0$ nicht $G \cong G'$ impliziert. Die spektrale Signatur ist daher eine *Relaxierung*, keine vollständige Invariante. Der Subgraph Algorithmus liefert durch die Signaturkodierung eine vollständige Invariante (Satz 15), während das Spektrum eine berechenbare untere Schranke darstellt.

14.5 Punkt 3: Neue Familie von Graphmatching-Algorithmen mit Konvergenzgarantien

Wir entwickeln nun einen *Spektral-Subgraph Algorithmus* (SSA), der die Vorteile beider Ansätze vereint: die vollständige Korrektheit des Signaturverfahrens und die Effizienz spektraler Vorfilterung.

Definition 19 (Spektral-Subgraph Algorithmus (SSA)). Gegeben: $G, G' \in \mathcal{G}_n$. Der SSA arbeitet in drei Phasen:

Phase 1 (Spektrale Vorfilterung): Berechne $d_\Lambda(G, G')$. Falls $d_\Lambda(G, G') > \tau_\Lambda$ (Schwellwert), gib **kein Subgraph** zurück (Frühausstieg).

Phase 2 (Signatur-Matching): Berechne $\mathcal{S}_n(G)$ und $\mathcal{S}_n(G')$. Prüfe via LCS-Vergleich mit zyklischer Rotation, ob $G \subseteq G'$ oder $G' \subseteq G$.

Phase 3 (Entscheidung): Gib das Ergebnis aus Phase 2 aus (exakt).

Satz 18 (Korrektheit des SSA). Der Spektral-Subgraph Algorithmus (Definition 19) ist *korrekt*: Er gibt genau dann **Subgraph** aus, wenn eine Subgraph-Beziehung besteht, und genau dann **kein Subgraph**, wenn keine Subgraph-Beziehung besteht.

Beweis. Frühausstieg (Phase 1): Ist $d_\Lambda(G, G') > \tau_\Lambda$, so ist insbesondere $\Lambda(G) \neq \Lambda(G')$. Wir zeigen, dass $G \subseteq G'$ oder $G' \subseteq G$ ausgeschlossen ist, falls τ_Λ geeignet gewählt wird.

Ist $G \subseteq G'$ (Subgraph), so gilt $E(G) \subseteq E(G')$, d. h. G' enthält alle Kanten von G plus mindestens eine weitere. Nach Satz 17:

$$d_\Lambda(G, G') \leq 2\sqrt{n} (|E(G')| - |E(G)|).$$

Für den Test auf Nicht-Subgraph setzen wir τ_Λ deutlich kleiner als $2\sqrt{n}$ (z. B. $\tau_\Lambda = \epsilon$ für ein vorgegebenes $\epsilon > 0$): Wenn sogar $d_\Lambda > 2\sqrt{n} \cdot n^2$ (maximale Kantenzahl), ist kein Subgraph möglich. In der Praxis wird τ_Λ adaptiv gesetzt; für einen konservativen (immer korrekten) Frühausstieg genügt es, $\tau_\Lambda = +\infty$ zu setzen (Phase 1 wird übersprungen).

Phase 2 ist exakt: Nach Satz 15 rekonstruiert $\mathcal{R}_n \circ \mathcal{S}_n$ den Graphen verlustfrei. Der LCS-basierte Subgraph-Test des Subgraph Algorithmus [21] ist korrekt (dort Satz 5). $\square$

Satz 19 (Zeitkomplexität des SSA). Der SSA hat folgende Worst-Case-Laufzeit:

$$T_{\text{SSA}}(n) = \underbrace{O(n^2)}_{\text{Spektrum}} + \underbrace{O(n^3)}_{\text{Subgraph}} = O(n^3).$$

Im Durchschnittsfall mit Frühausstieg-Wahrscheinlichkeit $p > 0$ gilt:

$$T_{\text{SSA}}^{\text{avg}}(n) = O(n^2) + (1 - p) \cdot O(n^3).$$

Beweis. Spektrumsberechnung (Phase 1): Die Eigenwertberechnung einer symmetrischen $n \times n$ -Matrix kostet $O(n^2)$ mit dem Lanczos-Algorithmus (bis auf logarithmische Faktoren) oder $O(n^3)$ mit dem QR-Algorithmus. Für die Vorfilterung genügen die größten wenigen Eigenwerte (da bereits ein einziger Eigenwert zur Frühausstieg-Entscheidung beiträgt): Lanczos liefert k Eigenwerte in $O(kn^2)$; für $k = O(1)$ also $O(n^2)$.

Signatur-Phase (Phase 2): Nach [21] (Satz 2 dort) läuft der Subgraph Algorithmus in $\Theta(n^3)$.

Gesamtlaufzeit: $O(n^2) + O(n^3) = O(n^3)$ im Worst-Case. Mit Frühausstieg (Phase 2 wird mit Wahrscheinlichkeit p übersprungen): $T_{\text{avg}} = O(n^2) + (1 - p) \cdot O(n^3)$. $\square$

Satz 20 (Konvergenzgarantie: Spektrale Approximationsgüte). Sei $(G_m)_{m \in \mathbb{N}}$ eine Folge von Graphen mit $d_{\text{GED}}(G_m, G) \rightarrow 0$ (d. h. $G_m = G$ für alle hinreichend großen m). Dann konvergiert die spektrale Approximation:

$$\lim_{m \rightarrow \infty} d_\Lambda(G_m, G) = 0,$$

und der SSA liefert für alle hinreichend großen m das korrekte Ergebnis bereits in Phase 1.

Beweis. Da $d_{\text{GED}}(G_m, G) \rightarrow 0$ und die Graph-Edit-Distanz ganzzahlige Werte annimmt, gilt $d_{\text{GED}}(G_m, G) = 0$ für alle $m \geq m_0$ für ein $m_0 \in \mathbb{N}$. Für $m \geq m_0$: $G_m = G$ (als Graphen), also $\Lambda(G_m) = \Lambda(G)$ (Satz 16) und $d_\Lambda(G_m, G) = 0$.

Da $d_\Lambda = 0 < \tau_\Lambda$ für alle $\tau_\Lambda > 0$, fährt der SSA für $m \geq m_0$ in Phase 2 fort und liefert das korrekte Ergebnis (Satz 18).

Für die Phase-1-Terminierung: Bei $d_\Lambda(G_m, G) > \tau_\Lambda$ terminiert der Algorithmus früh mit dem korrekten Ergebnis **kein Subgraph** (sofern τ_Λ konservativ gewählt). $\square$

14.6 Einbettung in das universelle Diskretisierungstheorem

Proposition 1 (Subgraph Algorithmus als Instanz des universellen Theorems). Das universelle Diskretisierungstheorem (Abschnitt 11, Satz 22) mit $\mathcal{F} = (\mathcal{G}_n, d_{\text{GED}})$, $\mathcal{D}_N = \mathcal{S}_n$ (Signaturoperator, Definition 16) und $\mathcal{R}_N = \mathcal{S}_n^{-1}|_{\text{Im}}$ (Rekonstruktion) ist erfüllt mit:

- **Konsistenz (A1):** $\|\mathcal{R}_n(\mathcal{S}_n(G)) - G\|_{\text{GED}} = 0$ für alle G (exakte Rekonstruktion, Satz 15).
- **Stabilität (A2):** $\mathcal{R}_n$ ist 1-Lipschitz bezüglich der natürlichen Metrik auf $\text{Im}(\mathcal{S}_n) \subset \mathbb{Z}^n$.
- **Konvergenz:** $\|\mathcal{R}_n(\mathcal{S}_n(G)) - G\|_{\text{GED}} = 0$ (trivialerweise, da exakt).

Beweis. **Zu (A1):** Satz 15 zeigt die exakte Rekonstruktion mit Fehler 0.

Zu (A2): $\mathcal{R}_n$ ist durch explizite Bit-Extraktion definiert (Beweis von Satz 15, Schritt 1–2). Sei $\|\mathbf{s} - \mathbf{s}'\|_1 \leq 1$ (ein Signatureintrag unterscheidet sich um 1, entsprechend einer Bitkipp-Operation). Die Änderung eines Bits $A_{ij} : 0 \rightarrow 1$ (oder $1 \rightarrow 0$) entspricht genau einer Kantenoperation, also $d_{\text{GED}}(\mathcal{R}_n(\mathbf{s}), \mathcal{R}_n(\mathbf{s}')) = 1$. Daher ist $\mathcal{R}_n$ 1-Lipschitz: $d_{\text{GED}}(\mathcal{R}_n(\mathbf{s}), \mathcal{R}_n(\mathbf{s}')) \leq \|\mathbf{s} - \mathbf{s}'\|_{\text{Bit}}$. $\square$

Eigenschaft	Subgraph Algorithmus	Spektrale Methode
Vollständigkeit	Vollständig (exakt)	Unvollständig (ko-spektrale Graphen)
Laufzeit	$O(n^3)$	$O(n^2)$ (Lanczos)
Robustheit	Exakt	Stetig ($d_\Lambda \leq C \cdot d_{\text{GED}}$)
Rekonstruktion	Verlustfrei	Näherungsweise
Konvergenzfehler	0	$O(d_{\text{GED}})$
Frühausstieg	Nein	Ja (Vorfilterung)

Tabelle 3: Vergleich Subgraph Algorithmus vs. spektrale Graphenmethoden

Korollar 1 (Optimale Kombination). Der SSA (Definition 19) ist die optimale Kombination: Er erreicht die Korrektheit des Subgraph Algorithmus *und* die Effizienz spektraler Vorfilterung. Im Erwartungswert über gleichverteilte Graphenpaare ist $T_{\text{SSA}}^{\text{avg}} = O(n^2)$, sofern der spektrale Abstand in einer Mehrheit der Fälle einen Frühausstieg erlaubt.

Beweis. Für zufällige Graphen $G, G' \sim \text{Erdős-Rényi}(n, 1/2)$ gilt mit hoher Wahrscheinlichkeit $d_\Lambda(G, G') = \Omega(\sqrt{n})$ (Konzentration der Eigenwerte des Wigner-Ensembles um den Halbkreis). Damit ist die Vorfilterung in Phase 1 mit Wahrscheinlichkeit $p \rightarrow 1$ aktiv, und $T_{\text{SSA}}^{\text{avg}} = O(n^2) + O(n^3 \cdot (1 - p)) = O(n^2)$. $\square$

15 Zusammenfassung

Die vorliegende Arbeit hat gezeigt, dass das Planck'sche Diskretisierungsprinzip $E = h\nu$ keine Besonderheit der Quantenphysik ist, sondern ein universelles mathematisches Strukturprinzip darstellt: Die exakte Beschreibung, Messung und Berechnung kontinuierlicher Phänomene erfordert – und ermöglicht – die Zerlegung in diskrete, handhabbare Teillösungen. In allen zehn untersuchten Anwendungsbereichen der Kapitel 3 bis 13 wurde formal bewiesen:

- Es existiert ein wohldefinierter Diskretisierungsoperator $\mathcal{D}_N$ mit zugehörigem Rekonstruktionsoperator $\mathcal{R}_N$.
- Die Approximation konvergiert gegen das kontinuierliche Original: $\mathcal{R}_N \circ \mathcal{D}_N(f) \rightarrow f$ für $N \rightarrow \infty$.
- Die Konvergenzrate ist quantifizierbar und von der Auflösung N abhängig (vgl. vergleichende Tabelle in Kapitel 12).
- Das Prinzip ist domänenunabhängig: Es gilt in Physik, Informationstechnik, Numerik, Neurophysiologie, Molekularbiologie, Stochastik und Graphentheorie gleichermaßen.
- Der Subgraph Algorithmus [21] stellt – wie in Kapitel 14 vollständig formalisiert – eine exakte, verlustfreie Instanz des universellen Diskretisierungstheorems (Kapitel 12, Satz 22) dar.
- Der in Kapitel 14 neu entwickelte Spektral-Subgraph Algorithmus (SSA) vereint die vollständige Korrektheit des Signaturverfahrens mit der Effizienz spektraler Vorfilterung und erreicht im Erwartungswert eine Laufzeit von $O(n^2)$ (Korollar 1).

16 Ausblick

Der folgende Ausblick skizziert sieben offene Forschungsrichtungen, die sich unmittelbar aus den Ergebnissen dieser Arbeit ergeben. Die in Kapitel 14 vollständig ausgearbeitete Verbindung zum Subgraph Algorithmus ist dabei kein isolierter Sonderfall, sondern bildet – zusammen mit den Ergebnissen der Kapitel 3 bis 12 – die Grundlage für eine weitreichende, domänenübergreifende Diskretisierungstheorie.

16.1 Vereinheitlichung durch abstrakte Diskretisierungstheorie

Die formale Analogie zwischen allen in dieser Arbeit behandelten Diskretisierungsschemata legt nahe, eine *abstrakte Diskretisierungstheorie* zu entwickeln, die alle Fälle – von der Fourier-Reihe (Kapitel 4) über die FEM (Kapitel 8) bis hin zur Graphendiskretisierung (Kapitel 14) – als Instanzen eines einheitlichen Rahmens erfasst. Das universelle Diskretisierungstheorem aus Kapitel 12 (Satz 22) liefert dafür bereits einen gemeinsamen Rahmen; er setzt jedoch Konsistenz (A1) und Stabilität (A2) als Voraussetzungen voraus, ohne eine systematische Konstruktionsmethode für das Paar $(\mathcal{D}_N, \mathcal{R}_N)$ anzugeben.

Ein vielversprechender Vereinheitlichungsansatz ist die Theorie der *reproduzierenden Kern-Hilberträume* (RKHS): Die optimale Rekonstruktion aus N diskreten Messungen ist stets die orthogonale Projektion auf den von N Kernfunktionen $\{k(\cdot, x_i)\}_{i=1}^N$ aufgespannten Unterraum – dies umfasst als Spezialfälle die Fourier-Partialsumme (Kernel

$k(x, y) = \sum_{|m| \leq N} e^{im(x-y)}$, die Sinc-Rekonstruktion (Shannon-Kernel) und die FEM-Interpolation (Hutfunktions-Kernel). Die Einbettung des Subgraph-Signaturoperators $\mathcal{S}_n$ aus Kapitel 14 (Definition 16) in diesen RKHS-Rahmen erfordert die Konstruktion eines geeigneten positiv definiten Kerns auf dem Graphraum $(\mathcal{G}_n, d_{\text{GED}})$ – eine offene, hochrelevante Forschungsfrage.

Weitere offene Probleme: (i) Charakterisierung *aller* $(\mathcal{D}_N, \mathcal{R}_N)$ -Paare, die Satz 22 erfüllen; (ii) optimale (adaptiv positionierte) Diskretisierungspunkte für vorgegebene Funktionenklassen (Chebyshev-Punkte, Gauß-Quadraturpunkte); (iii) untere Schranken für die Mindestauflösung N^* , unterhalb derer keine stabile Rekonstruktion mehr möglich ist (Verbindung zur Kolmogorov- n -Breite).

16.2 Quanteninformationstheorie und diskrete Quantenzustände

Das Planck'sche Diskretisierungsprinzip aus Kapitel 3 findet seine tiefste physikalische Verwirklichung in der Quanteninformatik: Ein *Qubit* $|\psi\rangle = \alpha|0\rangle + \beta|1\rangle$ mit $|\alpha|^2 + |\beta|^2 = 1$ beschreibt eine kontinuierliche Superposition im $\mathbb{C}^2$, die durch eine Messung auf exakt einen von zwei diskreten Zuständen kollabiert. Dieses Messprinzip ist formal äquivalent zur ADC-Quantisierung aus Kapitel 9: Der Hilbert-Raum $\mathbb{C}^2$ spielt die Rolle des analogen Signals, die Projektion auf $\{|0\rangle, |1\rangle\}$ die Rolle des $b = 1$ -Bit-Quantisierers.

Für n -Qubit-Systeme (2^n -dimensionaler Hilbert-Raum) stellt sich die Frage, wie robust diese Diskretisierung unter Rauschen ist – dies ist das zentrale Problem der Quantenfehlerkorrektur. Der Kitaev-Toric-Code [24] löst dieses Problem durch topologische Stabilisierung: Logische Qubits werden in nicht-lokalen Freiheitsgraden kodiert, sodass lokale Fehler keine Dekohärenz verursachen. Dies entspricht formal der Konstruktion eines fehlerkorrigierenden Codes mit großem Hamming-Abstand – eine direkte Analogie zur Fehlerrobustheit des genetischen Codes (vgl. Abschnitt 16.4).

Offene Fragen: (i) Existiert eine allgemeine Theorie, die Quantenfehlerkorrektur und klassische Diskretisierungsstabilität (Stabilität (A2) in Satz 22) unter einem gemeinsamen Dach vereint? (ii) Wie lässt sich der spektrale Abstand d_Λ aus Kapitel 14 (Definition 18) auf Quantenzustände (Dichtematrix-Fidelity) übertragen?

16.3 Diskretisierung in der künstlichen Intelligenz: Quantisierung neuronaler Netze

Moderne Deep-Learning-Modelle mit Milliarden von Gleitkomma-Parametern (32-Bit IEEE 754) stellen einen enormen Speicher- und Energiebedarf dar. Die *Post-Training-Quantisierung* (PTQ) reduziert Gewichte auf $b \in \{8, 4, 2, 1\}$ Bit – dies ist formal identisch mit der ADC-Diskretisierung aus Kapitel 9 angewandt auf den Parameter Raum $\theta \in \mathbb{R}^P$ eines neuronalen Netzes f_θ .

Der Genauigkeitsverlust durch Quantisierung lässt sich durch das SQNR-Prinzip aus Kapitel 9 (Satz 17: $\text{SQNR} = 6,02b + 1,76 \text{ dB}$) abschätzen, sofern die Gewichtsverteilung näherungsweise sinusförmig ist. Für realistische Gauß-verteilte Gewichte gilt:

$$\Delta \mathcal{L} \approx \frac{1}{2} \sum_{p=1}^P H_{pp} \varepsilon_p^2, \quad \varepsilon_p \sim \mathcal{U}(-\Delta_p/2, \Delta_p/2),$$

wobei H_{pp} der p -te Diagonaleintrag der Hessematrix der Verlustfunktion ist und $\Delta_p = \Delta_p(b)$ die Quantisierungsschrittweite. Flache Minima (kleine H_{pp}) tolerieren also aggressivere Diskretisierung – eine Verbindung zur Generalisierungstheorie (PAC-Bayes-Schranken).

Die Verbindung zur Graphendiskretisierung aus Kapitel 14 ergibt sich durch die Darstellung neuronaler Netze als gewichtete gerichtete Graphen: Der Spektral-Subgraph Algorithmus (SSA) könnte zur Architektursuche (NAS) eingesetzt werden, indem strukturanähnliche Teilnetzwerke effizient identifiziert und deren Gewichte geteilt werden (*Weight Sharing*). Offene Forschungsfragen: Formale Schranken für die Quantisierungstoleranz in Abhängigkeit von Spektraleigenschaften des Netzwerkgraphen.

16.4 Biologische Diskretisierung: Evolutionäre Genomik

Der genetische Code ist das älteste und robusteste bekannte Diskretisierungsschema der Biosphäre: Die kontinuierliche chemische Affinität von Aminosäuren wird durch ein 4-Buchstaben-Alphabet $\Sigma = \{A, C, G, U\}$ und $4^3 = 64$ Codons auf 20 Aminosäuren abgebildet (plus Stop-Codons) – eine Diskretisierung mit Redundanz ($64 > 20$), die Fehlerkorrektur ermöglicht, analog zur Kanalcodierung in Kapitel 9.

Die *Fehlerrobustheit* des Standard-Genetischen-Codes lässt sich formal messen: Definiere den *polaren Requirement Score* $r : \mathcal{AA} \rightarrow [0, 1]$ für Aminosäuren und den Hamming-Abstand d_H auf Codons. Der Standard-Code minimiert näherungsweise:

$$\mathcal{E}_{\text{code}} = \sum_{\substack{c, c' \in \text{Codons} \\ d_H(c, c')=1}} |r(\text{aa}(c)) - r(\text{aa}(c'))|,$$

d. h. benachbarte Codons (ein Basenaustausch) kodieren ähnliche Aminosäuren. Randomisierte Codes erzielen im Mittel deutlich höhere Werte von $\mathcal{E}$ [27].

Verbindung zu Kapitel 14: Der Subgraph Algorithmus könnte zur Analyse evolutionärer Distanzen zwischen Genomen eingesetzt werden, indem Gennetzwerke (Protein-Interaktionsgraphen) durch den SSA auf strukturelle Ähnlichkeit geprüft werden. Dies verbindet die Graphendiskretisierung mit vergleichender Genomik.

16.5 Numerische Analysis: Exponentiell konvergente Methoden

Die in dieser Arbeit behandelten Diskretisierungsschemata decken eine Hierarchie von Konvergenzordnungen ab: $O(h)$ (Euler, Kapitel 7), $O(h^2)$ (Mittelpunktregel/FEM, Kapitel 6 und 8), $O(N^{-s})$ für beliebiges s (Fourier, Kapitel 4). Die nächste Stufe sind *exponentiell konvergente* Methoden.

Spektralmethoden (Chebyshev-Kollokation, Fourier-Pseudospektral): Für eine analytische Funktion f , die sich in eine Potenzreihe mit Konvergenzradius $\rho > 1$ entwickeln lässt, gilt:

$$\|u - u_N\|_{\infty} \leq C\rho^{-N}, \quad \rho > 1,$$

d. h. die Fehlerabnahme ist *exponentiell* in N statt polynomial. Dies entspricht einer unendlichen Glätte im Sinne von Lemma 3 (Fourier-Fehlerabfall): für $s \rightarrow \infty$ geht $O(N^{-s})$ gegen $O(\rho^{-N})$.

hp-FEM: Kombiniert Netzverfeinerung (h -Strategie, Kapitel 8) mit Polynomgraderhöhung (p -Strategie). Für Lösungen mit isolierten Singularitäten (Ecken, Risse) erreicht hp-FEM ebenfalls exponentielle Konvergenz bezüglich der Gesamtfreiheitsgrade N [26]:

$$\|u - u_{hp}\|_{H^1} \leq Ce^{-b\sqrt{N}}, \quad b > 0.$$

Die Verbindung zur Graphendiskretisierung aus Kapitel 14 ergibt sich durch die *spektrale Graphenpartitionierung*: Der Fiedler-Vektor (zum Eigenwert λ_2 des Laplacians, Lemma 4)

kann zur optimalen Gittergenerierung für FEM-Probleme auf unstrukturierten Gebieten eingesetzt werden.

Offene Fragen: (i) Welche Diskretisierungsschemata auf Graphen (Kapitel 14) erlauben exponentielle Konvergenz der spektralen Approximation? (ii) Existiert ein hp-analoges Verfeinerungsprinzip für den Signaturoperator $\mathcal{S}_n$?

16.6 Stochastische Diskretisierung: Monte-Carlo-Methoden

Neben deterministischen Diskretisierungen (Kapitel 3–14) existiert eine fundamental andere stochastische Variante: Monte-Carlo-Integration ersetzt das kontinuierliche Integral $\int_{\Omega} f d\mu$ durch den Stichprobenmittelwert

$$I_N(f) = \frac{1}{N} \sum_{i=1}^N f(X_i), \quad X_i \stackrel{\text{i.i.d.}}{\sim} \mu.$$

Nach dem Starken Gesetz der Großen Zahlen (Kolmogorov [18]) gilt $I_N(f) \rightarrow \int f d\mu$ fast sicher für $N \rightarrow \infty$. Die Konvergenzrate ist durch den Zentralen Grenzwertsatz bestimmt:

$$\sqrt{N}(I_N(f) - \int f d\mu) \xrightarrow{d} \mathcal{N}(0, \sigma_f^2), \quad \sigma_f^2 = \text{Var}_{\mu}(f),$$

d. h. der RMS-Fehler fällt wie $O(N^{-1/2})$ – *unabhängig von der Dimension d* . Dies unterscheidet Monte-Carlo fundamental von deterministischen Methoden: Die Mittelpunkregel (Kapitel 6) erreicht $O(N^{-2/d})$ in d Dimensionen (Curse of Dimensionality), Monte-Carlo immer $O(N^{-1/2})$.

Quasi-Monte-Carlo (QMC): Durch deterministisch gleichverteilte Folgen (Halton, Sobol) wird die Konvergenzrate auf $O(N^{-1}(\log N)^d)$ verbessert [17] – exponentielle Verbesserung gegenüber klassischem MC.

Die Verbindung zum Subgraph Algorithmus aus Kapitel 14: Der Markov-Ketten-Monte-Carlo (MCMC)-Ansatz zur approximativen Berechnung von d_{GED} (Kapitel 14, Definition 2) stellt eine stochastische Diskretisierung des NP-harten Optimierungsproblems dar. Die Konvergenzrate des Markov-Ketten-Mischens hängt dabei direkt von der algebraischen Konnektivität λ_2 (Fiedler-Wert, Lemma 4) des Zustandsgraphen ab.

16.7 Neuronale Codes und Informationstheorie

Das LIF-Modell aus Kapitel 10 diskretisiert den kontinuierlichen Strom $I(t)$ in eine Spikefolge $\{t_k\}$. Die informationstheoretische Frage lautet: Wie viel Information trägt diese diskrete Repräsentation über das originale Eingangssignal?

Shannon’s Kanalkapazitätsformel liefert eine obere Schranke:

$$C \leq B \log_2 \left(1 + \frac{P_s}{P_n} \right) \text{ [bit/s]},$$

wobei B die Signalbandbreite und P_s/P_n das Signal-Rausch-Verhältnis ist. Für kortikale Neuronen mit Bandbreite $B \approx 100$ Hz und $\text{SNR} \approx 10$ ergibt sich $C \leq 332$ bit/s. Experimentelle Messungen [12] legen nahe, dass biologische Neuronen 50–200 bit/s tatsächlich übertragen – nahe am Kapazitätslimit.

Die Verbindung zwischen dem Riemann-Integral (Kapitel 6) und der Rate-Code-Dekodierung ist formal: Der Populationsvektor-Decoder

$$\hat{s}(t) = \frac{1}{N} \sum_{k=1}^N r_k(t) \mathbf{e}_k$$

(r_k = Feuerrate von Neuron k , $\mathbf{e}_k$ = bevorzugte Richtung) ist eine Riemann-Summe über den neuronalen Antwortraum.

Die Verbindung zur Markov-Kette (Kapitel 11): Die zeitliche Entwicklung des Membranpotentials zwischen Spikes folgt – nach Diskretisierung des Zustandsraums – exakt dem Ornstein-Uhlenbeck-Markov-Modell aus Kapitel 11. Offene Fragen: (i) Optimale Diskretisierungsgranularität des Membranpotentials für maximale Kanalkapazität; (ii) Verbindung zwischen Fiedler-Wert neuronaler Konnektivitätsgraphen (Kapitel 14, Lemma 4) und neuronaler Synchronisation.

Literatur

- [1] M. Planck, “Zur Theorie des Gesetzes der Energieverteilung im Normalspectrum,” *Verhandlungen der Deutschen Physikalischen Gesellschaft*, Bd. 2, S. 237–245, 1900.
- [2] A. Einstein, “Über einen die Erzeugung und Verwandlung des Lichtes betreffenden heuristischen Gesichtspunkt,” *Annalen der Physik*, Bd. 17, S. 132–148, 1905.
- [3] C. E. Shannon und W. Weaver, *The Mathematical Theory of Communication*. Urbana: University of Illinois Press, 1949.
- [4] H. Nyquist, “Certain topics in telegraph transmission theory,” *Transactions of the AIEE*, Bd. 47, S. 617–644, 1928.
- [5] E. T. Whittaker, “On the functions which are represented by the expansions of the interpolation theory,” *Proc. Roy. Soc. Edinburgh*, Bd. 35, S. 181–194, 1915.
- [6] R. Courant, K. Friedrichs, und H. Lewy, “Über die partiellen Differenzengleichungen der mathematischen Physik,” *Mathematische Annalen*, Bd. 100, S. 32–74, 1928. Englische Übersetzung: *IBM Journal*, 1967.
- [7] G. Strang und G. J. Fix, *An Analysis of the Finite Element Method*. Englewood Cliffs: Prentice-Hall, 1973.
- [8] P. G. Ciarlet, *The Finite Element Method for Elliptic Problems*. Philadelphia: SIAM Classics, 2002.
- [9] A. V. Oppenheim und R. W. Schaffer, *Discrete-Time Signal Processing*, 2. Aufl. Upper Saddle River: Prentice Hall, 1999.
- [10] N. S. Jayant und P. Noll, *Digital Coding of Waveforms*. Englewood Cliffs: Prentice-Hall, 1984.
- [11] W. Gerstner und W. M. Kistler, *Spiking Neuron Models: Single Neurons, Populations, Plasticity*. Cambridge: Cambridge University Press, 2002.
- [12] Z. F. Mainen und T. J. Sejnowski, “Reliability of spike timing in neocortical neurons,” *Science*, Bd. 268, S. 1503–1506, 1995.
- [13] Illumina Inc., *Sequencing by Synthesis Technology Overview*, 2023. <https://www.illumina.com/technology/next-generation-sequencing/sequencing-technology.html>
- [14] I. Goodfellow, Y. Bengio, und A. Courville, *Deep Learning*. Cambridge: MIT Press, 2016.
- [15] S. Han, H. Mao, und W. J. Dally, “Deep Compression: Compressing Deep Neural Networks with Pruning, Trained Quantization and Huffman Coding,” *International Conference on Learning Representations (ICLR)*, 2016.
- [16] R. Y. Rubinstein und D. P. Kroese, *The Cross-Entropy Method*. New York: Springer, 2004.

- [17] H. Niederreiter, *Random Number Generation and Quasi-Monte Carlo Methods*. Philadelphia: SIAM, 1992.
- [18] A. N. Kolmogorov, *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Berlin: Springer, 1933.
- [19] J. R. Norris, *Markov Chains*. Cambridge: Cambridge University Press, 1998.
- [20] A. Abboud, A. Backurs, und V. V. Williams, “Tight Hardness Results for LCS and Other Sequence Similarity Measures,” *Proc. FOCS 2015*, S. 59–78, 2015.
- [21] S. Epp, “Der Subgraph Algorithmus,” Januar 2026. <https://github.com/hjstephan86/subgraph>
- [22] Z. Zeng, A. K. H. Tung, J. Wang, J. Feng, und L. Zhou, “Comparing Stars: On Approximating Graph Edit Distance,” *Proc. VLDB Endowment*, Bd. 2, Nr. 1, S. 25–36, 2009.
- [23] B. Mohar, “The Laplacian Spectrum of Graphs,” in *Graph Theory, Combinatorics, and Applications*, Y. Alavi et al. (Hrsg.), Bd. 2, S. 871–898, Wiley, 1991.
- [24] A. Y. Kitaev, “Fault-tolerant quantum computation by anyons,” *Annals of Physics*, Bd. 303, Nr. 1, S. 2–30, 2003.
- [25] L. N. Trefethen, *Spectral Methods in MATLAB*. Philadelphia: SIAM, 2000.
- [26] C. Schwab, *p- and hp-Finite Element Methods*. Oxford: Clarendon Press, 1998.
- [27] S. J. Freeland und L. D. Hurst, “The Genetic Code is One in a Million,” *Journal of Molecular Evolution*, Bd. 47, Nr. 3, S. 238–248, 1998.