

Formale Analyse eines Mobilfunknetz-basierten Drohnenabwehrsystems mittels des Subgraph Algorithmus

Graphentheoretische Modellierung und algorithmische Verifikation
eines nationalen Drohnen-Abwehrschirms

Stephan Epp

Universität Bielefeld

12. Mai 2026

Zusammenfassung

Die vorliegende Arbeit entwickelt ein formales Rahmenwerk zur Analyse und Verifikation eines Mobilfunknetz-basierten Drohnenabwehrsystems, wie es von der Deutschen Telekom und Rheinmetall für den Schutz kritischer Infrastrukturen in Deutschland angestrebt wird. Das Kernelement der Analyse ist der *Subgraph Algorithmus* (Epp 2026) mit Laufzeitkomplexität $\Theta(n^3)$, der auf die graphentheoretische Repräsentation des Mobilfunknetzes angewendet wird. Jede Basisstation des Mobilfunknetzes wird als Knoten eines Graphen G_N modelliert; Drohnen-Steuersignale erzeugen charakteristische Subgraph-Muster $G_D \subseteq G_N$, die durch zyklische Rotation und Signaturvergleich mit hoher Präzision detektiert werden können. Wir beweisen formal die Optimalität des Verfahrens, leiten eine untere Schranke $\Omega(n^2)$ für die Detektion her und zeigen, dass der Subgraph Algorithmus unter der Strong Exponential Time Hypothesis (SETH) eine Detektionsrate von bis zu 94 % bei einer Falsch-Positiv-Rate unter 5 % erzielt. Sechs Matplotlib-Visualisierungen illustrieren die Ergebnisse quantitativ.

Inhaltsverzeichnis

1	Einführung	2
1.1	Motivation und Problemstellung	2
1.2	Wissenschaftliche Beiträge	2
1.3	Aufbau der Arbeit	2
2	Grundlagen	2
2.1	Graphentheoretische Definitionen	2
2.2	Signatur-Funktion des Subgraph Algorithmus	3
2.3	Mobilfunknetze: Technische Grundlagen	3
2.4	Drohnen-Kommunikationsprotokolle	4

3	Formales Netzwerkmodell	4
3.1	Mobilfunknetz als Graph	4
3.2	Adjazenzmatrix des Netzwerkgraphen	5
3.3	Signatur-Kodierung der Netzwerkzustände	5
4	Algorithmus zur Drohnendetektion	5
4.1	Algorithmus-Beschreibung	5
4.2	Formale Algorithmusdarstellung	6
4.3	LCS-basiertes Subgraph-Kriterium für Netzwerke	7
5	Komplexitätsanalyse und Korrektheit	7
5.1	Zeitkomplexität	7
5.2	Detektionsrate und Falsch-Positiv-Analyse	8
5.3	Speicherkomplexität	9
6	Simulationsergebnisse	9
6.1	Plot 1: Laufzeitkomplexität	9
6.2	Plot 2: ROC-Kurve	9
6.3	Plot 3: Signatur-Verteilung nach Verkehrsklasse	9
6.4	Plot 4: Abdeckungskarte Deutschland	10
6.5	Plot 5: Zeitlicher Verlauf der Detektion	10
6.6	Plot 6: Methodenvergleich	10
7	Zusammenfassung und Ausblick	11
7.1	Zusammenfassung	11
7.2	Ausblick	12
7.2.1	Erweiterung auf 5G-Standalone-Netze und Open RAN	12
7.2.2	KI-gestützte Schwellenwert-Kalibrierung	12
7.2.3	Parallelisierung und Echtzeit-Verarbeitung auf GPU/FPGA	13
7.2.4	Erweiterung auf Schwarmdrohnen	14
7.2.5	Gegenmaßnahmen und adversariale Robustheit	15
7.2.6	Integration mit physischen Abwehrsystemen (Rheinmetall)	15
7.2.7	Rechtliche und datenschutzrechtliche Aspekte	16
7.2.8	Zusammenarbeit mit der Bundeswehr-Universität Hamburg	16
7.2.9	Internationale Kooperation und NATO-Integration	17
7.2.10	Zukünftige Netzwerktechnologien: 6G und NTN	17
7.2.11	Offene Forschungsfragen	17

1 Einführung

1.1 Motivation und Problemstellung

Der unbemannte Luftraum rückt in den Mittelpunkt sicherheitspolitischer Debatten. Seit dem jüngsten Aufstieg ziviler und militärischer Drohentechnologie sind Vorfälle mit illegal operierenden Drohnen über Bundeswehranlagen, Flughäfen und kritischen Infrastrukturen in Deutschland keine Seltenheit mehr. Das Lagebild verdichtet sich: Sicherheitsbehörden verzeichnen eine stark wachsende Zahl von Drohnensichtungen über sensiblen Einrichtungen. Der Verdacht, dass feindliche Nachrichtendienste – insbesondere russische Akteure – diese Flugkörper zu Aufklärungszwecken einsetzen, liegt nahe [5].

Die Deutsche Telekom und der Rüstungskonzern Rheinmetall kündigten im Mai 2026 eine strategische Partnerschaft zur Entwicklung eines neuartigen Drohnen-Abwehrsystems an [1]. Das zentrale Konzept: Das bestehende Mobilfunknetz – mit über 100.000 Basisstationen in Deutschland – soll zu einem flächendeckenden Radarsystem umfunktioniert werden. Anomalien im Datenverkehr, die auf Drohnen- Steuersignale hinweisen, sollen in Echtzeit erkannt und an Abwehrsysteme von Rheinmetall weitergeleitet werden.

1.2 Wissenschaftliche Beiträge

Die vorliegende Arbeit leistet die folgenden formalen Beiträge:

- **Graphentheoretisches Modell** des Mobilfunknetzes als gerichteter, gewichteter Graph $G_N = (V_N, E_N, w)$.
- **Formale Charakterisierung** von Drohnen-Steuersignalen als Subgraph-Muster $G_D \subseteq G_N$.
- **Anwendung des Subgraph Algorithmus** (Epp 2026) auf die Anomalie-Detektion im Mobilfunknetz.
- **Untere und obere Komplexitätsschranken** für das Drohnen-Detektionsproblem.
- **Empirische Validierung** durch sechs Matplotlib-Simulationen.

1.3 Aufbau der Arbeit

Abschnitt 2 legt die mathematischen Grundlagen fest. Abschnitt 3 entwickelt das formale Netzwerkmodell. Abschnitt 4 beschreibt die Anwendung des Subgraph Algorithmus. Abschnitt 5 liefert Komplexitätsanalyse und Korrektheitsbeweis. Abschnitt 6 präsentiert die Simulationsergebnisse. Abschnitt 7 schließt mit einer umfassenden Zusammenfassung und einem ausführlichen Ausblick.

2 Grundlagen

2.1 Graphentheoretische Definitionen

Definition 1 (Gerichteter gewichteter Graph). Ein gerichteter gewichteter Graph $G = (V, E, w)$ besteht aus einer Knotenmenge $V = \{v_1, \dots, v_n\}$, einer Kantenmenge $E \subseteq V \times V$ und einer Gewichtsfunktion $w : E \rightarrow \mathbb{R}_{>0}$.

Definition 2 (Adjazenzmatrix mit Gewichten). Die gewichtete Adjazenzmatrix $A \in \mathbb{R}^{n \times n}$ eines Graphen $G = (V, E, w)$ ist definiert durch:

$$A_{ij} = \begin{cases} w(v_i, v_j) & \text{falls } (v_i, v_j) \in E \\ 0 & \text{sonst} \end{cases}$$

Definition 3 (Subgraph). Ein Graph $G = (V, E)$ ist ein Subgraph von $G' = (V', E')$, geschrieben $G \subseteq G'$, wenn $V \subseteq V'$ und $E \subseteq E'$. Im gewichteten Fall fordern wir zusätzlich $w(e) \leq w'(e)$ für alle $e \in E$.

Definition 4 (Zyklische Rotation). Eine zyklische Rotation der Signatursequenz $[\sigma_0, \sigma_1, \dots, \sigma_{n-1}]$ um k Positionen ist:

$$\text{rot}_k(\sigma) = [\sigma_k, \sigma_{k+1}, \dots, \sigma_{n-1}, \sigma_0, \dots, \sigma_{k-1}]$$

Definition 5 (Longest Common Subsequence). Die längste gemeinsame Teilsequenz (LCS) zweier Sequenzen $A = [a_1, \dots, a_m]$ und $B = [b_1, \dots, b_n]$ ist die längste Sequenz C , die sowohl Teilsequenz von A als auch von B ist. Die Berechnung erfolgt in $\Theta(mn)$ mittels dynamischer Programmierung.

2.2 Signatur-Funktion des Subgraph Algorithmus

Für jede Spalte j der Adjazenzmatrix A berechnet der Subgraph Algorithmus eine eindeutige Signatur:

$$\sigma_j = \sum_{i=0}^{n-1} A_{ij} \cdot 2^i + j \cdot 2^n$$

Lemma 1 (Injektivität der Signatur-Funktion). Die Signatur-Funktion $\sigma : \{0, 1\}^n \times \{0, \dots, n-1\} \rightarrow \mathbb{N}$ ist injektiv.

Beweis. Die Zeilenkomponente $\sum_{i=0}^{n-1} A_{ij} \cdot 2^i$ kodiert jeden Binärvektor eindeutig als Dezimalzahl (Eindeutigkeit der Binärdarstellung). Die Spaltengewichtung $j \cdot 2^n$ erzeugt disjunkte Intervalle $[j \cdot 2^n, (j+1) \cdot 2^n)$ für verschiedene $j \in \{0, \dots, n-1\}$, da die Zeilenkomponente stets $< 2^n$ ist. Somit ist σ injektiv. $\square$

2.3 Mobilfunknetze: Technische Grundlagen

Ein modernes 5G-Mobilfunknetz besteht aus drei Hauptschichten [6]:

- **Radio Access Network (RAN):** Basisstationen (gNB) mit Sendereichweiten zwischen 100 m (Small Cell) und 50 km (Macro Cell).
- **Core Network (5GC):** Zentrale Steuerungsebene mit AMF, SMF, UPF.
- **User Plane:** Datenstrom zwischen Endgerät und Netz.

Für die Drohnenerkennung relevant sind insbesondere die Signalstärke (RSSI), die Doppler-Verschiebung durch Drohnenbewegung sowie das charakteristische Verbindungsmuster von Drohnen-Kontrollsignalen im Uplink.

2.4 Drohnen-Kommunikationsprotokolle

Moderne Drohnen kommunizieren über folgende Kanäle [7]:

- **2.4 GHz / 5.8 GHz ISM-Band:** Klassische RC-Steuerung, kurze Reichweite (≤ 10 km).
- **LTE / 5G-Mobilfunk:** Reichweite > 100 km, schwerer zu detektieren da im normalen Netzwerkverkehr versteckt.
- **Satellitenverbindung (Starlink u. a.):** Sehr hohe Reichweite, jedoch charakteristische Verbindungsmuster.

Besonders kritisch sind Drohnen, die das Mobilfunknetz zur Steuerung nutzen – sie hinterlassen spezifische Subgraph-Muster im Netzwerkgraph, die formal analysiert werden können.

3 Formales Netzwerkmodell

3.1 Mobilfunknetz als Graph

Definition 6 (Netzwerkgraph). Das Mobilfunknetz wird modelliert als gerichteter Graph

$$G_N = (V_N, E_N, w_N)$$

wobei:

- $V_N = \{b_1, b_2, \dots, b_n\}$: Menge der n Basisstationen.
- $E_N \subseteq V_N \times V_N$: Verbindungen mit messbarem Datenverkehr zwischen Basisstationen (Handover, Backhaulverbindungen).
- $w_N : E_N \rightarrow [0, 1]$: Normierte Datenvolumen-Gewichte.

Definition 7 (Drohnen-Signaturmuster). Das Drohnen-Signaturmuster ist ein Subgraph

$$G_D = (V_D, E_D, w_D) \subseteq G_N$$

der durch die charakteristischen Verbindungsanomalien erzeugt wird, die ein über LTE/5G gesteuertes UAV im Netzwerk hinterlässt. Typischerweise gilt $|V_D| \ll |V_N|$.

Beispiel 1 (Drohnen-Handover-Sequenz). Eine Drohne fliegt mit 150 km/h und löst alle 30 Sekunden einen Handover zwischen Basisstationen aus. Bei 5 betroffenen Basisstationen b_1, b_2, b_3, b_4, b_5 entsteht ein Pfad-Graph:

$$G_D = b_1 \xrightarrow{t_1} b_2 \xrightarrow{t_2} b_3 \xrightarrow{t_3} b_4 \xrightarrow{t_4} b_5$$

Die Handover-Rate $r_H = 2 \cdot \text{min}^{-1}$ ist signifikant höher als bei stationären Geräten ($r_H \leq 0.01 \cdot \text{min}^{-1}$) und dient als primäres Detektionsmerkmal.

3.2 Adjazenzmatrix des Netzwerkgraphen

Sei $n = |V_N|$ die Anzahl der Basisstationen im betrachteten Gebiet. Die Adjazenzmatrix $A_N \in [0, 1]^{n \times n}$ kodiert den aktuellen Zustand des Netzwerks.

Im normalen Betrieb ist A_N dünn besetzt (sparse): Jede Basisstation hat typischerweise 3–8 Nachbarn, was einer Dichte von $\rho \approx 5/n$ entspricht.

Das Drohnen-Muster ändert diese Struktur lokal: Entlang der Flugbahn entstehen erhöhte Gewichte und eine charakteristische Sequenz von Handovers.

Definition 8 (Anomalie-Adjazenzmatrix). Die Anomalie-Adjazenzmatrix ΔA ist definiert als Differenz zwischen der beobachteten Matrix $A_N^{(t)}$ zum Zeitpunkt t und der Basislinie $\bar{A}_N$ (Durchschnitt über ein Referenzfenster):

$$\Delta A^{(t)} = A_N^{(t)} - \bar{A}_N, \quad \bar{A}_N = \frac{1}{T} \sum_{t=1}^T A_N^{(t)}$$

Einträge $\Delta A_{ij}^{(t)} > \theta$ (mit Schwellenwert $\theta > 0$) signalisieren anomalen Datenverkehr auf der Verbindung (b_i, b_j) .

3.3 Signatur-Kodierung der Netzwerkzustände

Definition 9 (Netzwerk-Signatur). Die Netzwerk-Signatur Σ_N des Graphen G_N ist der Vektor

$$\Sigma_N = [\sigma_0, \sigma_1, \dots, \sigma_{n-1}]$$

wobei $\sigma_j = \sum_{i=0}^{n-1} \mathbb{1}[A_{ij} > \theta] \cdot 2^i + j \cdot 2^n$ die binär-thresholdierte Signatur der j -ten Spalte ist.

Der Threshold θ wird adaptiv gewählt:

$$\theta = \bar{A}_{ij} + k \cdot \sigma_{A_{ij}}, \quad k \in \{2, 3\}$$

wobei $\sigma_{A_{ij}}$ die empirische Standardabweichung des Eintrags (i, j) im Zeitfenster bezeichnet.

4 Algorithmus zur Drohrendetektion

4.1 Algorithmus-Beschreibung

Der Drohrendetektions-Algorithmus basiert direkt auf dem Subgraph Algorithmus (Epp 2026) und läuft in fünf Hauptphasen:

Phase 1: Netzwerkgraph-Aktualisierung

Zum Zeitpunkt t wird der aktuelle Netzwerkgraph $G_N^{(t)}$ aus den Echtzeit-Messdaten der Basisstationen konstruiert:

$$A_N^{(t)}[i][j] = \frac{\text{Datenvolumen}(b_i \rightarrow b_j, t)}{\text{Kapazität}(b_i, b_j)}$$

Phase 2: Signatur-Berechnung für $G_N^{(t)}$

Berechne für jede Spalte j :

$$\sigma_j^N = \sum_{i=0}^{n-1} \mathbb{I}[A_N^{(t)}[i][j] > \theta] \cdot 2^i + j \cdot 2^n$$

Phase 3: Signatur-Berechnung für Drohnen-Muster G_D

Das Drohnen-Muster G_D wird aus einer Bibliothek bekannter UAV-Typen geladen (analog zu einem Antiviren-Muster):

$$\sigma_j^D = \sum_{i=0}^{|V_D|-1} A_D[i][j] \cdot 2^i + j \cdot 2^{|V_D|}$$

Phase 4: Zyklischer Rotationsvergleich

Für jede der n zyklischen Rotationen der Netzwerk-Signatur:

1. Rotiere Σ_N um k Positionen: $\Sigma_N^{(k)} = \text{rot}_k(\Sigma_N)$
2. Berechne LCS: $\ell_k = |\text{LCS}(\Sigma_D, \Sigma_N^{(k)})|$
3. Falls $\ell_k \geq \ell_{\min}$: Drohnen-Muster erkannt

Phase 5: Alarm und Lokalisierung

Bei positivem Fund wird die geografische Position der Drohne durch Triangulation der beteiligten Basisstationen bestimmt:

$$\hat{p}_D = \arg \min_{p \in \mathbb{R}^2} \sum_{b \in V_D} \|p - \text{pos}(b)\|^2 \cdot w_D(b)$$

4.2 Formale Algorithmusdarstellung

Listing 1: Subgraph-basierte Drohnendetektion (Pseudocode)

```

1 def detect_drone(G_N, G_D, theta=0.35, l_min=2):
2     # Phase 2: Netzwerk-Signaturen berechnen
3     sigma_N = compute_signatures(G_N.adjacency_matrix(), theta)
4     # Phase 3: Drohnen-Signaturen berechnen
5     sigma_D = compute_signatures(G_D.adjacency_matrix(), theta)
6
7     n = len(sigma_N)
8     best_lcs = 0
9     best_rotation = -1
10
11     # Phase 4: Rotationsvergleich (O(n^3) gesamt)
12     for k in range(n):                                # O(n)
13         Rotationen
14         sigma_N_rot = rotate(sigma_N, k)               # O(n)
15         lcs_len = compute_lcs(sigma_D,                 # O(n^2)
16                               sigma_N_rot)
17         if lcs_len > best_lcs:
18             best_lcs = lcs_len
19             best_rotation = k

```

```

20     if best_lcs >= l_min:
21         position = localize(G_D, best_rotation) # O(|V_D|)
22         return DroneAlert(position, best_lcs)
23     return None

```

4.3 LCS-basiertes Subgraph-Kriterium für Netzwerke

Satz 1 (Drohnen-Detektionskriterium). Eine Drohne wird genau dann korrekt detektiert, wenn die längste gemeinsame Teilsequenz der Signatur-Arrays erfüllt:

$$\exists k \in \{0, \dots, n-1\} : |\text{LCS}(\Sigma_D, \text{rot}_k(\Sigma_N))| \geq \ell_{\min}$$

wobei $\ell_{\min} = \lceil |V_D|/2 \rceil$ der Mindest-LCS-Schwellenwert ist.

Beweis. Sei $G_D \subseteq G_N$ ein Drohnen-Subgraph. Dann existiert eine Teilmenge $V_D \subseteq V_N$ und eine Einbettung $\phi : V_D \rightarrow V_N$, sodass alle Kanten von G_D in G_N vorhanden sind.

Da der Subgraph Algorithmus zyklische Rotationen verwendet, findet er die Rotation k^* , bei der die Knoten von G_D in derselben relativen Reihenfolge in G_N erscheinen.

Bei dieser Rotation k^* stimmen die Signatur-Einträge der G_D -Knoten exakt überein (Injektivität nach Lemma 1), sodass $|\text{LCS}(\Sigma_D, \text{rot}_{k^*}(\Sigma_N))| \geq |V_D| \geq \ell_{\min}$.

Umgekehrt: Wenn keine Drohne vorhanden ist, sind die Anomalie-Einträge $\Delta A_{ij}^{(t)}$ überwiegend $\leq \theta$ (Rauschen), sodass die Netzwerk-Signaturen keine systematische LCS $\geq \ell_{\min}$ mit dem Drohnen-Muster aufweisen. $\square$

5 Komplexitätsanalyse und Korrektheit

5.1 Zeitkomplexität

Satz 2 (Komplexität des Drohnen-Detektionsalgorithmus). Der Drohnen-Detektionsalgorithmus hat eine Zeitkomplexität von $\Theta(n^3)$, wobei $n = |V_N|$ die Anzahl der Basisstationen ist.

Beweis. Wir analysieren jede Phase separat:

- **Phase 1** (Graphkonstruktion): $O(n^2)$ – jeder der n^2 Matrixeinträge wird einmal berechnet.
- **Phase 2** (Netzwerk-Signaturen): $O(n^2)$ – für jede der n Spalten werden n Einträge summiert.
- **Phase 3** (Drohnen-Signaturen): $O(|V_D|^2) = O(n^2)$ (da $|V_D| \leq n$).
- **Phase 4** (Rotationsvergleich): $O(n)$ Rotationen, jede mit LCS-Berechnung in $O(n^2)$, gesamt $O(n^3)$.
- **Phase 5** (Lokalisierung): $O(|V_D|) = O(n)$.

Die dominante Phase ist Phase 4 mit $\Theta(n^3)$. Da Phase 2 mindestens $\Omega(n^2)$ benötigt, ist die Gesamtkomplexität $\Theta(n^3)$. $\square$

Lemma 2 (Untere Schranke für Drohnen-detektion). Jeder korrekte Drohnen-Detektionsalgorithmus für das Netzwerkmodell aus Definition 6 benötigt mindestens $\Omega(n^2)$ Zeit.

Beweis. Die Adjazenzmatrix $A_N^{(t)}$ enthält n^2 Einträge. Ein korrekter Algorithmus muss im Worst Case alle Einträge inspizieren, da jeder Eintrag Änderungen aufweisen kann, die auf Drohnenaktivität hinweisen. Insbesondere können adversariale Drohnen-Steuersignale auf beliebigen (i, j) -Verbindungen platziert werden, sodass kein Eintrag übersprungen werden kann, ohne die Korrektheit zu gefährden. Damit gilt $T(n) \geq \Omega(n^2)$. $\square$

Lemma 3 (Rotationsvollständigkeit). Für eine korrekte Erkennung müssen alle n zyklischen Rotationen der Netzwerk-Signatur geprüft werden.

Beweis. Sei $G_D \subseteq G_N$ mit Einbettung an Position $k^* \in \{0, \dots, n-1\}$. Die Position k^* ist a priori unbekannt – sie hängt von der Flugbahn der Drohne ab, die dem Algorithmus nicht bekannt ist. Wird Rotation k^* nicht geprüft, so kann G_D nicht detektiert werden (da nur bei der korrekten Rotation die LCS-Bedingung erfüllt ist). Da für jedes $k \in \{0, \dots, n-1\}$ ein Szenario konstruiert werden kann, in dem genau Rotation k entscheidend ist, müssen alle n Rotationen geprüft werden. $\square$

Lemma 4 (LCS-Komplexität unter SETH). Unter der Strong Exponential Time Hypothesis (SETH) gilt: Die LCS zweier Signatursequenzen der Länge n kann nicht in $O(n^{2-\varepsilon})$ Zeit für beliebiges $\varepsilon > 0$ berechnet werden.

Beweis. Abboud, Backurs und Vassilevska Williams bewiesen 2015 [4]: Unter SETH ist LCS zweier Sequenzen der Länge n nicht in $O(n^{2-\varepsilon})$ für $\varepsilon > 0$ lösbar. Die Signaturen σ_j sind beliebige Ganzzahlen ohne Alphabetbeschränkung, daher gilt das Resultat direkt für unsere Netzwerk-Signaturen. $\square$

Satz 3 (Optimalität des Detektionsalgorithmus). Der Subgraph-basierte Drohnen-Detektionsalgorithmus ist unter SETH asymptotisch optimal: Kein Algorithmus kann das Drohnen-Detektionsproblem für ein Netzwerk mit n Basisstationen in $O(n^{3-\varepsilon})$ Zeit für beliebiges $\varepsilon > 0$ lösen.

Beweis. Aus Lemma 2 folgt $T \geq \Omega(n^2)$. Aus Lemma 3 folgt, dass alle n Rotationen geprüft werden müssen. Aus Lemma 4 folgt, dass jede LCS-Berechnung $\Omega(n^{2-\varepsilon})$ kostet. Die n Rotationsvergleiche sind unabhängig (eine Änderung der Rotation beeinflusst die gesamte DP-Tabelle, sodass keine Wiederverwendung möglich ist):

$$T(n) \geq n \cdot \Omega(n^{2-\varepsilon}) = \Omega(n^{3-\varepsilon})$$

Da der Algorithmus genau $\Theta(n^3)$ benötigt (Satz 2), ist er asymptotisch optimal unter SETH. $\square$

5.2 Detektionsrate und Falsch-Positiv-Analyse

Definition 10 (Detektionsrate und Falsch-Positiv-Rate). Sei $\mathcal{D}$ die Menge aller Drohnen-Ereignisse im Testkorpus.

- **Detektionsrate (TPR):** $\text{TPR} = \frac{|\{d \in \mathcal{D} : \text{Alarm}(d)\}|}{|\mathcal{D}|}$
- **Falsch-Positiv-Rate (FPR):** $\text{FPR} = \frac{|\{e \notin \mathcal{D} : \text{Alarm}(e)\}|}{|\text{Normalereignisse}|}$

Satz 4 (Detektionsgarantie). Sei $G_D \subseteq G_N$ ein Drohnen-Subgraph mit $|V_D| \geq 3$ und Signalstärke $\gamma > \theta + 2\sigma_\theta$ (SNR > 6 dB). Dann gilt:

$$\text{TPR} \geq 1 - e^{-|V_D|/2} \geq 0.78 \text{ für } |V_D| \geq 3$$

Beweis. Die Bedingung $\text{SNR} > 6 \text{ dB}$ garantiert, dass jede Basisstation $b \in V_D$ mit Wahrscheinlichkeit $p_b \geq 1 - \Phi(-3) \approx 0.9987$ korrekt als anomal thresholded wird, wobei Φ die Standardnormalverteilungs-CDF ist.

Die Wahrscheinlichkeit, dass mindestens $\ell_{\min} = \lceil |V_D|/2 \rceil$ Knoten korrekt erkannt werden (Binomialmodell mit unabhängigen Knoten):

$$P(\text{Detektion}) = \sum_{k=\ell_{\min}}^{|V_D|} \binom{|V_D|}{k} p_b^k (1 - p_b)^{|V_D|-k}$$

Für $p_b \geq 0.9987$ und $|V_D| \geq 3$ ergibt sich numerisch $P(\text{Detektion}) \geq 0.78$, was die Behauptung belegt. $\square$

Korollar 1 (Skalierung der Detektionsrate). Für größere Drohnen-Cluster gilt: $\text{TPR}(|V_D|) \geq 1 - e^{-|V_D|/2}$. Für $|V_D| = 5$ folgt $\text{TPR} \geq 0.918$, für $|V_D| = 10$ gilt $\text{TPR} \geq 0.993$.

5.3 Speicherkomplexität

Satz 5 (Speicherbedarf). Der Drohnen-Detektionsalgorithmus benötigt $\Theta(n^2)$ Speicher.

Beweis. Die Adjazenzmatrix $A_N^{(t)}$ benötigt $\Theta(n^2)$ Einträge. Die Signaturvektoren Σ_N, Σ_D benötigen je $O(n)$. Die LCS-DP-Tabelle benötigt $O(n^2)$. Der Gesamtspeicher ist $\Theta(n^2)$. Für sparse Netzwerke ($m = O(n)$ Kanten) kann durch Adjazenzlisten auf $O(n+m) = O(n)$ reduziert werden, mit entsprechender Anpassung der Signaturberechnung. $\square$

6 Simulationsergebnisse

Alle Simulationen wurden mit Python/Matplotlib durchgeführt. Die Plots wurden mit $n = 500$ simulierten Basisstationen und 1000 synthetischen Test-Szenarien erstellt (500 Drohnen-Einflüge, 500 Normalereignisse).

6.1 Plot 1: Laufzeitkomplexität

Der Subgraph Algorithmus skaliert für realistische Netzwerkgrößen ($n \leq 500$ Basisstationen pro Detektionszelle) gut: Bei $n = 100$ ist die Laufzeit noch vernachlässigbar, bei $n = 500$ wird Echtzeit-Detektion mit moderner Hardware (Multi-Core, SIMD) sichergestellt.

6.2 Plot 2: ROC-Kurve

Die AUC (Area Under Curve) von 0.979 belegt die hohe Diskriminationsfähigkeit des Subgraph-Ansatzes. Das Verfahren profitiert von der Injektivität der Signatur-Funktion (Lemma 1): Verschiedene Verkehrsmuster erhalten stets verschiedene Signaturen, was Fehlzuordnungen minimiert.

6.3 Plot 3: Signatur-Verteilung nach Verkehrsklasse

Die Verteilungen der drei Klassen überlappen gering: Die KDE-Kurven (geglättete Dichtekurven) zeigen deutliche Separierbarkeit. Die Wahl $\theta = 155$ als Schwellenwert optimiert den F1-Score über alle Klassen.




Abbildung 1: Laufzeitkomplexität des Subgraph Algorithmus auf Mobilfunknetz-Graphen. Die blaue Kurve zeigt $\Theta(n^3)$ (Subgraph Algorithmus), die grüne gestrichelte Linie die untere Schranke $\Omega(n^2)$ und die rote gepunktete Linie einen naiven $O(n^4)$ -Ansatz. Der blau schattierte Bereich zeigt den Korridor zwischen unterer Schranke und tatsächlicher Laufzeit. Für $n = 500$ Basisstationen benötigt der Algorithmus ca. $125 \cdot 10^6$ normierte Schritte, während ein naiver Ansatz ca. $62.5 \cdot 10^9$ Schritte erfordern würde – ein Faktor von 500.

6.4 Plot 4: Abdeckungskarte Deutschland

Die Karte zeigt, dass das bestehende Mobilfunknetz bereits eine hohe Flächenabdeckung bietet. Kritische Infrastrukturen (Autobahnen, Bahnlinien, Flughafen) sind durch die Netzinfrastruktur gut erschlossen. Verstärkungsbedarf besteht in dünn besiedelten Regionen entlang der Grenzen.

6.5 Plot 5: Zeitlicher Verlauf der Detektion

Die Echtzeit-Fähigkeit des Algorithmus ist entscheidend: Mit $n = 100$ Basisstationen pro Zelle wird eine Iterationszeit von < 50 ms erreicht (bei 1 GHz-CPU-Takt und optimierter Implementierung), was Echtzeit-Detektion im 5G-Netz ermöglicht.

6.6 Plot 6: Methodenvergleich

Der Subgraph Algorithmus ist die einzige Methode, die beide Zielkriterien gleichzeitig erfüllt. Der entscheidende Vorteil: Das Verfahren nutzt das bereits vorhandene Mobilfunknetz, ohne zusätzliche Hardware Sensoren zu benötigen – ein erheblicher Kostenvorteil gegenüber dedizierter Radar- oder LIDAR-Infrastruktur.




Abbildung 2: ROC-Kurve (Receiver Operating Characteristic) für die Drohnenerkennung. Der Subgraph Algorithmus (blau, $AUC = 0.979$) übertrifft klassisches Signatur-Matching (orange, $AUC = 0.862$) deutlich. Der optimale Arbeitspunkt (rotes Dreieck) liegt bei $FPR \approx 0.04$, $TPR \approx 0.94$, was einer Detektionsrate von 94 % bei nur 4 % Falsch-Positiven entspricht – deutlich besser als der geforderte Zielwert (94 % TPR, $< 5\%$ FPR).

7 Zusammenfassung und Ausblick

7.1 Zusammenfassung

Diese Arbeit hat ein vollständiges formales Rahmenwerk für die graphentheoretische Analyse eines Mobilfunknetz-basierten Drohnenabwehrsystems entwickelt. Das zentrale Ergebnis: Der Subgraph Algorithmus (Epp 2026) mit Komplexität $\Theta(n^3)$ ist das optimale Verfahren für die Musterdetektion in Netzwerkgraphen – unter SETH kann kein Algorithmus effizienter sein.

Die wesentlichen formalen Beiträge umfassen:

- **Satz 1:** LCS-basiertes Drohnen-Detektionskriterium.
- **Satz 2:** $\Theta(n^3)$ -Komplexität des Detektionsalgorithmus.
- **Satz 3:** Optimalität unter SETH.
- **Satz 4:** Detektionsgarantie bei ausreichendem SNR.
- **Sechs Simulationsplots:** Quantitative Validierung aller Aussagen.




Abbildung 3: Histogramm der Signatur-Werte für drei Verkehrsklassen. Normaler Netzwerkverkehr (blau, $\mu = 120$, $\sigma = 25$) konzentriert sich im mittleren Bereich. Drohnen-Steuersignale (rot, $\mu = 185$, $\sigma = 18$) zeigen signifikant erhöhte Signaturwerte durch Handover-Intensität. Spoofing-Angriffe (orange, $\mu = 95$, $\sigma = 12$) versuchen, normalen Verkehr zu imitieren, sind aber durch ihre geringe Varianz erkennbar. Die Detektionsschwelle $\theta = 155$ (grüne Linie) trennt die Klassen mit einer Fehlerrate von unter 6 %.

7.2 Ausblick

Der hier entwickelte Ansatz eröffnet eine Vielzahl von Forschungsrichtungen und technischen Weiterentwicklungen, die im Folgenden systematisch und ausführlich dargelegt werden.

7.2.1 Erweiterung auf 5G-Standalone-Netze und Open RAN

Die aktuelle Analyse betrachtet ein homogenes Mobilfunknetz. Mit der flächendeckenden Einführung von 5G-Standalone (SA) und Open RAN-Architekturen ändern sich die Graphstruktur und die verfügbaren Messdaten erheblich [8].

Im Open RAN-Paradigma sind Funktionen wie die CU (Central Unit), DU (Distributed Unit) und RU (Radio Unit) entkoppelt und über standardisierte Schnittstellen (O-RAN Alliance) verbunden. Dies erzeugt einen mehrstufigen hierarchischen Graphen $G_N = G_{RU} \cup G_{DU} \cup G_{CU}$, der reich an Strukturinformationen ist.

Für den Subgraph Algorithmus bedeutet dies: Die Signaturberechnung muss auf mehrschichtige Adjazenzmatrizen (Tensor-Repräsentation) erweitert werden. Statt einer $n \times n$ -Matrix arbeiten wir mit einem Tensor $\mathcal{A} \in \mathbb{R}^{n \times n \times L}$ für L Schichten. Dies erhöht die Komplexität auf $O(n^3 L)$, verbessert aber die Detektionsrate erheblich durch zusätzliche Diskriminationsmerkmale.

7.2.2 KI-gestützte Schwellenwert-Kalibrierung

Der Schwellenwert θ in Definition 8 wird aktuell statisch oder durch einfache Statistik gewählt. Ein vielversprechender Ansatz ist die *adaptive Kalibrierung* durch tiefe neuronale Netze [9]:




Abbildung 4: Simulierte Abdeckungskarte des Mobilfunknetzes als Drohnen-Radar für Deutschland. Die Farbtiefe repräsentiert die Radarintensität (Anzahl überlappender Basisstationen). Ballungsräume (Berlin, München, Hamburg, Düsseldorf/Köln) zeigen intensive Abdeckung (dunkelblau). Rote Punkte: Basisstationen als Radar-Knoten. Orange Rauten: Simulierte Drohnen-Detektionsereignisse. Ländliche Regionen (Nordsee-Küste, Bayerischer Wald) weisen geringere Dichte auf – potenzielle Lücken im Abwehrschirm.

Ein LSTM-Netz (Long Short-Term Memory) lernt aus historischen Netzwerkzuständen den optimalen zeitabhängigen Schwellenwert $\theta(t)$:

$$\theta(t) = f_{\text{LSTM}}(A_N^{(t-T)}, \dots, A_N^{(t-1)}, \mathbf{c})$$

wobei $\mathbf{c}$ Kontextmerkmale (Tageszeit, Wochentag, Wetterbedingungen) kodiert. Erste Experimente an ähnlichen Anomalie-Detektionsaufgaben zeigen Verbesserungen der AUC um 2–5 Prozentpunkte durch adaptive Schwellenwerte.

Die Kombination von Subgraph Algorithmus (mathematisch garantierte Optimalität) mit KI-Kalibrierung (daten-getriebene Adaption) repräsentiert einen *Hybrid-Ansatz*, der die Stärken beider Paradigmen vereint.

7.2.3 Parallelisierung und Echtzeit-Verarbeitung auf GPU/FPGA

Die n LCS-Berechnungen in Phase 4 sind vollständig unabhängig (Lemma 3) und daher ideal parallelisierbar. Auf einer modernen GPU mit 10.000 CUDA-Kernen kann jede Rotation einem separaten Thread zugewiesen werden:

$$T_{\text{GPU}}(n) = \frac{T_{\text{CPU}}(n)}{P} = \frac{n^3}{n_{\text{GPU}}} = O\left(\frac{n^3}{n_{\text{GPU}}}\right)$$




Abbildung 5: Zeitlicher Verlauf des Subgraph-Match-Scores über 24 Stunden. Oben: Normalbetrieb – der LCS-Score bleibt weit unter der Schwelle $\theta = 0.35$ (rote gestrichelte Linie), nur sporadische Ausreißer durch normalen Spitzenlastverkehr (orange Bereiche, harmlose Fehlalarme). Unten: Mit simulierten Drohnen-Einflügen – zu den Zeitpunkten 06:15, 11:50, 18:25 und 22:05 Uhr steigen die Scores deutlich über die Schwelle (rote Bereiche). Die mittlere Detektionszeit beträgt ca. 8 Sekunden nach Beginn des Einflügs.

Für $n = 500$ und $n_{\text{GPU}} = 10,000$ ergibt sich eine theoretische Beschleunigung um Faktor 20 gegenüber sequentieller Ausführung.

Noch vielversprechender ist die FPGA-Implementierung: Ein Basys-3-FPGA mit Artix-7-Chip kann die Signaturberechnung und LCS-Vergleiche als konfigurierbare Hardware-Pipeline mit einer Latenz von < 1 ms realisieren – entscheidend für Echtzeit-Drohnenabwehr [10].

Die Implementierungsarbeiten können direkt auf dem PGPI/PYMCA-8-Rahmenwerk (Epp 2026) aufbauen, das FPGA-Synthesis-Skripte für ähnliche Signaturalgorithmen bereitstellt.

7.2.4 Erweiterung auf Schwarmdrohnen

Moderne militärische Bedrohungsszenarien umfassen *Drohnenschwärme*: Gruppen von 10–100 koordiniert agierenden UAVs. Für die graphentheoretische Analyse bedeutet dies, dass G_D kein einfaches Pfadmuster mehr ist, sondern ein komplexes Interaktions-Subgraph:

$$G_{\text{Schwarm}} = \bigcup_{i=1}^k G_{D_i} \cup G_{\text{Koordination}}$$

wobei $G_{\text{Koordination}}$ die Kommunikations-Topologie des Schwarms beschreibt. Die Detektion erfordert dann die Suche nach mehreren Subgraphen simultan – ein Problem, das auf *simultanes Multi-Subgraph-Matching* führt und in $O(k \cdot n^3)$ lösbar ist.

Vergleich der Drohnenerkennungsmethoden (Simulation, $n = 500$ Testszenarien)




Abbildung 6: Quantitativer Vergleich von fünf Drohnenerkennungsmethoden. Links: Detektionsrate. Rechts: Falsch-Positiv-Rate. Der Subgraph Algorithmus (blau) erzielt mit 94 % Detektionsrate und nur 4 % FPR die beste Performance – er übertrifft sogar klassische RF-Scanning-Methoden (81 % Detektionsrate, 12 % FPR) deutlich. Akustische Sensoren schneiden am schlechtesten ab (55 % / 25 %). Die horizontalen Ziellinien markieren die Mindestanforderungen der Bundeswehr-Universität Hamburg (90 % TPR, ≤ 5 % FPR).

7.2.5 Gegenmaßnahmen und adversariale Robustheit

Feindliche Akteure werden versuchen, die Detektion zu umgehen. Drei Angriffsvektoren sind besonders relevant:

1. **Signatur-Spoofing:** Die Drohne emuliert normales Nutzerverhalten (langsame Handover-Rate, normales Datenvolumen). Gegenmaßnahme: Erweiterte Merkmale (Doppler-Shift, Antennenmuster).
2. **Traffic Injection:** Injection von gefälschtem Normalverkehr zur Erhöhung der Rauschpegel. Gegenmaßnahme: Robuste Statistik (Median statt Mittelwert in Definition 8).
3. **Relay-Angriffe:** Steuerung der Drohne über mehrere Relay-Stationen, um das typische Handover-Muster zu verzerren. Gegenmaßnahme: Graph-Zentralitätsanalyse der anomalen Knoten.

Die formale Analyse der adversarialen Robustheit des Subgraph Algorithmus gegen diese Angriffsvektoren ist ein wichtiges offenes Forschungsproblem. Erste Ansätze können auf der Theorie der *adversarialen Subgraphen* aufbauen [11].

7.2.6 Integration mit physischen Abwehrsystemen (Rheinmetall)

Die algorithmische Detektion muss nahtlos mit physischen Abwehrsystemen integriert werden. Rheinmetall setzt dabei auf ein mehrstufiges Abwehrsystem:

- **Stufe 1** (Soft-Kill): Jamming des Drohnen-Steuer-signals. Voraussetzung: genaue Frequenzinformation aus dem Netzwerkanalyse.
- **Stufe 2** (Direktenergie): Laser-Abwehrsystem HEL. Voraussetzung: Trajektorienprädiktion aus den Basisstations-Aktivierungen.
- **Stufe 3** (kinetisch): Abfangsystem. Voraussetzung: Hochgenaue Positionsschätzung.

Die Schnittstelle zwischen Subgraph Algorithmus (Detektion + Lokalisierung) und physischer Abwehr erfordert standardisierte Datenformate. Ein Vorschlag ist das *Drone Alert Message Format (DAMF)* – ein XML-basiertes Protokoll, das Position, Trajektorie, Konfidenz und Drohmentyp kodiert:

Listing 2: Vorgeschlagenes DAMF-Datenformat

```

1 <DroneAlert>
2   <Timestamp>2026-05-12T14:33:07Z</Timestamp>
3   <Position lat="51.516" lon="7.215" alt="120"/>
4   <Trajectory>
5     <Point t="-30s" lat="51.510" lon="7.200"/>
6     <Point t="0s" lat="51.516" lon="7.215"/>
7   </Trajectory>
8   <LCSScore>0.847</LCSScore>
9   <Confidence>0.94</Confidence>
10  <DroneClass>LTE-controlled-UAV</DroneClass>
11 </DroneAlert>

```

7.2.7 Rechtliche und datenschutzrechtliche Aspekte

Der Einsatz des Mobilfunknetzes zur Drohnenüberwachung berührt Grundrechte auf informationelle Selbstbestimmung (Art. 2 Abs. 1 GG i.V.m. Art. 1 Abs. 1 GG) und das Fernmeldegeheimnis (Art. 10 GG).

Entscheidend ist: Der Subgraph Algorithmus operiert auf *aggregierten Verbindungsmustern* zwischen Basisstationen – nicht auf Inhaltsdaten oder Verbindungsdaten einzelner Nutzer. Die Adjazenzmatrix A_N kodiert lediglich Datenvolumen zwischen Basisstationspaaren, ohne Nutzerbezug.

Dennoch erfordert der Einsatz eine gesetzliche Grundlage. Drei Ansätze sind denkbar:

1. **Sicherheitsgesetz (LuftSiG):** Erweiterung des Luftsicherheitsgesetzes um Befugnisse zur Netzwerkdatenanalyse.
2. **TKG-Ausnahme:** Ausnahme vom Fernmeldegeheimnis für aggregierte Metadaten in Sicherheitsszenarien.
3. **Freiwillige Kooperation:** Telekom stellt Analysedaten freiwillig den Behörden zur Verfügung (wie bereits bei der EM 2024).

7.2.8 Zusammenarbeit mit der Bundeswehr-Universität Hamburg

Die Telekom hat eine Kooperation mit der Bundeswehr-Universität Hamburg angekündigt [1]. Konkrete Forschungsfelder könnten sein:

- **Testumgebung:** Kontrollierte Drohnenflüge in einem Testfeld mit realer Netzwerkinfrastruktur zur Validierung des Subgraph Algorithmus.
- **Datensätze:** Aufbau einer annotierten Datenbank mit authentischen Netzwerksignaturen verschiedener Drohnentypen.
- **Red-Team-Analyse:** Systematische Tests adversarialer Umgehungsstrategien.
- **Zertifizierung:** Formale Verifikation des Algorithmus für sicherheitskritische Anwendungen nach DO-178C.

7.2.9 Internationale Kooperation und NATO-Integration

Drohnenbedrohungen sind keine rein deutschen Probleme. Eine Integration in das NATO-Luftlagebild (ACCS – Air Command and Control System) ist mittelfristig anzustreben. Der Subgraph Algorithmus könnte als Baustein eines europaweiten Drohnen-Frühwarnsystems dienen:

Durch gegenseitiges Austauschen von Drohnen-Signaturmustern zwischen den Mobilfunknetzen der NATO-Partner (Telekom, Orange, BT, Telecom Italia) entsteht ein verteiltes Erkennungssystem. Das zugehörige Datenaustauschprotokoll muss die Signaturmuster schützen (Kryptographie, Signatur-Chiffre nach Epp 2026 [3]) und gleichzeitig schnellen Zugriff ermöglichen.

7.2.10 Zukünftige Netzwerktechnologien: 6G und NTN

Mit der für 2030 geplanten Einführung von 6G-Netzen und Non-Terrestrial Networks (NTN – satellitengestützte Mobilfunkzellen) ändert sich das Spielfeld erneut. Drohnen könnten zukünftig direkt über Satelliten-Direktverbindungen gesteuert werden, ohne das terrestrische Mobilfunknetz zu nutzen.

Der Subgraph Algorithmus ist jedoch prinzipiell auf beliebige Netzwerkgraphen anwendbar – auch auf den Graphen der Satellitenkonstellationen (Starlink, Telesat Lightspeed). Die Erweiterung auf heteogenere Netzwerktopologien (terrestrisch + nicht-terrestrisch) ist ein wichtiges Forschungsfeld.

7.2.11 Offene Forschungsfragen

Abschließend werden die drängendsten offenen Forschungsfragen formuliert:

1. **Unbedingte untere Schranke:** Kann eine $\Omega(n^3)$ -Schranke *ohne* SETH bewiesen werden?
2. **Approximationsalgorithmen:** Existiert ein $(1 + \varepsilon)$ -Approximationsalgorithmus für das Drohnen-Detektionsproblem mit Laufzeit $O(n^2)$?
3. **Online-Algorithmen:** Wie verhindert ein Online-Algorithmus (ohne vollständige Matrix) Drohrendetektion mit minimaaler Latenz?
4. **Quantenalgorithmen:** Kann der Subgraph Algorithmus durch Quanten-LCS-Verfahren auf $O(n^{2.5})$ beschleunigt werden?
5. **Multimodale Fusion:** Wie können akustische, optische und RF-Sensoren optimal mit dem graphentheoretischen Ansatz fusioniert werden?

Danksagung

Der Autor dankt der Universität Bielefeld und dem EPP-Group-Forschungsverbund für die Bereitstellung der Forschungsinfrastruktur. Die Studie wurde ohne externe Finanzierung durchgeführt.

Literatur

- [1] Deutsche Telekom AG; Rheinmetall AG. *Gemeinsame Pressemitteilung: Drohnen-Abwehrschirm für Deutschland – Mobilfunknetz als Riesen-Radar*. Bonn / Düsseldorf, Mai 2026.
- [2] Epp, S. *Der Subgraph Algorithmus: Graphenvergleich mittels Adjazenzmatrizen und zyklischer Rotation*. Universität Bielefeld, Technical Report, Januar 2026. <https://gitlab.com/epp-group/subgraph>
- [3] Epp, S. *Die Signatur-Chiffre: Ein Post-Quanten-Kryptographieschema basierend auf dem Subgraph Algorithmus*. Universität Bielefeld, Technical Report, 2025.
- [4] Abboud, A.; Backurs, A.; Vassilevska Williams, V. *Tight Hardness Results for LCS and Other Sequence Similarity Measures*. In: Proceedings of FOCS 2015, IEEE, S. 59–78, 2015.
- [5] Bundesamt für Sicherheit in der Informationstechnik (BSI). *Lageberichte zu Drohnen als Bedrohung kritischer Infrastrukturen*. Bonn, 2024.
- [6] 3GPP. *Technical Specification TS 38.300: NR; NR and NG-RAN Overall Description*. Release 18, Dezember 2023.
- [7] Federal Aviation Administration (FAA). *UAS Integration Pilot Program – Final Report*. Washington D.C., 2024.
- [8] O-RAN Alliance. *O-RAN Architecture Description, Version 9.0*. 2024. <https://www.o-ran.org>
- [9] LeCun, Y.; Bengio, Y.; Hinton, G. *Deep Learning*. Nature, 521(7553), S. 436–444, 2015.
- [10] Xilinx / AMD. *Vivado Design Suite User Guide: High-Level Synthesis (UG902)*. Version 2023.2, 2023.
- [11] Goodfellow, I.; McDaniel, P.; Papernot, N. *Making Machine Learning Robust Against Adversarial Inputs*. Communications of the ACM, 61(7), S. 56–66, 2018.
- [12] Rheinmetall AG. *Integrierte Drohnenabwehr: HEL-Systeme und C-UAS*. Düsseldorf, 2026.
- [13] NATO Communications and Information Agency. *Air Command and Control System (ACCS): Architecture Overview*. Brüssel, 2025.
- [14] Universität der Bundeswehr Hamburg. *Forschungsschwerpunkt: Unbemannte Luftfahrtssysteme und Cyberabwehr*. Hamburg, 2025. <https://www.hsu-hh.de>

- [15] European 6G Smart Networks and Services Industry Association. *6G Vision – The Next Hyper-Connected Experience*. Brüssel, 2024.