

Lernbasiertes Autonomes Netzwerkmanagement in Heterogenen Mobilfunknetzen

Formale Analyse, Optimierungsmodelle und Multi-Agent-Erweiterungen
auf Basis von Reinforcement Learning

Stephan Epp

Universität Bielefeld

`stephan.epp@uni-bielefeld.de`

3. Juni 2026

Abstract

Heterogene Mobilfunknetze (HetNets) stehen vor der Herausforderung, dynamische Benutzergerät-Lebenszyklen, variierende Lastverteilungen und hohe Energieeffizienzanforderungen gleichzeitig zu beherrschen. In dieser Arbeit analysieren wir das von Illian [1] vorgestellte lernbasierte autonome Netzwerkmanagementsystem *CellPilot* formal und exhaustiv. Wir modellieren die Leerlauf-Selektion von Mobilfunkzellen als partiell beobachtbares Markov-Entscheidungsprozess (POMDP) und zeigen, dass der REINFORCE-Algorithmus mit Reward-Shaping-Baselines zur Policy-Konvergenz führt. Des Weiteren formulieren wir die Bandwechsel-Energieoptimierung im Verbindungsmodus als gemischt-ganzzahliges konvexes Optimierungsproblem (MIQCP) und beweisen die Existenz einer eindeutigen optimalen Lösung unter gegebenen Kapazitätsnebenbedingungen. Alle Ergebnisse werden analytisch hergeleitet, formal bewiesen und durch umfangreiche Simulationen mit synthetischen sowie realen 3GPP-konformen Leistungsmodellen validiert. Der Ausblick beschreibt detailliert die Erweiterung auf Multi-Agent-RL-Architekturen sowie die Integration in 5G/6G-Netzwerkschichten.

Contents

1	Einführung	3
1.1	Beitrag dieser Arbeit	3
1.2	Verwandte Arbeiten	3
2	Grundlagen	3
2.1	Heterogene Mobilfunknetze	3
2.2	Markov-Entscheidungsprozesse	4
2.3	Policy-Gradient-Methoden	4

3	POMDP-Modellierung des Leerlauf-Selektionsproblems	5
3.1	Zustandsraum	5
3.2	Beobachtungsraum	5
3.3	Aktionsraum	5
3.4	Reward-Funktion	6
4	Konvergenzbeweis für REINFORCE mit Baselines	6
4.1	Policy-Gradient-Theorem	6
4.2	Varianzreduktion durch Baselines	7
4.3	Konvergenz des REINFORCE-Algorithmus	7
5	MIQCP-Formulierung der Bandwechsel-Energieoptimierung	8
5.1	Problemformulierung	8
5.2	Konvexität des Leistungsmodells	8
5.3	MIQCP-Umformulierung	8
5.4	Optimalitätsbedingungen	9
6	3GPP-konformes UE-Leistungsmodell	9
6.1	Analytische Herleitung	9
7	Experimentelle Validierung	10
7.1	Konvergenz der CellPilot-Policy	10
7.2	Durchsatzgewinne	10
7.3	Leistungsmodellvalidierung	10
7.4	Energiereduktion und Fairness	10
7.5	Multi-Agent-Konvergenzvergleich	10
7.6	POMDP-Zustandsraumwachstum	10
8	Zusammenfassung	10
9	Ausblick	11
9.1	Multi-Agent Reinforcement Learning	11
9.2	Mean-Field-Approximation für große Netzwerke	12
9.3	Integration in 5G NR und Open RAN	13
9.4	Energy Harvesting und Green 5G	14
9.5	Robustheit und Transferability	15
9.6	Integration des Subgraph-Algorithmus zur Topologieerkennung	15
9.7	Formale Verifikation der RL-Policy	16
9.8	6G und Terahertz-Kommunikation	16
9.9	Quantencomputing-Beschleunigung	17

1 Einführung

Moderne Mobilfunknetze entwickeln sich hin zu heterogenen Architekturen (HetNets), in denen Makrozellen, Kleinzellen (Small Cells) und millimeterwellenbasierte Zugangsknoten koexistieren. Gleichzeitig wächst die Anzahl der User Equipment (UE) rapide, und die Anforderungen an Energieeffizienz – sowohl seitens des Netzbetreibers als auch im Hinblick auf die Akkulaufzeit der Endgeräte – steigen stetig. Klassische regelbasierte Steuerungslogik ist den komplexen, nichtstationären Bedingungen dieser Netze nicht gewachsen.

Reinforcement Learning (RL) bietet eine elegante Alternative: Ein Agent lernt eine Netzwerksteuerungs-Policy durch wiederholte Interaktion mit der Umgebung und optimiert dabei eine langfristige Reward-Funktion ohne explizit modellierte Systemdynamik. Die vorliegende Arbeit untersucht das von Illian [1] vorgestellte System *CellPilot* wissenschaftlich und ergänzt es durch formale mathematische Beweise, ausführliche Herleitung der Optimierungsprobleme sowie extensive Simulationsresultate.

1.1 Beitrag dieser Arbeit

Diese Arbeit leistet folgende Beiträge:

- Formale POMDP-Modellierung des Leerlauf-Zellselektionsproblems (Abschnitt 3)
- Beweis der Policy-Konvergenz des REINFORCE-Algorithmus mit Baselines (Abschnitt 4)
- MIQCP-Formulierung der Bandwechsel-Energieoptimierung und Beweis der Optimalität (Abschnitt 5)
- Analytische Herleitung und Validierung des 3GPP-konformen UE-Leistungsmodells (Abschnitt 6)
- Simulative Validierung aller Ergebnisse mit matplotlib-Visualisierungen (Abschnitt 7)
- Detaillierter Ausblick auf Multi-Agent-RL-Erweiterungen und 5G/6G-Integration (Abschnitt 9)

1.2 Verwandte Arbeiten

Lernbasiertes Netzwerkmanagement wurde in den letzten Jahren intensiv untersucht. Deep-Q-Network-basierte (DQN) Ansätze für Handover-Entscheidungen wurden in [5] und [6] beschrieben. POMDP-Formulierungen für HetNet-Ressourcenzuweisung finden sich in [7]. Die Verwendung des REINFORCE-Algorithmus für Policy-Gradient-Optimierung in Telekommunikationsnetzen ist in [2] grundlegend beschrieben. Das Subgraph-basierte Optimierungsframework von Epp [14] liefert dabei allgemeine Methoden zur strukturellen Graphoptimierung, die direkt auf Netztopologien übertragbar sind.

2 Grundlagen

2.1 Heterogene Mobilfunknetze

Definition 1 (Heterogenes Netzwerk). Ein heterogenes Mobilfunknetz (HetNet) ist ein System $\mathcal{N} = (\mathcal{B}, \mathcal{U}, \mathcal{L})$, wobei $\mathcal{B} = \{b_1, \dots, b_M\}$ die Menge der Basisstationen, $\mathcal{U} =$

$\{u_1, \dots, u_K\}$ die Menge der User Equipment und $\mathcal{L} \subseteq \mathcal{B} \times \mathcal{U}$ die zulässigen Verbindungsrelationen bezeichnet.

Definition 2 (Leerlaufmodus und Verbindungsmodus). Ein UE $u_k \in \mathcal{U}$ befindet sich im *Leerlaufmodus* (idle mode), wenn keine aktive Datenverbindung besteht. Es befindet sich im *Verbindungsmodus* (connected mode), wenn eine aktive Datenübertragung stattfindet. Der Übergang zwischen beiden Modi erfolgt durch ein *Handover*-Ereignis.

Definition 3 (Referenzsignalempfangspegel – RSRP). Der RSRP (Reference Signal Received Power) eines UE u_k zur Basisstation b_j ist definiert als:

$$\text{RSRP}_{k,j} = P_j - \text{PL}_{k,j} - X_\sigma$$

wobei P_j die Sendeleistung, $\text{PL}_{k,j}$ den Pfadverlust und $X_\sigma \sim \mathcal{N}(0, \sigma^2)$ das Log-Normal-Shadowing bezeichnet.

2.2 Markov-Entscheidungsprozesse

Definition 4 (MDP). Ein Markov-Entscheidungsprozess (MDP) ist ein Tupel $\mathcal{M} = (\mathcal{S}, \mathcal{A}, P, R, \gamma)$, wobei:

- $\mathcal{S}$ die Zustandsmenge,
- $\mathcal{A}$ die Aktionsmenge,
- $P : \mathcal{S} \times \mathcal{A} \times \mathcal{S} \rightarrow [0, 1]$ die Übergangswahrscheinlichkeit,
- $R : \mathcal{S} \times \mathcal{A} \rightarrow \mathbb{R}$ die Reward-Funktion und
- $\gamma \in [0, 1)$ den Diskontfaktor bezeichnet.

Definition 5 (POMDP). Ein partiell beobachtbares MDP (POMDP) erweitert das MDP um einen Beobachtungsraum $\mathcal{O}$ und eine Beobachtungswahrscheinlichkeit $\Omega : \mathcal{S} \times \mathcal{A} \times \mathcal{O} \rightarrow [0, 1]$:

$$\mathcal{P} = (\mathcal{S}, \mathcal{A}, P, R, \mathcal{O}, \Omega, \gamma).$$

Der Agent beobachtet nicht direkt $s \in \mathcal{S}$, sondern nur $o \in \mathcal{O}$ mit $P(o \mid s, a) = \Omega(s, a, o)$.

2.3 Policy-Gradient-Methoden

Definition 6 (Stochastische Policy). Eine stochastische Policy $\pi_\theta : \mathcal{S} \times \mathcal{A} \rightarrow [0, 1]$ mit Parametervektor $\theta \in \mathbb{R}^d$ gibt für jeden Zustand s eine Wahrscheinlichkeitsverteilung über Aktionen an: $\pi_\theta(a \mid s) \geq 0$ und $\sum_{a \in \mathcal{A}} \pi_\theta(a \mid s) = 1$.

Definition 7 (Erwarteter Return). Der erwartete diskontierte Return einer Policy π_θ ist:

$$J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \gamma^t R(s_t, a_t) \right]$$

wobei $\tau = (s_0, a_0, r_0, s_1, \dots)$ eine Trajektorie bezeichnet.

3 POMDP-Modellierung des Leerlauf-Selektionsproblems

3.1 Zustandsraum

Im CellPilot-System befindet sich jedes UE u_k in einem der folgenden Modi:

Definition 8 (UE-Zustand). Der Zustand eines einzelnen UE u_k ist ein Tupel:

$$s_k = (b_k^{\text{serv}}, \text{pm}_k, \theta_k^{\text{tp}}, m_k) \in \mathcal{B} \times \mathcal{P} \times [0, T_{\max}] \times \{0, 1\}$$

wobei b_k^{serv} die serving cell, pm_k das UE-Leistungsmodell, θ_k^{tp} den Durchsatz und $m_k \in \{0, 1\}$ den Modus (idle/aktiv) bezeichnen.

Der Gesamtzustand des Systems ergibt sich als:

$$s = (s_1, \dots, s_K) \in \mathcal{S} = \prod_{k=1}^K \mathcal{S}_k$$

Proposition 1 (Zustandsraumgröße). Für K UEs mit je $|\mathcal{B}|$ Basisstationen, $|\mathcal{P}|$ Leistungsmodellen und diskretisiertem Durchsatz in N_θ Stufen gilt:

$$|\mathcal{S}| = (|\mathcal{B}| \cdot |\mathcal{P}| \cdot N_\theta \cdot 2)^K$$

Das Zustandsraumwachstum ist somit *exponentiell* in der UE-Anzahl K .

Proof. Jedes UE hat $|\mathcal{B}| \cdot |\mathcal{P}| \cdot N_\theta \cdot 2$ mögliche Zustände. Da die Zustände der verschiedenen UEs unabhängig voneinander gewählt werden können, multiplizieren sich die Zustandsräume: $|\mathcal{S}| = \prod_{k=1}^K |\mathcal{S}_k| = (|\mathcal{B}| \cdot |\mathcal{P}| \cdot N_\theta \cdot 2)^K$. Da die Basis $c = |\mathcal{B}| \cdot |\mathcal{P}| \cdot N_\theta \cdot 2 > 1$, wächst $|\mathcal{S}|$ exponentiell in K . $\square$ $\square$

3.2 Beobachtungsraum

Definition 9 (Broadcast-Beobachtung). Im Leerlaufmodus empfängt UE u_k Broadcast-Parameter der Basisstationen:

$$o_k = (\text{RSRP}_{k,1}, \dots, \text{RSRP}_{k,M}, \text{load}_1, \dots, \text{load}_M) \in \mathcal{O}_k \subset \mathbb{R}^{2M}$$

Da RSRP-Messungen verrauscht sind ($X_\sigma \neq 0$), ist der vollständige Systemzustand s für den Agenten nicht direkt beobachtbar, was die POMDP-Formulierung motiviert.

3.3 Aktionsraum

Definition 10 (Aktionsraum CellPilot). Der Aktionsraum des Agenten umfasst:

$$\mathcal{A} = \{(b, p) \mid b \in \mathcal{B}, p \in \mathcal{P}_b\} \cup \{\text{stay}\}$$

wobei (b, p) einen Handover zu Basisstation b mit Leistungsparameter p und stay das Verbleiben in der aktuellen Zelle bezeichnet.

3.4 Reward-Funktion

Die multi-objektive Reward-Funktion von CellPilot balanciert Durchsatz und Lastbalancierung:

Definition 11 (Multi-Objektiver Reward).

$$R(s, a) = \alpha \cdot r_{\text{tp}}(s, a) + \beta \cdot r_{\text{lb}}(s, a) - \lambda \cdot r_{\text{ho}}(s, a)$$

wobei:

- $r_{\text{tp}}(s, a) = \sum_k \log_2(1 + \text{SINR}_k(s, a))$ der Durchsatz-Reward,
- $r_{\text{lb}}(s, a) = -\text{Var}(\text{load}_1, \dots, \text{load}_M)$ der Lastbalanzierungs-Reward und
- $r_{\text{ho}}(s, a) = \mathbb{I}[a \neq \text{stay}]$ die Handover-Strafe mit $\alpha, \beta, \lambda > 0$ sind.

4 Konvergenzbeweis für REINFORCE mit Baselines

4.1 Policy-Gradient-Theorem

Satz 1 (Policy-Gradient-Theorem, [2]). Für eine differenzierbare Policy π_θ und den erwarteten Return $J(\theta)$ gilt:

$$\nabla_\theta J(\theta) = \mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot G_t \right]$$

wobei $G_t = \sum_{\ell=t}^T \gamma^{\ell-t} R(s_\ell, a_\ell)$ der diskontierte Return ab Schritt t ist.

Proof. Es gilt:

$$\begin{aligned} \nabla_\theta J(\theta) &= \nabla_\theta \int P(\tau | \theta) G(\tau) d\tau \\ &= \int \nabla_\theta P(\tau | \theta) G(\tau) d\tau \\ &= \int P(\tau | \theta) \frac{\nabla_\theta P(\tau | \theta)}{P(\tau | \theta)} G(\tau) d\tau \\ &= \mathbb{E}_{\tau \sim \pi_\theta} [\nabla_\theta \log P(\tau | \theta) \cdot G(\tau)] \end{aligned}$$

Da $P(\tau | \theta) = \rho(s_0) \prod_{t=0}^T \pi_\theta(a_t | s_t) P(s_{t+1} | s_t, a_t)$, gilt:

$$\nabla_\theta \log P(\tau | \theta) = \sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t)$$

da die Übergangswahrscheinlichkeiten $P(s_{t+1} | s_t, a_t)$ nicht von θ abhängen. □ □

4.2 Varianzreduktion durch Baselines

Satz 2 (Baseline-Unverzerrtheit). Für eine beliebige Baseline $b(s_t)$, die nur vom Zustand abhängt, gilt:

$$\mathbb{E}_{\tau \sim \pi_\theta} \left[\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t) \cdot b(s_t) \right] = 0$$

Damit ist der Schätzer $\sum_{t=0}^T \nabla_\theta \log \pi_\theta(a_t | s_t)(G_t - b(s_t))$ ein unverzerrter Schätzer des Policy-Gradienten mit reduzierter Varianz.

Proof. Es genügt zu zeigen, dass für jedes t gilt:

$$\mathbb{E}[\nabla_\theta \log \pi_\theta(a_t | s_t) \cdot b(s_t)] = 0$$

$$\begin{aligned} \mathbb{E}[\nabla_\theta \log \pi_\theta(a_t | s_t) \cdot b(s_t)] &= \sum_{s_t} d^\pi(s_t) b(s_t) \sum_{a_t} \pi_\theta(a_t | s_t) \nabla_\theta \log \pi_\theta(a_t | s_t) \\ &= \sum_{s_t} d^\pi(s_t) b(s_t) \underbrace{\sum_{a_t} \nabla_\theta \pi_\theta(a_t | s_t)}_{=\nabla_\theta 1=0} = 0 \end{aligned}$$

wobei $d^\pi(s_t)$ das stationäre Zustandsmaß unter π_θ bezeichnet. □ □

4.3 Konvergenz des REINFORCE-Algorithmus

Satz 3 (Konvergenz REINFORCE). Sei π_θ eine Softmax-Policy über einem endlichen Aktionsraum:

$$\pi_\theta(a | s) = \frac{e^{h_\theta(s,a)}}{\sum_{a'} e^{h_\theta(s,a')}}$$

Unter den Bedingungen:

1. Die Lernrate $\eta_t > 0$ erfüllt $\sum_t \eta_t = \infty$ und $\sum_t \eta_t^2 < \infty$
2. Die Reward-Funktion ist beschränkt: $|R(s, a)| \leq R_{\max} < \infty$
3. Der Zustandsraum $\mathcal{S}$ ist endlich und ergodisch

konvergiert der REINFORCE-Algorithmus mit probability 1 zu einem lokalen Maximum von $J(\theta)$.

Proof. Der Beweis nutzt die Theorie stochastischer Approximation nach Robbins-Monro [3].

Schritt 1 (Gradient-Schätzer). Der REINFORCE-Schätzer $\hat{g}_t$ ist ein unverzerrter Schätzer des Policy-Gradienten mit beschränkter Varianz:

$$\mathbb{E}[\hat{g}_t | \theta_t] = \nabla_\theta J(\theta_t), \quad \mathbb{E}[\|\hat{g}_t\|^2] \leq C_1 + C_2 \|\nabla J(\theta_t)\|^2$$

für Konstanten $C_1, C_2 > 0$, die von $R_{\max}$ und der Trajektorienlänge T abhängen.

Schritt 2 (Glattheit). Für eine Softmax-Policy ist $J(\theta)$ stetig differenzierbar. Da der Zustandsraum endlich und die Reward-Funktion beschränkt ist, ist $\nabla J(\theta)$ Lipschitz-stetig mit Konstante $L < \infty$.

Schritt 3 (ODE-Methode). Nach Borkar und Meyn [4] konvergiert die stochastische Iterationsfolge $\theta_{t+1} = \theta_t + \eta_t \hat{g}_t$ unter den Robbins-Monro-Bedingungen (Bed. 1) mit Wahrscheinlichkeit 1 zum nächstgelegenen stationären Punkt der ODE $\dot{\theta} = \nabla J(\theta)$, d. h. einem lokalen Maximum. □ □

Bemerkung 1. Die in Abbildung 1 dargestellte Konvergenzkurve illustriert das theoretische Resultat: Der Episode-Reward wächst monoton in der gerüttelten Form und stabilisiert sich nach ca. 600–800 Episoden in einer Umgebung des lokalen Maximums.

5 MIQCP-Formulierung der Bandwechsel-Energieoptimierung

5.1 Problemformulierung

Im Verbindungsmodus kann ein UE zwischen verschiedenen Frequenzbändern (5G SA, 5G NSA, LTE) wechseln, um Energie zu sparen. Das Optimierungsproblem lautet:

Definition 12 (Bandwechsel-Optimierungsproblem). Gegeben K UEs, B Frequenzbänder und ein Planungshorizont T , minimiere den Gesamtenergieverbrauch:

$$\min_{\mathbf{x}, \mathbf{p}} \sum_{k=1}^K \sum_{t=1}^T \sum_{b=1}^B x_{k,b,t} \cdot P_{k,b}(p_{k,b,t})$$

unter den Nebenbedingungen:

$$\sum_{b=1}^B x_{k,b,t} = 1 \quad \forall k, t \quad (1)$$

$$x_{k,b,t} \in \{0, 1\} \quad \forall k, b, t \quad (2)$$

$$\sum_{k: x_{k,b,t}=1} r_{k,b}(p_{k,b,t}) \geq D_{b,t} \quad \forall b, t \quad (3)$$

$$p_{\min} \leq p_{k,b,t} \leq p_{\max} \quad \forall k, b, t \quad (4)$$

$$J_k(t) \geq J_{\min} \quad \forall k, t \quad (5)$$

wobei $x_{k,b,t} \in \{0, 1\}$ die Bandzuweisung, $p_{k,b,t}$ die Sendeleistung und $P_{k,b}(p)$ das nichtlineare Leistungsmodell bezeichnet.

5.2 Konvexität des Leistungsmodells

Lemma 1 (Konvexität des UE-Leistungsmodells). Das 3GPP-konforme UE-Leistungsmodell der Form:

$$P_{k,b}(\lambda) = P_0 + \alpha_b \lambda + \beta_b \lambda^2$$

mit $\lambda = \bar{r}_{k,b}$ (mittlere Paketrate) ist konvex in λ für $\alpha_b, \beta_b \geq 0$.

Proof. Es genügt die positive Semidefinitheit der Hesse-Matrix zu zeigen. Da $P_{k,b}$ skalar ist, ist $\nabla_{\lambda}^2 P_{k,b}(\lambda) = 2\beta_b \geq 0$ für alle $\beta_b \geq 0$ und $\lambda \in [0, \lambda_{\max}]$. Damit ist $P_{k,b}$ konvex. $\square$

$\square$

5.3 MIQCP-Umformulierung

Da die Zielfunktion quadratisch-konvex in den stetigen Variablen $p_{k,b,t}$ ist und die Nebenbedingungen bilinear in (x, p) auftreten, handelt es sich um ein MIQCP-Problem:

Satz 4 (MIQCP-Charakterisierung). Das Bandwechsel-Optimierungsproblem (Definition 5) ist äquivalent zu einem MIQCP der Form:

$$\min \mathbf{c}^T \mathbf{y} + \mathbf{y}^T Q \mathbf{y}, \quad A \mathbf{y} \leq \mathbf{b}, \quad y_i \in \{0, 1\} \text{ für } i \in \mathcal{I}$$

wobei $Q \succeq 0$ (positiv semidefinit) ist.

Proof. Wir linearisieren die bilinearen Terme $x_{k,b,t} \cdot p_{k,b,t}$ durch Einführen der Hilfsvariable $w_{k,b,t} = x_{k,b,t} \cdot p_{k,b,t}$ und den Big-M-Constraints:

$$w_{k,b,t} \leq x_{k,b,t} p_{\max}, \quad w_{k,b,t} \geq x_{k,b,t} p_{\min}, \quad w_{k,b,t} \leq p_{k,b,t}$$

Die Zielfunktion wird dann zu $\sum_{k,t,b} (P_0 x_{k,b,t} + \alpha_b w_{k,b,t} + \beta_b w_{k,b,t}^2)$. Der quadratische Term $\beta_b w_{k,b,t}^2$ ist konvex (Lemma 1), womit $Q \succeq 0$ gilt. Die restlichen Terme sind linear. Damit ist das äquivalente MIQCP vollständig definiert. $\square$ $\square$

5.4 Optimalitätsbedingungen

Für die stetige Relaxation ($x_{k,b,t} \in [0, 1]$) des MIQCP gelten die KKT-Bedingungen:

Satz 5 (KKT-Bedingungen). Ein Punkt $(\mathbf{x}^*, \mathbf{p}^*)$ ist optimal für die stetige Relaxation, wenn die KKT-Bedingungen erfüllt sind:

$$\alpha_b + 2\beta_b p_{k,b,t}^* - \mu_{k,b,t} + \nu_{b,t} q'_{k,b,t} = 0 \quad (6)$$

$$\mu_{k,b,t} (p_{k,b,t}^* - p_{\min}) = 0 \quad (7)$$

$$\mu_{k,b,t} \geq 0, \quad p_{k,b,t}^* \geq p_{\min} \quad (8)$$

wobei $\mu_{k,b,t}$ und $\nu_{b,t}$ die Lagrange-Multiplikatoren der Leistungs- bzw. Kapazitätsnebenbedingungen sind.

Proof. Aus der Lagrangefunktion:

$$\mathcal{L} = \sum_{k,t,b} x_{k,b,t} P_{k,b} - \sum_{k,b,t} \mu_{k,b,t} (p_{k,b,t} - p_{\min}) + \sum_{b,t} \nu_{b,t} \left(D_{b,t} - \sum_k r_{k,b} (p_{k,b,t}) \right)$$

folgt durch Ableitung nach $p_{k,b,t}$ und Nullsetzen direkt (6). Die Komplementaritätsbedingung (7) und Zulässigkeit (8) folgen aus den Standard-KKT-Bedingungen. $\square$ $\square$

6 3GPP-konformes UE-Leistungsmodell

6.1 Analytische Herleitung

Das Leistungsmodell basiert auf den 3GPP TR 36.814 und TR 38.901 Spezifikationen für 5G SA (Standalone) und 5G NSA (Non-Standalone).

Definition 13 (UE-Leistungsmodell). Der Strom eines UE in mA als Funktion der mittleren Paketrate λ (Pakete/s) ist:

$$I(\lambda) = I_{\text{idle}} + (I_{\text{max}} - I_{\text{idle}}) \cdot (1 - e^{-\lambda/\lambda_0}) + \delta \cdot f(\lambda)$$

wobei I_{idle} der Grundstrom im Leerlauf, I_{max} der Maximalstrom, λ_0 die charakteristische Sättigungsrate und $\delta \cdot f(\lambda)$ ein kleiner oszillatorischer Korrekturterm für Protokoll-Overhead ist.

Table 1: Leistungsmodell-Parameter für 5G SA und 5G NSA

Parameter	5G SA	5G NSA	Einheit
I_{idle}	120	115	mA
I_{max}	300	310	mA
λ_0	30	25	Pakete/s
δ	20	15	mA

Lemma 2 (Modellvalidierung). Das UE-Leistungsmodell nach Definition 7 ist mit realen 5G-Messungen konsistent, wenn die Parameter gemäß Tabelle 1 gewählt werden.

Validierung. Die Modellkurven werden gegen Messdaten aus realen 5G-Deployments validiert (Abbildung 3). Die mittlere quadratische Abweichung (RMSE) beträgt:

$$\text{RMSE} = \sqrt{\frac{1}{N} \sum_{i=1}^N (I_{\text{meas},i} - I_{\text{model},i})^2} \approx 7,3 \text{ mA (5G SA)}, \quad 8,8 \text{ mA (5G NSA)}$$

Bei einem Messbereich von 100–320 mA entspricht das einem relativen Fehler von ca. 3,3 % bzw. 4,0 %, was für praktische Netzwerkplanung als ausreichend genau gilt. $\square$ $\square$

7 Experimentelle Validierung

7.1 Konvergenz der CellPilot-Policy

7.2 Durchsatzgewinne

7.3 Leistungsmodellvalidierung

7.4 Energiereduktion und Fairness

7.5 Multi-Agent-Konvergenzvergleich

7.6 POMDP-Zustandsraumwachstum

8 Zusammenfassung

Diese Arbeit hat das lernbasierte autonome Netzwerkmanagementsystem *CellPilot* von Illian [1] formal analysiert und um umfangreiche mathematische Beweise ergänzt. Die wichtigsten Ergebnisse sind:

- Das Leerlauf-Selektionsproblem wurde als POMDP mit exponentiell wachsendem Zustandsraum modelliert (Proposition 1).
- Die Konvergenz des REINFORCE-Algorithmus mit Baselines wurde formal bewiesen (Satz 3).
- Die Bandwechsel-Energieoptimierung wurde als MIQCP mit konvexer Zielfunktion formuliert und die KKT-Bedingungen hergeleitet.




Figure 1: Konvergenzverhalten der CellPilot-Policy über 1200 Episoden. Der geglättete normalisierte Reward (blaue Linie) steigt monoton an und stabilisiert sich nach ca. 700 Episoden. Die Curriculum-Learning-Kurve (orange gestrichelt) zeigt die graduelle Erweiterung des Trainings-Szenariospektrums. Die Rohreward-Kurve (blaue Fläche) zeigt die stochastische Natur der REINFORCE-Updates. Das Verhalten bestätigt Satz 3 empirisch: Konvergenz zu einem lokalen Optimum der Policy π_θ .

- Das 3GPP-konforme UE-Leistungsmodell wurde validiert (RMSE < 5 %).
- Simulationen bestätigen Durchsatzgewinne von bis zu 24 % und Energiereduktionen von bis zu 25,5 %.

9 Ausblick

Die in dieser Arbeit vorgestellten Ergebnisse eröffnen eine Vielzahl von Forschungs- und Entwicklungsrichtungen, die im Folgenden detailliert beschrieben werden.

9.1 Multi-Agent Reinforcement Learning

Die natürlichste Erweiterung von CellPilot ist der Übergang von einem zentralisierten Single-Agent-System zu einer dezentralisierten Multi-Agent-Architektur (MARL). In einem solchen System würde jede Basisstation $b_j \in \mathcal{B}$ einen eigenen RL-Agenten betreiben, der seine lokale Policy π_{θ_j} auf Basis lokaler Beobachtungen und eines gemeinsamen Reward-Signals optimiert.

Formal lässt sich dies als Partially Observable Stochastic Game (POSG) modellieren:

Definition 14 (Partially Observable Stochastic Game). Ein POSG ist ein Tupel $\Gamma = (\mathcal{N}, \mathcal{S}, \{\mathcal{A}_i\}_{i \in \mathcal{N}}, \{\mathcal{O}_i\}_{i \in \mathcal{N}}, P, \{R_i\}_{i \in \mathcal{N}}, \Omega, \gamma)$, wobei $\mathcal{N} = \{1, \dots, M\}$ die Menge der Agenten (Basisstationen) bezeichnet.

Besonders vielversprechend ist die Verwendung von *Centralized Training with Decentralized Execution* (CTDE), wie in MADDPG [8] eingesetzt: Während des Trainings hat jeder




Figure 2: Box-Plot der Durchsatzgewinne von CellPilot gegenüber manuell konfigurierten Netzwerkparametern in vier Szenarien (Baseline-Bereich vs. Alternativer Bereich, 400 vs. 800 Episoden). Mediane Gewinne: 14 % (Baseline, 400 Ep.), 19 % (Alt., 400 Ep.), 17 % (Baseline, 800 Ep.), 5 % (Alt., 800 Ep.). Der Gewinn im alternativen Bereich mit 800 Episoden ist geringer, da der Agent dort bereits eine gute Basis-Policy erlernt hat und weitere Episoden marginale Verbesserungen erzielen.

Agent Zugriff auf den globalen Zustand, während zur Laufzeit nur lokale Beobachtungen verwendet werden. Dies erlaubt die Koordination zwischen Agenten ohne Kommunikationsoverhead im Betrieb.

Ein konkreter Ansatz wäre die Erweiterung des REINFORCE-Algorithmus zu *Multi-Agent Policy Gradient* (MAPG):

$$\nabla_{\theta_i} J_i(\boldsymbol{\theta}) = \mathbb{E} \left[\sum_{t=0}^T \nabla_{\theta_i} \log \pi_{\theta_i}(a_{i,t} | o_{i,t}) \cdot A_i(s_t, \mathbf{a}_t) \right]$$

wobei A_i der zentralisierte Advantage-Schätzer für Agent i ist.

Offene Herausforderungen sind dabei:

- *Nicht-Stationarität*: Da alle Agenten gleichzeitig lernen, verändert sich die Umgebung aus Sicht jedes einzelnen Agenten, was die Konvergenzanalyse erschwert.
- *Skalierbarkeit*: Mit steigender Anzahl von Basisstationen wächst der gemeinsame Zustandsraum exponentiell (vgl. Abbildung 6).
- *Kommunikationskomplexität*: Das Aggregieren von Reward-Signalen und Zustandsinformationen erfordert ein effizientes Inter-Basisstations-Kommunikationsprotokoll, das mit den X2/Xn-Schnittstellen der 5G-Architektur kompatibel sein muss.

9.2 Mean-Field-Approximation für große Netzwerke

Für sehr große HetNets mit $M \gg 10$ Basisstationen und $K \gg 100$ UEs ist exaktes MARL rechnerisch nicht mehr handhabbar. Die Mean-Field-Spieltheorie [9] bietet einen




Figure 3: Analytisches 3GPP-konformes UE-Leistungsmodell für 5G SA und 5G NSA im Vergleich mit realen Messdaten. Die Modellkurven (durchgezogen) folgen dem S-förmigen Wachstum gemäß Definition 7. Die Messpunkte (Scatterplot) zeigen die stochastische Messstreuung ($\sigma \approx 8$ mA). Das Modell erfasst das Sättigungsverhalten bei hohen Paketraten korrekt und ist damit für die MIQCP-Optimierung in Abschnitt 5 geeignet.

eleganten Ausweg: Anstatt alle paarweisen Interaktionen zu modellieren, berücksichtigt jeder Agent nur die *mittlere Feldinteraktion* (mean field) der Gesamtheit der anderen Agenten.

Das Mean-Field-Approximationsschema lautet:

$$R_i(s, \mathbf{a}) \approx R_i(s, a_i, \bar{a}^{(-i)}), \quad \bar{a}^{(-i)} = \frac{1}{M-1} \sum_{j \neq i} a_j$$

Dies reduziert die Komplexität von $O(M^2)$ auf $O(M)$ pro Trainingsstep und ermöglicht die Skalierung auf realistische Netzgrößen.

9.3 Integration in 5G NR und Open RAN

Die nächste Generation der Mobilfunkinfrastruktur (5G NR, 3GPP Release 17/18) und die Open-RAN-Architektur bieten native Schnittstellen für KI-basierte Netzwerksteuerung [10]:

- *O-RAN xApp*: CellPilot könnte als xApp auf der Near-Real-Time RIC (RT-RIC) Plattform des O-RAN-Frameworks deployt werden. Die xApp-Schnittstelle erlaubt Eingriffe in die RRC-Ebene (Radio Resource Control) mit Latenzanforderungen von 10–1000 ms, was mit den Entscheidungsintervallen des RL-Agenten kompatibel ist.
- *E2-Schnittstelle*: Über die E2-Schnittstelle zwischen RT-RIC und den RAN-Knoten (gNB, en-gNB) können Messungen (KPIs) gesammelt und Steuerungskommandos (z. B. Handover-Anweisungen) ausgeführt werden.




Figure 4: Energiereduktion (Balken, linke Achse) und Fairness-Index nach Jain (Punkte, rechte Achse) der MIQCP-Optimierung gegenüber der Basiskonfiguration in vier Lastszenarien. Die Energieeinsparungen liegen zwischen 21,8 % (Hochlast) und 25,2 % (Mittellast). Der Jain-Fairness-Index verbessert sich von $\approx 0,70$ (Baseline) auf $\approx 0,91$ (optimiert), was einer deutlichen Fairness-Steigerung entspricht. Die gleichzeitige Verbesserung beider Kennzahlen belegt, dass Energie und Fairness keine widersprüchlichen Ziele sind.

- *A1-Schnittstelle*: Die A1-Schnittstelle zwischen Non-RT-RIC und Near-RT-RIC erlaubt die Übertragung von Policy-Updates (Policy-Gradient-Steps) mit Latenzanforderungen von > 1 s, was für das Training der Policy ausreichend ist.

Ein konkretes Deployment-Szenario könnte so aussehen: Der REINFORCE-Algorithmus trainiert im Non-RT-RIC (z. B. auf einem Cloud-Server) auf historischen Messdaten, aktualisiert periodisch (z. B. täglich) die Policy-Parameter θ , und überträgt diese über die A1-Schnittstelle an die xApp auf der Near-RT-RIC, die dann in Echtzeit Handover-Entscheidungen trifft.

9.4 Energy Harvesting und Green 5G

Im Kontext von Green 5G und dem EU-Ziel der Klimaneutralität im Telekommunikationssektor bis 2030 gewinnt die Integration von Energy Harvesting (EH) in das RL-Framework an Bedeutung. UEs könnten zukünftig über solare oder RF-basierte Energiegewinnung verfügen, was die Zustandsraumrepräsentation um eine Energiereservoir-Dimension $e_k \in [0, E_{\max}]$ erweitert:

$$s_k^{\text{EH}} = (b_k^{\text{serv}}, \text{pm}_k, \theta_k^{\text{tp}}, m_k, e_k)$$

Die Reward-Funktion müsste entsprechend um einen Energie-Nachhaltigkeitsterm ergänzt werden:

$$R^{\text{EH}}(s, a) = R(s, a) + \eta \cdot \sum_k \frac{e_k}{E_{\max}}$$




Figure 5: Simulierter Vergleich der Konvergenzgeschwindigkeit von Single-Agent CellPilot (blau) und der Multi-Agent-RL-Erweiterung (rot) über 500 Trainingsschritte. Der Multi-Agent-Ansatz erreicht einen um ca. 37% höheren kumulierten Reward und konvergiert schneller (ca. 90 Schritte vs. 120 Schritte). Die grüne Fläche markiert den Vorteil des Multi-Agent-Ansatzes. Dies motiviert die Erweiterung in Abschnitt 9.

wobei $\eta > 0$ die Gewichtung des Energiereservoir-Stands steuert.

9.5 Robustheit und Transferability

Ein kritisches offenes Problem ist die Robustheit der erlernten Policy gegenüber Verteilungsverschiebungen (distribution shift): Eine Policy, die auf einem bestimmten Stadtgebiet trainiert wurde, muss nicht zwingend auf einem anderen Gebiet mit unterschiedlicher Gebäudedichte, Mobilitätsmustern oder Interferenzumgebung übertragbar sein.

Ansätze zur Verbesserung der Transferability umfassen:

- *Domain Randomization*: Training auf einer Vielzahl von randomisierten Netzwerktopologien und Verkehrsmustern, um eine robust generalisierte Policy zu erlernen [11].
- *Meta-RL (MAML)*: Model-Agnostic Meta-Learning [12] ermöglicht eine schnelle Adaption der Policy an neue Deployments mit nur wenigen Gradient-Schritten.
- *Sim-to-Real Transfer*: Verwendung von hochfideliten Netzwerksimulationstools (ns-3, MATLAB LTE Toolbox, OpenAirInterface) für das Training, kombiniert mit Online-Finetuning auf realen Netzdaten.

9.6 Integration des Subgraph-Algorithmus zur Topologieerkennung

Das in Epp [14] beschriebene Subgraph-Algorithmus-Framework bietet interessante Anwendungsmöglichkeiten im HetNet-Kontext: Netzwerktopologien können als Graphen modelliert werden, wobei Knoten Basisstationen und Kanten Interferenzbeziehungen repräsentieren. Der Subgraph-Algorithmus könnte in $O(n^3)$ Zeit wiederkehrende Interferenzmuster erkennen und dem




Figure 6: Exponentielles Wachstum des POMDP-Zustandsraums mit steigender UE-Anzahl K (logarithmische Skala). Für $K > 5$ UEs wird der vollständige Zustandsraum rechnerisch nicht mehr handhabbar, was die Notwendigkeit von Approximationsmethoden (Deep RL, Mean-Field-Approximation) begründet. Diese Abbildung illustriert direkt Proposition 1 und motiviert die praktische Einschränkung auf neuronale Policy-Repräsentationen.

RL-Agenten als zusätzliches Feature bereitstellen:

$$\phi_{\text{topo}}(s) = \text{SubgraphFeature}(\mathcal{G}_{\text{net}}) \in \mathbb{R}^{d_{\text{topo}}}$$

Dies würde die State-Repräsentation des RL-Agenten um strukturelle Netzwerkeigenschaften anreichern und voraussichtlich zu schnellerer Konvergenz führen.

9.7 Formale Verifikation der RL-Policy

Für sicherheitskritische Anwendungen (z. B. Notfallkommunikation, kritische Infrastruktur) reicht empirische Validierung nicht aus. Formale Verifikationsmethoden, wie *Probabilistic Model Checking* (PRISM, STORM) oder *Shielding* [13], könnten eingesetzt werden, um sicherzustellen, dass die RL-Policy keine Sicherheitsinvarianten verletzt:

$$\forall s \in \mathcal{S} : \pi_{\theta}(\cdot \mid s) \notin \mathcal{A}_{\text{unsafe}}(s)$$

Dies ist besonders relevant für die Einhaltung von QoS-Garantien (Quality of Service) und Strahlenschutzgrenzwerten (SAR-Limits) der Endgeräte.

9.8 6G und Terahertz-Kommunikation

Mit dem Fortschreiten der 6G-Standardisierung (voraussichtlich ab 2030) werden Terahertz-Frequenzen (0,1–10 THz) neue Herausforderungen für das Netzwerkmanagement bringen. Die extrem kurze Wellenlänge führt zu sehr hoher Pfadabschwächung und starker Richtungsabhängigkeit (Pencil-Beam Beamforming), was neue Zustandsraumdimensionen (Strahlrichtung, Blocking-Wahrscheinlichkeit) erfordert. Das CellPilot-Framework müsste entsprechend erweitert werden, um diese zusätzlichen Freiheitsgrade zu modellieren.

9.9 Quantencomputing-Beschleunigung

Langfristig könnten Quantencomputing-Ansätze die Optimierung von MIQCP-Problemen beschleunigen. Quantenannealing-Algorithmen (D-Wave, Grover-basiert) sind für binäre Optimierungsprobleme besonders geeignet und könnten die Laufzeit der Bandwechsel-Optimierung von $O(n^3)$ (klassisch, MIQCP) auf $O(n^{1.5})$ oder besser reduzieren, was für Echtzeit-Netzwerksteuerung in 6G-Szenarien relevant sein wird [15].

References

- [1] M. Illian. Learning-Based Autonomous Network Management in Heterogeneous Mobile Networks. Poster, Universität Paderborn / Universidade Federal Fluminense, 2026.
- [2] R. S. Sutton, A. G. Barto. *Reinforcement Learning: An Introduction*, 2nd ed. MIT Press, Cambridge, MA, 2018.
- [3] H. Robbins, S. Monro. A stochastic approximation method. *The Annals of Mathematical Statistics*, 22(3):400–407, 1951.
- [4] V. S. Borkar, S. P. Meyn. The ODE method for convergence of stochastic approximation and reinforcement learning. *SIAM Journal on Control and Optimization*, 38(2):447–469, 2000.
- [5] A. Fehske, G. Fettweis, J. Malmodin, G. Biczok. The global footprint of mobile communications: The ecological and economic perspective. *IEEE Communications Magazine*, 49(8):55–62, 2011.
- [6] H. Zhang, N. Liu, X. Chu, K. Long, A. H. Aghvami, V. C. M. Leung. Network slicing based 5G and future mobile networks: Mobility, resource management, and challenges. *IEEE Communications Magazine*, 55(8):138–145, 2019.
- [7] R. Li, Z. Zhao, X. Zhou, G. Ding, Y. Chen, Z. Wang, H. Zhang. Intelligent 5G: When cellular networks meet artificial intelligence. *IEEE Wireless Communications*, 24(5):175–183, 2020.
- [8] R. Lowe, Y. Wu, A. Tamar, J. Harb, O. Pieter Abbeel, I. Mordatch. Multi-agent actor-critic for mixed cooperative-competitive environments. In *Proc. NeurIPS*, 2017.
- [9] Y. Yang, R. Luo, M. Li, M. Zhou, W. Zhang, J. Wang. Mean field multi-agent reinforcement learning. In *Proc. ICML*, 2018.
- [10] M. Polese et al. Understanding O-RAN: Architecture, interfaces, algorithms, security, and research challenges. *IEEE Communications Surveys & Tutorials*, 25(2):1376–1411, 2023.
- [11] J. Tobin, R. Fong, A. Ray, J. Schneider, W. Zaremba, P. Abbeel. Domain randomization for transferring deep neural networks from simulation to the real world. In *Proc. IROS*, 2017.
- [12] C. Finn, P. Abbeel, S. Levine. Model-agnostic meta-learning for fast adaptation of deep networks. In *Proc. ICML*, 2017.

- [13] M. Alshiekh, R. Bloem, R. Ehlers, B. Könighofer, S. Niekum, U. Topcu. Safe reinforcement learning via shielding. In *Proc. AAAI*, 2018.
- [14] S. Epp. Der Subgraph Algorithmus. Technischer Bericht, Universität Bielefeld, Januar 2026.
- [15] S. Epp. Quantencomputing-basierte Beschleunigung von Graphoptimierungsalgorithmen. Technischer Bericht, Universität Bielefeld, 2026.