

Plot 8: Zusammenfassung - Äquivalenz und Verallgemeinerung

GRADIENT vs. JACOBI-MATRIX: Äquivalenz und Verallgemeinerung

EIGENSCHAFT	GRADIENT	JACOBI-MATRIX
Definition	$f: \mathbb{R}^n \rightarrow \mathbb{R}$ (nur Skalar)	$f: \mathbb{R}^n \rightarrow \mathbb{R}^m$ (beliebig)
Größe	n-Vektor (Spaltenform)	$m \times n$ Matrix (Zeilenform: $1 \times n$)
Formel (m=1)	$\nabla f = (\partial f / \partial x_1, \dots \partial f / \partial x_n)^T$ $J_f = [\partial f / \partial x_1, \dots \partial f / \partial x_n]$ Also: $\nabla f = J_f^T$ ✓ ÄQUIVALENT	
Kettenregel	$\nabla(g \circ f) = (\nabla g)(f) \cdot \nabla f$ $J_{\{g \circ f\}} = J_g(f) \cdot J_f$ (Äquivalent bei Transposition) ✓	
Richtungsableitung	$D_v f = \nabla f^T \cdot v$ vs. $D_v f = J_f \cdot v$ Äquivalent ✓	
Optimierung (Grad. Descent)	$x_{k+1} = x_k - \alpha \nabla f$ vs. $x_{k+1} = x_k - \alpha J_f^T$ Numerisch identisch ✓	
Implizite Funktionen	NICHT GEEIGNET (Nur Skalarfelder)	$\partial y / \partial x = -J_{F,x} / J_{F,y}$ NOTWENDIG ✓
Vektorfelder (Curl, Div)	Nur $\text{grad}(f)$ für Skalarfelder	div, curl via J Allgemein ✓
Machine Learning (Backprop)	Backprop mit ∇ effizient	Backprop = Jacobi-Matrix-Multiplikation ✓
Verallgemeinerung (m-dim Output)	Stoppt bei $m > 1$ (kein Sinn)	Funktioniert für alle m, n ✓ UNIVERSAL

SCHLUSSFOLGERUNGEN:

- Für $f: \mathbb{R}^n \rightarrow \mathbb{R}$:
Der Gradient ist ÄQUIVALENT zur Jacobi-Matrix: $\nabla f = J_f^T$
(mathematisch und numerisch identisch)
- Die Jacobi-Matrix ist eine ECHTE VERALLGEMEINERUNG auf beliebige vektorwertige Funktionen $f: \mathbb{R}^n \rightarrow \mathbb{R}^m$
- In modernen Anwendungen (ML, Physik) ist die Jacobi-Matrix strukturell ÜBERLEGEN und universeller.
- Der Gradient bleibt nützlich für Intuition und Notation, aber mathematisch NICHT NOTWENDIG – alles kann durch die Jacobi-Matrix ausgedrückt werden.