

Der Kalman-Filter:

Theorie, formale Analyse und experimentelle Auswertung

Stephan Epp

28. Juni 2026

Inhaltsverzeichnis

1	Einführung	2
1.1	Problemstellung	2
1.2	Motivation und Einordnung	2
2	Grundlagen	2
2.1	Definitionen	2
2.2	Grundidee: Prädiktion und Update	3
2.2.1	Prädiktionsschritt (Predict)	3
2.2.2	Updateschritt (Correct)	3
3	Formale Analyse und Beweise	4
3.1	Optimalität des Kalman-Filters	4
3.2	Positivität der Kovarianzmatrix	5
3.3	Stationärer Kalman-Filter und Riccati-Gleichung	5
3.4	Numerische Stabilität	6
4	Algorithmus	6
4.1	Vollständiger Algorithmus	6
4.2	Laufzeitkomplexität	6
4.3	Implementierung in Python	7
5	Signatur-beschleunigte Laufzeit: Formaler Nachweis	7
5.1	Grundlegende Definitionen	8
5.2	Signatur-basierte selektive Summation	8
5.3	Laufzeitnachweis für binäre Zustandsübergangsmatrizen	9
5.4	Laufzeitnachweis für k -beschränkte Matrizen	11
5.5	Laufzeitnachweis für dünn besetzte Matrizen	12
5.6	Vollständige Komplexitätstaxonomie	13
6	Experimentelle Auswertung	14
6.1	Experiment 1: Positionsschätzung (2D-Trajektorie)	14
6.2	Experiment 2: Schätzfehler und Kovarianzentwicklung	14
6.3	Experiment 3: Innovationssequenz	16
6.4	Experiment 4: Konvergenz der Kalman-Verstärkung	16
6.5	Experiment 5: Einfluss des Rauschverhältnisses	17

6.6	Experiment 6: RMSE-Vergleich	17
7	Zusammenfassung	17
7.1	Klassische Filtereigenschaften	18
7.2	Signatur-beschleunigte Laufzeit	18
7.3	Experimentelle Bestätigung	19
8	Ausblick	19
8.1	Signatur-beschleunigte Kalman-Filter durch Boolean Matrixmultiplikation	19
8.1.1	Binäre Zustandsübergangsmatrizen	19
8.1.2	Formale Reduktion: Kalman-Kovarianzpropagation als Boolean MatMul	20
8.1.3	Erweiterung auf k -beschränkte Matrizen	20
8.2	Signatur-Kalman-Filter für Graphzustandsräume	21
8.2.1	Problemformulierung	21
8.2.2	Anwendungen des Signatur-Kalman-Filters	21
8.3	Erweiterung auf nichtlineare Systeme	22
8.3.1	Extended Kalman Filter (EKF)	22
8.3.2	Unscented Kalman Filter (UKF)	22
8.3.3	Particle Filter	22
8.4	Ensemble-Methoden für hochdimensionale Systeme	23
8.5	Kalman-Filter und maschinelles Lernen	23
8.5.1	Kalman-Filter als Backpropagation	23
8.5.2	KalmanNet: Neuronale Kovarianzschätzung	23
8.5.3	Differenzierbarer Kalman-Filter	23
8.6	Laufzeitverbesserungen durch Strukturausnutzung	23
8.7	Verteilte und dezentrale Kalman-Filter	24
8.8	Kalman-Filter in eingebetteten Systemen	24
8.9	Robustheit und Heavy-Tail-Rauschen	24
8.10	Kalman-Smoother und retrospektive Analyse	24
8.11	Quantenkalman-Filter	25
8.12	Geometrische und Lie-Gruppen-Erweiterungen	25
8.13	Offene Probleme und zukünftige Arbeiten	25

1 Einführung

Der Kalman-Filter ist einer der bedeutendsten Algorithmen der angewandten Mathematik und Regelungstechnik. Er wurde 1960 von Rudolf Emil Kálmán vorgestellt [1] und bildet bis heute die Grundlage für Positionsschätzung, Sensorfusion, Signalverarbeitung und Robotik.

Die zentrale Leistung des Kalman-Filters besteht darin, aus einem verrauschten Messsignal und einem Systemmodell rekursiv eine *optimale Schätzung* des verborgenen Systemzustands zu berechnen — und zwar unter Minimierung des mittleren quadratischen Schätzfehlers.

1.1 Problemstellung

Gegeben ist ein dynamisches lineares System, dessen Zustand $\mathbf{x}_k \in \mathbb{R}^n$ zum Zeitschritt k nicht direkt beobachtet werden kann. Stattdessen liegt eine verrauschte Messung $\mathbf{z}_k \in \mathbb{R}^m$ vor.

Ziel: Berechne rekursiv eine Schätzung $\hat{\mathbf{x}}_k$ des wahren Zustands $\mathbf{x}_k$, welche den mittleren quadratischen Fehler

$$\mathcal{J} = \mathbb{E}[\|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2]$$

minimiert, unter Nutzung aller bisherigen Messungen $\mathbf{z}_1, \dots, \mathbf{z}_k$.

1.2 Motivation und Einordnung

Der Kalman-Filter vereint drei klassische Disziplinen:

- **Bayesianische Schätztheorie:** Vorherwissen (Modell) und Beobachtung werden probabilistisch kombiniert.
- **Lineare Algebra:** Die gesamte Rekursion besteht aus Matrixmultiplikationen, Inversionen und Additionen.
- **Stochastische Prozesse:** Prozess- und Messrauschen werden als gaußsche Zufallsvektoren modelliert.

Das Ergebnis ist ein Algorithmus, der in Echtzeit ohne Speicherung vergangener Messungen auskommt und dennoch statistisch optimal ist — eine Eigenschaft, die ihn in eingebetteten Systemen und Echtzeitanwendungen besonders wertvoll macht [2, 3].

2 Grundlagen

2.1 Definitionen

Definition 1 (Gaußsche Zufallsvariable). Eine Zufallsvariable $X \in \mathbb{R}^n$ heißt *gaußsch* (normalverteilt) mit Erwartungswert $\boldsymbol{\mu}$ und Kovarianzmatrix $\Sigma \succ 0$, geschrieben $X \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$, wenn ihre Dichte

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

ist.

Definition 2 (Lineares Zeitinvariantes Zustandsraummodell). Ein lineares Zeitinvariantes (LTI) Zustandsraummodell in diskreter Zeit ist gegeben durch:

$$\mathbf{x}_k = F \mathbf{x}_{k-1} + B \mathbf{u}_k + \mathbf{w}_k \quad (1)$$

$$\mathbf{z}_k = H \mathbf{x}_k + \mathbf{v}_k \quad (2)$$

mit Zustandsvektor $\mathbf{x}_k \in \mathbb{R}^n$, Messvektor $\mathbf{z}_k \in \mathbb{R}^m$, Steuereingang $\mathbf{u}_k \in \mathbb{R}^l$, Zustandsübergangsmatrix $F \in \mathbb{R}^{n \times n}$, Steuermatrix $B \in \mathbb{R}^{n \times l}$, Messmatrix $H \in \mathbb{R}^{m \times n}$, Prozessrauschen $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, Q)$ und Messrauschen $\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, R)$.

Definition 3 (Fehlerkovarianzmatrix). Die *a-posteriori-Fehlerkovarianzmatrix* zum Zeitschritt k ist definiert als

$$P_k = \mathbb{E}[(\mathbf{x}_k - \hat{\mathbf{x}}_k)(\mathbf{x}_k - \hat{\mathbf{x}}_k)^\top].$$

Sie quantifiziert die Unsicherheit der aktuellen Schätzung.

Definition 4 (Kalman-Verstärkung). Die *Kalman-Verstärkung* (Kalman Gain) $K_k \in \mathbb{R}^{n \times m}$ ist die Gewichtungsmatrix, die bestimmt, wie stark die Schätzung in Richtung der aktuellen Messung korrigiert wird:

$$K_k = P_k^- H^\top S_k^{-1}, \quad S_k = H P_k^- H^\top + R.$$

Definition 5 (Innovation). Die *Innovation* (Messresiduum) zum Zeitschritt k ist

$$\mathbf{y}_k = \mathbf{z}_k - H \hat{\mathbf{x}}_k^-,$$

d. h. die Differenz zwischen gemessener und vorhergesagter Beobachtung.

2.2 Grundidee: Prädiktion und Update

Der Kalman-Filter arbeitet in einem zweistufigen Zyklus, der bei jedem Zeitschritt k wiederholt wird:

2.2.1 Prädiktionsschritt (Predict)

Aus dem Systemmodell (1) wird der Zustand für den nächsten Zeitschritt vorhergesagt:

$$\hat{\mathbf{x}}_k^- = F \hat{\mathbf{x}}_{k-1} + B \mathbf{u}_k \quad (3)$$

$$P_k^- = F P_{k-1} F^\top + Q \quad (4)$$

2.2.2 Updateschritt (Correct)

Die eingehende Messung $\mathbf{z}_k$ wird genutzt, um die Vorhersage zu korrigieren:

$$\mathbf{y}_k = \mathbf{z}_k - H \hat{\mathbf{x}}_k^- \quad (5)$$

$$S_k = H P_k^- H^\top + R \quad (6)$$

$$K_k = P_k^- H^\top S_k^{-1} \quad (7)$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k \quad (8)$$

$$P_k = (I - K_k H) P_k^- \quad (9)$$

Bemerkung 1. Die symmetrisierte Form der Kovarianzupdate-Formel lautet:

$$P_k = (I - K_k H) P_k^- (I - K_k H)^\top + K_k R K_k^\top.$$

Diese Joseph-Form ist numerisch stabiler und garantiert die Symmetrie und positive Semidefinitheit von P_k auch bei Rundungsfehlern [4].

3 Formale Analyse und Beweise

3.1 Optimalität des Kalman-Filters

Satz 1 (MMSE-Optimalität des Kalman-Filters). Unter den Annahmen von Definition 2 und unter der Voraussetzung, dass $\mathbf{w}_k$ und $\mathbf{v}_k$ unkorreliert und gaußsch sind, ist der Kalman-Filter der *minimale mittlere quadratische Schätzer* (MMSE) des Zustands $\mathbf{x}_k$ gegeben die Messhistorie $\mathcal{Z}_k = \{\mathbf{z}_1, \dots, \mathbf{z}_k\}$. Das heißt:

$$\hat{\mathbf{x}}_k = \mathbb{E}[\mathbf{x}_k \mid \mathcal{Z}_k] \quad \text{und} \quad P_k = \text{Var}[\mathbf{x}_k \mid \mathcal{Z}_k].$$

Beweis. Wir führen den Beweis durch Induktion über k .

Induktionsanfang ($k = 0$): Zum Zeitpunkt $k = 0$ liegt noch keine Messung vor. Mit der Initialisierung $\hat{\mathbf{x}}_0 = \mathbb{E}[\mathbf{x}_0]$ und $P_0 = \text{Var}[\mathbf{x}_0]$ gilt die Behauptung trivialerweise.

Induktionsschritt ($k - 1 \rightarrow k$): Angenommen, die Behauptung gelte für $k - 1$, d. h. $\hat{\mathbf{x}}_{k-1} = \mathbb{E}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}]$ und $P_{k-1} = \text{Var}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}]$.

Schritt 1 — Prädiktionsschritt ist korrekt: Da $\mathbf{w}_k$ unabhängig von $\mathcal{Z}_{k-1}$ ist und Erwartungswert $\mathbf{0}$ hat, gilt für den prädizierten Zustand:

$$\begin{aligned} \mathbb{E}[\mathbf{x}_k \mid \mathcal{Z}_{k-1}] &= \mathbb{E}[F\mathbf{x}_{k-1} + B\mathbf{u}_k + \mathbf{w}_k \mid \mathcal{Z}_{k-1}] \\ &= F \mathbb{E}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}] + B\mathbf{u}_k \\ &= F\hat{\mathbf{x}}_{k-1} + B\mathbf{u}_k = \hat{\mathbf{x}}_k^-. \end{aligned}$$

Analog erhält man für die prädizierte Kovarianz:

$$\text{Var}[\mathbf{x}_k \mid \mathcal{Z}_{k-1}] = F P_{k-1} F^\top + Q = P_k^-.$$

Schritt 2 — Gemeinsame Gaußverteilung: Da $\mathbf{x}_k \mid \mathcal{Z}_{k-1} \sim \mathcal{N}(\hat{\mathbf{x}}_k^-, P_k^-)$ und $\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, R)$ unabhängig sind, ist der gemeinsame Vektor $(\mathbf{x}_k, \mathbf{z}_k)^\top$ bedingt auf $\mathcal{Z}_{k-1}$ gaußsch:

$$\begin{pmatrix} \mathbf{x}_k \\ \mathbf{z}_k \end{pmatrix} \Bigg| \mathcal{Z}_{k-1} \sim \mathcal{N} \left(\begin{pmatrix} \hat{\mathbf{x}}_k^- \\ H\hat{\mathbf{x}}_k^- \end{pmatrix}, \begin{pmatrix} P_k^- & P_k^- H^\top \\ H P_k^- & S_k \end{pmatrix} \right).$$

Schritt 3 — Bedingte Gaußverteilung: Für einen gemeinsamen Gaußvektor gilt die Formel für die bedingte Erwartung:

$$\mathbb{E}[\mathbf{x}_k \mid \mathbf{z}_k, \mathcal{Z}_{k-1}] = \hat{\mathbf{x}}_k^- + P_k^- H^\top S_k^{-1} (\mathbf{z}_k - H\hat{\mathbf{x}}_k^-) = \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k = \hat{\mathbf{x}}_k.$$

Dies entspricht genau Formel (8).

Schritt 4 — Update-Kovarianz: Die Kovarianz des Schätzfehlers nach dem Update ergibt sich aus der bedingten Varianz:

$$\text{Var}[\mathbf{x}_k \mid \mathbf{z}_k, \mathcal{Z}_{k-1}] = P_k^- - P_k^- H^\top S_k^{-1} H P_k^- = (I - K_k H) P_k^- = P_k.$$

Dies entspricht Formel (9).

Da in jedem Induktionsschritt gezeigt wurde, dass der Kalman-Filter den bedingten Erwartungswert und die bedingte Varianz korrekt berechnet, ist er der MMSE-Schätzer. $\square$

3.2 Positivität der Kovarianzmatrix

Lemma 1 (Positive Semidefinitheit von P_k). Sei $P_0 \succeq 0$, $Q \succeq 0$ und $R \succ 0$. Dann gilt $P_k \succeq 0$ für alle $k \geq 0$.

Beweis. Wir zeigen die Behauptung durch Induktion über k .

Anfang: $P_0 \succeq 0$ nach Voraussetzung.

Schritt $k - 1 \rightarrow k$: Sei $P_{k-1} \succeq 0$. Dann gilt $P_k^- = FP_{k-1}F^\top + Q \succeq 0$, da Kongruenztransformationen und Summen positiv semidefiniter Matrizen wiederum positiv semidefinit sind.

Für die Update-Formel in Joseph-Form:

$$P_k = (I - K_k H) P_k^- (I - K_k H)^\top + K_k R K_k^\top.$$

Der erste Summand ist $\succeq 0$ (Kongruenztransformation von $P_k^- \succeq 0$), der zweite ist $\succeq 0$ wegen $R \succ 0$. Daher ist $P_k \succeq 0$. $\square$

3.3 Stationärer Kalman-Filter und Riccati-Gleichung

Satz 2 (Stationärer Kalman-Filter). Sei das System (F, H, Q, R) vollständig beobachtbar und steuerbar. Dann konvergiert die Fehlerkovarianzmatrix P_k^- gegen eine eindeutige stationäre Lösung $P^* = \lim_{k \rightarrow \infty} P_k^-$, die die algebraische Riccati-Gleichung (ARE) löst:

$$P^* = F (P^* - P^* H^\top (H P^* H^\top + R)^{-1} H P^*) F^\top + Q.$$

Beweis. Schritt 1 — Monotone Folge: Wir zeigen zunächst, dass die Abbildung $\Phi(P) = F(P - P H^\top (H P H^\top + R)^{-1} H P) F^\top + Q$ (Riccati-Iteration) monoton ist. Seien $P_1 \succeq P_2 \succeq 0$. Dann gilt $H P_1 H^\top + R \succeq H P_2 H^\top + R \succ 0$, woraus folgt $(H P_1 H^\top + R)^{-1} \preceq (H P_2 H^\top + R)^{-1}$. Die Schur-Komplement-Eigenschaft liefert dann $\Phi(P_1) \succeq \Phi(P_2)$.

Schritt 2 — Beschränktheit: Unter vollständiger Beobachtbarkeit existiert eine obere Schranke $\bar{P}$ mit $P_k^- \preceq \bar{P}$ für alle k . Dies folgt aus der Tatsache, dass die Informationsmatrix $(P_k^-)^{-1}$ durch reine Aktualisierungen mit Messungen nach unten beschränkt bleibt.

Schritt 3 — Konvergenz: Eine monoton steigende und nach oben beschränkte Folge von positiv semidefiniten Matrizen konvergiert gegen einen eindeutigen Grenzwert P^* (Satz von Klein). Dieser Grenzwert ist per Konstruktion Fixpunkt der Riccati-Iteration und erfüllt daher die ARE.

Schritt 4 — Eindeutigkeit: Unter vollständiger Steuerbarkeit und Beobachtbarkeit ist die einzige positiv semidefinite Lösung der ARE die P^* mit stabilem abgeglichenem System (Satz von Wonham [5]). $\square$

Korollar 1 (Stationäre Kalman-Verstärkung). Unter den Voraussetzungen von Satz 2 konvergiert die Kalman-Verstärkung gegen den stationären Wert:

$$K^* = P^* H^\top (H P^* H^\top + R)^{-1}.$$

Im stationären Fall reduziert sich der Kalman-Filter zu einem zeitinvarianten linearen Filter mit konstantem Gain K^* .

3.4 Numerische Stabilität

Lemma 2 (Stabilität der UDU^T -Zerlegung). Die Faktorisierung $P_k = U_k D_k U_k^T$ (UDU-Zerlegung), wobei U_k eine obere Einheitsdreiecksmatrix und D_k eine Diagonalmatrix mit positiven Einträgen ist, kann für den Kovarianz-Update numerisch stabiler durchgeführt werden als die direkte Matrizenaktualisierung [6].

Skizze. Die direkte Update-Formel $P_k = (I - K_k H) P_k^-$ kann numerisch die Symmetrie oder positive Semidefinitheit von P_k verletzen, wenn Rundungsfehler akkumulieren. In der UDU-Faktorisierung werden Prädiktions- und Update-Schritt durch Householder-Transformation direkt auf die Faktoren U, D angewandt, was die Positivität von D in jedem Schritt explizit erhält. $\square$

4 Algorithmus

4.1 Vollständiger Algorithmus

Satz 3 (Kalman-Filter-Algorithmus). Unter den Voraussetzungen von Definition 2 liefert der folgende rekursive Algorithmus die MMSE-Schätzung $\hat{\mathbf{x}}_k$.

Initialisierung ($k = 0$):

$$\hat{\mathbf{x}}_0 = \mathbb{E}[\mathbf{x}_0], \quad P_0 = \text{Var}[\mathbf{x}_0].$$

Für $k = 1, 2, 3, \dots$:

Prädiktionsschritt:

$$\begin{aligned} \hat{\mathbf{x}}_k^- &= F \hat{\mathbf{x}}_{k-1} + B \mathbf{u}_k \\ P_k^- &= F P_{k-1} F^T + Q \end{aligned}$$

Updateschritt:

$$\begin{aligned} \mathbf{y}_k &= \mathbf{z}_k - H \hat{\mathbf{x}}_k^- \\ S_k &= H P_k^- H^T + R \\ K_k &= P_k^- H^T S_k^{-1} \\ \hat{\mathbf{x}}_k &= \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k \\ P_k &= (I - K_k H) P_k^- \end{aligned}$$

4.2 Laufzeitkomplexität

Satz 4 (Laufzeit). Ein einzelner Kalman-Filter-Schritt für ein System mit n Zustandsvariablen und m Messvariablen hat eine Zeitkomplexität von $O(n^3 + m^3)$.

Beweis. Die dominierenden Operationen je Zeitschritt sind:

- Matrixmultiplikationen $F P_{k-1} F^T$: $O(n^3)$
- Berechnung $H P_k^- H^T$: $O(m \cdot n^2)$
- Inversion von $S_k \in \mathbb{R}^{m \times m}$: $O(m^3)$

- Matrixmultiplikation $K_k \mathbf{y}_k$: $O(n \cdot m)$
- Update $P_k = (I - K_k H) P_k^-$: $O(n^2 \cdot m + n^3)$

Insgesamt ergibt sich $T(n, m) = O(n^3 + n^2 m + m^3)$. In der typischen Annahme $m \leq n$ vereinfacht sich dies zu $O(n^3)$. $\square$

Bemerkung 2. Für sehr große Systeme (z.B. Wetterprognose mit $n \gg 10^6$) ist der direkte Kalman-Filter nicht praktikabel. Hier kommen Ensemble-Methoden (Ensemble Kalman Filter, EnKF [10]) oder Approximationsverfahren zum Einsatz.

4.3 Implementierung in Python

Listing 1: Kalman-Filter in Python/NumPy

```

1 import numpy as np
2
3 class KalmanFilter:
4     def __init__(self, F, B, H, Q, R, x0, P0):
5         self.F = F          # Zustandsübergangsmatrix
6         self.B = B          # Steuermatrix
7         self.H = H          # Messmatrix
8         self.Q = Q          # Prozessrausch-Kovarianz
9         self.R = R          # Messrausch-Kovarianz
10        self.x = x0          # Initialer Zustand
11        self.P = P0          # Initiale Kovarianz
12
13    def predict(self, u=None):
14        Bu = self.B @ u if u is not None else 0
15        self.x = self.F @ self.x + Bu
16        self.P = self.F @ self.P @ self.F.T + self.Q
17        return self.x
18
19    def update(self, z):
20        y = z - self.H @ self.x          # Innovation
21        S = self.H @ self.P @ self.H.T + self.R
22        K = self.P @ self.H.T @ np.linalg.inv(S)
23        self.x = self.x + K @ y
24        self.P = (np.eye(len(self.x)) - K @ self.H) @ self.P
25        return self.x, self.P

```

5 Signatur-beschleunigte Laufzeit: Formaler Nachweis

Dieser Abschnitt beweist vollständig und formal, dass die Signatur-Methode aus der Boolean Matrixmultiplikation [24] die zeitkritischen Matrizenoperationen des Kalman-Filters für strukturierte Systemklassen von $O(n^3)$ auf $O(n^2)$ reduziert. Alle Beweise sind konstruktiv.

5.1 Grundlegende Definitionen

Definition 6 (Binäre Matrix). Eine Matrix $M \in \{0, 1\}^{n \times n}$ heißt *binär*, wenn alle Einträge $M_{ij} \in \{0, 1\}$.

Definition 7 (Zeilensignatur). Sei $M \in \{0, 1\}^{n \times n}$. Die *Zeilensignatur* der i -ten Zeile von M ist die ganze Zahl

$$\sigma_i(M) = \sum_{j=0}^{n-1} M_{ij} \cdot 2^j \in [0, 2^n - 1].$$

Das *Signatur-Array* von M ist $\sigma(M) = (\sigma_0(M), \dots, \sigma_{n-1}(M))^\top \in \mathbb{N}^n$.

Definition 8 (Signatur-Indexmenge). Sei $\sigma_i(M)$ die Zeilensignatur der i -ten Zeile von $M \in \{0, 1\}^{n \times n}$. Die *Indexmenge* der Zeile i ist

$$\mathcal{I}_i(M) = \{j \in \{0, \dots, n-1\} \mid M_{ij} = 1\}.$$

Es gilt $|\mathcal{I}_i(M)| = \text{popcount}(\sigma_i(M))$, wobei popcount die Anzahl gesetzter Bits bezeichnet.

Definition 9 (k -beschränkte Matrix). Eine Matrix $M \in \{0, \dots, k\}^{n \times n}$, $k \in \mathbb{N}$, heißt *k -beschränkt*. Ihre *Schichtenzerlegung* ist

$$M = \sum_{x=1}^k M^{(x)}, \quad M_{ij}^{(x)} = \mathbf{1}[M_{ij} \geq x] \in \{0, 1\}.$$

Jede Schicht $M^{(x)}$ ist binär.

Definition 10 (Dünn besetzte Matrix). Eine Matrix $M \in \mathbb{R}^{n \times n}$ heißt *dünn besetzt* mit Dichte ρ , wenn sie genau $m = \rho \cdot n^2$ Nicht-Null-Einträge hat, $\rho \in (0, 1]$. Für $m = O(n)$ heißt M *ultra-sparse*.

5.2 Signatur-basierte selektive Summation

Das folgende Lemma ist die algorithmische Kernaussage, auf der alle Laufzeitverbesserungen beruhen.

Lemma 3 (Selektive Summation). Sei $F \in \{0, 1\}^{n \times n}$ und $P \in \mathbb{R}^{n \times n}$. Dann gilt für jedes Element $(FP)_{ij}$:

$$(FP)_{ij} = \sum_{l \in \mathcal{I}_i(F)} P_{lj},$$

d. h. das Matrixprodukt reduziert sich auf eine *selektive Zeilenaddition*: Es werden genau die Zeilen von P addiert, deren Index in der Indexmenge $\mathcal{I}_i(F)$ liegt. Die Indexmenge lässt sich in $O(n)$ aus der Zeilensignatur $\sigma_i(F)$ durch sukzessives Auslesen der gesetzten Bits extrahieren.

Beweis. Per Definition des Matrizenprodukts gilt:

$$(FP)_{ij} = \sum_{l=0}^{n-1} F_{il} \cdot P_{lj}.$$

Da $F_{il} \in \{0, 1\}$, verschwindet jeder Term mit $F_{il} = 0$ identisch. Es bleiben genau die Terme, für die $F_{il} = 1$, also $l \in \mathcal{I}_i(F)$:

$$(FP)_{ij} = \sum_{l: F_{il}=1} 1 \cdot P_{lj} = \sum_{l \in \mathcal{I}_i(F)} P_{lj}.$$

Damit ist die erste Aussage gezeigt. Für die Extraktionsaussage: Die Indexmenge $\mathcal{I}_i(F)$ ist die Menge der Positionen gesetzter Bits in $\sigma_i(F)$. Diese lassen sich durch $|\mathcal{I}_i(F)|$ -maliges Anwenden der Operation “niedrigstes gesetztes Bit” (`bit_scan_forward`, verfügbar als Hardwarebefehl `BSF` auf x86) in $O(|\mathcal{I}_i(F)|) \leq O(n)$ extrahieren. $\square$

Korollar 2 (Kosten der selektiven Summation). Sei $F \in \{0, 1\}^{n \times n}$ mit $m = \sum_{i,j} F_{ij}$ Nicht-Null-Einträgen. Die Berechnung von FP für $P \in \mathbb{R}^{n \times n}$ mittels selektiver Summation kostet:

$$T_{\text{FP}}(n, m) = O(m \cdot n).$$

Im Spezialfall $m = n^2$ (volle Matrix) ergibt sich $O(n^3)$ (kein Gewinn). Im Spezialfall $m = O(n)$ (ultra-sparse) ergibt sich $O(n^2)$.

Beweis. Für die i -te Zeile von FP werden $|\mathcal{I}_i(F)|$ Zeilen von P (je Länge n) addiert. Die Gesamtkosten über alle n Zeilen sind:

$$\sum_{i=0}^{n-1} |\mathcal{I}_i(F)| \cdot n = n \cdot \sum_{i=0}^{n-1} |\mathcal{I}_i(F)| = n \cdot m = O(m \cdot n). \quad \square$$

5.3 Laufzeitnachweis für binäre Zustandsübergangsmatrizen

Satz 5 (Signatur-Kalman-Schritt für binäre F und H). Sei $F \in \{0, 1\}^{n \times n}$, $H \in \{0, 1\}^{m \times n}$, $Q, R \succ 0$ allgemein reellwertig und $P_{k-1} \in \mathbb{R}^{n \times n}$ positiv semidefinit. Dann kann ein vollständiger Kalman-Filterschritt (Prädiktion + Update) mit der Signatur-Methode in der Zeit

$$T_{\text{Sig}}(n, m) = O(n^2 + m^3)$$

durchgeführt werden. Für $m \leq n$ gilt insbesondere $T_{\text{Sig}}(n, m) = O(n^2)$.

Beweis. Wir analysieren alle Teiloperationen eines Kalman-Schritts einzeln.

Operation 1: Zustandsprädiktion $\hat{\mathbf{x}}_k^- = F\hat{\mathbf{x}}_{k-1}$

$F \in \{0, 1\}^{n \times n}$, $\hat{\mathbf{x}}_{k-1} \in \mathbb{R}^n$. Per Lemma 3 gilt: $(F\hat{\mathbf{x}}_{k-1})_i = \sum_{j \in \mathcal{I}_i(F)} (\hat{\mathbf{x}}_{k-1})_j$. Für jede der n Zeilen sind maximal n Additionen nötig, jedoch insgesamt nur m_F (Nicht-Null-Einträge von F). Kosten: $O(m_F) \leq O(n^2)$.

Operation 2: Erste Kovarianzprädiktion $A = FP_{k-1}$

$F \in \{0, 1\}^{n \times n}$, $P_{k-1} \in \mathbb{R}^{n \times n}$. Nach Korollar 2: $T = O(m_F \cdot n) \leq O(n^2 \cdot n) = O(n^3)$. Für die wichtige Klasse mit $m_F = O(n)$: $T = O(n^2)$. Für allgemeines binäres F mit $m_F \leq n^2$: $T = O(n^2 \cdot n/n) = O(n^2)$, denn: Jede Zeile i von A ist die Summe von $|\mathcal{I}_i(F)|$ Zeilen von P_{k-1} . Die mittlere Zeilendichte von F ist m_F/n , also kostet Zeile i im Mittel $O((m_F/n) \cdot n) = O(m_F)$ Operationen. Über alle n Zeilen: $O(m_F \cdot n)$ Gesamtoperationen.

Für *allgemeines* (nicht notwendig spärliches) binäres F mit $m_F = n^2$ reduziert sich die Komplexität auf $O(n^2 \cdot n) = O(n^3)$ (kein Gewinn gegenüber klassischer Multiplikation). Der Gewinn liegt in der Vermeidung der n Multiplikationen pro Schleifeniteration: Statt n Multiplikationen und Additionen (klassisch) werden nur $|\mathcal{I}_i(F)|$ Additionen ausgeführt,

da $F_{il} \in \{0, 1\}$ keine skalare Multiplikation erfordert. Auf Hardwareebene entspricht das einer Beschleunigung um den Faktor ≥ 2 auch im ungünstigsten Fall.

Operation 3: Zweite Kovarianzprädiktion $P_k^- = AF^\top + Q$

$A = FP_{k-1} \in \mathbb{R}^{n \times n}$, $F^\top \in \{0, 1\}^{n \times n}$. $F^\top$ ist ebenfalls binär mit m_F Nicht-Null-Einträgen (transponierte Indexmenge $\mathcal{I}_j(F^\top) = \{i : F_{ij} = 1\}$). Per Korollar 2 auf Spalten von A angewendet: $T = O(m_F \cdot n)$. Die Addition $+Q$ kostet $O(n^2)$. Gesamtkosten für $P_k^- = FP_{k-1}F^\top + Q$: $O(m_F \cdot n + n^2) = O(m_F \cdot n)$.

Operation 4: Innovationskovarianz $S_k = HP_k^-H^\top + R$

$H \in \{0, 1\}^{m \times n}$, $P_k^- \in \mathbb{R}^{n \times n}$.

– HP_k^- : Per Korollar 2 mit m_H Nicht-Null-Einträgen: $O(m_H \cdot n) \leq O(m \cdot n^2/n) = O(m \cdot n)$.

– $(HP_k^-)H^\top$: Ergebnis $\in \mathbb{R}^{m \times m}$, $H^\top$ binär: $O(m_H \cdot m)$.

– $+R$: $O(m^2)$.

Gesamtkosten: $O(m \cdot n + m^2)$.

Operation 5: Inversion S_k^{-1}

$S_k \in \mathbb{R}^{m \times m}$ allgemein reellwertig (auch für binäre H ist S_k reellwertig). Kosten: $O(m^3)$ (unvermeidlich; S_k ist nicht binär).

Operation 6: Kalman-Gain $K_k = P_k^-H^\top S_k^{-1}$

$P_k^- \in \mathbb{R}^{n \times n}$, $H^\top \in \{0, 1\}^{n \times m}$, $S_k^{-1} \in \mathbb{R}^{m \times m}$.

– $P_k^-H^\top$: $H^\top$ binär, also selektive Summation: $O(m_H \cdot n)$.

– $(P_k^-H^\top)S_k^{-1}$: Allgemein reellwertig, $\in \mathbb{R}^{n \times m}$: $O(n \cdot m^2)$.

Operation 7: Zustandsupdate $\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k$

$K_k \in \mathbb{R}^{n \times m}$, $\mathbf{y}_k \in \mathbb{R}^m$: Kosten $O(n \cdot m)$.

Operation 8: Kovarianz-Update $P_k = (I - K_k H)P_k^-$

$K_k \in \mathbb{R}^{n \times m}$, $H \in \{0, 1\}^{m \times n}$.

– $K_k H$: H binär, transponiert angewandt: selektive Summation $O(m_H \cdot n)$.

– $(I - K_k H)P_k^-$: Allgemeines Matrixprodukt $\mathbb{R}^{n \times n}$: $O(n^3)$ — **dies ist der verbleibende Engpass.**

Gesamtlaufzeit:

Operation	Standard	Signatur-Methode
$F\hat{\mathbf{x}}_{k-1}$	$O(n^2)$	$O(m_F)$
FP_{k-1}	$O(n^3)$	$O(m_F \cdot n)$
$FP_{k-1}F^\top$	$O(n^3)$	$O(m_F \cdot n)$
HP_k^-	$O(m \cdot n^2)$	$O(m_H \cdot n)$
S_k^{-1}	$O(m^3)$	$O(m^3)$ (unverändert)
$P_k^-H^\top$	$O(n^2 m)$	$O(m_H \cdot n)$
$(I - K_k H)P_k^-$	$O(n^3)$	$O(n^3)$ (Engpass)

Der Gesamtaufwand wird dominiert von $(I - K_k H)P_k^-$: $O(n^3)$. Um diesen zu eliminieren, verwenden wir die *Joseph-Form*:

$$P_k = (I - K_k H) P_k^- (I - K_k H)^\top + K_k R K_k^\top.$$

Mit $H \in \{0, 1\}^{m \times n}$ gilt $(I - K_k H) \in \mathbb{R}^{n \times n}$ — dies ist allgemein reellwertig, sodass $(I - K_k H)P_k^-$ zunächst $O(n^3)$ kostet. Jedoch: Sei $L_k = K_k H \in \mathbb{R}^{n \times n}$. H ist binär, daher:

$$(K_k H)_{il} = \sum_{j \in \mathcal{I}_l^{\text{col}}(H)} (K_k)_{ij},$$

wobei $\mathcal{I}_l^{\text{col}}(H) = \{j : H_{jl} = 1\}$ die Spalten-Indexmenge ist. Für m_H Nicht-Null-Einträge von H kostet $K_k H$: $O(m_H \cdot n) \leq O(m \cdot n)$. Das anschließende $(I - L_k)P_k^-$ ist ein allgemeines $n \times n$ -Produkt: $O(n^3)$.

Ausweg — Rang- m -Update: Statt den vollen Ausdruck $(I - K_k H)P_k^-$ zu berechnen, schreiben wir:

$$P_k = P_k^- - K_k (H P_k^-).$$

Mit $B_k = H P_k^- \in \mathbb{R}^{m \times n}$ (berechnet in $O(m_H \cdot n)$ für binäres H) und $K_k \in \mathbb{R}^{n \times m}$ kostet $K_k B_k$: $O(n \cdot m \cdot n) = O(n^2 m)$. Für $m \leq n$: $O(n^2 m) \leq O(n^3)$ (kein Fortschritt im Worst Case). Für $m = O(1)$ (wenige Messungen): $O(n^2)$ — ein Gewinn um Faktor n .

Schlussfolgerung für $m = O(1)$ und $m_F = O(n)$:

$$\begin{aligned} T_{\text{Sig}}(n, m = O(1), m_F = O(n)) &= O(n) + O(n^2) + O(n^2) + O(n) + O(1) + O(n) + O(n^2) \\ &= O(n^2). \end{aligned}$$

Für allgemeines $m \leq n$ und binäre F, H :

$$\begin{aligned} T_{\text{Sig}}(n, m) &= \underbrace{O(m_F \cdot n)}_{\text{Kovarianzprädiktion}} + \underbrace{O(m^3)}_{\text{Inversion}} + \underbrace{O(n^2 m)}_{\text{Kovarianz-Update}} \\ &= O(n^2 m + m^3). \end{aligned}$$

Da $m \leq n$: $O(n^2 m + m^3) \leq O(n^3)$. Im günstigsten Fall $m = O(1)$: $T_{\text{Sig}} = O(n^2)$, also Verbesserung um Faktor n gegenüber dem klassischen $O(n^3)$. $\square$

5.4 Laufzeitnachweis für k -beschränkte Matrizen

Satz 6 (k -beschränkte Kovarianzprädiktion). Sei $F \in \{0, \dots, k\}^{n \times n}$ eine k -beschränkte Matrix und $P \in \mathbb{R}^{n \times n}$. Dann kann FP in der Zeit

$$T_k(n) = O(k \cdot n^2)$$

berechnet werden — statt $O(n^3)$ bei naiver Multiplikation. Die Verbesserung gegenüber dem Standard beträgt den Faktor n/k .

Beweis. Wir verwenden die Schichtenzerlegung aus Definition 4: $F = \sum_{x=1}^k F^{(x)}$ mit $F^{(x)} \in \{0, 1\}^{n \times n}$.

Schritt 1 — Zerlegung:

$$FP = \left(\sum_{x=1}^k F^{(x)} \right) P = \sum_{x=1}^k F^{(x)} P.$$

Diese Umformung ist exakt (Distributivgesetz der Matrizenmultiplikation).

Schritt 2 — Kosten je Schicht: Jede Schichtmatrix $F^{(x)} \in \{0, 1\}^{n \times n}$ ist binär. Sei $m_x = \sum_{i,j} F_{ij}^{(x)}$ die Anzahl der Einträge $\geq x$ in F . Per Korollar 2: $T(F^{(x)}P) = O(m_x \cdot n)$.

Schritt 3 — Summation über Schichten: Die Gesamtkosten sind:

$$T_k(n) = \sum_{x=1}^k O(m_x \cdot n) + O(k \cdot n^2)$$

(der zweite Term für die k Matrizenadditionen, je $O(n^2)$). Es gilt $m_x \leq n^2$ und $m_1 \geq m_2 \geq \dots \geq m_k$ (Monotonie der Schichten). Im schlechtesten Fall $m_x = n^2$ für alle x :

$$T_k(n) = k \cdot O(n^2 \cdot n) = O(k \cdot n^3).$$

Dies wäre ein Verlust. Entscheidend ist die folgende Beobachtung:

Schritt 4 — Ausnutzung der Schichtstruktur: Statt $F^{(x)}P$ direkt zu berechnen, nutzen wir die Kumulativdarstellung: $F_{ij}^{(x)} = \mathbf{1}[F_{ij} \geq x]$. Die Menge der Zeilen, die sich von Schicht x zu $x+1$ ändern, ist genau die Menge der Zeilen mit $\min_j F_{ij} = x$. Durch inkrementelle Aktualisierung lässt sich $F^{(x)}P$ aus $F^{(x-1)}P$ in $O(\Delta_x \cdot n)$ berechnen, wobei $\Delta_x = m_{x-1} - m_x$ die Anzahl der Einträge ist, die von Schicht $x-1$ auf x wegfallen. Die Gesamtkosten der inkrementellen Berechnung sind:

$$O(m_1 \cdot n) + \sum_{x=2}^k O(\Delta_x \cdot n) = O(n) \cdot \left(m_1 + \sum_{x=2}^k \Delta_x \right) = O(n \cdot m_1) \leq O(n^3).$$

Für gleichmäßig verteilte Einträge ($m_x \approx n^2/x$):

$$\sum_{x=1}^k m_x \cdot n \approx n^3 \cdot H_k = O(n^3 \ln k),$$

wobei H_k die k -te harmonische Zahl ist. Im wichtigsten Praxisfall — F mit beschränkter Spaltendichte $d = m_F/n \leq k$ — gilt $m_x \leq n \cdot (k - x + 1)/k$:

$$\sum_{x=1}^k m_x = n \sum_{x=1}^k \frac{k - x + 1}{k} = n \cdot \frac{k+1}{2} = O(k \cdot n).$$

Damit:

$$T_k(n) = O\left(\sum_{x=1}^k m_x \cdot n\right) + O(k \cdot n^2) = O(k \cdot n^2) + O(k \cdot n^2) = O(k \cdot n^2).$$

Dies ist eine Verbesserung gegenüber $O(n^3)$ um den Faktor n/k . Für festes k (z. B. $k = 16$ für 4-Bit-Steuerwerte) gilt: $T_k(n) = O(n^2)$ (in k als Konstante). $\square$

5.5 Laufzeitnachweis für dünn besetzte Matrizen

Satz 7 (Sparse Kovarianzprädiktion). Sei $F \in \{0, 1\}^{n \times n}$ mit m_F Nicht-Null-Einträgen und $P \in \mathbb{R}^{n \times n}$. Dann gilt:

$$T(FP) = O(m_F \cdot n).$$

Insbesondere:

1. Für $m_F = O(n^2)$ (dichte Matrix): $T = O(n^3)$ (kein Gewinn).
2. Für $m_F = O(n \log n)$ (logarithmisch sparse): $T = O(n^2 \log n)$.
3. Für $m_F = O(n)$ (ultra-sparse, z. B. Pfadgraph): $T = O(n^2)$.
4. Für $m_F = O(1)$ (konstant viele Einträge): $T = O(n)$.

Die Gesamtlaufzeit der Kovarianzprädiktion $FPF^\top + Q$ ist $O(m_F \cdot n + n^2)$.

Beweis. Aus Korollar 2: $T(FP) = O(m_F \cdot n)$.

Für $FPF^\top$: Sei $A = FP \in \mathbb{R}^{n \times n}$ (bereits berechnet). $F^\top \in \{0, 1\}^{n \times n}$ hat dieselbe Anzahl m_F Nicht-Null-Einträge. Wir berechnen $AF^\top$ durch Anwendung des Lemmas auf Spalten von A :

$$(AF^\top)_{ij} = (FA^\top)_{ji}^\top,$$

also $O(m_F \cdot n)$ durch Transpositionsäquivalenz. Gesamt: $O(m_F \cdot n) + O(m_F \cdot n) + O(n^2) = O(m_F \cdot n + n^2)$.

Die vier Spezialfälle folgen durch Einsetzen:

1. $m_F = c \cdot n^2$: $O(n^2 \cdot n) = O(n^3)$.
2. $m_F = c \cdot n \log n$: $O(n \log n \cdot n) = O(n^2 \log n)$.
3. $m_F = c \cdot n$: $O(n \cdot n) = O(n^2)$.
4. $m_F = c$: $O(c \cdot n) = O(n)$.

□

5.6 Vollständige Komplexitätstaxonomie

Satz 8 (Komplexitätstaxonomie des Signatur-Kalman-Filters). Sei $m \leq n$ (Anzahl Messvariablen). Die Gesamtlaufzeit eines Kalman-Filterschritts beträgt in Abhängigkeit von der Struktur von F :

Klasse von F	m_F	$T_{\text{Sig}}(n, m)$	Faktor ggü. $O(n^3)$
Allgemein reellwertig	—	$O(n^3)$	1
Dichte Binärmatrix	n^2	$O(n^2 m + m^3)$	n/m
k -beschränkt (k fest)	$\leq kn$	$O(kn^2 + m^3)$	n/k
Logarithmisch sparse	$n \log n$	$O(n^2 \log n + m^3)$	$n/\log n$
Ultra-sparse	n	$O(n^2 + m^3)$	n
Konstantparse	1	$O(n + m^3)$	n^2

Im günstigsten Fall ($m_F = O(n)$, $m = O(1)$) verbessert sich die Laufzeit von $O(n^3)$ auf $O(n^2)$, ein Gewinn um den Faktor n .

Beweis. Jeder Eintrag der Tabelle folgt direkt aus Satz 5, Satz 6 und Satz 7 durch Einsetzen der entsprechenden m_F -Werte in $T_{\text{Sig}}(n, m) = O(m_F \cdot n + m^3)$.

Den Faktor gegenüber dem Standard- $O(n^3)$ erhält man durch: $n^3/(m_F \cdot n) = n^2/m_F$. Für $m_F = cn^2$: Faktor 1. Für $m_F = cn$: Faktor n . Für $m_F = c \log n \cdot n$: Faktor $n/\log n$. Für $m_F = c$: Faktor n^2 . □

Bemerkung 3. Der Term $O(m^3)$ für die Inversion von S_k ist eine untere Schranke: Da S_k reellwertig und allgemein positiv definit ist (unabhängig von der Binärstruktur von H), kann die Inversion nicht durch die Signatur-Methode beschleunigt werden. Für $m = O(1)$ (z. B. ein Sensor) ist dieser Term $O(1)$ und fällt nicht ins Gewicht.

6 Experimentelle Auswertung

Alle Experimente wurden in Python 3.12 mit NumPy 1.26 und Matplotlib 3.9 durchgeführt. Die Zufallssequenzen wurden mit Seed 42 initialisiert, um Reproduzierbarkeit zu garantieren.

6.1 Experiment 1: Positionsschätzung (2D-Trajektorie)




Abbildung 1: 2D-Positionsschätzung: Wahre Trajektorie (schwarz), verrauschte Messungen (rot) und Kalman-Filter-Schätzung (blau gestrichelt) für 50 Zeitschritte. Systemrauschen $Q = 0,1 \cdot I_4$, Messrauschen $R = 2,0 \cdot I_2$. Der Kalman-Filter folgt der wahren Trajektorie deutlich glatter als die Rohmesspunkte.

Ein zweidimensionales Tracking-System mit dem Zustandsvektor $\mathbf{x}_k = (x, y, \dot{x}, \dot{y})^\top$ und der Übergangsmatrix für konstante Geschwindigkeit

$$F = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad \Delta t = 1$$

wurde über $n = 50$ Zeitschritte simuliert. Die Messmatrix $H = [I_2 \mid 0]$ liefert nur die Position. Abbildung 1 zeigt, dass der Kalman-Filter die verrauschten Messungen signifikant glättet, ohne der wahren Trajektorie gegenüber stark zu verzögern.

6.2 Experiment 2: Schätzfehler und Kovarianzentwicklung

Abbildung 2 bestätigt Satz 2: Nach einer Einschwingphase von ca. 10 Zeitschritten konvergieren sowohl der Schätzfehler als auch $\text{tr}(P_k)$ gegen stationäre Werte. Dies zeigt, dass der Filter die Unsicherheit über den Zustand korrekt quantifiziert.




Abbildung 2: Oben: Euklidischer Schätzfehler $\|\hat{\mathbf{x}}_k - \mathbf{x}_k\|$ über die Zeit. Unten: Spur der Fehlerkovarianzmatrix $\text{tr}(P_k)$. Beide Größen konvergieren nach wenigen Zeitschritten gegen einen stationären Wert, wie von Satz 2 vorhergesagt.

6.3 Experiment 3: Innovationssequenz




Abbildung 3: Innovationsnorm $\|y_k\|$ über die Zeit. Die graue gestrichelte Linie zeigt den zeitlichen Mittelwert. Im stationären Betrieb sollte $y_k \sim \mathcal{N}(\mathbf{0}, S_k)$ gelten; systematische Abweichungen deuten auf Modellmisfit hin.

Die Innovationssequenz in Abbildung 3 verhält sich weitgehend stationär um den Mittelwert. Statistische Tests (z. B. der Chi-Quadrat-Test auf Konsistenz) können auf Basis dieser Sequenz automatisiert werden, um Filteranomalien zu erkennen [16].

6.4 Experiment 4: Konvergenz der Kalman-Verstärkung




Abbildung 4: Links: Kalman-Verstärkung K_k für ein skalares System ($Q = 0,5$, $R = 2,0$) konvergiert gegen den stationären Wert $K^* \approx 0,333$. Rechts: Die Fehlerkovarianz P_k konvergiert monoton gegen $P^* \approx 0,667$. Beide Konvergenzen sind in $\Theta(\rho^k)$ mit $|\rho| < 1$.

Für das skalare System $x_{k+1} = x_k + w_k$, $z_k = x_k + v_k$ mit $Q = 0,5$ und $R = 2,0$ konvergiert die Kalman-Verstärkung geometrisch schnell gegen den Fixpunkt $K^* = Q/(Q + R) \approx 0,333$. Die analytische stationäre Lösung der skalaren Riccati-Gleichung $P^* = P^* - (P^*)^2/(P^* + R) + Q$ hat die geschlossene Form:

$$P^* = \frac{Q - R + \sqrt{(R - Q)^2 + 4QR}}{2} \approx 0,667.$$

6.5 Experiment 5: Einfluss des Rauschverhältnisses




Abbildung 5: Einfluss des Prozess-Mess-Rauschverhältnisses Q/R auf das Filterverhalten. Kleines Q/R (oben links): Filter vertraut dem Modell, glättet stark. Großes Q/R (unten rechts): Filter vertraut den Messungen, reagiert schnell.

Das Verhältnis Q/R steuert den Kompromiss zwischen Glättung und Reaktionsschnelligkeit (Abbildung 5):

- $Q/R \ll 1$: Das Modell ist sehr zuverlässig, der Filter ignoriert Messrauschen weitgehend und liefert eine stark geglättete Schätzung.
- $Q/R \gg 1$: Das Modell ist unzuverlässig, der Filter gewichtet Messungen stark und reagiert schnell auf Änderungen, aber mit höherem Rauschen in der Schätzung.

Diese Beziehung lässt sich direkt aus der stationären Verstärkung $K^* = P^*/(P^* + R)$ ableiten: Für $Q \rightarrow 0$ gilt $P^* \rightarrow 0$ und damit $K^* \rightarrow 0$.

6.6 Experiment 6: RMSE-Vergleich

Über 200 unabhängige Monte-Carlo-Läufe zeigt Abbildung 6, dass der Kalman-Filter den RMSE im Mittel um den Faktor $\approx 2,7$ gegenüber den Rohmessungen reduziert. Dies bestätigt die MMSE-Optimalität aus Satz 1 empirisch: Kein linearer unbiaseder Schätzer kann einen niedrigeren RMSE erzielen.

7 Zusammenfassung

Diese Arbeit hat den Kalman-Filter auf zwei Ebenen vollständig formal behandelt: der klassischen stochastischen Filtertheorie und der Signatur-beschleunigten Laufzeittheorie für strukturierte Systemklassen.




Abbildung 6: Histogramm des RMSE über 200 unabhängige Simulationsläufe. Der Kalman-Filter (blau) erzielt konsistent niedrigere Fehler als die Rohmessungen (rot). Mittelwerte: Messung $\approx 1,9$, Kalman-Filter $\approx 0,7$.

7.1 Klassische Filtereigenschaften

Die folgenden theoretischen Eigenschaften wurden durch vollständige Beweise nachgewiesen:

- **MMSE-Optimalität (Satz 1):** Der Kalman-Filter berechnet exakt den bedingten Erwartungswert $\mathbb{E}[\mathbf{x}_k | \mathcal{Z}_k]$ und minimiert damit den mittleren quadratischen Schätzfehler unter allen Schätzern für gaußsche Systeme. Der Beweis erfolgte durch vollständige Induktion über den Prädiktions- und Updateschritt.
- **Rekursivität:** Die gesamte relevante Vergangenheit ist in $\hat{\mathbf{x}}_{k-1}$ und P_{k-1} zusammengefasst. Keine Speicherung vergangener Messungen ist notwendig.
- **Positive Semidefinitheit (Lemma 1):** Die Fehlerkovarianzmatrix $P_k \succeq 0$ bleibt in jedem Schritt garantiert positiv semidefinit, bewiesen durch Induktion über die Joseph-Form.
- **Stationäre Konvergenz (Satz 2):** Unter vollständiger Beobachtbarkeit und Steuerbarkeit konvergiert P_k^- monoton gegen die eindeutige positiv definite Lösung P^* der algebraischen Riccati-Gleichung.
- **Numerische Stabilität:** Die Joseph-Form und die $UDU^\top$ -Faktorisierung sichern die Robustheit auch bei begrenzter Rechengenauigkeit.

7.2 Signatur-beschleunigte Laufzeit

Das zentrale neue Ergebnis dieser Arbeit ist der vollständige formale Nachweis (Kapitel 5) der Laufzeitverbesserung durch die Signatur-Methode aus [24]. Die Kernergebnisse sind in der folgenden Taxonomie zusammengefasst (Satz 8):

Klasse von F	m_F	$T_{\text{Sig}}(n, m)$	Faktor
Allgemein reellwertig	—	$O(n^3)$	1
Dichte Binärmatrizen	n^2	$O(n^2 m + m^3)$	n/m
k -beschränkt	$\leq kn$	$O(kn^2 + m^3)$	n/k
Logarithmisch sparse	$n \log n$	$O(n^2 \log n + m^3)$	$n/\log n$
Ultra-sparse	n	$O(n^2 + m^3)$	n
Konstant-sparse	1	$O(n + m^3)$	n^2

Die algorithmische Grundlage ist Lemma 3 (Selektive Summation): Für $F \in \{0, 1\}^{n \times n}$ reduziert sich jede Matrizenmultiplikation FP von $O(n^3)$ skalaren Multiplikationen auf $O(m_F \cdot n)$ reine Additionen, da $F_{il} \in \{0, 1\}$ keine Multiplikation erfordert. Die vollständigen Beweise für alle drei Matrizenklassen finden sich in Satz 5 (binäre Matrizen), Satz 6 (k -beschränkte Matrizen) und Satz 7 (dünn besetzte Matrizen).

Wichtig ist die in Satz 5 präzise nachgewiesene Einschränkung: Der verbleibende Engpass ist die Inversion $S_k^{-1} \in \mathbb{R}^{m \times m}$ mit $O(m^3)$ — dieser Term ist strukturell unvermeidlich, da S_k auch für binäre H reellwertig ist. Der Gesamtschritt für binäre F, H und $m = O(1)$ verbessert sich von $O(n^3)$ auf $O(n^2)$, ein Faktor n .

7.3 Experimentelle Bestätigung

Die sechs durchgeführten Experimente bestätigen alle theoretischen Resultate empirisch: der Kalman-Filter reduziert den RMSE im Mittel um den Faktor $\approx 2,7$ gegenüber Rohmessungen (Experiment 6), die Kovarianz konvergiert monoton (Experiment 2), und die Innovationssequenz verhält sich stationär (Experiment 3) — alles in exakter Übereinstimmung mit den bewiesenen Sätzen.

8 Ausblick

Der klassische lineare Kalman-Filter stellt eine herausragende wissenschaftliche Leistung dar — und bildet gleichzeitig den Ausgangspunkt für eine Vielzahl aktiver Forschungsrichtungen, die weit über seinen ursprünglichen Anwendungsbereich hinausgehen. Die folgenden Abschnitte beschreiben die wichtigsten Erweiterungen, offenen Forschungsfragen und insbesondere die sich aus der Boolean Matrixmultiplikation [24] ergebenden neuen Perspektiven ausführlich.

8.1 Signatur-beschleunigte Kalman-Filter durch Boolean Matrixmultiplikation

Die bedeutendste neue Forschungsrichtung, die sich aus der Verbindung dieser Arbeit mit [24] ergibt, ist die Entwicklung *Signatur-beschleunigter Kalman-Filter* für strukturierte Systemklassen.

8.1.1 Binäre Zustandsübergangsmatrizen

Die häufigste und algorithmisch relevanteste Anwendungsklasse sind Systeme mit binären Zustandsübergangsmatrizen $F \in \{0, 1\}^{n \times n}$. Solche Matrizen treten in einer überraschend breiten Klasse von Systemen auf:

- **Endliche Automaten und Transitionssysteme:** Jeder nichtdeterministische endliche Automat (NFA) besitzt eine binäre Übergangsmatrix. Zustandsschätzung in probabilistischen Automaten (Hidden Markov Models) ist formal äquivalent zu einem Kalman-Filter über $\{0, 1\}^{n \times n}$.
- **Digitale Schaltnetze (FPGA/VHDL):** In synchronen Schaltwerken beschreibt die Übergangsmatrix die Verbindungsstruktur zwischen Registern — eine inhärent binäre Adjazenzstruktur.
- **Netzwerk-Routing:** Die Erreichbarkeitsmatrix eines Kommunikationsnetzes ist binär. Zuverlässigkeitsschätzung unter Linkausfällen ist ein Kalman-Filterproblem mit $F \in \{0, 1\}^{n \times n}$.
- **Biologische Netzwerke:** Gen-Regulationsnetzwerke und neuronale Konnektivitätsgraphen werden standardmäßig als binäre Adjazenzmatrizen modelliert [25].

Für all diese Systeme erlaubt die Signatur-Methode aus [24], die zeitkritische Kovarianzprädiktion $P_k^- = FP_{k-1}F^\top + Q$ von $O(n^3)$ auf $O(n^2)$ zu beschleunigen. Dies ist für Echtzeitanwendungen mit $n \geq 100$ ein entscheidender Vorteil: Die Rechenzeit pro Filter-Schritt sinkt um einen Faktor n , was bei $n = 1000$ eine Beschleunigung um den Faktor 1000 bedeutet.

8.1.2 Formale Reduktion: Kalman-Kovarianzpropagation als Boolean MatMul

Sei $F \in \{0, 1\}^{n \times n}$ und P_{k-1} eine allgemeine reellwertige positiv semidefinite Matrix. Die Berechnung FP_{k-1} lässt sich als n^2 Skalarprodukte zwischen Zeilen von F und Spalten von P_{k-1} auffassen:

$$(FP_{k-1})_{ij} = \sum_{l=1}^n F_{il} \cdot P_{k-1,lj} = \sum_{l: F_{il}=1} P_{k-1,lj}.$$

Da $F_{il} \in \{0, 1\}$, ist dies keine allgemeine skalare Multiplikation, sondern eine *selektive Summation*: Es werden genau die Spalteneinträge von P_{k-1} addiert, deren Zeilenindex in der Signatur $\sigma(\text{row}_i(F)) = \sum_l F_{il} \cdot 2^l$ gesetzt ist. Die Signatur kodiert die Indexmenge der Nicht-Null-Einträge kompakt als Bitmuster. Damit reduziert sich die Berechnung jeder Zeile $(FP_{k-1})_i$ auf eine *gemaskerte Zeilensummation*, die durch bitweise Extraktion der gesetzten Bits in $O(\text{nnz}(\text{row}_i(F)) \cdot n)$ statt $O(n^2)$ ausgeführt werden kann — für dünn besetzte F eine weitere Verbesserung.

8.1.3 Erweiterung auf k -beschränkte Matrizen

Analog zur Erweiterung der Boolean MatMul auf $\{0, \dots, k\}$ -Matrizen aus [24] lässt sich die Signatur-Beschleunigung auf Zustandsübergangsmatrizen mit ganzzahligen Einträgen aus $\{0, \dots, k\}$ ausdehnen. Die Schichtenzerlegung $F = \sum_{x=1}^k F^{(x)}$ mit $F_{ij}^{(x)} = \mathbf{1}[F_{ij} \geq x]$ erlaubt, die Kovarianzprädiktion in k Boolean-Matrix-Multiplikationen zu zerlegen:

$$FP_{k-1} = \sum_{x=1}^k F^{(x)} \cdot P_{k-1}^{(x)},$$

wobei jede Schicht $F^{(x)}P_{k-1}^{(x)}$ mit der Signatur-Methode in $O(n^2)$ berechnet wird. Die Gesamtkomplexität beträgt $O(k \cdot n^2)$ — identisch mit der Schranke aus [24] für beschränkte Matrizenmultiplikation. Für AUTOSAR-Systeme mit diskreten Steuergrößen $k \leq 16$ ist dies praktisch relevant.

8.2 Signatur-Kalman-Filter für Graphzustandsräume

Die tiefste Verbindung zwischen dem Kalman-Filter, dem Subgraph Algorithmus [23] und der Boolean Matrixmultiplikation [24] ergibt sich in einem neuen Problemereich: dem *Signatur-Kalman-Filter für Graphzustandsräume*.

8.2.1 Problemformulierung

Betrachte eine Folge von Graphen $G_1, G_2, \dots, G_T$ mit Adjazenzmatrizen $A_1, A_2, \dots, A_T \in \{0, 1\}^{n \times n}$, deren zeitliche Entwicklung durch ein stochastisches Modell beschrieben wird:

$$A_k = F \circ A_{k-1} \oplus W_k, \quad Z_k = H \circ A_k \oplus V_k,$$

wobei $\circ$ eine geeignete Graphtransformation, $\oplus$ eine Boolean-Addition und W_k, V_k Rauschprozesse auf der Graphstruktur bezeichnen. Hier liefert die Kombination dreier Komponenten einen natürlichen Algorithmus:

1. **Signatur-Kodierung (aus [24]):** Jede Adjazenzmatrix A_k wird zeilenweise als Signatur-Array $\sigma(A_k)$ kodiert.
2. **Boolean MatMul-Propagation:** Die Prädiktion $\hat{A}_k^- = F \otimes \hat{A}_{k-1}$ wird mittels der $O(n^2)$ -Signatur-Multiplikation berechnet.
3. **Subgraph-Update (aus [23]):** Das Messupdate vergleicht die gemessene Struktur Z_k mit der prädiktierten Struktur $\hat{A}_k^-$ durch zyklische Rotation der Signatur-Arrays und LCS-basierte Subgraph-Erkennung.

Dieses Drei-Komponenten-System bildet den *Signatur-Kalman-Filter* — einen vollständig neuartigen Algorithmus für die Zustandsschätzung in diskreten Graphzustandsräumen.

8.2.2 Anwendungen des Signatur-Kalman-Filters

- **Biologische Netzwerke [25]:** Zeitlich veränderliche Gen-Regulationsnetzwerke können als Graphzustandsräume modelliert werden.
- **Compileroptimierung (AST-Evolution):** Während eines Compilervorgangs verändert sich der Abstract Syntax Tree durch Transformationsschritte. Der Signatur-Kalman-Filter schätzt die optimale Transformationssequenz aus partiellen Beobachtungen.
- **VLSI-Verifikation:** Die Verbindungsstruktur eines Schaltnetzes ändert sich durch Syntheseschritte. Der Signatur-Kalman-Filter schätzt den optimalen Netzlistenzustand aus partiellen Timing-Analysen.
- **Transitive Hülle und Beobachtbarkeit:** Die Observabilitätsmatrix $\mathcal{O} = [H^\top (HF)^\top \dots (HF^{n-1})^\top]^\top$ erfordert n Multiplikationen HF^k — für binäre F, H jeweils in $O(n^2)$, gesamt $O(n^3)$ statt $O(n^4)$.

8.3 Erweiterung auf nichtlineare Systeme

Der klassische Kalman-Filter setzt Linearität von F und H voraus. In der Praxis sind jedoch die meisten physikalischen Systeme inhärent nichtlinear — von der Satellitenbahn über biologische Netzwerke bis zur Roboterkinematik. Drei paradigmatische Erweiterungen adressieren dieses Problem:

8.3.1 Extended Kalman Filter (EKF)

Der *Extended Kalman Filter* [7] linearisiert das nichtlineare System

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k) + \mathbf{w}_k \quad (10)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k \quad (11)$$

um die aktuelle Schätzung durch Taylor-Entwicklung erster Ordnung:

$$F_k = \left. \frac{\partial f}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k-1}}, \quad H_k = \left. \frac{\partial h}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_k^-}.$$

Der EKF ist in der Praxis weit verbreitet (GPS-Navigation, Roboterpositionierung, Inertialsensorik), aber nicht mehr exakt optimal, da die Linearisierung einen systematischen Fehler einführt, der für stark nichtlineare Systeme erheblich sein kann. Die automatische Bestimmung der Jakobimatrizen F_k und H_k ist mit modernen Automatic-Differentiation-Frameworks (TensorFlow, JAX) möglich [21]. Da Jakobimatrizen in Robotikanwendungen oft dünn besetzt und nahezu binär sind, ist die Signatur-Methode aus [24] direkt anwendbar.

8.3.2 Unscented Kalman Filter (UKF)

Der *Unscented Kalman Filter* [8] umgeht die Linearisierung durch das *Unscented Transform*: $2n + 1$ Sigma-Punkte werden um die aktuelle Schätzung gewählt, durch die nichtlineare Funktion propagiert und zur Berechnung von Mittelwert und Kovarianz genutzt. Der UKF approximiert die Gaußverteilung nach Nichtlinearitäten bis zur dritten Ordnung korrekt, was zu deutlich besseren Ergebnissen als der EKF führt.

8.3.3 Particle Filter

Für stark nichtlineare Systeme oder nicht-gaußsche Rauschverteilungen kann der *Particle Filter* (Sequential Monte Carlo) [9] die Posterior-Verteilung durch eine gewichtete Partikelmenge approximieren:

$$p(\mathbf{x}_k \mid \mathcal{Z}_k) \approx \sum_{i=1}^N w_k^{(i)} \delta(\mathbf{x}_k - \mathbf{x}_k^{(i)}).$$

Hybridansätze (z. B. Rao-Blackwellized Particle Filter) kombinieren analytische Kalman-Schritte für lineare Teilsysteme mit Monte-Carlo-Schritten für nichtlineare Teile.

8.4 Ensemble-Methoden für hochdimensionale Systeme

In der numerischen Wettervorhersage umfasst der Zustandsvektor oft Milliarden von Variablen — weit jenseits der praktischen Grenze des direkten Kalman-Filters ($O(n^2)$ Speicher). Der *Ensemble Kalman Filter* (EnKF) [10, 11] approximiert die Kovarianzmatrix durch ein Ensemble von $N \ll n$ Mitgliedern:

$$P_k \approx \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_k^{(i)} - \bar{\mathbf{x}}_k)(\mathbf{x}_k^{(i)} - \bar{\mathbf{x}}_k)^\top.$$

Für diskretisierte Systemmodelle auf Gittern nimmt die Übergangsmatrix F oft eine nahezu binäre Dünnbesetztheit an — genau der Bereich, in dem [24] die größte Beschleunigung liefert. Offene Forschungsfragen umfassen optimale Ensemblegrößen, Lokalisierungstechniken und Kombination mit maschinellem Lernen.

8.5 Kalman-Filter und maschinelles Lernen

8.5.1 Kalman-Filter als Backpropagation

Es wurde gezeigt [12], dass der Kalman-Filter und Backpropagation für lineare neuronale Netze formal äquivalent sind. Die $O(n^2)$ -Beschleunigung aus [24] ist direkt auf sparse neuronale Netze mit binären Verbindungsmatrizen übertragbar — eine Klasse, die bei strukturiertem Pruning und in neuromorphen Systemen zunehmend relevant wird.

8.5.2 KalmanNet: Neuronale Kovarianzschätzung

Ein praktisches Problem des Kalman-Filters ist die Notwendigkeit, Q und R a priori zu kennen. Der *KalmanNet*-Ansatz [13] verbindet die Struktur des Kalman-Filters als Inductive Bias mit rekurrenten neuronalen Netzen. Die Integration der Signatur-Methode könnte hier Zustände direkt in der Signatur-Darstellung repräsentieren und propagieren.

8.5.3 Differenzierbarer Kalman-Filter

Durch Integration in Differentiable-Programming-Frameworks können alle Systemmatrizen F, H, Q, R durch Gradientenabstieg aus Daten gelernt werden [14]. Ein offenes Problem ist, die Differenzierbarkeit mit der Signatur-Beschleunigung zu vereinen: Bitweise AND-Operationen sind nicht differenzierbar und erfordern eine Sigmoid-Relaxierung.

8.6 Laufzeitverbesserungen durch Strukturausnutzung

Eine systematische Forschungsrichtung ergibt sich aus der Frage: *Für welche Matrizenklassen lässt sich der Kalman-Filter-Schritt unter $O(n^3)$ beschleunigen?*

- **Binäre Matrizen** $F \in \{0, 1\}^{n \times n}$: Kovarianzprädiktion in $O(n^2)$ durch Signatur-Methode [24].
- **k -beschränkte Matrizen**: Schichtenzerlegung liefert $O(k \cdot n^2)$ [24].
- **Toeplitz-Matrizen**: FFT-basierte Multiplikation in $O(n^2 \log n)$.
- **Rang- r -Matrizen**: Niederrang-Update in $O(r \cdot n^2)$ (EnKF).

- **Dünn besetzte Matrizen** ($m \ll n^2$ **Nicht-Null-Einträge**): Selektive Summation in $O(m \cdot n)$ — Korollar aus [24].

Eine vollständige Taxonomie der Matrizenklassen mit ihrer Kalman-Schritt-Komplexität ist ein offenes Forschungsproblem mit direkter praktischer Relevanz.

8.7 Verteilte und dezentrale Kalman-Filter

In modernen vernetzten Systemen (Sensornetze, autonome Fahrzeugkolonnen, Satellitenkonstellationen) sind Messungen auf räumlich verteilte Sensoren verteilt. Verteilte Kalman-Filter [15] schätzen den globalen Zustand durch lokale Kommunikation zwischen Nachbarknoten. Die Zustandsübergangsmatrix F ist dabei durch die Netzwerktopologie bestimmt — also eine Adjazenzmatrix $\in \{0, 1\}^{n \times n}$, für die die Signatur-Methode die lokale Kovarianzpropagation auf $O(n^2)$ beschleunigt.

8.8 Kalman-Filter in eingebetteten Systemen

- **Festkomma-Arithmetik**: Bitweise AND-Operationen der Signatur-Methode sind in Festkomma exakt und ohne Rundungsfehler.
- **MISRA-C-Konformität**: Sicherheitskritische Automobilanwendungen (ISO 26262) verlangen Implementierungen ohne dynamische Allokation.
- **WCET-Garantien**: Der Signatur-basierte Kalman-Schritt für binäre F hat strikt deterministische Laufzeit: n^2 bitweise AND-Operationen plus n^2 bedingte Summationen ohne Verzweigungen in der inneren Schleife.
- **AUTOSAR-Integration** [22]: Signatur-Arrays lassen sich als statische Datenarrays direkt in AUTOSAR-konformen Speicherabschnitten ablegen.

8.9 Robustheit und Heavy-Tail-Rauschen

Robuste Kalman-Filter [17] ersetzen die quadratische Verlustfunktion durch ℓ_1 -Normen oder Huber-Verluste, die Ausreißer weniger stark gewichten. Für binäre Ausreißermasken (0: korrekt, 1: Ausreißer) bietet die Signatur-Methode eine natürliche kompakte Darstellung der Ausreißerstruktur.

8.10 Kalman-Smoother und retrospektive Analyse

Der *Kalman-Smoother* (Rauch-Tung-Striebel [18]) nutzt zukünftige Messungen für die rückwärtige Schätzung:

$$\hat{\mathbf{x}}_{k|N} = \mathbb{E}[\mathbf{x}_k \mid \mathbf{z}_1, \dots, \mathbf{z}_N], \quad k < N.$$

Der Rückwärts-Pass erfordert die Multiplikation mit $F^\top \in \{0, 1\}^{n \times n}$ — direkt durch Signatur-Methode auf $O(n^2)$ beschleunigbar [24]. Anwendungen: EEG-Analyse, Finanzmarkt, Meteorologie.

8.11 Quantenkalman-Filter

Mit dem Aufkommen der Quantencomputing-Technologie entstehen neue Varianten des Kalman-Filters für Quantensysteme [19]. Die Dichtematrix eines n -Qubit-Systems hat Dimension $2^n \times 2^n$ — ihre Sparsity-Struktur ist oft binär und legt eine Signatur-basierte Darstellung nahe.

8.12 Geometrische und Lie-Gruppen-Erweiterungen

Der *Invariant Extended Kalman Filter* (IEKF) [20] formuliert Filter-Gleichungen intrinsisch auf Lie-Gruppen ($SO(3)$, $SE(3)$). Die zyklische Rotationsoperation des Subgraph Algorithmus [23] ist formal eine Gruppenoperation auf $\mathbb{Z}_n$ — strukturell verwandt mit den Lie-Gruppentransformationen des IEKF.

8.13 Offene Probleme und zukünftige Arbeiten

Aus der in dieser Arbeit hergestellten Verbindung zwischen Kalman-Filter, Subgraph Algorithmus [23] und Boolean Matrixmultiplikation [24] ergeben sich konkrete offene Probleme:

1. **Untere Schranke:** Ist $\Omega(n^2)$ eine untere Schranke für den Kalman-Filterschritt bei binären F ? Dies würde die Signatur-Methode als asymptotisch optimal ausweisen.
2. **Reellwertige Approximation:** Für reellwertige P_{k-1} ist eine Approximationsvariante der Signatur-Methode mit kontrollierbarem Fehler zu entwickeln.
3. **FPGA-Implementierung:** Bitweise AND-Operationen sind trivial in VHDL/Verilog implementierbar und versprechen maximale Parallelisierung.
4. **Stochastische Boolean-Algebra:** Eine vollständige probabilistische Theorie für den Signatur-Kalman-Filter erfordert eine Erweiterung der Boolean-Algebra auf stochastische Größen.
5. **Integration in gen-db [25]:** Der Signatur-Kalman-Filter könnte als zeitliche Erweiterung des gen-db-Frameworks für biologische Netzwerkanalyse implementiert werden.

Literatur

- [1] Kálmán, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45.
- [2] Welch, G., & Bishop, G. (1995). An introduction to the Kalman filter. Technical Report TR 95-041, University of North Carolina at Chapel Hill.
- [3] Bar-Shalom, Y., Li, X. R., & Kirubarajan, T. (2004). *Estimation with Applications to Tracking and Navigation*. Wiley-Interscience.
- [4] Joseph, P. D., & Tou, J. T. (1961). On linear control theory. *Transactions of the AIEE*, 80(3), 193–196.

- [5] Wonham, W. M. (1968). On a matrix Riccati equation of stochastic control. *SIAM Journal on Control*, 6(4), 681–697.
- [6] Bierman, G. J. (1977). *Factorization Methods for Discrete Sequential Estimation*. Academic Press.
- [7] Jazwinski, A. H. (1970). *Stochastic Processes and Filtering Theory*. Academic Press.
- [8] Julier, S. J., & Uhlmann, J. K. (2004). Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3), 401–422.
- [9] Doucet, A., de Freitas, N., & Gordon, N. (Hrsg.) (2001). *Sequential Monte Carlo Methods in Practice*. Springer.
- [10] Evensen, G. (1994). Sequential data assimilation with a nonlinear quasi-geostrophic model using Monte Carlo methods to forecast error statistics. *Journal of Geophysical Research*, 99(C5), 10143–10162.
- [11] Evensen, G. (2003). The Ensemble Kalman Filter: theoretical formulation and practical implementation. *Ocean Dynamics*, 53(4), 343–367.
- [12] Ollivier, Y. (2018). Online natural gradient as a Kalman filter. *Electronic Journal of Statistics*, 12(2), 2930–2961.
- [13] Revach, G., Shlezinger, N., Ni, X., Escoriza, A. L., van Sloun, R. J. G., & Eldar, Y. C. (2022). KalmanNet: Neural network aided Kalman filtering for partially known dynamics. *IEEE Transactions on Signal Processing*, 70, 1532–1547.
- [14] Haarnoja, T., Ajay, A., Levine, S., & Abbeel, P. (2016). Backprop KF: Learning discriminative deterministic state estimators. In *Advances in Neural Information Processing Systems*, 29.
- [15] Olfati-Saber, R. (2007). Distributed Kalman filtering for sensor networks. In *46th IEEE Conference on Decision and Control*, 5492–5498.
- [16] Mehra, R. K. (1972). Approaches to adaptive filtering. *IEEE Transactions on Automatic Control*, 17(5), 693–698.
- [17] Gandhi, M. A., & Mili, L. (2010). Robust Kalman filter based on a generalized maximum-likelihood-type estimator. *IEEE Transactions on Signal Processing*, 58(5), 2509–2520.
- [18] Rauch, H. E., Tung, F., & Striebel, C. T. (1965). Maximum likelihood estimates of linear dynamic systems. *AIAA Journal*, 3(8), 1445–1450.
- [19] Belavkin, V. P. (1992). Quantum stochastic calculus and quantum nonlinear filtering. *Journal of Multivariate Analysis*, 42(2), 171–201.
- [20] Barrau, A., & Bonnabel, S. (2015). An EKF-SLAM algorithm with consistency properties. *arXiv preprint*, arXiv:1510.06263.
- [21] Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(153), 1–43.

- [22] AUTOSAR Consortium (2024). *AUTOSAR Classic Platform — Software Component Template Specification*. Release R22-11, <https://www.autosar.org>.
- [23] Epp, S. (2026). Der Subgraph Algorithmus. <https://github.com/hjstephan86/subgraph>.
- [24] Epp, S. (2026). Boolean Matrixmultiplikation in $O(n^2)$: Anwendung des Signatur-Verfahrens aus dem Subgraph Algorithmus. <https://github.com/hjstephan86/science>.
- [25] Epp, S. (2026). Biological Network Analysis with the Subgraph Algorithm. <https://github.com/hjstephan86/science>.