

Der Kalman-Filter:

Theorie, formale Analyse und experimentelle Auswertung

Stephan Epp

28. Juni 2026

Inhaltsverzeichnis

1	Einführung	2
1.1	Problemstellung	2
1.2	Motivation und Einordnung	2
2	Grundlagen	2
2.1	Definitionen	2
2.2	Grundidee: Prädiktion und Update	3
2.2.1	Prädiktionsschritt (Predict)	3
2.2.2	Updateschritt (Correct)	3
3	Formale Analyse und Beweise	4
3.1	Optimalität des Kalman-Filters	4
3.2	Positivität der Kovarianzmatrix	5
3.3	Stationärer Kalman-Filter und Riccati-Gleichung	5
3.4	Numerische Stabilität	6
4	Algorithmus	6
4.1	Vollständiger Algorithmus	6
4.2	Laufzeitkomplexität	6
4.3	Implementierung in Python	7
5	Experimentelle Auswertung	7
5.1	Experiment 1: Positionsschätzung (2D-Trajektorie)	8
5.2	Experiment 2: Schätzfehler und Kovarianzentwicklung	8
5.3	Experiment 3: Innovationssequenz	8
5.4	Experiment 4: Konvergenz der Kalman-Verstärkung	10
5.5	Experiment 5: Einfluss des Rauschverhältnisses	10
5.6	Experiment 6: RMSE-Vergleich	10
6	Zusammenfassung	12
7	Ausblick	12
7.1	Erweiterung auf nichtlineare Systeme	12
7.1.1	Extended Kalman Filter (EKF)	12
7.1.2	Unscented Kalman Filter (UKF)	13

7.1.3	Particle Filter	13
7.2	Ensemble-Methoden für hochdimensionale Systeme	13
7.3	Kalman-Filter und maschinelles Lernen	13
7.3.1	Kalman-Filter als Backpropagation	13
7.3.2	Neuronale Netzwerke zur Kovarianzschätzung	14
7.3.3	Differenzierbarer Kalman-Filter	14
7.4	Verteilte und dezentrale Kalman-Filter	14
7.5	Kalman-Filter in eingebetteten Systemen	14
7.6	Robustheit und Heavy-Tail-Rauschen	15
7.7	Kalman-Smoother und retrospektive Analyse	15
7.8	Quantenkalman-Filter	15
7.9	Geometrische und Lie-Gruppen-Erweiterungen	15
7.10	Integration in den Subgraph Algorithmus	15

1 Einführung

Der Kalman-Filter ist einer der bedeutendsten Algorithmen der angewandten Mathematik und Regelungstechnik. Er wurde 1960 von Rudolf Emil Kálmán vorgestellt [1] und bildet bis heute die Grundlage für Positionsschätzung, Sensorfusion, Signalverarbeitung und Robotik.

Die zentrale Leistung des Kalman-Filters besteht darin, aus einem verrauschten Messsignal und einem Systemmodell rekursiv eine *optimale Schätzung* des verborgenen Systemzustands zu berechnen — und zwar unter Minimierung des mittleren quadratischen Schätzfehlers.

1.1 Problemstellung

Gegeben ist ein dynamisches lineares System, dessen Zustand $\mathbf{x}_k \in \mathbb{R}^n$ zum Zeitschritt k nicht direkt beobachtet werden kann. Stattdessen liegt eine verrauschte Messung $\mathbf{z}_k \in \mathbb{R}^m$ vor.

Ziel: Berechne rekursiv eine Schätzung $\hat{\mathbf{x}}_k$ des wahren Zustands $\mathbf{x}_k$, welche den mittleren quadratischen Fehler

$$\mathcal{J} = \mathbb{E}[\|\mathbf{x}_k - \hat{\mathbf{x}}_k\|^2]$$

minimiert, unter Nutzung aller bisherigen Messungen $\mathbf{z}_1, \dots, \mathbf{z}_k$.

1.2 Motivation und Einordnung

Der Kalman-Filter vereint drei klassische Disziplinen:

- **Bayesianische Schätztheorie:** Vorherwissen (Modell) und Beobachtung werden probabilistisch kombiniert.
- **Lineare Algebra:** Die gesamte Rekursion besteht aus Matrixmultiplikationen, Inversionen und Additionen.
- **Stochastische Prozesse:** Prozess- und Messrauschen werden als gaußsche Zufallsvektoren modelliert.

Das Ergebnis ist ein Algorithmus, der in Echtzeit ohne Speicherung vergangener Messungen auskommt und dennoch statistisch optimal ist — eine Eigenschaft, die ihn in eingebetteten Systemen und Echtzeitanwendungen besonders wertvoll macht [2, 3].

2 Grundlagen

2.1 Definitionen

Definition 1 (Gaußsche Zufallsvariable). Eine Zufallsvariable $X \in \mathbb{R}^n$ heißt *gaußsch* (normalverteilt) mit Erwartungswert $\boldsymbol{\mu}$ und Kovarianzmatrix $\Sigma \succ 0$, geschrieben $X \sim \mathcal{N}(\boldsymbol{\mu}, \Sigma)$, wenn ihre Dichte

$$p(\mathbf{x}) = \frac{1}{(2\pi)^{n/2} |\Sigma|^{1/2}} \exp\left(-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu})^\top \Sigma^{-1}(\mathbf{x} - \boldsymbol{\mu})\right)$$

ist.

Definition 2 (Lineares Zeitinvariantes Zustandsraummodell). Ein lineares Zeitinvariantes (LTI) Zustandsraummodell in diskreter Zeit ist gegeben durch:

$$\mathbf{x}_k = F \mathbf{x}_{k-1} + B \mathbf{u}_k + \mathbf{w}_k \quad (1)$$

$$\mathbf{z}_k = H \mathbf{x}_k + \mathbf{v}_k \quad (2)$$

mit Zustandsvektor $\mathbf{x}_k \in \mathbb{R}^n$, Messvektor $\mathbf{z}_k \in \mathbb{R}^m$, Steuereingang $\mathbf{u}_k \in \mathbb{R}^l$, Zustandsübergangsmatrix $F \in \mathbb{R}^{n \times n}$, Steuermatrix $B \in \mathbb{R}^{n \times l}$, Messmatrix $H \in \mathbb{R}^{m \times n}$, Prozessrauschen $\mathbf{w}_k \sim \mathcal{N}(\mathbf{0}, Q)$ und Messrauschen $\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, R)$.

Definition 3 (Fehlerkovarianzmatrix). Die *a-posteriori-Fehlerkovarianzmatrix* zum Zeitschritt k ist definiert als

$$P_k = \mathbb{E}[(\mathbf{x}_k - \hat{\mathbf{x}}_k)(\mathbf{x}_k - \hat{\mathbf{x}}_k)^\top].$$

Sie quantifiziert die Unsicherheit der aktuellen Schätzung.

Definition 4 (Kalman-Verstärkung). Die *Kalman-Verstärkung* (Kalman Gain) $K_k \in \mathbb{R}^{n \times m}$ ist die Gewichtungsmatrix, die bestimmt, wie stark die Schätzung in Richtung der aktuellen Messung korrigiert wird:

$$K_k = P_k^- H^\top S_k^{-1}, \quad S_k = H P_k^- H^\top + R.$$

Definition 5 (Innovation). Die *Innovation* (Messresiduum) zum Zeitschritt k ist

$$\mathbf{y}_k = \mathbf{z}_k - H \hat{\mathbf{x}}_k^-,$$

d. h. die Differenz zwischen gemessener und vorhergesagter Beobachtung.

2.2 Grundidee: Prädiktion und Update

Der Kalman-Filter arbeitet in einem zweistufigen Zyklus, der bei jedem Zeitschritt k wiederholt wird:

2.2.1 Prädiktionsschritt (Predict)

Aus dem Systemmodell (1) wird der Zustand für den nächsten Zeitschritt vorhergesagt:

$$\hat{\mathbf{x}}_k^- = F \hat{\mathbf{x}}_{k-1} + B \mathbf{u}_k \quad (3)$$

$$P_k^- = F P_{k-1} F^\top + Q \quad (4)$$

2.2.2 Updateschritt (Correct)

Die eingehende Messung $\mathbf{z}_k$ wird genutzt, um die Vorhersage zu korrigieren:

$$\mathbf{y}_k = \mathbf{z}_k - H \hat{\mathbf{x}}_k^- \quad (5)$$

$$S_k = H P_k^- H^\top + R \quad (6)$$

$$K_k = P_k^- H^\top S_k^{-1} \quad (7)$$

$$\hat{\mathbf{x}}_k = \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k \quad (8)$$

$$P_k = (I - K_k H) P_k^- \quad (9)$$

Bemerkung 1. Die symmetrisierte Form der Kovarianzupdate-Formel lautet:

$$P_k = (I - K_k H) P_k^- (I - K_k H)^\top + K_k R K_k^\top.$$

Diese Joseph-Form ist numerisch stabiler und garantiert die Symmetrie und positive Semidefinitheit von P_k auch bei Rundungsfehlern [4].

3 Formale Analyse und Beweise

3.1 Optimalität des Kalman-Filters

Satz 1 (MMSE-Optimalität des Kalman-Filters). Unter den Annahmen von Definition 2 und unter der Voraussetzung, dass $\mathbf{w}_k$ und $\mathbf{v}_k$ unkorreliert und gaußsch sind, ist der Kalman-Filter der *minimale mittlere quadratische Schätzer* (MMSE) des Zustands $\mathbf{x}_k$ gegeben die Messhistorie $\mathcal{Z}_k = \{\mathbf{z}_1, \dots, \mathbf{z}_k\}$. Das heißt:

$$\hat{\mathbf{x}}_k = \mathbb{E}[\mathbf{x}_k \mid \mathcal{Z}_k] \quad \text{und} \quad P_k = \text{Var}[\mathbf{x}_k \mid \mathcal{Z}_k].$$

Beweis. Wir führen den Beweis durch Induktion über k .

Induktionsanfang ($k = 0$): Zum Zeitpunkt $k = 0$ liegt noch keine Messung vor. Mit der Initialisierung $\hat{\mathbf{x}}_0 = \mathbb{E}[\mathbf{x}_0]$ und $P_0 = \text{Var}[\mathbf{x}_0]$ gilt die Behauptung trivialerweise.

Induktionsschritt ($k - 1 \rightarrow k$): Angenommen, die Behauptung gelte für $k - 1$, d. h. $\hat{\mathbf{x}}_{k-1} = \mathbb{E}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}]$ und $P_{k-1} = \text{Var}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}]$.

Schritt 1 — Prädiktionsschritt ist korrekt: Da $\mathbf{w}_k$ unabhängig von $\mathcal{Z}_{k-1}$ ist und Erwartungswert $\mathbf{0}$ hat, gilt für den prädizierten Zustand:

$$\begin{aligned} \mathbb{E}[\mathbf{x}_k \mid \mathcal{Z}_{k-1}] &= \mathbb{E}[F\mathbf{x}_{k-1} + B\mathbf{u}_k + \mathbf{w}_k \mid \mathcal{Z}_{k-1}] \\ &= F \mathbb{E}[\mathbf{x}_{k-1} \mid \mathcal{Z}_{k-1}] + B\mathbf{u}_k \\ &= F\hat{\mathbf{x}}_{k-1} + B\mathbf{u}_k = \hat{\mathbf{x}}_k^-. \end{aligned}$$

Analog erhält man für die prädizierte Kovarianz:

$$\text{Var}[\mathbf{x}_k \mid \mathcal{Z}_{k-1}] = F P_{k-1} F^\top + Q = P_k^-.$$

Schritt 2 — Gemeinsame Gaußverteilung: Da $\mathbf{x}_k \mid \mathcal{Z}_{k-1} \sim \mathcal{N}(\hat{\mathbf{x}}_k^-, P_k^-)$ und $\mathbf{v}_k \sim \mathcal{N}(\mathbf{0}, R)$ unabhängig sind, ist der gemeinsame Vektor $(\mathbf{x}_k, \mathbf{z}_k)^\top$ bedingt auf $\mathcal{Z}_{k-1}$ gaußsch:

$$\begin{pmatrix} \mathbf{x}_k \\ \mathbf{z}_k \end{pmatrix} \Big| \mathcal{Z}_{k-1} \sim \mathcal{N} \left(\begin{pmatrix} \hat{\mathbf{x}}_k^- \\ H\hat{\mathbf{x}}_k^- \end{pmatrix}, \begin{pmatrix} P_k^- & P_k^- H^\top \\ H P_k^- & S_k \end{pmatrix} \right).$$

Schritt 3 — Bedingte Gaußverteilung: Für einen gemeinsamen Gaußvektor gilt die Formel für die bedingte Erwartung:

$$\mathbb{E}[\mathbf{x}_k \mid \mathbf{z}_k, \mathcal{Z}_{k-1}] = \hat{\mathbf{x}}_k^- + P_k^- H^\top S_k^{-1} (\mathbf{z}_k - H\hat{\mathbf{x}}_k^-) = \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k = \hat{\mathbf{x}}_k.$$

Dies entspricht genau Formel (8).

Schritt 4 — Update-Kovarianz: Die Kovarianz des Schätzfehlers nach dem Update ergibt sich aus der bedingten Varianz:

$$\text{Var}[\mathbf{x}_k \mid \mathbf{z}_k, \mathcal{Z}_{k-1}] = P_k^- - P_k^- H^\top S_k^{-1} H P_k^- = (I - K_k H) P_k^- = P_k.$$

Dies entspricht Formel (9).

Da in jedem Induktionsschritt gezeigt wurde, dass der Kalman-Filter den bedingten Erwartungswert und die bedingte Varianz korrekt berechnet, ist er der MMSE-Schätzer. $\square$

3.2 Positivität der Kovarianzmatrix

Lemma 1 (Positive Semidefinitheit von P_k). Sei $P_0 \succeq 0$, $Q \succeq 0$ und $R \succ 0$. Dann gilt $P_k \succeq 0$ für alle $k \geq 0$.

Beweis. Wir zeigen die Behauptung durch Induktion über k .

Anfang: $P_0 \succeq 0$ nach Voraussetzung.

Schritt $k - 1 \rightarrow k$: Sei $P_{k-1} \succeq 0$. Dann gilt $P_k^- = FP_{k-1}F^\top + Q \succeq 0$, da Kongruenztransformationen und Summen positiv semidefiniter Matrizen wiederum positiv semidefinit sind.

Für die Update-Formel in Joseph-Form:

$$P_k = (I - K_k H) P_k^- (I - K_k H)^\top + K_k R K_k^\top.$$

Der erste Summand ist $\succeq 0$ (Kongruenztransformation von $P_k^- \succeq 0$), der zweite ist $\succeq 0$ wegen $R \succ 0$. Daher ist $P_k \succeq 0$. $\square$

3.3 Stationärer Kalman-Filter und Riccati-Gleichung

Satz 2 (Stationärer Kalman-Filter). Sei das System (F, H, Q, R) vollständig beobachtbar und steuerbar. Dann konvergiert die Fehlerkovarianzmatrix P_k^- gegen eine eindeutige stationäre Lösung $P^* = \lim_{k \rightarrow \infty} P_k^-$, die die algebraische Riccati-Gleichung (ARE) löst:

$$P^* = F (P^* - P^* H^\top (H P^* H^\top + R)^{-1} H P^*) F^\top + Q.$$

Beweis. Schritt 1 — Monotone Folge: Wir zeigen zunächst, dass die Abbildung $\Phi(P) = F(P - P H^\top (H P H^\top + R)^{-1} H P) F^\top + Q$ (Riccati-Iteration) monoton ist. Seien $P_1 \succeq P_2 \succeq 0$. Dann gilt $H P_1 H^\top + R \succeq H P_2 H^\top + R \succ 0$, woraus folgt $(H P_1 H^\top + R)^{-1} \preceq (H P_2 H^\top + R)^{-1}$. Die Schur-Komplement-Eigenschaft liefert dann $\Phi(P_1) \succeq \Phi(P_2)$.

Schritt 2 — Beschränktheit: Unter vollständiger Beobachtbarkeit existiert eine obere Schranke $\bar{P}$ mit $P_k^- \preceq \bar{P}$ für alle k . Dies folgt aus der Tatsache, dass die Informationsmatrix $(P_k^-)^{-1}$ durch reine Aktualisierungen mit Messungen nach unten beschränkt bleibt.

Schritt 3 — Konvergenz: Eine monoton steigende und nach oben beschränkte Folge von positiv semidefiniten Matrizen konvergiert gegen einen eindeutigen Grenzwert P^* (Satz von Klein). Dieser Grenzwert ist per Konstruktion Fixpunkt der Riccati-Iteration und erfüllt daher die ARE.

Schritt 4 — Eindeutigkeit: Unter vollständiger Steuerbarkeit und Beobachtbarkeit ist die einzige positiv semidefinite Lösung der ARE die P^* mit stabilem abgeglichenem System (Satz von Wonham [5]). $\square$

Korollar 1 (Stationäre Kalman-Verstärkung). Unter den Voraussetzungen von Satz 2 konvergiert die Kalman-Verstärkung gegen den stationären Wert:

$$K^* = P^* H^\top (H P^* H^\top + R)^{-1}.$$

Im stationären Fall reduziert sich der Kalman-Filter zu einem zeitinvarianten linearen Filter mit konstantem Gain K^* .

3.4 Numerische Stabilität

Lemma 2 (Stabilität der UDU^T -Zerlegung). Die Faktorisierung $P_k = U_k D_k U_k^T$ (UDU-Zerlegung), wobei U_k eine obere Einheitsdreiecksmatrix und D_k eine Diagonalmatrix mit positiven Einträgen ist, kann für den Kovarianz-Update numerisch stabiler durchgeführt werden als die direkte Matrizenaktualisierung [6].

Skizze. Die direkte Update-Formel $P_k = (I - K_k H) P_k^-$ kann numerisch die Symmetrie oder positive Semidefinitheit von P_k verletzen, wenn Rundungsfehler akkumulieren. In der UDU-Faktorisierung werden Prädiktions- und Update-Schritt durch Householder-Transformation direkt auf die Faktoren U, D angewandt, was die Positivität von D in jedem Schritt explizit erhält. $\square$

4 Algorithmus

4.1 Vollständiger Algorithmus

Satz 3 (Kalman-Filter-Algorithmus). Unter den Voraussetzungen von Definition 2 liefert der folgende rekursive Algorithmus die MMSE-Schätzung $\hat{\mathbf{x}}_k$.

Initialisierung ($k = 0$):

$$\hat{\mathbf{x}}_0 = \mathbb{E}[\mathbf{x}_0], \quad P_0 = \text{Var}[\mathbf{x}_0].$$

Für $k = 1, 2, 3, \dots$:

Prädiktionsschritt:

$$\begin{aligned} \hat{\mathbf{x}}_k^- &= F \hat{\mathbf{x}}_{k-1} + B \mathbf{u}_k \\ P_k^- &= F P_{k-1} F^T + Q \end{aligned}$$

Updateschritt:

$$\begin{aligned} \mathbf{y}_k &= \mathbf{z}_k - H \hat{\mathbf{x}}_k^- \\ S_k &= H P_k^- H^T + R \\ K_k &= P_k^- H^T S_k^{-1} \\ \hat{\mathbf{x}}_k &= \hat{\mathbf{x}}_k^- + K_k \mathbf{y}_k \\ P_k &= (I - K_k H) P_k^- \end{aligned}$$

4.2 Laufzeitkomplexität

Satz 4 (Laufzeit). Ein einzelner Kalman-Filter-Schritt für ein System mit n Zustandsvariablen und m Messvariablen hat eine Zeitkomplexität von $O(n^3 + m^3)$.

Beweis. Die dominierenden Operationen je Zeitschritt sind:

- Matrixmultiplikationen $F P_{k-1} F^T$: $O(n^3)$
- Berechnung $H P_k^- H^T$: $O(m \cdot n^2)$
- Inversion von $S_k \in \mathbb{R}^{m \times m}$: $O(m^3)$

- Matrixmultiplikation $K_k \mathbf{y}_k$: $O(n \cdot m)$
- Update $P_k = (I - K_k H) P_k^-$: $O(n^2 \cdot m + n^3)$

Insgesamt ergibt sich $T(n, m) = O(n^3 + n^2 m + m^3)$. In der typischen Annahme $m \leq n$ vereinfacht sich dies zu $O(n^3)$. $\square$

Bemerkung 2. Für sehr große Systeme (z.B. Wetterprognose mit $n \gg 10^6$) ist der direkte Kalman-Filter nicht praktikabel. Hier kommen Ensemble-Methoden (Ensemble Kalman Filter, EnKF [10]) oder Approximationsverfahren zum Einsatz.

4.3 Implementierung in Python

Listing 1: Kalman-Filter in Python/NumPy

```

1 import numpy as np
2
3 class KalmanFilter:
4     def __init__(self, F, B, H, Q, R, x0, P0):
5         self.F = F          # Zustandsübergangsmatrix
6         self.B = B          # Steuermatrix
7         self.H = H          # Messmatrix
8         self.Q = Q          # Prozessrausch-Kovarianz
9         self.R = R          # Messrausch-Kovarianz
10        self.x = x0          # Initialer Zustand
11        self.P = P0          # Initiale Kovarianz
12
13    def predict(self, u=None):
14        Bu = self.B @ u if u is not None else 0
15        self.x = self.F @ self.x + Bu
16        self.P = self.F @ self.P @ self.F.T + self.Q
17        return self.x
18
19    def update(self, z):
20        y = z - self.H @ self.x          # Innovation
21        S = self.H @ self.P @ self.H.T + self.R
22        K = self.P @ self.H.T @ np.linalg.inv(S)
23        self.x = self.x + K @ y
24        self.P = (np.eye(len(self.x)) - K @ self.H) @ self.P
25        return self.x, self.P

```

5 Experimentelle Auswertung

Alle Experimente wurden in Python 3.12 mit NumPy 1.26 und Matplotlib 3.9 durchgeführt. Die Zufallssequenzen wurden mit Seed 42 initialisiert, um Reproduzierbarkeit zu garantieren.




Abbildung 1: 2D-Positionsschätzung: Wahre Trajektorie (schwarz), verrauschte Messungen (rot) und Kalman-Filter-Schätzung (blau gestrichelt) für 50 Zeitschritte. Systemrauschen $Q = 0,1 \cdot I_4$, Messrauschen $R = 2,0 \cdot I_2$. Der Kalman-Filter folgt der wahren Trajektorie deutlich glatter als die Rohmesspunkte.

5.1 Experiment 1: Positionsschätzung (2D-Trajektorie)

Ein zweidimensionales Tracking-System mit dem Zustandsvektor $\mathbf{x}_k = (x, y, \dot{x}, \dot{y})^\top$ und der Übergangsmatrix für konstante Geschwindigkeit

$$F = \begin{pmatrix} 1 & 0 & \Delta t & 0 \\ 0 & 1 & 0 & \Delta t \\ 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 1 \end{pmatrix}, \quad \Delta t = 1$$

wurde über $n = 50$ Zeitschritte simuliert. Die Messmatrix $H = [I_2 \mid 0]$ liefert nur die Position. Abbildung 1 zeigt, dass der Kalman-Filter die verrauschten Messungen signifikant glättet, ohne der wahren Trajektorie gegenüber stark zu verzögern.

5.2 Experiment 2: Schätzfehler und Kovarianzentwicklung

Abbildung 2 bestätigt Satz 2: Nach einer Einschwingphase von ca. 10 Zeitschritten konvergieren sowohl der Schätzfehler als auch $\text{tr}(P_k)$ gegen stationäre Werte. Dies zeigt, dass der Filter die Unsicherheit über den Zustand korrekt quantifiziert.

5.3 Experiment 3: Innovationssequenz

Die Innovationssequenz in Abbildung 3 verhält sich weitgehend stationär um den Mittelwert. Statistische Tests (z. B. der Chi-Quadrat-Test auf Konsistenz) können auf Basis dieser Sequenz automatisiert werden, um Filteranomalien zu erkennen [16].




Abbildung 2: Oben: Euklidischer Schätzfehler $\|\hat{\mathbf{x}}_k - \mathbf{x}_k\|$ über die Zeit. Unten: Spur der Fehlerkovarianzmatrix $\text{tr}(P_k)$. Beide Größen konvergieren nach wenigen Zeitschritten gegen einen stationären Wert, wie von Satz 2 vorhergesagt.




Abbildung 3: Innovationsnorm $\|\mathbf{y}_k\|$ über die Zeit. Die graue gestrichelte Linie zeigt den zeitlichen Mittelwert. Im stationären Betrieb sollte $\mathbf{y}_k \sim \mathcal{N}(\mathbf{0}, S_k)$ gelten; systematische Abweichungen deuten auf Modellmisfit hin.

5.4 Experiment 4: Konvergenz der Kalman-Verstärkung




Abbildung 4: Links: Kalman-Verstärkung K_k für ein skalares System ($Q = 0,5$, $R = 2,0$) konvergiert gegen den stationären Wert $K^* \approx 0,333$. Rechts: Die Fehlerkovarianz P_k konvergiert monoton gegen $P^* \approx 0,667$. Beide Konvergenzen sind in $\Theta(\rho^k)$ mit $|\rho| < 1$.

Für das skalare System $x_{k+1} = x_k + w_k$, $z_k = x_k + v_k$ mit $Q = 0,5$ und $R = 2,0$ konvergiert die Kalman-Verstärkung geometrisch schnell gegen den Fixpunkt $K^* = Q/(Q + R) \approx 0,333$. Die analytische stationäre Lösung der skalaren Riccati-Gleichung $P^* = P^* - (P^*)^2/(P^* + R) + Q$ hat die geschlossene Form:

$$P^* = \frac{Q - R + \sqrt{(R - Q)^2 + 4QR}}{2} \approx 0,667.$$

5.5 Experiment 5: Einfluss des Rauschverhältnisses

Das Verhältnis Q/R steuert den Kompromiss zwischen Glättung und Reaktionsschnelligkeit (Abbildung 5):

- $Q/R \ll 1$: Das Modell ist sehr zuverlässig, der Filter ignoriert Messrauschen weitgehend und liefert eine stark geglättete Schätzung.
- $Q/R \gg 1$: Das Modell ist unzuverlässig, der Filter gewichtet Messungen stark und reagiert schnell auf Änderungen, aber mit höherem Rauschen in der Schätzung.

Diese Beziehung lässt sich direkt aus der stationären Verstärkung $K^* = P^*/(P^* + R)$ ableiten: Für $Q \rightarrow 0$ gilt $P^* \rightarrow 0$ und damit $K^* \rightarrow 0$.

5.6 Experiment 6: RMSE-Vergleich

Über 200 unabhängige Monte-Carlo-Läufe zeigt Abbildung 6, dass der Kalman-Filter den RMSE im Mittel um den Faktor $\approx 2,7$ gegenüber den Rohmessungen reduziert. Dies bestätigt die MMSE-Optimalität aus Satz 1 empirisch: Kein linearer unbiaseder Schätzer kann einen niedrigeren RMSE erzielen.




Abbildung 5: Einfluss des Prozess-Mess-Rauschverhältnisses Q/R auf das Filterverhalten. Kleines Q/R (oben links): Filter vertraut dem Modell, glättet stark. Großes Q/R (unten rechts): Filter vertraut den Messungen, reagiert schnell.




Abbildung 6: Histogramm des RMSE über 200 unabhängige Simulationsläufe. Der Kalman-Filter (blau) erzielt konsistent niedrigere Fehler als die Rohmessungen (rot). Mittelwerte: Messung $\approx 1,9$, Kalman-Filter $\approx 0,7$.

6 Zusammenfassung

Der Kalman-Filter liefert unter gaußschen Annahmen die statistisch optimale rekursive Zustandsschätzung für lineare Systeme. Seine Stärken liegen in:

- **Optimalität:** Er minimiert den mittleren quadratischen Schätzfehler (Satz 1).
- **Rekursivität:** Keine Speicherung vergangener Messungen notwendig.
- **Effizienz:** Polynomiale Laufzeit $O(n^3)$ je Zeitschritt.
- **Konvergenz:** Die Kovarianz konvergiert gegen die Lösung der Riccati-Gleichung (Satz 2).

Die experimentellen Ergebnisse bestätigen alle theoretischen Aussagen quantitativ.

7 Ausblick

Der klassische lineare Kalman-Filter stellt eine herausragende wissenschaftliche Leistung dar — und bildet gleichzeitig den Ausgangspunkt für eine Vielzahl aktiver Forschungsrichtungen, die weit über seinen ursprünglichen Anwendungsbereich hinausgehen. Die folgenden Abschnitte beschreiben die wichtigsten Erweiterungen und offenen Forschungsfragen ausführlich.

7.1 Erweiterung auf nichtlineare Systeme

Der klassische Kalman-Filter setzt Linearität von F und H voraus. In der Praxis sind jedoch die meisten physikalischen Systeme inhärent nichtlinear — von der Satellitenbahn über biologische Netzwerke bis zur Roboterkinematik. Zwei paradigmatische Erweiterungen adressieren dieses Problem:

7.1.1 Extended Kalman Filter (EKF)

Der *Extended Kalman Filter* [7] linearisiert das nichtlineare System

$$\mathbf{x}_k = f(\mathbf{x}_{k-1}, \mathbf{u}_k) + \mathbf{w}_k \quad (10)$$

$$\mathbf{z}_k = h(\mathbf{x}_k) + \mathbf{v}_k \quad (11)$$

um die aktuelle Schätzung durch Taylor-Entwicklung erster Ordnung:

$$F_k = \left. \frac{\partial f}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_{k-1}}, \quad H_k = \left. \frac{\partial h}{\partial \mathbf{x}} \right|_{\hat{\mathbf{x}}_k^-}.$$

Der EKF ist in der Praxis weit verbreitet (GPS-Navigation, Roboterpositionierung, Inertialsensorik), aber nicht mehr exakt optimal, da die Linearisierung einen systematischen Fehler einführt, der für stark nichtlineare Systeme erheblich sein kann.

Ein wesentliches offenes Problem ist die automatische Bestimmung der Jakobimatrizen F_k und H_k für komplexe Systemmodelle, wo symbolisches Differenzieren mit modernen *Automatic Differentiation*-Frameworks (TensorFlow, JAX) einen vielversprechenden Ansatz darstellt [21].

7.1.2 Unscented Kalman Filter (UKF)

Der *Unscented Kalman Filter* [8] umgeht die Linearisierung durch das *Unscented Transform*: Statt die Funktion f zu linearisieren, werden $2n + 1$ Sigma-Punkte um die aktuelle Schätzung gewählt, durch die nichtlineare Funktion propagiert und zur Berechnung von Mittelwert und Kovarianz genutzt. Der UKF approximiert die Gaußverteilung nach Nichtlinearitäten bis zur dritten Ordnung korrekt, was zu deutlich besseren Ergebnissen als der EKF führt — insbesondere für hochgradig nichtlineare Systeme wie die Lagrange-Gleichungen in der Robotik.

7.1.3 Particle Filter

Für stark nichtlineare Systeme oder nicht-gaußsche Rauschverteilungen kann der *Particle Filter* (Sequential Monte Carlo) [9] die Posterior-Verteilung durch eine gewichtete Partikelmenge approximieren:

$$p(\mathbf{x}_k \mid \mathcal{Z}_k) \approx \sum_{i=1}^N w_k^{(i)} \delta(\mathbf{x}_k - \mathbf{x}_k^{(i)}).$$

Während Particle Filter beliebige Verteilungen approximieren können, skalieren sie schlecht mit der Systemdimension (*curse of dimensionality*), weshalb Hybridansätze (z. B. Rao-Blackwellized Particle Filter) aktiv erforscht werden.

7.2 Ensemble-Methoden für hochdimensionale Systeme

In der numerischen Wettervorhersage, der Ozeanographie und der Klimamodellierung umfasst der Zustandsvektor oft Millionen bis Milliarden von Variablen — weit jenseits der praktischen Grenze des direkten Kalman-Filters, dessen Speicherbedarf $O(n^2)$ beträgt. Der *Ensemble Kalman Filter* (EnKF) [10, 11] approximiert die Kovarianzmatrix durch ein Ensemble von $N \ll n$ Mitgliedern:

$$P_k \approx \frac{1}{N-1} \sum_{i=1}^N (\mathbf{x}_k^{(i)} - \bar{\mathbf{x}}_k)(\mathbf{x}_k^{(i)} - \bar{\mathbf{x}}_k)^\top.$$

Der EnKF hat die Wettervorhersage revolutioniert und wird heute operativ bei nahezu allen großen Wetterdiensten eingesetzt. Offene Forschungsfragen umfassen die optimale Ensemblegröße, Lokalisierungstechniken zur Unterdrückung von Fernkorrelationsartefakten und die Kombination mit maschinellem Lernen.

7.3 Kalman-Filter und maschinelles Lernen

Eine der aufregendsten Entwicklungen der letzten Jahre ist die enge Verbindung zwischen dem Kalman-Filter und der Theorie neuronaler Netze:

7.3.1 Kalman-Filter als Backpropagation

Es wurde gezeigt [12], dass der Kalman-Filter und der Backpropagation-Algorithmus für lineare neuronale Netze formal äquivalent sind, wenn das Training als ein Problem der Zustandsschätzung aufgefasst wird. Diese Verbindung eröffnet neue Wege zur theoretischen Analyse von Lernalgorithmen.

7.3.2 Neuronale Netzwerke zur Kovarianzschätzung

Ein praktisches Problem des Kalman-Filters ist die Notwendigkeit, Q und R a priori zu kennen. *Adaptive Kalman-Filter* [16] schätzen diese Parameter aus der Innovationssequenz. Neuere Arbeiten ersetzen diese statistische Anpassung durch tiefe neuronale Netze, die aus Trainingsdaten lernen, optimale Rauschmatrizen vorherzusagen [13]. Insbesondere der *KalmanNet*-Ansatz verbindet die Struktur des Kalman-Filters als *Inductive Bias* mit der Ausdrucksstärke rekurrenter neuronaler Netze.

7.3.3 Differenzierbarer Kalman-Filter

Durch die Integration des Kalman-Filters in *Differentiable Programming*-Frameworks kann der gesamte Filter — einschließlich der Systemmatrizen F , H , Q , R — durch Gradientenabstieg aus Daten gelernt werden [14]. Dies ermöglicht end-to-end trainierbare Systeme, bei denen physikalisches Vorwissen (Systemstruktur) und Daten optimal kombiniert werden.

7.4 Verteilte und dezentrale Kalman-Filter

In modernen vernetzten Systemen — Sensornetzen, autonomen Fahrzeugkolonnen, Satellitenkonstellationen — sind Messungen auf räumlich verteilte Sensoren verteilt. Der klassische zentralisierte Kalman-Filter erfordert, alle Daten an einen Rechenknoten zu senden, was Kommunikationsbandbreite und Latenz begrenzt. Verteilte Kalman-Filter [15] schätzen den globalen Zustand durch lokale Kommunikation zwischen Nachbarknoten, ohne einen zentralen Server zu benötigen. Für autonome Fahrzeuge ist dies besonders relevant, da V2V-Kommunikation (Vehicle-to-Vehicle) Echtzeit-Latenz im Millisekundenbereich erfordert.

7.5 Kalman-Filter in eingebetteten Systemen

Die Integration des Kalman-Filters in ressourcenbeschränkte Mikrocontroller (z. B. ARM Cortex-M0) stellt spezifische Herausforderungen:

- **Festkomma-Arithmetik:** Matrizenoperationen in Festkomma statt Fließkomma erfordern sorgfältige Skalierungsanalyse, um numerische Stabilität zu gewährleisten.
- **MISRA-C-Konformität:** Sicherheitskritische Automobilanwendungen (ISO 26262) verlangen MISRA-C-konforme Implementierungen ohne dynamische Allokation.
- **Laufzeitgarantien:** Der Algorithmus muss in einem festen Zeitbudget (Worst-Case Execution Time, WCET) abschließen — dies beeinflusst die Wahl zwischen Cholesky- und direkter Matrixinversion.
- **AUTOSAR-Integration:** Für AUTOSAR-Plattformen [22] muss der Kalman-Filter als Software-Komponente (SWC) modelliert werden, mit klar definierten Ports für Eingangs- und Ausgangssignale.

7.6 Robustheit und Heavy-Tail-Rauschen

Die Gaußannahme ist in vielen realen Systemen verletzt: Sensorfehler durch kosmische Strahlung, GPS-Mehrwegeausbreitung oder mechanische Schläge erzeugen impulsartiges (heavy-tail) Rauschen. Robuste Kalman-Filter [17] ersetzen die quadratische Verlustfunktion durch ℓ_1 -Normen oder Huber-Verluste, die Ausreißer weniger stark gewichten. Ein offenes theoretisches Problem ist die Minimax-Optimalitätstheorie für robuste Filter: Unter welchen Robustheitsgarantien ist ein gegebener Filter optimal über alle Verteilungen einer bestimmten Robustheitsklasse?

7.7 Kalman-Smoother und retrospektive Analyse

Der klassische Kalman-Filter schätzt $\mathbf{x}_k$ auf Basis von $\mathcal{Z}_k = \{\mathbf{z}_1, \dots, \mathbf{z}_k\}$ (kausale Schätzung). Der *Kalman-Smoother* (Rauch-Tung-Striebel-Smoother [18]) nutzt zusätzlich zukünftige Messungen für die rückwärtige Schätzung:

$$\hat{\mathbf{x}}_{k|N} = \mathbb{E}[\mathbf{x}_k \mid \mathbf{z}_1, \dots, \mathbf{z}_N], \quad k < N.$$

Anwendungen umfassen retrospektive Datenanalyse, Systemidentifikation und offline-Verarbeitung von Zeitreihendaten (EEG, Finanzmarktanalyse, Meteorologie).

7.8 Quantenkalman-Filter

Mit dem Aufkommen der Quantencomputing-Technologie entstehen neue Varianten des Kalman-Filters für Quantensysteme [19]. Ein Quantensystem (z. B. ein supraleitender Qubit) unterliegt durch Messung einer Zustandsreduktion (Kollaps), die klassische Wahrscheinlichkeitsrechnung ersetzt durch den Formalismus der Dichtematrizen. Der *Quantum Kalman Filter* schätzt rekursiv den Zustand des Quantensystems basierend auf schwachen (nicht-projektiven) Messungen. Diese Theorie ist eng verwandt mit der stochastischen Mastergleichung und hat direkte Anwendungen in der Quantenfehlerkorrektur und im Quanten-Feedback-Control.

7.9 Geometrische und Lie-Gruppen-Erweiterungen

Viele Zustandsräume physikalischer Systeme sind keine Vektorräume, sondern glatte Mannigfaltigkeiten (Lie-Gruppen): Orientierungen im 3D-Raum liegen auf $SO(3)$, Posen auf $SE(3)$. Standard-Kalman-Filter, die auf Additionen in $\mathbb{R}^n$ beruhen, können auf diese Räume nicht direkt angewandt werden. Der *Invariant Extended Kalman Filter* (IEKF) [20] formuliert Filter-Gleichungen intrinsisch auf der Lie-Gruppe, was zu besserer Konvergenz und Konsistenz für rotationssensitive Anwendungen (Drohnennavigation, SLAM) führt.

7.10 Integration in den Subgraph Algorithmus

Der Kalman-Filter und der Subgraph Algorithmus [23] verbinden sich auf konzeptioneller Ebene durch die gemeinsame Grundidee der strukturellen Signaturanalyse: Beide Algorithmen verarbeiten Matrizenstrukturen, um latente Informationen (Zustand vs. Subgraph-Beziehung) zu extrahieren. Eine formale Integration könnte den Subgraph Algorithmus für zeitvariante Graphsequenzen erweitern: Betrachte eine Folge von Graphen

$G_1, G_2, \dots, G_k$, deren strukturelle Veränderungen durch ein stochastisches Zustandsraummodell beschrieben werden. Der Kalman-Filter würde dann den latenten “wahren” Graphzustand schätzen, während der Subgraph Algorithmus die gemessenen Graphen auf Teilgraph-Beziehungen prüft. Solche zeitvarianten Graphfilter haben potenzielle Anwendungen in der biologischen Netzwerkanalyse [24] und der Compileroptimierung durch AST-Evolution.

Literatur

- [1] Kálmán, R. E. (1960). A new approach to linear filtering and prediction problems. *Journal of Basic Engineering*, 82(1), 35–45.
- [2] Welch, G., & Bishop, G. (1995). An introduction to the Kalman filter. Technical Report TR 95-041, University of North Carolina at Chapel Hill.
- [3] Bar-Shalom, Y., Li, X. R., & Kirubarajan, T. (2004). *Estimation with Applications to Tracking and Navigation*. Wiley-Interscience.
- [4] Joseph, P. D., & Tou, J. T. (1961). On linear control theory. *Transactions of the AIEE*, 80(3), 193–196.
- [5] Wonham, W. M. (1968). On a matrix Riccati equation of stochastic control. *SIAM Journal on Control*, 6(4), 681–697.
- [6] Bierman, G. J. (1977). *Factorization Methods for Discrete Sequential Estimation*. Academic Press.
- [7] Jazwinski, A. H. (1970). *Stochastic Processes and Filtering Theory*. Academic Press.
- [8] Julier, S. J., & Uhlmann, J. K. (2004). Unscented filtering and nonlinear estimation. *Proceedings of the IEEE*, 92(3), 401–422.
- [9] Doucet, A., de Freitas, N., & Gordon, N. (Hrsg.) (2001). *Sequential Monte Carlo Methods in Practice*. Springer.
- [10] Evensen, G. (1994). Sequential data assimilation with a nonlinear quasi-geostrophic model using Monte Carlo methods to forecast error statistics. *Journal of Geophysical Research*, 99(C5), 10143–10162.
- [11] Evensen, G. (2003). The Ensemble Kalman Filter: theoretical formulation and practical implementation. *Ocean Dynamics*, 53(4), 343–367.
- [12] Ollivier, Y. (2018). Online natural gradient as a Kalman filter. *Electronic Journal of Statistics*, 12(2), 2930–2961.
- [13] Revach, G., Shlezinger, N., Ni, X., Escoriza, A. L., van Sloun, R. J. G., & Eldar, Y. C. (2022). KalmanNet: Neural network aided Kalman filtering for partially known dynamics. *IEEE Transactions on Signal Processing*, 70, 1532–1547.
- [14] Haarnoja, T., Ajay, A., Levine, S., & Abbeel, P. (2016). Backprop KF: Learning discriminative deterministic state estimators. In *Advances in Neural Information Processing Systems*, 29.

- [15] Olfati-Saber, R. (2007). Distributed Kalman filtering for sensor networks. In *46th IEEE Conference on Decision and Control*, 5492–5498.
- [16] Mehra, R. K. (1972). Approaches to adaptive filtering. *IEEE Transactions on Automatic Control*, 17(5), 693–698.
- [17] Gandhi, M. A., & Mili, L. (2010). Robust Kalman filter based on a generalized maximum-likelihood-type estimator. *IEEE Transactions on Signal Processing*, 58(5), 2509–2520.
- [18] Rauch, H. E., Tung, F., & Striebel, C. T. (1965). Maximum likelihood estimates of linear dynamic systems. *AIAA Journal*, 3(8), 1445–1450.
- [19] Belavkin, V. P. (1992). Quantum stochastic calculus and quantum nonlinear filtering. *Journal of Multivariate Analysis*, 42(2), 171–201.
- [20] Barrau, A., & Bonnabel, S. (2015). An EKF-SLAM algorithm with consistency properties. *arXiv preprint*, arXiv:1510.06263.
- [21] Baydin, A. G., Pearlmutter, B. A., Radul, A. A., & Siskind, J. M. (2018). Automatic differentiation in machine learning: a survey. *Journal of Machine Learning Research*, 18(153), 1–43.
- [22] AUTOSAR Consortium (2024). *AUTOSAR Classic Platform — Software Component Template Specification*. Release R22-11, <https://www.autosar.org>.
- [23] Epp, S. (2026). Der Subgraph Algorithmus. <https://github.com/hjstephan86/subgraph>.
- [24] Epp, S. (2026). Biological Network Analysis with the Subgraph Algorithm. <https://github.com/hjstephan86/science>.