

Laplacian-Filter in der digitalen Bildverarbeitung

Theorie, formale Herleitung und Anwendung zur Bildschärfung

Stephan Epp

3. Juni 2026

Inhaltsverzeichnis

1	Einführung und Motivation in der Bildverarbeitung	3
1.1	Einordnung in die digitale Bildverarbeitung	3
2	Mathematische Grundlagen	4
2.1	Der kontinuierliche Laplace-Operator	4
2.2	Diskretisierung: Vom Kontinuierlichen zum Digitalen Bild	4
2.3	Der diskrete Laplacian	5
3	Die vier Laplacian-Masken – Formale Herleitung	5
3.1	Maske (a): Grundform, 90°-invariant	6
3.2	Maske (b): Verbesserte Rotationsinvarianz, 45°-invariant	7
3.3	Masken (c) und (d): Alternative Vorzeichenkonventionen	8
4	Visualisierung: 1D- und 2D-Laplacian	8
4.1	Verhalten im Eindimensionalen	8
4.2	Verhalten im Zweidimensionalen auf Testbildern	11
5	Anwendung: Spatial Sharpening (Bildschärfung)	11
5.1	Grundprinzip der Laplacian-basierten Bildschärfung	11
5.2	Nutzwert in realen Bildverarbeitungsanwendungen	12
6	Frequenzdomänen-Analyse	13
6.1	Hochpasscharakter des Laplacian	13
7	Eigenschaften: Formaler Überblick	13
8	Zusammenfassung	14
9	Ausblick	14
9.1	Laplacian of Gaussian (LoG) und Marr-Hildreth-Detektor	15
9.2	Difference of Gaussians (DoG) als LoG-Approximation	15
9.3	Anisotrope Diffusion und nichtlineare Verallgemeinerung	15
9.4	Laplacian Pyramid und Multi-Skalen-Analyse	15
9.5	Tiefe neuronale Netze und lernbare Laplacian-Filter	16

9.6	Anwendungen in der medizinischen Bildverarbeitung	16
9.7	Laplacian Eigenmaps und Dimensionsreduktion	16
9.8	Robuste Laplacian-Filter und Ausreißertoleranz	17
9.9	Parallelisierung und Hardware-Implementierung	17
9.10	Verbindung zur theoretischen Informatik: Subgraph Algorithmus	17

1 Einführung und Motivation in der Bildverarbeitung

Die digitale Bildverarbeitung ist ein zentrales Teilgebiet der angewandten Informatik und Signalverarbeitung. In zahlreichen Anwendungsfeldern – medizinische Bildgebung, autonomes Fahren, industrielle Qualitätskontrolle, Satellitenbildanalyse und Videoüberwachung – ist es notwendig, relevante Strukturen in digitalen Bildern automatisch zu erkennen. Ein digitales Bild $I : \Omega \rightarrow \mathbb{R}$ ordnet jedem Pixel $(x, y) \in \Omega \subset \mathbb{Z}^2$ einen Intensitätswert (Grauwert oder Farbwert) zu.

Kernproblem der Kantendetektion in Bildern: Kanten sind die visuell und semantisch wichtigsten Strukturen eines Bildes. Sie entstehen dort, wo sich Intensitätswerte abrupt ändern – also an Objektgrenzen, Texturen oder Helligkeitsübergängen. Die automatische Extraktion dieser Kanten bildet die Grundlage für:

- **Segmentierung:** Zerlegung eines Bildes in bedeutungsreiche Regionen
- **Objekterkennung:** Identifikation und Klassifikation von Bildobjekten
- **Bildschärfung:** Verbesserung der visuellen Qualität durch Verstärkung von Kanten
- **Merkmalsextraktion:** Gewinnung invarianter Deskriptoren für maschinelles Lernen
- **Medizinische Diagnostik:** Hervorhebung von Tumorgrenzen in CT/MRT-Aufnahmen

Der **Laplacian-Filter** ist ein fundamentales Werkzeug zur Kantendetektion. Er approximiert den mathematischen Laplace-Operator ∇^2 auf diskreten Pixelgittern und reagiert sensitiv auf alle Positionen im Bild, an denen sich die Intensität schnell ändert – unabhängig von der Kantenorientierung. Gegenüber richtungsabhängigen Filtern (Sobel, Prewitt) bietet der Laplacian den entscheidenden Vorteil der *Rotationsinvarianz*: Kanten in beliebigen Richtungen werden gleich stark detektiert.

1.1 Einordnung in die digitale Bildverarbeitung

Digitale Bildfilterung erfolgt im Ortsbereich durch *Faltung* (Konvolution) des Bildes I mit einer Filtermaske H (auch: Kernel, Konvolutionsmaske):

$$(I * H)[x, y] = \sum_{s=-k}^k \sum_{t=-k}^k I[x + s, y + t] \cdot H[s, t]$$

wobei H eine $(2k+1) \times (2k+1)$ -Matrix ist. Für $k = 1$ ergibt sich eine 3×3 -Maske. Dieses Prinzip ist in Abbildung 7 visualisiert.

Klassen von Raumfiltern:

- **Tiefpassfilter** (z. B. Gaußfilter): Glätten das Bild, dämpfen Hochfrequenzen
- **Hochpassfilter** (z. B. Laplacian): Verstärken Kanten und feine Details
- **Bandpassfilter:** Selektive Frequenzverstärkung in einem Bereich

Der Laplacian ist ein klassischer **Hochpassfilter zweiter Ordnung**, da er die zweite räumliche Ableitung des Bildes approximiert.

2 Mathematische Grundlagen

2.1 Der kontinuierliche Laplace-Operator

Definition 1 (Laplace-Operator). Sei $f : \mathbb{R}^2 \rightarrow \mathbb{R}$ eine zweimal stetig differenzierbare Funktion. Der *Laplace-Operator* ∇^2 ist definiert als die Summe der zweiten partiellen Ableitungen:

$$\nabla^2 f(x, y) = \frac{\partial^2 f}{\partial x^2} + \frac{\partial^2 f}{\partial y^2}$$

Satz 1 (Rotationsinvarianz des Laplace-Operators). Der Laplace-Operator ist invariant unter Rotationen der Eingabefunktion. Für eine Drehung R_θ um den Winkel θ gilt:

$$\nabla^2(f \circ R_\theta) = (\nabla^2 f) \circ R_\theta$$

Beweis. Sei $R_\theta : (x, y) \mapsto (x \cos \theta - y \sin \theta, x \sin \theta + y \cos \theta)$ eine Rotation um den Ursprung. Wir substituieren $u = x \cos \theta - y \sin \theta$ und $v = x \sin \theta + y \cos \theta$. Mit der Kettenregel ergibt sich:

$$\begin{aligned} \frac{\partial^2}{\partial x^2}(f \circ R_\theta) &= \cos^2 \theta \cdot f_{uu} - 2 \sin \theta \cos \theta \cdot f_{uv} + \sin^2 \theta \cdot f_{vv} \\ \frac{\partial^2}{\partial y^2}(f \circ R_\theta) &= \sin^2 \theta \cdot f_{uu} + 2 \sin \theta \cos \theta \cdot f_{uv} + \cos^2 \theta \cdot f_{vv} \end{aligned}$$

Addition ergibt:

$$\nabla^2(f \circ R_\theta) = (\cos^2 \theta + \sin^2 \theta)(f_{uu} + f_{vv}) = f_{uu} + f_{vv} = (\nabla^2 f) \circ R_\theta \quad \square$$

Bemerkung 1. Diese Eigenschaft ist in der Bildverarbeitung von zentraler Bedeutung: Ein Kantendetektor auf Basis des Laplace-Operators spricht auf Kanten *aller Orientierungen* gleich an. Richtungsabhängige Filter wie der Sobel-Operator müssen für jede Kantenrichtung separat ausgewertet werden.

2.2 Diskretisierung: Vom Kontinuierlichen zum Digitalen Bild

Ein digitales Bild $I[x, y]$ ist auf einem diskreten Gitter $\mathbb{Z}^2$ definiert. Die kontinuierlichen partiellen Ableitungen werden durch *finite Differenzen* approximiert.

Definition 2 (Finite Differenzen zweiter Ordnung). Die zweite partielle Ableitung in x -Richtung am Punkt (x, y) wird durch den *zentralen Differenzenquotienten zweiter Ordnung* approximiert:

$$\left. \frac{\partial^2 I}{\partial x^2} \right|_{(x,y)} \approx I[x-1, y] - 2I[x, y] + I[x+1, y]$$

Analog in y -Richtung:

$$\left. \frac{\partial^2 I}{\partial y^2} \right|_{(x,y)} \approx I[x, y-1] - 2I[x, y] + I[x, y+1]$$

Herleitung via Taylor-Entwicklung. Entwickle $I[x + 1, y]$ und $I[x - 1, y]$ als Taylor-Reihe um (x, y) :

$$\begin{aligned} I[x + 1, y] &= I[x, y] + \frac{\partial I}{\partial x} + \frac{1}{2} \frac{\partial^2 I}{\partial x^2} + \frac{1}{6} \frac{\partial^3 I}{\partial x^3} + \mathcal{O}(h^4) \\ I[x - 1, y] &= I[x, y] - \frac{\partial I}{\partial x} + \frac{1}{2} \frac{\partial^2 I}{\partial x^2} - \frac{1}{6} \frac{\partial^3 I}{\partial x^3} + \mathcal{O}(h^4) \end{aligned}$$

(mit Schrittweite $h = 1$). Addition beider Gleichungen:

$$I[x + 1, y] + I[x - 1, y] = 2 I[x, y] + \frac{\partial^2 I}{\partial x^2} + \mathcal{O}(h^4)$$

Umstellen nach der zweiten Ableitung:

$$\frac{\partial^2 I}{\partial x^2} \approx I[x + 1, y] - 2 I[x, y] + I[x - 1, y] + \mathcal{O}(h^4)$$

Der Approximationsfehler ist von der Ordnung $\mathcal{O}(h^2)$ (hier $h = 1$, also $\mathcal{O}(1)$). In der Praxis ist dieser Fehler für natürliche Bilder vernachlässigbar klein. $\square$

2.3 Der diskrete Laplacian

Durch Addition beider Richtungsableitungen erhält man die diskrete Laplacian-Approximation:

Satz 2 (Diskreter Laplacian). Der diskrete Laplace-Operator am Bildpunkt (x, y) lautet:

$$\begin{aligned} \nabla^2 I[x, y] &= \frac{\partial^2 I}{\partial x^2} + \frac{\partial^2 I}{\partial y^2} \\ &\approx I[x - 1, y] + I[x + 1, y] + I[x, y - 1] + I[x, y + 1] - 4 I[x, y] \end{aligned} \quad (1)$$

Dies entspricht der Faltung mit der 3×3 -Maske:

$$H_a = \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Beweis. Direkte Substitution der finiten Differenzen:

$$\begin{aligned} \nabla^2 I[x, y] &\approx (I[x - 1, y] - 2I[x, y] + I[x + 1, y]) \\ &\quad + (I[x, y - 1] - 2I[x, y] + I[x, y + 1]) \\ &= I[x - 1, y] + I[x + 1, y] + I[x, y - 1] + I[x, y + 1] - 4I[x, y] \end{aligned}$$

Die Maske H_a kodiert genau diesen Ausdruck: Der Zentralkoeffizient -4 multipliziert den Mittelpunkt, die vier direkten Nachbarn erhalten den Koeffizienten $+1$, die Diagonalnachbarn werden nicht berücksichtigt. $\square$

3 Die vier Laplacian-Masken – Formale Herleitung

In der Praxis werden vier Varianten der Laplacian-Maske eingesetzt (vgl. Abb. 1). Alle haben gemeinsam, dass ihre Koeffizienten sich zu Null summieren – eine fundamentale Eigenschaft, die direkt aus der Physik des Operators folgt.




Abbildung 1: Die vier Laplacian-Masken (a)–(d) als Heatmaps. Positive Koeffizienten (blau) entsprechen Nachbarn, negative (rot) dem Zentralwert. Alle Masken summieren zu Null.




Abbildung 2: Balkendiagramme und Heatmaps aller vier Masken. Die grüne Beschriftung Summe = 0 bestätigt die Nullsummeneigenschaft für alle Varianten.

3.1 Maske (a): Grundform, 90°-invariant

Die Grundform entsteht direkt aus Gleichung (1):

$$H_a = \begin{pmatrix} 0 & 1 & 0 \\ 1 & -4 & 1 \\ 0 & 1 & 0 \end{pmatrix}$$

Diese Maske ist *invariant unter 90°-Rotationen*: Eine Drehung um $k \cdot 90^\circ$ (für $k \in \{1, 2, 3\}$) liefert dieselbe Maske. Die Diagonalrichtungen (45, 135, ...) werden jedoch *nicht* berücksichtigt, da nur die vier achsenparallelen Nachbarpixel eingehen.

Lemma 1 (Nullsummeneigenschaft). Für jede der vier Laplacian-Masken gilt: Die Summe aller Koeffizienten ist Null.

$$\sum_{s,t} H[s,t] = 0$$

Beweis. Für Maske H_a : $0 + 1 + 0 + 1 + (-4) + 1 + 0 + 1 + 0 = 4 - 4 = 0$.

Physikalische Bedeutung: Die Nullsummeneigenschaft ist äquivalent dazu, dass der Filter auf konstante Grauwertteppiche ($I[x,y] = c = \text{const}$) mit der Antwort Null reagiert:

$$(I * H)[x,y] = c \cdot \sum_{s,t} H[s,t] = c \cdot 0 = 0$$

Das ist genau richtig: Homogene Bildbereiche ohne Kanten sollen keine Filterantwort erzeugen. Für Maske H_b : $1 + 1 + 1 + 1 + (-8) + 1 + 1 + 1 + 1 = 8 - 8 = 0$. Für H_c und H_d gilt dasselbe durch Vorzeichenwechsel aller Koeffizienten. $\square$

3.2 Maske (b): Verbesserte Rotationsinvarianz, 45°-invariant

Um auch Diagonalkanten zu erfassen, werden die vier Diagonalnachbarn einbezogen:

$$H_b = \begin{pmatrix} 1 & 1 & 1 \\ 1 & -8 & 1 \\ 1 & 1 & 1 \end{pmatrix}$$

Der Zentralkoeffizient wird auf -8 angepasst (statt -4), um die Nullsummeneigenschaft zu erhalten. Diese Maske ist invariant unter Rotationen in 45-Schritten.

Satz 3 (Isotopie von Maske (b)). Maske H_b approximiert den isotropen Laplacian besser als H_a in dem Sinne, dass sie für Kanten aller Orientierungen (in 45-Schritten) eine konstantere Antwort liefert.

Beweis. Betrachte eine ideale Kantenfunktion der Form $I_\theta(x,y) = \mathbf{1}[x \cos \theta + y \sin \theta > 0]$ (Heaviside-Kante mit Orientierung θ). Die Filterantwort an einem Kantenpixel $(0,0)$ ist:

$$(I_\theta * H_a)[0,0] = I_\theta[-1,0] + I_\theta[1,0] + I_\theta[0,-1] + I_\theta[0,1] - 4 \cdot I_\theta[0,0]$$

Für $\theta = 0$ (vertikale Kante): Genau zwei der vier achsenparallelen Nachbarn liegen auf der Kantenseite mit Wert 1, zwei auf der Seite mit Wert 0. Die Antwort ist maximal. Für $\theta = 45$ (diagonale Kante): Nur ein Nachbar liegt klar auf einer Seite. Die Antwort von H_a fällt ab. Maske H_b schließt die Diagonalnachbarn ein und gleicht diesen Effekt aus. Quantitativ: Der Variationskoeffizient der Maximalantwort über alle $\theta \in \{0, 45, 90, 135\}$ ist für H_b deutlich kleiner als für H_a (vgl. Abb. 3). $\square$




Abbildung 3: Maximale Filterantwort von Maske (a) und (b) auf Kanten verschiedener Orientierungen. Maske (b) zeigt deutlich konstantere Antworten über alle Winkel – sie ist rotationsinvariant. In der Bildverarbeitung bedeutet dies: Kanten in allen Richtungen werden gleich zuverlässig detektiert.

3.3 Masken (c) und (d): Alternative Vorzeichenkonventionen

Die Masken H_c und H_d entstehen durch Vorzeichenwechsel von H_a bzw. H_b :

$$H_c = -H_a = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 4 & -1 \\ 0 & -1 & 0 \end{pmatrix}, \quad H_d = -H_b = \begin{pmatrix} -1 & -1 & -1 \\ -1 & 8 & -1 \\ -1 & -1 & -1 \end{pmatrix}$$

Lemma 2 (Äquivalenz der Vorzeichenvarianten). Für die Anwendung zur Bildschärfung gilt: Ob man H_a oder H_c verwendet, hängt nur vom Vorzeichen der Subtraktion in der Schärfungsformel ab.

$$I_{\text{scharf}} = I - \nabla^2 I \Leftrightarrow I_{\text{scharf}} = I + (-\nabla^2 I) = I + (I * H_c)$$

Beweis. Es gilt $I * H_c = -(I * H_a) = -\nabla^2 I$. Daher ist $I + (I * H_c) = I - (I * H_a) = I - \nabla^2 I$. $\square$

4 Visualisierung: 1D- und 2D-Laplacian

4.1 Verhalten im Eindimensionalen

Abbildung 4 zeigt den Laplacian auf einem 1D-Signal. An Stellen mit hoher Intensitätsänderung (Kanten) ist $|f''|$ groß; homogene Bereiche liefern $f'' \approx 0$. Dieses Verhalten ist die Grundlage aller Kantendetektionsverfahren zweiter Ordnung.




Abbildung 4: Oben: Original-Signal $f(x)$. Unten: Zweite Ableitung $\nabla^2 f(x)$. Positive Werte (rot) entstehen an Übergängen von dunkel zu hell (links), negative (blau) an Übergängen von hell zu dunkel (rechts). Nulldurchgänge markieren Kantenmitten – das Prinzip des *Zero-Crossing-Detektors* (Marr & Hildreth, 1980).




Abbildung 5: Diskrete Herleitung: Ursprungssignal, erste Differenz und diskrete Laplacian-Approximation $\nabla^2 f[x] = f[x-1] - 2f[x] + f[x+1]$. Die Werte an Intensitätsmaxima und -minima sind betragsmäßig am größten – genau dort liegen Kanten im Bild.

4.2 Verhalten im Zweidimensionalen auf Testbildern




Abbildung 6: 2D-Laplacian auf synthetischem Testbild (Kreis + Rechteck). Links: Original. Mitte links: Laplacian mit Maske (a) – achsenparallele Kanten werden scharf dargestellt. Mitte rechts: Laplacian mit Maske (b) – auch diagonale Kanten (z. B. am Kreis) sind deutlicher sichtbar. Rechts: Differenz zeigt die zusätzliche Sensitivität von (b). **Bildverarbeitungspraxis:** In realen Anwendungen (z. B. medizinische CT-Bilder) liefert Maske (b) deutlich vollständigere Kantenkarten.

5 Anwendung: Spatial Sharpening (Bildschärfung)

5.1 Grundprinzip der Laplacian-basierten Bildschärfung

Die wichtigste praktische Anwendung des Laplacian in der Bildverarbeitung ist die **Bildschärfung** (engl. *spatial sharpening*). Das Ziel ist, ein unscharfes oder detailarmes Bild I durch Verstärkung seiner hochfrequenten Anteile (Kanten, Texturen) zu verbessern.

Satz 4 (Laplacian-Schärfungsformel). Das geschärfte Bild I_s ergibt sich aus dem Original I durch:

$$I_s[x, y] = I[x, y] - c \cdot \nabla^2 I[x, y]$$

wobei $c > 0$ ein Schärfungsparameter ist. Für $c = 1$ und Maske H_a gilt:

$$I_s[x, y] = I[x, y] - (I * H_a)[x, y]$$

Dies kann kompakt als Faltung mit einer kombinierten Maske geschrieben werden:

$$H_s = \delta - H_a = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{pmatrix}$$

wobei δ die diskrete Dirac-Einheitsfunktion (Einheitsimpuls) darstellt.

Beweis. Der Einheitsimpuls $\delta[x, y]$ hat den Wert 1 bei $(0, 0)$ und 0 sonst:

$$(I * \delta)[x, y] = I[x, y]$$

Damit:

$$I_s = I - \nabla^2 I = I * \delta - I * H_a = I * (\delta - H_a)$$

Koeffizientenweise: $(\delta - H_a)[0,0] = 1 - (-4) = 5$, alle Nachbarkoeffizienten: $0 - 1 = -1$, alle anderen: $0 - 0 = 0$. Ergebnis:

$$H_s = \begin{pmatrix} 0 & -1 & 0 \\ -1 & 5 & -1 \\ 0 & -1 & 0 \end{pmatrix} \quad \square$$

Bemerkung 2. Der Zentralkoeffizient 5 (bzw. 9 für Maske H_b) erklärt sich physikalisch: Der aktuelle Pixel wird einmal als Original beibehalten (+1 vom Einheitsimpuls) plus die 4 (bzw. 8) Nachbareinflüsse zurückaddiert, die der Laplacian abgezogen hatte.




Abbildung 7: Spatial Sharpening in der Bildverarbeitung. Links: Unscharfes Originalbild. Mitte: Laplacian-Ausgabe (normiert, Null = Mittelgrau) – zeigt ausschließlich Kantenbereiche. Rechts: Geschärftes Bild $I_s = I - \nabla^2 I/c$. Kanten und Objektgrenzen sind deutlich verstärkt, homogene Bereiche bleiben unverändert. **Praktischer Nutzen:** Diese Methode wird eingesetzt in Druckvorverarbeitung, Kamerasoftware (Schärfe-Regler), medizinischer Bildgebung und Satellitenbildbearbeitung.

5.2 Nutzwert in realen Bildverarbeitungsanwendungen

Die Laplacian-basierte Schärfung findet direkten Einsatz in folgenden Bereichen:

- **Medizinische Bildgebung:** In CT- und MRT-Aufnahmen werden Laplacian-Filter eingesetzt, um Gewebegrenzen und pathologische Strukturen (Tumoren, Gefäßwände) schärfer darzustellen. Die Rotationsinvarianz ist hier entscheidend, da Strukturen in beliebigen Orientierungen vorliegen.
- **Satellitenbildverarbeitung:** Erdbeobachtungssatelliten (Sentinel, Landsat) verwenden Laplacian-Filter zur Kanten- und Strukturdetektion in Geländekarten.
- **Industrielle Qualitätskontrolle:** Defekterkennung auf Oberflächen (Kratzer, Risse) durch Verstärkung feiner Kantenstrukturen mit Laplacian-Masken.
- **Kamerasoftware:** Der *Unsharp Masking*-Algorithmus, der in nahezu jeder digitalen Kamera und in Programmen wie Adobe Photoshop eingesetzt wird, basiert auf dem Prinzip $I_s = I - \nabla^2 I$.
- **Autonomes Fahren:** Fahrspurerkennung und Hindernisdetektion durch Laplacian-of-Gaussian (LoG) und Canny-Kantendetektor.

6 Frequenzdomänen-Analyse

6.1 Hochpasscharakter des Laplacian

Satz 5 (Frequenzantwort des diskreten Laplacian). Die 2D-Fouriertransformierte der Laplacian-Maske H_a ist:

$$\hat{H}_a(u, v) = 2 \cos(2\pi u) + 2 \cos(2\pi v) - 4$$

wobei $u, v \in [-\frac{1}{2}, \frac{1}{2}]$ die normalisierten Frequenzkoordinaten sind.

Beweis. Die 2D-DFT der Maske H_a mit Stützstellen bei $(0, \pm 1)$ und $(\pm 1, 0)$ lautet:

$$\begin{aligned} \hat{H}_a(u, v) &= \sum_{s,t} H_a[s, t] \cdot e^{-j2\pi(us+vt)} \\ &= 1 \cdot e^{-j2\pi v} + 1 \cdot e^{j2\pi v} + 1 \cdot e^{-j2\pi u} + 1 \cdot e^{j2\pi u} + (-4) \cdot 1 \\ &= 2 \cos(2\pi v) + 2 \cos(2\pi u) - 4 \end{aligned}$$

Da $\cos(2\pi \cdot 0) = 1$ und der Ausdruck $2 \cos(2\pi u) + 2 \cos(2\pi v) - 4 \leq 0$ für alle u, v , bestätigt sich: Der Filter dämpft niedrige Frequenzen (Gleichanteile bei $u = v = 0$: $\hat{H}_a = 0$) und verstärkt hohe Frequenzen. Dies ist die Signatur eines **Hochpassfilters**. $\square$

Korollar 1 (Gleichanteil-Unterdrückung). Für die Gleichkomponente ($u = v = 0$) gilt $\hat{H}_a(0, 0) = 2 + 2 - 4 = 0$. Dies entspricht direkt der Nullsummeneigenschaft (Lemma 1) und erklärt, warum konstante Grauwertteppiche keine Filterantwort erzeugen.




Abbildung 8: 2D-Frequenzantwort der Masken (a) und (b) (logarithmisch skaliert, hellere Bereiche = stärkere Antwort). Beide Masken zeigen klares Hochpassverhalten: Die Energie konzentriert sich bei hohen Frequenzen (Randbereiche). Maske (b) zeigt eine rundere Hochpasscharakteristik – konsistent mit ihrer besseren Rotationsinvarianz. **Bildverarbeitungsbedeutung:** Kanten entsprechen hohen Ortsfrequenzen. Die Masken verstärken genau diese Frequenzen und dämpfen Gleichanteile.

7 Eigenschaften: Formaler Überblick

Satz 6 (Schlüsseigenschaften der Laplacian-Masken). Die vier Laplacian-Masken teilen folgende formal nachweisbare Eigenschaften:

1. **Nullsumme:** $\sum_{s,t} H[s, t] = 0$ (Lemma 1)
2. **Hochpassfilter:** $\hat{H}(0, 0) = 0$, $|\hat{H}(u, v)|$ wächst mit Frequenz
3. **Vorzeichenkonvention:** $H_c = -H_a$, $H_d = -H_b$
4. **Negative Ausgabewerte:** $(I * H)[x, y] \in \mathbb{R}$ kann negativ sein
5. **Keine Normierung:** Ableitungsfilter werden nicht auf Einheitsnorm normiert

Beweis. Punkte 1 und 2 wurden in Lemma 1 und Satz 5 bewiesen. Punkt 3 folgt aus $H_c[s, t] = -H_a[s, t]$ für alle (s, t) per Definition. Punkt 4: Da $I * H_a$ eine Linearkombination von Intensitätswerten mit positiven und negativen Koeffizienten ist, können negative Werte entstehen. Standardmäßig wird die Ausgabe normiert: Null entspricht Mittelgrau (128 bei 8-Bit), positive Werte hellen auf, negative verdunkeln. Punkt 5: Die Koeffizienten summieren zu Null; eine Normierung auf $\sum |H| = 1$ würde die Filterantwort skalieren, aber nicht die strukturelle Eigenschaft ändern. $\square$

8 Zusammenfassung

Der Laplacian-Filter ist ein fundamentales Werkzeug der digitalen Bildverarbeitung. Ausgehend vom kontinuierlichen Laplace-Operator $\nabla^2 = \partial^2/\partial x^2 + \partial^2/\partial y^2$ wurde gezeigt:

- Der Operator ist **rotationsinvariant** (Satz 1), was ihn für richtungsunabhängige Kantendetektion prädestiniert
- Die Diskretisierung über **finite Differenzen** liefert die 3×3 -Maske H_a (Satz 2) mit Approximationsfehler $\mathcal{O}(h^2)$
- Die **Nullsummeneigenschaft** (Lemma 1) sichert, dass homogene Bildbereiche keine Filterantwort erzeugen
- Maske H_b erreicht **verbesserte Isotropie** durch Einschluss der Diagonalnachbarn (Satz 3)
- Die **Schärfungsformel** $I_s = I - \nabla^2 I$ liefert geschärfte Bilder durch Addition hochfrequenter Kanteninformation (Satz 4)
- Im Frequenzbereich ist der Laplacian ein **Hochpassfilter** mit $\hat{H}(0, 0) = 0$ (Satz 5)

9 Ausblick

Die hier vorgestellten klassischen Laplacian-Masken bilden die Basis eines breiten Spektrums aktueller und zukünftiger Forschungsrichtungen in der Bildverarbeitung. Im Folgenden werden die wichtigsten Erweiterungen, offene Probleme und zukunftsweisende Entwicklungen ausführlich dargelegt.

9.1 Laplacian of Gaussian (LoG) und Marr-Hildreth-Detektor

Der direkte Laplacian ist empfindlich gegenüber Bildrauschen, da die zweite Ableitung Rauschen verstärkt. Die wichtigste Erweiterung ist der **Laplacian of Gaussian (LoG)**:

$$\text{LoG}(x, y) = \nabla^2 G_\sigma(x, y) = \frac{1}{\pi\sigma^4} \left(1 - \frac{x^2 + y^2}{2\sigma^2} \right) \exp\left(-\frac{x^2 + y^2}{2\sigma^2}\right)$$

Marr und Hildreth [2] zeigten 1980, dass dieser Filter biologisch plausible Kantendetektoren modelliert und *Zero Crossings* (Nulldurchgänge) exakt Kantenpositionen markieren. Der LoG löst das fundamentale Problem: Durch Vorglättung mit dem Gaußfilter G_σ (Tiefpassfilter, Standardabweichung σ) wird Rauschen unterdrückt, bevor der Laplacian die Kanten hervorhebt. Zukünftige Arbeiten könnten adaptives σ untersuchen, das lokal an die Bildeigenschaften angepasst wird.

9.2 Difference of Gaussians (DoG) als LoG-Approximation

In der Praxis wird LoG häufig durch die **Difference of Gaussians (DoG)** approximiert:

$$\text{DoG}(x, y; \sigma_1, \sigma_2) = G_{\sigma_1}(x, y) - G_{\sigma_2}(x, y), \quad \sigma_1 < \sigma_2$$

Diese Approximation bildet die Basis des SIFT-Algorithmus (Scale-Invariant Feature Transform) von Lowe [3]. SIFT-Merkmale sind robust gegenüber Skalierung, Rotation und partieller Beleuchtungsänderung und dominieren seit über zwei Jahrzehnten die Merkmalsdetektion in Computer Vision. Offene Forschungsfragen betreffen optimale (σ_1, σ_2) -Paare für spezifische Anwendungsdomänen wie Histopathologie oder Fernerkundung.

9.3 Anisotrope Diffusion und nichtlineare Verallgemeinerung

Perona und Malik [4] verallgemeinerten den isotropen Laplacian zur **anisotropen Diffusion**:

$$\frac{\partial I}{\partial t} = \text{div}(c(\|\nabla I\|) \cdot \nabla I)$$

wobei $c(\cdot)$ eine monoton fallende Diffusionsfunktion ist. Diese partielle Differentialgleichung glättet homogene Bereiche, erhält aber Kanten ($c \rightarrow 0$ bei großem $\|\nabla I\|$). Aktuelle Forschung kombiniert anisotrope Diffusion mit tiefen neuronalen Netzen, um die Diffusionskoeffizienten datengetrieben zu lernen.

9.4 Laplacian Pyramid und Multi-Skalen-Analyse

Burt und Adelson [5] führten die **Laplacian Pyramid** ein: eine hierarchische Darstellung, bei der jede Ebene die Differenz zwischen zwei aufeinanderfolgenden Gaußpyramidenstufen enthält – also bandpassgefilterte Bilder auf verschiedenen Skalierungsstufen. Diese Darstellung ermöglicht:

- **Bildkompression:** Die Laplacian-Koeffizienten sind spärlich und lassen sich effizient kodieren (Grundlage von JPEG 2000 und Wavelet-Kompressionsverfahren)
- **Bildmischung (Image Blending):** Nahtlose Komposition von Bildbereichen ohne sichtbare Übergänge durch frequenzbandspezifisches Blending
- **Super-Resolution:** Hochauflösungsrekonstruktion durch Kombination mehrerer Laplacian-Pyramid-Ebenen

9.5 Tiefe neuronale Netze und lernbare Laplacian-Filter

Mit dem Aufstieg der **Convolutional Neural Networks** (CNNs) durch LeCun et al. [6] und der Deep-Learning-Revolution nach AlexNet [7] stellt sich die Frage, welche Rolle klassische Laplacian-Filter in gelernten Architekturen spielen.

Aktuelle Analysen zeigen [8], dass die ersten Faltungsschichten tiefer Netze spontan Gabor-ähnliche und Laplacian-ähnliche Filter entwickeln – ohne explizite Vorgabe. Dies deutet darauf hin, dass Laplacian-Strukturen *fundamentale statistische Eigenschaften natürlicher Bilder* widerspiegeln (“efficient coding”-Hypothese von Barlow [9]).

Zukünftige Richtungen:

- **Laplacian-regularisierte Netzarchitekturen:** Integration von Laplacian-Constraints als Regularisierungsterm in Verlustfunktionen für Bildrekonstruktionsaufgaben (Deblurring, Inpainting, Super-Resolution)
- **Graph Laplacian in geometrischer Deep Learning:** Der Graph-Laplacian $L = D - A$ (Gradmatrix minus Adjazenzmatrix) verallgemeinert den Bildlaplacian auf irreguläre Graphen und 3D-Punktwolken [10]
- **Spektrale Graph-Faltungsnetze (GCN):** Kipf und Welling [11] nutzen den normalisierten Graph-Laplacian für spektrale Faltungen auf Graphdaten

9.6 Anwendungen in der medizinischen Bildverarbeitung

Laplacian-Filter spielen in der medizinischen Bildgebung eine zunehmend wichtige Rolle:

- **CT/MRT-Segmentierung:** Laplacian-Zero-Crossing-Detektoren markieren Organ Grenzen und Gewebeschichten in 3D-Volumendaten
- **Histopathologie:** Erkennung von Zellkern Grenzen in H&E-gefärbten Gewebeschnitten für automatisierte Krebsdiagnose
- **Ophthalmologie:** Detektion von Netzhautgefäßen in Fundusbildern (DRIVE-Datensatz) zur Früherkennung von diabetischer Retinopathie
- **Neuroimaging:** Kortikale Dickenmessung durch Laplacian-basierte Normalenvektoren auf MRT-basierten Kortex-Meshes [12]

9.7 Laplacian Eigenmaps und Dimensionsreduktion

Belkin und Niyogi [13] nutzen den Graph-Laplacian zur nichtlinearen Dimensionsreduktion (**Laplacian Eigenmaps**): Die ersten k Eigenvektoren des Laplacian einer Daten-Nachbarschaftsgraphstruktur liefern eine optimale niedrigdimensionale Einbettung unter Erhaltung lokaler Geometrie. Diese Methode wird in Bildklassifikation, Dokumentenclustering und Bioinformatik eingesetzt und ist direkt mit dem Diffusions-Map-Framework [14] verwandt.

9.8 Robuste Laplacian-Filter und Ausreißertoleranz

Klassische Laplacian-Filter reagieren sensitiv auf Impulsrauschen (Salt-and-Pepper-Rauschen). Zukünftige Arbeiten sollten robuste Varianten untersuchen, die auf Rang-basierten Statistiken oder M -Schätzern beruhen:

$$\hat{\nabla}^2 I[x, y] = \text{Median}\{I[x + s, y + t] \cdot H[s, t] : (s, t) \in \mathcal{N}\}$$

Solche robusten Operatoren wären besonders wertvoll für Ultraschall- und Elektronenmikroskopie-Bilder mit stark nicht-Gaußschem Rauschen.

9.9 Parallelisierung und Hardware-Implementierung

Für Echtzeitanwendungen (Videoverarbeitung, Kamerasysteme) ist die effiziente Implementierung entscheidend:

- **FPGA-Implementierung:** 3×3 -Faltung als Shift-Register-Pipeline mit konstantem Durchsatz von einem Pixel pro Takt
- **GPU-Parallelisierung (CUDA/OpenCL):** Massiv-parallele Berechnung über alle Bildpixel simultan, Speedup $> 100\times$ gegenüber CPU für hochauflösende Bilder
- **Neuromorphic Computing:** Implementierung auf Spike-basierten Neuromorphic-Chips (Intel Loihi, IBM TrueNorth) für energieeffiziente Kantendetektion in eingebetteten Systemen

9.10 Verbindung zur theoretischen Informatik: Subgraph Algorithmus

Eine unerwartete Verbindung besteht zur Theorie der Graphenalgorithmen: Adjazenzmatrizen diskreter Pixelgraphen (4-Nachbarschaft, 8-Nachbarschaft) sind genau die algebraischen Strukturen, auf denen der diskrete Laplacian operiert. Der Subgraph Algorithmus (Epp 2026, [18]) analysiert Graphen via Adjazenzmatrizen und Signatur-Vergleich – methodisch verwandt mit der spektralen Graphentheorie, die den Graph-Laplacian $L = D - A$ als zentrales Objekt verwendet. Zukünftige Arbeiten könnten untersuchen, ob die Signatur-Invarianten des Subgraph Algorithmus zur effizienten Berechnung von Laplacian-Spektren eingesetzt werden können, oder ob isomorphe Pixelgraph-Strukturen (rotierte Bildausschnitte) über den Subgraph Algorithmus erkannt werden können – was direkt zur Frage der Rotationsinvarianz von Bildmerkmalen führt.

Literatur

- [1] R. C. Gonzalez, R. E. Woods, *Digital Image Processing*, 4. Auflage, Pearson, 2018.
- [2] D. Marr, E. Hildreth, “Theory of Edge Detection”, *Proceedings of the Royal Society of London B*, 207(1167):187–217, 1980.
- [3] D. G. Lowe, “Distinctive Image Features from Scale-Invariant Keypoints”, *International Journal of Computer Vision*, 60(2):91–110, 2004.

- [4] P. Perona, J. Malik, “Scale-Space and Edge Detection Using Anisotropic Diffusion”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 12(7):629–639, 1990.
- [5] P. J. Burt, E. H. Adelson, “The Laplacian Pyramid as a Compact Image Code”, *IEEE Transactions on Communications*, 31(4):532–540, 1983.
- [6] Y. LeCun, L. Bottou, Y. Bengio, P. Haffner, “Gradient-Based Learning Applied to Document Recognition”, *Proceedings of the IEEE*, 86(11):2278–2324, 1998.
- [7] A. Krizhevsky, I. Sutskever, G. E. Hinton, “ImageNet Classification with Deep Convolutional Neural Networks”, *Advances in Neural Information Processing Systems (NeurIPS)*, 25, 2012.
- [8] M. D. Zeiler, R. Fergus, “Visualizing and Understanding Convolutional Networks”, *European Conference on Computer Vision (ECCV)*, 2014.
- [9] H. B. Barlow, “Possible Principles Underlying the Transformation of Sensory Messages”, in *Sensory Communication*, MIT Press, S. 217–234, 1961.
- [10] M. M. Bronstein, J. Bruna, Y. LeCun, A. Szlam, P. Vandergheynst, “Geometric Deep Learning: Going beyond Euclidean Data”, *IEEE Signal Processing Magazine*, 34(4):18–42, 2017.
- [11] T. N. Kipf, M. Welling, “Semi-Supervised Classification with Graph Convolutional Networks”, *International Conference on Learning Representations (ICLR)*, 2017.
- [12] S. E. Jones, B. R. Buchbinder, I. Aharon, “Three-Dimensional Mapping of Cortical Thickness Using Laplace’s Equation”, *Human Brain Mapping*, 11(1):12–32, 2000.
- [13] M. Belkin, P. Niyogi, “Laplacian Eigenmaps for Dimensionality Reduction and Data Representation”, *Neural Computation*, 15(6):1373–1396, 2003.
- [14] R. R. Coifman, S. Lafon, “Diffusion Maps”, *Applied and Computational Harmonic Analysis*, 21(1):5–30, 2006.
- [15] J. Canny, “A Computational Approach to Edge Detection”, *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 8(6):679–698, 1986.
- [16] J. M. S. Prewitt, “Object Enhancement and Extraction”, in *Picture Processing and Psychopictorics*, Academic Press, S. 75–149, 1970.
- [17] A. V. Oppenheim, R. W. Schaffer, *Discrete-Time Signal Processing*, 2. Auflage, Prentice Hall, 1999.
- [18] S. Epp, “Der Subgraph Algorithmus”, Januar 2026. <https://gitlab.com/epp-group/subgraph>