

KI-Power-Management-Modul für Lithium-Ionen-Akkumulatoren

*Formaler Nachweis der Überlegenheit eines lernenden,
verhaltensadaptiven Power-Management-Systems*

Autor: Stephan Epp

Datum: 7. März 2026

Zusammenfassung

Lithium-Ionen-Akkumulatoren (LIB) sind die dominierende Energiespeichertechnologie in mobilen Geräten, Elektrofahrzeugen und stationären Speichersystemen. Ihre Lebensdauer wird maßgeblich durch zwei physikalische Hauptmechanismen begrenzt: (1) temperaturinduziertes Kapazitätsdriften und (2) elektrochemische Degradation durch unkontrollierte Zellspannungen. Konventionelle Power-Management-Systeme (PMS) adressieren diese Mechanismen reaktiv anhand statischer Schwellwerte.

Diese Arbeit präsentiert ein formal nachgewiesenes, KI-getriebenes Power-Management-Modul (AI-PMM), das Nutzungsverhalten und Umgebungsparameter kontinuierlich erlernt und prädiktiv in Regelstrategien umsetzt. Mithilfe eines Reinforcement-Learning-Agenten sowie adaptiver Regler werden Temperatur und Zellspannung dynamisch optimiert.

Es wird mathematisch hergeleitet, dass das AI-PMM gegenüber einem statischen Referenz-PMS die Gesamtlebensdauer um den Faktor $\Phi \geq 1,47$ steigert. Formale Stabilitätsanalysen (Lyapunov) und Degradationsmodelle (Arrhenius, SEI-Wachstum) belegen die theoretische Fundierung. Simulationsergebnisse mit synthetischen Lastprofilen bestätigen die analytischen Resultate.

Schlüsselwörter: Lithium-Ionen-Akkumulator, Power Management, Künstliche Intelligenz, Reinforcement Learning, Lebensdauermaximierung, Temperaturregelung, Spannungsregelung, SEI-Schicht, Arrhenius-Modell, Lyapunov-Stabilität.

Inhaltsverzeichnis

1	Einleitung	5
1.1	Motivation und Problemstellung	5
1.2	Zielsetzung und Beitrag	5
2	Grundlagen der LIB-Degradation	5
2.1	Elektrochemische Grundprinzipien	5
2.2	Thermische Degradationsmechanismen	6
2.2.1	SEI-Wachstum	6
2.2.2	Arrhenius-Beschleunigung	6
2.2.3	Kapazitätsdriften – formale Definition	7
2.3	Spannungsbedingte Degradationsmechanismen	7
2.3.1	Überspannungsdegradation	7
2.3.2	Unterspannungsdegradation und Lithium-Plating	7
2.3.3	Spannungsfenster-Optimierung	8
3	Formales Degradationsmodell	8
3.1	Zustandsraumdarstellung	8
3.2	Gesamtdegradationsrate	8
3.3	Kumuliertes Degradationsintegral	8
3.4	Thermisches Netzwerkmodell	9
4	KI-gesteuertes Power-Management-Modul (AI-PMM)	9
4.1	Systemarchitektur	9
4.2	Markov-Entscheidungsprozess (MDP)	9
4.3	Nutzerverhaltensmodell	11
4.4	Adaptiver Temperaturregler	11
4.5	Modell-Prädiktiver Spannungsregler (MPC)	11
4.6	Lernen aus Nutzererfahrung	11
4.6.1	Reward Shaping durch Verhaltenslernen	11
4.6.2	Personalisierung durch Transferlernen	12
5	Formaler Beweis der Lebensdauermaximierung	12
5.1	Vergleichssystem: Statisches PMS	12
5.2	Hauptsatz: Lebensdauerüberlegenheit des AI-PMM	12
5.3	Lyapunov-Stabilitätsanalyse des Temperaturreglers	13
5.4	Quantitative Abschätzung des Verbesserungsfaktors Φ	14
6	Simulation und Validierung	14
6.1	Simulationsaufbau	14
6.2	Simulationsergebnisse	15
6.2.1	Kapazitätsentwicklung	15
6.2.2	Temperaturhistorie	16
6.2.3	Spannungsregelung	16
6.2.4	Lebensdauervergleich – alle Lastprofile	16
6.3	Konvergenzverhalten des RL-Agenten	16
7	Anwendung auf Elektrofahrzeuge: Lebensdauer und Reichweite	17

7.1	Relevanz für Elektrofahrzeuge	17
7.2	Fahrzeugspezifisches Degradationsmodell	17
7.2.1	Pack-Modell mit Zell-zu-Zell-Variation	17
7.2.2	Temperaturfeld im Pack	17
7.2.3	Reichweiten-Degradationsmodell	17
7.3	Quantitative Lebensdaueranalyse für EV-Anwendungen	18
7.3.1	Referenzfahrzeuge und Betriebsparameter	18
7.3.2	Lebensdauer in Jahren und Zyklen	18
7.4	Reichweitenanalyse über die Fahrzeuglebensdauer	18
7.4.1	Analytische Herleitung des Reichweitenverlaufs	18
7.4.2	Grafische Darstellung des Reichweitenverlaufs über Zyklen	19
7.4.3	Reichweitenverlauf über Betriebsjahre – alle Klassen	19
7.4.4	Kumulierter Reichweitengewinn EV-B	20
7.5	Reichweitengewinn durch Temperaturmanagement im Winterbetrieb	20
7.5.1	Kältebetrieb: Kapazitätsverlust	20
7.5.2	Prädiktives Vorheizmanagement	20
7.6	Wirtschaftliche und ökologische Analyse	21
7.6.1	Total Cost of Ownership (TCO)	21
7.6.2	CO ₂ -Einsparung	21
7.6.3	EV-Flottenanalyse: Hochskalierung	21
8	Dynamische Plattenabstandssteuerung durch das AI-PMM	22
8.1	Motivation und physikalische Grundlagen	22
8.2	Physikalisches Modell des Plattenabstands	22
8.2.1	Elektromechanisches Zellmodell	22
8.2.2	Ionentransport als Funktion des Abstands	23
8.2.3	Degradationsbeitrag durch mechanische Belastung	23
8.3	Erweiterung des AI-PMM um den Plattenabstand-Regelkanal	23
8.3.1	Erweiterter Zustandsraum und Aktionsraum	23
8.3.2	Erweitertes MDP und Belohnungsfunktion	24
8.3.3	Kaskadenregler: MPC für den Plattenabstand	24
8.3.4	Systemarchitektur mit Plattenabstandsregelung	24
8.4	Formaler Nachweis der Lebensdauersteigerung durch Plattenabstandsregelung	24
8.4.1	Mechanischer Degradationsbeitrag ohne Regelung	24
8.4.2	Mechanischer Degradationsbeitrag mit Plattenabstandsregelung	26
8.4.3	Gesamtlebensdauerbeweis mit mechanischem Kanal	26
8.4.4	Numerische Auswertung	26
8.5	Simulationsergebnisse: Plattenabstandsregelung	27
8.5.1	Plattenabstandstrajektorie und Spannungsreduktion	27
8.5.2	Einfluss auf die mechanische Degradationsrate	27
8.6	Anwendung auf Elektrofahrzeuge: Aktuatorssysteme und Implementierung	28
8.6.1	Geeignete Aktuatorssysteme	28
8.6.2	Wirtschaftliche Analyse: Kosten-Nutzen der Aktuatoren	28
8.6.3	Integration in den EU-Batteriepass	28
8.7	Zusammenfassung: Wirkung des dritten Regelungskanals	29
9	Experimentelle Validierung	29
9.1	Arrhenius-Ratenverhältnis und SEI-Schichtdickenwachstum	29
9.2	Spannungsbedingte Degradationsraten	31

9.3	Thermisches Zellmodell	32
9.4	Thermischer Verbesserungsfaktor Φ_T	33
9.5	Spannungs- und kombinierter Verbesserungsfaktor	33
9.6	Reichweiteverlauf und kältebedingte Kapazitätsreduktion	34
9.7	Quellung, Tortuosität und mechanische Degradationsrate	35
9.8	Erweiterter Gesamtverbesserungsfaktor Φ_{ges}	36
9.9	Zeitseriensimulation Lastprofil LP1 (Smartphone)	37
9.10	Zeitseriensimulation Lastprofil LP2 (E-Bike)	37
9.11	Zeitseriensimulation Lastprofil LP3 (Stationärspeicher)	38
9.12	Lastprofilvergleich LP1/LP2/LP3	39
9.13	SEI-Kapazitätsverlust und Kapazitätsdrift	40
9.14	Lebensdauer-Sensitivität und Vorheizeffizienz	41
9.15	E-Fahrzeug-Lebenszyklus und MPC-Referenztrajektorie	41
9.16	Zusammenfassung der Validierungsergebnisse	42
9.17	Interpretation der Ergebnisse	43
9.18	Grenzen des Modells	43
9.19	Vergleich mit verwandten Arbeiten	44
10	E-Batterietechnologien: Reichweite und Ladezeit	44
10.1	Motivation und Problemstellung	44
10.2	Physikalische Grundlagen und Kennzahlen	45
10.2.1	Energiedichte und Reichweitenmodell	45
10.2.2	Ladezeit-Modell	45
10.3	Ergebnisse: Energiedichte und Reichweite	46
10.4	Ergebnisse: Ladezeit und Zyklenlebensdauer	47
10.5	Formaler Beweis: Dominanz der Solid-State-Batterie	47
10.6	Kapazitätsdegradationsmodell	48
10.7	Kombinierter Leistungsindex und Pareto-Analyse	50
10.8	Kosten-Nutzen-Analyse	52
10.9	Temperaturabhängige Reichweite	53
10.10	Zusammenfassende Bewertung	53
11	Fazit und Ausblick	54
11.1	Ausblick – Forschungs- und Entwicklungsperspektiven	56
11.1.1	Kurzfristige Entwicklungen (1–3 Jahre)	56
11.1.2	Mittelfristige Entwicklungen (3–7 Jahre)	56
11.1.3	Langfristige Vision (7–15 Jahre)	57
11.1.4	Dynamische Plattenabstandssteuerung – Entwicklungsperspektiven	58

1 Einleitung

1.1 Motivation und Problemstellung

Lithium-Ionen-Akkumulatoren haben sich seit ihrer kommerziellen Einführung Anfang der 1990er Jahre als Schlüsseltechnologie für mobile Energiespeicherung etabliert. Mit einer gravimetrischen Energiedichte von typischerweise $150\text{--}300\text{ Wh kg}^{-1}$ und einer volumetrischen Energiedichte von $250\text{--}700\text{ Wh L}^{-1}$ übertreffen sie konkurrierende Technologien wie Nickel-Metallhydrid- oder Blei-Säure-Akkumulatoren deutlich [1].

Gleichwohl unterliegen LIB einem unvermeidlichen Alterungsprozess, der durch zwei dominierende Mechanismen gesteuert wird:

- (1) **Thermisch induzierte Alterung:** Erhöhte Temperaturen beschleunigen die Bildung der Solid-Electrolyte-Interphase (SEI) an der Anodenoberfläche, fördern Lithium-Plating, und führen zu mechanischen Spannungen durch anisotropes Gitterausdehnen. Das resultierende Kapazitätsdriften ist in erster Näherung arrheniusförmig [2].
- (2) **Elektrochemisch induzierte Alterung:** Über- und Unterspannungen jenseits des zulässigen Betriebsbereichs initiieren irreversible Phasenumwandlungen in Kathoden- und Anodenmaterialien, Elektrolytoxidation sowie Lithium-Dendritenbildung [3].

Konventionelle Power-Management-Systeme begegnen diesen Mechanismen durch statische Grenzwerte (z. B. $2,5\text{ V} \leq V_{\text{cell}} \leq 4,2\text{ V}$, $-20\text{ °C} \leq T \leq 45\text{ °C}$). Diese Grenzwerte sind jedoch konservativ und ignorieren den kontextabhängigen Betriebszustand sowie das individuelle Nutzerverhalten. Ein lernendes System kann diese Grenzen adaptiv und prädiktiv nutzen, um die Gesamtlebensdauer zu maximieren.

1.2 Zielsetzung und Beitrag

Diese Arbeit leistet folgende wissenschaftliche Beiträge:

- Formale Modellierung der temperatur- und spannungsbedingten Degradation von LIB durch etablierte elektrochemische und thermodynamische Modelle.
- Entwurf eines KI-gesteuerten Power-Management-Moduls (AI-PMM) basierend auf Deep Reinforcement Learning (DRL) mit expliziter Modellierung von Nutzungsverhalten und Umgebungsparametern.
- Mathematischer Nachweis der Lebensdauerüberlegenheit des AI-PMM gegenüber einem statischen Referenzsystem mittels Degradationsintegral und Lyapunov-Analyse.
- Simulation und Validierung an realistischen Lastprofilen.

2 Grundlagen der LIB-Degradation

2.1 Elektrochemische Grundprinzipien

Eine Lithium-Ionen-Zelle besteht aus Anode (üblicherweise Graphit LiC_6), Kathode (z. B. LiCoO_2 , LiFePO_4 , NMC), Elektrolyt und Separator. Die Gleichgewichtsspannung einer NMC/Graphit-Zelle berechnet sich zu:

$$E_{\text{cell}} = E_{\text{Kathode}}^{\circ} - E_{\text{Anode}}^{\circ} + \frac{RT}{nF} \ln \frac{a_{\text{Ox}}}{a_{\text{Red}}} \quad (1)$$

wobei $R = 8,314 \text{ J mol}^{-1} \text{ K}^{-1}$ die universelle Gaskonstante, T die absolute Temperatur, n die Anzahl übertragener Elektronen, $F = 96485 \text{ C mol}^{-1}$ die Faraday-Konstante und a_i die Aktivitäten der Reaktanden sind.

2.2 Thermische Degradationsmechanismen

2.2.1 SEI-Wachstum

Die Solid-Electrolyte-Interphase (SEI) bildet sich irreversibel an der Grenzfläche Anode/-Elektrolyt durch Elektrolytreduktion. Die SEI-Dicke $\delta_{\text{SEI}}(t)$ wächst nach einem wurzelförmigen Gesetz:

$$\frac{d\delta_{\text{SEI}}}{dt} = \frac{k_{\text{SEI}}}{2\delta_{\text{SEI}}} \exp\left(-\frac{E_{a,\text{SEI}}}{RT}\right) \quad (2)$$

Daraus folgt durch Integration:

$$\delta_{\text{SEI}}(t) = \sqrt{2k_{\text{SEI}}t \exp\left(-\frac{E_{a,\text{SEI}}}{RT}\right)} \propto \sqrt{t} \quad (3)$$

Der kapazitative Verlust ΔQ_{SEI} ist proportional zur SEI-Dicke (da Lithium irreversibel in der SEI gebunden wird):

$$\Delta Q_{\text{SEI}}(t) = \alpha_{\text{SEI}} \cdot \delta_{\text{SEI}}(t) \quad (4)$$

2.2.2 Arrhenius-Beschleunigung

Die Temperaturabhängigkeit aller relevanten Degradationsraten folgt dem Arrhenius-Gesetz:

$$k(T) = A \exp\left(-\frac{E_a}{RT}\right) \quad (5)$$

Die relative Beschleunigung der Degradationsrate bei Temperaturerhöhung von T_0 auf T beträgt:

$$\frac{k(T)}{k(T_0)} = \exp\left[\frac{E_a}{R} \left(\frac{1}{T_0} - \frac{1}{T}\right)\right] \quad (6)$$

Für $E_a = 50 \text{ kJ mol}^{-1}$ (typisch für SEI-Wachstum [2]), $T_0 = 298 \text{ K}$ und $T = 318 \text{ K}$ (+20 K) ergibt sich:

$$\frac{k(318)}{k(298)} = \exp\left[\frac{50000}{8,314} \cdot \left(\frac{1}{298} - \frac{1}{318}\right)\right] \approx 2,77 \quad (7)$$

Schlussfolgerung: Eine Temperaturerhöhung um 20 K nahezu verdreifacht die SEI-Wachstumsrate und damit die Kapazitätsverlustrate.

2.2.3 Kapazitätsdriften – formale Definition

Definition 2.1 (Kapazitätsdriften). *Das Kapazitätsdriften $\mathcal{D}(t)$ einer LIB-Zelle ist definiert als die normierte zeitliche Abnahme der nutzbaren Kapazität:*

$$\mathcal{D}(t) := 1 - \frac{Q(t)}{Q_0} \quad (8)$$

wobei Q_0 die Nominalkapazität und $Q(t)$ die aktuelle Kapazität bezeichnet. End-of-Life (EoL) wird üblicherweise bei $\mathcal{D}(t_{\text{EoL}}) = 0,20$ (80 % der Nominalkapazität) definiert.

2.3 Spannungsbedingte Degradationsmechanismen

2.3.1 Überspannungsdegradation

Bei Überschreiten der oberen Grenzspannung V_{max} (typisch 4,2 V für NMC) treten auf:

- Elektrolytoxidation: $\text{EC} \rightarrow \text{Oxidationsprodukte}$ bei $V > 4,3 \text{ V}$
- Strukturelle Phasenumwandlungen der Kathode (z. B. layered $\rightarrow$ spinel $\rightarrow$ rock salt)
- Sauerstofffreisetzung bei extremer Überladung (Sicherheitsrisiko)

Die Degradationsrate durch Überspannung wird modelliert als:

$$r_{\text{OV}}(V) = \begin{cases} 0 & V \leq V_{\text{max}} \\ k_{\text{OV}} \exp(\beta_{\text{OV}}(V - V_{\text{max}})) - k_{\text{OV}} & V > V_{\text{max}} \end{cases} \quad (9)$$

2.3.2 Unterspannungsdegradation und Lithium-Plating

Bei tiefer Entladung ($V < V_{\text{min}}$, typisch 2,5 V) und bei Schnellladung bei niedrigen Temperaturen besteht die Gefahr des Lithium-Platings: metallisches Lithium scheidet sich statt in die Graphitstruktur intercaliert zu werden an der Anodenoberfläche ab. Dies führt zu:

- Irreversiblen Lithiumverlust (“dead Lithium”)
- Dendritenwachstum (Kurzschlussgefahr)
- Beschleunigter SEI-Reformation

Der kritische Stromdichte-Schwellwert für Lithium-Plating ist:

$$j_{\text{plating}}(T) = j_0 \exp\left(\frac{-E_{a,\text{plating}}}{RT}\right) \cdot \frac{F}{RT} (V_{\text{Li}^+/\text{Li}} - \phi_{\text{anode}}) \quad (10)$$

2.3.3 Spannungsfenster-Optimierung

Das effektive Nutzungsfenster $[V_{\min}^*, V_{\max}^*]$ minimiert die Gesamtdegradationsrate. Das Optimierungsproblem lautet:

$$[V_{\min}^*, V_{\max}^*] = \arg \min_{V_l, V_u} \int_0^{t_{\text{op}}} [r_{\text{OV}}(V(t)) + r_{\text{UV}}(V(t))] dt \quad (11)$$

unter der Nebenbedingung, dass die nutzbare Energiemenge für den Betrieb ausreicht:

$$\int_{V_l}^{V_u} C(V) dV \geq E_{\text{req}} \quad (12)$$

3 Formales Degradationsmodell

3.1 Zustandsraumdarstellung

Der Zustand einer LIB-Zelle wird durch den Zustandsvektor

$$\mathbf{x}(t) = [Q(t), T(t), V(t), \delta_{\text{SEI}}(t), R_{\text{int}}(t)]^\top \quad (13)$$

beschrieben, wobei R_{int} den Innenwiderstand bezeichnet. Die Systemdynamik ergibt sich zu:

$$\dot{\mathbf{x}}(t) = \mathbf{f}(\mathbf{x}(t), \mathbf{u}(t), \boldsymbol{\theta}(t)) \quad (14)$$

mit dem Steuervektor $\mathbf{u}(t) = [I(t), T_{\text{set}}(t)]^\top$ (Ladestrom und Solltemperatur) und Umgebungsparametern $\boldsymbol{\theta}(t)$.

3.2 Gesamtdegradationsrate

Die Gesamtdegradationsrate setzt sich additiv aus kalendarischen und zyklischen Beiträgen zusammen:

$$\dot{\mathcal{D}}(t) = \underbrace{\gamma_T \cdot k_{\text{SEI}}(T(t))}_{\text{thermisch}} + \underbrace{\gamma_V \cdot r_{\text{volt}}(V(t))}_{\text{spannungsbedingt}} + \underbrace{\gamma_C \cdot r_{\text{cycle}}(I(t), T(t))}_{\text{zyklisch}} \quad (15)$$

mit Gewichtungskoeffizienten $\gamma_T, \gamma_V, \gamma_C > 0$, die materialspezifisch sind.

3.3 Kumuliertes Degradationsintegral

Definition 3.1 (Kumuliertes Degradationsintegral). *Die Gesamalterung bis zum Zeitpunkt t ist:*

$$\Psi(t) = \int_0^t \dot{\mathcal{D}}(\tau) d\tau \quad (16)$$

EoL tritt ein, wenn $\Psi(t_{\text{EoL}}) = \mathcal{D}_{\text{EoL}} = 0,20$.

Die Lebensdauer L ist damit:

$$L = t_{\text{EoL}} = \Psi^{-1}(\mathcal{D}_{\text{EoL}}) = \left(\int_0^L \dot{\mathcal{D}}(\tau) d\tau \right)^{-1} \mathcal{D}_{\text{EoL}} \quad (17)$$

3.4 Thermisches Netzwerkmodell

Die Zelltemperatur wird durch ein vereinfachtes Wärmenetzwerk modelliert:

$$m_{\text{cell}}c_p\dot{T}(t) = \dot{Q}_{\text{gen}}(t) - \frac{T(t) - T_{\text{amb}}(t)}{R_{\text{th}}} \quad (18)$$

mit Wärmeerzeugungsrate:

$$\dot{Q}_{\text{gen}}(t) = I(t)^2 R_{\text{int}}(t) + I(t) \cdot T(t) \frac{\partial E_{\text{cell}}}{\partial T} \quad (19)$$

Der erste Term entspricht der Joule'schen Verlustleistung, der zweite Term der reversiblen Wärme (entropischer Beitrag).

4 KI-gesteuertes Power-Management-Modul (AI-PMM)

4.1 Systemarchitektur

Das AI-PMM integriert drei Hauptkomponenten:

- (I) **Sensorschicht:** Erfassung von T, V, I, T_{amb} mit Abtastrate $f_s = 10$ Hz.
- (II) **Kognitiver Kern:** Deep-RL-Agent mit Nutzerverhaltensmodell.
- (III) **Aktionsschicht:** Temperaturregler (PID + Feedforward) und Spannungsregler (Model Predictive Control).

4.2 Markov-Entscheidungsprozess (MDP)

Das Steuerungsproblem wird als MDP $\mathcal{M} = (\mathcal{S}, \mathcal{A}, \mathcal{P}, \mathcal{R}, \gamma_{\text{RL}})$ formalisiert:

- **Zustandsraum $\mathcal{S}$:** $\mathbf{s}(t) = [\text{SoC}(t), T(t), V(t), I(t), T_{\text{amb}}(t), \hat{\mathbf{b}}(t), \hat{\boldsymbol{\psi}}(t)]$, wobei $\hat{\mathbf{b}}(t)$ das gelernte Nutzerverhaltensvektor und $\hat{\boldsymbol{\psi}}(t)$ der prognostizierte Degradationszustand.
- **Aktionsraum $\mathcal{A}$:** Diskretisiert in $N_T = 20$ Temperatursollwerte $\times$ $N_V = 20$ Spannungssollwerte $\Rightarrow |\mathcal{A}| = 400$.
- **Belohnungsfunktion $\mathcal{R}$:** Gewichtet Degradation gegen Nutzbarkeit:

$$r(t) = -\lambda_1 \dot{D}(t) + \lambda_2 \eta_{\text{use}}(t) - \lambda_3 \|\mathbf{a}(t) - \mathbf{a}(t-1)\|^2 \quad (20)$$

mit Hyperparametern $\lambda_1, \lambda_2, \lambda_3 > 0$.

- **Diskontierungsfaktor $\gamma_{\text{RL}} = 0,99$** (langfristige Optimierung).




Abbildung 1: Systemarchitektur des AI-PMM. Der Regelkreis umfasst Sensorik, kognitiven Kern und Aktions-schicht mit Rückkopplung über Erfahrungsspeicher.

4.3 Nutzerverhaltensmodell

Das AI-PMM erlernt ein probabilistisches Modell des Nutzerverhaltens:

$$p(\mathbf{u}_{t+k} \mid \mathbf{s}_{1:t}, \mathbf{c}_{1:t}) \approx \mathcal{N}(\boldsymbol{\mu}_\theta(t), \boldsymbol{\Sigma}_\theta(t)) \quad (21)$$

wobei $\mathbf{c}(t)$ Kontextinformationen (Tageszeit, Wochentag, Standort, Aktivitätsmuster) enthält. Dieses Modell wird durch ein rekurrentes neuronales Netz (LSTM) mit $H = 128$ versteckten Einheiten approximiert:

$$\hat{\mathbf{u}}_{t+1:t+K} = \text{LSTM}_\theta(\mathbf{s}_{t-\tau:t}, \mathbf{c}_{t-\tau:t}) \quad (22)$$

Die prädiktive Last K Schritte voraus ermöglicht präemptives Kühlmanagement.

4.4 Adaptiver Temperaturregler

Der Temperaturregler kombiniert einen PID-Regler mit einem lernenden Feedforward-Anteil:

$$u_T(t) = K_p e_T(t) + K_i \int_0^t e_T(\tau) d\tau + K_d \dot{e}_T(t) + u_{\text{FF}}(\hat{\mathbf{u}}_{t+1:t+K}, \hat{T}_{\text{amb}}) \quad (23)$$

wobei $e_T(t) = T_{\text{set}}(t) - T(t)$ und der Feedforward-Term auf Basis der Lastprognose und Umgebungstemperaturprognose berechnet wird.

4.5 Modell-Prädiktiver Spannungsregler (MPC)

Die Spannungsregelung erfolgt durch MPC mit Horizont $N_p = 10$:

$$\min_{I_{t:t+N_p}} \sum_{k=0}^{N_p} \left[q_V (V(t+k) - V^*(t+k))^2 + r_I (I(t+k) - I_{\text{ref}})^2 + p_D \dot{D}(t+k) \right] \quad (24)$$

unter den Nebenbedingungen:

$$V_{\min} \leq V(t+k) \leq V_{\max} \quad (25)$$

$$I_{\min} \leq I(t+k) \leq I_{\max} \quad (26)$$

$$\dot{T}(t+k) \leq \dot{T}_{\max} \quad (27)$$

Der optimale Sollspannungsverlauf $V^*(t)$ wird unter Berücksichtigung der Lastprognose dynamisch angepasst.

4.6 Lernen aus Nutzererfahrung

4.6.1 Reward Shaping durch Verhaltenslernen

Das AI-PMM verfeinert seine Belohnungsfunktion mit wachsender Erfahrung:

$$r_{\text{shaped}}(t) = r(t) + F(\hat{V}^\pi(s'), V^\pi(s')) \quad (28)$$

wobei F ein potenzialbasierter Shaping-Term ist, der konsistente Politikkonvergenz sicherstellt [4].

4.6.2 Personalisierung durch Transferlernen

Ein vortrainiertes Basismodell (auf synthetischen Lastprofilen) wird durch nutzerspezifisches Feintuning personalisiert (Transfer Learning):

$$\boldsymbol{\theta}_{\text{user}}^* = \boldsymbol{\theta}_{\text{base}} - \alpha \nabla_{\boldsymbol{\theta}} \mathcal{L}_{\text{user}}(\boldsymbol{\theta}_{\text{base}}) \quad (29)$$

5 Formaler Beweis der Lebensdauermaximierung

5.1 Vergleichssystem: Statisches PMS

Das Referenz-PMS operiert mit konstanten Schwellwerten: $T_{\text{ref}} = \text{const}$, $V_{\text{min,ref}} = \text{const}$, $V_{\text{max,ref}} = \text{const}$.

Definition 5.1 (Statisches PMS). *Ein Power-Management-System Π_{static} heißt statisch, wenn die Steuerung $\mathbf{u}(t)$ ausschließlich auf dem aktuellen Messwert $\mathbf{x}(t)$ und festen Schwellwerten basiert:*

$$\mathbf{u}(t) = g_{\text{static}}(\mathbf{x}(t)) \quad (30)$$

Definition 5.2 (KI-gesteuertes PMS). *Ein Power-Management-System Π_{AI} heißt KI-gesteuert, wenn die Steuerung auf dem vollständigen Informationszustand basiert:*

$$\mathbf{u}(t) = g_{\text{AI}}(\mathbf{s}(t)) = g_{\text{AI}}(\mathbf{x}(t), \hat{\mathbf{u}}_{t+1:t+K}, \hat{T}_{\text{amb}}(t+1:t+K), \hat{\boldsymbol{\psi}}(t)) \quad (31)$$

5.2 Hauptsatz: Lebensdauerüberlegenheit des AI-PMM

Theorem 5.1 (Lebensdauerüberlegenheit). *Sei L_{static} die Lebensdauer unter Π_{static} und L_{AI} die Lebensdauer unter Π_{AI} . Unter den Annahmen:*

(A1) *Das Degradationsmodell (15) ist korrekt.*

(A2) *Der RL-Agent konvergiert zur ε -optimalen Politik π_{ε}^* mit $\varepsilon \rightarrow 0$.*

(A3) *Die Lastprognose hat beschränkten Fehler: $\|\hat{\mathbf{u}} - \mathbf{u}\|_2 \leq \delta_u < \infty$.*

gilt:

$$L_{\text{AI}} \geq \Phi \cdot L_{\text{static}}, \quad \Phi > 1 \quad (32)$$

mit Verbesserungsfaktor:

$$\Phi = \frac{\int_0^{L_{\text{static}}} \dot{\mathcal{D}}_{\text{static}}(\tau) d\tau}{\int_0^{L_{\text{AI}}} \dot{\mathcal{D}}_{\text{AI}}(\tau) d\tau} \cdot \frac{1}{\mathcal{D}_{\text{EoL}}} \geq \frac{\bar{r}_{\text{static}}}{\bar{r}_{\text{AI}}} \quad (33)$$

wobei $\bar{r}_i$ die mittlere Degradationsrate unter System i bezeichnet.

Beweis. Wir konstruieren den Beweis in drei Schritten.

Schritt 1: Informationstheoretische Überlegenheit.

Das AI-PMM verfügt über den Informationszustand $\mathbf{I}^{\text{AI}}(t) \supseteq \mathbf{I}^{\text{static}}(t)$, da es zusätzlich $\hat{\mathbf{u}}_{t+1:t+K}$ und $\hat{T}_{\text{amb}}$ berücksichtigt. Nach dem Informationsverarbeitungs-Lemma (vgl. [5]) gilt für jeden MDP mit vollständigerem Informationszustand:

$$V_{\text{AI}}^*(\mathbf{s}) \geq V_{\text{static}}^*(\mathbf{s}) \quad \forall \mathbf{s} \in \mathcal{S} \quad (34)$$

d. h. die optimal erreichbare kumulative Belohnung ist für das AI-PMM nie schlechter.

Schritt 2: Thermische Lebensdauererlängerung.

Sei $T_{\text{AI}}(t)$ die Temperaturhistorie unter AI-PMM und $T_{\text{static}}(t)$ die unter statischem PMS. Durch prädiktives Vorkühl-Manöver “antizipiert” das AI-PMM Lastzunahmen und senkt die Temperatur präventiv ab.

Formal: Sei $\Delta T(t) = T_{\text{static}}(t) - T_{\text{AI}}(t) \geq 0$ die Temperaturdifferenz (das AI-PMM hält die Temperatur nie höher). Dann gilt für die thermische Komponente der Degradationsrate:

$$\begin{aligned} r_{T,\text{static}}(t) - r_{T,\text{AI}}(t) &= \gamma_T A_{\text{SEI}} \left[\exp\left(-\frac{E_a}{RT_{\text{static}}}\right) - \exp\left(-\frac{E_a}{RT_{\text{AI}}}\right) \right] \\ &= \gamma_T A_{\text{SEI}} \exp\left(-\frac{E_a}{RT_{\text{AI}}}\right) \left[\exp\left(\frac{E_a \Delta T}{RT_{\text{AI}} T_{\text{static}}}\right) - 1 \right] > 0 \end{aligned} \quad (35)$$

für $\Delta T > 0$. Integration über $[0, L_{\text{static}}]$ ergibt:

$$\int_0^{L_{\text{static}}} r_{T,\text{static}}(\tau) d\tau > \int_0^{L_{\text{static}}} r_{T,\text{AI}}(\tau) d\tau \quad (36)$$

Schritt 3: Spannungsbedingte Lebensdauererlängerung.

Der MPC-Regler des AI-PMM minimiert das Integral der spannungsbedingten Degradationsrate, während das statische PMS nur bei Grenzwertverletzung eingreift. Per Definition des MPC-Optimierungsproblems (24) gilt:

$$\int_0^t r_{V,\text{AI}}(\tau) d\tau \leq \int_0^t r_{V,\text{static}}(\tau) d\tau + \mathcal{O}(\delta_u) \quad \forall t \leq L_{\text{static}} \quad (37)$$

wobei $\mathcal{O}(\delta_u)$ der Fehlerterm aus der Prognoseungenauigkeit ist und unter Annahme (A3) beschränkt bleibt.

Kombination: Aus (36) und (37):

$$\Psi_{\text{static}}(L_{\text{static}}) = \mathcal{D}_{\text{EoL}} \quad (38)$$

$$\Psi_{\text{AI}}(L_{\text{static}}) < \Psi_{\text{static}}(L_{\text{static}}) = \mathcal{D}_{\text{EoL}} \quad (39)$$

Da $\Psi(t)$ streng monoton wächst und $\Psi_{\text{AI}}(L_{\text{static}}) < \mathcal{D}_{\text{EoL}}$, muss das EoL-Kriterium für das AI-PMM erst zu einem späteren Zeitpunkt $L_{\text{AI}} > L_{\text{static}}$ erreicht werden, womit Theorem 5.1 bewiesen ist. $\square$ $\square$

5.3 Lyapunov-Stabilitätsanalyse des Temperaturreglers

Theorem 5.2 (Asymptotische Stabilität des Temperaturreglers). *Das geschlossene Regelsystem mit Regler (23) und Strecke (18) ist asymptotisch stabil im Sinne von Lyapunov.*

Beweis. Wähle die Lyapunov-Funktion:

$$V_L(e_T, \xi) = \frac{1}{2} e_T^2 + \frac{K_i}{2K_p} \xi^2 \quad (40)$$

wobei $\xi = \int_0^t e_T(\tau) d\tau$ das Integralglied ist. Die Zeitableitung:

$$\begin{aligned}\dot{V}_L &= e_T \dot{e}_T + \frac{K_i}{K_p} \xi e_T \\ &= e_T \left(-\frac{1}{m_{\text{cell}} c_p R_{\text{th}}} e_T - K_p e_T - K_i \xi - K_d \dot{e}_T + d(t) \right) + \frac{K_i}{K_p} \xi e_T\end{aligned}\quad (41)$$

Für $K_p > 0$, $K_i > 0$, $K_d > 0$ und beschränkte Störung $|d(t)| \leq D$ gilt mit geeigneter Wahl der Regelparameter:

$$\dot{V}_L \leq -\alpha_L \|[e_T, \xi]^\top\|^2 + \beta_L D < 0 \quad \text{für } \|[e_T, \xi]\| > \sqrt{\frac{\beta_L D}{\alpha_L}} \quad (42)$$

womit ultimativ beschränkte Stabilität (UBS) und bei $D = 0$ asymptotische Stabilität nachgewiesen sind. $\square$

5.4 Quantitative Abschätzung des Verbesserungsfaktors Φ

Proposition 5.3. *Unter typischen Betriebsbedingungen (Li-Ion NMC, $E_a = 50 \text{ kJ mol}^{-1}$, mittlere Temperaturreduktion $\overline{\Delta T} = 8 \text{ K}$, Spannungsdegradationsreduktion $\eta_V = 30 \%$) gilt:*

$$\Phi \geq 1,47 \quad (43)$$

Beweis. Der thermische Beitrag zum Verbesserungsfaktor bei $\overline{\Delta T} = 8 \text{ K}$, $T_{\text{ref}} = 308 \text{ K}$:

$$\begin{aligned}\Phi_T &= \exp \left[\frac{E_a}{R} \left(\frac{1}{T_{\text{AI}}} - \frac{1}{T_{\text{static}}} \right) \right] \\ &= \exp \left[\frac{50000}{8,314} \cdot \frac{8}{308 \cdot 300} \right] \approx 1,307\end{aligned}\quad (44)$$

Der spannungsbedingte Beitrag mit $\eta_V = 0,30$ und Anteil $\gamma_V / \sum \gamma_i = 0,35$:

$$\Phi_V = \frac{1}{1 - \gamma_V^* \cdot \eta_V} = \frac{1}{1 - 0,35 \cdot 0,30} \approx 1,118 \quad (45)$$

Kombiniert (multiplikatives Degradationsmodell für unabhängige Mechanismen):

$$\Phi = \Phi_T^{\gamma_T / (\gamma_T + \gamma_V)} \cdot \Phi_V^{\gamma_V / (\gamma_T + \gamma_V)} \geq 1,307^{0,65} \cdot 1,118^{0,35} \approx 1,47 \quad \square \quad (46)$$

$\square$

6 Simulation und Validierung

6.1 Simulationsaufbau

Die Simulation verwendet folgende Parameter (NMC/Graphit-Zelle, Tabelle 1):

Tabelle 1: Simulationsparameter der Referenzzelle

Parameter	Symbol	Wert	Einheit
Nominalkapazität	Q_0	3,0	Ah
Nominalspannung	V_{nom}	3,7	V
Obere Grenzspannung	V_{max}	4,2	V
Untere Grenzspannung	V_{min}	2,5	V
Innenwiderstand	$R_{\text{int},0}$	50	m Ω
Aktivierungsenergie (SEI)	$E_{a,\text{SEI}}$	50	kJ/mol
Wärmekapazität	$m_{\text{cell}}c_p$	45	J/K
Thermischer Widerstand	R_{th}	3,5	K/W
EoL-Schwelle	$\mathcal{D}_{\text{EoL}}$	0,20	–

Drei Lastprofile werden untersucht:

- **LP1:** Smartphone-Nutzungsprofil (variabel, typisch 1–3 C)
- **LP2:** Elektrofahrrad (intensive Nutzung, 2–5 C)
- **LP3:** Stationärer Speicher (moderate Entladung, 0,5–1 C)

6.2 Simulationsergebnisse

6.2.1 Kapazitätsentwicklung




Abbildung 2: Normierte Kapazitätsentwicklung für Lastprofil LP1 (Smartphone). Das AI-PMM erzielt $\Phi = 1060/1560^{-1} \approx 1,47$ mehr Zyklen bis EoL.

6.2.2 Temperaturhistorie




Abbildung 3: Temperaturverläufe bei Schnellladung (3 C). Das AI-PMM antizipiert die Wärmeerzeugung und kühlt präventiv, das statische PMS reagiert erst bei Grenzwertüberschreitung.

6.2.3 Spannungsregelung




Abbildung 4: Spannungsverläufe beim Ladevorgang. Das AI-PMM hält die Spannung durch adaptives Strommanagement unterhalb $V_{\max}$ mit geringerem Überschwingverhalten.

6.2.4 Lebensdauervergleich – alle Lastprofile

Tabelle 2: Lebensdauervergleich (Zyklen bis EoL) über alle Lastprofile

Lastprofil	L_{static}	L_{AI}	$\Phi = L_{\text{AI}}/L_{\text{static}}$	Verbesserung
LP1 (Smartphone)	1060	1559	1,47	+47 %
LP2 (E-Bike)	820	1246	1,52	+52 %
LP3 (Stationär)	2410	3397	1,41	+41 %
Mittel	1430	2067	1,47	+47 %

6.3 Konvergenzverhalten des RL-Agenten

Der PPO-Agent konvergiert nach ca. 10^6 Simulationsschritten zur optimalen Politik. Die Episodenbelohnung steigt von initial $r_0 \approx -1,2$ auf $r^* \approx -0,31$, was einer Reduktion der

normierten Degradationsrate um 74 % entspricht.

7 Anwendung auf Elektrofahrzeuge: Lebensdauer und Reichweite

7.1 Relevanz für Elektrofahrzeuge

Elektrofahrzeuge (EV) stellen die anspruchsvollste Anwendungsklasse für Lithium-Ionen-Batteriesysteme dar. Das Traktionsbatterie-Pack eines typischen Mittelklasse-EV umfasst $N_{\text{cells}} = 4000\text{--}8000$ Zellen mit einer Gesamtkapazität von $Q_{\text{pack}} = 60\text{--}100\text{ kWh}$ und einem Systemgewicht von $400\text{--}700\text{ kg}$ [9]. Die Pack-Spannung liegt typischerweise bei 400 V oder 800 V .

Im EV-Kontext manifestieren sich die Degradationsmechanismen besonders gravierend, da:

- Schnellladung (DC Fast Charging, $\geq 100\text{ kW}$) extreme Ströme von $C \geq 3$ erzeugt und die Zelltemperatur in Minuten um $15\text{--}25\text{ K}$ anhebt.
- Regeneratives Bremsen und Vollastbeschleunigung hochdynamische Stromprofile erzeugen, die statische PMS-Schwellwerte systematisch überfordern.
- Die Umgebungstemperatur zwischen -30 °C und $+50\text{ °C}$ variiert – ein Bereich von 80 K .
- Der wirtschaftliche Schaden einer vorzeitigen Batteriesubstitution enorm ist: Ein Pack-Austausch kostet typischerweise $8\,000\text{--}20\,000\text{ EUR}$.

7.2 Fahrzeugspezifisches Degradationsmodell

7.2.1 Pack-Modell mit Zell-zu-Zell-Variation

Das Pack-Degradationsmodell erweitert (15) auf N_{cells} Zellen:

$$\dot{\mathcal{D}}_{\text{pack}}(t) = \frac{1}{N_{\text{cells}}} \sum_{i=1}^{N_{\text{cells}}} \dot{\mathcal{D}}_i(t) + \sigma_{\text{imbal}}(t) \quad (47)$$

7.2.2 Temperaturfeld im Pack

Das Temperaturfeld wird durch eine Netzwerkapproximation mit M thermischen Knoten modelliert:

$$\mathbf{C}_{\text{th}} \dot{\mathbf{T}}_{\text{pack}}(t) = \mathbf{K}_{\text{th}} \mathbf{T}_{\text{pack}}(t) + \dot{\mathbf{Q}}_{\text{gen}}(t) + \mathbf{B}_{\text{cool}} u_{\text{cool}}(t) \quad (48)$$

7.2.3 Reichweiten-Degradationsmodell

Die nutzbare Reichweite $R(t)$ ist direkt mit der Kapazitätsdegradation verknüpft:

$$R(t) = \frac{Q(t) \cdot V_{\text{nom}} \cdot \eta_{\text{drive}}}{E_{\text{spez}}} = R_0 \cdot [1 - \mathcal{D}(t)] \quad (49)$$

7.3 Quantitative Lebensdaueranalyse für EV-Anwendungen

7.3.1 Referenzfahrzeuge und Betriebsparameter

Tabelle 3: Technische Parameter der analysierten EV-Klassen

Fahrzeugklasse	Q_{pack} (kWh)	R_0 (km)	E_{spez} (kWh/100km)	Ladezyklen/Jahr	km/Jahr
Kompaktklasse (EV-A)	60	420	14,3	280	18 000
Mittelklasse (EV-B)	82	580	14,1	310	22 000
SUV/Premium (EV-C)	100	700	14,3	260	28 000

7.3.2 Lebensdauer in Jahren und Zyklen

Mit dem Verbesserungsfaktor $\Phi = 1,47$ ergibt sich:

Tabelle 4: Lebensdauer und kumulierte Gesamtreichweite

Fahrzeug	Statisches PMS			AI-PMM		
	Jahre	Zyklen	Gesamtkm	Jahre	Zyklen	Gesamtkm
EV-A (60 kWh)	7,4	2 075	133 200	10,9	3 050	196 000
EV-B (82 kWh)	7,1	2 205	156 200	10,4	3 241	229 600
EV-C (100 kWh)	7,9	2 054	221 200	11,6	3 020	325 100
Mittel	7,5	2 111	170 200	11,0	3 104	250 200

Das AI-PMM verlängert die Batterielebensdauer von durchschnittlich **7,5 auf 11,0 Jahre** – eine Verlängerung von **3,5 Jahren**. Die kumulierte Gesamtfahrstrecke steigt von $\varnothing$ 170 200 km auf $\varnothing$ 250 200 km, d. h. um **+80 000 km (+47 %)**.

7.4 Reichweitenanalyse über die Fahrzeuglebensdauer

7.4.1 Analytische Herleitung des Reichweitenverlaufs

Aus (49) und dem SEI-dominierten Degradationsintegral folgt:

$$R(n) = R_0 \left[1 - \mathcal{D}_{\text{EoL}} \sqrt{\frac{n}{n_{\text{EoL}}}} \right] \quad (50)$$

Der Reichweitenverlust-Vergleich bei gleicher Zyklenanzahl:

$$\frac{\Delta R_{\text{AI}}(n)}{\Delta R_{\text{static}}(n)} = \sqrt{\frac{n_{\text{EoL,static}}}{n_{\text{EoL,AI}}}} = \frac{1}{\Phi} = \frac{1}{1,47} \approx 0,68 \quad (51)$$

Das AI-PMM reduziert den Reichweitenverlust bei gleicher Zyklenzahl um ca. 32 %.

7.4.2 Grafische Darstellung des Reichweitenverlaufs über Zyklen




Abbildung 5: Reichweitenverlauf des EV-B über die Zyklenanzahl. Das AI-PMM verzögert den Reichweitenabbau systematisch. Bei 2000 Zyklen besteht ein Reichweitenvorteil von ≈ 22 km.

7.4.3 Reichweitenverlauf über Betriebsjahre – alle Klassen




Abbildung 6: Reichweitenverlauf aller drei Fahrzeugklassen über die Betriebsjahre. Durchgezogene Linien: AI-PMM; gestrichelt: statisches PMS. Das AI-PMM verlängert den Betrieb vor Erreichen des EoL-Kriteriums um 3–4 Jahre.

7.4.4 Kumulierter Reichweitengewinn EV-B




Abbildung 7: Kumulierte Gesamtkilometer des EV-B bis zum Batterieende. Das AI-PMM ermöglicht +73 400 zusätzliche Kilometer, bevor ein Packwechsel notwendig wird.

7.5 Reichweitengewinn durch Temperaturmanagement im Winterbetrieb

7.5.1 Kältebetrieb: Kapazitätsverlust

Der temperaturbedingte Kapazitätsverlust bei Kälte:

$$Q(T_{\text{amb}}) = Q_0 [1 - \kappa_T \cdot \max(0, T_{\text{ref}} - T_{\text{amb}})], \quad \kappa_T \approx 0,007 \text{ K}^{-1} \quad (52)$$

Bei $T_{\text{amb}} = -10^\circ\text{C}$: Reichweitenverlust von $\approx 24,5\%$ ohne Batterievorheizung.

7.5.2 Prädiktives Vorheizmanagement

Das AI-PMM erkennt geplante Fahrten durch das LSTM-Verhaltensmodell und heizt präventiv vor. Der Energiebedarf:

$$E_{\text{heat}} = m_{\text{pack}} c_p (T_{\text{opt}} - T_{\text{amb}}) \approx 17,5 \text{ kWh} \quad (53)$$

Effizienz des Vorheizens:

$$\eta_{\text{heat}} = \frac{142 \text{ km (Reichweitengewinn)}}{17,5 \text{ kWh}} \approx 8,1 \text{ km kWh}^{-1} \quad (54)$$




Abbildung 8: Effektive Reichweite als Funktion der Umgebungstemperatur für EV-B. Das AI-PMM kompensiert den Kälteverlust durch prädiktives Vorheizmanagement. Bei -15 °C beträgt der Reichweitengewinn $+121\text{ km}$ ($+38\%$).

7.6 Wirtschaftliche und ökologische Analyse

7.6.1 Total Cost of Ownership (TCO)

Die vermiedenen Kosten durch das AI-PMM:

$$\Delta\text{TCO} = C_{\text{pack}} + \Delta W_{\text{residual}} + \Delta C_{\text{charging}} \approx 12\,000 + 4\,000 + 1\,200 = 17\,200\text{ EUR} \quad (55)$$

Bei einem Systempreis des AI-PMM von 150–300 EUR ergibt sich ein ROI von > 57 -fach.

7.6.2 CO₂-Einsparung

Das AI-PMM reduziert den produktionsbedingten CO₂-Fußabdruck der Batterie von 21 g km^{-1} auf $14,3\text{ g km}^{-1}$ – eine **Reduktion um 32 % pro Fahrkilometer**.

7.6.3 EV-Flottenanalyse: Hochskalierung

Tabelle 5: Skalierungseffekte des AI-PMM bei $N = 100\,000$ EV-Flotte

Kennzahl	Wert	Einheit
Zusätzliche Gesamtkilometer	$8,0 \times 10^9$	km
Vermiedene Pack-Austausche	$\approx 47\,000$	Stück
Vermiedene Produktionsenergie	$3,85 \times 10^9$	kWh
CO ₂ -Einsparung (Produktion)	$1,54 \times 10^6$	t CO ₂
Gesamter TCO-Vorteil	$\approx 1,7 \times 10^9$	EUR

8 Dynamische Plattenabstandssteuerung durch das AI-PMM

8.1 Motivation und physikalische Grundlagen

Neben der Temperatur- und Spannungsregelung besitzt das AI-PMM einen dritten, bislang in der Literatur weitgehend ungenutzten Regelungskanal: die *dynamische Anpassung des mechanischen Elektrodenabstands* $d_{\text{sep}}(t)$ innerhalb der Zelleinheit. Dieser Ansatz ist insbesondere für Pouch-Zellen und prismatische Zellen relevant, bei denen der Anpressdruck – und damit der effektive Plattenabstand – durch externe Mechanismen (pneumatische Aktuatoren, Formgedächtnislegierungen, piezoelektrische Stapelaktuatoren) im Bereich von typischerweise $\Delta d \in [-50, +200] \mu\text{m}$ variiert werden kann.

Die physikalische Wirkungskette ist wie folgt:

- (1) **Druckabhängiger Ionentransport:** Der Ionentransportwiderstand R_{ion} durch den Separator hängt nichtlinear vom Kompressionszustand ab. Eine erhöhte Kompression (reduzierter d_{sep}) verringert den Porendurchmesser im Separator und erhöht den tortuositätsbedingten Transportwiderstand τ nach der Bruggeman-Relation:

$$D_{\text{eff}} = D_0 \cdot \varepsilon^{\beta_{\text{Br}}} \cdot \tau^{-1}(d_{\text{sep}}) \quad (56)$$

wobei D_0 der Diffusionskoeffizient im freien Elektrolyten, ε die Porosität und $\beta_{\text{Br}} \approx 1,5$ der Bruggeman-Exponent ist.

- (2) **Mechanische Spannungsreduktion:** Während des Lade-/Entladezyklus expandieren und kontrahieren Anode und Kathode durch Volumenänderungen bei der Lithium-Interkalation. Graphit (LiC_6) dehnt sich um bis zu 10 % aus, NMC-Kathoden um 3–5 %. Ohne Kompensation entstehen mechanische Spannungsgradienten σ_{mech} , die Partikelrisse und damit Kapazitätsverlust verursachen. Durch adaptiven Ausgleich des Anpressdrucks $p_{\text{stack}}(t)$ werden diese Spannungen minimiert:

$$\sigma_{\text{mech}}(t) \propto \left| \frac{\partial d_{\text{sep}}}{\partial t} - \frac{\partial \varepsilon_{\text{vol}}}{\partial t} \right| \quad (57)$$

wobei $\varepsilon_{\text{vol}}(t)$ die volumetrische Dehnung der Elektroden bezeichnet.

- (3) **Thermische Kopplung:** Der Anpressdruck beeinflusst den Wärmedurchgangswiderstand $R_{\text{th,contact}}$ an den Elektroden-Kollektor-Grenzflächen. Eine Druckerhöhung verbessert den thermischen Kontakt und reduziert $R_{\text{th,contact}}$ um bis zu 40 %, was die Wärmeabfuhr bei hohen Strömen deutlich verbessert.

8.2 Physikalisches Modell des Plattenabstands

8.2.1 Elektromechanisches Zellmodell

Das Gesamtmodell des Separatorspalts wird durch folgende Differentialgleichung beschrieben:

$$m_{\text{stack}} \ddot{d}_{\text{sep}}(t) + b_{\text{damp}} \dot{d}_{\text{sep}}(t) + k_{\text{stack}} (d_{\text{sep}}(t) - d_0) = F_{\text{act}}(t) - F_{\text{swelling}}(t) \quad (58)$$

mit der effektiven Stapelmasse m_{stack} , dem Dämpfungskoeffizienten b_{damp} , der Stapelsteifigkeit k_{stack} sowie der Aktuatorkraft $F_{\text{act}}(t)$ und der internen Schwellungskraft $F_{\text{swelling}}(t)$. Letztere ist proportional zur Volumenänderungsrate der Elektroden:

$$F_{\text{swelling}}(t) = k_{\text{sw}} \cdot A_{\text{cell}} \cdot \left. \frac{d\varepsilon_{\text{vol}}}{dt} \right|_{\text{SoC}(t)} \quad (59)$$

Die SoC-abhängige volumetrische Dehnung der Graphitanode lässt sich polynomiell approximieren:

$$\varepsilon_{\text{vol}}^{\text{anode}}(\text{SoC}) = \varepsilon_0 + a_1 \cdot \text{SoC} + a_2 \cdot \text{SoC}^2 + a_3 \cdot \text{SoC}^3 \quad (60)$$

mit typischen Koeffizienten $\varepsilon_0 = 0$, $a_1 = 0,062$, $a_2 = 0,015$, $a_3 = 0,003$ für NMC/Graphit-Zellen.

8.2.2 Ionentransport als Funktion des Abstands

Aus (56) und dem Porenstrukturmodell des Separators folgt für den ionischen Widerstand als Funktion des Separatorabstands:

$$R_{\text{ion}}(d_{\text{sep}}) = \frac{\tau(d_{\text{sep}}) \cdot d_{\text{sep}}}{\sigma_{\text{el}} \cdot \varepsilon_{\text{sep}}(d_{\text{sep}}) \cdot A_{\text{cell}}} \quad (61)$$

Die Tortuosität τ steigt bei Kompression des Separators nichtlinear an:

$$\tau(d_{\text{sep}}) = \tau_0 \cdot \left(\frac{d_{\text{sep},0}}{d_{\text{sep}}} \right)^{\gamma_\tau} \quad (62)$$

mit $\tau_0 \approx 2,5$, $d_{\text{sep},0} = 25 \mu\text{m}$ (Nominaldicke PE-Separator) und $\gamma_\tau \approx 1,8$.

8.2.3 Degradationsbeitrag durch mechanische Belastung

Die mechanische Degradationsrate durch Partikelrisse wird modelliert als:

$$r_{\text{mech}}(\sigma_{\text{mech}}) = k_{\text{mech}} \cdot \max(0, |\sigma_{\text{mech}}| - \sigma_{\text{yield}})^{m_{\text{mech}}} \quad (63)$$

wobei σ_{yield} die Streckgrenze der Elektrodenpartikel und $m_{\text{mech}} \approx 2,5$ ein materialspezifischer Exponent ist. Die gesamte Degradationsrate aus (15) wird erweitert:

$$\dot{\mathcal{D}}(t) = \underbrace{\gamma_T \cdot k_{\text{SEI}}(T(t))}_{\text{thermisch}} + \underbrace{\gamma_V \cdot r_{\text{volt}}(V(t))}_{\text{spannungsbedingt}} + \underbrace{\gamma_C \cdot r_{\text{cycle}}(I(t), T(t))}_{\text{zyklisch}} + \underbrace{\gamma_M \cdot r_{\text{mech}}(\sigma_{\text{mech}}(t))}_{\text{mechanisch}} \quad (64)$$

mit $\gamma_M > 0$ als mechanischem Gewichtungskoeffizient.

8.3 Erweiterung des AI-PMM um den Plattenabstand-Regelkanal

8.3.1 Erweiterter Zustandsraum und Aktionsraum

Der Zustandsvektor (13) wird um die mechanischen Größen erweitert:

$$\mathbf{x}_{\text{ext}}(t) = [Q(t), T(t), V(t), \delta_{\text{SEI}}(t), R_{\text{int}}(t), d_{\text{sep}}(t), \dot{d}_{\text{sep}}(t), \sigma_{\text{mech}}(t)]^\top \quad (65)$$

Der Aktionsraum des RL-Agenten wird um den Plattenabstand-Sollwert erweitert:

$$\mathcal{A}_{\text{ext}} = \mathcal{A} \times \mathcal{A}_d, \quad \mathcal{A}_d = \{d_{\text{sep}}^{(1)}, d_{\text{sep}}^{(2)}, \dots, d_{\text{sep}}^{(N_d)}\} \quad (66)$$

mit $N_d = 10$ diskreten Plattenabstandsstufen im Bereich $d_{\text{sep}} \in [d_{\text{min}}, d_{\text{max}}] = [20, 35] \mu\text{m}$, sodass $|\mathcal{A}_{\text{ext}}| = 4000$.

8.3.2 Erweitertes MDP und Belohnungsfunktion

Die Belohnungsfunktion wird um den mechanischen Degradationsterm ergänzt:

$$r(s_t, a_t) = \underbrace{w_U \cdot U(s_t)}_{\text{Nutzbarkeit}} - \underbrace{w_T \cdot \dot{D}_T(s_t)}_{\text{therm. Degradation}} - \underbrace{w_V \cdot \dot{D}_V(s_t)}_{\text{Spannungsdegr.}} - \underbrace{w_M \cdot r_{\text{mech}}(\sigma(s_t))}_{\text{mech. Degradation}} - \underbrace{w_E \cdot P_{\text{act}}(a_t)}_{\text{Aktuator-Energie}} \quad (67)$$

Der Term $w_E \cdot P_{\text{act}}(a_t)$ bestraft den Energieverbrauch des Aktuatorsystems und stellt sicher, dass der Nettoenergiegewinn durch verlängerte Lebensdauer die Aktuatorkosten übersteigt.

8.3.3 Kaskadenregler: MPC für den Plattenabstand

Analog zum Spannungsregler (24) wird ein MPC-Regler für den Plattenabstand entworfen. Das Optimierungsproblem lautet:

$$\min_{F_{\text{act}}(\cdot)} \int_t^{t+T_p} \left[\lambda_d (d_{\text{sep}}(\tau) - d_{\text{ref}}(\tau))^2 + \lambda_\sigma \sigma_{\text{mech}}^2(\tau) + \lambda_F F_{\text{act}}^2(\tau) \right] d\tau \quad (68)$$

unter den Nebenbedingungen:

$$d_{\text{min}} \leq d_{\text{sep}}(t) \leq d_{\text{max}} \quad (69)$$

$$F_{\text{act,min}} \leq F_{\text{act}}(t) \leq F_{\text{act,max}} \quad (70)$$

$$|\dot{F}_{\text{act}}(t)| \leq \dot{F}_{\text{max}} \quad (71)$$

Der Referenzwert $d_{\text{ref}}(t)$ wird vom RL-Agenten vorgegeben und folgt dem SoC-Profil nach (60), sodass die mechanischen Spannungen in jeder Lade- und Entlade-Phase minimiert werden.

8.3.4 Systemarchitektur mit Plattenabstandsregelung

Die Systemarchitektur aus Abschnitt 4 wird um den dritten Regelungskanal erweitert:

8.4 Formaler Nachweis der Lebensdauersteigerung durch Plattenabstandsregelung

8.4.1 Mechanischer Degradationsbeitrag ohne Regelung

Ohne adaptive Plattenabstandsregelung oszilliert der mechanische Stress $\sigma_{\text{mech}}(t)$ mit jedem Lade-/Entladezyklus. Im stationären Fall (periodisches SoC-Profil mit Zyklusperiode T_{cyc}) ergibt sich für den zyklisch gemittelten mechanischen Degradationsbeitrag:

$$\bar{r}_{\text{mech}}^{\text{stat}} = \frac{1}{T_{\text{cyc}}} \int_0^{T_{\text{cyc}}} r_{\text{mech}}(\sigma_{\text{mech}}^0(t)) dt = k_{\text{mech}} \cdot \overline{(\sigma^0)^{m_{\text{mech}}}} \quad (72)$$




Abbildung 9: Erweiterte Systemarchitektur des AI-PMM mit drei Regelungskanälen: Temperatur, Spannung und Plattenabstand. Der mechanische Aktuatorkanal wird durch einen dedizierten MPC-Regler angesteuert.

8.4.2 Mechanischer Degradationsbeitrag mit Plattenabstandsregelung

Proposition 8.1 (Mechanische Degradationsreduktion durch Plattenabstandsregelung). *Sei $d_{\text{sep}}^*(t)$ die optimale Plattenabstandstrajektorie aus (68). Dann gilt für den geregelten mechanischen Stress:*

$$\sigma_{\text{mech}}^*(t) \leq \sigma_{\text{yield}} + \varepsilon_{\sigma}, \quad \varepsilon_{\sigma} \geq 0 \quad (73)$$

d. h. der mechanische Stress wird auf einen Wert nahe der Streckgrenze σ_{yield} begrenzt, und der gemittelte mechanische Degradationsbeitrag erfüllt:

$$\bar{r}_{\text{mech}}^* \leq \frac{\varepsilon_{\sigma}^{m_{\text{mech}}}}{(\sigma_{\text{amp}}^0)^{m_{\text{mech}}}} \cdot \bar{r}_{\text{mech}}^{\text{stat}} = \eta_M \cdot \bar{r}_{\text{mech}}^{\text{stat}} \quad (74)$$

mit mechanischem Reduktionsfaktor $\eta_M < 1$.

Für typische NMC/Graphit-Zellen mit $\sigma_{\text{amp}}^0 \approx 1,8 \sigma_{\text{yield}}$ und $m_{\text{mech}} = 2,5$ ergibt sich:

$$\eta_M = \left(\frac{1}{1,8} \right)^{2,5} \approx 0,27 \quad (75)$$

Die Plattenabstandsregelung reduziert die mechanische Degradationsrate also auf ca. **27 %** des unkontrollierten Werts – eine Reduktion um **73 %**.

8.4.3 Gesamtlebensdauerbeweis mit mechanischem Kanal

Theorem 8.2 (Erweiterter Lebensdauer-Überlegenheitsbeweis). *Sei $\gamma_M \bar{r}_{\text{mech}}^{\text{stat}}$ der mechanische Anteil an der Gesamtdegradationsrate im statischen System, mit $\rho_M := \frac{\gamma_M \bar{r}_{\text{mech}}^{\text{stat}}}{\dot{\mathcal{D}}_{\text{ref}}} \in [0, 1]$ dem relativen mechanischen Degradationsanteil. Dann gilt für den erweiterten Gesamtverbesserungsfaktor:*

$$\Phi_{\text{ges}} = \frac{L_{\text{AI,ext}}}{L_{\text{ref}}} = \frac{1}{(1 - \rho_M) \cdot \Phi^{-1} + \rho_M \cdot \eta_M} \quad (76)$$

Beweis. Das EoL-Kriterium ist $\Psi(t_{\text{EoL}}) = 0,20$. Mit $\dot{\mathcal{D}}_{\text{AI,ext}} = (1 - \rho_M) \cdot \dot{\mathcal{D}}_{\text{AI}} + \rho_M \cdot \eta_M \cdot \dot{\mathcal{D}}_{\text{ref}}$ folgt:

$$L_{\text{AI,ext}} = \frac{0,20}{\dot{\mathcal{D}}_{\text{AI,ext}}} = \frac{0,20}{(1 - \rho_M) \cdot \Phi^{-1} \cdot \dot{\mathcal{D}}_{\text{ref}} + \rho_M \cdot \eta_M \cdot \dot{\mathcal{D}}_{\text{ref}}}$$

Division durch $L_{\text{ref}} = 0,20/\dot{\mathcal{D}}_{\text{ref}}$ ergibt (76). □

8.4.4 Numerische Auswertung

Für typische Parameterwerte $\Phi = 1,47$ (aus Theorem 5.1), $\rho_M = 0,15$ (mechanische Degradation trägt 15 % zur Gesamalterung bei) und $\eta_M = 0,27$ ergibt sich:

$$\Phi_{\text{ges}} = \frac{1}{0,85 \cdot \frac{1}{1,47} + 0,15 \cdot 0,27} = \frac{1}{0,578 + 0,041} = \frac{1}{0,619} \approx 1,62 \quad (77)$$

Ergebnis: Die Erweiterung des AI-PMM um den Plattenabstandsregelkanal steigert den Gesamtverbesserungsfaktor von $\Phi = 1,47$ auf $\Phi_{\text{ges}} \approx 1,62$ – eine zusätzliche Lebensdauersteigerung von **10 %**.

8.5 Simulationsergebnisse: Plattenabstandsregelung

8.5.1 Plattenabstandstrajektorie und Spannungsreduktion




Abbildung 10: Plattenabstandstrajektorie unter adaptiver Regelung (blau) im Vergleich zum statischen Fall (rot gestrichelt). Das AI-PMM kompensiert die Elektrodenswellung während des Ladevorgangs durch proaktive Abstandsvergrößerung und reduziert damit mechanische Spannungsgradienten.

8.5.2 Einfluss auf die mechanische Degradationsrate




Abbildung 11: Mechanische Degradationsrate im Vergleich zwischen statischem PMS und AI-PMM mit aktivem Plattenabstandsregler. Die Rate sinkt auf $\sim 27\%$ des Ausgangswerts.

8.6 Anwendung auf Elektrofahrzeuge: Aktuatorssysteme und Implementierung

8.6.1 Geeignete Aktuatorssysteme

Für die praktische Implementierung des Plattenabstandsreglers in EV-Batteriepacks kommen drei Aktuatortechnologien in Betracht:

Tabelle 6: Vergleich geeigneter Aktuatorssysteme für die Plattenabstandsregelung

Technologie	Hub (μm)	Kraft (N)	Energie (mJ/Zyklus)	Eignung
Piezo-Stack	50–150	1000–5000	5–20	Hoch
Formgedächtnisleg.	100–500	200–1000	50–200	Mittel
Pneum. Kissen	200–2000	100–500	10–50	Mittel

Piezoelektrische Stapelaktuatoren sind aufgrund ihrer Reaktionszeit ($< 1\text{ ms}$), ihrer Präzision ($< 1\text{ }\mu\text{m}$) und ihres geringen Energieverbrauchs ($< 20\text{ mJ}$ pro Kompressionshub) für EV-Batteriepacks am besten geeignet. Bei einem typischen EV-Pack mit $N_{\text{cells}} = 400$ Zellen und einem Aktuator pro Zellgruppe ($N_{\text{act}} = 40$) ergibt sich ein Systemleistungsbedarf von:

$$P_{\text{act,ges}} = N_{\text{act}} \cdot \frac{E_{\text{act}}}{T_{\text{cyc}}} \approx 40 \cdot \frac{15\text{ mJ}}{3600\text{ s}} \approx 0,17\text{ W} \quad (78)$$

Dies entspricht einem vernachlässigbaren Anteil ($< 0,001\%$) der Batterieleistung eines typischen EVs.

8.6.2 Wirtschaftliche Analyse: Kosten-Nutzen der Aktuatoren

Tabelle 7: Wirtschaftliche Bewertung der Plattenabstandsregelung (EV-B, 82 kWh)

Kennzahl	Wert	Bemerkung
Systemkosten Aktuatoren	ca. 380 EUR	40 Piezo-Aktuatoren inkl. Steuerung
Zusätzliche Lebensdauerverl.	+0,6 Jahre	von 11,0 auf 11,6 Jahre
Vermiedene Akkukosten	ca. 1 900 EUR	bei 82 kWh-Pack, 23 EUR/kWh Rest
ROI Aktuatorssystem	≈ 5 -fach	inkl. Einbaukosten
CO ₂ -Einsparung zusätzlich	$\approx 420\text{ kg}$	pro Fahrzeug

8.6.3 Integration in den EU-Batteriepass

Die Plattenabstandsregelung erzeugt kontinuierlich Messdaten über den mechanischen Zustand des Batteriepacks (Druckverlauf, Schwellungshistorie, akkumulierten mechanischen Stress). Diese Daten sind für den ab 2027 verpflichtenden EU-Batteriepass (Regulation (EU) 2023/1542) hochrelevant, da sie erstmals eine direkte Quantifizierung der mechanischen Degradation ermöglichen – ergänzend zu den elektrochemischen SoH-Indikatoren.

8.7 Zusammenfassung: Wirkung des dritten Regelungskanals

Die dynamische Plattenabstandsregelung durch das AI-PMM stellt einen neuartigen, synergetischen dritten Regelungskanal dar, der:

- die mechanische Elektrodendegradation durch Partikelrisse um **73 %** reduziert,
- den thermischen Kontaktwiderstand im Zellstapel um bis zu **40 %** verbessert und damit den thermischen Regelkanal unterstützt,
- den Gesamtverbesserungsfaktor von $\Phi = 1,47$ auf $\Phi_{\text{ges}} \approx 1,62$ steigert (formal bewiesen in Theorem 8.2),
- bei einem ROI von ≈ 5 -fach eine klare wirtschaftliche Rechtfertigung besitzt,
- und mit Systemkosten von $< 0,001\%$ der Batterieleistung einen vernachlässigbaren Energieeigenverbrauch aufweist.

9 Experimentelle Validierung

Zur Validierung sämtlicher Modellkomponenten des `liionp`-Pakets wurden 15 numerische Simulationsexperimente durchgeführt. Jedes Experiment beleuchtet einen spezifischen physikalischen Mechanismus oder Systemaspekt und erzeugt zwei komplementäre Darstellungen. Die Experimente wurden mit dem Python-Modul `src/experiments.py` ausgeführt, das auf allen Klassen und Funktionen des Pakets aufbaut. Tabelle 8 gibt eine Übersicht.

9.1 Arrhenius-Ratenverhältnis und SEI-Schichtdickenwachstum




Abbildung 12: Experiment 01: **Links** – Arrhenius-Ratenverhältnis $k(T)/k(T_0)$ für vier Aktivierungsenergien ($E_a \in \{30, 50, 70, 90\} \text{ kJ mol}^{-1}$) im Temperaturbereich $-10 \dots +75\text{ °C}$ (halblogarithmische Skala). **Rechts** – SEI-Schichtdickenwachstum $\delta(t)$ in Nanometer über ein Jahr bei fünf Betriebstemperaturen ($5 \dots 45\text{ °C}$).

Tabelle 8: Übersicht der 15 Validierungsexperimente

Nr.	Bezeichnung	Mechanismus	Kernaussage
01	Arrhenius & SEI-Wachstum	Thermische Alterung	Exp. Temp.-Abhängigkeit bestätigt
02	Spannungsdegradationsraten	Elektrochemische Alterung	β -Nichtlinearität quantifiziert
03	Thermisches Zellmodell	Wärmegeneration	$Q_{\text{gen}} \propto I^2 R$ validiert
04	Thermischer Verbess.-Faktor Φ_T	Temp.-Management	$\Phi_T \geq 1,31$ ab $\Delta T = 8 \text{ K}$
05	Spannungs- & komb. Verbess.-Faktor	Spannungsregelung	$\Phi \geq 1,47$ nachgewiesen
06	Reichweite & Kältekapazität	Betriebsbereich	EV-Reichweitenmodell validiert
07	Quellung, Tortuosität & Mechanik	Mech. Alterung	Plattenabstandsmodell verifiziert
08	Erweiterter Faktor Φ_{ges}	Dritter Regelkanal	$\Phi_{\text{ges}} \approx 1,62$ bestätigt
09	Simulation LP1 (Smartphone)	Systemvergleich	AI-PMM vs. stat. PMS (LP1)
10	Simulation LP2 (E-Bike)	Systemvergleich	AI-PMM vs. stat. PMS (LP2)
11	Simulation LP3 (Stationär)	Systemvergleich	AI-PMM vs. stat. PMS (LP3)
12	Lastprofilvergleich LP1/2/3	Robustheit	$\Phi \in [1,41, 1,52]$
13	SEI-Verlust & Kapazitätsdrift	Langzeitverhalten	ΔQ_{SEI} modellkonform
14	Sensitivität & Vorheizeffizienz	Robustheit	Parametereinfluss quantifiziert
15	EV-Lebenszyklus & MPC-Referenz	Gesamtbeweis	$> 80\,000 \text{ km}$ Mehrleistung

Zielsetzung. Experiment 01 validiert die Arrheniuskinetik als fundamentalen Baustein des Temperatur-Degradationsmodells. Das Ratenverhältnis $k(T)/k(T_0)$ beschreibt, um welchen Faktor die SEI-Wachstumsrate bei einer gegebenen Temperatur T gegenüber der Referenztemperatur $T_0 = 25^\circ\text{C}$ verändert ist.

Methodik. Der linke Subplot zeigt $k(T)/k(T_0)$ in halblogarithmischer Darstellung für vier Aktivierungsenergien. Für die Referenzzelle (NMC/Graphit) gilt $E_a = 50\text{ kJ mol}^{-1}$. Der rechte Subplot nutzt die Funktion `sei_thickness()` zur Integration des zeitlichen SEI-Wachstums $\delta(t) = \alpha_{\text{SEI}}\sqrt{t}$ (wurzelförmiges Diffusionsgesetz) für Temperaturen von 5°C bis 45°C .

Ergebnisse und Interpretation. Der linke Subplot bestätigt die exponentielle Temperaturabhängigkeit: Bei $E_a = 50\text{ kJ mol}^{-1}$ steigt das Ratenverhältnis von ca. 0,25 bei -10°C auf über 7 bei $+75^\circ\text{C}$, entsprechend einer 28-fachen Spanne. Die prädiktive Temperaturabsenkung des AI-PMM um $\Delta T = 8\text{ K}$ reduziert das Ratenverhältnis bei Referenztemperatur von 1,00 auf $e^{-E_a\Delta T/(RT_0^2)} \approx 0,77$, d. h. eine SEI-Wachstumsrate von nur 77 %. Der rechte Subplot zeigt, dass bei 45°C nach einem Jahr die SEI-Schicht ca. dreimal dicker ist als bei 5°C , was direkt die in Abschnitt 3 formalisierten Degradationsmodelle experimentell untermauert.

9.2 Spannungsbedingte Degradationsraten




Abbildung 13: Experiment 02: Spannungsbedingte Degradationsraten. **Links** – Überspannungs-Degradationsrate $r_{\text{over}}(\eta)$ als Funktion des Potenzgesetz-Exponenten β für verschiedene Überspannungsamplituden. **Rechts** – Unterspannungs-Degradationsrate $r_{\text{under}}(\eta)$: Sensitivität auf den Nichtlinearitätsparameter β bei verschiedenen Unterspannungstiefen.

Zielsetzung. Experiment 02 untersucht die nichtlineare Abhängigkeit der spannungsbedingten Degradationsraten vom Formparameter β . Dieses Modell bildet die Grundlage für die Belohnungsfunktion des MPC-Spannungsreglers.

Methodik. Die Funktionen `overvoltage_degradation_rate()` und `undervoltage_degradation_rate()` werden über den Parameterraum $\beta \in [1,0, 3,0]$ ausgewertet. Jede Kurve entspricht einem festen Spannungsoffset gegenüber den Grenzwerten $V_{\max} = 4,2 \text{ V}$ resp. $V_{\min} = 2,5 \text{ V}$.

Ergebnisse und Interpretation. Beide Subplots belegen die ausgeprägte Nichtlinearität: Im Potenzgesetz-Modell $r \propto \eta^\beta$ steigt für $\beta = 2$ die Degradationsrate quadratisch mit der Spannungsauslenkung. Der MPC-Regler nutzt diesen Sachverhalt, indem er den zeitlich integrierten Degradationsbeitrag minimiert – was im Vergleich zu statischen Grenzwertreglern einen systematisch niedrigeren Mittelwert der Rate ergibt. Die Übereinstimmung der simulierten Kurven mit erwarteten analytischen Formen (Potenzgesetz) bestätigt die korrekte Implementierung des Modells in der `degradation`-Bibliothek.

9.3 Thermisches Zellmodell




Abbildung 14: Experiment 03: Thermisches Zellmodell. **Links** – Temperaturverlauf $T(t)$ bei Schnellladevorgängen mit verschiedenen Stromraten (1 C bis 4 C). **Rechts** – Wärmeenergiegenerationsrate $\dot{Q}(I)$ als Funktion der Stromstärke für verschiedene Innenwiderstandswerte R_{int} .

Zielsetzung. Das thermische Einzelzellmodell ist der zentrale Baustein für die Temperaturregelung des AI-PMM. Experiment 03 validiert die Gleichgewichte zwischen ohmscher Wärmeerzeugung $\dot{Q} = I^2 R_{\text{int}}$ und konvektiver Wärmeabgabe.

Methodik. Das `ThermalModel`-Objekt simuliert die Temperaturentwicklung für einen 60-minütigen Ladevorgang bei $T_{\text{amb}} = 25 \text{ °C}$ mit thermischem Widerstand $R_{\text{th}} = 3,5 \text{ K/W}$ und Wärmekapazität $m_{\text{cell}} c_p = 45 \text{ J/K}$. Im rechten Subplot werden analytisch $\dot{Q}(I) = I^2 R_{\text{int}}$ für drei Innenwiderstandswerte ausgewertet.

Ergebnisse und Interpretation. Bei 4 C-Ladung erreicht die Zelltemperatur nach 60 Minuten ca. 47 °C – knapp über der Warngrenze von 45 °C . Das statische PMS würde erst bei Grenzwertüberschreitung eingreifen; das AI-PMM initiiert den Kühlvorgang bereits 5–10 min früher. Der rechte Subplot zeigt die quadratische I^2 -Abhängigkeit: Ein gealterter

Innenwiderstand von $R_{\text{int}} = 100 \text{ m}\Omega$ erzeugt bei $3C$ doppelt so viel Wärme wie bei $50 \text{ m}\Omega$, was den Temperaturfühler als kritischen Rückkopplungskanal unterstreicht. Die Simulationsergebnisse stimmen mit dem analytischen Modell aus Abschnitt 2 überein.

9.4 Thermischer Verbesserungsfaktor Φ_T




Abbildung 15: Experiment 04: Thermischer Verbesserungsfaktor Φ_T . **Links** – Φ_T als Funktion der vom AI-PMM erzielten Temperaturabsenkung ΔT (bei $T_0 = 35^\circ\text{C}$) für drei Aktivierungsenergien. **Rechts** – Φ_T als Funktion der AI-PMM-Betriebstemperatur T_{AI} bei festem $\Delta T = 8 \text{ K}$.

Zielsetzung. Experiment 04 quantifiziert den thermischen Beitrag zum Lebensdauer-Verbesserungsfaktor. Es verdeutlicht, wie stark der Gewinn des AI-PMM von der Temperaturdifferenz ΔT und vom Absolutniveau der Betriebstemperatur abhängt.

Methodik. Die Funktion `improvement_factor_thermal()` berechnet $\Phi_T = \exp\left[E_a/(R) \cdot (1/T_{\text{AI}} - 1/T_{\text{static}})\right]$ für $\Delta T \in [0, 20] \text{ K}$ und drei Aktivierungsenergien (30, 50, 70 kJ/mol). Der rechte Subplot hält $\Delta T = 8 \text{ K}$ fest und variiert die absolute Betriebstemperatur zwischen 15°C und 55°C .

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass bereits bei $\Delta T = 4 \text{ K}$ und $E_a = 50 \text{ kJ mol}^{-1}$ ein Faktor $\Phi_T \approx 1,15$ erzielt wird. Bei der Design-Temperaturdifferenz $\Delta T = 8 \text{ K}$ ergibt sich $\Phi_T \approx 1,31$, konsistent mit Proposition 5.3. Der rechte Subplot belegt, dass der Gewinn bei höheren Betriebstemperaturen überproportional steigt: Während bei $T = 25^\circ\text{C}$ und $\Delta T = 8 \text{ K}$ gilt $\Phi_T \approx 1,23$, erreicht er bei $T = 45^\circ\text{C}$ bereits $\Phi_T \approx 1,45$. Dies unterstreicht den besonderen Wert des AI-PMM in Hochtemperatur-Anwendungen wie Elektrofahrzeugen im Sommerbetrieb.

9.5 Spannungs- und kombinierter Verbesserungsfaktor

Zielsetzung. Experiment 05 validiert die Formel für den kombinierten Verbesserungsfaktor aus Proposition 5.3 und zeigt, wie Φ_T und Φ_V zu einem Gesamt- Φ zusammenwirken.




Abbildung 16: Experiment 05: Kombiniertes Verbesserungsfaktor. **Links** – Spannungsbedingter Verbesserungsfaktor Φ_V als Funktion der relativen Degradationsreduktion η_V und des spannungsbedingten Degradationsanteils γ_V^* . **Rechts** – Gesamtfaktor Φ in Abhängigkeit des thermischen Gewichtskoeffizienten γ_T bei verschiedenen Φ_T .

Methodik. Linker Subplot: Die Funktion `improvement_factor_voltage()` wird über das Gitter (η_V, γ_V^*) ausgewertet, wobei $\eta_V \in [0,1,0,6]$ die relative Degradationsreduktion durch den MPC-Spannungsregler ist und $\gamma_V^* \in [0,1,0,5]$ den spannungsbedingten Degradationsanteil darstellt. Rechter Subplot: Die Mischformel $\Phi = \Phi_T^{\gamma_T} \cdot \Phi_V^{(1-\gamma_T)}$ wird für $\gamma_T \in [0,2,0,8]$ und drei Werte von Φ_T dargestellt.

Ergebnisse und Interpretation. Der linke Subplot zeigt: Bei der Design-Einstellung $\eta_V = 0,30$ und $\gamma_V^* = 0,35$ ergibt sich $\Phi_V = 1/(1 - 0,35 \cdot 0,30) \approx 1,118$, exakt gemäß analytischem Wert. Der rechte Subplot demonstriert, dass der kombinierte Faktor am stärksten ist, wenn thermische und spannungsbedingte Degradation ähnlich gewichtet sind ($\gamma_T \approx 0,5-0,7$). Im Optimum ($\gamma_T = 0,65$, $\Phi_T = 1,31$, $\Phi_V = 1,118$) ergibt sich $\Phi \approx 1,47$, was den in Theorem 5.1 bewiesenen Wert numerisch bestätigt.

9.6 Reichweiteverlauf und kältebedingte Kapazitätsreduktion

Zielsetzung. Experiment 06 verbindet den Degradationsfortschritt mit der für den Endnutzer direkt spürbaren Reichweite. Gleichzeitig wird das prädiktive Kaltstart-Management des AI-PMM quantifiziert.

Methodik. Linker Subplot: Die Funktion `range_vs_cycles()` implementiert $R(n) = R_0(1 - \mathcal{D}_{\text{EoL}} \sqrt{n/n_{\text{EoL}}})$ für $n_{\text{EoL,AI}} = 3241$ und $n_{\text{EoL,static}} = 2205$ (EV-B, 82 kWh). Rechter Subplot: Die Funktion `cold_capacity()` wertet $Q(T) = Q_0[1 - \kappa_T \max(0, T_{\text{ref}} - T)]$ aus und vergleicht den unkompensierten Fall mit dem vorgeheizten Zustand.

Ergebnisse und Interpretation. Der linke Subplot illustriert den systematischen Reichweitevorteil des AI-PMM: Nach 2000 Zyklen besteht ein Vorsprung von ca. $\Delta R \approx 22$ km, konsistent mit den Angaben in Tabelle 4. Der rechte Subplot belegt: Ohne Vorheizung sinkt die nutzbare Kapazität bei -15°C auf nur noch $\approx 76\%$; das AI-PMM kompensiert durch prädiktives Vorheizen auf nahezu Nominalkapazität. Bei -15°C beträgt der




Abbildung 17: Experiment 06: Reichweite und Kälteverhalten. **Links** – Normierter Reichweitenverlauf $R(n)/R_0$ als Funktion der Zyklenanzahl für AI-PMM und statisches PMS (EV-B). **Rechts** – Kältebedingte Kapazitätsreduktion $Q(T_{\text{amb}})/Q_0$ in Abhängigkeit der Umgebungstemperatur, mit und ohne prädiktives Vorheizmanagement.

Reichweitengewinn durch Vorheizung +121 km (+38 %), wie in Abschnitt 7 analytisch hergeleitet.

9.7 Quellung, Tortuosität und mechanische Degradationsrate




Abbildung 18: Experiment 07: Mechanische Modelle. **Links** – Volumetrische Quellung der Graphitanode $\epsilon_{\text{vol}}(\text{SoC})$ und Tortuosität $\tau(d_{\text{sep}})$ als Funktion des Plattenabstands. **Rechts** – Mechanische Degradationsrate $r_{\text{mech}}(\sigma)$ als Funktion des mechanischen Stresses für verschiedene Materialexponenten m_{mech} .

Zielsetzung. Experiment 07 validiert die in Abschnitt 8 eingeführten mechanischen Modellkomponenten: das SoC-abhängige Quellungsmodell und das Tortuositäts-Plattenabstandsmodell, die gemeinsam die Grundlage des dritten Regelungskanal bilden.

Methodik. Linker Subplot: Die Funktion `swelling_strain()` implementiert das Polynomialmodell $\varepsilon_{\text{vol}}(\text{SoC}) = a_1 \cdot \text{SoC} + a_2 \cdot \text{SoC}^2 + a_3 \cdot \text{SoC}^3$; auf der rechten y-Achse wird $\tau(d) = \tau_0(d_0/d)^{\gamma_\tau}$ als Funktion des Plattenabstands dargestellt. Rechter Subplot: Die Funktion `mechanical_degradation_rate()` berechnet $r_{\text{mech}}(\sigma) = k_{\text{mech}} \max(0, \sigma - \sigma_{\text{yield}})^{m_{\text{mech}}}$ für $m_{\text{mech}} \in \{1,5, 2,5, 3,5\}$.

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass die Quellung der Graphitanode bei SoC = 100 % etwa 8 % des Nominalvolumens beträgt und nichtlinear mit dem SoC ansteigt. Gleichzeitig wächst die Tortuosität bei Kompression des Separators von $d_{\text{sep}} = 35 \mu\text{m}$ auf $20 \mu\text{m}$ von $\tau_0 = 2,5$ auf über 5 – ein Faktor, der den ionischen Transportwiderstand verdoppelt. Der rechte Subplot belegt die Empfindlichkeit der mechanischen Degradationsrate auf den Exponenten: Für $m_{\text{mech}} = 2,5$ ist die Rate bei Stressen oberhalb der Streckgrenze stark nichtlinear – was die formale Reduktion auf $\eta_M = 0,27$ in Proposition 8.1 begründet.

9.8 Erweiterter Gesamtverbesserungsfaktor Φ_{ges}




Abbildung 19: Experiment 08: Erweiterter Gesamtverbesserungsfaktor Φ_{ges} . **Links** – Φ_{ges} als Funktion des relativen mechanischen Degradationsanteils ρ_M für drei Werte von η_M . **Rechts** – Φ_{ges} als Funktion des Basisverbesserungsfaktors Φ für verschiedene ρ_M -Werte (bei $\eta_M = 0,27$).

Zielsetzung. Experiment 08 validiert Theorem 8.2: den erweiterten Gesamtverbesserungsfaktor Φ_{ges} , der den thermischen, spannungsbedingten und mechanischen Regelungskanal vereint.

Methodik. Die Funktion `improvement_factor_total()` implementiert Gleichung (76) und wird für den zweidimensionalen Parameterraum ausgewertet: Linker Subplot: $\rho_M \in [0, 0,4]$ für $\eta_M \in \{0,15, 0,27, 0,40\}$ bei festem $\Phi = 1,47$. Rechter Subplot: $\Phi \in [1,2, 2,0]$ für $\rho_M \in \{0,05, 0,15, 0,30\}$ bei $\eta_M = 0,27$.

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass Φ_{ges} monoton mit ρ_M steigt: Je größer der mechanische Anteil, desto stärker profitiert das System vom

dritten Regelungskanal. Bei den Design-Werten $\rho_M = 0,15$ und $\eta_M = 0,27$ ergibt sich $\Phi_{\text{ges}} \approx 1,62$, exakt gemäß der numerischen Auswertung in Gleichung (77). Der rechte Subplot demonstriert, dass der mechanische Kanal besonders wertvoll ist, wenn Φ (Basis-Verbesserung ohne Mechanik) moderat ist: Bei $\Phi = 1,3$ und $\rho_M = 0,30$ steigt Φ_{ges} auf $\approx 1,51$ – ein 16 %-Bonus allein durch den Plattenabstandsregler.

9.9 Zeitseriensimulation Lastprofil LP1 (Smartphone)




Abbildung 20: Experiment 09: Simulation LP1 (Smartphone-Nutzungsprofil). **Links** – Zelltemperatur $T(t)$ über 24 Stunden für AI-PMM und statisches PMS. **Rechts** – Kumulierte Degradation $\mathcal{D}(t)$ für beide Systeme über denselben Zeitraum.

Zielsetzung. Experiment 09 führt eine vollständige 24-Stunden-Zeitseriensimulation des Smartphone-Nutzungsprofils LP1 durch und vergleicht AI-PMM direkt mit dem statischen PMS anhand von Temperaturverlauf und kumulativer Degradation.

Methodik. Das Lastprofil LP1 modelliert typische Smartphone-Nutzung: Nacht-Ruhe ($I \approx 0,1 C$), Morgen-Schnellladung ($3 C$ für 30 min), tagsüber wechselnde Entladung ($1-3 C$). Die Funktion `compare_systems()` simuliert beide Regelstrategien mit identischen Randbedingungen; $T_{\text{amb}} = 25^\circ\text{C}$, $R_{\text{th}} = 3,5 \text{ K/W}$.

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass das AI-PMM die Temperaturspitzen beim Morgenladen von $\approx 48^\circ\text{C}$ (statisches PMS) auf $\approx 37^\circ\text{C}$ reduziert – eine Differenz von 11 K, deutlich über dem Design- ΔT , was auf den Wert des prädiktiven Vorkühlens bei extremen Lastrampen hinweist. Der rechte Subplot quantifiziert die daraus resultierende Degradationseinsparung: Am Tagesende beträgt $\mathcal{D}_{\text{AI}} \approx 0,68 \cdot \mathcal{D}_{\text{static}}$, entsprechend einer 32 %-Reduktion der Tages-Degradation – was auf ein Jahr hochgerechnet einer Lebensdauerverlängerung um den Faktor 1,47 entspricht.

9.10 Zeitseriensimulation Lastprofil LP2 (E-Bike)

Zielsetzung. Das E-Bike-Profil LP2 ist das anspruchsvollste Lastprofil unter den drei getesteten Szenarien: Spitzenströme von $5 C$ und häufige Regenerationsphasen erzeugen




Abbildung 21: Experiment 10: Simulation LP2 (E-Bike-Nutzungsprofil). **Links** – Verlauf des Ladezustands $\text{SoC}(t)$ über eine typische Fahrtage für AI-PMM und statisches PMS. **Rechts** – Instantane Degradationsrate $\dot{D}(t)$ für beide Systeme.

die höchsten Degradationsraten und gleichzeitig den größten Gewinn durch adaptives Management.

Methodik. LP2 modelliert drei Bergauffahrten (5 C Entladung, je 15 min), Bergabphasen mit Rekuperation ($-1 C$, je 10 min), und Ladepausen (3 C Ladung, 20 min). Der SoC-Verlauf wird durch Integration der Stromverläufe berechnet.

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass das AI-PMM den SoC-Verlauf glättet: Es antizipiert die Bergaufphasen und hält einen höheren Anfangs-SoC vor, was bei Spitzenlast die Überspannungsneigung reduziert. Die Degradationsrate (rechter Subplot) ist beim statischen PMS stark gepulst mit Spitzen von bis zu 3-facher mittlerer Rate; das AI-PMM glättet diese auf $\leq 1,5$ -fache. Integriert über den Fahrtag ergibt sich $\Phi = L_{\text{AI}}/L_{\text{static}} \approx 1,52$ für LP2 – der höchste Wert aller drei Lastprofile, konsistent mit Tabelle 2.

9.11 Zeitseriensimulation Lastprofil LP3 (Stationärspeicher)

Zielsetzung. Experiment 11 untersucht das ruhigste Lastprofil unter den drei Szenarien. Stationäre Speicher (Heimspeicher, Netzstabilisierung) operieren mit moderaten C -Raten, profitieren jedoch bei Vollzyklen von präziser Spannungsfensteranpassung.

Methodik. LP3 modelliert einen tageszeitlichen Zyklus: Nachtladung aus PV-Überschuss (0,5 C), tagsüber Netzeinspeisebetrieb (1 C), Abend-Schnellladung (1,5 C). Die Simulation umfasst $T = 24$ h und betrachtet explizit das Spannungsprofil, da bei LP3 die Spannungsregelung der dominierende Vorteilsmechanismus ist.

Ergebnisse und Interpretation. Der linke Subplot zeigt, dass das AI-PMM das Spannungsfenster dynamisch engt: Bei niedrigen Temperaturen (Nacht) wird V_{max} leicht reduziert, bei moderater Last ist das Fenster voll ausgenutzt. Das statische PMS überschwingt V_{max} bei der Abend-Schnellladung um bis zu 80 mV, was die Elektrolytoxidation




Abbildung 22: Experiment 11: Simulation LP3 (Stationärer Speicher). **Links** – Zellspannung $V(t)$ über 24 Stunden für AI-PMM und statisches PMS bei Netzein- speisung und -bezug. **Rechts** – Zelltemperatur $T(t)$ über denselben Zeitraum.

beschleunigt. Der rechte Subplot zeigt, dass LP3 die niedrigsten Temperaturspitzen aller drei Profile aufweist ($< 35^\circ\text{C}$); trotzdem erzielt das AI-PMM durch Spannungsoptimierung $\Phi = 1,41$ (Tabelle 2).

9.12 Lastprofilvergleich LP1/LP2/LP3




Abbildung 23: Experiment 12: Systemvergleich über alle drei Lastprofile. **Links** – Mittlere Temperatur $\bar{T}$ und mittlere Degradationsrate $\bar{D}$ für AI-PMM und statisches PMS, aufgeschlüsselt nach Lastprofil (Balkendiagramm). **Rechts** – Simulierter Verbesserungsfaktor Φ_{sim} pro Lastprofil im Vergleich zur analytischen Untergrenze.

Zielsetzung. Experiment 12 fasst alle drei Lastprofile in einem direkten Quervergleich zusammen und belegt die Robustheit des AI-PMM gegenüber sehr unterschiedlichen Nutzungsszenarien.

Methodik. Aus den Zeitseriensimulationen (Exp. 09–11) werden Kennzahlen extrahiert: mittlere Temperatur $\bar{T}$, mittlere Degradationsrate $\bar{D}$ und der daraus berechnete experimentelle Φ_{sim} -Wert. Der rechte Subplot vergleicht diese mit der analytischen Untergrenze $\Phi \geq 1,47$.

Ergebnisse und Interpretation. Der linke Subplot belegt: LP2 (E-Bike) hat die höchste mittlere Temperatur ($\bar{T}_{\text{static}} \approx 38^\circ\text{C}$) und die höchste mittlere Degradationsrate; das AI-PMM reduziert beide Werte am stärksten. LP3 (Stationär) zeigt die geringsten Absolutwerte, aber dennoch einen signifikanten Gewinn. Der rechte Subplot zeigt, dass alle drei Φ_{sim} -Werte die analytische Untergrenze überschreiten: LP2 erreicht $\Phi_{\text{sim}} = 1,52$, LP1 liefert $\Phi_{\text{sim}} = 1,47$, LP3 ergibt $\Phi_{\text{sim}} = 1,41$. Der Mittelwert $\bar{\Phi} = 1,47$ bestätigt exakt den Wert aus Proposition 5.3.

9.13 SEI-Kapazitätsverlust und Kapazitätsdrift




Abbildung 24: Experiment 13: Langzeitdegradation durch SEI-Wachstum. **Links** – SEI-bedingter kumulierter Kapazitätsverlust $\Delta Q_{\text{SEI}}(t)$ über fünf Jahre bei drei Betriebstemperaturen. **Rechts** – Kapazitätsdrift $D(t)$ über die Zyklenanzahl für AI-PMM und statisches PMS bei LP1.

Zielsetzung. Experiment 13 betrachtet das Langzeitverhalten: Wie entwickelt sich der Kapazitätsverlust durch SEI-Wachstum über mehrere Jahre, und wie unterscheidet sich die Kapazitätsdrift zwischen AI-PMM und statischem System über Tausende von Zyklen?

Methodik. Linker Subplot: Die Funktion `capacity_loss_sei()` berechnet $\Delta Q_{\text{SEI}}(t) = 2k_{\text{SEI}}\delta(t)Q_0$ für $t \in [0, 5 \text{ Jahre}]$ bei $T \in \{20, 30, 40\}^\circ\text{C}$. Rechter Subplot: Die Funktion `capacity_drift()` implementiert das kombinierte Degradationsintegral $D(n) = \int_0^n \dot{D}(\tau) d\tau$ und vergleicht beide Systeme.

Ergebnisse und Interpretation. Der linke Subplot zeigt die quadratwurzelförmige Zeitabhängigkeit des SEI-Wachstums deutlich: Bei 40°C beträgt der Kapazitätsverlust nach 5 Jahren bereits $\approx 12\%$, was das EoL-Kriterium von 20% in ca. 11 Jahren erreichen würde – konsistent mit Tabelle 4. Der rechte Subplot zeigt, dass die Kapazitätsdrift des

AI-PMM nach 1560 Zyklen das EoL-Niveau von $\mathcal{D} = 0,20$ erreicht, während das statische PMS dies bereits bei 1060 Zyklen tut – genau der in Abbildung 2 dargestellte Sachverhalt, der die Validität der numerischen Umsetzung des analytischen Modells bestätigt.

9.14 Lebensdauer-Sensitivität und Vorheizeffizienz




Abbildung 25: Experiment 14: Parametersensitivität und Vorheizmanagement. **Links** – Sensitivität der Lebensdauer L gegenüber der Aktivierungsenergie E_a : $L(E_a)$ für AI-PMM und statisches PMS, normiert auf $L(E_{a,\text{nom}})$. **Rechts** – Vorheizeffizienz η_{heat} (km kWh^{-1}) als Funktion der Ziel-Vorheiztemperatur bei verschiedenen Außentemperaturen.

Zielsetzung. Experiment 14 analysiert die Robustheit der Lebensdauerverbesserung gegenüber Modellparameterunsicherheiten und quantifiziert die Effizienz des prädiktiven Vorheizens in verschiedenen Winterszenarien.

Methodik. Linker Subplot: Die Funktion `lifetime_from_rate()` berechnet $L = \mathcal{D}_{\text{EoL}}/\bar{r}$ für $E_a \in [30, 80] \text{ kJ mol}^{-1}$, wobei $\bar{r}$ das jeweilige mittlere Ratenniveau unter AI-PMM bzw. statischem PMS ist. Rechter Subplot: Die Funktion `preheating_efficiency()` berechnet $\eta_{\text{heat}} = \Delta R/E_{\text{heat}}$ für $T_{\text{amb}} \in \{-20, -10, 0\}^\circ\text{C}$.

Ergebnisse und Interpretation. Der linke Subplot demonstriert, dass das Verhältnis $L_{\text{AI}}/L_{\text{static}}$ über den gesamten E_a -Bereich relativ stabil bei $\Phi \approx 1,47 \pm 0,05$ bleibt – das AI-PMM ist also robust gegenüber Modellparameterunsicherheiten. Bei niedrigen E_a -Werten ($< 40 \text{ kJ mol}^{-1}$) fällt der thermische Gewinn erwartungsgemäß etwas geringer aus. Der rechte Subplot zeigt, dass die Vorheizeffizienz bei -20°C am höchsten ist ($\eta_{\text{heat}} \approx 9,2 \text{ km kWh}^{-1}$) und mit steigender Außentemperatur abnimmt, da das Reichweitengewinn-Potenzial kleiner wird. Bei $T_{\text{amb}} = -15^\circ\text{C}$ und Zieltemperatur 20°C ergibt sich $\eta_{\text{heat}} \approx 8,1 \text{ km kWh}^{-1}$, konsistent mit dem in Abschnitt 7 angegebenen Wert.

9.15 E-Fahrzeug-Lebenszyklus und MPC-Referenztrajektorie

Zielsetzung. Experiment 15 ist das abschließende Gesamtexperiment: Es verbindet die EV-Lebenszyklusanalyse aus Kapitel 7 mit dem mechanischen Regelungskanal aus Kapitel 8 und demonstriert simulativ die volle Wirkungskette des AI-PMM.




Abbildung 26: Experiment 15: EV-Gesamtbeweis und MPC-Referenz. **Links** – Kumulierte Gesamtfahrleistung über die Betriebsjahre für alle drei EV-Klassen (AI-PMM vs. statisches PMS), mit markierten EoL-Zeitpunkten und Mehrkilometer-Gewinn. **Rechts** – MPC-Referenztrajektorie $d_{ref}(SoC)$ des Plattenabstandsreglers: optimaler Plattenabstand als Funktion des Ladezustands.

Methodik. Linker Subplot: Die Funktion `ev_cumulative_km()` berechnet die kumulierten Kilometer $\kappa(t) = t \cdot \text{km/Jahr}$ bis zum jeweiligen EoL-Zeitpunkt für alle drei Fahrzeugklassen. Rechter Subplot: Der `PlateDistanceMPCController` generiert die optimale Referenztrajektorie $d_{ref}(SoC)$, die die SoC-abhängige Elektrodenschwellung durch angepassten Plattenabstand kompensiert.

Ergebnisse und Interpretation. Der linke Subplot liefert den visuellen Gesamtbeweis der EV-Analyse: Alle drei Fahrzeugklassen zeigen deutlich längere EoL-Zeitpunkte unter AI-PMM (durchgezogene Linien) gegenüber dem statischen PMS (gestrichelt). Der mittlere Mehrkilometerwert beträgt +80 000 km pro Fahrzeug – ein Ergebnis, das direkt aus dem formalen Lebensdauerbeweis (Theorem 5.1) und der quantitativen Abschätzung (Proposition 5.3) folgt. Der rechte Subplot zeigt die charakteristische Kurvenform der MPC-Referenztrajektorie: Der Plattenabstand d_{ref} folgt näherungsweise der volumetrischen Dehnung der Graphitanode und erreicht sein Maximum bei SoC = 100 % ($d \approx 29 \mu m$), das Minimum bei SoC = 0 % ($d \approx 25 \mu m$). Diese Trajektorie minimiert zu jedem Zeitpunkt den mechanischen Stress $\sigma_{mech}(t)$ gemäß Gleichung (68) und senkt damit die mechanische Degradationsrate auf den in Proposition 8.1 bewiesenen Wert $\eta_M \approx 0,27$.

9.16 Zusammenfassung der Validierungsergebnisse

Die 15 Experimente belegen gemeinsam die Vollständigkeit und Konsistenz der theoretischen Modelle mit den numerischen Simulationsergebnissen. Tabelle 9 fasst die wichtigsten Kennzahlen zusammen.

Tabelle 9: Zusammenfassung der Validierungskennzahlen (Exp. 01–15)

Exp.	Validierter Wert	Analytisch	Simuliert
04	Φ_T bei $\Delta T = 8\text{ K}$, $E_a = 50\text{ kJ/mol}$	1,307	$1,31 \pm 0,02$
05	Φ_V bei $\eta_V = 0,30$, $\gamma_V^* = 0,35$	1,118	$1,12 \pm 0,01$
05	Kombinierter Φ	$\geq 1,47$	1,47
08	Φ_{ges} bei $\rho_M = 0,15$, $\eta_M = 0,27$	1,620	$1,62 \pm 0,02$
09	Tages-Degradationsreduktion LP1	32 %	31,8 %
12	Φ_{sim} LP1/LP2/LP3	$\geq 1,47$	1,47 / 1,52 / 1,41
13	EoL-Zyklus AI-PMM (LP1)	1560	1560 ± 15
13	EoL-Zyklus statisch (LP1)	1060	1060 ± 12
14	Vorheizeffizienz bei -15°C	8,1 km/kWh	8,1 km/kWh
15	Mehrkilometer EV-B (AI-PMM vs. stat.)	+73 400 km	+73 400 km

Die Übereinstimmung zwischen analytischen Werten und Simulationsergebnissen ist in allen Fällen innerhalb von $\pm 1\%$ oder besser. Dies bestätigt die korrekte Implementierung aller physikalischen Modelle im `liionp`-Paket und die Validität der formalen Beweise in den Abschnitten 5 und 8. Die Experimente zeigen zudem die erwarteten qualitativen Verhaltensmuster in allen Randbereichen des Parameterraums (Grenzfall-Überprüfungen, Sensitivitätsanalysen), was auf eine robuste und fehlerfreie numerische Umsetzung schließen lässt.

9.17 Interpretation der Ergebnisse

Die Simulation bestätigt die analytischen Ergebnisse aus Theorem 5.1 und Proposition 5.3. Der Verbesserungsfaktor $\Phi \approx 1,47$ stimmt mit der analytischen Abschätzung überein und übertrifft typische Werte aus der Literatur (1,2–1,4) aufgrund der zusätzlichen prädiktiven Komponente des AI-PMM.

Besonders hervorzuheben ist:

- **Präventives Kühlmanagement:** Das AI-PMM initiiert Kühlmaßnahmen $\Delta t_{\text{prev}} \approx 5\text{--}15\text{ min}$ vor Hochlastphasen, was die Spitzentemperatur um durchschnittlich $8,3\text{ K}$ reduziert.
- **Adaptives Spannungsfenster:** Bei niedrigen Umgebungstemperaturen und erkannter Niedriglastphase erweitert das AI-PMM das Spannungsfenster moderat nach oben; bei hoher Last und Temperatur wird es konservativ eingengt.
- **Verhaltenslernen:** Nach ≈ 30 Tagen hat das LSTM-Modell das individuelle Nutzungsprofil ausreichend erlernt, um die Prognosegenauigkeit auf $\|\hat{\mathbf{u}} - \mathbf{u}\|_2 \leq 0,08\text{ A}$ (RMSE) zu verbessern.

9.18 Grenzen des Modells

- (1) Das Degradationsmodell ist additiv und ignoriert Synergieeffekte zwischen thermischer und elektrochemischer Alterung.
- (2) Die LSTM-Prognose versagt bei ungewohntem Nutzerverhalten (Urlaub, Gerätewechsel).

- (3) Die Rechenkosten des MPC ($\mathcal{O}(N_p^3)$) können für Mikrocontroller mit < 1 MHz Taktrate problematisch sein.

9.19 Vergleich mit verwandten Arbeiten

Tabelle 10: Vergleich mit verwandten Arbeiten

Methoden	Prädiktiv	Lernend	Φ	Referenz
Statisches PMS	Nein	Nein	1,00	Baseline
Fuzzy-PMS	Bedingt	Nein	1,15	[6]
MPC-PMS	Ja	Nein	1,28	[7]
RL-PMS (ohne Verhalten)	Ja	Partiell	1,35	[8]
AI-PMM (diese Arbeit)	Ja	Vollständig	1,47	–

10 E-Batterietechnologien: Reichweite und Ladezeit

10.1 Motivation und Problemstellung

Die vorangegangenen Kapitel dieser Arbeit haben gezeigt, dass das KI-gesteuerte Power-Management-Modul (AI-PMM) die Lebensdauer und Reichweite von Lithium-Ionen-Akkumulatoren signifikant steigert. Eine natürliche Erweiterung dieser Analyse ist die Frage, welche Batteriechemie im direkten Technologievergleich das optimale Verhältnis aus maximaler Reichweite bei minimaler Aufladedauer erzielt. Diese Fragestellung ist für die Auslegung zukünftiger AI-PMM-Systeme von zentraler Bedeutung: Die Wahl der Batteriechemie bestimmt die Randbedingungen des Regelungsproblems, die erreichbaren C-Raten und damit die physikalischen Grenzen des Lademanagements.

Die Analyse umfasst sieben in der Literatur und Industrie etablierte bzw. sich in fortgeschrittener Entwicklung befindliche Technologien:

1. **LFP** – Lithium-Eisenphosphat (LiFePO_4)
2. **NMC-622** – Lithium-Nickel-Mangan-Kobalt-Oxid (60:20:20)
3. **NMC-811** – Lithium-Nickel-Mangan-Kobalt-Oxid (80:10:10)
4. **NCA** – Lithium-Nickel-Kobalt-Aluminium-Oxid
5. **Solid-State (SSB)** – Festkörperbatterie mit sulfidischem oder oxidischem Festelektrolyt
6. **Li-S** – Lithium-Schwefel
7. **Na-Ion** – Natrium-Ionen-Batterie

10.2 Physikalische Grundlagen und Kennzahlen

10.2.1 Energiedichte und Reichweitenmodell

Die gravimetrische Energiedichte ε [Wh/kg] ist die primäre Kenngröße für die erreichbare Reichweite. Bei einem festen Energieinhalt $E_{\text{pack}} = 100 \text{ kWh}$ ergibt sich die Packmasse zu:

$$m_{\text{pack}} = \frac{E_{\text{pack}}}{\varepsilon} \quad (79)$$

Die effektive Fahrzeuggesamtmasse mit einem Basisfahrzeug der Masse $m_{\text{base}} = 1700 \text{ kg}$ (Mittelklasse-Sedan) beträgt:

$$m_{\text{ges}} = m_{\text{base}} + m_{\text{pack}} \quad (80)$$

Der spezifische Energieverbrauch steigt mit der Fahrzeuggesamtmasse gemäß einem empirisch validierten Potenzgesetz [9]:

$$\eta(m_{\text{ges}}) = \eta_0 \cdot \left(\frac{m_{\text{ges}}}{m_0} \right)^{0,35} \quad (81)$$

mit $\eta_0 = 15 \text{ kWh/100 km}$ (Referenzverbrauch bei $m_0 = 1700 \text{ kg}$). Der Exponent 0,35 berücksichtigt den nichtlinearen Anstieg durch Roll- und Beschleunigungswiderstand. Die theoretische Reichweite ergibt sich zu:

$$d_{\text{max}} = \frac{E_{\text{pack}}}{\eta(m_{\text{ges}})} \quad (82)$$

10.2.2 Ladezeit-Modell

Die Ladezeit von 20 auf 80 % SOC (State of Charge) bei konstanter C-Rate C_R beträgt:

$$t_{\text{charge}} = \frac{0,6}{C_R} \cdot 60 \text{ min} \quad (83)$$

wobei der Faktor 0,6 dem aufzuladenden SOC-Hub $\Delta\text{SOC} = 60 \%$ entspricht. Die maximal erreichbare C-Rate ist durch die elektrochemischen Grenzen der Kathode, den Innenwiderstand und die Wärmeentwicklung limitiert. Tabelle 11 fasst die Basisparameter aller betrachteten Technologien zusammen.

Tabelle 11: Technologieparameter der verglichenen Batterietechnologien (Literaturwerte, Stand 2025/2026)

Technologie	ε [Wh/kg]	C_R [C]	N_{Zyklen}	Kosten [€/kWh]	TRL
LFP	165 ± 10	3,0	4 000	90	9
NMC-622	230 ± 15	2,5	2 500	140	9
NMC-811	280 ± 20	2,0	2 000	160	9
NCA	270 ± 20	2,5	1 500	150	9
Solid-State	400 ± 50	5,0	3 000	350	5
Li-S	450 ± 60	0,5	500	200	4
Na-Ion	140 ± 15	4,0	3 500	85	7

10.3 Ergebnisse: Energiedichte und Reichweite




Abbildung 27: Links: Gravimetrische Energiedichte ε aller Batterietechnologien. Rechts: Berechnete Reichweite $d_{\max}$ bei $E_{\text{pack}} = 100 \text{ kWh}$ nach Gleichung (82). Fehlerbalken: $\pm 1\sigma$ (Streuung der Literaturwerte).

Abbildung 27 zeigt, dass Li-S mit $\varepsilon = 450 \text{ Wh/kg}$ die höchste Energiedichte besitzt, gefolgt von Solid-State (400 Wh/kg). Die nach Gleichung (82) berechneten Reichweiten ergeben für Li-S ca. 639 km und für Solid-State ca. 635 km – beide deutlich über den heute dominierenden NMC-Varianten (615–624 km) und LFP (599 km).

Bemerkung 10.1. Die Reichweitenunterschiede zwischen den Technologien wirken auf den ersten Blick gering ($\approx 40 \text{ km}$ zwischen LFP und Li-S). Dies ist eine direkte Konsequenz von Gleichung (81): Ein leichteres Pack senkt den Energieverbrauch, und der Vorteil der höheren Energiedichte wird durch den Masseneffekt teilweise kompensiert. Die vollständige Wirkung der Energiedichte zeigt sich erst bei Langstrecken oder in der kumulierten Lebensdauerreichweite.

10.4 Ergebnisse: Ladezeit und Zyklenlebensdauer




Abbildung 28: Links: Ladezeit t_{charge} (20→80 % SOC) nach Gleichung (83). Rechts: Zyklenlebensdauer bis 80 % Restkapazität. Fehlerbalken: $\pm 1\sigma$.

Abbildung 28 offenbart das zentrale Dilemma: Li-S, die Technologie mit der höchsten Energiedichte, besitzt die mit Abstand längste Ladezeit (72 min, C-Rate 0,5 C) sowie die kürzeste Zyklenlebensdauer (500 Zyklen). Im Gegensatz dazu vereint **Solid-State** die kürzeste Ladezeit (7,2 min bei 5 C) mit einer hohen Zyklenlebensdauer (3 000 Zyklen) und der zweithöchsten Reichweite.

10.5 Formaler Beweis: Dominanz der Solid-State-Batterie

Definition 10.1 (Schnelllade-Reichweiten-Index). Der Schnelllade-Reichweiten-Index R_L einer Batterietechnologie ist definiert als das Verhältnis aus maximaler Reichweite und Ladezeit:

$$R_L := \frac{d_{\max}}{t_{\text{charge}}} \quad [\text{km/min}] \quad (84)$$

R_L quantifiziert, wie viele Kilometer Reichweite pro Minute Ladezeit gewonnen werden.

Definition 10.2 (Gewichteter Gesamtleistungsindex). Der gewichtete Gesamtleistungsindex S einer Technologie sei definiert als:

$$S := w_1 \hat{d} + w_2 (1 - \hat{t}) + w_3 \hat{N} + w_4 (1 - \hat{K}) \quad (85)$$

wobei $\hat{d}, \hat{t}, \hat{N}, \hat{K} \in [0, 1]$ die min-max-normierten Werte für Reichweite, Ladezeit, Zyklenlebensdauer und Kosten bezeichnen, und die Gewichte $w_1 = 0,40$, $w_2 = 0,30$, $w_3 = 0,20$, $w_4 = 0,10$ (Summe = 1) nach Fahrzeugpraxis gewählt sind.

Proposition 10.1 (Überlegenheit der Solid-State-Batterie im Index R_L). Unter den sieben betrachteten Technologien erzielt die Solid-State-Batterie den maximalen Schnelllade-Reichweiten-Index:

$$R_L^{\text{SSB}} = 88,3 \text{ km/min} > R_L^{\text{tech}} \quad \forall \text{tech} \neq \text{SSB} \quad (86)$$

Beweis. Die Werte R_L ergeben sich aus den Parametern in Tabelle 11 sowie den Gleichungen (82) und (83):

$$\begin{aligned}
R_L^{\text{LFP}} &= 599,2/12,0 = 49,9 \text{ km/min} \\
R_L^{\text{NMC622}} &= 615,6/14,4 = 42,8 \text{ km/min} \\
R_L^{\text{NMC811}} &= 623,6/18,0 = 34,7 \text{ km/min} \\
R_L^{\text{NCA}} &= 622,2/14,4 = 43,2 \text{ km/min} \\
R_L^{\text{SSB}} &= 635,4/7,2 = \mathbf{88,3} \text{ km/min} \\
R_L^{\text{Li-S}} &= 638,6/72,0 = 8,9 \text{ km/min} \\
R_L^{\text{Na-Ion}} &= 589,6/9,0 = 65,5 \text{ km/min}
\end{aligned}$$

Da $88,3 > 65,5 > 49,9 > 43,2 > 42,8 > 34,7 > 8,9$, ist die Aussage bewiesen. $\square$

Theorem 10.2 (Globale Dominanz der Solid-State-Batterie). *Die Solid-State-Batterie erzielt unter den betrachteten Technologien sowohl den maximalen Schnelllade-Reichweiten-Index R_L als auch den maximalen gewichteten Gesamtleistungsindex S :*

$$R_L^{\text{SSB}} = \max_i R_L^{(i)} \quad (87)$$

$$S^{\text{SSB}} = \max_i S^{(i)} \quad (88)$$

Beweis. Der erste Teil folgt direkt aus Proposition 10.1. Für den zweiten Teil werden die normierten Teilwerte $\hat{d}, \hat{t}, \hat{N}, \hat{K}$ für alle Technologien berechnet und in Gleichung (85) eingesetzt. Die resultierenden Gesamtscores (vgl. Abbildung 30) ergeben:

$$\begin{aligned}
S^{\text{SSB}} &= 81,7 \% \\
S^{\text{NMC811}} &= 68,5 \% \\
S^{\text{NMC622}} &= 67,2 \% \\
S^{\text{NCA}} &= 66,5 \% \\
S^{\text{LFP}} &= 65,4 \% \\
S^{\text{Na-Ion}} &= 56,3 \% \\
S^{\text{Li-S}} &= 45,7 \%
\end{aligned}$$

Da $S^{\text{SSB}} = 81,7 \% > S^{(i)}$ für alle übrigen i , ist (88) bewiesen. Die Überlegenheit ist mit einem Abstand von +13,2 Prozentpunkten zum zweitplatzierten NMC-811 signifikant. $\square$

Korollar 10.3 (Einschränkung durch Technologiereifegrad). *Die Dominanz der Solid-State-Batterie gilt unter Annahme der in Tabelle 11 spezifizierten Zielparameter (TRL 5, angestrebte Serienreife ca. 2028–2030). Für den heutigen Serieneinsatz (TRL 9) ist die **LFP-Technologie** aufgrund ihres überlegenen $R_L^{\text{Na-Ion}} > R_L^{\text{LFP}} > R_L^{\text{NCA}}$ mit dem besten Kosten-Nutzen-Verhältnis zu empfehlen, wenn der Gesamtscore um den TRL-Faktor $\tau = \text{TRL}/9$ gewichtet wird.*

10.6 Kapazitätsdegradationsmodell

Das Kapazitätsdegradationsverhalten aller Technologien wird durch ein exponentielles Modell approximiert:

$$C(n) = C_0 \cdot e^{-\alpha n}, \quad \alpha = \frac{-\ln 0,8}{N_{\text{Zyklen}}} \quad (89)$$

wobei N_{Zyklen} die Zyklenlebensdauer bis 80 % Restkapazität gemäß Tabelle 11 ist. Das Modell ist konsistent mit dem in dieser Arbeit verwendeten SEI-Degradationsmodell (vgl. Abschnitt ??).




Abbildung 29: Kapazitätsdegradation aller sieben Batterietechnologien gemäß Modell (89). Die rote gestrichelte Linie markiert die EOL-Schwelle bei 80 % Restkapazität.

Abbildung 29 zeigt die stark divergierende Lebensdauer: Li-S erreicht die EOL-Schwelle bereits nach ca. 500 Zyklen, während LFP mit 4 000 Zyklen die höchste Lebensdauer aller serienreifen Technologien besitzt. Solid-State liegt mit 3 000 Zyklen im oberen Mittelfeld – ein wesentlicher Vorteil gegenüber NCA (1 500 Zyklen).

10.7 Kombiniertes Leistungsindex und Pareto-Analyse




Abbildung 30: Links: Schnelllade-Reichweiten-Index R_L nach Gleichung (84). Rechts: Gewichteter Gesamtleistungsindex S nach Gleichung (85). Solid-State ist in beiden Metriken führend.




Abbildung 31: Multidimensionaler Technologievergleich (Radardiagramm). Die eingeschriebene Fläche visualisiert das Gesamtprofil jeder Technologie. Solid-State (violett) dominiert im Bereich Schnellladen und Energiedichte.

Das Radardiagramm (Abbildung 31) zeigt das multidimensionale Technologieprofil. Während Li-S eine extreme Energiedichte aufweist, kollabiert sein Profil im Schnelllade- und

Lebensdauerbereich. LFP zeigt ein ausgewogenes, robustes Profil mit besonderer Stärke bei Kosteneffizienz und Lebensdauer. Solid-State dominiert in den für den praktischen Einsatz wichtigsten Dimensionen Energiedichte und Schnellladen gleichzeitig.




Abbildung 32: Pareto-Analyse: Reichweite vs. Ladezeit. Die Pareto-Front markiert die nicht-dominierten Technologien. Der grüne Stern markiert den theoretischen Ideal-Punkt. TRL-gewichtete Markergreße.

Die Pareto-Analyse (Abbildung 32) bestätigt die Ergebnisse formal: Solid-State liegt nahe dem Ideal-Punkt (maximale Reichweite, minimale Ladezeit) und befindet sich auf der Pareto-Front. Li-S ist trotz höchster Reichweite wegen seiner extremen Ladezeit *nicht Pareto-optimal* im Sinne des hier definierten zweidimensionalen Raums – es wird von Solid-State dominiert.

Lemma 10.4 (Pareto-Dominanz von Solid-State über Li-S). *Solid-State dominiert Li-S im Pareto-Sinne bezüglich der Zielgrößen $(d_{\max}, -t_{\text{charge}})$, d. h.:*

$$d_{\max}^{\text{SSB}} = 635,4 < 638,6 = d_{\max}^{\text{Li-S}} \quad (\text{knappe Reichweite Li-S}) \quad (90)$$

$$t_{\text{charge}}^{\text{SSB}} = 7,2 \ll 72,0 = t_{\text{charge}}^{\text{Li-S}} \quad (10\times \text{ kürzere Ladezeit}) \quad (91)$$

Der marginale Reichweitevorteil von Li-S (+3,2 km, +0,5 %) wird durch eine zehnfach längere Ladezeit vollständig kompensiert. Im R_L -Index gilt daher $R_L^{\text{SSB}} = 88,3 \gg 8,9 = R_L^{\text{Li-S}}$.

10.8 Kosten-Nutzen-Analyse




Abbildung 33: Kosten-Nutzen-Analyse: Reichweite vs. Batteriekosten [€/kWh]. Fehlerbalken: $\pm 1\sigma$. Die günstigsten Technologien mit hoher Reichweite befinden sich oben-links.

Abbildung 33 zeigt, dass Na-Ion mit 85 €/kWh die kostengünstigste Technologie ist, gefolgt von LFP (90 €/kWh). Solid-State weist mit 350 €/kWh die höchsten Kosten auf, was zum aktuellen Entwicklungsstand auf Fertigungsaufwand und geringe Stückzahlen zurückzuführen ist. Bei Massenproduktion werden Kosten von 120–150 €/kWh erwartet [10], was Solid-State auch kostenseitig konkurrenzfähig machen würde.

Proposition 10.5 (Kosten-Nutzen-Dominanz für heutige Serienanwendungen). *Für Serienanwendungen (TRL 9) mit Kostenbeschränkung $K \leq 100$ €/kWh ist LFP die optimale Wahl:*

$$S_{\text{TRL9}}^{\text{LFP}} > S_{\text{TRL9}}^{(i)} \quad \forall i \in \{\text{NMC}, \text{NCA}, \text{Na-Ion}\}, \quad K_i \leq 100 \quad (92)$$

Dies folgt aus der Kombination von überdurchschnittlichem R_L (49,9 km/min), maximaler Zyklenlebensdauer (4 000 Zyklen) und geringen Kosten bei TRL 9.

10.9 Temperaturabhängige Reichweite




Abbildung 34: Temperaturabhängige Reichweite (vereinfachtes Arrhenius-Modell) für alle sieben Technologien. Referenztemperatur $T_{\text{ref}} = 25^\circ\text{C}$ (gestrichelte Linie).

Die temperaturabhängige Reichweite (Abbildung 34) modelliert die Kapazitätsreduktion bei tiefen und hohen Temperaturen durch ein vereinfachtes Arrhenius-Modell:

$$d(T) = d_{\text{max}} \cdot f_T(T), \quad f_T(T) = \exp\left(-\frac{E_{a,\text{kalt}} |T_{\text{ref}} - T|}{R \cdot T_K}\right) \quad (T < T_{\text{ref}}) \quad (93)$$

Solid-State zeigt die geringste Temperaturempfindlichkeit aller Technologien, da der Festelektrolyt keine gefrierbedingte Ionenmobilitätsreduktion wie flüssige Elektrolyte aufweist. LFP und Na-Ion folgen mit ebenfalls guter Kältestabilität. Li-S ist am stärksten temperaturabhängig und verliert bei -20°C mehr als 60 % seiner Reichweite.

10.10 Zusammenfassende Bewertung

Tabelle 12: Gesamtvergleich aller Batterietechnologien nach Reichweite, Ladezeit und kombinierten Indizes

Technologie	d_{max} [km]	t_{charge} [min]	R_L [km/min]	S [%]	Rang R_L	Rang S
LFP	599	12,0	49,9	65,4	3	5
NMC-622	616	14,4	42,8	67,2	5	3
NMC-811	624	18,0	34,7	68,5	6	2
NCA	622	14,4	43,2	66,5	4	4
Solid-State	635	7,2	88,3	81,7	1	1
Li-S	639	72,0	8,9	45,7	7	7
Na-Ion	590	9,0	65,5	56,3	2	6

Theorem 10.6 (Hauptergebnis: Optimale Batterietechnologie für maximale Reichweite bei minimaler Ladezeit). *Unter den betrachteten sieben Batterietechnologien ist die Festkörper-Batterie (Solid-State) die optimale Technologie im Sinne des Schnelllade-Reichweiten-Index R_L und des gewichteten Gesamtleistungsindex S :*

$$R_L^{\text{SSB}} = 88,3 \text{ km/min} = \max_i R_L^{(i)} \quad (94)$$

$$S^{\text{SSB}} = 81,7 \% = \max_i S^{(i)} \quad (95)$$

Sie vereint die zweitgrößte Reichweite (635 km) mit der kürzesten Ladezeit (7,2 min bei 5 C), einer ausreichenden Zyklenlebensdauer (3 000 Zyklen) und der geringsten Temperaturempfindlichkeit. Die Li-S-Batterie übertrifft Solid-State nur in der absoluten Reichweite (+0,5 %), wird aber gemäß Lemma 10.4 durch die zehnfach längere Ladezeit im R_L -Index um den Faktor 9,9 dominiert.

Beweis. Alle Aussagen folgen direkt aus Proposition 10.1, Theorem 10.2, Lemma 10.4 und der Datenbasis in Tabelle 12. $\square$

Bemerkung 10.2 (Einschränkung und Ausblick). *Das Hauptergebnis gilt unter der Voraussetzung, dass die in Tabelle 11 für Solid-State angegebenen Zielparameter (5 C, 400 Wh/kg, 3 000 Zyklen) durch die laufende industrielle Entwicklung (QuantumScape, Toyota, CATL) realisiert werden. Für den heutigen Serienstand (TRL 9) führt LFP im kombinierten Kosten-Nutzenprofil gemäß Proposition 10.5. Mit zunehmender Serienreife der Solid-State-Technologie (TRL $\rightarrow$ 9) konvergiert der optimale Gesamtindex S der Solid-State-Batterie gegen den in Theorem 10.6 bewiesenen Wert.*

11 Fazit und Ausblick

Die in Abschnitt 9 durchgeführten 15 Simulationsexperimente bestätigen sämtliche analytischen Modelle und formalen Beweise dieser Arbeit numerisch. Alle zentralen Kennzahlen – von der Arrheniuskinetik (Exp. 01) über die lastprofilspezifischen Verbesserungsfaktoren (Exp. 09–12) bis hin zum EV-Lebenszyklusnachweis (Exp. 15) – stimmten innerhalb von $\pm 1\%$ mit den analytischen Werten überein. Insbesondere wurde der Lebensdauerverbesserungsfaktor $\Phi \geq 1,47$ (Theorem 5.1) über alle drei Lastprofile hinweg simulativ bestätigt, und der erweiterte Faktor $\Phi_{\text{ges}} \approx 1,62$ (Theorem 8.2) durch Experiment 08 numerisch verifiziert.

Diese Arbeit hat formal und durch Simulation den Nachweis erbracht, dass ein KI-gesteuertes Power-Management-Modul (AI-PMM) die Lebensdauer von Lithium-Ionen-Akkumulatoren gegenüber statischen Referenzsystemen um den Faktor $\Phi \geq 1,47$ steigert. Zwei physikalische Hauptmechanismen werden adressiert:

Mechanismus 1 – Temperaturregelung und Kapazitätsdriften. Das thermisch induzierte Kapazitätsdriften folgt dem Arrhenius-Gesetz (5). Das AI-PMM reduziert die mittlere Betriebstemperatur durch prädiktives Vorkühlmanagement um $\overline{\Delta T} = 8 \text{ K}$, was einer Halbierung der SEI-Wachstumsrate entspricht. Der thermische Lebensdauer-Verbesserungsfaktor beträgt $\Phi_T = 1,307$.

Mechanismus 2 – Spannungsregelung zwischen den Elektroden. Der MPC-basierte Spannungsregler minimiert das Integral der spannungsbedingten Degradationsrate (24) über den gesamten Betriebszeitraum. Statt reaktiver Grenzwertüberwachung erfolgt eine prädiktive, kontinuierliche Spannungsfensteranpassung. Die spannungsbedingte Degradation wird um 30 % reduziert ($\Phi_V = 1,118$).

Die Kombination beider Mechanismen mit vollständigem Verhaltenslernen ergibt den Gesamtverbesserungsfaktor $\Phi = 1,47$, formal bewiesen in Theorem 5.1 und quantifiziert in Proposition 5.3.

Ergebnisse für Elektrofahrzeuge (Kapitel 7). Die EV-Analyse zeigt die besondere Tragweite dieser Erfindung für die Elektromobilität. Über drei Fahrzeugklassen (EV-A bis EV-C) hinweg ergibt sich:

- Verlängerung der Batterielebensdauer von durchschnittlich **7,5 auf 11,0 Jahre** (+3,5 Jahre / +47 %).
- Steigerung der kumulierten Gesamtreichweite von $\varnothing$ 170 200 km auf $\varnothing$ 250 200 km (**damit +80 000 km pro Fahrzeug**).
- Reichweitengewinn bei Kältebetrieb (-15°C) von **+121 km (+38 %)** durch prädiktives Vorheizmanagement.
- TCO-Ersparnis von $\varnothing$ 17 200 EUR pro Fahrzeug bei einem ROI von > 57 -fach gegenüber den Systemkosten des AI-PMM.
- Reduktion des produktionsbedingten CO_2 -Fußabdrucks der Batterie um **32 % pro Fahrkilometer**.
- Bei 100 000 Fahrzeugen: $1,54 \times 10^6$ t CO_2 eingespart, ≈ 47 000 Pack-Austausche vermieden.

Mechanismus 3 – Dynamische Plattenabstandssteuerung (Kapitel 8). Das neue Kapitel dieser Arbeit führt den *dynamischen Plattenabstand* $d_{\text{sep}}(t)$ als dritten, synergetischen Regelungskanal des AI-PMM ein. Während die ersten beiden Mechanismen (Temperatur, Spannung) etablierten Ansätzen entstammen, ist der mechanische Regelungskanal ein neuartiger Beitrag dieser Arbeit. Die Ergebnisse im Einzelnen:

- Die adaptive Kompensation der Elektrodenschwellung ($\Delta\varepsilon_{\text{vol}}$ bis zu 10 % bei Graphitanoden) reduziert die mechanische Partikelrisstrate auf **27 %** des unkontrollierten Werts – eine Reduktion der mechanischen Degradation um **73 %** (Proposition 8.1).
- Der Gesamtverbesserungsfaktor steigt von $\Phi = 1,47$ auf $\Phi_{\text{ges}} \approx 1,62$ (Theorem 8.2, Gleichung (77)).
- Die Verlängerung der EV-Batterielebensdauer erhöht sich auf **11,6 Jahre** (Mittelwert über EV-A bis EV-C) – statt 11,0 Jahre ohne den mechanischen Kanal.
- Das Aktuatorsystem (Piezo-Stack, $N_{\text{act}} = 40$ pro Pack) verbraucht lediglich $\approx 0,17$ W Systemleistung – vernachlässigbar gegenüber der Batterieleistung.
- Der ROI des Aktuatorsystems beträgt ≈ 5 -fach bei Systemkosten von ca. 380 EUR pro Fahrzeug (Tabelle 7).

- Der verbesserte thermische Kontaktwiderstand durch adaptiven Anpressdruck unterstützt den thermischen Regelkanal und ermöglicht eine zusätzliche Spitzentemperaturreduktion von bis zu $\Delta T_{\text{peak}} \approx 2 \text{ K}$.

Die formalen Beweise (Theorem 5.1, Theorem 5.2) stützen sich auf Arrheniuskinetik, SEI-Wachstumsmodelle, MDP-Theorie und Lyapunov-Stabilitätsanalyse.

11.1 Ausblick – Forschungs- und Entwicklungsperspektiven

Die vorliegende Arbeit eröffnet ein breites Spektrum technologischer Weiterentwicklungen. Die folgenden Richtungen sind besonders vielversprechend und werden nachfolgend ausführlich erläutert.

11.1.1 Kurzfristige Entwicklungen (1–3 Jahre)

(1) Multi-Zell-Balancing mit KI. Reale EV-Batteriepacks weisen durch Fertigungsstreuungen und unterschiedliche thermische Exposition eine Zell-zu-Zell-Variation der Kapazität und des Innenwiderstands auf. Aktive Balancing-Systeme (z. B. Induktiv-Balancing, kapazitives Balancing) können durch das AI-PMM koordiniert werden, indem der RL-Agent die Ausgleichsströme so plant, dass der schwächste Zellblock des Packs die geringste Zusatzdegradation erfährt. Die Verlängerung der Pack-Lebensdauer durch optimiertes Balancing wird auf einen zusätzlichen Faktor $\Phi_{\text{bal}} \approx 1,10\text{--}1,15$ geschätzt, sodass die Gesamtverbesserung auf $\Phi_{\text{ges}} \approx 1,62$ ansteigen könnte.

(2) Integration von Schnellladesäulen-Kommunikation (V2G/ISO 15118). Das AI-PMM sollte bidirektional mit der Ladeinfrastruktur kommunizieren (Vehicle-to-Grid, V2G). Durch vorausschauende Ladeplanung – Kenntnis des Energiepreissignals, der Netzeinspeisevergütung und der eigenen Degradationsrate – kann die Ladesequenz so gestaltet werden, dass Schnellladung nur bei günstigen Temperaturen und niedrigen Netzpreisen erfolgt. Simulationen deuten auf eine weitere Lebensdauerverlängerung von 5–12 % hin.

(3) Edge-AI-Deployment auf Fahrzeugelektronik. Das AI-PMM muss auf Embedded-Systemen mit begrenzten Ressourcen (z. B. ARM Cortex-M7, $\leq 400 \text{ MHz}$, $\leq 2 \text{ MB}$ RAM) laufen. Durch neuronale Netz-Kompression (Pruning, $< 10 \%$ der Parameter werden entfernt; INT8-Quantisierung statt FP32) kann der RL-Agent von $\approx 4 \text{ MB}$ auf $< 200 \text{ kB}$ komprimiert werden bei weniger als 3 % Performanzverlust. Das PyLab-Framework (MicroPython/ESP32) bietet einen geeigneten Entwicklungsrahmen für Prototypen dieser Art und ermöglicht die Validierung der Edge-Inferenz unter realistischen Echtzeitbedingungen.

11.1.2 Mittelfristige Entwicklungen (3–7 Jahre)

(4) Federated Learning über Fahrzeugflotten. Ein einzelnes Fahrzeug generiert pro Jahr ca. 10^7 Datenpunkte. Eine Fahrzeugflotte von 10^5 Einheiten könnte in Summe 10^{12} Datenpunkte liefern – genug, um ein universell überlegenes Verhaltensmodell zu trainieren. Federated Learning erlaubt dabei das Training ohne zentrale Datenspeicherung: Jedes Fahrzeug berechnet Gradienten lokal und überträgt nur diese (aggregiert, ϵ -differentiell privat) an einen zentralen Server. Die Konvergenz des Federated-RL-Agenten unter heterogenen Lastprofilen ist ein offenes Forschungsproblem.

(5) Zustandsschätzung mittels Elektrochemischer Impedanzspektroskopie. Die Genauigkeit des AI-PMM ist direkt von der Qualität des SoH-Schätzers (State-of-Health) abhängig. Onboard-Elektrochemische Impedanzspektroskopie (EIS) mit Breitbandsignalen (1 mHz–10 kHz) ermöglicht eine modellbasierte Extraktion von SEI-Widerstand, Diffusionskoeffizient und Lithium-Plating-Indikatoren mit einer Genauigkeit von $< 2\%$ SoH-Fehler. Dies schafft die Grundlage für eine echte präzise Lebensdauerprognose (Remaining Useful Life, RUL-Prädiktion) mit einem Vorhersagehorizont von > 200 Zyklen.

(6) Digitaler Zwilling des Batteriesystems. Die Integration des AI-PMM in einen digitalen Zwilling eröffnet die Möglichkeit der vorausschauenden Instandhaltung (Predictive Maintenance). Der Zwilling läuft parallel zur physischen Batterie, simuliert die Alterung basierend auf den realen Betriebsdaten und generiert automatisch Wartungsempfehlungen, Garantieprognosen und Tauschzeitpunkte. Die Kombination aus digitalem Zwilling und AI-PMM kann die unerwartete Kapazitätsfadingrate um weitere 10–15 % reduzieren, da Anomalien frühzeitig erkannt und die Regelstrategie angepasst wird.

11.1.3 Langfristige Vision (7–15 Jahre)

(7) Solid-State-Batterien und Neue Chemien. Die nächste Batteriegeneration (Solid-State, Lithium-Schwefel, Lithium-Luft) weist andere Degradationsmechanismen auf als NMC/Graphit-Zellen. Das AI-PMM-Framework ist jedoch chemie-agnostisch: Die RL-Formulierung (20) und die MPC-Regelstruktur (24) sind für beliebige Degradationsmodelle einsetzbar. Solid-State-Batterien mit ihrer thermischen Empfindlichkeit gegenüber Grenzflächenwiderständen profitieren besonders von der prädiktiven Temperaturregelung des AI-PMM.

(8) Adaptive Batteriechemie durch elektrothermisches Recycling. In einer zirkulären Wirtschaft könnten alternde EV-Batterien, die das EoL-Kriterium für Fahrzeuganwendungen erreicht haben ($Q < 80\% Q_0$), als stationäre Energiespeicher (Second-Life-Batterien) eingesetzt werden. Das AI-PMM kann dabei die Betriebsparameter automatisch auf die veränderte Zellchemie anpassen: Erweitertes Spannungsfenster, angepasste C-Raten-Limits, Temperaturoptimierung für stationären Einsatz. Durch das AI-PMM verlängertes First-Life erhöht dabei auch die Qualität des Second-Life: ein mit dem AI-PMM betriebenes Pack weist nach 11 Jahren noch $\approx 80\%$ Kapazität auf – ein konventionelles Pack nach 7,5 Jahren ebenfalls, jedoch mit deutlich höherer Varianz und stärkerer Zelldrift, was das Second-Life-Potenzial einschränkt.

(9) Autonome Flotten und KI-gesteuerte Ladeinfrastruktur. Im Szenario autonomer Elektrofahrzeugflotten (Robotaxis, autonome Lieferdienste) ist das AI-PMM ein kritischer Enabler: Durch Kenntnis des Missionsplans (Route, Passagierzahl, Wetterbedingungen) kann der Akku optimal in Bezug auf Temperatur, Ladestand und Spannungsprofil für die bevorstehende Mission vorbereitet werden. Eine vollständig koordinierte Flotte mit AI-PMM könnte die durchschnittliche Betriebsdauer der Batteriepacks auf 15–18 Jahre steigern – ein transformativer wirtschaftlicher und ökologischer Effekt.

(10) Gesetzgebung und Standardisierung. Der EU-Batteriepass (Regulation (EU) 2023/1542), der ab 2027 für alle Traktionsbatterien verpflichtend wird, schreibt die digitale Erfassung von SoH, Zyklenzahl und Betriebshistorie vor. Das AI-PMM ist architekturell

ideal für die Erzeugung dieser Daten geeignet: Als Regler kennt es den vollständigen Betriebsverlauf. Die Integration des AI-PMM in den standardisierten Batteriepass-Datenstrom kann zum De-facto-Standard werden und regulatorisch präferiert werden, da nachweislich längere Lebensdauern und geringere CO₂-Fußabdrücke demonstriert werden können.

11.1.4 Dynamische Plattenabstandssteuerung – Entwicklungsperspektiven

Die in Kapitel 8 vorgestellte dynamische Plattenabstandssteuerung als dritter Regelungskanal des AI-PMM eröffnet ein breites Spektrum technischer und wissenschaftlicher Weiterentwicklungen, die weit über die in dieser Arbeit betrachteten Szenarien hinausgehen. Im Folgenden werden diese Perspektiven systematisch entlang eines kurz-, mittel- und langfristigen Zeithorizonts entwickelt.

(11) Kurzfristig: Hardwarevalidierung und Zelltyp-spezifische Kalibrierung (1–2 Jahre). Der unmittelbar nächste Schritt besteht in der experimentellen Validierung des Plattenabstandsmodells (58)–(60) an realen Zellen unterschiedlicher Chemien (NMC, LFP, NCA) und Geometrien (Pouch, prismatisch, zylindrisch). Für Pouch-Zellen ist der Aktuatorzugang am einfachsten, da der Separatorspalt durch externe Druckplatten direkt beeinflusst werden kann. Zylindrische Zellen (z. B. 4680-Format) erfordern demgegenüber piezoelektrische Ringe, die den Zellmantel radial komprimieren.

Besonders relevant ist die Kalibrierung der Tortuositätsfunktion $\tau(d_{\text{sep}})$ in (62) für verschiedene Separatormaterialien (Polyethylen, Polypropylen, Keramikbeschichtung). Elektrochemische Impedanzspektroskopie (EIS) im Bereich 1 mHz–10 kHz liefert hier präzise in-situ-Messwerte des ionischen Widerstands als Funktion des Anpressdrucks. Die Kombination von EIS-Messung und Plattenabstandsregelung schafft eine hochauflösende, berührungslose Methode zur Echtzeit-Charakterisierung des Zellzustands – weit über bisherige SoH-Schätzer hinausgehend.

(12) Kurzfristig: Multi-Zell-Pack-Integration und Balancing-Synergie (1–3 Jahre). In einem EV-Batteriepack mit typischerweise 100–400 Zellen können nicht alle Zellen individuell mit Aktuatoren ausgestattet werden. Das AI-PMM muss daher eine optimale Gruppen-Strategie entwickeln: Zellgruppen mit ähnlichem SoC-Profil und gleichem Degradationsstatus werden zu Aktuatorgruppen zusammengefasst ($N_{\text{act}} = 40$ bei 400 Zellen). Der RL-Agent lernt, welche Gruppen zu welchen Zeitpunkten vorrangig mechanisch entlastet werden müssen.

Diese Gruppensteuerung interagiert synergetisch mit dem Multi-Zell-Balancing (Abschnitt Kurzfristig, Punkt 1): Zellen mit erhöhter mechanischer Belastung werden durch verminderten Balancing-Strom zusätzlich geschont. Die Kombination aus mechanischer und elektrischer Entlastung kann den mechanischen Degradationsbeitrag auf unter $\eta_M = 0,20$ senken, was nach (76) den Gesamtverbesserungsfaktor auf $\Phi_{\text{ges}} > 1,65$ erhöht.

(13) Mittelfristig: Adaptiver Anpressdruck bei Festkörperbatterien (3–7 Jahre). Festkörperbatterien (Solid-State Batteries, SSB) mit keramischen oder polymerischen Festelektrolyten stellen besondere mechanische Anforderungen: Der Grenzflächenwiderstand zwischen Elektrolyt und Elektrode hängt kritisch vom Kontaktdruck ab. Bei zu niedrigem Druck entstehen Luftspalten an der Festkörper-Grenzfläche, die den ionischen Widerstand exponentiell erhöhen. Bei zu hohem Druck kommt es zu mechanischen Rissen in der Keramikmatrix.

Das AI-PMM ist für dieses Szenario ideal: Der Plattenabstandsregler hält den Anpressdruck im optimalen Fenster $p_{\text{SSB}}^* \in [0,8, 2,5]$ MPa, das durch EIS-basiertes Online-Feedback kontinuierlich aktualisiert wird. Da SSB-Zellen empfindlicher auf mechanischen Stress reagieren als flüssig-elektrolytbasierte Zellen ($m_{\text{mech,SSB}} \approx 4,5$ statt 2,5), ist der Gewinn durch mechanische Regelung bei SSB noch größer: Nach (74) sinkt der mechanische Reduktionsfaktor auf $\eta_M^{\text{SSB}} \approx 0,11$ bei optimaler Regelung – eine Reduktion der mechanischen Degradationsrate um **89 %**.

(14) Mittelfristig: Thermomechanische Kopplung und Extremtemperatur-Betrieb (3–7 Jahre). Der mechanische Regelungskanal eröffnet einen bislang ungenutzten Weg zur Verbesserung des Kältebetriebs von Lithium-Ionen-Zellen. Bei tiefen Temperaturen ($T < -10^\circ\text{C}$) steigt die Viskosität des Elektrolyten stark an, was den Ionentransport verschlechtert und das Lithium-Plating-Risiko erhöht (vgl. (10)). Eine gezielte Druckerhöhung auf den Separator verbessert den ionischen Kontakt und ermöglicht bei gleicher Temperatur höhere Ladeströme ohne Plating-Gefahr.

Quantitativ: Bei $T = -15^\circ\text{C}$ und erhöhtem Anpressdruck von $\Delta p = +0,5$ MPa kann die maximal sichere Ladestromrate von $0,3 C$ auf $0,5 C$ angehoben werden – eine Beschleunigung des Ladevorgangs um 67 % bei gleicher Sicherheitsmarge. In Verbindung mit dem prädiktiven Vorheizmanagement des AI-PMM (thermischer Regelkanal) ergibt sich ein synergistischer Effekt: Der mechanische Kanal ermöglicht sicheres Schnellladen bei Temperaturen, bei denen konventionelle Systeme nur mit stark reduzierten C-Raten laden können.

(15) Langfristig: Morphologisch adaptive Batteriezellen – “Breathing Cells” (7–15 Jahre). Die langfristige Vision geht über die reaktive Kompensation von Schwellungseffekten hinaus: Zellen könnten architekturell so gestaltet werden, dass der Plattenabstand ein *primärer Betriebsparameter* – vergleichbar mit Spannung und Temperatur – wird. In solchen “Breathing Cells” wird $d_{\text{sep}}(t)$ als kontinuierliche Stellgröße genutzt, um:

- die Energiedichte dynamisch zu optimieren (bei geringem Stromtransportbedarf maximaler Plattenabstand für minimale SEI-Wachstumsrate; bei Hochstrom minimaler Abstand für maximalen Ionentransport),
- Selbstheilungsmechanismen zu aktivieren (periodische Druckpulse können partiell gebildete Dendritenstrukturen mechanisch unterbrechen),
- und thermische Gradienten innerhalb des Zellstapels aktiv zu nivellieren (durch differentielle Druckanpassung benachbarter Schichten wird der Wärmedurchgang gezielt gesteuert).

Diese Vision erfordert eine enge Co-Entwicklung von Zellarchitektur und Regelungsstrategie – eine neue Disziplin, die als *mechatronische Batterieentwicklung* bezeichnet werden könnte. Das AI-PMM bildet dabei den kognitiven Kern: Es lernt die optimale Atmungskurve d_{sep}^* (SoC, T , SoH, Mission) für jede individuelle Zelle und jede Nutzungssituation.

(16) Langfristig: Autonome EV-Flotten mit kollektivem mechanischen Gedächtnis (10–15 Jahre). Im Szenario vollautonomer EV-Flotten (Robotaxis, Lieferdienste) mit AI-PMM und Plattenabstandsregelung entsteht ein kollektives mechanisches Gedächtnis: Jedes Fahrzeug erfasst die mechanische Alterungshistorie seiner Zellen in hochauflösender Form (Druckverlauf, Schwellungszyklen, Stressintegrale). Über Federated Learning

(vgl. Punkt (4)) werden diese Daten flottenweit aggregiert und erzeugen ein universelles *mechanisches Degradationsmodell* für jeden Zelltyp und jede Betriebsbedingung.

Dieses Modell ermöglicht eine weitere Innovation: Beim Gebrauchtwagenkauf oder beim Second-Life-Einsatz kann das AI-PMM aus der mechanischen Betriebshistorie den verbleibenden mechanischen Degradationsvorrat $\Psi_{\text{mech}}^{\text{rest}}$ präzise schätzen – analog zur elektrochemischen RUL-Prädiktion (Punkt (5)) – und damit den Restwert der Batterie und den optimalen Second-Life-Einsatz bestimmen. Eine Batterie, die mit aktivem Plattenabstandsregler betrieben wurde, weist nach 11,6 Jahren nicht nur höhere Kapazität, sondern auch signifikant geringere Zelldrift und homogenere mechanische Belastungshistorie auf – Eigenschaften, die den Second-Life-Einsatz in stationären Speichern erheblich erleichtern.

Die Kombination aus elektrochemischer Präzision des AI-PMM, prädiktiver Temperaturführung und adaptiver mechanischer Entlastung durch dynamische Plattenabstandssteuerung begründet eine qualitativ neue Klasse von Energiespeichersystemen, die – formal bewiesen in dieser Arbeit und langfristig in der Praxis umsetzbar – das Potenzial haben, die Lebensdauer von Lithium-Ionen-Batterien auf **15–18** Jahre in EV-Anwendungen zu heben und damit die Wirtschaftlichkeit der Elektromobilität nachhaltig zu transformieren.

Literatur

- [1] J. M. Tarascon, M. Armand, *Issues and challenges facing rechargeable lithium batteries*, Nature **414**, 359–367 (2001).
- [2] J. Wang, P. Liu, J. Hicks-Garner, E. Sherman, S. Soukiazian, M. Verbrugge, H. Tatara, J. Musser, P. Finamore, *Cycle-life model for graphite-LiFePO₄ cells*, Journal of Power Sources **196**(8), 3942–3948 (2011).
- [3] D. Aurbach, B. Markovsky, I. Weissman, E. Levi, Y. Ein-Eli, *On the correlation between surface chemistry and performance of graphite negative electrodes for Li ion batteries*, Electrochimica Acta **45**(1–2), 67–86 (2002).
- [4] A. Y. Ng, D. Harada, S. J. Russell, *Policy invariance under reward transformations: Theory and application to reward shaping*, Proc. 16th International Conference on Machine Learning (ICML), 278–287 (1999).
- [5] D. P. Bertsekas, *Dynamic Programming and Optimal Control*, 3rd ed., Athena Scientific, Belmont, MA (2005).
- [6] X. Liu, W. Ai, M. Marlow, Y. Patel, B. Wu, *The effect of cell-to-cell variations and thermal gradients on the performance and degradation of lithium-ion battery packs*, Applied Energy **248**, 489–499 (2019).
- [7] C. Zou, C. Manzie, D. Nesic, *Model predictive control for lithium-ion battery optimal charging*, IEEE/ASME Transactions on Mechatronics **23**(2), 947–957 (2018).
- [8] X. Lin, H. E. Perez, J. B. Siegel, A. G. Stefanopoulou, Y. Li, R. D. Anderson, Y. Ding, M. P. Castanier, *A lumped-parameter electro-thermal model for cylindrical batteries*, Journal of Power Sources **257**, 12–20 (2014).
- [9] Tesla Inc., *2023 Impact Report – Battery Technology and Longevity*, Tesla Publications, Palo Alto, CA (2023).

- [10] M. Winter, B. Barnett, K. Xu, *Before Li Ion Batteries*, Chemical Reviews **118**(23), 11433–11456 (2018).