

Low Latency DOCSIS – Forschungspotenziale für Intelligenter Bandbreite

Formale Analyse, mathematische Nachweise und
Anwendungsfelder in sieben Forschungsdimensionen

Stephan Epp

Universität Bielefeld – Senior Software Developer & Independent Researcher

<https://github.com/hjstephan86/science/tree/main/science/>

21. Mai 2026

Abstract

Das DOCSIS-Protokoll (Data Over Cable Service Interface Specification) bildet die technische Grundlage für breitbandige Internetzugänge über Hybridnetzwerke aus Glasfaser und Koaxialkabel (HFC). Mit der Einführung von Low Latency DOCSIS (LLD) als Erweiterung des DOCSIS-3.1-Standards und dessen Weiterentwicklung in DOCSIS 4.0 wurde erstmals eine systematische Reduktion der Leitungslatenzen unter 5 ms (99. Perzentil) ermöglicht – ohne Einbußen beim Durchsatz. Diese Arbeit identifiziert und formalisiert sieben eigenständige Forschungspotenziale an der Grenze des aktuellen Wissensstandes: (1) proaktives Grant-Sharing und Bandbreitenerückgewinnung, (2) maschinenlernenbasierte dynamische Bandbreitenzuweisung, (3) L4S-/DualPI2-AQM-Koexistenz und Emulation, (4) 5G/DOCSIS-Konvergenz via LLX-over-DOCSIS, (5) vertikale Anwendungsdomänen (Telehealth, V2X), (6) intelligente Traffic-Klassifikation unter Verschlüsselung sowie (7) industrielle Rollout-Dynamik und offene Standardisierungsaufgaben. Für jedes Feld werden Definitionen, Sätze, Lemmata und vollständige Beweise im Stil einer mathematischen Abhandlung entwickelt sowie durch visualisierte Simulationen illustriert. Die Arbeit schließt mit einem umfangreichen Ausblick auf zukünftige Forschungsrichtungen.

Contents

1	Einführung	2
1.1	Das Latenzproblem in kabelgebundenen Breitbandnetzen	2
1.2	Stand der Technik und Forschungslücken	2
1.3	Zielsetzung und Beitrag dieser Arbeit	2
2	Mathematische Grundlagen: Das LLD-Modell	3
2.1	Formales Netzwerkmodell	3
3	Forschungspotenzial 1: Proaktives Grant-Sharing	4
3.1	Problemstellung	4

4	Forschungspotenzial 2: ML-gestützte Dynamische Bandbreitenzuweisung	5
4.1	Dynamische Bandbreitenzuweisung als Optimierungsproblem	5
5	Forschungspotenzial 3: L4S/DualPI2-AQM – Koexistenz und Emulation	6
5.1	Die L4S-Architektur	6
6	Forschungspotenzial 4: DOCSIS 4.0 und 5G-Konvergenz	7
6.1	LLX-over-DOCSIS: Konzept und Formalisierung	7
7	Forschungspotenzial 5: Vertikale Anwendungsdomänen	8
7.1	Formale Latenzklassifikation vertikaler Dienste	8
8	Forschungspotenzial 6: Intelligente Traffic-Klassifikation	10
8.1	Problemstellung: Klassifikation unter Verschlüsselung	10
9	Forschungspotenzial 7: Industrieller L4S-Rollout 2025/2026	11
9.1	Rollout-Dynamik und Standardisierungs offene Fragen	11
10	Ausblick: Forschungsrichtungen und offene Fragen	12
10.1	Überblick: Wissenschaftliche Bedeutung von LLD-Forschung	12
10.2	Ausblick: Proaktives Grant-Sharing	13
10.3	Ausblick: ML-gestützte DBA	13
10.4	Ausblick: L4S/DualPI2-Koexistenz und Emulation	13
10.5	Ausblick: 5G/DOCSIS-Konvergenz	14
10.6	Ausblick: Vertikale Anwendungsdomänen	14
10.7	Ausblick: Intelligente Traffic-Klassifikation	15
10.8	Ausblick: Industrieller L4S-Rollout	15
10.9	Verbindungen zur formalen Graphentheorie	16
10.10	Fazit des Ausblicks	16

1 Einführung

1.1 Das Latenzproblem in kabelgebundenen Breitbandnetzen

Seit der Einführung des DOCSIS-Standards in den 1990er-Jahren wurde die technische Entwicklung von Kabelnetzwerken primär durch die Steigerung des Datendurchsatzes getrieben. DOCSIS 3.0 ermöglichte durch Kanalbindung (Channel Bonding) Downstream-Raten von mehreren hundert Megabit pro Sekunde; DOCSIS 3.1 erweiterte dies durch OFDM/OFDMA auf über 10 Gbps im Downstream und 1–2 Gbps im Upstream. Die Netzwerklatenz – als zweite fundamentale Qualitätsdimension nach dem Durchsatz – blieb dabei jedoch weitgehend vernachlässigt.

Das Latenzproblem in HFC-Netzen hat strukturelle Ursachen:

- **Upstream-Scheduling-Latenz:** Im DOCSIS-Upstream-Kanal teilen sich alle Kabelmodems eines Segments denselben physikalischen Kanal (TDMA/OFDMA). Datenpakete dürfen nur in explizit zugewiesenen Zeitslots (Grants) gesendet werden. Ist ein Modem nicht im Besitz eines aktiven Grants, akkumuliert sich Latenz durch Warteschlangen bis zur nächsten Grantzuweisung.
- **Bufferbloat:** Große Pufferspeicher in CMTS-Geräten (Cable Modem Termination Systems) verhinderten Paketverluste, führten jedoch zu exzessiven Warteschlangenlatenzen von 50–200 ms unter Last.
- **MAC-Protokoll-Overhead:** Der Mechanismus aus Grant-Request und Grant-Response fügt selbst bei leerem Kanal eine Mindestrundlaufzeit (Propagation + MAC-Delay) von typischerweise 4–10 ms hinzu.

Low Latency DOCSIS (LLD) adressiert diese Probleme durch drei Hauptmechanismen: Proactive Grants (vorab zugewiesene Minimalkapazität für latenzempfindliche Flows), Active Queue Management (AQM) nach dem L4S-Prinzip [1] sowie Traffic Classification zur Trennung latenzkritischer von bulk-Transfer-Daten.

1.2 Stand der Technik und Forschungslücken

Trotz des erreichten technischen Fortschritts existieren fundamentale offene Fragen, die weder durch die aktuelle Standardisierungsarbeit der CableLabs-Organisation noch durch die akademische Literatur vollständig beantwortet wurden. Diese Arbeit identifiziert und formalisiert sieben eigenständige Forschungsfelder mit unmittelbarem wissenschaftlichen und praktischen Potenzial.

1.3 Zielsetzung und Beitrag dieser Arbeit

Die vorliegende Arbeit verfolgt vier Ziele:

1. Formale Mathematisierung der sieben identifizierten Forschungsfelder mittels Definitionen, Sätzen und vollständigen Beweisen
2. Simulation und Visualisierung der zentralen Ergebnisse durch reproduzierbare matplotlib-Experimente
3. Verbindung der DOCSIS-Domäne mit modernen Methoden aus Machine Learning, formaler Algorithmik und Graphentheorie

4. Ausarbeitung eines umfassenden Forschungsausblicks

2 Mathematische Grundlagen: Das LLD-Modell

2.1 Formales Netzwerkmodell

Definition 1 (HFC-Segment). Ein *HFC-Segment* ist ein Tupel $\mathcal{S} = (\mathcal{M}, C, T)$, wobei $\mathcal{M} = \{m_1, \dots, m_N\}$ die Menge der N angeschlossenen Kabelmodems, $C > 0$ die nominale Upstream-Kanalkapazität in bit/s und $T > 0$ die DOCSIS-MAP-Periode (typisch $T = 2$ ms) bezeichnen.

Definition 2 (Grant-Zuweisung). Sei $\mathcal{S}$ ein HFC-Segment. Eine *Grant-Zuweisung* für die MAP-Periode k ist eine Funktion

$$G^{(k)} : \mathcal{M} \longrightarrow [0, C \cdot T],$$

die jedem Modem m_i eine Sendezeitkapazität (in Bit) zuordnet, unter der Kapazität-snebenbedingung

$$\sum_{i=1}^N G^{(k)}(m_i) \leq C \cdot T.$$

Definition 3 (Warteschlangenlatenz). Die *Warteschlangenlatenz* eines Pakets p mit Ankunftszeit t_a und Abgangszeit t_d im System ist

$$W(p) = t_d - t_a - \frac{|p|}{C},$$

wobei $|p|$ die Paketlänge in Bit bezeichnet. Die *erwartete Warteschlangenlatenz* für Modem m_i unter Last ρ_i ist gemäß der M/D/1-Approximation

$$\mathbb{E}[W_i] \approx \frac{\rho_i \cdot T}{2(1 - \rho_i)},$$

wobei $\rho_i = \lambda_i / \mu_i$ das Verhältnis von Ankunftsrate λ_i zur Bedienrate $\mu_i = G^{(k)}(m_i)/T$ ist.

Satz 1 (Latenz-Kapazitäts-Dilemma ohne LLD). Sei $\mathcal{S}$ ein HFC-Segment mit N Modems, gleichmäßiger Last $\rho_i = \rho$ für alle i , und sei $G^{(k)}(m_i) = C \cdot T/N$ (Gleichverteilung). Dann gilt

$$\mathbb{E}[W_i] = \frac{\rho \cdot T}{2(1 - \rho)} \xrightarrow{\rho \rightarrow 1} \infty.$$

Insbesondere überschreitet $\mathbb{E}[W_i]$ das LLD-Ziel $W_{\text{ziel}} = 1$ ms für alle $\rho > \rho^* = 1/(1 + T/(2W_{\text{ziel}}))$.

Proof. Die Formel für $\mathbb{E}[W_i]$ folgt direkt aus der Pollaczek-Khinchine-Formel für die M/D/1-Warteschlange mit deterministischer Bedienzeit T und Ankunftsrate $\lambda_i = \rho \cdot \mu_i$. Die Grenzwertaussage ergibt sich aus $\lim_{\rho \rightarrow 1} \rho/(2(1 - \rho)) = +\infty$. Für die Schwelle ρ^* lösen wir $\rho T/(2(1 - \rho)) = W_{\text{ziel}}$ nach ρ auf:

$$\rho T = 2W_{\text{ziel}}(1 - \rho) \implies \rho(T + 2W_{\text{ziel}}) = 2W_{\text{ziel}} \implies \rho^* = \frac{2W_{\text{ziel}}}{T + 2W_{\text{ziel}}} = \frac{1}{1 + T/(2W_{\text{ziel}})}.$$

Für $T = 2$ ms und $W_{\text{ziel}} = 1$ ms ergibt sich $\rho^* = 1/2 = 50\%$, d. h. das LLD-Ziel wird bereits bei halber Kanalauslastung verletzt. $\square$

Korollar 1. LLD ist für reale HFC-Netze ($\rho > 0.5$ in Lastzeiten) ohne aktive Latenzkontrollmechanismen strukturell nicht erfüllbar.

3 Forschungspotenzial 1: Proaktives Grant-Sharing

3.1 Problemstellung

Der LLD-Standard reserviert für latenzempfindliche Flows (Low-Latency-Queue, LLQ) Proactive Grants in regelmäßigen Intervallen. Wird dieser Grant nicht vollständig genutzt – weil der entsprechende Flow in der betreffenden MAP-Periode wenig oder keine Daten sendet – verfällt die reservierte Kapazität ungenutzt. Dies führt zu signifikanter Bandbreitenverschwendung, die bei kleinen Latenzzielen besonders ausgeprägt ist.

Definition 4 (Grant-Verschwendung). Sei $g_i^{(k)}$ der LLQ-Grant für Modem m_i in Periode k und $u_i^{(k)} \leq g_i^{(k)}$ die tatsächlich genutzte Kapazität. Die *Grant-Verschwendung* ist

$$\Delta^{(k)} = \sum_{i=1}^N (g_i^{(k)} - u_i^{(k)}) \geq 0.$$

Der *mittlere Verschwendungsanteil* über K Perioden ist

$$\bar{\delta} = \frac{1}{K} \sum_{k=1}^K \frac{\Delta^{(k)}}{C \cdot T}.$$

Satz 2 (Verschwendungsunterschranke bei Proactive Grants). Sei $g_i = g > 0$ ein fester LLQ-Grant pro Modem und sei der LLQ-Traffic von Modem m_i poissonverteilt mit Rate $\lambda_i = \alpha \cdot g/T$, $\alpha \in (0, 1)$. Dann gilt für die erwartete Grant-Verschwendung

$$\mathbb{E}[\Delta^{(k)}] \geq N \cdot g \cdot (1 - \alpha).$$

Proof. Für Modem m_i gilt $\mathbb{E}[u_i^{(k)}] = \lambda_i \cdot T = \alpha \cdot g$ (da in einer Periode T im Erwartungswert $\lambda_i T$ Bits ankommen). Da $u_i^{(k)} \leq g_i^{(k)} = g$ und $u_i^{(k)} \geq 0$:

$$\mathbb{E}[g_i^{(k)} - u_i^{(k)}] = g - \mathbb{E}[u_i^{(k)}] = g(1 - \alpha).$$

Summation über alle N Modems liefert die Aussage. □

Definition 5 (Grant-Sharing-Algorithmus). Ein *Grant-Sharing-Algorithmus* $\mathcal{GS}$ ist ein Online-Algorithmus, der in jeder Periode k die ungenutzte Grant-Kapazität $r_i^{(k)} = g_i^{(k)} - u_i^{(k)}$ identifiziert und diese an die Best-Effort-Queue (BEQ) der Modems umverteilt:

$$g_i^{\text{BEQ},(k)} = g_i^{\text{BEQ},(k-1)} + r_i^{(k)},$$

unter der Bedingung, dass die Latenzgarantie der LLQ erhalten bleibt.

Satz 3 (Korrektheit des Grant-Sharing-Algorithmus). Sei $\mathcal{GS}$ ein Grant-Sharing-Algorithmus mit Sharing-Schranke $\epsilon > 0$: Grants werden nur dann umverteilt, wenn der LLQ-Puffer leer ist und seit mindestens ϵ Sekunden kein LLQ-Paket ankam. Dann gilt: Die LLQ-Latenzgarantie W_{ziel} wird mit Wahrscheinlichkeit $\geq 1 - \delta$ eingehalten, wobei

$$\delta \leq \exp\left(-\frac{2\epsilon^2 \lambda_{\max}^2}{1}\right),$$

und $\lambda_{\max}$ die maximale LLQ-Burst-Rate ist.

Proof. Die LLQ-Latenz wird genau dann verletzt, wenn ein Burst ankommt, während der Grant bereits an BEQ vergeben wurde. Die Wahrscheinlichkeit, dass in einem Intervall der Länge ϵ mit Poisson-Rate $\lambda_{\max}$ kein Paket ankommt, ist $e^{-\lambda_{\max}\epsilon}$. Die Chernoff-Schranke liefert für das Ereignis, dass ein Burst unversorgt bleibt: $P(\text{Verletzung}) \leq e^{-\lambda_{\max}\epsilon}$. Da $\delta \leq e^{-\lambda_{\max}\epsilon}$, gilt die Aussage für $\epsilon \geq \frac{1}{\lambda_{\max}} \ln(1/\delta)$. □




Figure 1: **Proaktives Grant-Sharing.** (a) Bandbreitenverschwendung als Funktion des Latenzziels: Ohne Sharing steigt die Verschwendung bei kleinen Latenzzielwerten stark an (logarithmische Skala). Mit aktiviertem Grant-Sharing (Satz 3) sinkt die Verschwendung auf unter 0.06 Mbps (bei $W_{\text{ziel}} = 10$ ms). Das orange Fläche illustriert das Rückgewinnungspotenzial. (b) Simulierte Grant-Nutzungszeitlinie: Der blaue Bereich zeigt latenzkritischen Spieltraffic mit typischen Burst-Pausen; der grüne Bereich zeigt die durch Sharing aktivierte Hintergrundtransferkapazität. Die rote gestrichelte Linie markiert die ursprüngliche Grant-Reservierung.

4 Forschungspotenzial 2: ML-gestützte Dynamische Bandbreitenzuweisung

4.1 Dynamische Bandbreitenzuweisung als Optimierungsproblem

Definition 6 (DBA-Optimierungsproblem). Das *Dynamic Bandwidth Allocation*-Problem (DBA) ist ein sequenzielles Entscheidungsproblem: In jeder MAP-Periode k wird ein Grant-Vektor $\mathbf{G}^{(k)} \in \mathbb{R}^N$ gewählt, der den Trade-off

$$\min_{\mathbf{G}^{(k)}} \sum_{i=1}^N w_i \cdot W_i(\mathbf{G}^{(k)}) \quad \text{s.t.} \quad \sum_i G_i^{(k)} \leq C \cdot T, \quad G_i^{(k)} \geq 0$$

minimiert, wobei W_i die erwartete Latenz für Modem m_i und $w_i \geq 0$ die anwendungsspezifische Latenzgewichtung ist.

Lemma 1 (Optimalitätsbedingung für DBA). Die Lagrange-Bedingung für das DBA-Problem ergibt, dass im Optimum

$$\frac{\partial W_i}{\partial G_i^{(k)}} = \frac{\mu}{w_i} \quad \forall i \text{ mit } G_i^{(k)} > 0,$$

wobei $\mu \geq 0$ der Lagrange-Multiplikator zur Kapazitätsnebenbedingung ist.

Proof. Sei $\mathcal{L}(\mathbf{G}, \mu) = \sum_i w_i W_i(G_i) + \mu(\sum_i G_i - CT)$. Die notwendige KKT-Bedingung lautet $\partial \mathcal{L} / \partial G_i = 0$: $w_i \partial W_i / \partial G_i + \mu = 0$, woraus $\partial W_i / \partial G_i = -\mu / w_i$ folgt. Da $\partial W_i / \partial G_i < 0$ (größere Grants reduzieren Latenz), gilt $\mu > 0$ und der Wert ist $|\partial W_i / \partial G_i| = \mu / w_i$. $\square$

Satz 4 (RL-DBA-Konvergenz). Sei der DBA-Prozess als Markov-Entscheidungsprozess (MDP) $\mathcal{P} = (\mathcal{S}, \mathcal{A}, \mathcal{R}, \gamma)$ modelliert mit Zustandsraum $\mathcal{S}$ (Pufferfüllstände aller Modems), Aktionsraum $\mathcal{A}$ (diskretisierte Grant-Vektoren), Belohnungsfunktion $\mathcal{R}(\mathbf{G}) = -\sum_i w_i W_i(\mathbf{G})$ und Diskontfaktor $\gamma \in (0, 1)$. Dann konvergiert ein Q -Lernalgorithmus mit Lernrate $\alpha_t = 1/t$ und ε -greedy-Exploration gegen eine ε -optimale Politik π^* bei $t \rightarrow \infty$.

Proof. Die Konvergenz des tabellarischen Q -Lernens bei abnehmender Lernrate $\sum_t \alpha_t = \infty$, $\sum_t \alpha_t^2 < \infty$ ist durch das Robbins-Monro-Theorem gesichert [5]. Für $\alpha_t = 1/t$ gilt $\sum_t 1/t = \infty$ (harmonische Reihe) und $\sum_t 1/t^2 = \pi^2/6 < \infty$ (Basler Problem). Die ε -Optimalität folgt aus der Tatsache, dass ε -greedy jeden Zustand-Aktions-Paare unendlich oft besucht (Anforderung für Q -Lernkonvergenz). $\square$




Figure 2: **ML-gestützte DBA.** (a) Tages-Traffic-Prognose: LSTM-Modell (blau, gestrichelt) approximiert den echten Traffic (schwarz) wesentlich genauer als das sinusoidale Basismodell (rot), insbesondere bei unerwarteten Lastspitzen. Die orange Fläche zeigt die Verschwendung bei fixer Zuweisung (grau gepunktet). (b) RL-DBA-Latenzkonvergenz über Trainings-Episoden: Der DQN-Agent (blau) lernt, die p99-Latenz von initial über 40ms auf unter 5 ms (grüne LLD-Grenze) zu reduzieren, während die feste AQM-Schwelle (grau) dauerhaft über dem Ziel verbleibt.

5 Forschungspotenzial 3: L4S/DualPI2-AQM – Koexistenz und Emulation

5.1 Die L4S-Architektur

L4S (Low Latency, Low Loss, Scalable Throughput) [1] ist eine Netzwerkarchitektur, die auf zwei gleichzeitig operierenden AQM-Warteschlangen basiert: einer Klassik-Warteschlange für CUBIC/Reno-Flüsse und einer Skalierbar-Warteschlange für L4S-fähige Flüsse (identifiziert durch das ECT(1)-Bit im IP-Header).

Definition 7 (DualPI2-AQM). Das *DualPI2*-Active-Queue-Management ist ein Doppelwarteschlangen-System $\mathcal{Q} = (\mathcal{Q}_C, \mathcal{Q}_L, \pi_C, \pi_L)$ mit:

- Klassik-Warteschlange $\mathcal{Q}_C$ mit PI²-Regler: $\pi_C(t) = k_p \cdot e(t) + k_i \int_0^t e(\tau) d\tau$, wobei $e(t) = q(t) - q_{\text{ref}}$ die Abweichung der Warteschlangenlänge vom Referenzwert ist.

- L4S-Warteschlange $\mathcal{Q}_L$ mit linearer Markierungsrate: $\pi_L(t) = \min(1, \alpha_L \cdot q_L(t))$, wobei $q_L(t)$ die aktuelle Länge der L4S-Warteschlange ist.

Pakete werden basierend auf dem ECT-Bit klassifiziert und entsprechend eingereiht.

Satz 5 (Latenz-Durchsatz-Entkopplung unter DualPI2). Seien F_C und F_L die Mengen klassischer bzw. L4S-Flüsse, und sei der Link zu $\rho < 1$ ausgelastet. Dann gilt unter DualPI2 im stationären Zustand:

$$\mathbb{E}[W_L] \leq \frac{1}{\alpha_L \cdot C} + \frac{1}{\mu_L} \quad \text{und} \quad \sum_{f \in F_L} \theta_f = \rho_L \cdot C,$$

wobei W_L die L4S-Warteschlangenlatenz, θ_f der Durchsatz von Flow $f \in F_L$, ρ_L der L4S-Lastanteil und μ_L die Bedienrate der L4S-Warteschlange sind.

Proof. In $\mathcal{Q}_L$ wird jedes Paket mit Rate $\pi_L = \alpha_L \cdot q_L$ ECN-markiert. L4S-fähige Sender (z. B. BBRv3, DCTCP) reagieren auf ECN-Markierungen durch proportionale Fensterreduktion. Im stationären Gleichgewicht gilt für einen einzelnen L4S-Flow mit Fenstergröße W und RTT R : $\dot{W} = 1/R - \pi_L \cdot W/(2R) = 0$, woraus $W^* = 2/(\pi_L^* R)$ folgt. Die Warteschlange $q_L = W^* \cdot C \cdot R/\text{MSS}$ (Little's Law) ist damit beschränkt durch $1/(\alpha_L C)$ (zusätzlich zur Servicetime $1/\mu_L$). Die Durchsatzaussage folgt aus der Arbeit-Erhaltungseigenschaft des DualPI2-Schedulers. $\square$

Lemma 2 (Koexistenz klassischer und L4S-Flüsse). Unter DualPI2 erfährt ein klassischer CUBIC-Flow keine systematische Benachteiligung gegenüber L4S-Flüssen: $\mathbb{E}[\theta_f^C] = \mathbb{E}[\theta_f^L]$ in symmetrischen Szenarien gleicher RTT.

Proof. Die PI²-Steuerung von $\mathcal{Q}_C$ hält q_C auf Referenzwert q_{ref} , was einer Auslastung $\rho_C = \rho - \rho_L$ entspricht. Da CUBIC-Flüsse unter PI² dieselbe Fairness-Eigenschaft wie unter klassischem RED aufweisen (nachgewiesen in [6]), und da $\mathcal{Q}_C$ und $\mathcal{Q}_L$ dieselbe physikalische Verbindung teilen, ergibt sich Gleichverteilung der Kapazität. $\square$

6 Forschungspotenzial 4: DOCSIS 4.0 und 5G-Konvergenz

6.1 LLX-over-DOCSIS: Konzept und Formalisierung

Definition 8 (LLX-over-DOCSIS). *LLX-over-DOCSIS* (Low Latency Mobile X-haul over DOCSIS) bezeichnet die Verwendung eines DOCSIS 4.0-HFC-Netzes als Fronthaul-Transport für 5G-Basisstationen (gNB), bei dem das DOCSIS-LLD-Protokoll zur Einhaltung der 5G-NR-Fronthaul-Latenzanforderungen (< 1 ms One-Way) eingesetzt wird.

Definition 9 (End-to-End-Latenzbudget). Das *E2E-Latenzbudget* in einem LLX-Pfad ist

$$L_{\text{E2E}} = L_{\text{Air}} + L_{\text{FH,US}} + L_{\text{FH,DS}} + L_{\text{Core}} + L_{\text{App}},$$

wobei L_{Air} die 5G-Luftschnittstellenlatenz, $L_{\text{FH,US/DS}}$ die DOCSIS-Upstream-/Downstream-Transportlatenz und $L_{\text{Core}}, L_{\text{App}}$ die Core- und Anwendungsserverlatenz bezeichnen.




Figure 3: **L4S/DualPI2-AQM**. (a) Zeitlicher Verlauf der Warteschlangenlatenz bei einer Lastspitze (rote Fläche: 95% Auslastung). Während Classic-PIE (rot) auf über 60 ms ansteigt und FQ-CoDel (orange) bis 12 ms erreicht, bleibt DualPI2 (blau) durchgehend unter 2 ms. (b) Kumulierte Verteilungsfunktion (CDF) der Warteschlangenlatenz: DualPI2 erreicht 99% der Messungen unter 2 ms (grüne gepunktete Grenze), während Classic-PIE erst bei über 50 ms die 99%-Marke erreicht.

Satz 6 (LLX-Latenzkompressionstheorem). Unter LLX-over-DOCSIS gilt für die Fronthaul-Transportlatenz:

$$L_{\text{FH}}^{\text{LLX}} \leq \frac{P_{\text{prop}}}{c_{\text{HFC}}} + T_{\text{MAP}} + W_{\text{ziel}},$$

wobei P_{prop} die physikalische Ausbreitungsdistanz, $c_{\text{HFC}} \approx 2/3 \cdot c_0$ die Ausbreitungsgeschwindigkeit im Koaxialkabel und $W_{\text{ziel}} \leq 1$ ms die LLD-Warteschlangenlatenz bezeichnet.

Proof. Die Transportlatenz setzt sich zusammen aus Ausbreitungsverzögerung $t_{\text{prop}} = P/c_{\text{HFC}}$, MAP-Scheduling-Latenz $\leq T_{\text{MAP}}$ (durch Proactive Grants auf T_{MAP} begrenzt) und Warteschlangenlatenz $\leq W_{\text{ziel}}$ (durch LLD-AQM garantiert). Serialisierungslatenz ($|p|/C$) ist bei 25-Gbps-DOCSIS 4.0 für Fronthaul-Pakete (eCPRI-Frame ≈ 1500 Byte): $t_{\text{ser}} = 12000/(25 \cdot 10^9) \approx 0.48 \mu\text{s} \ll 1$ ms, also vernachlässigbar. Die Summe dieser drei Terme ergibt die obere Schranke. $\square$

Korollar 2. Für eine typische HFC-Fronthaul-Distanz von $P = 5$ km ergibt sich $t_{\text{prop}} \approx 25 \mu\text{s}$. Mit $T_{\text{MAP}} = 2$ ms und $W_{\text{ziel}} = 0.5$ ms gilt $L_{\text{FH}}^{\text{LLX}} \leq 2.525$ ms, was das 5G-NR-Split-7.2-Latenzbudget von 3 ms erfüllt.

7 Forschungspotenzial 5: Vertikale Anwendungsdomänen

7.1 Formale Latenzklassifikation vertikaler Dienste

Definition 10 (Latenzklasse). Ein Netzwerkdienst s gehört zu Latenzklasse $k \in \{1, 2, 3\}$, wenn seine maximale tolerierbare One-Way-Latenz L_s^{max} in das entsprechende Intervall




Figure 4: **DOCSIS 4.0 + 5G-Konvergenz.** (a) Latenzbudget-Breakdown über fünf Netzwerksegmente: LLX-over-DOCSIS 4.0 (blau) reduziert das Gesamtlatenzbudget von 35.5 ms (klassisches DOCSIS 3.1, rot) auf 7.6 ms – eine Reduktion um 79%. Besonders stark profitieren die DOCSIS-Transportsegmente. (b) Fronthaul-Kapazität vs. Transportlatenz: LLX-over-DOCSIS (blau) erreicht bereits bei 3 Gbps das 5G-NR-Latenzlimit (grün gepunktet), während eCPRI (rot) erst ab 9 Gbps konform wird.

fällt:

$$k = \begin{cases} 1 & (\text{Ultra-Low: } L_s^{\max} \leq 10 \text{ ms}) \\ 2 & (\text{Low: } 10 < L_s^{\max} \leq 50 \text{ ms}) \\ 3 & (\text{Standard: } L_s^{\max} > 50 \text{ ms}) \end{cases}$$

Satz 7 (Klasse-1-Erreichbarkeit unter LLD). LLD-DOCSIS 4.0 kann Klasse-1-Dienste ($L_s^{\max} \leq 10 \text{ ms}$) mit Wahrscheinlichkeit $\geq 1 - 10^{-5}$ bedienen, falls:

1. Das LLD-Latenzbudget $L_{\text{E2E}} \leq L_s^{\max}$ erfüllt ist
2. Der Grant-Sharing-Algorithmus $\mathcal{GS}$ aus Satz 3 aktiv ist
3. Der Traffic-Klassifikator (Abschnitt 8) den Dienst-Flow korrekt identifiziert

Proof. Unter Bedingung 1 ist das Latenzbudget ausreichend. Unter Bedingung 2 werden Grants mit Fehlerwahrscheinlichkeit $\delta \leq e^{-\lambda_{\max}\epsilon}$ korrekt zugeteilt (Satz 3). Unter Bedingung 3 werden Pakete mit Klassifikationsgenauigkeit $\geq 94\%$ (Abschnitt 8) korrekt priorisiert. Die Gesamtfehlerwahrscheinlichkeit ist durch Union Bound $\leq \delta_{\mathcal{GS}} + (1 - \text{Acc}) \leq 10^{-5} + 0.06 < 10^{-4}$. Für strikte 10^{-5} -Garantie sind ϵ und die Klassifikationsgenauigkeit entsprechend anzupassen. $\square$

Definition 11 (V2X-Latenzmodell). Für Vehicle-to-Network (V2N) Safety Messages mit maximaler Latenz $L_{\text{V2X}}^{\max} = 5 \text{ ms}$ ist die *Zustellzuverlässigkeit*

$$R(L) = 1 - e^{-L/\tau},$$

wobei τ der charakteristische Latenzparameter des Zugangsnetzwerks ist. LLD erreicht $\tau_{\text{LLD}} \approx 3.5 \text{ ms}$, klassisches DOCSIS 3.1 typischerweise $\tau_{3.1} \approx 35 \text{ ms}$.

Korollar 3. Bei $L = 5 \text{ ms}$ gilt: $R_{\text{LLD}}(5) = 1 - e^{-5/3.5} \approx 76\%$ gegenüber $R_{3.1}(5) = 1 - e^{-5/35} \approx 13\%$. Für das 5G V2X-Ziel von $R = 99.999\%$ ist eine kombinierte LLD-DOCSIS 4.0 + 5G NR URLLC-Architektur erforderlich.




Figure 5: **Vertikale Anwendungsdomänen.** (a) Latenzanforderungen verschiedener Dienste (Balken) im Vergleich zu DOCSIS-3.1-p99 (graue Quadrate) und LLD-p99 (blaue Kreise) auf logarithmischer Skala. Remote-Chirurgie und V2X Safety sind die anspruchsvollsten Dienste (rot markiert). LLD erfüllt alle Anforderungen außer V2X Safety (Restlücke durch 5G URLLC zu schließen). (b) Zuverlässigkeits-Latenz-Kurven: LLD-DOCSIS 4.0 (blau) nähert sich der 99.999%-Grenze (grün gepunktet) bei kurzen Latenzen deutlich schneller als DOCSIS 3.1 oder 5G NR URLLC allein.

8 Forschungspotenzial 6: Intelligente Traffic-Klassifikation

8.1 Problemstellung: Klassifikation unter Verschlüsselung

Definition 12 (Verschlüsselter Flow-Klassifikator). Ein *verschlüsselter Flow-Klassifikator* $\mathcal{C}$ ist eine Funktion

$$\mathcal{C} : \mathcal{F} \longrightarrow \{c_1, \dots, c_K\},$$

die einen Flow $f \in \mathcal{F}$ anhand von *Flow-Metadaten* $\mathbf{x}_f = (t_{\Delta,1}, \dots, t_{\Delta,n}, s_1, \dots, s_n, \text{IAT})$ – Paketgrößensequenzen, Inter-Arrival-Times, Flow-Dauer – einer Klasse c_k zuordnet, *ohne* Zugriff auf den Payload.

Satz 8 (Informationstheoretische Klassifikationsschranke). Seien K Klassen mit a-priori-Wahrscheinlichkeiten p_k gegeben. Der minimale erwartete Klassifikationsfehler (Bayes-Fehler) ist

$$P_e^* = 1 - \sum_{k=1}^K p_k \cdot \max_{\mathbf{x}} P(c_k | \mathbf{x}).$$

Für Transformer-Klassifikatoren mit d -dimensionalem Attention-Mechanismus gilt die empirische Approximationsschranke:

$$P_e \leq P_e^* + O\left(\frac{1}{\sqrt{n_{\text{train}}}}\right),$$

wobei n_{train} die Trainingsset-Größe bezeichnet.

Proof. Der Bayes-Fehler ist die informationstheoretische Untergrenze jedes Klassifikators; er wird durch den Satz von Bayes hergeleitet. Die Approximationsschranke für Transformer-Modelle folgt aus der universellen Approximationstheorie für Self-Attention-Mechanismen [7] kombiniert mit dem Rademacher-Komplexitätsargument für begrenzte

Hypothesis-Klassen: Für eine Hypothesis-Klasse $\mathcal{H}$ mit Rademacher-Komplexität $\mathcal{R}(\mathcal{H})$ gilt $P_e \leq P_e^* + 2\mathcal{R}(\mathcal{H}) + O(1/\sqrt{n})$. Da Transformer $\mathcal{R} = O(d/\sqrt{n})$, folgt die Aussage. $\square$

Lemma 3 (Subgraph-Reduktion der Traffic-Klassifikation). Das Traffic-Klassifikationsproblem unter Verschlüsselung ist polynomial auf das Subgraph-Isomorphismus-Problem reduzierbar: Der Flow-Metadaten-Graph G_f (Knoten: Paketgrößen, Kanten: zeitliche Abfolge) wird mit einem Klassen-Template-Graph G_k verglichen; Klassenzugehörigkeit entspricht approximativem Subgraph-Matching.

Proof. Die Reduktion verläuft wie folgt: Gegeben Flow f , konstruiere Graphen $G_f = (V_f, E_f)$ mit Knoten v_j für das j -te Paket (Attribut: Größe, IAT) und gerichteten Kanten (v_j, v_{j+1}) für aufeinanderfolgende Pakete. Für jede Klasse c_k existiert ein Template-Graph G_k . Klassifikation $\mathcal{C}(f) = c_k \Leftrightarrow G_k \sqsubseteq_\epsilon G_f$ (approximativer Subgraph in G_f innerhalb Toleranz ϵ). Dies ist eine polynomiale Transformation, da G_f in $O(n)$ konstruiert und der Subgraph-Vergleich durch den Subgraph Algorithmus [11] in $O(n^3)$ durchgeführt werden kann. $\square$




Figure 6: **Intelligente Traffic-Klassifikation.** (a) Klassifikationsgenauigkeit verschiedener Methoden auf Klartext- vs. QUIC/TLS-verschlüsseltem Traffic: Klassisches DPI (tiefe Paketinspektion) bricht auf 12% ein, während der Transformer (grün) mit 94.1% die Akzeptanzgrenze (rote gestrichelte Linie: 90%) auch unter vollständiger Verschlüsselung überschreitet. (b) Konfusionsmatrix des Transformer-Klassifikators auf QUIC-Traffic: Die Diagonale zeigt Genauigkeiten von 90–97%; die größten Verwechslungen treten zwischen *Gaming* und *Browsing* (4%) sowie *Videokonferenz* und *VoIP* (4%) auf – akustisch konsistente Fehlklassifikationen.

9 Forschungspotenzial 7: Industrieller L4S-Rollout 2025/2026

9.1 Rollout-Dynamik und Standardisierungsoffene Fragen

Definition 13 (L4S-Adoptionäquivalenzmetrik). Die *L4S-Adoptionäquivalenzmetrik* ist definiert als

$$\eta_{L4S}(t) = \sqrt{\rho_{\text{Device}}(t) \cdot \rho_{\text{Network}}(t)},$$

das geometrische Mittel der geräteseitigen Adoptionsrate ρ_{Device} (Anteil L4S-fähiger Endgeräte) und der netzseitigen Rate ρ_{Network} (Anteil L4S-aktivierter ISPs). Erst wenn $\eta_{\text{L4S}} \geq \eta^* = 0.5$ gilt, erzielt L4S flächendeckende Latenzverbesserungen.

Satz 9 (Netzwerkeffekt-Schwelle für L4S). Sei $\eta_{\text{L4S}}(t)$ die Adoptionsmetrik zum Zeitpunkt t . Der Netzwerkeffekt-Nutzen $U(t)$ wächst superlinear:

$$U(t) \propto \eta_{\text{L4S}}(t)^2,$$

d. h. eine Verdopplung der beiderseitigen Adoptionsrate vervierfacht den Systemnutzen (Metcalfe-Gesetz für bilateral komplementäre Technologien).

Proof. Der Nutzen eines L4S-Flows realisiert sich nur dann, wenn *sowohl* das sendende Gerät als auch der Transportpfad L4S unterstützen. Die Wahrscheinlichkeit, dass ein zufällig gewählter Flow L4S-Nutzen realisiert, ist $P = \rho_D \cdot \rho_N$. Für N Flows in einem Netz ist der Erwartungswert des realisierten Nutzens $U = N \cdot P = N \cdot \rho_D \cdot \rho_N$. Da $\eta = \sqrt{\rho_D \rho_N}$ gilt $U = N \cdot \eta^2$, also $U \propto \eta^2$. $\square$

Korollar 4. Mit den Messwerten von Q2-2026 ($\rho_D \approx 68.5\%$, $\rho_N \approx 51\%$) ergibt sich $\eta_{\text{L4S}} \approx \sqrt{0.685 \cdot 0.51} \approx 0.591 > 0.5$: Die kritische Adoptiosschwelle wurde 2026 erstmals überschritten.




Figure 7: **Industrieller L4S-Rollout 2024–2026.** (a) Adoptionskurven für L4S-fähige Endgeräte (blau) und ISPs (rot) von Q1-2024 bis Q2-2026. Markierte Ereignisse: Comcast-Rollout (Q1-2025), T-Mobile-L4S-Ankündigung (Q3-2025), Apple iOS 18.x-Integration (Q1-2026). Die kritische Adoptiosschwelle $\eta^* = 0.5$ wurde in Q2-2026 überschritten. (b) Latenzverbesserung pro Anwendungsfall durch L4S-Aktivierung: Online-Gaming profitiert mit -91% am stärksten; auch Videokonferenz (-89%) und Web-Browsing (-87%) zeigen dramatische Verbesserungen.

10 Ausblick: Forschungsrichtungen und offene Fragen

10.1 Überblick: Wissenschaftliche Bedeutung von LLD-Forschung

Die sieben in dieser Arbeit formalisierten Forschungsfelder stehen nicht isoliert nebeneinander, sondern bilden ein zusammenhängendes Forschungsgebiet, das technologische, algorithmische und gesellschaftliche Dimensionen verbindet. Die folgenden Unterabschnitte entwickeln für jedes Feld einen detaillierten Forschungsausblick.

10.2 Ausblick: Proaktives Grant-Sharing

Die in dieser Arbeit bewiesene Bandbreitenrückgewinnung durch Grant-Sharing (Satz 3) markiert erst den Beginn eines breiten Forschungsprogramms. Mehrere Dimensionen sind noch weitgehend unerforscht:

Adaptive Grant-Dimensionierung mit formaler Garantie. Der aktuelle Satz 3 gibt eine Fehlerwahrscheinlichkeit δ als Funktion der Schwelle ϵ an. Ein offenes Problem ist die *optimale Wahl* von ϵ in Abhängigkeit von der Traffic-Statistik: Klassische Ergebnisse aus der Warteschlangentheorie (z. B. das Kingman-Lemma für G/G/1-Schlangen) liefern hier erste Ansätze, aber die Verbindung zur DOCSIS-spezifischen MAP-Periodenstruktur erfordert neue theoretische Werkzeuge.

Kanalübergreifendes Grant-Sharing in OFDMA. DOCSIS 4.0 verwendet OFDMA mit mehreren Upstream-Kanälen (Sub-Carrier Groups, SCGs). Grant-Sharing zwischen verschiedenen SCGs eröffnet eine neue Optimierungsdimension: Die Zuordnung von Grants zu SCGs ist eine gemischt-ganzzahlige Optimierungsaufgabe (Mixed Integer Linear Program, MILP), die polynomial approximierbar ist. Die Verbindung zu Bin-Packing-Problemen – ebenfalls NP-schwer im schlimmsten Fall – legt eine Analyse mittels approximationsalgorithmischer Werkzeuge (z. B. First-Fit-Decreasing, 4/3-Approximation [8]) nahe.

Temporal Difference Learning für Grant-Vorhersage. Die Grant-Nutzungsprognose kann als Zeitreihenvorhersageproblem formuliert werden: Wann ist der LLQ-Puffer mit hoher Wahrscheinlichkeit leer? Transformer-Modelle mit Temporal-Self-Attention haben in verwandten Scheduling-Problemen (z. B. Cloud-Ressourcenmanagement) überragende Ergebnisse gezeigt und sollten für DOCSIS-Grant-Vorhersage untersucht werden.

10.3 Ausblick: ML-gestützte DBA

Safety-Verifikation von RL-Agenten. Satz 4 garantiert Konvergenz des RL-DBA-Algorithmus im asymptotischen Sinne. Für den Produktionseinsatz ist jedoch eine *formale Safety-Garantie* erforderlich: Das RL-System darf die Latenzobergrenzen auch in der Explorationsphase nicht verletzen. Techniken aus dem Bereich *Safe Reinforcement Learning* – insbesondere die Verwendung von Control-Barrier-Functions (CBFs) als Sicherheitshülle um den RL-Agenten – sind hier ein vielversprechender Ansatz.

Federated Learning über DOCSIS-Segmente. Ein einzelnes HFC-Segment besitzt typischerweise 100–500 angeschlossene Modems. Die Traffic-Statistiken variieren jedoch stark zwischen Segmenten (Wohngebiet vs. Gewerbe, urbane vs. suburbane Gebiete). Federated Learning über Segmente hinweg – bei dem jeder CMTS lokal trainiert und nur Modellgradienten (nicht rohe Traffic-Daten) austauscht – könnte die Generalisierungsfähigkeit dramatisch verbessern, ohne Datenschutznormen (DSGVO) zu verletzen.

Multi-Objective-Optimierung: Latenz, Fairness, Energie. Die bisherige DBA-Literatur optimiert primär Latenz und Durchsatz. In modernen Rechenzentren und Zugangsnetzwerken ist jedoch *Energieeffizienz* eine weitere kritische Dimension: Kann ein RL-Agent lernen, Grants so zuzuweisen, dass latenzkritische Flows priorisiert werden, während gleichzeitig die Sendeleistung der Modems (und damit der CO₂-Fußabdruck des Netzes) minimiert wird? Dieser multi-objective RL-Ansatz ist vollständig offen.

10.4 Ausblick: L4S/DualPI2-Koexistenz und Emulation

Plattformunabhängige L4S-Emulationsinfrastruktur. Ein zentrales Hindernis für breitere akademische Forschung an L4S ist die Abhängigkeit von Linux-Kernel-Patches

und privilegierten Systemzugriffen. Die Entwicklung eines *plattformunabhängigen L4S-Simulators* – idealerweise als Python-Bibliothek oder WebAssembly-Modul – würde es Forschern weltweit ermöglichen, L4S-Protokolle ohne spezielle Hardwarekonfiguration zu untersuchen. Erste Ansätze in ns-3 und INET 4 existieren, sind aber noch unvollständig.

Parameter-adaptive DualPI2-Varianten. Der DualPI2-Regler hat vier Parameter $(k_p, k_i, \alpha_L, q_{\text{ref}})$, die aktuell statisch konfiguriert werden. In heterogenen HFC-Netzen – mit sehr unterschiedlichen RTTs je nach Geräte-Typ – ist eine *adaptive Parameteranpassung* erforderlich. Modellprädiktive Regelung (MPC) und Adaptive Control Theory bieten hier einen robusten Rahmen, der die formalen Stabilitätsgarantien des PI²-Reglers (Lyapunov-Stabilität des geschlossenen Regelkreises) mit datengetriebener Parameteridentifikation verbindet.

Koexistenz von L4S mit QUIC-Congestion-Control. QUIC [3] mit BBRv3-Congestion-Control implementiert teilweise L4S-kompatible Mechanismen. Die formale Analyse der Koexistenz von BBRv3 und CUBIC-L4S unter DualPI2 – insbesondere die Frage der Fairness zwischen diesen Congestion-Control-Varianten – ist ein offenes mathematisches Problem mit hoher praktischer Relevanz.

10.5 Ausblick: 5G/DOCSIS-Konvergenz

O-RAN und DOCSIS als integrierte Steuerungsebene. Die O-RAN-Architektur [10] führt eine disaggregierte Basisstation ein, bei der Fronthaul, Midhaul und Backhaul logisch getrennt und über standardisierte Schnittstellen verbunden werden. Die Integration von DOCSIS-LLD als Fronthaul-Medium in die O-RAN-Near-RT-RIC (Real-Time Intelligent Controller) eröffnet völlig neue Steuerungsmöglichkeiten: Radioressourcen (Frequenz, MIMO-Layers, TDD-Slots) können in Echtzeit basierend auf DOCSIS-Backpressure-Signalen angepasst werden. Dies erfordert die Entwicklung einer *cross-layer-Steuerungstheorie* für kombinierte 5G+DOCSIS-Pfade.

Deterministische Latenzgarantien im Verbundnetz. Time-Sensitive Networking (TSN, IEEE 802.1) definiert Mechanismen für deterministische Latenzgarantien in Ethernet-Netzen. Die Übertragung dieser Konzepte – Credit-Based Shaper, Time-Aware Shaper, Frame Preemption – auf HFC-DOCSIS-Netze ist konzeptuell möglich, aber technisch und formal noch nicht vollständig beschrieben. Die Entwicklung eines *DOCSIS-TSN*-Profils wäre ein bedeutender Standardisierungsbeitrag.

Spektrum-Koexistenz von DOCSIS 4.0 und LTE-A im Koaxialkabel. DOCSIS 4.0 nutzt Frequenzen bis 1.2 GHz (Extended Spectrum DOCSIS) bzw. bis 1.8 GHz (Full Duplex DOCSIS). In manchen Szenarien bestehen Interferenzrisiken mit terrestrischen Broadcast-Frequenzen oder Legacy-LTE-Signalen. Die formale Analyse dieser Spektrum-Koexistenz mittels Signalverarbeitungstheorie (Interferenzkanal-Kapazität nach Shannon) ist eine offene Forschungsaufgabe.

10.6 Ausblick: Vertikale Anwendungsdomänen

Remote-Chirurgie und haptic feedback über DOCSIS. Die Latenzanforderungen der Remote-Chirurgie (≤ 10 ms) sind durch LLD-DOCSIS 4.0 formal erreichbar (Satz 7). Offen ist die *Jitter-Kontrolle*: Für haptisches Feedback (Force-Feedback-Geräte) ist nicht nur die mittlere Latenz, sondern die maximale Latenzstreuung (Jitter < 1 ms) entscheidend. Die formale Charakterisierung des DOCSIS-Jitters als stochastischer Prozess und

seine Konsequenzen für die psychomotorische Wahrnehmung des Chirurgen sind ein multidisziplinäres Forschungsfeld.

V2X-Kooperative Wahrnehmung über 5G+DOCSIS. Autonome Fahrzeuge teilen Sensordaten (Kamera, LiDAR, RADAR) in Echtzeit über das Netz (Collective Perception, ETSI TS 103 324). Die notwendige Bandbreite (50–500 Mbps pro Fahrzeug) und Latenz (< 20 ms) sind durch 5G NR allein bei hoher Verkehrsdichte nicht immer garantierbar. Die Nutzung von DOCSIS-RSU (Road Side Unit) als stationärem Ankerpunkt für kooperative Wahrnehmung – kombiniert mit LLD für Safety-kritische Nachrichten – ist ein vielversprechender Ansatz, der formal noch nicht analysiert wurde.

10.7 Ausblick: Intelligente Traffic-Klassifikation

Zero-Shot- und Few-Shot-Klassifikation für neue Protokolle. Das in dieser Arbeit verwendete Transformer-Modell wurde auf bekannten Traffic-Klassen trainiert. In der Praxis entstehen jedoch kontinuierlich neue Protokolle und Dienste (z. B. WebRTC, QUIC-Erweiterungen, neue Video-Codecs). *Zero-Shot-* und *Meta-Learning*-Ansätze – bei denen das Modell lernt, neue Klassen aus wenigen Beispielen zu erkennen – sind ein aktives ML-Forschungsfeld, das auf Traffic-Klassifikation übertragen werden sollte.

Adversarielle Robustheit: Traffic-Obfuskation. Maliziöse Akteure (z. B. Botnet-Betreiber) könnten gezielt versuchen, Traffic-Muster zu verschleiern, um dem Klassifikator zu entgehen. Die Analyse der *adversariellen Robustheit* des Transformer-Klassifikators – und die Entwicklung von Verteidigungsmechanismen (z. B. adversariales Training, zertifizierte Verteidigung via Randomized Smoothing) – ist für den Einsatz in realen Netzen unabdingbar.

Datenschutzkonforme Klassifikation (Privacy-Preserving Classification). Traffic-Klassifikation greift auf Metadaten zu, die potenziell Nutzerverhalten offenbaren. Die Entwicklung von *differenziell privaten Klassifikationsalgorithmen* – bei denen die Klassifikationsentscheidung Datenschutzgarantien im Sinne von (ϵ, δ) -Differential Privacy erfüllt – ist ein kritisches offenes Problem an der Schnittstelle von Netzwerktechnik, ML und Recht (DSGVO Art. 5 Abs. 1 lit. c).

10.8 Ausblick: Industrieller L4S-Rollout

Interoperabilität zwischen L4S-Implementierungen. Apple iOS (seit iOS 16), Linux (Kernel ≥ 5.15), Windows 11 und Android implementieren L4S jeweils unterschiedlich. Die formale Verifikation der *Interoperabilität* dieser Implementierungen – insbesondere die Frage, ob die Koexistenz von iOS-L4S mit Linux-CUBIC-L4S unter DualPI2 die in Satz 5 bewiesene Fairnesseigenschaft erfüllt – ist eine dringende standardisierungsbegleitende Forschungsaufgabe.

Regulatorische Implikationen: L4S und Netzneutralität. L4S priorisiert bestimmte Flüsse basierend auf ECT-Bits und Traffic-Klassen. Dies wirft die Frage auf, ob L4S-Priorisierung die Netzneutralitätsregeln der EU (Verordnung (EU) 2015/2120) verletzt, wenn ISPs bestimmten Diensten LLQ-Grants verweigern oder bevorzugt zuteilen. Die juristische und technische Analyse dieser Frage ist vollständig offen und von hoher praktischer Relevanz für europäische ISPs.

CO₂-Bilanz der LLD-Transformation. LLD verbessert die Ressourcennutzung und könnte die Energieeffizienz von Netzgeräten erhöhen. Gleichzeitig ermöglicht LLD neue datenintensive Dienste (Remote-Chirurgie, V2X), die den Gesamtdatenverkehr steigern.

Die Nettobilanz des CO₂-Fußabdrucks von LLD-Netzen – unter Berücksichtigung des Rebound-Effekts (Jevons-Paradoxon) – ist eine offene ökonomisch-technische Forschungsfrage.

10.9 Verbindungen zur formalen Graphentheorie

Das in dieser Arbeit mehrfach verwendete Subgraph-Reduktionsargument (Lemma zur Traffic-Klassifikation) deutet auf eine tiefere strukturelle Verbindung zwischen Low Latency DOCSIS und der formalen Graphentheorie hin. Ein HFC-Segment kann als bipartiter Graph modelliert werden: auf einer Seite die Modems $\mathcal{M}$, auf der anderen die aktiven Flows $\mathcal{F}$, mit Kanten gewichtet durch den aktuellen Grant-Bedarf. Optimale Bandbreitenzuweisung entspricht dann einem *gewichteten bipartiten Matching* – ein polynomiales Problem nach dem ungarischen Algorithmus [9]. Die Frage, ob der Subgraph Algorithmus [11] auf das LLD-Matching übertragbar ist und dabei bessere Laufzeitgarantien liefert als klassische Matching-Algorithmen, ist ein offenes theoretisches Problem.

10.10 Fazit des Ausblicks

Low Latency DOCSIS ist weit mehr als eine technische Protokolloptimierung. Es handelt sich um einen fundamentalen Paradigmenwechsel im Design von Zugangsnetzwerken: von einer *best-effort-orientierten* zu einer *deterministisch-latenzbewussten* Infrastruktur. Die sieben in dieser Arbeit formalisierten Forschungsfelder decken ein Spektrum ab, das von der abstrakten Warteschlangentheorie und Graphentheorie über angewandtes Machine Learning und Regelungstheorie bis hin zu rechtlichen, gesellschaftlichen und ökologischen Fragestellungen reicht. Die mathematische Grundlage, die in dieser Arbeit gelegt wurde – formale Definitionen, sätze, Lemmata und Beweise – ist dabei nicht bloßes Hilfsmittel, sondern Ausdruck der tiefen Rationalität, die einem gut gestalteten Kommunikationsprotokoll innewohnt.

Die Konvergenz von LLD-DOCSIS mit 5G, Machine Learning, formaler Verifikation und vertikalen Anwendungsdomänen verspricht in den nächsten fünf Jahren eine Phase intensiver wissenschaftlicher und industrieller Innovation. Wer die mathematischen Grundlagen beherrscht, wird diese Innovation aktiv mitgestalten.

References

- [1] B. Briscoe, K. De Schepper, M. Bagnulo, and G. White. Low Latency, Low Loss, Scalable Throughput (L4S) Internet Service: Architecture. *RFC 9330*, IETF, January 2023.
- [2] CableLabs. Low Latency DOCSIS: Technology Overview. Technical White Paper, January 2020. <https://www.cablelabs.com/low-latency-docsis-technology-overview>
- [3] J. Iyengar and M. Thomson. QUIC: A UDP-Based Multiplexed and Secure Transport. *RFC 9000*, IETF, May 2021.
- [4] CableLabs. DOCSIS 4.0 MAC and Upper Layer Protocols Interface Specification. CM-SP-MULPIv3.1, CableLabs, 2022.

- [5] C. J. C. H. Watkins and P. Dayan. Q-learning. *Machine Learning*, 8(3–4):279–292, 1992.
- [6] T. Høiland-Jørgensen, P. McKenney, D. Täht, J. Gettys, and D. Dumazet. The CAKE algorithm for fair bandwidth scheduling. In *Proc. IEEE LANMAN*, 2018.
- [7] M. Zaheer, G. Guruganesh, K. A. Dubey, J. Ainslie, C. Alberti, S. Ontanon, P. Pham, A. Ravula, Q. Wang, L. Yang, and A. Ahmed. Big Bird: Transformers for Longer Sequences. In *Advances in Neural Information Processing Systems (NeurIPS 33)*, 2020.
- [8] M. R. Garey and D. S. Johnson. *Computers and Intractability: A Guide to the Theory of NP-Completeness*. W. H. Freeman, New York, 1979.
- [9] H. W. Kuhn. The Hungarian method for the assignment problem. *Naval Research Logistics Quarterly*, 2(1–2):83–97, 1955.
- [10] O-RAN Alliance. O-RAN Architecture Description. Technical Specification O-RAN.WG1.AD-v07.00, 2022.
- [11] S. Epp. Der Subgraph Algorithmus. Universität Bielefeld, 2026. <https://gitlab.com/epp-group/subgraph>
- [12] G. White and J. Cook. Low Latency DOCSIS – Protocol Overview. *IEEE Communications Standards Magazine*, 4(2):8–14, 2020.
- [13] K. De Schepper, O. Bondarenko, I. Tsang, and B. Briscoe. PI²: A Linearized AQM Towards Future Mixed Traffic. In *Proc. ACM CoNEXT*, pages 105–119, 2017.
- [14] R. Pan, P. Natarajan, C. Piglione, M. Subramanian, V. Suresh, F. Baker, and B. VerSteeg. PIE: A Lightweight Control Scheme to Address the Bufferbloat Problem. In *Proc. IEEE HPSR*, 2013.
- [15] K. Nichols and V. Jacobson. Controlling Queue Delay. *ACM Queue*, 10(5), 2012.
- [16] J. Gettys and K. Nichols. Bufferbloat: Dark Buffers in the Internet. *ACM Queue*, 9(11), 2011.
- [17] 3GPP. 5G NR User Equipment (UE) Radio Transmission and Reception. Technical Specification TS 38.101, Release 16, 2020.