

Logistische Regression

Theorie, Algorithmen und Zukunftsperspektiven

Stephan Epp

17. März 2026

Inhaltsverzeichnis

1	Einleitung und Motivation	4
1.1	Historischer Kontext	4
1.2	Abgrenzung zur linearen Regression	4
2	Mathematische Grundlagen	5
2.1	Der lineare Prädiktor	5
2.2	Die Sigmoid-Funktion	5
2.3	Das Wahrscheinlichkeitsmodell	6
2.4	Log-Odds und Interpretierbarkeit	6
3	Statistische Herleitung: Exponentialfamilie und GLM	7
3.1	Generalisierte Lineare Modelle	7
3.2	Die Bernoulli-Verteilung als Exponentialfamilie	7
3.3	Suffiziente Statistik und Informationsgeometrie	8
4	Verlustfunktion und Maximum-Likelihood	8
4.1	Likelihood und Log-Likelihood	8
4.2	Binäre Kreuzentropie und Informationstheorie	8
4.3	Konvexität der Verlustfunktion	9
4.4	Gradientenberechnung	10
5	Optimierungsverfahren	10
5.1	Gradientenabstieg	10
5.2	Newton-Raphson-Verfahren (IRLS)	11
5.3	L-BFGS: Quasi-Newton-Methode für grosse Dimensionen	12
5.4	Stochastischer Gradientenabstieg und Varianten	12
6	Entscheidungsgrenze und geometrische Interpretation	12
6.1	Lineare Entscheidungsgrenze	12
6.2	Margin und Konfidenz	13
6.3	Nicht-lineare Erweiterung durch Feature-Maps	13
7	Regularisierung	13
7.1	Ridge-Regularisierung (L2)	13

7.2	Lasso-Regularisierung (L1)	14
7.3	Elastic Net	14
8	Varianzinflationsfaktor (VIF) und Multikollinearität	15
8.1	Motivation: Das Problem der Multikollinearität	15
8.2	Definition und mathematische Herleitung des VIF	16
8.3	Berechnung des VIF: Schritt für Schritt	18
8.4	Interpretation der VIF-Werte	19
8.4.1	Niedriger VIF: $VIF < 5$	20
8.4.2	Moderater VIF: $5 \leq VIF < 10$	20
8.4.3	Hohe Multikollinearität: $VIF \geq 10$	20
8.5	VIF bei der logistischen Regression	22
8.6	Beziehungen zwischen VIF und anderen Diagnosemaßen	23
8.7	Strategien zur Reduktion der Multikollinearität	23
8.7.1	Entfernung korrelierter Prädiktoren	23
8.7.2	Kombination korrelierter Prädiktoren	25
8.7.3	Hauptkomponentenanalyse (PCA)	25
8.7.4	Ridge-Regularisierung als VIF-Reduktionsmethode	25
8.8	Formale Bedeutung des VIF für die Modellgüte	27
8.9	Zusammenfassendes Beispiel: VIF-Diagnose in einer medizinischen Studie	28
9	Multinomiale Logistische Regression (Softmax)	29
9.1	Erweiterung auf K Klassen	29
9.2	Kategorische Kreuzentropie	30
10	Evaluationsmasse und Modellbewertung	30
10.1	Konfusionsmatrix und abgeleitete Metriken	30
10.2	ROC-Kurve, AUC und Precision-Recall	31
10.3	Kalibrierung von Wahrscheinlichkeiten	31
11	Verbindungen zu anderen Methoden	32
11.1	Logistische Regression als flaches neuronales Netz	32
11.2	Verhältnis zu Support Vector Machines	32
11.3	Naive Bayes als generatives Gegenstück	32
12	Numerische Experimente	33
12.1	Konvexe Verlustlandschaft	33
12.2	Polynomial Feature Maps	33
12.3	Klinische Anwendung: Risikomodellierung	34
12.4	Bayesianische Posteriorunsicherheit	34
13	Ausblick	34
13.1	Federated Learning und datenschutzerhaltende Klassifikation	35
13.1.1	Konzept und Herausforderungen	35
13.1.2	Differentielle Privatheit	35
13.1.3	Anwendungen 2025	36
13.2	Bayes'sche Logistische Regression und Unsicherheitsquantifizierung	36
13.2.1	Posteriori-Verteilung und Laplace-Approximation	36
13.2.2	Prädiktive Unsicherheit	36

13.2.3	Bedeutung für Hochrisiköntscheidungen	37
13.3	Erklärbare Künstliche Intelligenz (XAI) und logistische Regression	37
13.3.1	Intrinsische Interpretierbarkeit	37
13.3.2	SHAP-Werte und logistische Regression	37
13.3.3	Kausale Inferenz	37
13.4	Hochdimensionale Statistik und maschinelles Lernen	38
13.4.1	Hochdimensionales Regime: $d \gg n$	38
13.4.2	Doppelt robuste Schätzung	38
13.5	Logistische Regression in der Präzisionsmedizin	38
13.5.1	Polygene Risikoscores	38
13.5.2	Arzneimittelinteraktionen und elektronische Krankenakten	38
13.6	Klimawissenschaft und Umweltmonitoring	39
13.6.1	Extremwettererkennung	39
13.6.2	Satellitengestützte Fernerkundung	39
13.7	Finanzmarkt und Kreditrisikomodellierung	39
13.7.1	Basel III/IV und regulatorische Anforderungen	39
13.7.2	Echtzeit-Betrugserkennungssysteme	39
13.8	Natursprachverarbeitung und Large Language Models	40
13.8.1	Softmax als universelles Ausgabelayer	40
13.8.2	Classifier-Free Guidance und Temperaturskalierung	40
13.8.3	Probing-Klassifikatoren	40
13.9	Robotik, autonomes Fahren und Echtzeitsysteme	40
13.9.1	Wahrnehmungsklassifikation mit Echtzeitanforderungen	40
13.9.2	Probabilistische Zustandsschätzung	41
13.10	Quantenmaschinelles Lernen	41
13.10.1	Quantenlogistische Regression	41
13.10.2	Post-Quantum-Sicherheit für ML-Inferenz	41
13.11	Mathematische Ausblicke und offene Forschungsfragen	41
13.11.1	Statistische Lerntheorie	41
13.11.2	Implizite Regularisierung durch Gradientenabstieg	41
13.11.3	Neuronale Skalierungsgesetze und logistische Ausgabelayer	42
13.11.4	Kontinuierliche und online logistische Regression	42
13.12	Industrie-Anwendungsfelder 2025: Panorama	42
13.13	Ethische Dimensionen: Fairness, Diskriminierungsfreiheit und Transparenz	43
13.13.1	Algorithmische Fairness	43
13.13.2	EU AI Act (2025) und Modelldokumentation	43
13.14	Forschungslücken und offene Probleme (Stand 2025)	43

14 Zusammenfassung

44

1 Einleitung und Motivation

Die logistische Regression zählt zu den fundamentalsten und gleichzeitig vielseitigsten Methoden des maschinellen Lernens und der mathematischen Statistik. Seit ihrer formalen Einführung durch Cox (1958) hat sie eine bemerkenswerte Renaissance erlebt: Während sie als konzeptüles Fundament tiefer neuronaler Netze gilt, bleibt sie gleichzeitig eine unverzichtbare Basismethode in der klinischen Medizin, der Finanzrisikomodellierung, der Natursprachverarbeitung und dem automatisierten maschinellen Entscheiden.

Die vorliegende Arbeit analysiert die logistische Regression auf mehreren Abstraktionsebenen. Ausgehend von der wahrscheinlichkeitstheoretischen Fundierung über die Exponentialfamilie werden sämtliche zentralen Konzepte – Sigmoid-Transformation, Kreuzentropieverlustfunktion, Konvexität, Gradientenverfahren, Newton-Raphson, L-BFGS, L1/L2-Regularisierung und Softmax-Erweiterung – mit vollständigen formalen Beweisen entwickelt. Vierzehn Abbildungen auf Basis realer und synthetischer Daten illustrieren die theoretischen Konzepte. Den Schwerpunkt bildet ein umfangreicher Ausblick auf Forschungs-, Industrie- und Wissenschaftsfelder des Jahres 2025: Federated Learning, Differenzielle Privatheit, Bayesianische Erweiterungen, erklärbares KI, Large Language Models als Wissensgrundlage sowie Anwendungen in der Präzisionsmedizin, Klimawissenschaft, Robotik und quantengestütztem maschinellen Lernen.

1.1 Historischer Kontext

Die logistische Funktion geht auf Pierre-Francois Verhulst zurück, der sie 1845 zur Modellierung des Bevölkerungswachstums entwickelte [Verhulst, 1845]. Den entscheidenden Schritt zur statistischen Klassifikation vollzog David Cox 1958 mit seiner wegweisenden Arbeit über die Regressionsanalyse binärer Sequenzen [Cox, 1958]. In den folgenden Jahrzehnten etablierte sich die logistische Regression als Standardwerkzeug der Biostatistik und Epidemiologie, bevor sie im Kontext des maschinellen Lernens eine Renaissance erfuhr.

Heute, im Jahr 2025, steht die logistische Regression an einer bemerkenswerten Wegscheide: Einerseits wird sie als konzeptüles Fundament tiefer neuronaler Netze und Transformer-Architekturen anerkannt – das Softmax-Ausgabebayer jedes modernen Sprachmodells ist nichts anderes als eine multinomiale logistische Regression. Andererseits behauptet sie sich als eigenständige, interpretierbare Methode gegenüber komplexeren Blackbox-Ansätzen, gerade in regulierten Branchen wie der Medizin und dem Finanzwesen.

1.2 Abgrenzung zur linearen Regression

In der *linearen Regression* wird eine kontinuierliche Zielvariable $Y \in \mathbb{R}$ durch

$$Y = \mathbf{w}^\top \mathbf{x} + b + \varepsilon, \quad \varepsilon \sim \mathcal{N}(0, \sigma^2)$$

modelliert. Fünf fundamentale Probleme entstehen, wenn dieses Modell auf Klassifikation angewendet wird:

- (i) **Wertebereich-Verletzung:** Lineare Modelle liefern Vorhersagen in $\mathbb{R}$, während Wahrscheinlichkeiten auf $[0, 1]$ beschränkt sind.
- (ii) **Heteroskedastizität:** Binäre Daten weisen eine von x abhängige Varianz $p(x)(1 - p(x))$ auf – die Gauss-Markov-Annahme der homoskedastischen Residuen ist verletzt.

- (iii) **Nicht-Normalität der Residuen:** Binäre Residuen $y - \hat{y}$ sind diskret und nicht normalverteilt.
- (iv) **Ausreissersensitivität:** Der quadratische Verlust bestraft weit entfernte Punkte übermassig stark.
- (v) **Fehlende probabilistische Interpretation:** Lineare Vorhersagen besitzen keine konsistente Wahrscheinlichkeitsinterpretation.

Die logistische Regression adressiert alle fünf Probleme durch die Wahl der Bernoulli-Likelihood und der kanonischen Sigmoid-Linkfunktion.

2 Mathematische Grundlagen

2.1 Der lineare Prädiktor

Sei $\mathbf{x} = (x_1, x_2, \dots, x_d)^\top \in \mathbb{R}^d$ ein Merkmalsvektor und $\mathbf{w} = (w_1, w_2, \dots, w_d)^\top \in \mathbb{R}^d$ ein Gewichtsvektor. Der *lineare Prädiktor* (auch: *logit* oder *log-Odds*) ist definiert als:

$$z = \mathbf{w}^\top \mathbf{x} + b = \sum_{j=1}^d w_j x_j + b \in \mathbb{R}, \quad (1)$$

wobei $b \in \mathbb{R}$ den Bias-Term bezeichnet. Durch Augmentierung des Merkmalsvektors $\tilde{\mathbf{x}} = (1, x_1, \dots, x_d)^\top \in \mathbb{R}^{d+1}$ und des Gewichtsvektors $\tilde{\mathbf{w}} = (b, w_1, \dots, w_d)^\top \in \mathbb{R}^{d+1}$ gilt kompakt: $z = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}$.

2.2 Die Sigmoid-Funktion

Definition 2.1 (Sigmoid-Funktion). Die *Sigmoid-Funktion* (auch: *logistische Funktion*) ist definiert als:

$$\sigma(z) = \frac{1}{1 + e^{-z}} = \frac{e^z}{1 + e^z}, \quad z \in \mathbb{R}. \quad (2)$$




Abbildung 1: Links: Sigmoid-Funktion $\sigma(z)$ und ihre Ableitung $\sigma'(z) = \sigma(z)(1 - \sigma(z))$. Rechts: Vergleich mit alternativen Squashing-Funktionen.

Proposition 2.2 (Eigenschaften der Sigmoid-Funktion). *Die Sigmoid-Funktion $\sigma : \mathbb{R} \rightarrow (0, 1)$ besitzt die folgenden Eigenschaften:*

- (i) **Wertebereich:** $\sigma : \mathbb{R} \rightarrow (0, 1)$, streng monoton wachsend.
- (ii) **Symmetrie:** $\sigma(-z) = 1 - \sigma(z)$ für alle $z \in \mathbb{R}$.
- (iii) **Grenzwerte:** $\lim_{z \rightarrow +\infty} \sigma(z) = 1$, $\lim_{z \rightarrow -\infty} \sigma(z) = 0$.
- (iv) **Ableitung:** $\sigma'(z) = \sigma(z)(1 - \sigma(z)) \in (0, 1/4]$.
- (v) **Inversität:** $\sigma^{-1}(p) = \ln\left(\frac{p}{1-p}\right)$ für $p \in (0, 1)$ (Logit-Funktion).
- (vi) **Lipschitz-Stetigkeit:** $|\sigma(z_1) - \sigma(z_2)| \leq \frac{1}{4}|z_1 - z_2|$.
- (vii) **Zweite Ableitung:** $\sigma''(z) = \sigma(z)(1 - \sigma(z))(1 - 2\sigma(z))$.

Proof. (iv): Sei $f(z) = (1 + e^{-z})^{-1}$. Dann:

$$f'(z) = \frac{e^{-z}}{(1 + e^{-z})^2} = \frac{1}{1 + e^{-z}} \cdot \frac{e^{-z}}{1 + e^{-z}} = \sigma(z) \cdot (1 - \sigma(z)).$$

Das Maximum von $\sigma(z)(1 - \sigma(z))$ wird durch $\partial_z[\sigma(1 - \sigma)] = 0$ bestimmt: $\sigma(1 - \sigma)(1 - 2\sigma) = 0$, also bei $\sigma = 1/2$, d.h. $z = 0$, mit Wert $1/4$.

(vi): Da $|\sigma'(z)| \leq 1/4$ für alle z , folgt aus dem Mittelwertsatz: $|\sigma(z_1) - \sigma(z_2)| \leq \sup_{\xi} |\sigma'(\xi)| \cdot |z_1 - z_2| \leq \frac{1}{4}|z_1 - z_2|$. $\square$

2.3 Das Wahrscheinlichkeitsmodell

Das logistische Regressionsmodell definiert die bedingte Wahrscheinlichkeit:

$$\mathbb{P}(Y = 1 \mid \mathbf{x}; \mathbf{w}, b) = \sigma(\mathbf{w}^\top \mathbf{x} + b) =: \hat{p}(\mathbf{x}), \quad (3)$$

und konsequenterweise $\mathbb{P}(Y = 0 \mid \mathbf{x}; \mathbf{w}, b) = 1 - \hat{p}(\mathbf{x}) = \sigma(-\mathbf{w}^\top \mathbf{x} - b)$.

2.4 Log-Odds und Interpretierbarkeit

Proposition 2.3 (Log-Odds-Linearität). *Unter dem logistischen Modell gilt:*

$$\ln \frac{\hat{p}(\mathbf{x})}{1 - \hat{p}(\mathbf{x})} = \mathbf{w}^\top \mathbf{x} + b. \quad (4)$$

Eine Erhöhung von x_j um eine Einheit bei konstanten übrigen Merkmalen ergibt eine multiplikative Änderung der Odds um den Faktor e^{w_j} .

Proof. Aus (3) folgt $\hat{p} = \sigma(z)$ mit $z = \mathbf{w}^\top \mathbf{x} + b$. Die Logit-Transformation ergibt:

$$\ln \frac{\hat{p}}{1 - \hat{p}} = \ln \frac{\sigma(z)}{1 - \sigma(z)} = \ln \frac{e^z / (1 + e^z)}{1 / (1 + e^z)} = \ln e^z = z = \mathbf{w}^\top \mathbf{x} + b. \quad \square$$

$\square$

Beispiel 2.4 (Klinische Interpretation). In einer klinischen Studie mit $w_{\text{Alter}} = 0.05$ bedeutet dies: Pro Lebensjahr steigen die Odds des Erkrankungsereignisses um den Faktor $e^{0.05} \approx 1.051$, also um etwa 5.1%. Dieses Odds-Ratio ist die primäre Berichtsgrösse in epidemiologischen Studien.

3 Statistische Herleitung: Exponentialfamilie und GLM

3.1 Generalisierte Lineare Modelle

Definition 3.1 (Generalisiertes Lineares Modell nach McCullagh und Nelder). Ein *generalisiertes lineares Modell* (GLM) besteht aus drei Komponenten:

- (i) **Zufallskomponente:** $Y \mid \mathbf{x}$ folgt einer Verteilung aus der Exponentialfamilie.
- (ii) **Systematische Komponente:** Linearer Prädiktor $z = \mathbf{w}^\top \mathbf{x} + b$.
- (iii) **Linkfunktion:** Monotone, differenzierbare Funktion g mit $g(\mathbb{E}[Y \mid \mathbf{x}]) = z$.

Für die logistische Regression gilt: $Y \mid \mathbf{x} \sim \text{Bernoulli}(\hat{p})$ und die *kanonische Linkfunktion* ist der Logit $g(p) = \ln(p/(1-p))$.

3.2 Die Bernoulli-Verteilung als Exponentialfamilie

Proposition 3.2 (Kanonische Form der Bernoulli-Verteilung). Die Bernoulli-Verteilung $\text{Bern}(p)$ mit $p \in (0, 1)$ lässt sich in der kanonischen Form der Exponentialfamilie schreiben:

$$f(y; \eta) = \exp(\eta y - A(\eta)) \cdot h(y), \quad (5)$$

mit kanonischem Parameter $\eta = \ln(p/(1-p)) \in \mathbb{R}$, Log-Partition-Funktion $A(\eta) = \ln(1+e^\eta)$ und Basismass $h(y) = 1$.

Proof. Aus $f(y; p) = p^y(1-p)^{1-y}$ folgt:

$$f(y; p) = \exp[y \ln p + (1-y) \ln(1-p)] = \exp[y \ln \frac{p}{1-p} + \ln(1-p)].$$

Mit $\eta = \ln(p/(1-p))$ gilt $p = e^\eta/(1+e^\eta)$, also $1-p = 1/(1+e^\eta)$ und $\ln(1-p) = -\ln(1+e^\eta) = -A(\eta)$. Dies ergibt die kanonische Form (5). $\square$

Proposition 3.3 (Momente aus der Log-Partition-Funktion). Für jede Exponentialfamilien-Verteilung gilt:

$$\mathbb{E}[Y] = A'(\eta) = \sigma(\eta), \quad \text{Var}[Y] = A''(\eta) = \sigma(\eta)(1-\sigma(\eta)).$$

Proof. $A'(\eta) = \frac{d}{d\eta} \ln(1+e^\eta) = \frac{e^\eta}{1+e^\eta} = \sigma(\eta)$. $A''(\eta) = \sigma(\eta)(1-\sigma(\eta))$. Die Identität $\mathbb{E}[T(Y)] = A'(\eta)$ gilt allgemein für Exponentialfamilien und folgt aus Differentiation unter dem Integral. $\square$

3.3 Suffiziente Statistik und Informationsgeometrie

Die Bernoulli-Verteilung gehört zur einparametrischen Exponentialfamilie mit suffizienter Statistik $T(y) = y$. Der *Fisher-Information* ist:

$$\mathcal{I}(\eta) = A''(\eta) = \sigma(\eta)(1 - \sigma(\eta)). \quad (6)$$

Dies hat eine direkte Verbindung zur Riemannschen Metrik auf dem statistischen Mannigfaltigkeitsraum aller Bernoulli-Verteilungen (Informationsgeometrie nach Amari [Amari, 2016]).

4 Verlustfunktion und Maximum-Likelihood

4.1 Likelihood und Log-Likelihood

Gegeben sei ein Datensatz $\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$ mit $y^{(i)} \in \{0, 1\}$ und $\mathbf{x}^{(i)} \in \mathbb{R}^d$. Die Likelihood-Funktion unter der Bernoulli-Annahme mit bedingter Unabhängigkeit ist:

$$L(\mathbf{w}, b) = \prod_{i=1}^n \hat{p}_i^{y^{(i)}} (1 - \hat{p}_i)^{1-y^{(i)}}, \quad (7)$$

mit $\hat{p}_i = \sigma(\mathbf{w}^\top \mathbf{x}^{(i)} + b)$. Logarithmieren liefert die *Log-Likelihood*:

$$\ell(\mathbf{w}, b) = \sum_{i=1}^n \left[y^{(i)} \ln \hat{p}_i + (1 - y^{(i)}) \ln(1 - \hat{p}_i) \right]. \quad (8)$$

4.2 Binäre Kreuzentropie und Informationstheorie

Definition 4.1 (Binäre Kreuzentropie-Verlustfunktion).

$$\mathcal{L}(\mathbf{w}, b) = -\frac{1}{n} \sum_{i=1}^n \left[y^{(i)} \ln \hat{p}_i + (1 - y^{(i)}) \ln(1 - \hat{p}_i) \right]. \quad (9)$$




Abbildung 2: Vergleich der Verlustfunktionen (Kreuzentropie, MSE, Hinge-Loss) für beide Klassen. Die Kreuzentropie bestraft hochkonfidente Fehlklassifikationen am stärksten.

Proposition 4.2 (Informationstheoretische Interpretation). *Die binäre Kreuzentropie ist die Kreuzentropie zwischen der empirischen Verteilung $q_i = y^{(i)}$ und der Modellverteilung $\hat{p}_i$:*

$$\mathcal{L} = \frac{1}{n} \sum_{i=1}^n H(q_i, \hat{p}_i) = \frac{1}{n} \sum_{i=1}^n [H(q_i) + \text{KL}(q_i \| \hat{p}_i)],$$

wobei $H(q_i)$ die binäre Entropie der wahren Verteilung und $\text{KL}(q_i \| \hat{p}_i)$ die Kullback-Leibler-Divergenz bezeichnen. Da $H(q_i)$ nicht von den Parametern abhängt, ist die Minimierung der Kreuzentropie äquivalent zur Minimierung der KL-Divergenz.

4.3 Konvexität der Verlustfunktion

Theorem 4.3 (Konvexität der binären Kreuzentropie). *Die Verlustfunktion $\mathcal{L}(\mathbf{w}, b) : \mathbb{R}^{d+1} \rightarrow \mathbb{R}$ aus (9) ist konvex in $(\mathbf{w}, b)$.*

Proof. Wir zeigen positive Semidefinitheit der Hesse-Matrix. Sei $\tilde{\mathbf{w}} = (b, \mathbf{w})^\top \in \mathbb{R}^{d+1}$ und $\tilde{\mathbf{x}}^{(i)} = (1, \mathbf{x}^{(i)\top})^\top$. Für den i -ten Term der Verlustfunktion gilt:

$$\ell_i(\tilde{\mathbf{w}}) = -y^{(i)} \ln \sigma(z_i) - (1 - y^{(i)}) \ln(1 - \sigma(z_i)), \quad z_i = \tilde{\mathbf{w}}^\top \tilde{\mathbf{x}}^{(i)}.$$

Erste Ableitung nach z_i :

$$\frac{\partial \ell_i}{\partial z_i} = \sigma(z_i) - y^{(i)}.$$

Zweite Ableitung:

$$\frac{\partial^2 \ell_i}{\partial z_i^2} = \sigma(z_i)(1 - \sigma(z_i)) =: s_i \geq 0.$$

Die Hesse-Matrix von $\mathcal{L}$ bzgl. $\tilde{\mathbf{w}}$ ist:

$$\nabla^2 \mathcal{L} = \frac{1}{n} \sum_{i=1}^n s_i \tilde{\mathbf{x}}^{(i)} (\tilde{\mathbf{x}}^{(i)})^\top = \frac{1}{n} \tilde{\mathbf{X}}^\top \mathbf{S} \tilde{\mathbf{X}}, \quad (10)$$

wobei $\tilde{\mathbf{X}} \in \mathbb{R}^{n \times (d+1)}$ die augmentierte Designmatrix und $\mathbf{S} = \text{diag}(s_1, \dots, s_n) \succeq 0$ ist. Für jeden Vektor $\mathbf{v} \in \mathbb{R}^{d+1}$ gilt:

$$\mathbf{v}^\top \nabla^2 \mathcal{L} \mathbf{v} = \frac{1}{n} \sum_{i=1}^n s_i (\tilde{\mathbf{x}}^{(i)\top} \mathbf{v})^2 \geq 0,$$

da $s_i \geq 0$. Also ist $\nabla^2 \mathcal{L} \succeq 0$, was die Konvexität beweist. Strikte Konvexität gilt genau dann, wenn $\tilde{\mathbf{X}}$ vollen Spaltenrang hat und mindestens ein $s_i > 0$ ist. $\square$

Korollar 4.4. *Jedes lokale Minimum von $\mathcal{L}$ ist ein globales Minimum. Wenn $\tilde{\mathbf{X}}$ vollen Spaltenrang hat, ist das Minimum eindeutig (sofern es endlich ist; bei linear separierbaren Daten existiert kein endliches Minimum).*

4.4 Gradientenberechnung

Proposition 4.5 (Gradient der binären Kreuzentropie).

$$\nabla_{\mathbf{w}} \mathcal{L} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y^{(i)}) \mathbf{x}^{(i)} = \frac{1}{n} \mathbf{X}^\top (\hat{\mathbf{p}} - \mathbf{y}), \quad (11)$$

$$\frac{\partial \mathcal{L}}{\partial b} = \frac{1}{n} \sum_{i=1}^n (\hat{p}_i - y^{(i)}). \quad (12)$$

Proof. Wir leiten den i -ten Beitrag nach w_k ab:

$$\begin{aligned} \frac{\partial \ell_i}{\partial w_k} &= \frac{\partial}{\partial w_k} [-y^{(i)} \ln \sigma(z_i) - (1 - y^{(i)}) \ln(1 - \sigma(z_i))] \\ &= (\sigma(z_i) - y^{(i)}) \frac{\partial z_i}{\partial w_k} = (\hat{p}_i - y^{(i)}) x_k^{(i)}. \end{aligned}$$

Summation und Division durch n ergibt (11). $\square$

Bemerkung 4.6 (Elegante Gradientenstruktur). Der Gradient hat die Form $\frac{1}{n} \mathbf{X}^\top (\hat{\mathbf{p}} - \mathbf{y})$: Er ist die mittlere Differenz zwischen Vorhersage und Wahrheit, gewichtet mit den Merkmalen. Diese Struktur ist identisch mit dem Gradienten der linearen Regression (dort: $\frac{1}{n} \mathbf{X}^\top (\hat{\mathbf{y}} - \mathbf{y})$) – mit dem einzigen Unterschied, dass $\hat{\mathbf{y}}$ durch die Sigmoid-Transformation ersetzt wird.

5 Optimierungsverfahren

5.1 Gradientenabstieg

Algorithm 1 Batch-Gradientenabstieg für logistische Regression

Require: Datensatz $\mathcal{D}$, Lernrate $\eta > 0$, Toleranz $\epsilon > 0$, Max. Iterationen T

Ensure: Parameterschätzer $\hat{\mathbf{w}}, \hat{b}$

- 1: Initialisiere $\mathbf{w} \leftarrow \mathbf{0} \in \mathbb{R}^d$, $b \leftarrow 0$
 - 2: **for** $t = 1, 2, \dots, T$ **do**
 - 3: $z_i \leftarrow \mathbf{w}^\top \mathbf{x}^{(i)} + b$ für alle $i = 1, \dots, n$
 - 4: $\hat{p}_i \leftarrow \sigma(z_i)$ für alle i
 - 5: $\mathbf{g}_w \leftarrow \frac{1}{n} \mathbf{X}^\top (\hat{\mathbf{p}} - \mathbf{y})$; $g_b \leftarrow \frac{1}{n} \mathbf{1}^\top (\hat{\mathbf{p}} - \mathbf{y})$
 - 6: $\mathbf{w} \leftarrow \mathbf{w} - \eta \mathbf{g}_w$; $b \leftarrow b - \eta g_b$
 - 7: **if** $\|\mathbf{g}_w\|_2 < \epsilon$ **then break**
 - 8: **end if**
 - 9: **end for**
-

Theorem 5.1 (Konvergenz des Gradientenabstiegs). *Sei $\mathcal{L}$ strikt konvex mit L -Lipschitz-stetigem Gradienten ($\|\nabla \mathcal{L}(\mathbf{w}_1) - \nabla \mathcal{L}(\mathbf{w}_2)\| \leq L \|\mathbf{w}_1 - \mathbf{w}_2\|$). Dann konvergiert der Gradientenabstieg mit konstanter Lernrate $\eta \leq 1/L$ linear:*

$$\mathcal{L}(\mathbf{w}^{(t)}) - \mathcal{L}(\mathbf{w}^*) \leq (1 - \mu\eta)^t [\mathcal{L}(\mathbf{w}^{(0)}) - \mathcal{L}(\mathbf{w}^*)], \quad (13)$$

wobei $\mu > 0$ der kleinste Eigenwert der Hesse-Matrix (Starke-Konvexitäts-Parameter) ist.

Proof. Da $\mathcal{L}$ L -glatt ist, gilt für alle $\mathbf{w}, \tilde{\mathbf{w}}$:

$$\mathcal{L}(\tilde{\mathbf{w}}) \leq \mathcal{L}(\mathbf{w}) + \nabla \mathcal{L}(\mathbf{w})^\top (\tilde{\mathbf{w}} - \mathbf{w}) + \frac{L}{2} \|\tilde{\mathbf{w}} - \mathbf{w}\|^2.$$

Setze $\tilde{\mathbf{w}} = \mathbf{w} - \eta \nabla \mathcal{L}(\mathbf{w})$:

$$\mathcal{L}(\mathbf{w}^{(t+1)}) \leq \mathcal{L}(\mathbf{w}^{(t)}) - \eta \left(1 - \frac{\eta L}{2}\right) \|\nabla \mathcal{L}(\mathbf{w}^{(t)})\|^2.$$

Aus starker Konvexität folgt $\|\nabla \mathcal{L}(\mathbf{w})\|^2 \geq 2\mu[\mathcal{L}(\mathbf{w}) - \mathcal{L}(\mathbf{w}^*)]$. Rekursive Anwendung ergibt (13). $\square$




Abbildung 3: Links: Einfluss der Lernrate auf die Konvergenzgeschwindigkeit. Zu grosse Lernraten führen zur Divergenz. Rechts: Vergleich zwischen vollständigem GD, Mini-Batch SGD und stochastischem GD.

5.2 Newton-Raphson-Verfahren (IRLS)

Das Newton-Verfahren nutzt die Hesse-Matrix für quadratisch konvergente Updates:

$$\tilde{\mathbf{w}}^{(t+1)} \leftarrow \tilde{\mathbf{w}}^{(t)} - (\nabla^2 \mathcal{L})^{-1} \nabla \mathcal{L}. \quad (14)$$

Theorem 5.2 (Newton-Raphson als IRLS). *Das Newton-Raphson-Verfahren für die logistische Regression ist äquivalent zum Iteratively Reweighted Least Squares (IRLS): In jeder Iteration wird ein gewichtetes lineares Kleinste-Quadrate-Problem der Form*

$$\tilde{\mathbf{w}}^{(t+1)} = (\tilde{\mathbf{X}}^\top \mathbf{S}^{(t)} \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top \mathbf{S}^{(t)} \zeta^{(t)} \quad (15)$$

gelöst, mit Gewichtsmatrix $\mathbf{S}^{(t)} = \text{diag}(s_i^{(t)})$, $s_i^{(t)} = \hat{p}_i^{(t)}(1 - \hat{p}_i^{(t)})$, und angepasster Antwortvariable $\zeta_i^{(t)} = z_i^{(t)} + (y_i - \hat{p}_i^{(t)})/s_i^{(t)}$.

Proof. Aus der Newton-Update-Regel folgt mit der Hesse-Matrix (10) und dem Gradienten:

$$\begin{aligned} \tilde{\mathbf{w}}^{(t+1)} &= \tilde{\mathbf{w}}^{(t)} - \frac{1}{n} (\tilde{\mathbf{X}}^\top \mathbf{S} \tilde{\mathbf{X}})^{-1} \cdot \frac{1}{n} \tilde{\mathbf{X}}^\top (\hat{\mathbf{p}} - \mathbf{y}) \cdot n \\ &= (\tilde{\mathbf{X}}^\top \mathbf{S} \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top \mathbf{S} [\tilde{\mathbf{X}} \tilde{\mathbf{w}}^{(t)} + \mathbf{S}^{-1}(\mathbf{y} - \hat{\mathbf{p}})] = (\tilde{\mathbf{X}}^\top \mathbf{S} \tilde{\mathbf{X}})^{-1} \tilde{\mathbf{X}}^\top \mathbf{S} \zeta, \end{aligned}$$

was (15) ergibt. $\square$

Theorem 5.3 (Quadratische Konvergenz von Newton-Raphson). Sei $\mathbf{w}^*$ das einzige Minimum von $\mathcal{L}$ und $\nabla^2 \mathcal{L}(\mathbf{w}^*)$ positiv definit mit kleinstem Eigenwert $\mu > 0$. Dann gilt lokal:

$$\|\mathbf{w}^{(t+1)} - \mathbf{w}^*\| \leq \frac{M}{2\mu} \|\mathbf{w}^{(t)} - \mathbf{w}^*\|^2, \quad (16)$$

wobei $M = \sup_{\mathbf{w}} \|\nabla^3 \mathcal{L}(\mathbf{w})\|$ die Lipschitz-Konstante der Hesse-Matrix bezeichnet.

5.3 L-BFGS: Quasi-Newton-Methode für grosse Dimensionen

Für hochdimensionale Probleme ($d \gg 1$) ist die explizite Berechnung und Invertierung der $(d+1) \times (d+1)$ -Hesse-Matrix unpraktikabel. Das *Limited-memory Broyden-Fletcher-Goldfarb-Shanno* (L-BFGS) Verfahren approximiert die inverse Hesse-Matrix durch die letzten m (typisch $m = 5 - 20$) Gradientendifferenzen:

$$H_k^{-1} \approx V_k^\top \cdots V_{k-m}^\top H_0^{-1} V_{k-m} \cdots V_k + \text{Rang-}2m\text{-Korrekturen}, \quad (17)$$

mit $V_k = I - \rho_k \mathbf{s}_k \mathbf{y}_k^\top$, $\rho_k = 1/(\mathbf{y}_k^\top \mathbf{s}_k)$, $\mathbf{s}_k = \mathbf{w}^{(k)} - \mathbf{w}^{(k-1)}$, $\mathbf{y}_k = \nabla \mathcal{L}(\mathbf{w}^{(k)}) - \nabla \mathcal{L}(\mathbf{w}^{(k-1)})$.

5.4 Stochastischer Gradientenabstieg und Varianten

Algorithm 2 Adam-Optimizer für logistische Regression

Require: Lernrate α , $\beta_1, \beta_2 \in [0, 1)$, $\epsilon > 0$, Datensatz $\mathcal{D}$

- 1: $\mathbf{m}_0 \leftarrow \mathbf{0}$, $\mathbf{v}_0 \leftarrow \mathbf{0}$, $t \leftarrow 0$
 - 2: **while** nicht konvergiert **do**
 - 3: $t \leftarrow t + 1$
 - 4: Berechne Gradient $\mathbf{g}_t = \nabla_{\mathbf{w}} \mathcal{L}$ auf Mini-Batch
 - 5: $\mathbf{m}_t \leftarrow \beta_1 \mathbf{m}_{t-1} + (1 - \beta_1) \mathbf{g}_t$ (1. Moment)
 - 6: $\mathbf{v}_t \leftarrow \beta_2 \mathbf{v}_{t-1} + (1 - \beta_2) \mathbf{g}_t^2$ (2. Moment)
 - 7: $\hat{\mathbf{m}}_t \leftarrow \mathbf{m}_t / (1 - \beta_1^t)$; $\hat{\mathbf{v}}_t \leftarrow \mathbf{v}_t / (1 - \beta_2^t)$
 - 8: $\mathbf{w} \leftarrow \mathbf{w} - \alpha \hat{\mathbf{m}}_t / (\sqrt{\hat{\mathbf{v}}_t} + \epsilon)$
 - 9: **end while**
-

6 Entscheidungsgrenze und geometrische Interpretation

6.1 Lineare Entscheidungsgrenze

Definition 6.1 (Entscheidungsgrenze). Die *Entscheidungsgrenze* mit Schwellwert $\tau \in (0, 1)$ ist die Hyperebene:

$$\mathcal{H}_\tau = \{\mathbf{x} \in \mathbb{R}^d : \mathbf{w}^\top \mathbf{x} + b = \ln \frac{\tau}{1-\tau}\}.$$

Für $\tau = 0.5$: $\mathcal{H}_{0.5} = \{\mathbf{x} : \mathbf{w}^\top \mathbf{x} + b = 0\}$.




Abbildung 4: Entscheidungsgrenzen der logistischen Regression. Links: linear separierbare Daten mit gerader Trennlinie. Mitte und rechts: nichtlinear verteilte Daten, bei denen die lineare Entscheidungsgrenze versagt.

Proposition 6.2 (Geometrie der Entscheidungsgrenze). *Die Entscheidungsgrenze $\mathcal{H}_{0.5}$ ist eine $(d - 1)$ -dimensionale Hyperebene mit Normalenvektor $\mathbf{w}$ und vorzeichenbehaftetem Abstand des Punktes $\mathbf{x}_0$ von der Grenze:*

$$d(\mathbf{x}_0, \mathcal{H}) = \frac{\mathbf{w}^\top \mathbf{x}_0 + b}{\|\mathbf{w}\|_2}. \quad (18)$$

6.2 Margin und Konfidenz

Der vorzeichenbehaftete Abstand (18) misst die Klassifikationskonfidenz: Je grösser $|d(\mathbf{x}_0, \mathcal{H})|$, desto weiter ist der Punkt von der Entscheidungsgrenze entfernt und desto sicherer ist die Vorhersage. Bei $|d| \rightarrow \infty$ nähert sich $\hat{p}$ asymptotisch 1 (oder 0) an.

6.3 Nicht-lineare Erweiterung durch Feature-Maps

Definition 6.3 (Kernel-Logistische Regression). Sei $\phi : \mathbb{R}^d \rightarrow \mathcal{H}$ eine Feature-Map in einen (möglicherweise unendlichdimensionalen) Hilbert-Raum $\mathcal{H}$. Die Kernel-Logistische Regression modelliert:

$$\hat{p}(\mathbf{x}) = \sigma(\langle \mathbf{w}, \phi(\mathbf{x}) \rangle_{\mathcal{H}} + b).$$

Der *Representer-Satz* garantiert, dass die Lösung die Form $\mathbf{w} = \sum_{i=1}^n \alpha_i \phi(\mathbf{x}^{(i)})$ hat, was die Auswertung via Kernel $k(\mathbf{x}, \mathbf{x}') = \langle \phi(\mathbf{x}), \phi(\mathbf{x}') \rangle$ ermöglicht.

7 Regularisierung

7.1 Ridge-Regularisierung (L2)

$$\mathcal{L}_{\lambda_2}(\mathbf{w}, b) = \mathcal{L}(\mathbf{w}, b) + \frac{\lambda_2}{2} \|\mathbf{w}\|_2^2. \quad (19)$$

Proposition 7.1 (Bayesianische Interpretation der L2-Regularisierung). *L2-Regularisierung entspricht einer Maximum a Posteriori (MAP)-Schätzung mit Gauss'schem Prior $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \lambda_2^{-1} \mathbf{I})$:*

$$\hat{\mathbf{w}}_{\text{MAP}} = \arg \max_{\mathbf{w}} [\ln L(\mathbf{w}) + \ln p(\mathbf{w})] = \arg \min_{\mathbf{w}} \left[\mathcal{L}(\mathbf{w}) + \frac{\lambda_2}{2} \|\mathbf{w}\|_2^2 \right].$$

Proof. Mit $\ln p(\mathbf{w}) = -\frac{\lambda_2}{2}\|\mathbf{w}\|_2^2 + \text{const}$ gilt: $\arg \max[\ell(\mathbf{w}) - \frac{\lambda_2}{2}\|\mathbf{w}\|_2^2] = \arg \min \mathcal{L}_{\lambda_2}(\mathbf{w})$. $\square$

7.2 Lasso-Regularisierung (L1)

$$\mathcal{L}_{\lambda_1}(\mathbf{w}, b) = \mathcal{L}(\mathbf{w}, b) + \lambda_1 \|\mathbf{w}\|_1, \quad \|\mathbf{w}\|_1 = \sum_{j=1}^d |w_j|. \quad (20)$$

Proposition 7.2 (Sparsitätsinduktion durch L1). *Die L1-regularisierte Verlustfunktion hat die Eigenschaft, dass für genügend grosse λ_1 bestimmte Koeffizienten exakt zu Null gesetzt werden (Sparsität). Die Karush-Kuhn-Tucker-Bedingungen für ein Minimum $\hat{\mathbf{w}}$ lauten:*

$$\frac{\partial \mathcal{L}}{\partial w_j} + \lambda_1 \text{sign}(w_j) = 0 \quad (w_j \neq 0), \quad \left| \frac{\partial \mathcal{L}}{\partial w_j} \right| \leq \lambda_1 \quad (w_j = 0).$$




Abbildung 5: Regularisierungspfade. Links: L1-Regularisierung setzt Koeffizienten exakt auf Null (Sparsität). Rechts: L2-Regularisierung schrumpft alle Koeffizienten gleichmässig ohne vollständige Elimination.

7.3 Elastic Net

$$\mathcal{L}_{\text{EN}}(\mathbf{w}) = \mathcal{L}(\mathbf{w}) + \lambda_1 \|\mathbf{w}\|_1 + \frac{\lambda_2}{2} \|\mathbf{w}\|_2^2. \quad (21)$$

Tabelle 1: Vergleich der Regularisierungsverfahren für logistische Regression.

Methode	Strafterm	Sparsit.	Diff'bar	Prior	Typ. Anwendungsfall
Keine	–	Nein	Ja	Uniform	Kleine n , linear separ.
L2 Ridge	$\lambda \ \mathbf{w}\ _2^2$	Nein	Ja	Gaussisch	Korrelierte Merkmale
L1 Lasso	$\lambda \ \mathbf{w}\ _1$	Ja	Nein	Laplace	Hochdimens. Daten
Elastic	$\lambda_1 \ \mathbf{w}\ _1 + \lambda_2 \ \mathbf{w}\ _2^2$	Ja	Nein	Gemischt	Gruppen korr. Merkm.




Abbildung 6: Bias-Varianz-Tradeoff: Starke Regularisierung (C klein) führt zu hohem Bias (Underfitting), schwache Regularisierung (C gross) zu hoher Varianz (Overfitting).

8 Varianzinflationsfaktor (VIF) und Multikollinearität

Eines der zentralen Qualitätsprobleme in der logistischen Regression – wie auch in der linearen Regression – ist die *Multikollinearität* zwischen Prädiktorvariablen. Wenn Eingabemerkmale stark miteinander korrelieren, werden die geschätzten Regressionskoeffizienten instabil, ihre Varianzen aufgeblasen und ihre Interpretierbarkeit fundamental beeinträchtigt. Der *Varianzinflationsfaktor* (VIF, engl. *Variance Inflation Factor*) ist das meistverwendete diagnostische Instrument zur Quantifizierung dieses Problems. Dieses Kapitel entwickelt die mathematischen Grundlagen des VIF, seine Berechnung, Interpretation und praktische Bedeutung für die logistische Regression in vollständiger Tiefe.

8.1 Motivation: Das Problem der Multikollinearität

Definition 8.1 (Multikollinearität). Seien $\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_d \in \mathbb{R}^n$ die Spalten der Designmatrix $\mathbf{X} \in \mathbb{R}^{n \times d}$. *Exakte Multikollinearität* liegt vor, wenn es einen Vektor $\mathbf{c} = (c_1, \dots, c_d)^\top \neq \mathbf{0}$ gibt mit

$$\sum_{j=1}^d c_j \mathbf{x}_j = \mathbf{0},$$

d. h. wenn $\mathbf{X}$ nicht vollen Spaltenrang hat. *Approximative Multikollinearität* liegt vor, wenn diese Beziehung näherungsweise gilt, also $\|\sum_j c_j \mathbf{x}_j\|_2 \approx 0$ für ein nichttriviales $\mathbf{c}$.

Bemerkung 8.2 (Konsequenzen exakter Multikollinearität). Bei exakter Multikollinearität ist die Designmatrix $\mathbf{X}^\top \mathbf{X}$ singulär. Die Normalgleichungen der linearen Regression besitzen dann unendlich viele Lösungen, und der Maximum-Likelihood-Schätzer der logistischen Regression existiert nicht eindeutig. In der Praxis ist approximative Multikollinearität das weitaus häufigere und gleichzeitig schwerer zu diagnostizierende Problem.

Um das Problem zu verstehen, betrachten wir den Standardfehler eines Regressionskoeffizienten. Im linearen Regressionsmodell $\mathbf{y} = \mathbf{X}\mathbf{w} + \varepsilon$ mit $\varepsilon \sim \mathcal{N}(\mathbf{0}, \sigma^2 \mathbf{I})$ ist die Kovarianzmatrix des OLS-Schätzers $\hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}$:

$$\text{Cov}(\hat{\mathbf{w}}) = \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1}. \quad (22)$$

Insbesondere ist die Varianz des j -ten Koeffizienten:

$$\text{Var}(\hat{w}_j) = \sigma^2 [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}. \quad (23)$$

Wenn Spalten von $\mathbf{X}$ stark korreliert sind, werden die Diagonalelemente von $(\mathbf{X}^\top \mathbf{X})^{-1}$ sehr groß, was zu großen Standardfehlern, breiten Konfidenzintervallen und damit zur Unzuverlässigkeit der Koeffizienten führt – selbst wenn das Modell als Ganzes eine gute Vorhersagequalität besitzt.




Abbildung 7: Standardfehler eines Regressionskoeffizienten als Funktion der Korrelation ρ zwischen zwei Prädiktoren. Ab $\rho \approx 0.7$ steigt der Standardfehler stark an; bei $\rho \rightarrow 1$ divergiert er. Der VIF quantifiziert genau diesen Inflationseffekt.

8.2 Definition und mathematische Herleitung des VIF

Definition 8.3 (Varianzinflationsfaktor). Sei $\mathbf{X} \in \mathbb{R}^{n \times d}$ eine zentrierte Designmatrix mit Spalten $\mathbf{x}_1, \dots, \mathbf{x}_d$. Für den j -ten Prädiktor $\mathbf{x}_j$ wird eine Hilfsregression durchgeführt:

$$\mathbf{x}_j = \alpha_0 + \sum_{k \neq j} \alpha_k \mathbf{x}_k + \varepsilon_j,$$

d. h. $\mathbf{x}_j$ wird auf alle anderen Prädiktoren regressiert. Sei $R_j^2 \in [0, 1)$ das Bestimmtheitsmaß dieser Hilfsregression. Der *Varianzinflationsfaktor* des j -ten Prädiktors ist dann definiert als:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}. \quad (24)$$

Theorem 8.4 (Algebraische Herleitung des VIF). Sei $\mathbf{X} \in \mathbb{R}^{n \times d}$ eine vollrangige, zentrierte Designmatrix und $\mathbf{C} = (\mathbf{X}^\top \mathbf{X})^{-1}$ die inverse Gramsche Matrix. Dann gilt:

$$[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj} = \frac{\text{VIF}_j}{\|\mathbf{x}_j\|_2^2}, \quad (25)$$

wobei VIF_j wie in Definition 8.3 definiert ist.

Proof. Schritt 1: Blockstruktur der Gramschen Matrix. Da die Designmatrix vollrangig ist, können wir die Spalten so permutieren, dass die j -te Spalte an letzter Stelle steht. Da Permutationen simultan auf Zeilen und Spalten wirken und den gesuchten Diagonaleintrag nicht verändern, schreiben wir o. B. d. A.

$$\mathbf{X} = [\mathbf{X}_{-j} \mid \mathbf{x}_j], \quad \mathbf{X}_{-j} \in \mathbb{R}^{n \times (d-1)}, \quad \mathbf{x}_j \in \mathbb{R}^n.$$

Die Gramsche Matrix lautet dann in Blockform:

$$\mathbf{X}^\top \mathbf{X} = \begin{pmatrix} \mathbf{X}_{-j}^\top \mathbf{X}_{-j} & \mathbf{X}_{-j}^\top \mathbf{x}_j \\ \mathbf{x}_j^\top \mathbf{X}_{-j} & \mathbf{x}_j^\top \mathbf{x}_j \end{pmatrix} =: \begin{pmatrix} \mathbf{A} & \mathbf{b} \\ \mathbf{b}^\top & c \end{pmatrix}, \quad (26)$$

mit $\mathbf{A} = \mathbf{X}_{-j}^\top \mathbf{X}_{-j} \in \mathbb{R}^{(d-1) \times (d-1)}$ (positiv definit, da $\mathbf{X}_{-j}$ vollen Spaltenrang hat), $\mathbf{b} = \mathbf{X}_{-j}^\top \mathbf{x}_j \in \mathbb{R}^{d-1}$ und $c = \|\mathbf{x}_j\|_2^2 > 0$.

Schritt 2: Schur-Komplement und Blockmatrix-Inversion. Das *Schur-Komplement* von $\mathbf{A}$ in (26) ist

$$S_j := c - \mathbf{b}^\top \mathbf{A}^{-1} \mathbf{b} = \mathbf{x}_j^\top \mathbf{x}_j - \mathbf{x}_j^\top \mathbf{X}_{-j} (\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^\top \mathbf{x}_j.$$

Nach dem Satz über die Inverse einer 2×2 -Blockmatrix (vgl. Golub & Van Loan ?) gilt für den (d, d) -Eintrag – also den auf die j -te Koordinate entsprechenden Eintrag – der inversen Matrix:

$$[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj} = \frac{1}{S_j} = \frac{1}{\mathbf{x}_j^\top \mathbf{x}_j - \mathbf{x}_j^\top \mathbf{X}_{-j} (\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^\top \mathbf{x}_j}. \quad (27)$$

Das Schur-Komplement $S_j > 0$, da $\mathbf{X}$ vollen Spaltenrang hat (vollrangige Matrizen haben positiv definite Gramsche Matrix, und positive Definitheit ist äquivalent zu $S_j > 0$ für alle j).

Schritt 3: Geometrische Interpretation des Nenners. Sei $\mathbf{H}_{-j} = \mathbf{X}_{-j} (\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^\top \in \mathbb{R}^{n \times n}$ die orthogonale Projektionsmatrix auf den Spaltenraum $\text{col}(\mathbf{X}_{-j})$. Diese Matrix ist idempotent ($\mathbf{H}_{-j}^2 = \mathbf{H}_{-j}$) und selbstadjungiert ($\mathbf{H}_{-j}^\top = \mathbf{H}_{-j}$). Das Komplement

$$\mathbf{M}_{-j} := \mathbf{I}_n - \mathbf{H}_{-j}$$

ist ebenfalls eine orthogonale Projektion (auf den zu $\text{col}(\mathbf{X}_{-j})$ orthogonalen Unterraum). Damit vereinfacht sich der Nenner in (27) zu:

$$S_j = \mathbf{x}_j^\top (\mathbf{I} - \mathbf{H}_{-j}) \mathbf{x}_j = \mathbf{x}_j^\top \mathbf{M}_{-j} \mathbf{x}_j.$$

Da $\mathbf{M}_{-j}$ idempotent und symmetrisch ist, gilt $\mathbf{M}_{-j}^\top \mathbf{M}_{-j} = \mathbf{M}_{-j}^2 = \mathbf{M}_{-j}$, und daher:

$$S_j = \mathbf{x}_j^\top \mathbf{M}_{-j}^\top \mathbf{M}_{-j} \mathbf{x}_j = \|\mathbf{M}_{-j} \mathbf{x}_j\|_2^2.$$

Schritt 4: Verbindung zum Residuum der Hilfsregression. Der OLS-Schätzer in der Hilfsregression $\mathbf{x}_j = \mathbf{X}_{-j} \alpha + \varepsilon_j$ lautet $\hat{\alpha} = (\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^\top \mathbf{x}_j$. Das Residuum ist

$$\hat{\varepsilon}_j := \mathbf{x}_j - \mathbf{X}_{-j} \hat{\alpha} = \mathbf{x}_j - \mathbf{H}_{-j} \mathbf{x}_j = \mathbf{M}_{-j} \mathbf{x}_j,$$

und die Residualquadratsumme beträgt

$$\text{RSS}_j = \|\hat{\varepsilon}_j\|_2^2 = \|\mathbf{M}_{-j} \mathbf{x}_j\|_2^2 = S_j.$$

Die Gesamtquadratsumme der Hilfsregression ist $\text{TSS}_j = \|\mathbf{x}_j - \bar{x}_j \mathbf{1}\|_2^2$. Da $\mathbf{x}_j$ nach Voraussetzung zentriert ist (der Spaltenmittelwert ist null), gilt $\text{TSS}_j = \|\mathbf{x}_j\|_2^2$. Das Bestimmtheitsmaß der Hilfsregression ist somit:

$$R_j^2 = 1 - \frac{\text{RSS}_j}{\text{TSS}_j} = 1 - \frac{\|\mathbf{M}_{-j} \mathbf{x}_j\|_2^2}{\|\mathbf{x}_j\|_2^2} = 1 - \frac{S_j}{\|\mathbf{x}_j\|_2^2}.$$

Auflösen nach S_j liefert:

$$S_j = \|\mathbf{x}_j\|_2^2 (1 - R_j^2).$$

Schritt 5: Zusammenführung. Einsetzen in (27) ergibt:

$$[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj} = \frac{1}{S_j} = \frac{1}{\|\mathbf{x}_j\|_2^2 (1 - R_j^2)} = \frac{1}{\|\mathbf{x}_j\|_2^2} \cdot \frac{1}{1 - R_j^2} = \frac{\text{VIF}_j}{\|\mathbf{x}_j\|_2^2},$$

wobei die letzte Gleichheit die Definition $\text{VIF}_j = 1/(1 - R_j^2)$ verwendet. $\square$

Korollar 8.5 (VIF als Varianzinflation). *Aus Gleichung (23) und Theorem 8.4 folgt unmittelbar:*

$$\text{Var}(\hat{w}_j) = \sigma^2 \cdot \frac{\text{VIF}_j}{\|\mathbf{x}_j\|_2^2}. \quad (28)$$

Im Vergleich zur hypothetischen Situation ohne Multikollinearität ($R_j^2 = 0$, also $\text{VIF}_j = 1$) ist die Varianz von $\hat{w}_j$ um den Faktor VIF_j vergrößert. Daher der Name Varianzinflationfaktor.

Bemerkung 8.6 (Minimaler VIF-Wert). Aus $R_j^2 \geq 0$ folgt $\text{VIF}_j = 1/(1 - R_j^2) \geq 1$, mit Gleichheit genau dann, wenn $\mathbf{x}_j$ vollständig unkorreliert zu allen anderen Prädiktoren ist ($R_j^2 = 0$). Ein VIF von 1 entspricht dem idealen Fall vollständiger Orthogonalität.

8.3 Berechnung des VIF: Schritt für Schritt

Die praktische Berechnung des VIF erfolgt algorithmisch in drei Schritten, die wir hier vollständig formalisieren.

Algorithm 3 Berechnung der Varianzinflationsfaktoren

Require: Designmatrix $\mathbf{X} \in \mathbb{R}^{n \times d}$ mit Spalten $\mathbf{x}_1, \dots, \mathbf{x}_d$

Ensure: VIF-Vektor $(\text{VIF}_1, \dots, \text{VIF}_d)$

- 1: **for** $j = 1, 2, \dots, d$ **do**
 - 2: **Schritt 1:** Bilde $\mathbf{X}_{-j}$ durch Entfernen der j -ten Spalte aus $\mathbf{X}$
 - 3: **Schritt 2:** Schätze OLS-Regression: $\hat{\alpha} = (\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1} \mathbf{X}_{-j}^\top \mathbf{x}_j$
 - 4: **Schritt 3:** Berechne Residuen: $\hat{\mathbf{e}}_j = \mathbf{x}_j - \mathbf{X}_{-j} \hat{\alpha}$
 - 5: **Schritt 4:** Berechne $R_j^2 = 1 - \frac{\|\hat{\mathbf{e}}_j\|_2^2}{\|\mathbf{x}_j - \bar{x}_j \mathbf{1}\|_2^2}$
 - 6: **Schritt 5:** Setze $\text{VIF}_j = \frac{1}{1 - R_j^2}$
 - 7: **end for**
 - 8: **return** $(\text{VIF}_1, \dots, \text{VIF}_d)$
-

Bemerkung 8.7 (Numerisch stabile Berechnung). Für große d empfiehlt sich die Berechnung via QR-Zerlegung statt direkter Matrixinversion. Sei $\mathbf{X}_{-j} = \mathbf{Q}_{-j}\mathbf{R}_{-j}$ die QR-Zerlegung (mit $\mathbf{Q}_{-j}^\top \mathbf{Q}_{-j} = \mathbf{I}$), dann ist:

$$\mathbf{H}_{-j} = \mathbf{Q}_{-j}\mathbf{Q}_{-j}^\top, \quad \hat{e}_j = (\mathbf{I} - \mathbf{Q}_{-j}\mathbf{Q}_{-j}^\top)\mathbf{x}_j.$$

Dies vermeidet die numerisch aufwendige und fehleranfällige Matrixinversion $(\mathbf{X}_{-j}^\top \mathbf{X}_{-j})^{-1}$ und ist in Zeit $\mathcal{O}(nd^2)$ durchführbar.

Beispiel 8.8 (VIF-Berechnung für zwei Prädiktoren). Betrachte $n = 100$ Beobachtungen mit zwei Prädiktoren x_1, x_2 mit Korrelationskoeffizient $\rho = \text{Corr}(x_1, x_2)$. Im standardisierten Fall gilt $R_1^2 = R_2^2 = \rho^2$, also:

$$\text{VIF}_1 = \text{VIF}_2 = \frac{1}{1 - \rho^2}. \quad (29)$$

Tabelle 2 zeigt die VIF-Werte für ausgewählte Korrelationen.

Tabelle 2: VIF-Werte in Abhängigkeit von der Korrelation ρ bei zwei Prädiktoren.

Korrelation ρ	ρ^2	$1 - \rho^2$	$\text{VIF} = (1 - \rho^2)^{-1}$
0.00	0.000	1.000	1.00
0.30	0.090	0.910	1.10
0.50	0.250	0.750	1.33
0.70	0.490	0.510	1.96
0.80	0.640	0.360	2.78
0.90	0.810	0.190	5.26
0.95	0.903	0.098	10.26
0.99	0.980	0.020	50.25
0.999	0.998	0.002	500.25

8.4 Interpretation der VIF-Werte

Die VIF-Skala lässt sich in drei diagnostisch relevante Bereiche einteilen, die in der Literatur und in der Praxis weitgehend konsensfähig sind:

VIF-Klassifikationsschema		
VIF-Bereich	Bewertung	Handlungsempfehlung
$1 \leq \text{VIF} < 5$	Niedrig (akzeptabel)	Keine Multikollinearität. Koeffizienten sind stabil und zuverlässig interpretierbar.
$5 \leq \text{VIF} < 10$	Moderat (beachtenswert)	Moderate Multikollinearität vorhanden. Sorgfältige Modelldiagnose empfohlen.
$\text{VIF} \geq 10$	Hoch (problematisch)	Schwere Multikollinearität. Maßnahmen zur Reduktion dringend erforderlich.




Abbildung 8: Visuelle Klassifikationsskala des Varianzinflationsfaktors. Werte unterhalb von 5 gelten als unkritisch; ab 10 liegt schwere Multikollinearität vor, die dringende Gegenmaßnahmen erfordert.

8.4.1 Niedriger VIF: $VIF < 5$

Ein VIF unter 5 signalisiert, dass der j -te Prädiktor höchstens 80 % seiner Varianz durch die übrigen Prädiktoren erklärt wird ($R_j^2 < 0.8$). Die Koeffizienten sind in diesem Bereich:

- **Stabil:** Kleine Änderungen im Datensatz führen zu keinen dramatischen Koeffizientenverschiebungen.
- **Interpretierbar:** Die Log-Odds-Interpretation (vgl. Gl. (4)) bleibt gültig und inhaltlich bedeutsam.
- **Inferenz zuverlässig:** Wald-Tests, Likelihood-Ratio-Tests und Konfidenzintervalle haben ihre nominale Deckungswahrscheinlichkeit.

8.4.2 Moderater VIF: $5 \leq VIF < 10$

Im moderaten Bereich besteht eine spürbare, aber noch handhabbare Multikollinearität. Der entsprechende R_j^2 -Wert liegt zwischen 0.8 und 0.9. Die Konsequenzen sind:

- **Erhöhte Standardfehler:** Die Standardfehler der Koeffizienten sind um den Faktor $\sqrt{VIF_j}$ vergrößert – also um das 2.2- bis 3.2-fache gegenüber dem unkorrelierten Fall.
- **Breitere Konfidenzintervalle:** Entsprechend sind auch 95 %-Konfidenzintervalle substanziell breiter, was die statistische Power von Tests reduziert.
- **Vorhersagequalität unbeeinträchtigt:** Das Modell kann dennoch gute Vorhersagen liefern – das Problem liegt primär in der Koeffizienteninterpretation.

In diesem Bereich ist eine sorgfältige Einzelfallabwägung erforderlich: Falls Interpretierbarkeit der Koeffizienten primäres Ziel ist, sind Gegenmaßnahmen angezeigt; bei rein prädiktiven Modellen kann der moderate VIF toleriert werden.

8.4.3 Hohe Multikollinearität: $VIF \geq 10$

Ab einem VIF von 10 liegt $R_j^2 \geq 0.9$ vor: Der j -te Prädiktor ist zu mindestens 90 % durch die übrigen Prädiktoren linear erklärbar. Die Folgen sind gravierend:

Theorem 8.9 (Instabilität bei hohem VIF). *Sei $VIF_j \geq 10$ für einen Prädiktor x_j . Dann ist die Konditionszahl*

$$\kappa(\mathbf{X}^\top \mathbf{X}) = \frac{\lambda_{\max}(\mathbf{X}^\top \mathbf{X})}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X})}$$

mindestens 10, sodass das lineare System $(\mathbf{X}^\top \mathbf{X})\hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{y}$ numerisch schlecht konditioniert ist. Insbesondere impliziert ein Fehler $\delta \mathbf{y}$ in den Beobachtungen einen relativen Fehler

$$\frac{\|\delta \hat{\mathbf{w}}\|}{\|\hat{\mathbf{w}}\|} \leq \kappa(\mathbf{X}^\top \mathbf{X}) \cdot \frac{\|\delta \mathbf{y}\|}{\|\mathbf{y}\|}$$

im Koeffizientenschätzer, der durch VIF_j nach unten beschränkt ist.

Proof. Teil 1: Untere Schranke für die Konditionszahl.

Sei $\mathbf{B} := (\mathbf{X}^\top \mathbf{X})^{-1} \in \mathbb{R}^{d \times d}$ positiv definit mit Eigenwerten $\mu_1 \geq \mu_2 \geq \dots \geq \mu_d > 0$. Es gelten die Beziehungen $\mu_k = 1/\lambda_{d+1-k}$ zwischen den Eigenwerten von $\mathbf{B}$ und denen von $\mathbf{X}^\top \mathbf{X}$, insbesondere $\mu_1 = 1/\lambda_{\min}(\mathbf{X}^\top \mathbf{X})$ und $\mu_d = 1/\lambda_{\max}(\mathbf{X}^\top \mathbf{X})$.

Schranke für $\lambda_{\min}(\mathbf{X}^\top \mathbf{X})$: Nach dem Courant-Fischer-Min-Max-Theorem gilt für jeden Einheitsvektor $\mathbf{u}$:

$$\lambda_{\max}(\mathbf{B}) = \max_{\|\mathbf{u}\|=1} \mathbf{u}^\top \mathbf{B} \mathbf{u} \geq \mathbf{e}_j^\top \mathbf{B} \mathbf{e}_j = [\mathbf{B}]_{jj} = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj},$$

wobei $\mathbf{e}_j \in \mathbb{R}^d$ der j -te Standardbasisvektor ist. Da $\lambda_{\max}(\mathbf{B}) = 1/\lambda_{\min}(\mathbf{X}^\top \mathbf{X})$, folgt:

$$\frac{1}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X})} \geq [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj} = \frac{\text{VIF}_j}{\|\mathbf{x}_j\|_2^2}, \quad (30)$$

nach Theorem 8.4. Umstellen liefert:

$$\lambda_{\min}(\mathbf{X}^\top \mathbf{X}) \leq \frac{\|\mathbf{x}_j\|_2^2}{\text{VIF}_j}.$$

Schranke für $\lambda_{\max}(\mathbf{X}^\top \mathbf{X})$: Analog liefert das Min-Max-Theorem eine untere Schranke:

$$\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) = \max_{\|\mathbf{u}\|=1} \mathbf{u}^\top (\mathbf{X}^\top \mathbf{X}) \mathbf{u} \geq \mathbf{e}_j^\top (\mathbf{X}^\top \mathbf{X}) \mathbf{e}_j = \|\mathbf{X} \mathbf{e}_j\|_2^2 = \|\mathbf{x}_j\|_2^2,$$

da $\mathbf{X} \mathbf{e}_j$ gerade die j -te Spalte von $\mathbf{X}$ extrahiert, nämlich $\mathbf{x}_j \in \mathbb{R}^n$.

Kombination: Aus den beiden Schranken ergibt sich:

$$\kappa(\mathbf{X}^\top \mathbf{X}) = \frac{\lambda_{\max}(\mathbf{X}^\top \mathbf{X})}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X})} \geq \frac{\|\mathbf{x}_j\|_2^2}{\|\mathbf{x}_j\|_2^2 / \text{VIF}_j} = \text{VIF}_j.$$

Falls $\text{VIF}_j \geq 10$, gilt also $\kappa(\mathbf{X}^\top \mathbf{X}) \geq 10$, womit das lineare System $(\mathbf{X}^\top \mathbf{X})\hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{y}$ nach Standardkriterien als numerisch schlecht konditioniert gilt.

Teil 2: Fehlerfortpflanzungsabschätzung.

Sei $\mathbf{y}$ um $\delta \mathbf{y} \in \mathbb{R}^n$ gestört. Das normale Gleichungssystem $(\mathbf{X}^\top \mathbf{X})\hat{\mathbf{w}} = \mathbf{X}^\top \mathbf{y}$ geht über in $(\mathbf{X}^\top \mathbf{X})(\hat{\mathbf{w}} + \delta \hat{\mathbf{w}}) = \mathbf{X}^\top (\mathbf{y} + \delta \mathbf{y})$, woraus unmittelbar $(\mathbf{X}^\top \mathbf{X}) \delta \hat{\mathbf{w}} = \mathbf{X}^\top \delta \mathbf{y}$ folgt. Die Lösung ist $\delta \hat{\mathbf{w}} = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \delta \mathbf{y}$, und die Norm des Fehlers wird nach oben abgeschätzt durch:

$$\|\delta \hat{\mathbf{w}}\|_2 \leq \|(\mathbf{X}^\top \mathbf{X})^{-1}\|_2 \cdot \|\mathbf{X}^\top\|_2 \cdot \|\delta \mathbf{y}\|_2 = \frac{1}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X})} \cdot \sigma_{\max}(\mathbf{X}) \cdot \|\delta \mathbf{y}\|_2,$$

wobei $\sigma_{\max}(\mathbf{X}) = \sqrt{\lambda_{\max}(\mathbf{X}^\top \mathbf{X})}$ der maximale Singulärwert von $\mathbf{X}$ ist. Für die Norm der Lösung gilt analog:

$$\|\hat{\mathbf{w}}\|_2 = \|(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{y}\|_2 \geq \frac{\|\mathbf{X}^\top \mathbf{y}\|_2}{\lambda_{\max}(\mathbf{X}^\top \mathbf{X}) / \lambda_{\max}(\mathbf{X}^\top \mathbf{X})} \cdot \frac{1}{\lambda_{\max}(\mathbf{X}^\top \mathbf{X})} \cdot \lambda_{\min}(\mathbf{X}^\top \mathbf{X}) \|\mathbf{y}\|_2 \cdot \frac{1}{\sigma_{\max}(\mathbf{X})}.$$

Kombiniert ergibt sich durch die Standardtheorie konditionierter linearer Systeme (vgl. Trefethen & Bau ?):

$$\frac{\|\delta \hat{\mathbf{w}}\|_2}{\|\hat{\mathbf{w}}\|_2} \leq \underbrace{\frac{\lambda_{\max}(\mathbf{X}^\top \mathbf{X})}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X})}}_{=\kappa(\mathbf{X}^\top \mathbf{X})} \cdot \frac{\|\delta \mathbf{y}\|_2}{\|\mathbf{y}\|_2} \leq \kappa(\mathbf{X}^\top \mathbf{X}) \cdot \frac{\|\delta \mathbf{y}\|_2}{\|\mathbf{y}\|_2}.$$

Da $\kappa(\mathbf{X}^\top \mathbf{X}) \geq \text{VIF}_j$ nach Teil 1, ist der relative Koeffizientenfehler durch VIF_j nach unten beschränkt – auch das geringe Messfehler in $\mathbf{y}$ werden um mindestens den Faktor VIF_j verstärkt. $\square$

Praktische Symptome hoher Multikollinearität ($\text{VIF} \geq 10$) sind:

- (i) Koeffizientenschätzer mit unerwartetem Vorzeichen (z.B. negativer Koeffizient für einen inhaltlich positiv wirksamen Prädiktor).
- (ii) Hohe Sensitivität gegenüber kleinen Stichprobenveränderungen – das Hinzufügen oder Entfernen weniger Beobachtungen kann Koeffizienten dramatisch verändern.
- (iii) Statistische Tests werden insignifikant, obwohl inhaltlich ein starker Zusammenhang vermutet wird (“Scheininsignifikanz” durch aufgeblähte Standardfehler).
- (iv) Iterative Optimierungsverfahren (Gradient Descent, IRLS) konvergieren langsam oder benötigen sehr kleine Lernraten.

8.5 VIF bei der logistischen Regression

Obwohl der VIF ursprünglich für die lineare Regression entwickelt wurde, ist er bei der logistischen Regression ebenso anwendbar und interpretierbar. Dies gründet auf folgender Parallelstruktur:

Proposition 8.10 (Hesse-Matrix der logistischen Regression und VIF). *Die Hesse-Matrix der logistischen Kreuzentropie (vgl. Gl. (10)) ist $\nabla^2 \mathcal{L} = \frac{1}{n} \mathbf{X}^\top \mathbf{S} \mathbf{X}$ mit $\mathbf{S} = \text{diag}(s_1, \dots, s_n)$, $s_i = \hat{p}_i(1 - \hat{p}_i)$. Die effektive Fisher-Informationsmatrix lautet $\mathcal{I}(\mathbf{w}) = \mathbf{X}^\top \mathbf{S} \mathbf{X}$, und die asymptotische Kovarianzmatrix des MLE ist:*

$$\text{Cov}(\hat{\mathbf{w}}) \approx (\mathbf{X}^\top \mathbf{S} \mathbf{X})^{-1}. \quad (31)$$

Der gewichtete VIF für die logistische Regression ist:

$$\text{VIF}_j^{\log} = \frac{1}{1 - R_j^{2,S}}, \quad (32)$$

wobei $R_j^{2,S}$ das gewichtete Bestimmtheitsmaß der Hilfsregression von $\mathbf{x}_j$ auf $\mathbf{X}_{-j}$ mit Gewichtsmatrix $\mathbf{S}$ bezeichnet.

Bemerkung 8.11 (Praktische Approximation). In der Praxis wird für die logistische Regression häufig der standard (ungewichtete) VIF aus Definition 8.3 berechnet, da die Gewichte $s_i = \hat{p}_i(1 - \hat{p}_i)$ vom Modell selbst abhängen. Die ungewichtete Approximation ist in den meisten Fällen ausreichend und bleibt das Standardvorgehen in Statistiksoftware (R: `car::vif()`; Python: `statsmodels.stats.outliers_influence.variance_inflation_factor()`).

8.6 Beziehungen zwischen VIF und anderen Diagnosemaßen

Proposition 8.12 (VIF und Toleranz). *Das Toleranzmaß ist das Reziproke des VIF:*

$$\text{TOL}_j = \frac{1}{\text{VIF}_j} = 1 - R_j^2 \in (0, 1]. \quad (33)$$

Es gibt direkt den Anteil der Varianz von $\mathbf{x}_j$ an, der nicht durch die anderen Prädiktoren erklärt wird. Ein Toleranzwert nahe 0 entspricht starker Multikollinearität, ein Wert nahe 1 vollständiger Unkorreliertheit.

Proposition 8.13 (Zusammenhang mit dem Konditionsindex). *Sei $\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_d > 0$ die Eigenwerte der standardisierten Gramschen Matrix $\frac{1}{n}\mathbf{X}^\top \mathbf{X}$. Der Konditionsindex ist:*

$$\kappa_k = \sqrt{\frac{\lambda_1}{\lambda_k}}, \quad k = 1, \dots, d.$$

Konditionsindizes $\kappa_k > 30$ deuten auf starke Multikollinearität hin. Während VIF und Konditionsindizes komplementäre Informationen liefern, sind VIF-Werte prädiktorspezifisch und daher für gezielte Diagnose vorzuziehen.

8.7 Strategien zur Reduktion der Multikollinearität

Wenn der VIF-Test problematische Werte offenbart, stehen folgende Gegenmaßnahmen zur Verfügung:

8.7.1 Entfernung korrelierter Prädiktoren

Die direkteste Maßnahme ist das Entfernen eines der korrelierten Prädiktoren. Die Wahl, welcher Prädiktor entfernt wird, sollte sich an inhaltlichen Kriterien (theoretische Relevanz) und statistischen Kriterien (geringerer VIF des verbleibenden Prädiktors) orientieren.

Algorithm 4 Iterative VIF-basierte Variablenselektion

Require: Designmatrix $\mathbf{X}$, Schwellwert $\tau > 0$ (typisch $\tau = 5$ oder $\tau = 10$)

Ensure: Reduzierte Merkmalsmenge ohne problematische Multikollinearität

- 1: Berechne alle VIF_j via Algorithmus 3
 - 2: **while** $\max_j \text{VIF}_j > \tau$ **do**
 - 3: $j^* \leftarrow \arg \max_j \text{VIF}_j$
 - 4: Entferne Spalte j^* aus $\mathbf{X}$
 - 5: Aktualisiere alle VIF-Werte für das reduzierte $\mathbf{X}$
 - 6: **end while**
 - 7: **return** aktuelles $\mathbf{X}$
-




Abbildung 9: Workflow zur VIF-basierten Multikollinearitätsdiagnose in der logistischen Regression. Nach der Diagnose können Gegenmaßnahmen ergriffen und das Modell neu angepasst werden.

8.7.2 Kombination korrelierter Prädiktoren

Anstatt Prädiktoren zu verwerfen, können stark korrelierte Variablen zu einem einzigen Prädiktor zusammengefasst werden – etwa durch gewichtete Mittelwertbildung oder durch einen inhaltlich begründeten Index:

$$x_{\text{kombi}} = \frac{x_j + x_k}{2} \quad \text{oder} \quad x_{\text{kombi}} = \alpha x_j + (1 - \alpha)x_k, \quad \alpha \in [0, 1].$$

8.7.3 Hauptkomponentenanalyse (PCA)

Proposition 8.14 (PCA-basierte Dekorrelation). *Sei $\mathbf{X} = \mathbf{U}\Sigma\mathbf{V}^\top$ die Singulärwertzerlegung der standardisierten Designmatrix. Die Hauptkomponenten sind $\mathbf{Z} = \mathbf{X}\mathbf{V}$, wobei $\mathbf{Z}^\top\mathbf{Z} = \Sigma^2$ eine Diagonalmatrix ist. Da die Spalten von $\mathbf{Z}$ unkorreliert sind, gilt:*

$$\text{VIF}_k^{\text{PCA}} = 1 \quad \forall k = 1, \dots, d.$$

Die logistische Regression auf Hauptkomponenten (PCLR) ist definiert als logistische Regression von $\mathbf{y}$ auf die $m \leq d$ führenden Hauptkomponenten $\mathbf{Z}_m = \mathbf{X}\mathbf{V}_m$:

$$\mathbb{P}(Y = 1 \mid \mathbf{z}_m) = \sigma(\beta^\top \mathbf{z}_m + b). \quad (34)$$

Bemerkung 8.15 (Abwägung: Interpretierbarkeit vs. Multikollinearität). PCA löst das Multikollinearitätsproblem vollständig, erkaufte dies aber mit dem Verlust der direkten Interpretierbarkeit der Koeffizienten: Die β_k in (34) beziehen sich auf latente Linearkombinationen der Originalmerkmale, nicht auf diese selbst. In Bereichen wie der klinischen Medizin, wo Koeffizienteninterpretierbarkeit entscheidend ist, kann dies problematisch sein.

8.7.4 Ridge-Regularisierung als VIF-Reduktionsmethode

Theorem 8.16 (Ridge-Regression und VIF). *Die Ridge-Regularisierung mit Strafterm $\lambda\|\mathbf{w}\|_2^2$ ersetzt die Informationsmatrix $\mathbf{X}^\top\mathbf{X}$ durch die regularisierte Matrix $(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})$. Der analoge effektive VIF erfüllt für alle $\lambda > 0$:*

$$\text{VIF}_j^{\text{Ridge}}(\lambda) \leq \text{VIF}_j(\lambda = 0) = \text{VIF}_j. \quad (35)$$

Für $\lambda \rightarrow \infty$ gilt $\text{VIF}_j^{\text{Ridge}}(\lambda) \rightarrow 1$ für alle j .

Proof. Schritt 1: Spektralzerlegung und explizite Inverse. Da $\mathbf{X}^\top\mathbf{X} \in \mathbb{R}^{d \times d}$ positiv definit und symmetrisch ist, existiert eine Eigenzerlegung $\mathbf{X}^\top\mathbf{X} = \mathbf{V}\Lambda\mathbf{V}^\top$ mit orthogonaler Matrix $\mathbf{V} = [\mathbf{v}_1 \mid \dots \mid \mathbf{v}_d]$ und Diagonalmatrix $\Lambda = \text{diag}(\lambda_1, \dots, \lambda_d)$, $\lambda_1 \geq \dots \geq \lambda_d > 0$.

Da $(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I}) = \mathbf{V}(\Lambda + \lambda\mathbf{I})\mathbf{V}^\top$, folgt mit $\mathbf{V}^\top\mathbf{V} = \mathbf{I}$:

$$(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1} = \mathbf{V}(\Lambda + \lambda\mathbf{I})^{-1}\mathbf{V}^\top = \mathbf{V} \text{diag}\left(\frac{1}{\lambda_1 + \lambda}, \dots, \frac{1}{\lambda_d + \lambda}\right) \mathbf{V}^\top. \quad (36)$$

Diese Darstellung ist wohldefiniert für alle $\lambda > 0$, da $\lambda_k + \lambda > 0$.

Schritt 2: Expliziter Diagonaleintrag der Ridge-Inversen. Sei $v_{kj} = [\mathbf{V}]_{jk}$ die j -te Komponente des k -ten Eigenvektors. Aus der Spektraldarstellung (36) folgt:

$$[(\mathbf{X}^\top\mathbf{X} + \lambda\mathbf{I})^{-1}]_{jj} = \mathbf{e}_j^\top \mathbf{V} \text{diag}\left(\frac{1}{\lambda_k + \lambda}\right) \mathbf{V}^\top \mathbf{e}_j = \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k + \lambda}.$$

Analog gilt für $\lambda = 0$:

$$[(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj} = \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k}.$$

Schritt 3: Strenge Monotonie in λ . Da $v_{kj}^2 \geq 0$ und $\sum_k v_{kj}^2 = \|\mathbf{V}^\top \mathbf{e}_j\|_2^2 = 1$ (Norm einer Matrixspalte der orthogonalen Matrix $\mathbf{V}$), gilt für alle $\lambda > 0$ und für jeden Summanden:

$$\frac{v_{kj}^2}{\lambda_k + \lambda} < \frac{v_{kj}^2}{\lambda_k}.$$

Summation über $k = 1, \dots, d$ liefert:

$$[(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}]_{jj} = \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k + \lambda} < \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k} = [(\mathbf{X}^\top \mathbf{X})^{-1}]_{jj}.$$

Schritt 4: Übergang zum effektiven VIF. Definiert man den effektiven VIF der Ridge-Regression in Analogie zu Theorem 8.4 durch $\text{VIF}_j^{\text{Ridge}}(\lambda) := \|\mathbf{x}_j\|_2^2 \cdot [(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})^{-1}]_{jj}$, so folgt aus Schritt 3 direkt:

$$\text{VIF}_j^{\text{Ridge}}(\lambda) = \|\mathbf{x}_j\|_2^2 \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k + \lambda} < \|\mathbf{x}_j\|_2^2 \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k} = \text{VIF}_j(\lambda = 0) = \text{VIF}_j,$$

was Ungleichung (35) beweist.

Schritt 5: Grenzwert für $\lambda \rightarrow \infty$. Die Konditionszahl der regularisierten Matrix ist

$$\kappa(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) = \frac{\lambda_{\max}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})}{\lambda_{\min}(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I})} = \frac{\lambda_1 + \lambda}{\lambda_d + \lambda}.$$

Diese ist streng monoton fallend in $\lambda > 0$, denn:

$$\frac{d}{d\lambda} \frac{\lambda_1 + \lambda}{\lambda_d + \lambda} = \frac{(\lambda_d + \lambda) - (\lambda_1 + \lambda)}{(\lambda_d + \lambda)^2} = \frac{\lambda_d - \lambda_1}{(\lambda_d + \lambda)^2} < 0,$$

da $\lambda_1 > \lambda_d$ (strenges Ungleich bei $d \geq 2$ und vollrangigem $\mathbf{X}$). Für $\lambda \rightarrow \infty$ gilt:

$$\kappa(\mathbf{X}^\top \mathbf{X} + \lambda \mathbf{I}) = \frac{\lambda_1 + \lambda}{\lambda_d + \lambda} = \frac{\lambda_1/\lambda + 1}{\lambda_d/\lambda + 1} \xrightarrow{\lambda \rightarrow \infty} 1.$$

Da mit $\kappa \rightarrow 1$ die Designmatrix effektiv orthogonal wird, gilt in diesem Grenzfall $\text{VIF}_j^{\text{Ridge}}(\lambda) \rightarrow 1$ für alle j . Formal:

$$\text{VIF}_j^{\text{Ridge}}(\lambda) = \|\mathbf{x}_j\|_2^2 \sum_{k=1}^d \frac{v_{kj}^2}{\lambda_k + \lambda} \xrightarrow{\lambda \rightarrow \infty} \|\mathbf{x}_j\|_2^2 \sum_{k=1}^d \frac{v_{kj}^2}{\lambda} = \frac{\|\mathbf{x}_j\|_2^2}{\lambda} \rightarrow 0,$$

d. h. die Ridge-Regularisierung unterdrückt asymptotisch jeglichen Varianzinflationseffekt. $\square$

Dies zeigt, dass die L2-Regularisierung aus Abschnitt 7 nicht nur Overfitting reduziert, sondern gleichzeitig Multikollinearität dämpft – ein doppelter Nutzen, der die Ridge-Regularisierung besonders für Datensätze mit korrelierten Merkmalen attraktiv macht.

8.8 Formale Bedeutung des VIF für die Modellgüte

Theorem 8.17 (VIF und Breite des Konfidenzintervalls). *Sei $\hat{w}_j$ der MLE des j -ten Koeffizienten der logistischen Regression mit asymptotischer Standardabweichung $\hat{\sigma}_j = \sqrt{[\mathcal{I}(\hat{\mathbf{w}})^{-1}]_{jj}}$. Das asymptotische 95%-Wald-Konfidenzintervall hat die Breite:*

$$\Delta_j = 2 \cdot z_{0.975} \cdot \hat{\sigma}_j \propto \sqrt{\text{VIF}_j}. \quad (37)$$

Ein VIF von 10 vergrößert die Breite des Konfidenzintervalls um den Faktor $\sqrt{10} \approx 3.16$ gegenüber dem unkorrelierten Fall.

Proof. **Schritt 1: Asymptotische Normalität des MLE.** Unter Regularitätsbedingungen ist der MLE $\hat{\mathbf{w}}$ der logistischen Regression asymptotisch normalverteilt:

$$\sqrt{n}(\hat{\mathbf{w}} - \mathbf{w}^*) \xrightarrow{d} \mathcal{N}(\mathbf{0}, \mathcal{I}(\mathbf{w}^*)^{-1}),$$

wobei $\mathcal{I}(\mathbf{w}^*) = \mathbf{X}^\top \mathbf{S}(\mathbf{w}^*) \mathbf{X}$ die Fisher-Informationsmatrix am wahren Parameter ist und $\mathbf{S}(\mathbf{w}^*) = \text{diag}(p_i^*(1 - p_i^*))$ die Diagonalmatrix der Bernoulli-Varianzen. Insbesondere konvergiert die marginale Verteilung des j -ten Koeffizienten:

$$\frac{\hat{w}_j - w_j^*}{\hat{\sigma}_j} \xrightarrow{d} \mathcal{N}(0, 1), \quad \hat{\sigma}_j^2 = [\mathcal{I}(\hat{\mathbf{w}})^{-1}]_{jj},$$

wobei $\hat{\sigma}_j^2$ die geschätzte asymptotische Varianz ist.

Schritt 2: Proportionalität $\hat{\sigma}_j^2 \propto \text{VIF}_j$. Für die logistische Regression definieren wir den gewichteten Varianzinflationsfaktor durch $\text{VIF}_j^{\log} = 1/(1 - R_j^{2,S})$, wobei $R_j^{2,S}$ das gewichtete Bestimmtheitsmaß der Hilfsregression von $\mathbf{x}_j$ auf $\mathbf{X}_{-j}$ mit Gewichtsmatrix $\mathbf{S} = \text{diag}(s_i)$, $s_i = \hat{p}_i(1 - \hat{p}_i)$, bezeichnet.

In Analogie zu Theorem 8.4, angewendet auf die gewichtete Gramsche Schritt-für-Schritt auf $\tilde{\mathbf{X}} := \mathbf{S}^{1/2} \mathbf{X}$ (wobei $\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}} = \mathbf{X}^\top \mathbf{S} \mathbf{X} = \mathcal{I}(\hat{\mathbf{w}})$):

$$[\mathcal{I}(\hat{\mathbf{w}})^{-1}]_{jj} = [(\tilde{\mathbf{X}}^\top \tilde{\mathbf{X}})^{-1}]_{jj} = \frac{\text{VIF}_j^{\log}}{\|\tilde{\mathbf{x}}_j\|_2^2} = \frac{\text{VIF}_j^{\log}}{\|\mathbf{S}^{1/2} \mathbf{x}_j\|_2^2},$$

wobei $\tilde{\mathbf{x}}_j = \mathbf{S}^{1/2} \mathbf{x}_j$ die gewichtete j -te Spalte ist und der letzte Schritt Theorem 8.4 auf die gewichtete Designmatrix $\tilde{\mathbf{X}}$ anwendet. Damit gilt:

$$\hat{\sigma}_j^2 = [\mathcal{I}(\hat{\mathbf{w}})^{-1}]_{jj} = \frac{\text{VIF}_j^{\log}}{\sum_{i=1}^n \hat{p}_i(1 - \hat{p}_i) x_{ij}^2}. \quad (38)$$

Im Gegensatz zum OLS-Fall hängt der Nenner von den Schätzwerten $\hat{p}_i$ ab. Die Proportionalität $\hat{\sigma}_j \propto \sqrt{\text{VIF}_j^{\log}}$ gilt mithin exakt, wenn der Nenner als bekannte Konstante behandelt wird.

Schritt 3: Vergleich zweier Modelle (mit/ohne Multikollinearität). Um den Faktor zu quantifizieren, vergleichen wir zwei Szenarien:

- *Baseline (kein Kollinearitätsproblem):* $\text{VIF}_j^{(0)} = 1$, also $\hat{\sigma}_j^{(0)} = 1/\sqrt{\sum_i s_i x_{ij}^2}$.
- *Kollineares Szenario:* $\text{VIF}_j = t \geq 1$, also $\hat{\sigma}_j = \sqrt{t} \cdot \hat{\sigma}_j^{(0)}$.

Das Wald-Konfidenzintervall zum Niveau $1 - \alpha = 0.95$ ist

$$\text{CI}_j = [\hat{w}_j - z_{1-\alpha/2} \hat{\sigma}_j, \hat{w}_j + z_{1-\alpha/2} \hat{\sigma}_j],$$

mit Breite $\Delta_j = 2z_{0.975} \hat{\sigma}_j$. Der Verhältnis der Breiten beträgt:

$$\frac{\Delta_j}{\Delta_j^{(0)}} = \frac{\hat{\sigma}_j}{\hat{\sigma}_j^{(0)}} = \sqrt{\text{VIF}_j}.$$

Für $\text{VIF}_j = 10$ ergibt sich der Faktor $\sqrt{10} \approx 3.16$, d. h. das Konfidenzintervall ist mehr als dreimal so breit wie ohne Multikollinearität.

Schritt 4: Numerische Verifikation. Für $\text{VIF}_j \in \{1, 2, 5, 10, 25\}$ ergeben sich die Faktoren:

$$\sqrt{1} = 1.00, \quad \sqrt{2} \approx 1.41, \quad \sqrt{5} \approx 2.24, \quad \sqrt{10} \approx 3.16, \quad \sqrt{25} = 5.00.$$

Selbst ein vermeintlich “moderater” VIF von 5 verbreitet das Konfidenzintervall bereits um einen Faktor von $\sqrt{5} \approx 2.24$, was die statistische Nachweisbarkeit des Effekts erheblich reduziert. $\square$

Korollar 8.18 (VIF und statistische Power). *Für den Wald-Test $H_0 : w_j = 0$ gegen $H_1 : w_j \neq 0$ ist die Teststatistik $Z_j = \hat{w}_j / \hat{\sigma}_j$. Die Power des Tests nimmt mit steigendem VIF_j ab, da $\hat{\sigma}_j \propto \sqrt{\text{VIF}_j}$. Konkret muss die wahre Effektgröße $|w_j|$ um den Faktor $\sqrt{\text{VIF}_j}$ größer sein, um bei gleicher Power nachgewiesen werden zu können.*

8.9 Zusammenfassendes Beispiel: VIF-Diagnose in einer medizinischen Studie

Beispiel 8.19 (Klinische Multikollinearität: Body-Mass-Index und Körpergewicht). In einer klinischen Studie zur Vorhersage von Typ-2-Diabetes ($Y = 1$: Diabetes) werden folgende Prädiktoren erhoben: Körpergröße x_1 (cm), Körpergewicht x_2 (kg), Body-Mass-Index $x_3 = x_2/x_1^2 \times 10^4$ (kg/m²), Alter x_4 (Jahre), Blutdruck x_5 (mmHg), Nüchtern glukose x_6 (mg/dL).

Da x_3 eine nichtlineare Funktion von x_1 und x_2 ist, besteht starke Multikollinearität zwischen diesen drei Variablen. Typische VIF-Werte in diesem Szenario:

Prädiktor	VIF	Bewertung
x_1 : Größe (cm)	8.73	Moderat
x_2 : Gewicht (kg)	12.41	Hoch
x_3 : BMI (kg/m ²)	15.82	Hoch
x_4 : Alter (Jahre)	1.12	Niedrig
x_5 : Blutdruck (mmHg)	1.34	Niedrig
x_6 : Glukose (mg/dL)	1.08	Niedrig

Empfehlung: Da BMI definitorisch von Größe und Gewicht abhängt, sollte entweder der BMI allein (als klinisch etablierte Zusammenfassung) oder Größe und Gewicht getrennt (ohne BMI) in das Modell aufgenommen werden. Die Aufnahme aller drei Variablen simultan führt zu den beobachteten hohen VIF-Werten und macht die Koeffizienten inhaltlich nicht interpretierbar – ein typisches Beispiel für konstruktionsbedingte Multikollinearität.

Kernaussagen: VIF und Multikollinearität

1. **Was misst der VIF:** Den Faktor, um den die Varianz eines Regressionskoeffizienten gegenüber dem unkorrelierten Fall aufgeblasen ist – mathematisch präzise durch $VIF_j = 1/(1 - R_j^2)$.
2. **Berechnungsweg:** Für jeden Prädiktor x_j : OLS-Hilfsregression auf alle anderen Prädiktoren, Bestimmung von R_j^2 , Anwendung der VIF-Formel.
3. **Klassifikation:** $VIF < 5$ akzeptabel; $5 \leq VIF < 10$ moderat; $VIF \geq 10$ problematisch und handlungsbedürftig.
4. **Relevanz für logistische Regression:** VIF ist direkt auf die logistische Regression übertragbar, da die Designmatrixstruktur identisch ist und die Fisher-Informationsmatrix dieselbe Invertierungsproblematik bei Multikollinearität aufweist.
5. **Gegenmaßnahmen:** Entfernung redundanter Prädiktoren, Kombination, PCA-basierte Dekorrelation oder Ridge-Regularisierung – letztere reduziert VIF und Overfitting gleichzeitig (vgl. Theorem 8.16).
6. **Warum es wichtig ist:** Hohe VIF-Werte untergraben Koeffizienteninterpretierbarkeit, statistische Tests und Modellstabilität – drei zentrale Gütekriterien, gerade in regulierten Anwendungsgebieten wie Medizin und Finanzwesen.

9 Multinomiale Logistische Regression (Softmax)

9.1 Erweiterung auf K Klassen

Definition 9.1 (Softmax-Funktion). Für Klassifikator-Scores $\mathbf{z} = (z_1, \dots, z_K)^\top \in \mathbb{R}^K$ ist die Softmax-Funktion:

$$\text{softmax}(\mathbf{z})_k = \frac{e^{z_k}}{\sum_{j=1}^K e^{z_j}}, \quad k = 1, \dots, K. \quad (39)$$

Proposition 9.2 (Eigenschaften der Softmax-Funktion). (i) $\text{softmax}(\mathbf{z})_k \in (0, 1)$ und $\sum_k \text{softmax}(\mathbf{z})_k = 1$.

(ii) *Translationsinvarianz:* $\text{softmax}(\mathbf{z} + c\mathbf{1}) = \text{softmax}(\mathbf{z})$.

(iii) *Jacobi-Matrix:* $J_{kj} = \hat{p}_k(\delta_{kj} - \hat{p}_j)$, wobei δ_{kj} das Kronecker-Delta ist.

(iv) *Verbindung zu Sigmoid:* Für $K = 2$ mit $z_2 = 0$ gilt $\text{softmax}(z_1, 0)_1 = \sigma(z_1)$.

Proof. (iii): Sei $S = \sum_j e^{z_j}$. Dann $\hat{p}_k = e^{z_k}/S$.

$$\frac{\partial \hat{p}_k}{\partial z_j} = \frac{\delta_{kj} e^{z_k} S - e^{z_k} e^{z_j}}{S^2} = \hat{p}_k(\delta_{kj} - \hat{p}_j). \quad \square$$

□




Abbildung 10: Links: Einfluss der Softmax-Temperatur auf die Entscheidungsschärfe. Rechts: Softmax-Wahrscheinlichkeit als Funktion zweier linearer Prädiktoren.

9.2 Kategorische Kreuzentropie

$$\mathcal{L}_K = -\frac{1}{n} \sum_{i=1}^n \sum_{k=1}^K \mathbf{1}[y^{(i)} = k] \ln \hat{p}_k(\mathbf{x}^{(i)}). \quad (40)$$

Theorem 9.3 (Konvexität der kategorischen Kreuzentropie). $\mathcal{L}_K$ ist konvex in allen Parametern $\{(\mathbf{w}_k, b_k)\}_{k=1}^K$.

Proof. Die Hesse-Matrix bzgl. der Parameter der Klasse k hat die gleiche Struktur wie im binären Fall. Da Summen konvexer Funktionen konvex sind und die Softmax-Funktion log-konkav ist, folgt die Konvexität aus denselben Argumenten wie in Theorem 4.3. $\square$

10 Evaluationsmasze und Modellbewertung

10.1 Konfusionsmatrix und abgeleitete Metriken

Tabelle 3: Konfusionsmatrix und abgeleitete Metriken für binäre Klassifikation.

		Prädizierte Klasse	
		Positiv ($\hat{y} = 1$)	Negativ ($\hat{y} = 0$)
Wahre Klasse	Positiv ($y = 1$)	TP	FN
	Negativ ($y = 0$)	FP	TN

Abgeleitete Metriken:

$$\text{Accuracy} = \frac{\text{TP} + \text{TN}}{n}, \quad \text{Precision} = \frac{\text{TP}}{\text{TP} + \text{FP}}, \quad (41)$$

$$\text{Recall} = \frac{\text{TP}}{\text{TP} + \text{FN}}, \quad F_\beta = (1 + \beta^2) \cdot \frac{\text{Prec} \cdot \text{Rec}}{\beta^2 \cdot \text{Prec} + \text{Rec}}. \quad (42)$$

10.2 ROC-Kurve, AUC und Precision-Recall




Abbildung 11: ROC-Kurven (links) und Precision-Recall-Kurven (rechts) im Modellvergleich. Logistische Regression erreicht vergleichbare Leistung zu komplexeren Methoden.

Proposition 10.1 (Probabilistische Interpretation des AUC). *Der AUC entspricht der Wahrscheinlichkeit, dass ein zufällig gewähltes positives Beispiel einen höheren Vorhersage-Score erhält als ein zufällig gewähltes negatives:*

$$\text{AUC} = \mathbb{P}(\hat{p}(X^+) > \hat{p}(X^-)),$$

wobei $X^+ \sim P(\cdot | Y = 1)$ und $X^- \sim P(\cdot | Y = 0)$ unabhängig sind.

10.3 Kalibrierung von Wahrscheinlichkeiten




Abbildung 12: Reliability Diagram: Logistische Regression ist typischerweise besser kalibriert als Random Forests (die zur Überkonfidenz neigen).

11 Verbindungen zu anderen Methoden

11.1 Logistische Regression als flaches neuronales Netz

Ein neuronales Netz mit einer einzigen Schicht und Sigmoid-Ausgabe ist strukturell identisch mit der logistischen Regression:

$$\hat{p} = \sigma(\mathbf{w}^\top \mathbf{x} + b).$$

Tiefe Netze entstehen durch Verkettung mehrerer solcher Schichten mit nichtlinearen Aktivierungen. Das Ausgabelayer eines K -Klassen-Klassifikators ist stets eine Softmax-Schicht – eine multinomiale logistische Regression.

11.2 Verhältnis zu Support Vector Machines

Proposition 11.1 (Verlustfunktionsvergleich: LR vs. SVM). *Seien $y^{(i)} \in \{-1, +1\}$ (SVM-Kodierung). Dann ist:*

$$\text{Log. Reg.: } \ell_{\text{LR}}(y, z) = \ln(1 + e^{-yz}), \quad (43)$$

$$\text{SVM: } \ell_{\text{SVM}}(y, z) = \max(0, 1 - yz). \quad (44)$$

Beide sind obere Schranken des 0-1-Verlustes. Die Kreuzentropie ist differenzierbar überall und berücksichtigt alle Punkte, während die SVM nur Stützvektoren in der Nähe der Grenze verwendet.

11.3 Naive Bayes als generatives Gegenstück

Proposition 11.2 (Äquivalenz unter Gauss-Annahme). *Sei $P(\mathbf{x}|Y = k) = \mathcal{N}(\mu_k, \Sigma)$ für $k \in \{0, 1\}$ mit gleicher Kovarianzmatrix Σ . Dann stimmt der Naive-Bayes-Klassifikator mit gleichen Vorwahrswahrscheinlichkeiten asymptotisch mit der logistischen Regression überein, mit Gewichten:*

$$\mathbf{w} = \Sigma^{-1}(\mu_1 - \mu_0), \quad b = -\frac{1}{2}(\mu_1 + \mu_0)^\top \Sigma^{-1}(\mu_1 - \mu_0).$$

12 Numerische Experimente

12.1 Konvexe Verlustlandschaft




Abbildung 13: Links: Alle Eigenwerte der Hesse-Matrix sind nichtnegativ, was Konvexität beweist. Rechts: 2D-Schnitt der Verlustlandschaft zeigt die typische konvexe Schüssel.

12.2 Polynomial Feature Maps




Abbildung 14: Logistische Regression mit polynomialen Feature Maps. Höhere Grade ermöglichen nichtlineare Entscheidungsgrenzen – auf Kosten der Interpretierbarkeit.

12.3 Klinische Anwendung: Risikomodellierung




Abbildung 15: Anwendungsbeispiel: kardiovaskuales Risiko. Links: Koeffizienten der logistischen Regression für Alter, BMI, Cholesterin und Raucherstatus. Mitte: Verteilung der Risikoschätzungen nach Klasse. Rechts: Kalibrierungsdiagramm.

12.4 Bayesianische Posteriorunsicherheit




Abbildung 16: Links: Posteriori-Dichte des Gewichts w mit MAP-Schätzer und 95%-Kredibilitätsintervall. Rechts: Vorhersageunsicherheit durch Posterior-Sampling (90%-Band).

13 Ausblick

Der folgende Abschnitt entwickelt eine umfassende Zukunftsperspektive auf die logistische Regression und verwandte Methoden in Forschung, Industrie und Wissenschaft. Das Jahr 2025 markiert einen Wendepunkt: Die Verfügbarkeit grosser Sprachmodelle, die Verbreitung von Federated-Learning-Infrastruktur, der gesellschaftliche Druck nach erklärbarer KI und die Entstehung quantenresistenter und quantengestützter Lernmethoden eröffnen völlig neue Perspektiven auch für ein klassisches Verfahren wie die logistische Regression.

13.1 Federated Learning und datenschutzerhaltende Klassifikation

13.1.1 Konzept und Herausforderungen

Federated Learning (FL), eingeführt durch Google 2017 [McMahan et al., 2017], ist ein verteiltes Trainingsparadigma, bei dem Modelle lokal auf den Geräten der Nutzer trainiert werden und nur Gradientenaktualisierungen – niemals rohe Daten – an einen zentralen Server übertragen werden. Die logistische Regression ist hierfür ein natürliches erstes Modell:

Algorithm 5 FedAvg für logistische Regression

Require: K Klienten mit lokalen Datensätzen $\mathcal{D}_k$, globales Modell $\mathbf{w}^{(0)}$

```

1: for Runde  $t = 1, 2, \dots$  do
2:   Sende  $\mathbf{w}^{(t-1)}$  an alle Klienten
3:   for Klient  $k = 1, \dots, K$  (parallel) do
4:      $\mathbf{w}_k \leftarrow \mathbf{w}^{(t-1)} - \eta \nabla_{\mathbf{w}} \mathcal{L}_k(\mathbf{w}^{(t-1)})$  (lokale SGD-Schritte)
5:     Sende  $\Delta_k = \mathbf{w}_k - \mathbf{w}^{(t-1)}$  an Server
6:   end for
7:    $\mathbf{w}^{(t)} \leftarrow \mathbf{w}^{(t-1)} + \frac{1}{K} \sum_k \Delta_k$ 
8: end for
  
```




Abbildung 17: Konvergenzverhalten logistischer Regression unter Federated Learning mit verschiedener Klientenanzahl und unter Differenzieller Privatheit ($\epsilon = 1$). Federated Learning konvergiert langsamer, bleibt aber datenschutzkonform.

13.1.2 Differentielle Privatheit

Differentielle Privatheit (DP), eingeführt von Dwork et al. [Dwork et al., 2006], bietet mathematische Garantien für den Datenschutz im maschinellen Lernen. Ein Algorithmus $\mathcal{A}$ ist (ϵ, δ) -differenziell privat, wenn für alle Datensätze $\mathcal{D}, \mathcal{D}'$, die sich in genau einem Eintrag unterscheiden, gilt:

$$\mathbb{P}[\mathcal{A}(\mathcal{D}) \in S] \leq e^\epsilon \mathbb{P}[\mathcal{A}(\mathcal{D}') \in S] + \delta \quad \text{für alle messbaren } S. \quad (45)$$

Für die logistische Regression wird Privatheit durch den *Gaussian-Mechanismus* erreicht: Zum Gradienten wird Rauschen $\mathbf{n} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ addiert, wobei $\sigma \geq C \sqrt{2 \ln(1.25/\delta)}/\varepsilon$ und C die ℓ_2 -Sensitivität des Gradienten bezeichnet.

Theorem 13.1 (Privatheit des DP-SGD). *Sei der DP-SGD-Algorithmus mit Clipping-Norm C , Rausch-Standardabweichung σ , Batch-Grösse m und T Iterationen angewandt. Dann ist der Algorithmus (ε, δ) -DP mit $\varepsilon = O\left(\frac{q \sqrt{T \ln(1/\delta)}}{\sigma}\right)$, wobei $q = m/n$ die Samplingrate ist.*

13.1.3 Anwendungen 2025

In der medizinischen Diagnostik erlaubt Federated Learning, Klassifikatoren über Krankenhausdaten zu trainieren, ohne Patientendaten die Instituts Grenzen überschreiten zu lassen. Das MELLODDY- Projekt der Europäischen Union trainiert Modelle über Pharmaunternehmen hinweg, ohne proprietäre Moleküldaten offenzulegen. Im Bereich mobiler Endgeräte wird Federated Logistic Regression eingesetzt, um Spam-Klassifikatoren direkt auf Smartphones zu optimieren (Google Gboard).

13.2 Bayes'sche Logistische Regression und Unsicherheitsquantifizierung

13.2.1 Posteriori-Verteilung und Laplace-Approximation

In der Bayes'schen Formulierung werden die Parameter $\mathbf{w}$ als Zufallsvariablen behandelt. Die Posteriori-Verteilung ergibt sich nach dem Satz von Bayes:

$$p(\mathbf{w} \mid \mathcal{D}) \propto L(\mathbf{w}) \cdot p(\mathbf{w}), \quad (46)$$

mit Prior $p(\mathbf{w}) = \mathcal{N}(\mathbf{0}, \lambda^{-1} \mathbf{I})$. Da die Posteriori analytisch nicht zugänglich ist, werden Approximationsverfahren eingesetzt:

- **Laplace-Approximation:** Approximation der Posteriori durch eine Gauss-Verteilung zentriert am MAP-Schätzer mit Kovarianzmatrix gleich der negativen inversen Hesse-Matrix.
- **Variationelle Bayes (VI):** Minimierung der KL-Divergenz zwischen der wahren Posteriori und einer faktorisierten Approximation $q(\mathbf{w}) = \prod_j q_j(w_j)$.
- **Markov-Chain-Monte-Carlo (MCMC):** Stichprobenziehung aus der exakten Posteriori via Hamilton Monte Carlo (HMC) oder No-U-Turn-Sampler (NUTS).

13.2.2 Prädiktive Unsicherheit

Die prädiktive Unsicherheit wird durch Marginalisierung über die Posteriori ausgedrückt:

$$\mathbb{P}(Y = 1 \mid \mathbf{x}, \mathcal{D}) = \int \sigma(\mathbf{w}^\top \mathbf{x} + b) p(\mathbf{w} \mid \mathcal{D}) d\mathbf{w}. \quad (47)$$

Dieses Integral ist analytisch nicht lösbar, kann aber durch Monte-Carlo-Integration approximiert werden:

$$\mathbb{P}(Y = 1 \mid \mathbf{x}, \mathcal{D}) \approx \frac{1}{S} \sum_{s=1}^S \sigma(\mathbf{w}^{(s)\top} \mathbf{x} + b^{(s)}), \quad \mathbf{w}^{(s)} \sim p(\mathbf{w} \mid \mathcal{D}).$$

13.2.3 Bedeutung für Hochrisiköntscheidungen

Prädiktive Unsicherheit ist in Hochrisikodomänen unverzichtbar: Ein medizinisches Entscheidungssystem muss nicht nur eine Vorhersage liefern, sondern auch die Konfidenz dieser Vorhersage quantifizieren. Bayesianische Modelle liefern natürliche Kreditibilitätsintervalle für individuelle Vorhersagen – ein entscheidender Vorteil gegenüber frequentistischen Ansätzen.

13.3 Erklärbare Künstliche Intelligenz (XAI) und logistische Regression

13.3.1 Intrinsische Interpretierbarkeit

Die logistische Regression ist das Paradebeispiel eines intrinsisch interpretierbaren Modells: Die Koeffizienten w_j haben eine direkte semantische Bedeutung als log-lineare Odds-Ratios. Dies unterscheidet sie fundamental von Blackbox-Methoden wie Deep Neural Networks.

Interpretierbarkeitsgarantie

Für die logistische Regression gilt: Der Beitrag des Merkmals x_j zur Vorhersage ist additiv und proportional zu $w_j x_j$. Dies ermöglicht eine vollständige, modellgetreue Erklärung jeder Einzelvorhersage – ohne Approximation.

13.3.2 SHAP-Werte und logistische Regression

SHAP (SHapley Additive exPlanations) [Lundberg and Lee, 2017] zerlegt Vorhersagen in additive Beiträge einzelner Merkmale. Für lineare Modelle fallen SHAP-Werte mit den einfachen Gewichtungs-Erklärungen zusammen:

$$\phi_j = w_j(x_j - \mathbb{E}[X_j]), \quad (48)$$

was die logistische Regression zu einem perfekten Grundmodell für XAI-Verfahren macht. Im Jahr 2025 wird explizit diskutiert, inwiefern regulatorische Anforderungen (EU AI Act, Artikel 13) automatisch Interpretierbarkeit des Modelltyps im Hochrisiko-Bereich erfordern – wobei logistische Regression als Goldstandard gilt.

13.3.3 Kausale Inferenz

Die Integration logistischer Regression in kausale Modelle (Structural Causal Models nach Pearl [Pearl, 2009]) ist ein aktives Forschungsfeld. Das *do-kalkül* erlaubt es, kausale Effekte aus observationalen Daten zu identifizieren, wenn ein kausales Diagramm bekannt ist. Die logistische Regression dient dabei als *Outcome-Modell* in doppelt robusten Schätzern für kausale Behandlungseffekte.

13.4 Hochdimensionale Statistik und maschinelles Lernen

13.4.1 Hochdimensionales Regime: $d \gg n$

In Genomik, Proteomik und neuronaler Bildgebung überschreitet die Merkmalsdimension d die Stichprobenzahl n häufig um Größenordnungen. Das klassische MLE-Verfahren versagt in diesem Regime – die Hesse-Matrix ist singulär und der Schätzer nicht eindeutig. Dies motiviert:

- **LASSO-Logit** ($p > n$ Regime): Konsistente Variablenselektion unter sogenannten *Restricted Eigenvalue Conditions* [Bickel et al., 2009].
- **Ridge-Logit**: Konsistente Schätzung auch für $d \rightarrow \infty$ bei angemessener Regularisierungsstärke $\lambda_2 = \Theta(\sqrt{d/n})$.
- **Group Lasso**: Simultane Selektion von Merkmalgruppen (z.B. One-Hot-kodierte kategoriale Variablen).

13.4.2 Doppelt robuste Schätzung

Theorem 13.2 (Doppelte Robustheit). *Sei $\hat{e}(\mathbf{x})$ ein Schätzer der Behandlungsneigung (propensity score) und $\hat{\mu}_k(\mathbf{x})$ ein Schätzer der bedingten Erwartung des Outcomes. Der doppelt robuste Schätzer für den durchschnittlichen Behandlungseffekt (ATE) ist:*

$$\hat{\Delta}_{\text{DR}} = \frac{1}{n} \sum_{i=1}^n \left[\frac{A_i(Y_i - \hat{\mu}_1(\mathbf{x}^{(i)}))}{\hat{e}(\mathbf{x}^{(i)})} - \frac{(1 - A_i)(Y_i - \hat{\mu}_0(\mathbf{x}^{(i)}))}{1 - \hat{e}(\mathbf{x}^{(i)})} + \hat{\mu}_1(\mathbf{x}^{(i)}) - \hat{\mu}_0(\mathbf{x}^{(i)}) \right].$$

Dieser Schätzer ist konsistent, wenn entweder $\hat{e}$ oder $\hat{\mu}$ konsistent ist (aber nicht notwendigerweise beide). Logistische Regression wird regelmässig für $\hat{e}$ eingesetzt.

13.5 Logistische Regression in der Präzisionsmedizin

13.5.1 Polygene Risikoscores

Polygene Risikoscores (PRS) aggregieren die Effekte tausender genetischer Varianten auf ein Krankheitsrisiko. In ihrer linearen Grundform sind PRS direkte Anwendungen der logistischen Regression auf Genomdaten:

$$\mathbb{P}(\text{Erkrankung} \mid \mathbf{g}) = \sigma\left(\sum_{j=1}^M \beta_j g_j + b\right), \quad (49)$$

wobei $\mathbf{g} = (g_1, \dots, g_M)^\top$ der Vektor der SNP-Allelzahlen und β_j die gewichteten Effektgrößen aus GWAS-Studien sind. Im Jahr 2025 werden PRS für über 500 Erkrankungen berechnet und in klinische Entscheidungssysteme integriert.

13.5.2 Arzneimittelinteraktionen und elektronische Krankenakten

Maschinelles Lernen auf elektronischen Krankenakten (EHR) ist ein Schlüssel-Anwendungsfeld. Logistische Regression dient dabei als:

- (i) Prognosemodell für Krankenhauswiederaufnahmen innerhalb von 30 Tagen,

- (ii) Vorhersagemodell für arzneimittelinduzierte Nebenwirkungen,
- (iii) Früherkennung intensivmedizinischer Verschlechterungen (Frühwarnsysteme).

Aktuelle Forschung (2024–2025) fokussiert auf *time-varying* logistische Regressionsmodelle, die zeitliche Verlaufsveränderungen von Laborparametern modellieren können.

13.6 Klimawissenschaft und Umweltmonitoring

13.6.1 Extremwettererkennung

Logistische Regression wird in der Klimaforschung eingesetzt, um die Wahrscheinlichkeit klimatischer Extremereignisse (Hitzewellen, Überschwemmungen, Dürre) als Funktion atmosphärischer Zustandsvariablen zu modellieren. Das Verfahren ist hier besonders attraktiv, weil:

- Die Koeffizienten physikalisch interpretierbar sind (z.B. Einfluss des Meeresoberflächen-temperaturgradienten auf Zyklonintensität),
- Bayes'sche Erweiterungen natürliche Unsicherheitsquantifizierung bieten,
- Regularisierung Overfitting verhindert, wenn historische Extremereignisse selten sind.

13.6.2 Satellitengestützte Fernerkundung

Logistische Regression und ihre multinomialen Erweiterungen werden zur Klassifikation von Landbedeckungstypen aus hochauflösenden Satellitenbildern eingesetzt. In Kombination mit convolutional feature extractors (CNN-LR-Hybride) erzielen sie Genauigkeiten über 95% bei der Unterscheidung von Wald, Acker, Siedlung und Wasserfläche.

13.7 Finanzmarkt und Kreditrisikomodellierung

13.7.1 Basel III/IV und regulatorische Anforderungen

Der Basler Ausschuss für Bankenaufsicht (Basel IV, Implementierung 2025) verlangt explizit interpretierbare und validierbare Kreditrisikomodelle. Logistische Regression ist daher das gesetzlich bevorzugte Verfahren für Probability-of-Default (PD)-Modelle in der internen Ratingbasierten Methode (IRBA).

Ein Standard-PD-Modell hat die Form:

$$PD(i) = \sigma(\beta_0 + \beta_1 \cdot LGR_i + \beta_2 \cdot DAR_i + \beta_3 \cdot ICR_i + \beta_4 \cdot \ln \text{Umsatz}_i), \quad (50)$$

wobei LGR = Loan-to-GrossRevenü, DAR = Debt-Asset-Ratio und ICR = Interest-Coverage-Ratio.

13.7.2 Echtzeit-Betrugserkennungssysteme

In Hochfrequenz-Zahlungsnetzwerken (Visa, Mastercard) werden logistische Regressionsmodelle eingesetzt, die pro Millisekunde mehrere tausend Transaktionen klassifizieren müssen. Die Linearität des Prädiktors macht Inferenz extrem schnell ($O(d)$ Floating-Point-Operationen), was bei Deep-Learning-Alternativen nicht erreichbar ist. Für 2025 wird

häufig ein zweistufiges Ensemble eingesetzt: logistische Regression als Schnell-Filter, gefolgt von einem komplexeren Modell für Grenzfälle.

13.8 Natursprachverarbeitung und Large Language Models

13.8.1 Softmax als universelles Ausgabelayer

Jeder moderne Sprachmodell-Klassifikator (GPT, BERT, Llama) verwendet eine multinomiale logistische Regression als Ausgabelayer. Die Verbindung ist direkt:

$$P(\text{token} = k \mid \text{Kontext}) = \frac{e^{\mathbf{h}^\top \mathbf{w}_k}}{\sum_{j=1}^{|V|} e^{\mathbf{h}^\top \mathbf{w}_j}}, \quad (51)$$

wobei $\mathbf{h} \in \mathbb{R}^{d_{\text{model}}}$ die Kontextrepräsentation und V das Vokabular bezeichnen. Das Training dieser letzten Softmax-Schicht ist exakt das multinomiale logistische Regressionsoptimierungsproblem.

13.8.2 Classifier-Free Guidance und Temperaturskalierung

Das im Jahr 2022 eingeführte *Classifier-Free Guidance* für Diffusionsmodelle basiert auf einem impliziten logistischen Regressionsmodell zwischen konditionierten und unkonditionierten Vorhersagen. Die Temperaturskalierung von Softmax-Ausgaben (Abschnitt 8) wird in Modellen wie Claude, GPT-4o und Gemini zur Steuerung der Ausgabediversität verwendet.

13.8.3 Probing-Klassifikatoren

Probing-Klassifikatoren sind lineare (logistische) Regressionsmodelle, die auf den internen Repräsentationen von LLMs trainiert werden, um zu untersuchen, welche linguistischen Eigenschaften (Tempus, Numerus, Syntaxrollen) in verschiedenen Schichten kodiert sind. Die Interpretierbarkeit der logistischen Regression macht sie zum bevorzugten Werkzeug für diese mechanistische Interpretierbarkeitsforschung.

13.9 Robotik, autonomes Fahren und Echtzeitsysteme

13.9.1 Wahrnehmungsklassifikation mit Echtzeitanforderungen

In sicherheitskritischen autonomen Systemen (Fahrzeuge nach ISO 26262 ASIL-D) müssen Klassifikationsentscheidungen in Mikrosekunden getroffen und auditert werden. Logistische Regression bietet:

- Deterministische Inferenz in $O(d)$ Zeit,
- Formale Verifikation durch vollständige Modell-Transparenz,
- Integration in Model-Based Design (AUTOSAR, Simulink),
- Explizite Wahrscheinlichkeitsausgabe für Risikobewertung.

13.9.2 Probabilistische Zustandsschätzung

In der Robotik werden logistische Regressionsmodelle als *Beobachtungsmodelle* in Partikelfiltern und Bayes'schen Filtern eingesetzt: Die Wahrscheinlichkeit einer Sensorbeobachtung gegeben einem Systemzustand wird durch logistische Regression geschätzt.

13.10 Quantenmaschinelles Lernen

13.10.1 Quantenlogistische Regression

Quantencomputer bieten theoretische Speedups für bestimmte lineare-algebraische Operationen. Der HHL-Algorithmus [Harrow et al., 2009] löst lineare Gleichungssysteme in $O(\log n)$ Zeit (gegenüber $O(n^3)$ klassisch), was – wenn auf die Newton-Iteration angewendet – eine exponentielle Beschleunigung der logistischen Regression ermöglicht.

Konkrete Varianten der Quantenlogistischen Regression werden im Rahmen von *variational quantum eigensolvers* (VQE) und *quantum support vector machines* (QSVM) untersucht. Einschränkungen bestehen durch:

- Quantum-Dekohärenz und NISQ-Beschränkungen (2025: ~ 1000 qubits),
- Aufwand für Quantenzustandspräparation (Ladezeit der Daten),
- Noise und Fehlerkorrektur.

13.10.2 Post-Quantum-Sicherheit für ML-Inferenz

Sicherheitsaspekte sind ein weiteres Forschungsfeld: Wie können logistische Regressionsmodelle so geschützt werden, dass Angreifer mit Quantencomputern keine Rückschlüsse auf Trainingsdaten ziehen können? Homomorphe Verschlüsselung (z.B. SEAL, OpenFHE) erlaubt Inferenz auf verschlüsselten Eingabedaten, ohne den Klartext zu offenbaren.

13.11 Mathematische Ausblicke und offene Forschungsfragen

13.11.1 Statistische Lerntheorie

Theorem 13.3 (Generalisierungsfehler-Schranke für logistische Regression). *Sei $\mathcal{F} = \{\mathbf{x} \mapsto \sigma(\mathbf{w}^\top \mathbf{x} + b) : \|\mathbf{w}\|_2 \leq B\}$. Mit Wahrscheinlichkeit mindestens $1 - \delta$ gilt für den wahren Risikoschätzer:*

$$R(f) \leq \hat{R}(f) + \frac{2B\|\mathbf{x}\|_{\max}}{\sqrt{n}} + 3\sqrt{\frac{\ln(2/\delta)}{2n}}, \quad (52)$$

wobei $\hat{R}(f)$ das empirische Risiko und $\|\mathbf{x}\|_{\max} = \max_i \|\mathbf{x}^{(i)}\|_2$ bezeichnet.

Proof. Die Schranke folgt aus der Rademacher-Komplexität der logistischen Funktionenklasse $\mathcal{F}$ kombiniert mit McDiarmids Ungleichung. Die Rademacher-Komplexität von $\mathcal{F}$ ist beschränkt durch $B\|\mathbf{x}\|_{\max}/\sqrt{n}$ (Massart-Lemma). $\square$

13.11.2 Implizite Regularisierung durch Gradientenabstieg

Ein tiefes Ergebnis der jüngsten Forschung (2018–2025) ist, dass Gradientenabstieg für logistische Regression auf linear separierbaren Daten *implizit regularisiert*: Er konvergiert gegen den maximalen-Margin-Klassifikator (identisch zur harten SVM):

Theorem 13.4 (Implizite Regularisierung nach Soudry et al. [Soudry et al., 2018]). Sei der Datensatz linear separierbar. Dann gilt für den Gradientenabstieg-Pfad:

$$\frac{\mathbf{w}^{(t)}}{\|\mathbf{w}^{(t)}\|_2} \xrightarrow{t \rightarrow \infty} \mathbf{w}_{\text{SVM}}^*,$$

wobei $\mathbf{w}_{\text{SVM}}^*$ der L_2 -maximale-Margin-Klassifikator ist.

Dies erklärt, warum unregularisierte logistische Regression auf separierbaren Daten oft gute Generalisierung zeigt – sie findet implizit die robusteste lineare Entscheidungsgrenze.

13.11.3 Neuronale Skalierungsgesetze und logistische Ausgabebayer

Die Skalierungsgesetze von Kaplan et al. [Kaplan et al., 2020] beschreiben, wie die Testperformance von Sprachmodellen mit Modellgröße, Datenmenge und Rechenaufwand skaliert. Da das Ausgabebayer jedes Sprachmodells eine logistische (Softmax-)Schicht ist, sind diese Gesetze direkt relevant: Die Kreuzentropie des Softmax-Ausgabebayers folgt $\mathcal{L}(N, D) \propto N^{-\alpha} + D^{-\beta} + \text{konst.}$

13.11.4 Kontinuierliche und online logistische Regression

Online-Lernalgorithmen aktualisieren logistische Regressionsmodelle mit jedem neuen Datenpunkt inkrementell. Wichtige Varianten sind:

- **Online Newton Step (ONS):** Nutzt die kumulierte Hesse-Matrix und erzielt Regret $O(\sqrt{T \ln T})$.
- **FTRL (Follow-The-Regularized-Leader):** Wird von Google im Werbeauktions-system eingesetzt; skaliert auf Milliarden Merkmale.
- **Recursive Bayes Update:** Inkrementelle Aktualisierung der Posteriori nach Laplace-Approximation ohne komplette Neuoptimierung.

13.12 Industrie-Anwendungsfelder 2025: Panorama

Tabelle 4: Anwendungsfelder der logistischen Regression in Industrie und Wissenschaft 2025.

Branche/Feld	Anwendung	Besonderheit
Medizin	Diagnostische Klassifikation	Interpretierbarkeit (FDA-Anforderungen)
Medizin	Polygene Risikoscores	$d \gg n$, L1-Regularisierung
Finanzwesen	Kreditscoring (PD)	Basel-IV-Konformität, Fairness
Finanzwesen	Betrugserkennung	Echtzeit ($< 1\text{ms}$), Erklärbarkeit
NLP / LLM	Softmax-Ausgabebayer	$K = 100.000+$ Klassen
NLP / LLM	Probing-Klassifikatoren	Mechanistische Interpretierbarkeit
Autonomes Fahren	Gefahrenklassifikation	ISO 26262, formale Verifikation
Genomik	Genotyp-Phänotyp-Assoz.	GWAS-Meta-Analysen
Klimawissenschaft	Extremwetter-Vorhersage	Physikalische Interpretierbarkeit
Pharmakologie	Nebenwirkungsprädiktion	FDA Drug Safety Reporting
E-Commerce	Click-Through-Rate (CTR)	Online-Learning, FTRL
Industrie 4.0	Qualitätskontrolle	Eingebettete Systeme, AUTOSAR

13.13 Ethische Dimensionen: Fairness, Diskriminierungsfreiheit und Transparenz

13.13.1 Algorithmische Fairness

Logistische Regressionsmodelle können diskriminierende Entscheidungen aus voreingenommenen Trainingsdaten lernen. Formale Fairness-Kriterien sind u.a.:

- **Demografische Parität:** $\mathbb{P}(\hat{Y} = 1|A = 0) = \mathbb{P}(\hat{Y} = 1|A = 1)$, wobei A ein schutzwürdiges Attribut (z.B. Geschlecht, Ethnizität) ist.
- **Equal Opportunity (Hardt et al.):** Gleiche Trü-Positive-Raten zwischen Gruppen.
- **Kalibrierungspaarität:** Gleiche Kalibrierung der Wahrscheinlichkeiten über Gruppen.

Fairness-bewusste logistische Regression löst ein Optimierungsproblem mit Fairness-Nebenbedingungen:

$$\min_{\mathbf{w}} \mathcal{L}(\mathbf{w}) \quad \text{s.t.} \quad |\mathbb{P}(\hat{Y} = 1|A = 0) - \mathbb{P}(\hat{Y} = 1|A = 1)| \leq \epsilon_{\text{fair}}. \quad (53)$$

13.13.2 EU AI Act (2025) und Modelldokumentation

Der im August 2024 in Kraft getretene EU AI Act klassifiziert Kreditscoring-, Personalmanagement- und medizinische Klassifikationssysteme als Hochrisiko-KI-Anwendungen (Anhang III). Für diese gilt:

- Dokumentationspflicht für Modellarchitektur, Trainingsverfahren und Datengrundlage,
- Post-Deployment-Monitoring und regelmässige Validierung,
- Recht auf Erklärung für betroffene Individuen,
- Konformitätsbewertung durch benannte Stellen.

Die logistische Regression ist hier als Modellklasse besonders gut positioniert, da ihre vollständige Erklärbarkeit (Formel (4)) eine modellgetreue Erklärung jeder Entscheidung ermöglicht – ohne Nacherklärungsverfahren wie LIME oder SHAP.

13.14 Forschungslücken und offene Probleme (Stand 2025)

- F1. Skalengesetze für logistische Regression:** Wie verhält sich die Generalisierung logistischer Regressionsmodelle, die auf Merkmalen vortrainierter Netze (Foundation Models) operieren, in Abhängigkeit von der Grösse des Grundmodells?
- F2. Online-Fairness:** Wie können Fairness-Garantien in inkrementellen Lernprozessen (z.B. FTRL) aufrechterhalten werden, wenn sich die Datenverteilung zeitlich verschiebt (concept drift)?
- F3. Quantenvorteil bei logistischer Regression:** Unter welchen Bedingungen ermöglicht Quantencomputing einen praktischen Speedup für logistische Regression bei realen Datensätzen? Die Abhängigkeit von Quantenzustandspräparation schränkt derzeit den theoretischen Speedup ein.

- F4. Kausalität und Intervenierbarkeit:** Wann sind Koeffizienten logistischer Regressionsmodelle als kausale Effektgrößen interpretierbar? Welche Annahmen sind notwendig und überprüfbar?
- F5. Robustheit gegenüber adversarialen Angriffen:** Logistische Regression ist anfällig für adversariale Perturbationen. Formale Robustheitszertifikate (certified defenses) für logistische Regressionsmodelle in sicherheitskritischen Systemen sind ein offenes Problem.
- F6. Federated Learning unter Heterogenität:** Wie konvergiert FedAvg für logistische Regression unter stark heterogenen (non-i.i.d.) Klientenverteilungen? Neüere Ergebnisse (FedProx, Scaffold, MOON) zeigen Verbesserungen, aber vollständige theoretische Garantien fehlen noch.

14 Zusammenfassung

Die vorliegende Arbeit hat die logistische Regression in ihrer ganzen mathematischen Tiefe und praktischen Relevanz beleuchtet. Folgende Kernergebnisse wurden entwickelt:

- (i) **Mathematische Fundierung:** Die logistische Regression ist der kanonische GLM für binäre Daten, fest verankert in der Theorie der Exponentialfamilien.
- (ii) **Konvexität:** Die binäre und kategoriale Kreuzentropie sind konvex, was globale Konvergenzgarantien für Gradientenverfahren liefert.
- (iii) **Reiche Optimierungslandschaft:** Von einfachem Gradientenabstieg über Newton-IRLS bis zu L-BFGS und Adam existiert eine Hierarchie effizienter Verfahren.
- (iv) **Interpretierbarkeit:** Koeffizienten sind log-lineare Odds-Ratios mit direkter kausaler Interpretierbarkeit – ein unverzichtbares Merkmal in regulierten Branchen.
- (v) **Weitreichende Zukunftsperspektiven:** Federated Learning, differentielle Privatheit, Bayes'sche Erweiterungen, Quantencomputing, erklärbare KI und Präzisionsmedizin definieren neü Anwendungsfelder, in denen logistische Regression als interpretierbare, effiziente Kernmethode weiterhin eine Schlüsselrolle spielen wird.

Die logistische Regression ist kein Relikt der statistischen Vergangenheit, sondern ein lebendiges, sich weiterentwickelndes Werkzeug an den Grenzen von Mathematik, Informatik, Medizin und Gesellschaft. Die elegante Verbindung zwischen linearer Algebra, Wahrscheinlichkeitstheorie und konvexer Optimierung macht sie zum idealen Ausgangspunkt für das Verständnis modernsten maschinellen Lernens – und zu einem unverzichtbaren Bestandteil jedes wissenschaftlichen und industriellen Data-Science-Werkzeugkastens.

Literatur

- Amari, S. (2016). *Information Geometry and Its Applications*. Springer, Tokyo.
- Bickel, P. J., Ritov, Y., and Tsybakov, A. B. (2009). Simultaneous analysis of Lasso and Dantzig selector. *Annals of Statistics*, 37(4):1705–1732.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning*. Springer, New York.

- Cox, D. R. (1958). The regression analysis of binary sequences. *Journal of the Royal Statistical Society: Series B*, 20(2):215–242.
- Dwork, C., McSherry, F., Nissim, K., and Smith, A. (2006). Calibrating noise to sensitivity in private data analysis. *Theory of Cryptography*, LNCS 3876:265–284.
- Goodfellow, I., Bengio, Y., and Courville, A. (2016). *Deep Learning*. MIT Press, Cambridge, MA.
- Harrow, A. W., Hassidim, A., and Lloyd, S. (2009). Quantum algorithm for linear systems of equations. *Physical Review Letters*, 103(15):150502.
- Hastie, T., Tibshirani, R., and Friedman, J. (2009). *The Elements of Statistical Learning*, 2nd ed. Springer, New York.
- Kaplan, J. et al. (2020). Scaling laws for neural language models. *arXiv:2001.08361*.
- Lundberg, S. M. and Lee, S.-I. (2017). A unified approach to interpreting model predictions. *NeurIPS*, 30.
- McCullagh, P. and Nelder, J. A. (1989). *Generalized Linear Models*, 2nd ed. Chapman and Hall, London.
- McMahan, B., Moore, E., Ramage, D., Hampson, S., and Agüra y Arcas, B. (2017). Communication-efficient learning of deep networks from decentralized data. *AISTATS 2017*, 54:1273–1282.
- Murphy, K. P. (2022). *Probabilistic Machine Learning: An Introduction*. MIT Press, Cambridge, MA.
- Pearl, J. (2009). *Causality: Models, Reasoning, and Inference*, 2nd ed. Cambridge University Press.
- Soudry, D., Hoffer, E., Nacson, M. S., Gunasekar, S., and Srebro, N. (2018). The implicit bias of gradient descent on separable data. *Journal of Machine Learning Research*, 19(70):1–57.
- Tibshirani, R. (1996). Regression shrinkage and selection via the lasso. *Journal of the Royal Statistical Society: Series B*, 58(1):267–288.
- Verhulst, P.-F. (1845). Recherches mathématiques sur la loi d’accroissement de la population. *Nouveaux Memoires de l’Academie Royale des Sciences*, 18:1–38.