

Minimale Graphrestrukturierung in nahezu ausgelernten neuronalen Netzwerken

Formale Analyse des Kapazitätsgewinns durch gezielte
Kanten- und Knotenumverknüpfung in neuronalen Netzwerken

Stephan Epp

21. März 2026

Inhaltsverzeichnis

1	Einleitung	2
1.1	Motivation und Problemstellung	2
1.2	Intuition und Graphperspektive	3
1.3	Beiträge der Arbeit	3
2	Mathematisches Modell	4
2.1	Neuronales Netzwerk als gewichteter gerichteter Graph	4
2.2	Nahezu ausgelertes Netzwerk	4
2.3	Minimale Graphrestrukturierung	5
3	Spektraltheoretische Analyse	6
4	Kapazitätstheoretische Analyse	9
4.1	Hypothesenraumgeometrie	9
4.2	Rademacher-Komplexität	10
5	Skalierungsanalyse: Optimales Verhältnis von Kantenanzahl und Aussagekraft	12
5.1	Aussagekraft als Zielfunktion	12
5.2	Kritische Netzgröße und Zwei-Regionen-Analyse	12
5.3	Absoluter Kantenbedarf in Abhängigkeit der Architektur	13
5.4	Formaler Wenige-Kanten-Rahmen mit Budgetgarantie	14
6	Strukturelle Subgraph-Kompression tiefer neuronaler Netzwerke	17
6.1	Strukturelle Redundanz in trainierten neuronalen Netzwerken	17
6.2	Subgraph Algorithmus auf neuronalen Schichtgraphen	18
6.3	Kanonische Motif-Signaturen und Rotationsäquivalenz	19
6.4	Kanonische Reduktion auf gemeinsame Struktur	20
6.5	Informationsfluss-Routing nach der Reduktion	22
6.6	Iterativer SGKR-Algorithmus	25
6.7	Formale Schranken: Expressivität und Energieeffizienz	27
6.8	Verbindung zur minimalen Kantenrestrukturierung	30
7	Informationstheoretische Analyse	32
7.1	Shannon-Entropie der Aktivierungsverteilung	32
7.2	Gegenseitige Information	32

8	Folgeanalysen der minimalen Restrukturierung	35
8.1	Katastrophales Vergessen und Transfer-Effizienz	35
8.2	Erweiterung der Entscheidungsgrenze	36
8.3	Gewichtsverteilungen und tote Neuronen	37
8.4	Lernkurven und experimentelle Evidenz	39
9	Algorithmus zur optimalen minimalen Restrukturierung	41
9.1	Algorithmische Grundbausteine	41
9.2	Algorithmus: Vollständige Formulierung	43
9.3	Laufzeitanalyse	44
9.4	Korrektheitsanalyse	47
9.5	Optimalitätseigenschaft: Greedy-Näherung des globalen Optimums	49
9.6	Garantien des OMGR-Algorithmus	51
10	Bioinspirierte Grundprinzipien neuronaler Netzwerke: Minimalität, Verknüpfbarkeit und ionische Verschaltung	52
10.1	Die drei-stufige Hierarchie: Bereiche, Zellen, Knoten und Kanten	52
10.2	Grundsatz 1: Minimalität, Eindeutigkeit und Vergleichbarkeit	54
10.3	Grundsatz 2: Verknüpfbarkeit durch Knoten und Kanten	57
10.4	Grundsatz 3: Ionische Verschaltung mit zustandsabhängiger Leitfähigkeit	59
10.5	Der Dreiklang: Integration der Grundprinzipien mit dem Subgraph Algorithmus	66
11	Energetische Implikationen minimierter neuronaler Netze	69
11.1	Energiemodell für neuronale Netzwerke im Rechenzentrum	69
11.1.1	FLOPs–Energie–Überführung	69
11.1.2	Gesamtleistungsmodell mit Festanteil und PUE	70
11.1.3	Energieeinspar-Theorem	70
11.2	Quantitative Einsparungsanalyse über Skalierungsstufen	71
11.3	CO ₂ -Bilanz und ökologischer Fußabdruck	73
11.4	Kühlungsoptimierung und PUE-Reduktion	74
11.5	Gesamtkostenanalyse (Total Cost of Ownership)	77
11.6	Modell-Lebenszyklus: Training versus Inferenz-Energiebudget	78
11.7	Synergie zwischen minimaler Restrukturierung und Energieeffizienz	81
11.8	Schlussfolgerungen und quantitative Praxisempfehlungen	81
12	KI-Recheninfrastruktur: Europas digitale Souveränität im Aufbruch	83
12.1	Einleitung und Problemlage	83
12.2	Der globale Cloud-Markt und Europas struktureller Rückstand	83
12.2.1	Marktkonzentration der Hyperscaler	83
12.2.2	Systemisches Ausfallrisiko: Der AWS-Vorfall vom 20. Oktober 2025	84
12.2.3	Rechtliche Dimension: US-Cloud-Act	85
12.3	Deutschlands neue KI-Infrastrukturstrategie	85
12.3.1	Politischer Rahmen: Merkz’sche Digitalsouveränitätsagenda	85
12.4	Schwarz Digits: Vom Handelskonzern zum Cloud-Hyperscaler	85
12.4.1	Strategische Positionierung	85
12.4.2	Technische Spezifikationen	87
12.4.3	Datensouveränität durch kryptographische Verschlüsselung	87
12.4.4	Ökologisches Betriebskonzept	88

12.5	Deutsche Telekom und Nvidia: KI-Fabrik München	88
12.5.1	Partnerschaft und Aufstellung	88
12.5.2	Strategische Stoßrichtung: Industrielle KI als Kernanwendungsfall	88
12.6	Google: Strategische Investition in deutsche Infrastruktur	89
12.7	EU-Förderprogramm für KI-Gigafactories	89
12.7.1	Rahmenbedingungen des EU-Ausschreibungsverfahrens	89
12.7.2	Potenzielle deutsch-deutsche Kooperation	89
12.8	Energetische Skalierung: Vom Megawatt zum Gigawatt	90
12.8.1	Globale Leistungsdimensionen im Vergleich	90
12.8.2	Prognose: Strombedarf von Rechenzentren bis 2030	91
12.8.3	Deutschland: Prognose der Rechenzentrums-Anschlussleistung	91
12.9	Ökologische Einbettung: Grünstrom und Fernwärme	92
12.10	Typen von Rechenzentren: Eine formale Klassifikation	93
12.11	Globale Investitionsperspektive und strategische Einordnung	94
12.11.1	Globale Investitionsprognosen	94
12.11.2	Parallelen zum Northvolt- und Intel-Schicksal	94
12.12	Implikationen für Graphrestrukturierungsforschung in Europa	94
12.13	Zusammenfassung	95
13	Zusammenfassung und Ausblick	97
13.1	Erweiterung auf moderne Architekturen	98
13.2	Skalierungsanalyse: Weiterführende Fragestellungen und offene Probleme	99
13.3	Strukturelle Subgraph-Kompression: Offene Fragen und Erweiterungen	104
13.4	Theoretische Vertiefungen und schärfere Schranken	108
13.5	Empirische Validierung auf großen Benchmarks	109
13.6	Verbindung zu kontinuierlichem Lernen und Lifelong Learning	110
13.7	Algorithmische Effizienz und praktische Implementierung	111
13.8	Verbindung zu biologischer Neuronenplastizität	111
13.9	Bioinspirierte Grundprinzipien: Forschungsausblick zu Kapitel 10	112
13.10	Anwendungsszenarien mit hohem Praxisbezug	118
13.11	Energetische Implikationen: Ausblick und offene Forschungsfragen	119
13.12	KI-Recheninfrastruktur und digitale Souveränität: Strategische Forschungsperspektiven	121
A	Ergänzende Beweise	129
A.1	Vollständiger Beweis von Proposition 7.2	129
A.2	Weyl-Perturbationsungleichung	129

Kapitel 1

Einleitung

Tiefe neuronale Netzwerke konvergieren nach ausgiebigem Training in der Regel gegen einen nahezu stationären Zustand: Verlustfunktion und Gradienten stagnieren, und das Netz scheint seine Kapazitätsgrenzen erreicht zu haben. Die vorliegende Arbeit untersucht das noch kaum formalisierte Phänomen, dass bereits *minimale Veränderungen der Graphstruktur* – konkret die Umverknüpfung einer sehr geringen Anzahl von Kanten bei nahezu unveränderter Knotenanzahl – signifikante Steigerungen der Ausdrucksstärke herbeiführen können, ohne die mühsam erlernten Repräsentationen zu zerstören.

Wir formalisieren einen tiefen neuronalen Netzwerk als gewichteten gerichteten Graphen $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ und definieren den Begriff der (ρ, k) -minimalen Restrukturierung, bei der höchstens der Bruchteil $\rho = k/|\mathcal{E}|$ aller Kanten verändert wird. Mittels spektraler Graphentheorie, VC-Dimensionsanalyse, Rademacher-Komplexität und informationstheoretischer Werkzeuge leiten wir formale obere und untere Schranken für den Kapazitätsgewinn einer solchen Restrukturierung her. Das zentrale Ergebnis – **Theorem 4.2** – belegt, dass der normierte Kapazitätzuwachs $\Delta C(\rho)$ für kleines ρ superlinear in ρ wächst, während der Generalisierungsverlust nur sublinear steigt, sodass ein positiver Netto-Informationsgewinn verbleibt. Ergänzend demonstrieren fünfzehn *matplotlib*-Abbildungen die hergeleiteten Ergebnisse rechnerisch und visuell.

Tiefe neuronale Netzwerke sind in ihrer mathematischen Essenz *parametrische Funktionenklassen*, deren Struktur durch einen gerichteten Graphen $\mathcal{G} = (\mathcal{V}, \mathcal{E})$ vollständig beschrieben wird. Die Leistungsfähigkeit des Netzes wird klassischerweise durch Training der Gewichte $\mathcal{W}$ bei *fixer Graphstruktur* optimiert. Nach Abschluss des Trainings – oder präziser: sobald kein signifikanter Fortschritt mehr erzielt wird – gilt das Netz als *nahezu ausgelernt* (*near-converged*).

Schlüsselwörter: neuronale Netzwerke, Graphrestrukturierung, spektrale Graphentheorie, VC-Dimension, Rademacher-Komplexität, katastrophales Vergessen, Transfer Learning, tote Neuronen.

1.1 Motivation und Problemstellung

Die gängige Praxis begegnet stagnierenden Netzwerken entweder durch Regularisierungsmaßnahmen (Dropout, Weight Decay), durch komplettes Neutraining mit erweiterter Architektur oder durch Fine-Tuning von Vortrainierten Modellen. Alle genannten Verfahren ignorieren jedoch eine geometrische Grundfrage:

Wie viel Ausdrucksstärke schlummert in einem nahezu ausgelernten Netz, das durch minimale Veränderung der Verbindungstopologie freizusetzen wäre?

Diese Arbeit formalisiert und beantwortet diese Frage. Die zentrale Beobachtung ist, dass eine *sehr geringe* Umstrukturierung – wir sprechen von Änderungen in der Größenordnung von 1–5 % aller Kanten – den Hypothesenraum des Netzwerks in qualitativ neuen Regionen erweitert, ohne die bereits gelernten Merkmalsrepräsentationen zu destabilisieren.

1.2 Intuition und Graphperspektive

Ein Feedforward-Netzwerk mit L Schichten und Breiten $n_0, n_1, \dots, n_L$ besitzt $|\mathcal{E}| = \sum_{\ell=1}^L n_{\ell-1} \cdot n_{\ell}$ Kanten. Die meisten dieser Kanten tragen nach langem Training einen *gesättigten* Informationsfluss: ihre Gewichte sind optimal auf die Trainingsverteilung abgestimmt, können aber durch kleine Perturbationen kaum noch verbessert werden. Dagegen gibt es stets eine Menge von Kanten, deren Entfernung zugunsten alternativer Verbindungen (gegebenenfalls Skip-Connections, Querverbindungen zwischen nicht-benachbarten Schichten) das *spektrale Profil* des Graphen günstig verändert und damit neue Hypothesenklassen zugänglich macht.

1.3 Beiträge der Arbeit

Die Hauptbeiträge dieser Arbeit sind:

- (i) **Formale Modellierung** des nahezu ausgelernten neuronalen Netzwerks als gewichteten Graphen mit Stagnationsmaß und Totneuron-Charakterisierung (chapter 2).
- (ii) **Spektraltheoretischer Nachweis**, dass eine (ϱ, k) -minimale Restrukturierung den algebraischen Zusammenhang und die Spektrallücke des Graphen gezielt verbessert (chapter 3).
- (iii) **Kapazitätstheoretische Schranken** (VC-Dimension, Rademacher-Komplexität) für den Hypothesenraumgewinn bei minimaler Strukturveränderung (chapter 4).
- (iv) **Skalierungsanalyse**: Herleitung des optimalen Verhältnisses zwischen Anzahl der umzustrukturierenden Kanten und Aussagekraft in Abhängigkeit der Netzwerkgröße, inklusive formaler Zwei-Regionen-Analyse und Wenige-Kanten-Garantie (chapter 5).
- (v) **Strukturelle Subgraph-Kompression** tiefer neuronaler Netzwerke: Anwendung des rotationsbasierten Subgraph Algorithmus (Laufzeit $O(L^2 q^3)$) zur Erkennung redundanter Schichtmotive, kanonischen Reduktion auf geteilte Gewichtsmatrizen mit Routing-Masken und iterativer Gesamtkompression für energieeffiziente Inferenz (chapter 6).
- (vi) **Informationstheoretische Analyse** des Entropiegewinns und der gegenseitigen Information zwischen Eingabe und Ausgabe nach der Restrukturierung (chapter 7).
- (vii) **Formale Schranken** für das katastrophale Vergessen bei minimaler Restrukturierung sowie Transfer-Effizienzaussagen (section 8.1).
- (viii) **Synthetische Experimente** zur Veranschaulichung aller theoretischen Resultate durch fünfzehn *matplotlib*-Abbildungen (section 8.4).

Kapitel 2

Mathematisches Modell

2.1 Neuronales Netzwerk als gewichteter gerichteter Graph

Definition 2.1 (Neuronales Netzwerk-Graph). Ein neuronales Netzwerk-Graph ist ein Tripel $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, wobei

- $\mathcal{V} = \{v_1, \dots, v_n\}$ die Menge der n Neuronen (Knoten),
- $\mathcal{E} \subseteq \mathcal{V} \times \mathcal{V}$ die gerichtete Kantenmenge mit $|\mathcal{E}| = m$,
- $\mathcal{W} : \mathcal{E} \rightarrow \mathbb{R}$ eine Gewichtsfunktion

bezeichnet. Jedem Knoten v_i ist eine Aktivierungsfunktion $\sigma_i : \mathbb{R} \rightarrow \mathbb{R}$ zugeordnet. Die durch $\mathcal{G}$ realisierte Funktion $f_{\mathcal{G}} : \mathbb{R}^{n_0} \rightarrow \mathbb{R}^{n_L}$ ergibt sich durch schichtweise Propagation:

$$\mathbf{h}^{(\ell)} = \sigma(\mathbf{W}^{(\ell)} \mathbf{h}^{(\ell-1)} + \mathbf{b}^{(\ell)}), \quad \ell = 1, \dots, L, \quad (2.1)$$

mit $\mathbf{h}^{(0)} = \mathbf{x}$ (Eingabe), Gewichtsmatrizen $\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ und Bias-Vektoren $\mathbf{b}^{(\ell)} \in \mathbb{R}^{n_\ell}$.

Definition 2.2 (Hypothesenraum). Der Hypothesenraum von $\mathcal{G}$ ist

$$\mathcal{H}_{\mathcal{G}} = \{f_{\mathcal{G}}(\cdot; \boldsymbol{\theta}) \mid \boldsymbol{\theta} \in \Theta_{\mathcal{G}}\},$$

wobei $\Theta_{\mathcal{G}} = \mathbb{R}^{|\mathcal{E}|}$ der Parameterraum über alle Kantengewichte ist.

2.2 Nahezu ausgelerntes Netzwerk

Definition 2.3 (Stagnationsmaß und nahezu ausgelernt). Sei $\mathcal{L}(\boldsymbol{\theta}) : \Theta_{\mathcal{G}} \rightarrow \mathbb{R}_{\geq 0}$ die Verlustfunktion. Das Netzwerk heißt δ -nahezu ausgelernt, falls nach T Trainingsschritten gilt:

$$\|\nabla_{\boldsymbol{\theta}} \mathcal{L}(\boldsymbol{\theta}^{(T)})\|_2 \leq \delta \quad \text{und} \quad |\mathcal{L}(\boldsymbol{\theta}^{(T)}) - \mathcal{L}(\boldsymbol{\theta}^{(T-\tau)})| \leq \delta \cdot \tau \quad (2.2)$$

für alle $\tau \in \{1, \dots, T_{\min}\}$ mit einem vorgegebenen Fenster $T_{\min} \in \mathbb{N}$.

Definition 2.4 (Totes Neuron). Ein Neuron $v_i \in \mathcal{V}$ heißt tot bezüglich Datensatz S und Aktivierungsfunktion $\sigma = \text{ReLU}$, falls

$$\mathbb{P}_{x \sim S} [\sigma_i((\mathbf{W}\mathbf{h})_i + b_i) = 0] \geq 1 - \varepsilon_{\text{dead}}$$

für ein kleines $\varepsilon_{\text{dead}} > 0$. Die Menge toter Neuronen ist $\mathcal{V}_{\text{dead}} \subseteq \mathcal{V}$; ihr Anteil sei $\alpha_{\text{dead}} = |\mathcal{V}_{\text{dead}}|/|\mathcal{V}|$.

In nahezu ausgelernten Netzwerken beobachtet man typischerweise $\alpha_{\text{dead}} \in [0.10, 0.35]$ in mittleren Schichten, wie Abbildung 6 (Panel oben rechts) empirisch veranschaulicht.

2.3 Minimale Graphrestrukturierung

Definition 2.5 ((ϱ, k) -minimale Restrukturierung). *Sei $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ ein neuronaler Netzwerk-Graph mit $|\mathcal{E}| = m$. Eine (ϱ, k) -minimale Restrukturierung ist eine Abbildung $\phi : \mathcal{G} \mapsto \mathcal{G}' = (\mathcal{V}', \mathcal{E}', \mathcal{W}')$, bei der*

- (a) $|\mathcal{V}' \setminus \mathcal{V}| + |\mathcal{V} \setminus \mathcal{V}'| \leq k_{\mathcal{V}}$ (höchstens $k_{\mathcal{V}}$ Knotenveränderungen),
- (b) $|\mathcal{E} \Delta \mathcal{E}'| \leq k$ mit $k = \lfloor \varrho \cdot m \rfloor$ (symmetrische Differenz der Kantenmengen),
- (c) $\boldsymbol{\theta}_{\mathcal{E} \cap \mathcal{E}'} = \boldsymbol{\theta}'_{\mathcal{E} \cap \mathcal{E}'}$ (unveränderte Kanten behalten ihre Gewichte),

wobei typischerweise $\varrho \in (0, 0.05]$ und $k_{\mathcal{V}} \ll n$.

Bemerkung 2.6. *Bedingung (c) ist entscheidend: Alle Gewichte nicht-betroffener Kanten bleiben exakt erhalten. Dies sichert, dass die bereits gelernten Repräsentationen intakt bleiben – in scharfem Kontrast zu Finetuning-Verfahren, die sämtliche Gewichte modifizieren.*

Kapitel 3

Spektraltheoretische Analyse

Wir betrachten den undirigierten Trägergraphen $\hat{\mathcal{G}}$ von $\mathcal{G}$, d.h. die symmetrische Version $(u, v) \in \hat{\mathcal{E}} \Leftrightarrow (u, v) \in \mathcal{E} \vee (v, u) \in \mathcal{E}$. Seine Laplace-Matrix ist $\mathbf{L} = \mathbf{D} - \mathbf{A}$, wobei $\mathbf{A}$ die Adjazenzmatrix und $\mathbf{D}$ die Gradmatrix bezeichnen.

Definition 3.1 (Spektrale Kenngrößen). *Seien $0 = \lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$ die Eigenwerte von $\mathbf{L}$. Dann heißen:*

- λ_2 der Fiedler-Wert (algebraische Konnektivität),
- $\Delta_{\text{sp}} = \lambda_3 - \lambda_2$ die Spektrallücke,
- $\kappa(\mathbf{L}) = \lambda_n / \lambda_2$ die Spektralkondition.

Theorem 3.2 (Spektraler Kapazitätsgewinn durch minimale Restrukturierung). *Sei $\mathcal{G}$ ein δ -nahezu ausgelerner neuronaler Netzwerk-Graph mit Fiedler-Wert λ_2 . Sei $\mathcal{G}'$ eine (ϱ, k) -minimale Restrukturierung von $\mathcal{G}$. Dann gilt für die Fiedler-Wert-Änderung:*

$$|\lambda_2(\mathcal{G}') - \lambda_2(\mathcal{G})| \leq \|\Delta \mathbf{L}\|_2 = \|\mathbf{L}' - \mathbf{L}\|_2, \quad (3.1)$$

und für den relativen Kapazitätswachstum gemessen durch den Fiedler-Wert:

$$\frac{\lambda_2(\mathcal{G}') - \lambda_2(\mathcal{G})}{\lambda_2(\mathcal{G})} \leq \frac{4k \cdot d_{\max}}{m \cdot \lambda_2(\mathcal{G})}, \quad (3.2)$$

wobei $d_{\max} = \max_{v \in \mathcal{V}} \deg(v)$ der maximale Knotengrad ist.

Beweis. Wir schreiben $\mathbf{L}' = \mathbf{L} + \Delta \mathbf{L}$, wobei $\Delta \mathbf{L} = \mathbf{L}' - \mathbf{L}$ die Laplace-Differenz ist. Per Weyl'scher Eigenwertperturbationsungleichung gilt für jeden Eigenwert λ_i :

$$|\lambda_i(\mathbf{L}') - \lambda_i(\mathbf{L})| \leq \|\Delta \mathbf{L}\|_2. \quad (3.3)$$

Damit ist (3.1) unmittelbar gezeigt.

Für (3.2) analysieren wir $\|\Delta \mathbf{L}\|_2$. Die Änderung $\Delta \mathbf{L}$ entsteht durch Entfernen und Hinzufügen von je höchstens k Kanten. Das Entfernen einer einzelnen Kante (u, v) ergibt einen Laplace-Rang-2-Update:

$$\Delta \mathbf{L}_{(u,v)} = -(\mathbf{e}_u - \mathbf{e}_v)(\mathbf{e}_u - \mathbf{e}_v)^\top,$$

der Spektralnorm $\|\Delta \mathbf{L}_{(u,v)}\|_2 = 2$. Da höchstens $2k$ solche Operationen (Entfernen + Hinzufügen) stattfinden, ergibt sich $\|\Delta \mathbf{L}\|_2 \leq 4k$. Der relative Fiedler-Wert-Gewinn wird nach oben beschränkt durch:

$$\frac{\lambda_2(\mathcal{G}') - \lambda_2(\mathcal{G})}{\lambda_2(\mathcal{G})} \leq \frac{\|\Delta \mathbf{L}\|_2}{\lambda_2(\mathcal{G})} \leq \frac{4k}{\lambda_2(\mathcal{G})}.$$

Da $\lambda_2(\mathcal{G}) \geq \lambda_2^{\min}$ für reguläre Graphen durch die Cheeger-Ungleichung $\lambda_2 \geq h^2/(2d_{\max})$ mit Kantenerweiterungszahl h nach unten beschränkt ist, folgt durch Einsetzen $k = \lfloor \varrho \cdot m \rfloor$ und Division durch m die Ungleichung (3.2). $\square$

Theorem 3.3 (Untere Schranke für den Fiedler-Gewinn). *Sei $\mathcal{G}$ ein zusammenhängender Graph mit $|\mathcal{V}_{\text{dead}}| \geq 1$ toten Neuronen. Dann existiert eine (ϱ, k) -minimale Restrukturierung $\mathcal{G}'$ mit $k = 1$, sodass*

$$\lambda_2(\mathcal{G}') - \lambda_2(\mathcal{G}) \geq \frac{1}{n-1} \left[\frac{1}{\deg(u)} + \frac{1}{\deg(v)} \right]^{-1} - 2 =: \gamma > 0 \quad (3.4)$$

für geeignete Knoten $u \in \mathcal{V}_{\text{dead}}$, $v \in \mathcal{V} \setminus \mathcal{V}_{\text{dead}}$, sofern $\deg(u)$ klein ist.

Beweis. Sei (u, v) eine neu hinzuzufügende Kante zwischen einem toten Neuron u und einem aktiven Neuron v . Nach dem Fiedler-Vektor-Argument von Fiedler (1973) gilt für jeden Graphen G und eine hinzuzufügende Kante (u, v) :

$$\lambda_2(G + (u, v)) - \lambda_2(G) \geq \frac{(f_u - f_v)^2}{n-1},$$

wobei $\mathbf{f} = (f_1, \dots, f_n)^\top$ der normierte Fiedler-Vektor von G ist. Da u tot ist, erhält sein Fiedler-Komponente durch die dünne Konnektivität einen extremalen Wert:

$$|f_u - f_v| \geq \frac{1}{\sqrt{\deg(u) + 1}},$$

woraus sich (3.4) ergibt. Das Vorzeichen ist positiv, da das Hinzufügen einer Kante den Fiedler-Wert nie verringert (Fiedler, 1973). $\square$

Bemerkung 3.4. *Theoreme 3.2 und 3.3 zusammen geben ein vollständiges Bild: Die obere Schranke zeigt, dass minimale Restrukturierung das Spektrum nicht destabilisiert; die untere Schranke garantiert, dass tote Neuronen durch eine einzige neue Kante eine messbare algebraische Konnektivitätssteigerung erfahren.*

Abb. 2: Spektralanalyse der Graphlaplace-Matrix vor und nach Restrukturierung




Abbildung 3.1: **Spektralanalyse der Graphlaplace-Matrix.** *Linkes Panel:* Eigenwertspektrum der Laplace-Matrix eines Barabási-Albert-Graphen mit $n = 80$ Knoten, vor (blau) und nach (rot) 2 %-Restrukturierung. Das Spektrum bleibt qualitativ stabil – nur einzelne Eigenwerte verschieben sich geringfügig, was mit Theorem 3.2 (Weyl-Schranke) übereinstimmt. *Mittleres Panel:* Fiedler-Wert λ_2 als Funktion der Anzahl umstrukturierter Kanten. Bei sehr geringer Restrukturierung (1–3 Kanten) steigt λ_2 an (gestrichelte Schwelle bei 2), während übermäßige Restrukturierung die algebraische Konnektivität destabilisiert. Die Kurve ist nicht-monoton, was das Optimum k^* in Abbildung 1 erklärt. *Rechtes Panel:* Spektrallücke $\lambda_3 - \lambda_2$ über 20 aufeinanderfolgende Restrukturierungsschritte. Blaue Balken repräsentieren minimale (ein Kante), rote Balken weitreichende Veränderungen. Die Spektrallücke bleibt bei minimaler Restrukturierung deutlich stabiler, was eine geringere Anfälligkeit für spektrale Instabilität belegt.

Kapitel 4

Kapazitätstheoretische Analyse

4.1 Hypothesenraumgeometrie

Definition 4.1 (Kapazitätswachstum). *Der normierte Kapazitätswachstum einer (ϱ, k) -minimalen Restrukturierung $\phi : \mathcal{G} \mapsto \mathcal{G}'$ ist definiert als*

$$\Delta C(\varrho) = \frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}'}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})}{\text{VCdim}(\mathcal{H}_{\mathcal{G}})} - \beta \cdot \varrho^2, \quad (4.1)$$

wobei der erste Term den relativen VC-Dimensionsgewinn und der zweite Term den quadratischen Generalisierungskostenterm modelliert, mit Konstante $\beta > 0$.

Theorem 4.2 (Superlinearer Kapazitätsgewinn bei kleinem ϱ). *Sei $\mathcal{G}$ ein δ -nahezu ausgelerner neuronaler Netzwerk-Graph mit $|\mathcal{V}_{\text{dead}}| = d > 0$ toten Neuronen und Tiefe $L \geq 3$. Dann gilt für jede (ϱ, k) -minimale Restrukturierung mit $k \leq \lfloor \varrho m \rfloor$ und $0 < \varrho \leq \varrho^*$:*

$$\Delta C(\varrho) \geq c_1 \cdot \frac{d}{n} \cdot \varrho \cdot L - \beta \cdot \varrho^2 > 0, \quad (4.2)$$

wobei $c_1 > 0$ eine universelle Konstante ist und das optimale ϱ^* durch

$$\varrho^* = \frac{c_1 \cdot d \cdot L}{2\beta \cdot n} \quad (4.3)$$

gegeben ist. Insbesondere ist ϱ^* klein für große Netze ($n \gg d$).

Beweis. Schritt 1: VC-Dimensionsunterschätzung. Nach Goldberg und Jerrum (1995) sowie Bartlett und Mendelson (2002) gilt für ReLU-Netzwerke mit p Parametern und Tiefe L :

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}}) \geq \Omega(p \cdot L). \quad (4.4)$$

Schritt 2: Parametergewinn durch Reaktivierung toter Neuronen. Jede Kante, die ein totes Neuron mit einem aktiven Neuron verbindet, reaktiviert das tote Neuron auf einem positiven Maß der Eingabeverteilung. Sei $v_i \in \mathcal{V}_{\text{dead}}$ ein totes Neuron mit eingehenden Gewichten $\mathbf{w}_i$. Nach Hinzufügen einer eingehenden Kante (v_j, v_i) mit Gewicht $w_{ji} \neq 0$ gilt:

$$\begin{aligned} \mathbb{P}_{x \sim \mu} [\sigma(\mathbf{w}_i^\top \mathbf{h} + w_{ji} h_j + b_i) > 0] &\geq \mathbb{P}_{x \sim \mu} [h_j \cdot \text{sgn}(w_{ji}) > -\frac{\mathbf{w}_i^\top \mathbf{h} + b_i}{|w_{ji}|}] \\ &\geq \frac{1}{2} \cdot \mathbb{P}_{x \sim \mu} [h_j \neq 0] > 0. \end{aligned} \quad (4.5)$$

Das reaktivierte Neuron nimmt also an der Berechnung effektiv teil und trägt zur effektiven Parameteranzahl bei. k solcher Reaktivierungen erhöhen die effektive Parameterzahl um $\Delta p \geq k \cdot \bar{d}$, wobei $\bar{d}$ der durchschnittliche Grad der betroffenen Schicht ist.

Schritt 3: Relativer VC-Dimensionsgewinn. Mit $\Delta p = \lfloor \varrho m \rfloor \cdot \bar{d}$ ergibt sich:

$$\frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}'}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})}{\text{VCdim}(\mathcal{H}_{\mathcal{G}})} \geq \frac{\Delta p \cdot L}{p \cdot L} = \frac{\lfloor \varrho m \rfloor \cdot \bar{d}}{m \cdot \bar{w}} \geq c_1 \cdot \frac{d}{n} \cdot \varrho \cdot L, \quad (4.6)$$

wobei wir $m = |\mathcal{E}|$, $\bar{w}$ als mittlere Breite und $c_1 = \bar{d}/(\bar{w} \cdot L^0)$ gesetzt haben.

Schritt 4: Generalisierungskosten. Nach Satz von Blumer et al. (1989) wächst die Generalisierungsschranke mit $\text{VCdim}(\mathcal{H}_{\mathcal{G}'}) \cdot m^{-1}$. Der Zuwachs der Schranke ist proportional zu $\Delta p/m \leq \varrho$, und der quadratische Term $-\beta \varrho^2$ in (4.1) absorbiert diesen Effekt für β groß genug.

Schritt 5: Optimum und Positivität. Sei $g(\varrho) = c_1 \frac{d}{n} L \varrho - \beta \varrho^2$. Dann ist $g'(\varrho^*) = 0$ für $\varrho^* = c_1 d L / (2\beta n) > 0$, und $g(\varrho) > 0$ für alle $\varrho \in (0, 2\varrho^*)$. Damit ist (4.2) bewiesen. $\square$

Abb. 1: Kapazitätsgewinn durch minimale Graphrestrukturierung




Abbildung 4.1: **Kapazitätsgewinn durch minimale Graphrestrukturierung.** *Linkes Panel:* Normierter Kapazitätsgewinn $\Delta C(\varrho)$ gemäß Theorem 4.2 als Funktion der Kantenänderungsrate ϱ [%]. Die blaue Kurve folgt dem Modell $\Delta C = C_0(1 - e^{-\alpha \varrho}) - \beta \varrho^2$, das die superlineare Steigerung bei kleinen ϱ (grüne Fläche, Nettogewinn) und die Übersättigung bei zu hoher Restrukturierung (rote Fläche, Nettoverlust) wiedergibt. Das Optimum liegt bei $\varrho^* \approx 2,2\%$, was mit der analytischen Formel (4.3) übereinstimmt. *Rechtes Panel:* Skalierung des optimalen Kapazitätsgewinns mit der Netzwerkgröße n . Für wachsendes n verschiebt sich das Optimum ϱ^* zu kleineren Werten (gemäß $\varrho^* \propto 1/n$), und der maximale erreichbare Zuwachs steigt logarithmisch in n . Dies belegt, dass große Netzwerke besonders effizient von minimaler Restrukturierung profitieren.

4.2 Rademacher-Komplexität

Theorem 4.3 (Rademacher-Schranke unter minimaler Restrukturierung). *Seien $\mathcal{G}$ und $\mathcal{G}'$ wie in Theorem 4.2. Die empirische Rademacher-Komplexität $\hat{\mathcal{R}}_m(\mathcal{H}_{\mathcal{G}'})$ bezüglich einer Stichprobe $S = (x_1, \dots, x_m)$ erfüllt:*

$$\hat{\mathcal{R}}_m(\mathcal{H}_{\mathcal{G}'}) - \hat{\mathcal{R}}_m(\mathcal{H}_{\mathcal{G}}) \leq C \cdot B_x \cdot B_w^L \cdot \sqrt{\frac{\varrho \cdot m_{\mathcal{E}}}{m}}, \quad (4.7)$$

wobei B_x die Eingabeschränke, B_w die Gewichtsschränke und $C > 0$ eine universelle Konstante ist. Für $m \gg \varrho \cdot m_\varepsilon$ ist die rechte Seite klein, d.h. die Komplexitätssteigerung ist vernachlässigbar.

Beweis. Die Rademacher-Komplexität eines L -schichtigen ReLU-Netzes mit p Parametern und beschränkten Gewichten ist nach Bartlett und Mendelson (2002):

$$\hat{\mathcal{R}}_m(\mathcal{H}) \leq C \cdot B_x \cdot B_w^L \cdot \sqrt{\frac{p}{m}}.$$

Da die Parameteranzahl von p auf $p + \Delta p$ steigt und $\Delta p \leq \varrho \cdot m_\varepsilon$ gilt, folgt:

$$\begin{aligned} \hat{\mathcal{R}}_m(\mathcal{H}_{G'}) - \hat{\mathcal{R}}_m(\mathcal{H}_G) &\leq C \cdot B_x \cdot B_w^L \left(\sqrt{\frac{p + \varrho m_\varepsilon}{m}} - \sqrt{\frac{p}{m}} \right) \\ &= C \cdot B_x \cdot B_w^L \cdot \frac{\varrho m_\varepsilon}{\sqrt{m}(\sqrt{p + \varrho m_\varepsilon} + \sqrt{p})} \\ &\leq C \cdot B_x \cdot B_w^L \cdot \sqrt{\frac{\varrho m_\varepsilon}{m}}, \end{aligned} \quad (4.8)$$

was (4.7) ergibt. $\square$

Abb. 8: Theoretische Generalisierungsschranken bei minimaler Restrukturierung




Abbildung 4.2: **Theoretische Generalisierungsschranken.** *Linkes Panel:* VC-Dimensions-basierte Schranke nach Blumer et al. für Baseline (VCdim = 500) und restrukturiertes Netz (VCdim = 530) als Funktion der Stichprobengröße m (log-log-Skala). Beide Kurven fallen mit $m^{-1/2}$; die minimale Erhöhung der VC-Dimension durch 2% Restrukturierung führt zu einem praktisch vernachlässigbaren Unterschied der Schranken, sobald $m \gtrsim 10^4$. *Mittleres Panel:* Rademacher-Komplexität für Baseline und restrukturiertes Netz; die rote Kurve zeigt die relative Differenz (rechte Achse). Gemäß Theorem 4.3 ist die Differenz $\mathcal{O}(\sqrt{\varrho/m})$ und bleibt für ausreichend große Datensätze minimal. *Rechtes Panel:* Bias-Varianz-Trade-off. Minimale Restrukturierung verschiebt den optimalen Arbeitspunkt leicht nach rechts (höhere Komplexität optimal), da tote Neuronen reaktiviert werden und Bias reduziert wird, ohne die Varianz wesentlich zu erhöhen.

Kapitel 5

Skalierungsanalyse: Optimales Verhältnis von Kantenanzahl und Aussagekraft

Das in Theorem 4.2 hergeleitete optimale ϱ^* beschreibt, welcher Bruchteil der Kanten für maximalen Kapazitätsgewinn umstrukturiert werden sollte. Offen bleibt die Frage, wie sich dieses Optimum – sowohl als relativer Anteil ϱ^* als auch als absolute Kantenanzahl $k^* = \lfloor \varrho^* m \rfloor$ – mit der Größe des neuronalen Netzwerks verändert, und unter welchen Bedingungen das Optimum garantiert innerhalb des *Wenige-Kanten-Rahmens* liegt. Dieser Abschnitt formalisiert diese Skalierungsabhängigkeit und leitet explizite Bedingungen für Netze ab, bei denen eine geringe Anzahl von Umstrukturierungen maximale Aussagekraft erzielt.

5.1 Aussagekraft als Zielfunktion

Definition 5.1 (Aussagekraft und Effizienzmaß). *Sei $\mathcal{G}$ ein δ -nahezu ausgelerner neuraler Netzwerk-Graph und $\mathcal{G}'$ eine (ϱ, k) -minimale Restrukturierung. Die Aussagekraft der Restrukturierung ist der normierte Kapazitätzuwachs*

$$A(\varrho) := \Delta C(\varrho) = c_1 \cdot \frac{d}{n} \cdot L \cdot \varrho - \beta \cdot \varrho^2,$$

und das Effizienzmaß ist die Aussagekraft pro umstrukturierter Kante:

$$\eta(\varrho) := \frac{A(\varrho)}{\varrho} = c_1 \cdot \frac{d \cdot L}{n} - \beta \cdot \varrho. \quad (5.1)$$

Bemerkung 5.2. Das Effizienzmaß $\eta(\varrho)$ ist streng fallend in ϱ : Jede zusätzlich umstrukturierte Kante liefert geringeren Grenznutzen (abnehmende Grenzerträge). Gleichzeitig ist die Gesamtaussagekraft $A(\varrho)$ für kleine ϱ noch steigend. Das Optimum ϱ^* balanciert Gesamtgewinn und marginale Effizienz.

5.2 Kritische Netzgröße und Zwei-Regionen-Analyse

Definition 5.3 (Wenige-Kanten-Regime und kritische Netzgröße). *Sei $\varrho_{\max} \in (0, 1)$ eine Schranke für das Wenige-Kanten-Regime (typisch $\varrho_{\max} = 0,05$). Dann ist*

$$\mathcal{R}_{\text{few}} := \left\{ \varrho \in (0, 1) \mid \varrho \leq \varrho_{\max} \right\}$$

das Wenige-Kanten-Regime, und die kritische Netzgröße ist

$$n_{\text{crit}}(d, L) := \frac{c_1 \cdot d \cdot L}{2 \beta \cdot \varrho_{\text{max}}}. \quad (5.2)$$

Theorem 5.4 (Konstringiertes Optimum: Zwei-Regionen-Analyse). *Sei $\varrho_{\text{con}}^*(n)$ definiert mit $\varrho_{\text{con}}^*(n) := \min(\hat{\varrho}^*(n), \varrho_{\text{max}})$ mit $\hat{\varrho}^*(n) = \frac{c_1 d L}{2 \beta n}$ das auf $\mathcal{R}_{\text{few}}$ konstringierte Optimum. Dann gilt:*

- (i) **Kleines Netz** ($n \leq n_{\text{crit}}$): *Das Optimum liegt am Rand, $\varrho_{\text{con}}^* = \varrho_{\text{max}}$, und die maximale erreichbare Aussagekraft beträgt*

$$A(\varrho_{\text{max}}) = c_1 \frac{dL}{n} \varrho_{\text{max}} - \beta \varrho_{\text{max}}^2 > 0.$$

- (ii) **Großes Netz** ($n > n_{\text{crit}}$): *Das unkonstringierte Optimum liegt im Inneren, $\varrho_{\text{con}}^* = \hat{\varrho}^*(n) < \varrho_{\text{max}}$, und die maximale Aussagekraft ist*

$$A(\hat{\varrho}^*) = \frac{(c_1 d L)^2}{4 \beta n^2}. \quad (5.3)$$

Das Effizienzmaß am Optimum erfüllt

$$\eta(\hat{\varrho}^*) = \frac{1}{2} \eta(0^+) = \frac{c_1 d L}{2 n}. \quad (5.4)$$

Insbesondere ist für $n > n_{\text{crit}}$ die Wenige-Kanten-Bedingung $\varrho_{\text{con}}^* \leq \varrho_{\text{max}}$ automatisch erfüllt: Große Netzwerke restrukturieren optimal mit wenigen Kanten, ohne dass diese Schranke extern auferlegt werden muss.

Beweis. Die Funktion $A(\varrho) = c_1 \frac{dL}{n} \varrho - \beta \varrho^2$ ist eine nach unten geöffnete Parabel mit Scheitelpunkt bei $\hat{\varrho}^* = \frac{c_1 d L}{2 \beta n}$. Das konstringierte Maximum auf $[0, \varrho_{\text{max}}]$ wird am Scheitelpunkt angenommen, sofern $\hat{\varrho}^* \leq \varrho_{\text{max}}$; andernfalls am Rand ϱ_{max} . Für $n > n_{\text{crit}}$ gilt $\hat{\varrho}^* = \frac{c_1 d L}{2 \beta n} < \frac{c_1 d L}{2 \beta n_{\text{crit}}} = \varrho_{\text{max}}$. Einsetzen in A liefert (i) und (ii). Die Effizienz-Gleichung (5.4) folgt aus $\eta(\hat{\varrho}^*) = c_1 d L / n - \beta \hat{\varrho}^* = c_1 d L / n - c_1 d L / (2n) = c_1 d L / (2n) = \frac{1}{2} \eta(0^+)$. $\square$

Korollar 5.5 (Universelle Halb-Effizienz am Optimum). *Am unkonstringierten Optimum $\hat{\varrho}^*$ gilt universell*

$$\frac{\eta(\hat{\varrho}^*)}{\eta(0^+)} = \frac{1}{2},$$

unabhängig von n , d und L . Das Optimum liegt stets bei halber maximaler Effizienz – ein netzwerkgrößenunabhängiges Resultat.

5.3 Absoluter Kantenbedarf in Abhängigkeit der Architektur

Die absolute optimale Kantenanzahl $k^*(n) = \lfloor \varrho^*(n) \cdot m \rfloor$ hängt von der Skalierung der Kantenanzahl $m = |\mathcal{E}|$ mit n ab. Wir betrachten drei kanonische Architekturfamilien.

Proposition 5.6 (Architekturskalierung von k^*). *Sei $n > n_{\text{crit}}$, sodass $\varrho^*(n) = \hat{\varrho}^*(n) = \frac{c_1 d L}{2 \beta n}$. Dann skaliert $k^*(n)$ wie folgt:*

(i) **Vollvernetztes Feedforward-Netz** ($n_\ell = w$, $n = Lw$, $m = (L-1)w^2$):

$$k^*(n) = \frac{c_1 d (L-1)}{2 \beta L^2} \cdot n = \Theta(n). \quad (5.5)$$

Der Bedarf wächst linear, der Anteil $\varrho^* \propto 1/n$ geht gegen null.

(ii) **Skalenfreies Netz** (Barabási-Albert, $m = \bar{d}_{\text{BA}} \cdot n$):

$$k^*(n) = \frac{c_1 d L \bar{d}_{\text{BA}}}{2 \beta} = \Theta(1). \quad (5.6)$$

Konstanter absoluter Bedarf: Kein zusätzlicher Aufwand für größere Netze.

(iii) **Partiell dichtes Netz** ($m = c_s n^{3/2}$):

$$k^*(n) = \frac{c_1 d L c_s}{2 \beta} \cdot n^{1/2} = \Theta(n^{1/2}). \quad (5.7)$$

Sublineares Wachstum: Auch für sehr große Netze $O(\sqrt{n})$ Umstrukturierungen.

Beweis. In allen Fällen gilt $k^*(n) = \varrho^*(n) \cdot m(n)$. Einsetzen von $\varrho^*(n) = \frac{c_1 d L}{2 \beta n}$ und der jeweiligen $m(n)$ liefert:

$$\begin{aligned} \text{(i)} \quad k^* &= \frac{c_1 d L}{2 \beta n} \cdot \frac{(L-1)n^2}{L^2} = \frac{c_1 d (L-1)}{2 \beta L^2} n; \\ \text{(ii)} \quad k^* &= \frac{c_1 d L}{2 \beta n} \cdot \bar{d}_{\text{BA}} n = \frac{c_1 d L \bar{d}_{\text{BA}}}{2 \beta}; \\ \text{(iii)} \quad k^* &= \frac{c_1 d L}{2 \beta n} \cdot c_s n^{3/2} = \frac{c_1 d L c_s}{2 \beta} n^{1/2}. \quad \square \end{aligned}$$

Korollar 5.7 (Sublinearität des Verhältnisses k^*/m). Für alle drei Architekturfamilien und $n > n_{\text{crit}}$ gilt

$$\frac{k^*(n)}{m(n)} = \varrho^*(n) = \frac{c_1 d L}{2 \beta n} \xrightarrow{n \rightarrow \infty} 0.$$

Große Netzwerke benötigen anteilig immer weniger Umstrukturierungen, um maximale Aussagekraft zu erzielen.

5.4 Formaler Wenige-Kanten-Rahmen mit Budgetgarantie

Theorem 5.8 (Wenige-Kanten-Garantie). Sei $K_{\text{budget}} \in \mathbb{N}$ ein festes Kantenbudget. Eine (ϱ, k) -minimale Restrukturierung mit $k \leq K_{\text{budget}}$ erzielt einen positiven Aussagekraftgewinn $A(k/m) > 0$, sofern

$$K_{\text{budget}} \geq 1 \quad \text{und} \quad n \leq \frac{c_1 d L m}{2 \beta K_{\text{budget}}}. \quad (5.8)$$

Wird das Budget genau ausgeschöpft ($k = K_{\text{budget}} \leq k^*$), so ist der Aussagekraftgewinn

$$A\left(\frac{K_{\text{budget}}}{m}\right) = c_1 \frac{d L}{n} \cdot \frac{K_{\text{budget}}}{m} - \beta \cdot \frac{K_{\text{budget}}^2}{m^2} > 0. \quad (5.9)$$

Insbesondere reicht $K_{\text{budget}} = 1$ für einen positiven Gewinn, sofern $n \leq c_1 d L m / (2 \beta)$.

Beweis. $A(\varrho) > 0$ für $\varrho \in (0, 2\hat{\varrho}^*)$ nach Theorem 4.2. Mit der Wahl $\varrho = K_{\text{budget}}/m$ ist $A > 0$ genau dann, wenn $K_{\text{budget}}/m < 2\hat{\varrho}^*$, d.h. $K_{\text{budget}} < \frac{c_1 d L m}{\beta n}$. Halbierung liefert die hinreichende Bedingung (5.8). Die Gleichung (5.9) ergibt sich unmittelbar durch Einsetzen von $\varrho = K_{\text{budget}}/m$ in die Definition $A(\varrho)$. $\square$

Bemerkung 5.9. Theorem 5.8 bestätigt, dass eine einzige Kantenumstrukturierung ($K_{\text{budget}} = 1$) bereits einen messbaren Aussagekraftgewinn liefert, solange $n \leq c_1 d L m / (2\beta)$. Für ein typisches vollvernetztes Netz ($L = 5$, $w = 100$, $m = 40\,000$, $d = 100$) lautet diese Bedingung $n \leq c_1 \cdot 10^7$ – für jede Konstante $c_1 > 5 \times 10^{-5}$ erfüllt. Selbst mit einem Kantebudget von $K_{\text{budget}} = 3\text{--}5$ (entsprechend $\varrho \approx 0,01\%$ bei $m = 40\,000$) lassen sich gemäß Theorem 5.4 und den experimentellen Belegen in Fig. 8.1 signifikante Kapazitätssteigerungen erzielen.

Abb. 10: Skalierungsverhalten des optimalen Umstrukturierungsverhältnisses




Abbildung 5.1: **Skalierungsverhalten des optimalen Umstrukturierungsverhältnisses.** *Oben links:* Optimales $\varrho^*(n)$ als Funktion der Netzgröße n (halblogarithmisch) für drei Totneuronen-Anteile $\alpha_d \in \{0,10, 0,20, 0,35\}$. Die gestrichelte rote Linie markiert $\varrho_{\max} = 5\%$. Für $n > n_{\text{crit}}$ (Schnittpunkte) liegt das Optimum automatisch im Wenige-Kanten-Regime ($\varrho^* < \varrho_{\max}$). *Oben rechts:* Absoluter optimaler Kantenbedarf $k^*(n)$ für vollvernetzte (blau, $k^* \propto n$), skalenfreie (grün, $k^* = \text{const}$) und partiell dichte Netze (orange, $k^* \propto \sqrt{n}$) gemäß Proposition 5.6. *Unten links:* Maximale Aussagekraft $A(\varrho^*)$ als Funktion von n (doppelt-logarithmisch). Für $n > n_{\text{crit}}$ fällt $A \propto n^{-2}$ gemäß (5.3) – die anteilige Reserve sinkt, die absoluten Kapazitätspotenziale großer Netze bleiben aber erheblich. *Unten rechts:* Effizienz-Verhältnis $\eta(\varrho)/\eta(0^+)$ und normierte Aussagekraft $A(\varrho)/A(\varrho^*)$ als Funktion von ϱ/ϱ^* . Am Optimum $\varrho = \varrho^*$ beträgt die Effizienz stets genau die Hälfte des Maximalwerts – Korollar 5.5 – unabhängig von der Netzgröße.

Kapitel 6

Strukturelle Subgraph-Kompression tiefer neuronaler Netzwerke

Nahezu ausgelernte neuronale Netzwerke weisen nach langem Training eine charakteristische Eigenschaft auf: Identische oder strukturell äquivalente Verbindungsmuster treten in verschiedenen Schichten mehrfach auf. Diese *strukturelle Redundanz* ist eine direkte Konsequenz des Trainings, das lokale Optima durch wiederholte Parallelverarbeitung ähnlicher Merkmale approximiert. Die vorliegende Sektion formalisiert einen neuen Ansatz zur Ausnutzung dieser Redundanz: den *Subgraph-basierten Kompressions-Algorithmus* (SGKR, Structural Graph Compression by Rotation-Based Subgraph Reduction), der auf dem in [1] entwickelten Subgraph Algorithmus basiert und strukturell identische Schichten auf eine gemeinsame kanonische Struktur reduziert – bei gleichzeitiger Erhaltung aller relevanten Informationsflüsse durch ein explizites Routing-Modell. Das Ergebnis ist ein *Minimalnetz* $\mathcal{G}_{\min}$, das bei formal gesicherter Ausdrucksstärke einen Bruchteil der ursprünglichen Parameter und einen Bruchteil des ursprünglichen Energieverbrauchs erfordert.

6.1 Strukturelle Redundanz in trainierten neuronalen Netzwerken

Definition 6.1 (Schichtgraph und Konnektivitätsmotiv). Sei $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ ein neuronaler Netzwerk-Graph mit L Schichten und Breiten $\mathbf{n} = (n_0, n_1, \dots, n_L)$. Der Schichtgraph von Schicht ℓ ist der bipartite Teilgraph

$$\mathcal{G}^{(\ell)} = (\mathcal{V}^{(\ell-1)} \cup \mathcal{V}^{(\ell)}, \mathcal{E}^{(\ell)}, \mathcal{W}^{(\ell)}), \quad \mathcal{E}^{(\ell)} = \mathcal{E} \cap (\mathcal{V}^{(\ell-1)} \times \mathcal{V}^{(\ell)}).$$

Das Konnektivitätsmotiv (kurz: Motiv) von Schicht ℓ ist die binäre Konnektivitätsmatrix

$$M^{(\ell)} \in \{0, 1\}^{n_\ell \times n_{\ell-1}}, \quad M_{ij}^{(\ell)} = \mathbf{1}[(v_i^{(\ell)}, v_j^{(\ell-1)}) \in \mathcal{E}].$$

Definition 6.2 (Quadratische Erweiterung). Sei $M^{(\ell)} \in \{0, 1\}^{n_\ell \times n_{\ell-1}}$. Die quadratische Erweiterung ist

$$\hat{M}^{(\ell)} \in \{0, 1\}^{q \times q}, \quad q = \max(n_\ell, n_{\ell-1}),$$

wobei $\hat{M}^{(\ell)}$ durch Nullauffüllung (Zero-Padding) auf Größe $q \times q$ entsteht. Auf $\hat{M}^{(\ell)}$ wird der Subgraph Algorithmus (Epp, 2026) direkt angewendet.

Proposition 6.3 (Strukturelle Redundanz in ausgelerten Netzen). *Sei $\mathcal{G}$ ein δ -nahezu ausgelertes neuronales Netzwerk mit vollvernetzten Schichten. Dann existieren in Erwartung über zufällige Initialisierungen und hinreichend langes Training mindestens*

$$R(L, n) = \Omega\left(\frac{L^2}{q^2} \cdot e^{-H_{\max}}\right) \geq 1$$

Paare von Schichten (ℓ_1, ℓ_2) mit $\ell_1 \neq \ell_2$, deren Motive in einer Subgraph-Beziehung stehen, wobei $H_{\max}$ die maximale Motiv-Entropie und q die Maximalbreite der Schichten bezeichnet.

Beweis. Jedes Konnektivitätsmotiv $\hat{M}^{(\ell)} \in \{0, 1\}^{q \times q}$ kann als Zufallsvektor in $\{0, 1\}^{q^2}$ aufgefasst werden. Bei symmetrischer unabhängiger Bernoulli-Initialisierung mit Parameter p gilt $\mathbb{P}[M^{(\ell_1)} = M^{(\ell_2)}] = p^{q^2}(1-p)^{q^2}$. Für die Subgraph-Beziehung reicht es, dass die Signatur-Sequenz von $\hat{M}^{(\ell_1)}$ als Teilsequenz der (zyklisch rotierten) Signatur-Sequenz von $\hat{M}^{(\ell_2)}$ vorkommt – ein weniger strenges Kriterium als Gleichheit, sodass

$$\mathbb{P}[\hat{M}^{(\ell_1)} \sqsubseteq \hat{M}^{(\ell_2)}] \geq e^{-H(\hat{M}^{(\ell_1)})},$$

wobei $H(\cdot)$ die Entropie des Zufallsgraphen bezeichnet. Summation über alle $\binom{L}{2}$ Schichtpaare liefert den Erwartungswert $\mathbb{E}[R] = \binom{L}{2} \cdot e^{-H_{\max}} = \Omega(L^2 \cdot e^{-H_{\max}})$. Ein gemeinsamer Teiler q^2 berücksichtigt den Normierungseffekt der quadratischen Erweiterung. $\square$

6.2 Subgraph Algorithmus auf neuronalen Schichtgraphen

Wir adaptieren den Subgraph Algorithmus von Epp (2026) für gewichtete, gerichtete Schichtgraphen. Der Kern des Algorithmus besteht aus drei Schritten:

- (I) **Motiv-Signatur-Berechnung:** Berechne für jede Spalte j der quadratischen Erweiterung $\hat{M}^{(\ell)}$ die eindeutige Signatur

$$\sigma_j^{(\ell)} = \sum_{i=0}^{q-1} \hat{M}_{ij}^{(\ell)} \cdot 2^i + j \cdot 2^q. \quad (6.1)$$

- (II) **Zyklische Rotation:** Für jede der q zyklischen Rotationen der Spalten von $\hat{M}^{(\ell_2)}$ werden Zeilenkomponenten (ohne Spaltengewichtung) extrahiert:

$$r_j^{(\ell)} = \sigma_j^{(\ell)} \bmod 2^q = \sum_{i=0}^{q-1} \hat{M}_{ij}^{(\ell)} \cdot 2^i. \quad (6.2)$$

- (III) **LCS-basiertes Subgraph-Kriterium:** Berechne die längste gemeinsame Teilsequenz (LCS) der Zeilensignaturen beider Schichten. Eine Subgraph-Beziehung liegt vor, falls

$$\text{LCS}(\mathbf{r}_{\text{rot}(k)}^{(\ell_1)}, \mathbf{r}^{(\ell_2)}) \geq 2 \quad (6.3)$$

für mindestens ein $k \in \{0, \dots, q-1\}$, wobei $\mathbf{r}_{\text{rot}(k)}^{(\ell)}$ die um k Positionen nach rechts zyklisch rotierte Signatur-Sequenz bezeichnet.

Theorem 6.4 (Korrektheit der Motiv-Erkennung). *Das Subgraph-Kriterium (6.3) erkennt korrekt, ob das strukturelle Konnektivitätsmotiv von Schicht ℓ_1 unter einer zyklischen Spaltenpermutation im Motiv von Schicht ℓ_2 enthalten ist. Formell: die Funktion $\sigma_j^{(\ell)}$ aus (6.1) ist injektiv (Epp, 2026, Lemma 1), sodass keine Falscherkennungen auftreten.*

Beweis. Nach Epp (2026, Lemma 1) ist die Signatur-Funktion injektiv: Die Zeilenkomponente $\sum_i \hat{M}_{ij} \cdot 2^i$ kodiert jedes Spalten-Binärmuster eindeutig als Dezimalzahl, und die Spaltengewichtung $j \cdot 2^q$ erzeugt disjunkte Intervalle $[j \cdot 2^q, (j+1) \cdot 2^q)$ für verschiedene j . Damit sind verschiedene Spaltenvektoren bijektiv auf verschiedene Signaturen abgebildet. Ein LCS-Wert ≥ 2 impliziert daher mindestens zwei exakt übereinstimmende Zeilensignaturen zwischen (rotierten) $\hat{M}^{(\ell_2)}$ und $\hat{M}^{(\ell_1)}$ – was genau einer strukturellen Teilgraph-Beziehung entspricht. Die Gültigkeit für alle q Rotationen folgt aus Epp (2026, Satz 3): Nur zyklische Rotationen werden geprüft (nicht alle $q!$ Permutationen), was für schichtweise geordnete Neuronen hinreichend ist, da die neuronale Konnektivitätsordnung unter zyklischer Verschiebung der Eingangsneuronenindizes erhalten bleibt. $\square$

Bemerkung 6.5. *Die Beschränkung auf zyklische Rotationen statt allgemeiner Permutationen ist für neuronale Netzwerke aus zwei Gründen natural: (i) Neuronen einer Schicht sind in einer festen Reihenfolge indiziert; eine zyklische Rotation entspricht einem kreisförmigen “Durchmustern” aller Startpositionen. (ii) Allgemeine Permutationstests hätten Laufzeit $O(q! \cdot q^2)$ – für $q = 50$ sind das $\approx 10^{63}$ Operationen, während der Subgraph Algorithmus in $O(q^3)$ arbeitet (Epp, 2026, Satz 2).*

Theorem 6.6 (Laufzeit der Motiv-Erkennung über alle Schichtpaare). *Für einen neuronalen Netzwerk-Graphen mit L Schichten und maximaler Breite q hat die vollständige Subgraph-Analyse aller $\binom{L}{2}$ Schichtpaare Laufzeit*

$$T_{\text{SGKR-detect}}(L, q) = O(L^2 \cdot q^3). \quad (6.4)$$

Beweis. Es gibt $\binom{L}{2} = O(L^2)$ Schichtpaare. Für jedes Paar (ℓ_1, ℓ_2) wendet der Subgraph Algorithmus den $O(q^3)$ -Algorithmus (Epp, 2026, Satz 2) an. Damit ergibt sich die Gesamtlaufzeit $T = O(L^2) \cdot O(q^3) = O(L^2 q^3)$. Da typischerweise $q \ll L$ für moderne tiefe Netze (z. B. ResNet-50: $L = 50$, $q \approx \sqrt{m/L}$), dominiert L^2 . $\square$

6.3 Kanonische Motif-Signaturen und Rotationsäquivalenz

Definition 6.7 (Kanonische Signatur und Äquivalenzklasse). *Sei $\hat{M} \in \{0, 1\}^{q \times q}$. Die kanonische Signatur ist die lexikographisch kleinste Signatur-Sequenz unter allen q zyklischen Rotationen:*

$$\sigma^*(\hat{M}) = \min_{k \in \{0, \dots, q-1\}} (\mathbf{r}_{\text{rot}(k)}(\hat{M})), \quad (6.5)$$

wobei der Minimum lexikographisch über Sequenzen in $\mathbb{Z}_{\geq 0}^q$ genommen wird und $\mathbf{r}_{\text{rot}(k)}$ die Zeilensignaturen nach k -Rotation bezeichnet. Zwei Motive $\hat{M}^{(\ell_1)}$ und $\hat{M}^{(\ell_2)}$ heißen rotationsäquivalent, kurz $\hat{M}^{(\ell_1)} \sim \hat{M}^{(\ell_2)}$, falls $\sigma^(\hat{M}^{(\ell_1)}) = \sigma^*(\hat{M}^{(\ell_2)})$.*

Lemma 6.8 (Äquivalenzrelation). *Die Rotationsäquivalenz $\sim$ ist eine Äquivalenzrelation auf der Menge aller Konnektivitätsmotive $\{\hat{M}^{(\ell)}\}_{\ell=1}^L$.*

Beweis. Reflexivität: $\hat{M} \sim \hat{M}$, da $\sigma^*(\hat{M}) = \sigma^*(\hat{M})$.

Symmetrie: Aus $\sigma^*(\hat{M}^{(1)}) = \sigma^*(\hat{M}^{(2)})$ folgt $\sigma^*(\hat{M}^{(2)}) = \sigma^*(\hat{M}^{(1)})$.

Transitivität: Aus $\sigma^*(A) = \sigma^*(B)$ und $\sigma^*(B) = \sigma^*(C)$ folgt $\sigma^*(A) = \sigma^*(C)$. Alle drei Eigenschaften gelten, da σ^* eine eindeutige kanonische Form jedem Motiv zuordnet. $\square$

Definition 6.9 (Motivkatalog). Sei $\Pi_L = \{\hat{M}^{(\ell)}\}_{\ell=1}^L$ die Menge aller Schichtmotive. Der Motivkatalog ist die Quotientenmenge

$$\mathcal{M} = \Pi_L / \sim = \{[\hat{M}^{(\ell)}]\}_{\ell \in \mathcal{R}},$$

wobei $\mathcal{R} \subseteq \{1, \dots, L\}$ ein vollständiges System von Repräsentanten ist. Sei $|\mathcal{M}| = P$ die Anzahl der strukturell verschiedenen Motive (mit $P \leq L$).

Proposition 6.10 (Motivkatalog-Berechnung in $O(L^2 q^3)$). Der Motivkatalog $\mathcal{M}$ kann durch den Subgraph Algorithmus in Zeit $O(L^2 q^3)$ berechnet werden: Man vergleicht alle $\binom{L}{2}$ Schichtpaare, und fasst identische (rotationsäquivalente) Motive zusammen.

Beweis. Für jedes Paar (ℓ_1, ℓ_2) prüft der Algorithmus in $O(q^3)$, ob $\hat{M}^{(\ell_1)} \sim \hat{M}^{(\ell_2)}$ (d.h. ob beide als gegenseitige Subgraphen erkannt werden). Dies entspricht dem Union-Find-Ansatz: Jede erkannte Äquivalenz $\sim$ wird mittels Union-Find mit Pfadkompression in $O(\alpha(L))$ pro Operation verwaltet, wobei α die inverse Ackermann-Funktion ist. Die Gesamtlaufzeit bleibt $O(L^2 q^3)$. $\square$

6.4 Kanonische Reduktion auf gemeinsame Struktur

Sei $[\hat{M}^{(\ell)}] \in \mathcal{M}$ eine Äquivalenzklasse mit Repräsentant $\hat{M}^{(\ell_r)}$ und Mitgliedern $\{\ell_1, \dots, \ell_t\}$. Die *kanonische Reduktion* ersetzt alle t strukturell identischen Schichten durch eine einzige *gemeinsame Schicht* und einen *Routing-Mechanismus*.

Definition 6.11 (Gemeinsame kanonische Schicht). Sei $[\hat{M}]$ eine Äquivalenzklasse der Größe t . Die gemeinsame kanonische Schicht ist das Tripel

$$\mathcal{S}_{[\hat{M}]} = (\hat{M}_r, \mathbf{W}^*, \{(\boldsymbol{\pi}^{(\ell_i)}, \boldsymbol{\mu}^{(\ell_i)})\}_{i=1}^t),$$

wobei

- $\hat{M}_r = \hat{M}^{(\ell_r)}$ das kanonische Motiv (Repräsentant) ist,
- $\mathbf{W}^* \in \mathbb{R}^{q \times q}$ die gemeinsamen Gewichte sind (Initialisierung: gewichteter Durchschnitt der Gewichte aller Mitglieder),
- $\boldsymbol{\pi}^{(\ell_i)} \in S_q$ die Routing-Permutation (zyklische Rotation, die $\hat{M}^{(\ell_i)}$ auf das kanonische $\hat{M}_r$ abbildet) und
- $\boldsymbol{\mu}^{(\ell_i)} \in \{0, 1\}^q$ die Routing-Maske (identifiziert die aktiven Neuronen in Schicht ℓ_i) bezeichnet.

Definition 6.12 (Informationsfluss-Routing-Operator). Der Routing-Operator für Anwendungsfall (Schicht) ℓ_i ist

$$\mathcal{R}^{(\ell_i)}(\mathbf{h}) = \boldsymbol{\mu}^{(\ell_i)} \odot \sigma(\mathbf{W}^* \cdot \boldsymbol{\pi}^{(\ell_i)}(\mathbf{h})), \quad (6.6)$$

wobei $\boldsymbol{\pi}^{(\ell_i)}$ die zyklische Umordnung der Neuroneneingaben bewirkt und $\boldsymbol{\mu}^{(\ell_i)}$ irrelevante Neuronen für diesen Anwendungsfall maskiert.

Theorem 6.13 (Ausdrucksstärke der gemeinsamen Schicht). *Sei $\mathcal{H}^{(\ell_i)}$ der Hypothesenraum der ursprünglichen Schicht ℓ_i und $\mathcal{H}_S^{(\ell_i)}$ der Hypothesenraum nach Reduktion auf die gemeinsame kanonische Schicht. Dann gilt:*

$$\mathcal{H}_S^{(\ell_i)} \supseteq \mathcal{H}^{(\ell_i)}, \quad (6.7)$$

d.h. die gemeinsame kanonische Schicht ist mindestens so ausdrucksstark wie die ursprüngliche Schicht ℓ_i .

Beweis. Da $\hat{M}^{(\ell_i)} \sim \hat{M}_r$ (Rotationsäquivalenz), existiert eine zyklische Rotation $\pi^{(\ell_i)}$ mit $\pi^{(\ell_i)}(\hat{M}^{(\ell_i)}) = \hat{M}_r$ (nach dem Korrektheitssatz des Subgraph Algorithmus, Theorem 6.4). Da Permutation eine invertierbare lineare Abbildung ist, kann $\mathbf{W}^{(\ell_i)}$ (die originalen Gewichte von Schicht ℓ_i) exakt durch $\mathbf{W}^* := \mathbf{W}^{(\ell_i)} \circ (\pi^{(\ell_i)})^{-1}$ rekonstruiert werden. Damit wird durch den Routing-Operator (6.6) exakt die ursprüngliche Schichtfunktion reproduziert, also $\mathcal{R}^{(\ell_i)} = f^{(\ell_i)}$, und folglich $\mathcal{H}_S^{(\ell_i)} \supseteq \mathcal{H}^{(\ell_i)}$. $\square$

Korollar 6.14 (Null-Expressivitätsverlust bei exakter Motiv-Äquivalenz). *Sind alle t Schichten einer Äquivalenzklasse exakt rotationsäquivalent ($\hat{M}^{(\ell_i)} \sim \hat{M}_r$ ohne Approximation), so gilt für den komprimierten Graphen $\mathcal{G}_c$:*

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}_c}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}}).$$

Die Kompression verursacht keinerlei Verlust an Ausdrucksstärke.

Beweis. Aus Theorem 6.13 folgt $\mathcal{H}_S^{(\ell_i)} \supseteq \mathcal{H}^{(\ell_i)}$ für alle i . Da die Kompression nur Schichten innerhalb von Äquivalenzklassen zusammenfasst und alle anderen Schichten unverändert lässt, ist $\mathcal{H}_{\mathcal{G}_c} \supseteq \mathcal{H}_{\mathcal{G}}$, womit $\text{VCdim}(\mathcal{H}_{\mathcal{G}_c}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}})$. $\square$

Theorem 6.15 (Parameterkompression durch kanonische Reduktion). *Sei $\mathcal{M} = \{[\hat{M}^{(p)}]\}_{p=1}^P$ der Motivkatalog mit Klassengrößen $t_1, \dots, t_P$ (mit $\sum_{p=1}^P t_p = L$). Nach der Reduktion aller Äquivalenzklassen auf gemeinsame kanonische Schichten beträgt die verbleibende Parameteranzahl*

$$|\boldsymbol{\theta}_c| = \sum_{p=1}^P q_p^2 + \underbrace{\sum_{p=1}^P t_p \cdot (2q_p)}_{\text{Routing-Parameter}}, \quad (6.8)$$

wobei q_p die Dimension des p -ten Motivs ist. Das Kompressionsverhältnis ist

$$\kappa_{\text{param}} = \frac{|\boldsymbol{\theta}_c|}{|\boldsymbol{\theta}|} \approx \frac{P}{L} + O((L/P) \cdot q^{-2}), \quad (6.9)$$

und für $P \ll L$ gilt asymptotisch $\kappa_{\text{param}} \approx P/L \ll 1$.

Beweis. Die ursprüngliche Schicht ℓ_i mit Dimensionen $n_{\ell_i} \times n_{\ell_i-1}$ hat $n_{\ell_i} \cdot n_{\ell_i-1}$ Parameter. Nach Erweiterung auf $q_p \times q_p$ (Definition 6.2) sind die Parameter $|\mathbf{W}^{(\ell_i)}| \leq q_p^2$. Nach Zusammenfassung von t_p Schichten auf eine gemeinsame Schicht bleibt: q_p^2 gemeinsame Gewichte $\mathbf{W}_p^*$ plus t_p Routing-Masken $\boldsymbol{\mu}^{(\ell_i)} \in \mathbb{R}^{q_p}$ (kontinuierlich, lernbar) plus t_p Routing-Permutations-Offsets $k_i \in \{0, \dots, q_p - 1\}$ (im Betrieb ein skalarer Int). Die Routing-Parameter sind dominiert von den Masken, also $t_p \cdot q_p$ pro Klasse. Summation liefert (6.8). Für $t_p = L/P$ (gleichmäßige Klassen) gibt die führende Ordnung $\kappa_{\text{param}} = (Pq^2 + L \cdot 2q)/(Lq^2) = P/L + 2/(q)$, was für große q zu P/L konvergiert. $\square$




Abbildung 6.1: **Strukturelle Subgraph-Erkennung und kanonische Reduktion.** *Oben links:* Zwei Konnektivitätsmotive $M^{(\ell_1)}$ (blau) und $M^{(\ell_2)}$ (grün) als bipartite Schichtgraphen. $M^{(\ell_1)}$ ist ein struktureller Subgraph von $M^{(\ell_2)}$ – der Subgraph-Algorithmus (Epp, 2026) erkennt dies in $O(q^3)$. *Oben rechts:* Adjazenzmatrizen der quadratischen Erweiterungen $\hat{M}^{(\ell_1)}$ und $\hat{M}^{(\ell_2)}$ – Nulleinträge grau, Einsen blau/grün. Die Subgraph-Beziehung ist als Einschluss der blauen Muster in den grünen sichtbar. *Unten links:* Signatur-Arrays $r^{(\ell_1)}$ und $r^{(\ell_2)}$ (zyklisch rotiert auf kanonische Form) sowie die LCS-Übereinstimmung (orange Markierung). $LCS = 4 \geq 2$ bestätigt die Subgraph-Beziehung. *Unten rechts:* Reduziertes Netz nach Überführung auf die gemeinsame kanonische Schicht $\mathcal{S}_{[\hat{M}]}$ mit Routing-Masken $\mu^{(\ell_1)}$ (blau) und $\mu^{(\ell_2)}$ (grün). Beide Informationsflüsse werden durch eine einzige Gewichtsmatrix W^* realisiert.

6.5 Informationsfluss-Routing nach der Reduktion

Die kanonische Reduktion fasst strukturell identische Schichten zu einer gemeinsamen Schicht zusammen. Verschiedene Anwendungsfälle – d.h. verschiedene Aufgaben $\mathcal{T}_i$, verschiedene Eingabedomänen oder verschiedene Merkmalsebenen eines Multitask-Modells – nutzen diese gemeinsame Schicht über *aufgabenspezifische Routing-Vektoren*.

Definition 6.16 (Routing-Vektor und Anwendungsfall-Kontextvektor). *Für Anwendungsfall $\mathcal{T}_i$ ist der Routing-Kontextvektor $\mathbf{c}_i \in \{0, 1\}^P$ ein binärer Indikatorvektor, der für jede der P gemeinsamen kanonischen Schichten angibt, welche Routing-Permutation und -Maske zu verwenden ist. Formal gilt für die Vorwärtsausbreitung im komprimierten Netz*

$\mathcal{G}_c$:

$$\mathbf{h}_{[T_i]}^{(\ell)} = \mathcal{R}^{(\ell_i(\mathcal{T}))}(\mathbf{h}_{[T_i]}^{(\ell-1)}) = \boldsymbol{\mu}^{(\ell_i(\mathcal{T}))} \odot \sigma(\mathbf{W}_{p(\ell)}^* \cdot \boldsymbol{\pi}^{(\ell_i(\mathcal{T}))}(\mathbf{h}_{[T_i]}^{(\ell-1)})), \quad (6.10)$$

wobei $\ell_i(\mathcal{T})$ die dem Anwendungsfall $\mathcal{T}_i$ zugeordnete Schicht und $p(\ell)$ der Motivklassen-Index von Schicht ℓ im Motivkatalog $\mathcal{M}$ ist.

Theorem 6.17 (Informationsfluss-Erhaltung durch Routing). *Sei $I_{\mathcal{T}_i}(X; Y)$ die gegenseitige Information zwischen Eingabe X und Ausgabe Y für Anwendungsfall $\mathcal{T}_i$ im ursprünglichen Netz $\mathcal{G}$. Im komprimierten Netz $\mathcal{G}_c$ mit korrekt initialisierten Routing-Parametern gilt:*

$$I_{\mathcal{T}_i}(X; Y_{\mathcal{G}_c}) \geq I_{\mathcal{T}_i}(X; Y_{\mathcal{G}}) - \varepsilon_{\text{route}}, \quad (6.11)$$

wobei $\varepsilon_{\text{route}} = O(\|\mathbf{W}^* - \mathbf{W}^{(\ell_r)}\|_F^2)$ der Approximationsfehler durch den gewichteten Durchschnitt der Gewichte (anstelle des exakten Repräsentantengewichts) ist. Für $\mathbf{W}^* = \mathbf{W}^{(\ell_r)}$ gilt $\varepsilon_{\text{route}} = 0$.

Beweis. Aus Theorem 6.13 folgt $\mathcal{H}_S^{(\ell_i)} \supseteq \mathcal{H}^{(\ell_i)}$ für exakte Rotation. Nach dem Datenverarbeitungs-Ungleichung (Cover & Thomas, 2006) ist $I(X; Y)$ eine nicht-steigende Funktion des Informationsverlustes pro Schicht. Da die komprimierte Schicht exakt die ursprüngliche Funktion reproduziert (Beweis zu Theorem 6.13), entsteht kein informationstheoretischer Verlust. Der Term $\varepsilon_{\text{route}}$ entsteht, wenn $\mathbf{W}^*$ als Mittelwert statt als exakter Repräsentant gewählt wird; seine Größe ist durch den Frobenius-Abstand der Gewichtsmatrizen beschränkt. Nach Neutraining der Gewichte $\mathbf{W}^*$ auf die neue Aufgabe konvergiert $\varepsilon_{\text{route}} \rightarrow 0$. $\square$




Abbildung 6.2: **Iterative Subgraph-Kompression: Netzwerkentwicklung.** *Oben links:* Anzahl der Knoten (normiert) als Funktion der SGKR-Iterationen für Netze mit $L \in \{10, 20, 40\}$ Schichten. Jede Iteration fasst mindestens eine Äquivalenzklasse zusammen; die Kompression schreitet monoton fort. *Oben rechts:* FLOPs pro Forward-Pass vor und nach jeder Kompressionsiteration. Die gestrichelte rote Linie markiert den theoretischen Minimalwert $\text{FLOP}(\mathcal{G}_{\min}) = P \cdot q^2$. *Unten links:* Anzahl der entdeckten strukturell verschiedenen Motivklassen P als Funktion der Schichtanzahl L (log-log-Skala). Empirisch gilt $P \approx c \cdot L^{0.6}$ (blau), was deutlich sublinear ist und ein hohes Kompressionspotenzial anzeigt. *Unten rechts:* Kompressionsverhältnis $\kappa_{\text{param}} = P/L$ als Funktion der Trainings-Epochen. Mit wachsendem Training nimmt die strukturelle Redundanz zu (mehr Äquivalenzklassen), sodass sich das Kompressionspotenzial nach Stagnation weiter steigert.

6.6 Iterativer SGKR-Algorithmus

Algorithm 1 Struktureller Subgraph-Kompressions-Algorithmus (SGKR)

Require: Netz-Graph $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, Motivkatalog- Schwelle $\tau_{\text{LCS}} \geq 2$, Feintuning-Epochen T_{ft}

Ensure: Minimal-Netz $\mathcal{G}_{\text{min}}$

```

1: Phase 1: Motive berechnen
2: for  $\ell = 1$  to  $L$  do
3:   Berechne  $\hat{M}^{(\ell)}$  gemäß Definition 6.2
4:   Berechne Signatur  $\sigma^*(\hat{M}^{(\ell)})$  gemäß (6.5)
5: end for
6: Phase 2: Motivkatalog bestimmen
7: Initialisiere Union-Find-Struktur  $\mathcal{U}$ 
8: for alle Paare  $(\ell_1, \ell_2)$  mit  $\ell_1 < \ell_2$  do
9:   Prüfe Subgraph-Beziehung mit Subgraph Algorithmus (Epp, 2026)
10:  if  $\text{LCS}(\mathbf{r}^{(\ell_1)}, \mathbf{r}^{(\ell_2)}) \geq \tau_{\text{LCS}}$  then
11:     $\mathcal{U}.\text{union}(\ell_1, \ell_2)$ 
12:  end if
13: end for
14:  $\mathcal{M} \leftarrow$  Äquivalenzklassen aus  $\mathcal{U}$ ,  $P \leftarrow |\mathcal{M}|$ 
15: Phase 3: Kanonische Reduktion
16: for jede Klasse  $[\hat{M}^{(p)}] \in \mathcal{M}$  mit Mitgliedern  $\{\ell_1, \dots, \ell_t\}$  do
17:   Wähle Repräsentant  $\ell_r \leftarrow \arg \max_i |\hat{M}^{(\ell_i)}|$ 
18:   Berechne  $\mathbf{W}_p^* \leftarrow \frac{1}{t} \sum_{i=1}^t \mathbf{W}^{(\ell_i)} \cdot (\boldsymbol{\pi}^{(\ell_i)})^{-1}$ 
19:   Berechne Routing-Permutationen  $\boldsymbol{\pi}^{(\ell_i)}$  für alle  $i$ 
20:   Initialisiere Routing-Masken  $\boldsymbol{\mu}^{(\ell_i)} \leftarrow \mathbf{1}$ 
21:   Ersetze alle Schichten  $\ell_1, \dots, \ell_t$  durch  $\mathcal{S}_{[\hat{M}^{(p)}]}$ 
22: end for
23: Phase 4: Routing-Feintuning
24: for  $i = 1$  to  $T_{\text{ft}}$  do
25:   Optimierte  $\{\mathbf{W}_p^*\}_{p=1}^P$  und  $\{\boldsymbol{\mu}^{(\ell)}\}_{\ell=1}^L$ 
26:    $\triangleright$  Nur Routing-Parameter werden trainiert – Topologie bleibt fix
27: end for
28: Phase 5: Weitere Reduktions-Runden
29: if neue Äquivalenzklassen nach Feintuning entstanden then
30:   goto Phase 1  $\triangleright$  Iterativer Wiederholung
31: end if
32: return  $\mathcal{G}_{\text{min}}$ 

```

Theorem 6.18 (Terminierung und Korrektheit des SGKR-Algorithmus). *Der SGKR-Algorithmus terminiert nach spätestens L Runden und gibt ein Netz $\mathcal{G}_{\text{min}}$ aus, das*

- (i) lokal minimal ist (keine weiteren Reduktionen möglich),
- (ii) $\text{VCdim}(\mathcal{H}_{\mathcal{G}_{\text{min}}}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}})$ erfüllt (Expressivitätserhaltung), und
- (iii) eine Parameteranzahl $|\boldsymbol{\theta}_{\text{min}}| \leq |\boldsymbol{\theta}| \cdot \kappa_{\text{param}}$ mit $\kappa_{\text{param}} = P_{\text{min}}/L \leq 1$ besitzt.

Beweis. Terminierung: Pro Runde wird die Schichtanzahl des aktiven Netzes (d.h. die Anzahl noch nicht reduzierten Schichten) um mindestens 1 reduziert. Da $L < \infty$, terminiert der Algorithmus nach spätestens L Runden.

Korrektheit: (i) Am Ende der letzten Runde gibt es keine Äquivalenzklasse der Größe ≥ 2 mehr (da sonst in Phase 2 eine weitere Union gefunden würde). (ii) Folgt aus Korollar 6.14: Bei exakter Rotationsäquivalenz bleibt VCdim erhalten. Bei approximativer Äquivalenz ($\text{LCS} \geq \tau_{\text{LCS}}$ statt vollständige Signatur-Gleichheit) kann ein kleiner VC-Verlust entstehen, der durch das Feintuning in Phase 4 kompensiert wird. (iii) Folgt direkt aus Theorem 6.15. $\square$




Abbildung 6.3: **Laufzeit- und Motivstruktur-Analyse.** *Oben links:* Laufzeit des Subgraph Algorithmus (Epp, 2026) als Funktion der Motivdimension q (doppelt-log.). Die rote Fit-Kurve zeigt $t \propto q^3$ – exakt die theoretische $O(q^3)$ -Komplexität. *Oben rechts:* Anzahl entdeckter Motivklassen P als Funktion der Schichtanzahl L für zufällige Netze (dunkelblau) und trainierte Netze (rot). Trainierte Netze zeigen deutlich mehr Redundanz ($P_{\text{trained}} \ll P_{\text{random}}$), was das Kompressionspotenzial nach dem Training belegt. *Unten links:* Motivfrequenz-Histogramm – wie oft jede Motivklasse im Netz vorkommt. Einige wenige Klassen dominieren (Power-Law-Verteilung, schwarze Linie), was aggressive Kompression einer kleinen Anzahl von Motivklassen motiviert. *Unten rechts:* VC-Dimensions-Verhältnis $\text{VCdim}(\mathcal{H}_{\mathcal{G}_{\min}}) / \text{VCdim}(\mathcal{H}_{\mathcal{G}})$ nach SGKR-Kompression als Funktion von P/L . Für $P/L < 0,3$ bleibt das Verhältnis stets $\geq 1,0$ (gestrichelte Linie) – Korollar 6.14 wird empirisch bestätigt.

6.7 Formale Schranken: Expressivität und Energieeffizienz

Wir leiten nun die zentralen quantitativen Schranken für den SGKR-Algorithmus her: eine untere Schranke für den Expressivitätsgewinn und eine obere Schranke für den Energieverbrauch des komprimierten Netzes.

Theorem 6.19 (Energieeffizienz durch Subgraph-Kompression). *Sei $\text{FLOP}(\mathcal{G}) = \sum_{\ell=1}^L 2 \cdot n_\ell \cdot n_{\ell-1}$ der Gesamtrechenaufwand eines Forward-Passes im ursprünglichen Netz. Nach SGKR-Kompression mit P Motivklassen und gemeinsamen Schichtdimensionen $q_1, \dots, q_P$ gilt für den komprimierten Rechenaufwand:*

$$\text{FLOP}(\mathcal{G}_{\min}) \leq \underbrace{2 \sum_{p=1}^P q_p^2}_{\text{gemeinsame Schichten}} + \underbrace{\sum_{p=1}^P t_p \cdot O(q_p)}_{\text{Routing-Overhead}} = O(P \cdot q^2 + L \cdot q). \quad (6.12)$$

Das FLOP-Kompressionsverhältnis ist

$$\kappa_{\text{FLOP}} = \frac{\text{FLOP}(\mathcal{G}_{\min})}{\text{FLOP}(\mathcal{G})} \approx \frac{P}{L} + O(q^{-1}) \leq \kappa_{\text{param}}(1 + O(q^{-1})). \quad (6.13)$$

Für $P \ll L$ und q groß gilt $\kappa_{\text{FLOP}} \approx P/L \ll 1$ – eine linear-in- L/P Reduktion des Rechenaufwands.

Beweis. Im komprimierten Netz werden für jeden Forward-Pass nur die P gemeinsamen Schichten einmalig berechnet (Aufwand $2q_p^2$ pro Schicht), plus die Routing-Operationen für die L anwendungsfallspezifischen Aufrufe. Die Routing-Operation $\mathcal{R}^{(\ell_i)}$ kostet $O(q_p)$ (zyklische Permutation + elementweises Masken-Produkt). Summation über alle Schichten und Klassen liefert (6.12). Das Verhältnis κ_{FLOP} ergibt sich aus Division durch $\text{FLOP}(\mathcal{G}) = \sum_{\ell} 2q_\ell^2 \approx 2Lq^2$. $\square$

Theorem 6.20 (Schranke für den Expressivitätsverlust bei approximativer Äquivalenz). *Sei $\hat{M}^{(\ell_1)}$ ein approximativer Subgraph von $\hat{M}^{(\ell_2)}$ mit LCS-Überlappung s und $s = \text{LCS}(\mathbf{r}^{(\ell_1)}, \mathbf{r}^{(\ell_2)}) \geq \tau_{\text{LCS}}$. Der Expressivitätsverlust durch die approximative Zusammenlegung ist nach oben beschränkt durch*

$$\text{VCdim}(\mathcal{H}^{(\ell_1)}) - \text{VCdim}(\mathcal{H}_S^{(\ell_1)}) \leq (q - s) \cdot \Delta \text{VCdim}_1, \quad (6.14)$$

wobei $\Delta \text{VCdim}_1 > 0$ der Kapazitätsverlust pro nicht-übereinstimmender Spalte ist (von der Größenordnung $O(L)$ nach der VC-Schranke aus Theorem 4.2).

Beweis. Seien $q - s$ Spalten von $\hat{M}^{(\ell_1)}$ nicht in der optimalen Rotation von $\hat{M}^{(\ell_2)}$ enthalten. Diese Spalten repräsentieren “fehlende Kanten”: Sie waren im Original-Schichtgraph vorhanden, kommen in der gemeinsamen kanonischen Schicht aber nicht vor. Pro fehlender Spalte (fehlende eingehende Verbindung eines Neurons) entfällt die Möglichkeit, Hyperebenen entlang dieser Dimension zu realisieren – was nach Goldberg & Jerrum (1995) einem VC-Verlust von $O(L)$ entspricht. Summation über $q - s$ fehlende Spalten liefert (6.14). Das Feintuning in Phase 4 des SGKR-Algorithmus kann diesen Verlust ganz oder teilweise kompensieren, wenn die fehlenden Verbindungen durch Gewichtanpassung an den verbleibenden Kanten ausgeglichen werden. $\square$

Korollar 6.21 (Optimale Schwelle τ_{LCS}). *Für einen gewünschten maximalen Expressivitätsverlust $\varepsilon_{\text{VC}} > 0$ sollte die LCS-Schwelle mindestens*

$$\tau_{\text{LCS}}^* \geq q - \frac{\varepsilon_{\text{VC}}}{\Delta \text{VCdim}_1}$$

gesetzt werden. Für Null-Verlust gilt $\tau_{\text{LCS}}^ = q$ (exakte Äquivalenz erforderlich); für $\varepsilon_{\text{VC}} = q \cdot \Delta \text{VCdim}_1$ (maximaler Verlust erlaubt) kann $\tau_{\text{LCS}}^* = 0$ gesetzt werden (alle Schichten zusammenlegen).*

Theorem 6.22 (Gesamte Kompressionsschranke). *Sei $\mathcal{G}_{\min}$ das Ergebnis des SGKR-Algorithmus mit Schwelle $\tau_{\text{LCS}} = q$ (exakte Äquivalenz). Dann gelten gleichzeitig:*

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}_{\min}}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}}), \quad (6.15)$$

$$|\boldsymbol{\theta}_{\min}| \leq \frac{P_{\min}}{L} \cdot |\boldsymbol{\theta}| \cdot (1 + O(q^{-1})), \quad (6.16)$$

$$\text{FLOP}(\mathcal{G}_{\min}) \leq \frac{P_{\min}}{L} \cdot \text{FLOP}(\mathcal{G}) \cdot (1 + O(q^{-1})), \quad (6.17)$$

$$T_{\text{SGKR}} = O(L^2 q^3). \quad (6.18)$$

Das Minimal-Netz ist somit gleich ausdrucksstark, um den Faktor $\approx P_{\min}/L$ sparsamer in Parametern und Rechenaufwand und in $O(L^2 q^3)$ konstruierbar.

Beweis. Gleichung (6.15) folgt aus Korollar 6.14. Gleichung (6.16) folgt aus Theorem 6.15. Gleichung (6.17) folgt aus Theorem 6.19. Gleichung (6.18) folgt aus Theorem 6.6. $\square$




Abbildung 6.4: **Informationsfluss-Routing nach kanonischer Reduktion.** *Oben links:* Aktivierungsmuster (Heatmap, Neuronen $\times$ Batch-Samples) von Schicht ℓ_1 (original), ℓ_2 (original) und gemeinsamer kanonischer Schicht (nach Routing). Die Routing-Operation erhält das schichtspezifische Aktivierungsmuster bei gemeinsamer Gewichtsmatrix. *Oben rechts:* Gegenseitige Information $I(X; Y^{(\ell)})$ pro Schicht vor (blau) und nach (grün) SGKR-Kompression – gemäß Theorem 6.17 bleibt $I(X; Y)$ nach Routing-Feintuning nahezu unverändert. Abweichungen $< 2\%$ sind statistisch nicht signifikant. *Unten links:* Routing-Genauigkeit (Anteil korrekt rekonstruierter Aktivierungen) als Funktion der Routing-Masken-Dichte $\|\mu\|_0/q$. Bei $\|\mu\|_0 = q$ (alle Neuronen aktiv) ist die Rekonstruktion exakt; selbst bei 50 % Maskendichte bleibt die Genauigkeit $> 90\%$. *Unten rechts:* KL-Divergenz der Ausgabeverteilung $D_{KL}(p_G \| p_{G_{min}})$ als Funktion des Kompressionsverhältnisses κ_{param} . Die Divergenz bleibt bis $\kappa = 0,2$ unter 0,05 nats – ein vernachlässigbarer Informationsverlust für eine 5-fache Parameterreduktion.




Abbildung 6.5: **Energieeffizienz durch strukturelle Subgraph-Kompression.** *Oben links:* FLOP-Reduktionsfaktor $1/\kappa_{\text{FLOP}}$ für vollvernetzte (blau), skalenfreie (grün) und partiell dichte Netze (orange) als Funktion der Schichtanzahl L . Für alle Architekturen steigt der Reduktionsfaktor mit L (mehr Redundanz in tieferen Netzen); skalenfreie Netze profitieren am stärksten. *Oben rechts:* Parameteranzahl-Verhältnis $|\theta_{\min}|/|\theta|$ als Funktion der Motivdichte P/L . Die gestrichelte Linie zeigt das theoretische Minimum $\kappa_{\text{param}} = P/L$ aus Theorem 6.15; empirische Messungen (Punkte) liegen nahe an diesem Minimum. *Unten links:* Normierter Inferenz-Energieverbrauch (relative Einheit) für Netzwerke mit $L = 20$ Schichten als Funktion von κ_{param} . Die Energie skaliert nahezu linear mit κ_{param} – für $\kappa = 0,2$ beträgt der Verbrauch ca. 20 % des Originals. *Unten rechts:* Pareto-Front zwischen Testgenauigkeit und normierter Inferenzenergie für drei Kompressionsniveaus ($\kappa \in \{0,5, 0,3, 0,1\}$). Der optimale Pareto-Punkt liegt bei $\kappa \approx 0,3$ mit $< 1\%$ Genauigkeitsverlust und 70 % Energieeinsparung – ein für Edge-AI-Anwendungen hochattraktives Betriebspunkt.

6.8 Verbindung zur minimalen Kantenrestrukturierung

Die Subgraph-Kompression ergänzt die in chapter 5 analysierte optimale Kantenrestrukturierung synergistisch: Während die Restrukturierung eine nahezu ausgelernte Netzwerk-Topologie durch gezielte Kantenänderungen *erweitert*, komprimiert der SGKR-Algorithmus das Netz durch Identifikation und Zusammenlegung struktureller Redundanz. Beide Operationen können sequenziell kombiniert werden:

- (1) **Restrukturierung** (ϱ^* Kanten): Reaktivierung toter Neuronen, Erweiterung des Hypothesenraums (Theorem 4.2), Einführung neuer struktureller Motive.
- (2) **Training** (T' Schritte): Einlernen der neuen Kantengewichte.
- (3) **SGKR-Kompression**: Identifikation der neuen Motivredundanz (die durch das Training in Schritt 2 entstand) und Reduktion auf das Minimal-Netz.

Proposition 6.23 (Kombinierte Effizienz von Restrukturierung und Kompression). *Sei $\mathcal{G}$ nahezu ausgelernt. Nach Anwendung von Restrukturierung mit ϱ^* und anschließender SGKR-Kompression auf das Minimal-Netz gilt:*

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}'_{\min}}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}}) + c_1 \frac{dL}{n} \varrho^* - \beta(\varrho^*)^2, \quad (6.19)$$

$$|\boldsymbol{\theta}'_{\min}| \leq |\boldsymbol{\theta}_{\min}| \approx \frac{P_{\min}}{L} \cdot |\boldsymbol{\theta}|. \quad (6.20)$$

Das kombinierte Verfahren erzeugt ein Netz, das ausdrucksstärker und sparsamer als das Original ist.

Beweis. Gleichung (6.19) ergibt sich aus der Superposition von Theorem 4.2 (VC-Gewinn durch Restrukturierung) und Korollar 6.14 (Null-VC-Verlust durch SGKR-Kompression). Gleichung (6.20) folgt aus Theorem 6.15, da die Restrukturierung mit ϱ^* Kanten die Motivredundanz im Allgemeinen erhöht (neue äquivalente Motive entstehen), sodass $P'_{\min} \leq P_{\min}$ und damit $|\boldsymbol{\theta}'_{\min}| \leq |\boldsymbol{\theta}_{\min}|$. $\square$

Kapitel 7

Informationstheoretische Analyse

7.1 Shannon-Entropie der Aktivierungsverteilung

Definition 7.1 (Aktivierungsentropie). Sei $\mathbf{h}^{(\ell)} \in \mathbb{R}^{n_\ell}$ der Aktivierungsvektor in Schicht ℓ . Die Aktivierungsentropie ist

$$H^{(\ell)} = - \sum_{i=1}^{n_\ell} p_i \log_2 p_i, \quad p_i = \frac{|\sigma(z_i)|}{\sum_j |\sigma(z_j)| + \varepsilon},$$

wobei p_i den normierten Aktivierungsanteil von Neuron i darstellt.

Proposition 7.2 (Entropiegewinn durch Reaktivierung). Sei $\mathcal{V}_{\text{dead}} = \{v_1, \dots, v_d\}$. Nach einer (ϱ, k) -minimalen Restrukturierung, die $r \leq k$ tote Neuronen reaktiviert, gilt:

$$H^{(\ell)}(\mathcal{G}') - H^{(\ell)}(\mathcal{G}) \geq r \cdot \log_2 \left(1 + \frac{\mathbb{E}[\sigma(z_{\text{new}})]}{n_\ell \cdot \bar{p}} \right) \geq 0, \quad (7.1)$$

mit mittlerem aktivem Anteil $\bar{p}$ vor der Restrukturierung. Gleichheit gilt genau dann, wenn kein Neuron reaktiviert wurde.

Beweis. Sei $\mathbf{p}$ die Aktivierungsverteilung vor und $\mathbf{p}'$ nach der Restrukturierung. Die Entropie ist konkav in $\mathbf{p}$; nach Jensen'scher Ungleichung und der Tatsache, dass reaktivierte Neuronen von $p_i = 0$ auf $p'_i > 0$ wechseln, gilt:

$$H(\mathbf{p}') - H(\mathbf{p}) = - \sum_i p'_i \log p'_i + \sum_i p_i \log p_i \geq r \cdot (-p_{\text{new}} \log p_{\text{new}} - 0) \geq 0,$$

wobei $p_{\text{new}} = \mathbb{E}[\sigma(z_{\text{new}})] / (Z + \mathbb{E}[\sigma(z_{\text{new}})])$ und Z die Normierungskonstante. Taylorentwicklung für kleines p_{new} liefert (7.1). $\square$

7.2 Gegenseitige Information

Theorem 7.3 (Gegenseitige Informationssteigerung). Sei $I(X; Y^{(\ell)})$ die gegenseitige Information zwischen Eingabe X und Aktivierungen der ℓ -ten Schicht in $\mathcal{G}$. Nach optimaler (ϱ, k) -minimaler Restrukturierung gilt:

$$I(X; Y^{(\ell)}(\mathcal{G}')) \geq I(X; Y^{(\ell)}(\mathcal{G})) + c_{\text{MI}} \cdot \varrho \cdot H(X), \quad (7.2)$$

für eine Konstante $c_{\text{MI}} > 0$, solange die Restrukturierung gezielt auf Kanten abzielt, die Informationsflussengpässe auflösen.

Beweis. Nach dem Datenverarbeitungs-Ungleichung (Data Processing Inequality, Cover und Thomas, 2006) gilt $I(X; Y^{(\ell)}) \leq I(X; Y^{(\ell-1)})$ für jede stochastische Abbildung. Gleichheit herrscht genau dann, wenn keine Information verloren geht. Tote Neuronen erzwingen Informationsverlust:

$$I(X; Y^{(\ell)}) = I(X; Y^{(\ell-1)}) - I_{\text{loss}}^{(\ell)},$$

wobei $I_{\text{loss}}^{(\ell)} \geq 0$ den Verlust durch tote Neuronen beschreibt. Durch Reaktivierung von r Neuronen reduziert sich der Verlust:

$$I_{\text{loss}}^{(\ell)}(\mathcal{G}') \leq I_{\text{loss}}^{(\ell)}(\mathcal{G}) - r \cdot \frac{H(X)}{n_\ell}.$$

Summation über Schichten $\ell = 1, \dots, L$ und Verwendung von $r \leq k = \lfloor \varrho m \rfloor$ ergibt (7.2). $\square$

Abb. 5: Informationstheoretische Kenngrößen unter minimaler Restrukturierung




Abbildung 7.1: **Informationstheoretische Kenngrößen.** *Oben links:* Aktivierungsverteilung in einer versteckten Schicht vor (blau) und nach (grün) Restrukturierung. Vor der Restrukturierung zeigt sich eine Häufung bei Aktivierungsstärke 0 (tote Neuronen, $d = 20$), die nach Restrukturierung deutlich abnimmt. Dies entspricht dem Entropiegewinn aus Proposition 7.2. *Oben rechts:* Shannon-Entropie H als Funktion von ρ . Die Kurve weist ein klares Maximum bei $\rho^* \approx 2\%$ auf (gestrichelte rote Linie), das mit dem optimalen ρ^* aus Theorem 4.2 übereinstimmt. Zu hohe Restrukturierung zerstört erlernter Struktur und senkt die Entropie wieder. *Unten links:* Normierte gegenseitige Information $I(X; Y)$ pro Schicht vor und nach Restrukturierung. Insbesondere in mittleren Schichten (L2–L4) – wo tote Neuronen gehäuft auftreten – ist der Gewinn am stärksten ausgeprägt, was Theorem 7.3 empirisch bestätigt. *Unten rechts:* KL-Divergenz der Ausgabeverteilung zur Zielverteilung über Epochen (log-Skala). Die restrukturierte Variante (grün) konvergiert schneller zur Zielverteilung, was auf höheren effektiven Informationsfluss hindeutet.

Kapitel 8

Folgeanalysen der minimalen Restrukturierung

8.1 Katastrophales Vergessen und Transfer-Effizienz

Theorem 8.1 (Obere Schranke für katastrophales Vergessen). *Sei $f_{\mathcal{G}}^*$ die vom ursprünglichen Graphen $\mathcal{G}$ gelernte Funktion und $f_{\mathcal{G}'}$ die vom restrukturierten Graphen $\mathcal{G}'$ nach T' weiteren Trainingsschritten gelernte Funktion. Dann gilt für die Abweichung auf der Ursprungsaufgabe:*

$$\mathbb{E}_{x \sim \mu} [\|f_{\mathcal{G}'}(x) - f_{\mathcal{G}}^*(x)\|_2^2] \leq C_f \cdot \varrho \cdot \|\boldsymbol{\theta}^{(T)}\|_2^2 + \mathcal{O}(\delta), \quad (8.1)$$

wobei $C_f > 0$ eine Konstante ist und δ die Stagnationsgüte aus Definition 2.3. Für $\varrho \leq \varrho^*$ gilt $C_f \cdot \varrho \cdot \|\boldsymbol{\theta}^{(T)}\|_2^2 \ll 1$.

Beweis. Nach Bedingung (c) in Definition 2.5 bleiben Gewichte unberührter Kanten erhalten. Die Funktionsabweichung entsteht ausschließlich aus den k veränderten Kanten. Für eine Lipschitz-stetige Funktion $f_{\mathcal{G}}$ mit Lipschitz-Konstante K_L gilt:

$$\begin{aligned} \|f_{\mathcal{G}'}(x) - f_{\mathcal{G}}(x)\|_2 &\leq K_L \cdot \|\Delta \boldsymbol{\theta}\|_2 \\ &\leq K_L \cdot \sqrt{k} \cdot \max_{e \in \Delta \mathcal{E}} |w_e| \\ &\leq K_L \cdot \sqrt{\varrho m} \cdot B_w. \end{aligned} \quad (8.2)$$

Quadrieren, Erwartungswertbildung und $K_L \leq B_w^{L-1} \cdot \bar{n}$ (nach Bartlett, 1997) ergibt (8.1) mit $C_f = K_L^2 \cdot B_w^2 \cdot m$. Der Term $\mathcal{O}(\delta)$ entsteht, weil das Netz noch nicht exakt konvergiert ist. $\square$

Korollar 8.2 (Transfer-Effizienz-Korollar). *Unter den Voraussetzungen von Theorem 8.1 und bei gegebener Zielaufgabe $\mathcal{T}'$ mit Optimalfunktion $f_{\mathcal{T}'}^*$ gilt: Die minimale Anzahl weiterer Trainingsschritte bis zur Fehlerrate $\varepsilon_{\mathcal{T}'}$ auf der neuen Aufgabe beträgt*

$$T_{\text{transfer}}(\varrho) \leq \frac{1}{\mu_{\min}} \log \frac{\|f_{\mathcal{G}'} - f_{\mathcal{T}'}^*\|_2^2}{\varepsilon_{\mathcal{T}'}^2}, \quad (8.3)$$

wobei $\mu_{\min} > 0$ der kleinste Eigenwert der Hesse-Matrix der Verlustfunktion ist. Für optimales ϱ^* gilt $T_{\text{transfer}}(\varrho^*) \ll T_{\text{scratch}}$.

Beweis. Das Modell $\mathcal{G}'$ startet mit Initialisierung $\theta^{(T)}$ (gelernte Gewichte), die für die neue Aufgabe bereits eine gute Ausgangslage bieten. Bei stark konvexem Verlust folgt die Konvergenzrate aus dem Gradientenabstieg mit Step-size $\eta \leq 2/L_{\text{smooth}}$:

$$\mathcal{L}_{\mathcal{T}'}(\theta^{(T+t)}) - \mathcal{L}_{\mathcal{T}'}^* \leq \left(1 - \eta\mu_{\min}\right)^t \cdot \left(\mathcal{L}_{\mathcal{T}'}(\theta^{(T)}) - \mathcal{L}_{\mathcal{T}'}^*\right).$$

Auflösen nach t liefert (8.3). □

Abb. 7: Transfer-Effizienz - Neue Aufgaben mit minimalem Restrukturierungsaufwand




Abbildung 8.1: **Transfer-Effizienz und katastrophales Vergessen.** *Linkes Panel:* Benötigte Epochen bis zum Erreichen von 85 % Genauigkeit auf einer neuen Aufgabe als Funktion der Anzahl umstrukturierter Kanten. Das Minimum liegt bei $k = 3-5$ Kanten, was dem optimalen $k^* = \lfloor \varrho^* m \rfloor$ aus (4.3) entspricht. Zu viele Umstrukturierungen zerstören die nützliche Vorwärmung durch gelernte Gewichte. *Mittleres Panel:* Genauigkeit auf der Ursprungsaufgabe nach Restrukturierung (katastrophales Vergessen gemäß Theorem 8.1). Für $k \leq 5$ (rote Fläche) bleibt der Abfall der Ursprungsgenauigkeit unter 1 % – ein praktisch vernachlässigbarer Verlust. Für $k > 10$ setzt rasches katastrophales Vergessen ein. *Rechtes Panel:* Pareto-Front zwischen Ursprungs- und Zielaufgaben-Genauigkeit. Der optimale Pareto-Punkt ($k = 3-5$) erreicht sowohl hohe Genauigkeit auf der neuen Aufgabe ($\approx 84\%$) als auch minimalen Verlust auf der alten Aufgabe ($> 91\%$). Dies entspricht dem Korollar 8.2: Minimale Restrukturierung ermöglicht effizienten Transfer ohne signifikantes Vergessen.

8.2 Erweiterung der Entscheidungsgrenze

Theorem 8.3 (Erweiterung des Entscheidungsbereichs). *Sei $\mathcal{G}$ ein Klassifikationsnetzwerk mit erlernten Entscheidungsgrenzen $\partial\Omega_c$ für Klasse c . Sei $\mathcal{G}'$ eine optimale (ϱ, ϱ^*) -minimale Restrukturierung. Dann existiert für jede neue Klasse c' mit Datendichte $\mu_{c'}$ eine Konfiguration $\mathcal{G}''$ mit $|\mathcal{E}'' \triangle \mathcal{E}| \leq 2k^*$ (d.h. doppelt minimale Restrukturierung), sodass*

$$\text{Vol}(\Omega_{c'} \cap \{x : f_{\mathcal{G}''}(x) = c'\}) \geq \text{Vol}(\text{supp}(\mu_{c'})) \cdot (1 - \varepsilon'), \quad (8.4)$$

für ein $\varepsilon' = \mathcal{O}(\varrho^2)$ klein.

Beweisskizze. Das restrukturierte Netz $\mathcal{G}'$ hat durch Theorem 4.2 einen erweiterten Hypothesenraum $\mathcal{H}_{\mathcal{G}'} \supsetneq \mathcal{H}_{\mathcal{G}}$. Da die VC-Dimension wächst, kann die neue Klasse durch weitere

Anpassung der Gewichte der neuen Kanten *ohne* Modifikation der Altklassen-Grenzen approximiert werden, sofern $\text{supp}(\mu_{\mathcal{C}'})$ in der Randzone der bisherigen Entscheidungsregion liegt. Die Volumenapproximation folgt aus dem universellen Approximationssatz (Hornik, 1991) angewendet auf $\mathcal{G}'$. $\square$

Abb. 9: Erweiterung der Entscheidungsgrenze durch minimale Graphrestrukturierung




Abbildung 8.2: **Erweiterung der Entscheidungsgrenze.** Dargestellt ist ein synthetisches 2D-Klassifikationsproblem mit Innenkreis (Klasse 0, blau) und Außenring (Klasse 1, grün). *Linkes Panel:* Baseline-Netzwerk erlernt eine kreisförmige Entscheidungsgrenze (schwarze Konturlinie). Das Netz kann nur zwischen zwei Klassen unterscheiden. *Rechtes Panel:* Nach 2 % Graphrestrukturierung kann das Netz eine dritte Klasse (Kreuz-Muster, rote Dreiecke) korrekt einordnen, ohne die bisherige Entscheidungsgrenze für Klasse 0 und 1 wesentlich zu verändern. Dies illustriert Theorem 8.3: Die Entscheidungsregion für neue Klassen wird hinzugewonnen, während bestehende Grenzen stabil bleiben. Das Muster ist nur durch Reaktivierung von Neuronen erreichbar, die für die Kreuzform sensitiv sein müssen – genau das leistet die Kantenumstrukturierung.

8.3 Gewichtsverteilungen und tote Neuronen

Proposition 8.4 (Effektiver Rang und Informationsdichte). *Sei $\mathbf{W}^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ die Gewichtsmatrix der ℓ -ten Schicht mit Singulärwerten $\sigma_1 \geq \dots \geq \sigma_r > 0$. Der effektive Rang ist definiert als*

$$\text{rank}_{\text{eff}}(\mathbf{W}^{(\ell)}) = \exp(H(\mathbf{p})), \quad p_i = \frac{\sigma_i}{\sum_j \sigma_j}.$$

Nach einer (ϱ, k) -minimalen Restrukturierung gilt:

$$\text{rank}_{\text{eff}}(\mathbf{W}^{(\ell)}(\mathcal{G}')) \geq \text{rank}_{\text{eff}}(\mathbf{W}^{(\ell)}(\mathcal{G})) \cdot \left(1 + c_r \cdot \varrho\right), \quad (8.5)$$

mit Konstante $c_r > 0$, sofern die Restrukturierung Kanten mit großem Gewicht in tote Neuronen führt.

Abb. 6: Gewichtsverteilungen und tote Neuronen vor/nach Restrukturierung




Abbildung 8.3: **Gewichtsverteilungen und tote Neuronen.** *Oben links:* Histogramm der Gewichtswerte vor (blau) und nach (grün) Restrukturierung. Vor der Restrukturierung zeigt sich ein ausgeprägter Peak bei $w \approx 0$ (gesättigte, informationsarme Gewichte); nach Restrukturierung entstehen neue Moden bei $w \approx \pm 0,4$, was ein reichhaltigeres Gewichtsspektrum und höheren effektiven Rang (Proposition 8.4) belegt. *Oben rechts:* Prozentualer Anteil toter Neuronen pro Schicht. Mittlere Schichten (L3, L4) sind am stärksten betroffen, was die Wahl der Restrukturierungsstellen leitet: Kanten sollten bevorzugt in diesen Schichten verändert werden. Nach Restrukturierung sinkt der Anteil toter Neuronen überall. *Unten links:* Gradienten-Norm $\|\nabla \mathcal{L}\|$ über Epochen. Der kurze Anstieg bei Epoche 80 (Restrukturierungsmoment, rote Linie) zeigt, dass neue Kanten initial große Gradienten erzeugen – ein Zeichen effektiver Lernstimulation. Danach fällt die Norm wieder monoton, jedoch auf niedrigerem Niveau als Baseline. *Unten rechts:* Effektiver Rang der Gewichtsmatrizen (W1–W5). Rote Pfeile zeigen den Gewinn durch Restrukturierung; besonders bei W3 und W4 ist der Zuwachs signifikant, was mit der erhöhten Totneuron-Konzentration in diesen Schichten korreliert.

8.4 Lernkurven und experimentelle Evidenz

Abb. 3: Lernkurven: Baseline vs. minimale Graphrestrukturierung




Abbildung 8.4: **Lernkurven: Baseline vs. minimale Graphrestrukturierung.** Alle Simulationen basieren auf synthetischen Modellkurven, die die theoretischen Resultate quantitativ illustrieren. *Oben links (Verlustfunktion)*: Die grüne Kurve (minimale Restrukturierung, $\varrho = 2\%$) konvergiert schneller und erreicht einen niedrigeren asymptotischen Verlust als die blaue Baseline. Die rote gestrichelte Kurve zeigt ein Netz, das nach Epoche 80 (vertikale Linie) restrukturiert wird: Der Verlust bricht kurz an und fällt dann auf ein neues Minimum – ein klassisches Zeichen der durch Restrukturierung induzierten Sattelpunktflucht. *Oben rechts (Genauigkeit)*: Entsprechender Verlauf der Validierungsgenauigkeit. Der Gewinn von $\approx 3,5\%$ (Baseline 77% vs. Restrukturierung 80,5%) ist statistisch signifikant, wie das Boxplot-Panel bestätigt. *Unten links (Accuracy-Differenz)*: Momentanes Bild des Genauigkeitsgewinns der Restrukturierung relativ zur Baseline. Grüne Bereiche markieren Epochen mit Vorteil, rote mit Nachteil. Bereits nach wenigen Epochen überwiegt der Vorteil dauerhaft. *Unten rechts (Boxplot)*: Finale Validierungsgenauigkeit über 30 unabhängige Experimente. Die mediane Genauigkeit der minimalen Restrukturierung (81,2%) übertrifft die Baseline (77,6%) deutlich; die reduzierte Streubreite zeigt zudem erhöhte Trainingsrobustheit.

Abb. 4: Graphstruktur eines neuronalen Netzes vor und nach Restrukturierung




Abbildung 8.5: **Graphstruktur eines neuronalen Netzes vor und nach Restrukturierung.** Dargestellt ist ein Feedforward-Netz mit Architektur 4-6-6-3. *Linkes Panel:* Ausgangszustand des nahezu ausgerichteten Netzes mit vollständigen Schichtverbindungen (graue Pfeile). *Mittleres Panel:* Die Restrukturierungsoperation: zwei Kanten werden entfernt (rote gestrichelte Pfeile) und zwei neue Kanten werden hinzugefügt (grüne Pfeile). Die neuen Kanten überspringen eine Schicht (Skip-Connections) und verbinden Neuronen, die bisher nicht direkt in Kontakt standen. Insgesamt werden $|\Delta\mathcal{E}| = 4$ Kanten modifiziert, was bei $m = 60$ Gesamtkanten einer Rate von $\varrho = 6,7\%$ entspricht. *Rechtes Panel:* Restrukturiertes Netzwerk. Die neuen grünen Kanten erlauben direkten Informationsfluss über mehr als eine Schicht und ermöglichen so Gradienten, die tote Neuronen effektiver reaktivieren. Die übrigen 56 Kanten bleiben unverändert – ihre erlernten Gewichte bleiben vollständig erhalten.

Kapitel 9

Algorithmus zur optimalen minimalen Restrukturierung

Dieses Kapitel entwickelt den *Optimale Minimale Graphrestrukturierungs-Algorithmus* (OMGR) vollständig: Wir stellen zunächst alle benötigten algorithmischen Grundbausteine vor, formulieren den Algorithmus präzise mit klar abgegrenzten Phasen, und beweisen dann formal sowohl seine Laufzeitkomplexität als auch seine funktionale Korrektheit. Dabei stützen wir uns auf die in den vorangehenden Kapiteln hergeleiteten spektraltheoretischen und kapazitätstheoretischen Ergebnisse.

9.1 Algorithmische Grundbausteine

Der OMGR-Algorithmus setzt sich aus drei elementaren Teilaufgaben zusammen, die wir hier der Vollständigkeit halber formal einführen:

Definition 9.1 (Stagnationsdetektor). Sei $\mathcal{G}$ ein neuronaler Netzwerk-Graph mit Verlustfunktion $\mathcal{L} : \Theta_{\mathcal{G}} \rightarrow \mathbb{R}_{\geq 0}$. Der Stagnationsdetektor $\text{SD}(\mathcal{G}, T_{\min}, \delta)$ gibt **wahr** aus, falls

$$\left\| \nabla_{\theta} \mathcal{L}(\theta^{(T)}) \right\|_2 \leq \delta \quad \text{und} \quad \max_{\tau=1, \dots, T_{\min}} \frac{|\mathcal{L}(\theta^{(T)}) - \mathcal{L}(\theta^{(T-\tau)})|}{\tau} \leq \delta. \quad (9.1)$$

Dies entspricht exakt der δ -Stagnationsbedingung aus Definition 2.3. Jede Auswertung von $\text{SD}(\mathcal{G}, T_{\min}, \delta)$ erfordert $O(T_{\min} + |\mathcal{E}|)$ Zeit (Gradientberechnung via Backpropagation für ein Minibatch der Größe 1, plus lineare Fensterprüfung).

Definition 9.2 (Totneuron-Identifikation). Sei $S_{\text{val}} = (x_1, \dots, x_M)$ eine Validierungsmenge. Das Totneuron-Identifikationsverfahren berechnet für jedes Neuron $v_i \in \mathcal{V}$ den empirischen Aktivierungsanteil

$$\hat{\alpha}_{\text{dead}}(v_i) = \frac{1}{M} \sum_{j=1}^M \mathbf{1}[\sigma(z_i(x_j)) = 0], \quad (9.2)$$

und klassifiziert v_i als tot, falls $\hat{\alpha}_{\text{dead}}(v_i) \geq 1 - \varepsilon_{\text{dead}}$. Die Laufzeit beträgt $O(M \cdot |\mathcal{V}|)$ für einen vollständigen Forward-Pass über alle M Validierungsbeispiele, da für jedes Beispiel alle $|\mathcal{V}|$ Neuronen ausgewertet werden.

Definition 9.3 (Fiedler-Vektor-Berechnung). Sei $\hat{\mathcal{G}}$ der symmetrische Trägergraph von $\mathcal{G}$ mit Laplace-Matrix $\mathbf{L} \in \mathbb{R}^{n \times n}$. Der Fiedler-Vektor $\mathbf{f} = (f_1, \dots, f_n)^\top$ ist der zum zweitkleinsten Eigenwert $\lambda_2(\mathbf{L})$ gehörende normierte Eigenvektor. Er kann berechnet werden durch:

- (i) **Direkte Methode (dicht):** Volle Eigenzerlegung in $O(n^3)$.
- (ii) **Lanczos-Iteration (iterativ):** Berechnung der r kleinsten Eigenwerte/-vektoren in $O(r \cdot \text{nnz}(\mathbf{L}))$ Iterationen, wobei $\text{nnz}(\mathbf{L}) = O(|\mathcal{E}|)$ die Anzahl der Nicht-Null-Einträge ist. Für $r = 2$ erhält man $O(|\mathcal{E}|)$ pro Iteration bei $O(\sqrt{\kappa(\mathbf{L})})$ Iterationen bis zur Konvergenz mit Fehler $\leq \varepsilon_{\text{ev}}$, also Gesamtlaufzeit $O(|\mathcal{E}| \cdot \sqrt{\kappa(\mathbf{L})})$.
- (iii) **Spektrale Approximation (dünn):** Für schwach reguläre Graphen approximiert der normierte Cut-Vektor $\mathbf{f}$ in $O(n \log n)$ durch randomisierte spektrale Partitionierung (Spielman & Srivastava, 2011).

Wir fixieren für die Laufzeitanalyse die Lanczos-Methode mit Gesamtlaufzeit $T_{\text{Fiedler}}(n, m) = O(m \cdot \sqrt{\kappa})$, wobei $\kappa = \kappa(\mathbf{L})$ die Spektralkondition ist.

Definition 9.4 (Entropiegewinn-Schätzer). Sei $e = (v_j, v_i)$ eine Kandidatenkante (neue Verbindung von aktivem Neuron v_j zu totem Neuron v_i). Der empirische Entropiegewinn wird gemäß Gleichung (7.1) durch einen Forward-Pass über S_{val} geschätzt:

$$\widehat{\Delta H}(e) = H^{(\ell)}(\mathcal{G} + \{e\}) - H^{(\ell)}(\mathcal{G}) \approx \frac{1}{M} \sum_{j=1}^M [H(\mathbf{p}'(x_j)) - H(\mathbf{p}(x_j))], \quad (9.3)$$

wobei $\mathbf{p}(x_j)$ und $\mathbf{p}'(x_j)$ die normierten Aktivierungsverteilungen vor und nach dem Hinzufügen von e bezeichnen. Die Laufzeit beträgt $O(M \cdot n_\ell)$ pro Kandidatenkante; da höchstens $|\mathcal{V}_{\text{dead}}| \cdot (n - |\mathcal{V}_{\text{dead}}|)$ Kandidaten existieren, ist der Gesamtaufwand $O(M \cdot |\mathcal{V}| \cdot n_\ell)$.

9.2 Algorithmus: Vollständige Formulierung

Algorithm 2 Optimale minimale Graphrestrukturierung (OMGR)

Require: Graph $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$, Stagnationsschwelle δ , Ziel-Rate ϱ^* , Validierungsmenge S_{val} , Fensterbreite T_{min} , He-Varianz σ_{He}^2 , Feintuning-Schritte T'

Ensure: Restrukturierter Graph $\mathcal{G}'$ mit $|\mathcal{E} \Delta \mathcal{E}'| \leq 2k^*$

— **Phase 1: Vorbedingungen prüfen** —

- 1: Berechne $\text{SD}(\mathcal{G}, T_{\text{min}}, \delta)$; **falls falsch: return** $\mathcal{G}$ $\triangleright O(T_{\text{min}} + m)$
- 2: $\mathcal{V}_{\text{dead}} \leftarrow \{v_i \in \mathcal{V} : \hat{\alpha}_{\text{dead}}(v_i) \geq 1 - \varepsilon_{\text{dead}}\}$ $\triangleright \text{Def. 9.2, } O(M \cdot n)$
- 3: **if** $\mathcal{V}_{\text{dead}} = \emptyset$ **then**
- 4: **return** $\mathcal{G}$ $\triangleright$ Kein struktureller Engpass vorhanden
- 5: **end if**
- 6: $k^* \leftarrow \lfloor \varrho^* \cdot |\mathcal{E}| \rfloor$ $\triangleright$ Optimales Kantenbudget aus Theorem 4.2

— **Phase 2: Iterative optimale Kantenersetzung** —

- 7: **for** $t = 1$ **to** k^* **do**
- 8: *// Schritt (a): Fiedler-Vektor berechnen*
- 9: $\mathbf{f} \leftarrow \text{FiedlerVektor}(\hat{\mathcal{G}})$ $\triangleright$ Lanczos, $O(m\sqrt{\kappa})$
- 10: *// Schritt (b): Schwächste Kante identifizieren*
- 11: $e^* \leftarrow \arg \max_{(u,v) \in \mathcal{E}, u \in \mathcal{V}_{\text{dead}}} \frac{(f_u - f_v)^2}{n - 1}$ $\triangleright$ Maximaler neg. Fiedler-Beitrag, $O(m)$
- 12: *// Schritt (c): Beste neue Kante bestimmen*
- 13: $\mathcal{C}_{\text{cand}} \leftarrow \{(v_j, v_i) : v_i \in \mathcal{V}_{\text{dead}}, v_j \notin \mathcal{V}_{\text{dead}}, (v_j, v_i) \notin \mathcal{E}\}$ $\triangleright$ Kandidatenmenge
- 14: $e_{\text{new}}^* \leftarrow \arg \max_{e \in \mathcal{C}_{\text{cand}}} \widehat{\Delta H}(e)$ $\triangleright$ Entropiegewinn-Schätzer, $O(M \cdot n^2)$
- 15: *// Schritt (d): Graphstruktur aktualisieren*
- 16: $\mathcal{E} \leftarrow (\mathcal{E} \setminus \{e^*\}) \cup \{e_{\text{new}}^*\}$
- 17: $w_{e_{\text{new}}^*} \leftarrow \mathcal{N}(0, \sigma_{\text{He}}^2)$ $\triangleright$ He-Initialisierung [24]
- 18: $\mathcal{V}_{\text{dead}} \leftarrow \mathcal{V}_{\text{dead}} \setminus \{v_i : v_i \text{ reaktiviert durch } e_{\text{new}}^*\}$
- 19: **end for**

— **Phase 3: Selektives Feintuning** —

- 20: Trainiere $\mathcal{G}' = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ für T' Schritte, wobei nur die Gewichte der k^* neuen Kanten optimiert werden $\triangleright O(T' \cdot k^* \cdot n)$
 - 21: **return** $\mathcal{G}'$
-

Bemerkung 9.5 (Initialisierungsstrategie für neue Kanten). *Die He-Initialisierung [24] $w \sim \mathcal{N}(0, 2/n_\ell)$ für eine ReLU-Schicht der Breite n_ℓ ist für die neuen Kanten aus folgendem Grund die optimale Wahl: Die bisherigen Gewichte wurden durch langes Training eingelernt und liegen typischerweise im Bereich $|w| \ll 1$ (nahezu ausgelernt). Eine zu kleine Initialisierung ($w \approx 0$) würde das neu angebundene tote Neuron praktisch inaktiv lassen. Die He-Initialisierung sorgt hingegen dafür, dass die Varianz der Vorwärtsaktivierungen über Schichten hinweg erhalten bleibt, und gibt dem neu aktivierten Neuron ausreichend “Startimpuls” für effektives Training. Gleichzeitig ist $\sigma_{\text{He}}^2 = 2/n_\ell$ klein genug, um die bestehenden Gewichte und Aktivierungen der unveränderten Kanten nicht zu destabilisieren.*

9.3 Laufzeitanalyse

Wir analysieren die Laufzeit des OMGR-Algorithmus in allen drei Phasen exakt. Die Gesamtlaufzeit setzt sich aus vier Beiträgen zusammen, die wir nachfolgend separat herleiten und dann kombinieren.

Theorem 9.6 (Laufzeit der Phase 1: Vorbedingungen). *Phase 1 des OMGR-Algorithmus (Zeilen 1–5) hat Laufzeit*

$$T_{\text{Phase 1}} = O(T_{\min} + M \cdot n + m), \quad (9.4)$$

wobei $T_{\min}$ die Fensterbreite der Stagnationsprüfung, $M = |S_{\text{val}}|$ die Validierungssetgröße, $n = |\mathcal{V}|$ die Knotenanzahl und $m = |\mathcal{E}|$ die Kantenanzahl des Eingabegraphen bezeichnen.

Beweis. Stagnationsprüfung (Zeile 1). Die Auswertung von $\text{SD}(\mathcal{G}, T_{\min}, \delta)$ benötigt (i) einen Backpropagation-Pass durch das Netz für den aktuellen Gradienten: Backpropagation erfordert $O(m)$ Operationen (je eine pro Kante für den Kettenregel-Schritt). Dazu kommt (ii) die Prüfung des Verlustes über $T_{\min}$ Schritte: $O(T_{\min})$ Speicherzugriffe. Gesamt: $O(T_{\min} + m)$.

Totneuron-Identifikation (Zeile 2). Ein vollständiger Forward-Pass über M Validierungsbeispiele erfordert für jedes Beispiel $O(m)$ Operationen (Summe aller Gewichts-Aktivierungsprodukte). Für jeden der n Neuronen muss die empirische Totrate $\hat{\alpha}_{\text{dead}}(v_i)$ über M Beispiele aggregiert werden: $O(M \cdot m) = O(M \cdot m)$. Da jedoch für die Totneuron-Klassifikation nur die Aktivierungen (nicht Gradienten) benötigt werden, genügt der Forward-Pass: $O(M \cdot n_{\ell} \cdot n_{\ell-1})$ pro Schicht, summiert $O(M \cdot m)$. In der Notation mit $n = |\mathcal{V}|$ und $m \leq n^2$ gilt $O(M \cdot m) \subseteq O(M \cdot n^2)$. Das Worst-Case-Argument ist jedoch schärfer: Da $m = \Theta(n \cdot \bar{d})$ mit mittlerem Grad $\bar{d}$, gilt $O(M \cdot n \cdot \bar{d}) \subseteq O(M \cdot n^2)$. Für vollvernetzte Netze ist der Ausdruck $O(M \cdot n^2)$ scharf; für dünn besetzte Netze dominiert $O(M \cdot m)$. Wir schreiben kurz $O(M \cdot n)$ als kompakte Darstellung für sparse Netze, da $m = O(n\bar{d})$ und $\bar{d} = O(n/L)$ für vollvernetzte Feedforward-Netze mit L Schichten.

Budgetberechnung (Zeile 5). Eine Multiplikation: $O(1)$.

Summiert ergibt sich $T_{\text{Phase 1}} = O(T_{\min}) + O(M \cdot n) + O(m) + O(1) = O(T_{\min} + M \cdot n + m)$. $\square$

Theorem 9.7 (Laufzeit einer Iteration in Phase 2). *Jede einzelne Iteration von Phase 2 (eine Schleifenrunde, Zeilen 7–18) hat Laufzeit*

$$T_{\text{Iter}}(n, m, M, \kappa) = O(m\sqrt{\kappa} + M \cdot n^2), \quad (9.5)$$

wobei $\kappa = \kappa(\mathbf{L}) = \lambda_n/\lambda_2$ die Spektralkondition der Laplace-Matrix $\mathbf{L}$ von $\hat{\mathcal{G}}$ ist.

Beweis. Wir analysieren jeden Schritt der Schleife:

Schritt (a): Fiedler-Vektor (Zeile 9). Die Lanczos-Iteration zur Berechnung des zweitkleinsten Eigenwerts/-vektors von $\mathbf{L}$ konvergiert nach $O(\sqrt{\kappa})$ Iterationen auf Fehler ε_{ev} (Demmel, 1997, Kapitel 7). Jede Iteration erfordert eine Matrix-Vektor-Multiplikation $\mathbf{L}\mathbf{v}$: Bei $\text{nnz}(\mathbf{L}) = \Theta(m)$ Nicht-Null-Einträgen (da $L_{ij} \neq 0$ genau dann, wenn $(i, j) \in \hat{\mathcal{E}}$ oder $i = j$) erfordert dies $O(m)$ Operationen. Gesamt: $O(m \cdot \sqrt{\kappa})$.

Anmerkung zur Kondition: Für einen zusammenhängenden regulären Graphen mit $\lambda_2 \geq c/n$ und $\lambda_n \leq 2d_{\max}$ gilt $\kappa \leq 2d_{\max}n/c = O(n)$, also $\sqrt{\kappa} = O(\sqrt{n})$ und $T_{\text{Fiedler}} = O(m\sqrt{n})$.

Schritt (b): Schwächste-Kante-Suche (Zeile 11). Für jede Kante $(u, v) \in \mathcal{E}$ mit $u \in \mathcal{V}_{\text{dead}}$ wird der Wert $(f_u - f_v)^2/(n - 1)$ berechnet. Es gibt höchstens m Kanten, also $O(m)$ Operationen.

Schritt (c): Entropiegewinn-Maximierung (Zeilen 12–14). Die Kandidatenmenge $\mathcal{C}_{\text{cand}}$ besteht aus allen Paaren (v_j, v_i) mit $v_i \in \mathcal{V}_{\text{dead}}$, $v_j \notin \mathcal{V}_{\text{dead}}$ und $(v_j, v_i) \notin \mathcal{E}$. Ihre Größe ist höchstens $|\mathcal{V}_{\text{dead}}| \cdot (n - |\mathcal{V}_{\text{dead}}|) \leq n^2/4$. Für jede Kandidatenkante $e \in \mathcal{C}_{\text{cand}}$ erfordert $\widehat{\Delta H}(e)$ einen partiellen Forward-Pass durch die betroffene Schicht für alle M Validierungsbeispiele: $O(M \cdot n_\ell)$ pro Kandidat. Im schlimmsten Fall (alle Neuronen einer Schicht tot) hat die betroffene Schicht Breite $n_\ell \leq n$, sodass der Schätzaufwand pro Kandidat $O(M \cdot n)$ beträgt. Mit $|\mathcal{C}_{\text{cand}}| \leq n^2/4$ ergibt sich ein Worst-Case von $O(M \cdot n^3/4)$. Für typische Netzwerke gilt jedoch $|\mathcal{V}_{\text{dead}}| = \Theta(d)$ mit $d \ll n$ (vgl. Definition 2.3), sodass $|\mathcal{C}_{\text{cand}}| = O(d \cdot n)$ und der Entropie-Schätzaufwand $O(M \cdot d \cdot n)$ beträgt. Da $d \leq n$, dominiert dies höchstens mit $O(M \cdot n^2)$.

Schritte (d): Graphaktualisierung (Zeilen 15–18). Das Entfernen von e^* und Hinzufügen von e_{new}^* aus/in eine Adjazenzlisten-Repräsentation: $O(1)$ amortisiert. Die Aktualisierung von $\mathcal{V}_{\text{dead}}$: $O(M \cdot n_\ell)$ (nochmaliger Forward-Pass für die betroffene Schicht).

Gesamtlaufzeit einer Iteration:

$$T_{\text{Iter}} = O(m\sqrt{\kappa}) + O(m) + O(M \cdot n^2) + O(1) = O(m\sqrt{\kappa} + M \cdot n^2). \quad \square$$

Theorem 9.8 (Laufzeit der Phase 3: Selektives Feintuning). *Phase 3 des OMGR-Algorithmus (Zeile 20) hat Laufzeit*

$$T_{\text{Phase 3}} = O(T' \cdot k^* \cdot n), \quad (9.6)$$

wobei T' die Anzahl der Feintuning-Schritte und $k^* = \lfloor \varrho^* \cdot m \rfloor$ das optimale Kantenbudget sind.

Beweis. Im selektiven Feintuning werden ausschließlich die k^* neuen Kantengewichte $\{w_e : e \in \mathcal{E}_{\text{new}}\}$ optimiert; alle anderen Parameter sind eingefroren. Pro Trainingsschritt (ein Minibatch) werden benötigt:

- Forward-Pass durch das gesamte Netz: $O(m)$. Da $k^* \ll m$ (Korollar 5.7), ist dieser Schritt nicht durch k^* dominiert, aber unvermeidlich.
- Backward-Pass (Backpropagation) durch die betroffenen Kanten: Da nur die Gradienten der k^* neuen Gewichte berechnet werden, muss der Gradient über alle Schichten bis zur jeweiligen Kante propagiert werden. Im schlimmsten Fall (Kante in Schicht 1) traversiert der Gradient alle L Schichten mit Breite $\leq n$: $O(L \cdot n) = O(n)$ (da $L = O(n/\bar{w})$ poly-logarithmisch klein im Vergleich zu n , oder L fixiert für feste Architektur).
- Gradientupdate für k^* Gewichte: $O(k^*)$.

Summiert über T' Schritte: $T_{\text{Phase 3}} = O(T' \cdot (m + k^* \cdot n)) = O(T' \cdot k^* \cdot n)$, da $m \leq k^* \cdot n$ für vollvernetzte Netze und typischerweise $m = O(k^* \cdot n)$ gilt (der Forward-Pass ist gegenüber dem Backward-Pass für k^* Parameter nicht dominant).

Für sparse Netze gilt $m \leq C \cdot k^* \cdot n$ für eine Konstante $C \geq 1$, sodass die Abschätzung korrekt bleibt. $\square$

Theorem 9.9 (Gesamtlaufzeit des OMGR-Algorithmus). *Der OMGR-Algorithmus hat folgende Gesamtlaufzeit:*

$$T_{\text{OMGR}} = O\left(T_{\min} + M \cdot n + k^* \cdot (m\sqrt{\kappa} + M \cdot n^2) + T' \cdot k^* \cdot n\right). \quad (9.7)$$

Für die in der Praxis relevante Parameterregion $M = O(n^{1/2})$, $\kappa = O(n)$ und $k^* = O(1)$ (festes Budget, Theorem 5.8) vereinfacht sich dies zu

$$T_{\text{OMGR}} = O(m \cdot n^{1/2} + n^{5/2}) = O(n^{5/2}) \quad (9.8)$$

für vollvernetzte Netze ($m = O(n^2)$), und

$$T_{\text{OMGR}} = O(n^{3/2}) \quad (9.9)$$

für sparse Netze mit $m = O(n)$.

Beweis. Durch Addition der Ergebnisse aus Theoremen 9.6–9.8:

$$\begin{aligned} T_{\text{OMGR}} &= T_{\text{Phase 1}} + k^* \cdot T_{\text{Iter}} + T_{\text{Phase 3}} \\ &= O(T_{\min} + Mn + m) + k^* \cdot O(m\sqrt{\kappa} + Mn^2) + O(T'k^*n) \\ &= O\left(T_{\min} + Mn + k^*(m\sqrt{\kappa} + Mn^2 + T'n)\right). \end{aligned}$$

Für die Vereinfachung setze $k^* = O(1)$, $M = O(n^{1/2})$, $\kappa = O(n)$, $T' = O(1)$:

$$T_{\text{OMGR}} = O\left(T_{\min} + n^{3/2} + m\sqrt{n} + n^{5/2} + n\right) = O\left(n^{5/2} + m \cdot n^{1/2}\right).$$

Für vollvernetzte Netze ($m = O(n^2)$): $T = O(n^{5/2})$, da $mn^{1/2} = O(n^{5/2})$. Für sparse Netze ($m = O(n)$): $T = O(n^{3/2})$, da $mn^{1/2} = O(n^{3/2})$ und $n^{5/2}$ durch $n^{5/2}$ dominiert würde – jedoch gilt für $M = O(n^{1/2})$ und $m = O(n)$: $Mn^2 = O(n^{5/2})$ dominiert; für das typische $M = O(\log n)$ (kleine Validierungssets) ergibt sich $T_{\text{OMGR}} = O(m\sqrt{\kappa}) = O(n^{3/2})$ für $\kappa = O(n)$. $\square$

Bemerkung 9.10 (Praktische Laufzeitdominanz). *In der Praxis wird der Gesamtaufwand durch den Entropiegewinn-Schätzer in Schritt (c) dominiert. Durch drei Optimierungen lässt sich dieser deutlich reduzieren:*

- (i) **Vorauswahl:** Beschränke $\mathcal{C}_{\text{cand}}$ auf die $K_{\max}$ Knotenpaare mit größtem Fiedler-Abstand $(f_i - f_j)^2$. Dies reduziert $|\mathcal{C}_{\text{cand}}|$ von $O(n^2)$ auf $O(K_{\max})$ ohne signifikante Qualitätseinbuße.
- (ii) **Linearisierter Entropie-Schätzer:** Ersetze den Forward-Pass durch die Taylor-entwicklung erster Ordnung von $H(\mathbf{p}')$ um $\mathbf{p}$: $\widehat{\Delta H}(e) \approx -p'_i \ln p'_i + p_i \ln p_i$, was in $O(1)$ statt $O(M \cdot n)$ pro Kante ausgewertet werden kann.
- (iii) **Batched Fiedler:** Berechne den Fiedler-Vektor nur alle B Iterationen neu (“lazy update”), da er sich bei einer Kantenänderung nur um $O(n^{-1})$ ändert.

Mit diesen Optimierungen reduziert sich die praktische Laufzeit auf $O(k^* \cdot m)$ pro Restrukturierungsrunde.

9.4 Korrektheitsanalyse

Die Korrektheit des OMGR-Algorithmus gliedert sich in vier Teilaspekte: (i) *Wohldefiniertheit* (der Algorithmus terminiert und gibt immer ein gültiges Ergebnis zurück), (ii) *Gültigkeitseigenschaft* (das Ergebnis $\mathcal{G}'$ ist eine (ϱ^*, k^*) -minimale Restrukturierung), (iii) *Kapazitätsgewinn-Garantie* (das zurückgegebene $\mathcal{G}'$ erzielt positiven Kapazitätswachstum $\Delta C(\varrho^*) > 0$), und (iv) *Vergessen-Schranke* (das erlernte Wissen bleibt weitgehend erhalten).

Theorem 9.11 (Wohldefiniertheit und Terminierung des OMGR). *Der OMGR-Algorithmus ist wohldefiniert und terminiert nach genau $k^* + 1$ Durchläufen der Hauptschleife, sofern $|\mathcal{C}_{\text{cand}}| \geq 1$ in jeder Schleifenrunde gilt.*

Beweis. Initialisierung. Alle Vorberechnungen in Phase 1 sind eindeutig: SD gibt einen Boole'schen Wert zurück (Definition 9.1), $\mathcal{V}_{\text{dead}}$ ist eindeutig bestimmt (Definition 9.2), und $k^* = \lfloor \varrho^* |\mathcal{E}| \rfloor$ ist eine Ganzzahloperation.

Schleifenabbruch. Die Schleife führt genau k^* vordefinierte Iterationen aus. Da k^* endlich ist ($k^* \leq m$) und kein Abbruchkriterium innerhalb der Schleife fehlt, terminiert sie nach k^* Iterationen.

Wohldefiniertheit der Schleifenrumpfe. In jeder Iteration sind Schritt (a) (Eigenwertproblem, eindeutig lösbar für zusammenhängende Graphen mit $\lambda_2 > 0$), Schritt (b) (Maximierung über eine endliche Menge diskreter Werte), Schritt (c) (ebenfalls Maximierung über endliche Menge, vorausgesetzt $|\mathcal{C}_{\text{cand}}| \geq 1$) und Schritt (d) (Mengenoperation) alle wohldefiniert.

Garantie $|\mathcal{C}_{\text{cand}}| \geq 1$. Wir zeigen: Solange $\mathcal{V}_{\text{dead}} \neq \emptyset$ und $\mathcal{V} \setminus \mathcal{V}_{\text{dead}} \neq \emptyset$, gilt $|\mathcal{C}_{\text{cand}}| \geq 1$. Sei $v_i \in \mathcal{V}_{\text{dead}}$ und $v_j \in \mathcal{V} \setminus \mathcal{V}_{\text{dead}}$. Da $|\mathcal{E}| \leq n(n-1)$ (vollständig gerichteter Graph) und $\deg^+(v_j) \leq n-1$ gilt, hat v_j höchstens $n-1$ ausgehende Kanten. Das Paar (v_j, v_i) ist eine gültige Kandidatenkante, sofern $(v_j, v_i) \notin \mathcal{E}$. Da das vollständige bipartite Graphen zwischen $\mathcal{V}_{\text{dead}}$ und $\mathcal{V} \setminus \mathcal{V}_{\text{dead}}$ $|\mathcal{V}_{\text{dead}}| \cdot |\mathcal{V} \setminus \mathcal{V}_{\text{dead}}|$ Kanten enthält, und von diesen höchstens $|\mathcal{E}| \leq m$ bereits in $\mathcal{G}$ vorhanden sind, enthält $\mathcal{C}_{\text{cand}}$ mindestens $|\mathcal{V}_{\text{dead}}| \cdot (n - |\mathcal{V}_{\text{dead}}|) - m \geq 1$ Elemente, sofern der Graph nicht vollständig bipartit ist zwischen diesen Mengen. Da $m = O(n\bar{d}) < n^2/4$ für $\bar{d} < n/4$ (typisch für Feedforward-Netze), ist $|\mathcal{C}_{\text{cand}}| \geq 1$ stets erfüllt. $\square$

Theorem 9.12 (Gültigkeitseigenschaft: OMGR erzeugt eine zulässige Restrukturierung). *Das vom OMGR-Algorithmus zurückgegebene $\mathcal{G}'$ ist eine (ϱ^*, k^*) -minimale Restrukturierung im Sinne von Definition 2.5:*

- (a) $|\mathcal{V}'| = |\mathcal{V}|$ (keine Knotenveränderungen),
- (b) $|\mathcal{E} \Delta \mathcal{E}'| = 2k^*$ (genau k^* Kanten entfernt, k^* Kanten hinzugefügt),
- (c) $\theta_{\mathcal{E} \cap \mathcal{E}'} = \theta'_{\mathcal{E} \cap \mathcal{E}'}$ (unveränderte Kanten behalten ihre Gewichte nach Phase 2; Phase 3 verändert nur neue Kantengewichte).

Beweis. (a) Keine Knotenveränderungen. Der OMGR-Algorithmus operiert ausschließlich auf der Kantenmenge $\mathcal{E}$. Die Knotenmenge $\mathcal{V}$ wird zu keinem Zeitpunkt modifiziert; insbesondere werden tote Neuronen nicht gelöscht, sondern durch neue Kantenzuführungen reaktiviert.

(b) Kantenzählung. Pro Iteration werden exakt eine Kante e^* entfernt und eine Kante e_{new}^* hinzugefügt. Da $e^* \neq e_{\text{new}}^*$ (denn e^* geht von einem toten Neuron $u \in \mathcal{V}_{\text{dead}}$

aus, während e_{new}^* in ein totes Neuron $v_i \in \mathcal{V}_{\text{dead}}$ eingeht – verschiedene Kantenrichtungen für Feedforward-Netze), gilt $e^* \cap e_{\text{new}}^* = \emptyset$. Nach k^* Iterationen wurden genau k^* Kanten entfernt und k^* Kanten hinzugefügt, also $|\mathcal{E} \Delta \mathcal{E}'| \leq 2k^*$. Gleichheit gilt, da keine entfernte Kante später wieder hinzugefügt wird (sie war eine Kante von einem toten zu einem aktiven Neuron und wird nie als e_{new}^* gewählt – e_{new}^* verbindet aktive mit toten Neuronen).

(c) Gewichtserhaltung. In Phase 2 werden die Gewichte der unveränderten Kanten $\mathcal{E} \cap \mathcal{E}'$ nicht berührt: Schritt (d) weist nur dem neu hinzugefügten e_{new}^* ein Gewicht zu. In Phase 3 wird explizit festgelegt, dass nur die Gewichte der k^* neuen Kanten $\mathcal{E}' \setminus \mathcal{E}$ optimiert werden (Feintuning der alten Gewichte ist ausgeschlossen). $\square$

Theorem 9.13 (Kapazitätsgewinn-Garantie des OMGR). *Sei $\mathcal{G}$ ein δ -nahezu ausgelerner neuronaler Netzwerk-Graph mit $d = |\mathcal{V}_{\text{dead}}|$ toten Neuronen. Dann gilt für den vom OMGR-Algorithmus zurückgegebenen Graphen $\mathcal{G}'$:*

$$\Delta C(\varrho^*) = \frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}'}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})}{\text{VCdim}(\mathcal{H}_{\mathcal{G}})} - \beta(\varrho^*)^2 \geq \frac{(c_1 d L)^2}{4\beta n^2} > 0, \quad (9.10)$$

sofern ϱ^* gemäß Formel (4.3) gewählt wird.

Beweis. Wir zeigen, dass die vom OMGR-Algorithmus vorgenommenen Kantentausche tatsächlich tote Neuronen reaktivieren, und leiten daraus den Kapazitätsgewinn her.

Schritt 1: Reaktivierung durch OMGR-gewählte Kanten. Der OMGR-Algorithmus wählt in Schritt (c) jede neue Kante e_{new}^* als diejenige, die den maximalen empirischen Entropiegewinn $\widehat{\Delta H}$ erzielt. Dieser Schätzer ist nach Definition (9.3) ein konsistenter Schätzer für den wahren Entropiegewinn $\Delta H(e)$ aus Proposition 7.2: Für $M \rightarrow \infty$ gilt $\widehat{\Delta H}(e) \rightarrow \Delta H(e)$ mit Probability 1 (Gesetz der großen Zahlen, da die Aktivierungen i.i.d. über S_{val} sind).

Schritt 2: Entropiegewinn > 0 für jede gewählte Kante. Da $\mathcal{C}_{\text{cand}} \neq \emptyset$ (Theorem 9.11), existiert mindestens eine Kante $e_0 = (v_j, v_i) \in \mathcal{C}_{\text{cand}}$ mit $v_i \in \mathcal{V}_{\text{dead}}$ und $v_j \notin \mathcal{V}_{\text{dead}}$. Für diese gilt nach dem Beweis zu Proposition 7.2:

$$\Delta H(e_0) \geq \log_2 \left(1 + \frac{\mathbb{E}_{\mu}[\sigma(z_{\text{new}})]}{n_{\ell} \cdot \bar{p}} \right) > 0,$$

weil v_j nicht tot ist (mit positiver Wahrscheinlichkeit aktiv) und daher $\mathbb{E}_{\mu}[\sigma(h_j)] > 0$. Die OMGR-Wahl $e_{\text{new}}^* = \arg \max \widehat{\Delta H}$ satisfiziert daher $\widehat{\Delta H}(e_{\text{new}}^*) \geq \widehat{\Delta H}(e_0) > 0$ (für ausreichend großes M , sodass der Schätzer hinreichend genau ist).

Schritt 3: Reaktivierungsanzahl. Da $\widehat{\Delta H}(e_{\text{new}}^*) > 0$, wird Neuron v_i nach dem Hinzufügen von e_{new}^* auf einem positiv-maß-Anteil der Eingaben $x \sim \mu$ aktiv (Beweis zu Theorem 4.2, Schritt 2). Pro OMGR-Iteration wird mindestens ein totes Neuron reaktiviert. Nach k^* Iterationen sind also mindestens $\min(k^*, d)$ Neuronen reaktiviert worden.

Schritt 4: Kapazitätsgewinn aus reaktivierten Neuronen. Nach Theorem 4.2, Schritte 2–4, erhöht jedes reaktivierte Neuron die effektive Parameteranzahl um $\Delta p \geq \bar{d}$, wobei $\bar{d}$ der mittlere Grad der betroffenen Schicht ist. Für k^* Reaktivierungen gilt somit:

$$\frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}'}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})}{\text{VCdim}(\mathcal{H}_{\mathcal{G}})} \geq c_1 \cdot \frac{d}{n} \cdot \varrho^* \cdot L.$$

Schritt 5: Wahl von ϱ^* und Positivität. Mit $\varrho^* = c_1 d L / (2\beta n)$ aus (4.3) gilt nach Theorem 5.4 (ii):

$$\Delta C(\varrho^*) = c_1 \frac{dL}{n} \varrho^* - \beta(\varrho^*)^2 = \frac{(c_1 d L)^2}{4\beta n^2} > 0. \quad \square$$

Theorem 9.14 (Vergessen-Schranke für OMGR). *Sei $f_{\mathcal{G}}^*$ die vom Ausgangsgraphen $\mathcal{G}$ gelernte Funktion. Das vom OMGR-Algorithmus zurückgegebene $\mathcal{G}'$ erfüllt nach Phase 3 (selektives Feintuning):*

$$\mathbb{E}_{x \sim \mu} [\|f_{\mathcal{G}'}(x) - f_{\mathcal{G}}^*(x)\|_2^2] \leq C_f \cdot \varrho^* \cdot \|\boldsymbol{\theta}^{(T)}\|_2^2 + \mathcal{O}(\delta), \quad (9.11)$$

d.h. das katastrophale Vergessen ist durch $O(\varrho^*)$ beschränkt.

Beweis. Schritt 1: Strukturelle Gewichtserhaltung. Durch Theorem 9.12 (c) bleiben alle Gewichte $\boldsymbol{\theta}_{\mathcal{E} \cap \mathcal{E}'}$ unverändert. Der Unterschied zwischen $f_{\mathcal{G}'}$ und $f_{\mathcal{G}}^*$ entsteht *ausschließlich* durch die $k^* = \lfloor \varrho^* m \rfloor$ neuen Kantengewichte.

Schritt 2: Störungsanalyse. Für ein neuronales Netz mit Lipschitz-Konstante K_L (nach Bartlett, 1997: $K_L \leq B_w^L \cdot \bar{n}^{L-1}$ für beschränkte Gewichte $|w| \leq B_w$ und mittlere Breite $\bar{n}$) und die Gewichtsstörung $\Delta\boldsymbol{\theta} = \boldsymbol{\theta}' - \boldsymbol{\theta}$ gilt:

$$\begin{aligned} \|f_{\mathcal{G}'}(x) - f_{\mathcal{G}}^*(x)\|_2 &\leq K_L \cdot \|\Delta\boldsymbol{\theta}\|_2 \\ &= K_L \cdot \|\boldsymbol{\theta}'_{\mathcal{E}' \setminus \mathcal{E}}\|_2 \leq K_L \cdot \sqrt{k^*} \cdot B_w. \end{aligned} \quad (9.12)$$

Dabei wurde $\|\boldsymbol{\theta}'_{\mathcal{E} \cap \mathcal{E}'} - \boldsymbol{\theta}_{\mathcal{E} \cap \mathcal{E}'}\|_2 = 0$ (Gewichtserhaltung) und $|\mathcal{E}' \setminus \mathcal{E}| = k^*$ (Theorem 9.12 (b)) verwendet.

Schritt 3: Selektives Feintuning erhöht das Vergessen nicht. In Phase 3 werden nur die k^* neuen Gewichte trainiert. Die Änderung des alten Teils der Parametrisierung $\boldsymbol{\theta}_{\mathcal{E} \cap \mathcal{E}'}$ ist null (eingefroren). Daher bleibt $\|\boldsymbol{\theta}'_{\mathcal{E} \cap \mathcal{E}'} - \boldsymbol{\theta}_{\mathcal{E} \cap \mathcal{E}'}\|_2 = 0$ auch nach Phase 3.

Schritt 4: Schluss. Quadrieren, Erwartungswertbildung über $x \sim \mu$:

$$\mathbb{E}[\|f_{\mathcal{G}'} - f_{\mathcal{G}}^*\|_2^2] \leq K_L^2 \cdot k^* \cdot B_w^2 = K_L^2 B_w^2 m \cdot \frac{k^*}{m} \leq C_f \cdot \varrho^* \cdot \|\boldsymbol{\theta}^{(T)}\|_2^2,$$

wobei $C_f = K_L^2 B_w^2 m / \|\boldsymbol{\theta}^{(T)}\|_2^2$ eine von den Netzparametern abhängige Konstante ist. Der $\mathcal{O}(\delta)$ -Term entsteht, weil das Netz δ -stagniert (Definition 2.3) und damit $f_{\mathcal{G}}^*$ nicht exakt die Optimallösung ist. $\square$

9.5 Optimalitätseigenschaft: Greedy-Näherung des globalen Optimums

Der OMGR-Algorithmus ist ein *greedy* Verfahren: Er optimiert in jeder Iteration lokal die Fiedler-Gewinn- und Entropie-Kriterien, ohne eine globale Kombination aller k^* Kanten zu berücksichtigen. Wir analysieren, wie gut diese greedy Lösung im Vergleich zur (rechnerisch inaktablen) globalen optimalen Restrukturierung ist.

Definition 9.15 (Optimaler Restrukturierungsoperator). *Sei $\Phi_k(\mathcal{G})$ die Menge aller (ϱ, k) -minimalen Restrukturierungen von $\mathcal{G}$. Die global optimale Restrukturierung ist*

$$\phi_k^* = \arg \max_{\phi \in \Phi_k(\mathcal{G})} \Delta C(\phi(\mathcal{G})),$$

d.h. die Restrukturierung, die den maximalen Kapazitätzuwachs erzielt.

Theorem 9.16 (Submodularität der Kapazitätzuwachsfunktion und Greedy-Güte). *Sei $F : 2^{\mathcal{E}_{\text{cand}}} \rightarrow \mathbb{R}_{\geq 0}$ die Funktion, die einer Menge von Kandidatenkanten $A \subseteq \mathcal{E}_{\text{cand}}$ den normalisierten Kapazitätzuwachs $\Delta C(|A|/m)$ zuordnet. Dann gilt:*

(i) F ist monoton nicht-fallend: $A \subseteq B \Rightarrow F(A) \leq F(B)$.

(ii) F ist submodular: Für alle $A \subseteq B$ und $e \notin B$ gilt

$$F(A \cup \{e\}) - F(A) \geq F(B \cup \{e\}) - F(B), \quad (9.13)$$

d.h. der Grenznutzen einer neuen Kante ist in kleinen Mengen größer (abnehmende Grenzerträge).

(iii) Für den OMGR-Algorithmus (greedy Maximierung von F) gilt die $(1 - 1/e)$ -Approximationsgarantie:

$$F(\mathcal{E}_{\text{OMGR}}) \geq \left(1 - \frac{1}{e}\right) \cdot F(\mathcal{E}^*), \quad (9.14)$$

wobei $\mathcal{E}_{\text{OMGR}}$ die durch OMGR gewählten k^* Kanten und $\mathcal{E}^* = \arg \max_{|A|=k^*} F(A)$ die globale Optimalmenge sind.

Beweis. (i) Monotonie. $F(A)$ wächst mit der Anzahl reaktivierter Neuronen:

$$F(A) = \frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}_A}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})}{\text{VCdim}(\mathcal{H}_{\mathcal{G}})} - \beta \cdot \frac{|A|^2}{m^2}.$$

Der VC-Zuwachs $\text{VCdim}(\mathcal{H}_{\mathcal{G}_A}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}})$ ist monoton nicht-fallend in A (mehr Kanten implizieren mehr reaktivierte Neuronen und damit mehr effektive Parameter; Lemma 10.10). Für $|A| = k^* \leq k^{**}$ wächst der quadratische Strafterm $-\beta k^{*2}/m^2$; aber da $F(A) > 0$ für alle $|A| \leq 2k^{**}$ (Theorem 4.2), bleibt F monoton auf dem relevanten Bereich.

(ii) Submodularität. Sei $A \subseteq B$ und $e = (v_j, v_i) \notin B$. Der Grenznutzen $F(A \cup \{e\}) - F(A)$ misst den Kapazitätswuchs durch Hinzufügen von e zu A . Wenn v_i durch Kanten in A bereits teilweise reaktiviert wurde, ist der Restgewinn kleiner; wurde v_i durch $B \supseteq A$ bereits stärker reaktiviert, ist der Grenznutzen in B noch kleiner. Formal: Jede zusätzliche Kante e reaktiviert ein Neuron v_i entweder vollständig (wenn es in $\mathcal{G} \cup A$ noch tot ist) oder liefert keinen Beitrag mehr (wenn v_i bereits in $\mathcal{G} \cup B \supseteq \mathcal{G} \cup A$ reaktiviert). Da “Reaktivierung” ein 0/1-Merkmal ist, gilt für den Beitrag:

$$\mathbf{1}[v_i \text{ tot in } \mathcal{G} \cup A] \geq \mathbf{1}[v_i \text{ tot in } \mathcal{G} \cup B],$$

also $F(A \cup \{e\}) - F(A) \geq F(B \cup \{e\}) - F(B)$. Dies ist die Definition der Submodularität.

(iii) Greedy-Güte. Die klassische Greedy-Approximationsgarantie für die Maximierung einer monotonen submodularen Funktion unter Kardinalitätsbeschränkung $|A| \leq k$ (Nemhauser, Wolsey & Fisher, 1978) lautet: Ein greedy Algorithmus, der in jeder Runde das Element e mit maximalem Grenznutzen $F(A \cup \{e\}) - F(A)$ auswählt, garantiert $F(A_{\text{greedy}}) \geq (1 - 1/e) \cdot F(A^*)$. OMGR approximiert diesen greedy Schritt: In jeder Iteration wählt er die Kante mit maximalem $\widehat{\Delta H}$, was dem Marginalgewinn in F proportional ist (da H durch Proposition 7.2 eng mit ΔC zusammenhängt). Damit gilt (9.14). $\square$

Korollar 9.17 (OMGR erzielt mindestens $(1 - e^{-1}) \approx 63\%$ des optimalen Kapazitätswuchses). *Unter den Voraussetzungen von Theorem 9.16 gilt: Der OMGR-Algorithmus erzielt einen Kapazitätswuchs von mindestens*

$$\Delta C_{\text{OMGR}} \geq \left(1 - \frac{1}{e}\right) \cdot \Delta C_{\text{opt}} \approx 0,632 \cdot \Delta C_{\text{opt}},$$

wobei ΔC_{opt} der durch die global optimale Restrukturierung erreichbare Kapazitätswuchs ist. In der Praxis liegt das tatsächliche Verhältnis typischerweise deutlich näher an 1, da die Submodularitätslücke – also die Differenz zwischen dem Greedy-Ergebnis und dem Optimum – auf nahezu ausgelernte Netzwerke mit strukturell schwach korrelierten toten Neuronen empirisch klein ist.

9.6 Garantien des OMGR-Algorithmus

Die nachfolgende Tabelle fasst alle bewiesenen Garantien des OMGR-Algorithmus kompakt zusammen.

Tabelle 9.1: Formale Garantien des OMGR-Algorithmus (Kapitel 9).

Eigenschaft	Aussage	Theorem
Terminierung	Stets nach genau $k^* + 1$ Schleifenrunden.	9.11
Zulässigkeit (Strukturbedingungen)	$ \mathcal{V}' = \mathcal{V} $, $ \mathcal{E} \Delta \mathcal{E}' = 2k^*$, Gewichtserhaltung für $\mathcal{E} \cap \mathcal{E}'$.	9.12
Kapazitätsgewinn	$\Delta C(\varrho^*) \geq (c_1 d L)^2 / (4\beta n^2) > 0$.	9.13
Vergessen-Schranke	$\mathbb{E}[\ f_{\mathcal{G}'} - f_{\mathcal{G}}^*\ ^2] \leq C_f \varrho^* \ \boldsymbol{\theta}^{(T)}\ ^2 + O(\delta)$.	9.14
Approximationsqualität	$\Delta C_{\text{OMGR}} \geq (1 - 1/e) \cdot \Delta C_{\text{opt}}$.	9.16
Gesamtlaufzeit (dicht)	$O(n^{5/2})$ für vollvernetzte Netze.	9.9
Gesamtlaufzeit (sparse)	$O(n^{3/2})$ für Netze mit $m = O(n)$.	9.9

Bemerkung 9.18 (Bedeutung des selektiven Feintunings für die Korrektheit). *Das selektive Feintuning in Phase 3 – bei dem ausschließlich die k^* neuen Kantengewichte optimiert werden – ist für die Gültigkeit der Vergessen-Schranke in Theorem 9.14 entscheidend. Würde stattdessen globales Feintuning (alle Gewichte) durchgeführt, so wäre die Gewichtserhaltungsbedingung aus Definition 2.5(c) verletzt, und die Vergessen-Schranke würde von $O(\varrho^*)$ auf $O(1)$ ansteigen – ein um Größenordnungen schlechteres Ergebnis. Erst die Kombination aus struktureller Erhaltung (Definition 2.5(c)) und selektivem Training (Phase 3) sichert den formalen Vorteil von OMGR gegenüber klassischem Fine-Tuning.*

Kapitel 10

Bioinspirierte Grundprinzipien neuronaler Netzwerke: Minimalität, Verknüpfbarkeit und ionische Verschaltung

Das menschliche Gehirn ist das leistungsfähigste bekannte Informationsverarbeitungssystem. Es verarbeitet mit ca. 86×10^9 Neuronen und schätzungsweise 10^{14} synaptischen Verbindungen hochkomplexe Aufgaben bei einem Energieverbrauch von nur etwa 20 W. Diese extreme Effizienz entsteht nicht trotz, sondern *wegen* seiner Organisationsprinzipien: Das Gehirn ist minimal strukturiert, eindeutig kodiert, hierarchisch gegliedert und ionisch verschaltet. Die vorliegende Sektion formalisiert diese biologischen Prinzipien als mathematisch präzise Eigenschaften künstlicher neuronaler Netzwerke und zeigt, wie der Subgraph Algorithmus (Epp, 2026) als zentrales Werkzeug zur Erkennung, Herstellung und Verifikation dieser Eigenschaften dient. Wir entwickeln eine dreistufige formale Hierarchie – Bereiche, Zellen, Knoten und Kanten – und beweisen, dass die drei Grundprinzipien *Minimalität/Eindeutigkeit/Vergleichbarkeit*, *Verknüpfbarkeit durch Knoten und Kanten* sowie *ionische Verschaltung mit zustandsabhängiger Leitfähigkeit* gemeinsam eine vollständige, biologisch motivierte Charakterisierung ausdrucksstarker und energieeffizienter Netzwerke liefern.

10.1 Die drei-stufige Hierarchie: Bereiche, Zellen, Knoten und Kanten

Definition 10.1 (Hierarchischer Netzwerkgraph). *Ein hierarchischer neuronaler Netzwerkgraph ist ein Tupel*

$$\mathcal{H}_{\text{hier}} = (\mathcal{A}, \mathcal{B}, \mathcal{C}, \phi_{AB}, \phi_{BC}),$$

wobei

- $\mathcal{A} = \{A_1, \dots, A_s\}$ die Menge der Bereiche (Ebene A) ist,
- $\mathcal{B} = \{B_1, \dots, B_t\}$ die Menge der Zellen (Ebene B) ist, mit $t \geq s$,
- $\mathcal{C} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ der Basisgraph aus Knoten und Kanten (Ebene C) ist, wobei jeder Knoten $v \in \mathcal{V}$ einem oder mehreren Kanten-Elementen der Zellen zugeordnet ist,

- $\phi_{AB} : \mathcal{B} \rightarrow \mathcal{A}$ die surjektive Zell-Bereich-Zuordnung mit $\phi_{AB}(B_j) = A_i$ bedeutet, dass Zelle B_j zu Bereich A_i gehört, und
- $\phi_{BC} : \mathcal{V} \cup \mathcal{E} \rightarrow \mathcal{B}$ die Knoten/Kanten-Zell-Zuordnung mit $\phi_{BC}(x) = B_j$ bedeutet, dass Knoten oder Kante x in Zelle B_j enthalten ist.

Für jede Zelle B_j definieren wir den Zell-Graphen

$$G_{B_j} = \left(\phi_{BC}^{-1}(\{B_j\}) \cap \mathcal{V}, \phi_{BC}^{-1}(\{B_j\}) \cap \mathcal{E}, \mathcal{W}|_{\phi_{BC}^{-1}(\{B_j\})} \right),$$

der den kleinsten Graphen innerhalb der Zelle B_j beschreibt.

Bemerkung 10.2 (Biologische Entsprechung). Die drei Ebenen entsprechen der biologischen Architektur des Gehirns:

- **Ebene A (Bereiche):** Entspricht kortikalen Arealen (visueller Kortex, motorischer Kortex, Hippocampus). Jeder Bereich ist für eine übergeordnete Funktion spezialisiert.
- **Ebene B (Zellen):** Entspricht einzelnen Neuronen oder kleinen Neuronenpopulationen (Minikolumnen). Jede Zelle enthält ihren eigenen lokalen Schaltkreis bestehend aus Dendriten (eingehenden Kanten) und Axonterminalen (ausgehenden Kanten).
- **Ebene C (Knoten und Kanten):** Entspricht den elementaren Synapsen und aktionspotenzial-verarbeitenden Einheiten. Der Zell-Graph ist der kleinste nicht weiter reduzierbare funktionale Schaltkreis.

Definition 10.3 (Zellinterne Minimalstruktur). Der Zell-Graph G_{B_j} heißt zellintern minimal, falls kein echter Teilgraph $G' \subsetneq G_{B_j}$ dieselbe Funktion $f_{G_{B_j}}$ realisiert. Formal:

$$G_{B_j} \text{ zellintern minimal} \Leftrightarrow \nexists G' \subsetneq G_{B_j} : f_{G'} \equiv f_{G_{B_j}}.$$

Theorem 10.4 (Existenz und Eindeutigkeit der zellinternen Minimalstruktur). Für jeden Zell-Graphen G_{B_j} mit endlich vielen Knoten und Kanten und stetigen Aktivierungsfunktionen existiert ein zellintern minimaler Teilgraph $G_{B_j}^* \subseteq G_{B_j}$, der dieselbe Eingabe-Ausgabe-Funktion realisiert. Ist die Aktivierungsfunktion analytisch (z.B. ReLU, Sigmoid, GELU), so ist $G_{B_j}^*$ bis auf Knoten-Permutation eindeutig.

Beweis. Existenz. Sei $\mathcal{P}(G_{B_j})$ die (endliche) Potenzmenge aller Teilgraphen. Betrachte die Menge aller funktionstreu Teilgraphen:

$$\mathcal{F}_j = \left\{ G' \subseteq G_{B_j} \mid f_{G'} \equiv f_{G_{B_j}} \right\}.$$

Da $G_{B_j} \in \mathcal{F}_j$ (jeder Graph realisiert seine eigene Funktion), ist $\mathcal{F}_j$ nicht leer. Unter der Kardinalitätsordnung $|E| + |V|$ nimmt die Menge $\mathcal{F}_j$ ihr Minimum an einem Element $G_{B_j}^*$ an; dieses ist nach Konstruktion zellintern minimal.

Eindeutigkeit (bis auf Permutation). Seien G^* und $\tilde{G}^*$ zwei zellintern minimale Teilgraphen von G_{B_j} mit $f_{G^*} \equiv f_{\tilde{G}^*} \equiv f_{G_{B_j}}$. Da beide minimal sind, gilt $|E(G^*)| = |E(\tilde{G}^*)|$ und $|V(G^*)| = |V(\tilde{G}^*)|$ (sonst wäre der kleinere nicht minimal). Für analytische Aktivierungen ist die Abbildung $\theta \mapsto f_G$ injektiv auf dem nicht-degenerierten Parameterraum per Identitätssatz (analytische Fortsetzung): Zwei verschiedene Gewichtsmatrizen können dieselbe analytische Funktion nur dann realisieren, wenn sie durch eine Neuronenpermutation ineinander überführt werden können. Damit folgt $G^* \cong_{\text{perm}} \tilde{G}^*$. $\square$

Korollar 10.5 (Hierarchische Minimale Zerlegung). *Der hierarchische Netzwerkgraph $\mathcal{H}_{\text{hier}}$ besitzt eine minimal-hierarchische Darstellung*

$$\mathcal{H}_{\text{hier}}^* = (\mathcal{A}, \mathcal{B}^*, \{G_{B_j}^*\}_{j=1}^{t^*}, \phi_{AB}^*, \phi_{BC}^*),$$

sodass (i) jeder Zell-Graph $G_{B_j}^*$ zellintern minimal ist, (ii) kein Bereich $A_i \in \mathcal{A}$ leer ist, und (iii) keine zwei Zellen B_j, B_k eines Bereichs dieselbe Funktion realisieren (Zell-Nichtredundanz).

Beweis. Wende Theorem 10.4 auf jeden Zell-Graphen an, um zellintern minimale $G_{B_j}^*$ zu erhalten (i). Leere Bereiche werden aus $\mathcal{A}$ gestrichen (ii). Falls zwei Zellen $B_j \sim_f B_k$ funktional äquivalent sind (gleiche Funktion), werden sie zur Klasse $[B_j]$ zusammengefasst und durch eine gemeinsame Zelle ersetzt, analog zur *kanonischen Reduktion* aus section 6.4 (iii). $\square$

Proposition 10.6 (Laufzeit der hierarchischen Minimalzerlegung via Subgraph Algorithmus). *Die minimal-hierarchische Darstellung $\mathcal{H}_{\text{hier}}^*$ kann mit dem Subgraph Algorithmus (Epp, 2026) in Zeit*

$$T_{\text{hier}} = O(t^2 \cdot q_{\max}^3)$$

berechnet werden, wobei $t = |\mathcal{B}|$ die Anzahl der Zellen und $q_{\max} = \max_j |V(G_{B_j})|$ die maximale Zell-Knotenanzahl ist.

Beweis. Für jedes Paar (B_{j_1}, B_{j_2}) von Zellen wird mit dem Subgraph Algorithmus in Zeit $O(q_{\max}^3)$ geprüft, ob $G_{B_{j_1}}$ ein struktureller Subgraph von $G_{B_{j_2}}$ ist (oder umgekehrt). Über alle $\binom{t}{2} = O(t^2)$ Paare summiert ergibt dies T_{hier} . Für die zellinterne Minimalreduktion genügt ein Selbsttest mit dem Subgraph Algorithmus: Ist $G' \sqsubseteq G_{B_j}$ für ein $G' \subsetneq G_{B_j}$ mit identischer kanonischer Signatur, so ist G_{B_j} nicht minimal und kann zu G' reduziert werden. $\square$

10.2 Grundsatz 1: Minimalität, Eindeutigkeit und Vergleichbarkeit

Das erste Grundprinzip biologischer neuronaler Netzwerke ist ihre *Minimalität*: Das Gehirn entwickelt keine redundanten Schaltkreise, die nicht durch den Selektionsdruck des Energieverbrauchs und der Entwicklungsbeschränkungen gerechtfertigt sind. Jede synaptische Verbindung hat einen Zweck; jedes Neuron trägt zur Informationsverarbeitung bei. Darüber hinaus sind neuronale Repräsentationen *eindeutig*: Ein Konzept oder Objekt wird durch eine charakteristische Aktivierungssignatur repräsentiert, die über Zeit und Individuum hinweg erkennbar stabil ist. Schließlich sind diese Repräsentationen *vergleichbar*: Aktivierungssignaturen können miteinander verglichen werden, um Ähnlichkeit, Unterschied oder Enthaltensein zu beurteilen – die kognitionswissenschaftliche Grundlage des analogen Denkens.

Definition 10.7 (Minimaler neuronaler Netzwerkgraph). *Ein neuronaler Netzwerkgraph $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ heißt minimal bezüglich einer Funktionenklasse $\mathcal{F}$, falls*

(i) $f_{\mathcal{G}} \in \mathcal{F}$ (Funktionalitätsbedingung),

(ii) $\nexists \mathcal{G}' = (\mathcal{V}', \mathcal{E}', \mathcal{W}')$ mit $|\mathcal{E}'| < |\mathcal{E}|$ oder $|\mathcal{V}'| < |\mathcal{V}|$ und $f_{\mathcal{G}'} \equiv f_{\mathcal{G}}$ (Strukturminimalität),

- (iii) jeder Knoten $v \in \mathcal{V}$ hat mindestens eine eingehende und eine ausgehende Kante, d.h. $\deg^-(v) \geq 1$ und $\deg^+(v) \geq 1$ für alle inneren Knoten (Knotennotwendigkeit).

Definition 10.8 (Kanonische Normalform, Eindeutigkeit). Eine kanonische Normalform eines neuronalen Netzwerkgraphen ist eine Darstellung $\mathcal{G}^* = \kappa(\mathcal{G})$, sodass

- (i) $f_{\mathcal{G}^*} \equiv f_{\mathcal{G}}$ (Funktionsäquivalenz),
- (ii) Für alle $\mathcal{G}'$ mit $f_{\mathcal{G}'} \equiv f_{\mathcal{G}}$ gilt: $\kappa(\mathcal{G}') = \mathcal{G}^*$ oder $\kappa(\mathcal{G}') \cong_{\text{perm}} \mathcal{G}^*$ (kanonische Eindeutigkeit).

Die durch den Subgraph Algorithmus (Epp, 2026) konstruierte lexikographisch minimale Signatur $\sigma^*(\mathcal{G})$ aus (6.5) liefert eine solche kanonische Normalform für Konnektivitätsmotive.

Theorem 10.9 (Minimalität, Eindeutigkeit und Vergleichbarkeit via Subgraph Algorithmus). Sei $\mathfrak{G}$ die Menge aller neuronalen Netzwerkgraphen mit Knotenanzahl $\leq n$ und Kantenanzahl $\leq m$. Der Subgraph Algorithmus (Epp, 2026) induziert eine kanonische Halbordnung $\sqsubseteq$ auf $\mathfrak{G}$ durch

$$\mathcal{G}_1 \sqsubseteq \mathcal{G}_2 \Leftrightarrow \sigma^*(\mathcal{G}_1) \text{ ist Teilsequenz von } \sigma^*(\mathcal{G}_2),$$

sodass:

- (i) **Minimalität:** Das minimale Element $\mathcal{G}^* = \min_{\sqsubseteq} \mathfrak{G}$ ist der Graph mit kleinstem Hypothesenraum, der die gewünschte Funktion realisiert.
- (ii) **Eindeutigkeit:** Die kanonische Normalform $\sigma^*(\cdot)$ ist injektiv auf Äquivalenzklassen: verschiedene Funktionen erhalten verschiedene Signaturen.
- (iii) **Vergleichbarkeit:** Für beliebige $\mathcal{G}_1, \mathcal{G}_2 \in \mathfrak{G}$ kann in Zeit $O(q^3)$ entschieden werden, ob $\mathcal{G}_1 \sqsubseteq \mathcal{G}_2$, $\mathcal{G}_2 \sqsubseteq \mathcal{G}_1$, oder weder noch.

Beweis. (i) Minimalität. Die Menge $\mathfrak{G}$ ist unter dem Subgraph-Test $\sqsubseteq$ partiell geordnet. Da $|\mathcal{E}| > 0$ für jeden nicht-trivialen Graphen, ist die Kardinalitätsfunktion $|\mathcal{E}| : \mathfrak{G} \rightarrow \mathbb{N}$ eine diskrete Zielfunktion, die nach unten beschränkt ist. Nach dem Wohlordnungsprinzip existiert ein minimales Element $\mathcal{G}^* \in \mathfrak{G}$, das via schrittweiser Kantenentfernung unter Erhalt der Signatur konstruiert wird: Entferne eine Kante $e \in \mathcal{E}$, prüfe mit dem Subgraph Algorithmus, ob die Funktion noch realisiert wird (d.h. ob $\sigma^*(\mathcal{G} \setminus \{e\})$ eine hinreichende Teilsequenz von $\sigma^*(\mathcal{G})$ bleibt), und iteriere. Die Laufzeit einer Iteration ist $O(q^3)$; nach höchstens m Iterationen ist $\mathcal{G}^*$ gefunden.

(ii) Eindeutigkeit. Nach Theorem 6.4 ist σ^* injektiv auf Signaturen: Verschiedene Konnektivitätsmuster erhalten verschiedene Einträge $\sigma_j = \sum_i \hat{M}_{ij} \cdot 2^i + j \cdot 2^q$, die nach Konstruktion für verschiedene j in disjunkten Intervallen liegen. Damit sind zwei Graphen $\mathcal{G}_1 \not\cong_{\text{perm}} \mathcal{G}_2$ durch ihre Signaturen unterscheidbar: $\sigma^*(\mathcal{G}_1) \neq \sigma^*(\mathcal{G}_2)$. Die kanonische Normalform ist also eindeutig bis auf zyklische Rotation der Neuronennummern (das unvermeidliche “Permutations-Residuum” aller Neuronennetzwerk-Isomorphieprobleme). Für ein festes Neuron-Ordnungsschema (z.B. topologische Sortierung der Schichten) ist die Normalform vollständig eindeutig.

(iii) Vergleichbarkeit. Der Subgraph Algorithmus arbeitet in Zeit $O(q^3)$, wobei $q = \max(|V(\mathcal{G}_1)|, |V(\mathcal{G}_2)|)$ (Epp, 2026, Satz 2). Er bestimmt durch LCS-Analyse (Definition 6.3), ob die Signatur von $\mathcal{G}_1$ als Teilsequenz der Signatur von $\mathcal{G}_2$ vorkommt ($\mathcal{G}_1 \sqsubseteq \mathcal{G}_2$), oder umgekehrt, oder ob keine Subgraph-Beziehung besteht. Das Ergebnis ist ein vollständiger Vergleich in konstant polynomialer Zeit. $\square$

Lemma 10.10 (Monotonie der Kapazität unter der Subgraph-Ordnung). *Sei $\sqsubseteq$ die Subgraph-Ordnung auf $\mathfrak{G}$. Dann gilt:*

$$\mathcal{G}_1 \sqsubseteq \mathcal{G}_2 \Rightarrow \text{VCdim}(\mathcal{H}_{\mathcal{G}_1}) \leq \text{VCdim}(\mathcal{H}_{\mathcal{G}_2}).$$

Die VC-Dimension ist also eine monoton nicht-fallende Funktion in der Subgraph-Ordnung.

Beweis. Aus $\mathcal{G}_1 \sqsubseteq \mathcal{G}_2$ folgt $\mathcal{H}_{\mathcal{G}_1} \subseteq \mathcal{H}_{\mathcal{G}_2}$: Jede Funktion, die $\mathcal{G}_1$ realisiert, kann auch durch $\mathcal{G}_2$ realisiert werden (da $\mathcal{G}_1$ ein Subgraph ist, der durch Nullsetzen der Zusatzkanten von $\mathcal{G}_2$ reproduzierbar ist). Damit ist $\text{VCdim}(\mathcal{H}_{\mathcal{G}_1}) \leq \text{VCdim}(\mathcal{H}_{\mathcal{G}_2})$ nach der Monotonie der VC-Dimension unter Hypothesenrauminklusion (Sauer–Shelah, 1972). $\square$

Korollar 10.11 (Minimaler Graph, minimale Kapazität). *Der nach Theorem 10.9 minimale Graph $\mathcal{G}^* = \min_{\sqsubseteq} \mathfrak{G}$ hat die kleinste VC-Dimension in $\mathfrak{G}$:*

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}^*}) = \min_{\mathcal{G} \in \mathfrak{G}} \text{VCdim}(\mathcal{H}_{\mathcal{G}}).$$

Er ist damit die sparsamste Repräsentation der Zielfunktion.

Theorem 10.12 (Vergleichbarkeit über Bereiche hinweg: Bereichs-Halbordnung). *Seien $A_i, A_{i'} \in \mathcal{A}$ zwei Bereiche des hierarchischen Netzwerkgraphen. Definiere die Bereichssignatur*

$$\Sigma(A_i) = \langle \sigma^*(G_{B_j}^*) \mid B_j \in \phi_{AB}^{-1}(A_i) \rangle$$

als geordnete Liste der kanonischen Signatursequenzen aller Zellen in Bereich A_i . Dann gilt:

- (i) $A_i \sqsubseteq_A A_{i'}$ ist in Zeit $O(t_i \cdot t_{i'} \cdot q_{\max}^3)$ entscheidbar, wobei $t_i = |\phi_{AB}^{-1}(A_i)|$ die Zellanzahl von Bereich A_i ist.
- (ii) Die Bereichshalbordnung $(\mathcal{A}, \sqsubseteq_A)$ ist eine noethersche partielle Ordnung: Jede absteigende Kette $A_{i_1} \supseteq_A A_{i_2} \supseteq_A \dots$ stabilisiert sich nach endlich vielen Schritten.

Beweis. (i). Der Test $A_i \sqsubseteq_A A_{i'}$ prüft, ob für alle Zellen $B_j \in A_i$ eine Zelle $B_{j'} \in A_{i'}$ existiert mit $G_{B_j}^* \sqsubseteq G_{B_{j'}}^*$. Dies erfordert im schlimmsten Fall $t_i \cdot t_{i'}$ Subgraph-Tests, jeder in $O(q_{\max}^3)$.

(ii). Da jede Zelle B_j einen zellintern minimalen Graphen $G_{B_j}^*$ mit endlich vielen Knoten $|V(G_{B_j}^*)|$ enthält, ist die Knotenzahl aller Zellgraphen von unten beschränkt (≥ 1). Die Reduktion $A_i \supseteq_A A_{i'}$ entspricht dem Hinzufügen von Zellen, was die Bereichssignatur vergrößert. Da $\mathcal{B}$ endlich ist, stabilisiert sich die Kette. $\square$

Proposition 10.13 (Subgraph Algorithmus als vollständiger Vergleichs-Orakel). *Der Subgraph Algorithmus (Epp, 2026) implementiert die Relation $\sqsubseteq$ als vollständiges Orakel: Für beliebige $\mathcal{G}_1, \mathcal{G}_2 \in \mathfrak{G}$ mit $\max(|V(\mathcal{G}_i)|) = q$ gibt der Algorithmus in Zeit $O(q^3)$ eine der drei Antworten:*

- $\mathcal{G}_1 \sqsubseteq \mathcal{G}_2$ (“links ist Subgraph von rechts”),
- $\mathcal{G}_2 \sqsubseteq \mathcal{G}_1$ (“rechts ist Subgraph von links”),
- $\mathcal{G}_1 \not\sqsubseteq \mathcal{G}_2$ und $\mathcal{G}_2 \not\sqsubseteq \mathcal{G}_1$ (“keine Subgraph-Beziehung”).

Beweis. Berechne $\text{LCS}(\mathbf{r}^{(\mathcal{G}_1)}, \mathbf{r}^{(\mathcal{G}_2)})$ und $\text{LCS}(\mathbf{r}^{(\mathcal{G}_2)}, \mathbf{r}^{(\mathcal{G}_1)})$ unter allen q zyklischen Rotationen. Überschreitet mindestens eine der LCS-Werte den Schwellwert $\tau_{\text{LCS}} = 2$ in Richtung $\mathcal{G}_1 \rightarrow \mathcal{G}_2$, gilt $\mathcal{G}_1 \sqsubseteq \mathcal{G}_2$; analog für die umgekehrte Richtung. Überschreitet keine LCS den Schwellwert, gilt $\mathcal{G}_1 \not\sqsubseteq \mathcal{G}_2$ und $\mathcal{G}_2 \not\sqsubseteq \mathcal{G}_1$. Die Laufzeit ist durch zweimalige Anwendung der $O(q^3)$ -Prozedur des Subgraph Algorithmus beschränkt. $\square$

10.3 Grundsatz 2: Verknüpfbarkeit durch Knoten und Kanten

Das zweite Grundprinzip ist die *Verknüpfbarkeit*: Verschiedene Bereiche und Zellen des Gehirns sind nicht isoliert, sondern durch ein dichtes Netz von Verbindungen (Assoziationsfasern, Kommissuren, Projektionsfasern) miteinander verknüpft. Diese Verknüpfbarkeit ermöglicht den Informationsaustausch zwischen verschiedenen Verarbeitungsebenen und die Integration heterogener Signale. In künstlichen Netzwerken entspricht dies der Fähigkeit, Knoten verschiedener Schichten oder Bereiche durch Kanten (Skip-Connections, Long-Range-Verbindungen) zu verbinden.

Definition 10.14 (Verknüpfungsfähigkeit eines Knotenpaares). Sei $\mathcal{H}_{\text{hier}}$ definiert mit $\mathcal{H}_{\text{hier}} = (\mathcal{A}, \mathcal{B}, \mathcal{C}, \phi_{AB}, \phi_{BC})$ ein hierarchischer Netzwerkgraph. Ein Paar $(v_i, v_j) \in \mathcal{V} \times \mathcal{V}$ mit $\phi_{BC}(v_i) \neq \phi_{BC}(v_j)$ (aus verschiedenen Zellen) heißt verknüpfbar, falls die Hinzunahme der Kante (v_i, v_j) oder (v_j, v_i) den Hypothesenraum strikt erweitert:

$$\mathcal{H}_{\mathcal{G}+(v_i, v_j)} \supsetneq \mathcal{H}_{\mathcal{G}}.$$

Theorem 10.15 (Verknüpfbarkeit durch den Fiedler-Vektor charakterisiert). Sei $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$ ein neuronaler Netzwerkgraph mit Fiedler-Vektor $\mathbf{f} = (f_1, \dots, f_n)^\top$ (normierter zweiter Eigenvektor der Laplace-Matrix). Ein Knotenpaar (v_i, v_j) ist genau dann verknüpfbar im Sinne einer positiven Kapazitätssteigerung, wenn

$$(f_i - f_j)^2 \geq \gamma_{\min} > 0, \quad (10.1)$$

wobei $\gamma_{\min}$ eine problemabhängige positive Konstante ist. Insbesondere ist das Paar (v_i, v_j) mit maximalem $(f_i - f_j)^2$ das optimal verknüpfbare Knotenpaar.

Beweis. Aus Theorem 3.3 (vgl. Fiedler, 1973) gilt für die Fiedler-Wert-Änderung beim Hinzufügen von Kante (v_i, v_j) :

$$\lambda_2(\mathcal{G} + (v_i, v_j)) - \lambda_2(\mathcal{G}) \geq \frac{(f_i - f_j)^2}{n - 1}.$$

Nach Theorem 4.2 ist jede Verbesserung von λ_2 mit einer positiven Kapazitätssteigerung assoziiert (die algebraische Konnektivität kontrolliert den Informationsfluss durch das Netz). Daher gilt: $\text{VCdim}(\mathcal{H}_{\mathcal{G}+(v_i, v_j)}) > \text{VCdim}(\mathcal{H}_{\mathcal{G}})$ genau dann, wenn $\lambda_2(\mathcal{G} + (v_i, v_j)) > \lambda_2(\mathcal{G})$, d.h. genau dann, wenn $(f_i - f_j)^2 > 0$. Die positive Konstante $\gamma_{\min} = (n-1)^{-1} \cdot \inf_{\mathbf{f}} \{(f_i - f_j)^2 : (f_i - f_j)^2 > 0\}$ existiert, da $\mathbf{f}$ normiert und n endlich ist. $\square$

Theorem 10.16 (Transitivität der Verknüpfbarkeit über Zellen und Bereiche). Seien $B_{j_1}, B_{j_2}, B_{j_3} \in \mathcal{B}$ drei Zellen des hierarchischen Netzwerkgraphen. Falls B_{j_1} mit B_{j_2} verknüpft ist und B_{j_2} mit B_{j_3} verknüpft ist, dann ist auch B_{j_1} mit B_{j_3} verknüpfbar. Formal:

$$\left(\exists e_1 \in (B_{j_1}, B_{j_2}) \right) \wedge \left(\exists e_2 \in (B_{j_2}, B_{j_3}) \right) \Rightarrow \left(\exists \text{ Pfad } B_{j_1} \rightarrow B_{j_3} \right), \quad (10.2)$$

und die Kapazitätssteigerung durch eine direkte Kante (v_{j_1}, v_{j_3}) ist mindestens so groß wie das Produkt der Einzelgewinne:

$$\Delta \text{VCdim}_{j_1 \rightarrow j_3} \geq \frac{\Delta \text{VCdim}_{j_1 \rightarrow j_2} \cdot \Delta \text{VCdim}_{j_2 \rightarrow j_3}}{\text{VCdim}_{\max}}. \quad (10.3)$$

Beweis. Pfad-Existenz. Per Graphentheorie ist in einem zusammenhängenden Graphen (Proposition: Der neuronale Netzwerkgraph ist nach Abschnitt 10.3 zusammenhängend) für jedes Knotenpaar (v_i, v_k) ein Pfad vorhanden. Die Transitivitätseigenschaft folgt direkt aus dem Geschlossenheitsaxiom der Zusammenhangskomponenten.

Kapazitätsbeschränkung (10.3). Sei $\text{VCdim}_\ell = \text{VCdim}(\mathcal{H}_{\mathcal{G}_\ell})$ die VC-Dimension nach der ℓ -ten Verbindung. Die Binomialschranke für Zusammensetzung von Hypothesenräumen (Blumer et al., 1989) ergibt:

$$\text{VCdim}(\mathcal{H}_{\mathcal{G}_1} \circ \mathcal{H}_{\mathcal{G}_2}) \geq \frac{\text{VCdim}(\mathcal{H}_{\mathcal{G}_1}) \cdot \text{VCdim}(\mathcal{H}_{\mathcal{G}_2})}{\text{VCdim}_{\max}},$$

wobei $\text{VCdim}_{\max}$ die maximale VC-Dimension über alle Teilhypothesen ist. Einsetzen von $\text{VCdim}(\mathcal{H}_{\mathcal{G}_1}) = \text{VCdim}_0 + \Delta \text{VCdim}_{j_1 \rightarrow j_2}$ und $\text{VCdim}(\mathcal{H}_{\mathcal{G}_2}) = \text{VCdim}_0 + \Delta \text{VCdim}_{j_2 \rightarrow j_3}$ sowie Subtraktion von $\text{VCdim}_0^2 / \text{VCdim}_{\max}$ liefert (10.3). $\square$

Lemma 10.17 (Verknüpfbarkeit und Spektrallücke). *Sei $\Delta_{\text{sp}} = \lambda_3 - \lambda_2$ die Spektrallücke des Graphen. Je größer Δ_{sp} , desto mehr Knotenpaare (v_i, v_j) sind verknüpfbar:*

$$|\{(v_i, v_j) : (f_i - f_j)^2 \geq \gamma_{\min}\}| \geq \frac{n \cdot \Delta_{\text{sp}}}{2 \lambda_n} \cdot (n - 1), \quad (10.4)$$

wobei λ_n der größte Laplace-Eigenwert ist.

Beweis. Der normierte Fiedler-Vektor $\mathbf{f}$ mit $\|\mathbf{f}\|_2 = 1$ hat nach dem Rayleigh-Quotient-Prinzip eine Streuung $\text{Var}(f) = \mathbb{E}[f^2] - (\mathbb{E}[f])^2 \geq \lambda_2 / \lambda_n$ (da der Fiedler-Wert die Rayleigh-Minimalform ist und $\|\mathbf{f}\| = 1$). Für $\Delta_{\text{sp}} > 0$ gilt, dass die auf λ_3 -Eigenvektoren projizierten Komponenten von $\mathbf{f}$ vernachlässigbar sind, sodass die Streuung von $\mathbf{f}$ mindestens $\Delta_{\text{sp}} / (2 \lambda_n)$ beträgt. Paare (v_i, v_j) mit $(f_i - f_j)^2 \geq \gamma_{\min}$ entsprechen Paaren mit hinreichend großem Komponentenunterschied. Ein Counting-Argument via Chebyshev-Ungleichung zeigt, dass mindestens der Anteil $\Delta_{\text{sp}} / (2 \lambda_n)$ aller Paare diese Bedingung erfüllt. $\square$

Theorem 10.18 (Vollständige Verknüpfbarkeit des Hierarchiegraphen). *Ein hierarchischer Netzwerkgraph $\mathcal{H}_{\text{hier}}$ ist vollständig verknüpfbar, falls für alle Bereiche $A_i, A_{i'} \in \mathcal{A}$ und alle Zellen $B_j \in A_i, B_{j'} \in A_{i'}$ mindestens ein verknüpfbares Knotenpaar $(v \in G_{B_j}, v' \in G_{B_{j'}})$ existiert. Eine hinreichende Bedingung ist:*

$$\lambda_2(\mathcal{G}) > 0 \quad \text{und} \quad \Delta_{\text{sp}} \geq \frac{2 \lambda_n}{n(n-1)} \cdot s, \quad (10.5)$$

wobei $s = |\mathcal{A}|$ die Anzahl der Bereiche ist.

Beweis. Aus $\lambda_2 > 0$ folgt, dass der Graph zusammenhängend ist (Fiedler, 1973). Aus Lemma 10.17 unter der Bedingung (10.5) folgt, dass mindestens $s \cdot (n - 1)$ Knotenpaare verknüpfbar sind – genug, um für jeden der s Bereiche mindestens ein verknüpfbares Paar zu garantieren. Da die Bereiche per Konstruktion die Zellen $\mathcal{B}$ überdecken und die Zellen die Knoten $\mathcal{V}$, folgt die vollständige Verknüpfbarkeit. $\square$

Korollar 10.19 (OMGR erhält vollständige Verknüpfbarkeit). *Der OMGR-Algorithmus (chapter 9, Algorithmus 2) wählt stets das Knotenpaar mit maximalem $(f_i - f_j)^2$ (Schritt 5). Damit gilt: Nach k^* OMGR-Schritten ist die Spektrallücke $\Delta_{\text{sp}}(\mathcal{G}')$ nicht kleiner als vor der Restrukturierung, und die vollständige Verknüpfbarkeit bleibt erhalten.*

Beweis. Jede vom OMGR-Algorithmus hinzugefügte Kante (v_i, v_j) verbindet das Knotenpaar mit maximalem Fiedler-Abstand $(f_i - f_j)^2$. Nach dem Nachteil-freien Fiedler-Satz (Fiedler, 1973) erhöht das Hinzufügen einer Kante den Fiedler-Wert λ_2 nie, kann ihn aber erhöhen. Da OMGR das Optimalpaar wählt, ist der Anstieg von λ_2 maximal unter allen möglichen Kanten. Die entfernte Kante senkt λ_2 um höchstens 2 (Spektralnorm-Argument aus chapter 3); die hinzugefügte erhöht ihn um mindestens $(f_i - f_j)^2/(n - 1)$. Die OMGR-Wahl garantiert $(f_i - f_j)^2/(n - 1) \geq 2$ für den ausgewählten Ersatz – daher bleibt $\lambda_2(\mathcal{G}') \geq \lambda_2(\mathcal{G})$, und die Bedingung (10.5) bleibt erfüllt. $\square$

10.4 Grundsatz 3: Ionische Verschaltung mit zustandsabhängiger Leitfähigkeit

Das dritte und biologisch profoundeste Grundprinzip ist die *ionische Verschaltung*. Unser Modell basiert auf dem *Ionotronic Reconfigurable Fabric* (IRF) [2], das ionisch dotiertes Wasservolumen als gleichzeitigen **Leiter, Schalter und Speicher** nutzt und damit die drei in klassischer CMOS-Architektur strikte getrennten Grundfunktionen in einem einzigen dynamischen Medium vereint. Diese *dreifache Simultaneität* (Triplexität) ist der Schlüssel zur Modellierung neuronaler Verschaltungsdynamik.

Im biologischen Gehirn kontrollieren Ionenkanäle – Na^+ , K^+ , Ca^{2+} , Cl^- – die synaptische Leitfähigkeit. Im IRF-Modell übernimmt die *Ionenkonzentration* c_k der extrazellulären Elektrolytlösung um die Zellen diese Rolle: Die elektrische Leitfähigkeit der ionischen Flüssigkeit ist nach dem Kohlrausch-Gesetz [2]

$$\sigma_k = \sum_i z_i \mu_i c_i^{(k)} F, \quad (10.6)$$

wobei z_i die Wertigkeit, μ_i die elektrophoretische Beweglichkeit, $c_i^{(k)}$ die molare Konzentration des i -ten Ionentyps im Zustand k und F die Faraday-Konstante sind. Durch die Wahl verschiedener Ionentypen und Konzentrationen – von niedrigkonzentriertem Puffer ($\sigma \sim 10^{-3} \text{ S/m}$) bis zu konzentrierter KCl-Lösung ($\sigma \sim 10 \text{ S/m}$) – entsteht ein über viele Größenordnungen *programmierbares Leitfähigkeitsspektrum*.

Der Schaltmechanismus des IRF beruht auf dem *Elektrowetting-on-Dielectric*-Prinzip (EWOD) [2]. Ein Gate-Potential V_G steuert den Kontaktwinkel θ der ionischen Flüssigkeit gemäß der Young-Lippmann-Gleichung:

$$\cos \theta(V_G) = \cos \theta_0 + \frac{\varepsilon_0 \varepsilon_r}{2 \gamma_{\text{LG}} d} V_G^2 =: \cos \theta_0 + \eta_{\text{EWOD}} V_G^2, \quad (10.7)$$

wobei θ_0 der Gleichgewichtskontaktwinkel ohne Spannung, γ_{LG} die Grenzflächenspannung Flüssigkeit-Gas, d die Dielektrikumdicke, ε_r die relative Permittivität des Dielektrikums und $\eta_{\text{EWOD}} = \varepsilon_0 \varepsilon_r / (2 \gamma_{\text{LG}} d)$ die EWOD-Effizienz sind. Die Kanalleitfähigkeit des resultierenden Ionotronic Field-Effect Transistor (IoFET) ist [2]:

$$G_{\text{Kanal}}(V_G) = G_{\text{max}} \cdot H(\cos \theta(V_G) - \cos \theta_c), \quad (10.8)$$

wobei $G_{\text{max}} = \sigma_k \cdot A_{\text{Kanal}} / L_{\text{Kanal}}$ die Vollleitfähigkeit, $H(\cdot)$ die Heaviside-Stufenfunktion und θ_c der kritische Kontaktwinkel für den Ein/Aus-Übergang sind. Im **linearen Betriebsbereich** ($V_G - V_T \ll V_{\text{DS}}$) gilt das IoFET-Analogon der MOSFET-Shockley-Gleichung:

$$I_{\text{DS,lin}} = G_0 \eta_{\text{EWOD}} (V_G - V_T) V_{\text{DS}}, \quad (10.9)$$

und im **Sättigungsbereich** (vollständige Benetzung):

$$I_{\text{DS,sat}} = \frac{1}{2} G_0 \eta_{\text{EWOD}} (V_G - V_T)^2. \quad (10.10)$$

Die vier Betriebszustände des IoFET – OFF, SUBTHRESHOLD, LINEAR, SATURATION – definieren formal die vier möglichen *Leitzustandsklassen* $k \in \{1, 2, 3, 4\}$ um eine Zelle B_j , je nach anliegender Gate-Spannung $V_G^{(k)}$ und Ionenkonzentration $c^{(k)}$:
Zusätzlich dienen höhere Leitzustände $k > 4$ der Modellierung metabolischer Modulationen durch unterschiedliche Ionenspezies mit verschiedenen Konzentrationsgradienten $c^{(k)}$.

Definition 10.20 (Ionisches Leitfähigkeitsmodell auf IRF-Basis). *Sei $K \in \mathbb{N}$ die Anzahl der Leitzustände. Für jeden Zustand $k \in \{1, \dots, K\}$ sei σ_k die ionische Leitfähigkeit des Elektrolytmediums um die Zellen gemäß (10.6), gesteuert durch die Gate-Spannung $V_G^{(k)}$ via (10.7)–(10.8). Der ionische Kontextvektor $\boldsymbol{\iota} = (\iota_1, \dots, \iota_K) \in \Delta^{K-1}$ mit $\sum_k \iota_k = 1$, $\iota_k \geq 0$ beschreibt die normierte Aktivierungsgewichtung der Zustände; physikalisch entspricht ι_k dem relativen Zeitanteil, in dem Zustand k aktiv ist (Duty-Cycle-Kodierung).*

Ein ionisch verschalteter neuronaler Netzwerkgraph ist

$$\mathcal{G}_{\text{ion}} = (\mathcal{V}, \mathcal{E}, \{\mathbf{W}^{(k)}\}_{k=1}^K, \boldsymbol{\iota}),$$

wobei die Gewichtsmatrix $\mathbf{W}^{(k)} \in \mathbb{R}^{n \times n}$ im Zustand k die Verbindungsstärken bei Leitfähigkeit σ_k kodiert. Formal gilt

$$\mathbf{W}^{(k)} = \frac{\sigma_k}{\sigma_1} \mathbf{W}^{(1)} + \Delta \mathbf{W}^{(k)}, \quad (10.11)$$

wobei $\Delta \mathbf{W}^{(k)}$ die zustandsspezifische Anpassungsmatrix ist (etwa durch ionische Plastizität, s. u.). Die effektive Gewichtsmatrix beim ionischen Kontext $\boldsymbol{\iota}$ ist

$$\mathbf{W}_{\text{eff}}(\boldsymbol{\iota}) = \sum_{k=1}^K \iota_k \cdot \mathbf{W}^{(k)}. \quad (10.12)$$

Die durch $\mathcal{G}_{\text{ion}}$ realisierte Funktionenfamilie ist

$$\mathcal{F}_{\text{ion}} = \{f_{\mathcal{G}}(\cdot; \mathbf{W}_{\text{eff}}(\boldsymbol{\iota})) \mid \boldsymbol{\iota} \in \Delta^{K-1}\}.$$

Bemerkung 10.21 (IRF-Entsprechung der Leitzustände und ionische Plastizität). *Die K Leitzustände haben folgende physikalische Entsprechung im IRF [2]:*

- $k = 1$ (OFF): Kein leitender Pfad; Oberflächenspannung zieht Flüssigkeit zurück. Biologisch: ruhende Synapse. $\mathbf{W}^{(1)} \approx \mathbf{0}$.
- $k = 2$ (SUBTHRESHOLD): Exponentiell kleiner Restleckstrom ($I \propto \exp(V_G/nV_{\text{th}})$). Biologisch: inhibitorische K^+ -Ausstromkanäle; $\mathbf{W}^{(2)} < 0$ (inhibitorisch).
- $k = 3$ (LINEAR): Ohmsche Vollleitung $G = G_0 \eta_{\text{EWOD}}(V_G - V_T)$. Biologisch: Na^+ -getriebene Aktionspotenzial-Weiterleitung; große exzitatorische Gewichte $\mathbf{W}^{(3)} \gg 0$.
- $k = 4$ (SATURATION): Maximale Kanalbenetzung, $G = G_{\text{max}} \sigma_4 / \sigma_3 \cdot G_3$. Biologisch: Ca^{2+} -abhängige Transmitterfreisetzung und synaptische Plastizitätsmodulation; $\mathbf{W}^{(4)}$ entspricht der Langzeitpotenzierungs-Matrix.

k	Zustand	Gate-Bedingung	Physik
1	OFF	$V_G < V_T/2$	Kanal gesperrt, Rückzug durch Oberflächenspannung
2	SUBTHRESHOLD	$V_T/2 \leq V_G < V_T$	Teilbenetzung, exponentieller Strom
3	LINEAR	$V_G \geq V_T, V_{DS}$ klein	Ohmsche Leitung, $I \propto V_G$
4	SATURATION	$V_G \geq V_T, V_{DS}$ groß	Maximale Leitfähigkeit

Tabelle 10.1: Leitzustände für $k = 1, 2, 3, 4$.

- $k > 4$: Metabolische Modulation durch weitere Ionenspezies (z.B. Cl^- , Mg^{2+} , HCO_3^-); entspricht langsamen neuromodulatorischen Rezeptoren.

Durch wiederholte gemeinsame Aktivierung zweier Kanäle k und k' verändert sich nach dem Hebbischen Plastizitätsprinzip [2] die ionische Konzentration im Verbindungsknoten:

$$\Delta\sigma_{\text{Kanal}} = \alpha \cdot f_{\text{Aktivierung}} \cdot \Delta t, \quad (10.13)$$

was in der Gewichtsmatrix durch $\Delta W_{ij}^{(k)} = \alpha f_{\text{akt}} \Delta t \cdot \sigma_k / F$ abgebildet wird. Die unterschiedliche Ionenflüssigkeit – d.h. die Konzentrationsgradienten $c^{(k)}$ in der extrazellulären Lösung um Knoten- und Kanten-Zellen – kontrolliert gemäß (10.6), welcher Leitzustand dominiert.

Definition 10.22 (Ionisches Verschaltungsfeld um eine Zelle). Sei $B_j \in \mathcal{B}$ eine Zelle des hierarchischen Netzwerkgraphen, G_{B_j} ihr Zell-Graph und $q_j = |V(G_{B_j})|$ die Anzahl ihrer Knoten. Das ionische Verschaltungsfeld $\Phi(B_j) \in \mathbb{R}^{K \times q_j}$ beschreibt für alle K Leitzustände und alle Knoten in B_j die lokale Leitfähigkeit nach dem IoFET-Modell (10.6)–(10.8):

$$\Phi_{k,i}(B_j) = G_{\text{Kanal}}(V_G^{(k)}) \cdot \left(\sum_{(v_i, v_h) \in E(G_{B_j})} W_{ih}^{(k)} + \sum_{(v_h, v_i) \in E(G_{B_j})} W_{hi}^{(k)} \right),$$

d.h. $\Phi_{k,i}(B_j)$ ist die totale gate-gewichtete Leitfähigkeit von Knoten v_i im Leitzustand k . Der normierte ionische Zustand einer Zelle ist

$$\bar{\iota}(B_j) = \iota \odot \frac{\|\Phi(B_j)\|_1}{K},$$

wobei $\odot$ das elementweise Produkt und $\|\cdot\|_1$ die Spaltensumme der Leitfähigkeitsmatrix bezeichnet. Der Kanalwiderstand zwischen zwei benachbarten Knoten v_i, v_h im Zustand k ist gemäß [2]:

$$R_{ih}^{(k)} = \frac{L_{ih}}{\sigma_k \cdot A_{ih}}, \quad (10.14)$$

wobei L_{ih} die effektive Kanallänge und A_{ih} der Kanalquerschnitt der Kante (v_i, v_h) sind, was $W_{ih}^{(k)} = 1/R_{ih}^{(k)}$ ergibt.

Theorem 10.23 (EWOD-vermittelter Zustandsübergang und Leitfähigkeitsstetigkeit). Seien k, k' zwei Leitzustände mit Gate-Spannungen $V_G^{(k)}$ und $V_G^{(k')}$. Die effektive Kanalleitfähigkeit G_{Kanal} ist eine stetige, nicht-abnehmende Funktion der Gate-Spannung. Insbesondere gilt für den Leitfähigkeitsunterschied zwischen zwei Zuständen:

$$\left| G_{\text{Kanal}}(V_G^{(k)}) - G_{\text{Kanal}}(V_G^{(k')}) \right| \leq G_{\text{max}} \cdot \eta_{\text{EWOD}} \cdot \left| (V_G^{(k)})^2 - (V_G^{(k')})^2 \right|. \quad (10.15)$$

Damit ist auch die Gewichtsmatrix $\mathbf{W}^{(k)}$ Lipschitz-stetig in $V_G^{(k)}$:

$$\|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F \leq C_W \cdot \eta_{\text{EWOD}} \cdot |V_G^{(k)} + V_G^{(k')}| \cdot |V_G^{(k)} - V_G^{(k')}|, \quad (10.16)$$

wobei $C_W = G_{\text{max}} \cdot \max_{i,h}(L_{ih}/A_{ih}) \cdot |\mathcal{E}|^{1/2}$ eine von der Netzgeometrie abhängige Konstante ist.

Beweis. Schritt 1: Stetigkeit von G_{Kanal} . Aus (10.7) folgt, dass $\cos \theta(V_G)$ differenzierbar und damit stetig in V_G ist (da das Polynom $\eta_{\text{EWOD}} V_G^2$ stetig ist). Die Heaviside-Funktion in (10.8) erzeugt eine Sprungstelle bei $\theta(V_G) = \theta_c$ (Schwellspannung V_T), die jedoch in der physikalischen Realisierung durch das Subthreshold-Regime (Eq. 10.9) geglättet wird; für unsere Zwecke betrachten wir G_{Kanal} als Heaviside-stetig für $V_G \neq V_T$.

Schritt 2: Lipschitz-Schranke für G . Für $V_G^{(k)}, V_G^{(k')} > V_T$ gilt nach (10.9):

$$|G_{\text{Kanal}}(V_G^{(k)}) - G_{\text{Kanal}}(V_G^{(k')})| = G_0 \eta_{\text{EWOD}} |V_G^{(k)} - V_G^{(k')}| \cdot V_{\text{DS}} \leq G_{\text{max}} \eta_{\text{EWOD}} |(V_G^{(k)})^2 - (V_G^{(k')})^2|,$$

wobei wir $G_0 V_{\text{DS}} \leq G_{\text{max}}$ im Sättigungsbereich und $|a^2 - b^2| = |a - b| \cdot |a + b| \geq |a - b| \cdot V_{\text{DS}}$ ausnutzen.

Schritt 3: Übertragung auf $\mathbf{W}^{(k)}$. Da $W_{ih}^{(k)} = G_{\text{Kanal}}(V_G^{(k)}) \cdot (L_{ih}/A_{ih})^{-1}$ und die Frobenius-Norm über alle $|\mathcal{E}|$ Kanten summiert:

$$\|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F^2 \leq |\mathcal{E}| \cdot G_{\text{max}}^2 \eta_{\text{EWOD}}^2 |(V_G^{(k)})^2 - (V_G^{(k')})^2|^2 \cdot \max_{i,h} (L_{ih}/A_{ih})^2.$$

Wurzelziehen ergibt (10.16) mit $C_W = G_{\text{max}} \max_{i,h} (L_{ih}/A_{ih}) |\mathcal{E}|^{1/2}$. $\square$

Theorem 10.24 (Kapazitätswachstum durch ionische Mehrzustandsverschaltung). *Sei $\mathcal{G}_{\text{ion}}$ ein ionisch verschalteter neuronaler Netzwerkgraph mit K Leitzuständen und Leitfähigkeiten $\sigma_1 \leq \sigma_2 \leq \dots \leq \sigma_K$ gemäß (10.6). Dann gilt für die VC-Dimension der zugehörigen Funktionenfamilie:*

$$\text{VCdim}(\mathcal{F}_{\text{ion}}) \geq K \cdot \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(1)})}) - \binom{K}{2} \cdot \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(1)} - \mathbf{W}^{(2)})}), \quad (10.17)$$

und für den Kapazitätswachstum gegenüber einem einfach-gewichteten Graphen $\mathcal{G}(\mathbf{W})$ mit $\mathbf{W} = \mathbf{W}_{\text{eff}}(\boldsymbol{\iota}^*)$ gilt:

$$\text{VCdim}(\mathcal{F}_{\text{ion}}) - \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W})}) \geq (K - 1) \cdot \Omega(p \cdot L), \quad (10.18)$$

wobei $p = |\mathcal{E}|$ die Parameteranzahl und L die Tiefe des Netzes ist. Die Monotonie $\sigma_k \nearrow$ impliziert $\|\mathbf{W}^{(k)}\|_F \nearrow$, sodass die Schranken (10.17)–(10.18) scharf sind.

Beweis. Schritt 1: Shattering-Argument. Die Funktionenfamilie $\mathcal{F}_{\text{ion}}$ ist parametrisiert durch $\boldsymbol{\iota} \in \Delta^{K-1}$. Für K reine Leitzustände ($\boldsymbol{\iota} = \mathbf{e}_k$, Einheitsvektoren) enthält $\mathcal{F}_{\text{ion}}$ als Teilklassen $\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})}$ für alle $k = 1, \dots, K$. Da σ_k nach Annahme paarweise verschieden sind, gilt $\mathbf{W}^{(k)} \neq \mathbf{W}^{(k')}$ für $k \neq k'$ (aus (10.11) und $\sigma_k \neq \sigma_{k'}$), also sind die K Teilklassen echt verschieden.

Schritt 2: Inklusion der reinen Leitzustand-Klassen. Da $\{\mathbf{e}_1, \dots, \mathbf{e}_K\} \subset \Delta^{K-1}$, gilt $\bigcup_{k=1}^K \mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})} \subseteq \mathcal{F}_{\text{ion}}$. Nach Sauer–Shelah (1972) addiert sich die VC-Dimension bei Vereinigung:

$$\text{VCdim}\left(\bigcup_{k=1}^K \mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})}\right) \geq \max_k \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})}) + (K - 1) \cdot \Omega(p \cdot L).$$

Die $K - 1$ additiven Terme entstehen aus den rationalen Konvexkombinationen auf dem Simplex Δ^{K-1} : jede Mischung $\boldsymbol{\iota} = \lambda \mathbf{e}_k + (1 - \lambda) \mathbf{e}_{k'}$ realisiert eine Gewichtsmatrix $\lambda \mathbf{W}^{(k)} + (1 - \lambda) \mathbf{W}^{(k')}$, die gemäß (10.11) eine neue, von den Randklassen verschiedene Leitfähigkeitskonfiguration definiert.

Schritt 3: Überschneidungs-Abzug. Die paarweisen Überschneidungen $\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})} \cap \mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k')})}$ entsprechen den Mittelpunkt-Gewichtsmatrizen $(\mathbf{W}^{(k)} + \mathbf{W}^{(k')})/2$, deren VC-Dimension durch $\text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)} - \mathbf{W}^{(k')})})$ beschränkt wird. Einschluss-Ausschluss über alle $\binom{K}{2}$ Paare ergibt (10.17).

Schritt 4: Vergleich mit einfach-gewichtetem Graphen. Für das optimale $\iota^* = \arg \max_{\iota} \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}_{\text{eff}}(\iota))})$ gilt $\text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W})}) \leq \max_k \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})})$. Damit ist der Zuwachs durch ionische Verschaltung mindestens $(K - 1) \cdot \Omega(pL)$, was (10.18) beweist.

Schritt 5: Schärfe für monotone Leitfähigkeiten. Da σ_k strikt monoton wächst, wächst auch $\|\mathbf{W}^{(k)}\|_F$ nach (10.11) monoton: $\|\mathbf{W}^{(k)}\|_F \leq \|\mathbf{W}^{(k+1)}\|_F$. Damit sind die Klassen $\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})}$ nach VC-Dimension geordnet, und der Maximalterm in der Sauer-Shelah-Summe wird durch $k = K$ erlangt – die Schranken sind für diese Wahl scharf. $\square$

Korollar 10.25 (Lineare Skalierung des Kapazitätswachses mit der Leitzustandsanzahl). *Der Kapazitätswuchs durch ionische Mehrzustandsverschaltung wächst linear in der Anzahl K der Leitzustände:*

$$\text{VCdim}(\mathcal{F}_{\text{ion}}) \geq K \cdot \Omega(p \cdot L).$$

Ein IRF-Modell mit $K = 4$ IoFET-Betriebszuständen (OFF, SUBTHRESHOLD, LINEAR, SATURATION) hat vierfaches Kapazitätspotenzial gegenüber einem einfach-synaptischen Netz.

Beweis. Direkt aus Theorem 10.24 (10.18) mit der Beobachtung, dass der Subtraktionsterm $\binom{K}{2} \cdot \text{VCdim}(\cdot)$ von Ordnung $K^2 \cdot o(pL)$ ist – also für $K \ll p \cdot L$ vernachlässigbar. Damit dominiert die untere Schranke linear in K . $\square$

Theorem 10.26 (Ionische Zustände durch Subgraph Algorithmus identifiziert). *Sei $\mathcal{G}_{\text{ion}}$ ein ionisch verschalteter Netzwerkgraph mit IoFET-basierten Leitzuständen $\{\mathbf{W}^{(k)}\}_{k=1}^K$ nach Definition 10.20. Der Subgraph Algorithmus kann auf die binarisierten Zustandsmatrizen $\hat{M}_{ih}^{(B_j, k)} = \mathbf{1}[|W_{ih}^{(k)}| > \tau]$ angewandt werden, um für jede Zelle B_j die dominante ionische Konfiguration zu ermitteln:*

$$k^*(B_j) = \arg \max_{k \in \{1, \dots, K\}} \text{LCS}(\mathbf{r}^{(B_j, k)}, \mathbf{r}^{(\text{ref})}), \quad (10.19)$$

wobei $\mathbf{r}^{(B_j, k)}$ die Zeilensignatur der binarisierten Matrix $\hat{M}^{(B_j, k)}$ und $\mathbf{r}^{(\text{ref})}$ eine Referenzsignatur eines Ziel-Leitverhaltens sind. Der Schwellwert τ entspricht physikalisch der IoFET-Schwellspannung: $\tau = G_0 \eta_{\text{EWOD}} V_T V_{\text{DS}}$. Die Gesamtlaufzeit für alle Zellen und Leitzustände ist

$$T_{\text{ion}} = O(t \cdot K \cdot q_{\text{max}}^3),$$

wobei t die Zellenanzahl und q_{max} die maximale Zell-Knotenanzahl ist.

Beweis. Für jede Zelle B_j und jeden Leitzustand k wird die binarisierte Matrix $\hat{M}^{(B_j, k)}$ mit dem physikalisch motivierten Schwellwert $\tau = G_0 \eta_{\text{EWOD}} V_T V_{\text{DS}}$ gebildet: Einträge oberhalb von τ entsprechen dem IoFET im Ein-Zustand (Zustände LINEAR/SATURATION), Einträge darunter dem Aus-Zustand (OFF/SUBTHRESHOLD). Der Subgraph Algorithmus berechnet die kanonische Signatur $\mathbf{r}^{(B_j, k)}$ in Zeit $O(q_j^3)$ und vergleicht sie per LCS mit der Referenzsignatur. Das Maximum über k liefert den dominanten Leitzustand. Über alle t Zellen und K Zustände summiert ergibt sich $T_{\text{ion}} = O(t \cdot K \cdot q_{\text{max}}^3)$. $\square$

Theorem 10.27 (Optimale ionische Kontextsteuerung für maximalen Kapazitätsgewinn). *Für einen ionisch verschalteten Netzwerkgraphen $\mathcal{G}_{\text{ion}}$ mit K Leitzuständen und gegebener Eingabeverteilung μ ist der optimale ionische Kontext*

$$\boldsymbol{\iota}^* = \arg \max_{\boldsymbol{\iota} \in \Delta^{K-1}} I_\mu(X; Y_{\mathcal{G}_{\text{ion}}}(\boldsymbol{\iota})) \quad (10.20)$$

derjenige Kontext, der die gegenseitige Information $I_\mu(X; Y)$ zwischen Eingabe und Ausgabe maximiert. Der Gewinn gegenüber dem Einstands-Kontext $\boldsymbol{\iota}_0 = \mathbf{e}_1$ (OFF-Zustand) ist:

$$I_\mu(X; Y(\boldsymbol{\iota}^*)) - I_\mu(X; Y(\boldsymbol{\iota}_0)) \geq (K - 1) \cdot c_{\text{MI}} \cdot H(X), \quad (10.21)$$

wobei $c_{\text{MI}} > 0$ von Theorem 7.3 übernommen wird. Physikalisch entspricht dies der Wahl der optimalen Gate-Spannungskombination $(V_G^{(1)}, \dots, V_G^{(K)})$, die gemäß (10.7) die Information zwischen Eingabe und Netzwerkausgabe maximiert.

Beweis. Die Zielfunktion $I_\mu(X; Y(\boldsymbol{\iota}))$ ist konkav in $\boldsymbol{\iota}$ – dies folgt daraus, dass $Y(\boldsymbol{\iota}) = f_{\mathcal{G}}(\mathbf{W}_{\text{eff}}(\boldsymbol{\iota}))$ eine affine Funktion von $\boldsymbol{\iota}$ ist und die gegenseitige Information konkav in der Kanalmatrix ist (Cover & Thomas, 2006, Korollar 2.7.4). Das Maximum einer konkaven Funktion auf dem Simplex Δ^{K-1} existiert und ist eindeutig. Im IRF-Modell liefert jeder Leitzustand k eine durch σ_k bestimmte Kanalkapazität; da σ_k nach Annahme paarweise verschieden sind (verschiedene Ionenkonzentrationen nach (10.6)), stellt jeder Zustand eine unabhängige Informationspfad-Komponente bereit. Nach Theorem 7.3 ist das Informationsgewinn-Inkrement pro zusätzlichem Zustand mindestens $c_{\text{MI}} \cdot H(X)$, woraus (10.21) folgt. $\square$

Lemma 10.28 (Kontinuierlicher Leitfähigkeitsübergang und Lipschitz-Stetigkeit). *Die Funktion $\boldsymbol{\iota} \mapsto f_{\mathcal{G}_{\text{ion}}}(\mathbf{x}; \boldsymbol{\iota})$ ist Lipschitz-stetig in $\boldsymbol{\iota}$ mit Konstante*

$$\text{Lip}(\boldsymbol{\iota}) \leq B_x \cdot L \cdot \max_{k \neq k'} \|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F, \quad (10.22)$$

wobei B_x die Eingabenorm-Schranke und L die Netztiefe sind. Da $\|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F \leq C_W \eta_{\text{EWOD}} |V_G^{(k)} + V_G^{(k')}| \cdot |V_G^{(k)} - V_G^{(k')}|$ nach Theorem 10.23, folgt: Kleine Änderungen der Gate-Spannung – und damit der Ionenflüssigkeit – führen zu kleinen Änderungen der Netzwerkausgabe.

Beweis. Schreibe $f_{\mathcal{G}}(\mathbf{x}; \boldsymbol{\iota}) = \sigma_{\text{act}}(\mathbf{W}_{\text{eff}}(\boldsymbol{\iota})\mathbf{x} + \mathbf{b})$. Für zwei Kontexte $\boldsymbol{\iota}$ und $\boldsymbol{\iota}'$ gilt:

$$\begin{aligned} \|f(\mathbf{x}; \boldsymbol{\iota}) - f(\mathbf{x}; \boldsymbol{\iota}')\|_2 &\leq \|\sigma_{\text{act}}\|_{\text{Lip}} \cdot \|(\mathbf{W}_{\text{eff}}(\boldsymbol{\iota}) - \mathbf{W}_{\text{eff}}(\boldsymbol{\iota}'))\mathbf{x}\|_2 \\ &\leq \|\mathbf{W}_{\text{eff}}(\boldsymbol{\iota}) - \mathbf{W}_{\text{eff}}(\boldsymbol{\iota}')\|_F \cdot \|\mathbf{x}\|_2 \\ &= \left\| \sum_k (\iota_k - \iota'_k) \mathbf{W}^{(k)} \right\|_F \cdot B_x \\ &\leq B_x \cdot \|\boldsymbol{\iota} - \boldsymbol{\iota}'\|_1 \cdot \max_k \|\mathbf{W}^{(k)}\|_F. \end{aligned}$$

Akkumulation über L Schichten ergibt den Faktor L und das Maximum über Differenzen $\|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F$, was (10.22) liefert. Die Verbindung zur EWOD-Physik folgt aus Theorem 10.23: $\text{Lip}(\boldsymbol{\iota}) \leq B_x L C_W \eta_{\text{EWOD}} \max_{k \neq k'} |V_G^{(k)} + V_G^{(k')}| \cdot |V_G^{(k)} - V_G^{(k')}|$. $\square$

Proposition 10.29 (IRF-basierte Leitfähigkeitshierarchie der IoFET-Zustände). *Im IRF-Modell mit $K = 4$ IoFET-Betriebszuständen sind die Gewichtsmatrizen nach aufsteigender*

Gate-Spannung $V_G^{(1)} < V_G^{(2)} < V_G^{(3)} < V_G^{(4)}$ und damit aufsteigender Leitfähigkeit $\sigma_1 < \sigma_2 < \sigma_3 < \sigma_4$ geordnet:

$$\|\mathbf{W}^{(1)}\|_F \leq \|\mathbf{W}^{(2)}\|_F \leq \|\mathbf{W}^{(3)}\|_F \leq \|\mathbf{W}^{(4)}\|_F, \quad (10.23)$$

wobei $\mathbf{W}^{(1)} \approx \mathbf{0}$ (OFF) und $\mathbf{W}^{(2)} \leq 0$ (inhibitorischer SUBTHRESHOLD-Leckstrom). Biologisch entspricht dies der Ionenkanal-Leitfähigkeitshierarchie K^+ (inhibitorisch) $\lesssim$ OFF $\prec$ Na^+ (LINEAR) $\prec$ Ca^{2+} (SATURATION). Diese Hierarchie sorgt für ein monoton wachsendes VC-Potenzial:

$$\text{VCdim}(\mathcal{F}_{\text{ion}}) \geq \text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(4)})}) \cdot K - O(K^2 \cdot pL \cdot \rho^2), \quad (10.24)$$

wobei $\rho = \|\mathbf{W}^{(1)}\|_F / \|\mathbf{W}^{(4)}\|_F \leq 1$ das Verhältnis von minimaler zu maximaler Leitfähigkeit ist. Aus (10.13) folgt zudem, dass ionische Plastizität die Off-diagonal-Terme $\Delta \mathbf{W}^{(k)}$ graduell anpasst und die Hierarchie (10.23) dynamisch verfeinert, was dem Langzeit-Potenzierungsmechanismus biologischer Synapsen entspricht.

Beweis. Hierarchie (10.23): Aus (10.11) gilt $\mathbf{W}^{(k)} = (\sigma_k / \sigma_1) \mathbf{W}^{(1)} + \Delta \mathbf{W}^{(k)}$. Da σ_k mit k wächst (monotone Konzentrationsreihe nach (10.6)) und $\Delta \mathbf{W}^{(k)}$ durch ionische Plastizität (10.13) nicht-negativ wächst ($\alpha \geq 0$, $f_{\text{akt}} \geq 0$), folgt $\|\mathbf{W}^{(k+1)}\|_F \geq \|\mathbf{W}^{(k)}\|_F$ per Dreiecksungleichung.

VC-Schranke (10.24): Da $\|\mathbf{W}^{(4)}\|_F = \max_k \|\mathbf{W}^{(k)}\|_F$ (monotone Hierarchie), dominiert $\text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(4)})})$ den Maximalterm in Theorem 10.24. Die Überschneidungsterme skalieren mit $\|\mathbf{W}^{(k)} - \mathbf{W}^{(k')}\|_F^2 \leq \rho^2 \|\mathbf{W}^{(4)}\|_F^2$ nach (10.23). Einsetzen in (10.17) ergibt (10.24). $\square$

Beweis. In expliziter Rechnung ist $\mathbf{W}_{\text{eff}}(\boldsymbol{\iota}) = \iota_1 \mathbf{W}^{(1)} + \iota_2 \mathbf{W}^{(2)} + \iota_3 \mathbf{W}^{(3)} + \iota_4 \mathbf{W}^{(4)}$. Die VC-Dimension ist eine nicht-lineare Funktion der Gewichtsmatrix-Norm. Für die Hauptachsen-Richtungen ($\boldsymbol{\iota} = \mathbf{e}_k$) ist $\text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{W}^{(k)})}) = \Omega(p \cdot L)$ nach Bartlett & Mendelson (2002) für alle k mit $\mathbf{W}^{(k)} \neq \mathbf{0}$. Einsetzen in Theorem 10.24 und Ersetzen der Überschneidungsterme durch ρ^2 -abhängige Schranken (da $\|\mathbf{W}^{(2)}\|_F = \rho \|\mathbf{W}^{(1)}\|_F$) ergibt das Resultat. $\square$

10.5 Der Dreiklang: Integration der Grundprinzipien mit dem Subgraph Algorithmus

Die drei Grundprinzipien – Minimalität/Eindeutigkeit/Vergleichbarkeit, Verknüpfbarkeit und ionische Verschaltung – sind nicht unabhängig, sondern bilden ein konsistentes, sich gegenseitig verstärkendes Gesamtsystem. Wir formulieren das integrierende Hauptresultat dieser Sektion:

Theorem 10.30 (Integriertes bioinspiriertes Optimalprinzip). Sei $\mathcal{G}_{\text{ion}}^{(*)}$ definiert mit $\mathcal{G}_{\text{ion}}^{(*)} = (\mathcal{V}^*, \mathcal{E}^*, \{\mathbf{W}^{(k)*}\}_{k=1}^K, \boldsymbol{\iota}^*)$ ein ionisch verschalteter neuronaler Netzwerkgraph, der die folgenden drei Bedingungen simultan erfüllt:

- (I) **Minimalität & Eindeutigkeit:** $\mathcal{G}_{\text{ion}}^{(*)}$ ist zellintern minimal im Sinne von Definition 10.3 – kein echter Teilgraph realisiert dieselbe Funktion; die kanonische Signatur $\sigma^*(\mathcal{G}_{\text{ion}}^{(*)})$ ist eindeutig.
- (II) **Verknüpfbarkeit:** Alle Zellpaare $(B_j, B_{j'})$ sind vollständig verknüpfbar im Sinne von Theorem 10.18.

(III) **Ionische Verschaltung:** Der Kontextvektor ι^* ist optimal gemäß Theorem 10.27.

Dann gilt die folgende simultane Schranke:

$$\text{VCdim}(\mathcal{F}_{\text{ion}}^{(*)}) \geq K \cdot c_1 \cdot \frac{d^* \cdot L}{n} \cdot \varrho^* \cdot |\mathcal{E}^*| + (K - 1) \cdot \Omega(|\mathcal{E}^*| \cdot L) + |\mathcal{E}^*|, \quad (10.25)$$

wobei $d^* = |\mathcal{V}_{\text{dead}}^*|$ die Anzahl der toten Neuronen im Minimum ist (typischerweise $d^* = 0$, da Minimalität Aktivierung impliziert), und jede der drei Terme die Beiträge von Restrukturierung, ionischer Mehrzustandsverschaltung und Basiskapazität beschreibt.

Beweis. Die Summe der drei Terme entsteht durch Superposition der einzelnen Schranken:

Term 1 (Restrukturierung). Aus dem Kapazitätsgewinn-Theorem 4.2 folgt, dass die optimale (ϱ^*, k^*) -Restrukturierung einen Kapazitätsgewinn von $c_1(d/n)L\varrho^*|\mathcal{E}^*|$ liefert. Da das Netz minimal ist und $d^* = 0$ (keine toten Neuronen in der Minimaldarstellung), trägt dieser Term mit $c_1 \cdot 0 \cdot (\dots) = 0$ zum rechten Überschuss bei; der Wert d^* ist jedoch als Parameter für Erweiterungen mit partieller Minimalität einbehalten.

Term 2 (Ionische Verschaltung). Aus Korollar 10.25 folgt der Kapazitätsbeitrag der K Leitzustände: mindestens $(K - 1) \cdot \Omega(|\mathcal{E}^*| \cdot L)$.

Term 3 (Basiskapazität). Aus der VC-Grundschränke (4.4) folgt $\text{VCdim}(\mathcal{H}_{\mathcal{G}(\mathbf{w}^{(1)})}) \geq \Omega(|\mathcal{E}^*| \cdot L)$, was den Basisterm liefert.

Summation. Die drei Terme addieren sich auf, da die zugrundeliegenden Hypothesenräume (restrukturierter Graph, ionische Zustände, Basiskapazität) für den optimalen Kontext ι^* und die optimale Struktur $\mathcal{G}^{(*)}$ additiv unabhängige Freiheitsgrade beschreiben. Die Ganzzahligkeitslücken der VC-Dimension sind durch die Ω -Notation in den Konstanten absorbiert. $\square$

Korollar 10.31 (Subgraph Algorithmus als effizientes Werkzeug für alle drei Prinzipien). *Der Subgraph Algorithmus (Epp, 2026) implementiert alle drei Grundprinzipien in einer gemeinsamen Rahmen-Komplexität von $O(t^2 \cdot K \cdot q_{\max}^3)$:*

- **Minimalität/Eindeutigkeit:** Kanonische Normalform und zellinterne Minimalreduktion (Theorem 10.9).
- **Verknüpfbarkeit:** Fiedler-Vektor-gestützte Knotenpaarselektion für optimale Verknüpfung (Korollar 10.19).
- **Ionische Verschaltung:** Dominante Leitzustandsidentifikation per LCS-Maximierung über K Zustände (Theorem 10.26).

Beweis. Für Minimalität: t^2 Paare à $O(q_{\max}^3)$ nach Proposition 10.6. Für Verknüpfbarkeit: Fiedler-Vektor in $O(n^2)$, was für t Zellen $O(t \cdot q_{\max}^2)$ ergibt. Für ionische Verschaltung: $t \cdot K$ Tests à $O(q_{\max}^3)$ nach Theorem 10.26. Die Gesamtkomplexität ist dominiert durch $O(t^2 \cdot K \cdot q_{\max}^3)$. $\square$

Theorem 10.32 (Energieeffizienz des vollständigen bioinspirierten Systems). *Sei $\mathcal{G}_{\text{ion}}^{(*)}$ das vollständig bioinspirierte optimale Netz aus Theorem 10.30. Sein Inferenz-Energieverbrauch ist nach unten durch den informationstheoretischen Wirkungsgrad begrenzt und nach oben durch die Subgraph-komprimierte Struktur beschränkt:*

$$\text{FLOP}_{\min} \leq \text{FLOP}(\mathcal{G}_{\text{ion}}^{(*)}) \leq K \cdot \text{FLOP}(\mathcal{G}_{\min}) = K \cdot O(P q_{\max}^2 + L q_{\max}), \quad (10.26)$$

wobei $\text{FLOP}_{\min} = \Omega(I(X;Y)/\log_2 n)$ die informationstheoretische untere Schranke (Landauer-Prinzip, Shannon, 1948) und $\mathcal{G}_{\min}$ das SGKR-komprimierte Minimal-Netz ist. Das FLOP-Kompressionsverhältnis gegenüber einem vollvernetzten K -Zustands-Netz beträgt

$$\kappa_{\text{ion}} = \frac{\text{FLOP}(\mathcal{G}_{\text{ion}}^{(*)})}{\text{FLOP}(\mathcal{G}_{\text{full},K})} \approx \frac{P}{L}, \quad (10.27)$$

d.h. dasselbe P/L -Verhältnis wie bei einfacher SGKR-Kompression.

Beweis. Die obere Schranke folgt aus Theorem 6.19: Das Minimal-Netz $\mathcal{G}_{\min}$ hat $\text{FLOP} = O(Pq^2 + Lq)$. Mit K Leitzuständen werden K Forward-Passes linear akkumuliert (im Worst-Case simultane Evaluation aller Zustände), was den Faktor K gibt. Der untere Schranke beruht auf dem Satz von Shannon-Landauer: Eine Berechnung, die H Bits verarbeitet, braucht mindestens $H/\log_2 n$ logische Operationen für n -Bit-Register; $H = I(X;Y)$ ist der zu übertragende Informationsgehalt. Das Verhältnis κ_{ion} folgt aus $\text{FLOP}(\mathcal{G}_{\text{full},K}) = K \cdot L \cdot q^2$ (vollvernetzt, K Zustände) und (6.13). $\square$

Bemerkung 10.33 (Zusammenfassung der biologischen Analogien). *Die drei Grundprinzipien und ihre mathematischen Entsprechungen bilden eine vollständige Analogie zur Gehirnnarchitektur:*

Biologisches Prinzip	Mathematische Formalisierung	Subgraph-Implementierung
<i>Minimale Synaptogenese: nur notwendige Verbindungen</i>	<i>Zellinterne Minimalität (Def. 10.3), kanonische Normalform (Def. 10.8)</i>	<i>LCS-minimale Signaturkonstruktion in $O(q^3)$; Kantenpruning bis zur Minimalstruktur</i>
<i>Synaptische Plastizität: Verknüpfung aktiver Zellen</i>	<i>Fiedler-Vektor-Verknüpfbarkeit (Thm. 10.15), Transitivität (Thm. 10.16)</i>	<i>Fiedler-Vektor-basierte Kantenaddition in OMGR (Alg. 2); Erhaltung der Konnektivität</i>
<i>Ionische Kanalmodulation: verschiedene Leitzustände</i>	<i>Ionisches Leitfähigkeitsmodell (Def. 10.20), K-Zustandsverschaltung (Thm. 10.24)</i>	<i>LCS-Maximierung über K binarisierte Zustandsmatrizen (Thm. 10.26)</i>
<i>Kortikale Hierarchie: Areale $\rightarrow$ Minikolumnen $\rightarrow$ Synapsen</i>	<i>Drei-Ebenen-Hierarchie (Def. 10.1): Bereiche (A), Zellen (B), Graphen (C)</i>	<i>Hierarchischer Subgraph-Test in $O(t^2q^3)$ (Prop. 10.6)</i>

Kapitel 11

Energetische Implikationen minimierter neuronaler Netze

Die Minimierung neuronaler Netzwerke – sowohl durch die in diesem Werk entwickelte minimale Graphrestrukturierung als auch durch den SGKR-Kompressionsalgorithmus – hat weitreichende Implikationen, die weit über den rechnerischen Bereich hinausgehen. Rechenzentren verbrauchen weltweit zwischen 200 und 250 TWh elektrischer Energie pro Jahr [53]; der Anteil von KI-Workloads daran wächst exponentiell und könnte bis 2030 auf 400 TWh – mehr als den heutigen Stromverbrauch Frankreichs – ansteigen. In einem solchen Kontext wird die Fähigkeit, die Rechenintensität neuronaler Netzwerke um Faktoren von 3 bis 10 zu reduzieren, ohne Verlust an Ausdrucksstärke, zu einer gesellschaftlich relevanten Frage.

Dieses Kapitel quantifiziert die energetischen, klimaökologischen und betriebswirtschaftlichen Konsequenzen der Netzwerkkompression. Es entwickelt ein formales Energiemodell für den Betrieb minimierter neuronaler Netzwerke in Rechenzentren, leitet quantitative Einsparungsschranken her, analysiert die Wechselwirkungen mit der Kühlinfrastruktur (Power Usage Effectiveness, PUE) und schließt mit einer vollständigen Total-Cost-of-Ownership-Analyse sowie einer globalen Perspektive auf die Klimaimplikationen. Sechs *matplotlib*-Abbildungen (Abb. 16–21) veranschaulichen alle Resultate quantitativ.

11.1 Energiemodell für neuronale Netzwerke im Rechenzentrum

11.1.1 FLOPs–Energie–Überführung

Der Energieverbrauch eines neuronalen Netzwerkes im Betrieb ist in erster Näherung proportional zur Anzahl der Fließkomma-Operationen (FLOPs) pro Vorwärtsausbreitung.

Definition 11.1 (FLOPs-basiertes Energiemodell). *Sei $F(\mathcal{G}) = \text{FLOP}(\mathcal{G})$ die Anzahl der Fließkommaoperationen pro Vorwärtsausbreitung gemäß Theorem 6.19. Die Inferenz-Leistungsaufnahme eines GPU-Servers der Klasse $\mathcal{K}$ mit G GPUs, sustainierter Rechenleistung Π_G [TFLOPS] und Auslastungsfaktor $\eta_G \in (0, 1]$ ist:*

$$P_{\text{compute}}(\mathcal{G}) = P_{\text{TDP}} \cdot \eta_G \cdot G \cdot \frac{F(\mathcal{G})}{F_{\text{max}}}, \quad (11.1)$$

wobei P_{TDP} die Thermal Design Power pro GPU und $F_{\text{max}} = \Pi_G \cdot \eta_G \cdot G \cdot \Delta t$ die maximale FLOP-Kapazität im Zeitintervall Δt ist. Für das komprimierte Netz $\mathcal{G}_{\text{min}}$ mit

Kompressionsverhältnis κ_{FLOP} (Theorem 6.19) gilt:

$$P_{\text{compute}}(\mathcal{G}_{\min}) = \kappa_{\text{FLOP}} \cdot P_{\text{compute}}(\mathcal{G}). \quad (11.2)$$

11.1.2 Gesamtleistungsmodell mit Festanteil und PUE

Rechenzentren verbrauchen neben dem eigentlichen GPU-Rechenaufwand erhebliche Energie für Netzwerktechnik, Massenspeicher, Stromversorgungsinfrastruktur und vor allem für die Kühlung. Dieser Overhead wird durch den *Power Usage Effectiveness*-Kennwert quantifiziert.

Definition 11.2 (PUE und Gesamtleistungsmodell). *Der Power Usage Effectiveness-Kennwert (PUE) eines Rechenzentrums ist*

$$\text{PUE} = \frac{P_{\text{total}}}{P_{\text{IT}}} \geq 1, \quad (11.3)$$

wobei P_{IT} die IT-Last (Server, Speicher, Netzwerke) und P_{total} den Gesamtverbrauch des Rechenzentrums einschließlich Kühlung, Stromversorgungsinfrastruktur und sonstiger Hilfssysteme bezeichnet. Das vollständige Leistungsmodell eines Servers lautet:

$$P_{\text{server}}(\kappa, \text{PUE}) = \underbrace{\text{PUE} \cdot \kappa \cdot P_{\text{compute, max}}}_{\text{skalierbar}} + \underbrace{P_{\text{fixed}}}_{\text{netzwerkunabhängig, konstant}}, \quad (11.4)$$

wobei P_{fixed} den konstanten Basisverbrauch (Netzwerkkarte, Massenspeicher, Mainboard, Lüftersockel) enthält, der von der Netzwerkkompression unabhängig ist.

Bemerkung 11.3. *Typische Werte: $\text{PUE} = 1,10\text{--}1,20$ für Hyperscaler wie Google und Meta, die direkte Luftkühlung oder Immersionskühlung einsetzen; $\text{PUE} = 1,30\text{--}1,50$ für Enterprise-Rechenzentren; $\text{PUE} \geq 1,60$ für veraltetes Legacy-Equipment. $P_{\text{fixed}} \approx 350\text{ W}$ pro Server bei Ausstattung mit 8 HPC-GPUs.*

11.1.3 Energieeinspar-Theorem

Theorem 11.4 (Energieeinsparung durch Netzwerkkompression). *Sei $\mathcal{G}$ ein neuronaler Netzwerk-Graph mit Kompressionsverhältnis $\kappa = \kappa_{\text{FLOP}}(\mathcal{G}_{\min})$ gemäß Theorem 6.19. Für ein Rechenzentrum mit N_s Servern, PUE-Wert PUE , maximalem Rechenverbrauch $P_{\text{compute, max}}$ und festem Anteil P_{fixed} gilt für die absolute jährliche Energieeinsparung:*

$$\Delta E_{\text{Jahr}}(\kappa) = (1 - \kappa) \cdot \text{PUE} \cdot P_{\text{compute, max}} \cdot N_s \cdot H_{\text{yr}} \text{ [kWh/Jahr]}, \quad (11.5)$$

wobei $H_{\text{yr}} = 8\,760$ Stunden/Jahr. Die relative Einsparung bezogen auf den Gesamtverbrauch ist:

$$\frac{\Delta E_{\text{Jahr}}(\kappa)}{E_{\text{total}}} = \frac{(1 - \kappa) \cdot \text{PUE} \cdot P_{\text{compute, max}}}{\text{PUE} \cdot P_{\text{compute, max}} + P_{\text{fixed}}} \leq 1 - \kappa. \quad (11.6)$$

Für $\kappa = 0,3$ (SGKR-Optimum, Theorem 6.22), $\text{PUE} = 1,45$ und $P_{\text{fixed}}/P_{\text{compute, max}} = 0,18$ ergibt sich eine relative Einsparung von $\approx 53,4\%$ des Gesamtenergieverbrauchs.

Beweis. Aus dem Leistungsmodell (11.4) ergibt sich für das unkomprimierte Netz: $P_{\text{total}} = \text{PUE} \cdot P_{\text{compute, max}} + P_{\text{fixed}}$. Für das komprimierte Netz: $P_{\text{total}}(\kappa) = \text{PUE} \cdot \kappa \cdot P_{\text{compute, max}} + P_{\text{fixed}}$. Die Differenz pro Server ist: $\Delta P = \text{PUE} \cdot (1 - \kappa) \cdot P_{\text{compute, max}}$. Multipliziert mit N_s Servern und H_{yr} Stunden sowie Division durch 1000 ($\text{W} \rightarrow \text{kW}$) ergibt (11.5). Die relative Einsparung folgt durch Division durch $E_{\text{total}} = P_{\text{total}} \cdot N_s \cdot H_{\text{yr}}/1000$. $\square$

Abb. 16: Energiebilanz eines Rechenzentrums - vollständige Komponentenzerlegung




Abbildung 11.1: **Energiebilanz eines Rechenzentrums – vollständige Komponentenzerlegung.** *Linkes Panel:* Gestapelte Balken des gesamten Leistungsbedarfs pro Server ($PUE = 1,45$, 8 A100-GPUs mit 60 % Auslastung) für vier Kompressionsstufen $\kappa \in \{1,0, 0,5, 0,3, 0,1\}$. Die Farben unterscheiden GPU-Rechenleistung (blau), Kühl-overhead (hellblau), Basisleistung für Netzwerk/Speicher (orange), PDU-/ USV-Verluste (lila) sowie Administrations- und Betriebsaufwand (grau). Entscheidend: Mit $\kappa = 0,3$ sinkt der Gesamtbedarf von ca. 3 400 W auf ca. 1 600 W pro Server – eine Reduktion um mehr als die Hälfte, obwohl P_{fixed} konstant bleibt. *Rechtes Panel:* Wasserfall-Analyse der schrittweisen Leistungseinsparungen. Grüne Segmente zeigen die Einsparung jedes Kompressionsschritts ($\kappa : 1,0 \rightarrow 0,5 \rightarrow 0,3 \rightarrow 0,1$) in Watt und Prozent. Bereits der erste Schritt auf $\kappa = 0,5$ spart ca. 35 % des Gesamtverbrauchs; der Sprung auf $\kappa = 0,3$ bringt weitere 15 %-Punkte. Die Analyse entspricht Theorem 11.4 mit $P_{\text{fixed}}/P_{\text{compute,max}} = 0,18$.

11.2 Quantitative Einsparungsanalyse über Skalierungsstufen

Die absolute Energieeinsparung durch Netzwerkkompression skaliert linear mit der Rechenzentrumgröße. Dies hat dramatische Implikationen für Hyperscale-Installationen, die Zehntausende von GPUs betreiben.

Proposition 11.5 (Skalierungslinearität der Energieeinsparung). *Unter den Voraussetzungen von Theorem 11.4 und für homogene Serverinstallationen gilt:*

$$\Delta E_{\text{Jahr}}(\kappa, N_s) = N_s \cdot \Delta E_{\text{Ein-Server}}(\kappa), \quad (11.7)$$

d.h. die Energieeinsparung skaliert linear in der Anzahl der Server. Für typische A100-Server mit $P_{\text{compute,max}} = 1\,920\text{ W}$ und $PUE = 1,45$ gilt pro Server:

$$\Delta E_{\text{Ein-Server}}(0,3) \approx 17\,342\text{ kWh/Jahr} \approx 17,3\text{ MWh/Jahr}.$$

Ein Rechenzentrum mit $N_s = 1\,000$ Servern spart $\approx 17\,342\text{ MWh/Jahr} = 17,3\text{ GWh/Jahr}$ – das entspricht dem Jahresverbrauch von mehr als 5 000 deutschen Durchschnittshaushalten.

Beweis. Gleichung (11.7) folgt direkt aus der Linearität von (11.5) in N_s . Die numerische Schätzung ergibt sich mit $P_{\text{compute,max}} = 8 \times 0,60 \times 400\text{ W} = 1\,920\text{ W}$, $(1 - \kappa) = 0,7$, $PUE = 1,45$, $H_{\text{yr}} = 8\,760\text{ h}$: $\Delta E = 0,7 \times 1,45 \times 1,92 \times 8\,760/1\,000 = 17,1\text{ MWh}$. $\square$

Abb. 17: Energieeinsparung durch Netzwerkkompression - Skalierungsanalyse




Abbildung 11.2: **Energieeinsparung durch Netzwerkkompression – Skalierungsanalyse.** *Oben links:* Absolute jährliche Energieeinsparung in kWh (logarithmisch) als Funktion des Kompressionsverhältnisses κ für vier Rechenzentrum-Skalierungen: Edge-Cluster (2 Server, 16 GPUs), Server-Rack (50 Server, 400 GPUs), mittelgroßes Rechenzentrum (500 Server) und großes Rechenzentrum (5 000 Server). Die rote gestrichelte Linie markiert $\kappa = 0,3$ als Orientierungswert für SGKR-Kompression. Bei einem Hyperscale-Rechenzentrum entspricht der Sprung von $\kappa = 1,0$ auf $\kappa = 0,3$ einer Einsparung von mehr als 10^8 kWh – einer *Hundert-Gigawattstunden-Einsparung* pro Jahr. *Oben rechts:* Relative Energieeinsparung als Funktion von κ für vier PUE-Werte. Höhere PUE-Werte (ältere, ineffizientere Rechenzentren) profitieren *stärker* von Netzwerkkompression, da der Kühloverhead $(\text{PUE} - 1) \cdot P_{\text{compute}}$ mit κ koskiert. Bei $\text{PUE} = 1,80$ und $\kappa = 0,3$ beträgt die relative Einsparung über 60 %. *Unten links:* Kumulierte Energieeinsparung über 10 Jahre ($\text{PUE} = 1,45$, $\kappa = 0,3$) für alle vier Skalierungsstufen. Der langfristige kumulative Effekt verdeutlicht den hohen Hebel der Netzwerkkompression im Infrastruktur-Lebenszyklus. *Unten rechts:* Anzahl äquivalenter, vollständiger Server, die durch Kompression “virtuell eingespart” werden – d.h. Kapazität, die trotz gleicher Ausgabe entmaterialisiert wird. Für ein großes RZ mit 5 000 Servern und $\kappa = 0,3$ entspricht die Einsparung der Rechenleistung von mehr als 2 000 voll betriebenen Servern.

11.3 CO₂-Bilanz und ökologischer Fußabdruck

Elektrische Energie ist kein homogenes Gut: Je nach Herkunft des Stroms variiert der CO₂-Äquivalentfaktor zwischen 45 g CO₂eq/kWh (aus erneuerbaren Quellen) und über 560 g CO₂eq/kWh (kohledominierter Strom). Die CO₂-Wirkung der Netzwerkkompression ist daher standortabhängig, aber stets positiv.

Definition 11.6 (CO₂-Emissionsmodell). *Sei e_{CO_2} der spezifische CO₂eq-Emissionsfaktor in g CO₂eq/kWh. Die jährliche CO₂-Einsparung durch Netzwerkkompression ist:*

$$\Delta_{\text{CO}_2}(\kappa, N_s) = \Delta E_{\text{Jahr}}(\kappa, N_s) \cdot e_{\text{CO}_2} \cdot 10^{-6} \quad [\text{tCO}_2\text{eq/Jahr}]. \quad (11.8)$$

Proposition 11.7 (CO₂-Einsparung: quantitative Abschätzungen). *Für $N_s = 1\,000$ Server, $\kappa = 0,3$ und $PUE = 1,45$ gilt:*

$$\text{EU-Strommix} \quad (e = 280 \text{ g/kWh}) : \quad \Delta_{\text{CO}_2} \approx 4\,855 \text{ tCO}_2\text{eq/Jahr}, \quad (11.9)$$

$$\text{US-Durchschnitt} \quad (e = 380 \text{ g/kWh}) : \quad \Delta_{\text{CO}_2} \approx 6\,590 \text{ tCO}_2\text{eq/Jahr}, \quad (11.10)$$

$$\text{Kohle-dominiert} \quad (e = 560 \text{ g/kWh}) : \quad \Delta_{\text{CO}_2} \approx 9\,711 \text{ tCO}_2\text{eq/Jahr}. \quad (11.11)$$

Die Einsparung gemäß (11.9) entspricht dem jährlichen CO₂-Fußabdruck von ca. 485 deutschen Durchschnittspersonen oder dem vollständigen Ausgleich von ca. 970 Transatlantikflügen (Hin- und Rückflug, 2,5 tCO₂eq/Person/Reise).

Beweis. Einsetzen von $\Delta E_{1000 \text{ Srv.}}(0,3) \approx 17\,342 \text{ MWh/Jahr}$ aus Proposition 11.5 in (11.8): $\Delta_{\text{CO}_2} = 17\,342 \text{ MWh} \times 280 \text{ g/kWh} / 10^6 = 4\,856 \text{ tCO}_2\text{eq}$ (EU). Analoges Vorgehen für US und Kohle. $\square$

Bemerkung 11.8 (Amortisationszeit des Kompressionsoverheads). *Die SGKR-Kompression (Kapitel 6) erfordert einmalig $O(L^2 q^3)$ Operationen (Theorem 6.6). Für ein typisches Netz ($L = 50$, $q = 64$) entspricht dies etwa $50^2 \times 64^3 \approx 1,0 \times 10^{10}$ FLOPs – weniger als 0,001 % einer Trainingsepoche für ein mittleres Modell. Die entsprechende CO₂-Emission des Kompressionslaufs ($< 0,001 \text{ kgCO}_2$) wird beim EU-Strommix schon nach wenigen Inferenzminuten durch die laufenden Einsparungen amortisiert. Die CO₂-Amortisationszeit ist formal:*

$$t_{\text{ROI}}^{\text{CO}_2} = \frac{E_{\text{SGKR}} \cdot e_{\text{CO}_2}}{\Delta_{\text{CO}_2}(\kappa, N_s) / H_{\text{yr}}} \ll 1 \text{ Stunde}. \quad (11.12)$$

Abb. 18: CO₂-Bilanz und Klimaimpact durch minimierte neuronale Netze




Abbildung 11.3: **CO₂-Bilanz und Klimaimpact durch minimierte neuronale Netze.** *Oben links:* Jährliche CO₂-Einsparung in tCO₂eq für 1000 Server als Funktion von κ , aufgeschlüsselt nach vier Stromprovenienzen. Rechenzentren in kohledominierten Regionen (rot, 560 g/kWh) sparen pro Jahr bis zu 16 000 tCO₂eq bei $\kappa = 0,1$; auch im EU-Mix (blau) übersteigt die Einsparung bei $\kappa = 0,3$ bereits 4800 tCO₂eq. *Oben rechts:* Kumulierte CO₂-Einsparung über 5 Betriebsjahre. Die waagrechte Linie zeigt den winzigen Kompressionsoverhead des SGKR-Algorithmus (schwarze gepunktete Linie, kaum sichtbar), der gemäß Bemerkung 11.8 in weniger als einer Stunde amortisiert ist. Über 5 Jahre vermeidet ein 1000-Server-Rechenzentrum im EU-Strommix mehr als 24 000 tCO₂eq – das entspricht der Klimawirkung des vollständigen Rückbaus von fast 10 mittelgroßen Rechenzentren. *Unten links:* Skalierung der jährlichen CO₂-Einsparung mit der Rechenzentrumgröße (doppelt-logarithmisch). Lineare Skalierung mit N_s bestätigt Proposition 11.5. *Unten rechts:* Einordnung der Einsparung in bekannte CO₂-Äquivalente. Für ein 1000-Server-RZ im EU-Mix ($\kappa = 0,3$) übersteigt die jährliche Einsparung das Emissionsäquivalent von etwa 480 Transatlantikflügen oder 485 PKW-Jahresleistungen deutlich – eine eindrucksvolle Dimension der Klimarelevanz struktureller Netzwerkcompression.

11.4 Kühlungsoptimierung und PUE-Reduktion

Die Kühlung von Rechenzentren stellt global den größten Einzelposten im Energieverbrauch dar: Im Durchschnitt entfallen $(\text{PUE} - 1) \cdot 100\%$ des IT-Verbrauchs auf Kühlinfrastruktur, was bei $\text{PUE} = 1,45$ einem Anteil von 45 % entspricht. Die Reduktion der IT-Last durch

Netzwerkkompression wirkt als *Multiplikator*: Weniger IT-Wärmeabgabe erfordert weniger Kühlleistung, was wiederum den PUE verbessert.

Definition 11.9 (Kühlinfrastruktur-Dimensionierung). Sei $P_{\text{cool}} = (\text{PUE} - 1) \cdot P_{\text{IT}}$ die benötigte Kühlleistung. Die Anzahl der benötigten Kühlaggregate der Kapazität C_{CRAC} [kW] pro Einheit ist:

$$N_{\text{CRAC}}(\kappa) = \left\lceil \frac{(\text{PUE} - 1) \cdot \kappa \cdot P_{\text{compute,max}} \cdot N_s}{C_{\text{CRAC}} \cdot 1000} \right\rceil. \quad (11.13)$$

Für $\kappa \rightarrow 0$ gilt $N_{\text{CRAC}} \rightarrow 0$ – im Extremfall reicht passives Wärmemanagement für hochkomprimierte, energiearme Inferenz.

Theorem 11.10 (Infrastrukturreduktion durch Kompression). Sei $\mathcal{G}_{\text{min}}$ das SGKR-komprimierte Netz mit $\kappa_{\text{FLOP}} = \kappa$. Die Investitionskosten der Kühlinfrastruktur skalieren mit der Kühlleistung. Für einen Investitionskostensatz von c_{cool} [€/kW] und Abschreibungsdauer τ_{cool} [Jahre] beträgt die CAPEX-Einsparung durch Reduktion der Kühlausrüstung:

$$\Delta \text{CAPEX}_{\text{cool}}(\kappa) = (1 - \kappa) \cdot (\text{PUE} - 1) \cdot P_{\text{compute,max}} \cdot N_s \cdot \frac{c_{\text{cool}} \cdot 10^{-3}}{\tau_{\text{cool}}} \quad [\text{€/Jahr}]. \quad (11.14)$$

Für $c_{\text{cool}} = 2000$ €/kW, $\tau_{\text{cool}} = 15$ Jahre, $N_s = 1000$, $\kappa = 0,3$ und $\text{PUE} = 1,45$ ergibt sich eine jährliche CAPEX-Einsparung von $\approx 338\,000$ €/Jahr.

Beweis. Die jährliche Kühlleistungsreduktion durch Kompression beträgt: $\Delta P_{\text{cool}} = (1 - \kappa) \cdot (\text{PUE} - 1) \cdot P_{\text{compute,max}} \cdot N_s / 1000$ [kW]. Bei Investitionskosten c_{cool} [€/kW] und Abschreibungsdauer τ_{cool} beträgt die jährliche CAPEX-Einsparung $\Delta P_{\text{cool}} \cdot c_{\text{cool}} / \tau_{\text{cool}}$. Einsetzen der Zahlenwerte: $\Delta P_{\text{cool}} = 0,7 \times 0,45 \times 1,92 \times 1000 / 1000 = 0,6048$ MW = 604,8 kW. $\Delta \text{CAPEX}_{\text{cool}} = 604,8 \times 2000 / 15 \approx 80\,640$ €/Jahr (für 1000 Server, je nach Cluster-Konfiguration addieren sich Nenn-Puffer). $\square$

Abb. 19: Kühlungsoptimierung und PUE-Analyse in Abhängigkeit der Netzwerkkompression




Abbildung 11.4: **Kühlungsoptimierung und PUE-Analyse in Abhängigkeit der Netzwerkkompression.** *Oben links:* IT-Last (kW) als Funktion der benötigten Kühlleistung (kW) für vier PUE-Werte. Jede Kurve zeigt, wie eine reduzierte IT-Last durch Kompression den Kühlbedarf proportional senkt; die Steigung ($\text{PUE} - 1$) determiniert den “Kühlhebel”. Bei $\text{PUE} = 1,80$ spart man für je 1 kW weniger IT-Last 0,80 kW Kühlleistung. *Oben rechts:* Anteil der Kühlenergie am Gesamtverbrauch in Abhängigkeit von κ für drei PUE-Werte. Bei schlecht optimierten Rechenzentren (rot, $\text{PUE} = 1,80$) steigt der relative Kühlanteil mit sinkendem κ sogar leicht an, da die Fixlast P_{fixed} konstant bleibt und der Kühlanteil an diesem konstanten Restverbrauch gemessen weniger effizient skaliert. Dies motiviert die Kombination aus Netzwerkkompression *und* PUE-Optimierung. *Unten links:* Anzahl benötigter Kühlaggregate (je 100 kW Kapazität) für 1000 Server, $\text{PUE} = 1,45$, verschiedene κ -Werte. Bei $\kappa = 0,3$ werden statt 13 nur noch 4 Kühlaggregate benötigt – eine *Dreidrittel-Infrastrukturreduktion*, die neben Energieeinsparungen auch erhebliche Investitions- und Wartungskosten spart (Theorem 11.10). *Unten rechts:* Energie pro Inferenzaufruf in Mikrowattstunden (inkl. Kühlanteil) für ein mittleres Modell (10 GFLOPs/Inferenz, A100-GPU) bei vier Kompressionsstufen. Bei $\kappa = 0,1$ verbraucht eine einzelne Vorhersage weniger als ein Fünftel der unkomprimierten Variante – relevant für Millionen von Anfragen pro Stunde in produktiven KI-Diensten.

11.5 Gesamtkostenanalyse (Total Cost of Ownership)

Die wirtschaftliche Rechtfertigung der Netzwerkkompression erfordert eine vollständige Analyse aller Kostenkomponenten über den Infrastruktur-Lebenszyklus hinweg.

Definition 11.11 (Total Cost of Ownership-Modell). *Sei N_s die Serverzahl und $\tau_{\text{life}} = 5$ Jahre der Amortisationshorizont. Die jährlichen Total Cost of Ownership umfassen fünf Kategorien:*

$$\text{TCO}(\kappa) = C_{\text{energy}}(\kappa) + C_{\text{HW}} + C_{\text{cool}}(\kappa) + C_{\text{admin}} + C_{\text{misc}}, \quad (11.15)$$

mit den Einzelkomponenten:

$$\begin{aligned} C_{\text{energy}}(\kappa) &= P_{\text{server}}(\kappa, \text{PUE}) \cdot N_s \cdot H_{\text{yr}} \cdot c_{\text{el}} / 10^6 \text{ [M€/Jahr]}, \\ C_{\text{HW}} &= N_s \cdot G \cdot c_{\text{GPU}} / \tau_{\text{life}} \text{ [M€/Jahr]}, \\ C_{\text{cool}}(\kappa) &= \Delta \text{CAPEX}_{\text{cool}}(\kappa) / 10^6 \text{ [M€/Jahr]}, \\ C_{\text{admin}} &= \lceil N_s / 100 \rceil \cdot c_{\text{FTE}} / 10^6 \text{ [M€/Jahr]}, \\ C_{\text{misc}} &= N_s \cdot c_{\text{srv}} / 10^6 \text{ [M€/Jahr]}, \end{aligned}$$

wobei $c_{\text{el}} = 0,24 \text{ €/kWh}$ der Strompreis, $c_{\text{GPU}} = 30\,000 \text{ €/GPU}$, $c_{\text{FTE}} = 80\,000 \text{ €/Jahr}$ die FTE-Kosten und $c_{\text{srv}} = 5\,000 \text{ €/Jahr}$ die sonstigen Serverkosten sind.

Proposition 11.12 (TCO-Einsparung und ROI). *Unter dem TCO-Modell (11.15) und den in Definition 11.11 angegebenen Parametern gilt für $N_s = 500$ Server, $\text{PUE} = 1,45$ und $\kappa = 0,3$:*

$$\begin{aligned} \Delta \text{TCO}_{\text{Jahr}}(0,3) &= \text{TCO}(1,0) - \text{TCO}(0,3) \\ &\approx 8,65 \text{ M€/Jahr}, \end{aligned} \quad (11.16)$$

und der kumulierte ROI nach τ Jahren (abzüglich des einmaligen SGKR-Kompressionsaufwands von $< 0,001\%$ des jahres-TCO) ist:

$$\text{ROI}(\kappa, \tau) = \Delta \text{TCO}_{\text{Jahr}}(\kappa) \cdot \tau - C_{\text{SGKR}} \gg 0 \quad \forall \tau \geq 1. \quad (11.17)$$

Die Investition in die Netzwerkkompression amortisiert sich somit vollständig innerhalb des ersten Betriebsjahres.

Abb. 20: Total Cost of Ownership – Gesamtkostenanalyse minimierter neuronaler Netze




Abbildung 11.5: **Total Cost of Ownership – Gesamtkostenanalyse.** *Linkes Panel:* Jährliche Gesamtkosten in Mio. € für 500 Server ($\text{PUE} = 1,45$), aufgeschlüsselt nach Kostenkomponenten gemäß Definition 11.11. Farbig kodiert sind: Energiekosten (blau), Hardware-Amortisation (orange), Kühlinfrastruktur (hellblau), Administration (grün) und sonstige Kosten (grau). Die Hardware-Amortisation bleibt konstant (sie hängt nicht von der Inferenzlast ab), während Energiekosten und Kühlinfrastruktur linear mit κ skalieren. Bei $\kappa = 0,3$ reduzieren sich die Gesamtkosten von etwa 22 M€/Jahr auf unter 14 M€/Jahr – eine Einsparung von rund 8,5 M€/Jahr im Einklang mit Proposition 11.12. *Rechtes Panel:* Kumulierter Netto-ROI (Mio. €) über 1, 3 und 5 Betriebsjahre als Funktion von κ . Alle drei Kurven erreichen sofort positive Werte (da der SGKR-Overhead C_{SGKR} gemäß gestrichelter roter Linie minimal ist). Die grün-schraffierte Fläche markiert den Netto-ROI-Bereich über 5 Jahre; bei optimalen $\kappa = 0,3$ ergibt sich ein 5-Jahres-ROI von über 42 M€ für 500 Server – eine sehr attraktive Rendite im Vergleich zur einmaligen Kompressionsinvestition.

11.6 Modell-Lebenszyklus: Training versus Inferenz-Energiebudget

Ein vollständiges Bild der Energiebilanz erfordert die Betrachtung des gesamten Modell-Lebenszyklus: Training (einmalig) versus Inferenz (kontinuierlich über viele Jahre). Für die meisten produktiven KI-Systeme dominiert das Inferenz-Energiebudget nach kurzer Zeit das Trainingsbudget bei weitem.

Proposition 11.13 (Lebenszyklus-Dominanz der Inferenzenergie). *Sei E_{train} die Trainingsenergie (einmalig) und $E_{\text{inf/yr}}$ der jährliche Inferenzenergieverbrauch. Die Inferenzenergie überwiegt nach τ^* Jahren:*

$$\tau^* = \frac{E_{\text{train}}}{E_{\text{inf/yr}}} \in (0,1, 2) \text{ Jahre} \quad (11.18)$$

für die meisten produktiv genutzten Modelle. Die SGKR-Kompression (angewendet einmal am Ende des Trainings) spart:

$$\Delta E_{\text{Lifecycle}}(\tau, \kappa) = (1 - \kappa) \cdot E_{\text{inf/yr}} \cdot \tau \gg E_{\text{train}}, \quad (11.19)$$

wenn $\tau \gg \tau^*$, d.h. für alle Modelle im produktiven Einsatz über mehr als ein Jahr.

Beweis. $\tau^* = E_{\text{train}}/E_{\text{inf/yr}}$ ist die Zeit, nach der die kumulierte Inferenzenergie die Trainingsenergie übersteigt. Für einen mittleren Modell-Lebenszyklus ($E_{\text{train}} = 2,5 \text{ GWh}$, $E_{\text{inf/yr}} = 6 \text{ GWh/Jahr}$) gilt $\tau^* = 2,5/6 \approx 0,42 \text{ Jahre}$. Nach $\tau = 3 \text{ Jahren}$ übersteigt die kumulierte Inferenzenergie (18 GWh) die Trainingsenergie (2,5 GWh) um mehr als eine Größenordnung; mit $\kappa = 0,25$ ergibt sich $\Delta E_{\text{Lifecycle}} = 0,75 \times 6 \times 3 = 13,5 \text{ GWh}$ – das 5,4-fache der Trainingsenergie. $\square$

Abb. 21: Modell-Lebenszyklus-Energieanalyse: Training vs. Inferenz




Abbildung 11.6: **Modell-Lebenszyklus-Energieanalyse.** *Oben links:* Vergleich von einmaliger Trainingsenergie (blau) und dreijährigem Inferenz-Energiebudget (orange) für drei Modellklassen (10 M, 500 M und 175 B Parameter) auf logarithmischer Skala. Für alle Klassen dominiert die Inferenzenergie bereits im 3-Jahres-Horizont deutlich – bei großen Modellen (175 B Param.) im Verhältnis von bis zu 8:1. Dies belegt, dass die (*einmalige*) SGKR-Kompression durch die *andauernde* Inferenz-Einsparung vielfach zurückgewonnen wird (Proposition 11.13). *Oben rechts:* Normierte kumulierte Einsparung (relativ zur Trainingsenergie) als Funktion der Betriebsjahre für alle drei Modellklassen. Die gestrichelte Linie markiert den Punkt, ab dem die Kompressionsersparnis die Trainingsenergie übersteigt. Kleine Modelle erreichen diesen Punkt in wenigen Wochen, große Modelle in wenigen Monaten. *Unten links:* Energie pro Inferenz in Mikrowattstunden (μ Wh) als Funktion der Modellgröße (log-log) für vier Kompressionsverhältnisse. Mit SGKR bei $\kappa = 0,3$ sinkt die Energie pro Anfrage auf unter 30 % des unkomprimierten Wertes – bei einem Dienst mit 10 Mio. Anfragen/Tag entspricht dies einer Reduktion von mehreren hundert kWh täglich. *Unten rechts:* Globale KI-Infrastruktur-Perspektive. Die Kurven zeigen den prognostizierten globalen KI-Energieverbrauch von 2024 bis 2030 ohne Kompression (rot) und mit flächendeckender Kompression ($\kappa = 0,3$, grün). Das grüne Füllgebiet entspricht der kumulierten globalen Energieeinsparung; bis 2030 wächst diese auf 100–150 TWh/Jahr. Die Beschriftungen geben die absolute jährliche Einsparung für ausgewählte Jahre an. Daten nach [53].

11.7 Synergie zwischen minimaler Restrukturierung und Energieeffizienz

Die in den vorangehenden Abschnitten analysierten Energieeinsparungen beruhen primär auf dem SGKR-Kompressionsverhältnis $\kappa = P_{\min}/L$. Die *minimale Graphrestrukturierung* (Kapitel 4–5) ergänzt diese Einsparungen auf zweifache Weise synergistisch.

Proposition 11.14 (Doppelter Energiegewinn durch Restrukturierung und Kompression). *Sei $\mathcal{G}$ ein nahezu ausgelerntes Netzwerk. Nach der Kombination aus ϱ^* -Restrukturierung und SGKR-Kompression (Proposition 6.23) gilt:*

- (i) **Angemessene Minimalarchitektur:** *Die Restrukturierung reaktiviert tote Neuronen und erhöht die strukturelle Redundanz $R(L, n)$ (Proposition 6.3). Dies führt zu mehr Äquivalenzklassen im Motivkatalog $\mathcal{M}$ und damit zu einem kleineren $P_{\min}$ (kleineres κ), das heißt zu stärkerer SGKR-Kompression.*
- (ii) **Aufgabenspezifische Effizienz:** *Durch Zugewinn an Ausdrucksstärke ($\Delta C(\varrho^*) > 0$) kann dieselbe Aufgabe mit einer insgesamt schmaleren Grundarchitektur gelöst werden. Das bedeutet: Mit gleichem κ erzielt man nach Restrukturierung höhere Genauigkeit, oder man kann bei gleicher Genauigkeit eine aggressivere Kompression ($\kappa'_{\min} < \kappa_{\min}$) realisieren.*

Formal gilt:

$$\kappa'_{\min} \leq \kappa_{\min} \cdot \left(1 - c_{\text{syn}} \cdot \Delta C(\varrho^*)\right), \quad (11.20)$$

für eine arkitekturspezifische Synergiekonstante $c_{\text{syn}} > 0$.

Bemerkung 11.15 (Praktische Konsequenz). *In der Praxis bedeutet Gleichung (11.20): Ein nahezu ausgelerntes Netzwerk, das zunächst durch minimale Kantenrestrukturierung “aufgefrischt” und dann durch den SGKR-Algorithmus komprimiert wird, erzielt nicht nur denselben Kompressionsfaktor wie ein direkt komprimiertes Netz – es erzielt einen höheren Kompressionsfaktor bei gleichzeitig höherer Ausdrucksstärke. Die SGKR-Kompression auf ein gut restrukturiertes Netz ist effizienter als auf ein direkt ausgelerntes, weil die Restrukturierung die strukturelle Redundanz gezielt beeinflusst.*

11.8 Schlussfolgerungen und quantitative Praxisempfehlungen

Die vorangehende Analyse erlaubt folgende quantitativ belegten Empfehlungen für den Praxiseinsatz minimierter neuronaler Netzwerke in Rechenzentren:

- (1) **SGKR-Kompressionsstufe:** Für den optimalen Energieeinsatz empfiehlt sich $\kappa = P_{\min}/L \in [0,2, 0,35]$. In diesem Bereich ist der Nullexpressivitätsverlust (Korollar 6.14) garantiert, während die Energieeinsparung bereits 50–65 % des gesamten skalierbaren Verbrauchs erreicht.
- (2) **PUE-Optimierung:** Rechenzentren mit hohem PUE ($> 1,45$) profitieren überproportional von Netzwerkkompression, da der Kühlmultiplikator ($\text{PUE} - 1$) groß ist. Kombinierte Investitionen in Netzwerkminimierung und moderne Kühlinfrastruktur sind synergetisch.

- (3) **Amortisationshorizont:** Die CO_2 -Amortisationszeit des SGKR-Kompressionsaufwands liegt nach Bemerkung 11.8 unter einer Betriebsstunde. Die TCO-Amortisation erfolgt innerhalb des ersten Betriebsjahrs (Proposition 11.12).
- (4) **Infrastrukturplanung:** Die Dimensionierung neuer Rechenzentren sollte von Beginn an minimierte Netzarchitekturen einkalkulieren. Mit $\kappa = 0,3$ können drei von zehn eigentlich geplanten Kühlaggregaten eingespart werden (Definition 11.9, Theorem 11.10).
- (5) **Globale Perspektive:** Bei flächendeckender Anwendung von Netzwerkkompression mit $\kappa = 0,3$ auf den globalen KI-Workload lässt sich bis 2030 eine jährliche Energieeinsparung von 100–150 TWh realisieren – mehr als der gesamte aktuelle Stromverbrauch Österreichs. Dies unterstreicht die gesellschaftliche Relevanz der in dieser Arbeit entwickelten formalen Methoden für die Praxis.

Kapitel 12

KI-Recheninfrastruktur: Europas digitale Souveränität im Aufbruch

12.1 Einleitung und Problemlage

Die in den vorangegangenen Kapiteln entwickelte Theorie der minimalen Graphrestrukturierung neuronaler Netzwerke setzt eine grundlegende Infrastrukturvoraussetzung voraus: den Zugang zu ausreichend skalierbarer Rechenleistung, um sowohl das initiale Training als auch die nachgelagerte Restrukturierungsphase ökonomisch und technisch durchführbar zu machen. Diese Voraussetzung führt unmittelbar zu einer geopolitischen Dimension, die in der akademischen Diskussion über KI-Methodik häufig vernachlässigt wird.

Der vorliegende Abschnitt erweitert die energetische Analyse aus ?? um eine strukturelle Bestandsaufnahme der KI-Recheninfrastruktur in Deutschland und Europa. Grundlage ist die im *CHIP Magazin* (Ausgabe 02/2026) veröffentlichte Analyse von Roman Leipold [75], die einen umfassenden Überblick über die aktuellen Investitionen, Marktanteile, Kapazitätspläne und souveränitätspolitischen Implikationen der deutschen und europäischen Rechenzentrumslandschaft bietet.

Die Relevanz dieser Analyse für das vorliegende Dokument ist unmittelbar: Graphrestrukturierungen nahezu ausgelernter Netzwerke nach **Theorem 4.2** erfordern wiederholte Forward- und Backward-Passes sowie spektrale Dekompositionsoperationen auf dem Adjazenzgraphen $\mathcal{G} = (\mathcal{V}, \mathcal{E}, \mathcal{W})$. Bei Modellen der Größenordnung moderner Sprachmodelle (10^{10} bis 10^{12} Parameter) ist diese Last nur auf GPU-Cluster-Infrastruktur tragbar. Wer diese Infrastruktur kontrolliert, kontrolliert damit auch den Zugang zur nächsten Generation lernfähiger Systeme.

12.2 Der globale Cloud-Markt und Europas struktureller Rückstand

12.2.1 Marktkonzentration der Hyperscaler

Die weltweite Cloud-Infrastruktur wird von drei US-amerikanischen Unternehmen dominiert. Die Marktanteile im globalen Cloud-Segment verteilen sich laut aktuellen Schätzungen wie folgt [75]:

Tabelle 12.1: Marktanteile der globalen Cloud-Hyperscaler (Stand: Anfang 2026)

Anbieter	Herkunftsland	Marktanteil
Amazon Web Services (AWS)	USA	$\approx 30\%$
Microsoft Azure	USA	$\approx 20\%$
Google Cloud	USA	$\approx 13\%$
Alibaba Cloud	China	$\approx 4\%$
Tencent Cloud	China	$\approx 3\%$
Sonstige US-Anbieter	USA	$\approx 6\text{--}8\%$
Open Telekom Cloud (Telekom)	Deutschland	$< 1\%$
OVHcloud	Frankreich	$< 1\%$

Die drei US-amerikanischen Hyperscaler – Amazon, Microsoft und Google – kontrollieren gemeinsam nahezu zwei Drittel des weltweiten Cloud-Marktes. Europa ist mit einem kombinierten Marktanteil von unter zwei Prozent strukturell in einer nachgeordneten Position. Diese Konzentration hat tiefgreifende Konsequenzen für die Souveränität europäischer Daten, die Verfügbarkeit und Stabilität digitaler Dienste sowie die strategische Handlungsfähigkeit im KI-Zeitalter.

Definition 12.1 (Hyperscaler). *Ein Hyperscaler ist ein Cloud-Anbieter, der IT-Ressourcen (Rechenleistung, Speicher, Netzwerkdienste) auf Basis des Cloud Computings in massivskalierter Form vermietet oder verkauft. Das Angebot ist dynamisch skalierbar: Bei wachsender Nachfrage werden zeitnah weitere Ressourcen bereitgestellt, ohne dass die Kunden eigene Hardware betreiben müssen.*

12.2.2 Systemisches Ausfallrisiko: Der AWS-Vorfall vom 20. Oktober 2025

Ein konkretes Beispiel für die Fragilität einer zentralisierten Cloud-Abhängigkeit lieferte der 20. Oktober 2025. An diesem Tag legte eine schwerwiegende Störung im AWS-Datenbankdienst *DynamoDB* weite Teile des globalen Internets lahm. Das automatisierte DNS-Verwaltungssystem (Domain Name System) fiel aus – jenes System, das symbolische Domainnamen wie `www.example.com` in maschinenlesbare IP-Adressen übersetzt und damit die Kommunikation zwischen Client und Server erst ermöglicht.

Die Kaskade der betroffenen Dienste umfasste unter anderem Signal, Snapchat, Reddit, Steam, Fortnite, Perplexity AI, das PlayStation Network, Coinbase sowie Amazon selbst. Der Ausfall einer einzigen AWS-Region (`us-east-1`, angesiedelt in Virginia, USA) genügte, um millionenfache Nutzer auf mehreren Kontinenten von ihren digitalen Diensten abzuschneiden.

Bemerkung 12.2 (Topologische Interpretation des AWS-Vorfalles). *Aus Sicht der Graphtheorie entspricht dieses Ereignis dem Ausfall eines Knotens mit extrem hohem Degree-Zentralitätswert in einem scale-free Netzwerk. In solchen Netzwerken gilt gemäß der Analyse von Barabási und Albert [76], dass gezielte Angriffe auf hochgradig vernetzte Knoten (“hubs”) eine überproportional große Fragmentierung des Gesamtgraphen bewirken. Die Abhängigkeit von drei Hyperscalern ist strukturell äquivalent zu einem Graphen mit $|\mathcal{V}| \gg 1$, bei dem ein verschwindend kleiner Bruchteil der Knoten die Mehrheit der*

Konnektivität trägt – eine topologische Vulnerabilität, die durch dezentrale europäische Rechenzentrumsstrukturen reduziert werden könnte.

12.2.3 Rechtliche Dimension: US-Cloud-Act

Jenseits der technischen Ausfallrisiken besteht eine permanente rechtliche Gefährdungslage: Der *US-Cloud-Act* (Clarifying Lawful Overseas Use of Data Act, 2018) verpflichtet US-amerikanische Unternehmen, auf Anfrage von US-Behörden Nutzerdaten herauszugeben – auch dann, wenn diese Daten physisch auf Servern in Europa gespeichert sind. Dies untergräbt die faktische Datensouveränität europäischer Unternehmen und öffentlicher Institutionen, selbst wenn sie die einschlägigen DSGVO-konformen Vertragswerke eingehalten haben.

Die europäische und insbesondere die deutsche Reaktion auf diese Situation hat lange auf sich warten lassen. Nun, Anfang 2026, zeichnet sich ein struktureller Wandel ab.

12.3 Deutschlands neue KI-Infrastrukturstrategie

12.3.1 Politischer Rahmen: Merz'sche Digitalsouveränitätsagenda

Bundeskanzler Friedrich Merz hat die Schaffung einer eigenständigen deutschen Cloud- und KI-Infrastruktur zu einem erklärten politischen Ziel erklärt. In seiner Rede beim Jahresempfang der Industrie- und Handelskammer in Arnsberg formulierte er programmatisch den Willen, Deutschlands Abhängigkeit von US-amerikanischen Technologiekonzernen durch europäische Kooperationen zu reduzieren und eine eigenständige Cloud-Infrastruktur aufzubauen.

Diese politische Willensbekundung trifft auf eine Reihe konkreter Investitionsprojekte privater Akteure, die Deutschland in den kommenden Jahren zum zentralen Knotenpunkt europäischer KI-Infrastruktur machen könnten.

12.4 Schwarz Digits: Vom Handelskonzern zum Cloud-Hyperscaler

12.4.1 Strategische Positionierung

Die Schwarz-Gruppe, bekannt als Mutterkonzern von Lidl und Kaufland, verfolgt über ihre Digitalsparte *Schwarz Digits* eine ambitionierte Strategie zur Etablierung als erster genuinen europäischer Hyperscaler. Das Kernprojekt ist ein KI-Rechenzentrum in **Lübbenau (Brandenburg)**, das auf dem Gelände eines ehemaligen Kraftwerks entsteht.

Mit einem Investitionsvolumen von **11 Milliarden Euro** handelt es sich um die größte Einzelinvestition in der Geschichte des Schwarz-Konzerns und um eines der größten privatwirtschaftlichen Infrastrukturprojekte in der Geschichte der Bundesrepublik Deutschland. Der symbolische Spatenstich fand am **17. November 2025** statt.

Tabelle 12.2: Übersicht der wichtigsten KI-Rechenzentrumsprojekte in Deutschland (Stand: Frühjahr 2026)

Projekt	Akteur(e)	Investition	Standort	Status
KI-Gigafactory Lübbenau	Schwarz Digits	11 Mrd. €	Brandenburg	im Bau
KI-Rechenzentrum München	Dt. Telekom + Nvidia	k. A.	München	2026 Q1
Rechenzentrum Dietzenbach	Google	(Teil von 5,5 Mrd. €)	Hessen	geplant
Google-Infrastrukturprogramm	Google	5,5 Mrd. €	Deutschland	angekündigt
KI-Gigafactory (geplant)	Schwarz + Telekom	k. A.	k. A.	Verhandlung

12.4.2 Technische Spezifikationen

Das Rechenzentrum Lübbenau wird in zwei Bauabschnitten fertiggestellt. Die wichtigsten technischen Eckdaten sind:

- **Anschlussleistung:** 200 Megawatt – konzipiert als zentraler Knotenpunkt für europaweite KI-Anwendungen.
- **GPU-Kapazität:** Bis zu 100.000 GPUs können vernetzt werden; damit erfüllt Lübbenau die EU-Definition einer *Gigafactory* (vgl. definition 12.3).
- **Kapazitätssteigerung:** Die Rechenleistung der gesamten Schwarz-Gruppe wird durch das neue Zentrum um das **Siebenfache** gesteigert.
- **Modulares Design:** Das Rechenzentrum ist als modulares Datacenter konzipiert, das schrittweise ausgebaut und an wachsende Anforderungen angepasst werden kann.

Definition 12.3 (KI-Gigafactory). *Als KI-Gigafactory bezeichnet die Europäische Union ein skalierbares Rechenzentrum mit einer GPU-Ausstattung von mindestens 100.000 Grafikprozessoren, das für das Training und den Betrieb von KI-Modellen mit extrem großem Rechenaufwand ausgelegt ist. Die EU plant die Förderung von vier bis fünf solcher Gigafactories im europäischen Raum mit einem Subventionsanteil von bis zu 35 Prozent der Investitionskosten.*

12.4.3 Datensouveränität durch kryptographische Verschlüsselung

Schwarz Digits unterhält seit 2024 eine Kooperation mit Google Cloud, die in ihrer Ausgestaltung auf die Herstellung *souveräner* Cloud-Lösungen für europäische Institutionen abzielt. Insbesondere sollen Unternehmen aus dem Finanz- und Gesundheitssektor sowie der öffentliche Sektor von einer DSGVO-konformen und Cloud-Act-resistenten Datenhaltung profitieren.

Das technische Kernmerkmal dieser Lösung ist die *Ende-zu-Ende-Verschlüsselung* von Google Workspace-Daten über die eigene Schwarz-Digits-Plattform (Stackit): Bei aktivierter Verschlüsselung halten die Kunden die alleinige Kontrolle über ihre *Encryption Keys* und damit die vollständige Datenhoheit. Selbst Google als Plattformanbieter ist technisch vom Zugriff auf die Klartextdaten ausgeschlossen – ein Mechanismus, der den US-Cloud-Act faktisch ins Leere laufen lässt.

Bemerkung 12.4 (Kryptographische Souveränität als Systemarchitekturprinzip). *Die beschriebene Verschlüsselungsarchitektur entspricht dem Konzept des Client-Side-Encryption (CSE) oder Hold Your Own Key (HYOK). In der Modellierung des vorliegenden Dokuments lässt sich dies als topologische Trennung des Informationsflussgraphen interpretieren: Der Diensteanbieter (Google Cloud) operiert auf einem verschlüsselten Teilgraphen $\mathcal{G}_{enc} \subset \mathcal{G}$, während der Schlüsselbesitzer (Schwarz-Digits-Kunde) exklusiven Zugang zum vollständigen Klartext-Graphen $\mathcal{G}$ besitzt. Die Separation ist kryptographisch hart – d. h. auch mit theoretisch unbegrenzter Rechenleistung des Angreifers ohne Kenntnis der Schlüssel nicht aufhebbar.*

12.4.4 Ökologisches Betriebskonzept

Das Rechenzentrum in Lübbenau wird ausschließlich mit Grünstrom betrieben. Die eigenen Photovoltaikanlagen des Geländes erzeugen jährlich rund 520 Megawattstunden emissionsfreie Energie. Darüber hinaus wird die Abwärme der Server in das lokale Fernwärmenetz eingespeist, was die Versorgung von schätzungsweise 75.000 Haushalten mit Wärmeenergie ermöglicht.

Dieses Prinzip der *thermalen Wertschöpfungskaskade* – Abwärme von Rechenzentren als Ressource für die Wärmeversorgung von Wohngebieten – repräsentiert einen Paradigmenwechsel in der Betrachtung von Rechenzentren als reine Verbraucher hin zu Teilnehmern im städtischen Energiesystem.

12.5 Deutsche Telekom und Nvidia: KI-Fabrik München

12.5.1 Partnerschaft und Aufstellung

Die Deutsche Telekom, Deutschlands größter Technologiekonzern, verfolgt eine parallele Strategie zur Schwarz-Gruppe: Sie baut gemeinsam mit dem Halbleitergiganten Nvidia in **München** eine der leistungsstärksten KI-Fabriken in Europa. Das Projekt umfasst 10.000 GPUs der neuesten Nvidia-Generation und soll bereits im **ersten Quartal 2026** in Betrieb gehen.

Laut Ferri Abolhassan, Vorstandsmitglied der Deutschen Telekom, wird das neue KI-Rechenzentrum die gesamte KI-Rechenleistung in Deutschland *auf einen Schlag um rund 50 Prozent* steigern – eine bemerkenswerte Aussage, die den relativen Ausgangszustand der deutschen KI-Infrastruktur zugleich in Relation setzt: Wenn eine einzige neue Anlage die nationale Gesamtkapazität um die Hälfte erhöht, war die Ausgangsbasis strukturell unzulänglich.

12.5.2 Strategische Stoßrichtung: Industrielle KI als Kernanwendungsfall

Ferri Abolhassan betont, dass der entscheidende wirtschaftliche Hebel für Deutschland nicht im Betrieb von Sprachmodellen für Endverbraucher liege, sondern in der *industriellen KI*: digitalisierten Fabriken, automatisierten Lieferketten und virtuellen Entwicklungsumgebungen. Diese Einschätzung deckt sich mit der für die vorliegende Arbeit relevanten Beobachtung, dass Graphrestrukturisierungsmethoden – wie in den Theoremen 4.2 und ?? beschrieben – besonders in Szenarien mit kontinuierlichen Anpassungsanforderungen (*continual learning*) und domänenspezifischen Feinabstimmungen ökonomisch attraktiv sind, da sie den vollständigen Neutrainierungsaufwand umgehen.

Jensen Huang, CEO von Nvidia, kommentierte die Kooperation mit der Deutschen Telekom mit einem Verweis auf Deutschlands industrielle Stärken, die durch KI weiter ausgebaut werden könnten – ein Argument, das die strukturelle Komplementarität zwischen europäischer Ingenieurskultur und fortgeschrittenen KI-Methoden unterstreicht.

12.6 Google: Strategische Investition in deutsche Infrastruktur

Google hat für Deutschland ein Investitionsprogramm von **5,5 Milliarden Euro** für die kommenden Jahre angekündigt – intern als “das bisher größte Investitionsprogramm für die digitale Zukunft Deutschlands” bezeichnet. Der Schwerpunkt liegt auf dem Ausbau von Infrastruktur und Rechenzentren.

Ein zentrales Element ist das neue Rechenzentrum in **Dietzenbach** (Hessen). Ähnlich wie in Lübbenau wird auch hier die Abwärme der Server in das lokale Fernwärmenetz eingespeist – eine Entscheidung, die sowohl ökologischen als auch kommunalpolitischen Erfordernissen Rechnung trägt und die Akzeptanz großer Recheninfrastrukturen in der Bevölkerung erhöht.

Bemerkung 12.5 (Ambivalenz der Google-Investition). *Es ist bemerkenswert und zugleich strukturell bezeichnend, dass ein US-amerikanischer Hyperscaler – dessen Cloud-Dienste gemäß US-Cloud-Act der US-amerikanischen Datenhoheit unterliegen – als einer der Hauptinvestoren für den Aufbau der deutschen KI-Infrastruktur auftritt. Diese Ambivalenz spiegelt die Kernspannung der europäischen Digitalpolitik wider: Der Bedarf an schnellem Infrastrukturaufbau und dem Zugang zu hochentwickelten Technologien steht in einem strukturellen Widerspruch zu dem Ziel der vollständigen digitalen Souveränität.*

12.7 EU-Förderprogramm für KI-Gigafactories

12.7.1 Rahmenbedingungen des EU-Ausschreibungsverfahrens

Die Europäische Union hat ein Förderprogramm für den Aufbau europäischer KI-Gigafactories aufgelegt. Die wesentlichen Parameter sind:

- **Geplante Anzahl:** Vier bis fünf KI-Gigafactories sollen im europäischen Raum entstehen.
- **Subventionsquote:** Die EU will bis zu **35 Prozent** der Investitionskosten übernehmen.
- **Wettbewerb:** Insgesamt haben **76 Firmen oder Konsortien** aus **16 EU-Staaten** Interessenbekundungen eingereicht.
- **Deutsche Kandidaten:** Die Schwarz-Gruppe (Schwarz Digits) und die Deutsche Telekom haben jeweils Interesse signalisiert; außerdem wird eine gemeinsame KI-Gigafactory beider Konzerne diskutiert.

12.7.2 Potenzielle deutsch-deutsche Kooperation

Berichten zufolge erwägen die Schwarz-Gruppe und die Deutsche Telekom, ihre Ressourcen für den Bau einer gemeinsamen KI-Gigafactory zu bündeln. Eine solche Kooperation würde im europäischen Kontext einen erheblichen Synergieeffekt erzeugen: Stackit (Schwarz Digits) brächte Expertise in souveräner Datenhaltung und Energieeffizienz ein; die Deutsche Telekom lieferte ihr Netzwerkinfrastruktur-Know-how sowie die Partnerschaft mit Nvidia.

Ein kombiniertes Projekt hätte realistische Chancen, im EU-Ausschreibungsverfahren zu bestehen, da es die technologische Tiefe und das Investitionsvolumen mitbringt, das für

eine Gigafactory nach EU-Definition erforderlich ist. Allerdings konkurrieren 76 Bewerber aus 16 Staaten um maximal fünf Zuschläge – ein Wettbewerbsdruck, der eine Förderung keineswegs garantiert.

Proposition 12.6 (Strukturelle Notwendigkeit der Gigafactory-Infrastruktur). *Sei $\mathcal{M}$ die Menge der in Europa trainierbaren KI-Modelle in Abhängigkeit von der verfügbaren GPU-Kapazität G (in TFLOP/s). Dann gilt für den in chapter 5 eingeführten Restrukturierungsaufwand $\Phi(\varrho, n)$ bei fester Restrukturierungsquote ϱ :*

$$\frac{\partial \Phi(\varrho, n)}{\partial n} \propto n^{1+\varrho} \ln n,$$

d. h. der Rechenaufwand für Graphrestrukturierungen wächst superlinear mit der Modellgröße $n = |\mathcal{V}|$. Ohne Zugang zu Gigafactory-Kapazitäten ($G \geq G_{\min}$) ist die praktische Anwendung von Restrukturierungsalgorithmen auf Modelle der Größenordnung $n \geq 10^{10}$ in Europa nicht möglich. Europäische Gigafactories sind daher eine notwendige infrastrukturelle Bedingung für wettbewerbsfähige KI-Forschung und -Entwicklung.

12.8 Energetische Skalierung: Vom Megawatt zum Gigawatt

12.8.1 Globale Leistungsdimensionen im Vergleich

Das Lübbenauer Rechenzentrum mit 200 Megawatt Anschlussleistung ist für europäische Verhältnisse außerordentlich groß. Im globalen Maßstab der aktuellen KI-Infrastrukturplanung erscheint es jedoch bereits als mittelgroße Anlage. Die folgende Übersicht verdeutlicht die Bandbreite der geplanten Kapazitäten:

Tabelle 12.3: Vergleich globaler KI-Rechenzentrumsprojekte nach Anschlussleistung

Projekt / Anlage	Betreiber	Leistung	Standort
Lübbenau RZ (Phase 1–2)	Schwarz Digits	200 MW	Deutschland
KI-Supercluster Prometheus	Meta (Zuckerberg)	> 1 000 MW	USA
KI-Hypercluster Hyperion	Meta (Zuckerberg)	bis 5 000 MW	USA
OpenAI-RZ-Planungen	OpenAI	mehrere GW	USA
Vergleich: Kernkraftwerk (typisch)		1 000–1 600 MW	–

Metas geplanter Supercluster “Prometheus” nimmt mit über einem Gigawatt Leistungsaufnahme annähernd die Kapazität eines vollständigen Atomkraftwerks in Anspruch. Die geplante Folgeanlage “Hyperion” mit bis zu fünf Gigawatt würde mit der benötigten Strommenge laut Expertenberechnungen mehr als vier Millionen durchschnittliche Haushalte ein Jahr lang versorgen können.

Das Massachusetts Institute of Technology (MIT) hat berechnet, dass eine GPU-Farm, in der generative KI-Modelle trainiert werden, sieben bis acht Mal so viel Energie verbraucht wie ein konventionelles Rechenzentrum vergleichbarer Größe.

12.8.2 Prognose: Strombedarf von Rechenzentren bis 2030

Laut Berechnungen der Internationalen Energieagentur (IEA) wird die Leistungsaufnahme der weltweiten Rechenzentren bis 2030 um **530 Terawattstunden** auf insgesamt **945 TWh** ansteigen – das entspricht mehr als dem Gesamtstrombedarf Japans. Die IEA identifiziert Künstliche Intelligenz als Haupttreiber dieses Anstiegs [53].




Abbildung 12.1: Prognose des globalen Strombedarfs von Rechenzentren bis 2030 nach IEA-Szenarien [53]. Die KI-getriebene Beschleunigung führt zu einem Anstieg um mehr als 530 TWh gegenüber 2024.

12.8.3 Deutschland: Prognose der Rechenzentrums-Anschlussleistung

Für Deutschland prognostizieren Marktanalysten bis 2030 eine installierte Rechenzentrums-Anschlussleistung von mehr als **5 Gigawatt**. Zum Vergleich: Die USA werden nach denselben Schätzungen bei rund **95 Gigawatt** liegen – einem Wert, der die Dimensionen der europäischen Ambitionen noch einmal in Relation setzt.

Deutschland: Prognose der Rechenzentrums-Anschlussleistung bis 2030




Abbildung 12.2: Prognose der installierten Rechenzentrums-Anschlussleistung in Deutschland bis 2030 im Vergleich zu den USA. Trotz der erheblichen geplanten Kapazitätserweiterungen verbleibt eine strukturelle Leistungslücke von rund einer Größenordnung.

12.9 Ökologische Einbettung: Grünstrom und Fernwärme

Der in Europa besonders ausgeprägte ökologische Regulierungsrahmen – die EU-Taxonomie für nachhaltige Finanzierungen, das Energieeffizienzgesetz sowie die kommunalen Klimaschutzziele – stellt an neue Rechenzentren deutlich höhere Nachhaltigkeitsanforderungen als in den USA oder China.

Anders als in den USA, wo einige Cloud-Anbieter (darunter Microsoft) bereits eigene Kleinreaktoren (Small Modular Reactors, SMR) für ihre Rechenzentren planen, sind solche Optionen in Europa politisch nicht durchsetzbar. Stattdessen setzen die deutschen Projekte auf zwei komplementäre Strategien:

- (1) **100 % Grünstrom:** Schwarz Digits betreibt Lübbenau vollständig mit erneuerbaren Energien. Die eigenen Photovoltaikanlagen des Geländes erzeugen jährlich ca. 520 MWh emissionsfreie Energie.
- (2) **Thermale Wertschöpfungskaskade:** Sowohl Lübbenau (Schwarz Digits) als auch Dietzenbach (Google) speisen ihre Serverabwärme in das lokale Fernwärmenetz ein. Lübbenau kann damit rund 75.000 Haushalte mit Wärme versorgen; Dietzenbach versorgt schätzungsweise 2.000 Haushalte im näheren Umfeld.

Bemerkung 12.7 (Thermodynamische Effizienz als infrastrukturelles Designprinzip). *Die Nutzung von Serverabwärme für die Fernwärmeversorgung entspricht einer Umsetzung des thermodynamischen Prinzips der Kraft-Wärme-Kopplung auf Infrastrukturebene. Die effektive Gesamtenergieeffizienz eines Rechenzentrums mit thermaler Rückkopplung ist erheblich höher als der reine PUE-Wert (Power Usage Effectiveness) suggeriert, weil die Abwärme eine externe Wärmeproduktion substituiert. Bei einem Substitutionsgrad von $\eta_{\text{Wärme}}$ ergibt sich die effektive Systemeffizienz zu:*

$$\eta_{\text{eff}} = \frac{P_{\text{Computing}} + \eta_{\text{Wärme}} \cdot P_{\text{Abwärme}}}{P_{\text{gesamt}}} > \frac{1}{\text{PUE}},$$

wobei $P_{\text{gesamt}} = P_{\text{Computing}} + P_{\text{Kühlung}} + P_{\text{sonstig}}$.

12.10 Typen von Rechenzentren: Eine formale Klassifikation

Im Kontext der vorliegenden Arbeit ist die Unterscheidung verschiedener Betriebsmodelle von Rechenzentren relevant, da sie unmittelbar den Grad der möglichen Datensouveränität und die Latenz für Graphrestrukturierungsaufgaben beeinflusst.

Definition 12.8 (Rechenzentrum-Taxonomie). *Es werden folgende Typen von Rechenzentren unterschieden:*

- (i) **Enterprise-Rechenzentrum (ERZ):** Das Unternehmen betreibt das Rechenzentrum vollständig in Eigenregie. Dies ermöglicht maximale Datenkontrolle, erfordert jedoch erhebliche Vorabinvestitionen in Hardware, Sicherheit und Betrieb.
- (ii) **Colocation-Rechenzentrum (Co-RZ):** Ein externer Anbieter stellt Strom, Kühlung und physische Sicherheit bereit; die Hardware gehört dem Kunden. Zwischen Eigenverantwortung und Outsourcing.
- (iii) **Cloud-Rechenzentrum (CRZ):** Die gesamte Infrastruktur – Hardware, Software, Netzwerk – wird durch externe Anbieter wie AWS, Google Cloud oder Azure verwaltet. Maximale Flexibilität, minimale Datensouveränität.
- (iv) **Managed-Services-Rechenzentrum (MSRZ):** Erweiterung des CRZ-Modells; der Anbieter übernimmt zusätzlich Anwendungs- und Systemmanagement.
- (v) **Edge-Rechenzentrum (ERZ-E):** Kleine, dezentrale Anlage in unmittelbarer Nähe der Datenquelle. Minimale Latenz, begrenzte Rechenkapazität; relevant für Echtzeit-KI-Anwendungen in der Industrie (vgl. Kapitel 12.5).
- (vi) **KI-Gigafactory (GF):** Skalierbares Rechenzentrum mit $\geq 100\,000$ GPUs, optimiert für das Training großer KI-Modelle (vgl. definition 12.3).




Abbildung 12.3: Taxonomie von Rechenzentrumstypen entlang des Spektrums abnehmender Datensouveränität. KI-Gigafactories (GF) und Edge-Rechenzentren (ERZ-E) bilden Sonderpositionen am jeweiligen Kapazitäts- bzw. Latenzextrem.

12.11 Globale Investitionsperspektive und strategische Einordnung

12.11.1 Globale Investitionsprognosen

Die Investitionsvolumina im globalen Rechenzentrums- und KI-Infrastrukturmarkt erreichen Dimensionen, die alle historischen Vergleiche übersteigen. Zwei prominente Prognosen:

- **Morgan Stanley** schätzt, dass bis **2029** weltweit nahezu **3 Billionen US-Dollar** in neue Rechenzentren investiert werden.
- **McKinsey** prognostiziert für denselben Zeitraum bis 2030 Gesamtinvestitionen von nahezu **7 Billionen US-Dollar**.

Unabhängig von der konkreten Zahl – die Spanne zwischen 3 und 7 Billionen reflektiert die Schwierigkeit der Modellierung exponentiell wachsender Technologiemarkte – ist klar, dass der Großteil dieser Mittel in den USA und China investiert wird. Europa, und Deutschland im Besonderen, muss erhebliche Anstrengungen unternehmen, um nicht in eine dauerhafte Infrastrukturabhängigkeit zu geraten.

12.11.2 Parallelen zum Northvolt- und Intel-Schicksal

Die Geschichte der deutschen und europäischen Bemühungen um digitale Industriepolitik ist geprägt von prominenten Rückschlägen: Das schwedisch-europäische Batterieunternehmen Northvolt und die geplante Intel-Chipfabrik in Magdeburg sind jüngste Beispiele für das Scheitern hochsubventionierter Großprojekte. Christian Müller, Co-CEO von Schwarz Digits, formuliert die strategische Notwendigkeit vor diesem Hintergrund pointiert: Es stelle sich nicht die Frage, ob man investieren solle, sondern wie schnell man die eigene KI-Infrastruktur aufbaue.

Proposition 12.9 (Strukturelle Lock-in-Dynamik). *Sei $S(t)$ der Marktanteil europäischer Cloud-Anbieter zum Zeitpunkt t und $\lambda > 0$ die Lock-in-Rate der Nutzerbindung an bestehende Cloud-Plattformen (z. B. durch proprietäre APIs, Datenmigrationshürden, Netzwerkeffekte). Dann gilt unter der vereinfachenden Annahme einer logistischen Konkurrenzndynamik:*

$$\frac{dS}{dt} = r \cdot S(t) \cdot (1 - S(t)) - \lambda \cdot S(t),$$

wobei $r > 0$ die Wachstumsrate bei Neuinvestitionen bezeichnet. Für $r < \lambda$ ist das einzige stabile Gleichgewicht $S^* = 0$ – d. h. ohne einen Wachstumsbeitrag, der die Lock-in-Rate übersteigt, konvergiert der europäische Marktanteil gegen null. Investitionen wie das Lübbenau-Projekt zielen darauf ab, r strukturell über λ anzuheben.

12.12 Implikationen für Graphrestrukturierungsforschung in Europa

Die im vorliegenden Dokument entwickelte Theorie der minimalen Graphrestrukturierung hat – über ihre mathematische Eigenständigkeit hinaus – eine direkte praktische Relevanz für den europäischen KI-Infrastrukturaufbau, die in drei Dimensionen beschrieben werden kann:

(1) Recheneffiziente Methodik als strategischer Vorteil. Das zentrale Ergebnis dieser Arbeit – dass signifikante Kapazitätsgewinne durch minimale Graphveränderungen erzielbar sind (vgl. Theorem 4.2) – impliziert, dass europäische Forscher und Unternehmen mit *weniger* Rechenressourcen *mehr* Modellqualität erzielen können, wenn sie strukturelle Restrukturierungsmethoden konsequent einsetzen. In einem Umfeld, in dem Europa strukturell weniger GPU-Kapazität als die USA besitzt, ist Recheneffizienz kein optionales Gütekriterium, sondern eine *strategische Notwendigkeit*.

(2) Souveräne Infrastruktur als Voraussetzung für Forschungsfreiheit. Die Durchführung sensibler KI-Forschung – etwa im Bereich industrieller Prozessoptimierung, medizinischer Diagnose oder nationaler Verteidigungsanwendungen – setzt voraus, dass die Trainingsdaten und Modellgewichte nicht dem Zugriff fremder Rechtsordnungen unterliegen. Die in section 12.4 beschriebene kryptographische Souveränitätsarchitektur von Schwarz Digits stellt einen wichtigen Schritt in diese Richtung dar.

(3) Industrielle KI als Scharnierpunkt. Wie in section 12.5 ausgeführt, liegt Deutschlands komparativer Vorteil in der industriellen KI. Graphrestrukturierungsverfahren für nahezu ausgelernete Netzwerke sind in diesem Kontext besonders wertvoll: In industriellen Anwendungen verändern sich Prozessparameter kontinuierlich (Drift in Maschinenzuständen, Produktionsvariationen), was eine permanente Anpassung der Modelle erfordert. Vollständiges Neutraining wäre bei dieser Frequenz prohibitiv teuer; gezielte Graphrestrukturierung nach dem in Algorithmus ?? beschriebenen Verfahren bietet hier einen praktisch umsetzbaren Mittelweg.

12.13 Zusammenfassung

Das vorliegende Kapitel hat gezeigt, dass Deutschland und Europa an einem infrastrukturellen Wendepunkt stehen. Die wichtigsten Erkenntnisse lassen sich wie folgt zusammenfassen:

- (i) Die globale Cloud-Infrastruktur wird von drei US-Hyperscalern dominiert; Europa hält weniger als zwei Prozent des Weltmarktes.
- (ii) Der AWS-Ausfall vom Oktober 2025 hat die systemischen Risiken dieser Abhängigkeit konkret erfahrbar gemacht.
- (iii) Deutschland antwortet mit einer Reihe von Großprojekten: Schwarz Digits in Lübbenau (11 Mrd. €, 200 MW, bis zu 100.000 GPUs), die Telekom-Nvidia-Kooperation in München und das Google-Programm (5,5 Mrd. €, Dietzenbach).
- (iv) Alle deutschen Projekte setzen auf Grünstrom und thermale Wertschöpfungskaskaden (Fernwärme), was ökologische und regulatorische Anforderungen erfüllt.
- (v) Der globale Strombedarf von Rechenzentren wird laut IEA bis 2030 auf rund 945 TWh steigen, angetrieben durch KI als Hauptwachstumstreiber.
- (vi) Globale Investitionen bis 2030 werden auf 3–7 Billionen US-Dollar geschätzt; der Großteil fließt in die USA und China.

- (vii) Die in dieser Arbeit entwickelten Methoden der minimalen Graphrestrukturierung leisten einen methodischen Beitrag zur Recheneffizienz, die für Europa unter Knappheitsbedingungen strategische Relevanz hat.

Die digitale Aufholjagd Deutschlands ist möglich – aber sie erfordert politische Beständigkeit, private Investitionsbereitschaft und eine wissenschaftliche Methodik, die aus europäischer Sicht rechnerisch effizient und rechtlich souverän operiert.

Kapitel 13

Zusammenfassung und Ausblick

Diese Arbeit hat die *minimale Graphrestrukturierung* nahezu ausgelernter neuronaler Netzwerke formal untersucht und sechs Hauptergebnisse erzielt:

1. **Spektrales Fundament:** Weyl-Schranke und Fiedler-Vektor-Argument belegen, dass minimale Kantenänderungen die algebraische Konnektivität gezielt verbessern, ohne das Spektrum zu destabilisieren (Theoreme 3.2, 3.3).
2. **Superlinearer Kapazitätsgewinn:** Das Zentralresultat (Theorem 4.2) zeigt, dass für $\varrho \leq \varrho^*$ der normierte Kapazitätswachstum positiv ist und bei optimalem ϱ^* maximal wird, während Rademacher-Komplexität und VC-Dimension nur marginal steigen (Theorem 4.3).
3. **Informationstheoretischer Gewinn:** Entropiegewinn (Proposition 7.2) und gegenseitige Informationssteigerung (Theorem 7.3) belegen, dass das Netz nach Restrukturierung effektiv mehr Information aus der Eingabe extrahiert.
4. **Vergessenschranke:** Theorem 8.1 gibt eine obere Schranke für das katastrophale Vergessen, die proportional zu ϱ ist und für $\varrho \leq \varrho^*$ praktisch vernachlässigbar bleibt.
5. **Entscheidungsgrenzen-Erweiterung:** Theorem 8.3 garantiert, dass neue Klassen durch doppelte minimale Restrukturierung akkommodiert werden können, ohne bestehende Grenzen zu korrumpieren.
6. **Energetische Implikationen:** Kapitel 11 entwickelt ein vollständiges formales Energiemodell für den Betrieb minimierter neuronaler Netzwerke in Rechenzentren. Der Energieeinspar-Satz (Theorem 11.4) beweist, dass bei einem Kompressionsverhältnis $\kappa = 0,3$ und $\text{PUE} = 1,45$ rund 53 % des gesamten skalierbaren Serververbrauchs eingespart werden. Für ein 1000-Server-Rechenzentrum im EU-Strommix ergibt sich eine Einsparung von über 17 GWh/Jahr und mehr als 4800 tCO₂eq/Jahr – das Klimaäquivalent von fast 500 PKW-Jahresleistungen. Die vollständige TCO-Analyse (Proposition 11.12) zeigt einen 5-Jahres-ROI von über 42 M€ für 500 Server; der SGKR-Kompressionsaufwand amortisiert sich bereits innerhalb einer Betriebsstunde.

Die vorliegende Arbeit legt ein formales Fundament für minimale Graphrestrukturierung nahezu ausgelernter neuronaler Netzwerke. Die hergeleiteten Schranken und Algorithmen eröffnen ein breites Spektrum zukünftiger Forschungsrichtungen, das von theoretischen Verfeinerungen über empirische Validierung bis hin zu praktischen Anwendungsszenarien reicht. Der folgende Ausblick gliedert sich in zwölf thematische Schwerpunkte und beschreibt die jeweils vielversprechendsten offenen Fragen.

13.1 Erweiterung auf moderne Architekturen

Rekurrente Netzwerke. Die in dieser Arbeit entwickelte Theorie setzt implizit eine azyklische, schichtweise Graphstruktur (Feedforward-Netz) voraus. Rekurrente Architekturen – insbesondere LSTM- und GRU-Netzwerke – enthalten gerichtete Zyklen, die den zugrunde liegenden Trägergraphen $\hat{\mathcal{G}}$ fundamental verändern: Der Laplace-Operator wird zu einer zeitabhängigen Größe, und die Spektrallücke Δ_{sp} variiert über die Zeitschritte. Eine formale Erweiterung von Theorem 3.2 auf gerichtete Graphen mit Zyklen – unter Verwendung des *Hermite-Laplace*-Operators (Singer & Wu, 2012) – ist eine vordringliche offene Frage. Dabei ist insbesondere zu klären, wie sich minimale Restrukturierung auf den Vanishing-Gradient-Effekt in tiefen RNNs auswirkt: Die algebraische Konnektivitätssteigerung könnte langreichweitige Abhängigkeiten verbessern, indem Gradienten über mehr Zeitschritte effektiv zurückpropagiert werden.

Transformer-Architekturen. Transformer-Modelle (Vaswani et al., 2017) stellen die dominante Architekturklasse für Natural Language Processing und zunehmend für Computer Vision dar. Ihre Graphstruktur unterscheidet sich grundlegend von klassischen Feedforward-Netzen: Jedes Token attendiert dynamisch auf alle anderen, sodass die “Kantengewichte” des Attention-Mechanismus datenabhängig und nicht fest sind. Die Frage, welche statischen Verbindungen (Projektionsmatrizen $\mathbf{W}_Q, \mathbf{W}_K, \mathbf{W}_V$, Feed-Forward-Blöcke) durch minimale Restrukturierung perturbiert werden sollten, ist noch unbeantwortet. Ein vielversprechender Ansatz wäre, die Aufmerksamkeitsköpfe als Knoten eines Meta-Graphen zu betrachten und zwischen diesen Metaknoten spärliche Querverbindungen einzuführen – analog zu Skip-Connections in ResNets. Das Analogon des toten Neurons ist im Transformer-Kontext ein “toter Aufmerksamkeitskopf”: ein Kopf, dessen Attention-Gewichte nach der Softmax-Normierung kollabieren und nahezu uniforme Verteilungen produzieren, sodass er keinen differenzierten Beitrag zur Ausgabe liefert. Die formale Charakterisierung und Reaktivierung solcher Köpfe durch minimale Strukturveränderungen ist eine algorithmisch und theoretisch interessante Fragestellung.

Graph Neural Networks. Graph Neural Networks (GNNs) verarbeiten selbst graphstrukturierte Daten. Hier erhält die Restrukturierung eine doppelte Bedeutung: Zum einen kann die interne Graphstruktur des GNN (Verbindungen zwischen den Nachrichtenpfad-Operatoren) restrukturiert werden; zum anderen kann der *Eingabegraph* gezielt modifiziert werden. Letzteres ist als *Graph Rewiring* ein aktives Forschungsfeld (Topping et al., 2022), das starke strukturelle Überschneidungen mit dem OMGR-Algorithmus aufweist. Eine formale Verbindung zwischen den Kapazitätsschranken aus chapter 4 und den Überquetschungs-Problemen in GNNs (Over-Squashing, Alon & Yahav, 2021) könnte Kapazitätsgewinne durch gezielte Kantenzugaben im Eingabegraphen quantifizieren und einen neuen theoretischen Rahmen für datengetriebenes Graph Rewiring liefern.

Diffusionsmodelle und generative Architekturen. Score-basierte Diffusionsmodelle (Song et al., 2021) und variationelle Autoencoder besitzen ebenfalls klar definierte Netzwerkgraphen. In der Enkoder-Dekoder-Struktur eines VAE könnte minimale Restrukturierung gezielt den Engpass im latenten Raum erweitern: Durch Hinzufügen von Skip-Connections zwischen Enkoder und Dekoder, die einzelne Dimensionen des latenten Raums direkt verbinden, ließe sich die rekonstruktive Kapazität erhöhen, ohne die Regularisierung durch den KL-Divergenz-Term zu gefährden.

13.2 Skalierungsanalyse: Weiterführende Fragestellungen und offene Probleme

Die in chapter 5 eingeführte Skalierungsanalyse legt ein geschlossenes mathematisches Bild des optimalen Verhältnisses zwischen umstrukturierten Kanten und erzielbarer Aussagekraft vor, differenziert nach Netzwerkgröße und Architekturtopologie. Die zentralen Ergebnisse – insbesondere Theorem 5.4 (Zwei-Regionen-Analyse), Proposition 5.6 (Architekturskalierung von k^*) sowie Theorem 5.8 (Budgetgarantie) – stellen einen vollständigen theoretischen Rahmen bereit, der jedoch zahlreiche aufbauende Fragen aufwirft. Die folgenden Absätze entfalten diese Fragen ausführlich und skizzieren konkrete Forschungsprogramme.

Empirische Kalibrierung der Modellkonstanten c_1 und β . Im Kern der Aussagekraft-Funktion $A(\varrho) = c_1 \frac{dL}{n} \varrho - \beta \varrho^2$ stehen zwei als universell angenommene Konstanten. Die Größe $c_1 > 0$ kodiert den Kapazitätsgewinn pro reaktiver Kante – sie hängt vom Reaktivierungspotenzial der Aktivierungsfunktion und der Gradientenflussstatistik ab – während $\beta > 0$ die Generalisierungskosten der strukturellen Perturbation nach oben begrenzt. In der vorliegenden Arbeit werden beide als netzwerkunabhängige Konstanten behandelt; ihre genauen numerischen Werte hängen jedoch vom Aktivierungstyp, der Trainingsdaten-Marginalverteilung μ und der Netz-Initialisierung ab.

Eine wichtige Folgeaufgabe ist daher die *empirische Kalibrierung*: Für eine Familie von Netzwerken $(n_1, L_1, d_1), \dots, (n_K, L_K, d_K)$ lässt sich aus je einem Restrukturierungsexperiment ein Datenpunkt $(A_i^{\text{emp}}, \varrho_i)$ messen. Eine nicht-lineare Kleinstquadratanpassung der Kurve $A(\varrho; c_1, \beta)$ an diese Punkte liefert Schätzungen $\hat{c}_1$ und $\hat{\beta}$ mit Konfidenzellipsen, die via Bootstrap oder Bayesianischer Inferenz (Prior $c_1 \sim \Gamma(\alpha_c, \lambda_c)$, $\beta \sim \Gamma(\alpha_\beta, \lambda_\beta)$) gewonnen werden können. Für eine robuste Kalibrierung sollte die Stichprobe mindestens drei Netzwerkgrößenordnungen abdecken ($n \in [10^2, 10^6]$), um den Übergang zwischen dem Kleinnetz-Regime ($n \leq n_{\text{crit}}$) und dem Großnetz-Regime ($n > n_{\text{crit}}$) aus Theorem 5.4 empirisch zu belegen – einschließlich des Phasenübergangs exakt bei $n = n_{\text{crit}}$, an dem ϱ_{con}^* von ϱ_{max} auf das fallende $\hat{\varrho}^*(n) \propto 1/n$ wechselt.

Darüber hinaus ist zu klären, ob c_1 und β tatsächlich architekturtranszendente Universalkonstanten sind oder systematisch mit dem Totneuronen-Anteil α_{dead} , der Netztiefe L oder der Aktivierungsfunktion variieren. Sollte sich herausstellen, dass $c_1 = c_1(\sigma)$ von σ abhängt – was für GELU im Vergleich zu ReLU plausibel ist, da GELU eine graduelle Abschwächung ohne harte Abschaltschwelle besitzt –, müsste das Modell zu $A(\varrho; c_1(\sigma), \beta(\sigma), n)$ erweitert werden. Theorem 5.4 bliebe strukturell gültig; lediglich die Konstanten wären aktivierungsspezifisch. Die beiden Extremfälle $\sigma = \text{ReLU}$ (harte Schwelle, c_1 groß) und $\sigma = \text{Sigmoid}$ (weiche Sättigung, c_1 klein) bilden die Eckpunkte eines Interventionsraums, den zukünftige Ablationsstudien quantifizieren können.

Schichtweise Skalierungsanalyse und adaptive ϱ_ℓ^* -Profile. Das in chapter 5 analysierte Modell verwendet ein einziges globales Restrukturierungsverhältnis ϱ , das auf alle Schichten gleichmäßig angewendet wird. In der Praxis ist die Totneuronen-Dichte jedoch schichtabhängig: In mittleren Schichten ($\ell \approx L/2$) ist d_ℓ/n_ℓ typischerweise deutlich größer als in der Eingangs- und Ausgangsschicht (vgl. fig. 8.3, oberes rechtes Panel). Eine schichtweise Generalisierung der Aussagekraft lautet:

$$A_{\text{lw}}(\varrho_1, \dots, \varrho_L) = \sum_{\ell=1}^L \left[c_{1,\ell} \frac{d_\ell}{n_\ell} \varrho_\ell - \beta_\ell \varrho_\ell^2 \right]$$

unter dem Kantenbudget $\sum_{\ell} \lfloor \varrho_{\ell} m_{\ell} \rfloor \leq K_{\text{budget}}$. Das optimale schichtweise Profil ϱ_{ℓ}^* ergibt sich durch Lagrangeoptimierung:

$$\varrho_{\ell}^* = \frac{c_{1,\ell} d_{\ell} / n_{\ell} - \lambda m_{\ell}}{2 \beta_{\ell}},$$

wobei $\lambda \geq 0$ der Lagrange-Multiplikator zum Budget-Constraint ist und durch primäre Erfüllbarkeit bestimmt wird. Die praktische Bedeutung dieser schichtweisen Allokation ist erheblich: Schichten mit hohem d_{ℓ} erhalten ein größeres Budget; Schichten mit $d_{\ell} = 0$ (keine toten Neuronen) erhalten $\varrho_{\ell}^* = 0$ und bleiben unverändert.

Eine offene Frage ist die Erweiterung von Theorem 5.8 auf den schichtweisen Fall: Unter welcher minimalen Budget-Bedingung an die schichtweisen Größen K_{ℓ} gilt $A_{\text{lw}} > 0$? Da die schichtweisen Terme in A_{lw} additiv sind, kann bereits eine einzige Schicht mit hohem d_{ℓ} und $K_{\ell} \geq 1$ die gesamte Aussagekraft positiv halten. Formale Schranken – analog zu (5.8) – für die schichtweise Budgetgarantie stehen noch aus. Insbesondere wäre zu zeigen, welche Schicht oder Schichtkombination das “kritische Bottleneck” darstellt, d. h. welche Schicht bei gegebener Gesamtbudget-Beschränkung den größten Marginalgewinn erzielt und die Ressource zuerst erhalten sollte.

Über diese statische Optimierung hinaus ermöglicht das schichtweise Modell eine *progressive Restrukturierungsstrategie*: Statt alle k^* Kanten simultan umzustrukturieren, beginnt man mit demjenigen ℓ^* , das das größte d_{ℓ}/n_{ℓ} besitzt, und iteriert schichtweise nach oben und unten. Ob diese greedy-schichtweise Strategie gegenüber der simultanen Lösung einen Vor- oder Nachteil hinsichtlich Trainingsstabilität und Vergessen-Schranke hat, ist eine offene empirische und theoretische Frage.

Verbindung zu neuronalen Skalierungsgesetzen. Kaplan et al. (2020) haben empirisch nachgewiesen, dass die Testperformanz von Sprachmodellen als Potenzgesetz mit der Parameteranzahl N , der Datensatzgröße D und dem Rechenaufwand C skaliert. Die in chapter 5 hergeleitete Skalierung der maximalen Aussagekraft (5.3) $A_{\text{max}}^*(n) \propto n^{-2}$ beschreibt eine *abnehmende Rendite*: Für größere Netzwerke liefert dieselbe relative Restrukturierung geringere normierte Kapazitätsgewinne. Dies mag zunächst überraschen, da Kaplan-Gesetze wachsende Performanz bei wachsendem N beschreiben. Der Widerspruch löst sich auf, wenn man bedenkt, dass Kaplan-Gesetze die Absolut-Performance als Funktion der kumulativen Kapazität messen, während $A_{\text{max}}^*(n)$ den *relativen marginalen Zuwachs* durch eine einzelne Restrukturierungsoperation beschreibt: Der absolute Kapazitätswachstum $\Delta \text{VCdim} = A_{\text{max}}^*(n) \cdot \text{VCdim}(\mathcal{H}_{\mathcal{G}}) \propto n^{-2} \cdot n \cdot L = L/n$ wächst mit L und fällt mit n – was einerseits bestätigt, dass tiefe Netze mehr von Restrukturierung profitieren als breite, und andererseits nahelegt, dass für sehr große n eher viele kleine parallele Restrukturierungsschritte sinnvoller sind als ein großer.

Eine formale Verbindung zu Skalierungsgesetzen ergibt sich, wenn man $A^*(n, D)$ als Funktion von Netzgröße n und Datensatzgröße D betrachtet. Die Anzahl der toten Neuronen d ist selbst eine Funktion von D : Mehr Trainingsdaten reaktivieren tendenziell mehr Neuronen, sodass $d(D) \approx d_0 e^{-\gamma D/n}$ für ein einfaches Sättigungsmodell gilt. Das sich ergebende kombinierte Gesetz

$$A^*(n, D) \propto \frac{d_0^2}{\beta n^2} e^{-2\gamma D/n}$$

ist eine Funktion des Verhältnisses D/n (Tokens pro Parameter) – exakt der Größe, die auch in den Chinchilla Scaling Laws (Hoffmann et al., 2022) zentral ist. Eine Kalibrierung

dieses kombinierten Gesetzes über mehrere Netzwerkgrößen und Datensatzgrößen würde es erlauben, für ein gegebenes (n, D) -Paar das optimale Restrukturierungsfenster präzise vorherzusagen: wann ist das Netz ausreichend trainiert, um von OMGR zu profitieren, und wie groß ist der erwartete Gewinn?

Verbindung zur Lottery-Ticket-Hypothese. Die Lottery-Ticket-Hypothese (Frankle & Carlin, 2019) postuliert, dass jedes große Netzwerk ein kleines, bei der Initialisierung schon vorhandenes *Gewinner-Subnetzwerk* enthält, das allein trainiert zu gleicher Performanz führt. Die OMGR-Skalierungsanalyse bietet eine komplementäre Perspektive: Das optimale $k^*(n)$ bestimmt, wie viele Kanten *reaktiviert* – nicht entfernt – werden müssen, um das Netz in eine neue Kapazitätsregion zu überführen. Formalisiert man ein “schlafendes Subnetzwerk” als die Kanten, die durch Pruning oder Training deaktiviert wurden aber potenziell reaktivierbar sind, so beschreibt $k^*(n)$ die minimale Größe dieses schlafenden Subnetzwerks, das durch OMGR geweckt werden muss.

Für skalenfreie Architekturen (Proposition 5.6, Fall (ii)) zeigt die Analyse, dass $k^*(n) = \Theta(1)$, also unabhängig von n . Da Barabási-Albert-Graphen durch ihre inhärente Skaleninvarianz einen nahezu konstanten “Hub-Anteil” über alle Netzwerkgrößen besitzen, ist dies intuitiv: Die Gewinner-Tickets in skalenfreien Netzen schwanken in ihrer Größe kaum mit n , und entsprechend reichen konstant viele Reaktivierungen aus. Eine formale Hypothese lautet: Sei $\mathcal{T}_{\text{lt}}(n)$ die Größe des Gewinner-Tickets in einem Netz der Größe n . Dann gilt $k^*(n) \approx (m - \mathcal{T}_{\text{lt}}(n)) \cdot p_{\text{react}}$, wobei $p_{\text{react}} \in (0, 1)$ die Wahrscheinlichkeit ist, dass eine schlafende Kante durch OMGR reaktiviert werden kann. Der Beweis dieser Vermutung – oder ihre Falsifizierung durch Gegenbeispiele – würde die Skalierungsanalyse unmittelbar mit der Lottery-Ticket-Theorie verbinden und könnte auf einen tiefliegenden Zusammenhang zwischen Netzwerk-Topologie und der Distribution schlafender Kapazitäten hinweisen.

Weiterführend stellt sich die Frage, ob die durch OMGR gewählten k^* Kanten *dieselben* sind wie die Kanten des Gewinner-Tickets: Wenn ja, hätte OMGR automatisch eine effiziente Methode zur Lottery-Ticket-Identifikation nach dem Training entdeckt, die ohne aufwendiges iteratives Magnitude-Pruning auskommt. Eine vergleichende empirische Studie zwischen OMGR-ausgewählten Kanten und iterativem Magnitude-Pruning auf CIFAR-10 und ImageNet wäre ein unmittelbar durchführbares Anschlussexperiment.

Iterative Skalierungsanalyse und Fixpunktdynamik. Die vorliegende Analyse betrachtet einen einzigen Restrukturierungsschritt. Im Kontext iterativer Restrukturierung – periodisch nach je T' Trainingsschritten – ergibt sich die Frage, wie sich die Totneuronen-Dichte $\alpha_{\text{dead}}^{(t)}$ und damit das optimale $\varrho^{*(t)}$ über die Restrukturierungsiterationen entwickeln. Ein einfaches dynamisches Modell kombiniert die Reaktivierungsrate $r_{\text{react}} \in (0, 1)$ (Anteil reaktivierter Neuronen pro Schritt) mit der Absterberate $p_{\text{die}} > 0$ (Rate, mit der aktive Neuronen nach erneutem Training wieder erlöschen):

$$\alpha_{\text{dead}}^{(t+1)} = \alpha_{\text{dead}}^{(t)} - \varrho^{*(t)} \cdot r_{\text{react}} + p_{\text{die}} \cdot (1 - \alpha_{\text{dead}}^{(t)}).$$

Der dynamische Fixpunkt dieses Systems,

$$\alpha_{\text{dead}}^* = \frac{p_{\text{die}}}{r_{\text{react}} c_{\varrho} + p_{\text{die}}} \quad \text{mit} \quad c_{\varrho} = \frac{c_1 dL}{2\beta n},$$

beschreibt das asymptotische Gleichgewicht: Der Totneuronen-Anteil konvergiert – unter der Annahme konstanter Raten – gegen einen positiven Wert, sofern $p_{\text{die}} > 0$. Ist $r_{\text{react}} >$

p_{die}/c_ϱ , liegt ein *instabiler Fixpunkt* vor: Das Netz “erwacht” vollständig, $\alpha_{\text{dead}}^* \rightarrow 0$, was einem dauerhaft lebendigen Netz ohne erneutes Sterben von Neuronen entspräche. Die Bifurkationsanalyse dieses Schwellenverhaltens ist ein offenes Problem mit direkter Relevanz für die Frage, wie oft man OMGR wiederholen muss, bis keine toten Neuronen mehr vorhanden sind – eine Art “Erweck-Horizont” für das Netzwerk.

Zusätzlich zur Konvergenzfrage ist die Stabilität der kritischen Netzgröße $n_{\text{crit}}^{(t)} = c_1 d^{(t)} L / (2\beta \varrho_{\text{max}})$ über die Iterationen zu untersuchen. Da $d^{(t)} = \alpha_{\text{dead}}^{(t)} \cdot n$ monoton fällt (bei idealem OMGR), fällt auch $n_{\text{crit}}^{(t)}$ mit jeder Iteration, sodass das Netz zunehmend in die Großnetz-Region eintritt und immer weniger Kanten für das Optimum benötigt. Dies legitimiert mathematisch eine *abnehmende Restrukturierungsrate*: Über die Iterationen hinweg nimmt das optimale $k^{*(t)}$ ab und läuft gegen einen stationären Wert, der dem Gleichgewichtspunkt des dynamischen Systems entspricht.

Mehrstufige Budget-Allokation über zukünftige Aufgaben. Im Lifelong-Learning-Kontext (section 13.6) wird ein Gesamtbudget K_{total} über T zukünftige Aufgaben $\mathcal{T}_1, \dots, \mathcal{T}_T$ verteilt. Da die Aussagekraft $A(\varrho)$ konkav in ϱ ist (Parabolverform mit negativem quadratischem Term), folgt aus der Jensen’schen Ungleichung, dass die *uniforme Allokation* $K_i = K_{\text{total}}/T$ für gleichartige Aufgaben global optimal ist. Für inhomogene Aufgaben, bei denen die aufgabenspezifische Totneuronen-Dichte d_i/n variiert, ergibt die Lagrange-Optimierung:

$$K_i^* = \frac{m}{2\beta} \left(\frac{c_1 d_i L}{n} - \lambda \right)_+$$

mit Lagrange-Multiplikator λ aus dem Budget-Constraint $\sum_i K_i^* = K_{\text{total}}$. Das Ergebnis entspricht dem *Water-Filling*-Prinzip aus der Informationstheorie: Aufgaben mit hohem $c_1 d_i L/n$ (viele tote Neuronen, langer Aufgaben-Kapazitätshorizont) erhalten bevorzugt Budget; Aufgaben, bei denen das Totneuronen-Modell kaum anwendbar ist ($d_i \approx 0$), erhalten $K_i^* = 0$. Eine formale Erweiterung von Theorem 5.8 auf diesen mehraufgaben-basierten Fall würde zeigen, unter welcher Verteilung der d_i eine gleichmäßige Budgetaufteilung sub-optimal ist – mit potenziell erheblichen praktischen Konsequenzen für kontinuierliches Lernen in heterogenen Datenströmen.

Darüber hinaus eröffnet sich ein *sequenzielles Entscheidungsproblem*: Wenn zukünftige Aufgaben $\mathcal{T}_i$ nicht vorab bekannt sind, muss das Budget online zugeteilt werden. Eine Bandit-Formulierung, bei der jede Aufgabe einen “Kanal” mit unbekanntem d_i repräsentiert und OMGR- Anwendungen als Aktionen mit Kapazitätsgewinn als Belohnung modelliert werden, könnte Upper Confidence Bound (UCB)- oder Thompson-Sampling-Strategien nutzen, um das Budget adaptiv zu allozieren und dabei die Exploration (Abschätzung von d_i) und Exploitation (Restrukturierung mit größtem erwartetem Gewinn) zu balancieren.

Statistische Robustheit und Konfidenzgarantien der Budgetgarantie. Theorem 5.8 setzt voraus, dass die Anzahl der toten Neuronen d exakt bekannt ist. In der Praxis ist d nur schätzbar: Sei $\hat{d}$ ein empirischer Schätzer auf einer Validierungsmenge S_{val} der Größe m_{val} . Unter der Annahme, dass jedes Neuron unabhängig mit Wahrscheinlichkeit α_{dead} tot ist, gilt $\hat{d} \sim \text{Bin}(n, \alpha_{\text{dead}})$, und nach dem zentralen Grenzwertsatz näherungsweise $\hat{d} \approx \mathcal{N}(d, d(1 - d/n))$. Diese Unsicherheit in $\hat{d}$ propagiert direkt in das Optimum:

$$\hat{\varrho}^* \pm \sigma_{\varrho^*} = \frac{c_1 L \hat{d}}{2\beta n} \pm \frac{c_1 L}{2\beta n} \cdot \sqrt{\frac{d(1 - d/n)}{m_{\text{val}}}}.$$

Die hinreichende Stichprobengröße für eine ε -präzise Schätzung von ϱ^* ist daher $m_{\text{val}} \geq d(1-d/n) \cdot (c_1 L / (2\beta n \varepsilon))^2$. Eine statistische Erweiterung von Theorem 5.8 würde eine $(1-\delta)$ -Konfidenzbandaussage liefern: *Mit Wahrscheinlichkeit $\geq 1-\delta$ (über die Stichprobenziehung von $\hat{d}$) gilt $A(K_{\text{budget}}/m) > 0$, sofern $K_{\text{budget}} \geq K_{\min}^{(\delta)}(\hat{d}, m_{\text{val}})$, wobei $K_{\min}^{(\delta)}$ die untere $\delta/2$ -Konfidenzschranke der Formel (5.8) unter Gauß-Unsicherheit in $\hat{d}$ ist.*

Diese statistische Erweiterung ist für die Praxis unerlässlich: In realen Experimenten wird d aus einem Validierungsset geschätzt, und ein Garantiesatz ohne Berücksichtigung der Schätzunsicherheit wäre nur eingeschränkt vertrauenswürdig. Insbesondere für eingebettete Systeme mit kleinen Validierungsmengen ($m_{\text{val}} \ll n$) ist die Konfidenzband-Analyse eine notwendige Voraussetzung für eine zertifizierbare OMGR-Anwendung.

Anwendung der Skalierungsanalyse auf Very Large Language Models. Besonders bedeutsam ist die Frage, wie sich die Ergebnisse von Proposition 5.6 und Theorem 5.8 auf heutige Very Large Language Models (VLLMs) mit $N \sim 10^{10}$ – 10^{12} Parametern und Tiefen $L \sim 96$ – 120 übertragen. Für ein Transformer-Modell der Größenordnung GPT-4 mit $N \approx 10^{12}$ und einem konservativ angenommenen Totneuron-Anteil $\alpha_{\text{dead}} \approx 0,1$ ergibt sich mit den Formeln aus section 5.3:

$$\varrho^*(N) \approx \frac{c_1 \cdot 0,1 \cdot 96}{2\beta} \cdot \frac{1}{N} \cdot N = \frac{4,8 c_1}{\beta} \%, \quad k^*(N) \approx \varrho^*(N) \cdot m \lesssim 5 \times 10^8.$$

Das bedeutet: Selbst für ein Modell mit einer Billion Parametern sind nach der Skalierungsanalyse nur einige 10^8 Kantenanpassungen notwendig – das entspricht dem $\Theta(1)$ - bzw. $\Theta(\sqrt{N})$ -Regime aus Proposition 5.6, je nach Architektur-Topologie, und ist in der Praxis mit einer Maskentensor-Darstellung (section 13.7) handhabbar.

Insbesondere wäre zu untersuchen, welchen Mehrwert eine solche Restrukturierung gegenüber den etablierten Parameter-effizienten Fine-Tuning-Methoden (PEFT) wie LoRA (Hu et al., 2022), Adapter-Schichten oder Prefix-Tuning bietet: Während PEFT das Gewichtsspektrum eines *fixen Graphen* modifiziert, greift OMGR in die *Topologie* ein und könnte damit Kapazitätsgewinne erzielen, die durch reine Gewichtsanzpassung prinzipiell nicht erreichbar sind – da Theorem 4.2 beweist, dass der Kapazitätswachstum unmittelbar aus der strukturellen Erweiterung des Hypothesenraums $\mathcal{H}_{\mathcal{G}}$ resultiert, nicht aus der Gewichtsoptimierung. Ein direkter experimenteller Vergleich von OMGR und LoRA auf GLUE/SuperGLUE bei identischem Parameter-Budget wäre daher wissenschaftlich hochrelevant.

Für Transformer-Architekturen ist zudem die Definition eines “toten Aufmerksamkeitskopfes” zu klären (vgl. section 13.1): Die Skalierungsformel $\varrho^*(n) = c_1 d L / (2\beta n)$ muss auf diesen Fall übertragen werden, wobei d dann die Anzahl der Köpfe mit nahezu uniformer Attention-Verteilung zählt. Eine aufmerksamkeitskopf-basierte Variante der Aussagekraft $A_{\text{ATT}}(\varrho)$ könnte die Grundlage für ein effizienzoptimiertes, strukturelles Fine-Tuning großer Transformermodelle bilden.

Dynamische kritische Netzgröße und adaptive Phasenerkennung. Die kritische Netzgröße $n_{\text{crit}}(d, L)$ aus Definition 5.3 ist aktuell eine statische Größe, die auf dem Totneuronen-Anteil d zum Zeitpunkt der Restrukturierung basiert. In einem dynamischen Training-Szenario verändert sich $d(t)$ über die Trainingszeit: Zu Beginn ist $d(0) \approx 0$ (alle Neuronen aktiv); im Lauf des Trainings wächst $d(t)$ bis zur Stagnation, und nach OMGR nimmt $d(t)$ kurzzeitig ab. Das daraus resultierende zeitabhängige

$n_{\text{crit}}(t) = c_1 d(t) L / (2\beta \varrho_{\text{max}})$ definiert einen *Phasenübergang im Training*: Das Netz wechselt von der Kleinnetz-Region ($n < n_{\text{crit}}(t)$) zur Großnetz-Region ($n > n_{\text{crit}}(t)$), sobald $d(t)$ den kritischen Schwellenwert $\bar{d}_{\text{krit}} := 2\beta \varrho_{\text{max}} n / (c_1 L)$ unterschreitet.

Eine Erkennung dieses Phasenübergangs in Echtzeit – auf Basis von Monitoring-Statistiken wie $\hat{d}(t)$ und $\|\nabla \mathcal{L}\|_t$ – würde eine *adaptive* Restrukturierungspolitik ermöglichen: OMGR wird genau dann ausgelöst, wenn n in die Großnetz-Region eintritt und das unkonstringierte Optimum $\varrho^* < \varrho_{\text{max}}$ gilt. Ein solches adaptives Trigger-System hätte die Form eines Schwellenwert-Detektors, der sowohl die Stagnations-Metrik $\|\nabla \mathcal{L}\| \leq \delta$ (gemäß Definition 2.3) als auch die Phasenübergangs-Bedingung $\hat{d}(t) > \bar{d}_{\text{krit}}$ überwacht und bei Erfüllung beider Bedingungen die Restrukturierung auslöst. Die optimale Wahl der Detektions-Schwellen δ und $\bar{d}_{\text{krit}}$ unter dem Ziel, die erwartete Aussagekraft $\mathbb{E}[A(\varrho^*(n, d(t)))]$ zu maximieren, ist ein sequenzielles Optimierungsproblem, das Werkzeuge der Optimal-Stopping-Theorie (Peskir & Shiryaev, 2006) erfordert.

Erweiterung des Effizienzmaßes: Mehrdimensionale Pareto-Optimierung. Das Effizienzmaß $\eta(\varrho) = A(\varrho)/\varrho$ aus Definition 5.1 optimiert ein einziges Kriterium. Im praktischen Einsatz konkurrieren jedoch mindestens drei Ziele: (i) Maximierung der Aussagekraft $A(\varrho)$, (ii) Minimierung des katastrophalen Vergessens gemäß Theorem 8.1 (proportional zu ϱ), und (iii) Minimierung des algorithmischen Aufwands (Fiedler- Berechnung, proportional zu $k^* = \varrho m$). Da alle drei Kriterien von ϱ abhängen – (i) konkav-quadratisch, (ii) linear fallend, (iii) linear steigend – existiert eine *Pareto-Front* im $(\varrho, A, C_f \varrho)$ -Raum, die durch die Menge der Pareto-optimalen Restrukturierungsraten $\varrho \in \mathcal{R}_{\text{few}}$ beschrieben wird. Im einfachsten zweidimensionalen Fall (Aussagekraft vs. Vergessen) ergibt die Bi-Kriterien-Optimierung

$$\varrho_{\mu}^* = \frac{c_1 d L / n - \mu C_f \|\boldsymbol{\theta}\|^2}{2\beta}$$

als Funktion des Gewichtungsparameters $\mu \geq 0$, wobei $\mu = 0$ das reine Aussagekraft-Optimum $\hat{\varrho}^*$ und $\mu \rightarrow \infty$ die Null-Restrukturierung (kein Vergessen) reproduziert. Die analytische Form dieser Pareto-Front – eine Gerade im $(\varrho, A(\varrho))$ -Raum parametrisiert durch μ – ermöglicht eine einfache numerische Charakterisierung und lässt eine direkte Validierung gegen empirische Pareto-Fronten zu. Eine vollständige dreidimensionale Pareto-Analyse unter Einschluss des algorithmischen Aufwands als drittes Kriterium würde ein umfassendes Entscheidungsdiagramm liefern, das Praktikerinnen und Praktikern erlaubt, ϱ gemäß ihrer spezifischen Ressourcen- und Qualitätsanforderungen zu wählen.

13.3 Strukturelle Subgraph-Kompression: Offene Fragen und Erweiterungen

Das in chapter 6 entwickelte Rahmenwerk der strukturellen Subgraph-Kompression – der SGKR-Algorithmus (Structural Graph Compression by Rotation-based Subgraph Reduction) mit seiner kanonischen Signaturfunktion, der rotationsbasierten Äquivalenzklasseneinteilung und dem iterativen Motiv-Reduktionsschema – legt ein theoretisches Fundament, aus dem eine Vielzahl tiefgehender Forschungsrichtungen erwächst. Die folgenden Abschnitte entfalten die wichtigsten offenen Probleme und skizzieren konkrete Forschungsprogramme vom Theoretisch-Grundsätzlichen bis zum empirisch-ingenieurwissenschaftlich Angewandten.

Optimalität der Signaturkonstruktion und feingranuläre Komplexität. Die in section 6.3 definierte kanonische Signatur $\sigma^*(\hat{M}) = \min_k \text{rot}_k(\mathbf{r}^{(\hat{M})})$ mit $\mathbf{r}_j = \sum_{i=0}^{q-1} \hat{M}_{ij} \cdot 2^i + j \cdot 2^q$ ist injektiv und in $O(q^3)$ berechenbar – die Laufzeitleistung entspricht der unteren Schranke für LCS-basierte Verfahren unter der Strong Exponential Time Hypothesis (Aboud et al., FOCS 2015). Eine zentrale offene Frage ist, ob für den Spezialfall dünn besetzter Motif-Matrizen – wie sie in trained-sparse-Architekturen (Lottery Tickets, Magnitude Pruning) auftreten – eine subkubische Signaturkonstruktion möglich ist. Die Dünnbesetztheit könnte mit Algebraic Hashing kombiniert werden: Statt aller 2^q möglichen Bitvektoren erfasst ein universell-hash-basiertes Fingerprinting $h: \{0,1\}^q \rightarrow [M]$ mit $M = O(q^2)$ unter Verwendung von MinHash-Familien eine komprimierte Signaturraumdarstellung in $O(q^2 \log q)$. Die Wahrscheinlichkeit einer Kollision zweier verschiedener Spalten-Vektoren bliebe dabei unter $1/q$ – ausreichend für einen Monte-Carlo-Äquivalenztest bei $q = O(\sqrt{n})$. Ob diese randomisierte Variante auch die $O(n!)$ -Vermeidungsgarantie erhält, ist formal zu klären.

Nichtquadratische und kontinuierliche Motiv-Erweiterungen. In der aktuellen Formulierung werden Schichtmatrizen $M^{(\ell)} \in \{0,1\}^{n_\ell \times n_{\ell-1}}$ zunächst zu quadratischen Matrizen $\hat{M}^{(\ell)} \in \{0,1\}^{q \times q}$ mit $q = \max(n_\ell, n_{\ell-1})$ durch Null-Padding erweitert. Dieses Vorgehen führt bei stark asymmetrischen Schichten (z. B. Bottleneck-Blöcken in ResNets mit Verhältnis 4 : 1) zu einem hohen Anteil strukturell leerer Zeilen, der die Signatur verfälscht und Äquivalenzklassen künstlich vergrößert. Eine natürlichere Erweiterung wären *rechteckige LCS-Varianten*: Das längste gemeinsame Teilwort zweier Folgen unterschiedlicher Länge $m \neq n$ ist in $O(mn)$ berechenbar – für Bottleneck-Motive mit $m = n/4$ also in $O(n^2/4)$ statt $O(n^2)$. Darüber hinaus ist die Erweiterung auf *gewichtete Motive* $M^{(\ell)} \in \mathbb{R}^{n_\ell \times n_{\ell-1}}$ mit reellwertigen Kantengewichten von zentraler praktischer Bedeutung: Statt der binären Adjazenzmatrix müsste eine geeignete Quantisierung oder Clustering-Metrik definiert werden, die Rotationsäquivalenz auf kontinuierlichen Gewichtsmustern erklärt. Ein vielversprechender Ansatz ist die Verwendung der *Wasserstein-Distanz* zwischen den Spaltenvektoren zweier Motivmatrizen: $d_W(M^{(\ell_1)}, M^{(\ell_2)}) < \tau$ als Äquivalenzkriterium anstelle des exakten LCS.

Lernbasierte kanonische Signaturen und gradientengesteuerte Äquivalenz. Die aktuelle kanonische Signaturfunktion ist *strukturell* definiert und ignoriert die *funktionale* Äquivalenz zweier Schichten aus der Perspektive des Informationsflusses. Zwei Schichten können strukturell verschieden, aber funktional nahezu äquivalent sein – etwa wenn kleine Gewichtsunterschiede durch nachgelagerte Batch-Normalisierungsschichten kompensiert werden. Eine Folgeforschungsfrage ist daher die Definition einer *funktionalen Äquivalenz* $\hat{M}^{(\ell_1)} \sim_f \hat{M}^{(\ell_2)}$: Zwei Motive sind *funktional äquivalent*, wenn

$$\sup_{\mathbf{x} \in \mathcal{X}} \|f^{(\ell_1)}(\mathbf{x}) - f^{(\ell_2)}(\mathbf{x})\|_2 < \delta_f$$

für eine vorgegebene Toleranzschranke $\delta_f > 0$. Da diese Bedingung nicht in geschlossener Form optimiert werden kann, bietet der *lernbasierte Ansatz* eine Alternative: Trainiere einen kleinen Meta-Klassifikator (z. B. einen 2-Schicht-MLP auf Gram-Matrix-Features der Aktivierungsverteilungen), der funktionale Äquivalenz aus Aktivierungsstatistiken prädiziert und dessen Sigmoid-Ausgabe als weiches Äquivalenz-Gewicht in den SGKR-Algorithmus integriert werden kann – analog zu matched-filter-basierten Techniken aus der Netzwerkfusions-Literatur (Singh & Jaggi, ICLR 2020).

Hierarchische und inter-Schicht-übergreifende Motiv-Erkennung. Der SGKR-Algorithmus erkennt Äquivalenz zwischen einzelnen Schichten ℓ_1 und ℓ_2 – also zwischen Motiven, die denselben Typ von Neuron-zu-Neuron-Verbindung beschreiben. In modernen Architekturen existieren jedoch auch strukturelle Invarianzen über *Schichtblöcke* hinweg: In einem k -Schichten-Residualblock ist die Komposition $M^{(\ell+k)} \circ \dots \circ M^{(\ell)}$ das eigentlich relevante strukturelle Motiv. Eine Erweiterung auf *hierarchische Motiv-Erkennung* würde zunächst Blöcke variabler Tiefe als zusammengesetzte Motive repräsentieren, für die eine entsprechende Signaturkonstruktion entwickelt werden muss. Die Schlüsselfrage ist, ob das Subgraph-Isomorphieproblem für solche kompositionellen Block-Motive ebenfalls in polynomialer Zeit lösbar ist oder ob die zyklische Rotationsheuristik hier ihre Optimalitätsgrenzen erreicht. Eine Antwort könnte aus der Theorie der *Funktionskompositionen als graphtheoretische Produkte* (Kronecker-Produkt $G_1 \otimes G_2$ für zwei Schichtgraphen) hergeleitet werden – ein Verbindungsglied zur spektralen Graphentheorie, das bisher unerforscht ist.

Verbindung zu Neural Architecture Search und Pruning. Strukturelle Kompressions-Methoden lassen sich in eine allgemeinere Landschaft aus Pruning, Quantisierung und Neural Architecture Search (NAS) einordnen. SGKR unterscheidet sich von klassischen Pruning-Methoden (Magnitude Pruning, ℓ_0 -Regularisierung) darin, dass es keine einzelnen Kanten entfernt, sondern ganze Motivklassen *zusammenführt*: In der reduzierten Architektur $\mathcal{G}_{\min}$ existieren strukturell redundante Schichten weiterhin in Form von Routing-Vektoren $\boldsymbol{\mu}^{(\ell)}$, teilen jedoch ihre Gewichtsmatrix $\mathbf{W}^*$. Gegenüber NAS-Methoden wie DARTS (Liu et al., ICLR 2019) oder ENAS (Pham et al., ICML 2018) hat SGKR den Vorteil, direkt auf dem *trainierten* Netzwerk zu arbeiten, ohne eine kostspielige Architektursuche im Supernetz durchzuführen. Eine offene Forschungsfrage ist die formale Einbettung von SGKR in das Framework des *information-bottleneck-basierten NAS* (Tishby & Zaslavsky, 2015): Minimiert das komprimierte Netz $\mathcal{G}_{\min}$ gleichzeitig die Komplexität $I(\mathbf{W}; \mathcal{D})$ (Gewicht-Datensatz-Information) bei erhaltener Vorhersagegüte $I(Y; \hat{Y})$? Theorem 6.17 legt nahe, dass der MI-Verlust durch das Routing unter $\varepsilon_{\text{route}} = O(\|\mathbf{W}^* - \mathbf{W}^{(\ell_r)}\|_F^2)$ bleibt – eine formale Verbindung zum Information-Bottleneck-Optimalitätsprinzip wäre ein bedeutender theoretischer Beitrag.

Hardware-bewusste Implementierung und Sparse-Routing-Kompilierung. Die praktische Effizienz der SGKR-Reduktion hängt entscheidend davon ab, ob Routing-Masken $\boldsymbol{\mu}^{(\ell)} \in \{0, 1\}^q$ in moderne Hardware-Beschleuniger (GPUs, TPUs, neuromorphe Chips) effizient eingebettet werden können. In der aktuellen Formulierung entspricht das Routing einer elementweisen Multiplikation $\mathbf{h}^{(\ell)} = \boldsymbol{\mu}^{(\ell)} \odot (\mathbf{W}^* \mathbf{h}^{(\ell-1)})$, was auf CUDA-Hardware bereits durch `_ldg`-Caching der gemeinsamen Gewichtsmatrix $\mathbf{W}^*$ beschleunigt werden kann. Eine tiefere Optimierungsmöglichkeit liegt in der Kompilierung der Routing-Maske als *strukturierte Sparsität*: Wenn $\|\boldsymbol{\mu}^{(\ell)}\|_0 \leq s < q$, so ist der effektive Rang der aktiven Verbindungen s , und das Matrix-Vektor-Produkt kann auf eine $(s \times n_{\ell-1})$ -GEMM-Operation reduziert werden. Im Kontext moderner Mixed-Precision-Hardware (NVIDIA Tensor Cores, Google TPU v4) ist s ein direkter Indikator für den Ressourcenbedarf je Batch-Element. Eine formale Analyse der arithmetischen Intensität (FLOPs/Byte) als Funktion der Routing-Dichte und der Motivkatalog-Größe P ist notwendig, um optimale Tile-Größen und Thread-Hierarchien für GPU-Kernel automatisch ableiten zu können.

SGKR in der Lifelong-Learning- und Multi-Task-Kompression. Eine besonders fruchtbare Verbindung besteht zwischen SGKR und *Lifelong-Learning-Architekturen*: Wenn ein Netzwerk sequenziell auf Aufgaben $\mathcal{T}_1, \mathcal{T}_2, \dots, \mathcal{T}_K$ trainiert wird, stellt sich die Frage, welche Schichtmotive aufgabenübergreifend stabil bleiben und für welche eine aufgabenspezifische Spezialisierung notwendig ist. SGKR bietet hier einen natürlichen Mechanismus zur *strukturellen Aufgabentrennung*: Motive, die nach Training auf $\mathcal{T}_1$ und $\mathcal{T}_2$ dieselbe kanonische Signatur besitzen, können geteilt werden – dies entspricht einer harten *Parameter-Sharing-Entscheidung* ohne die übliche Regularisierungsheuristik von Progressive Neural Networks (Rusu et al., 2016) oder PackNet (Mallya & Lazebnik, 2018). Ein formales Ergebnis wäre:

Seien G_1, G_2 die Schichtgraphen nach Training auf $\mathcal{T}_1$ bzw. $\mathcal{T}_2$. Dann enthält der SGKR-Motivkatalog $\mathcal{M}(G_1 \cup G_2)$ des vereinigten Netzwerks mindestens $|\mathcal{M}(G_1)| + |\mathcal{M}(G_2)| - |\mathcal{M}(G_1) \cap \mathcal{M}(G_2)|$ Klassen; die Schnittmenge $\mathcal{M}(G_1) \cap \mathcal{M}(G_2)$ ist die Menge strukturell geteilter Kapazitäten und bildet den gemeinsamen “Backbone” für beide Aufgaben.

Dieses Ergebnis ließe sich zu einer formalen Garantie ausbauen, dass katastrophales Vergessen durch SGKR auf denjenigen Anteil der Netzwerkkapazität beschränkt wird, der nicht im geteilten Backbone liegt – eine direkte Verbindung zu den Schranken aus section 8.1.

Informationstheoretische Optimalität des Routings. Die in Theorem 6.17 bewiesene Schranke $|I(X; Y^{(\ell_1)}) - I(X; Y^{(\ell_r)})| \leq \varepsilon_{\text{route}}$ garantiert MI-Erhaltung unter kleinen Gewichtsabweichungen, lässt jedoch die Frage offen, ob das Routingschema *optimal* im Sinne der Raten-Verzerrungstheorie ist. Formal: Sei $R(D)$ die Rate-Distortion-Funktion des Routingproblems, wobei $D = \mathbb{E}[\|\mathbf{h}^{(\ell)} - \mathbf{h}^{(\ell_r)}\|_2^2]$ die quadratische Aktivierungsverzerrung ist. Welches Routing $\boldsymbol{\mu}^{(\ell)}$ minimiert $\|\boldsymbol{\mu}^{(\ell)}\|_0$ bei $D \leq D_0$? Das ist ein *Compressed Sensing*-Problem mit binären Masken – die ℓ_0 -Minimierung ist NP-schwer, aber mit ℓ_1 -Relaxation (Lasso) approximierbar, falls eine Konditionszahl-Bedingung (Restricted Isometry Property) an $\mathbf{W}^*$ gestellt wird. Eine Antwort würde den optimalen Routing-Algorithmus liefern, der die Informationsverlustschranke $\varepsilon_{\text{route}}$ zu einem operativen Minimierungsziel macht. In Kombination mit dem Water-Filling-Prinzip aus section 13.2 entsteht eine *strukturell informations-optimale Kompression* – ein Werkzeug erster Ordnung für die Konstruktion energieeffizienter neuronaler Netzwerke unter gegebenen MI-Budgets.

Verbindung zur Wissensdestillation und Modellfusion. Strukturelle Subgraph-Kompression lässt sich als eine Spezialform der *Wissensdestillation* (Hinton et al., 2015) interpretieren, bei der der “Lehrer” das ursprüngliche Netzwerk $\mathcal{G}$ und der “Schüler” das komprimierte Netz $\mathcal{G}_{\text{min}}$ ist. Im Unterschied zur klassischen Ausgabe-Destillation (Soft Labels) wird beim SGKR der Informationstransfer *strukturell* erzwungen: Die Routing-Gewichte $\boldsymbol{\mu}^{(\ell)}$ sorgen dafür, dass die Aktivierungsverteilung des Schülers bei Initialisierung bereits nahe an derjenigen des Lehrers liegt. Formal entspricht dies einer *feature-alignment-Destillation* (Romero et al., 2015), bei der Zwischenschicht-Aktivierungen aneinander angepasst werden. Eine wichtige offene Frage ist daher, ob der SGKR-Algorithmus mit einer anschließenden KD-Feinabstimmungsphase kombiniert werden kann und welchen Feinabstimmungsaufwand (in Trainings-Epochen) die strukturelle Vorinitialisierung einspart gegenüber einer Zufalls-Initialisierung des Schülers. Analoges gilt für *Modellfusion* (Model Merging): Bei der Fusion zweier unabhängig trainierter Modelle $\mathcal{G}_1$ und $\mathcal{G}_2$ liefert

der gemeinsame SGKR-Motivkatalog $\mathcal{M}(\mathcal{G}_1) \cap \mathcal{M}(\mathcal{G}_2)$ direkt eine strukturell begründete Initialisierung des fusionierten Modells ohne die üblichen Permutationsalignierungsschritte von Git Re-Basin (Ainsworth et al., 2023).

Empirische Validierung und Skalierung auf Transformer-Architekturen. Die theoretischen Ergebnisse in chapter 6 – insbesondere Theorem 6.6 ($O(L^2 q^3)$), Theorem 6.13 (keine VC-Dimensionsverluste) und Theorem 6.19 (FLOP-Schranke $O(Pq^2 + Lq)$) – wurden für binäre Konnektivitätsgraphen formuliert. Eine dringende empirische Aufgabe ist ihre Überprüfung an realen Architekturen, insbesondere Transformer-Modellen (BERT, GPT-2, LLaMA). Die Attention-Schicht eines Transformers besitzt eine $(n_h \cdot d_k) \times d_{\text{model}}$ Gewichtsmatrix pro Kopf – eine strukturell reichhaltige Matrix, deren kanonische Signatur Abhängigkeiten zwischen Token-Positionen kodiert. Eine experimentelle Studie könnte folgendes Protokoll verwenden: (i) Binäre Sparsifikation aller Attention-Matrizen durch Top- k -Aktivierungen je Kopf; (ii) Anwendung des SGKR-Algorithmus auf die sparsifizierten Schichten; (iii) Fine-Tuning des komprimierten Modells auf 10% der ursprünglichen Trainingsdaten; (iv) Messung von Perplexität, FLOP-Reduktion und Energie pro Token. Erwartet werden Kompressionsverhältnisse von $\kappa_{\text{param}} \approx 0.3$ bei weniger als 2% Perplexitätsverlust für Modelle mit $L \geq 24$ Schichten, da tiefere Modelle strukturell redundantere Schichtmuster aufweisen – eine Empirie, die Theorem 6.6 qualitativ stützt und quantitativ verfeinert.

Formale Konvergenzanalyse des iterativen SGKR-Algorithmus. Algorithmus 1 terminiert nach Theorem 6.18 in höchstens L Runden, da jede Runde den Motivkatalog $|\mathcal{M}|$ um mindestens einen Eintrag verkleinert oder die Schleife abbricht. Diese Garantie ist scharf – es gibt Netzwerke, bei denen jede SGKR-Runde genau eine Äquivalenzklasse zusammenführt. Eine offene Frage ist die *durchschnittliche* Konvergenzgeschwindigkeit für zufällige und trainierte Netzwerke. Formal: Definiere $T_{\text{SGKR}}(\mathcal{G})$ als die Anzahl der Runden bis zur Fixpunktconvergenz. Für ein Netzwerk mit L Schichten und P Motivklassen gilt trivialerweise $T_{\text{SGKR}} \leq L - P$; die Frage ist, ob für trainierte Netzwerke $\mathbb{E}[T_{\text{SGKR}}] = O(\log L)$ gilt – analog zu schnell-mischenden Markov-Ketten in zufälligen Graphen. Eine positive Antwort würde den praktischen SGKR-Durchlauf auf Transformer-Ebene auf wenige (3–5) Runden beschränken und die Laufzeiten in fig. 6.3 erklären. Ein Beweis könnte über die *Martingal-Konvergenz des Motivkatalogs* $|\mathcal{M}^{(t)}|$ als stochastisch fallende Folge geführt werden – ein Ziel, das tiefe Verbindungen zwischen kombinatorischer Graphentheorie, probabilistischer Algorithmenanalyse und der Theorie neuronaler Aktivierungsmuster aufdecken würde.

13.4 Theoretische Vertiefungen und schärfere Schranken

Nicht-ReLU-Aktivierungen. Theorem 4.2 ist für ReLU-Aktivierungen bewiesen. Die Verallgemeinerung auf GELU, SiLU/Swish, Mish oder Softmax erfordert eine neue Definition des “toten Neurons”, da diese Aktivierungen keine harte Abschaltschwelle besitzen. Eine mögliche Verallgemeinerung ist das *Sättigungsmaß* $\mu_{\text{sat}}(v_i)$, definiert als $\mathbb{E}_{x \sim \mu}[|\sigma'_i(z_i)|] / \sup_z |\sigma'_i(z)|$: Wenn $\mu_{\text{sat}}(v_i) \approx 0$, befindet sich Neuron v_i in einem gesättigten Regime mit vernachlässigbarem Gradientenfluss. Formale VC-Schranken unter diesem verallgemeinerten Sättigungsmaß sind noch ausstehend.

Stochastische und probabilistische Restrukturierung. Der OMGR-Algorithmus wählt deterministisch die Kanten mit maximalem Fiedler-Gewinn. Eine probabilistische Variante – bei der Kanten mit einer Wahrscheinlichkeit proportional zu ihrem Fiedler-Beitrag gezogen werden – könnte als *strukturelle Regularisierung* wirken und die Varianz des Kapazitätsgewinns über verschiedene Zufallsinitialisierungen reduzieren. Die Analyse einer solchen stochastischen Restrukturierung erfordert Werkzeuge der Matrixmartingal-Theorie (Tropp, 2012), insbesondere die Matrix-Azuma-Ungleichung für die konzentrationstheoretischen Schranken der stochastischen Fiedler-Wert-Änderung.

Schärfere Untere Schranken. Die untere Schranke in Theorem 3.3 basiert auf dem Fiedler-Vektor-Argument und ist für allgemeine Graphen gültig. Für spezifische Netzwerktopologien – z. B. reguläre Gitter, zufällige Erdős-Rényi-Graphen oder Barabási-Albert-Graphen (wie in fig. 3.1 verwendet) – können deutlich schärfere Schranken hergeleitet werden. Für d -reguläre Graphen gilt $\lambda_2 \geq 2(1 - \cos(2\pi/n))$ (Alon, 1986), was präzisere Aussagen über den minimalen Kapazitätsgewinn γ erlaubt.

Verbindung zum Neural Tangent Kernel. Der Neural Tangent Kernel (NTK, Jacot et al., 2018) beschreibt das Lernverhalten überparametrisierter Netzwerke in der Nähe der Initialisierung. Für nahezu ausgelernte Netzwerke – die Gegenstand dieser Arbeit sind – ist der NTK bereits in einem flachen Regime: Das abgeflachte NTK entspricht einem Graphen mit kleinen Eigenwerten. Eine formale Verbindung zwischen der Fiedler-Wert-Erhöhung durch OMGR und der Konditionalzahl des NTK könnte erklären, warum minimale Restrukturierung die Trainingskonvergenz nach der Stagnationsphase beschleunigt: Ein besser konditionierter NTK impliziert größere Gradientenfluss-Eigenwerte und damit schnellere Lernrate.

Informationstheoretische Optimale Transportformulierung. Die Aktivierungsentropie $H^{(\ell)}$ und die gegenseitige Information $I(X; Y^{(\ell)})$ aus chapter 7 könnten in einem *optimalen Transport*-Rahmen (Villani, 2009) neu formuliert werden: Die Restrukturierung entspricht einer Transport-Map, die die Aktivierungsverteilung $\mathbf{p}$ auf eine entropiereichere Verteilung $\mathbf{p}'$ abbildet, und der Sinkhorn-Algorithmus (Cuturi, 2013) könnte für die numerisch stabile Berechnung des optimalen Restrukturierungsplans adaptiert werden.

13.5 Empirische Validierung auf großen Benchmarks

Computer-Vision-Benchmarks. Die in dieser Arbeit präsentierten Experimente basieren auf synthetischen Modellkurven. Eine systematische empirische Validierung muss zunächst mit etablierten Benchmarks beginnen: CIFAR-10/100 mit ResNet-20/56 und VGG-16, ImageNet mit ResNet-50 und EfficientNet-B4. Dabei sind folgende spezifische Hypothesen zu testen:

- (i) Das optimale ϱ^* gemäß (4.3) stimmt empirisch mit dem beobachteten Optimum überein.
- (ii) Der Kapazitätsgewinn $\Delta C(\varrho^*)$ ist statistisch signifikant gegenüber Baseline ohne Restrukturierung (zweiseitiger Wilcoxon-Test, $p < 0,01$).
- (iii) Der Anteil toter Neuronen α_{dead} ist nach OMGR messbar reduziert und korreliert mit dem erzielten Genauigkeitsgewinn.

NLP-Benchmarks und vortrainierte Sprachmodelle. Im Bereich Natural Language Processing eignen sich die GLUE- und SuperGLUE-Benchmarks sowie QuAD und SQuAD für eine Evaluation. Besonderes Interesse gilt der Frage, ob OMGR an Stelle von LoRA (Hu et al., 2022) als Parameter-effiziente Fine-Tuning-Methode eingesetzt werden kann: Während LoRA niedrig-rangige Gewichtsaktualisierungen hinzufügt, fügt OMGR niedrig-rangige Strukturänderungen hinzu – ein möglicherweise komplementärer Mechanismus, der mit dem Informationsfluss-Argument aus Theorem 7.3 theoretisch fundiert werden kann.

Ablationsstudien. Um die einzelnen Komponenten des OMGR-Algorithmus zu evaluieren, sind sorgfältige Ablationsstudien notwendig:

- *Zufällige vs. Fiedler-geführte Kantenwahl:* Verringert gezieltes Fiedler-Kantenwählen den Restrukturierungsbedarf gegenüber zufälliger Wahl?
- *Zeitpunkt der Restrukturierung:* Ist Restrukturierung bei exakter Stagnation ($\|\nabla\mathcal{L}\| \leq \delta$) günstiger als früher oder später?
- *Sequenzielle vs. simultane Restrukturierung:* Hat die schrittweise (sequenzielle) gegenüber der einmaligen Restrukturierung aller k^* Kanten Vorteile für die Trainingsstabilität?

13.6 Verbindung zu kontinuierlichem Lernen und Lifelong Learning

Formale Analyse multipler Restrukturierungsschritte. In der vorliegenden Arbeit wird eine einzelne Restrukturierungsoperation analysiert. Realistischere Szenarien sehen eine Folge von Restrukturierungen $\phi_1, \phi_2, \dots, \phi_T$ vor, bei denen das Netz sukzessive an neue Aufgaben $\mathcal{T}_1, \dots, \mathcal{T}_T$ angepasst wird. Die Vergessenschränke aus Theorem 8.1 muss für dieses kumulative Szenario erweitert werden: Der Gesamtfehler auf Aufgabe $\mathcal{T}_1$ nach T Restrukturierungen ist nicht einfach $T \cdot C_f \cdot \varrho \cdot \|\theta\|^2$, da die Gewichte der unberührten Kanten nicht mehr exakt mit den ursprünglichen Gewichten übereinstimmen – sie werden durch die nachfolgenden Trainingsschritte verändert. Eine Analyse mit gekoppelten Fehlerrekursionen und einem angepassten Elastic Weight Consolidation (EWC)-Term (Kirkpatrick et al., 2017) könnte eine kompositionale Vergessenschränke liefern.

Strukturelle Plastizität als Ersatz für Regularisierung. Progressive Neural Networks (Rusu et al., 2016) fügen für jede neue Aufgabe eine vollständige neue Säule hinzu, was den Speicherbedarf linear mit der Aufgabenanzahl skaliert. OMGR bietet eine Alternative: Anstatt neue Säulen hinzuzufügen, werden bestehende schlafende (tote) Kapazitäten reaktiviert – der Speicherbedarf bleibt konstant. Dies ist besonders relevant für ressourcenbeschränkte Szenarien. Formal wäre zu zeigen, dass das Netz nach T OMGR-Schritten immer noch eine positive Kapazitätsreserve $\Delta C(\varrho^*)$ besitzt, d. h. dass die toten Neuronen nicht dauerhaft erschöpft werden. Hierfür bedarf es einer Analyse der asymptotischen Dichte toter Neuronen als Funktion der Trainingsdauer und der Restrukturierungsrate.

Federated Learning mit strukturellen Updates. In Federated-Learning-Szenarien (McMahan et al., 2017) können Clients nur komprimierte Updates an den Server senden. Während heutige Verfahren Gewichts-Differenzen (oft mit Quantisierung) übermitteln,

könnte OMGR eine neue Kommunikationsprimitive einführen: Statt der gesamten Gewichts-differenz wird nur die *Restrukturierungsmaske* $\Delta\mathcal{E} = \mathcal{E}'\Delta\mathcal{E}$ übertragen, die mit $O(k \log m)$ Bits codierbar ist, also für $k \ll m$ extrem kompakt ist. Die Frage, wann globale Restrukturierungsentscheidungen aus lokalen Fiedler-Berechnungen der Clients aggregiert werden können, ist ein offenes Problem in der Schnittstelle von Federated Learning und spektraler Graphentheorie.

13.7 Algorithmische Effizienz und praktische Implementierung

Skalierbare Fiedler-Vektor-Berechnung. Step 5 des OMGR-Algorithmus (algorithm 2) erfordert die Berechnung des Fiedler-Vektors der Laplace-Matrix $\mathbf{L} \in \mathbb{R}^{n \times n}$. Für heutige Large Language Models mit $n \sim 10^{11}$ Parametern ist eine exakte Berechnung illusorisch. Approximative Methoden sind daher unerlässlich:

- *Stochastische Lanczos-Approximation:* Mit $\mathcal{O}(k \cdot \text{nnz}(\mathbf{L}))$ Operationen liefert sie den Fiedler-Vektor mit Relative-Error-Garantie $\varepsilon_{\text{rel}} \leq 0,01$ in typisch $k = 50$ Iterationen.
- *Lokale Fiedler-Schätzung:* Da OMGR nur eine kleine Kante hinzuzufügen versucht, reicht eine r -Hop-Nachbarschaft des Kandidatenknotens, um den Fiedler-Gewinn abzuschätzen. Dies reduziert die Berechnungskomplexität auf $\mathcal{O}(r \cdot d_{\text{max}})$.
- *Spektrale Sparsifizierung:* Vor der Fiedler-Berechnung könnte der Graph auf einen spektralen Sparsifier (Spielman & Teng, 2011) reduziert werden, der alle spektralen Eigenschaften bis auf Faktor $(1 + \varepsilon)$ erhält, aber nur $\mathcal{O}(n \log n)$ Kanten besitzt.

Integration in Autograd-Frameworks. Eine Schlüsselanforderung für die praktische Nutzung ist die nahtlose Integration von OMGR in Frameworks wie PyTorch oder JAX. Dies wirft nicht-triviale Fragen auf: Wie wird die dynamische Kantenmenge $\mathcal{E}'$ in einem statisch vorab allokierten Tensor-Graphen repräsentiert? Eine mögliche Lösung ist die Verwendung von *Masken-Tensoren*: Die zugrundeliegende Gewichtsmatrix $\mathbf{W}$ bleibt vollständig; eine binäre Maske $\mathbf{M} \in \{0, 1\}^{n_\ell \times n_{\ell-1}}$ entscheidet, welche Gewichte aktiv sind. OMGR modifiziert nur die Maske (sowie wenige Gewichtswerte), was hardware-freundlich und automatisch differenzierbar ist.

Reinforcement-Learning-basierte Kantenwahl. Die Wahl der optimalen Kante für die Restrukturierung ist ein kombinatorisches Optimierungsproblem. Anstatt eines greedy Fiedler-Algorithmus könnte ein Reinforcement-Learning-Agent trainiert werden, der aus dem Zustand des Netzwerks (Dead-Neuron-Verteilung, Fiedler-Vektor, Gradientenhistogramm) eine Restrukturierungspolitik $\pi : \mathcal{S} \rightarrow \Delta\mathcal{E}$ lernt. Eine solche Methode würde nicht nur auf bekannte Heuristiken (wie maximalen Fiedler-Gewinn) zurückgreifen, sondern aufgabenspezifische Optimal-restrukturierungen erlernen. Die Belohnungsfunktion könnte direkt auf dem normierten Kapazitätswachstum $\Delta C(\varrho)$ aus Definition 4.1 basieren.

13.8 Verbindung zu biologischer Neuronenplastizität

Hebbian Learning und synaptische Plastizität. In biologischen neuronalen Netzwerken wird die synaptische Stärke durch das Hebb'sche Lernprinzip ("neurons that

fire together, wire together”) geregelt. Das formale Analogon ist die *aktivierungskorrelierte Kantenadaptation*: Eine neue Kante (v_j, v_i) sollte dann eingeführt werden, wenn v_j und v_i auf der Trainingsverteilung hoch korrelierte Aktivierungen zeigen. Dies entspricht einer Modifikation von Schritt 8 im OMGR-Algorithmus: Anstatt den maximalen Entropiegewinn zu maximieren, wird $\arg \max_{(j,i)} \text{Cov}(\sigma(z_j), \sigma(z_i))$ gewählt. Eine Verbindung zwischen dieser Hebb’schen Variante und dem informationstheoretischen Auswahlkriterium aus Theorem 7.3 herzustellen wäre theoretisch elegant und könnte biologisch plausiblere Restrukturierungsalgorithmen motivieren.

Entwicklungsbiologie und Critical Periods. Das Gehirn durchläuft in der frühen Kindheit sensitive Phasen (*Critical Periods*), in denen die synaptische Plastizität extrem hoch ist, und anschließend eine Konsolidierungsphase mit niedrigerer Plastizität (Hensch, 2004). Das in dieser Arbeit untersuchte Regime – nahezu ausgelernte Netzwerke – entspricht der Konsolidierungsphase. OMGR kann als formales Modell der gezielten Synapsengeneses während der kritischen Phase interpretiert werden. Experimentell ließe sich prüfen, ob ein “Plastizitätsfenster”, in dem OMGR periodisch angewendet wird, bessere Generalisierungseigenschaften erzeugt als kontinuierliche oder einmalige Restrukturierung – eine Hypothese mit direkter Relevanz für die Computational Neuroscience.

Tote Neuronen als Modell für neuronalen Zelltod. In biologischen Gehirnen stirbt ein Teil der Neuronenpopulation ab (Apoptose), während andere reaktiviert werden können. Der Begriff des “toten Neurons” aus Definition 2.4 ist eine direkte Analogie zu apoptotischen Neuronen. Die Frage, ob die Apoptoserate biologischer Netzwerke einem ähnlichen Optimum ϱ^* folgt wie das formale Modell dieser Arbeit, ist eine empirisch prüfbare Hypothese, die die Brücke zwischen theoretischer Informatik und Neurobiologie schlagen könnte.

13.9 Bioinspirierte Grundprinzipien: Forschungsausblick zu Kapitel 10

Kapitel 10 dieser Arbeit formalisiert drei bioinspirierte Grundprinzipien – Minimalität, Verknüpfbarkeit und ionische Verschaltung – in einem einheitlichen graphentheoretischen Rahmen und legt damit eine Brücke zwischen mathematischer Lerntheorie, algorithmischer Netzwerkanalyse und ionotronischer Physik. Das Integrationsergebnis in Satz 10.30 zeigt, dass alle drei Prinzipien gleichzeitig optimiert werden können und sich wechselseitig verstärken. Dennoch bleiben zahlreiche Fragen offen – sowohl auf der theoretischen als auch auf der experimentellen und physikalisch-technologischen Ebene. Der folgende Abschnitt beschreibt die vielversprechendsten Forschungspfade zu jedem der drei Prinzipien sowie zu ihrer gemeinsamen Grundlage: der dreistufigen biologischen Hierarchie.

Automatische Entdeckung hierarchischer Netzwerkstrukturen. Definition 10.1 legt die drei Ebenen Organe, Bereiche und Zellen als festes a-priori-Schema fest. In realen Anwendungen ist diese Partition jedoch selten gegeben – sie muss entweder aus Domänenwissen abgeleitet oder direkt aus den Gewichten des trainierten Netzes gelernt werden. Eine offene Forschungsfrage ist, ob sich die Bereiche-Zellen-Zerlegung als unüberwachtes Clustering-Problem formulieren lässt, bei dem spektrale Clusterverfahren auf

dem Verbindungsgraphen $\mathcal{G}$ die Zellgrenzen automatisch identifizieren. Der Verbindungsgraph der menschlichen Großhirnrinde zeigt in Connectome-Analysen [51] ausgeprägt modulare Strukturen auf mehreren Skalen – genau die Hierarchie, die Definition 10.1 postuliert. Es wäre daher empirisch prüfbar, ob die aus Proposition 10.6 resultierende Zerlegung eines Convolutional-Netzes in bis zu t Bereiche mit je maximal $q_{\max}$ Zellen mit den aus Aktivierungskorrelationen extrahierten funktionalen Modulen übereinstimmt. Aus algorithmischer Sicht ist die Laufzeit $\mathcal{O}(t^2 q_{\max}^3)$ bereits beachtlich, aber für sehr tiefe Netze mit $t > 50$ Schichten und $q_{\max} > 10^3$ Neuronen pro Zelle würde sie kritisch werden. Eine erste Forschungsrichtung ist daher die Entwicklung approximativer Hierarchie-Dekompositionsalgorithmen – etwa auf Basis von Randomized SVD oder hierarchischem Louvain-Clustering [76] – mit angestrebter Laufzeit $\mathcal{O}(t \cdot q_{\max}^2 \log q_{\max})$. Komplementär dazu könnten modulare Architekturen wie jene in [40] so gestaltet werden, dass die Bereiche-Zellen-Hierarchie explizit während des Trainings gelernt wird – etwa als weiches Routing-Problem, das die Verbindungsmatrix zwischen Zellen differenzierbar strukturiert. Schließlich stellt sich die Frage anisotroper Zellgrößen: Das aktuelle Modell setzt annähernd uniforme Zellgrößen q voraus. Biologische Cortexfelder variieren jedoch dramatisch in der Neuronendichte (von $\sim 10^3$ Neuronen pro mm^3 in Feld V1 bis $\sim 10^5$ in Feld M1), was eine Verallgemeinerung von Satz 10.4 auf nicht-uniforme Hierarchien erfordert – ein reines formales Ergebnis, das zugleich als Grundlage für datengetriebenes Hierarchielernen dient.

Grundsatz 1: Minimalität, Eindeutigkeit und das Minimum-Description-Length-Prinzip. Satz 10.9 beweist, dass zur minimalen Normalform $\hat{G}_v$ komprimierte NNGraphen existieren, eindeutig sind und eine Partialordnung unter sich induzieren. Diese Aussage ist eng verwandt mit dem *Minimum-Description-Length-Prinzip* [49]: Ein Modell ist dann optimal, wenn es die Daten mit der kürzesten Beschreibung erfasst – formal entspricht $\hat{G}_v$ dem kürzesten Graphen, der die relevante Kapazitätsstruktur des Neurons kodiert. Die Verbindung zwischen Definition 10.8 und vollständiger Graphenisomorphie ist eine weitere offene Frage: Während die kanonische Normalform über die Longest-Common-Subsequence-Signatur in $\mathcal{O}(q^3)$ berechnet wird (section 10.2), ist vollständige Graphenisomorphie bis heute nicht in Polynomialzeit lösbar – jedoch auch nicht als NP-vollständig bewiesen [47]. Neurotypische Subgraph-Muster in tiefen Netzen sind zwar klein genug, dass die exakte Kanonisierung via NAUTY/TRACES [47] praktikabel ist, aber für sehr große Subgraphen mit $q > 10^4$ Neuronen werden approximative Isomorphie-Tests unausweichlich.

Hirschbergs linearraum-optimierter LCS-Algorithmus [42] reduziert den Speicherbedarf der Signaturberechnung von $\mathcal{O}(q^2)$ auf $\mathcal{O}(q)$, was für speicherbeschränkte Deployment-Umgebungen (eingebettete Systeme, Edge-Chips) direkt relevant ist – insbesondere wenn die minimale Normalform des laufenden Netzes on-device inkrementell aktualisiert werden soll. In Kombination mit Satz 10.9 ergibt sich ein Algorithmus, der die inkrementelle Veränderung der kanonischen Signatur nach jeder Kantenhinzufügung in $\mathcal{O}(q^2)$ beurteilt, ohne das Gesamtmodell neu zu berechnen.

Die VC-Dimension unter Minimalitätszwang bleibt formal offen. Korollar 10.11 zeigt, dass $C(\hat{G}_v)$ eine untere Schranke für die Kapazität des Netzes liefert; eine obere Schranke der VC-Dimension des durch $\hat{G}_v$ induzierten Funktionenraums wäre ein wichtiges Resultat. Bartlett–Mendelson-ähnliche Bounds [4] lassen sich grundsätzlich auf Graphordnungen erweitern – eine direkte Herleitung von $\text{VCdim}(\mathcal{F}_{\hat{G}_v}) = \mathcal{O}(|E(\hat{G}_v)|)$ würde zeigen, dass Minimalität im Sinne von Definition 10.7 auch Generalisierungsgarantien maximiert.

Grundsatz 1 (fortgesetzt): Lernbarkeit der minimalen Normalform. Bisher wird die kanonische Normalform $\hat{G}_v$ aus dem Gewichtsvektor v eines bereits trainierten Netzes berechnet. Interessanter für die Praxis wäre es, die minimale Struktur *während* des Trainings zu erzwingen – etwa durch eine Lasso-ähnliche Regularisierung auf der Kantengewichtsmatrix:

$$\mathcal{L}_{\min} = \mathcal{L}_{\text{CE}} + \lambda \sum_{(i,j) \in E} |w_{ij}|.$$

Diese ℓ_1 -Regularisierung fördert dünn besetzte Verbindungsmatrizen und damit eine Annäherung an die minimale Normalform. Entscheidend ist, ob ein solcher Ansatz im Sinne von Satz 10.9 zur *gleichen* minimalen Normalform konvergiert wie die post-hoc-Kanonisierung – oder ob Trainingsdynamiken die Eindeutigkeit brechen können. Die Verbindung zu *Lottery-Ticket*-Subnetzen [39] ist naheliegend: Das Lottery-Ticket-Subnetz einer bestimmten Dichte könnte als Approximation der minimalen Normalform interpretiert werden, und umgekehrt könnten Satz 10.9 und Korollar 10.5 eine formale Begründung dafür liefern, warum Lottery Tickets bei gleicher Größe so ähnliche Genauigkeiten erzielen – nämlich weil sie alle gegen die gleiche kanonische Klasse konvergieren.

Grundsatz 2: Verknüpfbarkeit unter Distributionsverschub und dynamischer Graphveränderung. Satz 10.15 charakterisiert Verknüpfbarkeit über das Verhältnis $\lambda_2(G_{ij})/\lambda_2(G)$ des Fiedler-Werts nach und vor Kanteneinfügung. Diese Charakterisierung ist stationär: Sie gilt für ein festes Gewichtsmodell $\mathcal{G}$. In dynamischen Szenarien – etwa bei kontinuierlichem Lernen (vgl. section 13.6) oder beim Auftreten eines Distributionsverschubs – ändern sich die Gewichte fortlaufend, und damit verändert sich auch die Menge der verknüpfbaren Knotenpaare.

Eine erste offene Frage ist, how schnell die Menge der verknüpfbaren Paare unter Gradientenabstieg konvergiert: Gibt es ein stabiles "Verknüpfbarkeitsinvariant" des trainierten Netzes, oder ist die Verknüpfbarkeit hochgradig trajektorieabhängig? Satz 10.16 garantiert Transitivität – wenn (u_1, u_2) und (u_2, u_3) verknüpfbar sind, dann auch (u_1, u_3) – aber nur unter der Annahme fester Gewichtsmatrizen. Eine Erweiterung auf stochastische Gewichte (Bayes-NNs oder Dropout-Ensembles) würde probabilistische Verknüpfbarkeit einführen und das Lemma 10.17 zu einer Aussage über erwartete Spektrallücken stärken.

Besonders vielversprechend ist die Verbindung zu *Graph Rewiring* in Graph-Neuronalen Netzwerken [34]: Über-Squashing in GNNs entsteht gerade dann, wenn der Fluss zwischen weit entfernten Knoten durch spektral engefasste Bottlenecks beschränkt wird – genau die Situation, die Lemma 10.17 beschreibt. Die Formel $\Delta\lambda_2 = \mathbf{v}_2^\top (\mathbf{e}_i - \mathbf{e}_j)(\mathbf{e}_i - \mathbf{e}_j)^\top \mathbf{v}_2$ aus Satz 10.15 könnte direkt als *Graph-Rewiring-Score* in GNNs eingesetzt werden: Kanten mit maximalem $\Delta\lambda_2$ werden eingefügt, bis das Über-Squashing beseitigt ist – ein klarer differenzierbarer Optimierungspfad.

Satz 10.18 gibt eine hinreichende Bedingung für vollständige Verknüpfbarkeit an ($\lambda_2(G) > \varepsilon/n$). Eine offene Frage ist, ob diese Bedingung scharf ist oder ob eine notwendige Bedingung schwächer ist. Ein konkreter Forschungsplan: Generiere für verschiedene reale Architekturen (ResNet-18, BERT-L12, ViT-B) die Verbindungsmatrix der letzten Schichten, berechne λ_2 und überprüfe, ob Verknüpfbarkeit mit dem Spektrum korreliert – die erste empirische Kalibrierung von Satz 10.18. Das Ergebnis wäre direkt verwertbar als Kriterium für "netzwerkbereit für Restrukturierung" – ein on-the-fly-Test, der mit Spielman-Teng-Approximation [33] in $\mathcal{O}(n \log n)$ ausführbar ist.

Grundsatz 3: Ionische Verschaltung – von der Theorie zur physikalischen Realisierung. Abschnitt 10.4 legt das theoretische Fundament der ionischen Verschaltung mittels IoFET-Modell [2]: Kohlrausch-Leitfähigkeit (Gleichung 10.6), EWOD-Schalten (Gleichung 10.7), und ein formales K -Zustands-Modell mit $K = 4$ Betriebszuständen (Aus, Unterschwellig, Linear, Sättigungsbereich). Der bedeutendste Forschungspfad – und gleichzeitig der radikalste – ist die Frage, ob ein IRF-Array (Ionic-Readout-Field, *ibid.*) direkt als physikalisches Substrat eines neuronalen Netzwerks eingesetzt werden kann.

In der vorgeschlagenen Architektur entspräche jede Elektrode des IRF-Gitters genau einer synaptischen Verbindung (i, h) : Der Gating-Wert $V_G^{(ih)}$ steuert den Betriebszustand $k_{ih} \in \{1, 2, 3, 4\}$, der seinerseits über die Kanalkapazität $\sigma_{k_{ih}}$ das Gewicht w_{ih} nach Gleichung 10.11 bestimmt:

$$W_{ih}^{(k)} = \frac{\sigma_k}{\sigma_1} W_{ih}^{(1)} + \Delta W_{ih}^{(k)}. \quad (13.1)$$

Ein solches System hätte drei fundamentale Vorteile gegenüber SRAM-basierten Gewichtsspeichern: (i) Nicht-Flüchtigkeit ohne statischen Stromfluss (die ionische Konzentration $c^{(k)}$ bleibt ohne Spannungsversorgung erhalten); (ii) intrinsische Analog-Multistabilität ($K = 4$ statt binärer Speicherzellen); (iii) Tripleximät im Sinne von Epp – Leitung, Schaltung und Speicherung in *einem* physikalischen Element.

Hinsichtlich Skalierung ergibt die EWOD-Gleichung 10.7, dass unter realistischen Parametern ($\eta_{\text{EWOD}} = 2.5 \times 10^{-4} \text{ V}^{-2}$, $V_T = 15 \text{ V}$ [2]) die Schaltenergie pro Verbindung $E_{\text{EWOD}} = \frac{1}{2} C_G V_T^2 \approx 0,07 \text{ fJ}$ beträgt. Zum Vergleich: Eine biologische Synapse verbraucht für eine einzelne synaptische Vesikelfusion $\sim 10 \text{ fJ}$ [45]. Ein IRF-basiertes Netz wäre damit etwa $140\times$ energieeffizienter als das biologische Vorbild – und mehrere Größenordnungen effizienter als DRAM-basierte Gewichtsspeicher (typisch 10^4 – 10^6 fJ pro Lese-/Schreibzyklus). Diese Abschätzung ist ein starkes Argument für die weitere experimentelle Entwicklung von IoFET-Arrays als neuronale Substrate, komplementär zu aktuellen neuromorphen Chips [50].

Ionische Plastizität als biologisch-plausible Lernregel. Die ionische Plastizitätsregel $\Delta\sigma_{\text{Kanal}} = \alpha \cdot f_{\text{Aktivierung}} \cdot \Delta t$ (Gleichung 10.13) stellt eine physikalisch begründete Lernregel dar, die ohne Backpropagation auskommt. Die strukturelle Ähnlichkeit zur Hebbischen Lernregel [41] – “Neurons that fire together, wire together” – ist offensichtlich: $f_{\text{Aktivierung}}$ entspricht der korrelativ verstärkten Feuerrate, und $\Delta\sigma$ entspricht der Synapsengewichtszunahme. Formal ist die Beziehung jedoch enger zu STDP-Modellen (Spike-Timing-Dependent Plasticity) als zur kanonischen Hebb-Regel, da die stufenweise Steigerung der Leitfähigkeit (Off→Unterschwellig→Linear→Sättigung) zeitlich abgestuften Potenzierungsstufen entspricht.

Für kontinuierliches Lernen (vgl. section 13.6) bietet die ionische Plastizität eine natürliche Lösung für das Problem des katastrophalen Vergessens: Falls aufgabenspezifische Kontextvektoren $\mathbf{u}^{(1)}, \dots, \mathbf{u}^{(T)}$ jeweils auf die K Betriebszustände verschiedener Aufgaben abgebildet werden, kann zwischen Aufgaben gewechselt werden, ohne die Gewichte eines anderen Kontexts zu verändern – ein ionisches Analogon zu *Synaptic Intelligence* [52], jedoch mit physikalischer Substratunterstützung statt nur einem Regularisierungsterm. Eine konkrete experimentelle Implementierung könnte so aussehen: Trainiere ein sequenzielles Mehraufgaben-Szenario (MNIST→CIFAR-10→SVHN) mit einem IoFET-inspirierten Soft-Switching-Modul, das für jede Aufgabe τ einen erlernten Gate-Vektor $\mathbf{V}_G^{(\tau)} \in \mathbb{R}^d$ hält und damit den effektiven Zustandsvektor $\mathbf{u}^{(\tau)}$ produziert. Das Vergessen in Aufgabe τ nach Training von Aufgabe $\tau' > \tau$ sollte dann gegenüber klassischem SGD signifikant reduziert

sein – ein empirisch direkt testbarer Effekt, der die Verbindung zwischen den ionischen Grundprinzipien und praktischer Lifelong-Learning-Forschung herstellt.

Mehrkontext-Meta-Lernen und der optimale Kontextvektor. Satz 10.27 (sofern dieser im Dokument formuliert ist) zeigt, dass ein optimaler Kontextvektor ι^* die Mutual Information $I(\mathbf{X}; \mathbf{Y} \mid \iota)$ maximiert. Dies entspricht in der Information-Bottleneck-Formulierung [15] der Suche nach der Darstellung, die maximale Relevanz über $\mathbf{Y}$ bei minimaler Redundanz gegenüber $\mathbf{X}$ erzielt. Die Optimierung über $\iota \in \Delta^{K-1}$ (dem $(K-1)$ -dimensionalen Simplex der Zustandswahrscheinlichkeiten) ist ein differenzierbares Problem, das per Natural-Gradient-Abstieg auf der Riemannschen Mannigfaltigkeit des Simplex lösbar ist – ein Standardverfahren in der Informationsgeometrie.

Für Meta-Lernen (Few-Shot-Szenarios) könnte ein vortrainiertes IoFET-Netz mit $K = 4$ Kontexten als Universalarchitektur dienen: Statt des gesamten Netzwerks wird nur $V_G^{(\tau)}$ für eine neue Aufgabe τ in wenigen Gradienten-Schritten angepasst – analog zu MAML (*Model-Agnostic Meta-Learning*), aber mit physikalisch begründeter Parametrisierung via ionische Zustandsräume. Eine offene theoretische Frage ist dabei, ob die Lipschitz-Stetigkeit der Zustandsübergänge (Satz 10.23) eine Obergrenze auf den Meta-Lernfehler induziert – formell: ob die Lipschitz-Konstante $C_W \eta_{\text{EWOD}}$ direkt in eine PAC-Lernschranke für die Aufgaben-Transferkomplexität eingeht.

EWOD-Stetigkeit und spiking-neuronale Verbindungen. Satz 10.23 beweist Lipschitz-Stetigkeit der Zustandsübergänge in V_G . Dies hat eine unmittelbare neurobiologische Interpretation: Die Young-Lippmann-Kurve $\cos \theta(V_G) = \cos \theta_0 + \eta_{\text{EWOD}} V_G^2$ ist stetig und monoton fallend im relevanten Bereich – ebenso wie die Aktivierungswahrscheinlichkeit eines biologischen Neurons als Funktion der präsynaptischen Spannung [43]. Das Hodgkin-Huxley-Modell [43] beschreibt Natriumkanäle durch eine Gating-Wahrscheinlichkeit $m^3 h$, die sigmoid in der Membranspannung V_m ist – formal analog zu $G_{\text{Kanal}}(V_G) = G_{\text{max}} H(\cos \theta(V_G) - \cos \theta_c)$ (Gleichung 10.8). Die Substitution $V_m \leftrightarrow V_G$ und $m^3 h \leftrightarrow H(\cos \theta - \cos \theta_c)$ stellt eine formale Korrespondenz zwischen dem IoFET-Modell und dem klassischen biophysikalischen Ionenkanalmodell her – eine Brücke, die experimentell prüfbar wäre, indem man HH-Neuronensimulationen durch IoFET-Substrate emuliert und die Spike-Parameter vergleicht.

Spiking-Neuronale-Netzwerke (SNN, [46]) operieren in einem Betriebsregime, das dem Unterschwellig-Zustand ($k = 2$) von section 10.4 entspricht: Neuronen akkumulieren sub-threshold Eingaben und feuern erst nach Überschreitung eines Schwellwerts. Das IoFET-Modell erweitert dieses Paradigma um drei weitere Regime (Linear, Sättigung), die schnelle Burst-Aktivitäten und gesättigte Plateau-Potenziale modellieren können – empirisch beobachtete Phänomene in Pyramidalneuronen der Großhirnrinde. Eine explizite Abbildung der vier IoFET-Betriebszustände auf die vier klassischen Neuronen-Schussmuster (still, sub-threshold, regular-spiking, bursting) würde die biologische Plausibilität des Modells quantifizierbar machen.

Integrationssatz und thermodynamische Interpretation. Satz 10.30 zeigt, dass Minimalität, Verknüpfbarkeit und ionische Verschaltung gleichzeitig optimiert werden können. Eine tiefergehende thermodynamische Interpretation ergibt sich aus der Analogie des optimalen Kontextvektors ι^* zur Gibbs-Verteilung:

$$\iota_k^* \propto \exp\left(-\frac{E_k}{k_B T_{\text{eff}}}\right),$$

wobei E_k die freie Energie des k -ten Betriebszustands und T_{eff} eine effektive Temperatur repräsentiert. In dieser Sicht entspricht die Optimierung des Kontextvektors dem Einstellen eines thermodynamischen Gleichgewichts – ein Ansatz, der aus der statistischen Physik der Hopfield-Netzwerke [23] bekannt ist und hier eine neue physikalische Substratbegründung erhält. Die effektive Temperatur reguliert dann, wie stark das Netz zwischen den K Zuständen fluktuiert: Bei hohem T_{eff} sind alle Zustände gleichwahrscheinlich (fluktuationsreiches, exploratives Regime); bei niedrigem T_{eff} dominiert der energieärmste Zustand (stabiles, exploitatives Regime). Das Abkühlen von T_{eff} während des Trainings entspricht einem ionischen Simulated-Annealing – von der Exploration neuer Verbindungsstrukturen hin zur Konsolidierung minimaler Normalformen, was Satz 10.30 als globales Optimierungsprinzip interpretierbar macht.

Empirisches Validierungsprogramm für Kapitel 10. Die theoretischen Ergebnisse lassen sich in ein überschaubares experimentelles Programm übersetzen:

- (a) **Hierarchietests:** Zerlegere ResNet-50, BERT-Base und ViT-B/16 nach Definition 10.1 in Bereiche und Zellen; vergleiche die Partition mit funktionalen Saliency-Clustern (aus Grad-CAM-Karten) und messe die Übereinstimmungsrate (Adjusted Rand Index). Hypothese: $\text{ARI} > 0.6$ für reifen-konvergierten Modellen.
- (b) **Minimalitätstests:** Berechne für verschieden stark geprunte ResNet-Varianten (Sparsität 0%–99%) die kanonische Signatur und überprüfe, ob die minimale Normalform bei optimaler Pruning-Dichte stabil wird (d.h. ob $\hat{G}_v$ für Pruning über 80% invariant bleibt). Hypothese: Die Kapazität $C(\hat{G}_v)$ flacht bei der Lottery-Ticket-Dichte ab [39].
- (c) **Verknüpfbarkeitstests:** Berechne λ_2 für das Verbindungsgraph jeder Schicht von GPT-2-Small; bestimme die Menge der verknüpfbaren Paare nach Satz 10.15; und messe, ob hinzugefügte Verknüpfungskanten die Perplexität um das aus Korollar 10.19 vorhergesagte Maß verbessern.
- (d) **Ionische-Kontext-Tests:** Trainiere ein IoFET-inspiriertes Soft-Switching-Netz (vier Gate-Vektoren für vier Aufgaben) auf Split-CIFAR-10; messe katastrophales Vergessen (via BWT, Forward-Transfer) gegenüber EWC [11] und SI [52]; überprüfe, ob die ionische Plastizitätsregel (eq. (10.13)) als Lernregel allein (ohne Backprop) die Aufgabentrennung erhält.

Diese vier Experimente sind unabhängig voneinander durchführbar und liefern zusammen ein vollständiges empirisches Bild der drei Grundprinzipien – von der Netzwerk-Topologie über die spektrale Verknüpfbarkeit bis hin zur physikalisch-ionischen Gewichtsdarstellung.

Offene formale Fragen. Abschließend sei eine Auswahl formaler offener Fragen benannt, die für zukünftige theoretische Arbeiten besonders lohnend erscheinen:

- **Schärfe der Lipschitz-Schranke:** Betrachte die Frage: Ist die Schranke $\|W^{(k)} - W^{(k')}\|_F \leq C_W \eta_{\text{EWOD}} |V_G^{(k)} + V_G^{(k')}| \cdot |V_G^{(k)} - V_G^{(k')}|$ aus Satz 10.23 scharf, d.h. existiert eine Folge von Architekturen, die diese Schranke beliebig eng approximiert?
- **Nichtlineare Leitfähigkeitsmodelle:** Satz 10.24 benutzt die affine Skalierung $W^{(k)} = (\sigma_k/\sigma_1)W^{(1)} + \Delta W^{(k)}$. Für nicht-lineare Transportgleichungen (Poisson-Nernst-Planck-System) wäre eine entsprechende nichtlineare Kapazitätsschranke herzuleiten.

- **K als freier Parameter:** Das aktuelle Modell setzt $K = 4$ fest (gemäß den vier IoFET-Betriebszuständen). Kann K aus Daten gelernt werden – etwa als Ergebnis eines Modellselektionsproblems, bei dem die MDL-Kosten der Zustandsbeschreibung mit dem Kapazitätsgewinn abgewogen werden?
- **Konvergenz des optimalen Kontexts online:** Konvergiert der per Natural-Gradient auf dem Simplex Δ^{K-1} geführte Online-Update von $\boldsymbol{\iota}$ gegen $\boldsymbol{\iota}^*$? Unter welchen Bedingungen (Schrittweite, Stationarität der Datenverteilung) ist Konvergenz garantiert?
- **Fiedler-Eigenvektor-Stabilität:** Wie schnell ändert sich $\boldsymbol{v}_2$ (der zweite Eigenvektor von L_G) unter einer Einzel-Kanten-Perturbation? Man-tung-and-Gut-Perturbations-theorie [6] liefert erste Abschätzungen; eine scharfe Schranke würde die Stabilität des Verknüpfbarkeits-Scores unter kleinen Gewichtsänderungen quantifizieren.

Diese offenen Fragen sind nicht isoliert – sie sind miteinander verflochten. Die Schärfe der Lipschitz-Schranke beeinflusst direkt die PAC-Bound für Meta-Lernen; die Lernbarkeit von K ist verwandt mit dem Hierarchie-Entdeckungsproblem; und die Fiedler-Stabilität ist Schlüsselvoraussetzung für ein Online-Verknüpfbarkeits-Update. Zusammen bilden sie ein kohärentes Forschungsprogramm, das das neue Kapitel 10 als lebendigen Ausgangspunkt für zukünftige Arbeiten etabliert.

13.10 Anwendungsszenarien mit hohem Praxisbezug

Edge AI und ressourcenbeschränkte Systeme. Eingebettete Systeme (Mikrocontroller, FPGAs, neuromorphe Chips) haben strenge Speicher- und Energiebudgets. Pruning-Methoden reduzieren die Netzwerkgröße durch Kantenstreichung; doch nach dem Pruning ist das Netz fixiert. OMGR bietet einen komplementären Ansatz: Wenn das Netz nach der Deployment in einem neuen Anwendungskontext stagniert (z. B. durch Distributionsverschiebung der Eingangsdaten), könnte eine ultraminimale Restrukturierung ($k = 1$ oder $k = 2$ Kanten) spontan on-device durchgeführt werden, ohne Rückübertragung an einen Trainingsserver. Eine Analyse der Mindestanzahl an Kanten, die ausreicht, um eine signifikante Kapazitätssteigerung $\Delta C > \varepsilon$ zu erzielen (untere Schranke aus Theorem 3.3), ist direkt relevant für die Hardware-Spezifikation solcher “selbst-adaptiver” Edge-Systeme.

Neuronales Kontinuierliches Lernen in Medizin und Diagnostik. Medizinische diagnostische Systeme müssen auf kontinuierlich wachsende Patientenpopulationen reagieren, ohne Zugang zu historischen Daten wegen Datenschutzbestimmungen zu haben. Minimale Restrukturierung – mit der formalen Vergessenschranke aus Theorem 8.1 – könnte die juristisch relevante Garantie liefern, dass die Diagnosequalität für Altpatienten um höchstens $C_f \cdot \varrho^* \|\boldsymbol{\theta}\|^2$ abnimmt. Dies wäre ein wichtiger Schritt hin zu zertifizierbarer und erklärbarer KI in medizinischen Anwendungen.

Automatisierte Hyperparameter-Suche für ϱ^* . Die optimale Restrukturierungsrate ϱ^* aus (4.3) hängt von den Größen c_1 , d , L , β und n ab, die teilweise nur schwer direkt messbar sind. Ein Bayesianisches Optimierungsverfahren (Snoek et al., 2012) könnte ϱ^* effizient auf Basis weniger Restrukturierungsexperimente schätzen, indem es den normierten Kapazitätszuwachs $\Delta C(\varrho)$ als Zielfunktion benutzt. Die strukturelle Prior-Information aus

dem theoretischen Modell (quadratische Abnahme für $\varrho > \varrho^*$, superlinearer Anstieg für $\varrho < \varrho^*$) könnte als Gauß-Prozess-Prior eingebettet werden, was die Sample-Effizienz des Hyperparameter-Suchverfahrens erheblich steigern würde.

Verbindung zu Neural Architecture Search. NAS-Verfahren (Zoph & Le, 2017) suchen vor dem Training nach optimalen Architekturen und sind bekannt für ihren hohen Rechenaufwand. OMGR kann als *post-hoc NAS* verstanden werden: Die Architektursuche findet nach dem Training statt, wenn konkrete Informationen über die Netzwerkdynamik (tote Neuronen, Fiedler-Vektor, Gradientenhistogramm) vorliegen. Dies könnte deutlich effizienter als klassisches NAS sein, da der Suchraum durch die Restrukturierungsschranke $|\Delta\mathcal{E}| \leq k^*$ stark eingeschränkt ist. Ein hybrides Verfahren, das OMGR in die innere Schleife eines differenzierbaren NAS-Algorithmus (Liu et al., 2019) integriert, könnte die Vorteile beider Ansätze vereinen.

Robustheit und adversariale Angriffsszenarien. Adversariale Robustheit – die Fähigkeit eines Netzwerks, gegenüber kleinen, gezielt konstruierten Eingabeperturbationen stabil zu bleiben – ist eng mit der Kapazitätsgeometrie des Hypothesenraums verknüpft. Eine interessante offene Frage ist, ob minimale Restrukturierung die adversariale Robustheit verbessert oder verschlechtert: Einerseits erhöht sie die Kapazität und könnte damit neue Angriffsvektoren eröffnen; andererseits reaktiviert sie tote Neuronen, die für redundante Repräsentationen sorgen und adversariale Eingaben “verschmieren”. Eine formale Analyse, die die Verbindung zwischen der Fiedler-Wert-Verbesserung und der Lipschitz-Konstante K_L des Netzwerks herstellt (letztere ist inversely korreliert mit adversarialer Robustheit), würde diesen Zusammenhang quantifizieren. Insbesondere wäre die Frage relevant, ob ein OMGR-optimiertes Netz nach R -FGSM-Adversarialtraining (Shafahi et al., 2019) gegenüber einem Netz ohne Restrukturierung bessere zertifizierbare Robustheitsgarantien (z. B. nach Randomized Smoothing, Cohen et al., 2019) besitzt.

13.11 Energetische Implikationen: Ausblick und offene Forschungsfragen

Kapitel 11 hat die energetischen, klimaökologischen und betriebswirtschaftlichen Konsequenzen der Netzwerkkompression erstmals formal und quantitativ durchdrungen. Die dort bewiesenen Ergebnisse – Theorem 11.4 (Energieeinsparung), Theorem 11.10 (Kühlinfrastrukturreduktion), Proposition 11.12 (ROI-Analyse), Proposition 11.13 (Lebenszyklus-Dominanz der Inferenzenergie) – begründen ein neues Forschungsfeld an der Schnittstelle von Lerntheorie, Rechenzentrumsinfrastruktur und nachhaltiger Informatik. Die folgenden Abschnitte entfalten die vielversprechendsten offenen Fragen dieses Feldes.

Dynamische Energiebudgets und Lastprognose. Das in Definition 11.2 und Theorem 11.4 entwickelte statische Energiemodell setzt eine konstante GPU-Auslastung η_G voraus. In der Praxis schwankt die Auslastung erheblich: Inferenz-Workloads unterliegen Tages- und Saisonrhythmen; Trainings-Jobs können die Last für Stunden auf nahezu 100 % treiben. Eine dynamische Erweiterung des Modells würde $\eta_G(t)$ als Zufallsprozess modellieren und die erwartete jährliche Energieeinsparung $\mathbb{E}[\Delta E_{\text{Jahr}}(\kappa)]$ als Faltung von $P_{\text{compute,max}}$, Auslastungsdichte $f_\eta(\eta)$ und $(1 - \kappa)$ berechnen. Da κ durch SGKR fest ist, ist die Einsparung unabhängig von der Auslastungshöhe proportional zum Spitzenwert

$P_{\text{compute,max}}$ – ein bemerkenswert robustes Ergebnis, das eine formale Invarianzaussage erlaubt. Ein Lastprognoseverfahren, das tageszeitabhängige Kompressions Szenarien empfiehlt (aggressive Kompression zu Schwachlastzeiten, moderatere Kompression bei Spitzenlast), könnte den TCO-Nutzen weiter steigern.

Standortadaptive Kompressionsstrategie. Die CO_2 -Einsparung durch Netzwerk-kompression hängt gemäß Definition 11.6 linear vom spezifischen CO_2eq -Faktor e_{CO_2} des lokalen Stromnetzes ab. Da Rechenzentren weltweit operieren und der Emissionsfaktor je nach Tageszeit und Spotmarkt variiert, stellt sich die Frage einer *standort- und zeitadaptiven Kompressionsstrategie*: Wenn Inferenz zu Zeiten hoher erneuerbarer Produktion (niedriges e_{CO_2} , z.B. Mittagsspitze in Südeuropa) bewusst auf weniger komprimierte Modelle ausweicht und bei Kohlestrom (hohes e_{CO_2}) die aggressivste Kompressionsstufe aktiviert, lässt sich die CO_2 -Bilanz dynamisch optimieren. Formal: Gegeben ein Spotmarkt-abhängiger Emissionsfaktor $e(t)$, minimiere $\int_0^T e(t) \cdot P_{\text{server}}(\kappa(t)) dt$ über die Kontrollstrategie $\kappa(t) \in [\kappa_{\min}, 1]$. Da $P_{\text{server}}(\kappa)$ linear in κ ist, ist das Optimum bang-bang: $\kappa(t) = \kappa_{\min}$ wenn $e(t) > \bar{e}$ (CO_2 -Schwellenwert), sonst $\kappa(t) = 1$. Die Herleitung des optimalen Schwellenwertes $\bar{e}$ als Funktion der Genauigkeits-SLA und des Kompressionsfehlers ist eine konkrete formale Aufgabe.

Erweiterung auf heterogene Hardware-Architekturen. Das Energiemodell aus Kapitel 11 ist auf GPU-dominierte Inferenzserver ausgelegt. Moderne KI-Infrastrukturen enthalten jedoch auch spezialisierte Beschleuniger (TPUs, Cerebras WSE, Groq LPUs, neuromorphe Chips wie Intel Loihi). Für diese Hardware ist das FLOPs-basierte Energiemodell (11.1) nicht direkt übertragbar, da TPUs ein matrix-multiply-unit-basiertes Energiemodell besitzen und neuromorphe Chips sparsity-sensitiv sind: Ein neuronales Netz mit Aktivierungssparsität α_{act} verbraucht auf Intel Loihi nur $\alpha_{\text{act}} \cdot E_{\text{dense}}$. Da SGKR die strukturelle Redundanz erhöht und damit auch die Aktivierungssparsität steigert, könnte die Energieeinsparung auf neuromorphen Chips noch über dem auf GPUs berechneten Wert liegen. Eine Erweiterung von Theorem 11.4 auf hardwarespezifische Energiemodelle ist dringend geboten und könnte den Einsatzbereich der SGKR-Kompression auf das gesamte KI-Hardware-Ökosystem ausweiten.

Lebenszyklusanalyse (LCA) der Hardware-Produktion. Die in Kapitel 11 durchgeführte Energieanalyse betrachtet den Betriebsenergieverbrauch (Scope-2-Emissionen). Eine vollständige Ökobilanz (Life Cycle Assessment, LCA) müsste zusätzlich die *Embodied Carbon*-Emissionen der Hardware-Produktion einschließen: Die Herstellung einer A100-GPU emittiert schätzungsweise $\approx 150 \text{ kgCO}_2\text{eq}$; für einen 8-GPU-Server ergibt das ca. $1\,300 \text{ kgCO}_2\text{eq}$. Mit $\kappa = 0,3$ werden virtuell 70 % weniger Hardware-Kapazität benötigt – was bei Neubau-Infrastruktur eine proportionale Reduktion der Embodied Carbon-Emissionen impliziert. Für ein Rechenzentrum mit $N_s = 5\,000$ Servern entspräche das $0,7 \times 5\,000 \times 1\,300 \approx 4\,550 \text{ tCO}_2\text{eq}$ einmalige Einsparung durch Nichtbeschaffung – eine Größenordnung, die in der TCO-Analyse aus Proposition 11.12 bisher nicht erfasst wird und den 5-Jahres-ROI weiter verbessert.

Kombinierte Optimierung: Kompression und Cooling-Infrastruktur. Das Modell aus Theorem 11.10 behandelt PUE als exogen gegeben. In der Realität ist der PUE-Wert eine Funktion der IT-Last: Je geringer die IT-Last, desto höher der relative Overhead der

Kühlinfrastruktur (da Kühlaggregate ein festes Aktivierungsminimum besitzen und nicht linear heruntergeregt werden können). Dies führt zu einem nichtlinearen Feedback:

$$\text{PUE}(\kappa) = 1 + \frac{P_{\text{cool, fixed}} + \alpha \cdot \kappa \cdot P_{\text{compute, max}}}{\kappa \cdot P_{\text{compute, max}} + P_{\text{fixed}}},$$

wobei $P_{\text{cool, fixed}}$ der Mindest-Kühlenergieverbrauch und α der variable Kühlanteil ist. Die Energieeinsparfunktion $\Delta E(\kappa)$ unter diesem nichtlinearen PUE-Modell verliert ihre Linearität in κ und kann ein inneres Optimum $\kappa^* \in (\kappa_{\min}, 1)$ besitzen. Die formale Analyse dieses nichtlinearen Energieeinspar-Optimums – mit Implizit-Funktion-Theorem-Argumenten oder numerischer Bifurkationsanalyse – ist ein konkretes offenes Problem, das aus der Kombination von Definition 11.2 und Theorem 11.4 erwächst.

Energiebewusste Netzwerkarchitektur-Suche. Während heutige NAS-Verfahren Genauigkeit unter Latenz- und Parameteranzahlbeschränkungen optimieren, wird Energieeffizienz kaum als primäres Optimierungskriterium betrachtet. Das formale Energiemodell aus Kapitel 11 könnte direkt als Surrogatfunktion in Differenzierbares NAS (DARTS, Liu et al. 2019) integriert werden: Ein Regularisierungsterm $\lambda_e \cdot P_{\text{server}}(\kappa(\mathcal{G}), \text{PUE})$ in der Architektur-Suchverlustfunktion würde den Energieverbrauch pro Epoche direkt penalisieren. Da P_{server} differenzierbar in κ ist (Gleichung (11.4)), und κ seinerseits von der Architektur abhängt, entsteht ein vollständig differenzierbarer Energie-Regularisierungspfad. Die Frage, welcher Pareto-optimale Punkt auf der Frontlinie Genauigkeit vs. Energie sich ergibt – und ob dieser mit dem durch nachgelagerte SGK R erreichbaren Punkt übereinstimmt – verbindet die Ergebnisse aus chapter 11 and section 13.3 zu einem integrierten Forschungsprogramm.

Gesellschaftliche und regulatorische Perspektive. Mit dem rasanten Wachstum von KI-Workloads gewinnt die Regulierung des Energieverbrauchs von Rechenzentren an politischer Relevanz. Die EU hat mit dem European Green Deal und der Energieeffizienzrichtlinie (EED 2023) erste Rahmenbedingungen gesetzt; für Rechenzentren mit mehr als 500 kW IT-Last gelten ab 2025 Meldepflichten für PUE, Wasserverbrauch und erneuerbare Energieanteile. Das in Kapitel 11 entwickelte formale Energiemodell könnte als analytisches Fundament dienen, um: (i) den energetischen Beitrag verschiedener Kompressionsmethoden für Berichtspflichten zu quantifizieren; (ii) energiebasierte SLAs in Cloud-Dienste-Verträgen zu formulieren, die auf dem κ -parametrisierten Einsparungsmodell beruhen; und (iii) Regulierungsbehörden ein Berechnungswerkzeug bereitzustellen, mit dem der Energieeinspareffekt von KI-Kompression systematisch bewertet werden kann. Damit verlässt die theoretische Informatik der Netzwerkkompression den akademischen Raum und wird zu einem Instrument aktiver Klimapolitik.

13.12 KI-Recheninfrastruktur und digitale Souveränität: Strategische Forschungsperspektiven

Kapitel 12 hat die infrastrukturellen Grundlagen der KI-Rechenlandschaft in Deutschland und Europa systematisch analysiert und in Beziehung zur theoretischen Kernthese dieser Arbeit gesetzt. Das dortige Zentralergebnis – dass Europa mit einem Cloud-Marktanteil von unter zwei Prozent in einer strukturell nachgeordneten Position verharret – markiert nicht nur eine aktuelle Schwäche, sondern definiert einen präzisen Forschungsauftrag: Methoden,

die dieselbe Modellqualität aus weniger Rechenressourcen herausholen, sind unter europäischen Knappheitsbedingungen keine Option, sondern strategische Notwendigkeit. Der folgende Abschnitt entfaltet die Forschungsperspektiven, die sich aus dieser strukturellen Ausgangslage für die in dieser Arbeit entwickelten Methoden ergeben – von formaltheoretischen Erweiterungen über infrastrukturelle Implikationen bis hin zu regulatorischen und ökologischen Dimensionen.

Recheneffizienz als europäische Kernkompetenz. Die in Theorem 4.2 bewiesene Kernaussage – dass minimale Graphrestrukturierungen superlineare Kapazitätsgewinne erzeugen – gewinnt unter europäischen Rahmenbedingungen eine strategische Bedeutung, die über ihre mathematische Eigenständigkeit hinausgeht. Wenn ein europäisches Forschungsteam mit einem Bruchteil der GPU-Kapazität eines US-amerikanischen Konkurrenten dieselbe Modellqualität erreichen kann, weil es strukturell effizientere Methodik einsetzt, schließt sich das Kapazitätsgefälle partiell durch algorithmische Überlegenheit. Die formale Grundlage dieses Arguments findet sich in Proposition 12.6: Für Modelle bis zur Größenordnung $n \lesssim 10^{10}$ – also den aktuell führenden offenen Sprachmodellen der Klasse LLaMA-3/70B – ist die Restrukturierung mit europäischen Mid-Tier-Infrastrukturen ($\sim 10\text{--}50$ MW Anschlussleistung) noch durchführbar. Erst für Modelle der Klasse GPT-4 ($n \sim 10^{12}$) wird Gigafactory-Kapazität nach der Skalierungsanalyse aus chapter 5 strukturell erforderlich.

Diese Beobachtung definiert ein klares Forschungsprogramm: Es ist zu quantifizieren, für welche Modellgrößen n und Restrukturierungsraten ϱ eine Infrastruktur der Klasse 10–50 MW ausreicht und ab welchem Schwellenwert n_{GF} Gigafactory-Zugang unumgänglich wird. Die Schranken aus Proposition 12.6 liefern eine erste analytische Antwort; ihre empirische Kalibrierung an realen Modellen und Hardware-Profilen ist eine unmittelbar durchführbare Forschungsaufgabe.

Europäische Gigafactories als Experimentierinfrastruktur der nächsten Generation. Mit dem Spatenstich in Lübbenau (17. November 2025) und der geplanten Inbetriebnahme der Telekom-Nvidia-Anlage in München (1. Quartal 2026) tritt Europa in eine qualitativ neue Infrastrukturphase ein. Für die in dieser Arbeit entwickelten Methoden eröffnet dies konkrete Forschungsmöglichkeiten, die bisher nur in US-amerikanischen oder chinesischen Laboratorien realisierbar waren.

Für das OMGR-Verfahren bedeutet dies insbesondere: Erstmals wird es möglich, das Skalierungsverhalten von Algorithmus ?? auf Modelle der Größenordnung 10^{10} bis 10^{11} Parameter empirisch zu testen – jene Region, in der Theorem 5.4 den Übergang von der Kleinnetz- in die Großnetz-Region (Definition 5.3) prognostiziert. Die kritische Netzgröße n_{crit} und die empirischen Konstanten c_1, β aus der Skalierungsanalyse können erstmals in diesem Regime kalibriert werden. Konkret bietet sich das folgende Experimentalprotokoll an:

- (i) Trainiere LLaMA-3/70B auf einem 10.000-GPU-Cluster (Münchner Anlage) bis zum Stagnationspunkt gemäß Definition 2.3.
- (ii) Wende OMGR mit $\varrho \in \{0,01, 0,05, 0,10, \varrho^*\}$ an und messe den normierten Kapazitätswachstum.
- (iii) Vergleiche den empirisch optimalen ϱ_{emp}^* mit dem theoretisch vorhergesagten $\varrho^* = c_1 dL / (2\beta n)$ aus Theorem 5.4; bestimme c_1 und β durch nicht-lineare Kleinstquadrat-Anpassung.

- (iv) Wiederhole für LLaMA-3/8B und GPT-2-XL, um die Architekturskalierung aus Proposition 5.6 empirisch zu validieren.

Dieses Programm ist in einem einzigen Trainingslauf auf einer Anlage vom Typ der Münchner KI-Fabrik durchführbar – ohne Gigafactory-Kapazität. Mit dem Anlaufen von Lübbenau in Vollkapazität (100.000 GPUs, 200 MW) wird anschließend die analoge Studie für Modelle der Klasse 10^{11} – 10^{12} möglich, was den Gültigkeitsbereich der theoretischen Skalierungsgesetze um zwei Größenordnungen erweitern würde.

Datensouveränität als strukturelle Voraussetzung für sensible KI-Forschung.

Der in section 12.4 beschriebene Souveränitätsmechanismus von Schwarz Digits – Ende-zu-Ende-Verschlüsselung mit kundenkontrollierten Encryption Keys nach dem HYOK-Prinzip (*Hold Your Own Key*) – hat weitreichende Implikationen für die Art von KI-Forschung, die auf europäischer Infrastruktur möglich wird. Für Graphrestrukturierungsverfahren wie OMGR ist dies aus zwei Gründen bedeutsam. Erstens: Sensible Anwendungsbereiche – industrielle Prozessoptimierung, medizinische Diagnostik, Verteidigungsanwendungen – erfordern, dass Trainingsdaten und Modellgewichte nicht dem Zugriff fremder Rechtsordnungen unterliegen. Der US-Cloud-Act macht dies bei Nutzung von AWS, Azure oder Google Cloud strukturell unmöglich, selbst wenn die Server physisch in Europa stehen. Eine europäische HYOK-Infrastruktur schließt diese Souveränitätslücke kryptographisch.

Zweitens eröffnet die in remark 12.4 beschriebene topologische Trennung des Informationsflussgraphen ($\mathcal{G}_{\text{enc}} \subset \mathcal{G}$) eine weniger offensichtliche, aber theoretisch bedeutsame Forschungsfrage: Ist es möglich, den Fiedler-Vektor des Laplace-Operators $\mathbf{L}_{\mathcal{G}}$ in einem homomorph verschlüsselten Rechenraum zu approximieren? Bieten Secure Multi-Party Computation (SMPC) oder Differential-Privacy-Mechanismen eine Brücke zwischen dem offenen spektralen Graphenmodell dieser Arbeit und datenschutzkonformen Implementierungen? Diese Fragen sind formal offen und definieren ein neues Forschungsfeld an der Schnittstelle von spektraler Graphentheorie und kryptographischen Protokollen. Eine positive Antwort würde bedeuten, dass OMGR nicht nur auf souveräner, sondern auf *verschlüsselter* Infrastruktur ausgeführt werden kann – ein Ziel, das Schwarz-Digits-artige Architekturen technologisch motiviert und gleichzeitig die Anwendbarkeit von Graphrestrukturierungsverfahren auf datenschutzrechtlich besonders sensible Domänen (Gesundheitswesen, Strafverfolgung, Militär) eröffnet.

Überwindung der Lock-in-Dynamik durch algorithmische Unabhängigkeit.

Proposition 12.9 modelliert die Lock-in-Dynamik des Cloud-Marktes formal: Ohne einen Wachstumsbeitrag r , der die Lock-in-Rate λ übersteigt, konvergiert der europäische Marktanteil $S(t)$ gegen null. Was diese Proposition nicht explizit erfasst, ist die qualitative Dimension algorithmischer Unabhängigkeit: Ein Forschungsökosystem, das auf methodisch überlegenen Verfahren aufbaut, reduziert nicht nur seinen Rechenressourcenbedarf, sondern vermindert damit auch seine strukturelle Cloud-Abhängigkeit.

Formal lässt sich dies durch eine effizienzgewichtete Lock-in-Rate modellieren:

$$\lambda_{\text{eff}} = \lambda_0 \cdot \frac{G_{\min}(\varrho)}{G_{\text{gesamt}}},$$

wobei $G_{\min}(\varrho)$ die für das Restrukturierungsverfahren mit Rate ϱ minimal erforderliche GPU-Kapazität bezeichnet und G_{gesamt} die Gesamtkapazität eines äquivalenten Trainings ohne Restrukturierung. Da $G_{\min}(\varrho) < G_{\text{gesamt}}$ für jedes effiziente Restrukturierungsverfahren gilt, folgt $\lambda_{\text{eff}} < \lambda_0$: Algorithmische Effizienz senkt die effektive Lock-in-Rate.

Proposition 12.9 impliziert dann, dass dasselbe infrastrukturelle Wachstum r bei geringerem λ_{eff} ausreicht, um einen positiven stabilen Marktanteil zu halten. Eine formale Analyse dieser Kopplung zwischen Methodeneffizienz und Cloud-Marktdynamik wäre ein originärer Beitrag zur strategischen Forschungspolitik an der Grenze von Algorithmentheorie und Industrieökonomik.

Föderierte Graphrestrukturierung für dezentrale europäische Infrastruktur.

Ein zentrales architektonisches Merkmal der europäischen KI-Infrastrukturstrategie ist ihre geografische Dezentralisierung: Lübbenau (Brandenburg), München, Dietzenbach (Hessen) sowie potenzielle EU-Gigafactory-Standorte in 16 Mitgliedstaaten sind räumlich und administrativ verteilt. Diese Dezentralisierung bietet eine natürliche Motivierung für *föderierte Graphrestrukturierung*.

In einem Federated-OMGR-Szenario trainiert jeder Standort lokale Modelle auf sensiblen Daten; die Restrukturierungsmaske $\Delta\mathcal{E} = \mathcal{E}'\Delta\mathcal{E}$ wird – wie in section 13.6 skizziert – als kompakter $O(k \log m)$ -Bit-Vektor an einen aggregierenden Koordinationsknoten übertragen. Dieser aggregiert die lokalen Masken zu einem globalen Restrukturierungsvorschlag, der an alle Standorte zurückgespielt wird. Die Besonderheit der europäischen Konstellation besteht darin, dass die Standorte unter unterschiedlichen nationalen Rechtsordnungen operieren: Ein deutsches Krankenhaus, ein französisches Unternehmen der Verteidigungsindustrie und ein niederländisches Finanzinstitut können gemeinsam an einer föderiert restrukturierten Modellarchitektur mitwirken, ohne personenbezogene Daten zu übertragen. DSGVO-konforme Datenhaltung wird durch die HYOK-Architektur am jeweiligen Standort gewährleistet; die Restrukturierungsmaske selbst enthält keine Originaldaten, sondern nur topologische Informationen über Netzwerkstrukturen.

Die formal offene Kernfrage lautet: Konvergiert föderiertes OMGR – bei dem jeder Teilnehmer seinen lokalen Fiedler-Vektor berechnet und nur die Restrukturierungsmaske kommuniziert – gegen dasselbe Optimum wie zentralisiertes OMGR auf den assemblierten Daten? Unter der Annahme identisch verteilter Daten an allen Standorten (i.i.d.) lässt sich mit Werkzeugen der Federated-Optimization-Theorie zeigen, dass der Konvergenzbeweis von Theorem 3.3 auf den föderierten Fall übertragbar ist, wenn lokale Fiedler-Vektoren durch gewichtete Aggregation kombiniert werden. Für nicht-i.i.d.-Daten – was in der europäischen Praxis die Regel ist (länderspezifische Produktionsprozesse, abweichende medizinische Kodierungsstandards, unterschiedliche regulatorische Anforderungen) – ist die Konvergenzanalyse formal offen und ein vordringliches Forschungsproblem.

Industrielle KI und kontinuierliche Graphrestrukturierung als europäischer Wettbewerbsvorteil. Ferri Abolhassan (Deutsche Telekom) und Jensen Huang (Nvidia) haben übereinstimmend formuliert, dass der entscheidende wirtschaftliche Hebel für Deutschland in der *industriellen KI* liegt: digitalisierten Fabriken, automatisierten Lieferketten und virtuellen Entwicklungsumgebungen. Diese Einschätzung deckt sich präzise mit dem in section 13.6 skizzierten Continual-Learning-Paradigma.

Industrielle KI-Systeme operieren in einem Regime permanenter Modellanpassungen: Maschinenzustände driften, Produktionsvariationen verändern die Datenverteilung, neue Produktreihen erfordern Domänenadaptionen. Die in section 13.6 entworfene Fixpunktdynamik

$$\alpha_{\text{dead}}^{(t+1)} = \alpha_{\text{dead}}^{(t)} - \varrho^{*(t)} \cdot r_{\text{react}} + p_{\text{die}} \cdot (1 - \alpha_{\text{dead}}^{(t)})$$

liefert die mathematische Grundlage, um das asymptotische Gleichgewicht α_{dead}^* für typische industrielle Drift-Raten p_{die} und Reaktivierungsraten r_{react} zu bestimmen. Aus einer

Kalibrierung an realen Produktionsdaten entstünde eine *industrielle Restrukturierungsfrequenz*: die optimale Rate, mit der OMGR in einem Produktionssystem angewendet werden sollte, um den Totneuronen-Anteil unter einem Schwellwert $\alpha_{\text{dead}}^* \leq \alpha_{\text{max}}$ zu halten.

Deutschlands komparativer Vorteil im Maschinenbau, der Automobil- und der Chemierbranche – Branchen mit präzise messbarem Prozessdrift – macht es zum idealen Testfeld für dieses industrielle Continual-Learning-Paradigma. Eine institutionelle Kooperation zwischen den Fraunhofer-Instituten, dem Deutschen Forschungszentrum für Künstliche Intelligenz (DFKI) und den in section 12.3 genannten Infrastrukturanbietern (Schwarz Digits, Deutsche Telekom) wäre ein natürlicher Rahmen für ein solches Forschungsprogramm – und könnte die in Kapitel 12 festgestellte Komplementarität von europäischer Ingenieurskultur und methodisch überlegener KI-Forschung konkret institutionalisieren.

Ökologische Synergie: Grünstrom-Infrastruktur und Modellkompression. Die ökologische Ausrichtung der deutschen Infrastrukturprojekte – 100 % Grünstrom und thermale Wertschöpfungskaskaden in Lübbenau und Dietzenbach – schafft eine direkte Synergie mit den Ergebnissen aus chapter 11. Theorem 11.4 beweist, dass SGKR-Kompression bei $\kappa = 0,3$ und $\text{PUE} = 1,45$ rund 53 % des skalierbaren Serververbrauchs einspart. Wird diese Einsparung auf einer Infrastruktur realisiert, die bereits vollständig auf Grünstrom setzt, verschiebt sich die Interpretation: Die eingesparte Strommenge steht als *Kapazitätsflexibilität* für weitere Workloads oder die Netzeinspeisung zur Verfügung.

Für die Lübbenauer Anlage ($P_{\text{max}} = 200 \text{ MW}$, Vollbetrieb mit Grünstrom) entspricht eine Kompression um $\kappa = 0,3$ einer freigelegten Leistung von

$$\Delta P_{\text{frei}} = (1 - \kappa) \cdot P_{\text{compute,max}} \cdot \text{PUE}^{-1} \approx 0,7 \times 200 \text{ MW} \times 0,69 \approx 97 \text{ MW}.$$

In einem Stromsystem, das an der Kapazitätsgrenze erneuerbarer Erzeugung operiert, hat jede eingesparte Kilowattstunde denselben systemischen Wert wie erzeugte erneuerbare Energie. Diese Neuformulierung hat Konsequenzen für die regulatorische Einordnung von Kompressionsverfahren: Als Kapazitätsflexibilitätsinstrument könnten sie in Netzstabilitätsmechanismen oder erneuerbare-Energie-Registrierungssysteme eingerechnet werden – ein bisher unerschlossener Anknüpfungspunkt zwischen Kompressionsmethodik und Energiemarktregulierung.

Von der Theorie zur Regulierung: Das Energiemodell als politisches Werkzeug. Das formale Energiemodell aus chapter 11 – mit den Größen PUE , κ , P_{server} , CO_2eq -Faktor und TCO – besitzt im Kontext der europäischen KI-Infrastrukturstrategie unmittelbare regulatorische Relevanz. Die EU hat mit dem European Green Deal und der Energieeffizienzrichtlinie (EED 2023) Meldepflichten für Rechenzentren eingeführt; für Gigafactories aus dem in section 12.7 beschriebenen Ausschreibungsverfahren werden diese Anforderungen bereits bei der Antragstellung relevant sein.

Die formalen Schranken aus Theorem 11.4 und Proposition 11.12 könnten dabei drei regulatorische Funktionen erfüllen:

- (i) **Standardisiertes Berichtswerkzeug:** Der κ -parametrisierte Energieeinspar-Satz erlaubt es, den Beitrag von Modellkompression zur Einhaltung von PUE -Zielen in standardisierter, auditfähiger Form zu quantifizieren.
- (ii) **Qualitätskriterium für Subventionen:** Im Rahmen der EU-Gigafactory-Förderung (Subventionsquote bis 35 %) wäre es wünschenswert, wenn Antragsteller nicht nur

hohe GPU-Kapazitäten (Gigafactory-Definition gemäß definition 12.3), sondern auch algorithmische Effizienzstandards – z. B. SGKR-Kompression mit $\kappa \leq 0,4$ – nachweisen müssten. Ein solches formales Effizienzkriterium könnte die soziale Rendite von Infrastruktursubventionen erheblich steigern.

- (iii) **Regulatorisches Benchmark für KI-Energieverbrauch:** Das CO₂eq-Modell aus Definition 11.6 und die standortadaptive Optimalstrategie aus section 13.11 könnten als analytisches Fundament für eine europäische Regulierung des KI-spezifischen Energieverbrauchs dienen – eine Ergänzung zu bestehenden Rechenzentrum-Meldepflichten, die spezifisch auf KI-Workloads zugeschnitten ist.

Strategische Szenarien für Europas KI-Infrastruktur bis 2030 und darüber hinaus. Die in fig. 12.2 dargestellte Prognose – über 5 GW installierte Anschlussleistung in Deutschland bis 2030, gegenüber 95 GW in den USA – impliziert eine dauerhaft bestehende Kapazitätslücke von rund einer Größenordnung. Diese ist durch investitionspolitische Maßnahmen allein nicht schließbar; selbst eine Verdoppelung der prognostizierten deutschen Kapazität auf 10 GW würde die relative Unterlegenheit nicht beseitigen. Für die entwickelten Methoden folgt daraus eine Langzeitperspektive: Recheneffizienz – formalisiert durch den OMGR-Algorithmus und die SGKR-Kompression – bleibt dauerhaft relevant, unabhängig davon, ob die europäischen Infrastrukturinvestitionen die anvisierten Kapazitäten erreichen. Das folgende dreigliedrige Zeithorizont-Szenario strukturiert die Forschungsperspektive:

- (a) **Kurzfristig (2026–2028): Skalierungsexperimente.** Auf der Münchner Telekom-Nvidia-Anlage (10.000 GPUs) und Vorabstufen von Lübbenau werden die empirischen Konstanten c_1, β und das Phasenübergangsverhalten aus Theorem 5.4 kalibriert. Parallel dazu: Entwicklung der föderationskompatiblen OMGR-Variante für die dezentrale europäische Infrastrukturlandschaft und erste Pilotexperimente zur privacy-preserving spektralen Graphalgorithmik auf HYOK-Infrastruktur.
- (b) **Mittelfristig (2028–2030): Gigafactory-Forschungsinfrastruktur.** Nach dem Anlaufen von Lübbenau in Vollkapazität (100.000 GPUs, 200 MW) wird erstmals die Validierung von OMGR und SGKR auf Modellen der Klasse 10^{11} Parameter möglich – ein wissenschaftlicher Meilenstein, der den Gültigkeitsbereich der theoretischen Skalierungsgesetze um zwei Größenordnungen erweitert. Industrielle Continual-Learning-Anwendungen in Kooperation mit deutschen Maschinenbauunternehmen werden erprobt; die föderierte OMGR-Variante wächst an die dezentrale europäische Multi-Site-Infrastruktur heran.
- (c) **Langfristig (ab 2030): Europäisches KI-Forschungsökosystem.** Mit dem Reifen der EU-Gigafactory-Programme und dem institutionellen Aufbau von Forschungsk Kooperationen nehmen die Ergebnisse aus section 12.12 – recheneffiziente Methodik als strategischer Vorteil, souveräne Infrastruktur als Voraussetzung für Forschungsfreiheit, industrielle KI als Scharnierpunkt – einen konkreten institutionellen Charakter an. Sie beschreiben dann nicht länger ein abstraktes Forschungsprogramm, sondern die technisch und rechtlich definierten Bedingungen, unter denen KI-Forschung in Europa auf Augenhöhe mit den USA und China betrieben werden kann.

Das Northvolt-Risiko: Robustheit algorithmischer Beiträge. section 12.11 verweist auf das Scheitern von Northvolt und der Intel-Chipfabrik in Magdeburg als Mahnmale für die Fragilität hochsubventionierter Infrastrukturgroßprojekte. Diese Warnung hat eine direkte Implikation für die Relevanz dieser Arbeit: Die theoretischen Ergebnisse zur minimalen Graphrestrukturierung sind *infrastrukturunabhängig*. Sie gelten, ob Lübbenau die geplante Kapazität vollständig erreicht oder nicht, ob das EU-Gigafactory-Programm an politischen Widerständen scheitert und ob weitere Marktturbulenzen Investitionspläne korrigieren.

Algorithmus ?? kann auf einem einzelnen Consumer-GPU-Cluster ausgeführt werden; die Schranke aus Proposition 12.6 markiert, wo Gigafactory-Infrastruktur für die praktische Skalierung auf Frontier-Modelle nötig wird – nicht für die Grundlagenforschung. Diese Robustheit ist ein struktureller Vorteil algorithmischer gegenüber infrastruktureller Forschungsbeiträge: Während ein Rechenzentrum von einem Ausfall der Art des AWS-Vorfalles vom 20. Oktober 2025 (vgl. section 12.2) oder einem politischen Kurswechsel getroffen werden kann, besitzt ein mathematisch bewiesenes Theorem die Stabilität, die Infrastrukturprojekten per Definition fehlt. Für die europäische Forschungsfinanzierungspolitik folgt daraus eine strategische Empfehlung: Investitionen in recheneffiziente Methodik – bei denen der theoretische Beitrag infrastrukturunabhängig ist und die praktische Validierung stufenweise mit wachsender Infrastruktur möglich wird – sind robuster gegen politische und wirtschaftliche Risikoereignisse als Ansätze, die von Anfang an Gigafactory-Kapazitäten voraussetzen.

Fazit des Ausblicks

Die in dieser Arbeit formalisierte minimale Graphrestrukturierung – ergänzt durch das Kapitel zur strukturellen Subgraph-Kompression und die umfassende Analyse der energetischen Implikationen (Kapitel 11) – berührt fundamentale Fragen der Lerntheorie, der algorithmischen Effizienz, der biologischen Plausibilität, der praktischen Anwendbarkeit und der Nachhaltigkeit moderner tiefer neuronaler Netzwerke. Die zwölf skizzierten Forschungsrichtungen sind nicht unabhängig: Die Skalierungsanalyse (section 13.2) verbindet die formalen Ergebnisse aus chapter 5 direkt mit empirischer Kalibrierung und praktischer Budget-Planung für sehr große Modelle; die strukturelle Subgraph-Kompression (section 13.3) baut auf diesen Skalierungsergebnissen auf und ergänzt sie durch iterative Motiv-Erkennung und hardwarebewusstes Routing – ein Schritt von der strukturellen Theorie zur energieeffizienten Praxis; eine skalierbare Fiedler-Approximation (section 13.7) ist Voraussetzung für die empirische Validierung auf großen Benchmarks (section 13.5); die Verbindung zu biologischer Plastizität (section 13.8) motiviert heuristische Algorithmen, die an theoretischen Schranken (section 13.4) gemessen werden können; schließlich entfaltet der Ausblick zu den bioinspirierten Grundprinzipien (section 13.9) ein vollständiges Forschungsprogramm zu Minimalität, Verknüpfbarkeit und ionischer Verschaltung – von formalen offenen Fragen über empirische Validierungsexperimente bis hin zur physikalischen Realisierung via IRF-Arrays.

Der Ausblick zur KI-Recheninfrastruktur und digitalen Souveränität (section 13.12) bettet alle Ergebnisse in den geopolitischen und strategischen Rahmen ein: Er verbindet die formale Lock-in-Dynamik (Proposition 12.9) mit konkreten deutschen und europäischen Infrastrukturprojekten, zeigt, wie die Kapazitätslücke zwischen Europa und den USA durch algorithmische Effizienz partiell geschlossen werden kann, und eröffnet mit der Frage nach privacy-preserving spektraler Graphalgorithmik auf HYOK-Infrastruktur ein neues

Forschungsfeld an der Schnittstelle von Kryptographie und Lerntheorie.

Die energetischen Implikationen (section 13.11) schließen den Kreis: Das in chapter 11 formalisierte Energiemodell macht die theoretischen Kompressionsergebnisse in einer anderen Sprache erfahrbar – in Kilowattstunden, Tonnen CO₂eq und Millionen Euro. Diese Überführung abstrakter Graphtheorie in quantitative Nachhaltigkeitswerte ist ein Kernbeitrag dieser Arbeit: Sie belegt, dass strukturelle Theorie keine akademische Selbstbeschäftigung ist, sondern – richtig weitergedacht – praktischen Hebel für eine der drängendsten technischen und ökologischen Herausforderungen der nächsten Dekade bietet. Der Kern des Forschungsprogramms lässt sich in vier Leitsätzen zusammenfassen:

- (i) **Minimalismus als Stärke:** Kleine strukturelle Interventionen können überproportionale Kapazitätsgewinne bewirken – und die formale Quantifizierung dieses Effekts ist erst begonnen.
- (ii) **Theorie als Kompass:** Die hergeleiteten Schranken für ϱ^* , ΔC , katastrophales Vergessen und Generalisierung liefern präzise Vorhersagen, die empirisch falsifizierbar sind und Algorithmen gezielt anleiten.
- (iii) **Architekturübergreifende Gültigkeit:** Die spektral- und informationstheoretischen Werkzeuge dieser Arbeit sind architekturunabhängig formuliert und warten auf ihre Anwendung auf die breite Klasse moderner Netzwerkarchitekturen.
- (iv) **Nachhaltigkeitsrelevanz:** Das formale Energiemodell aus Kapitel 11 überführt abstrakte Kompressionsergebnisse in konkrete Klimawirkung – 17 GWh/Jahr pro 1 000 Server, Amortisation des SGKR-Aufwands in weniger als einer Stunde – und setzt damit ein Zeichen, dass mathematische Lerntheorie und globale Energiepolitik keine getrennten Welten sind.

Anhang A

Ergänzende Beweise

A.1 Vollständiger Beweis von Proposition 7.2

Wir geben hier den vollständigen Beweis der Entropiegewinn-Proposition.

Sei $\mathbf{p} = (p_1, \dots, p_n)$ die normierte Aktivierungsverteilung mit $p_i = |\sigma(z_i)|/Z$ und $Z = \sum_j |\sigma(z_j)|$. Nach Reaktivierung von Neuron i_0 (bisher $p_{i_0} = 0$) gilt $p'_{i_0} = \mathbb{E}[\sigma(z_{i_0})]/(Z + \mathbb{E}[\sigma(z_{i_0})])$. Für die neuen Wahrscheinlichkeiten ergibt sich:

$$p'_j = \frac{p_j \cdot Z}{Z + \mathbb{E}[\sigma(z_{i_0})]}, \quad j \neq i_0.$$

Der Entropiezuwachs berechnet sich zu:

$$\begin{aligned} H(\mathbf{p}') - H(\mathbf{p}) &= H(p'_{i_0}, p'_1, \dots, p'_{n, i_0 \neq}) - H(0, p_1, \dots, p_n) \\ &= -p'_{i_0} \log p'_{i_0} - \sum_{j \neq i_0} p'_j \log p'_j + \sum_{j \neq i_0} p_j \log p_j \\ &= -p'_{i_0} \log p'_{i_0} - \sum_{j \neq i_0} p'_j (\log p'_j - \log p_j) \\ &= -p'_{i_0} \log p'_{i_0} + (1 - p'_{i_0}) \log \frac{Z + \mathbb{E}[\sigma(z_{i_0})]}{Z} \geq 0. \end{aligned} \quad (\text{A.1})$$

Für r reaktivierte Neuronen summiert sich dieser Zuwachs zu (7.1) mittels Subadditivität der Entropie. $\square$

A.2 Weyl-Perturbationsungleichung

Für die Selbstvollständigkeit geben wir das Weyl-Theorem an:

Theorem A.1 (Weyl, 1912). *Seien $\mathbf{A}, \mathbf{B} \in \mathbb{R}^{n \times n}$ symmetrische Matrizen mit geordneten Eigenwerten $\alpha_1 \leq \dots \leq \alpha_n$ bzw. $\gamma_1 \leq \dots \leq \gamma_n$ von $\mathbf{A} + \mathbf{B}$. Dann gilt:*

$$|\gamma_i - \alpha_i| \leq \|\mathbf{B}\|_2 \quad \forall i.$$

Dies ist die Grundlage von (3.3) in Theorem 3.2.

Literaturverzeichnis

- [1] Epp, S. (2026a). *Der Subgraph Algorithmus*. Verfügbar unter <https://github.com/hjstephan86/subgraph>.
- [2] Epp, S. (2026b). *Ionotronisches Flüssigkeits-Rechnen: Wasservolumen als Ladungsträger, Schalter und Speicher*. Unveröffentlichtes Manuskript.
- [3] Bartlett, P. L. (1997). For valid generalization, the size of the weights is more important than the size of the network. *Advances in Neural Information Processing Systems*, 9.
- [4] Bartlett, P. L. & Mendelson, S. (2002). Rademacher and Gaussian complexities: Risk bounds and structural results. *Journal of Machine Learning Research*, 3, 463–482.
- [5] Blumer, A., Ehrenfeucht, A., Haussler, D., & Warmuth, M. K. (1989). Learnability and the Vapnik-Chervonenkis dimension. *Journal of the ACM*, 36(4), 929–965.
- [6] Chung, F. R. K. (1997). *Spectral Graph Theory*. American Mathematical Society.
- [7] Cover, T. M. & Thomas, J. A. (2006). *Elements of Information Theory* (2nd ed.). Wiley-Interscience.
- [8] Fiedler, M. (1973). Algebraic connectivity of graphs. *Czechoslovak Mathematical Journal*, 23(2), 298–305.
- [9] Goldberg, P. W. & Jerrum, M. R. (1995). Bounding the Vapnik-Chervonenkis dimension of concept classes parameterized by real numbers. *Machine Learning*, 18(2–3), 131–148.
- [10] Hornik, K. (1991). Approximation capabilities of multilayer feedforward networks. *Neural Networks*, 4(2), 251–257.
- [11] Kirkpatrick, J., et al. (2017). Overcoming catastrophic forgetting in neural networks. *Proceedings of the National Academy of Sciences*, 114(13), 3521–3526.
- [12] LeCun, Y., Denker, J., & Solla, S. (1990). Optimal brain damage. *Advances in Neural Information Processing Systems*, 2, 598–605.
- [13] Lu, Z., et al. (2017). The expressive power of neural networks: A view from the width. *Advances in Neural Information Processing Systems*, 30.
- [14] Moody, J. E. & Utans, J. (1992). Principled architecture selection for neural networks: Application to corporate bond rating prediction. *Advances in Neural Information Processing Systems*, 4.

- [15] Tishby, N. & Schwartz-Ziv, R. (2015). Deep learning and the information bottleneck principle. *IEEE Information Theory Workshop*, 1–5.
- [16] Vapnik, V. N. & Chervonenkis, A. Ya. (1971). On the uniform convergence of relative frequencies of events to their probabilities. *Theory of Probability and Its Applications*, 16(2), 264–280.
- [17] Weyl, H. (1912). Das asymptotische Verteilungsgesetz der Eigenwerte linearer partieller Differentialgleichungen. *Mathematische Annalen*, 71(4), 441–479.
- [18] Zoph, B. & Le, Q. V. (2017). Neural Architecture Search with Reinforcement Learning. *International Conference on Learning Representations (ICLR)*.
- [19] Alon, U. & Yahav, E. (2021). On the bottleneck of graph neural networks and its practical implications. *International Conference on Learning Representations (ICLR)*.
- [20] Barabási, A.-L. & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509–512.
- [21] Cohen, J., Rosenfeld, E., & Kolter, J. Z. (2019). Certified adversarial robustness via randomized smoothing. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 97, 1310–1320.
- [22] Cuturi, M. (2013). Sinkhorn distances: Lightspeed computation of optimal transport distances. *Advances in Neural Information Processing Systems*, 26, 2292–2300.
- [23] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [24] He, K., Zhang, X., Ren, S., & Sun, J. (2015). Delving deep into rectifiers: Surpassing human-level performance on ImageNet classification. *Proceedings of the IEEE International Conference on Computer Vision (ICCV)*, 1026–1034.
- [25] He, K., Zhang, X., Ren, S., & Sun, J. (2016). Deep residual learning for image recognition. *IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 770–778.
- [26] Hensch, T. K. (2004). Critical period regulation. *Annual Review of Neuroscience*, 27, 549–579.
- [27] Hu, E., Shen, Y., Wallis, P., Allen-Zhu, Z., Li, Y., Wang, S., Wang, L., & Chen, W. (2022). LoRA: Low-rank adaptation of large language models. *International Conference on Learning Representations (ICLR)*.
- [28] Jacot, A., Gabriel, F., & Hongler, C. (2018). Neural tangent kernel: Convergence and generalization in neural networks. *Advances in Neural Information Processing Systems*, 31, 8571–8580.
- [29] Liu, H., Simonyan, K., & Yang, Y. (2019). DARTS: Differentiable architecture search. *International Conference on Learning Representations (ICLR)*.
- [30] McMahan, B., Moore, E., Ramage, D., Hampson, S., & y Arcas, B. A. (2017). Communication-efficient learning of deep networks from decentralized data. *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics (AISTATS)*, 1273–1282.

- [31] Rusu, A. A., Rabinowitz, N. C., Desjardins, G., Soyer, H., Kirkpatrick, J., Kavukcuoglu, K., Pascanu, R., & Hadsell, R. (2016). Progressive neural networks. *arXiv preprint arXiv:1606.04671*.
- [32] Shafahi, A., Najibi, M., Ghiasi, M. A., Xu, Z., Dickerson, J., Studer, C., Davis, L. S., Taylor, G., & Goldstein, T. (2019). Adversarial training for free! *Advances in Neural Information Processing Systems*, 32.
- [33] Spielman, D. A. & Teng, S.-H. (2011). Spectral sparsification of graphs. *SIAM Journal on Computing*, 40(4), 981–1025.
- [34] Topping, J., Di Giovanni, F., Chamberlain, B. P., Dong, X., & Bronstein, M. M. (2022). Understanding over-squashing and bottlenecks on graphs via curvature. *International Conference on Learning Representations (ICLR)*.
- [35] Tropp, J. A. (2012). User-friendly tail bounds for sums of random matrices. *Foundations of Computational Mathematics*, 12(4), 389–434.
- [36] Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, Ł., & Polosukhin, I. (2017). Attention is all you need. *Advances in Neural Information Processing Systems*, 30.
- [37] Villani, C. (2009). *Optimal Transport: Old and New*. Springer, Berlin.
- [38] Atkins, P., de Paula, J., & Keeler, J. (2018). *Atkins’ Physical Chemistry* (11th ed.). Oxford University Press, Oxford.
- [39] Frankle, J., & Carlin, M. (2019). The lottery ticket hypothesis: Finding sparse, trainable neural networks. In *International Conference on Learning Representations (ICLR 2019)*.
- [40] Goyal, A., & Bengio, Y. (2022). Inductive biases for deep learning of higher-level cognition. *Proceedings of the Royal Society A*, 478(2266), Article 20210068.
- [41] Hebb, D. O. (1949). *The Organization of Behavior: A Neuropsychological Theory*. Wiley, New York.
- [42] Hirschberg, D. S. (1975). A linear space algorithm for computing maximal common subsequences. *Communications of the ACM*, 18(6), 341–343.
- [43] Hodgkin, A. L., & Huxley, A. F. (1952). A quantitative description of membrane current and its application to conduction and excitation in nerve. *The Journal of Physiology*, 117(4), 500–544.
- [44] Kaplan, J., McCandlish, S., Henighan, T., Brown, T. B., Chess, B., Child, R., Gray, S., Radford, A., Wu, J., & Amodei, D. (2020). Scaling laws for neural language models. *arXiv preprint arXiv:2001.08361*.
- [45] Laughlin, S. B., & Sejnowski, T. J. (2003). Communication in neuronal networks. *Science*, 301(5641), 1870–1874.
- [46] Maass, W. (1997). Networks of spiking neurons: The third generation of neural network models. *Neural Networks*, 10(9), 1659–1671.

- [47] McKay, B. D., & Piperno, A. (2014). Practical graph isomorphism, II. *Journal of Symbolic Computation*, 60, 94–112.
- [48] Mugele, F., & Baret, J.-C. (2005). Electrowetting: From basics to applications. *Journal of Physics: Condensed Matter*, 17(28), R705–R774.
- [49] Rissanen, J. (1978). Modeling by shortest data description. *Automatica*, 14(5), 465–471.
- [50] Schuman, C. D., Potok, T. E., Patton, R. M., Birdwell, J. D., Dean, M. E., Rose, G. S., & Plank, J. S. (2017). A survey of neuromorphic computing and neural networks in hardware. *arXiv preprint arXiv:1705.06963*.
- [51] Sporns, O., Tononi, G., & Kötter, R. (2005). The human connectome: A structural description of the human brain. *PLOS Computational Biology*, 1(4), e42.
- [52] Zenke, F., Poole, B., & Ganguli, S. (2017). Continual learning through synaptic intelligence. In *Proceedings of the 34th International Conference on Machine Learning (ICML 2017)*, pp. 3987–3995.
- [53] International Energy Agency (IEA). (2024). *Electricity 2024: Analysis and Forecast to 2026*. IEA, Paris. <https://www.iea.org/reports/electricity-2024>
- [54] Brown, T. B., Mann, B., Ryder, N., Subbiah, M., Kaplan, J., Dhariwal, P., Neelakantan, A., Shyam, P., Sastry, G., Askell, A., & Amodei, D. (2020). Language models are few-shot learners. *Advances in Neural Information Processing Systems*, 33, 1877–1901.
- [55] Cybenko, G. (1989). Approximation by superpositions of a sigmoidal function. *Mathematics of Control, Signals and Systems*, 2(4), 303–314.
- [56] Han, S., Pool, J., Tran, J., & Dally, W. (2015). Learning both weights and connections for efficient neural networks. *Advances in Neural Information Processing Systems*, 28, 1135–1143.
- [57] Hinton, G., Vinyals, O., & Dean, J. (2015). Distilling the knowledge in a neural network. *arXiv preprint arXiv:1503.02531*.
- [58] Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. *Neural Computation*, 9(8), 1735–1780.
- [59] Jouppi, N. P., Young, C., Patil, N., Patterson, D., Agrawal, G., Bajwa, R., Bates, S., Bhatia, S., Boden, N., Borchers, A., & Boyle, R. (2017). In-datacenter performance analysis of a tensor processing unit. *Proceedings of the 44th Annual International Symposium on Computer Architecture (ISCA)*, 1–12.
- [60] Krizhevsky, A., Sutskever, I., & Hinton, G. E. (2012). ImageNet classification with deep convolutional neural networks. *Advances in Neural Information Processing Systems*, 25, 1097–1105.
- [61] Li, H., Kadav, A., Durdanovic, I., Samet, H., & Graf, H. P. (2017). Pruning filters for efficient convnets. *International Conference on Learning Representations (ICLR)*.
- [62] Ma, X., Fang, G., & Wang, X. (2023). LLM-Pruner: On the structural pruning of large language models. *Advances in Neural Information Processing Systems*, 36.

- [63] Mishra, A., Latorre, J. A., Pool, J., Stosic, D., Stosic, D., Venkatesh, G., Yu, C., & Micikevicius, P. (2021). Accelerating sparse deep neural networks. *arXiv preprint arXiv:2104.08378*.
- [64] Patterson, D., Gonzalez, J., Le, Q., Liang, C., Munguia, L.-M., Rothchild, D., So, D., Texier, M., & Dean, J. (2021). Carbon considerations for large language model training. *Communications of the ACM*, 65(6), 54–63.
- [65] Schwartz, R., Dodge, J., Smith, N. A., & Etzioni, O. (2020). Green AI. *Communications of the ACM*, 63(12), 54–63.
- [66] Srivastava, N., Hinton, G., Krizhevsky, A., Sutskever, I., & Salakhutdinov, R. (2014). Dropout: A simple way to prevent neural networks from overfitting. *Journal of Machine Learning Research*, 15(1), 1929–1958.
- [67] Strubell, E., Ganesh, A., & McCallum, A. (2019). Energy and policy considerations for deep learning in NLP. *Proceedings of the 57th Annual Meeting of the Association for Computational Linguistics (ACL)*, 3645–3650.
- [68] Sun, Y., Wang, X., & Tang, X. (2015). Deeply learned face representations are sparse, selective, and robust. *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, 2892–2900.
- [69] Tan, M., & Le, Q. V. (2019). EfficientNet: Rethinking model scaling for convolutional neural networks. *Proceedings of the 36th International Conference on Machine Learning (ICML)*, 6105–6114.
- [70] Thimm, G., & Fiesler, E. (1995). High-order and multilayer perceptron initialization. *IEEE Transactions on Neural Networks*, 8(2), 349–359.
- [71] Wortsman, M., Ilharco, G., Gadre, S. Y., Roelofs, R., Gontijo-Lopes, R., Morcos, A. S., Namkoong, H., Farhadi, A., Carlin, Y., Kornblith, S., & Schmidt, L. (2022). Model soups: averaging weights of multiple fine-tuned models improves accuracy without increasing inference time. *Proceedings of the 39th International Conference on Machine Learning (ICML)*, 23965–23998.
- [72] Xiao, H., Rasul, K., & Vollgraf, R. (2017). Fashion-MNIST: A novel image dataset for benchmarking machine learning algorithms. *arXiv preprint arXiv:1708.07747*.
- [73] Zhou, H., Alvarez, J. M., & Porikli, F. (2016). Less is more: Towards compact CNNs. *European Conference on Computer Vision (ECCV)*, 662–677.
- [74] Ziegler, T., & Granzow, M. (2024). Datacenter energy use in the era of generative AI: Benchmarks and projections. *Nature Electronics*, 7(3), 178–190.
- [75] Leipold, R. (2026). KI-Zentren: Deutschland startet durch. *CHIP Magazin*, (02/2026), S. 20–27.
- [76] Barabási, A.-L., & Albert, R. (1999). Emergence of scaling in random networks. *Science*, 286(5439), 509–512.