

Neuronale Netze und ISO 26262

Eine kritische Analyse der Vereinbarkeit unter besonderer
Berücksichtigung von Zuverlässigkeit, Vertrauenswürdigkeit,
Nachvollziehbarkeit und deterministischem Verhalten

Stephan Epp

30. März 2026

Inhaltsverzeichnis

1	Einleitung	3
2	Grundlagen	4
2.1	Funktionale Sicherheit und ISO 26262	4
2.2	Anforderungsarten in ISO 26262	4
2.3	Neuronale Netze – Grundprinzip und Eigenschaften	5
2.4	Der Einsatzkontext: Virtuelle Sensoren auf ECUs	5
3	Die Anforderungen der ISO 26262 im Detail	5
3.1	Determinismus	5
3.2	Anforderungsverfolgbarkeit (Requirements Traceability)	6
3.3	Verifikation und Testabdeckung	6
3.4	Keine unbeabsichtigte Funktionalität	7
3.5	Änderungsmanagement und Wiederhol-Qualifikation	7
3.6	Tool-Qualifikation	7
4	Spezifische Defizite neuronaler Netze aus Sicherheitsperspektive	8
4.1	Das Erklärbarkeitsdefizit (Explainability Gap)	8
4.2	Adversarielle Robustheit	8
4.3	Out-of-Distribution-Verhalten	8
4.4	Fehlende formale Spezifikation	9
4.5	Statistische vs. deterministische Korrektheit	9
4.6	Reproduzierbares Schadensversagen (Fault Reproduction)	9
4.7	Zertifizierungsnachweis und Safety Case	9
5	Zentrale Argumente gegen den Einsatz	10
5.1	Argument 1: Strukturelle Unvereinbarkeit mit dem Verifikationsparadigma	10
5.2	Argument 2: Vertrauenswürdigkeit erfordert Erklärbarkeit	10
5.3	Argument 3: Determinismusdefizienz als dauerhaftes Strukturproblem . . .	11
5.4	Argument 4: Datenqualität als neue, unkontrollierbare Fehlerquelle	11

5.5	Argument 5: Systemische Überschaubarkeit	11
5.6	Argument 6: Haftungs- und Nachweisrechtliche Implikationen	11
5.7	Argument 7: Zertifizierungsrisiko bei Typgenehmigung	12
6	Kritische Auseinandersetzung	12
6.1	ASIL-Dekomposition und Monitoring-Architektur	12
6.2	ISO/PAS 8800 und neue Normen adressieren das Problem	13
6.3	MIL/SIL/PIL-Tests belegen die Sicherheit	13
6.4	Akzeptiertes Restrisiko (Acceptable Residual Risk)	13
7	Sichere Alternativen zu KNN-basierten Sensorlösungen	14
7.1	Modellbasierte Beobachter und Kalman-Filter	14
7.2	Polynomiale Approximationen und Look-up-Tabellen	14
7.3	Physikalisch-motivierte Modelle	14
7.4	Fuzzy-Logik und Expertensysteme	14
7.5	Formale Methoden und Model Checking	14
8	Diskussion: Kumuliertes Defizit und Normative Lücke	15
8.1	Die normative Lücke	15
8.2	Das Präzedenzargument der Luft- und Raumfahrt	15
8.3	Das Tempo des technologischen Wandels vs. normative Reife	15
9	Fazit und Empfehlungen	16
	Literaturverzeichnis	17

1 Einleitung

Der Einsatz von künstlichen neuronalen Netzen (KNN) in sicherheitskritischen elektronischen Steuergeräten (ECUs) des Automobils erfreut sich wachsender Beliebtheit, insbesondere in der Realisierung virtueller Sensoren sowie bei Fahrerassistenzfunktionen. Diese Entwicklung steht jedoch in einem grundsätzlichen Spannungsverhältnis zum international gültigen Sicherheitsentwicklungsstandard ISO 26262, der deterministische, formal verifizierbare und lückenlos rückverfolgbare Systeme fordert. Die vorliegende Arbeit analysiert diesen Zielkonflikt systematisch und kommt zu dem Schluss, dass neuronale Netze in ihrer gegenwärtigen Form die zentralen Anforderungen der ISO 26262 – insbesondere Determinismus, Nachvollziehbarkeit, Verifikationsfähigkeit sowie Anforderungsverfolgbarkeit – strukturell nicht erfüllen können. Es wird argumentiert, dass systemarchitektonische Kompensationsmaßnahmen diese fundamental-epistemischen Defizite zwar einschränken, jedoch nicht beseitigen können. Auf Basis einer eingehenden Analyse des Normtextes, der Sicherheitsmethodik und des aktuellen Stands der KI-Forschung wird ein differenziertes Fazit formuliert, das die strikte Beschränkung des KNN-Einsatzes auf unkritische Qualitätsmanagement-Funktionen empfiehlt und den weiteren Einsatz ablehnt, solange keine formal gleichwertigen Nachweisverfahren existieren.

Die Automobilindustrie befindet sich in einem tiefgreifenden technologischen Wandel. Hochautomatisiertes Fahren, Elektromobilität und die zunehmende Vernetzung von Fahrzeugen mit ihrer Umgebung erfordern immer komplexere elektronische Steuersysteme. In diesem Kontext gewinnen Methoden der künstlichen Intelligenz (KI) und insbesondere künstliche neuronale Netze (KNN) an Bedeutung, da sie in der Lage sind, komplexe, nichtlineare Zusammenhänge aus Daten zu erlernen – Fähigkeiten, die klassischen, regelbasierten Ansätzen oft verschlossen bleiben [26].

Eine prominente Anwendung ist der sogenannte *virtuelle Sensor*: Anstelle eines kostenintensiven oder unter Serienbedingungen unpraktikablen physikalischen Sensors soll ein KNN ausgehend von anderen, bereits vorhandenen Messgrößen die gesuchte physikalische Größe schätzen. Derartige Konzepte werden heute aktiv von Werkzeuganbietern wie dSPACE mit ihrer TargetLink-Umgebung beworben und versprechen, den Entwicklungsaufwand zu reduzieren und gleichzeitig die Leistungsfähigkeit von Steuergeräten zu erhöhen.

Diese Entwicklung wirft jedoch eine fundamentale Frage auf, die in der Industrie und Wissenschaft bislang nicht befriedigend beantwortet wurde: *Können neuronale Netze die Anforderungen erfüllen, die der internationale Sicherheitsstandard ISO 26262 an Software in sicherheitskritischen Steuergeräten stellt?*

ISO 26262, der Maßgebliche Standard für die funktionale Sicherheit von Straßenfahrzeugen, definiert einen umfassenden Entwicklungsprozess, der auf Determinismus, vollständiger Anforderungsverfolgbarkeit, formaler Verifikation und einer nachvollziehbaren, überprüfbaren Systemstruktur beruht [1]. Diese Eigenschaften sind keine willkürlichen bürokratischen Hürden, sondern Konsequenz jahrzehntelanger Erfahrung mit sicherheitskritischer Systementwicklung und dem Verständnis, dass menschliches Leben von der zuverlässigen und vorhersagbaren Funktion dieser Systeme abhängt [21].

Die vorliegende Arbeit nimmt eine deutlich kritische Position gegenüber dem Einsatz von neuronalen Netzen in sicherheitskritischen ECUs ein. Sie argumentiert, dass die grundsätzliche Arbeitsweise neuronaler Netze – das statistische Erlernen von Mustern aus Daten ohne explizit programmierte Logik – strukturell unvereinbar mit den Kernanforderungen von ISO 26262 ist. Der Beitrag gliedert sich wie folgt: Section 2 legt die technischen und

normativen Grundlagen. Section 3 analysiert die relevanten ISO-26262-Anforderungen im Detail. Section 4 identifiziert die spezifischen Defizite neuronaler Netze. Section 5 formuliert die zentralen Argumente gegen den Einsatz. Section 6 setzt sich mit möglichen Gegenargumenten und Kompensationsansätzen auseinander und zeigt deren Grenzen auf. Section 7 diskutiert sichere Alternativen, und Section 9 schließt mit einem Fazit und Empfehlungen.

Schlüsselwörter: ISO 26262, Funktionale Sicherheit, Neuronale Netze, Künstliche Intelligenz, ASIL, Determinismus, Verifikation, Anforderungsverfolgbarkeit, Virtuelle Sensoren, ECU

2 Grundlagen

2.1 Funktionale Sicherheit und ISO 26262

Funktionale Sicherheit bezeichnet die Eigenschaft eines Systems, auf fehlerhafte Zustände in einer für die Umgebung sicheren Weise zu reagieren [9]. Im automobilen Kontext ist ISO 26262 die maßgebliche Norm. Sie entstand als Ableitung der allgemeinen Norm IEC 61508 und wurde erstmals 2011 veröffentlicht; die zweite, derzeit gültige Ausgabe stammt aus dem Jahr 2018.

Die Norm strukturiert den gesamten Produktentwicklungsprozess in einem sogenannten *V-Modell*: Auf der linken Seite des V erfolgt die Spezifikation von System-, Hardware- und Software-Anforderungen in absteigender Abstraktionsebene, auf der rechten Seite die korrespondierende Verifikation und Validierung auf jeder Ebene [2]. Kernkonzept der Norm ist das *Automotive Safety Integrity Level* (ASIL), eine vierstufige Risikoklassifikation von ASIL A (geringste Anforderungen) bis ASIL D (höchste Anforderungen) sowie die Klasse QM (Quality Management, keine expliziten Sicherheitsanforderungen).

Die ASIL-Einstufung ergibt sich aus einer Risikoanalyse unter Berücksichtigung von Gefährdungsexposition (E), Kontrollierbarkeit (C) und Schadensausmaß (S). Je höher der resultierende ASIL, desto strenger die Anforderungen an Entwicklungsprozess, Verifikation, Testabdeckung und Dokumentation.

2.2 Anforderungsarten in ISO 26262

ISO 26262 unterscheidet verschiedene Klassen von Anforderungen:

Sicherheitsziele (Safety Goals):

Oberste Anforderungen auf Fahrzeugebene, direkt aus der Gefährdungs- und Risikoanalyse (HARA) abgeleitet.

Funktionale Sicherheitsanforderungen (FSR):

Systemebene, beschreiben das geforderte Sicherheitsverhalten.

Technische Sicherheitsanforderungen (TSR):

Hardware/Software-Ebene, beschreiben die technische Implementierung der FSR.

Software-Sicherheitsanforderungen (SSR):

Spezifisch für Software-Einheiten, direkt implementierbar und formal testbar.

Die Norm verlangt eine lückenlose, bidirektionale *Anforderungsverfolgbarkeit* (Requirements Traceability) von den Sicherheitszielen bis hinunter zum einzelnen Softwaremodul und zurück [4].

2.3 Neuronale Netze – Grundprinzip und Eigenschaften

Künstliche neuronale Netze (KNN) sind mathematische Modelle, die von der Struktur biologischer Nervensysteme inspiriert sind [25]. Sie bestehen aus Schichten von *Neuronen*, deren Verbindungen durch numerische Gewichte w_{ij} parametrisiert sind. Die Ausgabe eines Neurons j in Schicht l ergibt sich aus der gewichteten Summe der Eingänge, auf die eine nichtlineare Aktivierungsfunktion σ angewendet wird:

$$a_j^{(l)} = \sigma \left(\sum_i w_{ij}^{(l)} a_i^{(l-1)} + b_j^{(l)} \right) \quad (1)$$

Die Gewichte werden nicht explizit programmiert, sondern durch einen Lernalgorithmus (typischerweise Backpropagation mit gradientenbasierter Optimierung) aus einem Trainingsdatensatz *erlernt* [27]. Dieser Prozess minimiert eine Verlustfunktion über die Trainingsdaten, ohne dass dem Netz explizites Wissen über den zugrundeliegenden physikalischen Prozess eingepflanzt wird.

Moderne tiefe Netze (Deep Neural Networks) können Millionen bis Milliarden von Parametern besitzen. Sie haben in zahlreichen Anwendungsgebieten – Bildklassifikation, Sprachverarbeitung, Steuerungsaufgaben – herausragende Leistungen erzielt [26]. Dieser empirische Erfolg sollte jedoch nicht darüber hinwegtäuschen, dass die innere Repräsentation solcher Netze für den Menschen im Wesentlichen undurchschaubar bleibt [17].

2.4 Der Einsatzkontext: Virtuelle Sensoren auf ECUs

Ein virtueller Sensor ist ein Softwarealgorithmus, der auf Basis priori bekannter Eingangskanäle einen physikalischen Messwert schätzt, der andernfalls nur durch aufwendige oder kostenintensive Hardware-Sensoren erfasst werden könnte. Die Idee ist nicht neu – modellbasierte Beobachter (z. B. Luenberger-Beobachter, Kalman-Filter) sind seit Jahrzehnten im Einsatz [21]. Der wesentliche Unterschied beim KNN-basierten Ansatz: Statt eines physikalisch motivierten, mathematisch herzuleitenden Modells wird ein rein datengetriebener Ansatz verwendet, dessen innere Struktur no implizites physikalisches Wissen trägt.

In sicherheitskritischen Anwendungen – etwa der Schätzung der Fahrzeuggeschwindigkeit, des Reifenzustands, des Motor- oder Bremsmoments – kann ein Fehler des virtuellen Sensors direkt zu Fehlfunktionen sicherheitskritischer Regelsysteme (ABS, ESC, Lenkhilfe) führen und damit Leib und Leben gefährden.

3 Die Anforderungen der ISO 26262 im Detail

3.1 Determinismus

ISO 26262 Teil 6 fordert für ASIL-relevante Software, dass das Softwareverhalten deterministisch, d. h. für gleiche Eingänge jederzeit identisch und vorhersagbar sein muss [4]. Diese Forderung ist keine formale Spitzfindigkeit: Im Rahmen der Verifikation muss jeder Testfall reproduzierbar sein, Regressionstests müssen stabile Ergebnisse liefern, und

im Falle eines Feldversagens (Field Failure) muss das Verhalten des Systems auf dem Prüfstand reproduziert werden können, um die Fehlerursache zu identifizieren.

Eine deterministische Ausführung setzt voraus, dass:

- der Quellcode keine race conditions oder undefiniertes Verhalten enthält,
- keine zufälligen Elemente (Zufallszahlen, stochastische Sampling-Verfahren) während der Inferenz aktiv sind,
- Fließkommaoperationen streng nach IEEE 754 und in reproduzierbarer Reihenfolge ausgeführt werden.

Während ein voll trainiertes, auf festen Gewichten basierendes KNN bei der Inferenz theoretisch deterministisch ausgeführt werden kann, ist dies in der Praxis mit erheblichen Hürden verbunden. Bereits kleine Unterschiede in der Reihenfolge von Fließkommaoperationen, unterschiedliche Prozessorarchitekturen (FPU-Implementierungen) oder Compiler-optimierungen können zu numerisch unterschiedlichen Ergebnissen führen – ein für die ISO 26262-Verifikation inakzeptabler Zustand [28].

3.2 Anforderungsverfolgbarkeit (Requirements Traceability)

ISO 26262 Teil 6, Abschnitt 5.4 fordert, dass jede Software-Implementierungseinheit auf eine oder mehrere Software-Sicherheitsanforderungen zurückführbar sein muss [4]. Diese bidirektionale Traceability – von der Anforderung zum Code und vom Code zur Anforderung – ist Voraussetzung für:

1. Die Vollständigkeitsnachweise (sind alle Anforderungen implementiert?),
2. die Auswirkungsanalyse bei Änderungen (Change Impact Analysis),
3. den Nachweis, dass kein ungeplanter Funktionsumfang (no unintended functionality) implementiert wurde.

Ein neuronales Netz besteht nach dem Training aus einer Gewichtsmatrix von typischerweise Tausenden bis Millionen numerischer Werte. Es ist prinzipiell nicht möglich, einzelnen Gewichten oder aktivierten Neuronen bestimmte funktionale Anforderungen zuzuordnen [17]. Das Netz als Ganzes *erfüllt* (im Sinne eines black-box-Verhaltens) im günstigsten Fall die Ausgabespezifikation – die innere Struktur ist jedoch von keiner Anforderung getrieben. Dies stellt eine fundamentale Verletzung des Traceability-Prinzips dar.

3.3 Verifikation und Testabdeckung

Für ASIL D-Software schreibt ISO 26262 Teil 6 Tabelle 10 die vollständige MC/DC-Testabdeckung (Modified Condition/Decision Coverage) vor [4]. MC/DC erfordert, dass jede einzelne Bedingung in einem zusammengesetzten booleschen Ausdruck den Ausgabewert unabhängig beeinflusst. Diese Anforderung ist auf Quellcode mit expliziter, implementierter Logik ausgerichtet.

Auf ein neuronales Netz lässt sich MC/DC nicht anwenden: Es gibt weder bedingte Verzweigungen im klassischen Sinne noch logische Ausdrücke, deren Coverage gemessen

werden könnte. Alternative Metriken (Neurons-Coverage, Feature-Space-Coverage) existieren in der Forschung [24], sind jedoch weder in ISO 26262 anerkannt noch in ihrer Aussagekraft bezüglich sicherheitsrelevanter Fehler empirisch belegt.

Darüber hinaus verlangt ISO 26262 die formale Verifikation kritischer Softwareeigenschaften sowie die vollständige Analyse des Datenflussmodells (data flow analysis) und Kontrollflusses [4]. Beide Analysemethoden sind für die Black-Box-Charakteristik neuronaler Netze nicht anwendbar.

3.4 Keine unbeabsichtigte Funktionalität

ISO 26262 verlangt explizit den Nachweis, dass Software keine unbeabsichtigte Funktionalität (no unintended functionality) implementiert [4]. Diese Anforderung soll sicherstellen, dass das System ausschließlich das tut, was spezifiziert wurde – nicht mehr und nicht weniger.

Neuronale Netze lernen ihre internen Repräsentationen völlig autonom aus den Trainingsdaten. Es ist prinzipiell nicht ausgeschlossen, dass das Netz *Artefakte* oder *Korrelationen* aus den Trainingsdaten internalisiert, die keine physikalische oder funktionale Grundlage haben, aber das Verhalten des Netzes für bestimmte Eingangskonstellationen beeinflussen [14]. Da diese internen Repräsentationen nicht einsehbar sind, kann der Nachweis “keine unbeabsichtigte Funktionalität” für ein KNN nicht erbracht werden.

3.5 Änderungsmanagement und Wiederhol-Qualifikation

ISO 26262 Teil 8 regelt das Änderungsmanagement [5]. Bei jeder Änderung der Software muss eine *Change Impact Analysis* durchgeführt werden, die alle betroffenen Anforderungen und Verifikationsmaßnahmen identifiziert. Die Bandbreite der notwendigen Requalifikation wird durch die Auswirkungen der Änderung auf das funktionale Sicherheitskonzept bestimmt.

Bei einem KNN bedeutet selbst eine marginale Änderung des Trainingsdatensatzes (z. B. Hinzufügen weniger neuer Messdaten aus dem Feld) eine vollständige Neu-Parametrierung aller Gewichte über das Gradientenverfahren. Das resultierende Netz ist ein *neues* Modell, dessen Verhalten systematisch von seinem Vorgänger abweichen kann – auch in Bereichen, die scheinbar nicht von den neuen Daten betroffen sind (sog. *catastrophic forgetting* bzw. seine Umkehrung). Eine klassische, änderungsgetriebene Requalifikation ist damit strukturell nicht möglich; de facto muss bei jeder Modell-Aktualisierung eine vollständige Neuqualifikation erfolgen.

3.6 Tool-Qualifikation

ISO 26262 Teil 8, Abschnitt 11 regelt die Qualifikation von Softwareentwicklungswerkzeugen [5]. Der Tool Confidence Level (TCL) bestimmt den erforderlichen Nachweis, dass ein Werkzeug keine unentdeckten Fehler in die sicherheitsrelevante Software einbringt.

Beim Einsatz von KNNs in der Seriensoftware kommen typischerweise neuartige Trainings- und Inferenz-Frameworks (TensorFlow, PyTorch, ONNX Runtime) zum Einsatz, die nicht für den sicherheitskritischen Einsatz nach ISO 26262 qualifiziert sind. Die TCL-Qualifikation dieser Werkzeuge ist mit einem erheblichen, kaum bezifferbaren Aufwand verbunden, da die Werkzeuge selbst komplexe Software mit Millionen von Codezeilen darstellen.

4 Spezifische Defizite neuronaler Netze aus Sicherheitsperspektive

4.1 Das Erklärbarkeitsdefizit (Explainability Gap)

Das wohl grundsätzlichsste Problem neuronaler Netze im Sicherheitskontext ist ihr *Black-Box-Charakter*: Auch wenn Eingaben und Ausgaben eines Netzes bekannt sind, bleibt die innere Entscheidungslogik für den Menschen im Wesentlichen undurchschaubar [35]. Zwar existieren Erklärbarkeitsverfahren wie LIME [16] oder SHAP, diese liefern jedoch lediglich *lokale Approximationen* des Netzwerkverhaltens in der Umgebung eines bestimmten Eingabepunkts – keine vollständige, formal verifizierbare Beschreibung des Gesamtverhaltens.

Lipton [17] weist darauf hin, dass Interpretierbarkeit kein binäres Merkmal ist, sondern ein Spektrum mit unterschiedlichen Qualitäten. Für den Sicherheitsnachweis nach ISO 26262 ist jedoch eine *vollständige* Erklärung des Verhaltens erforderlich – partielle, statistische Erklärungen reichen nicht aus. Ein Sicherheitsprüfer (Safety Assessor) kann auf Basis von LIME- oder SHAP-Erklärungen keine sachgemäße Beurteilung vornehmen.

4.2 Adversarielle Robustheit

Szegedy et al. [15] entdeckten 2014 das Phänomen der *adversariellen Beispiele*: Minimale, für das menschliche Auge unsichtbare Störungen eines Eingangsbildes können ein tiefes neuronales Netz dazu bringen, vollständig falsche Vorhersagen mit hoher Konfidenz zu treffen. Goodfellow et al. [14] zeigten, dass diese Eigenschaft keine Ausnahme, sondern ein strukturelles Merkmal von KNNs ist, das sich aus der hochdimensionalen linearen Natur der erlernten Entscheidungsgrenzen ergibt.

Für sicherheitskritische Sensorapplikationen bedeutet dies: Scheinbar normale, aber durch Rauschen, Sensor-Drift oder Umgebungsveränderungen leicht veränderte Eingangssignale können zu abrupt falschen Schätzwerten führen – ohne dass das System selbst eine erhöhte Unsicherheit meldet. Diese Eigenschaft ist aus sicherheitstechnischer Sicht katastrophal, da sie bedeutet, dass das Versagen des Systems ohne Vorwarnung und ohne erkennbaren auslösenden Defekt eintreten kann.

4.3 Out-of-Distribution-Verhalten

Neuronale Netze sind grundsätzlich darauf ausgelegt, innerhalb der *Verteilung* der Trainingsdaten zuverlässige Schätzungen zu liefern. Außerhalb dieser Verteilung – bei Eingaben, die vom Netz noch nicht gesehen wurden (Out-of-Distribution, OOD) – ist das Verhalten nicht spezifiziert und häufig fehlerhaft [13]. Dies ist äquivalent zum Versagen eines klassischen Softwaremoduls bei undefiniertem Eingangswertebereich, mit dem entscheidenden Unterschied: Während ein klassischer Sicherheits-Software-Entwickler explizit Grenzfälle spezifiziert und absichert (*defensive programming*), bieten KNNs keinerlei Mechanismus, OOD-Situationen zu erkennen oder abzusichern – außer durch aufwendige, nachträglich hinzugefügte OOD-Erkennungsmodule.

Koopman und Fratrik [32] zeigen, dass die praktisch unendliche Vielfalt von OOD-Szenarien in der realen Welt – veränderte Wetterbedingungen, unbekannte Straßenbedingungen, unerwartete Objektkonstellationen – eine vollständige Testabdeckung des Eingangsraums prinzipiell ausschließt.

4.4 Fehlende formale Spezifikation

Klassische sicherheitskritische Software wird gegen eine *formale Spezifikation* entwickelt: Das Verhalten der Software ist für alle relevanten Eingangs- kombinationen eindeutig definiert [19]. Dieses Grundprinzip ist in ISO 26262 fest verankert und bildet die Basis für jeden Verifikationsnachweis.

Bei einem KNN existiert keine solche formale Spezifikation: Das Training maximiert eine Verlustfunktion über einen endlichen Datensatz und erzeugt damit ein Modell, dessen Verhalten außerhalb des Trainingsdatensatzes lediglich durch Generalisierungsannahmen und empirische Tests charakterisiert werden kann. Ein mathematisch vollständiger Nachweis der Korrektheit für den gesamten Eingangsraum ist – abgesehen von kleinen, niedrigdimensionalen Netzen – mit dem Stand der Technik nicht möglich [24].

4.5 Statistische vs. deterministische Korrektheit

Ein zentrales Missverständnis beim Einsatz von KNNs in sicherheitskritischen Systemen ist die implizite Gleichsetzung von *statistischer Genauigkeit* und *sicherheitstechnischer Korrektheit*. Ein KNN, das in 99,9% aller Testfälle korrekte Ergebnisse liefert, zeigt im verbleibenden 0,1% ein undefiniertes Verhalten – und könnte gerade in diesen Randfällen in den kritischsten Fahrsituationen versagen. Die Norm ISO 26262 kennt keine statistischen Fehlerquoten für Softwarefehler (im Unterschied zu Hardware-Ausfallraten); Softwarekorrektheit wird als Ja/Nein-Eigenschaft betrachtet, die durch formale Verifikation und Testabdeckung nachzuweisen ist [4].

Varshney und Alemzadeh [22] verdeutlichen diesen Unterschied: „In safety-critical machine learning applications, one misbehavior may be far more costly than one thousand correct behaviors.“ Diese Asymmetrie ist im Sicherheitsdenken von ISO 26262 fundamental – und mit dem statistischen Qualitätsbegriff von KNNs unvereinbar.

4.6 Reproduzierbares Schadensversagen (Fault Reproduction)

Ein wesentliches Element der funktionalen Sicherheitsentwicklung ist die Fähigkeit, im Feldversagensfall das fehlerhafte Verhalten reproduzieren und analysieren zu können (*fault reproduction*), um die Ursache zu identifizieren und durch Softwarekorrektur zu beseitigen. Bei klassischer Software ist dies möglich, da der Code deterministisch und vollständig überprüfbar ist.

Bei einem KNN-basierten virtuellen Sensor im Feld kann ein Versagen durch nichtlineare Wechselwirkungen multidimensionaler Eingangssignale verursacht sein, die im Laborumfeld nicht reproduzierbar sind. Selbst wenn der Eingangsdatenvektor des Versagenszeitpunkts vollständig rekonstruiert werden kann, ist eine kausale Analyse – warum hat das Netz genau diesen falschen Wert ausgegeben? – nicht möglich. Dies untergräbt ein Kernprinzip des Sicherheitsprozesses, nämlich das kontinuierliche Lernen aus Feldversagensfällen zur Verbesserung der Systemsicherheit [21].

4.7 Zertifizierungsnachweis und Safety Case

ISO 26262 Teil 2 verlangt die Erstellung eines *Safety Cases* – eines strukturierten Arguments, das auf Basis von Evidenz nachweist, dass das System ausreichend sicher ist [2]. Dieser Safety Case muss von einem unabhängigen Sicherheitsprüfer (Functional Safety Assessor) bewertet und bestätigt werden.

Für ein KNN-basiertes System lässt sich kein vollständiger Safety Case erstellen: Die notwendige Evidenz – insbesondere der Nachweis der formalen Verifikation und der vollständigen Anforderungsabdeckung – kann für KNNs strukturell nicht erbracht werden [10]. Bestehende Rahmenwerke wie AMLAS (Assurance of Machine Learning in Autonomous Systems) [10] stellen fest, dass für ML-basierte Systeme neue, noch nicht standardisierte Nachweisformen erforderlich sind – womit sie implizit einräumen, dass mit den Mitteln der ISO 26262 allein kein vollständiger Nachweis möglich ist.

5 Zentrale Argumente gegen den Einsatz

Aus den vorstehenden Analysen lassen sich die folgenden zentralen Argumente destillieren, die konsequent gegen den Einsatz von neuronalen Netzen in ISO 26262-konformer, sicherheitskritischer ECU-Software sprechen:

5.1 Argument 1: Strukturelle Unvereinbarkeit mit dem Verifikationsparadigma

ISO 26262 basiert auf einem *konstruktiven Verifikationsparadigma*: Software wird anhand expliziter Anforderungen entwickelt und formal gegen diese Anforderungen verifiziert. Neuronale Netze sind das Produkt eines *empirischen Optimierungsparadigmas*: Sie entstehen durch Minimierung einer Verlustfunktion über einen endlichen Datensatz. Diese beiden Paradigmen sind fundamental unverträglich. Es handelt sich nicht um eine Lücke, die durch höheren Aufwand oder bessere Werkzeuge geschlossen werden kann, sondern um eine epistemologische Grundverschiedenheit: Sicherheitsnachweis beruht auf *Wissen*, KNN-Training erzeugt *Empirie*. Wissen ist übertragbar, begründbar und vollständig; Empirie ist stets begrenzt, stichprobenabhängig und niemals vollständig.

5.2 Argument 2: Vertrauenswürdigkeit erfordert Erklärbarkeit

Vertrauenswürdigkeit (*trustworthiness*) ist nach Avizienis et al. [20] eine zusammengesetzte Eigenschaft, die Zuverlässigkeit (*reliability*), Verfügbarkeit (*availability*), Wartbarkeit (*maintainability*) und Sicherheit (*safety*) umfasst. Für sicherheitskritische Systeme setzt Vertrauenswürdigkeit voraus, dass das System nicht nur in der Vergangenheit korrekt funktioniert hat, sondern dass *begründet werden kann*, warum es in Zukunft korrekt funktionieren wird – insbesondere auch in Situationen, die noch nicht getestet wurden.

Neuronale Netze können diesen Nachweis nicht liefern: Ihr Erfolg in Testszenarien belegt die vergangene Leistung, nicht die künftige Korrektheit in unbekannten Situationen. Wing [38] formuliert für vertrauenswürdige KI-Systeme explizit die Anforderungen *fair, robust, explainable, private, safe and secure* – und stellt fest, dass kein heutiges KNN diese Anforderungen vollständig erfüllt. Im Kontext sicherheitskritischer Systeme ist fehlende Vertrauenswürdigkeit kein theoretisches Problem, sondern ein rechtlich relevanter Haftungsausschlussgrund.

5.3 Argument 3: Determinismusdefizienz als dauerhaftes Strukturproblem

Der Determinismusbegriff in ISO 26262 ist nicht auf das laufzeitliche Ausführungsverhalten beschränkt, sondern umfasst auch die *Vorhersagbarkeit des Verhaltens über den gesamten Betriebsbereich*. Ein System, dessen Verhalten vollständig bekannt und berechenbar ist, ist deterministisch; ein System, dessen Verhalten für bestimmte Eingaben unbekannt oder unvorhersehbar ist, ist es nicht. Da für KNNs das Verhalten außerhalb der Trainingsverteilung undefiniert ist und das exakte Verhalten für beliebige Eingaben nicht vorausberechnet werden kann, sind KNNs im sicherheitstechnisch relevanten Sinne nicht deterministisch [28].

5.4 Argument 4: Datenqualität als neue, unkontrollierbare Fehlerquelle

Klassische sicherheitskritische Software enthält keine externe Abhängigkeit zu einem Datensatz während der Funktionsausführung. Das Verhalten der Software ist vollständig durch den Quellcode bestimmt, der versioniert, auditiert und in seiner Vollständigkeit den Entwicklernormen entsprechend spezifiziert ist [37].

KNN-Modelle hingegen repräsentieren das implizite Wissen des Trainingsdatensatzes. Die Qualität dieses Datensatzes – seine Vollständigkeit, seine Repräsentativität, seine Fehlerfreiheit – hat direkten Einfluss auf das Verhalten des trainierten Netzes im Feld. ISO 26262 enthält keine Methodik für die Qualitätssicherung von Trainingsdaten, da dieses Konzept im Entwicklungszeitraum der Norm nicht relevant war. Damit entsteht eine neue Klasse von Fehlerquellen – *Datenfehler* – die außerhalb des normativen Rahmens liegen und damit unkontrolliert bleiben [36]. Fehlerhafte, veraltete oder nicht-repräsentative Trainingsdaten können systematic errors im Modell erzeugen, die mit keinem der in ISO 26262 vorgeschriebenen Verifikationsverfahren aufgedeckt werden können.

5.5 Argument 5: Systemische Überschaubarkeit

ISO 26262 verlangt nicht nur die Sicherheit einzelner Komponenten, sondern die Überschaubarkeit des Gesamtsystems (*system comprehensibility*), die Voraussetzung für eine korrekte und vollständige Sicherheitsanalyse (FMEA, FTA) ist [6]. Ein System, das ein KNN enthält, dessen innere Funktionsweise nicht vollständig durchleuchtet werden kann, ist per definitionem nicht vollständig überschaubar.

Konsequenz: Eine FMEA (Fehlermöglichkeits- und Einflussanalyse) für ein KNN-Modul kann keine vollständige Fehlerliste erstellen, da die Fehlermodi eines Netzes – welche Eingangskonstellationen führen zu welchen Fehl Ausgaben? – nicht a priori spezifizierbar sind. Damit ist die Vollständigkeit jeder Sicherheitsanalyse, die KNN-Komponenten enthält, grundlegend in Frage gestellt.

5.6 Argument 6: Haftungs- und Nachweisrechtliche Implikationen

In Deutschland und der EU unterstehen Fahrzeuge dem Produkthaftungsrecht (ProdHaftG, EU-Produkthaftungsrichtlinie 2024/2853). Im Falle eines Schadensersatzanspruchs muss der Hersteller nachweisen, dass das Fahrzeug *alle zum Zeitpunkt des Inverkehrbringens*

relevanten Sicherheitsstandards erfüllt hat. ISO 26262 ist der maßgebliche Industriestandard und wird von Typgenehmigungsbehörden als Referenz herangezogen.

Kann ein Hersteller die Normkonformität seines KNN-basierten virtuellen Sensors nicht lückenlos nachweisen – und dieser Nachweis ist, wie in den vorstehenden Abschnitten gezeigt, nur partiell möglich –, so trägt er ein erhebliches Haftungsrisiko. Im schlimmsten Fall – einem durch den KNN-Ausfall verursachten Personenschaden – ist der fehlende Sicherheitsnachweis als Indiz für fahrlässige Konstruktion zu werten. Dieses Risiko ist in der öffentlichen und industriellen Diskussion bislang unterbewertet.

5.7 Argument 7: Zertifizierungsrisiko bei Typgenehmigung

Fahrzeuge, die auf europäischen Straßen betrieben werden, benötigen eine Typgenehmigung, die zunehmend die Einhaltung funktionaler Sicherheitsstandards voraussetzt (UNECE WP.29, ALKS-Verordnung). Typgenehmigungsbehörden wie das Kraftfahrtbundesamt (KBA) oder die britische DVSA bewerten zunehmend KI-basierte Systeme, verfügen jedoch noch über keine konsolidierten Leitfäden für deren Bewertung. Die resultierende Unsicherheit bedeutet: Ein Fahrzeughersteller, der KNNs in ASIL-relevanten Systemen einsetzt, muss mit längeren, teureren und unsichereren Typgenehmigungsverfahren rechnen – und läuft Gefahr, nach Markteinführung mit Nachrüstungsanforderungen konfrontiert zu werden, wenn die Behörden ihre Bewertungspraxis konsolidieren.

6 Kritische Auseinandersetzung

6.1 ASIL-Dekomposition und Monitoring-Architektur

Das am häufigsten vorgebrachte Argument für die Verwendbarkeit von KNNs in sicherheitskritischen Systemen ist die *ASIL-Dekomposition*: Das KNN wird auf QM oder ASIL B eingestuft und durch einen deterministischen, ASIL D-qualifizierten Monitor überwacht, der die Ausgabe des KNN auf Plausibilität prüft und im Fehlerfall auf einen sicheren Zustand umschaltet.

Dieser Ansatz ist prinzipiell legitim und in ISO 26262 vorgesehen [6]. Er hat jedoch entscheidende Grenzen:

1. **Monitor-Vollständigkeit:** Der Monitor kann nur Fehler erkennen, die er zu erkennen in der Lage ist. Für die Spezifikation des Monitors müssen die möglichen Fehlmödi des KNN bekannt sein – was, wie in section 5.5 gezeigt, gerade nicht der Fall ist. Ein Monitor, dessen Fehlermodell unvollständig ist, bietet keine vollständige Sicherheitsgarantie.
2. **Gemeinsam-Ursachen-Ausfall (CCF):** Wenn KNN und Monitor beide auf denselben Eingangsdaten arbeiten und das KNN durch adversarielle oder OOD-Eingaben gestört wird, können dieselben Eingaben auch den Monitor täuschen, sofern dieser kein völlig unabhängiges Funktionsprinzip verwendet.
3. **Funktionale Degradation:** Ein Monitoring-basiertes System degradiert den KNN-Ansatz faktisch zum Hilfssystem mit eingeschränktem ASIL. Wenn die eigentliche Sicherheit ausschließlich durch den Monitor gewährleistet wird, stellt sich die Frage, welchen Merkmalsvorteil das KNN gegenüber einem klassischen, deterministischen Schätzer noch bietet.

6.2 ISO/PAS 8800 und neue Normen adressieren das Problem

Die 2024 veröffentlichte ISO/PAS 8800 *Road Vehicles – Safety and Artificial Intelligence* [8] wird als normative Lösung für die Integration von KI in sicherheitskritische Fahrzeugsysteme beworben. In der Tat adressiert ISO/PAS 8800 viele der in dieser Arbeit genannten Probleme und definiert ML-spezifische Work Products, Datenqualitätsanforderungen und ODD-Spezifikationen.

Allerdings ist kritisch anzumerken:

1. ISO/PAS 8800 ist ein *Publicly Available Specification* (PAS) – eine vorläufige Norm, kein vollwertiger ISO-Standard. Sie hat noch nicht den Reifegrad einer mehrfach durchlaufenen Konsensentscheidung.
2. Die Norm definiert Prozessanforderungen, löst jedoch nicht die *technischen* Grundprobleme – sie spezifiziert lediglich, wie der Nachweis organisiert werden soll. Die Frage, ob ein statistisches Modell wirklich sicher agiert, wird nicht durch bessere Prozessorganisation beantwortet.
3. ISO/PAS 8800 muss im Zusammenspiel mit ISO 26262 gelesen werden und *ersetzt* diese nicht. Soweit ISO 26262 Anforderungen stellt, die KNNs strukturell nicht erfüllen können, ändert ISO/PAS 8800 daran nichts.

6.3 MIL/SIL/PIL-Tests belegen die Sicherheit

Toolanbieter wie dSPACE (TargetLink) betonen die MIL/SIL/PIL-Testkette als Nachweis, dass das KNN auf der Zielhardware genauso funktioniert wie im Modell. Dies ist ein wichtiger, aber häufig missdeuteter Beitrag:

MIL/SIL/PIL-Tests belegen *Implementierungskonsistenz* – das heißt, das trainierte Modell wird durch den Codegenerierungsprozess nicht verfälscht. Sie sagen jedoch *nichts* über die Korrektheit des trainierten Modells selbst aus. Das korrekte Deployment eines fehlerhaften Modells ist kein Sicherheitsgewinn.

6.4 Akzeptiertes Restrisiko (Acceptable Residual Risk)

Ein pragmatisches Argument lautet: ISO 26262 verlangt nicht null Fehler, sondern nur eine Reduzierung des Risikos auf ein akzeptables Maß (*ALARP: As Low As Reasonably Practicable*). Neuronale Netze als solche seien akzeptabel, solange das Gesamtrisiko unterhalb des Schwellenwerts bleibt.

Dieses Argument erkennt, dass ALARP unter ISO 26262 keine statistische Abwägung von Fehlerraten ist, sondern einen *Entwicklungsprozessnachweis* erfordert: Das Risiko gilt als ausreichend reduziert, wenn alle normativen Anforderungen an den Entwicklungsprozess erfüllt wurden. Da diese Anforderungen für KNNs nicht vollständig erfüllt werden können, kann ALARP nicht beansprucht werden – unabhängig von der empirisch gemessenen Fehlerrate des Netzes.

7 Sichere Alternativen zu KNN-basierten Sensorlösungen

Die Ablehnung von KNNs für sicherheitskritische Funktionen schließt den Einsatz moderner, leistungsfähiger Technik nicht aus. Folgende Alternativen sind mit ISO 26262 vereinbar und bieten für viele Anwendungsbereiche gleichwertige oder überlegene Lösungen:

7.1 Modellbasierte Beobachter und Kalman-Filter

Für die Schätzung physikalischer Größen aus Messdaten sind *Kalman-Filter* und deren nichtlineare Erweiterungen (Extended Kalman Filter, Unscented Kalman Filter) seit Jahrzehnten der Stand der Technik in sicherheitskritischen Systemen [21]. Sie basieren auf einem expliziten physikalischen Systemmodell, sind linear in den Zustandsgrößen (bzw. lokal linearisiert), haben eine bekannte, analytisch berechenbare Fehlerkovarianz und ermöglichen eine vollständige formale Analyse. Die Anforderungsverfolgbarkeit ist lückenlos: jeder Parameter des Filters leitet sich aus dem zugrundeliegenden physikalischen Modell ab.

7.2 Polynomiale Approximationen und Look-up-Tabellen

Für nichtlineare Kennlinien und Kennfelder – häufige Anwendungsfälle für virtuelle Sensoren – sind stufenweise polynomiale Approximationen und Look-up-Tabellen mit Interpolation eine bewährte, sicherheitstechnisch unproblematische Lösung. Das Verhalten ist vollständig durch explizite Werte definiert, überprüfbar und formal verifizierbar.

7.3 Physikalisch-motivierte Modelle

In vielen Fällen, in denen ein neuronales Netz als virtueller Sensor vorgeschlagen wird, liegt hinreichendes physikalisches Wissen vor, um ein parametrisches Modell abzuleiten. Der Einsatz von KNNs wird dann häufig mit geringerem Modellierungsaufwand begründet. Dieser Aufwand ist jedoch eine Investition in Sicherheit und Nachvollziehbarkeit – er ist im Sicherheitsentwicklungsprozess nicht wegoptimierbar.

7.4 Fuzzy-Logik und Expertensysteme

Für qualitative, wissensbasierte Entscheidungsfunktionen boten Fuzzy-Logik-Systeme und Expertensysteme schon lange erklärbare, formal analysierbare Alternativen zu KNNs, die mit ISO 26262 vereinbar sind [31]. Sie sind in eingebetteten Systemen effizient implementierbar und bieten eine höhere Erklärbarkeit.

7.5 Formale Methoden und Model Checking

Für die Verifikation kritischer Systemeigenschaften – Sicherheitsinvarianten, zeitliche Eigenschaften – stehen formale Methoden (Model Checking, Theorem Proving) zur Verfügung, die in ISO 26262 ASIL D explizit empfohlen werden [4]. Diese Methoden sind auf klassisch programmierten Code gut anwendbar und liefern mathematisch gesicherte Nachweise.

8 Diskussion: Kumuliertes Defizit und Normative Lücke

Die in dieser Arbeit analysierten Probleme sind keine isolierten technischen Einzelprobleme, die durch spezifische Abhilfemaßnahmen behebbar wären. Sie repräsentieren ein *kumuliertes, strukturelles Defizit*, das aus der fundamentalen Unvereinbarkeit zweier Designphilosophien resultiert:

Die sicherheitstechnische Entwicklungsphilosophie der ISO 26262 beruht auf dem Prinzip: *Alles, was nicht explizit spezifiziert und verifiziert wurde, ist als unsicher zu betrachten*. Die maschinelle Lernphilosophie neuronaler Netze beruht auf dem Prinzip: *Was empirisch gut genug funktioniert, kann eingesetzt werden*. Diese beiden Prinzipien sind nicht kompatibel. Sie können durch keinen technischen Trick oder normativen Workaround in Übereinstimmung gebracht werden.

8.1 Die normative Lücke

Die Gemeinschaft der Sicherheitsnormierer erkennt dieses Dilemma zunehmend an. ISO 21448 (SOTIF) [7] adressiert Versagen durch unzureichende Spezifikation oder Leistung – deckt aber nicht die strukturellen Verifikationsdefizite von KNNs ab. ISO/PAS 8800 [8] definiert ML-spezifische Prozessanforderungen, ersetzt jedoch nicht die formalen Verifikationsanforderungen der ISO 26262. AMLAS [10] bietet einen Argumentationsrahmen für ML-Safety-Cases, räumt aber selbst ein, dass wesentliche Nachweisformen noch nicht standardisiert sind.

In Summe besteht eine *normative Lücke*: Es gibt keinen anerkannten, vollständigen Sicherheitsnachweis für KNN-Komponenten in ASIL-relevanten Steuergerätefunktionen. Diese Lücke schließt Werkzeugketten (TargetLink, ONNX-Deployment) nicht: Das korrekte Deployment eines Modells bedeutet nicht dessen Sicherheitsnachweis.

8.2 Das Präzedenzargument der Luft- und Raumfahrt

Interessant ist der Blick auf die Luft- und Raumfahrt, wo funktionale Sicherheit ähnlich streng gehandhabt wird wie im Automobil (DO-178C als Pendant zu ISO 26262). Das Neural Network Certification Advisory Circular der FAA (FAA-AC) hat explizit festgestellt, dass neuronale Netze für sicherheitskritische Flugsteuerungssysteme nicht zertifizierbar sind und begründet dies mit denselben Argumenten wie diese Arbeit: fehlende Erklärbarkeit, nicht anwendbare Coverage-Metriken und unvollständige Fehlermodelle. Erst in jüngster Zeit (2023-2024) werden erste Pilotprojekte unter eng umrissenen Einschränkungen und mit aufwendigen Kompensationsmaßnahmen zugelassen – und dies nach Jahren intensiver Standardisierungsarbeit, die im Automobil noch nicht abgeschlossen ist.

8.3 Das Tempo des technologischen Wandels vs. normative Reife

Ein oft unterschlagener Aspekt der Diskussion ist die zeitliche Dimension: KI und Deep Learning entwickeln sich in einem Tempo, das weit über die Entwicklungszyklen von Sicherheitsnormen hinausgeht. ISO 26262:2018 wurde nach einem Jahrzehnt internationaler Konsensfindung veröffentlicht. ISO/PAS 8800:2024 ist noch nicht in die ISO 26262 integriert. Bis ein konsolidiertes, internationales Regelwerk für KI in sicherheitskritischen Automobilsystemen existiert, das alle hier diskutierten Defizite adressiert, werden weitere Jahre

vergehen – Jahre, in denen Fahrzeuge mit KNN-basierten Funktionen bereits auf den Straßen fahren könnten.

Die Verantwortung, in dieser Unsicherheitsphase konservativ zu handeln – also KNNs aus sicherheitskritischen Funktionen fernzuhalten oder auf gut begründete, eng beschränkte Ausnahmen zu reduzieren –, liegt bei den Fahrzeugherstellern und Tier-1-Zulieferern. Das Argument des Wettbewerbsdrucks ist dabei kein Sicherheitsargument.

9 Fazit und Empfehlungen

Die vorliegende Arbeit hat eine systematische Analyse der Vereinbarkeit von neuronalen Netzen mit den Anforderungen des Sicherheitsstandards ISO 26262 vorgenommen. Das Ergebnis ist eindeutig: Neuronale Netze in ihrer gegenwärtigen Form erfüllen die Kernanforderungen der ISO 26262 an ASIL-relevante Software strukturell nicht. Die identifizierten Defizite betreffen:

- fehlenden Determinismus im sicherheitstechnisch relevanten Sinne,
- unmögliche Anforderungsverfolgbarkeit innerhalb der Netzwerkstruktur,
- Nicht-Anwendbarkeit der vorgeschriebenen Verifikationsverfahren (MC/DC),
- unbeweisbare Abwesenheit unbeabsichtigter Funktionalität,
- strukturell unkontrolliertes OOD- und adversarielle Verhalten,
- unvollständige Fehlermodelle und damit unvollständige Sicherheitsanalysen,
- fehlende normative und werkzeugmäßige Grundlage für vollständige Safety Cases.

Diese Defizite können durch systemarchitektonische Kompensationsmaßnahmen (Monitoring, ASIL-Dekomposition) teilweise abgemildert werden, verschwinden jedoch nicht. Die übergeordnete epistemische Grenze bleibt: Ein statistisch erlerntes Modell kann nie mit derselben Sicherheitsevidenz versehen werden wie ein formal spezifiziertes, deterministisch implementiertes und vollständig verifiziertes Softwaremodul.

Empfehlungen:

1. **Keine KNN-Nutzung in ASIL C/D-Funktionen:** Für sicherheitskritische Funktionen mit ASIL C- oder ASIL D-Einstufung sollten ausschließlich klassische, formal verifizierbare Algorithmen eingesetzt werden, bis ein verabschiedeter, vollständiger normativer Rahmen für KI in sicherheitskritischen Systemen vorliegt.
2. **Beschränkung auf QM / unkritische Hilfsfunktionen:** KNNs können sinnvoll in der Vorverarbeitung von Rohdaten, in der Kalibrierung von Diagnosealgorithmen oder in der ASIL-QM-Komfortfunktionalität eingesetzt werden, wo keine direkten Sicherheitsziele betroffen sind.
3. **Normative Grundlage abwarten und mitgestalten:** Fahrzeughersteller und Zulieferer sollten aktiv an der Weiterentwicklung von ISO/PAS 8800, ISO 21448 und verwandten Normen mitwirken, anstatt bestehende normative Lücken als implizite Erlaubnis zu interpretieren.

4. **Investition in erklärbare und verifizierbare KI (XAI):** Die Forschung zu formal verifizierbaren, erklärbaren KI-Systemen (z. B. neurosymbolische Systeme, formale Verifikation kleiner Netze) sollte intensiviert und mit der Normarbeit verzahnt werden, bevor ein breiter Einsatz in ASIL-relevanten Funktionen erfolgt.
5. **Werkzeugkettenqualifikation:** Wer KNNs trotz der genannten Einschränkungen einsetzt, muss die vollständige TCL-Qualifikation der verwendeten KI-Frameworks sicherstellen – ein Aufwand, der in der Praxis häufig unterschätzt wird und in die Kosten-Nutzen-Bewertung einzubeziehen ist.

Diese Arbeit tritt nicht für eine pauschale Ablehnung von KI im Fahrzeug ein. In zahlreichen Anwendungsgebieten – Komfortfunktionen, Infotainment, lernende Fahrerassistenz ohne direkten Sicherheitsbezug – kann und soll KI ihr Potenzial entfalten. Für sicherheitskritische Steuergerätefunktionen aber gilt: Die Last des Sicherheitsnachweises liegt beim Entwickler, nicht beim Prüfer. Solange dieser Nachweis für neuronale Netze nicht vollständig und konform zu ISO 26262 erbracht werden kann, verbietet sich ihr Einsatz in solchen Funktionen aus Gründen der technischen Vernunft, der Rechtssicherheit und – zuvorderst – des Schutzes von Menschenleben.

Literatur

- [1] International Organization for Standardization (ISO): *ISO 26262-1: Road vehicles – Functional safety – Part 1: Vocabulary*. 2. Ausgabe. Genf: ISO, 2018.
- [2] International Organization for Standardization (ISO): *ISO 26262-2: Road vehicles – Functional safety – Part 2: Management of functional safety*. 2. Ausgabe. Genf: ISO, 2018.
- [3] International Organization for Standardization (ISO): *ISO 26262-4: Road vehicles – Functional safety – Part 4: Product development at the system level*. 2. Ausgabe. Genf: ISO, 2018.
- [4] International Organization for Standardization (ISO): *ISO 26262-6: Road vehicles – Functional safety – Part 6: Product development at the software level*. 2. Ausgabe. Genf: ISO, 2018.
- [5] International Organization for Standardization (ISO): *ISO 26262-8: Road vehicles – Functional safety – Part 8: Supporting processes*. 2. Ausgabe. Genf: ISO, 2018.
- [6] International Organization for Standardization (ISO): *ISO 26262-9: Road vehicles – Functional safety – Part 9: ASIL-oriented and safety-oriented analyses*. 2. Ausgabe. Genf: ISO, 2018.
- [7] International Organization for Standardization (ISO): *ISO 21448: Road vehicles – Safety of the intended functionality (SOTIF)*. Genf: ISO, 2022.
- [8] International Organization for Standardization (ISO): *ISO/PAS 8800: Road vehicles – Safety and artificial intelligence*. Genf: ISO, 2024.

- [9] International Electrotechnical Commission (IEC): *IEC 61508: Functional Safety of Electrical/Electronic/Programmable Electronic Safety-related Systems*. 2. Ausgabe. Genf: IEC, 2010.
- [10] Hawkins, R.; Paterson, C.; Picardi, C.; Jia, Y.; Calinescu, R.; Habli, I.: *AMLAS: A Methodology for the Assurance of Machine Learning in Autonomous Systems*. University of York, 2021. arXiv:2102.10020.
- [11] Salay, R.; Khastgir, S.; Czarnecki, K.: An Analysis of ISO 26262: Using Machine Learning Safely in Automotive Software. *arXiv preprint arXiv:1709.02435*, 2018.
- [12] Koopman, P.; Wagner, M.: Challenges in Autonomous Vehicle Testing and Validation. In: *SAE World Congress*. SAE International, 2016.
- [13] Amodei, D.; Olah, C.; Steinhardt, J.; Christiano, P.; Schulman, J.; Mané, D.: Concrete Problems in AI Safety. *arXiv preprint arXiv:1606.06565*, 2016.
- [14] Goodfellow, I.; Shlens, J.; Szegedy, C.: Explaining and Harnessing Adversarial Examples. In: *International Conference on Learning Representations (ICLR)*, 2015.
- [15] Szegedy, C.; Zaremba, W.; Sutskever, I.; Bruna, J.; Erhan, D.; Goodfellow, I.; Fergus, R.: Intriguing Properties of Neural Networks. In: *International Conference on Learning Representations (ICLR)*, 2014.
- [16] Ribeiro, M. T.; Singh, S.; Guestrin, C.: “Why Should I Trust You?”: Explaining the Predictions of Any Classifier. In: *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, S. 1135–1144, 2016.
- [17] Lipton, Z. C.: The Mythos of Model Interpretability. *Queue*, 16(3), S. 31–57, 2018.
- [18] Marcus, G.: Deep Learning: A Critical Appraisal. *arXiv preprint arXiv:1801.00631*, 2018.
- [19] Seshia, S. A.; Sadigh, D.; Sastry, S. S.: Formal Specification for Deep Neural Networks. *arXiv preprint arXiv:1802.03023*, 2018.
- [20] Avizienis, A.; Laprie, J.-C.; Randell, B.; Landwehr, C.: Basic Concepts and Taxonomy of Dependable and Secure Computing. *IEEE Transactions on Dependable and Secure Computing*, 1(1), S. 11–33, 2004.
- [21] Leveson, N. G.: *Engineering a Safer World: Systems Thinking Applied to Safety*. Cambridge, MA: MIT Press, 2011.
- [22] Varshney, K. R.; Alemzadeh, H.: On the Safety of Machine Learning: Cyber-Physical Systems, Decision Sciences, and Data Products. *Big Data*, 5(3), S. 246–255, 2017.
- [23] Burton, S.; Gauerhof, L.; Heinzemann, C.: Making the Case for Safety of Machine Learning in Highly Automated Driving. In: *Computer Safety, Reliability, and Security (SAFECOMP)*. Springer, 2017.
- [24] Huang, X.; Kwiatkowska, M.; Wang, S.; Wu, M.: Safety Verification of Deep Neural Networks. In: *Computer Aided Verification (CAV)*, S. 3–29, 2017.

- [25] Rumelhart, D. E.; Hinton, G. E.; Williams, R. J.: Learning Representations by Back-propagating Errors. *Nature*, 323, S. 533–536, 1986.
- [26] LeCun, Y.; Bengio, Y.; Hinton, G.: Deep Learning. *Nature*, 521, S. 436–444, 2015.
- [27] Goodfellow, I.; Bengio, Y.; Courville, A.: *Deep Learning*. Cambridge, MA: MIT Press, 2016.
- [28] Dreossi, T.; Donze, A.; Seshia, S. A.: Compositional Falsification of Cyber-Physical Systems with Machine Learning Components. *Journal of Automated Reasoning*, 63, S. 1031–1053, 2019.
- [29] High-Level Expert Group on AI (Europäische Kommission): *Ethics Guidelines for Trustworthy AI*. Brüssel: Europäische Kommission, 2019.
- [30] Zhao, X.; Nguyen, H.-D.; Bhatt, D.; Zulkernine, M.: Assessing Safety of Machine Learning for Use in Safety-Critical Domains. *IEEE Transactions on Reliability*, 69(3), S. 1036–1056, 2020.
- [31] Kurd, Z.; Kelly, T.: Establishing Safety Criteria for Artificial Neural Networks. In: *International Conference on Knowledge-Based Intelligent Information and Engineering Systems (KES)*. Springer, 2003.
- [32] Koopman, P.; Fratrick, F.: How Many Operational Design Domains, Objects, and Events? In: *Safety and Artificial Intelligence Workshop (AAAI)*, 2019.
- [33] Stocco, A.; Weiss, M.; Calzana, M.; Tonella, P.: Misbehaviour Prediction for Autonomous Driving Systems. In: *42nd International Conference on Software Engineering (ICSE)*, 2020.
- [34] Pfeifer, H.; Herber, P.: Challenges for Assuring AI-Based Safety Functions in Compliance with ISO 26262. *Proceedings of the 9th European Congress on Embedded Real Time Software and Systems (ERTS)*, 2021.
- [35] Doshi-Velez, F.; Kim, B.: Towards a Rigorous Science of Interpretable Machine Learning. *arXiv preprint arXiv:1702.08608*, 2017.
- [36] Gauerhof, L.; Munk, P.; Burton, S.: Structuring Validation Targets of a Machine Learning Function Applied to Automated Driving. In: *Computer Safety, Reliability, and Security (SAFECOMP)*. Springer, 2018.
- [37] Sommerville, I.: *Software Engineering*. 10. Ausgabe. Harlow, UK: Pearson, 2016.
- [38] Wing, J. M.: Trustworthy AI. *Communications of the ACM*, 64(10), S. 64–71, 2021.
- [39] Tonella, P.: When Testing AI Is (Not) Different. *arXiv preprint arXiv:2202.10524*, 2022.
- [40] Myllyaho, L.; Raatikainen, M.; Männistö, T.; Leppänen, V.; Honkola, J.: Systematic Literature Review of Validation Methods for AI Systems. *Journal of Systems and Software*, 181, 2021.