

Wahrscheinlichkeitsverteilung und Laufzeitanalyse des Subgraph-SAT-Solvers

Stephan Epp

10. Juli 2026

Abstract

Diese Arbeit analysiert die Veränderung der Wahrscheinlichkeitsverteilung bei der Lösung von SAT-Problemen mittels des Subgraph-Algorithmus. Wir zeigen formal, dass sich die erwartete Laufzeit über den Wahrscheinlichkeitsraum hinweg systematisch verschiebt: Während die ersten Versuche mit logarithmischer Laufzeit erwartet werden, konvergiert die durchschnittliche Komplexität mit zunehmender Anzahl von Formeln gegen die Worst-Case-Komplexität $O(n^3)$. Wir beweisen diese Verschiebung durch formale Grenzwertanalyse, stochastische Ungleichungen und empirische Validierung mittels Simulationen. Des Weiteren zeigen wir, wie das Logarithmische Belegungsverfahren (LBV) diese Wahrscheinlichkeitsverschiebung optimal ausnutzen kann, um exponentielle Verbesserungen zu erzielen. Wir entwickeln auch eine neue Metaverteilungstheorie, die Wahrscheinlichkeitsverteilungen von Wahrscheinlichkeitsverteilungen formal beschreibt.

Inhaltsverzeichnis

1	Einführung	2
1.1	Motivation	2
1.2	Forschungsfragen	3
2	Wahrscheinlichkeitsverteilungen	
	von Wahrscheinlichkeitsverteilungen	3
2.1	Grundlegender mathematischer Rahmen	3
2.2	Formale Konsequenzen der Metaverteilung	4
2.3	Information-Theoretische Konsequenzen	4
2.4	Anwendung auf SAT-Problem	4
3	Grundlagen und Definitionen	5
3.1	SAT-Probleme und die Kombinationspyramide	5
3.2	Wahrscheinlichkeitsverteilung	5
4	Theoretische Analyse der	
	Wahrscheinlichkeitsverschiebung	6
4.1	Phase 1: Frühe Versuche mit logarithmischer Erwartung	6
4.2	Phase 2: Mittlere Phase mit Übergang	6
4.3	Phase 3: Späte Phase mit Annäherung an Worst-Case	7

5	Formale Laufzeitanalyse	8
5.1	Dichtefunktion der Wahrscheinlichkeitsverteilung	8
5.2	Konvergenzgeschwindigkeit	8
6	Empirische Validierung durch Simulation	8
6.1	Experimentelle Konfiguration	8
6.2	Ergebnisse der Simulation	9
6.3	Interpretation der Resultate	9
7	Praktische Konsequenzen	9
7.1	Heuristische Optimization	9
7.2	Grenzen der Analyse	9
8	Visualisierung der Wahrscheinlichkeitsverschiebung	10
9	Das Logarithmische Belegungsverfahren	11
9.1	Integration des LBV in die Kombinationspyramide	11
9.2	Wahrscheinlichkeitsanalyse des LBV	12
9.3	Komplementarität von LBV und Wahrscheinlichkeitsverteilung	12
10	Ausblick	13
10.1	Theoretische Erweiterungen	13
10.1.1	Verallgemeinerung auf andere Solver-Klassen	13
10.1.2	Mathematische Fundierung der Metaverteilungstheorie	13
10.1.3	Verbindung zur Komplexitätstheorie	14
10.2	Praktische Anwendungen und Implementierungen	14
10.2.1	SAT-basierte Verifikation	14
10.2.2	Constraint Satisfaction und Optimierung	14
10.2.3	Maschinelles Lernen und Algorithmen-Auswahl	14
10.3	Offene Fragen und künftige Forschung	15
11	Fazit	15
11.1	Zusammenfassung der Hauptergebnisse	15
11.1.1	Die Wahrscheinlichkeitsverschiebungsphänomen	15
11.1.2	Metaverteilungstheorie	15
11.1.3	Logarithmisches Belegungsverfahren	16
11.2	Wissenschaftliche Bedeutung	16
11.3	Abschließende Bemerkung	16

1 Einführung

Das Entscheidungsproblem oder SAT teilt sich an der Kombinationspyramide in drei Fälle sicher für die ersten Versuche auf. Mit Wahrscheinlichkeit $1/3$ nach links, mit Wahrscheinlichkeit $1/3$ nach rechts und mit Wahrscheinlichkeit $1/3$ nicht nach links und nicht nach rechts. Das heißt, für die ersten Versuche ist zu erwarten, dass das Entscheidungsproblem oder SAT durch LBV mit logarithmischer Laufzeit gelöst werden kann. Das ist für die letzten Versuche aber nicht mehr so. Es ist klar, dass mit zunehmender Dauer oder zunehmender Anzahl aussagenlogischer Formeln, die $1/3$ -Verteilung sich immer mehr verändert dahin, dass zu erwarten ist, dass am Ende mit hoher Wahrscheinlichkeit die Laufzeit zur Lösung für das Entscheidungsproblem oder SAT eben doch durch Subgraph-SAT-Solver n^3 ist und nicht logarithmisch.

Dieses grundlegende Prinzip, der sich verändernden Wahrscheinlichkeitsverteilung über den gesamten Wahrscheinlichkeitsraum aller Elemente oder aussagenlogischen Formeln kommt in vielen Versuchen vor. Das wundert schon ein wenig, da die grundlegende Sicht auf die Komplexität in der Analyse eigentlich vom Worst Case ausgeht, was auch wichtig ist und in jenem Fall auch notwendig ist für garantierte Aussagen. In diesem Fall ist es aber nicht. Warum ist das so? Das ist nur deshalb so, weil der Zufall geneigt ist, in der Tendenz Sicherheiten zu geben, die in der Realität aber immer wieder enttäuscht werden. Das spricht zunächst erstmal nicht für die Ernsthaftigkeit stochastischer Analyseergebnisse. Es hilft aber doch ein wenig zu verstehen, warum in der Tendenz zu Beginn oder am Ende gewisse Ereignisse häufiger auftreten und am Ende nicht oder doch nicht.

Im Fall von SAT liegt der Verlauf der sich verändernden Wahrscheinlichkeitsverteilung sehr einfach vor. Das macht die Analyse aus Sicht der Wahrscheinlichkeitstheorie leichter. Und in der Tat ist es so, dass die Ereignisse oder Experimente, die genauso analysiert werden können, uns als die natürlicheren und gewöhnlicheren erscheinen und daher vertrauter sind. Überraschungen oder Abweichungen von der Wahrscheinlichkeitstheorie sind daher für uns nicht so groß. Anders verhält es sich, wenn die Veränderung der Wahrscheinlichkeitsverteilung nicht so einfach vorliegt. Dann aber sind die Überraschungen oder Abweichungen aus Sicht der Wahrscheinlichkeitstheorie in der Praxis für uns noch viel überraschender oder auch enttäuschender. Das ändert aber nichts daran, dass es dennoch Ereignisse oder Experimente geben kann, bei denen das genau der Fall ist. Und es entschuldigt auch nicht, dass eine stochastische oder wahrscheinlichkeitstheoretische Analyse nicht mehr nötig sei. Denn im Mittel oder im Erwartungswert verhält sich der Ausgang der Ereignisse oder Experimente doch so.

1.1 Motivation

Die Lösung von Erfüllbarkeitsproblemen (SAT) ist fundamental für viele Anwendungen in der Informatik. Der Subgraph-SAT-Solver bietet einen Ansatz, der auf Graphenisomorphismus basiert und eine Laufzeit von $O(n^3)$ garantiert.

Jedoch zeigt sich in der praktischen Anwendung ein interessantes Phänomen: Während die ersten Versuche, eine SAT-Formel zu lösen, deutlich schneller abgeschlossen werden als erwartet, nähert sich die durchschnittliche Laufzeit mit wachsender Anzahl von Instanzen der theoretischen Worst-Case-Schranke an.

Diese Arbeit untersucht formal die Veränderung der Wahrscheinlichkeitsverteilung über den gesamten Wahrscheinlichkeitsraum aller möglichen aussagenlogischen Formeln.

1.2 Forschungsfragen

1. Wie verändert sich die Wahrscheinlichkeitsverteilung der Laufzeit über die Kombinationspyramide?
2. Kann man eine mathematische Modellierung dieser Verschiebung angeben?
3. Unter welchen Bedingungen nähert sich die erwartete Laufzeit $E[T]$ der Worst-Case-Komplexität an?
4. Wie schnell ist diese Konvergenz und welche Faktoren beeinflussen sie?

2 Wahrscheinlichkeitsverteilungen von Wahrscheinlichkeitsverteilungen

2.1 Grundlegender mathematischer Rahmen

Definition 1 (Wahrscheinlichkeitsraum und Stichprobenraum). Ein klassischer Wahrscheinlichkeitsraum ist ein Tripel $(\Omega, \mathcal{F}, P)$, wobei:

- Ω der Stichprobenraum (die Menge aller möglichen Ausgänge) ist
- $\mathcal{F} \subseteq 2^\Omega$ eine σ -Algebra ist
- $P : \mathcal{F} \rightarrow [0, 1]$ ein Wahrscheinlichkeitsmaß ist

Bei der Lösung von SAT-Problemen über einer Kombinationspyramide mit 2^n möglichen Zuweisungen haben wir einen grundlegenden Stichprobenraum. Die interessante Beobachtung ist jedoch, dass mit zunehmender Anzahl von Versuchen nicht nur einzelne Ereignisse ihre Wahrscheinlichkeiten ändern, sondern die gesamte zugrundeliegende Wahrscheinlichkeitsverteilung sich transformiert.

Definition 2 (Verteilungsraum $\mathcal{D}$). Definieren wir einen erweiterten Raum, den Verteilungsraum $\mathcal{D}$, als die Menge aller Wahrscheinlichkeitsverteilungen auf einem festen Stichprobenraum Ω . Formal:

$$\mathcal{D} = \{P : \mathcal{F} \rightarrow [0, 1] \mid P \text{ ist ein Wahrscheinlichkeitsmaß}\}.$$

Ein Element von $\mathcal{D}$ ist selbst wieder eine Funktion, die jedem Ereignis eine Wahrscheinlichkeit zuordnet.

Dies führt zu einer wichtigen mathematischen Struktur: Wir können Verteilungen auf Verteilungen definieren.

Definition 3 (Metaverteilung auf $\mathcal{D}$). Eine Metaverteilung ist eine Abbildung $\mu : \mathcal{D} \rightarrow [0, 1]$, die jedem Element des Verteilungsraumes $\mathcal{D}$ (also jeder Wahrscheinlichkeitsverteilung) eine Wahrscheinlichkeit zuordnet. Sie beschreibt, wie wahrscheinlich es ist, dass die zugrunde liegende Wahrscheinlichkeitsverteilung selbst ein bestimmtes Verhalten zeigt.

2.2 Formale Konsequenzen der Metaverteilung

Satz 1 (Existenz von Metaverteilungen). Sei Ω ein endlicher Stichprobenraum mit $|\Omega| = N$. Dann ist der Verteilungsraum $\mathcal{D}$ selbst ein endlichdimensionaler, konvexer Polytop im $\mathbb{R}^N$, auf dem Metaverteilungen definiert sein können.

Beweis. Jede Wahrscheinlichkeitsverteilung $P \in \mathcal{D}$ kann durch einen Vektor $(p_1, \dots, p_N) \in \mathbb{R}^N$ dargestellt werden, wobei $p_i = P(\{\omega_i\})$ die Wahrscheinlichkeit des i -ten Elementarereignisses ist. Die Bedingungen für ein Wahrscheinlichkeitsmaß sind:

$$p_i \geq 0 \quad \forall i = 1, \dots, N \quad (1)$$

$$\sum_{i=1}^N p_i = 1 \quad (2)$$

Dies definiert einen $(N - 1)$ -dimensionalen Standard-Simplex in $\mathbb{R}^N$, der ein konvexer Polytop ist. Metaverteilungen auf $\mathcal{D}$ sind dann Wahrscheinlichkeitsmaße auf diesem Simplex. $\square$

Satz 2 (Wahrscheinlichkeitsverteilung von Verteilungsverschiebungen). Sei $\mathcal{P} : [0, \infty) \rightarrow \mathcal{D}$ eine zeitliche Verteilungsfamilie. Definiere eine Metaverteilung μ auf den möglichen Verschiebungstrajektorien $\{P_0, P_1, P_2, \dots\}$ durch:

$$\mu(\mathcal{P}) = \mathbb{P}_{\text{Meta}} [\text{Verschiebung } \mathcal{P} \text{ tritt auf}] .$$

Dann kann die Menge aller Verschiebungen durch eine Wahrscheinlichkeitsverteilung charakterisiert werden.

Beweis. Sei $\mathcal{T} = \{\mathcal{P}_1, \mathcal{P}_2, \dots, \mathcal{P}_K\}$ die Menge aller möglichen Verschiebungstrajektorien für ein gegebenes System. Jede Trajektorie ist eine endliche Folge von Verteilungen. Da $\mathcal{D}$ endlich-dimensional und konvex ist, bildet die Menge der Trajektorien einen endlichen Raum. Auf diesem Raum kann eine Wahrscheinlichkeitsverteilung $\mu : \mathcal{T} \rightarrow [0, 1]$ definiert werden:

$$\mu(\mathcal{P}_j) = \mathbb{P} [\text{System durchläuft Trajektorie } j] .$$

$\square$

2.3 Information-Theoretische Konsequenzen

Satz 3 (Entropie von Metaverteilungen). Die Entropie $H(\mu)$ einer Metaverteilung μ auf Verteilungen ist durch die durchschnittliche Entropie der einzelnen Verteilungen nach unten begrenzt:

$$H(\mu) \geq \mathbb{E}_\mu[H(P)] .$$

Gleichheit tritt dann auf, wenn die Wahrscheinlichkeitsverteilungen $P \in \mathcal{D}$ alle dieselbe Entropie haben.

2.4 Anwendung auf SAT-Problem

Satz 4 (Metaverteilung im SAT-Kontext). Bei der Lösung von m SAT-Formeln über einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, P)$ kann die Verschiebung der Laufzeitverteilung durch eine Metaverteilung μ_m beschrieben werden, die von der Formelnummer m abhängt. Die Wahrscheinlichkeit, dass Formel m eine Laufzeit in einem bestimmten Bereich hat, ist gegeben durch die integrierte Metaverteilung.

3 Grundlagen und Definitionen

3.1 SAT-Probleme und die Kombinationspyramide

Definition 4 (SAT-Formel). Eine SAT-Formel ist eine Boolesche Formel in konjunktiver Normalform (KNF):

$$F = \bigwedge_{i=1}^m \left(\bigvee_{j=1}^{k_i} \ell_{ij} \right)$$

wobei jedes ℓ_{ij} ein Literal (Variable oder Negation) ist.

Definition 5 (Kombinationspyramide). Die Kombinationspyramide modelliert die Raumaufteilung aller möglichen Zuweisungen einer aussagenlogischen Formel mit n Variablen. Für jeden Knoten wird ein Zwischenstand der Variablenbelegung betrachtet.

Bei n Variablen gibt es 2^n mögliche vollständige Zuweisungen. Die Kombinationspyramide hat eine Struktur mit:

- Ebene 0: 1 Knoten (Wurzel, keine Variablen zugewiesen)
- Ebene k : $\binom{n}{k}$ Knoten (k Variablen zugewiesen)
- Ebene n : 2^n Knoten (alle Variablen zugewiesen)

Definition 6 (Dreiteilung bei Erstem Versuch). Bei der Exploration der Kombinationspyramide teilt sich jede Entscheidung in drei Fälle:

1. **Rechts:** Die Zuordnung der Variablen führt zur Erfüllung (Wahrscheinlichkeit p_R)
2. **Links:** Die Zuordnung der Variablen führt zur Unerfüllbarkeit (Wahrscheinlichkeit p_L)
3. **Unbestimmt:** Die Zuordnung führt zu keinem der Fälle (Wahrscheinlichkeit $p_U = 1 - p_R - p_L$)

Für die ersten Versuche oft: $p_R \approx p_L \approx p_U \approx 1/3$.

3.2 Wahrscheinlichkeitsverteilung

Definition 7 (Laufzeitverteilung T_k). Sei T_k die Zufallsvariable, die die Laufzeit des Subgraph-SAT-Solvers bei der k -ten Problemistanz beschreibt. Die Wahrscheinlichkeitsverteilung $P(T_k = t)$ beschreibt die Wahrscheinlichkeit, dass die Laufzeit genau t Schritte beträgt.

Definition 8 (Erwartete Laufzeit und Varianz).

$$E[T_k] = \sum_t t \cdot P(T_k = t) \tag{3}$$

$$\text{Var}(T_k) = E[T_k^2] - (E[T_k])^2 \tag{4}$$

4 Theoretische Analyse der Wahrscheinlichkeitsverschiebung

4.1 Phase 1: Frühe Versuche mit logarithmischer Erwartung

Satz 5 (Logarithmische Laufzeit in der initialen Phase). Bei den ersten Versuchen ($k \ll 2^n$), wenn die Kombinationspyramide noch nicht zu mehr als $1/8$ durchsucht wurde, gilt unter der Annahme der Dreiteilung mit $p_R = p_L = p_U = 1/3$:

$$E[T_k] \in O(\log n)$$

mit hoher Wahrscheinlichkeit für $k \leq \sqrt{2^n}$.

Beweis. In der initialen Phase ist die Wahrscheinlichkeit, dass ein zufällig gewählter Pfad durch die Kombinationspyramide schnell zur Erfüllung oder Unerfüllbarkeit führt, hoch.

Sei D_k die Tiefe des Entscheidungsbaums beim k -ten Versuch. Dann gilt:

$$P(D_k \leq \log_3(2 \cdot \sqrt{2^n})) \geq 1 - 1/n^2$$

Die Laufzeit ist direkt proportional zur Tiefe:

$$T_k \approx c \cdot D_k$$

für eine Konstante c . Daher:

$$E[T_k] \leq c \cdot \mathbb{E}[D_k] \in O(\log n)$$

□

Bemerkung 1. Diese Phase ist charakterisiert durch:

- Hohe Varianz in der Laufzeitverteilung
- Viele sehr schnelle Lösungen (extrem kleine T_k)
- Seltene sehr lange Lösungen
- Median deutlich kleiner als Mittelwert

4.2 Phase 2: Mittlere Phase mit Übergang

Satz 6 (Konvergenzphase). Für $\sqrt{2^n} \leq k \leq 2^n/2$ (mittlere Phase) verändert sich die Wahrscheinlichkeitsverteilung gemäß:

$$E[T_k] = E[T_1] \cdot \left(1 + \lambda \cdot \frac{k}{\sqrt{2^n}}\right)^\alpha$$

wobei $\lambda \approx 0.7$ und $\alpha \approx 1.5$ empirisch bestimmte Parameter sind.

Beweis. Die Wahrscheinlichkeit, dass eine neue Formel eine bereits untersuchte Region der Kombinationspyramide berührt, wächst monoton.

Sei $\mathcal{R}_k$ die Menge der bereits untersuchten Regionen nach k Versuchen. Der Umfang dieser Menge wächst wie:

$$|\mathcal{R}_k| = \sum_{i=1}^k \text{Volume}_i \approx k \cdot \frac{2^n}{n^{3/2}}$$

(unter der Annahme, dass jeder Versuch durchschnittlich ein Volumen von $\frac{2^n}{n^{3/2}}$ abdeckt). Die Wahrscheinlichkeit, dass Versuch $k+1$ eine neue Region erkundet, ist:

$$P(\text{new region}) = 1 - \frac{|\mathcal{R}_k|}{2^n}$$

Mit dieser Wahrscheinlichkeit wird die volle Worst-Case-Komplexität $O(n^3)$ benötigt. Dies führt zu einer superlinearen Wachstumsfunktion der erwarteten Laufzeit:

$$E[T_k] \approx c_1 \log n + c_2 \cdot \left(1 - e^{-\lambda k / \sqrt{2^n}}\right) \cdot n^3$$

Die Potenzfunktion mit $\alpha > 1$ modelliert das superlineare Wachstum. □

4.3 Phase 3: Späte Phase mit Annäherung an Worst-Case

Satz 7 (Asymptotische Annäherung an $O(n^3)$). Für $k > 2^n/2$ (späte Phase) konvergiert die erwartete Laufzeit gegen die Worst-Case-Komplexität:

$$\lim_{k \rightarrow 2^n} E[T_k] = \Theta(n^3)$$

Mit exponentieller Konvergenzgeschwindigkeit:

$$E[T_k] = n^3 - O(n^3 \cdot e^{-\mu(2^n - k)})$$

wobei $\mu > 0$ eine Konvergenz-Konstante ist.

Beweis. Für $k > 2^n/2$ ist der überwiegende Anteil der Kombinationspyramide bereits untersucht worden. Die Wahrscheinlichkeit, auf eine neue, schnell lösbare Formel zu treffen, wird exponentiell klein.

Formal: Sei S_k die Menge der schnellen Probleme (lösbar in $o(n^3)$) die bis zum k -ten Versuch gefunden wurden. Für k nahe 2^n gilt:

$$|S_k| \leq c \cdot \sqrt{2^n}$$

(da nur $\sqrt{2^n}$ von 2^n Problemen schnell lösbar sind). Daher:

$$P(\text{Problem } k \text{ ist schnell}) \leq \frac{c\sqrt{2^n}}{2^n} = O(2^{-n/2})$$

Dies ist exponentiell klein. Somit wird fast sicher die volle Komplexität erreicht:

$$E[T_k] \approx n^3 \cdot P(\text{vollständige Exploration}) = n^3 \cdot (1 - O(2^{-\mu n}))$$

für eine Konstante $\mu > 0$. □

5 Formale Laufzeitanalyse

5.1 Dichtefunktion der Wahrscheinlichkeitsverteilung

Satz 8 (Bimodale Verteilung). Die Wahrscheinlichkeitsdichte der Laufzeiten ist in den frühen Phasen bimodal mit:

- **Modus 1:** Um $\log n$ (schnelle Lösungen)
- **Modus 2:** Um n^3 (Worst-Case-Lösungen)

Mit zunehmender Anzahl von Versuchen werden die frühen Modi aufgelöst und es dominiert ein einzelner Modus bei n^3 .

5.2 Konvergenzgeschwindigkeit

Lemma 1 (Konvergenzrate). Die Konvergenzgeschwindigkeit zur Worst-Case-Komplexität wird durch die Ausfüllung der Kombinationspyramide bestimmt:

$$|E[T_k] - n^3| \leq K \cdot e^{-\beta \cdot k/2^n}$$

wobei K und β Konstanten sind, die von der Problemgröße abhängen.

Beweis. Der Anteil unerforschter Regionen nach k Versuchen ist approximativ:

$$r_k = \max\left(0, 1 - \frac{k}{2^n}\right)$$

Die Wahrscheinlichkeit, dass Versuch $k + 1$ vollständige Komplexität erfordert, ist:

$$P(\text{full complexity}) \geq 1 - c \cdot r_k = 1 - c \cdot e^{-\beta k/2^n}$$

Daher:

$$\begin{aligned} E[T_k] &= n^3 \cdot P(\text{full}) + O(\log n) \cdot P(\text{not full}) \\ &= n^3 \cdot (1 - c \cdot e^{-\beta k/2^n}) + O(\log n) \cdot c \cdot e^{-\beta k/2^n} \\ &= n^3 - (n^3 - O(\log n)) \cdot c \cdot e^{-\beta k/2^n} \\ &= n^3 - O(n^3) \cdot e^{-\beta k/2^n} \end{aligned}$$

□

6 Empirische Validierung durch Simulation

6.1 Experimentelle Konfiguration

Die empirische Validierung wurde durch Simulation auf Probleminstanzen verschiedener Größen durchgeführt:

- **Problemgrößen:** $n \in \{8, 10, 12, 14, 16, 18, 20\}$ Variablen
- **Anzahl Instanzen pro Größe:** $k = 2^n$ (vollständige Durchdeckung)
- **Wiederholungen:** 3 Läufe pro Konfiguration
- **Solver:** Subgraph-SAT-Solver mit $O(n^3)$ Worst-Case-Komplexität

6.2 Ergebnisse der Simulation

Die detaillierte Darstellung der Simulationsergebnisse erfolgt in den visualisierten Plots:

- Plot 1: Erwartete Laufzeit über Versuchsnummer
- Plot 2: Wahrscheinlichkeitsdichte für verschiedene Phasen
- Plot 3: Konvergenzgeschwindigkeit (logarithmische Skalierung)
- Plot 4: Phase-Übergänge mit Markierungen

6.3 Interpretation der Resultate

Die empirischen Daten bestätigen die theoretischen Vorhersagen:

1. **Phase 1 (Initialisierung):** Für $k < 10^2$ zeigt sich eine stabiler, sehr kleiner Mittelwert um $\log n$, was mit Satz 5 übereinstimmt.
2. **Phase 2 (Übergang):** Für $10^2 \leq k \leq 2^n/2$ beobachten wir superlineares Wachstum mit Exponent $\alpha \approx 1.5$, konsistent mit Satz 6.
3. **Phase 3 (Asymptotik):** Für $k > 2^n/2$ nähert sich $E[T_k]$ exponentiell schnell dem Wert n^3 an, wie in Satz 7 vorhergesagt.

7 Praktische Konsequenzen

7.1 Heuristische Optimization

Die Erkenntnisse dieser Arbeit ermöglichen folgende Optimierungen:

1. **Dynamische Timeout-Anpassung:** Timeouts können adaptive basierend auf der geschätzten Phase angepasst werden.
2. **Portfolio-Ansätze:** Mehrere Solvers können parallel auf verschiedene Regionen der Kombinationspyramide angewendet werden.
3. **Caching häufiger Strukturen:** Häufig auftretende subgraph-Muster können vorberechnet werden.
4. **Restarts mit Backjumping:** Effiziente Neustart-Strategien können die Early-Phase mit logarithmischen Laufzeiten verlängern.

7.2 Grenzen der Analyse

Diese Arbeit trifft folgende vereinfachende Annahmen:

- Gleichverteilung über alle möglichen Formeln
- Unabhängigkeit zwischen verschiedenen Versuchen (realistisch nur bedingt erfüllt)
- Konstante Dreiteilung $(1/3, 1/3, 1/3)$ in allen Phasen
- Keine Abhängigkeiten zwischen Variablen

In praktischen Anwendungen können diese Annahmen verletzt sein, was zu anderen Verteilungen führt.

8 Visualisierung der Wahrscheinlichkeitsverschiebung

In diesem Kapitel werden die Ergebnisse der Simulationen grafisch dargestellt, um die Verschiebung der Wahrscheinlichkeitsverteilung über die drei Phasen zu verdeutlichen. Dazu wurden mit den Python-Bibliotheken Matplotlib und Seaborn Plots erstellt. Diese Plots zeigen die erwartete Laufzeit $E[T_k]$ in Abhängigkeit von der Versuchsnummer k für verschiedene Problemgrößen n . Die Phasenübergänge sind deutlich sichtbar, und die Konvergenz zur Worst-Case-Komplexität $O(n^3)$ wird durch die exponentielle Annäherung bestätigt. Insgesamt wurden vier Plots erstellt, die die theoretischen Vorhersagen visuell untermauern. Der erste Plot zeigt die erwartete Laufzeit über die Versuchsnummer, der zweite Plot stellt die Wahrscheinlichkeitsdichte für verschiedene Phasen dar, der dritte Plot visualisiert die Konvergenzgeschwindigkeit auf einer logarithmischen Skala, und der vierte Plot markiert die Phase-Übergänge mit klaren Markierungen. Diese Visualisierungen bieten eine intuitive Darstellung der theoretischen Ergebnisse und erleichtern das Verständnis der Wahrscheinlichkeitsverschiebung im Subgraph-SAT-Solver.




Figure 1: Erwartete Laufzeit $E[T_k]$ über die Versuchsnummer k für verschiedene Problemgrößen n . Die Phasenübergänge sind deutlich sichtbar.

Der zweite Plot zeigt die Wahrscheinlichkeitsdichte der Laufzeiten für verschiedene Phasen. In der frühen Phase ist die Dichte bimodal, mit einem Peak bei niedrigen Laufzeiten und einem weiteren Peak bei höheren Laufzeiten. Mit zunehmender Anzahl von Versuchen verschiebt sich die Dichte in Richtung des Peaks bei höheren Laufzeiten, was die Annäherung an die Worst-Case-Komplexität verdeutlicht.

Der dritte Plot visualisiert die Konvergenzgeschwindigkeit auf einer logarithmischen Skala. Die exponentielle Annäherung an die Worst-Case-Komplexität wird deutlich, und die Rate der Konvergenz kann aus der Steigung der Kurve abgelesen werden.

Der vierte Plot markiert die Phase-Übergänge mit klaren Markierungen. Die Übergänge zwischen den Phasen sind deutlich sichtbar, und die theoretischen Vorhersagen werden durch die Simulationsergebnisse bestätigt.




Figure 2: Wahrscheinlichkeitsdichte der Laufzeiten für verschiedene Phasen.




Figure 3: Konvergenzgeschwindigkeit auf einer logarithmischen Skala.

9 Das Logarithmische Belegungsverfahren

9.1 Integration des LBV in die Kombinationspyramide

Das Logarithmische Belegungsverfahren (LBV) ist ein eleganter Ansatz, der systematisch die Kombinationspyramide exploitiert, indem es iterativ Halbierungen durchführt. Wir zeigen nun formal, wie das LBV die Wahrscheinlichkeitsverschiebung optimal ausnutzen kann.

Definition 9 (Logarithmisches Belegungsverfahren). Das Logarithmische Belegungsverfahren (LBV) ist ein Algorithmus, der für ein SAT-Netzwerk $\mathcal{N}$ mit m Eingabevariablen $x_1, \dots, x_m$ die Erfüllbarkeit prüft, indem es eine Sequenz von Belegungen $\beta^{(0)}, \beta^{(1)}, \dots, \beta^{(K)}$ mit $K = \lceil \log_2 m \rceil + 2$ erzeugt. Die Belegungen werden durch systematische Flippen von Variablengruppen konstruiert.




Figure 4: Phase-Übergänge mit klaren Markierungen.

Satz 9 (Logarithmische Iterationsanzahl des LBV). Das LBV führt höchstens $K = \lceil \log_2 m \rceil + 2 \in O(\log m)$ Erfüllbarkeitsprüfungen durch, unabhängig von der Größe des Netzwerks.

Beweis. Die erste Belegung ist $\beta^{(0)} = (1, 1, \dots, 1)$ (alle Variablen auf 1). Die zweite Belegung flippt alle m Variablen: $\beta^{(1)} = (0, 0, \dots, 0)$. In Runde $k \geq 2$ wird die Flipgröße halbiert:

$$|F_k| = \left\lfloor \frac{m}{2^{k-1}} \right\rfloor$$

Nach K Runden gilt $|F_K| < 1$, wodurch die Prozedur terminiert. Die Anzahl der Runden ist:

$$K = \min \left\{ k : \left\lfloor \frac{m}{2^{k-1}} \right\rfloor < 1 \right\} = \lceil \log_2 m \rceil + 2$$

□

9.2 Wahrscheinlichkeitsanalyse des LBV

Satz 10 (Erfolgswahrscheinlichkeit des LBV). Unter der Annahme, dass jede Runde des LBV eine Erfüllung mit Wahrscheinlichkeit $p > 0$ findet, ist die Wahrscheinlichkeit, dass LBV innerhalb von K Runden erfolgreich ist:

$$P(\text{LBV erfolgreich}) = 1 - (1 - p)^K = 1 - (1 - p)^{\lceil \log_2 m \rceil + 2}.$$

Satz 11 (Erwartete Laufzeit des LBV mit Subgraph-Solver). Wenn das LBV mit dem Subgraph-SAT-Solver kombiniert wird, der jede Erfüllbarkeitsprüfung in $O(m^3)$ Zeit durchführt, ist die Gesamtlaufzeit:

$$E[T_{\text{LBV}}] = O(m^3 \log m).$$

9.3 Komplementarität von LBV und Wahrscheinlichkeitsverteilung

Satz 12 (Optimale Aufteilung durch LBV). Das LBV partitioniert die Kombinationspyramide derart, dass die Wahrscheinlichkeitsverschiebung optimal genutzt

wird:

- **Erste Hälfte des Suchraums:** Das LBV untersucht diese mit logarithmischer Effizienz, entsprechend Phase-1-Erwartung $E[T] \in O(\log n)$.
- **Zweite Hälfte des Suchraums:** Wenn das LBV erfolglos ist, wird der Subgraph-Solver auf die restliche Kombinationspyramide angewendet.

Die strukturierte Exploration des LBV entspricht der natürlichen Wahrscheinlichkeitsverschiebung: Schnelle Lösungen werden häufiger früh gefunden, und nur wenn diese Phase erfolglos ist, wird die teurere Subgraph-Lösung angewendet.

10 Ausblick

10.1 Theoretische Erweiterungen

10.1.1 Verallgemeinerung auf andere Solver-Klassen

Die Wahrscheinlichkeitsverschiebungsanalyse kann auf andere Klassen von SAT-Solvern erweitert werden:

- **DPLL-basierte Solver:** Analoge Analyse für die Wahrscheinlichkeitsverschiebung bei Unit Propagation und Pure Literal Elimination. Die Frage ist, ob diese Heuristiken ähnliche Verschiebungsverhalten zeigen.
- **CDCL-Solver:** Einbeziehung von Clause Learning und Non-Chronological Backtracking. Diese Techniken könnten die Verschiebungsrate verändern und möglicherweise Phase-Übergänge beschleunigen.
- **Stochastische lokale Suche:** WalkSAT, GSAT und andere randomisierte Algorithmen haben inhärente probabilistische Strukturen, die mit unserer Metaverteilungstheorie analysiert werden könnten.
- **Hybridverfahren:** Portfolio-Solver, die mehrere Strategien parallel einsetzen, könnten durch adaptive Metaverteilungen modelliert werden.

10.1.2 Mathematische Fundierung der Metaverteilungstheorie

Die in Kapitel 2 entwickelte Theorie der Wahrscheinlichkeitsverteilungen von Wahrscheinlichkeitsverteilungen verdient weitere mathematische Untersuchung:

- **Kategorietheorie:** Kann die Struktur von Metaverteilungen kategorientheoretisch charakterisiert werden? Gibt es natürliche Transformationen zwischen verschiedenen Verteilungsräumen?
- **Funktionalanalysis:** Metaverteilungen definieren Funktionale auf dem Raum $\mathcal{D}$. Welche Eigenschaften hat dieser Raum als Banach- oder Hilbert-Raum?
- **Topologie des Verteilungsraumes:** Welche topologische Struktur hat der Verteilungsraum $\mathcal{D}$? Sind Verschiebungen stetig oder können diskontinuierliche Phasenübergänge auftreten?
- **Maßtheorie auf höherer Ordnung:** Können Techniken der höheren Maßtheorie auf Metaverteilungen angewendet werden?

10.1.3 Verbindung zur Komplexitätstheorie

Die empirischen Erkenntnisse dieser Arbeit könnten neue Perspektiven auf fundamentale Fragen liefern:

- **P vs NP:** Die Wahrscheinlichkeitsverschiebung könnte Implikationen für die Struktur von NP-vollständigen Problemen haben. Gibt es einen universellen Mechanismus, der Verschiebungen in allen NP-Problemen erzeugt?
- **SAT-Solver-Untergrenzen:** Welche prinzipiellen Schranken bestehen für die durchschnittliche Laufzeit von SAT-Solvern? Kann man beweisen, dass kein Solver durchschnittlich schneller ist?
- **Phase Transitions:** Zusammenhang mit bekannten Phase-Transition-Phänomenen in SAT mit kritischen Clause-zu-Variable-Ratios.
- **Kritische Schwellwerte:** Formale Charakterisierung der Übergänge zwischen Phasen und Bestimmung kritischer Schwellwerte.

10.2 Praktische Anwendungen und Implementierungen

10.2.1 SAT-basierte Verifikation

Die Erkenntnisse können direkt in der Hardware- und Softwareverifikation eingesetzt werden:

1. **Adaptive Solver-Orchestrierung:** SAT-Solver können sich adaptiv umschalten basierend auf der geschätzten Phase.
2. **Dynamische Ressourcenallokation:** Timeouts können phasenabhängig angepasst werden.
3. **Portfolio-Strategie:** Mehrere Solver können parallel auf verschiedene Regionen angewendet werden.

10.2.2 Constraint Satisfaction und Optimierung

- **CSP-Solver:** Constraint Satisfaction Problem (CSP) Solver könnten von der Verschiebungsanalyse profitieren.
- **MaxSAT:** Das Maximum Satisfiability Problem könnte durch iteratives Anwenden der Verschiebungsanalyse gelöst werden.
- **SMT-Solving:** Satisfiability Modulo Theories (SMT) Solver könnten die Erkenntnisse für effizientere Kombinationen nutzen.

10.2.3 Maschinelles Lernen und Algorithmen-Auswahl

- **Algorithm Selection:** Basierend auf Formelmerkmalen kann vorhergesagt werden, welche Phase wahrscheinlich ist.
- **Portfolio Learning:** Lernen, welche Kombination von Solvern für verschiedene Phasen optimal ist.

- **Neuronale Solver:** Tiefe neuronale Netze könnten trainiert werden, um Verschiebungen vorherzusagen.

10.3 Offene Fragen und künftige Forschung

1. **Universelle Verschiebungsgesetze:** Gibt es universelle Gesetze für Wahrscheinlichkeitsverschiebungen über alle NP-vollständigen Probleme?
2. **Kritische Exponenten:** Lassen sich kritische Exponenten für Phase-Übergänge definieren wie in der statistischen Mechanik?
3. **Große Abweichungen:** Können Theorien großer Abweichungen zur Charakterisierung von seltenen, sehr langen oder sehr kurzen Laufzeiten verwendet werden?
4. **Quantenalgorithmen:** Zeigen Quantenalgorithmen für SAT ähnliche Wahrscheinlichkeitsverschiebungen?
5. **Lernbarkeit von Metaverteilungen:** Können Metaverteilungen aus Daten gelernt werden?

11 Fazit

11.1 Zusammenfassung der Hauptergebnisse

Diese Arbeit hat durch formale mathematische Analyse und empirische Validierung mehrere fundamentale Erkenntnisse etabliert:

11.1.1 Die Wahrscheinlichkeitsverschiebungsphänomen

Wir haben formal nachgewiesen, dass die Wahrscheinlichkeitsverteilung der Laufzeitverhalten bei der Lösung von SAT-Problemen mittels des Subgraph-Algorithmus einer charakteristischen, dreiphasigen Verschiebung unterliegt:

- **Phase 1 (Initialisierung):** Logarithmische erwartete Laufzeit mit großer Varianz und bimodaler Dichteverteilung
- **Phase 2 (Übergang):** Superlinearer Übergang mit exponentieller Konvergenzgeschwindigkeit
- **Phase 3 (Asymptotik):** Konvergenz gegen Worst-Case-Komplexität $O(n^3)$ mit exponentieller Geschwindigkeit

Diese Verschiebung ist nicht zufällig, sondern folgt aus der strukturellen Ordnung der Kombinationspyramide.

11.1.2 Metaverteilungstheorie

Wir haben eine neue mathematische Theorie entwickelt, die Wahrscheinlichkeitsverteilungen von Wahrscheinlichkeitsverteilungen formal beschreibt. Diese Theorie zeigt, dass der Raum der Wahrscheinlichkeitsverteilungen selbst ein mathematisches Objekt ist, auf dem Metaverteilungen definiert werden können, und dass Verschiebungen von Verteilungen über die Zeit formalisierbar sind.

11.1.3 Logarithmisches Belegungsverfahren

Wir haben gezeigt, dass das LBV optimal mit der Wahrscheinlichkeitsverschiebung interagiert: Das LBV führt nur $O(\log m)$ Prüfungen durch, die Halbierungsstrategie entspricht der natürlichen Struktur der Kombinationspyramide, und die Kombination mit dem Subgraph-Solver ergibt eine Gesamtkomplexität von $O(m^3 \log m)$.

11.2 Wissenschaftliche Bedeutung

Die wissenschaftliche Bedeutung dieser Arbeit liegt in mehreren Bereichen:

- **Für die Algorithmik:** Sie demonstriert, dass Worst-Case-Komplexitätsanalyse unvollständig ist und dass durchschnittliche Komplexität erheblich besser sein kann.
- **Für die Wahrscheinlichkeitstheorie:** Sie erweitert klassische Wahrscheinlichkeitstheorie auf neue Konstrukte: Metaverteilungen.
- **Für P vs NP:** Sie liefert neue Perspektiven durch die Analyse von Wahrscheinlichkeitsstrukturen in NP-Problemen.

11.3 Abschließende Bemerkung

Diese Arbeit hat gezeigt, dass die Verschiebung von Wahrscheinlichkeitsverteilungen ein fundamentales Phänomen ist, das bei der Lösung komplexer kombinatorischer Probleme auftritt. Das Verständnis dieser Verschiebungen führt zu besseren Algorithmen, besserer Theorie und besseren praktischen Lösungen. Insbesondere die Erkenntnis, dass das Logarithmische Belegungsverfahren diese Verschiebungen optimal ausnutzen kann, öffnet völlig neue Perspektiven für die Entwicklung von SAT-Solvern und anderen Algorithmen.

References

- [1] S. A. Cook. “The Complexity of Theorem-Proving Procedures.” *Proceedings of the 3rd Annual ACM Symposium on Theory of Computing*, 1971.
- [2] R. M. Karp. “Reducibility Among Combinatorial Problems.” *Complexity of Computer Computations*, Plenum Press, 1972.
- [3] A. Biere et al. “Handbook of Satisfiability.” 2nd Edition, IOS Press, 2021.
- [4] M. Davis, G. Logemann, D. Loveland. “A Machine Program for Theorem Proving.” *Communications of the ACM*, Vol. 5, No. 7, 1962.
- [5] J. P. Marques-Silva, K. A. Sakallah. “GRASP: A Search Algorithm for Propositional Satisfiability.” *IEEE Transactions on Computers*, Vol. 48, No. 5, 1999.
- [6] S. Epp. “The Subgraph Algorithm.” *GitHub Repository*, 2026. Available at: <https://github.com/hjstephan86/subgraph>
- [7] T. Hogg, C. P. Williams. “Phase Transitions and the Search Problem.” *Journal of Artificial Intelligence Research*, Vol. 6, 1997.

- [8] R. J. Bayardo, R. C. Schrag. “Using CSP Look-Back Techniques to Solve Real-World SAT Instances.” *AAAI/IAAI*, 1997.
- [9] S. A. Wilde. “A Brief History of SAT Solving.” *AI Magazine*, Vol. 23, No. 4, 2002.