

Quantitative Analyse von Softwaresystemen: Markov-Ketten, Warteschlangentheorie und UML-Profile zur optimalen Auslegung und Ausfallsicherheit

Stephan Epp

4. August 2026

Abstract

Diese umfangreiche wissenschaftliche Arbeit präsentiert einen integrierten quantitativen Ansatz zur Analyse und optimalen Auslegung von Softwaresystemen durch die Kombination von drei komplementären mathematischen Beschreibungszielen: Markov-Ketten zur Modellierung der Ausfallsicherheit, Warteschlangentheorie zur Bewertung der Verfügbarkeit und UML-Profile zur quantitativen Spezifikation von Systemeigenschaften. Wir entwickeln formale Modelle zur Skalierung und optimalen Auslegung von Softwaresystemen in Abhängigkeit dieser drei Beschreibungsziele. Der zentrale Beitrag ist eine systematische Methodik zur Ableitung optimaler Entwurfseigenschaften aus den quantitativen Anforderungen. Alle Ergebnisse werden formal sehr ausführlich bewiesen und durch sieben umfangreiche Matplotlib-Visualisierungen veranschaulicht. Wir demonstrieren die praktische Anwendbarkeit durch detaillierte Fallstudien aus der Automotive-, Cloud- und Finanzdomäne. Der sehr ausführliche Ausblick diskutiert zukünftige Forschungsrichtungen in den Bereichen künstliche Intelligenz, verteilte Systeme und adaptive Softwarearchitekturen.

Contents

1	Einführung und Motivation	3
1.1	Forschungsfragen	3
2	Mathematische Grundlagen und formale Definitionen	3
2.1	Markov-Prozesse und Zuverlässigkeitsmodelle	3
2.2	Warteschlangentheorie und M/M/c-Systeme	5
2.3	UML-Profile und Quantitative Annotation	7
3	Integriertes quantitatives Modell	7
4	Ableitung optimaler Entwurfseigenschaften	9
4.1	Parallelisierung und Concurrency Design	9
4.2	Caching-Strategien	10
4.3	Redundanzdesign	11
5	Visualisierungen und numerische Resultate	12
5.1	Plot 1: Skalierungsverhalten – Erforderliche Serverzahl vs. Verfügbarkeit	13
5.1.1	Analyse und formale Interpretation	13
5.2	Plot 2: Markov-Zustandsübergänge – Wahrscheinlichkeitsentwicklung über Zeit	14
5.2.1	Analyse und formale Interpretation	14
5.2.2	MTTF-Berechnung aus dem Modell	15
5.3	Plot 3: M/M/c Warteschlangen-Charakteristiken	16
5.3.1	Analyse und formale Interpretation	16
5.4	Plot 4: Amdahl's Gesetz – Parallelisierungsgrenzen	17
5.4.1	Analyse und formale Interpretation	18
5.5	Plot 5: Cache-Hit-Rate unter Zipf-Verteilung	19
5.5.1	Analyse und formale Interpretation	19
5.6	Plot 6: Redundanzdesign – Verfügbarkeitsverbesserung	20
5.6.1	Analyse und formale Interpretation	20
5.7	Plot 7: MTTF-Vergleich verschiedener Computerkomponenten	22
5.7.1	Analyse und formale Interpretation	22
6	Erweiterte Fallstudien und praktische Anwendungen	23
6.1	Fallstudie 1: Automotive-ECU mit erweiterten Anforderungen	23
6.2	Fallstudie 2: Cloud-Datenbank-Service (Google Cloud SQL-ähnlich)	24
7	Systemübersicht und Anforderungsspezifikation	25
7.1	Systemkontext	25
7.2	Quantitative Anforderungen	26
8	Schritt 1: Markov-Kettenmodell für Ausfallsicherheit	26
8.1	Systemzustände	26
8.2	Übergangsraten	26
8.3	Markov-Kettenvisualisierung	27
8.4	Generatormatrix	27
8.5	Stationäre Verteilung und Verfügbarkeit	27
8.6	Verfügbarkeitsmessung	28

9	Schritt 2: M/M/c Warteschlangenmodell für Durchsatz	28
9.1	Systemkonfiguration	28
9.2	Berechnung der optimalen Anzahl von Instanzen	28
9.3	M/M/c Warteschlange Visualisierung	29
9.4	Latenz-Berechnung mit Littles Gesetz	29
10	Schritt 3: UML-Profil und Architektur-Modell	29
10.1	Komponenten-Spezifikation	29
10.2	UML-Profil-Visualisierung	30
11	Schritt 4: Systemdesign und Zielerreichung	30
11.1	Designentscheidungen	30
11.2	Formaler Nachweis der Zielerreichung	31
11.3	Zusammenfassung der Anforderungserfüllung	32
12	Schritt 5: Kostenbewertung und Optimierung	32
12.1	Ressourcenkalkulation	32
12.2	Kosten-Nutzen-Analyse	33
13	Zusammenfassung des integrierten Systemdesigns	33
14	Sehr ausführlicher Ausblick und zukünftige Forschungsrichtungen	33
14.1	Integration mit künstlicher Intelligenz und Large Language Models	33
14.1.1	Herausforderung 1: Halluzinationen und stochastische Fehlerquoten . . .	33
14.1.2	Herausforderung 2: Explainability und Compliance	34
14.2	Verteilte Systeme und Netzwerk-Resilienz	34
14.2.1	Byzantine Generals Problem	34
14.2.2	Konsistenz und das CAP-Theorem	34
14.3	Adaptive und selbstoptimierbare Softwarearchitekturen	34
14.3.1	Dynamische Skalierung und Load Balancing	35
14.3.2	Self-Healing Systeme	35
14.4	Quantitative Cybersecurity	35
14.5	Edge Computing und latenzempfindliche Systeme	35
14.5.1	Heterogene Hardware und beschleunigte Berechnung	36
15	Zusammenfassung und abschließende Beobachtungen	36

1 Einführung und Motivation

Die Entwicklung moderner Softwaresysteme erfordert nicht nur funktionale Korrektheit, sondern auch quantitativ garantierbare Nicht-funktionale Eigenschaften wie Verfügbarkeit, Durchsatz, Latenz und Zuverlässigkeit. Die traditionelle Separation dieser Aspekte — Ausfallsicherheit unabhängig von Verfügbarkeit, beide unabhängig von Architekturmodellen — führt zu suboptimalen Lösungen und verdeckten Abhängigkeiten.

Diese Arbeit argumentiert, dass eine *integrierte quantitative Analyse* notwendig ist, die drei Perspektiven konsistent zusammenbringt:

1. **Ausfallsicherheit (Reliability)** durch Markov-Ketten-Modelle mit formalen Zuverlässigkeitsfunktionen
2. **Verfügbarkeit (Availability)** durch Warteschlangentheorie mit M/M/c-Systemen und Erlang-Formeln
3. **Quantitative Architekturspezifikation** durch annotierte UML-Profile mit Quality-of-Service-Anforderungen

Die zentrale Hypothese lautet: Es existiert ein optimales Verhältnis dieser drei Dimensionen für die Auslegung von Softwaresystemen, das abhängig von Systemgröße, Skalierung und Anwendungsdomäne mathematisch berechenbar und formal hergeleitet werden kann.

1.1 Forschungsfragen

Diese Arbeit adressiert folgende Forschungsfragen:

1. Wie lassen sich Markov-Ketten, Warteschlangentheorie und UML-Profile formal in einem konsistenten mathematischen Rahmen vereinigen?
2. Welche Bedingungen müssen erfüllt sein, damit ein Softwaresystem skalierbar ist, während Ausfallsicherheit und Verfügbarkeit simultan gewährleistet bleiben?
3. Wie leiten sich aus quantitativen Anforderungen optimale Entwurfseigenschaften formal ab?
4. Welche neuen Stereotypen und Constraints müssen UML-Profile enthalten?
5. Wie können diese Erkenntnisse in praktischen Domänen angewendet werden?

2 Mathematische Grundlagen und formale Definitionen

2.1 Markov-Prozesse und Zuverlässigkeitsmodelle

Definition 1 (Kontinuierliche Zeit Markov-Kette). Eine kontinuierliche Zeit Markov-Kette (CTMC) $\mathcal{M} = (\mathcal{Z}, Q, \pi_0)$ ist definiert durch:

- Eine endliche Zustandsmenge $\mathcal{Z} = \{z_1, z_2, \dots, z_n\}$ mit z_1 (funktionsfähig), z_n (ausgefallen)
- Eine Generatormatrix $Q \in \mathbb{R}^{n \times n}$ mit $Q_{ij} \geq 0$ für $i \neq j$ und $Q_{ii} = -\sum_{j \neq i} Q_{ij}$
- Eine Startverteilung $\pi_0 \in \mathbb{R}^n$ mit $\pi_0^T \mathbf{1} = 1$

Die Zustandswahrscheinlichkeit $\pi(t) \in \mathbb{R}^n$ genügt der Master-Gleichung:

$$\frac{d\pi(t)}{dt} = \pi(t)^T Q$$

mit Anfangsbedingung $\pi(0) = \pi_0$.

Satz 1 (Eindeutigkeit der Lösung der Master-Gleichung). Für eine CTMC mit Generatormatrix Q und Startverteilung π_0 existiert eine eindeutige Lösung der Master-Gleichung, gegeben durch:

$$\pi(t) = \pi_0^T e^{Qt}$$

wobei $e^{Qt} = \sum_{k=0}^{\infty} \frac{(Qt)^k}{k!}$ die Matrixexponentialfunktion ist.

Beweis. Die Existenz folgt aus der Theorie der linearen gewöhnlichen Differentialgleichungen, da Q eine beschränkte lineare Abbildung ist. Zur Eindeutigkeit: Angenommen, es gäbe zwei Lösungen $\pi_1(t)$ und $\pi_2(t)$. Dann genügt $\delta(t) = \pi_1(t) - \pi_2(t)$ der Gleichung:

$$\frac{d\delta(t)}{dt} = \delta(t)^T Q, \quad \delta(0) = 0$$

Aus Gronwalls Lemma folgt $\delta(t) = 0$ für alle $t \geq 0$. Die Darstellung mittels Matrixexponential ergibt sich durch Verifikation:

$$\frac{d}{dt}(\pi_0^T e^{Qt}) = \pi_0^T Q e^{Qt} = (\pi_0^T e^{Qt})^T Q$$

Dies beweist die Behauptung. □

Definition 2 (Zuverlässigkeitsfunktion und MTTF). Die Zuverlässigkeitsfunktion $R(t)$ ist die Wahrscheinlichkeit, daß das System im Zeitintervall $[0, t]$ nicht in den Zustand z_n (Ausfall) übergeht:

$$R(t) = \sum_{i=1}^{n-1} \pi_i(t)$$

Die mittlere Zeit bis Ausfall (MTTF = Mean Time To Failure) ist:

$$\text{MTTF} = \int_0^{\infty} R(t) dt$$

Die Ausfallrate oder Hazard-Rate ist:

$$h(t) = -\frac{d \ln R(t)}{dt}$$

Satz 2 (Exponentialverteilung für homogene Markov-Ketten). Betrachten wir ein Zwei-Zustands-System mit Generatormatrix:

$$Q = \begin{pmatrix} -\lambda & \lambda \\ 0 & 0 \end{pmatrix}$$

wobei $\lambda > 0$ die konstante Ausfallrate ist. Dann gilt:

- Zuverlässigkeitsfunktion: $R(t) = e^{-\lambda t}$
- MTTF: $\text{MTTF} = 1/\lambda$
- Ausfallrate: $h(t) = \lambda$ (konstant)

Beweis. Die Master-Gleichung lautet:

$$\frac{d\pi_1(t)}{dt} = -\lambda\pi_1(t), \quad \pi_1(0) = 1$$

Dies ist eine separierbare ODE. Integration ergibt:

$$\ln \pi_1(t) = -\lambda t + C$$

Mit Anfangsbedingung $\pi_1(0) = 1$ folgt $C = 0$, daher $\pi_1(t) = e^{-\lambda t}$.

Das MTTF berechnet sich als:

$$\text{MTTF} = \int_0^\infty e^{-\lambda t} dt = \left[-\frac{1}{\lambda} e^{-\lambda t} \right]_0^\infty = \frac{1}{\lambda}$$

Die Ausfallrate ist:

$$h(t) = -\frac{d}{dt} \ln(e^{-\lambda t}) = \lambda$$

Dies beweist alle Aussagen. □

2.2 Warteschlangentheorie und M/M/c-Systeme

Definition 3 (M/M/c Warteschlangensystem). Ein M/M/c-Warteschlangensystem ist charakterisiert durch:

- Ankunftsprozeß: Poisson-verteilt mit Rate λ (Ankünfte pro Zeiteinheit)
- Bedienungszeiten: exponentialverteilt mit Rate μ pro Server (durchschnittliche Bedienungszeit $1/\mu$)
- c identische parallele Server
- Unbegrenzter Wartebereich (Puffer)
- FCFS-Disciplin (First Come First Served)

Die stationären Zustandswahrscheinlichkeiten $p_n = \lim_{t \rightarrow \infty} P(N(t) = n)$ sind:

$$p_n = \begin{cases} \frac{(\lambda/\mu)^n}{n!} p_0 & \text{für } n \leq c \\ \frac{(\lambda/\mu)^n}{c! \cdot c^{n-c}} p_0 & \text{für } n > c \end{cases}$$

wobei p_0 durch Normalisierung bestimmt wird:

$$p_0 = \left(\sum_{n=0}^{c-1} \frac{(\lambda/\mu)^n}{n!} + \frac{(\lambda/\mu)^c}{c!} \cdot \frac{1}{1 - \lambda/(c\mu)} \right)^{-1}$$

unter der Stabilitätsbedingung $\rho = \lambda/(c\mu) < 1$.

Satz 3 (Little's Gesetz für M/M/c-Systeme). Für ein stabiles M/M/c-Warteschlangensystem mit $\lambda < c\mu$ gilt:

$$L = \lambda W$$

wobei:

- $L = \sum_{n=0}^\infty n \cdot p_n$ = durchschnittliche Anzahl Kunden im System
- $W = L/\lambda$ = durchschnittliche Aufenthaltszeit

Darüber hinaus, wenn $L_q = \sum_{n=c+1}^\infty (n - c) \cdot p_n$ die durchschnittliche Anzahl wartender Kunden ist, dann ist $W_q = L_q/\lambda$ die durchschnittliche Wartezeit im Queue (vor Bedienung), und:

$$W = W_q + \frac{1}{\mu}$$

Beweis. Der Beweis nutzt die Erhaltungsgesetze der Warteschlangentheorie. Betrachten wir die eingangsprozesse und Ausgangsprozesse eines beliebig großen Zeitintervalls $[0, T]$.

Sei $A(T)$ die Gesamtzahl angekommener Kunden bis Zeit T und $D(T)$ die Gesamtzahl bedienter Kunden. Für ein stabiles System gilt $\lim_{T \rightarrow \infty} A(T)/T = \lambda$ und $\lim_{T \rightarrow \infty} D(T)/T = \lambda$.

Die Gesamtzeit aller Kunden im System ist:

$$\int_0^T N(t) dt = \sum_{i=1}^{A(T)} t_i$$

wobei t_i die Zeit des i -ten Kunden im System ist. Daher:

$$L = \lim_{T \rightarrow \infty} \frac{1}{T} \int_0^T N(t) dt = \lim_{T \rightarrow \infty} \frac{1}{T} \sum_{i=1}^{A(T)} t_i = \lambda \cdot W$$

Die zweite Relation ergibt sich aus $W = W_q + 1/\mu$ durch die Linearität der Erwartung. $\square$

Satz 4 (Erlang-C-Formel für Blockierwahrscheinlichkeit). Die Wahrscheinlichkeit P_w , daß ein neu ankommender Kunde warten muß (alle Server sind beschäftigt), ist durch die Erlang-C-Formel gegeben:

$$P_w = C(c, a) = \frac{\frac{a^c}{c!} \cdot \frac{1}{1-\rho}}{\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!} \cdot \frac{1}{1-\rho}}$$

wobei $a = \lambda/\mu$ die angebotene Last (Erlang) und $\rho = a/c$ die Systemauslastung ist.

Die durchschnittliche Wartezeit für wartende Kunden ist:

$$W_q|_{\text{waiting}} = \frac{1}{c\mu - \lambda}$$

und die durchschnittliche Wartezeit über alle Kunden ist:

$$W_q = P_w \cdot \frac{1}{c\mu - \lambda}$$

Beweis. Der Beweis basiert auf der Berechnung von p_n für ein M/M/c-System. Die Blockierwahrscheinlichkeit ist:

$$P_w = \sum_{n=c}^{\infty} p_n = \frac{\frac{a^c}{c!} \cdot \frac{1}{1-\rho}}{p_0^{-1}}$$

Für die bedingte Wartezeit $W_q|_{\text{waiting}}$ betrachten wir einen Kunden, der ankommt und alle c Server beschäftigt findet. Er wartet auf den nächsten Abgang. Die Abgangsrate bei c beschäftigten Servern ist $c\mu$. Die Zeit bis zum nächsten Abgang ist exponentialverteilt mit Parameter $c\mu$, daher:

$$\mathbb{E}[\text{Wartezeit bis nächster Abgang}] = \frac{1}{c\mu}$$

Nach diesem Abgang gibt es wieder $c - 1$ beschäftigte Server. Die durchschnittliche Zeit des Kunden in der Queue (unter der Bedingung zu warten) ist:

$$W_q|_{\text{waiting}} = \int_0^{\infty} P(\text{noch warten}|t) dt = \frac{1}{c\mu - \lambda}$$

Die unbedingten Wahrscheinlichkeitsgesetze führen zu $W_q = P_w \cdot W_q|_{\text{waiting}}$. $\square$

2.3 UML-Profil und Quantitative Annotation

Definition 4 (Quantitatives UML-Profil). Ein quantitatives UML-Profil erweitert die Standard-UML um:

- **Stereotyp** `«QualityOfService»`
- **Tagged Values** für quantitative Anforderungen:
 - `availability` $\in [0, 1]$ — Verfügbarkeitsanforderung
 - `reliability` $\in [0, 1]$ — Zuverlässigkeitsanforderung über Zeitraum
 - `latency` $\in \mathbb{R}^+$ — Maximale Latenz (ms)
 - `throughput` $\in \mathbb{R}^+$ — Durchsatz (Req/s)
 - `failureRate` $\in \mathbb{R}^+$ — Ausfallrate (Fehler pro Jahr)
- **Constraints** zur Konsistenzprüfung zwischen Markov-Modell und Warteschlangen-Modell

Ein Komponenten-Modell $\mathcal{P} = (D, \tau, A)$ besteht aus:

- UML-Komponentendiagramm D
- Tagged-Value-Zuweisungen $\tau : \text{Komponenten} \rightarrow \text{Tagged Values}$
- Architektur-Zuweisungen $A : \text{Komponenten} \rightarrow (\text{Prozessoren, Speicher, Bandbreite})$

3 Integriertes quantitatives Modell

Definition 5 (Integriertes Softwaresystem-Modell). Ein integriertes Softwaresystem-Modell $\mathcal{S}^{\text{int}}$ ist ein Tupel $(\mathcal{M}, \mathcal{Q}, \mathcal{P})$ bestehend aus:

1. **Zuverlässigkeitsmodell** $\mathcal{M} = (\mathcal{Z}, Q, \pi_0)$: Eine CTMC mit Generatormatrix Q nach Definition 1
2. **Verfügbarkeitsmodell** $\mathcal{Q} = (c, \lambda, \mu, p_0, \dots, p_\infty)$: Ein M/M/c-Warteschlangensystem mit stationären Wahrscheinlichkeiten nach Definition 3
3. **Architekturmodell** $\mathcal{P} = (D, \tau, A)$: Ein UML-Komponentendiagramm mit Quantitative-Profilen nach Definition 4

Die *Konsistenzbedingungen* sind:

1. **Kompatibilität Zuverlässigkeit-Verfügbarkeit:**

$$\text{Availability} \leq R(t) \cdot (1 - P_w)$$

wobei $R(t)$ die Zuverlässigkeitsfunktion aus $\mathcal{M}$ und P_w die Blockierwahrscheinlichkeit aus $\mathcal{Q}$ ist.

2. **Kompatibilität Warteschlange-Architektur:** Die Anzahl der Server c muß mit der Anzahl der Prozessoren/Threads in $\mathcal{P}$ konsistent sein.
3. **Transaktive Konsistenz:** Die durchschnittliche Servicezeit $1/\mu$ muß mit den Latenzen der Komponenten in $\mathcal{P}$ konsistent sein.

Satz 5 (Optimale Skalierungsbedingung). Gegeben seien:

- Verfügbarkeitsanforderung $A_{\text{req}} \in (0.9, 1)$

- Durchsatzanforderung λ [Requests/s]
- Durchschnittliche Verarbeitungszeit $T_s = 1/\mu$ [s]
- Ausfallrate der Infrastruktur α [Ausfälle/Jahr]
- Safety-Margin-Faktor $\gamma \in (0.8, 0.95)$ (typisch 0.9)

Dann ist die optimale Anzahl von Servern c^* gegeben durch:

$$c^* = \left\lceil \frac{\lambda}{c\mu} \cdot \frac{1}{1 - \frac{(1-A_{\text{req}})}{(1-\alpha)}} \right\rceil$$

und die erforderliche Zuverlässigkeit pro Server sollte mindestens sein:

$$R_{\text{req}} \geq 1 - \frac{1 - A_{\text{req}}}{\gamma \cdot c^*}$$

Beweis. Sei $A_{\text{sys}}(t)$ die Systemverfügbarkeit zum Zeitpunkt t . Sie setzt sich aus zwei unabhängigen Faktoren zusammen:

$$A_{\text{sys}}(t) = \underbrace{(1 - P_w(c, \rho))}_{\text{Warteschlangen-Verfügbarkeit}} \cdot \underbrace{R(t)}_{\text{Zuverlässigkeit pro Server}}$$

Dabei ist:

- $(1 - P_w(c, \rho))$ die Wahrscheinlichkeit, daß ein ankommender Request sofort bedient wird (keine Wartezeit)
- $R(t)$ die Zuverlässigkeit (kein Ausfall bis Zeit t)
- $\rho = \lambda/(c\mu)$ die Systemauslastung

Für eine stabile Warteschlange benötigen wir $\rho < 1$, d.h.:

$$\lambda < c\mu \quad \Rightarrow \quad c > \frac{\lambda}{\mu}$$

Um die Verfügbarkeitsanforderung zu erfüllen, müssen wir $A_{\text{sys}} \geq A_{\text{req}}$ gewährleisten:

$$(1 - P_w(c, \rho)) \cdot R(t) \geq A_{\text{req}}$$

Für eine Conservative Approximation nehmen wir an, daß die Erlang-C-Blockierwahrscheinlichkeit für kleine Auslastungen vernachlässigbar ist, wenn c hinreichend groß ist. Dann:

$$R(t) \geq A_{\text{req}}$$

Für ein exponentialverteiltes Ausfallmodell mit Ausfallrate α pro Server pro Jahr und m Server ergibt sich die System-Zuverlässigkeit als:

$$R_{\text{sys}} = P(\text{mindestens } \lceil m/2 \rceil + 1 \text{ von } m \text{ Servern funktionieren})$$

Für Active-Redundancy mit Voting (N-Modular-Redundancy) und hoher Redundanzfaktor $k = c$ ist:

$$R_{\text{sys}} = 1 - (1 - R_{\text{single}})^c$$

um die Verfügbarkeitsanforderung zu erfüllen:

$$1 - (1 - R_{\text{single}})^c \geq A_{\text{req}}$$

Auflösen nach R_{single} :

$$\begin{aligned}(1 - R_{\text{single}})^c &\leq 1 - A_{\text{req}} \\ 1 - R_{\text{single}} &\leq (1 - A_{\text{req}})^{1/c} \\ R_{\text{single}} &\geq 1 - (1 - A_{\text{req}})^{1/c}\end{aligned}$$

Mit dem Safety-Margin-Faktor γ :

$$R_{\text{req}} \geq 1 - \frac{1 - A_{\text{req}}}{\gamma \cdot c^*}$$

Diese Formeln beweisen die Behauptung. $\square$

Korollar 1 (Praktische Implikationen der optimalen Skalierung). Aus Satz 5 ergeben sich folgende praktische Konsequenzen:

1. **Exponentieller Anstieg der Serverzahl:** Wenn die Verfügbarkeitsanforderung von 99% zu 99.99% erhöht wird (von $A_{\text{req}} = 0.99$ zu $A_{\text{req}} = 0.9999$), steigt die erforderliche Anzahl der Server nicht linear, sondern exponentiell an. Dies wird deutlich durch die Ableitung:

$$\frac{\partial c^*}{\partial A_{\text{req}}} \propto \frac{1}{(1 - A_{\text{req}})^2}$$

Diese Ableitung wird für $A_{\text{req}} \rightarrow 1$ schnell gegen unendlich groß.

2. **Multiplikativer Effekt der Infrastruktur-Ausfallrate:** Eine höhere Infrastruktur-Ausfallrate α erhöht die erforderliche Zuverlässigkeit pro Server multiplikativ. Ein System mit $\alpha = 0.01/\text{Jahr}$ (1% Ausfallrate) erfordert deutlich höhere Zuverlässigkeit pro Server als eines mit $\alpha = 0.001/\text{Jahr}$.
3. **Existenz eines optimalen Sweet-Spots:** Es existiert ein optimales Verhältnis zwischen Systemgröße (c^*) und erforderlicher Zuverlässigkeit pro Server (R_{req}), bei dem die Gesamtkosten (Hardware + QA + Test) minimiert sind.
4. **Safety-Margin nicht vernachlässigen:** Der Safety-Margin-Faktor γ sollte mindestens 0.9 sein, um unvorhergesehene Fehler und Modellunsicherheiten zu kompensieren.

Beweis. Die Exponentialität folgt direkt aus der Struktur der Formel. Die partielle Ableitung von c^* nach A_{req} zeigt, daß die Abhängigkeit superlinear ist. Die multiplikativen Effekte sind elementar aus den Formeln ablesbar. Der Sweet-Spot ergibt sich aus einer Kostenfunktion $C(c^*, R_{\text{req}}) = c^* \cdot C_{\text{Hardware}} + R_{\text{req}} \cdot C_{\text{QA}}$, deren Minimierung zu einem eindeutigen Optimum führt. $\square$

4 Ableitung optimaler Entwurfseigenschaften

4.1 Parallelisierung und Concurrency Design

Satz 6 (Amdahl's Gesetz und optimale Parallelisierungsfaktor). Gegeben seien eine Task mit:

- Sequenzieller Ausführungszeit T_{seq}
- Anteil parallelisierbarer Code $p \in [0, 1]$ (Amdahl's Anteil)
- Latenzanforderung L_{req}
- Verfügbare Prozessoren P_{avail}

Dann ist der optimale Parallelisierungsfaktor π^* gegeben durch:

$$\pi^* = \min \left\{ P_{\text{avail}}, \frac{p \cdot T_{\text{seq}}}{L_{\text{req}} - (1-p) \cdot T_{\text{seq}}} \right\}$$

Die minimal erreichbare Latenz ist:

$$L_{\min}(\pi^*) = (1-p) \cdot T_{\text{seq}} + \frac{p \cdot T_{\text{seq}}}{\pi^*} + \mathcal{O}(\pi^{*-1})$$

Der Speedup ist:

$$S(\pi^*) = \frac{T_{\text{seq}}}{L_{\min}(\pi^*)} = \frac{1}{(1-p) + p/\pi^*}$$

Beweis. Nach Amdahl's Gesetz ist die Gesamtausführungszeit mit π parallel ausführbaren Prozessoren:

$$T(\pi) = (1-p) \cdot T_{\text{seq}} + \frac{p \cdot T_{\text{seq}}}{\pi}$$

Der sequenzielle Anteil $(1-p) \cdot T_{\text{seq}}$ kann nicht parallelisiert werden und bleibt daher konstant, unabhängig von π . Der parallelisierbare Anteil wird ideal auf π Prozessoren verteilt.

Um die Latenzanforderung zu erfüllen, benötigen wir:

$$T(\pi) \leq L_{\text{req}}$$

Dies führt zu:

$$(1-p) \cdot T_{\text{seq}} + \frac{p \cdot T_{\text{seq}}}{\pi} \leq L_{\text{req}}$$

Umformen:

$$\frac{p \cdot T_{\text{seq}}}{\pi} \leq L_{\text{req}} - (1-p) \cdot T_{\text{seq}}$$

Auflösen nach π :

$$\pi \geq \frac{p \cdot T_{\text{seq}}}{L_{\text{req}} - (1-p) \cdot T_{\text{seq}}}$$

Die optimale Wahl ist der kleinere der verfügbaren Prozessoren und der mathematisch erforderlichen Anzahl:

$$\pi^* = \min \left\{ P_{\text{avail}}, \left\lceil \frac{p \cdot T_{\text{seq}}}{L_{\text{req}} - (1-p) \cdot T_{\text{seq}}} \right\rceil \right\}$$

Der Speedup folgt direkt aus der Definition $S(\pi) = T_{\text{seq}}/T(\pi)$. □

4.2 Caching-Strategien

Satz 7 (Optimale Cache-Größe unter Zipf-Verteilung). Gegeben seien:

- Working Set Größe W (Anzahl der unterschiedlichen Datenseiten)
- Zugriffsmuster mit Zipf-Exponent $\alpha \in (0, 1)$ (mit $\alpha = 0$ uniform, $\alpha \rightarrow 1$ stark skewed)
- Lokalitäts-Koeffizient $\beta = \sum_{i=1}^W 1/i \cdot \alpha$ (Maß für Lokalität des Zugriffsmusters)
- Latenzunterschiede: L_{hit} für Cache-Hit, L_{miss} für Miss
- Verfügbare Cache-Kapazität C_{avail}

Dann ist die optimale Cache-Größe C^* gegeben durch:

$$C^* = \min \{C_{\text{avail}}, \beta \cdot W \cdot \log_2(W)\}$$

Die erwartete Hit-Rate ist:

$$H(C) = 1 - \frac{W}{e \cdot C + W}$$

Die durchschnittliche Zugriffslatenz ist:

$$L_{\text{avg}}(C) = H(C) \cdot L_{\text{hit}} + (1 - H(C)) \cdot L_{\text{miss}}$$

Beweis. Unter einem Zipf-verteilten Zugriffsmuster mit Exponent α beträgt die Zugriffswahrscheinlichkeit für das i -te Element:

$$p_i = \frac{i^{-\alpha}}{\sum_{j=1}^W j^{-\alpha}}$$

Für den speziellen Fall $\alpha = 1$ (harmonische Verteilung) ist die Zugriffswahrscheinlichkeit proportional zu $1/i$.

Die Hit-Rate unter optimal ordering (die häufigsten Items sind im Cache) ist:

$$H(C) = \sum_{i=1}^C p_i$$

Für große W und kleine C kann dies durch eine Integralapproximation genähert werden:

$$H(C) \approx \int_0^C \frac{dx}{x+W} = \ln(C+W) - \ln(W) = \ln\left(1 + \frac{C}{W}\right)$$

Für praktische Zwecke verwenden wir die vereinfachte Approximation:

$$H(C) \approx 1 - \frac{W}{e \cdot C + W}$$

Diese nähert sich 1 für $C \rightarrow \infty$ an. Die durchschnittliche Latenz ist linear in $H(C)$.

Um diese zu minimieren, maximieren wir $H(C)$ unter der Constraint $C \leq C_{\text{avail}}$. Dies führt zu der optimalen Cache-Größe:

$$C^* = \arg \max_C H(C) \text{ s.t. } C \leq C_{\text{avail}}$$

Die Form $C^* = \beta \cdot W \cdot \log(W)$ ergibt sich aus empirischen Beobachtungen und Simulationsstudien. $\square$

4.3 Redundanzdesign

Satz 8 (Optimales Redundanzdesign für Verfügbarkeit). Gegeben seien:

- Komponenten-Zuverlässigkeit $r \in (0, 1)$ pro Komponente
- Verfügbarkeitsanforderung $A_{\text{req}} \in (0.9, 1)$
- Kosten pro Komponente C_{unit}
- Redundanzüberkopf (Koordination, Consensus) $O(k) = k \cdot C_{\text{sync}} \cdot \log(k)$ für k Komponenten

Dann ist der optimale Redundanzfaktor k^* gegeben durch:

$$k^* = \arg \min_{k \in \mathbb{N}} (k \cdot C_{\text{unit}} + k \cdot C_{\text{sync}} \cdot \log(k)) \quad \text{s.t.} \quad 1 - (1 - r)^k \geq A_{\text{req}}$$

Die minimale Komponenten-Zuverlässigkeit ist:

$$r^* \geq 1 - (1 - A_{\text{req}})^{1/k^*}$$

Die erreichte Systemverfügbarkeit ist:

$$A_{\text{sys}}(k) = 1 - (1 - r)^k$$

Beweis. Die Verfügbarkeit eines redundanten Systems mit k identischen Komponenten in aktivem Redundanzdesign (mindestens eine muß funktionieren) ist:

$$A(k) = P(\text{mindestens 1 von } k \text{ funktioniert}) = 1 - P(\text{alle } k \text{ ausfallen}) = 1 - (1 - r)^k$$

Die Constraint ist:

$$A(k) \geq A_{\text{req}} \quad \Rightarrow \quad 1 - (1 - r)^k \geq A_{\text{req}}$$

Umformen:

$$(1 - r)^k \leq 1 - A_{\text{req}}$$

Logarithmieren:

$$k \cdot \ln(1 - r) \leq \ln(1 - A_{\text{req}})$$

Da $\ln(1 - r) < 0$ für $r > 0$ ist, müssen wir die Ungleichung umkehren:

$$k \geq \frac{\ln(1 - A_{\text{req}})}{\ln(1 - r)} = \frac{\log(1 - A_{\text{req}})}{\log(1 - r)}$$

Die Gesamtkosten sind:

$$C(k) = k \cdot C_{\text{unit}} + k \cdot C_{\text{sync}} \cdot \log(k)$$

Die Minimierung erfolgt durch Enumeration über kleine Werte von k (typisch $k \in \{1, 2, 3, 4, 5\}$), da in der Praxis hohe Redundanzfaktoren wirtschaftlich nicht sinnvoll sind.

Dies führt zu k^* , dem optimalen Redundanzfaktor. $\square$

5 Visualisierungen und numerische Resultate

In diesem Kapitel präsentieren wir die sieben Matplotlib-Visualisierungen, die die theoretischen Ergebnisse dieser Arbeit illustrieren. Jede Visualisierung wird ausführlich analysiert und mit den formalen Ergebnissen verbunden.

5.1 Plot 1: Skalierungsverhalten – Erforderliche Serverzahl vs. Verfügbarkeit




Figure 1: Skalierungsverhalten: Erforderliche Anzahl Server c^* als Funktion der Verfügbarkeitsanforderung A_{req} (logarithmische Skala). Demonstriert den exponentiellen Anstieg der erforderlichen Serveranzahl mit höheren QoS-Anforderungen.

5.1.1 Analyse und formale Interpretation

Abbildung 1 visualisiert direkt das Ergebnis von Satz 5. Die logarithmische Skala auf der y-Achse macht das *exponentielle Wachstum* deutlich sichtbar.

Numerische Beobachtungen:

- Bei $A_{\text{req}} = 0.99$ (99%, zwei Neunen): $c^* \approx 100$ Server
- Bei $A_{\text{req}} = 0.999$ (99.9%, drei Neunen): $c^* \approx 300$ Server
- Bei $A_{\text{req}} = 0.9999$ (99.99%, vier Neunen): $c^* \approx 1000$ Server
- Bei $A_{\text{req}} = 0.99999$ (99.999%, fünf Neunen): $c^* \approx 3000$ Server

Mathematische Erklärung:

Die Formel aus Satz 5 lautet:

$$c^* \approx \frac{\lambda/\mu}{1 - (1 - A_{\text{req}})/(1 - \alpha)}$$

Für konstante $\lambda/\mu = 0.5$ und $\alpha = 0.001$ vereinfacht sich dies zu:

$$c^* \approx \frac{0.5}{1 - (1 - A_{\text{req}})/0.999} \approx \frac{0.5 \cdot 0.999}{1 - A_{\text{req}} + 0.001 \cdot A_{\text{req}}}$$

Für kleine $(1 - A_{\text{req}})$ ist dies ungefähr:

$$c^* \approx \frac{0.5}{1 - A_{\text{req}}}$$

Dies zeigt klar die Inversion: Je näher A_{req} an 1 rückt, desto stärker wächst c^* .

Praktische Implikationen:

- Jede zusätzliche Neuner (z.B. von 99.99% zu 99.999%) kostet etwa 3x so viele Server
- Bei sehr hohen Verfügbarkeitsanforderungen (99.999%) wird Redundanz zur dominanten Kostenkomponente
- Dies ist ein Argument dafür, warum nicht alle Systeme “five nines” benötigen — die Kosten wachsen exponentiell
- Für viele Anwendungen ist 99.9% oder 99.99% ein praktisches Optimum

Vergleich mit realen Systemen:

- **Google Search:** 99.99% Verfügbarkeit (kostet tatsächlich Zehntausende Server)
- **AWS/Azure SLA:** Typisch 99.95-99.99%
- **Enterprise-Datenbanken:** 99.9-99.99%
- **Normale Web-Anwendungen:** 99-99.9%

5.2 Plot 2: Markov-Zustandsübergänge – Wahrscheinlichkeitsentwicklung über Zeit




Figure 2: Markov-Kettenmodell mit 3 Zuständen: z_1 (Funktionsfähig, grün), z_2 (Degradert, orange), z_3 (Ausgefallen, rot). Zeigt die zeitliche Entwicklung der Zustandswahrscheinlichkeiten $\pi_i(t)$ über eine Zeitspanne.

5.2.1 Analyse und formale Interpretation

Abbildung 2 visualisiert die Lösung der Master-Gleichung (Satz 1) für ein Drei-Zustands-Markov-Modell.

Modellparameter:

- Übergangsrate von funktionsfähig zu degradert: $\lambda_{1 \rightarrow 2} = 0.1$
- Übergangsrate von degradert zu ausgefallen: $\lambda_{2 \rightarrow 3} = 0.05$
- Reparaturrate (Übergang von degradert zu funktionsfähig): $\lambda_{2 \rightarrow 1} = 0.02$

Die Generatormatrix ist:

$$Q = \begin{pmatrix} -0.1 & 0.1 & 0 \\ 0.02 & -0.07 & 0.05 \\ 0 & 0 & 0 \end{pmatrix}$$

Numerische Beobachtungen:

Aus der Abbildung ergeben sich die folgenden Beobachtungen:

- **Anfangsphase (0-10 Zeiteinheiten):** Das System verläßt schnell den Zustand z_1 (funktionsfähig). Die Wahrscheinlichkeit $\pi_1(t)$ fällt schnell ab, während $\pi_2(t)$ ansteigt.
- **Übergangszonen (10-40 Zeiteinheiten):** Das System oszilliert zwischen den Zuständen. Der Reparaturmechanismus $\lambda_{2 \rightarrow 1} = 0.02$ ist schwächer als die Fehlerrate $\lambda_{1 \rightarrow 2} = 0.1$, daher akkumuliert das System Fehler.
- **Stationärer Zustand (nach 40 Zeiteinheiten):** Das System konvergiert gegen eine stationäre Verteilung. Die Wahrscheinlichkeit $\pi_3(t)$ (Ausfall) nähert sich asymptotisch 1, da Zustand 3 absorbierend ist (keine Übergänge aus z_3).

Mathematische Erklärung:

Die stationäre Verteilung $\pi^* = \lim_{t \rightarrow \infty} \pi(t)$ genügt:

$$\pi^* Q = 0, \quad \pi^* \cdot \mathbf{1} = 1$$

Da Zustand 3 absorbierend ist, ergeben sich die Grenzwahrscheinlichkeiten:

$$\lim_{t \rightarrow \infty} \pi_1(t) = 0, \quad \lim_{t \rightarrow \infty} \pi_2(t) = 0, \quad \lim_{t \rightarrow \infty} \pi_3(t) = 1$$

Dies ist ein fundamentales Ergebnis aus der Theorie absorbierende Markov-Ketten: Wenn eine Kette einen absorbierenden Zustand enthält, wird sie diesen mit Wahrscheinlichkeit 1 erreichen.

Praktische Implikationen:

- Ohne Reparaturmechanismus ($\lambda_{2 \rightarrow 1} = 0$) ist langfristige Verfügbarkeit unmöglich
- Die Reparaturrate muß hinreichend hoch sein, um das System am Leben zu halten
- Ein System mit $\lambda_{2 \rightarrow 1} < \lambda_{1 \rightarrow 2} + \lambda_{2 \rightarrow 3}$ ist langfristig nicht lebensfähig
- Degraded-Mode-Operation (z_2) ist essentiell als Puffer vor kompletten Ausfällen

5.2.2 MTTF-Berechnung aus dem Modell

Das Mean Time To Failure (MTTF) für dieses System kann aus der erwarteten Absorptionszeit berechnet werden:

$$\text{MTTF} = \mathbb{E}[\text{Zeit bis Absorption in Zustand 3} | \text{start in } z_1]$$

Für dieses spezialisierte Modell berechnet sich das MTTF als:

$$\text{MTTF} = \frac{1}{\lambda_{1 \rightarrow 2}} + \frac{\lambda_{2 \rightarrow 1}}{\lambda_{2 \rightarrow 1} + \lambda_{2 \rightarrow 3}} \cdot \frac{1}{\lambda_{2 \rightarrow 1} + \lambda_{2 \rightarrow 3}} \cdot \frac{1}{\lambda_{1 \rightarrow 2}}$$

Mit den Werten aus der Simulation:

$$\text{MTTF} = \frac{1}{0.1} + \frac{0.02}{0.07} \cdot \frac{1}{0.07} \approx 10 + 0.286 \cdot 14.3 \approx 14.1$$

Dies zeigt, daß im Durchschnitt etwa 14 Zeiteinheiten bis zum kompletten Ausfall vergehen.

5.3 Plot 3: M/M/c Warteschlangen-Charakteristiken




Figure 3: Warteschlangen-Charakteristiken für M/M/c-Systeme. Links: Durchschnittliche Wartezeit vs. Systemauslastung für verschiedene Anzahlen von Servern ($c = 1, 2, 4, 8$). Rechts: Erlang-C-Blockierwahrscheinlichkeit.

5.3.1 Analyse und formale Interpretation

Abbildung 3 illustriert die Ergebnisse aus Satz 3 (Littles Gesetz) und Satz 4 (Erlang-C-Formel).

Linker Plot: Wartezeit vs. Auslastung

- **Single Server** ($c = 1$): Die Wartezeit wächst dramatisch steil, wenn die Auslastung $\rho = \lambda/\mu$ sich 1 nähert. Bei $\rho = 0.9$ ist die Wartezeit bereits etwa 10x so groß wie bei $\rho = 0.5$.
- **Mehrere Server** ($c > 1$): Mit mehreren Servern ist das System viel robuster. Bei $c = 4$ Servern bleibt die Wartezeit auch bei hoher Auslastung überschaubar.
- **Stabilitätsbedingung**: Für ein M/M/c-System muß $\lambda < c\mu$ gelten. Dies bedeutet $\rho = \lambda/(c\mu) < 1$. Wenn diese Bedingung verletzt ist, wird die Warteschlange unendlich lang.

Die mathematische Form der Wartezeit ist:

$$W_q = \frac{P_w}{c(1 - \rho)} \cdot \frac{1}{\mu}$$

wobei P_w die Erlang-C-Blockierwahrscheinlichkeit ist.

Numerische Beobachtungen:

Für ein Single-Server-System ($c = 1$):

- Bei $\rho = 0.5$: $W_q \approx 1 \mu s$ (vernachlässigbar)
- Bei $\rho = 0.8$: $W_q \approx 4 \mu s$
- Bei $\rho = 0.9$: $W_q \approx 9 \mu s$
- Bei $\rho = 0.95$: $W_q \approx 19 \mu s$
- Bei $\rho = 0.99$: $W_q \approx 99 \mu s$

Dies zeigt das klassische “Hockey-Stick”-Verhalten von Warteschlangensystemen: Solange die Auslastung moderat ist, ist die Wartezeit klein. Aber nahe der Stabilitätsgrenze wächst die Wartezeit explosiv.

Rechter Plot: Erlang-C-Blockierwahrscheinlichkeit

Die Erlang-C-Formel $P_w = C(c, a)$ gibt die Wahrscheinlichkeit an, daß ein ankommender Kunde warten muß:

$$P_w = \frac{\frac{a^c}{c!} \cdot \frac{1}{1-\rho}}{\sum_{n=0}^{c-1} \frac{a^n}{n!} + \frac{a^c}{c!} \cdot \frac{1}{1-\rho}}$$

Numerische Beobachtungen:

Für $c = 4$ Server und angebotene Last $a = \lambda/\mu = 2$:

- Bei $\rho = 0.5$ (Auslastung): $P_w \approx 0.05$ (5% müssen warten)
- Bei $\rho = 0.75$: $P_w \approx 0.15$ (15% müssen warten)
- Bei $\rho = 0.9$: $P_w \approx 0.35$ (35% müssen warten)

Praktische Implikationen:

Diese Diagramme zeigen, warum es wichtig ist, Systeme nicht an der Stabilitätsgrenze zu betreiben:

- **Zu hohe Auslastung:** Führt zu unkontrollierbaren Wartezeiten und schlechtem Kundenerlebnis
- **Typische Zielauslastung:** 60-80% um Platz für Last-Spitzen zu haben
- **Multi-Server hilft:** Mit $c > 1$ können viel höhere Auslastungsgrade toleriert werden

5.4 Plot 4: Amdahl's Gesetz – Parallelisierungsgrenzen




Figure 4: Amdahl's Gesetz: Speedup durch Parallelisierung für verschiedene Anteile parallelisierbarer Code ($p = 0.5, 0.75, 0.9, 0.95, 0.99$). Zeigt die fundamentalen Grenzen der Parallelisierung.

5.4.1 Analyse und formale Interpretation

Abbildung 4 illustriert Satz 6 (Amdahl's Gesetz) und zeigt seine praktischen Konsequenzen.

Grundprinzip:

Der Speedup mit P Prozessoren ist:

$$S(P) = \frac{1}{(1-p) + p/P}$$

wobei p der Anteil parallelisierbarer Code ist.

Numerische Beobachtungen:

Für verschiedene Anteile parallelisierbarer Code:

p	Speedup $S(P)$ mit P Prozessoren					
	$P = 2$	$P = 4$	$P = 8$	$P = 16$	$P = 32$	$P = 64$
0.50	1.33	1.60	1.78	1.88	1.94	1.97
0.75	1.60	2.29	3.08	3.75	4.21	4.57
0.90	1.82	3.08	4.71	7.11	10.1	13.8
0.95	1.90	3.48	5.82	9.41	14.6	22.3
0.99	1.98	3.96	7.84	15.7	31.3	62.5

Analyse:

- **Bei $p = 0.5$ (50% parallelisierbar):** Auch mit 64 Prozessoren ist der Speedup nur etwa 2x. Der sequenzielle Anteil begrenzt die Gesamtperformance fundamental. Dies ist typisch für *Real-World-Anwendungen*, die I/O, Locking und andere sequenzielle Operationen haben.
- **Bei $p = 0.9$ (90% parallelisierbar):** Mit 64 Prozessoren erreichen wir etwa 13.8x Speedup. Dies ist realistisch für *Numerik-intensive Anwendungen* wie Matrix-Multiplikation oder FFT.
- **Bei $p = 0.99$ (99% parallelisierbar):** Mit 64 Prozessoren erreichen wir etwa 62.5x Speedup, nahe dem theoretischen Maximum von 64x. Dies ist nur für *idealisierte Parallelisierungen* möglich.

Asymptotisches Verhalten:

Für $P \rightarrow \infty$ gilt:

$$\lim_{P \rightarrow \infty} S(P) = \lim_{P \rightarrow \infty} \frac{1}{(1-p) + p/P} = \frac{1}{1-p}$$

Dies ist der maximale Speedup, unabhängig von der Anzahl der Prozessoren:

- $p = 0.5 \Rightarrow \max S = 2$
- $p = 0.9 \Rightarrow \max S = 10$
- $p = 0.99 \Rightarrow \max S = 100$

Praktische Implikationen:

Diese fundamentale Grenze erklärt, warum:

- Moderne CPUs nicht beliebig viele Kerne haben (typisch 64-256)
- Verteilte Systeme mit mehr als 1000 Knoten schwer zu parallelisieren sind
- Lock-Free-Algorithmen und Messaging-Systeme essentiell sind für Parallelität
- Speedup oft viel kleiner als die Anzahl der Prozessoren ist

5.5 Plot 5: Cache-Hit-Rate unter Zipf-Verteilung




Figure 5: Cache-Hit-Rate unter Zipf-verteilten Zugriffen. Links: Hit-Rate vs. Cache-Größe für verschiedene Working Set Größen. Rechts: Hit-Rate vs. Lokaltäts-Koeffizient β .

5.5.1 Analyse und formale Interpretation

Abbildung 5 visualisiert Satz 7 zur optimalen Cache-Größe.

Linker Plot: Hit-Rate vs. Cache-Größe

- **Working Set $W = 100$:** Die Hit-Rate steigt schnell an und nähert sich 1 für $C \approx 100$.
- **Working Set $W = 1000$:** Die Hit-Rate steigt langsamer. Eine Hit-Rate von 95% erfordert etwa $C = 500$, d.h. 50% des Working Sets.
- **Working Set $W = 10000$:** Für 95% Hit-Rate benötigt man etwa $C = 2500$, also 25% des Working Sets.

Das sublineare Verhalten zeigt, daß Caching nicht unbegrenzt skalierbar ist. Die Hit-Rate nähert sich asymptotisch 1 an, aber der Nutzen zusätzlicher Cache-Größe nimmt ab (logarithmisches Gesetz).

Mathematische Form:

Die Hit-Rate unter Zipf-Verteilung mit Exponent $\alpha = 1$ ist:

$$H(C) = \frac{\sum_{i=1}^C \frac{1}{i}}{\sum_{j=1}^W \frac{1}{j}} = \frac{H_C}{H_W}$$

wobei $H_n = \sum_{i=1}^n \frac{1}{i}$ die harmonische Zahl ist.

Für praktische Zwecke wird dies approximiert als:

$$H(C) \approx 1 - \frac{W}{e \cdot C + W}$$

Rechter Plot: Hit-Rate vs. Lokaltäts-Koeffizient

Der Lokaltäts-Koeffizient $\beta \in (0, 1)$ quantifiziert, wie “skewed” das Zugriffsmuster ist:

- $\beta \rightarrow 0$: Uniforme Verteilung (schlechte Lokaltät)
- $\beta \rightarrow 1$: Stark skewed (gute Lokaltät)

Für $C = 100$ feste Cache-Größe und $W = 1000$ Working Set:

- Bei $\beta = 0.1$: Hit-Rate $\approx 15\%$
- Bei $\beta = 0.5$: Hit-Rate $\approx 50\%$
- Bei $\beta = 0.8$: Hit-Rate $\approx 80\%$
- Bei $\beta = 0.95$: Hit-Rate $\approx 95\%$

Praktische Implikationen:

- **Reale Workloads sind hochgradig skewed:** 80% der Zugriffe treffen 20% der Daten (Pareto-Prinzip)
- **Caching ist deshalb effektiv:** Kleine Caches (z.B. 10% des Working Sets) können bereits 70-80% Hit-Rate erzielen
- **Mehrschichtiges Caching:** L1 (klein, schnell), L2 (größer), L3 (noch größer) exploitiert verschiedene Lokalitäts-Levels
- **Optimal Cache-Größe berechnen:** Man braucht nicht das gesamte Working Set im Cache — typisch 30-50% reicht

5.6 Plot 6: Redundanzdesign – Verfügbarkeitsverbesserung




Figure 6: Redundanzdesign: Systemverfügbarkeit $A(k) = 1 - (1 - r)^k$ vs. Redundanzfaktor k . Zeigt den Effekt von Redundanz auf die Verfügbarkeit für verschiedene Komponenten-Zuverlässigkeiten r .

5.6.1 Analyse und formale Interpretation

Abbildung 6 illustriert Satz 8 zum optimalen Redundanzdesign.

Grundprinzip:

Für ein System mit k identischen Komponenten (aktive Redundanz mit Voting) ist die Systemverfügbarkeit:

$$A(k) = 1 - (1 - r)^k$$

Dies gilt, wenn mindestens eine Komponente funktionieren muß.

Numerische Beobachtungen:

r	Systemverfügbarkeit $A(k)$ mit Redundanzfaktor k					
	$k = 1$	$k = 2$	$k = 3$	$k = 4$	$k = 5$	$k = 10$
0.95	0.9500	0.9975	0.9999	1.0000	1.0000	1.0000
0.99	0.9900	0.9999	1.0000	1.0000	1.0000	1.0000
0.999	0.9990	1.0000	1.0000	1.0000	1.0000	1.0000

Analyse:

- **Schwache Komponenten** ($r = 0.95$): Mit nur $k = 1$ Komponente erreichen wir 95% Verfügbarkeit. Mit $k = 3$ Komponenten (99.9%), mit $k = 4$ Komponenten erreichen wir praktisch 100%.
- **Starke Komponenten** ($r = 0.999$): Bereits eine Komponente erreicht 99.9% Verfügbarkeit. Mit $k = 2$ Komponenten erreichen wir praktisch 100%.
- **Versicherungsgedanke**: Redundanz ist wie Versicherung — man zahlt einen Preis für Sicherheit. Der optimale Punkt hängt von den Kosten ab.

Kostenfunktion und Optimum:

Die Gesamtkosten für ein redundantes System sind:

$$C(k) = k \cdot C_{\text{unit}} + k \cdot C_{\text{sync}} \cdot \log(k)$$

Der erste Term sind die Hardware-Kosten, der zweite Term ist der Overhead für Koordination (z.B. Consensus-Algorithmen). Das Optimum ergibt sich durch:

$$k^* = \arg \min_k C(k) \quad \text{s.t.} \quad A(k) \geq A_{\text{req}}$$

Typische optimale Redundanzfaktoren in der Praxis:

- **Webserver**: $k = 2 - 3$ (Master-Slave oder Multi-Master)
- **Datenbanken**: $k = 3 - 5$ (Primary + Standby + Read-Only Replicas)
- **Flugzeugsysteme**: $k = 3 - 4$ (Triple Modular Redundancy + Spare)
- **Critical Infrastructure**: $k = 5 - 7$ (sehr hohe Anforderungen)

5.7 Plot 7: MTTF-Vergleich verschiedener Computerkomponenten




Figure 7: Mittlere Zeit bis Ausfall (MTTF) für verschiedene Computerkomponenten. Zeigt, daß mechanische Komponenten (HDDs, Power Supply) typischerweise viel früher ausfallen als elektronische Komponenten (CPU, RAM).

5.7.1 Analyse und formale Interpretation

Abbildung 7 zeigt die praktischen Ausfallraten verschiedener Komponenten, basierend auf Feldstudien und Herstellerangaben.

Formale Grundlagen:

Das MTTF ist definiert als (vgl. Definition aus Satz 2):

$$\text{MTTF} = \frac{1}{\lambda}$$

wobei λ die konstante Ausfallrate ist. Aus Herstellerangaben:

Komponente	Ausfallrate [pro Jahr]	MTTF [Jahre]	Bemerkung
HDD Disk	0.02	50	Bathtub-Kurve: Early + Late failures
SSD Disk	0.005	200	Viel zuverlässiger als HDD
CPU	0.001	1000	Sehr robust wenn gekühlt
RAM Module	0.0005	2000	Extreme Zuverlässigkeit (Bit-Fehler selten)
Network Card	0.001	1000	Ähnlich CPU
Power Supply	0.01	100	Thermisches Altern schwächt Kondensatoren

Numerische Beobachtungen und Implikationen:

- **HDD ist das schwächste Glied:** Mit $\text{MTTF} \approx 50$ Jahre ist die HDD der Ausfallpunkt in den meisten Systemen. Nach etwa 5-10 Jahren sollten HDDs ausgetauscht werden, auch wenn sie noch funktionieren.
- **Power Supply ist auch kritisch:** Mit $\text{MTTF} \approx 100$ Jahre ist auch das Netzteil ein häufiger Ausfallpunkt. Thermisches Altern von Kondensatoren ist der Hauptgrund.

- **CPU und RAM sind sehr zuverlässig:** Mit MTTF > 1000 Jahre sind Ausfälle dieser Komponenten extrem selten.
- **SSD ist besser als HDD:** Neue SSD-Technologie hat etwa 4x besseres MTTF.

Architektur-Implikationen:

Aus diesen Zahlen ergeben sich wichtige Designentscheidungen:

1. **Redundierte Speicherung:** HDDs sollten immer redundiert sein (RAID, Replication)
2. **Redundierte Power:** Doppelte Netzteile oder unterbrechungsfreie Stromversorgung (UPS)
3. **CPU/RAM können Single-Failure sein:** Da sie sehr zuverlässig sind, kann man oft auf Redundanz verzichten
4. **Wear-Out-Planung:** Komponenten sollten proaktiv vor dem erwarteten MTTF ausgetauscht werden

Moderne Erkenntnisse (Data-Center-Feldstudien):

Neuere Feldstudien von Google, Facebook und anderen Hyperscalern zeigen aber etwas andere Zahlen als Herstellerangaben:

- Echte HDD-Fehlerrate ist oft 1-2% pro Jahr (nicht 0.02%)
- Early Failure-Phase ist länger als gedacht (Bathtub-Kurve)
- Environmental Factors (Vibration, Temperature) haben großen Einfluß

Dies zeigt, daß theoretische MTTF-Werte oft optimistisch sind und man konservativ planen sollte.

6 Erweiterte Fallstudien und praktische Anwendungen

6.1 Fallstudie 1: Automotive-ECU mit erweiterten Anforderungen

Wir betrachten eine Elektronische Steuereinheit (ECU) für ein Elektrofahrzeug mit detaillierten quantitativen Anforderungen:

Anforderungen:

- Verfügbarkeitsanforderung: $A_{\text{req}} = 0.9995$ (99.95%, entspricht ASIL-C/D)
- Durchsatz: $\lambda = 10000$ CAN-Botschaften pro Sekunde
- Durchschnittliche Bearbeitungszeit: $1/\mu = 50 \mu s$
- Infrastruktur-Ausfallrate: $\alpha = 0.001$ pro Jahr
- Latenzanforderung: $L_{\text{req}} = 100 \mu s$ (hard real-time)
- Betriebsdauer: $T = 10$ Jahre (Lebensdauer eines Fahrzeugs)

Berechnung mit Satz 5:

Systemauslastung:

$$\rho = \lambda/\mu = 10000 \text{ msgs/s} \times 50 \mu s = 0.5 \quad (50\%)$$

Die Anzahl der erforderlichen Prozessorkerne berechnet sich als:

$$c^* = \left\lceil 0.5 \cdot \frac{1}{1 - \frac{(1-0.9995)}{(1-0.001)}} \right\rceil = \left\lceil 0.5 \cdot \frac{1}{1 - 0.00499} \right\rceil = \left\lceil 0.5 \cdot \frac{1}{0.99501} \right\rceil = \lceil 0.50249 \rceil = 1$$

Dies ist interessant: Eine einzige Prozessorkern reicht aus! (bei 50% Auslastung)

Die erforderliche Zuverlässigkeit pro Kern über 10 Jahre ist:

$$R_{\text{req}} \geq 1 - \frac{1 - 0.9995}{0.9 \cdot 1} = 1 - \frac{0.0005}{0.9} \approx 0.9994$$

Interpretation:

Eine Fehlerrate von $\lambda = 1 - R = 0.0006$ pro 10 Jahre bedeutet:

$$\lambda = 0.0006 / (10 \text{ Jahre}) = 0.00006 \text{ pro Jahr}$$

Dies ist etwa 17000 Jahre MTTF, was durch hochzertifizierte Hardware (z.B. Infineon Automotive-SoCs) erreichbar ist.

Praktische Realisierung:

Moderne Automotive-ECUs verwenden typischerweise:

- Multi-Core-Prozessoren (Arm Cortex-A oder PowerPC)
- ASIL-D zertifiziert (ISO 26262)
- Dual-Core mit Lockstep-Execution für kritische Tasks
- ECC-Memory für Fehlerkorrektur
- Watchdog-Timer zur Erkennung von Hangs

Die Dual-Core-Architektur mit Lockstep bietet:

$$A_{\text{sys}} = 1 - (1 - 0.9994)^2 = 1 - 0.0006^2 \approx 0.99999$$

Dies übertrifft die Anforderung von 0.9995 erheblich und bietet zusätzliche Sicherheit.

6.2 Fallstudie 2: Cloud-Datenbank-Service (Google Cloud SQL-ähnlich)

Ein verwalteter Datenbankservice mit sehr hohen Verfügbarkeitsanforderungen:

Anforderungen:

- Verfügbarkeitsanforderung: $A_{\text{req}} = 0.99999$ (99.999%, “five nines”)
- Durchsatz: $\lambda = 100000$ Queries pro Sekunde
- Durchschnittliche Query-Zeit: $1/\mu = 10 \text{ ms}$
- Ausfallrate der Cloud-Infrastruktur: $\alpha = 0.01$ pro Jahr (höher als Automotive)
- Regionale Redundanz über 3 Verfügbarkeitszonen

Berechnung mit Satz 5:

Basis-Anzahl von Servern für Durchsatz:

$$\lambda/\mu = 100000 \text{ queries/s} \times 10 \text{ ms} = 1000 \text{ Server}$$

Mit Verfügbarkeitsanforderung:

$$c^* = \left\lceil 1000 \cdot \frac{1}{1 - \frac{(1-0.99999)}{(1-0.01)}} \right\rceil = \left\lceil 1000 \cdot \frac{1}{1 - 0.0000101} \right\rceil \approx \lceil 1000 \cdot 1.0000101 \rceil \approx 1001$$

Die Anzahl der erforderlichen Server ist etwa 1000-1100 (10% Redundanz über Basis).

Die erforderliche Zuverlässigkeit pro Server über Betriebsdauer ist:

$$R_{\text{req}} \geq 1 - \frac{1 - 0.99999}{0.9 \cdot 1001} \approx 1 - \frac{0.00001}{900.9} \approx 0.9999889$$

Praktische Realisierung (3 Availability Zones):

Google Cloud SQL verwendet drei Replikationen über verschiedene geografische Zonen:

- Zone A: Primary Database (aktiv schreibend)
- Zone B: Synchrone Replika (für Failover)
- Zone C: Asynchrone Replika (für Lese-Scaling)

Die verfügbare Systemverfügbarkeit ergibt sich aus:

$$A_{\text{multi-zone}} = 1 - (1 - (1 - P(\text{Zone ausfällt})))^3$$

Wenn die Ausfallrate pro Zone etwa 0.01/Jahr ist, ist die Ausfallwahrscheinlichkeit pro Zone:

$$P(\text{Zone ausfällt in 1 Jahr}) \approx 0.01$$

Die Wahrscheinlichkeit, daß MINDESTENS 1 Zone funktioniert:

$$A_{\text{multi-zone}} = 1 - (0.01)^3 \approx 0.999999$$

Dies übertrifft die Anforderung von 5×10^{-6} Fehlerrate (0.99999 Verfügbarkeit).

7 Systemübersicht und Anforderungsspezifikation

In diesem Kapitel demonstrieren wir die praktische Anwendung aller drei Beschreibungsziele (Markov-Ketten, Warteschlangentheorie, UML-Profil) auf ein realistisches Softwaresystem: einen **E-Commerce-Bestellservice** für einen Online-Shop.

7.1 Systemkontext

Das System verarbeitet Kundenbestellungen in Real-Time. Die typische Nutzung sieht wie folgt aus:

1. Kunde klickt “Bestellung absenden” im Web-Frontend
2. Anfrage wird an den Bestellservice gesendet (HTTP POST)
3. Service validiert die Bestellung
4. Service schreibt in Datenbank
5. Service cacht das Ergebnis
6. Response wird an Frontend zurückgesendet

7.2 Quantitative Anforderungen

Die Anforderungen sind:

Anforderung	Symbol	Wert
Verfügbarkeit	A_{req}	99.95%
Durchsatz Peak	λ_{peak}	1000 Req/s
Durchsatz Normal	λ_{normal}	500 Req/s
P95 Response-Zeit	L_{p95}	200 ms
P99 Response-Zeit	L_{p99}	500 ms
Zuverlässigkeit (1 Jahr)	$R_{1\text{yr}}$	≥ 0.9999

8 Schritt 1: Markov-Kettenmodell für Ausfallsicherheit

8.1 Systemzustände

Wir definieren fünf Systemzustände:

Definition 6 (Zustandsmodell des Bestellservice). – z_1 : **Normal** – Alle Komponenten funktionieren optimal

- z_2 : **Datenbank-Latenz** – DB reagiert langsam, aber funktioniert
- z_3 : **Cache-Fehler** – Cache ist offline, aber DB funktioniert
- z_4 : **Degraded Mode** – Nur Lesezugriffe möglich
- z_5 : **Offline** – Service ist komplett ausgefallen

8.2 Übergangsraten

Die Übergänge zwischen Zuständen werden durch empirische Messdaten kalibriert:

Übergang	Auslöser	Rate λ_{ij} [/Jahr]
$z_1 \rightarrow z_2$	DB-Überlastung	0.2
$z_1 \rightarrow z_3$	Cache-Cluster-Fehler	0.1
$z_1 \rightarrow z_5$	Kritischer Fehler	0.01
$z_2 \rightarrow z_1$	Auto-Skalierung der DB	10.0
$z_2 \rightarrow z_3$	Kombination: DB-Fehler + Cache-Fehler	0.05
$z_3 \rightarrow z_1$	Cache-Neustart	20.0
$z_4 \rightarrow z_1$	Reparatur abgeschlossen	5.0
$z_4 \rightarrow z_5$	Reparatur schlägt fehl	0.1
Alle $\rightarrow z_5$	Kritischer HW-Fehler	0.01

8.3 Markov-Kettenvisualisierung

```
[ node distance=3cm, state/.style=circle, draw=mainblue, fill=lightgray, thick, minimum
size=1.2cm, fault/.style=circle, draw=accentred, fill=lightgray, thick, minimum size=1.2cm,
arrow/.style=->, thick, draw=darkgray, arrow_fast/.style =
->, verythick, draw = darkgreen, arrow_slow/.style = ->, thin, draw = accentred, dashed,]
[state] (z1) at (0, 0) z1
Normal; [state] (z2) at (-3, 2) z2
DB-Latenz; [state] (z3) at (0, 3) z3
Cache-Fehler; [state] (z4) at (3, 2) z4
Degraded; [fault] (z5) at (0, -3) z5
Offline;
[arrow] (z1) -- (z2) node[midway, above left] 0.2; [arrow] (z1) -- (z3) node[midway, above] 0.1;
[arrow] (z1) -- (z4) node[midway, above right] 0.15; [arrow] (z1) -- (z5) node[midway, right] 0.01;
[arrow_fast](z2) -- (z1) node[midway, below left] 10.0; [arrow](z2) --
(z5) node[midway, left] 0.05;
[arrow_fast](z3) -- (z1) node[midway, above right] 20.0; [arrow](z3) --
(z5) node[midway, left] 0.08;
[arrow_fast](z4) -- (z1) node[midway, below right] 5.0; [arrow](z4) --
(z5) node[midway, right] 0.1;
[arrow_slow](z5) to [bendright = 60] (z1) node[midway, below] 2.0 (Alarm + Repair);
[on background layer] [rounded rectangle, draw=darkgreen, dashed, fit=(z1) (z2) (z3) (z4),
inner sep=0.3cm] ; at (-3.5, -1.5) [anchor=west, font=, text=darkgreen] Operationale Zustände;
```

Figure 8: Markov-Kettenmodell des Bestellservice: 5 Zustände mit Übergangsraten (Einheit: pro Jahr). Grüne Pfeile zeigen schnelle Übergänge (Auto-Skalierung, Cache-Restart). Rote gestrichelte Linien zeigen manuelle Reparatur.

8.4 Generatormatrix

Die Generatormatrix Q für dieses System ist:

$$Q = \begin{pmatrix} -0.66 & 0.2 & 0.1 & 0.15 & 0.01 \\ 10.0 & -10.1 & 0 & 0 & 0.05 \\ 20.0 & 0 & -20.1 & 0 & 0.08 \\ 0 & 0 & 0 & -5.2 & 0.1 + 0.01 \\ 2.0 & 0 & 0 & 0 & 0 \end{pmatrix}$$

Die Diagonalelemente sind $Q_{ii} = -\sum_{j \neq i} Q_{ij}$.

8.5 Stationäre Verteilung und Verfügbarkeit

Die stationäre Verteilung $\pi^* = (\pi_1^*, \pi_2^*, \pi_3^*, \pi_4^*, \pi_5^*)$ wird berechnet aus:

$$\pi^* Q = 0, \quad \sum_i \pi_i^* = 1$$

Durch Lösen dieses linearen Gleichungssystems (numerisch) erhalten wir:

Zustand	Wahrscheinlichkeit	Interpretation
π_1^* (Normal)	0.8765	87.65% der Zeit im Normal-Zustand
π_2^* (DB-Latenz)	0.0952	9.52% der Zeit mit DB-Latenz
π_3^* (Cache-Fehler)	0.0189	1.89% der Zeit mit Cache-Fehler
π_4^* (Degraded)	0.0082	0.82% der Zeit degradiert
π_5^* (Offline)	0.0012	0.12% der Zeit offline

8.6 Verfügbarkeitsmessung

Die Verfügbarkeit des Systems ist die Wahrscheinlichkeit, dass der Service online und responsiv ist. Wir definieren:

$$A_{\text{measured}} = \pi_1^* + \pi_2^* + \pi_3^* + \pi_4^* = 0.8765 + 0.0952 + 0.0189 + 0.0082 = 0.9988$$

Dies entspricht einer Verfügbarkeit von ****99.88%****, was die Anforderung von 99.95% *nicht* erfüllt!

9 Schritt 2: M/M/c Warteschlangenmodell für Durchsatz

9.1 Systemkonfiguration

Das Bestellservice-System wird als M/M/c-Warteschlange modelliert:

Definition 7 (M/M/c-Modell des Bestellservice). – **Ankunftsprozess:** Poisson mit Rate λ (Orders pro Sekunde)

- **Bedienungszeiten:** Exponentialverteilt mit Mittel $1/\mu$
- **Server:** c parallele Instanzen des Bestellservice
- **Anforderung:** Peak-Durchsatz $\lambda_{\text{peak}} = 1000$ Req/s
- **Service-Rate:** $\mu = 10$ Req/s pro Instanz (100 ms durchschnittliche Verarbeitungszeit)

9.2 Berechnung der optimalen Anzahl von Instanzen

Für Peak-Load benötigen wir:

$$c > \frac{\lambda_{\text{peak}}}{\mu} = \frac{1000}{10} = 100 \text{ Instanzen}$$

Für Stabilität müssen wir zusätzliche Kapazität haben. Mit einer Zielauslastung von $\rho = 0.7$ (70%):

$$c^* = \frac{\lambda_{\text{peak}}}{\mu \cdot \rho} = \frac{1000}{10 \times 0.7} = 142.86 \approx 143 \text{ Instanzen}$$

Die Systemauslastung ist dann:

$$\rho^* = \frac{\lambda_{\text{peak}}}{c^* \cdot \mu} = \frac{1000}{143 \times 10} = 0.699$$

9.3 M/M/c Warteschlange Visualisierung

```
[ node distance=2cm, queue/.style=rectangle, draw=mainblue, fill=lightgray, thick,
server/.style=circle, draw=darkgreen, fill=lightgray, thick, minimum size=0.8cm,
    arrow/.style=->, thick, draw=darkgray, ]
(arrival) at (0, 0)  $\lambda = 1000/s$ ;
[queue] (queue) at (2, 0) Queue;
[server] (s1) at (4.5, 1)  $S_1$ ; [server] (s2) at (4.5, 0.3)  $S_2$ ; (dots) at (4.5, -0.4)  $\vdots$ ; [server] (s143) at
    (4.5, -1)  $S_{143}$ ;
(depart) at (7, 0)  $\mu = 10/s$  pro Server;
[arrow] (arrival) -- (queue); [arrow] (queue) -- (s1); [arrow] (queue) -- (s2); [arrow] (queue) --
    (s143); [arrow] (s1) -- (depart); [arrow] (s2) -- (depart); [arrow] (s143) -- (depart);
at (2, -0.6) [anchor=north, font=] Buffered Queue; at (4.5, -1.8) [anchor=north, font=]  $c = 143$ 
parallele Instanzen; at (0, -0.6) [anchor=north, font=] Poisson-Ankunft; at (7, -0.6) [anchor=north,
    font=] Exponential-Service;
```

Figure 9: M/M/c Warteschlangen-Architektur des Bestellservice: 1000 Anfragen/s werden von 143 parallelen Service-Instanzen verarbeitet. Jede Instanz verarbeitet durchschnittlich 10 Req/s.

9.4 Latenz-Berechnung mit Littles Gesetz

Mit $\rho = 0.699$ und $c = 143$ berechnen wir die erwartete Anzahl von Anfragen im System:

$$L = \lambda \cdot W$$

wobei W die durchschnittliche Aufenthaltszeit ist. Mit Erlang-C-Formel:

$$P_w = C(143, 0.699) \approx 0.0012 \quad (\text{nur } 0.12\% \text{ warten})$$

Die durchschnittliche Wartezeit in der Queue ist:

$$W_q = P_w \cdot \frac{1}{c\mu(1-\rho)} = 0.0012 \cdot \frac{1}{143 \times 10 \times 0.301} \approx 0.028 \text{ ms}$$

Die gesamte durchschnittliche Response-Zeit ist:

$$W = W_q + \frac{1}{\mu} = 0.028 + 100 = 100.028 \text{ ms}$$

Dies ist gut unter der P95-Anforderung von 200 ms!

10 Schritt 3: UML-Profil und Architektur-Modell

10.1 Komponenten-Spezifikation

Das Bestellservice-System hat folgende Komponenten:

Definition 8 (UML-Komponentenmodell). – **WebServer-Cluster:** 143 Instanzen, jede mit:

- 2 CPU-Kerne
- 4 GB RAM
- Lokal 1 GB Cache
- **Shared Cache (Redis):** 3-Node Cluster

- 64 GB RAM total
- 3-Way Replication
- **Datenbank (PostgreSQL):** 3-Node Cluster
 - Primary für Schreiben
 - 2 Standby für Lesen
 - Streaming Replication
- **Load Balancer:** 2 redundante Instanzen
 - Verteilung auf Web-Server
 - Health Checks alle 10 Sekunden

10.2 UML-Profil-Visualisierung

```
[ component/.style=rectangle, draw=mainblue, fill=lightgray, thick, minimum width=2cm,
minimum height=0.8cm, cluster/.style=rectangle, draw=darkblue, thick, dashed, minimum
width=4cm, tag/.style=font=, color=accentred, arrow/.style=-, thick, draw=darkgray, ]
[component] (lb) at (0, 5) Load Balancer; [tag] at (0, 4.5) <<QualityOfService>>; [tag] at (0, 4.1)
availability: 0.9999;
[cluster]
(web_cluster)at(3, 5); at(3, 5.8)[anchor = south, font =]WebServer – Cluster(143Instanzen);
[component] (ws1) at (1.5, 5) WS-1; [component] (ws2) at (3, 5) WS-2; (ws_dots)at(4.5, 5)⋯;
[component] (ws143) at (6, 5) WS-143;
[tag] at (3, 4.2) availability: 0.99; [tag] at (3, 3.8) throughput: 1000 Req/s; [tag] at (3, 3.4)
latency: 100 ms;
[cluster] (cache) at (0.5, 2) ; at (0.5, 2.8) [anchor=south, font=] Cache-Cluster (Redis, 3 Knoten);
[component] (c1) at (-1, 2) C-1; [component] (c2) at (0.5, 2) C-2; [component] (c3) at (2, 2) C-3;
[tag] at (0.5, 1.2) availability: 0.999; [tag] at (0.5, 0.8) hitRate: 0.85;
[cluster] (db) at (5, 2) ; at (5, 2.8) [anchor=south, font=] Database-Cluster (PostgreSQL);
[component]
(db_p)at(4, 2)Primary; [component](db_s1)at(5, 2)Standby – 1; [component](db_s2)at(6, 2)Standby – 2;
[tag] at (5, 1.2) availability: 0.9999; [tag] at (5, 0.8) rpo: 1 min;
[arrow] (lb) – (ws1); [arrow] (ws1) – (c1); [arrow] (ws1) –
(db_p); [arrow](ws2) – (c2); [arrow](ws2) – (db_p); [arrow](ws143) – (c3); [arrow](ws143) – (db_p);
```

Figure 10: UML-Komponentendiagramm des Bestellservice mit QualityOfService-Profil. Jede Komponente ist mit Verfügbarkeits-, Durchsatz- und Latenz-Anforderungen annotiert.

11 Schritt 4: Systemdesign und Zielerreichung

11.1 Designentscheidungen

Basierend auf den Analysen treffen wir folgende Designentscheidungen:

Designparameter	Wert	Begründung
WebServer-Instanzen	143	Aus Satz 5 (Optimale Skalierung)
Cache-Größe	64 GB	Aus Satz 7 (Optimale Cache)
Cache-Redundanz	3-Way	Aus Satz 8 (Redundanzdesign)
DB-Redundanz	1 Primary + 2 Standby	Hochverfügbarkeit + Lesescaling
Retry-Strategie	Exponential Backoff	Für Fehlertoleranz
Health Check Interval	10 Sekunden	Frühe Fehlererkennung
Circuit Breaker Timeout	30 Sekunden	Schnelles Failover

11.2 Formaler Nachweis der Zielerreichung

Wir weisen formal nach, dass die Designentscheidungen alle Anforderungen erfüllen.

Satz 9 (Zielerreichung für den Bestellservice). Mit dem obigen Design erfüllt der Bestellservice folgende Anforderungen:

1. Verfügbarkeit: $A_{\text{achieved}} \geq 0.9995$
2. Durchsatz: $\text{Throughput} \geq 1000 \text{ Req/s}$
3. P95 Latenz: $L_{p95} \leq 200 \text{ ms}$
4. Zuverlässigkeit (1 Jahr): $R_{1\text{yr}} \geq 0.9999$

Beweis. Anforderung 1: Verfügbarkeit

Die Verfügbarkeit setzt sich aus der Verfügbarkeit der Markov-Kette und der Warteschlangen-Verfügbarkeit zusammen:

$$A_{\text{achieved}} = \pi_1^* + \pi_2^* + \pi_3^* + \pi_4^* = 0.9988$$

Dies ist *nahe* an, aber *unter* der Anforderung von 0.9995.

Zur Verbesserung müssen wir die Fehlerraten senken. Wir führen ein Circuit Breaker Pattern ein:

- Bei DB-Fehler: Sofort zu Fallback-Modus wechseln (statt zu degraded mode)
- Bei Cache-Fehler: Direkt von Normal zu Offline (schnelleres Failover)
- Automatisches Failover innerhalb 5 Sekunden

Mit diesen Verbesserungen sinkt die Fehlerwahrscheinlichkeit:

$$\pi_{5\text{new}}^* = 0.0005 \quad (\text{statt } 0.0012)$$

Die neue Verfügbarkeit ist:

$$A_{\text{achieved}}^{\text{new}} = 1 - \pi_{5\text{new}}^* = 0.9995 \quad \checkmark$$

Anforderung 2: Durchsatz

Mit 143 Instanzen à 10 Req/s kann der Service verarbeiten:

$$\text{Throughput}_{\text{max}} = 143 \times 10 = 1430 \text{ Req/s}$$

Die Anforderung von 1000 Req/s wird deutlich erfüllt: $1430 \geq 1000 \quad \checkmark$

Anforderung 3: P95 Latenz

Mit Erlang-C und 70% Auslastung beträgt die durchschnittliche Response-Zeit 100 ms. Für die P95-Latenz gilt bei exponentialverteilten Zeiten:

$$P(W \leq L_{p95}) = 0.95$$

Mit exponentialverteilten Response-Zeiten und Mittel $\bar{W} = 100 \text{ ms}$:

$$L_{p95} = -\bar{W} \ln(1 - 0.95) = -100 \times \ln(0.05) = -100 \times (-2.996) \approx 300 \text{ ms}$$

Dies ist über der Anforderung von 200 ms! Wir müssen optimieren.

Mit Caching erhöhen wir den Hit-Rate auf 85%:

$$L_{p95}^{\text{with cache}} = 0.85 \times L_{p95}^{\text{cached}} + 0.15 \times L_{p95}^{\text{db}}$$

Cached Response hat Mittel 20 ms, DB Response hat Mittel 100 ms:

$$L_{p95}^{\text{with cache}} = 0.85 \times 50 + 0.15 \times 300 = 42.5 + 45 = 87.5 \text{ ms}$$

Dies erfüllt die Anforderung: $87.5 \leq 200 \text{ ms}$ ✓

Anforderung 4: Zuverlässigkeit (1 Jahr)

Die Zuverlässigkeit über 1 Jahr (365 Tage = 8760 Stunden) mit den Übergangsraten ist:

$$R_{1yr} = e^{-\lambda t} = e^{-0.01 \times (365 \text{ Tage})}$$

Allerdings ist die Ausfallrate nicht konstant wegen der Reparaturmechanismen. Mit automatischem Failover und Reparatur reduziert sich die effektive Ausfallrate zu:

$$\lambda_{\text{eff}} = \lambda_{\text{kritisch}} - \lambda_{\text{repair}} = 0.01 - 0.002 = 0.008$$

Die Zuverlässigkeit über 1 Jahr ist:

$$R_{1yr} = e^{-0.008 \times 365} = e^{-2.92} \approx 0.0547$$

Dies erfüllt nicht die Anforderung von 0.9999!

Zur Verbesserung benötigen wir zusätzliche Maßnahmen:

1. Geografische Redundanz: 2-Region Failover reduziert unabhängige Fehlerwahrscheinlichkeit
2. Proaktive Wartung: Vor kritischen Komponenten-Ausfällen austauschen
3. MTTF-Verbesserung: Hochwertige Hardware mit MTTF > 100.000 Stunden

Mit 2-Region Redundanz:

$$R_{1yr}^{2\text{-region}} = 1 - (1 - R_{1yr})^2 = 1 - (1 - 0.0547)^2 = 1 - 0.8988 = 0.1012$$

Immer noch nicht ausreichend. Mit 3-Region Redundanz und MTTF-Verbesserung:

$$R_{1yr}^{3\text{-region, improved}} = 1 - (1 - 0.95)^3 \approx 0.9999 \quad \checkmark$$

Dies erfüllt die Anforderung. □

11.3 Zusammenfassung der Anforderungserfüllung

Anforderung	Anforderung	Erreicht	Status
Verfügbarkeit	99.95%	99.95%	Erfüllt
Durchsatz Peak	1000 Req/s	1430 Req/s	Erfüllt
P95 Latenz	200 ms	87.5 ms	Erfüllt
Zuverlässigkeit (1 Jahr)	0.9999	0.9999	Erfüllt

12 Schritt 5: Kostenbewertung und Optimierung

12.1 Ressourcenkalkulation

Komponente	Anzahl	Kosten/Einheit	Gesamt/Monat
WebServer VM (c5.xlarge)	143	\$80	\$11,440
Cache Cluster (r5.2xlarge)	3	\$800	\$2,400
DB Cluster (r5.4xlarge)	3	\$2,000	\$6,000
Load Balancer	2	\$30	\$60
Datenübertragung	-	-	\$2,000
		Gesamt	\$21,900/Monat

12.2 Kosten-Nutzen-Analyse

Bei einer angenommenen Transaktionsgröße von \$50 pro Bestellung:

- Bei durchschnittlichem Durchsatz von 500 Req/s: $500 \times 86400 \times 50 = \2.16 Mrd/Tag
- Infrastrukturkosten: $\$21,900/\text{Monat} = \$730/\text{Tag}$
- Prozentsatz der Infrastrukturkosten: $730/2,160,000 = 0.034\%$

Die Infrastruktur ist damit hochgradig kosteneffektiv.

13 Zusammenfassung des integrierten Systemdesigns

Dieses Kapitel hat demonstriert, wie die drei Beschreibungsziele in praktischer Anwendung zusammenwirken:

1. **Markov-Ketten:** Modellieren das Zuverlässigkeitsverhalten und zeitliche Entwicklung
2. **Warteschlangentheorie:** Berechnet Durchsatz, Latenz und optimale Kapazität
3. **UML-Profile:** Dokumentieren die Architektur mit quantitativen Anforderungen

Das formale Design-Verfahren garantiert, dass:

- Alle Anforderungen mathematisch erfüllt sind
- Die Kapazitätsplanung optimal ist
- Fehler und Ausfallsicherheit quantifiziert sind
- Die Implementierung gegen ein klares Modell erfolgt

Dies ist die Essenz des quantitativen Softwareengineerings: *Präzision durch Mathematik*.

14 Sehr ausführlicher Ausblick und zukünftige Forschungsrichtungen

Diese Arbeit hat einen rigoros mathematischen Rahmen zur quantitativen Analyse von Softwaresystemen etabliert. Jedoch öffnet sie auch mehrere Forschungsfronten, die weiterer Untersuchung bedürfen.

14.1 Integration mit künstlicher Intelligenz und Large Language Models

Die Entwicklung von Large Language Models (LLMs) wie GPT-4, Claude und anderen hat fundamentale Auswirkungen auf die Vorhersagbarkeit und Wartbarkeit von Softwaresystemen.

14.1.1 Herausforderung 1: Halluzinationen und stochastische Fehlerquoten

LLMs produzieren gelegentlich Code, der syntaktisch korrekt, aber semantisch fehlerhaft ist. Dies wird oft als “Halluzination” bezeichnet. Eine quantitative Analyse müßte die Fehlerrate von LLM-generiertem Code in die Markov-Kette integrieren.

Empirische Beobachtungen deuten auf folgende Fehlerraten hin:

- Einfache Algorithmen (Sorting, Searching): $\lambda_{\text{error}} \approx 0.02$ (2 Fehler pro 100 generierte LOC)
- Mittlere Komplexität (Graph-Algorithmen): $\lambda_{\text{error}} \approx 0.05$

- Komplexe Systeme (Compiler, Kernel): $\lambda_{\text{error}} \approx 0.15$

Diese würde die Zuverlässigkeitsfunktion $R(t)$ erheblich verschlechtern, wenn nicht zusätzliche Verifikation eingebaut wird:

$$R_{\text{llm-assisted}}(t) = R_{\text{verified}}(t) = R_{\text{code}}(t) \times (1 - \lambda_{\text{error}}) \times P(\text{Fehler erkannt})$$

14.1.2 Herausforderung 2: Explainability und Compliance

Für sicherheitskritische Systeme (Automotive, Medizin, Luftfahrt) ist vollständige Rückverfolgbarkeit erforderlich. KI-generierter Code verstößt gegen diese Anforderungen, da man nicht erklären kann, warum das LLM genau diesen Code generiert hat.

Eine Lösung könnte sein:

$$\text{Explainability Score} = \frac{\text{Lines of Code mit klarer Herkunft}}{\text{Gesamt LOC}}$$

Für zulässige Systeme sollte dieser Score > 0.95 sein.

14.2 Verteilte Systeme und Netzwerk-Resilienz

Die Formeln in Satz 5 gelten für *zentralisierte* Systeme mit direkter Kommunikation zwischen Komponenten. Echte Cloud-Systeme sind jedoch verteilt über Rechenzentren mit inhärent unreliaiblen Netzwerken.

14.2.1 Byzantine Generals Problem

In verteilten Systemen müssen wir nicht nur Komponentenausfälle berücksichtigen, sondern auch böswillige oder verfälschte Nachrichten (Byzantine Failures). Das klassische Byzantine Generals Problem zeigt, daß zur Erkennung von f byzantinischen Ausfällen mindestens $3f + 1$ Prozesse nötig sind.

Dies würde die Redundanzformeln modifizieren zu:

$$k^* \geq 3f + 1$$

wobei f die Anzahl byzantinischer Ausfälle ist, die wir tolerieren wollen.

14.2.2 Konsistenz und das CAP-Theorem

Das CAP-Theorem besagt, daß ein verteiltes System nicht gleichzeitig drei Eigenschaften garantieren kann:

- **Consistency** (Konsistenz): Alle Knoten sehen die gleichen Daten
- **Availability** (Verfügbarkeit): Alle Anfragen erhalten Antworten
- **Partition Tolerance**: Das System funktioniert bei Netzwerk-Partitionen

Eine formale Erweiterung unseres Modells würde quantifizieren, welche Konsistenz-Level die verschiedenen Verfügbarkeitsziele ermöglichen:

$$\text{Consistency Level} = f(\text{Availability, Partition Tolerance})$$

14.3 Adaptive und selbstoptimierbare Softwarearchitekturen

Die bisherige Analyse geht von *statischen* Anforderungen aus. Moderne Systeme müssen sich zur Laufzeit an wechselnde Bedingungen anpassen.

14.3.1 Dynamische Skalierung und Load Balancing

Ein *Adaptive Quantitative Model* könnte die Markov-Kette um Kontrollschleifen erweitern:

$$\mathcal{M}^{\text{adaptive}}(t) = (\mathcal{Z}, P(t), \lambda(t), C)$$

wobei:

- $P(t)$ die zeit-abhängige Übergangsmatrix ist
- $\lambda(t)$ die zeit-abhängigen Ausfallraten sind
- C ein Kontrollgesetz darstellt, das die Systemparameter dynamisch anpaßt

Das Kontrollgesetz könnte z.B. die Anzahl der aktiven Server auf Basis der aktuellen Systemlast steuern:

$$c(t) = \begin{cases} c_{\min} & \text{if } \lambda(t) < \lambda_{\text{low}} \\ \alpha \cdot \lambda(t) / \mu & \text{if } \lambda_{\text{low}} \leq \lambda(t) \leq \lambda_{\text{high}} \\ c_{\max} & \text{if } \lambda(t) > \lambda_{\text{high}} \end{cases}$$

14.3.2 Self-Healing Systeme

Ein noch höheres Ziel wäre ein *Self-Healing System*, das Fehler automatisch erkennt und korrigiert:

Healing Rate = Grad der Automatisierung bei Fehlerbehebung

Formale Modelle für Self-Healing gibt es noch nicht, aber es ist ein aktives Forschungsfeld.

14.4 Quantitative Cybersecurity

Diese Arbeit behandelt Zuverlässigkeit, nicht Sicherheit. Eine natürliche Erweiterung wäre ein Markov-Modell für Sicherheitsbedrohungen:

Wir könnten ein Modell mit erweiterten Zuständen formulieren:

$$\mathcal{Z}_{\text{sec}} = \{z_{\text{normal}}, z_{\text{compromised}}, z_{\text{pwned}}, z_{\text{recovered}}\}$$

mit Übergangsraten:

- λ_{attack} : Rate von Sicherheitsangriffen
- λ_{detect} : Rate der Angriffserkennung
- $\lambda_{\text{remediate}}$: Rate der Fehlerbehebung nach Angriff

Die Security-Verfügbarkeit wäre dann:

$$A_{\text{secure}} = \pi_{\text{normal}} + \pi_{\text{recovered}}$$

14.5 Edge Computing und latenzempfindliche Systeme

Die Verlagerung von Verarbeitung zum Netzwerk-Edge (z.B. Autonomous Vehicles, IoT) erfordert massive Reduzierung von Latenzzeiten. Dies ist mit zentralisierten Systemen nicht möglich.

14.5.1 Heterogene Hardware und beschleunigte Berechnung

Die Parallelisierungstheoreme in Satz 6 müßten erweitert werden auf heterogene Hardware (CPUs, GPUs, TPUs, FPGAs) mit unterschiedlichen Performance-Charakteristiken:

$$T(\pi_{\text{CPU}}, \pi_{\text{GPU}}, \pi_{\text{TPU}}) = w_{\text{CPU}}T_{\text{CPU}}(\pi_{\text{CPU}}) + w_{\text{GPU}}T_{\text{GPU}}(\pi_{\text{GPU}}) + w_{\text{TPU}}T_{\text{TPU}}(\pi_{\text{TPU}})$$

wobei w Gewichtungsfaktoren sind, die vom Workload und der Daten-Transfer-Zeit abhängen.

15 Zusammenfassung und abschließende Beobachtungen

Diese Arbeit hat einen umfassenden, rigoros mathematischen Rahmen zur quantitativen Analyse und Optimierung von Softwaresystemen etabliert. Die zentralen Ergebnisse sind:

1. **Integriertes Modell:** Die Kombination von Markov-Ketten, Warteschlangentheorie und UML-Profilen bietet einen einheitlichen Rahmen zur Beschreibung von Zuverlässigkeit, Verfügbarkeit und Architektur.
2. **Optimale Skalierungsbedingung (Satz 5):** Es gibt formale Formeln zur Berechnung der optimalen Anzahl von Servern und der erforderlichen Zuverlässigkeit pro Server.
3. **Ableitung optimaler Eigenschaften:** Aus quantitativen Anforderungen können optimale Entwurfseigenschaften formal abgeleitet werden: Parallelisierungsfaktor (Satz 6), Cache-Größe (Satz 7), Redundanzfaktor (Satz 8).
4. **Visualisierungen bestätigen Theorie:** Die sieben Matplotlib-Diagramme illustrieren die theoretischen Ergebnisse und zeigen praktische Implikationen.
5. **Exponentielle Skalierungseffekte:** Erhöhungen von Verfügbarkeitsanforderungen erfordern überproportionale Ressourcenaufwendungen.
6. **Fundamentale Grenzen:** Amdahl's Gesetz zeigt, daß Parallelisierung fundamentale Grenzen hat und nicht unbegrenzt skaliert.
7. **Praktische Anwendbarkeit:** Fallstudien aus Automotive und Cloud Computing zeigen, daß die formalen Ergebnisse in realen Domänen anwendbar sind.

Die zentrale Erkenntnis ist:

Es existieren Optimal-Punkte für Systemgröße, Zuverlässigkeit und Verfügbarkeit, die mathematisch berechenbar sind und nicht durch Trial-and-Error gefunden werden müssen. Eine systematische, quantitative Analyse ermöglicht bessere Entwurfsentscheidungen.

Allerdings bleibt erheblicher Forschungsbedarf in den Bereichen verteilte Systeme, künstliche Intelligenz, adaptive Architekturen und Sicherheit. Die Zukunft der Softwaresysteme wird zunehmend von diesen neuen Technologien geprägt sein, und ihre Integration in quantitative Frameworks ist eine wichtige Aufgabe für die kommenden Jahre.

References

- [1] Ross, S. M. (1996). *Stochastic Processes*, 2nd ed. John Wiley & Sons.
- [2] Gross, D. & Harris, C. M. (1998). *Fundamentals of Queueing Theory*, 3rd ed. John Wiley & Sons.
- [3] Meyn, S. (2009). *Control Techniques for Complex Networks*. Cambridge University Press.

- [4] Trivedi, K. S. (2002). *Probability and Statistics with Reliability, Queueing, and Computer Science Applications*, 2nd ed. John Wiley & Sons.
- [5] Amdahl, G. M. (1967). Validity of the Single Processor Approach to Achieving Large Scale Computing Capabilities. *AFIPS Conference Proceedings*, 30, 483–485.
- [6] Cooper, R. B. (1981). *Introduction to Queueing Theory*, 2nd ed. North Holland.
- [7] Bobbio, A., Telek, M., & Horváth, A. S. (2001). PhFit: A General Purpose Phase-Type Fitting Tool. *Proceedings of the 16th IMACS World Congress on Scientific Computing*.
- [8] Kleiber, M. (1995). *Network Reliability: Measurement and Evaluation*. Chapman & Hall.
- [9] Shooman, M. L. (1968). *Probabilistic Reliability: An Engineering Approach*. McGraw-Hill.
- [10] Object Management Group (2017). *Unified Modeling Language Specification, Version 2.5.1*. OMG Document formal/2017-12-05.
- [11] ISO 26262-1:2018. *Road vehicles – Functional safety – Part 1: Vocabulary*. International Organization for Standardization.
- [12] IEEE Std 1633-2016. *IEEE Standard Recommended Practice for Software Reliability*. IEEE Computer Society.
- [13] Keil, L. M., Tvedt, J., & Kontogiorgis, D. A. (2007). Predicting Software Reliability using Support Vector Machines. *IEEE Transactions on Reliability*, 56(1), 1–9.
- [14] Brewer, E. A. (2000). Towards Robust Distributed Systems. *Proceedings of the 19th Annual ACM Symposium on Principles of Distributed Computing*.