

Die Lehre vom Zufall in der Mathematik

Vollständige Beschreibbarkeit von Experimenten,
Wahrscheinlichkeitstheorie und randomisierte Algorithmen

Stephan Epp

8. Januar 2026

Inhaltsverzeichnis

1	Einleitung	4
2	Grundlagen	5
2.1	Ergebnisraum und Ereignisse	5
2.2	Kolmogorows Axiome und das Prinzip der Vollständigkeit	6
2.3	Wichtige Rechenregeln	7
2.4	Laplace-Wahrscheinlichkeit	7
2.5	Unabhängigkeit von Ereignissen	8
3	Bedingte und totale Wahrscheinlichkeit	8
3.1	Bedingte Wahrscheinlichkeit	8
3.2	Multiplikationsregel und Kettenregel	8
3.3	Satz der totalen Wahrscheinlichkeit	8
3.4	Satz von Bayes	9
4	Zufallsvariablen, Erwartungswert und Varianz	9
4.1	Zufallsvariablen	9
4.2	Erwartungswert	9
4.3	Varianz und Standardabweichung	10
4.4	Wichtige Ungleichungen	11
4.5	Bedingter Erwartungswert	11
5	Diskrete Wahrscheinlichkeitsverteilungen	12
5.1	Überblick und Vollständigkeitsprüfung	12
5.2	Bernoulli-Verteilung	12
5.3	Binomialverteilung	13
5.4	Geometrische Verteilung	13
5.5	Poisson-Verteilung	14
5.6	Stetige Verteilungen	14
5.6.1	Gleichverteilung $\mathcal{U}([a, b])$	14
5.6.2	Normalverteilung $\mathcal{N}(\mu, \sigma^2)$	14
5.6.3	Exponentialverteilung $\text{Exp}(\lambda)$	15
5.7	Anwendung: Hybrider Registerspeicher	15

6	Randomisierte Algorithmen	16
6.1	3-SAT-Approximation mit Erwartungswert $\geq 7/8$	16
6.1.1	Das Problem	16
6.1.2	Der randomisierte Algorithmus	16
6.1.3	Erwartungswert-Analyse	17
6.1.4	Derandomisierung via Methode der bedingten Erwartungswerte	18
6.1.5	Laufzeitanalyse	18
6.2	Randomisiertes Quicksort	18
6.2.1	Idee und Pseudocode	18
6.2.2	Erwartete Laufzeitanalyse	19
6.3	Kargerscher Algorithmus für minimale Schnitte	20
6.3.1	Das Problem und die Idee	20
6.3.2	Analyse: Wahrscheinlichkeit des Erfolgs	20
6.3.3	Karger-Stein-Algorithmus und Gesamtlaufzeit	21
6.3.4	Laufzeit einer Einzeliteration	21
6.4	Miller-Rabin-Primzahltest	21
6.4.1	Motivation	21
6.4.2	Mathematische Grundlagen	21
6.4.3	Fehlerwahrscheinlichkeit und Laufzeit	22
6.5	Polynomial Identity Testing (Schwartz-Zippel-Lemma)	23
6.5.1	Polynomial Identity Testing	23
6.6	Hashing und Universal Hashing	23
6.6.1	Motivation	23
6.6.2	Erwartete Listenlänge	24
6.7	Randomisierter Las-Vegas-Algorithmus: Randomisiertes Finden des Minimums	24
7	Die probabilistische Methode	25
7.1	Grundprinzip	25
7.2	Beispiel: Turán-Ramsey und unabhängige Mengen	25
7.3	Lovász Local Lemma	25
8	Gesetz großer Zahlen und Zentraler Grenzwertsatz	26
8.1	Gesetz der großen Zahlen	26
8.2	Zentraler Grenzwertsatz	26
9	Schluss	26
9.1	Komplexitätstheorie und derandomisierte Algorithmen	27
9.2	Quantencomputing und Quanten-Wahrscheinlichkeitstheorie	27
9.3	Maschinelles Lernen und Stochastische Optimierung	28
9.3.1	Stochastischer Gradientenabstieg (SGD)	28
9.3.2	Dropout und Regularisierung via Zufall	28
9.3.3	Convolutional Neural Networks und Zufälligkeit	28
9.4	Kryptographie und Informationstheorie	28
9.4.1	Perfekte Sicherheit und Einmalblock-Verschlüsselung	28
9.4.2	Pseudozufallsgeneratoren in der Kryptographie	29
9.4.3	Zero-Knowledge-Beweise	29
9.5	Randomisierte Datenstrukturen	29
9.5.1	Skip-Listen	29
9.5.2	Bloom-Filter	29

9.5.3	Treaps	29
9.6	Approximationsalgorithmen und semidefinite Programmierung	30
9.6.1	Goemans-Williamson-Algorithmus für MAX-CUT	30
9.6.2	Håstads 3-SAT-Härte und optimale Approximierbarkeit	30
9.7	Monte-Carlo-Simulation und numerische Integration	30
9.7.1	Monte-Carlo-Integration	30
9.7.2	Markov-Ketten-Monte-Carlo (MCMC)	30
9.7.3	Simulated Annealing	30
9.8	Streaming und Sublinear-Zeit-Algorithmen	31
9.8.1	Frequenz-Schätzung und Count-Min-Sketch	31
9.8.2	F_0 -Schätzung (distinct elements)	31
9.9	Randomisierung in der Bioinformatik und Computational Biology	31
9.9.1	BLAST und Heuristischer Sequenzvergleich	31
9.9.2	Phylogenetische Rekonstruktion via Bootstrap	31
9.10	Lerntheorie und PAC-Lernen	31
9.10.1	Probably Approximately Correct (PAC) Lernen	31
9.11	Offene Probleme und Forschungsfrontieren	32
9.12	Abschlussbemerkung: Das Vollständigkeitsprinzip als epistemologisches Fundament	32

1 Einleitung

Diese Arbeit behandelt die mathematischen Grundlagen der Lehre vom Zufall. Ausgangspunkt ist das fundamentale Prinzip der vollständigen Beschreibbarkeit von Experimenten: Ein Experiment ist genau dann vollständig beschrieben, wenn die Summe der Wahrscheinlichkeiten aller möglichen Ereignisse gleich 1 ist – sowohl im diskreten als auch im kontinuierlichen Wahrscheinlichkeitsraum. Aufbauend auf diesem Grundprinzip werden Erwartungswert, Varianz, bedingte Wahrscheinlichkeit, bedingter Erwartungswert und die wichtigsten Wahrscheinlichkeitsverteilungen systematisch entwickelt. Im algorithmischen Teil werden randomisierte Algorithmen der Informatik vorgestellt und tiefgehend analysiert: der probabilistische $\frac{7}{8}$ -Approximationsalgorithmus für 3-SAT, der Algorithmus von Karger für minimale Schnitte, randomisiertes Quicksort, der Miller-Rabin-Primzahltest sowie der Algorithmenentwurf mittels der Probabilistischen Methode. Abschließend wird ein umfangreicher Ausblick auf offene Fragen und aktuelle Forschungsrichtungen gegeben.

Die Frage, was Zufall bedeutet, begleitet die Mathematik seit der Antike. Bereits die griechischen Philosophen diskutierten, ob Ereignisse kausal determiniert oder prinzipiell unvorhersehbar sein können. Pascal und Fermat legten im 17. Jahrhundert mit ihrer Korrespondenz über das *Problème des points* den Grundstein für eine systematische mathematische Beschreibung zufälliger Ereignisse [11]. Jacob Bernoulli formulierte das Gesetz der großen Zahlen, Abraham de Moivre erkannte die Normalverteilung, und Pierre-Simon Laplace schuf in seiner *Théorie analytique des probabilités* [27] eine erste axiomatische Fundierung. Den entscheidenden Formalisierungsschritt vollzog Andrei Nikolajewitsch Kolmogorow 1933 mit seiner axiomatischen Wahrscheinlichkeitstheorie [26], die bis heute das Fundament des Fachs bildet.

Wir verwenden Zufall, weil diese Art der Beschreibung weniger kompliziert ist als eine realistischere Beschreibung. Eine realistischere Beschreibung berücksichtigt weit mehr Randbedingungen und ist daher komplizierter und länger. Der Leser muss auch Aufwand zum Verstehen aufbringen. Der Wert zur Wiederverwendung ist dabei allerdings viel geringer, denn die Beschreibung durch Zufall hat viel mehr Anwendungen - vor allem im Entwurf von Algorithmen.

Gibt es einen Beweis in der Lehre vom Zufall, der mit Hilfe von Abbildungen bzw. Funktionen möglich ist, aber ohne nicht? Randbemerkung: Abbildungen eignen sich für diskrete Beschreibungen und Funktionen eignen sich für kontinuierliche Beschreibungen.

Es ist sinnvoll, von der Modellierung in der Lehre vom Zufall zu sprechen. Denn Experimente werden in gewisser Weise, ob diskret oder kontinuierlich, abstrakt, also mit Hilfe eines Modells, beschrieben. Modelle abstrahieren und erlauben eine einfachere und kürzere Beschreibung. Modelle eignen sich besonders für die Wiederverwendung. Einen besonderen Nutzen haben sie dabei in der Informatik, wo sie auch für die Codegenerierung verwendet werden.

Im Allgemeinen ist die Beschreibung durch ein Modell viel leichter in Code zu verfassen, das tut der Mensch oder ein KI-Chat. Dieser Code kann auf viele Instanzen oder Eingaben angewendet und automatisiert ausgeführt werden. Das ermöglicht das Ausführen von vielen Wiederholungen und unterschiedlichen Eingaben für allgemeinere und sicherere Aussagen in der konkreten Beschreibung oder Modellierung.

Was beschreibbar ist, ist berechenbar. Diese Aussage wurde soeben in der praktischen Umsetzung beschrieben. Dieses Vorgehen ist auf beliebige Beschreibungen oder Modelle anwendbar und der große Nutzen der Modellierung und Berechenbarkeit wird dadurch sehr deutlich.

Der zentrale Gedanke dieser Arbeit geht auf Kolmogorows drittes Axiom zurück: *Die Summe der Wahrscheinlichkeiten aller Elementarereignisse eines Experiments ist 1.* Dieses scheinbar einfache Axiom hat weitreichende Konsequenzen: Es legt fest, was ein *vollständig beschriebenes Experiment* ist, und es bildet die operationale Grundlage für alle weitergehenden Begriffe wie Erwartungswert, Varianz und bedingte Wahrscheinlichkeit.

2 Grundlagen

Um jede Unruhe über den Ausgang des Zufalls allen Beteiligten zu nehmen, wird der Zufall für diskrete Ereignisse mit Hilfe der Mathematik beschrieben und analysiert.

2.1 Ergebnisraum und Ereignisse

Für das diskrete Ereignis, bei dem ein Würfel einmal geworfen wird, können folgende diskrete Ereignisse zufällig eintreten. Der Würfel kann auf die Augenzahl 1 fallen, der Würfel kann auf die Augenzahl 2 fallen, $\dots$, der Würfel kann auf die Augenzahl 6 fallen. Dabei ist jeder Fall des Würfels auf eine andere Augenzahl ein Ereignis. Es gibt damit also sechs Ereignisse beim Würfeln des Würfels mit sechs Seiten.

Ein *Versuch* beschreibt das Vorhaben, zum Beispiel einen Würfel zu würfeln. In diesem Versuch können unterschiedliche Ereignisse zufällig eintreten. *Die Menge aller Ereignisse für einen Versuch*, die zufällig eintreten können, wird definiert mit Ω . Um nun zu sagen, wie zufällig es ist, dass der Würfel beim Wurf auf die Augenzahl 3 fällt, muss nur dieses Ereignis ins Verhältnis zu allen möglichen Ereignissen gesetzt werden. Damit ergibt sich als Wert für den Zufall des Ereignisses, dass der Würfel beim Wurf auf die Augenzahl 3 fällt, die *Wahrscheinlichkeit* von $\frac{1}{6}$. Es fällt auf, dass für jedes Ereignis dieses Versuches gilt, dass der Würfel beim Wurf auf die Augenzahl k fällt, die *Wahrscheinlichkeit* $\frac{1}{6}$ hat, $k \in \Omega = \{1, \dots, 6\}$. Denn der Würfel hat ja sechs gleich große Seiten und keine der Seiten des Würfels ist durch die Art des Würfels bevorzugt. Ist die Summe aller Wahrscheinlichkeiten der Zufälle aller Ereignisse insgesamt 1, wurden alle Ereignisse des Versuchs berücksichtigt und der Versuch ist *mathematisch vollständig beschrieben*.

Für Versuche, die durch diskrete Ereignisse beschrieben werden, ist die Überprüfung der vollständigen mathematischen Beschreibung notwendig. Erst dann liegt eine mathematische Beschreibung vor, auf deren Grundlage weitere Ereignisse für diesen Versuch betrachtet und analysiert werden können. Für den Versuch, einen Würfel einmal zu würfeln, kann man sich auch fragen, wie wahrscheinlich der Zufall für das Ereignis ist, dass der Würfel nicht auf die Augenzahl 3 fällt. Das ist komplizierter im Allgemeinen. Glücklicherweise aber betrachten wir diskrete Ereignisse. Deshalb lässt sich die Wahrscheinlichkeit für den Zufall des Ereignisses, dass der Würfel nicht auf die Augenzahl 3 fällt, wie folgt *abzählen*. Die Wahrscheinlichkeit für den Zufall des Ereignisses, dass der Würfel nicht auf die Augenzahl 3 fällt, ist dieselbe wie für den Zufall der Ereignisse, dass der Würfel auf die Augenzahl 1, 2, 4, 5 oder 6 fällt. Dies sind fünf Ereignisse. Damit ergibt sich eine Wahrscheinlichkeit von $\frac{5}{6}$.

Definition 2.1 (Ergebnisraum und Ereignis). Sei Ω eine nichtleere Menge, die sog. **Ergebnismenge** oder **Stichprobenraum**. Ihre Elemente $\omega \in \Omega$ heißen **Elementarereignisse** oder **Ergebnisse**. Eine Teilmenge $A \subseteq \Omega$ heißt **Ereignis**. Die Potenzmenge $\mathcal{P}(\Omega)$ ist im diskreten Fall der **Ergebnisraum**; im allgemeinen Fall tritt an ihre Stelle eine σ -Algebra $\mathcal{F} \subseteq \mathcal{P}(\Omega)$.

Ein Ereignis A tritt ein, wenn das realisierte Ergebnis $\omega \in A$ liegt. Das sichere Ereignis ist Ω selbst, das unmögliche Ereignis ist $\emptyset$.

Definition 2.2 (σ -Algebra). Eine Mengenfamilie $\mathcal{F} \subseteq \mathcal{P}(\Omega)$ heißt **σ -Algebra**, wenn gilt:

- (i) $\Omega \in \mathcal{F}$,
- (ii) $A \in \mathcal{F} \Rightarrow A^c := \Omega \setminus A \in \mathcal{F}$,
- (iii) $A_1, A_2, \dots \in \mathcal{F} \Rightarrow \bigcup_{i=1}^{\infty} A_i \in \mathcal{F}$.

Das Tripel $(\Omega, \mathcal{F})$ heißt **Messbarer Raum**.

2.2 Kolmogorows Axiome und das Prinzip der Vollständigkeit

Definition 2.3 (Wahrscheinlichkeitsmaß (Kolmogorow, 1933)). Sei $(\Omega, \mathcal{F})$ ein messbarer Raum. Eine Abbildung $\mathbb{P}: \mathcal{F} \rightarrow [0, 1]$ heißt **Wahrscheinlichkeitsmaß**, wenn die drei Kolmogorowschen Axiome gelten:

(K1) Nichtnegativität: $\mathbb{P}(A) \geq 0$ für alle $A \in \mathcal{F}$.

(K2) Normierung: $\mathbb{P}(\Omega) = 1$.

(K3) σ -Additivität: Für paarweise disjunkte Ereignisse $A_1, A_2, \dots \in \mathcal{F}$ gilt

$$\mathbb{P}\left(\bigcup_{i=1}^{\infty} A_i\right) = \sum_{i=1}^{\infty} \mathbb{P}(A_i).$$

Das Tripel $(\Omega, \mathcal{F}, \mathbb{P})$ heißt **Wahrscheinlichkeitsraum**.

Das zweite Axiom (K2) – die *Normierung* – ist das mathematische Fundament des folgenden zentralen Prinzips dieser Arbeit:

Prinzip der vollständigen Beschreibbarkeit.

Diskreter Fall. Ein Experiment mit diskretem Ergebnisraum $\Omega = \{\omega_1, \omega_2, \dots\}$ ist *genau dann vollständig beschrieben*, wenn

$$\sum_i \mathbb{P}(\{\omega_i\}) = 1.$$

Kontinuierlicher Fall. Ein Experiment mit stetigem Ergebnisraum $\Omega \subseteq \mathbb{R}^n$ und Dichtefunktion $f: \Omega \rightarrow [0, \infty)$ ist *genau dann vollständig beschrieben*, wenn

$$\int_{\Omega} f(\omega) d\omega = 1.$$

In beiden Fällen besagt die vollständige Beschreibbarkeit: Jedes mögliche Ergebnis des Experiments ist berücksichtigt; kein Ergebnis ist „vergessen“ worden, und kein Szenario wird doppelt gezählt.

Beispiel 2.1 (Würfelwurf – vollständige Beschreibung). Betrachte einen fairen sechsseitigen Würfel. Der Ergebnisraum ist $\Omega = \{1, 2, 3, 4, 5, 6\}$. Das Experiment „Wirf den Würfel einmal“ weist jedem Elementarereignis die gleiche Wahrscheinlichkeit zu:

$$\mathbb{P}(\{k\}) = \frac{1}{6}, \quad k \in \{1, \dots, 6\}.$$

Die Vollständigkeitsbedingung ist erfüllt:

$$\sum_{k=1}^6 \mathbb{P}(\{k\}) = 6 \cdot \frac{1}{6} = 1.$$

Das Teilerperiment „Der Würfel zeigt die 1“ hat den Ergebnisraum $\Omega' = \{1\}$ mit $\mathbb{P}(\{1\}) = \frac{1}{6}$. Diese Beschreibung ist *unvollständig*, denn $\frac{1}{6} \neq 1$. Um sie zu vervollständigen, fügen wir das Komplementärereignis $\{2, 3, 4, 5, 6\}$ hinzu:

$$\mathbb{P}(\{1\}) + \mathbb{P}(\{2, 3, 4, 5, 6\}) = \frac{1}{6} + \frac{5}{6} = 1.$$

Erst durch das explizite Benennen des Komplementärereignisses – „der Würfel zeigt **nicht** die 1 – ist das Experiment vollständig beschrieben. Mit Wahrscheinlichkeit $\frac{1}{6}$ fällt der Würfel auf die Augenzahl 1 und mit Wahrscheinlichkeit $\frac{5}{6}$ fällt der Würfel nicht auf die Augenzahl 1.

2.3 Wichtige Rechenregeln

Aus den Kolmogorow-Axiomen lassen sich unmittelbar folgende Regeln ableiten:

Satz 2.1 (Grundlegende Wahrscheinlichkeitsregeln). Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $A, B \in \mathcal{F}$. Dann gilt:

- (i) $\mathbb{P}(\emptyset) = 0$.
- (ii) $\mathbb{P}(A^c) = 1 - \mathbb{P}(A)$ (Komplementregel).
- (iii) $A \subseteq B \Rightarrow \mathbb{P}(A) \leq \mathbb{P}(B)$ (Monotonie).
- (iv) $\mathbb{P}(A \cup B) = \mathbb{P}(A) + \mathbb{P}(B) - \mathbb{P}(A \cap B)$ (Siebformel / Inklusion-Exklusion).
- (v) **Union Bound (Boole'sche Ungleichung):** $\mathbb{P}(\cup_{i=1}^n A_i) \leq \sum_{i=1}^n \mathbb{P}(A_i)$.

Beweis. (i) Aus (K2) und (K3) folgt $1 = \mathbb{P}(\Omega) = \mathbb{P}(\Omega \cup \emptyset) = \mathbb{P}(\Omega) + \mathbb{P}(\emptyset)$, also $\mathbb{P}(\emptyset) = 0$.

(ii) $\Omega = A \cup A^c$ (disjunkt), daher $1 = \mathbb{P}(A) + \mathbb{P}(A^c)$.

(iii) $B = A \cup (B \setminus A)$ (disjunkt), also $\mathbb{P}(B) = \mathbb{P}(A) + \mathbb{P}(B \setminus A) \geq \mathbb{P}(A)$.

(iv) $A \cup B = A \cup (B \setminus A)$ (disjunkt), $\mathbb{P}(B \setminus A) = \mathbb{P}(B) - \mathbb{P}(A \cap B)$. □

2.4 Laplace-Wahrscheinlichkeit

Im klassischen Laplace-Modell ist Ω endlich und alle Elementarereignisse sind gleich wahrscheinlich:

Definition 2.4 (Laplace-Wahrscheinlichkeit). Für ein endliches Ω mit $|\Omega| = n$ und $\mathbb{P}(\{\omega\}) = \frac{1}{n}$ für alle $\omega \in \Omega$ gilt für jedes Ereignis $A \subseteq \Omega$:

$$\mathbb{P}(A) = \frac{|A|}{|\Omega|} = \frac{\text{Anzahl günstiger Ergebnisse}}{\text{Anzahl aller möglichen Ergebnisse}}.$$

Die Vollständigkeitsbedingung ist hier trivialerweise erfüllt: $\sum_{\omega \in \Omega} \frac{1}{|\Omega|} = |\Omega| \cdot \frac{1}{|\Omega|} = 1$.

2.5 Unabhängigkeit von Ereignissen

Definition 2.5 (Stochastische Unabhängigkeit). Zwei Ereignisse $A, B \in \mathcal{F}$ heißen (**stochastisch**) **unabhängig**, wenn

$$\mathbb{P}(A \cap B) = \mathbb{P}(A) \cdot \mathbb{P}(B).$$

Eine Familie $(A_i)_{i \in I}$ heißt **vollständig unabhängig**, wenn für jede endliche Teilmenge $J \subseteq I$:

$$\mathbb{P}\left(\bigcap_{j \in J} A_j\right) = \prod_{j \in J} \mathbb{P}(A_j).$$

3 Bedingte und totale Wahrscheinlichkeit

3.1 Bedingte Wahrscheinlichkeit

Ein fundamentales Konzept der Wahrscheinlichkeitstheorie ist die bedingte Wahrscheinlichkeit: Wie verändert sich die Wahrscheinlichkeit eines Ereignisses, wenn man über das Eintreten eines anderen Ereignisses informiert wird?

Definition 3.1 (Bedingte Wahrscheinlichkeit). Sei $(\Omega, \mathcal{F}, \mathbb{P})$ ein Wahrscheinlichkeitsraum und $B \in \mathcal{F}$ mit $\mathbb{P}(B) > 0$. Die **bedingte Wahrscheinlichkeit** von A gegeben B ist definiert als

$$\mathbb{P}(A \mid B) := \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)}.$$

Bemerkung 3.1. Die Abbildung $A \mapsto \mathbb{P}(A \mid B)$ ist selbst ein Wahrscheinlichkeitsmaß auf $(\Omega, \mathcal{F})$. Insbesondere gilt $\mathbb{P}(\Omega \mid B) = 1$, was die vollständige Beschreibbarkeit im bedingten Experiment sicherstellt.

Beispiel 3.1 (Bedingte Wahrscheinlichkeit beim Würfel). Beim einmaligen Würfelwurf sei $B = \{2, 4, 6\}$ (gerade Augenzahl) und $A = \{4, 5, 6\}$ (Augenzahl ≥ 4). Dann:

$$\mathbb{P}(A \mid B) = \frac{\mathbb{P}(A \cap B)}{\mathbb{P}(B)} = \frac{\mathbb{P}(\{4, 6\})}{\mathbb{P}(\{2, 4, 6\})} = \frac{2/6}{3/6} = \frac{2}{3}.$$

Wenn man weiß, dass eine gerade Zahl gefallen ist, steigt die Wahrscheinlichkeit für eine Zahl ≥ 4 von $\frac{3}{6} = \frac{1}{2}$ auf $\frac{2}{3}$.

3.2 Multiplikationsregel und Kettenregel

Satz 3.1 (Multiplikationsregel). Für Ereignisse $A_1, \dots, A_n \in \mathcal{F}$ mit $\mathbb{P}(A_1 \cap \dots \cap A_{n-1}) > 0$ gilt:

$$\mathbb{P}(A_1 \cap A_2 \cap \dots \cap A_n) = \mathbb{P}(A_1) \cdot \mathbb{P}(A_2 \mid A_1) \cdot \mathbb{P}(A_3 \mid A_1 \cap A_2) \cdots \mathbb{P}(A_n \mid A_1 \cap \dots \cap A_{n-1}).$$

3.3 Satz der totalen Wahrscheinlichkeit

Satz 3.2 (Satz der totalen Wahrscheinlichkeit). Sei $(B_i)_{i=1}^n$ eine Partition von Ω mit $\mathbb{P}(B_i) > 0$ für alle i . Dann gilt für jedes $A \in \mathcal{F}$:

$$\mathbb{P}(A) = \sum_{i=1}^n \mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i).$$

Beweis. Da (B_i) eine Partition ist, gilt $A = \bigsqcup_i (A \cap B_i)$. Mit σ -Additivität folgt $\mathbb{P}(A) = \sum_i \mathbb{P}(A \cap B_i) = \sum_i \mathbb{P}(A \mid B_i) \mathbb{P}(B_i)$. $\square$

3.4 Satz von Bayes

Der Satz von Bayes ermöglicht die Umkehrung bedingter Wahrscheinlichkeiten und ist das Fundament der bayesischen Statistik:

Satz 3.3 (Satz von Bayes). *Sei $(B_i)_{i=1}^n$ eine Partition von Ω mit $\mathbb{P}(B_i) > 0$ und $\mathbb{P}(A) > 0$. Dann gilt:*

$$\mathbb{P}(B_j \mid A) = \frac{\mathbb{P}(A \mid B_j) \cdot \mathbb{P}(B_j)}{\sum_{i=1}^n \mathbb{P}(A \mid B_i) \cdot \mathbb{P}(B_i)}.$$

Man bezeichnet $\mathbb{P}(B_j)$ als **A-priori-Wahrscheinlichkeit** und $\mathbb{P}(B_j \mid A)$ als **A-posteriori-Wahrscheinlichkeit**.

Zentral ist, dass der Nenner gerade $\mathbb{P}(A) = 1$ sein würde, wenn $A = \Omega$, was die Konsistenz mit dem Vollständigkeitsprinzip unterstreicht.

4 Zufallsvariablen, Erwartungswert und Varianz

4.1 Zufallsvariablen

Für Versuche, die durch diskrete Ereignisse beschrieben werden, ist es für die Analyse manchmal hilfreich, eine Zufallsvariable zu verwenden. Dabei beschreibt die Zufallsvariable den Zufall für das Ereignis variabel für den konkreten Ausgang. Zum Beispiel kann für den Versuch, einen Würfel zu würfeln, eine Zufallsvariable definiert werden durch

$$X = \{\text{Anzahl der Augen, auf die der Würfel fällt}\}. \quad (1)$$

Es fiel auf, dass für jedes Ereignis dieses Versuches gilt, dass der Würfel beim Wurf auf die Augenzahl k fällt, die *Wahrscheinlichkeit* $\frac{1}{6}$ hat, $k \in \{1, \dots, 6\}$. Mit der Zufallsvariable ist diese Beobachtung nun so beschreibbar: $P(X = k) = \frac{1}{6}$, wobei P für Probability steht.

Definition 4.1 (Zufallsvariable). Eine **Zufallsvariable** (ZV) $X: \Omega \rightarrow \mathbb{R}$ ist eine messbare Funktion von einem Wahrscheinlichkeitsraum $(\Omega, \mathcal{F}, \mathbb{P})$ nach $(\mathbb{R}, \mathcal{B}(\mathbb{R}))$. Die **Verteilungsfunktion** von X ist

$$F_X(x) := \mathbb{P}(X \leq x), \quad x \in \mathbb{R}.$$

Eine ZV X heißt **diskret**, wenn sie nur abzählbar viele Werte annimmt; sie heißt **stetig**, wenn F_X absolut stetig ist, d. h. eine Dichte f_X besitzt mit $F_X(x) = \int_{-\infty}^x f_X(t) dt$.

4.2 Erwartungswert

Bei dem Versuch, den Würfel zu würfeln, ist es vor dem Versuch von Bedeutung, zu ermitteln, welcher Ausgang des Versuches zu erwarten ist. Für Versuche, die durch diskrete Ereignisse beschrieben werden, wird der Erwartungswert für eine Zufallsvariable X berechnet.

Definition 4.2 (Erwartungswert). Sei X eine ZV auf $(\Omega, \mathcal{F}, \mathbb{P})$.

- **Diskreter Fall:** X nimmt die Werte $x_1, x_2, \dots$ an. Existiert $\sum_i |x_i| \mathbb{P}(X = x_i) < \infty$, so ist

$$\mathbb{E}[X] := \sum_i x_i \cdot \mathbb{P}(X = x_i).$$

- **Stetiger Fall:** X besitzt Dichte f_X . Existiert $\int_{-\infty}^{\infty} |x| f_X(x) dx < \infty$, so ist

$$\mathbb{E}[X] := \int_{-\infty}^{\infty} x \cdot f_X(x) dx.$$

- **Allgemeiner Fall (Lebesgue-Integral):** $\mathbb{E}[X] := \int_{\Omega} X(\omega) d\mathbb{P}(\omega)$.

Beispiel 4.1 (Erwartungswert beim fairen Würfel). X sei die Augenzahl beim einmaligen Würfeln gemäß (1), $\mathbb{P}(X = k) = \frac{1}{6}$ für $k \in \{1, \dots, 6\}$. Dann:

$$E[X] = \sum_{k \in \{1, \dots, 6\}} k \cdot P(X = k) \quad (2)$$

$$= 1 \cdot P(X = 1) + \dots + 6 \cdot P(X = 6) \quad (3)$$

$$= 1 \cdot \frac{1}{6} + \dots + 6 \cdot \frac{1}{6} \quad (4)$$

$$= 3,5. \quad (5)$$

Das bedeutet, bevor wir den Würfel einmal gewürfelt haben, erwarten wir, dass der Würfel auf die Augenzahl 3,5 fällt. Diese Augenzahl gibt es nicht. Der Erwartungswert aber beschreibt formal am genauesten, welcher Ausgang bei diesem Versuch wirklich zu erwarten ist. Denn erst wenn wir diesen Versuch oft wiederholen, ist es interessant, wie der tatsächliche Ausgang des Versuches vom Erwartungswert abweicht. Beachte: $3,5 \notin \Omega$. Der Erwartungswert ist der *langfristige Durchschnitt*, keine einzelne Augenzahl.

Satz 4.1 (Linearität des Erwartungswerts). Für ZV X, Y und Konstanten $a, b \in \mathbb{R}$ gilt stets:

$$\mathbb{E}[aX + bY] = a \mathbb{E}[X] + b \mathbb{E}[Y].$$

Diese Eigenschaft gilt **unabhängig** davon, ob X und Y unabhängig sind.

Die Linearität des Erwartungswerts ist eines der mächtigsten Werkzeuge der Wahrscheinlichkeitstheorie und fundamental für die Analyse randomisierter Algorithmen.

4.3 Varianz und Standardabweichung

Definition 4.3 (Varianz und Standardabweichung).

$$\text{Var}(X) := \mathbb{E}[(X - \mathbb{E}[X])^2] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2.$$

Die **Standardabweichung** ist $\sigma_X := \sqrt{\text{Var}(X)}$.

Satz 4.2 (Rechenregeln für die Varianz). (i) $\text{Var}(aX + b) = a^2 \text{Var}(X)$ für $a, b \in \mathbb{R}$.

(ii) Sind $X_1, \dots, X_n$ paarweise unkorreliert (insb. unabhängig):

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n \text{Var}(X_i).$$

4.4 Wichtige Ungleichungen

Satz 4.3 (Markov-Ungleichung). Für eine nicht-negative ZV X und $a > 0$:

$$\mathbb{P}(X \geq a) \leq \frac{\mathbb{E}[X]}{a}.$$

Satz 4.4 (Tschebyschow-Ungleichung). Für eine ZV X mit $\mathbb{E}[X] = \mu$ und $\text{Var}(X) = \sigma^2$ sowie $k > 0$:

$$\mathbb{P}(|X - \mu| \geq k\sigma) \leq \frac{1}{k^2}.$$

Äquivalent: $\mathbb{P}(|X - \mu| \geq t) \leq \frac{\sigma^2}{t^2}$.

Satz 4.5 (Chernoff-Schranken). Seien $X_1, \dots, X_n$ unabhängige Bernoulli-ZV mit $\mathbb{P}(X_i = 1) = p_i$ und $\mu = \mathbb{E}[\sum X_i] = \sum p_i$. Dann gilt für $\delta > 0$:

$$\mathbb{P}\left(\sum_{i=1}^n X_i \geq (1 + \delta)\mu\right) \leq \left(\frac{e^\delta}{(1 + \delta)^{1+\delta}}\right)^\mu \leq e^{-\mu\delta^2/3} \quad \text{für } \delta \leq 1.$$

Für die untere Schranke gilt für $0 < \delta < 1$:

$$\mathbb{P}\left(\sum_{i=1}^n X_i \leq (1 - \delta)\mu\right) \leq e^{-\mu\delta^2/2}.$$

4.5 Bedingter Erwartungswert

Definition 4.4 (Bedingter Erwartungswert). Sei X eine ZV und $B \in \mathcal{F}$ mit $\mathbb{P}(B) > 0$. Der **bedingte Erwartungswert** von X gegeben B ist

$$\mathbb{E}[X \mid B] := \frac{\mathbb{E}[X \cdot \mathbf{1}_B]}{\mathbb{P}(B)} = \frac{1}{\mathbb{P}(B)} \int_B X(\omega) d\mathbb{P}(\omega).$$

Für eine diskrete ZV Y mit Werten $y_1, y_2, \dots$ ist der **bedingte Erwartungswert** von X gegeben Y die ZV $\mathbb{E}[X \mid Y] := g(Y)$, wobei $g(y_j) = \mathbb{E}[X \mid Y = y_j]$.

Satz 4.6 (Turm-Eigenschaft (Law of Total Expectation)).

$$\mathbb{E}[\mathbb{E}[X \mid Y]] = \mathbb{E}[X].$$

Insbesondere: Ist (B_i) eine Partition von Ω mit $\mathbb{P}(B_i) > 0$, so gilt

$$\mathbb{E}[X] = \sum_i \mathbb{E}[X \mid B_i] \cdot \mathbb{P}(B_i).$$

Die Turm-Eigenschaft ist das Analogon des Satzes der totalen Wahrscheinlichkeit für Erwartungswerte. Sie drückt erneut das Prinzip der vollständigen Beschreibbarkeit aus: Man kann den Erwartungswert berechnen, indem man über eine vollständige Partition des Ergebnisraums mittelt.

5 Diskrete Wahrscheinlichkeitsverteilungen

5.1 Überblick und Vollständigkeitsprüfung

Wann immer die Lehre vom Zufall in der Mathematik so verlassen wird, dass sie in der Praxis nicht mehr anwendbar ist, verletzen wir das eigentliche Ziel der Mathematik in diesem wichtigen Thema. Beim Erwartungswert war dies schon der Fall, denn auf die Augenzahl 3,5 wird der Würfel nie zufällig fallen. Damit muss die Lehre vom Zufall in der Mathematik sehr vorsichtig entwickelt werden. Denn wenn man zum Beispiel den Versuch, einen Würfel zu würfeln, oft wiederholt, ist beobachtbar, dass die Abweichung vom Erwartungswert beachtlich ist.

Die bekannten Wahrscheinlichkeitsverteilungen der Mathematik sind für die unterschiedlichen Versuche mit diskreten Ereignissen mit großer Genauigkeit und Vorsicht anzuwenden. Wird ein Versuch in seiner Beschreibung auf eine Anwendung einer Wahrscheinlichkeitsverteilung überprüft, können kleinste Details in der Beschreibung des Versuchs entscheidend sein für die Wahl der Wahrscheinlichkeitsverteilung. Wird ein Detail in der Beschreibung des Versuchs übersehen und eine andere Wahrscheinlichkeitsverteilung gewählt, kann dies in der Analyse für den Versuch zu einem anderen Ergebnis führen.

Im Folgenden werden die unterschiedlichen Wahrscheinlichkeitsverteilungen aufgeführt. Für jede Verteilung wird explizit gezeigt, dass die Vollständigkeitsbedingung $\sum_k \mathbb{P}(X = k) = 1$ erfüllt ist. Dabei sollen Gemeinsamkeiten auffallen und dazu führen, dass diese Verteilungen mit Genauigkeit und Vorsicht anzuwenden sind.

5.2 Bernoulli-Verteilung

Die Bernoulli-Verteilung beschreibt Versuche, bei denen es nur zwei mögliche Ereignisse gibt. Ein Ereignis wird als Erfolg bezeichnet und das andere als Misserfolg. Zum Beispiel kann beim Wurf einer Münze das Ereignis Kopf als Erfolg und das Ereignis Zahl als Misserfolg bezeichnet werden. Ebenso kann beim Würfeln eines Würfels das Ereignis, dass der Würfel auf die Augenzahl 6 fällt, als Erfolg bezeichnet werden und alle anderen Ereignisse, dass der Würfel auf die Augenzahlen 1, 2, 3, 4 oder 5 fällt, als Misserfolg.

Definition 5.1 (Bernoulli-Verteilung $\text{Ber}(p)$). Für einen Versuch, der durch die Bernoulli-Verteilung beschrieben wird, wird eine Zufallsvariable X definiert durch

$$X = \begin{cases} 1, & \text{falls Erfolg eintritt} \\ 0, & \text{falls Misserfolg eintritt} \end{cases} \quad (6)$$

Die Wahrscheinlichkeit für den Erfolg wird mit p bezeichnet, also $P(X = 1) = p$. Die Wahrscheinlichkeit für den Misserfolg ist dann $P(X = 0) = 1 - p$. Es ist wichtig zu beachten, dass die Summe aller Wahrscheinlichkeiten $p + (1 - p) = 1$ ergibt. Damit ist der Versuch mathematisch vollständig beschrieben. Es gilt $\mathbb{E}[X] = p$ und $\text{Var}(X) = p(1 - p)$.

Der Erwartungswert einer bernoulli-verteilten Zufallsvariablen X berechnet sich wie folgt:

$$E[X] = 1 \cdot P(X = 1) + 0 \cdot P(X = 0) \quad (7)$$

$$= 1 \cdot p + 0 \cdot (1 - p) \quad (8)$$

$$= p. \quad (9)$$

Das bedeutet, bei einem Versuch, der durch die Bernoulli-Verteilung beschrieben wird, erwarten wir im Mittel den Wert p . Für den Münzwurf mit $p = \frac{1}{2}$ erwarten wir also den Wert 0,5. Dieser Wert kann nicht eintreten, denn die Münze zeigt entweder Kopf oder Zahl. Der Erwartungswert beschreibt aber formal genau, was bei vielen Wiederholungen dieses Versuchs zu erwarten ist.

Beispiel 5.1 (Basketball). Ein Basketballspieler trifft den Korb mit einer Wahrscheinlichkeit von $p = 0,7$. Bei einem einzelnen Wurf wird der Erfolg (Treffer) mit der Zufallsvariablen X beschrieben, die bernoulli-verteilt ist mit Parameter $p = 0,7$. Der erwartete Wert ist $E[X] = 0,7$.

Die Bernoulli-Verteilung ist die einfachste aller Wahrscheinlichkeitsverteilungen. Sie ist die Grundlage für viele weitere Verteilungen. Wird ein Versuch, der durch die Bernoulli-Verteilung beschrieben wird, mehrfach unabhängig wiederholt, ergeben sich andere Wahrscheinlichkeitsverteilungen.

5.3 Binomialverteilung

Definition 5.2 (Binomialverteilung $\text{Bin}(n, p)$). $X \sim \text{Bin}(n, p)$: Anzahl der Erfolge bei n unabhängigen Bernoulli-Experimenten mit Erfolgswahrscheinlichkeit p .

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1-p)^{n-k}, \quad k = 0, \dots, n.$$

Vollständigkeit (Binomischer Lehrsatz): $\sum_{k=0}^n \binom{n}{k} p^k (1-p)^{n-k} = (p + (1-p))^n = 1$.
 $\mathbb{E}[X] = np$, $\text{Var}(X) = np(1-p)$.

5.4 Geometrische Verteilung

Die geometrische Verteilung beschreibt Versuche, bei denen ein Bernoulli-Versuch so oft wiederholt wird, bis zum ersten Mal ein Erfolg eintritt. Es stellt sich die Frage: Wie viele Versuche sind nötig, bis der erste Erfolg eintritt? Beim Würfeln eines Würfels kann man fragen: Wie oft muss der Würfel geworfen werden, bis zum ersten Mal die Augenzahl 6 fällt? Bei diesem Versuch wird der Würfel so lange geworfen, bis die Augenzahl 6 das erste Mal erscheint.

Definition 5.3 (Geometrische Verteilung $\text{Geo}(p)$). Für einen Versuch, der durch die geometrische Verteilung beschrieben wird, wird eine Zufallsvariable X definiert durch

$$X = \{\text{Anzahl der Versuche bis zum ersten Erfolg}\}. \quad (10)$$

Die Wahrscheinlichkeit, dass der erste Erfolg genau beim k -ten Versuch eintritt: Es müssen zunächst $k-1$ Misserfolge eintreten, jeder mit Wahrscheinlichkeit $1-p$, und dann muss beim k -ten Versuch ein Erfolg mit Wahrscheinlichkeit p eintreten. Damit ergibt sich:

$$\mathbb{P}(X = k) = (1-p)^{k-1} p, \quad k = 1, 2, \dots$$

Die Vollständigkeit überprüfen wir explizit:

$$\sum_{k=1}^{\infty} \mathbb{P}(X = k) = \sum_{k=1}^{\infty} (1-p)^{k-1} \cdot p = p \cdot \frac{1}{1-(1-p)} = p \cdot \frac{1}{p} = 1. \quad (11)$$

Damit ist der Versuch mathematisch vollständig beschrieben. $\mathbb{E}[X] = \frac{1}{p}$, $\text{Var}(X) = \frac{1-p}{p^2}$.

Das bedeutet, im Erwartungswert benötigen wir $\frac{1}{p}$ Versuche bis zum ersten Erfolg. Für das Würfeln einer 6 mit einem Würfel ist $p = \frac{1}{6}$. Damit erwarten wir $E[X] = \frac{1}{1/6} = 6$ Würfe bis zum ersten Mal die Augenzahl 6 fällt. Dies ist ein intuitives Ergebnis. Wird der Versuch in der Praxis durchgeführt, kann es sein, dass die 6 bereits beim ersten Wurf fällt. Es kann aber auch sein, dass die 6 erst nach 20 Würfeln das erste Mal fällt. Der Erwartungswert beschreibt das, was im Mittel über viele Wiederholungen dieses gesamten Versuchs zu erwarten ist.

Beispiel 5.2 (Telefonverkauf). Ein Unternehmen ruft potenzielle Kunden an. Jeder Kunde kauft mit Wahrscheinlichkeit $p = 0,2$ das Produkt. Die Anzahl der Anrufe bis zum ersten Verkauf ist geometrisch verteilt mit Parameter $p = 0,2$. Im Erwartungswert sind $E[X] = \frac{1}{0,2} = 5$ Anrufe nötig bis zum ersten Verkauf.

Die geometrische Verteilung zeigt, wie vorsichtig der Erwartungswert interpretiert werden muss. In der Praxis kann die tatsächliche Anzahl der benötigten Versuche erheblich vom Erwartungswert abweichen. Dies ist bei allen Wahrscheinlichkeitsverteilungen zu beachten.

5.5 Poisson-Verteilung

Definition 5.4 (Poisson-Verteilung $\text{Poi}(\lambda)$).

$$\mathbb{P}(X = k) = \frac{\lambda^k e^{-\lambda}}{k!}, \quad k = 0, 1, 2, \dots, \lambda > 0.$$

Vollständigkeit (Exponentialreihe): $\sum_{k=0}^{\infty} \frac{\lambda^k e^{-\lambda}}{k!} = e^{-\lambda} \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} = e^{-\lambda} \cdot e^{\lambda} = 1$.
 $\mathbb{E}[X] = \lambda$, $\text{Var}(X) = \lambda$.

5.6 Stetige Verteilungen

5.6.1 Gleichverteilung $\mathcal{U}([a, b])$

$$f(x) = \frac{1}{b-a} \cdot \mathbf{1}_{[a,b]}(x).$$

Vollständigkeit: $\int_a^b \frac{1}{b-a} dx = 1$. $\mathbb{E}[X] = \frac{a+b}{2}$, $\text{Var}(X) = \frac{(b-a)^2}{12}$.

5.6.2 Normalverteilung $\mathcal{N}(\mu, \sigma^2)$

Die Gaußsche Verteilung, auch Normalverteilung genannt, beschreibt kontinuierliche Ereignisse. Bei kontinuierlichen Ereignissen kann die Zufallsvariable jeden beliebigen Wert aus einem Intervall annehmen, zum Beispiel alle reellen Zahlen. Ein Beispiel für einen Versuch mit kontinuierlichen Ereignissen ist die Messung der Körpergröße von Menschen. Die Körpergröße kann jeden Wert aus einem bestimmten Intervall annehmen – sie ist keine diskrete Größe wie die Augenzahl beim Würfeln, sondern eine kontinuierliche Größe.

Die Gaußsche Verteilung wird durch zwei Parameter beschrieben: den Erwartungswert μ und die Varianz σ^2 . Der Erwartungswert μ gibt an, um welchen Wert herum die Zufallsvariable streut. Die Varianz σ^2 gibt an, wie stark die Zufallsvariable um den Erwartungswert streut. Die Standardabweichung σ ist die Wurzel aus der Varianz.

$$f(x) = \frac{1}{\sigma\sqrt{2\pi}} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right), \quad x \in \mathbb{R}.$$

Bei kontinuierlichen Verteilungen kann nicht mehr nach der Wahrscheinlichkeit für ein einzelnes Ereignis gefragt werden, denn diese ist immer 0. Stattdessen wird nach der Wahrscheinlichkeit gefragt, dass die Zufallsvariable X in einem bestimmten Intervall $[a, b]$ liegt:

$$\mathbb{P}(a \leq X \leq b) = \int_a^b f(x) dx.$$

Vollständigkeit: $\int_{-\infty}^{\infty} f(x) dx = 1$ (Gaußsches Integral). $\mathbb{E}[X] = \mu$, $\text{Var}(X) = \sigma^2$.

Beispiel 5.3 (Körpergröße). Die Körpergröße von erwachsenen Männern in Deutschland ist annähernd normalverteilt mit Erwartungswert $\mu = 180$ cm und Standardabweichung $\sigma = 7$ cm. Die Wahrscheinlichkeit, dass ein zufällig ausgewählter Mann eine Körpergröße zwischen 173 cm und 187 cm hat, entspricht etwa 68 %. Dies ist ein bekanntes Ergebnis der Gaußschen Verteilung: Etwa 68 % aller Werte liegen im Intervall $[\mu - \sigma, \mu + \sigma]$.

Nicht jede Größe ist normalverteilt. Wird eine Größe fälschlicherweise als normalverteilt angenommen, können die Ergebnisse der Analyse völlig falsch sein. Zum Beispiel sind Aktienkurse nicht normalverteilt, obwohl dies oft angenommen wird. Extreme Ereignisse treten bei Aktienkursen viel häufiger auf als die Gaußsche Verteilung vorhersagt. Die Gaußsche Verteilung ist ein mächtiges Werkzeug, aber sie muss mit Genauigkeit und Vorsicht angewendet werden. Nur wenn die Voraussetzungen für ihre Anwendung erfüllt sind, liefert sie zuverlässige Ergebnisse.

5.6.3 Exponentialverteilung $\text{Exp}(\lambda)$

$$f(x) = \lambda e^{-\lambda x} \cdot \mathbf{1}_{[0, \infty)}(x), \quad \lambda > 0.$$

Vollständigkeit: $\int_0^{\infty} \lambda e^{-\lambda x} dx = 1$. $\mathbb{E}[X] = \frac{1}{\lambda}$, $\text{Var}(X) = \frac{1}{\lambda^2}$.

Die Exponentialverteilung besitzt die **Gedächtnislosigkeit**: $\mathbb{P}(X > s + t \mid X > s) = \mathbb{P}(X > t)$.

5.7 Anwendung: Hybrider Registerspeicher

Ein interessantes Beispiel der Gaußschen Verteilung ist die Optimierung von Registerspeichern in Prozessoren. Dabei wird beobachtet, dass die Zugriffe auf Register nicht gleichmäßig verteilt sind, sondern einer Gaußschen Verteilung folgen. Einige Register werden sehr häufig verwendet, während andere Register selten genutzt werden.

Anstatt alle Register gleich zu behandeln, wird eine hierarchische Struktur eingeführt. Die Register, die am häufigsten genutzt werden, werden in schnellem und teurem Speicher realisiert. Die Register, die seltener genutzt werden, werden in langsamem und günstigem Speicher realisiert.

Für diesen Versuch wird eine Zufallsvariable X definiert durch

$$X = \{\text{Register-Index, auf den zugegriffen wird}\}.$$

Die Beobachtung zeigt, dass X annähernd normalverteilt ist mit einem Erwartungswert μ und einer Standardabweichung σ . Der Erwartungswert μ gibt an, welcher Register-Index im Mittel am häufigsten genutzt wird.

Der hierarchische Aufbau des Registerspeichers erfolgt in zwei Bereichen. Der erste Bereich, genannt *Tier 1*, enthält etwa 32 bis 64 Register, die nahe beim Erwartungswert μ liegen, also im Intervall $[\mu - \sigma, \mu + \sigma]$. Wie beim Körpergröße-Beispiel wissen wir, dass

etwa 68 % aller Zugriffe auf Register in diesem Intervall liegen. Diese Register werden in schnellem Speicher realisiert. Der zweite Bereich, genannt *Tier 2*, enthält alle übrigen Register in langsamem, aber günstigem Speicher.

Um zu ermitteln, welche Register zu Tier 1 gehören, muss das Zugriffsmuster analysiert werden. Für jedes Register i wird während des Betriebs eine Zufallsvariable Y_i gezählt (Anzahl der Zugriffe auf Register i). Die Register mit den höchsten Werten von Y_i werden Tier 1 zugeordnet.

Es ist wichtig zu beachten, dass die Zuordnung nicht statisch ist – die Zugriffsmuster können sich während der Laufzeit ändern. Tier 1 und Tier 2 müssen daher dynamisch angepasst werden.

Die Kostenersparnis durch diesen Ansatz lässt sich berechnen. Sei n_1 die Anzahl der Register in Tier 1 und n_2 die Anzahl in Tier 2, $c_1 \gg c_2$ die jeweiligen Kosten pro Register. Die Gesamtkosten betragen $C = n_1 c_1 + n_2 c_2$. Ohne die hierarchische Struktur wären alle $n_1 + n_2$ Register in teurem Speicher mit Gesamtkosten $(n_1 + n_2) c_1$. Die Kostenersparnis beträgt damit

$$\Delta C = (n_1 + n_2) c_1 - (n_1 c_1 + n_2 c_2) = n_2 (c_1 - c_2). \quad (12)$$

Da typischerweise $n_2 \gg n_1$ gilt, ist die Ersparnis erheblich. Dieses Beispiel zeigt, wie die Gaußsche Verteilung in der Praxis angewendet wird – aber auch, wie wichtig es ist, die Voraussetzung der Normalverteilung für das konkrete Programm zu überprüfen.

6 Randomisierte Algorithmen

Zufall ist nicht nur ein Gegenstand mathematischer Analyse, sondern ein mächtiges *algorithmisches Werkzeug*. Randomisierte Algorithmen nutzen Zufallsentscheidungen, um

- im **Worst Case schwere** Probleme *im Erwartungswert* effizient zu lösen (*Las-Vegas-Algorithmen*: immer korrekt, erwartete Laufzeit gut),
- korrekte Lösungen *mit hoher Wahrscheinlichkeit* schnell zu finden (*Monte-Carlo-Algorithmen*: eventuell falsch, aber mit kleiner Fehlerwahrscheinlichkeit),
- im kontinuierlichen Raum integrierbar zu machen (*Monte-Carlo-Integration*).

6.1 3-SAT-Approximation mit Erwartungswert $\geq 7/8$

6.1.1 Das Problem

Definition 6.1 (3-SAT). Gegeben eine aussagenlogische Formel $\varphi = C_1 \wedge C_2 \wedge \dots \wedge C_m$ in konjunktiver Normalform, wobei jede Klausel C_j genau drei Literale enthält. Gesucht ist eine Variablenbelegung, die so viele Klauseln wie möglich erfüllt. Das Entscheidungsproblem (alle Klauseln erfüllbar?) ist NP-vollständig [9].

6.1.2 Der randomisierte Algorithmus

Die folgende Idee stammt von Johnson [22]: Weise jeder Variable x_i unabhängig und gleichverteilt einen der Werte $\{\text{wahr}, \text{falsch}\}$ zu.

Algorithm 1 Randomisierte 3-SAT-Approximation

Require: 3-CNF-Formel φ mit Variablen $x_1, \dots, x_n$ und Klauseln $C_1, \dots, C_m$

Ensure: Variablenbelegung β (erfüllt in Erwartung $\geq 7m/8$ Klauseln)

```
1: for  $i \leftarrow 1$  to  $n$  do
2:   Wähle  $\beta(x_i) \in \{\text{wahr}, \text{falsch}\}$  gleichverteilt und unabhängig.
3: end for
4:  $SAT \leftarrow 0$ 
5: for  $j \leftarrow 1$  to  $m$  do
6:   if  $C_j$  ist unter  $\beta$  erfüllt then
7:      $SAT \leftarrow SAT + 1$ 
8:   end if
9: end for
10: return  $\beta$  (und  $SAT$ )
```

6.1.3 Erwartungswert-Analyse

Satz 6.1 (Erwartungswert der erfüllten Klauseln). Sei $Y_j = \mathbf{1}[\text{Klausel } C_j \text{ ist erfüllt}]$ für $j = 1, \dots, m$. Dann gilt:

$$\mathbb{E}\left[\sum_{j=1}^m Y_j\right] \geq \frac{7}{8}m.$$

Beweis. Da jede Klausel genau drei Literale enthält, ist eine Klausel genau dann *nicht* erfüllt, wenn alle drei Literale den Wert **falsch** haben. Jedes Literal ist unabhängig mit Wahrscheinlichkeit $\frac{1}{2}$ falsch. Also:

$$\mathbb{P}(C_j \text{ nicht erfüllt}) = \left(\frac{1}{2}\right)^3 = \frac{1}{8}.$$

Daher:

$$\mathbb{P}(C_j \text{ erfüllt}) = 1 - \frac{1}{8} = \frac{7}{8}.$$

Mit der Linearität des Erwartungswerts (Satz 4.1):

$$\mathbb{E}\left[\sum_{j=1}^m Y_j\right] = \sum_{j=1}^m \mathbb{E}[Y_j] = \sum_{j=1}^m \mathbb{P}(C_j \text{ erfüllt}) = m \cdot \frac{7}{8}.$$

Hierbei wurde *keine* Unabhängigkeit der Y_j benötigt – nur die Linearität des Erwartungswerts. $\square$

Die erwartete Gesamtzahl aller erfüllten Klauseln beträgt damit also $\frac{7}{8}m$. Sei O die optimale Anzahl an Klauseln, die in φ erfüllt werden können. Dann kann O höchstens alle m Klauseln erfüllen, also $O \leq m$. Damit ergibt sich

$$\mathbb{E}[Y] = \frac{7}{8}m \geq \frac{7}{8}O.$$

Das bedeutet: Die Lösung des Algorithmus erfüllt im Erwartungswert mindestens $\frac{7}{8}$ aller Klauseln der optimalen Lösung, die überhaupt in φ erfüllt werden können. Die Laufzeit ist linear in der Anzahl der Klauseln und Variablen.

Verbindung zum Vollständigkeitsprinzip. Der Beweis nutzt implizit die vollständige Beschreibbarkeit: Für jede Klausel C_j ist $\mathbb{P}(C_j \text{ erfüllt}) + \mathbb{P}(C_j \text{ nicht erfüllt}) = \frac{7}{8} + \frac{1}{8} = 1$.

6.1.4 Derandomisierung via Methode der bedingten Erwartungswerte

Mit der Methode der bedingten Erwartungswerte [2] lässt sich der Algorithmus *derandomisieren*: Man setzt die Variablen nacheinander auf **wahr** oder **falsch**, indem man bei jedem Schritt denjenigen Wert wählt, der den bedingten Erwartungswert der erfüllten Klauseln maximiert. Das resultierende deterministische Verfahren hat Laufzeit $O(nm)$ und garantiert ebenfalls $\geq \frac{7}{8}m$ erfüllte Klauseln. Håstad zeigte, dass $\frac{7}{8}$ optimal unter der Annahme $P \neq NP$ ist [19].

6.1.5 Laufzeitanalyse

- Schleife zur Belegung: $\Theta(n)$ Zufallszüge.
- Auswertung: $\Theta(m)$ (jede Klausel hat konstante Größe 3).
- Gesamtlaufzeit: $\Theta(n + m)$ – linear in der Eingabegröße.

6.2 Randomisiertes Quicksort

6.2.1 Idee und Pseudocode

Beim deterministischen Quicksort kann ein adversarial gewähltes Pivot-Element zur Worst-Case-Laufzeit $\Theta(n^2)$ führen. Die randomisierte Variante wählt das Pivot-Element zufällig und gleichverteilt:

Algorithm 2 Randomisiertes Quicksort

Require: Array $A[1..n]$ mit n verschiedenen Elementen

Ensure: A sortiert in aufsteigender Reihenfolge

```
1: function RANDQUICKSORT( $A, l, r$ )
2:   if  $l \geq r$  then
3:     return
4:   end if
5:    $p \leftarrow \text{ZUFÄLLIGER-INDEX}(l, r)$  ▷ gleichverteilt in  $\{l, \dots, r\}$ 
6:   Tausche  $A[p]$  mit  $A[r]$ 
7:    $q \leftarrow \text{PARTITION}(A, l, r)$  ▷ Lomuto- oder Hoare-Partition
8:   RANDQUICKSORT( $A, l, q - 1$ )
9:   RANDQUICKSORT( $A, q + 1, r$ )
10: end function

11: function PARTITION( $A, l, r$ )
12:    $pivot \leftarrow A[r]$ 
13:    $i \leftarrow l - 1$ 
14:   for  $j \leftarrow l$  to  $r - 1$  do
15:     if  $A[j] \leq pivot$  then
16:        $i \leftarrow i + 1$ 
17:       Tausche  $A[i]$  mit  $A[j]$ 
18:     end if
19:   end for
20:   Tausche  $A[i + 1]$  mit  $A[r]$ 
21:   return  $i + 1$ 
22: end function
```

6.2.2 Erwartete Laufzeitanalyse

Satz 6.2 (Erwartete Laufzeit von Randomisiertem Quicksort). *Die erwartete Anzahl von Vergleichen beim randomisierten Quicksort auf einem Array der Länge n (mit paarweise verschiedenen Elementen) beträgt:*

$$\mathbb{E}[T(n)] = 2n \ln n + O(n) = O(n \log n).$$

Beweis. Seien $z_1 < z_2 < \dots < z_n$ die sortierten Elemente. Definiere die Indikatorvariable

$$X_{ij} = \mathbf{1}[z_i \text{ und } z_j \text{ werden verglichen}], \quad 1 \leq i < j \leq n.$$

Die Gesamtzahl der Vergleiche ist $C = \sum_{i < j} X_{ij}$. Mit der Linearität des Erwartungswerts:

$$\mathbb{E}[C] = \sum_{i=1}^n \sum_{j=i+1}^n \mathbb{P}(z_i \text{ und } z_j \text{ werden verglichen}).$$

Schlüsselbeobachtung: z_i und z_j werden genau dann verglichen, wenn in der Menge $\{z_i, z_{i+1}, \dots, z_j\}$ entweder z_i oder z_j als erstes zum Pivot gewählt wird. Da das Pivot gleichverteilt aus dieser Menge der $j - i + 1$ Elemente gewählt wird:

$$\mathbb{P}(X_{ij} = 1) = \frac{2}{j - i + 1}.$$

Vollständigkeit: Es gilt

$$\begin{aligned} & \mathbb{P}(z_i \text{ zuerst Pivot in } \{z_i, \dots, z_j\}) + \mathbb{P}(z_j \text{ zuerst Pivot}) + \mathbb{P}(\text{anderes Element zuerst}) \\ &= \frac{1}{j-i+1} + \frac{1}{j-i+1} + \frac{j-i-1}{j-i+1} = 1. \end{aligned}$$

Damit ergibt sich:

$$\begin{aligned} \mathbb{E}[C] &= \sum_{i=1}^n \sum_{j=i+1}^n \frac{2}{j-i+1} = \sum_{i=1}^n \sum_{k=2}^{n-i+1} \frac{2}{k} \leq \sum_{i=1}^n \sum_{k=2}^n \frac{2}{k} \\ &= 2n \sum_{k=2}^n \frac{1}{k} = 2n(H_n - 1) \leq 2n \ln n + O(n), \end{aligned}$$

wobei $H_n = \sum_{k=1}^n \frac{1}{k} \approx \ln n + \gamma$ die n -te harmonische Zahl ist. $\square$

Die Worst-Case-Laufzeit bleibt $\Theta(n^2)$, tritt aber nur mit exponentiell kleiner Wahrscheinlichkeit auf: Per Chernoff-Schranke (Satz 4.5) gilt $T(n) > cn^2$ mit Wahrscheinlichkeit $e^{-\Omega(n)}$.

6.3 Kargerscher Algorithmus für minimale Schnitte

6.3.1 Das Problem und die Idee

Definition 6.2 (Minimaler Schnitt). Gegeben ein ungerichteter, zusammenhängender Multigraph $G = (V, E)$ mit $|V| = n$ Knoten. Ein **Schnitt** ist eine Partition $V = S \cup \bar{S}$; seine **Kapazität** ist $|E(S, \bar{S})|$, die Anzahl der Kanten zwischen S und $\bar{S}$. Gesucht ist ein Schnitt minimaler Kapazität.

Kargers randomisierter Kontraktionsalgorithmus [23] funktioniert durch wiederholte *Kantenkontraktion*:

Algorithm 3 Karger-Kontraktion

Require: Multigraph $G = (V, E)$ mit $n = |V| \geq 2$

Ensure: Kandidat für einen minimalen Schnitt

- 1: $G' \leftarrow G$
 - 2: **while** $|V(G')| > 2$ **do**
 - 3: Wähle eine Kante $e = \{u, v\} \in E(G')$ uniformly at random.
 - 4: Kontrahiere e : Verschmelze u und v zu einem Superknoten. ▷ Schleifen werden entfernt, Mehrfachkanten bleiben
 - 5: Entferne alle Schleifen aus G' .
 - 6: **end while**
 - 7: **return** die Menge $E(G')$ (alle verbleibenden Kanten bilden einen Kandidat-Schnitt)
-

6.3.2 Analyse: Wahrscheinlichkeit des Erfolgs

Satz 6.3 (Erfolgswahrscheinlichkeit der Karger-Kontraktion). *Sei k die Größe eines minimalen Schnitts. Der Algorithmus gibt diesen minimalen Schnitt mit Wahrscheinlichkeit $\geq \frac{2}{n(n-1)}$ zurück.*

Beweis. Sei F die Kantenmenge eines festen minimalen Schnitts mit $|F| = k$. Da jeder Knoten mindestens k Kanten hat, gilt $|E| \geq \frac{nk}{2}$.

Beim i -ten Schritt enthält der Graph noch $n - i + 1$ Superknoten, also mindestens $\frac{(n-i+1)k}{2}$ Kanten. Die Wahrscheinlichkeit, eine Kante aus F nicht zu kontrahieren, ist mindestens

$$1 - \frac{k}{\frac{(n-i+1)k}{2}} = 1 - \frac{2}{n-i+1}.$$

Die Wahrscheinlichkeit, dass *keine* der $n - 2$ Kontraktionsschritte eine Kante aus F trifft, ist mindestens:

$$\prod_{i=1}^{n-2} \left(1 - \frac{2}{n-i+1}\right) = \prod_{t=3}^n \frac{t-2}{t} = \frac{1 \cdot 2 \cdot 3 \cdots (n-2)}{3 \cdot 4 \cdots n} = \frac{2}{n(n-1)}.$$

Hierbei wurde Vollständigkeit genutzt: Die Wahrscheinlichkeiten der k Kantenwahlen summieren sich in jedem Schritt zu 1. $\square$

6.3.3 Karger-Stein-Algorithmus und Gesamtlaufzeit

Durch $\Theta(n^2 \log n)$ -fache Wiederholung und rekursive Beschleunigung [24] erhält man den **Karger-Stein-Algorithmus** mit:

- Erfolgswahrscheinlichkeit $\geq 1 - \frac{1}{n}$ (hohe Wahrscheinlichkeit).
- Laufzeit $O(n^2 \log^3 n)$.

6.3.4 Laufzeit einer Einzeliteration

Eine Kontraktion benötigt $O(n)$ Zeit (Aktualisierung der Adjazenzlisten). Es gibt $n - 2$ Kontraktionen, daher ist eine Iteration in $O(n^2)$ durchführbar.

6.4 Miller-Rabin-Primzahltest

6.4.1 Motivation

Der deterministische Primzahltest hat lange Zeit Schwierigkeiten bereitet. AKS (2002) liefert einen deterministischen Polynomialzeitalgorithmus [1], ist aber in der Praxis langsamer als der randomisierte Miller-Rabin-Test.

6.4.2 Mathematische Grundlagen

Definition 6.3 (Zusammengesetzte Zahl und Fermat-Test). Für eine Primzahl p gilt nach dem Kleinen Fermatschen Satz: $a^{p-1} \equiv 1 \pmod{p}$ für alle a mit $\gcd(a, p) = 1$. Schreibe $p - 1 = 2^s \cdot d$ mit d ungerade. Dann gilt für alle a : Entweder $a^d \equiv 1 \pmod{p}$, oder es existiert ein $r \in \{0, \dots, s-1\}$ mit $a^{2^r d} \equiv -1 \pmod{p}$. Trifft keines zu, ist p zusammengesetzt.

Algorithm 4 Miller-Rabin-Primzahltest

Require: Ungerade Zahl $n \geq 3$; Sicherheitsparameter $t \geq 1$

Ensure: ZUSAMMENGESETZT oder WAHRSCHEINLICH PRIM

```
1: Schreibe  $n - 1 = 2^s \cdot d$  mit  $d$  ungerade.
2: for  $i \leftarrow 1$  to  $t$  do
3:   Wähle  $a \in \{2, 3, \dots, n - 2\}$  gleichverteilt zufällig.
4:    $x \leftarrow a^d \bmod n$  ▷ Schnelle Exponentiation:  $O(\log n)$  Multiplikationen
5:   if  $x = 1$  oder  $x = n - 1$  then
6:     continue
7:   end if
8:    $found \leftarrow \text{false}$ 
9:   for  $r \leftarrow 1$  to  $s - 1$  do
10:     $x \leftarrow x^2 \bmod n$ 
11:    if  $x = n - 1$  then
12:       $found \leftarrow \text{true}$ ; break
13:    end if
14:  end for
15:  if not  $found$  then
16:    return ZUSAMMENGESETZT
17:  end if
18: end for
19: return WAHRSCHEINLICH PRIM
```

6.4.3 Fehlerwahrscheinlichkeit und Laufzeit

Satz 6.4 (Fehlerwahrscheinlichkeit des Miller-Rabin-Tests). *Ist n zusammengesetzt, so gilt: Für eine gleichverteilt zufällige Basis $a \in \{2, \dots, n - 2\}$ ist*

$$\mathbb{P}(a \text{ ein „starker Lügner“ für } n) \leq \frac{1}{4}.$$

Nach t unabhängigen Iterationen:

$$\mathbb{P}(n \text{ zusammengesetzt und Algorithmus sagt PRIM}) \leq \left(\frac{1}{4}\right)^t.$$

Mit $t = 40$ gilt die Fehlerwahrscheinlichkeit $\leq 4^{-40} \approx 10^{-24}$, also kleiner als die Fehlerwahrscheinlichkeit moderner Hardware.

Vollständigkeit: In jeder Iteration gilt $\mathbb{P}(\text{kein Lügner}) + \mathbb{P}(\text{Lügner}) = 1$.

Laufzeit:

- Exponentiation $a^d \bmod n$: $O(\log n)$ modulare Multiplikationen, jede $O(\log^2 n)$ bitweise, also $O(\log^3 n)$ pro Basis.
- Quadrierungen: $s \leq \log_2 n$ Schritte, je $O(\log^2 n)$.
- Gesamtlaufzeit: $O(t \log^3 n)$.
- Mit FFT-basierter Multiplikation: $O(t \log^2 n \cdot \log \log n)$.

6.5 Polynomial Identity Testing (Schwartz-Zippel-Lemma)

6.5.1 Polynomial Identity Testing

Definition 6.4 (Polynomial Identity Testing (PIT)). Gegeben zwei Polynome $P, Q \in \mathbb{F}[x_1, \dots, x_n]$ mit $\text{Grad} \leq d$, jeweils als Schaltkreis gegeben. Entscheide, ob $P \equiv Q$.

Satz 6.5 (Schwartz-Zippel-Lemma). Sei $\mathbb{F}$ ein Körper, $S \subseteq \mathbb{F}$ eine endliche nicht-leere Teilmenge und $P \in \mathbb{F}[x_1, \dots, x_n] \setminus \{0\}$ ein Polynom vom Grad $\leq d$. Wählt man $r_1, \dots, r_n$ unabhängig gleichverteilt aus S , so gilt:

$$\mathbb{P}(P(r_1, \dots, r_n) = 0) \leq \frac{d}{|S|}.$$

Algorithm 5 Randomisierter Polynom-Identitätstest (Schwartz-Zippel)

Require: Polynome P, Q (als Schaltkreise), endliche Menge $S \subseteq \mathbb{F}$ mit $|S| \geq 2d$, Grad d

Ensure: IDENTISCH oder VERSCHIEDEN

```
1:  $R \leftarrow P - Q$ 
2: for  $i \leftarrow 1$  to  $n$  do
3:   Wähle  $r_i \in S$  gleichverteilt und unabhängig.
4: end for
5: if  $R(r_1, \dots, r_n) = 0$  then
6:   return IDENTISCH ▷ Falsch-Positiv mit  $\mathbb{P} \leq d/|S| \leq 1/2$ 
7: else
8:   return VERSCHIEDEN ▷ Immer korrekt
9: end if
```

Laufzeit: $O(n \cdot d \cdot \text{Schaltkreisgröße})$ für eine Auswertung. Mit $|S| = 2d$ ist Fehlerwahrscheinlichkeit $\leq \frac{1}{2}$; durch k -fache Wiederholung auf 2^{-k} reduzierbar.

6.6 Hashing und Universal Hashing

6.6.1 Motivation

Hash-Tabellen erreichen $O(1)$ amortisierte Laufzeit für Einfügen, Löschen und Suchen – im Erwartungswert unter randomisiertem Hashing.

Definition 6.5 (Universelle Hashfamilie). Eine Familie $\mathcal{H}$ von Hashfunktionen $h : U \rightarrow \{0, \dots, m-1\}$ heißt **universell**, wenn für alle $x \neq y \in U$:

$$\mathbb{P}_{h \sim \mathcal{H}}(h(x) = h(y)) \leq \frac{1}{m}.$$

Algorithm 6 Randomisiertes Hashing (Chaining)

Require: Universum U , Tabellengröße m , universelle Hashfamilie $\mathcal{H}$

Ensure: Hash-Tabelle mit erwartet $O(1)$ Operationen

- 1: Wähle $h \in \mathcal{H}$ gleichverteilt.
- 2: Initialisiere Tabelle $T[0..m-1]$ mit leeren Listen.

- 3: **function** INSERT(x)
- 4: Füge x an $T[h(x)]$ an.
- 5: **end function**

- 6: **function** SEARCH(x)
- 7: Durchsuche Liste $T[h(x)]$ nach x .
- 8: **return** GEFUNDEN oder NICHT GEFUNDEN
- 9: **end function**

6.6.2 Erwartete Listenlänge

Satz 6.6 (Erwartete Listenlänge bei universalem Hashing). *Sei $S \subseteq U$ die gespeicherte Menge mit $|S| = n$ und $m = n$. Für jedes $x \in S$ gilt:*

$$\mathbb{E}[\text{Anzahl Kollisionen mit } x] = \sum_{y \in S, y \neq x} \mathbb{P}(h(x) = h(y)) \leq (n-1) \cdot \frac{1}{n} < 1.$$

Daher ist die erwartete Suchzeit für jedes Element $O(1)$.

6.7 Randomisierter Las-Vegas-Algorithmus: Randomisiertes Finden des Minimums

Algorithm 7 Randomisiertes Minimum-Finden (LazySelect)

Require: Array $A[1..n]$, Position k (gesucht: k -kleinstes Element)

Ensure: Das k -kleinste Element von A

- 1: $r \leftarrow n^{3/4}$
 - 2: Wähle eine Stichprobe R von r Elementen aus A gleichverteilt mit Zurücklegen.
 - 3: Sortiere R .
 - 4: $\ell \leftarrow \max(1, \lfloor kn^{-1/4} \rfloor - \sqrt{n})$, $h \leftarrow \min(r, \lceil kn^{-1/4} \rceil + \sqrt{n})$
 - 5: $a \leftarrow R[\ell]$, $b \leftarrow R[h]$
 - 6: $P \leftarrow \{x \in A : a \leq x \leq b\}$
 - 7: **if** k -kleinstes Element von A liegt in P **und** $|P| \leq 4n^{3/4} + 2$ **then**
 - 8: Sortiere P und gib das $(k - |\{x \in A : x < a\}|)$ -te Element zurück.
 - 9: **else**
 - 10: Starte neu (Misserfolg mit Wahrscheinlichkeit $O(n^{-1/4})$).
 - 11: **end if**
-

Laufzeit: Erwartet $O(n)$ Vergleiche – optimal für das Selektionsproblem.

7 Die probabilistische Methode

7.1 Grundprinzip

Die *probabilistische Methode* [2] ist eine nicht-konstruktive Beweistechnik: Man zeigt, dass ein bestimmtes Objekt (Graph, Belegung, Kode) existiert, indem man zeigt, dass ein zufällig gewähltes Objekt die gewünschte Eigenschaft mit positiver Wahrscheinlichkeit besitzt.

Probabilistische Methode – Grundschemata.

Sei $\mathcal{O}$ eine Menge von Objekten und $\mathcal{E}$ eine Eigenschaft. Man definiert eine Wahrscheinlichkeitsverteilung auf $\mathcal{O}$ und zeigt:

$$\mathbb{P}(O \in \mathcal{O} \text{ hat Eigenschaft } \mathcal{E}) > 0.$$

Daraus folgt: Es existiert ein Objekt in $\mathcal{O}$ mit Eigenschaft $\mathcal{E}$.

7.2 Beispiel: Turán-Ramsey und unabhängige Mengen

Satz 7.1 (Ramsey-Schranke via probabilistische Methode). *Es gilt $R(k, k) \geq 2^{k/2}$ für alle $k \geq 3$.*

Beweis. Betrachte K_n mit $n = \lfloor 2^{k/2} \rfloor$. Färbe jede Kante unabhängig mit Wahrscheinlichkeit $\frac{1}{2}$ rot oder blau. Für eine feste k -Knotenmenge S gilt:

$$\mathbb{P}(\text{alle Kanten in } S \text{ einfarbig}) = 2 \cdot 2^{-\binom{k}{2}}.$$

Mit der Union Bound (Satz 2.1):

$$\mathbb{P}(\exists \text{ einfarbige } k\text{-Clique}) \leq \binom{n}{k} \cdot 2^{1-\binom{k}{2}}.$$

Für $n < 2^{k/2}$ ergibt sich, dass diese Schranke < 1 ist, also mit positiver Wahrscheinlichkeit existiert keine einfarbige k -Clique – und daher existiert eine Färbung ohne solche. $\square$

7.3 Lovász Local Lemma

Satz 7.2 (Lovász Local Lemma (symmetrische Form)). *Seien $A_1, \dots, A_n$ Ereignisse mit $\mathbb{P}(A_i) \leq p$ für alle i . Jedes A_i hängt von höchstens d anderen ab. Falls $ep(d+1) \leq 1$, dann gilt:*

$$\mathbb{P}\left(\bigcap_{i=1}^n \overline{A_i}\right) > 0.$$

Das LLL ist eine der tiefsten Anwendungen der probabilistischen Methode und hat weitreichende algorithmische Konsequenzen (Konstruktiver Beweis via Moser-Tardos [31]).

8 Gesetz großer Zahlen und Zentraler Grenzwertsatz

8.1 Gesetz der großen Zahlen

Satz 8.1 (Schwaches Gesetz der großen Zahlen (GGZ)). *Seien $X_1, X_2, \dots$ i.i.d. ZV mit $\mathbb{E}[X_i] = \mu < \infty$. Dann gilt für alle $\varepsilon > 0$:*

$$\mathbb{P}\left(\left|\frac{X_1 + \dots + X_n}{n} - \mu\right| > \varepsilon\right) \rightarrow 0 \quad \text{für } n \rightarrow \infty.$$

Das GGZ rechtfertigt die Interpretation des Erwartungswerts als *langfristiger Durchschnitt*: Wenn man das Experiment unendlich oft wiederholt und die Ergebnisse summiert, summieren sich die Wahrscheinlichkeiten aller Experimente zu $n \cdot 1 = n$, und der Durchschnitt konvergiert zu μ .

8.2 Zentraler Grenzwertsatz

Satz 8.2 (Zentraler Grenzwertsatz (Lindeberg-Lévy, ZGS)). *Seien $X_1, X_2, \dots$ i.i.d. ZV mit $\mathbb{E}[X_i] = \mu$ und $\text{Var}(X_i) = \sigma^2 \in (0, \infty)$. Dann gilt für alle $x \in \mathbb{R}$:*

$$\lim_{n \rightarrow \infty} \mathbb{P}\left(\frac{X_1 + \dots + X_n - n\mu}{\sigma\sqrt{n}} \leq x\right) = \Phi(x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-t^2/2} dt.$$

Der ZGS erklärt die Allgegenwart der Normalverteilung in der Natur und bildet die Grundlage der statistischen Inferenz. Dass der ZGS aussagt, dass die Normalverteilung die Verteilung für Beschreibungen in der Natur ist, ist nicht überraschend. Lindeberg-Lévy hat dies richtig beschrieben und das muss auch so sein, dass wir erst über die Betrachtung der Normalverteilung und ihrer Notwendigkeit in der Natur klar sehen, dass es eben doch bewusste Absichten in den scheinbar zufälligen Ereignissen der Natur gibt.

9 Schluss

In dieser Arbeit wurde die Lehre vom Zufall in der Mathematik entwickelt. Ausgangspunkt war das einfache Beispiel des Würfels eines Würfels. An diesem Beispiel wurden die grundlegenden Begriffe eingeführt: der Versuch, die Ereignisse, die Menge aller Ereignisse Ω , und die Wahrscheinlichkeit für den Zufall eines Ereignisses. Es wurde gezeigt, dass ein Versuch mathematisch vollständig beschrieben ist, wenn die Summe aller Wahrscheinlichkeiten der Zufälle aller Ereignisse insgesamt 1 ergibt.

Für die Analyse von Versuchen wurde das Konzept der Zufallsvariable eingeführt. Eine Zufallsvariable beschreibt den Zufall für das Ereignis variabel für den konkreten Ausgang. Mit Hilfe der Zufallsvariable kann der Erwartungswert berechnet werden. Der Erwartungswert beschreibt formal am genauesten, welcher Ausgang bei einem Versuch zu erwarten ist. Es wurde aber auch gewarnt, dass der Erwartungswert in der Praxis nicht immer sinnvoll interpretierbar ist. Beim Würfeln eines Würfels ergibt sich ein Erwartungswert von 3,5, eine Augenzahl, die es nicht gibt. Der Erwartungswert beschreibt das, was im Mittel über viele Wiederholungen des Versuchs zu erwarten ist.

Am Beispiel des 3-SAT-Algorithmus mit Zufall wurde gezeigt, wie Zufall in der Informatik eingesetzt wird, um effiziente Algorithmen zu entwickeln. Der Algorithmus erreicht eine Approximationsgüte von $\frac{7}{8}$: Im Erwartungswert werden mindestens 87,5 % aller erfüllbaren

Klauseln erfüllt. Die mathematische Analyse zeigt, dass $\mathbb{E}[Y] = \frac{7}{8}m \geq \frac{7}{8}O$, wobei O die optimale Anzahl erfüllbarer Klauseln ist. Dies ist ein Beispiel dafür, dass die mathematische Beschreibung des Zufalls in der Praxis anwendbar ist und zu verlässlichen Ergebnissen führt.

Die Wahrscheinlichkeitsverteilungen sind zentrale Werkzeuge für die Analyse von Versuchen mit Zufall. Es wurden mehrere Verteilungen vorgestellt: die Bernoulli-Verteilung für Versuche mit zwei möglichen Ereignissen, die Binomialverteilung für die Anzahl der Erfolge bei n Versuchen, die geometrische Verteilung für die Anzahl der Versuche bis zum ersten Erfolg, sowie die Gaußsche Verteilung für kontinuierliche Ereignisse. Jede dieser Verteilungen hat ihre spezifischen Anwendungsbereiche. Es wurde mehrfach betont, dass die Wahl der richtigen Verteilung entscheidend ist: Kleinste Details in der Beschreibung des Versuchs können darüber entscheiden, welche Verteilung anwendbar ist. Wird eine andere Verteilung gewählt, führt dies zu anderen Ergebnissen in der Analyse.

Die Lehre vom Zufall in der Mathematik muss mit Genauigkeit und Vorsicht entwickelt und angewendet werden. Wann immer die mathematische Beschreibung so weit von der Praxis entfernt ist, dass sie nicht mehr anwendbar ist, wird das eigentliche Ziel der Mathematik in diesem Thema verletzt. Die Mathematik soll helfen, den Zufall zu verstehen und in der Praxis verlässliche Entscheidungen zu treffen.

Das in dieser Arbeit entwickelte Bild zeigt: Die Lehre vom Zufall ist kein Randgebiet der Mathematik, sondern ein lebendiges Kerngebiet, das in alle Bereiche der modernen Wissenschaft und Technik hineinwirkt. Im Folgenden werden aktuelle Forschungsrichtungen und offene Fragen ausführlich diskutiert.

9.1 Komplexitätstheorie und derandomisierte Algorithmen

Eine der tiefsten offenen Fragen der Theoretischen Informatik lautet:

Offene Frage: P vs. BPP.

Gilt $P = BPP$? Ist jede Sprache, die ein probabilistischer Polynomialzeit-Algorithmus mit Fehlerwahrscheinlichkeit $\leq 1/3$ entscheidet, auch deterministisch in Polynomialzeit entscheidbar?

Impagliazzo und Wigderson [21] zeigten, dass falls exponentielle untere Schranken für bestimmte Schaltkreisfamilien gelten (konkret: falls $EXP \not\subseteq P/poly$), dann ist $P = BPP$. Dies weist den Weg zu einer vollständigen Derandomisierung: *Pseudozufallsgeneratoren* von ausreichender Güte würden den Zufall in Polynomialzeitalgorithmen überflüssig machen. Aktuelle Forschung (z. B. Ta-Shma [43], Braverman et al.) arbeitet an optimalen expliziten Konstruktionen von Pseudozufallsgeneratoren mit minimalem Seed-Length.

9.2 Quantencomputing und Quanten-Wahrscheinlichkeitstheorie

Quantenalgorithmen erweitern das Modell des randomisierten Algorithmus fundamental: Statt klassischer Wahrscheinlichkeitsamplituden arbeiten Quantenalgorithmen mit *komplexen Amplituden* $\alpha_i \in \mathbb{C}$, wobei die Normierungsbedingung lautet:

$$\sum_i |\alpha_i|^2 = 1.$$

Dies ist die Quantenversion des Vollständigkeitsprinzips. Interference zwischen Pfaden ermöglicht *exponentielle Beschleunigung* für bestimmte Probleme:

- **Shors Algorithmus** [40]: Primfaktorzerlegung in $O((\log n)^3)$ Quantengattern – gegenüber sub-exponentiell im Klassischen.
- **Grovers Suchalgorithmus** [18]: Datenbanksuche in $O(\sqrt{N})$ statt $O(N)$ klassisch. Dieser quadratische Speedup ist optimal [5].
- **Quantum Approximate Optimization Algorithm (QAOA)**: Hybridalgorithmus für kombinatorische Optimierung, der auf randomisierten Variationsprinzipien beruht [13].

Offene Fragen betreffen die genaue Abgrenzung von BQP (Bounded-Error Quantum Polynomial Time) gegenüber BPP und NP. Es ist unbekannt, ob $NP \subseteq BQP$.

9.3 Maschinelles Lernen und Stochastische Optimierung

Randomisierung ist das Herzstück moderner lerntheoretischer Verfahren:

9.3.1 Stochastischer Gradientenabstieg (SGD)

Der *Stochastic Gradient Descent* [36] approximiert den echten Gradienten $\nabla L(\theta) = \frac{1}{N} \sum_i \nabla \ell_i(\theta)$ durch einen zufälligen Mini-Batch-Gradienten:

$$\theta_{t+1} = \theta_t - \eta_t \cdot \frac{1}{|B_t|} \sum_{i \in B_t} \nabla \ell_i(\theta_t),$$

wobei $B_t \subseteq \{1, \dots, N\}$ ein zufällig gezogener Mini-Batch ist. Das Vollständigkeitsprinzip in diesem Kontext: Die Ziehung des Mini-Batches ist eine Wahrscheinlichkeitsverteilung auf $\binom{N}{b}$ Teilmengen der Größe b , die zu 1 normiert ist.

9.3.2 Dropout und Regularisierung via Zufall

Dropout [42] deaktiviert während des Trainings jedes Neuron unabhängig mit Wahrscheinlichkeit p : Ein randomisiertes Ensemble von 2^n dünnen Netzwerken wird implizit trainiert. Die Vollständigkeitsbedingung – $p + (1 - p) = 1$ – sichert, dass jedes Neuron entweder aktiv oder inaktiv ist.

9.3.3 Convolutional Neural Networks und Zufälligkeit

Zufällige Initialisierung (He-Initialisierung, Xavier-Initialisierung) und Data Augmentation (zufällige Spiegelungen, Ausschnitte, Farbveränderungen) sind essentiell für den Trainingserfolg moderner tiefer Netze.

9.4 Kryptographie und Informationstheorie

9.4.1 Perfekte Sicherheit und Einmalblock-Verschlüsselung

Shannon zeigte [39], dass ein kryptographisches System genau dann *perfekt sicher* ist, wenn

$$\mathbb{P}(M = m \mid C = c) = \mathbb{P}(M = m)$$

für alle Klartexte m und Chiffretexte c gilt – d. h., das Beobachten des Chiffrextes ändert die Wahrscheinlichkeit des Klartextes nicht. Das One-Time-Pad erreicht perfekte

Sicherheit genau dann, wenn der Schlüssel gleichverteilt und so lang wie der Klartext ist (Vollständigkeit!).

9.4.2 Pseudozufallsgeneratoren in der Kryptographie

Kryptographisch sichere Pseudozufallsgeneratoren (CSPRNG) erzeugen aus kurzen, echten Zufallsquellen (Seeds) lange, ununterscheidbare Bitfolgen. Grundlegende Konstruktionen:

- AES-CTR-DRBG (NIST-Standard SP 800-90A),
- Blum-Blum-Shub-Generator [6], beweisbar sicher unter Annahme der Schwierigkeit der Quadratwurzel modulo $n = pq$.

9.4.3 Zero-Knowledge-Beweise

Interaktive Beweissysteme [17] nutzen Zufall fundamental: Der Verifier stellt zufällige Challenges, und der Prover muss sie korrekt beantworten – mit Wahrscheinlichkeit $1/2$ pro Runde scheitert ein Betrüger. Die *Vervollständigung* (Completeness) ist: Ein ehrlicher Prover beantwortet immer korrekt ($\mathbb{P} = 1$); die *Solidität* (Soundness) garantiert, dass ein Betrüger mit $\mathbb{P} \leq 1/2$ erwischt wird.

9.5 Randomisierte Datenstrukturen

9.5.1 Skip-Listen

Pugh [33] entwickelte die Skip-Liste: Eine probabilistische Alternative zu Suchbäumen mit erwarteter $O(\log n)$ Such-, Einfüge- und Löschozeit. Jedes Element wird auf Level k gefördert mit Wahrscheinlichkeit p^k – eine geometrische Verteilung, deren Vollständigkeit $\sum_{k=0}^{\infty} p^k(1-p) = 1$ garantiert, dass jedes Element auf einem endlichen Level endet.

9.5.2 Bloom-Filter

Bloom [7] führte eine randomisierte Mengendarstellung mit Falsch-Positiv-Rate ε und ohne Falsch-Negativ ein:

$$\mathbb{P}(\text{false positive}) \approx \left(1 - e^{-kn/m}\right)^k,$$

wobei n die Elementanzahl, m die Bitgröße des Filters und k die Zahl der Hashfunktionen ist. Optimal ist $k = \frac{m}{n} \ln 2$.

9.5.3 Treaps

Ein *Treap* [38] kombiniert einen binären Suchbaum mit einem Max-Heap, wobei die Heap-Prioritäten gleichverteilt zufällig zugewiesen werden. Die erwartete Suchtiefe beträgt $O(\log n)$, und die Struktur verhält sich wie ein zufällig aufgebauter Suchbaum.

9.6 Approximationsalgorithmen und semidefinite Programmierung

9.6.1 Goemans-Williamson-Algorithmus für MAX-CUT

Goemans und Williamson [16] zeigten mittels *Semidefiniter Programmierung* (SDP) und anschließendem Runden durch einen zufälligen Hyperebenen-Schnitt, dass MAX-CUT mit Faktor $\alpha_{\text{GW}} = \frac{2}{\pi} \int_0^\pi \frac{1-\cos\theta}{2} \cdot \frac{d\theta}{\pi} \approx 0,878$ approximierbar ist.

Das Runden: Sei v ein gleichverteilter zufälliger Einheitsvektor in $\mathbb{R}^n$. Weise Knoten i der Seite $+1$ zu, falls $v \cdot x_i \geq 0$, und -1 sonst. Die Vollständigkeit: $\mathbb{P}(v \cdot x_i \geq 0) + \mathbb{P}(v \cdot x_i < 0) = 1$.

9.6.2 Håstad's 3-SAT-Härte und optimale Approximierbarkeit

Håstad [19] bewies, dass für E3-SAT kein Approximationsalgorithmus mit Faktor $> 7/8$ existiert (unter $P \neq NP$), womit der in Abschnitt 6.1 beschriebene einfache Algorithmus optimal ist.

9.7 Monte-Carlo-Simulation und numerische Integration

9.7.1 Monte-Carlo-Integration

Für die numerische Integration einer Funktion $f : [0, 1]^d \rightarrow \mathbb{R}$:

$$I = \int_{[0,1]^d} f(x) dx \approx \hat{I}_n = \frac{1}{n} \sum_{i=1}^n f(U_i),$$

wobei $U_1, \dots, U_n$ gleichverteilt zufällig in $[0, 1]^d$ gewählt werden. Das GGZ garantiert $\hat{I}_n \rightarrow I$, der ZGS liefert die Konvergenzrate:

$$\text{Var}(\hat{I}_n) = \frac{\sigma_f^2}{n}, \quad \text{Standardfehler} = \frac{\sigma_f}{\sqrt{n}}.$$

Im Unterschied zu deterministischen Quadraturregeln, die für d -dimensional unter dem *Fluch der Dimensionalität* leiden, skaliert der Monte-Carlo-Fehler unabhängig von d mit $O(n^{-1/2})$.

9.7.2 Markov-Ketten-Monte-Carlo (MCMC)

Markov-Ketten-Monte-Carlo-Methoden wie der **Metropolis-Hastings-Algorithmus** [20, 29] und **Gibbs-Sampling** erzeugen Stichproben aus komplexen Wahrscheinlichkeitsverteilungen π durch eine Markov-Kette, die π als stationäre Verteilung hat. Ihre Vollständigkeit: $\sum_y \mathbb{P}(X_{t+1} = y \mid X_t = x) = 1$ (die Übergangswahrscheinlichkeiten bilden eine vollständig beschriebene Verteilung für jeden Zustand x).

9.7.3 Simulated Annealing

Simulated Annealing [25] ist ein randomisiertes metaheuristisches Optimierungsverfahren: Schlechtere Lösungen werden mit Wahrscheinlichkeit $\mathbb{P}(\text{Akzeptanz}) = e^{-\Delta E/T}$ akzeptiert, wobei T eine fallende „Temperatur“ ist. Die Normierung $\mathbb{P}(\text{Akzeptanz}) + \mathbb{P}(\text{Ablehnung}) = 1$ stellt die vollständige Beschreibbarkeit des Übergangsereignisses sicher.

9.8 Streaming und Sublinear-Zeit-Algorithmen

9.8.1 Frequenz-Schätzung und Count-Min-Sketch

Cormode und Muthukrishnan [10] entwickelten Count-Min-Sketch zur Approximation von Element-Häufigkeiten in Datenströmen: Mit $O(\frac{1}{\varepsilon} \log \frac{1}{\delta})$ Speicherplatz wird die Häufigkeit jedes Elements bis auf εn mit Wahrscheinlichkeit $1 - \delta$ korrekt ausgegeben. Vollständigkeit: $\mathbb{P}(\text{Fehler} \leq \varepsilon n) + \mathbb{P}(\text{Fehler} > \varepsilon n) = 1$.

9.8.2 F_0 -Schätzung (distinct elements)

Flajolet und Martin [15] entwickelten den ersten probabilistischen Algorithmus zur Schätzung der Anzahl verschiedener Elemente in einem Datenstrom – ein Problem, das deterministisch $\Omega(n)$ Speicher erfordert, randomisiert aber in $O(\log n)$ Bits gelöst werden kann.

9.9 Randomisierung in der Bioinformatik und Computational Biology

9.9.1 BLAST und Heuristischer Sequenzvergleich

Der BLAST-Algorithmus [3] nutzt randomisierte Heuristiken für den lokalen Sequenzvergleich: Durch zufälliges Sampling von Keimwörtern und statistische Modellierung der Erwartungswerte von Treffern (E-Value) unter der Annahme zufälliger Sequenzen wird die Sensitivität/Spezifität-Abwägung quantifiziert. Das E-Value ist gerade der Erwartungswert der Anzahl Treffer in einer Zufallsdatenbank.

9.9.2 Phylogenetische Rekonstruktion via Bootstrap

Felsenstein [14] führte das phylogenetische *Bootstrap-Verfahren* ein: Durch B zufällige Stichproben mit Zurücklegen aus den Alignment-Spalten werden B Bootstrap-Bäume erstellt; der Bootstrap-Unterstützungswert eines Astes ist sein Anteil in diesen Bäumen. Grundlage ist das Vollständigkeitsprinzip: Jede Bootstrap-Stichprobe ist vollständig beschrieben (alle n Spalten werden gezogen, die Summe der Stichproben-Wahrscheinlichkeiten ist 1).

9.10 Lerntheorie und PAC-Lernen

9.10.1 Probably Approximately Correct (PAC) Lernen

Valiants PAC-Lernmodell [44] quantifiziert, wie viele Stichproben ein Lernalgorithmus braucht, um mit Wahrscheinlichkeit $\geq 1 - \delta$ einen Klassifizierer mit Fehler $\leq \varepsilon$ zu lernen. Die Stichprobenkomplexität für eine Hypothesenklasse $\mathcal{H}$ mit VC-Dimension d beträgt:

$$m = O\left(\frac{d + \log(1/\delta)}{\varepsilon}\right).$$

Vollständigkeit: Der Lernfehler ist eine ZV; sein Erwartungswert $\sum_{\varepsilon'} \varepsilon' \mathbb{P}(\text{Fehler} = \varepsilon')$ existiert und ist klein.

9.11 Offene Probleme und Forschungsfrieder

1. **P vs. NP:** Die wichtigste offene Frage der Informatik berührt die Lehre vom Zufall: Falls $P \neq NP$, existieren Probleme, für die randomisierte Algorithmen exponentiell besser als deterministische sein könnten [9].
2. **P vs. BPP:** Wie oben diskutiert: Ist Randomisierung prinzipiell eliminierbar [21]?
3. **Derandomisierung von RL:** Gilt $RL = L$? Reingold [35] zeigte dies für ungerichtetes Grapherreichbarkeitsproblem; der gerichtete Fall ist offen.
4. **Optimale Pseudozufallsgeneratoren:** Existieren explizite PRGs mit Seed-Länge $O(\log n)$, die alle Polynomialzeit-Tests täuschen? Dies würde $P = BPP$ implizieren.
5. **3-SAT und Random 3-SAT:** Zufällige 3-SAT-Instanzen nahe dem Satisfiability-Schwellenwert $\approx 4,267$ sind besonders schwer [28]. Das Verhalten randomisierter Algorithmen in dieser Phase ist noch nicht vollständig verstanden.
6. **MCMC-Mischzeiten:** Für viele natürliche Markov-Ketten sind scharfe Schranken an die Mischzeit offen – insbesondere für Glauber-Dynamik auf Ising-Modellen bei kritischer Temperatur.
7. **Quantum Advantage:** Für welche Problemklassen können Quantencomputer exponentiell schneller sein als klassische (randomisierte) Computer?
8. **Robustheit und Adversarial Machine Learning:** Wie können randomisierte Abwehrstrategien (z. B. Randomized Smoothing [8]) robuste neuronale Netze garantieren?
9. **Differentially Private Algorithmen:** Randomisierung ist zentral für differential privacy [12]: Die Ausgabe soll für ähnliche Datenbanken ähnliche Wahrscheinlichkeitsverteilungen haben – ein direkter Bezug zum Vollständigkeitsprinzip.
10. **Oblivious Algorithmen und Pandemie-Modellierung:** Stochastische Epidemiemodelle (SIR, SEIR) [4] nutzen die Lehre vom Zufall, um Ausbruchsdynamiken zu beschreiben; Verbesserungen in der Modellierungsgenauigkeit sind von hoher gesellschaftlicher Relevanz.

9.12 Abschlussbemerkung: Das Vollständigkeitsprinzip als epistemologisches Fundament

Das in der Einleitung formulierte Prinzip – die Summe aller Wahrscheinlichkeiten ist 1 – erscheint zunächst wie eine technische Normierungskonvention. Tatsächlich hat es tiefe epistemologische Bedeutung: Es besagt, dass unser Modell der Wirklichkeit *vollständig* ist – dass wir alle möglichen Ausgänge eines Experiments in Betracht gezogen haben. Kein Ergebnis wird ignoriert, keines wird doppelt gewichtet.

Diese Vollständigkeit ist die mathematische Entsprechung des Prinzips der *geschlossenen Welt*: Was nicht modelliert ist, kann in der Analyse nicht auftreten. In der Praxis bedeutet dies eine ständige Warnung: Wahrscheinlichkeitsmodelle sind nur so gut wie die Vollständigkeit ihrer Ergebnisräume. Wenn das Modell wichtige Szenarien vergisst, summieren sich die Wahrscheinlichkeiten zu weniger als 1 – ein mathematisch quantifizierbares Signal für Unvollständigkeit.

Von Kolmogorows Axiomen über randomisierte Algorithmen bis hin zu Quantencomputern bleibt dieses Prinzip der unverrückbare Anker der Lehre vom Zufall.

Literatur

- [1] M. Agrawal, N. Kayal, N. Saxena: *PRIMES is in P*. Annals of Mathematics, 160(2):781–793, 2004.
- [2] N. Alon, J. Spencer: *The Probabilistic Method*. 4. Auflage. Wiley, Hoboken, 2016.
- [3] S. F. Altschul, W. Gish, W. Miller, E. W. Myers, D. J. Lipman: *Basic local alignment search tool*. Journal of Molecular Biology, 215(3):403–410, 1990.
- [4] R. M. Anderson, R. M. May: *Infectious Diseases of Humans: Dynamics and Control*. Oxford University Press, Oxford, 1991.
- [5] C. H. Bennett, E. Bernstein, G. Brassard, U. Vazirani: *Strengths and Weaknesses of Quantum Computing*. SIAM Journal on Computing, 26(5):1510–1523, 1997.
- [6] L. Blum, M. Blum, M. Shub: *A Simple Unpredictable Pseudo-Random Number Generator*. SIAM Journal on Computing, 15(2):364–383, 1986.
- [7] B. H. Bloom: *Space/time trade-offs in hash coding with allowable errors*. Communications of the ACM, 13(7):422–426, 1970.
- [8] J. Cohen, E. Rosenfeld, J. Z. Kolter: *Certified Adversarial Robustness via Randomized Smoothing*. ICML 2019. Proceedings of Machine Learning Research, 97:1310–1320, 2019.
- [9] S. A. Cook: *The Complexity of Theorem-Proving Procedures*. Proc. 3rd Annual ACM Symposium on Theory of Computing (STOC), S. 151–158, 1971.
- [10] G. Cormode, S. Muthukrishnan: *An Improved Data Stream Summary: The Count-Min Sketch and Its Applications*. Journal of Algorithms, 55(1):58–75, 2005.
- [11] F. N. David: *Games, Gods and Gambling: The Origins and History of Probability and Statistical Ideas*. Griffin, London, 1962.
- [12] C. Dwork, A. Roth: *The Algorithmic Foundations of Differential Privacy*. Foundations and Trends in Theoretical Computer Science, 9(3–4):211–407, 2014.
- [13] E. Farhi, J. Goldstone, S. Gutmann: *A Quantum Approximate Optimization Algorithm*. arXiv:1411.4028, 2014.
- [14] J. Felsenstein: *Confidence Limits on Phylogenies: An Approach Using the Bootstrap*. Evolution, 39(4):783–791, 1985.
- [15] P. Flajolet, G. N. Martin: *Probabilistic Counting Algorithms for Data Base Applications*. Journal of Computer and System Sciences, 31(2):182–209, 1985.
- [16] M. X. Goemans, D. P. Williamson: *Improved Approximation Algorithms for Maximum Cut and Satisfiability Problems Using Semidefinite Programming*. Journal of the ACM, 42(6):1115–1145, 1995.

- [17] S. Goldwasser, S. Micali, C. Rackoff: *The Knowledge Complexity of Interactive Proof Systems*. SIAM Journal on Computing, 18(1):186–208, 1989.
- [18] L.K. Grover: *A fast quantum mechanical algorithm for database search*. Proc. 28th ACM STOC, S. 212–219, 1996.
- [19] J. Håstad: *Some Optimal Inapproximability Results*. Journal of the ACM, 48(4):798–859, 2001.
- [20] W.K. Hastings: *Monte Carlo Sampling Methods Using Markov Chains and Their Applications*. Biometrika, 57(1):97–109, 1970.
- [21] R. Impagliazzo, A. Wigderson: *$P = BPP$ if E Requires Exponential Circuits: Derandomizing the XOR Lemma*. Proc. 29th ACM STOC, S. 220–229, 1997.
- [22] D.S. Johnson: *Approximation Algorithms for Combinatorial Problems*. Journal of Computer and System Sciences, 9(3):256–278, 1974.
- [23] D.R. Karger: *Global Min-cuts in RNC, and Other Ramifications of a Simple Min-Cut Algorithm*. Proc. 4th Annual ACM-SIAM Symposium on Discrete Algorithms (SODA), S. 21–30, 1993.
- [24] D.R. Karger, C. Stein: *A New Approach to the Minimum Cut Problem*. Journal of the ACM, 43(4):601–640, 1996.
- [25] S. Kirkpatrick, C.D. Gelatt, M.P. Vecchi: *Optimization by Simulated Annealing*. Science, 220(4598):671–680, 1983.
- [26] A.N. Kolmogorov: *Grundbegriffe der Wahrscheinlichkeitsrechnung*. Springer, Berlin, 1933. (Nachdruck: Springer, 1977.)
- [27] P.-S. Laplace: *Théorie analytique des probabilités*. Courcier, Paris, 1812. (3. Auflage mit Supplements, 1820.)
- [28] S. Mertens, M. Mézard, R. Zecchina: *Threshold Values of Random K -SAT from the Cavity Method*. Random Structures & Algorithms, 28(3):340–373, 2006.
- [29] N. Metropolis, A.W. Rosenbluth, M.N. Rosenbluth, A.H. Teller, E. Teller: *Equation of State Calculations by Fast Computing Machines*. Journal of Chemical Physics, 21(6):1087–1092, 1953.
- [30] G.L. Miller: *Riemann’s Hypothesis and Tests for Primality*. Journal of Computer and System Sciences, 13(3):300–317, 1976.
- [31] R.A. Moser, G. Tardos: *A Constructive Proof of the General Lovász Local Lemma*. Journal of the ACM, 57(2):Article 11, 2010.
- [32] R. Motwani, P. Raghavan: *Randomized Algorithms*. Cambridge University Press, Cambridge, 1995.
- [33] W. Pugh: *Skip Lists: A Probabilistic Alternative to Balanced Trees*. Communications of the ACM, 33(6):668–676, 1990.

- [34] M. O. Rabin: *Probabilistic Algorithm for Testing Primality*. Journal of Number Theory, 12(1):128–138, 1980.
- [35] O. Reingold: *Undirected Connectivity in Log-Space*. Journal of the ACM, 55(4):Article 17, 2008.
- [36] H. Robbins, S. Monro: *A Stochastic Approximation Method*. Annals of Mathematical Statistics, 22(3):400–407, 1951.
- [37] J. T. Schwartz: *Fast Probabilistic Algorithms for Verification of Polynomial Identities*. Journal of the ACM, 27(4):701–717, 1980.
- [38] R. Seidel, C. R. Aragon: *Randomized Search Trees*. Algorithmica, 16(4/5):464–497, 1996.
- [39] C. E. Shannon: *Communication Theory of Secrecy Systems*. Bell System Technical Journal, 28(4):656–715, 1949.
- [40] P. W. Shor: *Algorithms for Quantum Computation: Discrete Logarithms and Factoring*. Proc. 35th Annual Symposium on Foundations of Computer Science (FOCS), S. 124–134, 1994.
- [41] M. Sipser: *Introduction to the Theory of Computation*. 3. Auflage. Cengage Learning, Boston, 2012.
- [42] N. Srivastava, G. Hinton, A. Krizhevsky, I. Sutskever, R. Salakhutdinov: *Dropout: A Simple Way to Prevent Neural Networks from Overfitting*. Journal of Machine Learning Research, 15:1929–1958, 2014.
- [43] A. Ta-Shma: *Explicit, Almost Optimal, Epsilon-Balanced Codes*. Proc. 49th ACM STOC, S. 238–251, 2017.
- [44] L. G. Valiant: *A Theory of the Learnable*. Communications of the ACM, 27(11):1134–1142, 1984.
- [45] D. P. Williamson, D. B. Shmoys: *The Design of Approximation Algorithms*. Cambridge University Press, Cambridge, 2011.
- [46] R. Zippel: *Probabilistic Algorithms for Sparse Polynomials*. Proc. International Symposium on Symbolic and Algebraic Computation (EUROSAM), Lecture Notes in Computer Science 72, S. 216–226. Springer, 1979.